



Modelarea piețelor financiare

Capitolul 20 (capitol special): Semnătura traiectoriilor și volatilitatea realizată —
un studiu de cercetare



Daniel Traian PELE

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

Acronime folosite în acest material (1/2)

- AAPL: Apple Inc. (Nasdaq ticker) (Apple Inc., simbolul bursier Nasdaq)
- ACM: Association for Computing Machinery (Asociația pentru Mașini de Calcul)
- AI: Artificial Intelligence (inteligență artificială)
- AR: AutoRegressive (model); in event studies: Abnormal Return (model autoregresiv; în studiile de eveniment: randament anormal)
- ARIMA: AutoRegressive Integrated Moving Average (model) (model autoregresiv integrat cu medie mobilă)
- AUD: Australian Dollar (ISO 4217 code) (dolarul australian (cod ISO 4217))
- BH: Benjamini–Hochberg (procedure) (procedura Benjamini–Hochberg)
- BIC: Bayesian Information Criterion (criteriul informațional bayesian)
- BPQ: Bollerslev–Patton–Quaedvlieg (insanity filter of the HARQ paper) (Bollerslev–Patton–Quaedvlieg (filtrul din articolul HARQ))
- CAD: Canadian Dollar (ISO 4217 code) (dolarul canadian (cod ISO 4217))
- CL: Crude oil (WTI light sweet) futures, NYMEX ticker (contractul futures pe petrol (WTI), simbolul NYMEX)
- COVID-19: COronaVirus Disease 2019 (boala provocată de coronavirus, 2019)
- DM: Diebold–Mariano (test) (testul Diebold–Mariano de comparare a prognozelor)
- ES: E-mini S&P 500 futures (CME ticker) (contractul futures E-mini S&P 500 (simbolul CME))
- EURUSD: Euro / US dollar exchange rate (FX pair code) (cursul euro / dolar american (codul perechii FX))
- FDR: False Discovery Rate (rata descoperirilor false)
- FWER: Family-Wise Error Rate (probabilitatea de cel puțin o eroare de tip I în familia de teste)
- FX: Foreign eXchange (piața valutară)
- GARCH: Generalised AutoRegressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă generalizată)
- GC: Gold futures, COMEX ticker (contractul futures pe aur, simbolul COMEX)
- GW: Giacomini–White (test) (testul Giacomini–White)
- HAC: Heteroskedasticity and Autocorrelation Consistent (standard errors) (erori standard robuste la heteroscedasticitate și autocorelație)
- HAR: Heterogeneous AutoRegressive (model) (model autoregresiv heterogen)
- HARQ: HAR model with Realised Quarticity (model HAR cu cvarticitatea realizată)
- JPM: JPMorgan Chase & Co. (NYSE ticker) (JPMorgan Chase & Co. (simbolul bursier NYSE))
- KDD: Knowledge Discovery and Data Mining (ACM SIGKDD conference) (descoperirea cunoașterii și data mining (conferința ACM SIGKDD))

Acronime folosite în acest material (2/2)

- LARS: Least-Angle RegreSsion (algorithm) (algoritmul regresiei unghiului minim)
- LASSO: Least Absolute Shrinkage and Selection Operator (regresie penalizată L1 cu selecția variabilelor)
- MCS: Model Confidence Set (mulțimea de încredere a modelelor)
- MSE: Mean Squared Error (eroarea pătratică medie)
- NG: Natural Gas futures, NYMEX ticker (contractul futures pe gaze naturale, simbolul NYMEX)
- NVDA: NVIDIA Corporation (Nasdaq ticker) (NVIDIA Corporation, simbolul bursier Nasdaq)
- OLS: Ordinary Least Squares (metoda celor mai mici pătrate)
- PDE: Partial Differential Equation (ecuație cu derivate parțiale)
- PRDS: Positive Regression Dependence on a Subset (of p-values) (dependența pozitivă de regresie pe o submulțime (a valorilor p))
- QLIKE: Quasi-LIKelihood (loss function) (funcția de pierdere de tip cvasi-verosimilitate)
- RQ: Realised Quarticity (cvarticitatea realizată)
- RV: Realised Variance (varianța realizată)
- SHAR: Semivariance HAR model (model HAR cu semivarianțe)
- TSLA: Tesla, Inc. (Nasdaq ticker) (Tesla, Inc., simbolul bursier Nasdaq)
- USDJPY: US dollar / Japanese yen exchange rate (FX pair code) (cursul dolar american / yen japonez (codul perechii FX))
- VOLARE: VOLatility Archive for Realized Estimates (database) (arhiva de estimatori realizați ai volatilității (bază de date))
- XOM: Exxon Mobil Corporation (NYSE ticker) (Exxon Mobil Corporation, simbolul bursier NYSE)

Parcursul capitolului și rezultatele învățării

Parcursul capitolului

- Un studiu de cercetare: metoda lui Gu et al. (2024), publicată pentru tarifele de transport de la Amazon, transferată la varianța realizată zilnică a 50 de active VOLARE Cipollini et al. (2026)
- Partea I: măsuri realizate, datele, reperele HAR, semnăturile traiectoriilor
- Partea a II-a: articolul lui Gu et al., un design fixat înaintea rezultatelor, rezultate, robustețe, o trecere prin bucla descoperirii asistate de AI
- Detaliile de implementare sunt în [▶ Anexa](#) de la final

După acest capitol puteți


- calcula semnătura unei traiectorii liniare pe porțiuni și interpreta aria ei Lévy
- construi trăsături (variabile) de semnătură și ponderi de nucleu pentru o prognoză a volatilității
- compara prognoze pe multe active cu teste DM, mulțimi de încredere pentru modele și corecții Holm/BH
- preînregistra transferul unei metode și raporta un rezultat nul împreună cu mecanismul lui

De ce prognozăm varianța realizată?

- ▣ Volatilitatea intră în calculul aproape tuturor indicatorilor de risc din acest curs
 - ▶ Măsuri de tail risk (Capitolul 7), prețuri de opțiuni (Capitolul 12), ponderi de portofoliu (Capitolul 4)
- ▣ Datele intraday fac varianța zilnică aproape observabilă: varianța realizată (Realised Variance, RV, Capitolul 9)
 - ▶ Astfel, prognoza volatilității devine o problemă de regresie cu o țintă zgomotoasă, dar calculată fără a specifica un model parametric
- ▣ Reperul este greu de bătut: modelul HAR [Corsi \(2009\)](#) (Capitolul 9)
 - ▶ Trei medii ale RV trecute; liniar; estimat prin OLS într-o secundă
- ▣ Orice metodă nouă trebuie să bată HAR în afara eșantionului, pe multe active, cu un test corect

Întrebarea de cercetare

- Gu et al. descriu o fereastră recentă a unei serii ca o **traietorie** și o rezumă prin **semnătura traietoriei** (engl. *path signature*)
 - ▶ Trăsăturile de semnătură intră într-o regresie liniară cu puțini coeficienți nenuli (LASSO în doi pași)
 - ▶ Perioadele trecute a căror traietorie seamănă cu cea de azi primesc o pondere mai mare (un nucleu de semnătură)
- Ei raportează o creștere de peste cinci ori a acurateței față de o prognoză din industrie pentru tarifele de transport
 - ▶ Întrebare: îmbunătățește aceeași rețetă modelele de tip HAR pentru varianța realizată?
- Două ingrediente separate de testat: trăsăturile de semnătură și ponderile date de nucleu



Wall Street și Bursa din New York, 25 martie 2020

Foto: Billie Grace Ward (2020); CC BY 2.0; Wikimedia

[Commons](#)

Varianța realizată și variația pătratică

- ▣ Prețul logaritmic p_t cu $dp_t = \mu_t dt + \sigma_t dW_t + dJ_t$; ziua t împărțită în M randamente intraday $r_{t,i}$
 - ▶ $RV_t = \sum_{i=1}^M r_{t,i}^2 \xrightarrow{M \rightarrow \infty} \int_{t-1}^t \sigma_s^2 ds + \sum_{t-1 < s \leq t} (\Delta J_s)^2$ Barndorff-Nielsen & Shephard (2002)
- ▣ Fără salturi și fără zgomot, pe o grilă echidistantă, limita este varianța integrată IV_t ; eroarea are o distribuție Normală mixtă
 - ▶ $\sqrt{M}(RV_t - IV_t) \Rightarrow MN(0, 2IQ_t)$, $IQ_t = \int_{t-1}^t \sigma_s^4 ds$ (cvarticitatea integrată)
- ▣ Zgomotul de microstructură introduce o deplasare în estimare la frecvențe foarte mari de eșantionare; randamentele la cinci minute sunt compromisul standard (Capitolul 9)
- ▣ Capitolul 9 deduce aceste rezultate; aici sunt folosite ca atare

Măsurile realizate din VOLARE

- ▣ Semivarianțele [Barndorff-Nielsen, Kinnebrock & Shephard \(2010\)](#): $RV_t^+ = \sum_i r_{t,i}^2 1\{r_{t,i} > 0\}$,
 $RV_t^- = \sum_i r_{t,i}^2 1\{r_{t,i} < 0\}$
 - ▶ Se adună: $RV_t = RV_t^+ + RV_t^-$ (în VOLARE, până la precizia mașinii)
- ▣ Cvarticitatea realizată: $RQ_t = \frac{M}{3} \sum_i r_{t,i}^4 \rightarrow IQ_t$, scala erorii de măsurare a RV
 - ▶ Limita cere un preț continuu, fără zgomot, și o grilă echidistantă; un salt ΔJ adaugă aproximativ $M(\Delta J)^4/3$, deci RQ brută este sensibilă la salturi
- ▣ Variația bipower (robustă la salturi), nucleul realizat (robust la zgomot) [Barndorff-Nielsen et al. \(2008\)](#), estimatori bazați pe amplitudinea zilnică a prețului (range)
- ▣ Ținta acestui capitol: RV la cinci minute
 - ▶ Pe 400 de active, puțini estimatori bat RV la cinci minute ca aproximare a varianței zilnice [Liu, Patton & Sheppard \(2015\)](#)
 - ▶ Semivarianțele și cvarticitatea sunt calculate pe aceeași grilă temporală, deci SHAR și HARQ folosesc date de intrare coerente

Ținte și funcții de pierdere

- Orizontul h : $RV_{t+1:t+h} = \frac{1}{h} \sum_{j=1}^h RV_{t+j}$, $h \in \{1, 5, 22\}$; modelele logaritmice prognozează $\ln RV_{t+1:t+h}$
 - ▶ Înapoi la nivel cu $F_t = \exp(\hat{y}_t + \hat{s}^2/2)$, $\hat{s}^2$ = varianța reziduurilor: exactă dacă eroarea logaritmică este condiționat Normală cu varianță constantă, altfel o aproximare
 - ▶ Pentru $h > 1$ țintele se suprapun: apare dependență serială (până la lagul $h - 1$ prin construcție, posibil mai departe), deci fiecare test folosește o varianță HAC
- O funcție de pierdere este **robustă** dacă, pentru o aproximare condiționat nedeplasată ($\mathbb{E}_{t-1}[RV_t] = \sigma_t^2$), ordinea pierderilor *așteptate* cu RV_t coincide cu cea cu varianța adevărată [Patton \(2011\)](#)
 - ▶ $MSE_t = (RV_t - F_t)^2$, $QLIKE_t = RV_t/F_t - \ln(RV_t/F_t) - 1 \geq 0$ (zero doar dacă $F_t = RV_t$)
- QLIKE depinde de raportul RV_t/F_t : aceeași eroare proporțională produce aceeași pierdere într-o zi calmă ca într-o zi agitată
- MSE este dominată de câteva zile de criză; QLIKE este pierderea principală, MSE cea secundară

VOLARE: o arhivă deschisă de măsuri realizate

- Construită la universitățile din Messina și Florența din date tick cu tick [Cipollini et al. \(2026\)](#)
 - ▶ Curățare specifică fiecărui activ, calendare de tranzacționare și precizia marcajelor de timp; aceiași estimatori pentru toate clasele de active
- Gratuită pentru cercetare la volare.unime.it; nu este redistribuită împreună cu acest curs
 - ▶ Descărcați fișierele de varianță realizată și indicați notebook-urilor folderul vostru local
- Citarea cerută de autori: Cipollini, Cruciani, Gallo, Insana, Otranto și Spagnolo (2026), arXiv:2602.19732



Universitatea din Messina, gazda VOLARE


Foto: [Superchilum \(2013\)](#); CC BY-SA 3.0; [Wikimedia Commons](#)

Panelul: 50 de active în trei clase

Clasa	Active	Eșantion	Observații	Volatilitate mediană
Acțiuni americane cu capitalizare mare	40	2 ian. 2015 – 30 ian. 2026	111 440	17,1%
Futures (C, CL, ES, GC, NG)	5	28 sept. 2009 – 30 ian. 2026	21 059	19,7%
FX (AUD, EUR, GBP, CAD, JPY față de USD)	5	25 sept. 2009 – 30 ian. 2026	21 203	7,3%

- Acțiuni: 40 de componente ale Dow Jones 30 și S&P 100 (de la AAPL la XOM); futures: porumb, petrol, E-mini S&P 500, aur, gaze naturale
- Volatilitatea mediană: $\sqrt{252 \text{ mediana}(RV_t)}$ pentru fiecare activ, apoi mediana clasei; datele conțin doar zilele de tranzacționare
- Variabile folosite: RV la cinci minute, semivarianțele pozitivă și negativă (RV^+ , RV^-), cvarticitatea realizată (RQ) și prețurile zilnice de deschidere și de închidere

Volatilitatea realizată în clasele de active



- Volatilitatea anualizată $\sqrt{252 RV_t}$, medie pe cinci zile, scală logaritmică, două active pe clasă (acțiuni: JPM = JPMorgan Chase, NVDA = Nvidia; futures: ES = E-mini S&P 500, CL = petrol; FX: EURUSD, USDJPY = dolarul american în yen); niveluri tipice: FX în jur de 7,3%, acțiunile în jur de 17,1% pe an
- Toate clasele au în comun martie 2020; petrolul (CL) atinge maximul în aprilie 2020, când contractul cu scadența cea mai apropiată s-a tranzacționat la un preț negativ: un prognosticator trebuie să se adapteze în câteva zile
- Pe scală logaritmică volatilitatea este staționară și persistentă (memoria lungă pe care o aproximează HAR); vârfurile se sting în câteva săptămâni, deci forma traiectoriei recente conține informație

HAR: trei medii ale trecutului

- Modelul HAR (Heterogeneous AutoRegressive, autoregresiv heterogen) [Corsi \(2009\)](#)

- $$\text{RV}_{t+1:t+h} = \beta_0 + \beta_d \text{RV}_t + \beta_w \text{RV}_t^{(w)} + \beta_m \text{RV}_t^{(m)} + \varepsilon_{t+h}$$
- $$\text{RV}_t^{(w)} = \frac{1}{5} \sum_{j=0}^4 \text{RV}_{t-j}, \quad \text{RV}_t^{(m)} = \frac{1}{22} \sum_{j=0}^{21} \text{RV}_{t-j}$$

- HAR este un AR(22) restricționat: cei 22 de coeficienți ai lagurilor iau doar trei valori distincte

- $$\phi_1 = \beta_d + \beta_w/5 + \beta_m/22, \quad \phi_{2..5} = \beta_w/5 + \beta_m/22, \quad \phi_{6..22} = \beta_m/22$$

- Traderi la frecvență zilnică, săptămânală și lunară: o cascadă care imită memoria lungă cu trei parametri

- log-HAR: $\ln \text{RV}_{t+1:t+h}$ pe $\ln \text{RV}_t$, $\ln \text{RV}_t^{(w)}$, $\ln \text{RV}_t^{(m)}$; fără prognoze negative, mai puțin dominat de vârfuri
 - Logaritmul mediei nu este media logaritmilor, deci acest log-HAR nu este exact un AR(22) restricționat în $\ln \text{RV}$ (Seminarul 20, A5)

Două rafinări: HARQ și SHAR

- RV este un regresor generat: $RV_t = IV_t + \eta_t$, $\text{Var}(\eta_t) \approx 2IQ_t/M$; erorile în variabile atenuază β_d în zilele zgomotoase
 - ▶ HARQ [Bollerslev, Patton & Quaedvlieg \(2016\)](#):
 $RV_{t+1:t+h} = \beta_0 + (\beta_d + \beta_Q(RQ_t^{1/2} - \overline{RQ^{1/2}}))RV_t + \beta_w RV_t^{(w)} + \beta_m RV_t^{(m)} + \varepsilon_{t+h}$, se așteaptă $\beta_Q < 0$
 - ▶ Filtrul BPQ: o prognoză în afara intervalului din eșantion al țintei este înlocuită cu media din eșantion („insanity filter”)
- SHAR [Patton & Sheppard \(2015\)](#): împărțim termenul zilnic după semnul randamentelor intraday
 - ▶ $RV_{t+1:t+h} = \beta_0 + \beta^+ RV_t^+ + \beta^- RV_t^- + \beta_w RV_t^{(w)} + \beta_m RV_t^{(m)} + \varepsilon_{t+h}$
 - ▶ Patton și Sheppard găsesc $\beta^- > \beta^+$: o versiune intraday a efectului de levier (Capitolul 5)
- Semnătura poate surprinde un efect înrudit din date zilnice: aria Lévy dintre randamente și log RV (secțiunea despre semnături)


Șapte modele într-un tabel

Model	Țintă	Ponderi	Regresori
HAR	RV	egale	$RV_t, RV_t^{(w)}, RV_t^{(m)}$
log-HAR	$\ln RV$	egale	aceiași, în logaritmi
HARQ	RV	egale	$HAR + RV_t (RQ_t^{1/2} - \overline{RQ^{1/2}})$
SHAR	RV	egale	$RV_t^+, RV_t^-, RV_t^{(w)}, RV_t^{(m)}$
log-HAR-K	$\ln RV$	nucleul de semnătură	regresorii log-HAR
Sig-L	$\ln RV$	egale	log-HAR + 39 de termeni ai semnăturii, LASSO în doi pași
Sig-LK	$\ln RV$	nucleul de semnătură	ca Sig-L: metoda lui Gu et al.

- Ultimele patru formează o analiză 2×2 pe componente (ablație: fiecare ingredient pornit sau oprit separat): trăsături de semnătură (da/nu) $\times$ ponderi de nucleu (da/nu)
- Log-HAR este reperul natural pentru modelele cu semnături: aceeași țintă, iar regresorii lui sunt printre candidați; dar LASSO poate elimina și termeni log-HAR, deci Sig-L față de log-HAR compară două proceduri, nu doar două mulțimi de variabile

De unde vin semnăturile

- **Chen (1957)**: integralele iterate ale unei traiectorii formează o algebră și o determină până la reparametrizare
 - ▶ Kuo-Tsai Chen, geometria spațiilor de bucle
- **Lyons (1998)**: teoria traiectoriilor aspre (rough paths); semnătura este mulțimea naturală de trăsături pentru ecuațiile diferențiale controlate
 - ▶ Un răspuns la o traiectorie depinde de ea (în prima aproximare) doar prin semnătura ei
- Învățare automată: **Levin, Lyons & Ni (2013)**, **Chevyrev & Kormilitzin (2016)**, **Lyons & McLeod (2022)**; finanțe: modele de prețuri bazate pe semnături **Cuchiero, Gazzani & Svaluto-Ferro (2023)**



Terry Lyons (stânga), Oberwolfach, 2024

Foto: **Katrin Schmid (2024)**; CC BY-SA 2.0 DE; Wikimedia

[Commons](#)

O fereastră de date este o traiectorie

- Luăm ultimele L zile din $d - 1$ serii și unim punctele liniar
 - ▶ $X : [0, 1] \rightarrow \mathbb{R}^d$, $X_{u_i} = (u_i, \ln RV_{t-L+1+i}, \sum_{j \leq t-L+1+i} r_j)$, $u_i = i/(L - 1)$
- **Augmentarea cu timpul:** primul canal este chiar timpul
 - ▶ Fără el, semnătura nu distinge o mișcare rapidă de una lentă (invarianța la reparametrizare)
- O regresie pe fereastră vede 22 de laguri; un rezumat al traiectoriei vede ordinea, viteza și co-mișcarea lor
 - ▶ Exemplu: RV a crescut în timp ce prețurile scădeau, sau RV a crescut întâi și prețurile au scăzut mai târziu

Semnătura: definiție

- Pentru o traiectorie $X : [a, b] \rightarrow \mathbb{R}^d$ cu variație mărginită și un cuvânt $(i_1, \dots, i_k)$ cu litere din $\{1, \dots, d\}$
 - ▶ $S(X)_{a,b}^{i_1 \dots i_k} = \int_{a < u_1 < \dots < u_k < b} dX_{u_1}^{i_1} \dots dX_{u_k}^{i_k}$ (integrală iterată)
- Semnătura este întregul șir de niveluri
 - ▶ $\text{Sig}(X) = (1, S^{(1)}, S^{(2)}, S^{(3)}, \dots)$, $S^{(k)} \in (\mathbb{R}^d)^{\otimes k}$ are d^k termeni
- Nivelul 1: $S^i = X_b^i - X_a^i$, incrementele totale
 - ▶ Nivelul 2: $S^{ij} = \int_a^b (X_u^i - X_a^i) dX_u^j$; nivelul 3 adaugă încă o integrală

Segmente liniare și identitatea lui Chen

- Un segment liniar cu incrementul $\Delta \in \mathbb{R}^d$ are ca semnătură exponențială tensorială
 - ▶ $\text{Sig}(\text{segment}) = \exp_{\otimes}(\Delta) = (1, \Delta, \frac{1}{2!}\Delta^{\otimes 2}, \frac{1}{3!}\Delta^{\otimes 3}, \dots)$
- **Identitatea lui Chen** [Chen \(1957\)](#): semnătura unei concatenări este produsul tensorial
 - ▶ $\text{Sig}(X * Y) = \text{Sig}(X) \otimes \text{Sig}(Y), \quad (A \otimes B)^{(k)} = \sum_{p=0}^k A^{(k-p)} \otimes B^{(p)}$
- O traiectorie liniară pe porțiuni cu m segmente: $\text{Sig} = \exp_{\otimes}(\Delta_1) \otimes \dots \otimes \exp_{\otimes}(\Delta_m)$
 - ▶ Acesta este tot algoritmul: m actualizări, fiecare de cost $O(d^N)$ la adâncimea N (câteva rânduri de numpy)
 - ▶ Ferestre mobile: Chen dă și $\text{Sig}(X_{[s,t]}) = \text{Sig}(X_{[a,s]})^{-1} \otimes \text{Sig}(X_{[a,t]})$

Exemplu lucrat: o traiectorie cu două segmente

Traectoria

- ▣ $X : (0, 0) \rightarrow (1, 0) \rightarrow (1, 2); \Delta_1 = (1, 0), \Delta_2 = (0, 2)$
- ▣ Nivelul 1: $S^{(1)} = \Delta_1 + \Delta_2 = (1, 2)$
- ▣ Nivelul 2 prin Chen:


$$S^{ij} = \frac{1}{2}\Delta_1^i\Delta_1^j + \Delta_1^i\Delta_2^j + \frac{1}{2}\Delta_2^i\Delta_2^j$$

Rezultat

- ▣ $S^{11} = \frac{1}{2}, S^{12} = 0 + 1 \cdot 2 + 0 = 2$
- ▣ $S^{21} = 0, S^{22} = \frac{1}{2} \cdot 2^2 = 2$
- ▣ Verificare: $S^{11} = (\Delta X^1)^2/2$ și $S^{22} = (\Delta X^2)^2/2$ (identitatea shuffle)
- ▣ $S^{12} \neq S^{21}$: ordinea contează (întâi la dreapta, apoi în sus)

Aria Lévy: ordinea ca număr

- Partea antisimetrică a nivelului 2
 - ▶ $A^{ij} = \frac{1}{2}(S^{ij} - S^{ji}) =$ aria cu semn dintre traiectorie și coarda ei
- Partea simetrică: $\frac{1}{2}(S^{ij} + S^{ji}) = \frac{1}{2} \Delta X^i \Delta X^j$, nicio informație nouă
 - ▶ Exemplul de mai sus: $A^{12} = (2 - 0)/2 = 1$, aria triunghiului de sub traiectorie
- Canalele (randament, log RV): o scădere a prețului urmată de o creștere a volatilității dă $A < 0$, dar la fel și o creștere urmată de o scădere a volatilității
 - ▶ O statistică de avans-întârziere: secvențele de tip levier (Capitolul 5) sunt una dintre sursele unei arii negative; semnul singur nu le identifică




Paul Lévy (1886–1971)

Foto: Konrad Jacobs; CC BY-SA 2.0 DE;

[Wikimedia Commons](#)

Două ferestre JPM ca niște traiectorii




- Traectoria (randament cumulat de la deschidere la închidere, log RV) pe 22 de zile; coarda punctată unește începutul și sfârșitul; zona hașurată dă aria Lévy
- Fereastra calmă (până la 15 nov. 2019): log RV se schimbă cu -0,58, traiectoria rătăcește, aria Lévy -0,011; fereastra de stres (până la 16 mar. 2020): log RV crește cu +4,32 ($RV \times 75$) în timp ce randamentele scad, aria Lévy -0,247
- Randamentul intraday net este doar +0,5%: prăbușirea s-a produs în mare parte peste noapte, în afara acestui canal; niciun nivel al semnăturii nu recuperează ce lipsește din date

De ce funcționează semnăturile: trei teoreme

- **Unicitate** Hambly & Lyons (2010): întreaga $\text{Sig}(X)$ determină X până la o echivalență de tip arbore și o translație; cu un canal de timp strict crescător, doar până la o translație
 - ▶ O trunchiere finită Sig^N nu este injectivă
- **Identitatea shuffle**: produsele termenilor semnăturii sunt combinații liniare de termeni superiori, $S^i S^j = S^{ij} + S^{ji}$, $S^{ij} S^k = S^{ijk} + S^{ikj} + S^{kij}$
 - ▶ Deci un model liniar în $\text{Sig}^N(X)$ conține deja polinoame în incremente
- **Universalitate**: pentru o mulțime compactă K (topologia 1-variației) de traiectorii augmentate cu timpul, cu start comun, și $f : K \rightarrow \mathbb{R}$ continuă, pentru orice $\varepsilon > 0$ există ℓ liniară cu $\sup_{X \in K} |f(X) - \langle \ell, \text{Sig}(X) \rangle| < \varepsilon$ (Stone–Weierstrass, prin identitatea shuffle)
 - ▶ De aceea un LASSO pe semnături poate aproxima funcții neliniare ale traiectoriei; prețul este de d^N trăsături, deci este necesară o soluție cu puțini coeficienți nenuli
- **Descreștere factorială**: $\|S^{(k)}\| \leq \|X\|_{\mathbf{1-var}}^k / k!$: trunchierea la o adâncime mică N pierde puțin pentru traiectorii de lungime moderată

Câte trăsături? Dimensiunea trunchierii



- Nivelurile 1..N ale unei traiectorii d -dimensionale:

$$M(d, N) = \sum_{k=1}^N d^k = \frac{d^{N+1} - d}{d - 1} \text{ termeni}$$
- În acest capitol: $d = 3$ canale (timp, log RV, randament cumulat), adâncimea $N = 3$: $3 + 9 + 27 = 39$ de termeni
 - Trei sunt constanți (cuvintele doar cu litera timpului), deci 36 variază
- $d = 5$, $N = 4$ ar da 780 de termeni pentru 1000 de observații: LASSO ar alege din zgomot
- Gu et al. nu publică N și L ; aici $N = 3$, $L = 22$ sunt fixate dinainte, cu $N = 2$ ca verificare de robustețe

Două invarianțe de reținut

- **Invarianța la translație:** $\text{Sig}(X + c) = \text{Sig}(X)$ — intră doar incrementele
 - ▶ Semnătura nu vede **nivelul** volatilității, doar forma traiectoriei recente
 - ▶ Deci nivelul trebuie să intre separat: termenii log-HAR joacă rolul factorilor externi x_T ai lui Gu et al.
- **Invarianța la reparametrizare:** parcurgerea traiectoriei mai repede sau mai încet lasă Sig neschimbată
 - ▶ Eliminată de canalul de timp; augmentarea cu punct de bază (adăugarea la început a unui segment de la 0 la punctul de start inițial) ar elimina prima invarianță [Morrill et al. \(2020\)](#)
 - ▶ Translatarea traiectoriei ca să pornească din 0 nu o elimină: este ea însăși o translație (Seminarul 20, C1 folosește segmentul adăugat la început)

Nucleul de semnătură

- Nucleu = produsul scalar al aplicațiilor de trăsături [Király & Oberhauser \(2019\)](#)
 - ▶ $k_N(X, Y) = \langle \text{Sig}^N(X), \text{Sig}^N(Y) \rangle = 1 + \sum_{k=1}^N \sum_{|w|=k} S(X)^w S(Y)^w$
- Distanța indusă de nucleu (Gu et al., ec. 9)
 - ▶ $d_{\text{Sig}}(X, Y) = k(X, X) - 2k(X, Y) + k(Y, Y) = \|\text{Sig}^N(X) - \text{Sig}^N(Y)\|^2$
- Gu et al. și acest capitol folosesc acest nucleu **trunchiat**, cu același N ca pentru trăsături
 - ▶ Nucleul netrunchiat rezolvă o ecuație cu derivate parțiale de tip Goursat (Partial Differential Equation, PDE) [Salvi et al. \(2021\)](#); articolul îl citează, dar nu îl folosește
- Canalele se rescalează înaintea nucleului (▶ [Anexă](#)): altfel domină canalul cu unitățile cele mai mari

Problema de la Amazon și trăsăturile

- Tarife săptămânale pe piața nord-americană de transport rutier, la nivel național și în cinci regiuni, 2018–2022, prognozate pe până la 12 săptămâni [Gu et al. \(2024\)](#)
 - Peste 100 de factori candidați, reduși la aproximativ 40; în operațiunile Amazon din noiembrie 2022; KDD 2024 (ACM Conference on Knowledge Discovery and Data Mining)
- Trăsăturile în săptămâna τ (Secțiunea 4.1, ec. 14): factorii externi x_τ și semnătura traiectoriei țintei, augmentată cu timpul
 - $\xi_\tau = [x_\tau, \text{Sig}^N(\hat{y}_{\tau-l:\tau})]$, $\hat{y}_{\tau-l:\tau} = \{(t_i, y_{t_i})\}$
- O regresie directă pe orizont, $y_{\tau+\Delta t}$ pe ξ_τ ; fereastra l , adâncimea N , temperatura γ nu sunt publicate (confidențialitate)



Un camion cu container pe o autostradă americană,
2025

Foto: [DanTD \(2025\)](#); CC BY 4.0; [Wikimedia Commons](#)

Metoda: LASSO în doi pași

- ▣ Selecție printr-un LASSO ponderat (Least Absolute Shrinkage and Selection Operator) [Tibshirani \(1996\)](#) (ec. 14)
 - ▶ $\hat{\theta}_L = \arg \min_{\theta} \sum_{\tau} w_{\tau} (y_{\tau+\Delta t} - \xi_{\tau}^{\top} \theta)^2 + \lambda \|\theta\|_1$
- ▣ Reestimare prin OLS ponderat pe suportul selectat (ec. 15)
 - ▶ $\hat{\theta} = \arg \min_{\text{supp}(\theta)=\text{supp}(\hat{\theta}_L)} \sum_{\tau} w_{\tau} (y_{\tau+\Delta t} - \xi_{\tau}^{\top} \theta)^2$
- ▣ De ce reestimăm: LASSO micșorează spre zero coeficienții păstrați; OLS după selecție elimină această deplasare [Belloni & Chernozhukov \(2013\)](#)
 - ▶ Articolul îl numește „adaptiv” din cauza ponderilor w_{τ} , nu în sensul LASSO-ului adaptiv al lui [Zou \(2006\)](#)
- ▣ Modul de alegere a lui λ nu este raportat

Metoda: ponderi date de nucleu

- ▣ Traectoria nucleului: *perechile* $z_\tau = (x_\tau, y_{\tau+\Delta t})$ de predictor și țintă ulterioară, nu trăsăturile ξ_τ (Algoritmul 1)
 - ▶ Distanța față de ultima fereastră cu țintă observată (ec. 11): $\delta_\tau = d_{\text{Sig}, N}(z_{\tau-l:\tau}, z_{t-\Delta t-l:t-\Delta t})$
- ▣ Ponderi softmax cu temperatura $\gamma \geq 0$ (ec. 12)
 - ▶ $w_\tau = \frac{\exp(-\gamma \delta_\tau)}{\sum_s \exp(-\gamma \delta_s)}$
 - ▶ $\gamma = 0$: regresie obișnuită (ponderi egale); $\gamma \rightarrow \infty$: doar cea mai asemănătoare fereastră trecută
- ▣ O idee de tip cel mai apropiat vecin într-o regresie: învățăm din perioadele trecute care arătau ca azi
 - ▶ Costul ideii: mai puține observații efective, $n_{\text{eff}} = 1 / \sum_\tau w_\tau^2$ (Kish)

Ce raportează articolul, citit critic

- Tarife naționale, cu trei luni înainte, aprilie–noiembrie 2021 (Tabelul 1): eroarea relativă $|y - \hat{y}|/|y|$ de aproximativ 1–2% față de 13–27% pentru prognoza din industrie, „de peste cinci ori”
 - ▶ Orizonturi de 1–12 săptămâni (Tabelul 2): 1,06–2,60% la nivel național, 1,05–5,69% pe regiuni; economie anuală estimată de aproximativ 50 de milioane de dolari
 - ▶ Ablația nucleului (Tabelul 3, șase valori săptămânale, 31 octombrie–5 decembrie 2021, o regiune): erori de până la 9,85% fără nucleu, față de până la 5,15% cu el
- Limitele dovezilor
 - ▶ **Un singur reper:** o prognoză comercială al cărei furnizor nu este precizat; fără ARIMA, fără LASSO fără semnături, fără mers aleator
 - ▶ **Evaluare scurtă:** câteva luni, câteva serii, fără erori standard, fără un test de acuratețe egală
 - ▶ **Calibrare nepublicată:** I , N , γ , λ și modul lor de alegere
- Aceste limite nu invalidează metoda, dar slăbesc dovezile; de aceea o testăm în alt context, replicarea înaintea extinderii (Capitolul 19)

Ce se transferă la volatilitate și ce nu

Se transferă

- ▣ Semnătura traiectoriei recente a țintei, augmentată cu timpul
- ▣ LASSO în doi pași cu ponderi, regresie directă pe orizont
- ▣ Ponderi softmax $\exp(-\gamma \delta_\tau)$ cu nucleul de semnătură trunchiat

Trebuie adaptat

- ▣ Țintă zilnică și zgomotoasă în loc de tarife săptămânale: logaritmi, inferență HAC, pierderi robuste
- ▣ Factorii externi x_τ înlocuiți de termenii log-HAR (ei aduc nivelul)
- ▣ Alegerile nepublicate (I, N, γ, λ) fixate dinainte în acest capitol
- ▣ Nucleul: traiectoria din acest capitol (timp, ln RV, randament) care se termină în τ față de fereastra care se termină în t , actualizat la 5 zile, în locul perechilor $(x_\tau, y_{\tau+\Delta t})$ care se termină în $t - \Delta t$: o adaptare
- ▣ Repere puternice și teste formale în locul unei singure prognoze comerciale


Ipoteze

- ▣ **H1 (trăsături):** termenii semnăturii aduc informație dincolo de log-HAR
 - ▶ Test: Sig-L față de log-HAR, aceeași țintă, aceleași ponderi egale
- ▣ **H2 (ponderi):** ponderile de nucleu îmbunătățesc o regresie dată
 - ▶ Teste: Sig-LK față de Sig-L și log-HAR-K față de log-HAR
- ▣ **H3 (metoda):** metoda completă a lui Gu et al. bate familia HAR
 - ▶ Teste: Sig-LK față de HAR și de log-HAR; mulțimea de încredere a celor șapte modele
- ▣ **H4 (stres):** orice câștig este mai mare în perioadele de stres (prăbușirea din pandemia COVID-19, 2–30 aprilie 2025, șocul tarifelor americane), unde ferestrele trecute asemănătoare ar trebui să conteze cel mai mult

Temperatura nucleului: o alegere pe clasă, pe un bloc de validare

- Temperatură fără unități: $\gamma = c/\text{mediana}_\tau(\delta_\tau)$ în fiecare fereastră
 - ▶ $c = 1$: o fereastră la distanța mediană primește ponderea e^{-1} față de una identică
 - Grila $c \in \{0,5; 1; 2; 4\}$, aleasă pe orizont și pe clasă de active, pe primele 250 de zile de prognoză ale fiecărui activ, agregat la nivelul clasei de active
 - ▶ Criteriu: media pe clasă a $\text{QLIKE}(c)$ împărțită la media activului pe grilă
 - ▶ Evaluarea începe după ultima țintă de validare a clasei, deci nicio țintă folosită la calibrare nu este ulterioară unei origini evaluate
 - Pentru cele 40 de acțiuni, cea mai mică temperatură, $c = 0,5$ (ponderile cele mai apropiate de cele egale), câștigă la fiecare orizont pentru Sig-LK; pentru futures și FX alegerea se schimbă cu orizontul: un criteriu plat și zgomotos (toate valorile în
- ▶ Anexă)

Estimarea pe fereastră mobilă, pas cu pas



primele 250 de zile de prognoză ale fiecărui activ: doar validarea lui c , agregat la nivelul clasei de active

apoi evaluarea tuturor modelelor, de la prima origine de după ultima țintă de validare a clasei până la ultima țintă

- Reestimăm la fiecare 5 zile de tranzacționare pe ultimele 1000 de perechi complete; între reestimări coeficienții sunt ficși, dar regresorii se actualizează zilnic
- Distanțele nucleului se recalculează la fiecare reestimare, față de fereastră care se termină la originea t


Protocolul de evaluare

- Pe activ și orizont: QLIKE și MSE medii; testul DM (Diebold–Mariano) cu varianță Newey–West, lățime de bandă $\max(h, \lceil T^{1/3} \rceil)$ [Diebold & Mariano \(1995\)](#)
 - ▶ Estimare pe fereastră mobilă, deci testul se citește ca testul GW (Giacomini–White) necondiționat; testul GW condiționat folosește instrumentele $(1, d_{t-h})$ [Giacomini & White \(2006\)](#)
- MCS (Model Confidence Set, mulțimea de încredere a modelelor) la 90%, statistica $T_{\max}$, bootstrap staționar, 1000 de replicări [Hansen, Lunde & Nason \(2011\)](#)
 - ▶ Lungimea blocului $\max(h, 10)$ zile
- Panel: testul DM pe diferența medie de pierdere pe secțiune transversală (o serie pe dată)
 - ▶ Numărarea victoriilor pe 50 de active: corecțiile Holm (FWER) și BH (FDR) [Benjamini & Hochberg \(1995\)](#)
- Subperioade: 20 feb.–30 apr. 2020, 2–30 apr. 2025, toate celelalte zile; eroarea relativă din articol ca statistică descriptivă
- 265 929 de prognoze în afara eșantionului pentru fiecare model; acțiunile sunt evaluate din ianuarie 2020 (prăbușirea COVID-19 este în eșantionul fiecărei acțiuni), futures și FX din 2014 (datele în [▶ Anexă](#))

O abatere declarată

- ▣ Preînregistrat: filtrul BPQ („insanity filter”) pe toate modelele
 - ▶ Un test al codului pe JPM (un singur activ, înaintea oricărui rezultat pe panel) a arătat că înlocuiește prognoze corecte din perioada prăbușirii cu media din perioada calmă a eșantionului
 - ▶ Pe 12 martie 2020, RV observată în ziua următoare pentru JPM a fost de aproximativ 40 de ori mai mare decât prognoza HAR filtrată
- ▣ Schimbat înainte de estimarea pe panelul de 50 de active: rezultatele principale doar cu pozitivitate (o prognoză ≤ 0 devine media din eșantion)
 - ▶ Filtrul BPQ rămâne ca verificare de robustețe și este raportat complet
- ▣ Regula: o abatere este permisă, o abatere ascunsă nu; spuneți ce ați observat înainte de modificare

QLIKE relativ la HAR, activ cu activ




- Cutii: intervalul intercuartilic pe cele 50 de active; linia: mediana; romb: media; mustățile: 1,5 intervale intercuartilice
- $h = 1$: log-HAR, log-HAR-K și Sig-L sunt apropiate (0,883; 0,885; 0,886); Sig-LK este la +4,5% față de log-HAR: niciun câștig din 36 de trăsături în plus
- $h = 5, 22$: Sig-LK rămâne în urma log-HAR (+28,0%; +92,9%); medianele (0,997; 0,968) sunt mult mai bune decât mediile: câteva active și zile determină pierdere
- HARQ și SHAR pierd aici în fața HAR în nivel, pentru că designul principal nu aplică filtrul BPQ (vezi [▶ Anexa](#): filtrul salvează HARQ); primul verdict: metoda nu bate cel mai simplu model logaritm (o egalitate aproximativă nu dovedește acuratețe egală)

Activ cu activ: victorii și înfrângeri, corectate


Comparația (QLIKE)	$h = 1$		$h = 5$		$h = 22$	
Sig-LK vs log-HAR	2/0/0	5/0/0	0/0/0	15/0/2	0/0/0	27/1/16
Sig-L vs log-HAR	3/1/1	5/0/0	0/0/0	9/0/0	1/0/0	21/0/0
log-HAR-K vs log-HAR	3/0/0	3/0/0	3/0/0	1/0/0	5/0/0	6/0/0
Sig-LK vs Sig-L	2/0/0	5/0/0	0/0/0	5/0/0	2/0/0	10/0/0
Sig-LK vs HAR	12/5/6	0/0/0	7/1/1	0/0/0	8/2/4	1/0/0
log-HAR vs HAR	21/5/17	0/0/0	23/13/20	0/0/0	42/25/42	0/0/0

- Celula: numărul de active semnificativ mai bune, fără corecție/Holm/BH | semnificativ mai slabe, fără corecție/Holm/BH; DM unilateral la 5%, familie de 50 de active; Holm controlează FWER sub orice dependență, BH controlează FDR sub independență sau PRDS [Benjamini & Yekutieli \(2001\)](#)
- H1 (semnături): Sig-L bate log-HAR pe 3 din 50 de active la $h = 1$ fără corecție, 1 după Holm; din întâmplare se așteaptă aproximativ 2,5 victorii necorectate
- H2 (ponderi): log-HAR-K față de log-HAR și Sig-LK față de Sig-L: nicio diferență semnificativă după Holm, la niciun orizont
- Față de HAR la $h = 1$, Sig-LK câștigă pe 12 active, dar log-HAR singur câștigă pe 21: alegeți reperul care izolează ideea



- Q MFM ch20 case study

Mulțimi de încredere pentru modele




- Proporția din cele 50 de active pentru care fiecare model aparține MCS de 90% sub QLIKE: log-HAR 100%, 98%, 98%; Sig-LK 100%, 94%, 88% ($h = 1, 5, 22$)
- MCS separă rar cele patru modele logaritmice; HAR, HARQ și SHAR sunt excluse pentru o cincime până la o treime dintre active: ținta în nivel este cel mai clar învins
- Sub MSE aproape fiecare model rămâne în mulțime [Patton \(2011\)](#): diferențele mici de pierdere medie cer eșantioane foarte lungi [Pele & Mazurencu-Marinescu-Pele \(2026\)](#)

Teste pe panel: cumularea dovezilor

Comparația: DM t (p unilateral)	$h = 1$	$h = 5$	$h = 22$
Sig-LK vs log-HAR	+1,45 (0,927)	+1,68 (0,953)	+1,80 (0,964)
Sig-L vs log-HAR	-1,91 (0,028)	+1,48 (0,931)	+1,51 (0,935)
log-HAR-K vs log-HAR	+1,89 (0,971)	+0,40 (0,654)	+1,92 (0,973)
Sig-LK vs Sig-L	+1,74 (0,959)	+0,98 (0,837)	-0,77 (0,221)
log-HAR vs HAR	-3,09 (<0,001)	-3,95 (<0,001)	-4,50 (<0,001)


- ▣ Seria: diferența medie QLIKE pe toate activele tranzacționate în acea zi; t negativ = primul model mai bun
- ▣ Cumulat, doar transformarea logaritmică este clar semnificativă; Sig-L față de log-HAR la $h = 1$ este la limită ($p = 0,028$), datorită futures
 - ▶ Doar pentru cele 40 de acțiuni semnul se inversează: $t = +1,72$ împotriva Sig-L
- ▣ Testul GW condiționat, Sig-LK față de log-HAR: 0, 0 și 0 respingeri Holm din 50

În prăbușirea din pandemia COVID-19: JPM, ziua următoare




- Volatilitatea anualizată $\sqrt{252F_t}$ a prognozelor și $\sqrt{252RV_{t+1}}$ a țintei, februarie–mai 2020; toate modelele întârzie față de primul salt
- Sig-LK reacționează puțin mai repede decât log-HAR la mijlocul lui martie, când traiectoria și-a schimbat deja direcția; după vârf ambele scad cu viteze asemănătoare
- HAR în nivel depășește ținta, apoi devine negativ la sfârșitul lui martie: regula de pozitivitate îl înlocuiește cu media din eșanțion (segmentul plat)

Perioade de stres vs perioade normale (H4)




- Media pe active a QLIKE relativ la HAR în fiecare subperioadă fixată înaintea evaluării
- $h = 1$, prăbușirea COVID-19: log-HAR 0,70, Sig-LK 0,73, HARQ 1,89; 2–30 aprilie 2025 (șocul tarifelor americane): 0,88 și 0,92; celelalte zile: 0,94 și 0,97
- $h = 22$, prăbușirea COVID-19: Sig-LK de 6,35 ori și Sig-L de 8,30 ori pierderea HAR: exact unde ferestrele trecute asemănătoare ar trebui să ajute, modelele cu semnături eșuează cel mai mult; H4 nesuținută (descriptiv, fără test formal de interacțiune)

Ponderile nucleului la originea din 16 martie 2020




- Ponderile Sig-LK ($h = 1$) la originea din 16 martie 2020 pe zilele de antrenare (24 mar. 2016 – 13 mar. 2020), înmulțite cu lungimea ferestrei: 1 = ponderare egală
- Aproape egale: între 0,61 și 1,43 ori $1/n$, mărimea efectivă a eșantionului 975 din 1000 (media celor 40 de acțiuni); cele mai mari ponderi merg la ultimele zile dinaintea originii
- Scăderile de la sfârșitul lui 2018 primesc o pondere *mai mică*; ponderile sunt aproape necorelate cu log-volatilitatea (+0,04): semnătura invariantă la translație vede forma, nu nivelul

Favorizează vreodată nucleul stresul?




- ▣ Ponderea pe care Sig-LK ($h = 1$) o atribuie celor mai volatile 10% dintre zile din fereastra de antrenare, medie pe clasă și pe trei luni
- ▣ Acțiuni: media 6,7%, între 4,4% și 9,9% (maximul pe 17 mar. 2020): mereu sub cele 10% ale ponderării egale; futures și FX arată același tipar
- ▣ Mecanismul din spatele rezultatului nul pentru H2: ponderile nu implementează „învățăm din crizele trecute”

Ce selectează LASSO




- Ponderea reestimărilor în care un regresor este în suportul ales prin BIC pentru Sig-LK; t = timp, $\ln RV = \ln RV$, r = randament cumulat
- Termenii log-HAR sunt păstrați în 99%, 94% și 93% dintre reestimări: LASSO redescoperă HAR; suport mediu 8,7 regresori (Sig-L), 6,7 (Sig-LK)
- Cel mai frecvent termen al semnăturii, (t,r,r) (27%), și toți cei frecvenți sunt de nivelul 3: cubici în incremente, mult în afara intervalului de antrenare într-o prăbușire, amplificăți de $\exp(\cdot)$

Ablația 2×2 

- Media pe cele 50 de active a QLIKE relativ la log-HAR: trăsături (semnătură sau nu) încrucișate cu ponderi (nucleu sau egale)
- Doar ponderile (log-HAR-K): 1,002; 1,002; 1,004, niciun efect (mărima efectivă medie 816 din 1000); doar trăsăturile (Sig-L): 1,004; 1,285; 2,238
- Ambele (Sig-LK: 1,045; 1,280; 1,929) atenuează eșecul la o lună fără să-l elimine și înrăutățesc $h = 1$ prin petrol (CL: 2,71); Gu et al. (Tabelul 3) au văzut un câștig al nucleului în șase valori săptămânale dintr-o regiune

Robustețea Sig-LK



- Sig-LK relativ la HAR (media pe 50 de active) în designul principal, în două variante preînregistrate și cu filtrul BPQ (abaterea declarată); linia marchează log-HAR
- Adâncimea 2: 0,922 și 0,820 la $h = 5, 22$ (principal: 1,104; 1,334); traiectoria fără randamente: 0,878 și 0,770: eșecurile la orizont lung vin din termenii de nivelul 3 cu canalul randamentelor
- Variantele stabile doar egalează log-HAR (0,871; 0,765): rezultatul nul pentru H1 nu depinde de adâncime sau de canale, instabilitatea depinde

Pe clase de active

Sig-L relativ la log-HAR (QLIKE)	$h = 1$	$h = 5$	$h = 22$
Acțiuni (40)	1,009	1,332	2,505
Futures (5)	0,965	1,084	1,206
FX (5)	0,996	1,111	1,134

- Singurul câștig: futures la $h = 1$ (-3,5%) și, marginal, FX
 - Cinci futures și un orizont: un candidat pentru un nou studiu preînregistrat, nu o concluzie a acestuia
- Acțiunile, 80% din panel, nu arată niciun câștig: rezultatul agregat este în principal un rezultat pentru acțiuni

Limite și direcții deschise

Limitele acestui studiu

- Un design din multe ($L = 22$, $N = 3$, trei canale, BIC, o grilă de patru puncte pentru c): un rezultat nul pentru acest design nu este unul pentru semnături în general
- Doar nucleul trunchiat; fără factori externi (volatilitate implicită, știri macro), centrali la Gu et al.
- Realized GARCH Hansen, Huang & Shek (2012) și modelele de referință din învățarea automată (Capitolul 13) sunt în afara comparației; acțiunile sunt evaluate doar pe șase ani

Direcții deschise

- Un nucleu care vede nivelul: augmentarea cu punct de bază sau nivelul ln RV în distanță (Seminarul 20, C1)
- Semnături ale traiectoriei intraday (randamente la 5 minute); nucleul PDE Salvi et al. (2021); log-semnături și canale mărginite (tanh) împotriva termenilor explozivi de nivelul 3 Morrill et al. (2020)
- Traiectorii între active, unde ariile Lévy măsoară avansul-întârzierea între piețe; futures la $h = 1$ pe un panel mai lung, cu acest design fixat dinainte

O întrebare deschisă

Când se transferă o metodă între domenii?

- Metodele circulă mai repede decât dovezile: un articol KDD despre tarife de transport devine candidat pentru volatilitate, credit, energie
 - ▶ Ce proprietăți ale problemei-sursă au făcut metoda să funcționeze și le are și problema-țintă?
- Finanțele adaugă un filtru sever: 164 de echipe pe aceleași date diferă mai mult decât sugerează erorile lor standard Menkveld et al. (2024)
- Formulare formală: un transfer reușește dacă câștigul față de cel mai puternic reper simplu rezistă pe o mulțime preînregistrată $\mathcal{S}$ de designuri, active și orizonturi, cu o corecție pentru testarea multiplă aplicată familiei de teste
 - ▶ În acest capitol: $\mathcal{S} = 50$ de active $\times$ 3 orizonturi $\times$ 4 variante; Holm/BH s-au aplicat pe comparație și orizont (familii de 50 de active), variantele sunt raportate descriptiv; nicio corecție comună pe toate cele 600 de celule; câștigul nu a rezistat

Bucula descoperirii aplicată acestui capitol

- **Citim:** un asistent listează fiecare ecuație, hiperparametru și reper din articol și marchează ce nu este publicat; fiecare element se verifică în PDF
 - ▶ **Stabilim corespondența:** pentru fiecare componentă, se transferă, ce trebuie schimbat, ce reper o izolează
- **Preînregistrăm:** ipotezele, grila, testele și corecția fixate într-un document datat înaintea primului rezultat; asistentul face ciorna, echipa decide fiecare cifră
- **Construim și testăm piesele:** semnăturile față de identități (nivelul 1 = incrementul, Chen pe o traiectorie împărțită), nu față de altă bibliotecă
- **Rulăm grila, apoi o supunem unor teste de rezistență:** ce concluzii rezistă corecției Holm pe 50 de active, ce activ ar da un titlu înșelător?
- **Explicăm rezultatul nul:** aici ponderi plate (invarianța la translație) și termeni explozivi de nivelul 3 (legătura exponențială), ambele verificate cu date; cererile complete și lista de verificări a cercetătorului sunt în [▶ Anexă](#)

Mini-caz: trei titluri din aceleași rulări

- „Semnăturile bat HAR pe 12 din 50 de active” (orizont de o zi, DM necorectat)
 - ▶ Adevărat, dar log-HAR singur bate HAR pe 21: câștigul aparține transformării logaritmice
- „Semnăturile îmbunătățesc prognozele de volatilitate pentru E-mini S&P 500” (ES, $h = 1$, DM $t = -2,91$ față de log-HAR)
 - ▶ O celulă din 150 de celule activ-orizont: după Holm, 0 din 50 la $h = 1$ și niciuna la $h = 5, 22$
- Titlul rezultat din evaluarea preînregistrată: „niciun câștig față de log-HAR; mai slab la orizonturi mai lungi; ponderile nucleului inerte”
 - ▶ Un asistent AI rugat să „găsească unde funcționează metoda” le va produce pe primele două; planul îl protejează pe al treilea

Rândul vostru

- Alegeți o direcție deschisă din acest capitol (nucleu care vede nivelul, semnături intraday, log-semnături, doar futures)
 - ▶ Scrieți H_0/H_1 , reperul care o izolează și rezultatul care v-ar face să renunțați la ea
- Folosiți un asistent pentru a lista ce poate merge prost în designul vostru, apoi scrieți un test unitar pentru fiecare element
- Fixați preînregistrarea într-un document datat înaintea primei cifre în afara eșantionului; rulați grila; raportați distribuția pe $\mathcal{S}$
- Notați fiecare eroare AI prinsă în `AI_ERRORS.md` (Seminarul 20, C2 dă erori tipice)

Idei de reținut

- Semnăturile transformă o fereastră într-un vector de trăsături cu fundament teoretic: identitatea lui Chen, unicitate, universalitate
- Transferată la varianța realizată, metoda lui Gu et al. nu bate log-HAR
 - ▶ H1 (semnăturile aduc informație): nesuținută, niciun câștig la o zi, pierdere la o săptămână și la o lună
 - ▶ H2 (ponderile nucleului ajută): nesuținută, ponderile sunt aproape plate și reduc ponderea stresului trecut; H3: doar HAR în nivel este bătut, prin ținta logaritmică; H4 (câștiguri în stres): nesuținută
- Nucleul invariant la translație vede forma, nu nivelul; termenii de nivelul 3 explodează în prăbușiri
- Cel mai puternic efect din studiu este cel mai vechi: modelați logaritmul RV
- Un rezultat năprînregistrat, cu ablații și cu un mecanism, este o concluzie

Studiu suplimentar

Lecturi

- Semnături: Chevyrev & Kormilitzin (2016); Lyons & McLeod (2022); măsuri realizate: Franke, Härdle & Hafner (2019) și Capitolul 9

Cursuri avansate pe quantinar.com

-  Statistics of Financial Markets
-  Applied Time Series Analysis with Python
-  Machine Learning in Financial Risk

Cod și date

- Quantlets: github.com/danpele/MFM/tree/main/Quantlets/Ch_20; date: VOLARE, gratuit pentru cercetare la volare.unime.it

Anexă: Trăsături și scalare

- Regresorii în ziua τ pentru modelele cu semnături: 3 termeni log-HAR + 39 de termeni ai semnăturii
 - ▶ $\xi_\tau = [\ln RV_\tau, \ln RV_\tau^{(w)}, \ln RV_\tau^{(m)}, \text{Sig}^3(X_{\tau-21:\tau})]$, traiectoria $X = (\text{timp}, \ln RV, r \text{ cumulat})$, 22 de puncte
- Canalul c (altul decât timpul) împărțit la $s_c \sqrt{L-1}$, $s_c =$ abaterea standard a incrementelor sale zilnice în fereastra de antrenare, până la originea t
 - ▶ Timpul nu se rescalează (incrementele constante, $s = 0$): merge de la 0 la 1; un cuvânt $(i_1..i_k)$ se rescalează cu $\prod_j c_{i_j}$, deci semnăturile se calculează o singură dată
- Înaintea LASSO fiecare coloană este standardizată cu momentele ponderate ale ferestrei de antrenare; coloanele constante (cuvintele doar cu timp) se elimină
- Variabilele brute din τ folosesc date până la τ ; scalele și standardizarea folosesc date până la originea t : limita fără informație din viitor este t

Anexă: Estimare: alegerea lui λ fără look-ahead bias

- În fiecare fereastră de antrenare: întreaga traiectorie de regularizare LASSO ponderată, prin LARS (Least-Angle Regression, regresia unghiului minim)
 - ▶ Pentru fiecare suport de pe traiectoria de regularizare: reestimare OLS ponderată (pasul 2 din Gu et al.)
- Alegem suportul care minimizează un criteriu de tip BIC (Bayesian Information Criterion, criteriul informațional bayesian) cu mărimea efectivă a eșantionului Kish, o euristică a acestui design
 - ▶ $\text{BIC}(S) = n_{\text{eff}} \ln \hat{S}_S^2 + (|S| + 1) \ln n_{\text{eff}}, \quad n_{\text{eff}} = 1 / \sum_{\tau} w_{\tau}^2$
- De ce nu validare încrucișată: 50 de active $\times$ 3 orizonturi $\times$ sute de reestimări; BIC folosește doar fereastra
 - ▶ Mărimea Kish corectează ponderile inegale, nu dependența serială (ținte suprapuse, $h > 1$): nu este un BIC bazat pe verosimilitate pentru aceste date

Anexă: Temperaturile nucleului alese pe blocul de validare

- c ales pentru Sig-LK ($h = 1, 5, 22$)
 - ▶ acțiuni 0,5; 0,5; 0,5; futures 2,0; 1,0; 0,5; FX 0,5; 2,0; 0,5
- c ales pentru log-HAR-K ($h = 1, 5, 22$)
 - ▶ acțiuni 0,5; 0,5; 1,0; futures 2,0; 1,0; 4,0; FX 4,0; 2,0; 4,0
- Grila $c \in \{0,5; 1; 2; 4\}$; cea mai mică temperatură (ponderile cele mai apropiate de cele egale) câștigă pentru acțiuni la fiecare orizont; pentru futures și FX alegerea se schimbă cu orizontul

Anexă: Ce s-a evaluat

Clasa	Evaluarea începe	Se termină	Zile pe activ (mediana)
Acțiuni	27 ian. 2020	29 ian. 2026	1 499
Futures	25 sept. 2014	29 ian. 2026	2 919
FX	27 aug. 2014	29 ian. 2026	2 952

- 265 929 de prognoze în afara eșantionului pentru fiecare model (50 de active $\times$ 3 orizonturi)
- Acțiunile încep în 2015, deci evaluarea lor începe în ianuarie 2020: prăbușirea din pandemia COVID-19 este în eșantionul fiecărei acțiuni
 - Futures și FX încep în 2009 și sunt evaluate din 2014

Anexă: Metrica articolului pe datele VOLARE

Eroarea relativă mediană $ RV - F /RV$ (%)	$h = 1$	$h = 5$	$h = 22$
HAR	57,2	48,9	51,7
log-HAR	50,4	41,9	38,7
HARQ	55,0	49,0	50,7
SHAR	57,9	49,2	51,8
log-HAR-K	49,7	41,0	38,7
Sig-L	50,1	42,6	42,6
Sig-LK	50,6	43,6	43,7

- Mediana pe active a erorii relative medii: aproximativ 40–60%, față de 1–2% pentru tarifele de transport la Gu et al.
- RV zilnică este o țintă zgomotoasă, cu cozi groase: modelele evaluate au erori relative mult mai mari decât cele raportate pentru tarifele de transport, fără ca aceasta să stabilească o limită inferioară a erorii posibile
 - Prognoze Sig-LK care depășesc pragul de zece ori maximul din eșantion: 8, 29, 36 ($h = 1, 5, 22$), pe 10 active la $h = 5$; log-HAR: niciuna

Anexă: Filtrul „insanity”, revăzut

QLIKE relativ la HAR, filtrul BPQ pe toate modelele	$h = 1$	$h = 5$	$h = 22$
HAR	1,000	1,000	1,000
log-HAR	0,763	0,654	0,778
HARQ	0,995	0,912	1,014
SHAR	1,014	1,003	1,000
log-HAR-K	0,772	0,659	0,779
Sig-L	0,871	0,819	0,904
Sig-LK	0,890	0,867	0,930

- Filtrul salvează HARQ față de HAR (0,995 la $h = 1$ în loc de 1,140), cum au intenționat BPQ
- Sig-LK relativ la log-HAR, ambele filtrate: 1,238; 1,424; 1,209 (nefiltrat 1,045; 1,280; 1,929): distanța crește la $h = 1, 5$ și scade la $h = 22$
- Prognoze filtrate, $h = 1$: HAR 180, HARQ 140, Sig-LK 143, log-HAR 29 (din 89 893): filtrul lovește modelele cu semnături mult mai des decât log-HAR

Anexă: Ce verifică cercetătorul

- **Metoda este cea din articol:** nucleul, ponderile, reestimarea, ca în ecuațiile citate
 - ▶ Test: fiecare slide de design citează o ecuație, un tabel sau o secțiune a articolului; alegerile nepublicate sunt marcate ca alegeri ale studiului
- **Fără look-ahead bias:** λ , scalele, c și trăsăturile folosesc doar date disponibile la origine
 - ▶ Test: schimbați fiecare valoare de după origine (de exemplu, înmulțiți RV viitoare cu 10); prognoza făcută la origine nu trebuie să se schimbe
- **Reperul izolează ideea**
 - ▶ Test: ablația 2×2 este raportată, nu doar modelul complet față de HAR
- **Funcțiile de pierdere și testele sunt aplicate corect**
 - ▶ Test: $QLIKE(RV, RV) = 0$ și $QLIKE(RV, F) > 0$ în rest; varianța DM este HAC cu lățimea de bandă cel puțin h

Anexă: Bucla descoperirii, cererile (1/2)

- **Citim:** extragem exact ce a făcut articolul
 - ▶ „Din Gu et al. (2024, KDD), listează fiecare ecuație a estimatorului, fiecare hiperparametru și valoarea raportată și reperul fiecărui tabel. Marchează ce nu este publicat.”
 - ▶ Verificați fiecare element în PDF: numerele ecuațiilor, ale tabelelor, nucleul folosit efectiv
- **Stabilim corespondența:** ce se transferă, ce trebuie adaptat
 - ▶ „Ținta noastră este varianța realizată zilnică. Pentru fiecare componentă a metodei, spune dacă se transferă, ce trebuie schimbat și ce reper o izolează.”
- **Preînregistrăm:** ipoteze, grilă, teste, corecție, fixate într-un document datat înaintea primului rezultat
 - ▶ Asistentul face ciorna; echipa decide fiecare cifră și semnează preînregistrarea datată

Anexă: Bucla descoperirii, cererile (2/2)

- **Construim și testăm piesele:** semnăturile față de identități, nu față de altă bibliotecă
 - ▶ „Scrie teste unitare pentru o semnătură de adâncime 3: nivelul 1 egal cu incrementul, partea simetrică a nivelului 2 egală cu jumătate din produsul exterior, identitatea lui Chen pe o traiectorie împărțită.”
- **Rulăm grila, apoi o supunem unor teste de rezistență**
 - ▶ „Iată toate cele 600 de rulări (50 de active $\times$ 3 orizonturi $\times$ 4 specificații: principală, adâncimea 2, fără canalul randamentelor, filtrul BPQ). Ce concluzii rezistă corecției Holm pe 50 de active? Ce activ sau ce subperioadă ar da un titlu înșelător?”
- **Explicăm rezultatul nul:** găsim mecanismul, nu o scuză
 - ▶ Aici: ponderi plate (invarianța la translație) și termeni explozivi de nivelul 3 (legătura exponențială), ambele verificate cu date

Bibliografie (1/2)

- ▣ Barndorff-Nielsen, O.E., Hansen, P.R., Lunde, A., Shephard, N. (2008). [Designing realized kernels to measure the ex post variation of equity prices in the presence of noise](#). *Econometrica*, 76(6), 1481–1536.
- ▣ Barndorff-Nielsen, O.E., Kinnebrock, S., Shephard, N. (2010). [Measuring downside risk: realised semivariance](#). In *Volatility and Time Series Econometrics*, Oxford University Press, 117–136.
- ▣ Barndorff-Nielsen, O.E., Shephard, N. (2002). [Econometric analysis of realized volatility and its use in estimating stochastic volatility models](#). *Journal of the Royal Statistical Society B*, 64(2), 253–280.
- ▣ Belloni, A., Chernozhukov, V. (2013). [Least squares after model selection in high-dimensional sparse models](#). *Bernoulli*, 19(2), 521–547.
- ▣ Benjamini, Y., Hochberg, Y. (1995). [Controlling the false discovery rate: a practical and powerful approach to multiple testing](#). *Journal of the Royal Statistical Society B*, 57(1), 289–300.
- ▣ Benjamini, Y., Yekutieli, D. (2001). [The control of the false discovery rate in multiple testing under dependency](#). *The Annals of Statistics*, 29(4), 1165–1188.
- ▣ Bollerslev, T., Patton, A.J., Quaedvlieg, R. (2016). [Exploiting the errors: a simple approach for improved volatility forecasting](#). *Journal of Econometrics*, 192(1), 1–18.
- ▣ Chen, K.-T. (1957). [Integration of paths, geometric invariants and a generalized Baker–Hausdorff formula](#). *Annals of Mathematics*, 65(1), 163–178.
- ▣ Chevyrev, I., Kormilitzin, A. (2016). [A primer on the signature method in machine learning](#). arXiv:1603.03788.
- ▣ Cipollini, F., Cruciani, G., Gallo, G.M., Insana, A., Otranto, E., Spagnolo, F. (2026). [VOLatility Archive for Realized Estimates \(VOLARE\)](#). arXiv:2602.19732.
- ▣ Corsi, F. (2009). [A simple approximate long-memory model of realized volatility](#). *Journal of Financial Econometrics*, 7(2), 174–196.
- ▣ Cuchiero, C., Gazzani, G., Svaluto-Ferro, S. (2023). [Signature-based models: theory and calibration](#). *SIAM Journal on Financial Mathematics*, 14(3), 910–957.
- ▣ Diebold, F.X., Mariano, R.S. (1995). [Comparing predictive accuracy](#). *Journal of Business & Economic Statistics*, 13(3), 253–263.
- ▣ Franke, J., Härdle, W.K., Hafner, C.M. (2019). [Statistics of Financial Markets: An Introduction](#), 5th ed. Springer.
- ▣ Giacomini, R., White, H. (2006). [Tests of conditional predictive ability](#). *Econometrica*, 74(6), 1545–1578.
- ▣ Gu, H., Guo, X., Jacobs, T.L., Kaminsky, P., Li, X. (2024). [Transportation marketplace rate forecast using signature transform](#). *Proceedings of the 30th ACM SIGKDD Conference on Knowledge Discovery and Data Mining*, 4997–5005; arXiv:2401.04857.

Bibliografie (2/2)

- ▣ Hambly, B., Lyons, T. (2010). Uniqueness for the signature of a path of bounded variation and the reduced path group. *Annals of Mathematics*, 171(1), 109–167.
- ▣ Hansen, P.R., Huang, Z., Shek, H.H. (2012). Realized GARCH: a joint model for returns and realized measures of volatility. *Journal of Applied Econometrics*, 27(6), 877–906.
- ▣ Hansen, P.R., Lunde, A., Nason, J.M. (2011). The model confidence set. *Econometrica*, 79(2), 453–497.
- ▣ Király, F.J., Oberhauser, H. (2019). Kernels for sequentially ordered data. *Journal of Machine Learning Research*, 20(31), 1–45.
- ▣ Levin, D., Lyons, T., Ni, H. (2013). Learning from the past, predicting the statistics for the future, learning an evolving system. arXiv:1309.0260.
- ▣ Liu, L.Y., Patton, A.J., Sheppard, K. (2015). Does anything beat 5-minute RV? A comparison of realized measures across multiple asset classes. *Journal of Econometrics*, 187(1), 293–311.
- ▣ Lyons, T. (1998). Differential equations driven by rough signals. *Revista Matemática Iberoamericana*, 14(2), 215–310.
- ▣ Lyons, T., McLeod, A.D. (2022). Signature methods in machine learning. arXiv:2206.14674.
- ▣ Menkveld, A.J., Dreber, A., Holzmeister, F., Huber, J., Johannesson, M., Kirchler, M., et al. (2024). Nonstandard errors. *Journal of Finance*, 79(3), 2339–2390.
- ▣ Morrill, J., Fermanian, A., Kidger, P., Lyons, T. (2020). A generalised signature method for multivariate time series feature extraction. arXiv:2006.00873.
- ▣ Patton, A.J. (2011). Volatility forecast comparison using imperfect volatility proxies. *Journal of Econometrics*, 160(1), 246–256.
- ▣ Patton, A.J., Sheppard, K. (2015). Good volatility, bad volatility: signed jumps and the persistence of volatility. *Review of Economics and Statistics*, 97(3), 683–697.
- ▣ Pele, D.T., Mazurencu-Marinescu-Pele, M. (2026). Finite-sample precision limits for expected shortfall forecast comparisons. *Mathematics*, 14(13), 2316.
- ▣ Salvi, C., Cass, T., Foster, J., Lyons, T., Yang, W. (2021). The signature kernel is the solution of a Goursat PDE. *SIAM Journal on Mathematics of Data Science*, 3(3), 873–899.
- ▣ Tibshirani, R. (1996). Regression shrinkage and selection via the lasso. *Journal of the Royal Statistical Society B*, 58(1), 267–288.
- ▣ Zou, H. (2006). The adaptive lasso and its oracle properties. *Journal of the American Statistical Association*, 101(476), 1418–1429.