



Modelarea piețelor financiare

Seminarul 1: Fapte stilizate și randamente — aplicații



Daniel Traian PELE

Antoaneta Amza

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognostic Economică

MSCA Digital Finance

Acronime folosite în acest material (1/2)

- ▣ **ACF**: AutoCorrelation Function — *funcția de autocorelație*
- ▣ **AI**: Artificial Intelligence — *inteligență artificială*
- ▣ **AR**: AutoRegressive (model); in event studies: Abnormal Return — *model autoregresiv; în studiile de eveniment: randament anormal*
- ▣ **ARCH-LM**: ARCH Lagrange Multiplier (test) — *testul multiplicatorului Lagrange pentru efecte ARCH*
- ▣ **BET-TR**: BET Total Return (index) — *indicele BET cu dividendele reinvestite*
- ▣ **BNR**: Banca Națională a României
- ▣ **BVB**: Bursa de Valori București
- ▣ **CAGR**: Compound Annual Growth Rate — *rata anuală compusă de creștere*
- ▣ **CI**: Confidence Interval — *interval de încredere*
- ▣ **COVID-19**: COronaVirus Disease 2019 — *boala provocată de coronavirus, 2019*
- ▣ **CUSUM**: CUmulative SUM (of squares) — *suma cumulată (a pătratelor)*
- ▣ **EGARCH**: Exponential GARCH — *GARCH exponențial*
- ▣ **ETF**: Exchange-Traded Fund — *fond tranzacționat la bursă*
- ▣ **FIGARCH**: Fractionally Integrated GARCH — *GARCH integrat fracționar*
- ▣ **FTSE**: Financial Times Stock Exchange (FTSE Russell, index provider) — *furnizorul de indici FTSE Russell*
- ▣ **GARCH**: Generalised AutoRegressive Conditional Heteroskedasticity — *heteroscedasticitate condiționată autoregresivă generalizată*

Acronime folosite în acest material (2/2)

- ▣ **GJR-GARCH**: Glosten–Jagannathan–Runkle GARCH — *GARCH asimetric Glosten–Jagannathan–Runkle*
- ▣ **HAC**: Heteroskedasticity and Autocorrelation Consistent (standard errors) — *erori standard robuste la heteroscedasticitate și autocorelație*
- ▣ **HAR**: Heterogeneous AutoRegressive (model) — *model autoregresiv heterogen*
- ▣ **JB**: Jarque–Bera (test) — *testul de normalitate Jarque–Bera*
- ▣ **MDD**: Maximum DrawDown — *drawdown-ul maxim*
- ▣ **OHLC**: Open, High, Low, Close — *deschidere, maxim, minim, închidere*
- ▣ **OLS**: Ordinary Least Squares — *metoda celor mai mici pătrate*
- ▣ **QQ**: Quantile–Quantile (plot) — *graficul cuantilă–cuantilă*
- ▣ **RMSE**: Root Mean Squared Error — *rădăcina erorii pătratice medii*
- ▣ **SE**: Standard Error — *eroare standard*
- ▣ **SUA**: Statele Unite ale Americii
- ▣ **UTC**: Coordinated Universal Time (Temps Universel Coordonné) — *timpul universal coordonat*
- ▣ **VIX**: CBOE Volatility Index — *indicele de volatilitate CBOE*

Întrebarea de azi și traseul (1/2)

▣ Întrebarea seminarului

- ▶ **care dintre faptele stilizate ale randamentelor rămân valide atunci când inferența ține cont de cozile groase și de volatility clustering?**

▣ Traseul seminarului

- ▶ noțiuni necesare azi: douăzeci și trei de slide-uri introductive (cursul are loc după seminar)
- ▶ randamente, drawdown și momente: A1, A4(a), B1, A3, B2
- ▶ cozi și dependență: A6, B3, B9, B4
- ▶ un răspuns AI de corectat: C2
- ▶ după curs: A7, B11, A10

Întrebarea de azi și traseul (2/2)

- ▣ Rezultate de obținut
 - ▶ răspunsurile A
 - ▶ cîte o figură și un tabel pentru fiecare exercițiu B
 - ▶ codul corectat din C2
 - ▶ o frază de interpretare pentru fiecare exercițiu
- ▣ Notebook-ul de azi: [deschideți notebook-ul seminarului în Colab](#)
 - ▶ fiecare cerință indică secțiunea din notebook
- ▣ Seminar: drd. Antoaneta Amza, antoaneta.amza@csie.ase.ro

Harta exercițiilor

Exercițiu	Întrebare	Tip	Model
A1	cum se agregă randamentele în timp?	Rezolvat	–
A4(a)	cît de mare este un drawdown?	Propus	A1
B1	cît de groase sînt cozile și cît de robust este kurtosisul?	Rezolvat	–
A3	de la statistică la p-value: JB și Ljung–Box	Rezolvat	–
B2	cît de mare este VaR 1% (Value-at-Risk, valoarea la risc) pentru BET-TR?	Propus	B1
A6	de ce generează volatilitatea aleatoare cozi groase?	Rezolvat	–
B3	sînt randamentele Bitcoin independente?	Rezolvat	–
B9	ce autocorelații rămîn semnificative la inferența robustă?	Rezolvat	–
B4	se apropie randamentele de distribuția Normală cînd orizontul crește?	Propus	B1, B3
C2	ce este greșit într-un răspuns AI?	Propus	A3, B3, B9
După curs	A7 [Rezolvat], B11 [Rezolvat], A10 [Propus] (grosimea cozii, lărgimea benzii ACF)	temă	A6, B9
Pachete de extindere	A1(c), A2, A4(b–e), A5, A8, A9, A11, B1(d), B5–B8, B10, B12–B15, C1, C3 (opționale)	Rezolvat sau Propus	indicat la fiecare cerință

- ▣ **[Rezolvat]:** rezolvarea completă, în slide-uri și în notebook, servește drept model
- ▣ **[Propus]:** se rezolvă individual; rezolvarea se discută la seminar
- ▣ Partea A: derivări pe hîrtie
- ▣ Partea B: verificare și inferență pe date reale, fiecare cu o întrebare de interpretare la final
- ▣ Partea C: întrebări deschise și critica unui răspuns AI

Datele folosite

Serie	Tip de preț	Perioadă	Calendar	Randamente
BET-TR	închidere zilnică	23 sept. 2014 – 18 sept. 2026	zilele de tranzacționare BVB	2 992
Bitcoin	închidere zilnică (USD)	17 sept. 2014 – 18 sept. 2026	în fiecare zi, 24:00 UTC	4 384
EUR/RON	cursul de referință BNR	4 iul. 2005 – 18 sept. 2026	zilele lucrătoare din România	5 352
S&P 500	OHLC zilnic	2 ian. 1990 – 18 sept. 2026	zilele de tranzacționare din SUA	9 245
ETF-ul SPY	OHLC, închidere ajustată (pentru dividende și splituri)	2 ian. 2008 – 18 sept. 2026 (B8)	zilele de tranzacționare din SUA	–
VIX, VIX pe 9 zile	închidere zilnică	doar C3	zilele de tranzacționare din SUA	–

- ▣ Prețurile zilnice din datele cursului, câte o serie pe activ (cîmpul folosit: close / adjusted close)
- ▣ EUR/RON este cursul oficial de referință BNR, nu o serie de cotații de piață
- ▣ Unități: randamentele sînt în zecimale în cod și în % pe slide-uri
- ▣ Calendare: fiecare serie pe propriul calendar
 - ▶ analizele pe mai multe serii aliniază întîi *prețurile* pe zilele comune

Pregătire: rulați și verificați

```
# secțiunea "Date" din notebook definește load_data(name)
closes = {a: load_data(a)['Close'] for a in
           ['sp500', 'bettr', 'btc', 'eurron']}
rets = {a: np.log(c).diff().dropna()
        for a, c in closes.items()}
r_bet, r_btc = rets['bettr'], rets['btc']
r_eur, r_sp = rets['eurron'], rets['sp500']
for a, r in rets.items():
    print(a, r.index[0].date(), len(r))
```

- Rezultat așteptat: data primului randament și numărul de randamente

Serie	primul randament	T
S&P 500	1990-01-03	9 245
BET-TR	2014-09-24	2 992
Bitcoin	2014-09-18	4 384
EUR/RON	2005-07-05	5 352

- Convenții în cod
 - ▶ momente: `scipy.stats.skew` și `kurtosis` (exces de kurtosis, fără corecție de eșantion mic)
 - ▶ abateri standard cu `ddof=1`
 - ▶ cuantile cu `numpy.quantile` (liniar)
- Dacă un număr diferă, opriți-vă și verificați seria, tipul de preț și data de început

Notății folosite în toate exercițiile (1/6): prețuri și randamente

▣ Indicii și prețurile

- ▶ $t = 0, 1, \dots, T$: indicii zilei de tranzacționare; $t - 1$ este ziua precedentă
- ▶ P_t : prețul de închidere din ziua t ; T : numărul de randamente

▣ **Randamentul simplu**: variația relativă a prețului într-o zi

$$R_t = \frac{P_t}{P_{t-1}} - 1$$

▣ **Randamentul logaritm**: logaritmul natural ($\ln$) al raportului dintre prețuri

$$r_t = \ln \frac{P_t}{P_{t-1}} = \ln(1 + R_t)$$

- ▶ $r_t \approx R_t$ pentru variații mici; $r_t < R_t$ ori de câte ori $R_t \neq 0$
- ▶ un exemplu: $P_0 = 100$, $P_1 = 102$: $R_1 = 2,00\%$, $r_1 = \ln 1,02 = 1,98\%$

Notații folosite în toate exercițiile (2/6): media, abaterea standard, standardizarea

- Convenții de scriere

- ▶ notația $\hat{\theta}$: $\hat{\theta}$ este valoarea estimată din eșantion a unei mărimi teoretice θ
- ▶ $\sum_t$: suma după toate zilele $t = 1, \dots, T$

- Media de selecție** $\bar{r} = \frac{1}{T} \sum_t r_t$: randamentul mediu zilnic

- Abaterea standard de selecție** (volatilitatea zilnică): dispersia tipică a randamentelor în jurul mediei

$$\hat{\sigma} = \sqrt{\frac{1}{T-1} \sum_t (r_t - \bar{r})^2}$$

- Randamentul centrat $x_t = r_t - \bar{r}$: abaterea față de medie

- Randamentul standardizat $z_t = (r_t - \bar{r})/\hat{\sigma}$: numărul de abateri standard față de medie

- ▶ $z_t = -3$: o zi cu trei abateri standard sub medie

- i.i.d.**: independente și identic distribuite, ipoteza de referință a testelor clasice

- ▶ randamentul de azi nu depinde de cele trecute, iar distribuția lui este aceeași în fiecare zi

Notății folosite în toate exercițiile (3/6): operatorii probabilistici și distribuția Normală

- ▣ Operatorii probabilistici, pentru o variabilă aleatoare X
 - ▶ $\mathbb{E}X$: media teoretică (speranța matematică); $\text{Var}(X) = \mathbb{E}(X - \mathbb{E}X)^2$: varianța
 - ▶ $\text{Cov}(X, Y)$, $\text{corr}(X, Y)$: covarianța și corelația a două variabile
 - ▶ $P(\cdot)$: probabilitatea unui eveniment

- ▣ **Distribuția Normală** $N(\mu, \sigma^2)$: media μ , varianța σ^2

- ▶ $N(0, 1)$: distribuția Normală standard, cu densitatea și funcția de repartiție

$$\varphi(x) = \frac{1}{\sqrt{2\pi}} e^{-x^2/2}, \quad \Phi(x) = P(Z \leq x) = \int_{-\infty}^x \varphi(u) du$$

- ▶ $Z \sim N(0, 1)$; $\varphi(x)$: înălțimea curbei în x ; $\Phi(x)$: aria de sub curbă la stînga lui x
- ▶ Φ^{-1} : inversa lui Φ , adică cuantilele lui $N(0, 1)$; $\Phi^{-1}(0,975) = 1,96$
- ▶ Z ia valori în $[-1,96; 1,96]$ cu probabilitatea 95%
- ▶ dacă $X \sim N(\mu, \sigma^2)$, atunci $Z = (X - \mu)/\sigma \sim N(0, 1)$

Notății folosite în toate exercițiile (4/6): agregarea în timp și anualizarea

- ▣ **Agregarea în timp:** randamentul pe zilele $1, \dots, n$, de la P_0 la P_n

$$1 + R_{0 \rightarrow n} = \frac{P_n}{P_0} = \prod_{t=1}^n (1 + R_t), \quad r_{0 \rightarrow n} = \ln \frac{P_n}{P_0} = \sum_{t=1}^n r_t$$

- ▶ $\prod$: produsul factorilor; randamentele simple se compun (se înmulțesc factorii $1 + R_t$)
- ▶ randamentele logaritmice se adună: suma este telescopică, $\ln P_n - \ln P_0$
- ▶ între active, într-un portofoliu, se adună ponderat randamentele simple (A1(c))

- ▣ **Anualizarea:** A este numărul de intervale de randament dintr-un an

$$\bar{r}_{\text{an}} = A \bar{r}, \quad \hat{\sigma}_{\text{an}} = \sqrt{A} \hat{\sigma}, \quad \text{deoarece } \text{Var}\left(\sum_{t=1}^A r_t\right) = A \sigma^2$$

- ▶ $A = 252$ (BET-TR, S&P 500, EUR/RON: zilele de tranzacționare), $A = 365$ (Bitcoin, tranzacționat zilnic)
- ▶ $A \sigma^2$ presupune randamente necorelate, cu varianță constantă (A2: cazul autocorelat)
- ▶ exemplu: $\hat{\sigma} = 1\%$ pe zi și $A = 252$: $\hat{\sigma}_{\text{an}} = 15,87 \times 1\% = 15,9\%$

Notății folosite în toate exercițiile (5/6): asimetria, kurtosisul, autocorelația

- ▣ **Asimetria** $\hat{S} = \frac{1}{T} \sum_t z_t^3$: media cuburilor randamentelor standardizate
 - ▶ $\hat{S} = 0$ pentru o distribuție simetrică
 - ▶ $\hat{S} < 0$: pierderile extreme sînt mai mari, în valoare absolută, decît câștigurile extreme
- ▣ **Kurtosisul** $\hat{K} = \frac{1}{T} \sum_t z_t^4$: media puterilor a patra, determinată mai ales de zilele extreme
 - ▶ $\hat{K} = 3$ pentru distribuția Normală
 - ▶ **excesul de kurtosis** $\hat{K} - 3$: 0 pentru distribuția Normală, pozitiv pentru cozi groase
- ▣ **Autocorelația** la lagul k : corelația dintre randamentele aflate la k zile distanță


$$\hat{\rho}_k = \frac{\sum_{t=k+1}^T x_t x_{t-k}}{\sum_{t=1}^T x_t^2}$$

- ▶ $k = 1, 2, \dots$: lagul, în zile; $\hat{\rho}_k \in [-1, 1]$; ρ_k fără $\hat{}$: valoarea teoretică
- ▶ $\hat{\rho}_k > 0$: o zi peste medie tinde să fie urmată, după k zile, de o zi peste medie
- ▶ $\hat{\rho}_k \approx 0$: nicio legătură liniară între randamentele aflate la k zile distanță

Notății folosite în toate exercițiile (6/6): testele statistice

- ▣ Componentele unui test
 - ▶ H_0 : ipoteza nulă, de exemplu “randamentele nu sînt autocorelate”
 - ▶ statistica de test: un număr calculat din date, cu atît mai mare cu cît datele contrazic mai mult H_0
 - ▶ distribuția de referință: distribuția statisticii atunci cînd H_0 este adevărată
- ▣ Distribuția χ_m^2 (hi-pătrat cu m grade de libertate)
 - ▶ distribuția sumei pătratelor a m variabile $N(0, 1)$ independente; media ei este m
 - ▶ valori critice la 5%: 3,84 ($m = 1$), 5,99 ($m = 2$), 11,07 ($m = 5$), 18,3 ($m = 10$)
- ▣ Valoarea critică la 5%: valoarea depășită cu probabilitatea 5% sub H_0
 - ▶ respingem H_0 la pragul de 5% dacă statistica depășește valoarea critică
- ▣ p-value: probabilitatea, sub H_0 , a unei statistici cel puțin la fel de extreme ca cea observată
 - ▶ $p < 0,05$ este echivalent cu depășirea valorii critice de 5%
 - ▶ nu este probabilitatea ca H_0 să fie adevărată

Analiză preliminară: prețuri, randamente și zile extreme



- Fiecare zi extremă corespunde unui eveniment identificabil
 - ▶ taxa pe activele bancare (19 dec. 2018)
 - ▶ crahul din pandemia COVID-19 (martie 2020)
 - ▶ deprecierea leului din 2008
- Perioade calme alternează cu perioade turbulente în toate cele trei serii
- EUR/RON este aproape constant după 2013
- Analiza grafică precede testarea formală

Noțiuni necesare azi (1/23): faptele stilizate

- ▣ Seminarul are loc **înaintea** cursului
 - ▶ aceste douăzeci și trei de slide-uri prezintă doar noțiunile necesare pentru cerințele seminarului
 - ▶ detaliile se găsesc în [Capitolul 1](#), prezentat la cursul care urmează seminarului
- ▣ **Fapt stilizat:** o proprietate statistică comună multor active, piețe și perioade [Cont \(2001\)](#)
- ▣ Cele patru fapte stilizate de azi
 - ▶ **cozi groase:** zilele extreme sînt mai frecvente decît sub distribuția Normală cu aceeași varianță
 - ▶ **volatility clustering:** variațiile mari sînt urmate de variații mari, de orice semn
 - ▶ **lipsa autocorelației liniare:** randamentul de azi nu este o funcție liniară a randamentelor trecute, $\hat{\rho}_k \approx 0$
 - ▶ **gaussianitate prin agregare:** randamentele pe orizonturi mai lungi au cozi mai apropiate de cele ale distribuției Normale

Noțiuni necesare azi (2/23): mersul aleator și mișcarea browniană

- ▣ **Mersul aleator:** logaritmul prețului, $X_t = \ln P_t$, adună șocuri independente

$$X_t = X_{t-1} + r_t, \quad r_t \text{ i.i.d. } N(\mu\Delta, \sigma^2\Delta)$$

- ▶ Δ : lungimea unui pas, în ani (o zi de tranzacționare: $\Delta = 1/252$)
- ▶ μ : drift-ul anual al lui X_t ; σ : volatilitatea anuală
- ▶ reperul față de care se definesc faptele stilizate: randamente i.i.d. cu distribuția Normală

- ▣ **Mișcarea browniană standard** W_t , $t \geq 0$: limita mersului aleator când $\Delta \rightarrow 0$


- ▶ $W_0 = 0$; creșterea $W_t - W_s$, $s < t$, este independentă de trecut și are distribuția $N(0, t - s)$
- ▶ deci $W_t \sim N(0, t)$: abaterea standard crește ca $\sqrt{t}$, iar $|W_t| \leq 1,96\sqrt{t}$ cu probabilitatea 95%

- ▣ **Prețul** ca mișcare browniană geometrică (A4, A5)

$$X_t = X_0 + \mu t + \sigma W_t, \quad P_t = P_0 e^{\mu t + \sigma W_t}$$

- ▶ $P_t > 0$; randamentul logaritm pe un interval de lungime Δ are distribuția $N(\mu\Delta, \sigma^2\Delta)$


Noțiuni necesare azi (3/23): traiectorii simulate ale mișcării browniene



95% band $\pm 1.96\sqrt{t}$ — Simulated paths ---- Median price $100 e^{\mu t}$

- Stînga: cinci traiectorii simulate ale lui W_t pe 5 ani și banda de 95% $\pm 1,96\sqrt{t}$, care se lărgțește ca $\sqrt{t}$
- Dreapta: aceleași traiectorii transformate în prețuri, $P_t = 100 e^{\mu t + \sigma W_t}$, cu $\mu = 0,05$ și $\sigma = 0,20$
 - după 5 ani, prețurile simulate sînt între 54 și 270: incertitudinea crește cu orizontul
 - linia întreruptă $100 e^{\mu t}$ este mediana prețului, deoarece mediana lui W_t este 0

Noțiuni necesare azi (4/23): drawdown-ul



- **Vîrful curent:** cea mai mare valoare atinsă pînă la momentul t

$$M_t = \max_{s \leq t} V_s$$

- ▶ V_t : valoarea portofoliului sau prețul la momentul t

- **Drawdown-ul:** pierderea relativă față de vîrful curent

$$DD_t = \frac{V_t}{M_t} - 1 \leq 0$$

- ▶ $DD_t = 0$ la fiecare nou maxim; graficul lui DD_t este curba underwater

- **Drawdown-ul maxim** $MDD = \min_t DD_t$

- ▶ cea mai mare scădere de la un vîrf la un minim ulterior
- ▶ în grafic: -28,2%, de la punctul verde la punctul roșu

- **CAGR** $= (V_n/V_0)^{1/Y} - 1$: rata anuală constantă de creștere

- ▶ Y : numărul de ani dintre V_0 și V_n

Noțiuni necesare azi (5/23): rapoartele Sharpe, Sortino și Calmar

- ▣ **Raportul Sharpe:** randamentul anual în exces pe unitatea de volatilitate anuală

$$SR = \frac{A \bar{R} - r_f}{\sqrt{A} \hat{\sigma}_R}$$

- ▶ $\bar{R}$, $\hat{\sigma}_R$: media și abaterea standard a randamentelor simple; r_f : rata anuală a dobânzii fără risc
- ▶ $SR = 0,5$: fiecare punct procentual de volatilitate anuală aduce 0,5 puncte procentuale de randament în exces

- ▣ **Raportul Sortino** Sortino & van der Meer (1991): penalizează doar zilele cu pierderi

$$\text{Sortino} = \frac{A \bar{R} - r_f}{\sqrt{A} \hat{\sigma}_D}, \quad \hat{\sigma}_D = \sqrt{\frac{1}{T} \sum_{t=1}^T \min(R_t, 0)^2}$$

- ▶ $\hat{\sigma}_D$: semiabaterea inferioară; zilele cu $R_t \geq 0$ contribuie cu 0
- ▶ Sortino > Sharpe atunci când pierderile sînt mai mici sau mai rare decît cîștigurile

- ▣ **Raportul Calmar** = CAGR/|MDD| (slide-ul anterior)

- ▶ creșterea anuală pe unitatea de pierdere maximă de la un vîrf
- ▶ depinde de un singur episod, deci este o măsură descriptivă, fără o eroare standard simplă


Noțiuni necesare azi (6/23): momentele și puterea a patra

- ▣ **Momentul de ordinul k :** media puterii k
 - ▶ pentru randamente: $\mathbb{E}[r^k]$; pentru randamentele standardizate $z = (r - \mu)/\sigma$: $\mathbb{E}[z^k]$
 - ▶ $k = 1$: media; $k = 2$: varianța; $k = 3$: asimetria S ; $k = 4$: kurtosisul K
 - ▶ **moment de ordinul patru finit:** $\mathbb{E}[r^4] < \infty$; altfel $\hat{K}$ nu se stabilizează când T crește
- ▣ **Kurtosisul de selecție:** media puterilor a patra ale randamentelor standardizate

$$\hat{K} = \frac{1}{T} \sum_{t=1}^T z_t^4, \quad z_t = \frac{r_t - \bar{r}}{\hat{\sigma}}$$

- ▶ $\hat{K} = 3$ pentru distribuția Normală; **excesul de kurtosis** $\hat{K} - 3 > 0$ indică cozi groase
- ▣ De ce puterea a patra măsoară cozile
 - ▶ contribuția unei zile crește foarte repede cu $|z_t|$: $1^4 = 1$, $2^4 = 16$, $3^4 = 81$, $10^4 = 10\,000$
 - ▶ deci $\hat{K}$ este determinat de zilele extreme, nu de zilele obișnuite
 - ▶ o zi cu $z_t = 10$ adaugă singură $10^4/T$ la $\hat{K}$: pentru $T = 2\,500$, adică $+4$

Noțiuni necesare azi (7/23): contribuția zilelor extreme la kurtosis



- Stînga: contribuția unei singure zile la $\sum_t z_t^2$ (varianța) și la $\sum_t z_t^4$ (kurtosisul), pe scală logaritmică
 - ▶ o zi cu $|z_t| = 5$ contează de 25 de ori mai mult decât o zi cu $|z_t| = 1$ în varianță, dar de 625 de ori mai mult în kurtosis
- Dreapta: un eșantion simulat cu cozi groase, $T = 2500$; ponderea celor mai mari zile în cele două sume
 - ▶ cele mai mari 10 zile (0,4% din zile) dau 9% din $\sum_t z_t^2$, dar 40% din $\sum_t z_t^4$
 - ▶ de aceea $\hat{K}$ se schimbă mult când se elimină câteva zile (B1)

Noțiuni necesare azi (8/23): cuantilele și o măsură robustă a cozilor

- ▣ **Cuantila** de ordin p , notată q_p : valoarea sub care se află fracțiunea p a randamentelor

$$q_p = F^{-1}(p), \quad F(x) = P(r_t \leq x)$$

- ▶ F : funcția de repartiție; empiric, q_p este valoarea de pe poziția pT în randamentele sortate crescător
- ▶ $q_{0,5}$ este mediana; $q_{0,25}$ și $q_{0,75}$ sînt cuantilele

- ▣ Alternativa robustă [Kim & White \(2004\)](#): excesul de kurtosis Crow–Siddiqui pe cuantile

$$\frac{q_{0,975} - q_{0,025}}{q_{0,75} - q_{0,25}} - 2,91$$

- ▶ numărătorul: lățimea intervalului care conține 95% din zile; numitorul: lățimea celor 50% din mijloc
- ▶ 2,91 este valoarea raportului pentru distribuția Normală, deci măsura este 0 pentru distribuția Normală
- ▶ valoare pozitivă: cozile sînt mai lungi, față de partea centrală, decît la distribuția Normală
- ▶ depinde doar de cuantile, deci cîteva zile extreme o modifică foarte puțin

Noțiuni necesare azi (9/23): testul Jarque–Bera

- ▣ **Jarque–Bera** Jarque & Bera (1980): măsoară cât de departe sînt asimetria și excesul de kurtosis de valorile distribuției Normale, ambele egale cu 0

$$JB = T \left[\frac{\hat{S}^2}{6} + \frac{(\hat{K} - 3)^2}{24} \right]$$

- ▶ 6 și 24: varianțele lui $\sqrt{T} \hat{S}$ și $\sqrt{T}(\hat{K} - 3)$ sub H_0 , pentru T mare
- ▶ fiecare termen este, așadar, pătratul unei variabile aproximativ $N(0, 1)$
- ▶ $JB \geq 0$, iar $JB = 0$ doar dacă $\hat{S} = 0$ și $\hat{K} = 3$
- ▣ H_0 : randamente i.i.d. cu distribuția Normală
 - ▶ sub H_0 , $JB \sim \chi^2_2$ pentru T mare (doi termeni); valoarea critică la 5% este 5,99
 - ▶ un JB mare: asimetria sau cozile sînt incompatibile cu distribuția Normală
- ▣ Exemplu: $T = 1\,000$, $\hat{S} = 0$, $\hat{K} = 6$: $JB = 1\,000 \times 9/24 = 375 > 5,99$, respingem H_0

Noțiuni necesare azi (10/23): Value-at-Risk și distribuția Normală

- ▣ **Value-at-Risk (VaR) 1%** pe o zi: pragul de pierdere depășit cu probabilitatea de 1%

$$P(L_t > \text{VaR}_\alpha) = \alpha, \quad L_t = -r_t, \quad \text{VaR}_\alpha = -q_\alpha$$

- ▶ L_t : pierderea zilei t ; α : nivelul VaR, aici $1\% = 0,01$
- ▶ q_α : cuantila de ordin α a randamentului; semnul minus transformă cuantila, negativă, într-o pierdere pozitivă
- ▶ VaR nu este pierderea maximă: în aproximativ 1% din zile pierderea îl depășește, iar VaR nu spune cu cât

- ▣ Dacă randamentul are distribuția Normală $N(\mu, \sigma^2)$


$$q_\alpha = \mu + \sigma \Phi^{-1}(\alpha)$$

- ▶ $\Phi^{-1}(0,01) = -2,326$: 1% din valorile unei variabile $N(0, 1)$ sînt sub $-2,326$
- ▶ exemplu: $\mu = 0,05\%$, $\sigma = 1\%$: $q_{0,01} = 0,05 - 2,326 = -2,28\%$, deci $\text{VaR } 1\% = 2,28\%$

- ▣ **VaR empiric**: minus cuantila de selecție de 1%

- ▶ pe eșantionul pe care a fost estimat este depășit, prin construcție, în 1% din zile

Noțiuni necesare azi (11/23): cuantila și VaR pe o densitate



- Density of $r_t \sim N(\mu, \sigma^2)$
- Left tail, probability $\alpha = 1\%$
- - - Quantile $q_{0.01} = -2.28\%$
- Mean $\mu = 0.05\%$

□ **Densitatea** f : aria de sub curbă între a și b este $P(a < r_t \leq b)$; aria totală este 1

□ Densitatea distribuției Normale $N(\mu, \sigma^2)$

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$$

► simetrică în jurul lui μ ; lățimea este dată de σ

□ **Cuantila** $q_{0,01}$: punctul care lasă la stînga o arie de 1% (zona roșie)

$$\int_{-\infty}^{q_{0,01}} f(x) dx = 0,01$$

□ **VaR 1%** = $-q_{0,01}$: distanța de la 0 la cuantilă, exprimată ca pierdere pozitivă

► $\mu = 0,05\%$, $\sigma = 1\%$: $q_{0,01} = -2,28\%$, VaR 1% = 2,28% (exemplul de pe slide-ul anterior)

► cu cozi mai groase, aria de 1% se află mai departe la stînga, iar VaR crește (B2)

Noțiuni necesare azi (12/23): distribuția Student- t

- ▣ **Student- t** cu $\nu > 0$ grade de libertate: o distribuție simetrică, cu cozi mai groase decât distribuția Normală
 - ▶ $P(|X| > x)$ descrește proporțional cu $x^{-\nu}$ când x crește: cu cât ν este mai mic, cu atât cozile sînt mai groase
 - ▶ pentru $\nu \rightarrow \infty$ se obține distribuția Normală
- ▣ Momentele: $\mathbb{E}|X|^p$ este finit doar pentru $p < \nu$
 - ▶ varianța există pentru $\nu > 2$ și este egală cu $\nu/(\nu - 2)$; kurtosisul există pentru $\nu > 4$
- ▣ Cuantilele: $t_{\nu}^{-1}(\alpha)$ este cuantila de ordin α a distribuției Student- t standard
 - ▶ $t_3^{-1}(0,01) = -4,54$
 - ▶ standardizată la varianță unitară (împărțită la $\sqrt{3/(3-2)} = \sqrt{3}$): $-4,54/\sqrt{3} = -2,62$, mai extremă decât $-2,33$, cuantila distribuției Normale
- ▣ Estimarea: prin verosimilitate maximă, pentru variabila $m + sY$, cu Y Student- t standard
 - ▶ m : parametrul de locație (centrul); $s > 0$: parametrul de scală (lățimea); `scipy.stats.t.fit`

Noțiuni necesare azi (13/23): densitatea Student- t și tail index-ul

- ▣ **Densitatea Student- t standard** cu ν grade de libertate

$$f_{\nu}(x) = \frac{\Gamma(\frac{\nu+1}{2})}{\sqrt{\nu\pi} \Gamma(\frac{\nu}{2})} \left(1 + \frac{x^2}{\nu}\right)^{-\frac{\nu+1}{2}}$$

- ▶ Γ : funcția gamma, $\Gamma(n) = (n-1)!$ pentru n întreg; fracția din față face ca aria totală să fie 1
- ▶ pentru $|x|$ mare, $f_{\nu}(x)$ descrește ca $|x|^{-(\nu+1)}$, o putere a lui $|x|$
- ▶ densitatea Normală descrește ca $e^{-x^2/2}$, mult mai repede: de aici diferența dintre cozi

- ▣ **Tail index-ul** α : viteza cu care scade probabilitatea unei mișcări mari


$$P(|r_t| > x) \propto x^{-\alpha}, \quad x \text{ mare}$$

- ▶ α : proporțional cu; un α mic înseamnă cozi groase; pentru Student- t , $\alpha = \nu$
- ▶ $\mathbb{E}|r_t|^p$ este finit doar pentru $p < \alpha$: cu $\alpha \leq 4$, kurtosisul nu există

- ▣ După curs

- ▶ A7 și B11 estimează α cu estimatorul Hill; A10 derivă varianța lui $\hat{\rho}_k$

Noțiuni necesare azi (14/23): distribuția Normală și Student- t cu aceeași varianță



- Stînga: $N(0, 1)$ și Student- t cu $\nu = 3$, rescalată la varianța 1 (împărțită la $\sqrt{3}$)
 - aceeași varianță, dar Student- t are vârful mai înalt, flancurile mai subțiri și cozile mai groase (zoom)
- Dreapta: $P(|X| > k)$ pe scală logaritmică
 - $k = 3$: 1,4% pentru Student- t , față de 0,27% pentru distribuția Normală, de 5 ori mai probabil
 - $k = 5$: 0,32% față de 0,00006%, de peste 5 000 de ori mai probabil


Noțiuni necesare azi (15/23): ACF și testul Ljung–Box

- ▣ **ACF** (funcția de autocorelație): șirul $\hat{\rho}_k$, $k = 1, 2, \dots$, reprezentat în funcție de lag
 - ▶ pentru randamente i.i.d. $\hat{\rho}_k \approx N(0, 1/T)$, deci abaterea standard a lui $\hat{\rho}_k$ este $1/\sqrt{T}$
 - ▶ banda de 95%: $\pm 1,96/\sqrt{T}$ ($T = 2\,500$: $\pm 0,039$); un $\hat{\rho}_k$ în afara ei este semnificativ la 5%
- ▣ **Volatility clustering** în ACF: $|r_t|$ și r_t^2 sînt autocorelate, deși r_t nu este
- ▣ **Ljung–Box** [Ljung & Box \(1978\)](#): testează împreună primele m autocorelații

$$Q(m) = T(T+2) \sum_{k=1}^m \frac{\hat{\rho}_k^2}{T-k}$$

- ▶ m : numărul de laguri testate; $H_0: \rho_1 = \dots = \rho_m = 0$
- ▶ pentru randamente i.i.d., $Q(m) \sim \chi_m^2$; un Q peste valoarea critică: cel puțin o autocorelație nenulă
- ▶ aplicat pe r_t , testează predictibilitatea liniară; aplicat pe r_t^2 , testează prezența volatility clustering

Noțiuni necesare azi (16/23): ACF pentru zgomot i.i.d. și pentru volatility clustering



- Seria din dreapta, simulată: $r_t = \sigma_t \varepsilon_t$, $\sigma_t^2 = 0,05 + 0,10 r_{t-1}^2 + 0,85 \sigma_{t-1}^2$, ε_t i.i.d. $N(0, 1)$
 - o zi cu $|r_{t-1}|$ mare crește volatilitatea de azi: alternează perioade calme și turbulente
- ACF a lui r_t rămîne în banda $\pm 1,96/\sqrt{T} = \pm 0,039$ ($T = 2\,500$) pentru ambele serii
- ACF a lui $|r_t|$: în bandă pentru zgomotul i.i.d., mult peste bandă pentru seria din dreapta (0,16 la lagul 1)

Noțiuni necesare azi (17/23): testul ARCH-LM

- ▣ **ARCH-LM Engle (1982)**: testează dacă pătratul randamentului de azi depinde de pătratele trecute, adică volatility clustering

- ▣ Regresia auxiliară, estimată prin OLS

$$x_t^2 = a_0 + a_1 x_{t-1}^2 + \cdots + a_q x_{t-q}^2 + u_t$$

- ▶ q : numărul de laguri; $a_0, \dots, a_q$: coeficienții; u_t : eroarea
- ▶ $H_0: a_1 = \cdots = a_q = 0$, adică fără volatility clustering
- ▣ Statistica $LM = (T - q)R^2$, comparată cu χ_q^2
 - ▶ $R^2 \in [0, 1]$: proporția din variația lui x_t^2 explicată de pătratele trecute
 - ▶ $T - q$: numărul de observații folosite în regresie
 - ▶ exemplu: $T = 1000$, $q = 5$, $R^2 = 0,02$: $LM = 995 \times 0,02 = 19,9 > 11,07$, valoarea critică la 5% a lui χ_5^2 : există volatility clustering

Noțiuni necesare azi (18/23): mixtura de distribuții Normale

- ▣ **Mixtură de distribuții Normale Clark (1973):** randamentul este un șoc Normal scalat de o volatilitate aleatoare

$$r_t = \sigma_t \varepsilon_t$$


- ▶ ε_t : șocul, i.i.d. $N(0, 1)$ și independent de σ_t
- ▶ $\sigma_t > 0$: volatilitatea zilei t , ea însăși aleatoare (de exemplu, după ritmul sosirii informației)

- ▣ Kurtosisul teoretic al lui r_t

$$K = \frac{\mathbb{E}r^4}{(\mathbb{E}r^2)^2} = \frac{3\mathbb{E}\sigma^4}{(\mathbb{E}\sigma^2)^2} \geq 3$$

- ▶ 3 este $\mathbb{E}\varepsilon^4$, kurtosisul distribuției $N(0, 1)$
- ▶ $K = 3$ doar dacă σ_t este constantă; cu cât σ_t variază mai mult, cu atât K este mai mare
- ▶ cozi groase generate de șocuri cu distribuția Normală (A6)

Noțiuni necesare azi (19/23): o mixtură de două distribuții Normale



--- calm days: $0.7 \times N(0, 0.6^2)$

--- turbulent days: $0.3 \times N(0, 1.6^2)$

— Mixture (kurtosis 5.9)

— Normal, same variance 1.02 (kurtosis 3)

- Zile calme, cu probabilitatea 0,7: $\sigma_t = 0,6$; zile turbulente, cu probabilitatea 0,3: $\sigma_t = 1,6$

$$f(x) = 0,7 \varphi_{0,6}(x) + 0,3 \varphi_{1,6}(x), \quad \varphi_s(x) = \frac{1}{s} \varphi\left(\frac{x}{s}\right)$$

- ▶ φ_s : densitatea lui $N(0, s^2)$; varianța mixturii $0,7 \times 0,6^2 + 0,3 \times 1,6^2 = 1,02$; $K = 3 \mathbb{E}\sigma^4 / (\mathbb{E}\sigma^2)^2 = 5,9$
- ▶ mai multe zile foarte mici și mai multe zile foarte mari decât la distribuția Normală cu aceeași varianță
- ▶ $P(|r_t| > 4)$: 0,37% în mixtură, față de 0,0075% pentru distribuția Normală

Noțiuni necesare azi (20/23): inferența în prezența volatility clustering

- Când există volatility clustering, $\text{Var}(\hat{\rho}_k) > 1/T$
 - ▶ banda $\pm 1,96/\sqrt{T}$ este prea îngustă, iar $Q(m)$ respinge H_0 prea des
- Varianța lui $\hat{\rho}_k$ se estimează direct din date [Lobato, Nankervis & Savin \(2001\)](#)

$$\hat{\tau}_k = \frac{\sum_{t>k} x_t^2 x_{t-k}^2}{(\sum_t x_t^2)^2}$$


- ▶ pentru randamente i.i.d. $\hat{\tau}_k \approx 1/T$; $T\hat{\tau}_k$ arată de câte ori varianța lui $\hat{\rho}_k$ depășește $1/T$
- ▶ banda robustă $\pm 1,96\sqrt{\hat{\tau}_k}$
- Ljung–Box robust (B9): fiecare $\hat{\rho}_k^2$ este împărțit la propria varianță estimată

$$\tilde{Q}(m) = \sum_{k=1}^m \frac{\hat{\rho}_k^2}{\hat{\tau}_k}$$

- ▶ același H_0 ca $Q(m)$, comparat tot cu χ_m^2
- ▶ exemplu: $T\hat{\tau}_1 = 4$ implică o bandă robustă de $\sqrt{4} = 2$ ori mai largă decât $\pm 1,96/\sqrt{T}$

Noțiuni necesare azi (21/23): gaussianitatea prin agregare

- **Randamentul logaritm pe h zile:** suma a h randamente zilnice consecutive, $r_t^{(h)} = r_t + r_{t-1} + \dots + r_{t-h+1}$
 - ▶ h : orizontul, în zile; κ : excesul de kurtosis al randamentului zilnic
 - ▶ pentru randamente i.i.d., excesul de kurtosis pe h zile este $\kappa/h \rightarrow 0$: suma se apropie de distribuția Normală




- **Randamente zilnice simulate i.i.d. cu cozi groase ($\kappa = 6$), însumate pe $h = 1, 5, 20$ zile și standardizate**
 - ▶ excesul de kurtosis scade de la 6 la 1,2 și la 0,3; coada (dreapta) se apropie de cea a distribuției Normale
 - ▶ cu volatility clustering, apropierea este mai lentă decât κ/h (B4)

Noțiuni necesare azi (22/23): QQ plot-ul

- **QQ plot:** cuantilele datelor față de cuantilele distribuției $N(0, 1)$, câte un punct pentru fiecare z_i

$$\left(\Phi^{-1}\left(\frac{i - 0,5}{T}\right), z_{(i)} \right), \quad i = 1, \dots, T$$


- $z_{(1)} \leq \dots \leq z_{(T)}$: randamentele standardizate sortate crescător; $(i - 0,5)/T$: proporția corespunzătoare



--- 45-degree line: perfect Normal fit ○ Normal: points on the line ○ Heavy tails: S-shape

- Pe dreapta de 45 de grade: distribuția Normală (stînga); formă de S: cozi groase (dreapta, Student- t cu $\nu = 3$)
 - coada stîngă sub dreaptă, coada dreaptă deasupra ei: cuantilele extreme ale datelor depășesc cuantilele Normale

Noțiuni necesare azi (23/23): range-ul zilnic și volatilitatea Parkinson



- Pentru pachetele de extindere (A5, B8)
- O_t, H_t, L_t, C_t : deschiderea, maximul, minimul și închiderea zilei t
 - ▶ cu litere mici, logaritmi lor: $o_t = \ln O_t, h_t = \ln H_t, l_t = \ln L_t, c_t = \ln C_t$
- **Range-ul logaritm** $h_t - l_t = \ln(H_t/L_t)$: amplitudinea zilei
 - ▶ folosește maximul și minimul traiectoriei, nu doar prețul de închidere
 - ▶ în grafic: range-ul este 2,58%, iar $c_t - o_t$ doar 1,01%
- **Estimatorul Parkinson** [Parkinson \(1980\)](#)

$$\hat{\sigma}_P^2 = \frac{1}{4 \ln 2} \cdot \frac{1}{n} \sum_{t=1}^n (h_t - l_t)^2$$

- ▶ n : numărul de zile; $\hat{\sigma}_P^2$: varianța zilnică estimată
- ▶ $4 \ln 2 = 2,77$: pentru o mișcare browniană fără drift, $\mathbb{E}[(h_t - l_t)^2] = 4 \ln 2 \sigma^2$

A1 [Rezolvat]: randamente și anualizare — cerința

▣ Întrebări

- ▶ ce randament se adună în timp?
- ▶ cum se anualizează mărimile zilnice?

▣ Date de intrare

- ▶ o acțiune închide la 100, 110, 99, 104,5 în zilele 0–3 și nu plătește dividend
- ▶ un indice are un randament logaritmic mediu zilnic de 0,04% și o volatilitate zilnică de 1,2%
- ▶ Bitcoin are o volatilitate zilnică de 3,5%
- ▶ randamentele sînt necorelate serial, cu varianță constantă

▣ Cerințe

1. Calculați cele trei randamente simple R_t și cele trei randamente logaritmice r_t , toate în %.
2. Calculați randamentele pe 3 zile $P_3/P_0 - 1$ și $\ln(P_3/P_0)$ și comparați-le cu $\sum_t R_t$ și $\sum_t r_t$.
3. Anualizați randamentul logaritmic mediu și volatilitatea indicelui cu $A = 252$.
4. Anualizați volatilitatea Bitcoin și justificați alegerea lui A .

▣ **De raportat:** un tabel cu coloanele zi, preț, R_t , r_t și cele trei valori anualizate


▣ Notebook: secțiunea A1

A1 [Rezolvat]: rezolvare

t	P_t	R_t	r_t
0	100	—	—
1	110	+10,00%	+9,53%
2	99	-10,00%	-10,54%
3	104,5	+5,56%	+5,41%
sumă		5,56%	4,40%
$0 \rightarrow 3$		4,50%	4,40%

- Randamentele logaritmice se însumează telescopic la $\ln(104,5/100)$

- Randamentele simple se compun:
 $1,1 \times 0,9 \times 1,0556 - 1 = 4,5\%$



- Indice

- ▶ randamentul logaritmic mediu anualizat
 $252 \times 0,04\% = 10,08\%$
- ▶ volatilitatea $\sqrt{252} \times 1,2\% = 15,87 \times 1,2\% = 19,05\%$
- Bitcoin se tranzacționează zilnic: $\sqrt{365} \times 3,5\% = 66,9\%$
- ▶ cu $\sqrt{252}$ s-ar obține 55,6%, cu 17% mai puțin

A4(a) [Propus]: amplitudinea unui drawdown — cerința

▣ **Model:** A1 [Rezolvat]; secțiunea A4 din notebook

▣ **Întrebări**

- ▶ care este cea mai mare pierdere față de un vîrf anterior?
- ▶ cum se raportează aceasta la rata anuală de creștere?

▣ **Date de intrare**

- ▶ valorile portofoliului la sfîrșit de an $V_0, \dots, V_5 = 100, 120, 90, 110, 130, 117$
- ▶ CAGR pe 5 ani $(V_5/V_0)^{1/5} - 1 = 3,19\%$: rata anuală constantă care duce V_0 la V_5

▣ **Cerințe:** completați tabelul

1. Calculați vîrfurile $M_t = \max_{s \leq t} V_s$, cel mai mare V_s din anii $s = 0, \dots, t$.
2. Calculați drawdown-ul $DD_t = V_t/M_t - 1 \leq 0$, pierderea relativă față de vîrf.
3. Determinați drawdown-ul maxim $MDD = \min_t DD_t$ și anul în care apare.
4. Calculați raportul Calmar $CAGR/|MDD|$, creșterea anuală pe unitatea de pierdere maximă.

Anul	0	1	2	3	4	5
V_t	100	120	90	110	130	117
M_t	100	120	...	...	...	...
DD_t	0%	0%	...	...	...	...

▣ **Interpretare:** de ce scăderea la 117 din anul 5 nu este drawdown-ul maxim?

B1 [Rezolvat]: statistici descriptive — cerința

▣ Întrebări

- ▶ cît de groase sînt cozile BET-TR, Bitcoin și EUR/RON?
- ▶ în ce măsură depinde kurtosisul de cîteva zile extreme?

▣ Date: r_bet , r_btc , r_eur din secțiunea de pregătire

- ▶ $T = 2\,992, 4\,384, 5\,352$; $A = 252, 365, 252$

▣ Cerințe

1. Calculați media, abaterea standard, volatilitatea anualizată, asimetria, excesul de kurtosis, minimul și maximul fiecărei serii.
2. Calculați $JB = T[\hat{S}^2/6 + (\hat{K} - 3)^2/24]$ și cei doi termeni ai săi.
3. Comparați JB cu 5,99, valoarea critică la 5% a lui χ^2_2 .
4. Recalculați fiecare exces de kurtosis după eliminarea zilei cu cel mai mare $|r_t|$ și după eliminarea celor mai mari cinci.
5. Recalculați excesul de kurtosis Crow–Siddiqui pe cuantile, $\frac{q_{0,975} - q_{0,025}}{q_{0,75} - q_{0,25}} = 2,91$, pe aceleași eșantioane reduse (q_p : cuantila de ordin p ; 0 pentru distribuția Normală).

▣ De raportat: un tabel pentru pașii 1–3 și un grafic al kurtosisului în funcție de numărul de zile eliminate


▣ Interpretare: ce măsură a grosimii cozilor puteți raporta cu încredere?

B1 [Rezolvat]: rezolvare (1/2) — BET-TR pas cu pas

- Pasul 1: $\bar{r} = 0,077\%$, $\hat{\sigma} = 0,978\%$, volatilitatea $\sqrt{252} \times 0,978\% = 15,5\%$
 - ▶ $\hat{S} = -1,40$, $\hat{K} - 3 = 17,79$
 - ▶ cea mai mare scădere zilnică, $-11,86\%$, pe 19 dec. 2018 (taxa pe activele bancare)
 - ▶ cea mai mare creștere zilnică, $+6,71\%$, pe 24 dec. 2018
- Pasul 2: $JB = 40\,433$
 - ▶ termenul de asimetrie $2\,992 \times 1,40^2/6 = 977$
 - ▶ termenul de kurtosis $2\,992 \times 17,79^2/24 = 39\,455$, 98% din statistică
- Pasul 3: $40\,433 > 5,99$, $p < 10^{-10}$
- Pasul 4: exces de kurtosis 17,8 cu toate zilele
 - ▶ 11,8 fără 19 dec. 2018
 - ▶ 5,95 fără cele mai mari cinci zile: 19 dec. 2018, 16 mar. 2020, 9 mar. 2020, 24 dec. 2018, 9 mar. 2022
- Pasul 5: Crow–Siddiqui 1,06 cu toate zilele, 1,01 fără cele mai mari cinci zile
- O singură zi generează o treime din kurtosisul calculat pe momente
 - ▶ măsura bazată pe cuantile rămîne practic neschimbată

	BET-TR	Bitcoin	EUR/RON
Medie (% pe zi)	0,077	0,118	0,007
Abatere std. (% pe zi)	0,978	3,485	0,279
Volatilitate (% pe an)	15,5	66,6	4,4
Asimetrie	-1,40	-0,70	0,73
Exces de kurtosis	17,8	12,0	15,1
Min (%)	-11,9	-46,5	-2,5
Max (%)	6,7	22,5	2,9
JB	40 433	26 482	51 575
Fără cele 5 zile extreme	5,95	4,24	11,17

B1 [Rezolvat]: rezolvare (2/2) — sensibilitatea kurtosisului



- Toate statisticile JB depășesc de peste 4 000 de ori valoarea critică 5,99
- Bitcoin fără ziua de 12 mar. 2020: kurtosis 12,0 → 5,3
- Interpretare: cozile sînt groase conform ambelor măsuri
 - ▶ raportați excesul de kurtosis pe cuantile, care nu depinde de cîteva zile extreme

A3 [Rezolvat]: Jarque–Bera și Ljung–Box, pas cu pas — cerința

▣ Întrebări

- ▶ cum se trece de la o statistică de test la o decizie?
- ▶ pe ce ipoteze se sprijină decizia?

▣ Date de intrare: două eșantioane ipotetice de randamente zilnice; teste la pragul de 5%

- ▶ eșantionul 1: $T = 2500$, asimetria $\hat{S} = -0,5$, kurtosisul $\hat{K} = 8$ (nu excesul)
- ▶ eșantionul 2: $T = 1000$, $\hat{\rho}_1 = 0,10$, $\hat{\rho}_2 = -0,05$, $\hat{\rho}_3 = 0,03$

▣ Cerințe

1. Calculați cei doi termeni ai $JB = T[\hat{S}^2/6 + (\hat{K} - 3)^2/24]$ Jarque & Bera (1980), statistica și $p = P(\chi_2^2 \geq JB)$.
2. Calculați cei trei termeni ai $Q(3) = T(T+2) \sum_{k=1}^3 \hat{\rho}_k^2 / (T-k)$ Ljung & Box (1978), statistica și $p = P(\chi_3^2 \geq Q)$.
3. Formulați H_0 pentru fiecare test.
4. Identificați, pentru fiecare distribuție de referință χ^2 , ipoteza care nu mai este satisfăcută în prezența volatility clustering.


▣ De raportat: termenii, cele două statistici, p-value-urile și deciziile

▣ Notebook: secțiunea A3

A3 [Rezolvat]: rezolvare (1/2) — pas cu pas

1. $\hat{S}^2/6 = 0,25/6 = 0,042$; $(\hat{K} - 3)^2/24 = 25/24 = 1,042$
 - ▶ $JB = 2500 \times 1,084 = 2708,3$, $p < 10^{-10}$: respingem H_0
 - ▶ 96% din JB este termenul de kurtosis
2. $0,01/999 = 1,001 \times 10^{-5}$, $0,0025/998 = 0,251 \times 10^{-5}$, $0,0009/997 = 0,090 \times 10^{-5}$
 - ▶ $Q(3) = 1000 \times 1002 \times 1,342 \times 10^{-5} = 13,44$, $p = 0,004$: respingem H_0
3. H_0 pentru fiecare test
 - ▶ JB: randamente i.i.d. cu distribuția Normală
 - ▶ Ljung–Box: absența autocorelației
4. Distribuția de referință χ^2_3 a testului Ljung–Box presupune, în plus, randamente i.i.d.
 - ▶ în prezența volatility clustering $\text{Var}(\hat{p}_k) > 1/T$, iar Q respinge prea des (A10, B9)

A3 [Rezolvat]: rezolvare (2/2) — distribuțiile de referință



- p-value-ul este aria de sub densitatea χ^2 la dreapta statisticii observate
- Interpretare: pentru un eșantion i.i.d. ambele respingeri sînt valide
 - ▶ pentru randamente cu volatility clustering doar respingerea prin JB a ipotezei "i.i.d. și distribuție Normală" este validă
 - ▶ în acest caz, p-value-ul lui Q(3) este subestimat

B2 [Propus]: cozi groase și VaR 1% pe BET-TR — cerința (1/2)

- ▣ **Model:** B1 [Rezolvat]; secțiunea B2 din notebook
- ▣ **Întrebare:** cât de mare este VaR 1% pe o zi, adică pragul de pierdere depășit cu probabilitatea de 1%, sub trei ipoteze de distribuție?
- ▣ **Date:** r_{bet} , $T = 2\,992$
 - ▶ modelele sînt estimate și verificate pe **același** eșantion: comparația este descriptivă
 - ▶ nu este un backtesting (verificarea VaR pe date ulterioare estimării)
- ▣ **Cerințe**
 1. Standardizați $z_t = (r_t - \bar{r})/\hat{\sigma}$ și numărați zilele cu $|z_t| > 3$.
 2. Comparați ponderea lor cu ponderea teoretică sub distribuția Normală, $P(|Z| > 3) = 0,27\%$ pentru $Z \sim N(0, 1)$.
 3. Estimați o distribuție Student- t pentru z_t prin verosimilitate maximă (`scipy.stats.t.fit`: grade de libertate ν , locație m , scală s).

B2 [Propus]: cozi groase și VaR 1% pe BET-TR — cerința (2/2)

▣ Cerințe (continuare)

4. Calculați $\text{VaR}_{1\%} = -q_r$, cu $q_r = \bar{r} + \hat{\sigma}q_z$, pentru trei variante ale cuantilei de 1%.

- q_z : cuantila de 1% a lui z_t ; q_r : aceeași cuantilă exprimată în randamente (inversa standardizării)
- Student- t : $q_z = m + s t_{\nu}^{-1}(0,01)$, cu t_{ν}^{-1} cuantila Student- t standard
- distribuția Normală: $q_z = \Phi^{-1}(0,01) = -2,326$
- empiric: q_r = cuantila de 1% a lui r_t

5. Numărați depășirile (zilele cu $r_t < q_r$, adică cu o pierdere mai mare decât VaR) și comparați-le cu numărul așteptat 0,01 $T = 29,9$.

▣ **De raportat:** un tabel metodă / VaR / depășiri și un grafic al cozii stîngi cu cele trei cuantile

▣ **Interpretare:** de ce are VaR-ul empiric, prin construcție, circa 30 de depășiri?

A6 [Rezolvat]: kurtosisul unei mixturi de volatilitate — cerința


- ▣ **Întrebare:** poate volatilitatea aleatoare să genereze, singură, cozi groase?
- ▣ **Ipoteze:** $r_t = \sigma_t \varepsilon_t$, ε_t i.i.d. $N(0, 1)$ și independent de σ_t
 - ▶ σ_t : volatilitatea aleatoare a zilei t ; ε_t : șocul standardizat
 - ▶ $\sigma_t = 1\%$ cu probabilitatea 0,8 și 2% cu probabilitatea 0,2
 - ▶ σ_t este extras **independent în fiecare zi**
- ▣ **Cerințe**
 1. Folosind independența și $\mathbb{E}\varepsilon^4 = 3$, arătați că kurtosisul teoretic (nu excesul) este $K = \mathbb{E}r^4 / (\mathbb{E}r^2)^2 = 3 \mathbb{E}\sigma^4 / (\mathbb{E}\sigma^2)^2$.
 2. Completați un tabel cu cele două stări: probabilitatea, σ^2 (în $\%^2$) și σ^4 (în $\%^4$).
 3. Calculați $\mathbb{E}\sigma^2$, $\mathbb{E}\sigma^4$ și K .
 4. Folosiți inegalitatea lui Jensen, $\mathbb{E}[X^2] \geq (\mathbb{E}X)^2$ cu $X = \sigma^2$, pentru a arăta că $K \geq 3$.
 5. Stabiliți dacă acest model produce volatility clustering.
- ▣ **De raportat:** tabelul, K și excesul de kurtosis
- ▣ **Interpretare:** puneți rezultatul în legătură cu ipoteza mixturii de distribuții a lui [Clark \(1973\)](#)
- ▣ Notebook: secțiunea A6

A6 [Rezolvat]: rezolvare (1/2) — momente

Stare	Prob.	σ^2	σ^4
calmă	0,8	1	1
turbulentă	0,2	4	16
medie		1,6	4,0

1. $\mathbb{E}r^4 = \mathbb{E}\sigma^4 \mathbb{E}\varepsilon^4 = 3 \mathbb{E}\sigma^4$ și $\mathbb{E}r^2 = \mathbb{E}\sigma^2$
2. Tabelul din stînga
3. $\mathbb{E}\sigma^2 = 1,6$, $\mathbb{E}\sigma^4 = 4,0$
 - $K = 3 \times 4,0 / 1,6^2 = 12 / 2,56 = 4,69$; excesul de kurtosis 1,69
4. $\mathbb{E}[(\sigma^2)^2] \geq (\mathbb{E}\sigma^2)^2$, cu egalitate doar pentru σ constant: $K \geq 3$
5. Fără volatility clustering: stările sînt independente de la o zi la alta
 - deci $|r_t|$ este necorelat
 - în A8, stările devin persistente

A6 [Rezolvat]: rezolvare (2/2) — densități




- $P(|r_t| > 4\%)$: 0,92% în mixtură, 0,16% pentru distribuția Normală cu aceeași varianță
- Interpretare: timpul operațional aleator (ritmul sosirii informației) al lui [Clark \(1973\)](#) este o astfel de mixtură
 - variabilitatea volatilității generează cozi groase

B3 [Rezolvat]: necorelate, dar nu independente (Bitcoin) — cerința

- ▣ **Întrebare:** conțin randamentele trecute ale Bitcoin informație despre direcția sau doar despre mărimea randamentului curent?
- ▣ **Date:** r_{btc} , 18 sept. 2014 – 18 sept. 2026, $T = 4\,384$
- ▣ **Cerințe**
 1. Reprezentați grafic randamentele.
 2. Reprezentați grafic ACF pentru r_t , $|r_t|$ și r_t^2 la lagurile 1–100, cu banda de referință i.i.d. $\pm 1,96/\sqrt{T} = \pm 0,030$.
 3. Calculați Ljung–Box $Q(10)$ pe r_t și pe r_t^2 (acorr_ljungbox), cu p-value-uri din χ_{10}^2 .
 4. Aplicați testul ARCH-LM cu 5 laguri [Engle \(1982\)](#).
 - regresați x_t^2 pe o constantă și pe $x_{t-1}^2, \dots, x_{t-5}^2$
 - comparați $(T-5)R^2$ cu χ_5^2
- ▣ **De raportat:** graficul, autocorelațiile la lagul 1 și cele trei statistici
 - ▶ fiecare însoțită de seria analizată și de ipoteza H_0
- ▣ **Interpretare:** $Q(10)$ pe r_t are $p \approx 3\%$
 - ▶ ținând cont de pasul 4, este validă distribuția lui de referință i.i.d.?
- ▣ Notebook: secțiunea B3

B3 [Rezolvat]: rezolvare (1/2) — randamente și ACF



- Direcția: ACF a lui r_t nu prezintă nicio structură
- Mărimea: $|r_t|$ și r_t^2 sînt autocorelate pe zeci de laguri

B3 [Rezolvat]: rezolvare (2/2) — teste

2. $\hat{\rho}_1$: $-0,022$ pentru r_t (în interiorul benzii), $0,213$ pentru $|r_t|$ și $0,137$ pentru r_t^2
3. Rezultatele $Q(10)$
 - ▶ pe r_t : $20,2$, $p = 0,028$
 - ▶ pe r_t^2 : $212,7$, $p \approx 4 \times 10^{-40}$
4. ARCH-LM(5) = $114,7$, $p \approx 4 \times 10^{-23}$
 - ▶ distribuția sa de referință χ^2 presupune $\mathbb{E}r^4 < \infty$, deci p-value-ul are doar valoare orientativă
- ▣ Valorile absolute ale randamentelor sînt dependente în timp: randamentele nu sînt i.i.d.
 - ▶ p-value-ul de 2,8% al lui $Q(10)$ pe r_t se bazează pe o ipoteză încălcată
- ▣ Banda i.i.d. este doar un reper, nu un test valid pentru $|r_t|$ și r_t^2
 - ▶ A10 și B9 corectează inferența pentru r_t

B9 [Rezolvat]: Ljung–Box robust la heteroscedasticitate — cerința (1/2)

▣ **Întrebare:** ce autocorelații ale randamentelor rămân semnificative atunci când varianța lui $\hat{\rho}_k$ este corectată pentru volatility clustering?

▣ **Date:** $r_{sp}, r_{bet}, r_{eur}, r_{btc}$; $x_t = r_t - \bar{r}$

▣ **Cerințe**

1. Pentru $k = 1, \dots, 20$ calculați $\hat{\rho}_k$ și $\hat{\tau}_k = \sum_{t=k+1}^T x_t^2 x_{t-k}^2 / (\sum_{t=1}^T x_t^2)^2$ Lobato, Nankervis & Savin (2001), varianța estimată a lui $\hat{\rho}_k$.
2. Reprezentați $\hat{\rho}_k$ cu banda clasică $\pm 1,96/\sqrt{T}$ și banda robustă $\pm 1,96\sqrt{\hat{\tau}_k}$.
3. Calculați $Q(10)$ clasic și $\tilde{Q}(10) = \sum_{k=1}^{10} \hat{\rho}_k^2 / \hat{\tau}_k$ robust.
4. Comparați-le cu χ_{10}^2 , a cărei valoare critică la 5% este 18,3.
5. Numărați lagurile dintre 1 și 20 aflate în afara fiecărei benzi.
 - sînt verificări punctuale, diferite de testul conjunct pe 10 laguri de la pașii 3–4

B9 [Rezolvat]: Ljung–Box robust la heteroscedasticitate — cerința (2/2)

▣ Ipotezele lui $\tilde{Q}$


- ▶ un moment de ordinul patru finit, $\mathbb{E}r^4 < \infty$, necesar pentru ca $\hat{\tau}_k$ să estimeze o varianță finită
- ▶ termeni încrucișați nuli, $\mathbb{E}[x_t^2 x_{t-k} x_{t-l}] = 0$ pentru $k \neq l$
- ▶ adică x_t^2 nu este corelat cu produsele $x_{t-k} x_{t-l}$ ale randamentelor trecute de la laguri diferite

▣ Interpretare

- ▶ pentru ce serii rămîne semnificativă autocorelația?
- ▶ este credibilă ipoteza momentului de ordinul patru?

▣ Notebook: secțiunea B9

B9 [Rezolvat]: rezolvare (1/3) — ACF cu ambele benzi



- S&P 500, lagul 1: $\hat{\rho}_1 = -0,079$, $T\hat{\tau}_1 = 5,00$
 - varianța lui $\hat{\rho}_1$ este de 5 ori mai mare decât valoarea i.i.d. $1/T$
 - banda robustă este $1,96\sqrt{5,00/9\,245} = 0,046$, nu 0,020
- La lagul 1, banda robustă este de $\sqrt{T\hat{\tau}_1}$ ori mai largă decât cea clasică: de la 1,7 ori (Bitcoin) pînă la 2,6 ori (EUR/RON)

B9 [Rezolvat]: rezolvare (2/3) — teste conjuncte și interpretare

	S&P 500	BET-TR	EUR/RON	Bitcoin
$Q(10)$ (p)	91,6 ($< 10^{-10}$)	70,0 ($< 10^{-10}$)	221,7 ($< 10^{-10}$)	20,2 (0,028)
$\tilde{Q}(10)$ (p)	19,0 (0,041)	16,9 (0,076)	37,4 ($< 0,001$)	11,9 (0,29)
Laguri în afara benzii, clasic / robust	8 / 3	5 / 2	6 / 2	3 / 0
Laguri în afara benzii robuste	1, 15, 16	2, 10	1, 3	niciunul

- La 5%, testul clasic respinge H_0 pentru toate cele patru serii
 - ▶ testul robust respinge doar pentru S&P 500 (la limită) și EUR/RON
- Bitcoin (B3): p-value-ul de 2,8% devine 29%
 - ▶ nicio dovadă de autocorelație liniară la lagurile 1–10
- Pentru EUR/RON rămîne semnificativă autocorelația $\hat{\rho}_1 = 0,17$
 - ▶ în regimul de managed float, cursul de referință BNR se ajustează prin variații mici, distribuite pe mai multe zile

B9 [Rezolvat]: rezolvare (3/3) — ipotezele de verificat

- ▣ Termeni încrucișați nuli
 - ▶ testul lui [Dalla, Giraitis & Phillips \(2022\)](#) păstrează doar termenii încrucișați semnificativi
 - ▶ nu găsește niciunul pentru S&P 500, BET-TR și Bitcoin
- ▣ Moment de ordinul patru finit
 - ▶ dacă $P(|r_t| > x)$ descrește proporțional cu $x^{-\nu}$ cu $\nu \leq 4$, $\mathbb{E}r^4$ este infinit
 - ▶ atunci p-value-urile robuste nu sînt valide
 - ▶ A7 și B11 estimează acest tail index după curs

B4 [Propus]: gaussianitate prin agregare (Bitcoin) — cerința

- ▣ **Model:** B1 și B3 [Rezolvat]; secțiunea B4 din notebook
- ▣ **Întrebare:** se apropie randamentele Bitcoin pe h zile de distribuția Normală când h crește?
- ▣ **Date:** r_btc , $T = 4\,384$, în blocuri care nu se suprapun, începînd cu prima zi
 - ▶ primul bloc de 5 zile este 18–22 sept. 2014, al doilea 23–27 sept. 2014
 - ▶ ultimul bloc incomplet (4 zile pentru $h = 5$ și $h = 20$) se elimină
- ▣ **Cerințe**
 1. Construiți randamentele logaritmice pe h zile (sume de h randamente zilnice consecutive) pentru $h = 1, 5, 20$.
 2. Reprezentați un QQ plot al fiecărei serii standardizate față de distribuția Normală, cu N , numărul de blocuri, în titlu.
 3. Calculați excesul de kurtosis și SE de referință pentru date i.i.d. cu distribuția Normală, $\sqrt{24/N}$.
 - $\sqrt{24/N}$: eroarea standard a excesului de kurtosis estimat din N observații i.i.d. Normale (24, ca în JB)
- ▣ **De raportat:** cele trei QQ plot-uri și un tabel h , N , exces de kurtosis, $\sqrt{24/N}$
- ▣ **Interpretare**
 - ▶ de ce subestimează $\sqrt{24/N}$ incertitudinea în acest caz?
 - ▶ de ce blocurile disjuncte nu au zile comune, dar nu elimină dependența volatilității?

C2 [Propus]: critica unui răspuns AI — răspunsul

- **Promptul** trimis unui asistent AI: “Sînt randamentele logaritmice zilnice ale BET-TR distribuite Normal? Sînt autocorelate? Dă cod Python și o concluzie”
- **Răspunsul:** codul de mai jos și concluzia

```
from scipy import stats
from statsmodels.stats.diagnostic import acorr_ljungbox
r = np.log(bet["close"]).diff().dropna()      # daily log returns
k = stats.kurtosis(r)                          # sample kurtosis
print("excess_kurtosis:", k - 3)               # the Normal has kurtosis 3
jb, p = stats.jarque_bera(r)
lb = acorr_ljungbox(r**2, lags=[10])          # Ljung-Box, 10 lags
```

- **Concluzia asistentului**
 - ▶ “Exces de kurtosis 14,8: cozi groase”
 - ▶ “p-value JB 0,000: probabilitatea ca randamentele BET-TR să urmeze distribuția Normală este 0%”
 - ▶ “Ljung-Box $Q(10) = 713,5$, $p < 0,001$: randamentele sînt puternic autocorelate, deci BET-TR este predictibil și nu este un mers aleator”

C2 [Propus]: critica unui răspuns AI — cerința (1/2)

▣ **Model:** A3, B3 și B9 [Rezolvat]; secțiunea C2 din notebook

▣ **Date:** `r_bet`, cele 2 992 de randamente din pregătire

▣ **Cerințe**

1. Identificați toate erorile de fond din cod și din cele trei concluzii.
2. Pentru fiecare eroare, precizați cum poate fi detectată.
 - un test pe date simulate sau o valoare din slide-urile introductive
 - un exercițiu rezolvat sau documentația bibliotecii
3. Scrieți codul corectat, în formă executabilă.

C2 [Propus]: critica unui răspuns AI — cerința (2/2)

▣ Cerințe (continuare)

4. Raportați excesul de kurtosis, JB cu p-value-ul său, $Q(10)$ pe r_t și pe r_t^2 și $\tilde{Q}(10)$ robust din B9.
5. Formulați ipotezele din spatele p-value-ului robust.
6. Scrieți concluzia corectată în trei fraze.

▣ De raportat

- ▶ codul corectat
- ▶ un tabel valoare AI / valoare corectă
- ▶ un grafic al ACF pentru r_t și r_t^2

▣ Codul generat de AI se execută de obicei fără mesaje de eroare

- ▶ erorile sînt de natură statistică, nu sintactică
- ▶ consemnați erorile identificate în `AI_ERRORS.md`

A7 [Rezolvat]: estimatorul Hill, pas cu pas — cerința (1/2)

▣ Întrebări

- ▶ cum se estimează un tail index din cele mai mari observații?
- ▶ cât de precisă este estimarea?

- ▣ **Date de intrare:** cele mai mari 11 randamente zilnice absolute (%) ale unui eșantion ipotetic: 12,0; 9,5; 8,2; 7,4; 6,9; 6,1; 5,8; 5,5; 5,2; 5,0; 4,8

▣ Notatii

- ▶ $X_{(1)} \geq X_{(2)} \geq \dots$: valorile absolute ordonate descrescător (statisticile de ordine)
- ▶ k : numărul de observații din coadă; $X_{(k+1)}$: pragul de la care începe coada

- ▣ **Ipoteză:** peste pragul $X_{(k+1)}$, coada urmează o distribuție Pareto, $P(X > x) \propto x^{-\alpha}$

- ▶ α : tail index-ul; un α mic înseamnă o coadă groasă; $\mathbb{E}|X|^p$ este finit doar pentru $p < \alpha$
- ▶ observațiile sînt independente

A7 [Rezolvat]: estimatorul Hill, pas cu pas — cerința (2/2)

- Estimatorul Hill Hill (1975): inversul mediei log-rapoartelor dintre cele mai mari k valori și prag

$$\hat{\alpha} = \left(\frac{1}{k} \sum_{i=1}^k \ln \frac{X_{(i)}}{X_{(k+1)}} \right)^{-1}$$

► o coadă groasă are log-rapoarte mari, deci un $\hat{\alpha}$ mic


- Cerințe**

- Pentru $k = 10$ calculați log-rapoartele $\ln(X_{(i)}/X_{(11)})$, media lor și $\hat{\alpha} = 1/\text{medie}$.
- Calculați eroarea standard $SE = \hat{\alpha}/\sqrt{k}$ (valabilă pentru observații i.i.d.) și intervalul de 95% $\hat{\alpha} \pm 1,96 SE$.
- Precizați ce momente $\mathbb{E}|X|^p$ ($p < \alpha$) există dacă α este egal cu estimarea punctuală.
- Precizați care dintre aceste concluzii rămân valabile la nivelul de încredere de 95%.
- Repetăți pașii 1–2 pe cele mai mari 11 valori $|r_t|$ ale BET-TR, folosind tabelul afișat de notebook.

- De raportat:** $\hat{\alpha}$, SE și intervalul pentru ambele eșantioane

- Notebook: secțiunea A7

A7 [Rezolvat]: rezolvare (1/2) — eșantionul ipotetic



1. Etichetele din grafic sînt log-rapoartele față de pragul 4,8: suma 3,616, media 0,3616, $\hat{\alpha} = 1/0,3616 = 2,77$
2. $SE = 2,77/\sqrt{10} = 0,87$; intervalul $[1,05; 4,48]$
 ► o aproximare grosieră prin distribuția Normală, valabilă pentru cozi Pareto i.i.d.
3. Pentru $\alpha = 2,77$, varianța este finită, iar momentul de ordinul patru este infinit
4. Intervalul conține valori sub 2 și peste 4: nicio concluzie nu este susținută la 95%

A7 [Rezolvat]: rezolvare (2/2) — tabelul BET-TR

i	Data	r_t (%)	$X_{(i)}$ (%)	$\ln(X_{(i)}/X_{(11)})$
1	19 dec. 2018	-11,857	11,857	0,824
2	16 mar. 2020	-10,075	10,075	0,661
3	9 mar. 2020	-7,827	7,827	0,409
4	24 dec. 2018	+6,707	6,707	0,254
5	9 mar. 2022	+6,662	6,662	0,247
6	24 aug. 2015	-6,512	6,512	0,225
7	24 mar. 2020	+5,972	5,972	0,138
8	17 mar. 2020	+5,928	5,928	0,131
9	4 mar. 2022	-5,490	5,490	0,054
10	12 mar. 2020	-5,285	5,285	0,016
11	18 ian. 2016	-5,202	5,202	prag

- Calculul pentru primul rând:
 $\ln(11,857/5,202) = \ln 2,279 = 0,824$
- Suma celor zece log-raapoarte este 2,958;
 $\hat{\alpha}_{10} = 10/2,958 = 3,38$
- $SE = 3,38/\sqrt{10} = 1,07$; intervalul $[1,28; 5,48]$
- Șapte dintre cele zece zile se situează în decembrie 2018 sau în martie 2020
 - ▶ valorile extreme sînt grupate în timp, deci SE calculată sub ipoteza i.i.d. subestimează incertitudinea
- Interpretare: zece observații nu sînt suficiente pentru a stabili dacă momentul de ordinul patru există
 - ▶ B11 folosește $k = 2\%$ din n

B11 [Rezolvat]: estimatorul Hill pe ambele cozi, BET-TR și Bitcoin — cerința (1/2)

- ▣ **Întrebare:** sînt pierderile mari mai frecvente decît câștigurile mari de aceeași mărime?
- ▣ **Date:** r_{bet} ($n = 2\,992$), r_{btc} ($n = 4\,384$)
 - ▶ pierderi $\text{loss} = -r[r < 0]$, câștiguri $\text{gain} = r[r > 0]$
 - ▶ fiecare serie ordonată descrescător
- ▣ **Notății**
 - ▶ $\hat{\alpha}(k)$: estimatorul Hill din A7, calculat cu cele mai mari k valori ale unei cozi
 - ▶ $\hat{\alpha}_-$: tail index-ul pierderilor; $\hat{\alpha}_+$: tail index-ul câștigurilor; $\hat{\alpha}_- < \hat{\alpha}_+$ înseamnă că pierderile au coada mai groasă
 - ▶ $[\cdot]$: partea întreagă
- ▣ **Cerințe**
 1. Reprezentați grafic estimarea Hill $\hat{\alpha}(k)$ pentru fiecare coadă, pentru k între 1% și 10% din n (volumul întregului eșantion), cu banda $\hat{\alpha}(1 \pm 1,96/\sqrt{k})$.
 2. Calculați $\hat{\alpha}_-$ și $\hat{\alpha}_+$ la $k = \lfloor 0,02 n \rfloor$ (BET-TR 59, Bitcoin 87), cu intervale de 95%.
 - cursul folosește $k = 2,5\%$ din n pentru $|r_t|$, care combină ambele cozi

B11 [Rezolvat]: estimatorul Hill pe ambele cozi, BET-TR și Bitcoin — cerința (2/2)

▣ Cerințe (continuare)

3. Calculați statistica aproximativă pentru cozi independente și p-value-ul ei bilateral.

$$z = \frac{\hat{\alpha}_- - \hat{\alpha}_+}{\sqrt{\hat{\alpha}_-^2/k + \hat{\alpha}_+^2/k}}$$

- numitorul: eroarea standard a diferenței, din $SE = \hat{\alpha}/\sqrt{k}$ pentru fiecare coadă
- sub $H_0: \alpha_- = \alpha_+$, $z \approx N(0, 1)$; $|z| > 1,96$: respingem H_0 la 5%


4. Comparați rezultatele cu $\hat{\nu}$ al distribuției Student- t estimate pe randamentele standardizate: 3,10 pentru BET-TR (B2), 2,23 pentru Bitcoin.

▣ Interpretare

- ▶ este asimetria dintre câștiguri și pierderi semnificativă statistic?
- ▶ gruparea în timp a valorilor extreme crește sau reduce SE adevărată?

▣ Notebook: secțiunea B11

B11 [Rezolvat]: rezolvare (1/2) — graficele Hill și estimările



□ BET-TR: $\hat{\alpha}_- = 2,19$ [1,63; 2,75], $\hat{\alpha}_+ = 3,08$ [2,30; 3,87]

□ Bitcoin: $\hat{\alpha}_- = 2,89$ [2,28; 3,50], $\hat{\alpha}_+ = 3,62$ [2,86; 4,38]

□ De exemplu, pierderile BET-TR: $2,19 \times (1 \pm 1,96/\sqrt{59}) = 2,19 \times (1 \pm 0,255)$

B11 [Rezolvat]: rezolvare (2/2) — testul și interpretarea

- ▣ BET-TR: $\sqrt{2,19^2/59 + 3,08^2/59} = \sqrt{0,0812 + 0,1612} = 0,492$; $z = (2,19 - 3,08)/0,492 = -1,82$, $p = 0,069$
- ▣ Bitcoin: $\sqrt{2,89^2/87 + 3,62^2/87} = 0,497$; $z = (2,89 - 3,62)/0,497 = -1,47$, $p = 0,14$
- ▣ Decizie: coada pierderilor este mai groasă pe ambele piețe, dar $H_0: \alpha_- = \alpha_+$ nu este respinsă la 5%
 - ▶ statistica tratează cele două cozi ca eșantioane independente
 - ▶ valorile extreme sînt grupate în timp, deci SE adevărată este mai mare, iar evidența statistică mai slabă
 - ▶ un bootstrap pe blocuri aplicat simultan ambelor cozi, pe randamentele originale, păstrează ambele caracteristici (extindere)
- ▣ $\hat{\nu}$ este estimat pe întreaga distribuție, pe cînd $\hat{\alpha}$ folosește doar coada
 - ▶ valoarea 2,23 pentru Bitcoin este sub ambele tail index-uri
 - ▶ Student- t nu poate descrie simultan partea centrală și cozile

A10 [Propus]: lărgirea benzii autocorelației în prezența volatility clustering — cerința (1/2)

- ▣ **Model:** A6 [Rezolvat]; secțiunea A10 din notebook
- ▣ **Cadru:** $x_t = \sigma_t \varepsilon_t$, cu ε_t i.i.d. $N(0, 1)$, independent de procesul staționar al volatilității
 - ▶ în acest caz, x_t este necorelat serial
 - ▶ $\text{Var}(\hat{\rho}_1) \approx v_1/T$, cu $v_1 = \mathbb{E}[x_t^2 x_{t-1}^2] / (\mathbb{E}x_t^2)^2$ [Lobato, Nankervis & Savin \(2001\)](#)
 - ▶ v_1 : factorul cu care volatility clustering crește varianța lui $\hat{\rho}_1$ față de valoarea i.i.d. $1/T$
- ▣ **Date de intrare**
 - ▶ A6: $\mathbb{E}\sigma^2 = 1,6$, $\text{Var}(\sigma^2) = 4,0 - 1,6^2 = 1,44$ (în %⁴)
 - ▶ regimuri persistente (A8): $\text{Cov}(\sigma_t^2, \sigma_{t-1}^2) = \lambda \text{Var}(\sigma^2)$ cu $\lambda = 0,875$
 - ▶ $\lambda \in [0, 1)$: persistența regimurilor; $\lambda = 0$: stări independente de la o zi la alta
 - ▶ S&P 500: $T = 9\,245$, $\hat{\rho}_1 = -0,079$, $T\hat{\tau}_1 = 5,00$

A10 [Propus]: lărgirea benzii autocorelației în prezența volatility clustering — cerința (2/2)

▣ Cerințe

1. Arătați că $v_1 = 1$ pentru mixtura din A6, ale cărei stări sînt independente de la o zi la alta.
2. Arătați că $v_1 = 1 + \lambda \text{Var}(\sigma^2)/(\mathbb{E}\sigma^2)^2$ pentru regimuri persistente.
3. Calculați v_1 și factorul de lărgire a benzii $\sqrt{v_1}$.
4. Calculați statistica $t = \hat{\rho}_1/\text{SE}$ pentru autocorelația de lag 1 a S&P 500 cu SE i.i.d. $1/\sqrt{T}$ și cu SE robustă $\sqrt{\hat{\tau}_1}$ ($|t| > 1,96$: semnificativă la 5%).
5. Calculați cele două semilățimi ale benzii de 95%.

▣ **Interpretare:** ce factor lărgeste banda: cozile groase sau volatilitatea persistentă?

După curs: cerințele rămase

- Aceste trei cerințe folosesc instrumente introduse în [Capitolul 1](#)
 - ▶ A7 [Rezolvat] și B11 [Rezolvat]: estimatorul Hill al tail index-ului, pas cu pas și pe ambele cozi
 - ▶ A10 [Propus]: volatility clustering, nu cozile groase, lărgeste banda autocorelației din B9
- Rezolvați-le după curs, înaintea seminarului următor
- Rezolvarea A10 se discută la seminarul următor

Pachete de extindere: conținut și cunoștințe necesare

Pachet	Exerciții	Cunoștințe necesare
1. Aritmetica randamentelor și drawdown	A1(c) [Rezolvat], A2, A4(b–e)	A1, A4(a)
2. Mixturi, regimuri și cozi	A5 [Rezolvat], A8, A9, A11	A6, A7, A10
3. Momente robuste și verificarea modelelor	B1(d) [Rezolvat], B10, B14	B1, B9, B11
4. Dependență și asimetrie	B5, B12, B6, B15	B3, B9
5. Randament ajustat la risc și estimatori de volatilitate bazați pe range	B7, B13, B8	A1, A5, B1
6. Proiecte	C1, C3	B9, studiul de caz din curs

- Secțiunile din notebook poartă aceleași etichete ca exercițiile
- Rezolvările exercițiilor [Propus] se discută la seminarul următor

A1(c) [Rezolvat]: randamentul unui portofoliu — cerința și rezolvarea

- ▣ **Întrebare:** ce randament se agregă liniar între active?
- ▣ **Date de intrare:** un portofoliu investit 60% în activul A și 40% în activul B, pe o zi; $R_A = +5\%$, $R_B = -2\%$
- ▣ **Cerințe**
 1. Calculați randamentul simplu al portofoliului $R_p = 0,6R_A + 0,4R_B$.
 2. Calculați randamentul logaritmic ponderat $0,6 r_A + 0,4 r_B$, cu $r_A = \ln(1 + R_A)$, $r_B = \ln(1 + R_B)$.
 3. Calculați randamentul logaritmic adevărat al portofoliului $\ln(1 + R_p)$.
- ▣ **Rezolvare**
 1. $R_p = 0,6 \times 5\% + 0,4 \times (-2\%) = 2,20\%$
 2. $0,6 \times \ln 1,05 + 0,4 \times \ln 0,98 = 0,6 \times 4,879\% - 0,4 \times 2,020\% = 2,119\%$
 3. $\ln 1,022 = 2,176\%$
- ▣ Interpretare: randamentele simple se agregă liniar între active, cele logaritmice în timp (A1)
 - ▶ pentru variații zilnice, diferența dintre cele două reguli este mică
 - ▶ pentru variații mari, diferența devine importantă

A2 [Propus]: regula $\sqrt{h}$ în prezența autocorelației — cerința (1/2)

- ▣ **Model:** A1 [Rezolvat]; secțiunea A2 din notebook
- ▣ **Ipoteză:** randamentele urmează un proces AR(1) staționar

$$r_t = \rho r_{t-1} + e_t, \quad |\rho| < 1$$

- ▶ e_t : șoc necorelat în timp, cu media 0
- ▶ ρ : coeficientul autoregresiv, egal cu autocorelația de lag 1; $\rho > 0$: randamentele de același semn tind să se succedă
- ▶ $\text{Var}(r_t) = \sigma^2$; autocovarianța la lagul j este $\gamma_j = \text{Cov}(r_t, r_{t-j}) = \sigma^2 \rho^j$, iar $\gamma_0 = \sigma^2$
- ▣ **Regula $\sqrt{h}$:** varianța randamentului pe h zile este $h\sigma^2$, adevărat doar pentru randamente necorelate
- ▣ **Raportul varianțelor:** $VR(h) = \text{Var}(\sum_{j=1}^h r_{t+j}) / (h\sigma^2)$
 - ▶ $VR(h) = 1$ pentru randamente necorelate; $VR(h) > 1$ pentru $\rho > 0$, deci regula $\sqrt{h}$ subestimează riscul
- ▣ **Punct de plecare, $h = 3$:** $\text{Var}(r_1 + r_2 + r_3) = 3\gamma_0 + 2(2\gamma_1 + \gamma_2)$: două perechi la lagul 1, o pereche la lagul 2

A2 [Propus]: regula $\sqrt{h}$ în prezența autocorelației — cerința (2/2)

▣ Cerințe

1. Generalizați numărul de perechi: arătați că $\text{Var}(\sum_{j=1}^h r_{t+j}) = h\sigma^2[1 + 2\sum_{j=1}^{h-1}(1 - j/h)\rho^j]$.
2. Folosind $\sum_{j=1}^{h-1} \rho^j = \rho(1 - \rho^{h-1})/(1 - \rho)$ și $\sum_{j \geq 1} j|\rho|^j = |\rho|/(1 - |\rho|)^2$, arătați că $VR(h) \rightarrow (1 + \rho)/(1 - \rho)$ când $h \rightarrow \infty$.
3. Calcul ilustrativ: calculați $\sqrt{VR(252)}$ și volatilitățile anuale corectate, tratând autocorelațiile de selecție la lagul 1 drept parametri AR(1).
 - EUR/RON: $\rho = 0,170$, volatilitate 4,44%
 - S&P 500: $\rho = -0,079$, volatilitate 17,99%
4. Explicați de ce volatility clustering, singur, nu modifică rezultatul de la pasul 1.

▣ **Interpretare:** ce verificare a ACF trebuie făcută înaintea pasului 3?

A4(b–e) [Propus]: un reper pentru drawdown — cerința (1/2)

- ▣ **Model:** A4(a); secțiunea A4 din notebook
- ▣ **Ipoteză:** logaritmul prețului este $X_t = \mu t + \sigma W_t$
 - ▶ W_t este o mișcare browniană standard: creșteri independente, $W_t \sim N(0, t)$
 - ▶ μ : drift-ul anual al logaritmului prețului; σ : volatilitatea anuală; T : orizontul, în ani
 - ▶ drawdown-ul maxim logaritm $D = \max_{s \leq t \leq T} (X_s - X_t) = -\ln(1 + MDD)$: cea mai mare scădere a lui X de la un vîrf s la un moment ulterior t
 - ▶ pentru $\mu = 0$: $\mathbb{E}[D] = \sqrt{\pi/2} \sigma \sqrt{T}$ Magdon-Ismail et al. (2004), cu $\sqrt{\pi/2} = 1,2533$
- ▣ **Date de intrare:** aur spot, 1990–2026
 - ▶ $\sigma = 16,3\%$, $T = 36,7$ ani, randament logaritm mediu $6,5\%$ pe an
 - ▶ MDD observat = $-44,7\%$, deci $D = 0,592$

A4(b–e) [Propus]: un reper pentru drawdown — cerința (2/2)

▣ Cerințe

1. Folosiți $W(cT) \stackrel{d}{=} \sqrt{c} W(T)$ pentru a explica de ce $\mathbb{E}[D]$ este proporțional cu $\sqrt{T}$ când $\mu = 0$ ($c > 0$: factorul de scalare a timpului; $\stackrel{d}{=}$: aceeași distribuție).
2. Calculați raportul valorilor $\mathbb{E}[D]$ pentru 40 și 10 ani ai aceluiași proces.
3. Calculați reperul fără drift pentru aur și comparați-l cu D observat.
4. Simulați 2 000 de traiectorii zilnice (seed 42) cu $\mu = 0$ și cu $\mu = 6,5\%$.
5. Reprezentați media lui D în funcție de T , pentru ambele valori ale drift-ului.

- ▣ **Interpretare:** ce implică pașii 1–5 pentru rapoartele Calmar calculate pe eșantioane de lungimi diferite?

A5 [Rezolvat]: volatilitatea Parkinson și eficiența ei — cerința (1/2)

- ▣ **Întrebare:** câtă informație despre volatilitate conține range-ul zilnic?
- ▣ **Notatii**
 - ▶ O_t, H_t, L_t, C_t : deschiderea, maximum, minimum și închiderea zilei t
 - ▶ logaritmi lor: $o_t = \ln O_t, h_t = \ln H_t, l_t = \ln L_t, c_t = \ln C_t$
 - ▶ range-ul logaritmic: $h_t - l_t = \ln(H_t/L_t)$
- ▣ **Date de intrare:** H/L pentru cinci zile: 1,020, 1,015, 1,030, 1,010, 1,025; $A = 252$
- ▣ **Ipoteză:** pe parcursul zilei, logaritmul prețului este o mișcare browniană fără drift, cu volatilitatea σ
 - ▶ fără salturi peste noapte
- ▣ **Estimatorul Parkinson** [Parkinson \(1980\)](#): varianța zilnică estimată din range

$$\hat{\sigma}_P^2 = \frac{\overline{(h-l)^2}}{4 \ln 2}$$

- ▶ $\overline{(h-l)^2}$: media pe zile a pătratelor range-ului
- ▶ $4 \ln 2 = 2,7726$: sub ipoteză, $\mathbb{E}[(h-l)^2] = 4 \ln 2 \sigma^2$, deci împărțirea face estimatorul nedeplasat

A5 [Rezolvat]: volatilitatea Parkinson și eficiența ei — cerința (2/2)

▣ Cerințe


1. Completați un tabel cu cinci rînduri: $\ln(H/L)$, pătratul său și media pătratelor.
2. Calculați $\hat{\sigma}_P^2$, volatilitatea zilnică și cea anuală.
3. Precizați ce informație nu este folosită de estimator.
4. Explicați ce efect are un drift puternic asupra estimării.
5. Folosind $\mathbb{E}[(h-l)^2] = 4 \ln 2 \sigma^2$ și $\mathbb{E}[(h-l)^4] = 9\zeta(3) \sigma^4$, comparați varianța zilnică a lui $(h-l)^2/(4 \ln 2)$ cu $\text{Var}(r_t^2) = 2\sigma^4$.
 - $\zeta(3) = \sum_{n \geq 1} n^{-3} = 1,202$: funcția zeta a lui Riemann în punctul 3
 - r_t^2 : estimatorul close-to-close al varianței zilnice, dintr-un randament cu distribuția $N(0, \sigma^2)$
 - estimatorul cu varianța mai mică este mai eficient: are nevoie de mai puține zile pentru aceeași precizie

▣ Notebook: secțiunea A5

A5 [Rezolvat]: rezolvare (1/2) — estimarea

H/L	$\ln(H/L)$	pătrat ($\times 10^{-4}$)
1,020	0,0198	3,92
1,015	0,0149	2,22
1,030	0,0296	8,74
1,010	0,0100	0,99
1,025	0,0247	6,10
medie		4,39

- $\hat{\sigma}_P^2 = 0,000439/2,7726 = 0,000158$; $\hat{\sigma}_P = 1,26\%$ pe zi, $1,26\% \times 15,87 = 20,0\%$ pe an
- Informație nefolosită: deschiderea și saltul de peste noapte Yang & Zhang (2000)
- Un drift lărgeste range-ul și introduce o deplasare pozitivă în $\hat{\sigma}_P$ Rogers & Satchell (1991)



- O zi simulată: range-ul $h_t - l_t$ folosește întreaga traiectorie, randamentul close-to-close doar valorile de la capete

A5 [Rezolvat]: rezolvare (2/2) — eficiența

5. $\text{Var}((h - l)^2) = (9\zeta(3) - 16(\ln 2)^2)\sigma^4 = (10,819 - 7,687)\sigma^4 = 3,131\sigma^4$

- ▶ după împărțirea la $(4 \ln 2)^2 = 7,687$: $0,407\sigma^4$ pe zi pentru termenul Parkinson
- ▶ close-to-close: $\text{Var}(r_t^2) = 3\sigma^4 - \sigma^4 = 2\sigma^4$ pe zi

- Pentru o medie pe n zile independente, ambele varianțe se împart la n

- ▶ raportul rămîne $2/0,407 = 4,9$

- Range-ul unei zile conține aproximativ informația a cinci zile de randamente close-to-close

- Interpretare: câștigul de eficiență presupune tranzacționare continuă, fără drift și fără salturi peste noapte

- ▶ un stale open (deschidere calculată din prețuri ale componentelor încă netranzacționate) afectează estimatorii care folosesc deschiderea
- ▶ adică Garman–Klass, Rogers–Satchell și Yang–Zhang, nu Parkinson (B8)

A8 [Propus]: originea autocorelației lui r_t^2 — cerința (1/2)

- ▣ **Model:** A6 [Rezolvat] și A10; secțiunea A8 din notebook
- ▣ **Ipoteză:** ca în A6, $\sigma_t^2 \in \{1, 4\}$ (în %²), cu probabilitățile staționare (0,8; 0,2)
 - ▶ dar starea urmează un lanț Markov cu două stări [Hamilton \(1989\)](#): starea de mâine depinde doar de starea de azi
 - ▶ matricea de tranziție $\begin{pmatrix} 0,975 & 0,025 \\ 0,1 & 0,9 \end{pmatrix}$ (rîndurile: starea curentă, calmă L sau turbulentă H)
 - ▶ $p_{LL} = 0,975$ și $p_{HH} = 0,9$ sînt probabilitățile de a rămîne în aceeași stare
 - ▶ $\pi_L = 0,8$, $\pi_H = 0,2$: probabilitățile staționare, adică ponderile pe termen lung ale celor două stări
- ▣ **Cerințe**
 1. Verificați condiția de echilibru $\pi_L(1 - p_{LL}) = \pi_H(1 - p_{HH})$, adică $0,8 \times 0,025 = 0,2 \times 0,1$: fluxul din L în H este egal cu fluxul din H în L .
 2. Calculați $\lambda = p_{LL} + p_{HH} - 1$, persistența lanțului: $\lambda = 0$ pentru stări independente, $\lambda \rightarrow 1$ pentru regimuri foarte persistente.

A8 [Propus]: originea autocorelației lui r_t^2 — cerința (2/2)

▣ Cerințe (continuare)

3. Cu indicatorul $I_t = 1$ în starea turbulentă, $\sigma_t^2 = 1 + 3I_t$; arătați că $\text{Cov}(I_t, I_{t-k}) = \pi_H(1 - \pi_H)\lambda^k$.
4. Deduceți că $\text{Cov}(r_t^2, r_{t-k}^2) = \text{Var}(\sigma^2)\lambda^k$ pentru $k \geq 1$.
5. Folosind A6, calculați $\text{Var}(\sigma^2)$, $\text{Var}(r^2) = 3\mathbb{E}\sigma^4 - (\mathbb{E}\sigma^2)^2$ și $\text{corr}(r_t^2, r_{t-k}^2)$ la lagurile 1 și 10.
6. Reprezentați grafic ACF implicată de model, comparativ cu ACF empirică a lui r_t^2 pentru S&P 500 (0,31 la lagul 1, 0,04 la lagul 100).

▣ Interpretare: care sînt cele două caracteristici ale datelor pe care acest model nu le poate reproduce?

A9 [Propus]: cozile S&P 500 într-un GARCH cu inovații din distribuția Normală — cerința (1/2)

▣ **Model:** A6 [Rezolvat]; secțiunea A9 din notebook

▶ o introducere anticipată în [Capitolul 5](#)

▣ **Ecuatiile modelului GARCH(1,1) Bollerslev (1986):** varianța de azi depinde de șocul de ieri și de varianța de ieri

$$r_t = \mu + \varepsilon_t, \quad \varepsilon_t = \sigma_t z_t, \quad \sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2 + \beta \sigma_{t-1}^2$$

▶ μ : randamentul mediu; ε_t : șocul zilei t ; z_t : inovația standardizată, i.i.d. $N(0, 1)$

▶ σ_t^2 : varianța condiționată, cunoscută la sfârșitul zilei $t - 1$

▶ $\omega > 0$: nivelul de bază al varianței; $\alpha \geq 0$: reacția la șocul de ieri; $\beta \geq 0$: persistența varianței de ieri

▶ $\alpha + \beta < 1$: varianța revine spre media ei pe termen lung, $\omega/(1 - \alpha - \beta)$

▶ aici α este un coeficient GARCH, nu tail index-ul

A9 [Propus]: cozile S&P 500 într-un GARCH cu inovații din distribuția Normală — cerința (2/2)

- ▣ **Rezultat:** dacă $1 - (\alpha + \beta)^2 - 2\alpha^2 > 0$, kurtosisul necondiționat al lui r_t este

$$K = \frac{3[1 - (\alpha + \beta)^2]}{1 - (\alpha + \beta)^2 - 2\alpha^2} > 3$$

▣ **Cerințe**

1. Calculați K pentru $(\alpha, \beta) = (0,10; 0,85)$ și $(0,10; 0,88)$.
2. Formulați condiția pentru un moment de ordinul patru finit.
3. Comparați-o cu $\alpha + \beta < 1$.
4. Cu $\alpha + \beta = 0,99$, determinați α pentru care modelul reproduce kurtosisul S&P 500, $K = 13,9$.
5. Estimați modelul pe r_{sp} în %.

- `arch_model(100*r_sp, mean='Constant', vol='GARCH', p=1, q=1, dist='normal')`

6. Calculați K implicat.
7. Reprezentați QQ plot-ul lui $\hat{z}_t = \hat{\varepsilon}_t / \hat{\sigma}_t$.

- ▣ **Interpretare:** ce indică QQ plot-ul despre ipoteza distribuției Normale pentru z_t ?

A11 [Propus]: estimatorul Hill ca estimator de verosimilitate maximă — cerința (1/2)

- ▣ **Model:** A7 [Rezolvat]; secțiunea A11 din notebook
- ▣ **Ipoteză:** fiind dat pragul $u = X_{(k+1)}$, cele k depășiri sînt statisticile de ordine ale unui eșantion Pareto i.i.d.
 - ▶ densitatea Pareto $f(x) = \alpha u^\alpha x^{-\alpha-1}$, $x > u$, cu tail index-ul α
- ▣ **Noțiuni**
 - ▶ log-verosimilitatea $\ell(\alpha) = \sum_{i=1}^k \ln f(X_{(i)})$: cît de plauzibile sînt datele pentru o valoare dată a lui α
 - ▶ estimatorul de verosimilitate maximă: valoarea lui α care maximizează $\ell(\alpha)$
 - ▶ ℓ' , ℓ'' : derivatele de ordinul 1 și 2 în raport cu α
 - ▶ informația Fisher $-\mathbb{E} \ell''(\alpha)$; $\text{SE}(\hat{\alpha}) \approx 1/\sqrt{\text{informația}}$

A11 [Propus]: estimatorul Hill ca estimator de verosimilitate maximă — cerința (2/2)

▣ Cerințe

1. Scrieți log-verosimilitatea $\ell(\alpha)$ a celor k depășiri (ordonarea adaugă doar constanta $\ln k!$).
2. Rezolvați $\ell'(\alpha) = 0$ și arătați că maximul este estimatorul Hill $\hat{\alpha} = k / \sum_{i=1}^k \ln(X_{(i)}/u)$ Hill (1975).
3. Calculați $\ell''(\alpha)$, informația k/α^2 și $\text{SE}(\hat{\alpha}) \approx \hat{\alpha}/\sqrt{k}$.
4. Verificați SE pe datele din A7.
5. Simulați $n = 2\,000\,000$ de valori $|X|$, X Student- t cu $\nu = 3$ (`numpy.random.default_rng(1)`).
6. Reprezentați $\hat{\alpha}_k$ (estimarea Hill cu k valori) în funcție de k/n și raportați $k = 200, 2\,000, 20\,000, 200\,000$.

▣ Interpretare: de ce se îndepărtează $\hat{\alpha}_k$ de 3 când k este mare?

B1(d) [Rezolvat]: momente pe cuantile, cu intervale bootstrap (1/2)

- ▣ **Întrebare:** se confirmă asimetria negativă și excesul de kurtosis cu măsuri care nu presupun existența momentelor?
- ▣ **Măsuri Kim & White (2004)**, ambele egale cu 0 pentru distribuția Normală (q_p : cuantila de ordin p)
 - ▶ asimetria Hinkley $\frac{q_{0,95} + q_{0,05} - 2q_{0,5}}{q_{0,95} - q_{0,05}}$: poziția medianei între $q_{0,05}$ și $q_{0,95}$
 - ▶ ia valori în $[-1, 1]$; negativă: coada stîngă este mai lungă decît cea dreaptă
 - ▶ kurtosisul Crow–Siddiqui $\frac{q_{0,975} - q_{0,025}}{q_{0,75} - q_{0,25}} - 2,91$ (Noțiuni necesare azi, 2/10)
- ▣ **Bootstrap pe blocuri:** 1000 de reeșantionări (`default_rng(42)`)
 - ▶ extrageți uniform $\lceil T/20 \rceil$ zile de început ($\lceil \cdot \rceil$: rotunjire în sus) și preluați cîte 20 de randamente consecutive, începînd cu fiecare
 - ▶ blocurile păstrează volatility clustering din interiorul lor
 - ▶ trunchiați seria la T observații și recalculați ambele măsuri
 - ▶ intervalul percentil de 95%: cuantilele de 2,5% și 97,5% ale celor 1000 de valori recalculate

B1(d) [Rezolvat]: momente pe cuantile, cu intervale bootstrap (2/2)

	Asimetrie (momente)	Hinkley [CI 95%]	Exces kurt.	Crow-Siddiqui [CI 95%]
BET-TR	-1,40	-0,036 [-0,085; 0,025]	17,8	1,06 [0,73; 1,43]
Bitcoin	-0,70	-0,018 [-0,069; 0,032]	12,0	2,25 [1,88; 2,64]
EUR/RON	0,73	0,041 [-0,022; 0,093]	15,1	4,87 [3,74; 6,13]

- Toate intervalele pentru kurtosis se situează integral peste 0: cozile groase sînt confirmate fără a folosi momente
- Asimetria pe momente și asimetria Hinkley măsoară caracteristici diferite ale distribuției
 - ▶ toate intervalele Hinkley conțin 0
 - ▶ aceasta nu dovedește simetria

B10 [Propus]: un kurtosis care nu converge — cerința

- ▣ **Model:** B1 [Rezolvat]; secțiunea B10 din notebook
- ▣ **Date:** `r_sp`; fereastra n cuprinde randamentele anterioare datei de 3 ianuarie a anului $1990 + n$, $n = 1, \dots, 36$
 - ▶ 253 de randamente pentru $n = 1$, 2 527 pentru $n = 10$, 9 067 pentru $n = 36$
- ▣ **Simulare:** 500 de traiectorii Student- t de lungime 9 245 pentru $\nu = 3$ și pentru $\nu = 6$ (`default_rng(42)`)
 - ▶ trunchiate la aceleași lungimi ale ferestrelor
- ▣ **Cerințe**
 1. Calculați excesul de kurtosis al S&P 500 pe fiecare fereastră.
 2. Identificați cele mai mari trei salturi și zilele care le generează.
 3. Pentru fiecare ν calculați cuantilele de 5%, 50% și 95% ale kurtosisului simulat pentru fiecare n .
 4. Reprezentați curba empirică suprapusă peste ambele benzi, pe o scală logaritmică simetrică.
- ▣ **Interpretare**
 - ▶ de ce se stabilizează lent banda pentru $\nu = 6$, deși kurtosisul lui t_6 este finit?
 - ▶ ce informație transmite, în acest caz, valoarea “exces de kurtosis = 10,9”?

B14 [Propus]: faptele stilizate reproduse de GARCH- t — cerința (1/2)

▣ **Model:** B3 și B11 [Rezolvat], A9; secțiunea B14 din notebook

▣ **Date:** r_{sp} exprimat în % ($T = 9\,245$)

▶ medie constantă

▶ ω în %² pe zi

```
from arch import arch_model
from arch.univariate import StudentsT
am = arch_model(100 * r_sp, mean='Constant', vol='GARCH', p=1, q=1, dist='t')
res = am.fit(dispatch='off')
am.distribution = StudentsT(seed=np.random.default_rng(42)) # reproducible paths
sim = am.simulate(res.params, nobs=len(r_sp), burn=1000)['data']
```

B14 [Propus]: faptele stilizate reproduse de GARCH- t — cerința (2/2)

□ Cerințe

1. Estimați modelul și raportați toți cei cinci parametri, cu unitățile lor.
2. Verificare: simulați o traiectorie și calculați-i excesul de kurtosis.
3. Apoi simulați 200 de traiectorii.
4. Pentru fiecare traiectorie, calculați următoarele statistici.
 - excesul de kurtosis
 - ACF a lui $|r_t|$ la lagurile 1, 20, 100, 250
 - $\hat{\alpha}$ Hill pentru $|r_t|$ la $k = 2\%$ din T
 - $L(1) = \text{corr}(r_t, |r_{t+1}|)$: corelația dintre randamentul de azi și mărimea celui de mâine (efectul de levier, B5)
5. Construiți intervalele 5–95%, separat pentru fiecare statistică.
6. Precizați, pentru fiecare valoare observată, dacă se află în interiorul intervalului.

□ Interpretare

- ▶ ce fapte stilizate nu sînt reproduse?
- ▶ ce componentă a modelului ar trebui modificată pentru fiecare dintre ele?

B5 [Propus]: efectul de levier, BET-TR față de Bitcoin — cerința (1/2)

- ▣ **Model:** B3 [Rezolvat]; secțiunea B5 din notebook
- ▣ **Convenția lagului:** $L(k) = \text{corr}(r_t, |r_{t+k}|)$ [Christie \(1982\)](#)
 - ▶ $L(k) < 0$: după scăderi, randamentele ulterioare sînt mai mari în valoare absolută (efectul de levier)
 - ▶ k este exprimat în zile de observație ale fiecărei serii
 - ▶ pentru $k > 0$, randamentul curent este asociat cu o valoare absolută ulterioară
 - ▶ exemplu, $k = 1$: randamentul BET-TR de luni, 16 mar. 2020, este asociat cu $|r|$ de marți, 17 mar. 2020
- ▣ **Date:** `r_bet` și `r_btc`, fiecare pe propriul calendar
- ▣ **Cerințe**
 1. Calculați $L(k)$ pentru $k = -20, \dots, 20$.
 2. Reprezentați ambele serii cu benzile de referință i.i.d. $\pm 1,96/\sqrt{T}$ (0,036 și 0,030).

B5 [Propus]: efectul de levier, BET-TR față de Bitcoin — cerința (2/2)

▣ **Cerințe** (continuare)

3. Raportați $L(1)$ și $L(5)$ pentru ambele piețe.
4. Precizați dacă se află în afara benzilor de referință.
5. Propuneți două explicații alternative pentru un efect mai slab la Bitcoin.

▣ **Interpretare**

- ▶ de ce o bandă de referință nu este un interval de încredere în prezența volatility clustering?
- ▶ ce informație suplimentară oferă B12?

B12 [Propus]: efectul de levier ca regresie — cerința (1/2)

- ▣ **Model:** B5, B9 [Rezolvat]; secțiunea B12 din notebook
- ▣ **Regresia:** $|r_{t+1}| = c + \beta^+ r_t^+ + \beta^- r_t^- + \sum_{j=1}^5 \delta_j |r_{t-j}| + u_{t+1}$
 - ▶ $r_t^+ = \max(r_t, 0) \geq 0$, $r_t^- = \min(r_t, 0) \leq 0$: partea pozitivă și partea negativă a randamentului
 - ▶ c : constanta; δ_j : efectul lui $|r_{t-j}|$, variabile de control pentru volatility clustering; u_{t+1} : eroarea
 - ▶ un câștig $+a$ contribuie cu $\beta^+ a$, o pierdere $-a$ contribuie cu $-\beta^- a$
 - ▶ un răspuns simetric înseamnă $\beta^+ = -\beta^-$
 - ▶ rîndul din matricea de regresori pentru ziua t : $(1, r_t^+, r_t^-, |r_{t-1}|, \dots, |r_{t-5}|)$
 - ▶ variabila dependentă: $|r_{t+1}|$
- ▣ **Date:** r_sp, r_bet, r_btc, r_eur

B12 [Propus]: efectul de levier ca regresie — cerința (2/2)

▣ Cerințe

1. Estimați prin OLS cu erori standard Newey–West [Newey & West \(1987\)](#), robuste la heteroscedasticitate și autocorelație, cu lungimea de trunchiere $\lfloor 4(T/100)^{2/9} \rfloor$ (numărul de laguri ale erorilor luate în calcul).
2. Testați $H_0: \beta^+ + \beta^- = 0$ (răspuns simetric) la 5%, față de χ_1^2 , cu statistica Wald
 - $W = (\hat{\beta}^+ + \hat{\beta}^-)^2 / [\text{Var}(\hat{\beta}^+) + \text{Var}(\hat{\beta}^-) + 2 \text{Cov}(\hat{\beta}^+, \hat{\beta}^-)]$
 - numitorul: varianța lui $\hat{\beta}^+ + \hat{\beta}^-$, din matricea de covarianță Newey–West; W este pătratul unei statistici t
3. Reprezentați valoarea estimată a lui $|r_{t+1}|$ după un câștig $+a$ și după o pierdere $-a$, cu variabilele de control fixate la mediile lor.
4. Arătați de ce $|r_t|$ nu poate fi adăugat printre variabilele de control.

B6 [Propus]: EUR/RON pe regimuri — cerința (1/3)

- ▣ **Model:** B1, B9 [Rezolvat]; secțiunea B6 din notebook
- ▣ **Date:** r_{eur} (cursul de referință BNR), seria împărțită în trei perioade
 - ▶ iul. 2005 – 2011, 2012–2019, 2020–2026: 1 656, 2 013, 1 683 de randamente
 - ▶ lagurile se construiesc în interiorul fiecărei perioade
- ▣ **Cerințe**
 1. Pentru fiecare perioadă, estimați prin OLS regresia $r_t = a + \rho r_{t-1} + e_t$, cu SE HAC (lungimea de trunchiere $\lfloor 4(T/100)^{2/9} \rfloor$).
 - a : constanta; ρ : autocorelația de lag 1; e_t : eroarea
 - SE HAC: eroare standard robustă la heteroscedasticitate și autocorelație (ca la B12)
 2. Raportați $\hat{\rho}$, SE, volatilitatea și excesul de kurtosis pentru fiecare perioadă.

B6 [Propus]: EUR/RON pe regimuri — cerința (2/3)

▣ Cerințe (continuare)

3. Testați egalitatea lui ρ între perioade cu statistica de mai jos.

$$W = \sum_j w_j (\hat{\rho}_j - \bar{\rho})^2 \sim \chi_2^2$$

- $j = 1, 2, 3$: perioada; ponderi $w_j = 1/\text{SE}_j^2$, deci estimările precise contează mai mult
- $\bar{\rho} = \sum_j w_j \hat{\rho}_j / \sum_j w_j$: media ponderată a celor trei estimări
- W măsoară dispersia estimărilor în jurul lui $\bar{\rho}$; 2 grade de libertate = 3 perioade — 1

B6 [Propus]: EUR/RON pe regimuri — cerința (3/3)

▣ Cerințe (continuare)

4. Separat, identificați o ruptură în varianță cu suma cumulată a pătratelor (CUSUM) [Inclán & Tiao \(1994\)](#).

- $C_k = \sum_{t \leq k} x_t^2$: suma pătratelor pînă în ziua k
- $D_k = C_k / C_T - k / T$: fracțiunea din varianța totală acumulată pînă în ziua k , minus fracțiunea de timp scursă
- $D_k \approx 0$ pentru orice k dacă varianța este constantă
- ruptura este estimată la $\arg \max_k |D_k|$, ziua k în care $|D_k|$ este maxim

▣ Interpretare

- ▶ de ce este atît de mare SE pentru 2020–2026?
- ▶ de ce data rupturii identificată prin CUSUM are caracter descriptiv și nu constituie un test?

B15 [Propus]: memorie lungă sau rupturi structurale — cerința (1/3)

- ▣ **Model:** B9, B11 [Rezolvat]; secțiunea B15 din notebook (funcția `local_whittle(x, m)`)
- ▣ **Parametrul de memorie d :** viteza cu care descrește ACF a lui $x_t = |r_t|$
 - ▶ $d = 0$: memorie scurtă, ACF descrește geometric
 - ▶ $0 < d < 0,5$: memorie lungă staționară, ACF descrește lent, ca k^{2d-1}
 - ▶ $d \geq 0,5$: seria nu mai este staționară
- ▣ **Date:** $|r_t|$ pentru S&P 500, BET-TR și Bitcoin

B15 [Propus]: memorie lungă sau rupturi structurale — cerința (2/3)

- ▣ **Metoda local Whittle Robinson (1995):** centrați $x_t = |r_t|$
 - ▶ frecvențele Fourier $\lambda_j = 2\pi j/T, j = 1, \dots, m$; frecvențele mici corespund ciclurilor lungi
 - ▶ periodograma $I(\lambda) = \frac{1}{2\pi T} \left| \sum_t x_t e^{-i\lambda t} \right|^2$: intensitatea ciclurilor de frecvență λ din serie
 - ▶ memoria lungă face ca $I(\lambda_j)$ să crească proporțional cu λ_j^{-2d} la frecvențe mici
- ▣ $\hat{d}$ minimizează pe $d \in [-0,49; 0,99]$

$$\ln \left(\frac{1}{m} \sum_{j=1}^m \lambda_j^{2d} I(\lambda_j) \right) - \frac{2d}{m} \sum_{j=1}^m \ln \lambda_j$$

- ▶ $m = \lfloor T^p \rfloor$: numărul de frecvențe mici folosite; $p \in (0, 1)$ stabilește lățimea de bandă
- ▶ $SE = 1/(2\sqrt{m})$

B15 [Propus]: memorie lungă sau rupturi structurale — cerința (3/3)

▣ Cerințe

1. Estimați d cu $p = 0,65$ și raportați intervalul de încredere de 95%.
2. Reprezentați $\hat{d}$ în funcție de p de la 0,45 la 0,80, cu dreptele $d = 0$ și $d = 0,5$.
3. Identificați o ruptură în varianța lui r_t (B6).
4. Reestimați $\hat{d}$ de fiecare parte a rupturii.
5. Reprezentați ACF a lui $|r_t|$ înainte și după ruptură.

▣ Interpretare

- ▶ este $\hat{d} > 0$ robust la p și la ruptură?
- ▶ este rezultatul compatibil și cu un model cu regimuri Diebold & Inoue (2001)?
- ▶ ce implică $\hat{d} \geq 0,5$?

B7 [Propus]: BET-TR față de S&P 500 pe aceeași perioadă — cerința (1/2)

- ▣ **Model:** A1, B1 [Rezolvat]; secțiunea B7 din notebook
- ▣ **Date:** BET-TR (randament total, lei) și S&P 500 (indice de preț, USD)
 - ▶ aliniați *prețurile* pe zilele comune (23 sept. 2014 – 18 sept. 2026)
 - ▶ apoi calculați cele 2 903 randamente
 - ▶ lungimea intervalelor: 2 231 de o zi, 538 de două sau trei zile, 134 mai lungi (cel mult 6 zile)
- ▣ **Cerințe**
 1. Reprezentați valoarea investiției, rebazată (scală logaritmică), și cele două curbe de drawdown (underwater), DD_t din A4(a).

B7 [Propus]: BET-TR față de S&P 500 pe aceeași perioadă — cerința (2/2)

▣ Cerințe (continuare)

2. Calculați următoarele măsuri pentru ambii indici.

- $CAGR = (P_{\text{final}}/P_{\text{inițial}})^{1/Y} - 1$, cu Y numărul de ani calendaristici; volatilitatea randamentelor simple ($A = 252$)
- raportul Sharpe $252\bar{R}/(\sqrt{252}\hat{\sigma}_R)$ cu $r_f = 0$: randamentul anual pe unitatea de volatilitate
- $\bar{R}$, $\hat{\sigma}_R$: media și abaterea standard a randamentelor simple zilnice; r_f : rata dobânzii fără risc
- raportul Sortino [Sortino & van der Meer \(1991\)](#) $252\bar{R}/(\sqrt{252}\hat{\sigma}_D)$, cu semiabaterea inferioară
 $\hat{\sigma}_D = \sqrt{\frac{1}{T} \sum_t \min(R_t, 0)^2}$, calculată pe toate zilele
- Sortino penalizează doar zilele cu pierderi
- MDD și raportul Calmar ($A4(a)$)

▣ De raportat: graficul și un tabel cu două coloane

▣ Interpretare: indicați trei motive pentru care comparația este doar descriptivă (dividende, monedă, dobânda fără risc în lei)

B13 [Propus]: semnificația diferenței dintre rapoartele Sharpe — cerința (1/2)

▣ **Model:** B7, B1(d); secțiunea B13 din notebook

▣ **Date:** cele 2903 perechi de randamente din B7

- ▶ randamente simple pentru rapoartele Sharpe (1,36 și 0,75)
- ▶ randamente logaritmice pentru corelații

▣ **Cerințe**

1. Converteți rapoartele Sharpe în valori zilnice ($\widehat{SR}/\sqrt{252}$).
2. Calculați testul Jobson–Korkie [Jobson & Korkie \(1981\)](#) cu corecția lui [Mommel \(2003\)](#).

- $z = (\widehat{SR}_1 - \widehat{SR}_2)/\sqrt{\widehat{V}}$
- $\widehat{V} = \frac{1}{T} [2(1 - \hat{\rho}) + \frac{1}{2}(\widehat{SR}_1^2 + \widehat{SR}_2^2 - 2\widehat{SR}_1\widehat{SR}_2\hat{\rho}^2)]$
- $\widehat{SR}_1, \widehat{SR}_2$: rapoartele Sharpe zilnice ale BET-TR și S&P 500; $\hat{\rho}$: corelația randamentelor lor
- $\widehat{V}$: varianța estimată a diferenței; sub H_0 (rapoarte Sharpe egale) $z \approx N(0, 1)$

B13 [Propus]: semnificația diferenței dintre rapoartele Sharpe — cerința (2/2)

▣ Cerințe (continuare)

3. Aplicați un bootstrap circular pe blocuri, pe perechi de randamente, cu 2 000 de reeșantionări (`default_rng(42)`).
 - extrageți $\lceil T/21 \rceil$ zile de început, preluați câte 21 de zile consecutive (circular, reluând seria de la început), trunchiați la T
 - aplicați **aceiași** indici ambelor serii
4. Raportați intervalul percentil de 95% pentru diferența anualizată.
5. Calculați patru corelații.
 - în aceeași zi
 - BET-TR cu S&P 500 din ziua precedentă și din ziua următoare
 - pe randamente săptămânale (vineri)

▣ Interpretare

- ▶ este diferența semnificativă?
- ▶ ce presupun cele două metode?
- ▶ ce corelație trebuie folosită la construcția unui portofoliu?

B8 [Propus]: estimatori de range volatility pentru S&P 500 — cerința (1/2)

- ▣ **Model:** A5 [Rezolvat]; secțiunea B8 din notebook
 - ▶ notebook-ul conține funcții testate pentru toți cei cinci estimatori
 - ▶ formulele se găsesc în [Capitolul 1](#)
- ▣ **Date:** OHLC pentru indicele S&P 500, 2 ian. 2008 – 18 sept. 2026
- ▣ ETF-ul SPY, cu toate prețurile ajustate pe aceeași bază
 - ▶ C^* = închiderea ajustată (pentru dividende și splituri)
 - ▶ $O^*, H^*, L^* = (C^*/C) \times O, H, L$, cu C închiderea neajustată și C^*/C factorul de ajustare al zilei
 - ▶ exemplu, 16 mar. 2020: factorul $218,08/239,85 = 0,9092$; $O^* = 241,18 \times 0,9092 = 219,29$, $H^* = 233,58$, $L^* = 215,82$

B8 [Propus]: estimatori de range volatility pentru S&P 500 — cerința (2/2)

▣ Cerințe

1. Calculați volatilitățile mobile pe 21 de zile close-to-close, Parkinson, Garman–Klass [Garman & Klass \(1980\)](#), Rogers–Satchell [Rogers & Satchell \(1991\)](#) și Yang–Zhang [Yang & Zhang \(2000\)](#) ($A = 252$).
2. Calculați mediile lor în timp.
3. Pentru indice și pentru SPY, comparați mediile estimatorilor close-to-close și Yang–Zhang pe 21 de zile cu două volatilități calculate pe întregul eșantion.
 - volatilitatea de peste noapte: $\text{sd}(o_t - c_{t-1})\sqrt{252}$, cu $o_t - c_{t-1}$ randamentul logaritmic de peste noapte (notațiile din A5)
 - volatilitatea de la deschidere la închidere: $\text{sd}(c_t - o_t)\sqrt{252}$
 - sd: abaterea standard de selecție

- ▣ **Interpretare:** de ce rămîne Yang–Zhang sub close-to-close pe indice, dar nu și pe SPY?

C1 [Propus]: autocorelația BET-TR după reclasificarea FTSE (1/3)

- ▣ **Model:** B6, B9 [Rezolvat]; o propunere de proiect
- ▣ **Context:** BET-TR are o autocorelație pozitivă la lagul 1, caracteristică piețelor mai puțin lichide
 - ▶ FTSE Russell a reclasificat România ca piață emergentă secundară, începând cu 21 sept. 2020
- ▣ **Date:** r_{bet} și o măsură a lichidității
 - ▶ lichiditatea: valoarea zilnică tranzacționată ($\text{volum} \times \text{preț de închidere brut, în lei}$) a 11 blue chips de la BVB
 - ▶ acțiunile: TLV, SNP, BRD, TGN, FP, SNG, H2O, SNN, EL, DIGI, TEL
 - ▶ însumată pe acțiunile listate în ziua respectivă
 - ▶ raportați numărul de acțiuni listate în fiecare an

C1 [Propus]: autocorelația BET-TR după reclasificarea FTSE (2/3)

▣ Cerințe

1. Calculați $\hat{\rho}_1$ pe ferestre mobile de 250 de zile (pas de 5 zile).
2. Adăugați benzile din B9, etichetate drept benzi de referință în ipoteza $\rho_1 = 0$.
3. Estimați ρ_1 înainte și după 21 sept. 2020 ca pantă AR(1), cu SE HAC (B6).
4. Raportați statistica pentru diferența celor două estimări.

$$z = \frac{\hat{\rho}_{\text{după}} - \hat{\rho}_{\text{înainte}}}{\sqrt{SE_1^2 + SE_2^2}}$$

- SE_1, SE_2 : erorile standard HAC înainte și după
- sub H_0 (nicio schimbare) $z \approx N(0, 1)$, dacă cele două perioade sînt independente

C1 [Propus]: autocorelația BET-TR după reclasificarea FTSE (3/3)

▣ **Cerințe** (continuare)

5. Raportați interacțiunea e din regresia de mai jos (HAC, 10 laguri).

$$r_t = a + b r_{t-1} + c \text{post}_t + e r_{t-1} \text{post}_t$$

- $\text{post}_t = 1$ după 21 sept. 2020 și 0 înainte
- b : autocorelația înainte; e : modificarea ei după reclasificare; a , c : constanta și modificarea ei

6. Calculați corelația dintre $\hat{\rho}_1$ mobil și logaritmul valorii medii tranzacționate pe 250 de zile.

▣ **Livrabil:** un folder Quantlet și un slide

- ▶ o concluzie descriptivă și principala ei limită
- ▶ nu o afirmație cauzală

C3 [Propus]: dependența VIX de traiectoria prețurilor — cerința (1/5)

- **Model:** studiul de caz din curs
 - ▶ un proiect de replicare, nu o sarcină de seminar
- **Întrebare:** pot randamentele trecute ale S&P 500 să explice, singure, VIX, așa cum arată [Guyon & Lekeufack \(2023\)](#)?
 - ▶ 94,6% din varianța sa în 2000–2018, 85,5% în 2019 – mai 2022
- **Date:** închiderile zilnice ale S&P 500, VIX și VIX pe 9 zile
 - ▶ S_{t_i} : nivelul S&P 500 la închiderea zilei t_i ; randamente simple $r_{t_i} = S_{t_i}/S_{t_i-1} - 1$
 - ▶ indicii de volatilitate împărțiți la 100
- **Modelul**, ec. (3.7) din lucrare: volatilitatea de azi este o funcție liniară de două rezumate ale randamentelor trecute

$$\sigma_t = \beta_0 + \beta_1 R_{1,t} + \beta_2 \Sigma_t$$

- ▶ σ_t : VIX (sau VIX pe 9 zile) la închiderea zilei t , împărțit la 100
- ▶ $\beta_0, \beta_1, \beta_2$: coeficienți estimați din date

C3 [Propus]: dependența VIX de traiectoria prețurilor — cerința (2/5)

- ▣ **Componenta de trend:** o medie ponderată a randamentelor din ultimele 1 000 de zile

$$R_{1,t} = \sum_{i=0}^{999} K_1(i\Delta t) r_{t-i}$$

- ▶ i : vechimea randamentului, în zile; $\Delta t = 1/252$: o zi, exprimată în ani; $K_1(i\Delta t)$: ponderea lui
- ▶ $R_{1,t} < 0$ după o perioadă de scăderi, $R_{1,t} > 0$ după o perioadă de creșteri

- ▣ **Componenta de volatilitate:** rădăcina pătrată a unei medii ponderate a randamentelor la pătrat

$$\Sigma_t = \left(\sum_{i=0}^{999} K_2(i\Delta t) r_{t-i}^2 \right)^{1/2}$$

- ▶ o volatilitate istorică ponderată, cu ponderile K_2

- ▣ **Interpretarea coeficienților**

- ▶ $\beta_1 < 0$: după scăderi ($R_{1,t} < 0$) volatilitatea crește, adică efectul de levier
- ▶ $\beta_2 > 0$: o volatilitate recentă mare ridică volatilitatea de azi, adică volatility clustering

C3 [Propus]: dependența VIX de traiectoria prețurilor — cerința (3/5)

- **Nuclee**, ec. (3.9) din lucrare: o lege de putere decalată în timp

$$K_j(\tau) = \frac{(\tau + \delta_j)^{-\alpha_j}}{Z_j}, \quad j = 1, 2$$

- ▶ τ : vechimea, în ani; Z_j este ales astfel încât $\sum_{i=0}^{999} K_j(i\Delta t)\Delta t = 1$
- ▶ $\alpha_j > 1$: viteza de scădere a ponderilor; un α_j mic înseamnă memorie lungă
- ▶ $\delta_j > 0$: lagul; un δ_j mic concentrează ponderea pe ultimele câteva zile

- **Parametri și unități**

- ▶ β_0 în unități de volatilitate ($0,03 = 3$ puncte VIX)
- ▶ β_1, β_2 adimensionali
- ▶ δ_j în ani

- **Valori inițiale** (Tabelul 3 din lucrare, rîndul VIX)

- ▶ $\beta_0 = 0,057$, $\beta_1 = -0,095$, $\beta_2 = 0,82$
- ▶ $\alpha_1 = 1,06$, $\delta_1 = 0,020$, $\alpha_2 = 1,60$, $\delta_2 = 0,052$
- ▶ limitele $\alpha_j \in [1,0001; 20]$, $\delta_j \in [10^{-4}; 5]$

C3 [Propus]: dependența VIX de traiectoria prețurilor — cerința (4/5)

▣ **Cerințe**, pe etape

1. Nuclee fixe: calculați $R_{1,t}$ și Σ_t cu nucleele din Tabelul 3.
2. Estimați $\beta_0, \beta_1, \beta_2$ prin OLS pe 2000–2018.
3. Modelul complet: estimați toți cei șapte parametri prin cele mai mici pătrate neliniare pe 1 ian. 2000 – 31 dec. 2018, minimizând $\sum_t (\sigma_t - \hat{\sigma}_t)^2$, cu $\hat{\sigma}_t$ valoarea dată de model.
 - folosiți `scipy.optimize.least_squares`
 - recalculați variabilele la fiecare evaluare a parametrilor
4. Raportați R^2 și RMSE pe eșantionul de antrenare și pe perioada 1 ian. 2019 – 15 mai 2022.
 - pentru modelul complet și pentru restricțiile $\beta_1 = 0$ și $\beta_2 = 0$
5. Repetați modelul complet pentru VIX pe 9 zile (antrenare din 2011).
6. Cu parametrii menținuți ficși, evaluați modelul pe perioada 16 mai 2022 – 18 sept. 2026.

C3 [Propus]: dependența VIX de traiectoria prețurilor — cerința (5/5)

- ▣ **Criteriile de evaluare**, calculate separat pe fiecare eșantion de T zile
 - ▶ $\text{RMSE} = \sqrt{\frac{1}{T} \sum_t (\sigma_t - \hat{\sigma}_t)^2}$: eroarea tipică, în unități de volatilitate
 - ▶ $R^2 = 1 - \sum_t (\sigma_t - \hat{\sigma}_t)^2 / \sum_t (\sigma_t - \bar{\sigma})^2$: proporția din variația lui σ_t explicată de model
 - ▶ $\bar{\sigma}$: media lui σ_t ; $R^2 = 1$: potrivire perfectă; $R^2 \leq 0$: nu mai bun decât media
- ▣ **De raportat**
 - ▶ tabelul parametrilor și scorurile, comparate cu Tabelul 2 din lucrare
 - ▶ graficul VIX observat și estimat și raportul dintre acestea
 - ▶ nucleele estimate
- ▣ **Interpretare**: modelul explică VIX din aceeași zi
 - ▶ nu este o prognoză pentru ziua următoare
 - ▶ ce variabilă explică mai mult, $R_{1,t}$ sau Σ_t ?

Bibliografie (1/3)

- Bollerslev, T. (1986). Generalized autoregressive conditional heteroskedasticity. *Journal of Econometrics*, 31(3), 307–327.
- Bollerslev, T., Hood, B., Huss, J., Pedersen, L.H. (2018). Risk everywhere: modeling and managing volatility. *Review of Financial Studies*, 31(7), 2729–2773.
- Christie, A.A. (1982). The stochastic behavior of common stock variances: value, leverage and interest rate effects. *Journal of Financial Economics*, 10(4), 407–432.
- Clark, P.K. (1973). A subordinated stochastic process model with finite variance for speculative prices. *Econometrica*, 41(1), 135–155.
- Cont, R. (2001). Empirical properties of asset returns: stylized facts and statistical issues. *Quantitative Finance*, 1(2), 223–236.
- Dalla, V., Giraitis, L., Phillips, P.C.B. (2022). Robust tests for white noise and cross-correlation. *Econometric Theory*, 38(5), 913–941.
- Diebold, F.X., Inoue, A. (2001). Long memory and regime switching. *Journal of Econometrics*, 105(1), 131–159.
- Dimson, E. (1979). Risk measurement when shares are subject to infrequent trading. *Journal of Financial Economics*, 7(2), 197–226.
- Engle, R.F. (1982). Autoregressive conditional heteroscedasticity with estimates of the variance of United Kingdom inflation. *Econometrica*, 50(4), 987–1007.
- Franke, J., Härdle, W.K., Hafner, C.M. (2019). *Statistics of Financial Markets: An Introduction* (ed. a 5-a). Springer.
- Garman, M.B., Klass, M.J. (1980). On the estimation of security price volatilities from historical data. *Journal of Business*, 53(1), 67–78.
- Guyon, J., Lekeufack, J. (2023). Volatility is (mostly) path-dependent. *Quantitative Finance*, 23(9), 1221–1258.

Bibliografie (2/3)

- ▣ Hamilton, J.D. (1989). A new approach to the economic analysis of nonstationary time series and the business cycle. *Econometrica*, 57(2), 357–384.
- ▣ Hill, B.M. (1975). A simple general approach to inference about the tail of a distribution. *Annals of Statistics*, 3(5), 1163–1174.
- ▣ Inclán, C., Tiao, G.C. (1994). Use of cumulative sums of squares for retrospective detection of changes of variance. *Journal of the American Statistical Association*, 89(427), 913–923.
- ▣ Jarque, C.M., Bera, A.K. (1980). Efficient tests for normality, homoscedasticity and serial independence of regression residuals. *Economics Letters*, 6(3), 255–259.
- ▣ Jobson, J.D., Korkie, B.M. (1981). Performance hypothesis testing with the Sharpe and Treynor measures. *Journal of Finance*, 36(4), 889–908.
- ▣ Kim, T.-H., White, H. (2004). On more robust estimation of skewness and kurtosis. *Finance Research Letters*, 1(1), 56–73.
- ▣ Ledoit, O., Wolf, M. (2008). Robust performance hypothesis testing with the Sharpe ratio. *Journal of Empirical Finance*, 15(5), 850–859.
- ▣ Ljung, G.M., Box, G.E.P. (1978). On a measure of lack of fit in time series models. *Biometrika*, 65(2), 297–303.
- ▣ Lo, A.W. (2002). The statistics of Sharpe ratios. *Financial Analysts Journal*, 58(4), 36–52.
- ▣ Lobato, I., Nankervis, J.C., Savin, N.E. (2001). Testing for autocorrelation using a modified Box–Pierce Q test. *International Economic Review*, 42(1), 187–205.

Bibliografie (3/3)

- ▣ Magdon-Ismail, M., Atiya, A.F., Pratap, A., Abu-Mostafa, Y.S. (2004). On the maximum drawdown of a Brownian motion. *Journal of Applied Probability*, 41(1), 147–161.
- ▣ Memmel, C. (2003). Performance hypothesis testing with the Sharpe ratio. *Finance Letters*, 1(1), 21–23.
- ▣ Newey, W.K., West, K.D. (1987). A simple, positive semi-definite, heteroskedasticity and autocorrelation consistent covariance matrix. *Econometrica*, 55(3), 703–708.
- ▣ Parkinson, M. (1980). The extreme value method for estimating the variance of the rate of return. *Journal of Business*, 53(1), 61–65.
- ▣ Robinson, P.M. (1995). Gaussian semiparametric estimation of long range dependence. *Annals of Statistics*, 23(5), 1630–1661.
- ▣ Rogers, L.C.G., Satchell, S.E. (1991). Estimating variance from high, low and closing prices. *Annals of Applied Probability*, 1(4), 504–512.
- ▣ Sortino, F.A., van der Meer, R. (1991). Downside risk. *Journal of Portfolio Management*, 17(4), 27–31.
- ▣ Yang, D., Zhang, Q. (2000). Drift-independent volatility estimation based on high, low, open, and close prices. *Journal of Business*, 73(3), 477–492.