



Modelarea piețelor financiare

Seminarul 1: Fapte stilizate și randamente — aplicații



Daniel Traian PELE

Antoaneta Amza

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognostic Economică

MSCA Digital Finance

Acronime folosite în acest material (1/2)

- ACF: AutoCorrelation Function (funcția de autocorelație)
- AI: Artificial Intelligence (inteligență artificială)
- AR: AutoRegressive (model); in event studies: Abnormal Return (model autoregresiv; în studiile de eveniment: randament anormal)
- ARCH-LM: ARCH Lagrange Multiplier (test) (testul multiplicatorului Lagrange pentru efecte ARCH)
- BET-TR: BET Total Return (index) (indicele BET cu dividendele reinvestite)
- BNR: Banca Națională a României
- BVB: Bursa de Valori București
- CAGR: Compound Annual Growth Rate (rata anuală compusă de creștere)
- CI: Confidence Interval (interval de încredere)
- COVID-19: COronaVirus Disease 2019 (boala provocată de coronavirus, 2019)
- CUSUM: CUMulative SUM (of squares) (suma cumulată (a pătratelor))
- EGARCH: Exponential GARCH (GARCH exponențial)
- ETF: Exchange-Traded Fund (fond tranzacționat la bursă)
- FIGARCH: Fractionally Integrated GARCH (GARCH integrat fracționar)
- FTSE: Financial Times Stock Exchange (FTSE Russell, index provider) (furnizorul de indici FTSE Russell)
- GARCH: Generalised AutoRegressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă generalizată)
- GJR-GARCH: Glosten-Jagannathan-Runkle GARCH (GARCH asimetric Glosten-Jagannathan-Runkle)
- HAC: Heteroskedasticity and Autocorrelation Consistent (standard errors) (erori standard robuste la heteroscedasticitate și autocorelație)
- HAR: Heterogeneous AutoRegressive (model) (model autoregresiv heterogen)
- JB: Jarque-Bera (test) (testul de normalitate Jarque-Bera)
- MDD: Maximum DrawDown (scăderea maximă de la vîrf)
- OHLC: Open, High, Low, Close (deschidere, maxim, minim, închidere)
- OLS: Ordinary Least Squares (metoda celor mai mici pătrate)
- QQ: Quantile-Quantile (plot) (graficul cuantilă-cuantilă)
- RMSE: Root Mean Squared Error (rădăcina erorii pătratice medii)
- SE: Standard Error (eroare standard)

Acronime folosite în acest material (2/2)

- SUA: **Statele Unite ale Americii**
- UTC: **Coordinated Universal Time (Temps Universel Coordonné)**
(timpul universal coordonat)
- VIX: **CBOE Volatility Index (indicele de volatilitate CBOE)**

Întrebarea de azi și traseul

- ▣ Întrebarea seminarului: **ce fapte stilizate ale randamentelor rezistă unei inferențe care ține cont de cozile groase și de volatility clustering?**
- ▣ Traseul seminarului
 - ▶ noțiuni necesare azi: cinci slide-uri introductive (cursul are loc după seminar)
 - ▶ randamente, drawdown și momente: A1, A4(a), B1, A3, B2
 - ▶ cozi și dependență: A6, B3, B9, B4; un răspuns AI de corectat: C2
 - ▶ după curs: A7, B11, A10
- ▣ Rezultate de obținut: răspunsurile A, câte o figură și un tabel pentru fiecare exercițiu B, codul corectat din C2, o frază de interpretare pentru fiecare exercițiu
- ▣ Notebook-ul de azi: [deschideți notebook-ul seminarului în Colab](#); fiecare cerință indică secțiunea din notebook
- ▣ Seminar: drd. Antoaneta Amza, antoaneta.amza@csie.ase.ro

Harta exercițiilor

Exercițiu	Întrebare	Tip	Model
A1	cum se adună randamentele în timp?	Rezolvat	–
A4(a)	cît de adînc este un drawdown?	Propus	A1
B1	cît de groase sînt cozile și cît de fragil este kurtosisul?	Rezolvat	–
A3	de la statistică la p-value: JB și Ljung–Box	Rezolvat	–
B2	cît de mare este VaR 1% (Value-at-Risk, valoarea la risc) pentru BET-TR?	Propus	B1
A6	de ce creează volatilitatea aleatoare cozi groase?	Rezolvat	–
B3	sînt randamentele Bitcoin independente?	Rezolvat	–
B9	ce autocorelații rezistă inferenței robuste?	Rezolvat	–
B4	se apropie randamentele de distribuția Normală odată cu orizontul?	Propus	B1, B3
C2	ce este greșit într-un răspuns A1?	Propus	A3, B3, B9
După curs	A7 [Rezolvat], B11 [Rezolvat], A10 [Propus] (grosimea cozii, lărgimea benzii ACF)	temă	A6, B9
Pachete de extindere	A1(c), A2, A4(b–e), A5, A8, A9, A11, B1(d), B5–B8, B10, B12–B15, C1, C3 (opționale)	Rezolvat sau Propus	indicat la fiecare cerință

- **[Rezolvat]**: rezolvarea completă în slide-uri și în notebook, un model de urmat; **[Propus]**: îl rezolvați voi, rezolvarea se discută la seminar
- Partea A: derivări pe hîrtie; Partea B: verificare și inferență pe date reale, fiecare cu o întrebare de interpretare la final; Partea C: întrebări deschise și critica unui răspuns A1

Datele folosite

Serie	Tip de preț	Perioadă	Calendar	Randamente
BET-TR	închidere zilnică	23 sept. 2014 – 18 sept. 2026	zilele de tranzacționare BVB	2.992
Bitcoin	închidere zilnică (USD)	17 sept. 2014 – 18 sept. 2026	în fiecare zi, 24:00 UTC	4.384
EUR/RON	cursul de referință BNR	4 iul. 2005 – 18 sept. 2026	zilele lucrătoare din România	5.352
S&P 500	OHLC zilnic	2 ian. 1990 – 18 sept. 2026	zilele de tranzacționare din SUA	9.245
ETF-ul SPY	OHLC, închidere ajustată (pentru dividende și splituri)	2 ian. 2008 – 18 sept. 2026 (B8)	zilele de tranzacționare din SUA	–
VIX, VIX pe 9 zile	închidere zilnică	doar C3	zilele de tranzacționare din SUA	–

- ▣ Prețurile zilnice din datele cursului, câte o serie pe activ (câmpul folosit: close / adjusted close)
- ▣ EUR/RON este cursul oficial de referință BNR, nu o serie de cotații de piață
- ▣ Unități: randamentele sînt în zecimale în cod și în % pe slide-uri; fiecare serie pe propriul calendar; analizele pe mai multe serii aliniază întîi *prețurile* pe zilele comune

Pregătire: rulați și verificați

```
# secțiunea "Date" din notebook definește load_data(name)
closes = {a: load_data(a)['Close'] for a in
           ['sp500', 'bettr', 'btc', 'eurron']}
rets = {a: np.log(c).diff().dropna()
        for a, c in closes.items()}
r_bet, r_btc = rets['bettr'], rets['btc']
r_eur, r_sp = rets['eurron'], rets['sp500']
for a, r in rets.items():
    print(a, r.index[0].date(), len(r))
```

- Rezultat așteptat: data primului randament și numărul de randamente


Serie	primul randament	T
S&P 500	1990-01-03	9.245
BET-TR	2014-09-24	2.992
Bitcoin	2014-09-18	4.384
EUR/RON	2005-07-05	5.352

- Momente: `scipy.stats.skew` și `kurtosis` (exces de kurtosis, fără corecție de eșantion mic); abateri standard cu `ddof=1`; cuantile cu `numpy.quantile` (liniar)
- Dacă un număr diferă, opriți-vă și verificați seria, tipul de preț și data de început

Notății folosite în toate exercițiile

- ▣ P_t : preț; randament simplu $R_t = P_t/P_{t-1} - 1$; randament logaritmic $r_t = \ln(P_t/P_{t-1})$; T : numărul de randamente
- ▣ $\bar{r}$, $\hat{\sigma}$: media și abaterea standard de selecție; $z_t = (r_t - \bar{r})/\hat{\sigma}$; $x_t = r_t - \bar{r}$
- ▣ **i.i.d.**: independente și identic distribuite, ipoteza de referință a testelor clasice
- ▣ **Asimetria** $\hat{S} = \frac{1}{T} \sum_t z_t^3$; **kurtosisul** $\hat{K} = \frac{1}{T} \sum_t z_t^4$; **excesul de kurtosis** $\hat{K} - 3$ (0 pentru distribuția Normală)
- ▣ **Autocorelația** la lagul k : $\hat{\rho}_k = \sum_{t=k+1}^T x_t x_{t-k} / \sum_{t=1}^T x_t^2$
- ▣ **Anualizarea** cu P intervale de randament pe an: 252 (BET-TR, S&P 500, EUR/RON), 365 (Bitcoin); volatilitatea $\sqrt{P} \hat{\sigma}$
- ▣ **p-value**: probabilitatea, sub H_0 , a unei statistici cel puțin la fel de extreme ca cea observată; nu este probabilitatea ca H_0 să fie adevărată
- ▣ Un exemplu: $P_0 = 100$, $P_1 = 102$: $R_1 = 2,00\%$, $r_1 = \ln 1,02 = 1,98\%$

Prima privire: prețuri, randamente și extreme datate



- Fiecare zi extremă este un eveniment datat: taxa pe activele bancare (19 dec. 2018), crahul din pandemia COVID-19 (martie 2020), deprecierea leului din 2008
- Perioadele calme alternează cu cele agitate în toate cele trei serii
- EUR/RON este aproape plat după 2013
- Întâi privim datele, apoi testăm

Noțiuni necesare azi (1/5): faptele stilizate

- ▣ Seminarul are loc **înaintea** cursului: aceste cinci slide-uri dau doar ce folosesc cerințele de la seminar; detaliile în [Capitolul 1](#), cursul de după seminar
- ▣ **Fapt stilizat**: o proprietate statistică comună multor active, piețe și perioade [Cont \(2001\)](#)
- ▣ Cele patru fapte stilizate de azi
 - ▶ **cozi groase**: zilele extreme sînt mai frecvente decît la distribuția Normală cu aceeași varianță
 - ▶ **volatility clustering**: mișcările mari urmează mișcărilor mari, de orice semn
 - ▶ **lipsa autocorelației liniare**: randamentul de azi nu este o funcție liniară a randamentelor trecute, $\hat{\rho}_k \approx 0$
 - ▶ **gaussianitate prin agregare**: randamentele pe orizonturi mai lungi au cozi mai apropiate de cele ale distribuției Normale

Noțiuni necesare azi (2/5): kurtosis și testul Jarque–Bera

- ▣ **Cozi groase:** se măsoară prin excesul de kurtosis $\hat{K} - 3$, 0 pentru distribuția Normală
 - ▶ o singură zi extremă poate muta mult $\hat{K}$; alternativa robustă este excesul de kurtosis Crow–Siddiqui pe cuantile, $\frac{q_{0,975} - q_{0,025}}{q_{0,75} - q_{0,25}} - 2,91$, 0 pentru distribuția Normală [Kim & White \(2004\)](#)
- ▣ **Jarque–Bera** [Jarque & Bera \(1980\)](#): $JB = T[\hat{S}^2/6 + (\hat{K} - 3)^2/24]$; H_0 : randamente i.i.d. cu distribuția Normală; sub H_0 , $JB \sim \chi^2_2$, valoarea critică la 5% este 5,99
- ▣ Exemplu: $T = 1.000$, $\hat{S} = 0$, $\hat{K} = 6$: $JB = 1.000 \times 9/24 = 375 > 5,99$, respingem H_0

Noțiuni necesare azi (3/5): Value-at-Risk și distribuția Student- t

- ▣ **VaR 1%:** pierderea pe o zi depășită în 1% din zile; $\text{VaR}_\alpha = -q_\alpha$, unde q_α este cuantila de ordin α a randamentului
- ▣ Distribuția Normală: $q_\alpha = \mu + \sigma \Phi^{-1}(\alpha)$, $\Phi^{-1}(0,01) = -2,326$
 - ▶ exemplu: $\mu = 0,05\%$, $\sigma = 1\%$: $q_{0,01} = 0,05 - 2,326 = -2,28\%$, deci $\text{VaR } 1\% = 2,28\%$
- ▣ **Student- t** cu ν grade de libertate: $P(|X| > x)$ scade ca $x^{-\nu}$, deci $\mathbb{E}|X|^p$ este finit doar pentru $p < \nu$ (varianța: $\nu > 2$; kurtosisul: $\nu > 4$)
 - ▶ $t_3^{-1}(0,01) = -4,54$; rescalată la varianță 1, $-4,54\sqrt{1/3} = -2,62$, mai adâncă decât $-2,33$
 - ▶ se estimează prin verosimilitate maximă, cu o locație m și o scală s : `scipy.stats.t.fit`
- ▣ **VaR empiric:** minus cuantila de selecție de 1%; pe eșantionul din care provine este depășit, prin construcție, în 1% din zile

Noțiuni necesare azi (4/5): ACF, Ljung–Box și ARCH-LM

- ▣ **ACF**: autocorelațiile $\hat{\rho}_k$, $k = 1, 2, \dots$; pentru randamente i.i.d. $\hat{\rho}_k \approx N(0, 1/T)$, de aici banda $\pm 1,96/\sqrt{T}$ ($T = 2.500$: $\pm 0,039$)
- ▣ **Volatility clustering** în ACF: $|r_t|$ și r_t^2 sînt autocorelate, deși r_t nu este
- ▣ **Ljung–Box** [Ljung & Box \(1978\)](#): $Q(m) = T(T+2) \sum_{k=1}^m \hat{\rho}_k^2 / (T-k)$, comparat cu χ_m^2 pentru randamente i.i.d.
 - ▶ pe r_t testează predictibilitatea liniară; pe r_t^2 testează volatility clustering
- ▣ **ARCH-LM** [Engle \(1982\)](#): regresați x_t^2 pe o constantă și pe $x_{t-1}^2, \dots, x_{t-q}^2$; $LM = (T-q)R^2$, comparat cu χ_q^2
 - ▶ exemplu: $T = 1.000$, $q = 5$, $R^2 = 0,02$: $LM = 995 \times 0,02 = 19,9 > 11,07$, valoarea critică la 5% a lui χ_5^2 : există volatility clustering

Noțiuni necesare azi (5/5): efectul volatility clustering asupra inferenței

- ▣ **Mixtură de distribuții Normale Clark (1973):** $r_t = \sigma_t \varepsilon_t$ cu σ_t aleator are kurtosisul $3\mathbb{E}\sigma^4/(\mathbb{E}\sigma^2)^2 \geq 3$: cozi groase din șocuri cu distribuția Normală (A6)
- ▣ Când există volatility clustering, $\text{Var}(\hat{\rho}_k) > 1/T$; se estimează prin $\hat{\tau}_k = \sum_{t>k} x_t^2 x_{t-k}^2 / (\sum_t x_t^2)^2$ Lobato, Nankervis & Savin (2001)
 - ▶ banda robustă $\pm 1,96\sqrt{\hat{\tau}_k}$; $\tilde{Q}(m) = \sum_{k=1}^m \hat{\rho}_k^2 / \hat{\tau}_k$ robust, comparat cu χ_m^2 (B9)
 - ▶ exemplu: $T\hat{\tau}_1 = 4$ face banda robustă de $\sqrt{4} = 2$ ori mai largă decât $\pm 1,96/\sqrt{T}$
- ▣ **Gaussianitate prin agregare:** randamentul logaritmic pe h zile este suma a h randamente zilnice; pentru randamente i.i.d. cu excesul de kurtosis zilnic κ , excesul de kurtosis pe h zile este $\kappa/h \rightarrow 0$
- ▣ **QQ-plot:** randamentele standardizate, sortate, față de cuantilele distribuției Normale; o dreaptă înseamnă distribuția Normală, o formă de S înseamnă cozi groase
- ▣ După curs: A7 și B11 estimează exponentul α al cozii din $P(|r_t| > x) \propto x^{-\alpha}$; A10 derivă varianța lui $\hat{\rho}_k$

A1 [Rezolvat]: randamente și anualizare — cerința

▣ Întrebări

- ▶ ce randament se adună în timp?
- ▶ cum devin cifrele zilnice cifre anuale?

- ▣ **Date de intrare:** o acțiune închide la 100, 110, 99, 104,5 în zilele 0–3 și nu plătește dividend; un indice are un randament logaritmico mediu zilnic de 0,04% și o volatilitate zilnică de 1,2%; Bitcoin are o volatilitate zilnică de 3,5%; randamentele sînt necorelate serial, cu varianță constantă

▣ Cerințe

1. Calculați cele trei randamente simple R_t și cele trei randamente logaritmice r_t , toate în %.
2. Calculați randamentele pe 3 zile $P_3/P_0 - 1$ și $\ln(P_3/P_0)$ și comparați-le cu $\sum_t R_t$ și $\sum_t r_t$.
3. Anualizați randamentul logaritmico mediu și volatilitatea indicelui cu $P = 252$.
4. Anualizați volatilitatea Bitcoin și justificați alegerea lui P .


- ▣ **De raportat:** un tabel zi, preț, R_t , r_t și cele trei cifre anuale

- ▣ Notebook: secțiunea A1

A1 [Rezolvat]: rezolvare

t	P_t	R_t	r_t
0	100	—	—
1	110	+10,00%	+9,53%
2	99	-10,00%	-10,54%
3	104,5	+5,56%	+5,41%
sumă		5,56%	4,40%
$0 \rightarrow 3$		4,50%	4,40%

- Randamentele logaritmice se reduc telescopic la $\ln(104,5/100)$; randamentele simple se compun: $1,1 \times 0,9 \times 1,0556 - 1 = 4,5\%$



- Indice: randamentul logaritmic mediu anualizat
 $252 \times 0,04\% = 10,08\%$; volatilitatea
 $\sqrt{252} \times 1,2\% = 15,87 \times 1,2\% = 19,05\%$
- Bitcoin se tranzacționează zilnic: $\sqrt{365} \times 3,5\% = 66,9\%$; cu
 $\sqrt{252}$ s-ar raporta 55,6%, cu 17% prea puțin

A4(a) [Propus]: adîncimea unui drawdown — cerința

▣ **Model:** A1 [Rezolvat]; secțiunea A4 din notebook

▣ **Întrebări**

- ▶ care este cea mai mare pierdere față de un vîrf anterior?
- ▶ cum se compară ea cu rata de creștere?

▣ **Date de intrare:** valorile portofoliului la sfîrșit de an $V_0, \dots, V_5 = 100, 120, 90, 110, 130, 117$; CAGR pe 5 ani 3,19%

▣ **Cerințe:** completați tabelul

1. Vîrfurile curente $M_t = \max_{s \leq t} V_s$.
2. Drawdown-ul $DD_t = V_t / M_t - 1$, ca număr negativ.
3. Drawdown-ul maxim $MDD = \min_t DD_t$, anul în care apare și raportul Calmar $CAGR / |MDD|$.

Anul	0	1	2	3	4	5
V_t	100	120	90	110	130	117
M_t	100	120	...	...	...	...
DD_t	0%	0%	...	...	...	...

▣ **Interpretare:** de ce scăderea la 117 din anul 5 nu este drawdown-ul maxim?

B1 [Rezolvat]: statistici descriptive — cerința

▣ Întrebări

- ▶ cît de groase sînt cozile BET-TR, Bitcoin și EUR/RON?
- ▶ cît depinde kurtosisul de cîteva zile?

▣ **Date:** r_{bet} , r_{btc} , r_{eur} din pregătire ($T = 2.992, 4.384, 5.352$); $P = 252, 365, 252$

▣ Cerințe

1. Calculați media, abaterea standard, volatilitatea anualizată, asimetria, excesul de kurtosis, minimul și maximul fiecărei serii.
2. Calculați $JB = T[\hat{S}^2/6 + (\hat{K} - 3)^2/24]$ și cei doi termeni ai săi; comparați JB cu 5,99, valoarea critică la 5% a lui χ^2_2 .
3. Recalculați fiecare exces de kurtosis după eliminarea zilei cu cel mai mare $|r_t|$ și după eliminarea celor mai mari cinci.
4. Recalculați excesul de kurtosis Crow–Siddiqui pe cuantile, $\frac{q_{0,975} - q_{0,025}}{q_{0,75} - q_{0,25}} - 2,91$, pe aceleași eșantioane reduse (0 pentru distribuția Normală).

▣ **De raportat:** un tabel pentru pașii 1–2 și un grafic al kurtosisului în funcție de numărul de zile eliminate


▣ **Interpretare:** ce măsură a grosimii cozilor puteți raporta cu încredere?

B1 [Rezolvat]: rezolvare (1/2) — BET-TR pas cu pas

- Pasul 1: $\bar{r} = 0,077\%$, $\hat{\sigma} = 0,978\%$; volatilitatea $\sqrt{252} \times 0,978\% = 15,5\%$; $\hat{S} = -1,40$, $\hat{K} - 3 = 17,79$
 - ▶ cea mai slabă zi $-11,86\%$ pe 19 dec. 2018 (taxa pe activele bancare), cea mai bună $+6,71\%$ pe 24 dec. 2018
- Pasul 2: termenul de asimetrie $2.992 \times 1,40^2/6 = 977$; termenul de kurtosis $2.992 \times 17,79^2/24 = 39.455$
 - ▶ $JB = 40.433$: 98% din statistică vine din termenul de kurtosis; $p < 10^{-10}$
- Pasul 3: exces de kurtosis 17,8 cu toate zilele, 11,8 fără 19 dec. 2018, 5,95 fără cele mai mari cinci zile (19 dec. 2018, 16 mar. 2020, 9 mar. 2020, 24 dec. 2018, 9 mar. 2022)
- Pasul 4: Crow-Siddiqui 1,06 cu toate zilele, 1,01 fără cele mai mari cinci zile
- O singură zi aduce o treime din kurtosisul pe momente; măsura pe cuantile aproape nu se modifică

	BET-TR	Bitcoin	EUR/RON
Medie (% pe zi)	0,077	0,118	0,007
Abatere std. (% pe zi)	0,978	3,485	0,279
Volatilitate (% pe an)	15,5	66,6	4,4
Asimetrie	-1,40	-0,70	0,73
Exces de kurtosis	17,8	12,0	15,1
Min (%)	-11,9	-46,5	-2,5
Max (%)	6,7	22,5	2,9
JB	40.433	26.482	51.575
Fără primele 5 zile	5,95	4,24	11,17

B1 [Rezolvat]: rezolvare (2/2) — sensibilitate



- Toate statisticile JB depășesc de peste 4.000 de ori valoarea critică 5,99; Bitcoin fără ziua de 12 mar. 2020: kurtosis 12,0 → 5,3
- Interpretare: cozile sînt groase după ambele măsuri; raportați excesul de kurtosis pe cuantile, a cărui valoare nu depinde de cîteva zile

A3 [Rezolvat]: Jarque–Bera și Ljung–Box, pas cu pas — cerința

▣ Întrebări

- ▶ cum devine o statistică o decizie?
- ▶ de ce ipoteze are nevoie decizia?

▣ Date de intrare: două eșantioane ipotetice de randamente zilnice; teste la pragul de 5%

- ▶ eșantionul 1: $T = 2.500$, asimetria $\hat{S} = -0,5$, kurtosisul $\hat{K} = 8$ (nu excesul)
- ▶ eșantionul 2: $T = 1.000$, $\hat{\rho}_1 = 0,10$, $\hat{\rho}_2 = -0,05$, $\hat{\rho}_3 = 0,03$

▣ Cerințe

1. Calculați cei doi termeni ai $JB = T[\hat{S}^2/6 + (\hat{K} - 3)^2/24]$ Jarque & Bera (1980), statistica și $p = P(\chi_2^2 \geq JB)$.
2. Calculați cei trei termeni ai $Q(3) = T(T + 2) \sum_{k=1}^3 \hat{\rho}_k^2 / (T - k)$ Ljung & Box (1978), statistica și $p = P(\chi_3^2 \geq Q)$.
3. Formulați H_0 pentru fiecare test și ipoteza distribuției de referință χ^2 care eșuează în prezența volatility clustering.


▣ De raportat: termenii, cele două statistici, p-value-urile și deciziile

▣ Notebook: secțiunea A3

A3 [Rezolvat]: rezolvare (1/2) — pas cu pas

1. $\hat{S}^2/6 = 0,25/6 = 0,042$; $(\hat{K} - 3)^2/24 = 25/24 = 1,042$
▶ $JB = 2.500 \times 1,084 = 2.708,3$, $p < 10^{-10}$: respingem; 96% din JB este termenul de kurtosis
2. $0,01/999 = 1,001 \times 10^{-5}$, $0,0025/998 = 0,251 \times 10^{-5}$, $0,0009/997 = 0,090 \times 10^{-5}$
▶ $Q(3) = 1.000 \times 1.002 \times 1,342 \times 10^{-5} = 13,44$, $p = 0,004$: respingem
3. JB: H_0 = i.i.d. și distribuție Normală; Ljung–Box: H_0 = fără autocorelație, dar referința χ^2_3 cere și randamente i.i.d.
▶ în prezența volatility clustering $\text{Var}(\hat{\rho}_k) > 1/T$, iar Q respinge prea des (A10, B9)

A3 [Rezolvat]: rezolvare (2/2) — distribuțiile de referință



- p-value-ul este aria de sub densitatea χ^2 dincolo de statistica observată
- Interpretare: pentru un eșantion i.i.d. ambele respingeri sînt corecte; pentru randamente cu volatility clustering doar respingerea prin JB a ipotezei "i.i.d. și distribuție Normală" este corectă, p-value-ul lui Q(3) este prea mic

B2 [Propus]: cozi groase și VaR 1% pe BET-TR — cerința

- ▣ **Model:** B1 [Rezolvat]; secțiunea B2 din notebook
- ▣ **Întrebare:** cât de mare este pierderea pe o zi depășită în 1% din zile, sub trei distribuții?
- ▣ **Date:** r_{bet} , $T = 2.992$; modelele sînt estimate și verificate pe **același** eșantion: o comparație descriptivă, nu un backtesting (verificarea VaR pe date ulterioare estimării)
- ▣ **Cerințe**
 1. Standardizați $z_t = (r_t - \bar{r})/\hat{\sigma}$ și numărați zilele cu $|z_t| > 3$; comparați ponderea lor cu 0,27% sub distribuția Normală.
 2. Estimați o distribuție Student- t pentru z_t prin verosimilitate maximă (`scipy.stats.t.fit`: grade de libertate ν , locație m , scală s).
 3. Calculați cuantila de 1% a lui z_t ca $q_z = m + s t_{\nu}^{-1}(0,01)$, apoi $q_r = \bar{r} + \hat{\sigma} q_z$ și $\text{VaR}_{1\%} = -q_r$; repetați cu $q_z = \Phi^{-1}(0,01) = -2,326$ și cu cuantila empirică de 1% a lui r_t .
 4. Numărați depășirile ($r_t < q_r$) pentru fiecare VaR și comparați-le cu 0,01 $T = 29,9$.
- ▣ **De raportat:** un tabel metodă / VaR / depășiri și un grafic al cozii stîngi cu cele trei cuantile
- ▣ **Interpretare:** de ce are VaR-ul empiric, prin construcție, circa 30 de depășiri?

A6 [Rezolvat]: kurtosisul unei mixturi de volatilitate — cerința


- ▣ **Întrebare:** poate volatilitatea aleatoare să creeze singură cozi groase?
- ▣ **Ipoteze:** $r_t = \sigma_t \varepsilon_t$, ε_t i.i.d. $N(0, 1)$ și independent de σ_t ; $\sigma_t = 1\%$ cu probabilitatea 0,8 și 2% cu probabilitatea 0,2, extras **independent în fiecare zi**
- ▣ **Cerințe**
 1. Folosind independența și $\mathbb{E}\varepsilon^4 = 3$, arătați că $K = \mathbb{E}r^4 / (\mathbb{E}r^2)^2 = 3 \mathbb{E}\sigma^4 / (\mathbb{E}\sigma^2)^2$.
 2. Completați un tabel cu cele două stări: probabilitatea, σ^2 (în %²) și σ^4 (în %⁴); calculați $\mathbb{E}\sigma^2$, $\mathbb{E}\sigma^4$ și K .
 3. Folosiți inegalitatea lui Jensen, $\mathbb{E}[X^2] \geq (\mathbb{E}X)^2$ cu $X = \sigma^2$, ca să arătați că $K \geq 3$.
 4. Spuneți dacă acest model produce volatility clustering.
- ▣ **De raportat:** tabelul, K și excesul de kurtosis
- ▣ **Interpretare:** legați rezultatul de ipoteza mixturii de distribuții a lui [Clark \(1973\)](#)
- ▣ Notebook: secțiunea A6

A6 [Rezolvat]: rezolvare (1/2) — momente

Stare	Prob.	σ^2	σ^4
calmă	0,8	1	1
agitată	0,2	4	16
medie		1,6	4,0

1. $\mathbb{E}r^4 = \mathbb{E}\sigma^4 \mathbb{E}\varepsilon^4 = 3 \mathbb{E}\sigma^4$ și $\mathbb{E}r^2 = \mathbb{E}\sigma^2$
2. $K = 3 \times 4,0 / 1,6^2 = 12 / 2,56 = 4,69$; excesul de kurtosis 1,69
3. $\mathbb{E}[(\sigma^2)^2] \geq (\mathbb{E}\sigma^2)^2$, cu egalitate doar pentru σ constant: $K \geq 3$
4. Fără volatility clustering: stările sînt independente de la o zi la alta, deci $|r_t|$ este necorelat; A8 le face persistente

A6 [Rezolvat]: rezolvare (2/2) — densități




- $P(|r_t| > 4\%)$: 0,92% în mixtură, 0,16% pentru distribuția Normală cu aceeași varianță
- Interpretare: timpul operațional aleator (ritmul sosirii informației) al lui [Clark \(1973\)](#) este o astfel de mixtură: variația volatilității creează cozi groase

B3 [Rezolvat]: necorelate, dar nu independente (Bitcoin) — cerința

- ▣ **Întrebare:** prezic randamentele trecute ale lui Bitcoin direcția sau doar mărimea randamentului de azi?
- ▣ **Date:** r_{btc} , 18 sept. 2014 – 18 sept. 2026, $T = 4.384$
- ▣ **Cerințe**
 1. Reprezentați randamentele, apoi ACF pentru r_t , $|r_t|$ și r_t^2 la lagurile 1–100, cu banda de referință i.i.d. $\pm 1,96/\sqrt{T} = \pm 0,030$.
 2. Calculați Ljung–Box $Q(10)$ pe r_t și pe r_t^2 (acorr_ljungbox), cu p-value-uri din χ_{10}^2 .
 3. Rulați testul ARCH-LM cu 5 laguri Engle (1982): regresați x_t^2 pe o constantă și pe $x_{t-1}^2, \dots, x_{t-5}^2$ și comparați $(T - 5)R^2$ cu χ_5^2 .
- ▣ **De raportat:** graficul, autocorelațiile de lag 1 și cele trei statistici, fiecare cu seria și ipoteza H_0
- ▣ **Interpretare:** $Q(10)$ pe r_t are $p \approx 3\%$; ținând cont de pasul 3, este validă distribuția lui de referință i.i.d.?
- ▣ Notebook: secțiunea B3

B3 [Rezolvat]: rezolvare (1/2) — randamente și ACF



□ Direcția: nicio structură în ACF a lui r_t ; mărimea: $|r_t|$ și r_t^2 sînt autocorelate pe zeci de laguri


B3 [Rezolvat]: rezolvare (2/2) — teste

1. $\hat{\rho}_1$: $-0,022$ pentru r_t (în interiorul benzii), $0,213$ pentru $|r_t|$ și $0,137$ pentru r_t^2
 2. $Q(10)$ pe r_t : $20,2$, $p = 0,028$; pe r_t^2 : $212,7$, $p \approx 4 \times 10^{-40}$
 3. ARCH-LM(5) = $114,7$, $p \approx 4 \times 10^{-23}$; referința sa χ^2 cere $\mathbb{E}r^4 < \infty$, deci p-value-ul este orientativ
- ☐ Mărimile randamentelor sînt dependente: randamentele nu sînt i.i.d., deci p-value-ul de 2,8% al lui $Q(10)$ pe r_t se sprijină pe o ipoteză falsă
 - ☐ Banda i.i.d. este o referință, nu un test valid pentru $|r_t|$ și r_t^2 ; A10 și B9 corectează inferența pentru r_t

B9 [Rezolvat]: Ljung–Box robust la heteroscedasticitate — cerința

- ▣ **Întrebare:** ce autocorelații ale randamentelor rezistă când varianța lui $\hat{\rho}_k$ ține cont de volatility clustering?
- ▣ **Date:** $r_{\text{sp}}, r_{\text{bet}}, r_{\text{eur}}, r_{\text{btc}}$; $x_t = r_t - \bar{r}$
- ▣ **Cerințe**
 1. Pentru $k = 1, \dots, 20$ calculați $\hat{\rho}_k$ și $\hat{\tau}_k = \sum_{t=k+1}^T x_t^2 x_{t-k}^2 / (\sum_{t=1}^T x_t^2)^2$; reprezentați $\hat{\rho}_k$ cu banda clasică $\pm 1,96/\sqrt{T}$ și banda robustă $\pm 1,96\sqrt{\hat{\tau}_k}$ [Lobato, Nankervis & Savin \(2001\)](#).
 2. Calculați $Q(10)$ clasic și $\tilde{Q}(10) = \sum_{k=1}^{10} \hat{\rho}_k^2 / \hat{\tau}_k$ robust; comparați-le cu χ_{10}^2 (valoarea critică la 5%: 18,3).
 3. Numărați lagurile dintre 1 și 20 aflate în afara fiecărei benzi: sînt verificări punctuale, diferite de testul comun pe 10 laguri de la pasul 2.
- ▣ **Ipotezele lui $\tilde{Q}$:** $\mathbb{E}r^4 < \infty$ și termeni încrucișați nuli, $\mathbb{E}[x_t^2 x_{t-k} x_{t-l}] = 0$ pentru $k \neq l$
- ▣ **Interpretare**
 - pentru ce serii rezistă autocorelația?
 - este credibilă ipoteza momentului de ordinul patru?
- ▣ Notebook: secțiunea B9

B9 [Rezolvat]: rezolvare (1/2) — ACF cu ambele benzi



- S&P 500, lagul 1: $\hat{\rho}_1 = -0,079$, $T\hat{\tau}_1 = 5,00$; banda robustă este $1,96\sqrt{5,00/9.245} = 0,046$, nu 0,020
- La lagul 1 banda robustă este de $\sqrt{T\hat{\tau}_1} = 1,7$ (Bitcoin) până la 2,6 (EUR/RON) ori mai largă decât cea clasică

B9 [Rezolvat]: rezolvare (2/2) — teste comune și interpretare

	S&P 500	BET-TR	EUR/RON	Bitcoin
$Q(10)$ (p)	91,6 ($< 10^{-10}$)	70,0 ($< 10^{-10}$)	221,7 ($< 10^{-10}$)	20,2 (0,028)
$\tilde{Q}(10)$ (p)	19,0 (0,041)	16,9 (0,076)	37,4 ($< 0,001$)	11,9 (0,29)
Laguri în afară, clasic / robust	8 / 3	5 / 2	6 / 2	3 / 0
Laguri în afara benzii robuste	1, 15, 16	2, 10	1, 3	niciunul

- La 5%, testul clasic respinge pentru toate cele patru serii; testul robust respinge doar pentru S&P 500 (la limită) și EUR/RON
- Bitcoin (B3): p-value-ul de 2,8% devine 29%: nicio dovadă de autocorelație liniară la lagurile 1–10
- EUR/RON păstrează $\hat{\rho}_1 = 0,17$: în regimul de managed float, cursul de referință BNR se ajustează în pași mici, pe mai multe zile
- Ipoteze rămase: testul lui [Dalla, Giraitis & Phillips \(2022\)](#), care păstrează doar termenii încrucișați semnificativi, nu găsește niciunul pentru S&P 500, BET-TR și Bitcoin
- Dacă $P(|r_t| > x)$ scade ca $x^{-\nu}$ cu $\nu \leq 4$, $\mathbb{E}r^4$ este infinit și p-value-urile robuste nu sînt valide; A7 și B11 estimează acest exponent după curs

B4 [Propus]: gaussianitate prin agregare (Bitcoin) — cerința

- ▣ **Model:** B1 și B3 [Rezolvat]; secțiunea B4 din notebook
- ▣ **Întrebare:** se apropie randamentele Bitcoin pe h zile de distribuția Normală când h crește?
- ▣ **Date:** r_btc , $T = 4.384$; blocuri care nu se suprapun, începînd cu prima zi: primul bloc de 5 zile este 18–22 sept. 2014, al doilea 23–27 sept. 2014; ultimul bloc incomplet (4 zile pentru $h = 5$ și $h = 20$) se elimină
- ▣ **Cerințe**
 1. Construiți randamentele logaritmice pe h zile (sume de h randamente zilnice consecutive) pentru $h = 1, 5, 20$.
 2. Desenați un QQ-plot al fiecărei serii standardizate față de distribuția Normală, cu N , numărul de blocuri, în titlu.
 3. Calculați excesul de kurtosis și SE de referință pentru date i.i.d. cu distribuție Normală, $\sqrt{24/N}$.
- ▣ **De raportat:** cele trei QQ-plot-uri și un tabel h , N , exces de kurtosis, $\sqrt{24/N}$
- ▣ **Interpretare**
 - ▶ de ce este $\sqrt{24/N}$ prea optimistă aici?
 - ▶ de ce blocurile care nu se suprapun elimină zilele comune, dar nu și dependența volatilității?

C2 [Propus]: critica unui răspuns AI — răspunsul

- **Promptul** trimis unui asistent AI: “Sînt randamentele logaritmice zilnice ale BET-TR distribuite Normal? Sînt autocorelate? Dă cod Python și o concluzie”
- **Răspunsul:** codul de mai jos și concluzia

```
from scipy import stats
from statsmodels.stats.diagnostic import acorr_ljungbox
r = np.log(bet["close"]).diff().dropna()      # daily log returns
k = stats.kurtosis(r)                          # sample kurtosis
print("excess_kurtosis:", k - 3)               # the Normal has kurtosis 3
jb, p = stats.jarque_bera(r)
lb = acorr_ljungbox(r**2, lags=[10])          # Ljung-Box, 10 lags
```

- **Concluzia asistentului**
 - ▶ “Exces de kurtosis 14,8: cozi groase”
 - ▶ “p-value JB 0,000: probabilitatea ca randamentele BET-TR să urmeze distribuția Normală este 0%”
 - ▶ “Ljung-Box $Q(10) = 713,5$, $p < 0,001$: randamentele sînt puternic autocorelate, deci BET-TR este predictibil și nu este un mers aleator”

C2 [Propus]: critica unui răspuns AI — cerința

- ▣ **Model:** A3, B3 și B9 [Rezolvat]; secțiunea C2 din notebook
- ▣ **Date:** `r_bet`, cele 2.992 de randamente din pregătire
- ▣ **Cerințe**
 1. Găsiți toate erorile de fond din cod și din cele trei concluzii.
 2. Pentru fiecare eroare spuneți cum ați detecta-o: un test pe date simulate, o cifră din slide-urile introductive, un exercițiu rezolvat sau documentația bibliotecii.
 3. Scrieți cod corectat, executabil, și raportați excesul de kurtosis, JB cu p-value-ul său, $Q(10)$ pe r_t și pe r_t^2 și $\tilde{Q}(10)$ robust din B9.
 4. Formulați ipotezele din spatele p-value-ului robust.
 5. Scrieți concluzia corectată în trei fraze.
- ▣ **De raportat:** codul corectat, un tabel valoare AI / valoare corectă, un grafic al ACF pentru r_t și r_t^2
- ▣ Codul generat de AI rulează de obicei fără mesaj de eroare: greșelile sînt de statistică, nu de sintaxă; notați ce găsiți în `AI_ERRORS.md`

A7 [Rezolvat]: estimatorul Hill, pas cu pas — cerința

▣ Întrebări

- ▶ cum se estimează un tail index din cele mai mari observații?
- ▶ cît de precis este?

▣ **Date de intrare:** cele mai mari 11 randamente zilnice absolute (%) ale unui eșantion ipotetic: 12,0; 9,5; 8,2; 7,4; 6,9; 6,1; 5,8; 5,5; 5,2; 5,0; 4,8

▣ **Ipoteză:** deasupra pragului $X_{(k+1)}$ coada este Pareto, $P(X > x) \propto x^{-\alpha}$, iar observațiile sînt independente


▣ Cerințe

1. Pentru $k = 10$ calculați log-rapoartele $\ln(X_{(i)}/X_{(11)})$, media lor și $\hat{\alpha} = 1/\text{medie}$ Hill (1975).
2. Calculați $SE = \hat{\alpha}/\sqrt{k}$ și intervalul $\hat{\alpha} \pm 1,96 SE$.
3. Spuneți ce momente $\mathbb{E}|X|^p$ ($p < \alpha$) există la estimarea punctuală și ce afirmații rămîn valabile la 95%.
4. Repetați pașii 1–2 pe cele mai mari 11 valori $|r_t|$ ale BET-TR, folosind tabelul afișat de notebook.

▣ **De raportat:** $\hat{\alpha}$, SE și intervalul pentru ambele eșantioane

▣ Notebook: secțiunea A7

A7 [Rezolvat]: rezolvare (1/2) — eșantionul ipotetic



1. Etichetele sînt log-rapoartele față de 4,8; suma 3,616, media 0,3616, $\hat{\alpha} = 1/0,3616 = 2,77$
2. $SE = 2,77/\sqrt{10} = 0,87$; intervalul $[1,05; 4,48]$, o aproximare grosieră prin distribuția Normală, valabilă pentru cozi Pareto i.i.d.
3. La 2,77 varianța există, iar momentul de ordinul patru nu, dar intervalul conține valori sub 2 și peste 4: nicio afirmație nu rezistă la 95%

A7 [Rezolvat]: rezolvare (2/2) — tabelul BET-TR


i	Data	r_t (%)	$X_{(i)}$ (%)	$\ln(X_{(i)}/X_{(11)})$
1	19 dec. 2018	-11,857	11,857	0,824
2	16 mar. 2020	-10,075	10,075	0,661
3	9 mar. 2020	-7,827	7,827	0,409
4	24 dec. 2018	+6,707	6,707	0,254
5	9 mar. 2022	+6,662	6,662	0,247
6	24 aug. 2015	-6,512	6,512	0,225
7	24 mar. 2020	+5,972	5,972	0,138
8	17 mar. 2020	+5,928	5,928	0,131
9	4 mar. 2022	-5,490	5,490	0,054
10	12 mar. 2020	-5,285	5,285	0,016
11	18 ian. 2016	-5,202	5,202	prag

- Primul rând, calculat:
 $\ln(11,857/5,202) = \ln 2,279 = 0,824$
- Suma celor zece log-raapoarte 2,958;
 $\hat{\alpha}_{10} = 10/2,958 = 3,38$
- $SE = 3,38/\sqrt{10} = 1,07$; intervalul [1,28; 5,48]
- Șapte dintre cele zece zile sînt în decembrie 2018 sau martie 2020: extremele se grupează, deci SE i.i.d. subestimează incertitudinea
- Interpretare: zece observații nu pot decide dacă momentul de ordinul patru există; B11 folosește $k = 2\%$ din n

B11 [Rezolvat]: Hill pe ambele cozi, BET-TR și Bitcoin — cerința

- ▣ **Întrebare:** sînt pierderile mari mai frecvente decît câștigurile mari de aceeași mărime?
- ▣ **Date:** r_{bet} ($n = 2.992$), r_{btc} ($n = 4.384$); pierderi $\text{loss} = -r[r < 0]$, câștiguri $\text{gain} = r[r > 0]$, fiecare ordonat descrescător
- ▣ **Cerințe**
 1. Reprezentați estimarea Hill $\hat{\alpha}(k)$ pentru fiecare coadă, cu k de la 1% la 10% din n al întregului eșantion, cu banda $\hat{\alpha}(1 \pm 1,96/\sqrt{k})$.
 2. Calculați $\hat{\alpha}_-$ (pierderi) și $\hat{\alpha}_+$ (câștiguri) la $k = \lfloor 0,02 n \rfloor$ (BET-TR 59, Bitcoin 87), cu intervale de 95%; cursul folosește $k = 2,5\%$ din n pentru $|r_t|$, care combină ambele cozi.
 3. Calculați statistica aproximativă pentru cozi independente $z = (\hat{\alpha}_- - \hat{\alpha}_+)/\sqrt{\hat{\alpha}_-^2/k + \hat{\alpha}_+^2/k}$ și p-value-ul ei bilateral.
 4. Comparați cu $\hat{v}$ al distribuției Student- t estimate pe randamentele standardizate: 3,10 pentru BET-TR (B2), 2,23 pentru Bitcoin.
- ▣ **Interpretare**
 - ▶ este asimetria câștig/pierdere stabilită statistic?
 - ▶ gruparea extremelor în timp face SE adevărată mai mare sau mai mică?
- ▣ Notebook: secțiunea B11

B11 [Rezolvat]: rezolvare (1/2) — graficele Hill și estimările



□ BET-TR: $\hat{\alpha}_- = 2,19$ [1,63; 2,75], $\hat{\alpha}_+ = 3,08$ [2,30; 3,87]; Bitcoin: $\hat{\alpha}_- = 2,89$ [2,28; 3,50], $\hat{\alpha}_+ = 3,62$ [2,86; 4,38]

□ De exemplu, pierderile BET-TR: $2,19 \times (1 \pm 1,96/\sqrt{59}) = 2,19 \times (1 \pm 0,255)$

B11 [Rezolvat]: rezolvare (2/2) — testul și interpretarea

- ▣ BET-TR: $\sqrt{2,19^2/59 + 3,08^2/59} = \sqrt{0,0812 + 0,1612} = 0,492$; $z = (2,19 - 3,08)/0,492 = -1,82$, $p = 0,069$
- ▣ Bitcoin: $\sqrt{2,89^2/87 + 3,62^2/87} = 0,497$; $z = (2,89 - 3,62)/0,497 = -1,47$, $p = 0,14$
- ▣ Decizie: pierderile au cozi mai groase pe ambele piețe, dar $H_0: \alpha_- = \alpha_+$ nu este respinsă la 5%
 - ▶ statistica tratează cele două cozi ca eșantioane independente; extremele se grupează în timp, deci SE adevărată este mai mare, iar dovada mai slabă
 - ▶ un bootstrap comun pe blocuri al randamentelor originale păstrează ambele trăsături (extindere)
- ▣ $\hat{\nu}$ este estimat pe toată distribuția; valoarea 2,23 pentru Bitcoin este sub ambii tail index-uri: Student- t nu poate descrie simultan partea centrală și cozile, pe cînd $\hat{\alpha}$ folosește doar coada

A10 [Propus]: lărgirea benzii autocorelației în prezența volatility clustering — cerința

- ▣ **Model:** A6 [Rezolvat]; secțiunea A10 din notebook
- ▣ **Cadru:** $x_t = \sigma_t \varepsilon_t$, cu ε_t i.i.d. $N(0, 1)$, independent de procesul staționar al volatilității; atunci x_t este necorelat și $\text{Var}(\hat{\rho}_1) \approx v_1 / T$, cu $v_1 = \mathbb{E}[x_t^2 x_{t-1}^2] / (\mathbb{E}x_t^2)^2$ [Lobato, Nankervis & Savin \(2001\)](#)
- ▣ **Date de intrare:** A6: $\mathbb{E}\sigma^2 = 1,6$, $\text{Var}(\sigma^2) = 4,0 - 1,6^2 = 1,44$ (în %⁴); regimuri persistente (A8): $\text{Cov}(\sigma_t^2, \sigma_{t-1}^2) = \lambda \text{Var}(\sigma^2)$ cu $\lambda = 0,875$; S&P 500: $T = 9.245$, $\hat{\rho}_1 = -0,079$, $T\hat{\rho}_1 = 5,00$
- ▣ **Cerințe**
 1. Arătați că $v_1 = 1$ pentru mixtura din A6, ale cărei stări sînt independente de la o zi la alta.
 2. Arătați că $v_1 = 1 + \lambda \text{Var}(\sigma^2) / (\mathbb{E}\sigma^2)^2$ pentru regimuri persistente; calculați-l, împreună cu factorul de lărgire a benzii $\sqrt{v_1}$.
 3. Calculați statistica t pentru lagul 1 al S&P 500 cu SE i.i.d. $1/\sqrt{T}$ și cu SE robustă $\sqrt{\hat{\rho}_1}$, plus cele două semilățimi ale benzii de 95%.
- ▣ **Interpretare:** ce lărgște banda: cozile groase sau volatilitatea persistentă?

După curs: cerințele rămase

- ▣ Aceste trei cerințe folosesc instrumente introduse în [Capitolul 1](#): lucrați-le după curs, înaintea seminarului următor
 - ▶ A7 [Rezolvat] și B11 [Rezolvat]: estimatorul Hill al tail index-ului, pas cu pas și pe ambele cozi
 - ▶ A10 [Propus]: volatility clustering, nu cozile groase, lărgeste banda autocorelației din B9
- ▣ Rezolvarea A10 se discută la seminarul următor

Pachete de extindere: conținut și cunoștințe necesare

Pachet	Exerciții	Cunoștințe necesare
1. Aritmetica randamentelor și drawdown	A1(c) [Rezolvat], A2, A4(b–e)	A1, A4(a)
2. Mixturi, regimuri și cozi	A5 [Rezolvat], A8, A9, A11	A6, A7, A10
3. Momente robuste și verificarea modelelor	B1(d) [Rezolvat], B10, B14	B1, B9, B11
4. Dependență și asimetrie	B5, B12, B6, B15	B3, B9
5. Randament ajustat la risc și estimatori de range volatility	B7, B13, B8	A1, A5, B1
6. Proiecte	C1, C3	B9, studiul de caz din curs

- Secțiunile din notebook poartă aceleași etichete ca exercițiile
- Rezolvările exercițiilor [Propus] se discută la seminarul următor

A1(c) [Rezolvat]: randamentul unui portofoliu — cerința și rezolvarea

- ▣ **Întrebare:** ce randament se adună între active?
- ▣ **Date de intrare:** 60% în activul A și 40% în activul B, pentru o zi; $R_A = +5\%$, $R_B = -2\%$
- ▣ **Cerințe**
 1. Calculați randamentul simplu al portofoliului $R_p = 0,6R_A + 0,4R_B$.
 2. Calculați randamentul logaritmic ponderat $0,6r_A + 0,4r_B$ și randamentul logaritmic adevărat al portofoliului $\ln(1 + R_p)$.
- ▣ **Rezolvare**
 1. $R_p = 0,6 \times 5\% + 0,4 \times (-2\%) = 2,20\%$
 2. $0,6 \times \ln 1,05 + 0,4 \times \ln 0,98 = 0,6 \times 4,879\% - 0,4 \times 2,020\% = 2,119\%$, în timp ce $\ln 1,022 = 2,176\%$
- ▣ **Interpretare:** randamentele simple se adună între active, cele logaritmice în timp (A1); pentru mișcări zilnice diferența dintre cele două reguli este mică, pentru mișcări mari nu

A2 [Propus]: regula $\sqrt{h}$ în prezența autocorelației — cerința

- ▣ **Model:** A1 [Rezolvat]; secțiunea A2 din notebook
- ▣ **Ipoteză:** AR(1) staționar, $r_t = \rho r_{t-1} + e_t$, $|\rho| < 1$, $\text{Var}(r_t) = \sigma^2$, deci $\gamma_j = \text{Cov}(r_t, r_{t-j}) = \sigma^2 \rho^j$
- ▣ **Punct de plecare**, $h = 3$: $\text{Var}(r_1 + r_2 + r_3) = 3\gamma_0 + 2(2\gamma_1 + \gamma_2)$: două perechi la lagul 1, o pereche la lagul 2
- ▣ **Cerințe**
 1. Generalizați numărarea perechilor: arătați că $\text{Var}(\sum_{j=1}^h r_{t+j}) = h\sigma^2[1 + 2\sum_{j=1}^{h-1}(1-j/h)\rho^j]$.
 2. Folosind $\sum_{j=1}^{h-1} \rho^j = \rho(1 - \rho^{h-1})/(1 - \rho)$ și $\sum_{j \geq 1} j|\rho|^j = |\rho|/(1 - |\rho|)^2$, arătați că raportul varianțelor $VR(h) = \text{Var}(\cdot)/(h\sigma^2) \rightarrow (1 + \rho)/(1 - \rho)$.
 3. Calcul ilustrativ: tratați autocorelațiile de lag 1 de selecție ca parametri AR(1), EUR/RON $\rho = 0,170$ (volatilitate 4,44%), S&P 500 $\rho = -0,079$ (17,99%); calculați $\sqrt{VR(252)}$ și volatilitățile anuale corectate.
 4. Explicați de ce volatility clustering, singur, nu schimbă rezultatul de la pasul 1.
- ▣ **Interpretare:** ce verificare a ACF trebuie făcută înaintea pasului 3?

A4(b–e) [Propus]: un reper pentru drawdown — cerința

- ▣ **Model:** A4(a); secțiunea A4 din notebook
- ▣ **Ipoteză:** logaritmul prețului este $X_t = \mu t + \sigma W_t$, cu W_t o mișcare browniană standard, σ volatilitatea anuală, T orizontul în ani; drawdown-ul maxim logaritm $D = \max_{s \leq t \leq T} (X_s - X_t) = -\ln(1 + MDD)$; pentru $\mu = 0$:
 $\mathbb{E}[D] = \sqrt{\pi/2} \sigma \sqrt{T}$ Magdon-Ismail et al. (2004)
- ▣ **Date de intrare:** aur spot, 1990–2026: $\sigma = 16,3\%$, $T = 36,7$ ani, $MDD = -44,7\%$ observat ($D = 0,592$),
randament logaritm mediu $6,5\%$ pe an
- ▣ **Cerințe**
 1. Folosiți $W(cT) \stackrel{d}{=} \sqrt{c} W(T)$ ca să explicați de ce $\mathbb{E}[D]$ este proporțional cu $\sqrt{T}$ când $\mu = 0$.
 2. Calculați raportul valorilor $\mathbb{E}[D]$ pentru 40 și 10 ani ai aceluiași proces.
 3. Calculați reperul fără drift pentru aur și comparați-l cu D observat.
 4. Simulați 2.000 de traiectorii zilnice (seed 42) cu $\mu = 0$ și cu $\mu = 6,5\%$ și reprezentați media lui D în funcție de T .
- ▣ **Interpretare:** ce implică pașii 1–4 pentru rapoartele Calmar calculate pe eșantioane de lungimi diferite?


A5 [Rezolvat]: volatilitatea Parkinson și eficiența ei — cerința

- ▣ **Întrebare:** câtă informație despre volatilitate conține amplitudinea zilnică?
- ▣ **Notații:** o_t, h_t, l_t, c_t = logaritmi deschiderii, maximului, minimului și închiderii; $h_t - l_t = \ln(H_t/L_t)$
- ▣ **Date de intrare:** H/L pentru cinci zile: 1,020, 1,015, 1,030, 1,010, 1,025; $P = 252$
- ▣ **Ipoteză:** în timpul zilei logaritmul prețului este o mișcare browniană fără drift, cu volatilitatea σ ; fără salturi peste noapte
- ▣ **Cerințe**
 1. Completați un tabel cu cinci rînduri: $\ln(H/L)$, pătratul său și media pătratelor.
 2. Calculați $\hat{\sigma}_P^2 = \overline{(h-l)^2}/(4 \ln 2)$ Parkinson (1980), volatilitatea zilnică și cea anuală.
 3. Spuneți ce informație ignoră estimatorul și ce efect are un drift puternic.
 4. Folosind $\mathbb{E}[(h-l)^2] = 4 \ln 2 \sigma^2$ și $\mathbb{E}[(h-l)^4] = 9\zeta(3) \sigma^4$ ($\zeta(3) = 1,202$), comparați varianța zilnică a lui $(h-l)^2/(4 \ln 2)$ cu $\text{Var}(r_t^2) = 2\sigma^4$.
- ▣ Notebook: secțiunea A5

A5 [Rezolvat]: rezolvare (1/2) — estimarea

H/L	$\ln(H/L)$	pătrat ($\times 10^{-4}$)
1,020	0,0198	3,92
1,015	0,0149	2,22
1,030	0,0296	8,74
1,010	0,0100	0,99
1,025	0,0247	6,10
medie		4,39

- $\hat{\sigma}_P^2 = 0,000439/2,7726 = 0,000158$; $\hat{\sigma}_P = 1,26\%$ pe zi, $1,26\% \times 15,87 = 20,0\%$ pe an
- Ignore: deschiderea și saltul de peste noapte Yang & Zhang (2000); un drift mărește amplitudinea și deplasează $\hat{\sigma}_P$ în sus Rogers & Satchell (1991)



- O zi simulată: amplitudinea $h_t - l_t$ folosește toată traiectoria, randamentul close-to-close doar capetele ei

A5 [Rezolvat]: rezolvare (2/2) — eficiența

4. $\text{Var}((h - l)^2) = (9\zeta(3) - 16(\ln 2)^2)\sigma^4 = (10,819 - 7,687)\sigma^4 = 3,131\sigma^4$

- ▶ împărțit la $(4 \ln 2)^2 = 7,687$: $0,407\sigma^4$ pe zi pentru termenul Parkinson
- ▶ close-to-close: $\text{Var}(r_t^2) = 3\sigma^4 - \sigma^4 = 2\sigma^4$ pe zi

- Pentru o medie pe n zile independente, ambele varianțe se împart la n : raportul rămîne $2/0,407 = 4,9$
- O zi de amplitudini conține aproximativ informația a cinci zile de randamente close-to-close
- Interpretare: câștigul presupune tranzacționare continuă, fără drift și fără salturi peste noapte; o deschidere învechită afectează estimatorii care folosesc deschiderea (Garman–Klass, Rogers–Satchell, Yang–Zhang), nu Parkinson (B8)

A8 [Propus]: originea autocorelației lui r_t^2 — cerința

- ▣ **Model:** A6 [Rezolvat] și A10; secțiunea A8 din notebook
- ▣ **Ipoteză:** ca în A6, $\sigma_t^2 \in \{1, 4\}$ (în %²), cu probabilitățile staționare (0,8; 0,2), dar starea urmează un lanț Markov cu două stări [Hamilton \(1989\)](#) cu matricea de tranziție $\begin{pmatrix} 0,975 & 0,025 \\ 0,1 & 0,9 \end{pmatrix}$ (rînduri: azi calm L , agitat H); $p_{LL} = 0,975$ și $p_{HH} = 0,9$ sînt probabilitățile de a rămîne în aceeași stare, $\pi_H = 0,2$
- ▣ **Cerințe**
 1. Verificați condiția de echilibru $0,8 \times 0,025 = 0,2 \times 0,1$ și calculați $\lambda = p_{LL} + p_{HH} - 1$.
 2. Cu indicatorul $I_t = 1$ în starea agitată, $\sigma_t^2 = 1 + 3I_t$; arătați că $\text{Cov}(I_t, I_{t-k}) = \pi_H(1 - \pi_H)\lambda^k$, deci $\text{Cov}(r_t^2, r_{t-k}^2) = \text{Var}(\sigma^2)\lambda^k$ pentru $k \geq 1$.
 3. Folosind A6, calculați $\text{Var}(\sigma^2)$, $\text{Var}(r^2) = 3\mathbb{E}\sigma^4 - (\mathbb{E}\sigma^2)^2$ și $\text{corr}(r_t^2, r_{t-k}^2)$ la lagurile 1 și 10.
 4. Reprezentați ACF implicată față de ACF a lui r_t^2 pentru S&P 500 (0,31 la lagul 1, 0,04 la lagul 100).
- ▣ **Interpretare:** ce două trăsături ale datelor nu poate reproduce acest model?

A9 [Propus]: cozile S&P 500 într-un GARCH cu inovații Normale — cerința

- ▣ **Model:** A6 [Rezolvat]; o anticipare a [Capitolului 5](#); secțiunea A9 din notebook
- ▣ **Ecuațiile modelului Bollerslev (1986):** $r_t = \mu + \varepsilon_t$, $\varepsilon_t = \sigma_t z_t$, z_t i.i.d. $N(0, 1)$, $\sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2 + \beta \sigma_{t-1}^2$, $\omega > 0$, $\alpha, \beta \geq 0$, $\alpha + \beta < 1$; aici α este un coeficient GARCH, nu tail index-ul
- ▣ **Rezultat:** dacă $1 - (\alpha + \beta)^2 - 2\alpha^2 > 0$, atunci $K = 3[1 - (\alpha + \beta)^2]/[1 - (\alpha + \beta)^2 - 2\alpha^2]$
- ▣ **Cerințe**
 1. Calculați K pentru $(\alpha, \beta) = (0,10; 0,85)$ și $(0,10; 0,88)$.
 2. Formulați condiția pentru un moment de ordinul patru finit și comparați-o cu $\alpha + \beta < 1$.
 3. Cu $\alpha + \beta = 0,99$, găsiți α care dă kurtosisul S&P 500, $K = 13,9$.
 4. Estimați modelul pe `r_sp` în % (`arch_model(100*r_sp, mean='Constant', vol='GARCH', p=1, q=1, dist='normal')`); calculați K implicat și desenați QQ-plot-ul lui $\hat{z}_t = \hat{\varepsilon}_t / \hat{\sigma}_t$.
- ▣ **Interpretare:** ce spune QQ-plot-ul despre distribuția Normală a lui z_t ?

A11 [Propus]: estimatorul Hill ca estimator de verosimilitate maximă — cerința

- ▣ **Model:** A7 [Rezolvat]; secțiunea A11 din notebook
- ▣ **Ipoteză:** dat pragul $u = X_{(k+1)}$, cele k depășiri sînt statisticile de ordine ale unui eșantion Pareto i.i.d. cu densitatea $f(x) = \alpha u^\alpha x^{-\alpha-1}$, $x > u$
- ▣ **Cerințe**
 1. Scrieți log-verosimilitatea $\ell(\alpha)$ a celor k depășiri (ordonarea adaugă doar constanta $\ln k!$).
 2. Rezolvați $\ell'(\alpha) = 0$ și arătați că maximul este estimatorul Hill $\hat{\alpha} = k / \sum_{i=1}^k \ln(X_{(i)}/u)$ Hill (1975).
 3. Calculați $\ell''(\alpha)$, informația k/α^2 și $\text{SE}(\hat{\alpha}) \approx \hat{\alpha}/\sqrt{k}$; verificați pe datele din A7.
 4. Simulați $n = 2.000.000$ de valori $|X|$, X Student- t cu $\nu = 3$ (`numpy.random.default_rng(1)`); reprezentați $\hat{\alpha}_k$ în funcție de k/n și raportați $k = 200, 2.000, 20.000, 200.000$.
- ▣ **Interpretare:** de ce se îndepărtează $\hat{\alpha}_k$ de 3 cînd k este mare?

B1(d) [Rezolvat]: momente pe cuantile, cu intervale bootstrap

- ▣ **Întrebare:** se confirmă asimetria negativă și excesul de kurtosis cu măsuri care nu presupun existența momentelor?
- ▣ **Măsuri Kim & White (2004):** asimetria Hinkley $\frac{q_{0,95} + q_{0,05} - 2q_{0,5}}{q_{0,95} - q_{0,05}}$ și kurtosisul Crow–Siddiqui $\frac{q_{0,975} - q_{0,025}}{q_{0,75} - q_{0,25}} - 2,91$; ambele 0 pentru distribuția Normală
- ▣ **Bootstrap:** extrageți uniform $\lceil T/20 \rceil$ zile de start, luați câte 20 de randamente consecutive de la fiecare, tăiați la T ; recalculați ambele măsuri; 1.000 de reeșantionări (`default_rng(42)`); interval de percentile de 95%

	Asimetrie (momente)	Hinkley [CI 95%]	Exces kurt.	Crow–Siddiqui [CI 95%]
BET-TR	−1,40	−0,036 [−0,085; 0,025]	17,8	1,06 [0,73; 1,43]
Bitcoin	−0,70	−0,018 [−0,069; 0,032]	12,0	2,25 [1,88; 2,64]
EUR/RON	0,73	0,041 [−0,022; 0,093]	15,1	4,87 [3,74; 6,13]

- ▣ Toate intervalele pentru kurtosis sînt peste 0: cozile groase sînt confirmate fără a folosi momente
- ▣ Asimetria pe momente și asimetria Hinkley măsoară lucruri diferite; toate intervalele Hinkley conțin 0, ceea ce nu dovedește simetria

B10 [Propus]: un kurtosis care nu converge — cerința

- ▣ **Model:** B1 [Rezolvat]; secțiunea B10 din notebook
- ▣ **Date:** `r_sp`; fereastra n = randamentele date înainte de 3 ianuarie al anului $1990 + n$, $n = 1, \dots, 36$ (253 de randamente pentru $n = 1$, 2.527 pentru $n = 10$, 9.067 pentru $n = 36$)
- ▣ **Simulare:** 500 de traiectorii Student- t de lungime 9.245 pentru $\nu = 3$ și pentru $\nu = 6$ (`default_rng(42)`), tăiate la aceleași lungimi de fereastră
- ▣ **Cerințe**
 1. Calculați excesul de kurtosis al S&P 500 pe fiecare fereastră și listați cele mai mari trei salturi, cu zilele care le produc.
 2. Pentru fiecare ν calculați cuantilele de 5%, 50% și 95% ale kurtosisului simulat pentru fiecare n .
 3. Reprezentați curba datelor peste ambele benzi, pe o scală logaritmică simetrică.
- ▣ **Interpretare**
 - ▶ de ce se stabilizează încet banda pentru $\nu = 6$, deși kurtosisul lui t_6 este finit?
 - ▶ ce înseamnă atunci “exces de kurtosis = 10,9”?

B14 [Propus]: faptele stilizate reproduse de GARCH- t — cerința

- Model: B3 și B11 [Rezolvat], A9; secțiunea B14 din notebook
- Date: r_sp transformat în % ($T = 9.245$); medie constantă; ω în %² pe zi

```
from arch import arch_model
from arch.univariate import StudentsT
am = arch_model(100 * r_sp, mean='Constant', vol='GARCH', p=1, q=1, dist='t')
res = am.fit(displ='off')
am.distribution = StudentsT(seed=np.random.default_rng(42)) # reproducible paths
sim = am.simulate(res.params, nobs=len(r_sp), burn=1000)['data']
```

Cerințe

- Estimați modelul și listați toți cei cinci parametri, cu unitățile lor.
- Verificare: simulați o traiectorie și calculați-i excesul de kurtosis; apoi rulați 200 de traiectorii.
- Pentru fiecare traiectorie calculați excesul de kurtosis, ACF a lui $|r_t|$ la lagurile 1, 20, 100, 250, $\hat{\alpha}$ Hill pentru $|r_t|$ la $k = 2\%$ din T și $L(1) = \text{corr}(r_t, |r_{t+1}|)$.
- Construiți intervalele punctuale de 5–95% și marcați fiecare valoare observată ca fiind în interior sau în afară.

Interpretare

- ce fapte nu sînt reproduse?
- ce componentă a modelului ați schimba pentru fiecare?

B5 [Propus]: efectul de levier, BET-TR față de Bitcoin — cerința

- ▣ **Model:** B3 [Rezolvat]; secțiunea B5 din notebook
- ▣ **Convenția lagului:** $L(k) = \text{corr}(r_t, |r_{t+k}|)$ [Christie \(1982\)](#); k numără zilele de observație ale fiecărei serii; $k > 0$: randamentul de azi și o mărime ulterioară
 - ▶ exemplu, $k = 1$: randamentul BET-TR de luni, 16 mar. 2020, este asociat cu $|r|$ de marți, 17 mar. 2020
- ▣ **Date:** `r_bet` și `r_btc`, fiecare pe propriul calendar
- ▣ **Cerințe**
 1. Calculați $L(k)$ pentru $k = -20, \dots, 20$ și reprezentați ambele serii cu benzile de referință i.i.d. $\pm 1,96/\sqrt{T}$ (0,036 și 0,030).
 2. Raportați $L(1)$ și $L(5)$ pentru ambele piețe și spuneți dacă sînt în afara benzilor de referință.
 3. Dați două explicații concurente pentru un efect mai slab la Bitcoin.
- ▣ **Interpretare**
 - ▶ de ce o bandă de referință nu este un interval de încredere în prezența volatility clustering?
 - ▶ ce aduce B12?

B12 [Propus]: efectul de levier ca regresie — cerința

- ▣ **Model:** B5, B9 [Rezolvat]; secțiunea B12 din notebook
- ▣ **Regresia:** $|r_{t+1}| = c + \beta^+ r_t^+ + \beta^- r_t^- + \sum_{j=1}^5 \delta_j |r_{t-j}| + u_{t+1}$, $r_t^+ = \max(r_t, 0) \geq 0$, $r_t^- = \min(r_t, 0) \leq 0$
 - ▶ un câștig $+a$ adaugă $\beta^+ a$, o pierdere $-a$ adaugă $-\beta^- a$: un răspuns simetric înseamnă $\beta^+ = -\beta^-$
 - ▶ rîndul din matricea de regresori pentru ziua t : $(1, r_t^+, r_t^-, |r_{t-1}|, \dots, |r_{t-5}|)$, variabila dependentă $|r_{t+1}|$
- ▣ **Date:** r_sp, r_bet, r_btc, r_eur
- ▣ **Cerințe**
 1. Estimați prin OLS cu erori standard Newey–West [Newey & West \(1987\)](#), trunchierea lagurilor $\lfloor 4(T/100)^{2/9} \rfloor$.
 2. Testați $H_0: \beta^+ + \beta^- = 0$ cu $W = (\hat{\beta}^+ + \hat{\beta}^-)^2 / [\text{Var}(\hat{\beta}^+) + \text{Var}(\hat{\beta}^-) + 2 \text{Cov}(\hat{\beta}^+, \hat{\beta}^-)]$, χ_1^2 la 5%.
 3. Reprezentați $|r_{t+1}|$ prezis după un câștig $+a$ și după o pierdere $-a$, cu controalele de lag la mediile lor.
 4. Arătați de ce $|r_t|$ nu poate fi adăugat printre controale.

B6 [Propus]: EUR/RON pe regimuri — cerința

- ▣ **Model:** B1, B9 [Rezolvat]; secțiunea B6 din notebook
- ▣ **Date:** r_{eur} (cursul de referință BNR), împărțit în iul. 2005 – 2011, 2012–2019, 2020–2026 (1.656, 2.013, 1.683 de randamente); lagurile se construiesc în interiorul fiecărei perioade
- ▣ **Cerințe**
 1. În fiecare perioadă regresați $r_t = a + \rho r_{t-1} + e_t$ prin OLS, cu SE HAC (trunchierea lagurilor $\lfloor 4(T/100)^{2/9} \rfloor$); raportați $\hat{\rho}$, SE, volatilitatea și excesul de kurtosis.
 2. Testați egalitatea lui ρ între perioade: ponderi $w_j = 1/\text{SE}_j^2$, $\bar{\rho} = \sum_j w_j \hat{\rho}_j / \sum_j w_j$, $W = \sum_j w_j (\hat{\rho}_j - \bar{\rho})^2 \sim \chi_2^2$.
 3. Separat, localizați o ruptură de varianță cu suma cumulată a pătratelor [Inclán & Tiao \(1994\)](#):
 $D_k = C_k / C_T - k / T$, $C_k = \sum_{t \leq k} x_t^2$, ruptura la $\arg \max_k |D_k|$.
- ▣ **Interpretare**
 - ▶ de ce este atât de mare SE pentru 2020–2026?
 - ▶ de ce data CUSUM este descriptivă, nu un test?

B15 [Propus]: memorie lungă sau rupturi? — cerința

- ▣ **Model:** B9, B11 [Rezolvat]; secțiunea B15 din notebook (funcția `local_whittle(x, m)`)
- ▣ **Metoda Robinson (1995):** centrați $x_t = |r_t|$, periodograma $I(\lambda_j)$ la $\lambda_j = 2\pi j/T$; $\hat{d}$ minimizează $\ln\left(\frac{1}{m} \sum_{j=1}^m \lambda_j^{2d} I(\lambda_j)\right) - \frac{2d}{m} \sum_{j=1}^m \ln \lambda_j$ pe $d \in [-0,49; 0,99]$; $m = \lfloor T^p \rfloor$; $SE = 1/(2\sqrt{m})$
- ▣ **Date:** $|r_t|$ pentru S&P 500, BET-TR și Bitcoin
- ▣ **Cerințe**
 1. Estimați d cu $p = 0,65$ și dați intervalul de 95%.
 2. Reprezentați $\hat{d}$ în funcție de p de la 0,45 la 0,80, cu dreptele $d = 0$ și $d = 0,5$.
 3. Localizați o ruptură de varianță a lui r_t (B6); reestimați $\hat{d}$ de fiecare parte și reprezentați ACF a lui $|r_t|$ înainte și după.
- ▣ **Interpretare**
 - ▶ este $\hat{d} > 0$ robust la p și la ruptură sau compatibil cu regimuri Diebold & Inoue (2001)?
 - ▶ ce implică $\hat{d} \geq 0,5$?

B7 [Propus]: BET-TR față de S&P 500 pe aceeași perioadă — cerința

- ▣ **Model:** A1, B1 [Rezolvat]; secțiunea B7 din notebook
- ▣ **Date:** BET-TR (randament total, lei) și S&P 500 (indice de preț, USD); aliniați *prețurile* pe zilele comune (23 sept. 2014 – 18 sept. 2026), apoi calculați 2.903 randamente
 - ▶ lungimea intervalului: 2.231 de o zi, 538 de două sau trei zile, 134 mai lungi (cel mult 6 zile)
- ▣ **Cerințe**
 1. Reprezentați averea rebazată (scală logaritmică) și cele două curbe de drawdown (underwater).
 2. Calculați CAGR, volatilitatea randamentelor simple ($P = 252$), raportul Sharpe $252\bar{R}/(\sqrt{252}\hat{\sigma}_R)$ cu $r_f = 0$, raportul Sortino (abaterea negativă pe toate zilele) [Sortino & van der Meer \(1991\)](#), MDD și raportul Calmar.
- ▣ **De raportat:** graficul și un tabel cu două coloane
- ▣ **Interpretare:** dați trei motive pentru care comparația este doar descriptivă (dividende, monedă, dobânda fără risc în lei)

B13 [Propus]: semnificația diferenței dintre rapoartele Sharpe — cerința

- ▣ **Model:** B7, B1(d); secțiunea B13 din notebook
- ▣ **Date:** cele 2.903 perechi de randamente din B7; randamente simple pentru rapoartele Sharpe (1,36 și 0,75), logaritmice pentru corelații
- ▣ **Cerințe**
 1. Treceți la rapoarte Sharpe zilnice ($\widehat{SR}/\sqrt{252}$) și calculați testul Jobson–Korkie [Jobson & Korkie \(1981\)](#) cu corecția lui [Mommel \(2003\)](#): $z = (\widehat{SR}_1 - \widehat{SR}_2)/\sqrt{\widehat{V}}$, $\widehat{V} = \frac{1}{T} [2(1 - \hat{\rho}) + \frac{1}{2}(\widehat{SR}_1^2 + \widehat{SR}_2^2 - 2\widehat{SR}_1\widehat{SR}_2\hat{\rho}^2)]$.
 2. Bootstrap circular pe blocuri, pe perechi: extrageți $\lceil T/21 \rceil$ zile de start, luați câte 21 de zile consecutive (reluând de la început la final), tăiați la T , aplicați **aceiași** indici ambelor serii; 2.000 de reșantionări (`default_rng(42)`); interval de percentile de 95% pentru diferența anualizată.
 3. Calculați patru corelații: în aceeași zi, BET-TR cu S&P 500 din ziua precedentă și din ziua următoare, și pe randamente săptămânale (vineri).
- ▣ **Interpretare**
 - ▶ este diferența semnificativă?
 - ▶ ce presupun cele două metode?
 - ▶ ce corelație se folosește într-un portofoliu?

B8 [Propus]: estimatori de range volatility pentru S&P 500 — cerința

- ▣ **Model:** A5 [Rezolvat]; secțiunea B8 din notebook (funcții testate pentru toți cei cinci estimatori; formulele în Capitolul 1)
- ▣ **Date:** OHLC pentru indicele S&P 500, 2 ian. 2008 – 18 sept. 2026; ETF-ul SPY pe aceeași bază ajustată: C^* = închiderea ajustată (pentru dividende și splituri), $O^*, H^*, L^* = (C^*/C) \times O, H, L$
 - ▶ exemplu, 16 mar. 2020: factorul $218,08/239,85 = 0,9092$; $O^* = 241,18 \times 0,9092 = 219,29$, $H^* = 233,58$, $L^* = 215,82$
- ▣ **Cerințe**
 1. Calculați volatilitățile mobile pe 21 de zile close-to-close, Parkinson, Garman–Klass [Garman & Klass \(1980\)](#), Rogers–Satchell [Rogers & Satchell \(1991\)](#) și Yang–Zhang [Yang & Zhang \(2000\)](#) ($P = 252$) și mediile lor în timp.
 2. Pentru indice și pentru SPY comparați mediile pe 21 de zile ale close-to-close și Yang–Zhang cu volatilitatea de peste noapte pe tot eșantionul, $sd(o_t - c_{t-1})\sqrt{252}$, și cu volatilitatea de la deschidere la închidere.
- ▣ **Interpretare:** de ce rămîne Yang–Zhang sub close-to-close pe indice, dar nu și pe SPY?

C1 [Propus]: a scăzut autocorelația BET-TR după reclasificarea FTSE?

- ▣ **Model:** B6, B9 [Rezolvat]; o propunere de proiect
- ▣ **Context:** BET-TR are o autocorelație pozitivă de lag 1, tipică piețelor mai puțin lichide; România a devenit piață emergentă secundară FTSE Russell pe 21 sept. 2020
- ▣ **Date:** r_{bet} ; lichiditatea: valoarea zilnică tranzacționată ($\text{volum} \times \text{preț de închidere brut, în lei}$) a 11 blue chips de la BVB (TLV, SNP, BRD, TGN, FP, SNG, H2O, SNN, EL, DIGI, TEL), însumată pe acțiunile listate în ziua respectivă; raportați câte sînt listate în fiecare an
- ▣ **Cerințe**
 1. Calculați $\hat{\rho}_1$ pe ferestre mobile de 250 de zile (pas de 5 zile), cu benzile din B9, etichetate ca benzi de referință sub $\rho_1 = 0$.
 2. Estimați ρ_1 înainte și după 21 sept. 2020 ca pantă AR(1), cu SE HAC (B6); raportați $z = (\hat{\rho}_{\text{după}} - \hat{\rho}_{\text{înainte}}) / \sqrt{SE_1^2 + SE_2^2}$ și interacțiunea e din $r_t = a + b r_{t-1} + c \text{post}_t + e r_{t-1} \text{post}_t$ (HAC, 10 laguri).
 3. Corelați $\hat{\rho}_1$ mobil cu logaritmul valorii tranzacționate medii pe 250 de zile.
- ▣ **Livrabil:** un folder Quantlet și un slide cu o concluzie descriptivă și principala ei limită, nu o afirmație cauzală

C3 [Propus]: depinde VIX în mare parte de traiectorie? — cerința (1/2)

- ▣ **Model:** studiul de caz din curs; un proiect de replicare, nu o sarcină de seminar
- ▣ **Întrebare:** pot randamentele trecute ale S&P 500 să explice singure VIX, cum găesc [Guyon & Lekeufack \(2023\)](#) (94,6% din varianța sa în 2000–2018, 85,5% în 2019 – mai 2022)?
- ▣ **Date:** închiderile zilnice ale S&P 500, VIX și VIX pe 9 zile; randamente simple $r_{t_i} = S_{t_i}/S_{t_{i-1}} - 1$; indicii de volatilitate împărțiți la 100
- ▣ **Modelul**, ec. (3.7) din lucrare: $\sigma_t = \beta_0 + \beta_1 R_{1,t} + \beta_2 \Sigma_t$, $R_{1,t} = \sum_{i=0}^{999} K_1(i\Delta t) r_{t-i}$, $\Sigma_t = \left(\sum_{i=0}^{999} K_2(i\Delta t) r_{t-i}^2 \right)^{1/2}$, $\Delta t = 1/252$
- ▣ **Nuclee**, ec. (3.9) din lucrare: $K_j(\tau) = (\tau + \delta_j)^{-\alpha_j} / Z_j$, cu Z_j astfel încît $\sum_{i=0}^{999} K_j(i\Delta t) \Delta t = 1$
- ▣ **Parametri și unități:** β_0 în unități de volatilitate (0,03 = 3 puncte VIX), β_1, β_2 fără unitate, $\alpha_j > 1$, $\delta_j > 0$ în ani
- ▣ **Start** (Tabelul 3 din lucrare, rîndul VIX): $\beta_0 = 0,057$, $\beta_1 = -0,095$, $\beta_2 = 0,82$, $\alpha_1 = 1,06$, $\delta_1 = 0,020$, $\alpha_2 = 1,60$, $\delta_2 = 0,052$; limite $\alpha_j \in [1,0001; 20]$, $\delta_j \in [10^{-4}; 5]$

C3 [Propus]: depinde VIX în mare parte de traiectorie? — cerința (2/2)

▣ **Cerințe**, pe etape

1. Nuclee fixe: calculați $R_{1,t}$ și Σ_t cu nucleele din Tabelul 3 și estimați $\beta_0, \beta_1, \beta_2$ prin OLS pe 2000–2018.
2. Modelul complet: estimați toți cei șapte parametri prin cele mai mici pătrate neliniare (`scipy.optimize.least_squares`) pe 1 ian. 2000 – 31 dec. 2018, recalculînd variabilele la fiecare valoare încercată.
3. Raportați r^2 și RMSE pe eșantionul de antrenare și pe 1 ian. 2019 – 15 mai 2022, pentru modelul complet și pentru restricțiile $\beta_1 = 0$ și $\beta_2 = 0$; repetați modelul complet pentru VIX pe 9 zile (antrenare din 2011).
4. Păstrați parametrii fixați și evaluați perioada 16 mai 2022 – 18 sept. 2026.

▣ **De raportat**: tabelul parametrilor, scorurile alături de Tabelul 2 din lucrare, VIX observat și estimat, raportul dintre VIX observat și estimat, nucleele estimate

▣ **Interpretare**: modelul explică VIX din aceeași zi; nu este o prognoză pentru ziua următoare; ce variabilă explică mai mult, $R_{1,t}$ sau Σ_t ?

Bibliografie (1/3)

- Bollerslev, T. (1986). Generalized autoregressive conditional heteroskedasticity. *Journal of Econometrics*, 31(3), 307–327.
- Bollerslev, T., Hood, B., Huss, J., Pedersen, L.H. (2018). Risk everywhere: modeling and managing volatility. *Review of Financial Studies*, 31(7), 2729–2773.
- Christie, A.A. (1982). The stochastic behavior of common stock variances: value, leverage and interest rate effects. *Journal of Financial Economics*, 10(4), 407–432.
- Clark, P.K. (1973). A subordinated stochastic process model with finite variance for speculative prices. *Econometrica*, 41(1), 135–155.
- Cont, R. (2001). Empirical properties of asset returns: stylized facts and statistical issues. *Quantitative Finance*, 1(2), 223–236.
- Dalla, V., Giraitis, L., Phillips, P.C.B. (2022). Robust tests for white noise and cross-correlation. *Econometric Theory*, 38(5), 913–941.
- Diebold, F.X., Inoue, A. (2001). Long memory and regime switching. *Journal of Econometrics*, 105(1), 131–159.
- Dimson, E. (1979). Risk measurement when shares are subject to infrequent trading. *Journal of Financial Economics*, 7(2), 197–226.
- Engle, R.F. (1982). Autoregressive conditional heteroscedasticity with estimates of the variance of United Kingdom inflation. *Econometrica*, 50(4), 987–1007.
- Franke, J., Härdle, W.K., Hafner, C.M. (2019). *Statistics of Financial Markets: An Introduction* (ed. a 5-a). Springer.
- Garman, M.B., Klass, M.J. (1980). On the estimation of security price volatilities from historical data. *Journal of Business*, 53(1), 67–78.
- Guyon, J., Lekeufack, J. (2023). Volatility is (mostly) path-dependent. *Quantitative Finance*, 23(9), 1221–1258.

Bibliografie (2/3)

- ▣ Hamilton, J.D. (1989). A new approach to the economic analysis of nonstationary time series and the business cycle. *Econometrica*, 57(2), 357–384.
- ▣ Hill, B.M. (1975). A simple general approach to inference about the tail of a distribution. *Annals of Statistics*, 3(5), 1163–1174.
- ▣ Inclán, C., Tiao, G.C. (1994). Use of cumulative sums of squares for retrospective detection of changes of variance. *Journal of the American Statistical Association*, 89(427), 913–923.
- ▣ Jarque, C.M., Bera, A.K. (1980). Efficient tests for normality, homoscedasticity and serial independence of regression residuals. *Economics Letters*, 6(3), 255–259.
- ▣ Jobson, J.D., Korkie, B.M. (1981). Performance hypothesis testing with the Sharpe and Treynor measures. *Journal of Finance*, 36(4), 889–908.
- ▣ Kim, T.-H., White, H. (2004). On more robust estimation of skewness and kurtosis. *Finance Research Letters*, 1(1), 56–73.
- ▣ Ledoit, O., Wolf, M. (2008). Robust performance hypothesis testing with the Sharpe ratio. *Journal of Empirical Finance*, 15(5), 850–859.
- ▣ Ljung, G.M., Box, G.E.P. (1978). On a measure of lack of fit in time series models. *Biometrika*, 65(2), 297–303.
- ▣ Lo, A.W. (2002). The statistics of Sharpe ratios. *Financial Analysts Journal*, 58(4), 36–52.
- ▣ Lobato, I., Nankervis, J.C., Savin, N.E. (2001). Testing for autocorrelation using a modified Box–Pierce Q test. *International Economic Review*, 42(1), 187–205.

Bibliografie (3/3)

- ▣ Magdon-Ismail, M., Atiya, A.F., Pratap, A., Abu-Mostafa, Y.S. (2004). On the maximum drawdown of a Brownian motion. *Journal of Applied Probability*, 41(1), 147–161.
- ▣ Memmel, C. (2003). Performance hypothesis testing with the Sharpe ratio. *Finance Letters*, 1(1), 21–23.
- ▣ Newey, W.K., West, K.D. (1987). A simple, positive semi-definite, heteroskedasticity and autocorrelation consistent covariance matrix. *Econometrica*, 55(3), 703–708.
- ▣ Parkinson, M. (1980). The extreme value method for estimating the variance of the rate of return. *Journal of Business*, 53(1), 61–65.
- ▣ Robinson, P.M. (1995). Gaussian semiparametric estimation of long range dependence. *Annals of Statistics*, 23(5), 1630–1661.
- ▣ Rogers, L.C.G., Satchell, S.E. (1991). Estimating variance from high, low and closing prices. *Annals of Applied Probability*, 1(4), 504–512.
- ▣ Sortino, F.A., van der Meer, R. (1991). Downside risk. *Journal of Portfolio Management*, 17(4), 27–31.
- ▣ Yang, D., Zhang, Q. (2000). Drift-independent volatility estimation based on high, low, open, and close prices. *Journal of Business*, 73(3), 477–492.