



Modelarea piețelor financiare

Seminarul 2: Eficiența pieței — aplicații



Daniel Traian PELE

Drd. Antoaneta Amza, antoaneta.amza@csie.ase.ro

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

Acronime folosite în acest material (1/2)

- **AI:** Artificial Intelligence — *inteligență artificială*
- **AMH:** Adaptive Markets Hypothesis — *ipoteza piețelor adaptive*
- **AR:** AutoRegressive (model); in event studies: Abnormal Return — *model autoregresiv; în studiile de eveniment: randament anormal*
- **BDS:** Brock–Dechert–Scheinkman (test) — *testul Brock–Dechert–Scheinkman de independență*
- **BET:** Bucharest Exchange Trading (index) — *indicele de referință al Bursei de Valori București*
- **BET-TR:** BET Total Return (index) — *indicele BET cu dividendele reinvestite*
- **BIST:** Borsa İstanbul (BIST 100 index) — *Bursa din Istanbul (indicele BIST 100)*
- **BUX:** Budapesti Értéktőzsde index — *indicele Bursei din Budapesta*
- **BVB:** Bursa de Valori București
- **CD:** Chow–Denning (multiple variance-ratio test) — *testul multiplu Chow–Denning pentru raportul dispersiilor*
- **COVID-19:** COronaVirus Disease 2019 — *boala provocată de coronavirus, 2019*
- **CV:** Cross-Validation — *validare încrucișată*
- **DFA:** Detrended Fluctuation Analysis — *analiza fluctuațiilor fără tendință*
- **ETF:** Exchange-Traded Fund — *fond tranzacționat la bursă*
- **FRED:** Federal Reserve Economic Data — *baza de date economice a Rezervei Federale (St. Louis)*
- **FTSE:** Financial Times Stock Exchange (FTSE Russell, index provider) — *furnizorul de indici FTSE Russell*

Acronime folosite în acest material (2/2)

- **FWER**: Family-Wise Error Rate — *probabilitatea de cel puțin o eroare de tip I în familia de teste*
- **GARCH**: Generalised AutoRegressive Conditional Heteroskedasticity — *heteroscedasticitate condiționată autoregresivă generalizată*
- **HAC**: Heteroskedasticity and Autocorrelation Consistent (standard errors) — *erori standard robuste la heteroscedasticitate și autocorelație*
- **IPC**: Índice de Precios y Cotizaciones — *indicele Bursei din Mexic*
- **NW**: Newey–West (standard errors) — *erori standard Newey–West*
- **OLS**: Ordinary Least Squares — *metoda celor mai mici pătrate*
- **PX**: Prague Stock Exchange index (index Burzy cenných papírů Praha) — *indicele Bursei din Praga*
- **RW1**: Random Walk 1 (i.i.d. increments) — *mersul aleator 1 (creșteri i.i.d.)*
- **RW2**: Random Walk 2 (independent increments) — *mersul aleator 2 (creșteri independente)*
- **RW3**: Random Walk 3 (uncorrelated increments) — *mersul aleator 3 (creșteri necorelate)*
- **SE**: Standard Error — *eroare standard*
- **SUA**: Statele Unite ale Americii
- **TOM**: Turn Of the Month — *trecerea de la o lună la alta (efectul de sfârșit de lună)*
- **VR**: Variance Ratio — *raportul dispersiilor*
- **WIG20**: Warszawski Indeks Giełdowy 20 — *indicele celor mai mari 20 de companii de la Bursa din Varșovia*

Întrebarea seminarului și traseul

- ▣ Întrebarea seminarului: **care respingeri ale eficienței slabe din Capitolul 2 rămân valabile sub inferență robustă, pe mai multe orizonturi și la mai multe teste?**
- ▣ Traseul seminarului
 - ▶ noțiuni necesare: trei slide-uri de notații și douăzeci și trei de slide-uri introductive (cursul are loc după acest seminar)
 - ▶ A1, A5–A6: un raport al dispersiilor și un exponent Hurst implicat, pe hîrtie
 - ▶ B1, B7, C2: rapoarte ale dispersiilor clasice față de robuste, rolul crizelor, un răspuns AI de verificat
 - ▶ B5, B6: un efect de calendar cu erori HAC, apoi cincisprezece teste cu Holm
 - ▶ după curs: B3, B4, DFA și rapoarte ale dispersiilor pe ferestre mobile, cu benzi bootstrap
- ▣ Livrabile: fișele A, un tabel și o figură pentru fiecare exercițiu B, verificarea C2, o frază de interpretare pentru fiecare exercițiu
- ▣ Notebook-ul de azi: [deschideți notebook-ul seminarului în Colab](#); fiecare cerință indică secțiunea din notebook
- ▣ Seminar: prof. Daniel Traian Pele, danpele@ase.ro; drd. Antoaneta Amza, antoaneta.amza@csie.ase.ro

Harta exercițiilor

Exercițiul	Întrebarea	Tipul	Model
A1	ce calculează $\widehat{VR}(2)$, rînd cu rînd?	Rezolvat	–
A5, A6	dovedește un $H(20) \neq 0,5$ implicat memoria lungă?	Rezolvat, Propus	A5
B1	resping S&P 500 și BET ipoteza RW3 cu erori robuste?	Rezolvat	–
B7	este inversarea S&P 500 un efect al crizelor?	Propus	B1
C2	ce erori conține un răspuns AI despre raportul dispersiilor?	Propus	A1, B1
B5	este real efectul schimbării lunii?	Rezolvat	–
B6	care dintre 15 efecte de calendar rămîn după corecția Holm?	Propus	B5
După curs	B3 [Rezolvat], B4 [Propus]: DFA și rapoarte ale dispersiilor pe ferestre mobile, cu benzi bootstrap	temă	B1
Pachete de extindere	A2, A3, A4, B2, B8, B9, C1, C3 (opționale, după seminar)	Rezolvat sau Propus (indicat la fiecare cerință)	la fiecare enunț

- **[Rezolvat]:** rezolvarea completă în slide-uri și în notebook, un model de urmat; **[Propus]:** îl rezolvați individual, rezolvarea se discută la seminar
- Partea A: derivări pe hîrtie; Partea B: calcul și inferență pe date reale, fiecare încheiat cu o întrebare de interpretare; Partea C: întrebări deschise și critica unui răspuns AI

Datele folosite

Seria	Prețul folosit	Calendar	Folosită în
S&P 500	închidere	zilele de tranzacționare din SUA	A6, B1, B3, B5–B7, C2
BET	închidere	zilele de tranzacționare BVB	A5, B1, B2, B5, B6, C1
BET-TR și 8 indici emergenți	închidere (WIG20, BUX, PX, BIST 100, Bovespa, IPC, Nifty 50, Shanghai)	fiecare pe calendarul propriu	B2, B6, C1
Euro Stoxx 50	închidere	calendarul propriu	B6
Bitcoin	închidere (USD)	în fiecare zi	B4
Banca Transilvania, BRD	închidere ajustată (dividende, split-uri)	zilele comune cu BET	B9
S&P 500 lunar	Shiller S&P Composite, închiderile S&P 500, dividendele SPY; titluri de stat americane la 3 luni (FRED, TB3MS)	sfârșit de lună	B8
49 de portofolii sectoriale	Kenneth French Data Library , ponderate cu capitalizarea, lunar	sfârșit de lună	C3

- Prețurile zilnice de închidere din datele cursului, câte o serie pe activ, din 2000 (Bitcoin din 2011) până la 18 sep. 2026; randamente log zilnice $r_t = \ln P_t - \ln P_{t-1}$, pe calendarul propriu al fiecărei serii
- Regula de curățare pentru indici: doar zilele lucrătoare; o închidere egală cu cea anterioară este eliminată (de obicei o zi nelucrătoare completată)

Pregătire: rulați și verificați

```
# secțiunile "Date" și  
# "Teste de eficiență" definesc  
# log_returns(name, start=None)  
# variance_ratio(r, q) -> (VR, z, z*)  
# chow_denning(r), runs_test(r), dfa_hurst(r)  
sp = log_returns('sp500') # S&P 500  
bet = log_returns('bet') # BET  
print(len(sp), sp.index[0].date(),  
      sp.index[-1].date(), len(bet))  
print(sp.head(3).round(5))
```

- Rezultat așteptat: 6 714 randamente S&P 500 între 2000-01-04 și 2026-09-18; 6 670 randamente BET

data	close	r_t
2000-01-03	1 455,22	–
2000-01-04	1 399,42	–0,03910
2000-01-05	1 402,11	+0,00192
2000-01-06	1 403,45	+0,00096

- Dacă numărul sau prima valoare diferă, verificați seria, tipul de preț (închidere ajustată sau neajustată) și regula de curățare

Notății folosite în toate exercițiile (1/3): randamente și momente de selecție

- **Randamentul log zilnic** al unei serii cu prețurile de închidere P_t

$$r_t = \ln P_t - \ln P_{t-1}, \quad t = 1, \dots, T$$

- ▶ T : numărul de randamente; în B5 randamentele sînt în puncte de bază, 10 000 r_t
- ▶ q : un orizont în zile; $r_t + r_{t-1} + \dots + r_{t-q+1}$ este randamentul log pe q zile

- Media de selecție, abaterile și dispersia

$$\bar{r} = \hat{\mu} = \frac{1}{T} \sum_{t=1}^T r_t, \quad e_t = r_t - \bar{r}, \quad \hat{\sigma}^2 = \frac{1}{T-1} \sum_{t=1}^T e_t^2$$

- ▶ $\hat{\cdot}$ (căciula): o estimatie calculată din selecție; fără căciulă: valoarea din populație
- ▶ $\mathbb{E}[\cdot]$, $\text{Var}(\cdot)$, $\text{Cov}(\cdot, \cdot)$: media, dispersia și covarianța în populație

- **i.i.d.**: independente și identic distribuite

- ▶ reperul testelor clasice; [Capitolul 1](#) a arătat că randamentele zilnice nu sînt i.i.d. (volatility clustering)

Notății folosite în toate exercițiile (2/3): autocorelația

- Autocorelația de ordinul k : corelația dintre randamentul de azi și cel de acum k zile

$$\rho_k = \frac{\text{Cov}(r_t, r_{t-k})}{\text{Var}(r_t)}, \quad \hat{\rho}_k = \frac{\sum_{t=k+1}^T e_t e_{t-k}}{\sum_{t=1}^T e_t^2}$$

- k : lagul, în zile; $\rho_k \in [-1, 1]$; $\rho_k = 0$ pentru orice $k \geq 1$: nicio predictibilitate liniară din trecut

- Eroarea standard a lui $\hat{\rho}_k$ când $\rho_k = 0$

- randamente i.i.d.: $\text{se}(\hat{\rho}_k) = 1/\sqrt{T}$, de aici banda $\pm 1,96/\sqrt{T}$
- robustă (volatility clustering permis, [Capitolul 1](#)): $\text{se}(\hat{\rho}_k) = \sqrt{\hat{\tau}_k}$

- Dispersia robustă a lui $\hat{\rho}_k$ și statistica t robustă

$$\hat{\tau}_k = \frac{\sum_{t=k+1}^T e_t^2 e_{t-k}^2}{(\sum_{t=1}^T e_t^2)^2}, \quad \hat{\delta}_k = T \hat{\tau}_k, \quad t_k = \frac{\hat{\rho}_k}{\sqrt{\hat{\tau}_k}}$$

- $\hat{\delta}_k$: de câte ori dispersia robustă o depășește pe cea i.i.d.
- $\hat{\delta}_k \approx 1$ pentru randamente i.i.d.; $\hat{\delta}_k > 1$ când zilele mari urmează după zile mari


Notății folosite în toate exercițiile (3/3): teste și decizii

- Un **test** compară o statistică cu distribuția ei sub ipoteza nulă H_0
 - ▶ $z \approx N(0, 1)$ sub H_0 : statistica are (aproximativ) distribuția Normală standard
 - ▶ Φ : funcția de repartiție a distribuției $N(0, 1)$; $\Phi(1,96) = 0,975$
- **p-value-ul** unui test bilateral: probabilitatea, sub H_0 , a unei statistici cel puțin la fel de extreme

$$p = 2(1 - \Phi(|z|))$$

- ▶ respingem H_0 la nivelul $\alpha = 5\%$ când $p < 0,05$, adică atunci când $|z| > 1,96$
 - ▶ nivelul α este probabilitatea acceptată a unei respingeri false (eroare de tipul I)
- Interval de 95%: estimația $\pm 1,96 \times$ eroarea standard
 - ▶ conține 0 exact atunci când testul bilateral nu respinge la 5%
- O nerespingere nu dovedește H_0
 - ▶ un test cu putere mică (puține observații, date zgomotoase) respinge rar chiar și atunci când H_0 este falsă

O primă privire asupra datelor (1/2)




O primă privire asupra datelor (2/2)

- Există volatility clustering: anii calmi alternează cu episoade agitate (2008–2009, 2020), deci erorile standard i.i.d. sînt prea mici în toate exercițiile B

Noțiuni necesare azi (1/23): eficiența slabă

- ▣ Seminarul are loc **înaintea** cursului
 - ▶ aceste douăzeci și trei de slide-uri prezintă doar noțiunile folosite în cerințe; slide-urile 18–23 sînt necesare doar pentru pachetele de extindere
 - ▶ detaliile se găsesc în **Capitolul 2**, cursul de după seminar
- ▣ **Piață eficientă Fama (1970)**: prețurile reflectă informația disponibilă
 - ▶ **forma slabă**: informația este formată din prețurile și randamentele trecute
 - ▶ **forma semi-tare**: toată informația publică (anunțuri, știri; B9)
 - ▶ **forma tare**: și informația privată
- ▣ Consecința testabilă a formei slabe
 - ▶ randamentele trecute nu permit cîștiguri ajustate la risc, după costuri
 - ▶ în particular, $\mathbb{E}[r_t \mid r_{t-1}, r_{t-2}, \dots]$ nu depinde de trecut: randamentele nu pot fi prevăzute din propriul trecut
- ▣ Semnul dependenței
 - ▶ $\rho_k > 0$: persistență (momentum); $\rho_k < 0$: inversare (revenire la medie)
 - ▶ un $\hat{\rho}_k$ semnificativ nu este încă o regulă profitabilă: decid costurile, riscul și stabilitatea

Noțiuni necesare azi (2/23): trei variante ale mersului aleator




- **Mersul aleator al prețului logaritmat** [Campbell, Lo & MacKinlay \(1997\)](#)

$$\ln P_t = \mu + \ln P_{t-1} + \varepsilon_t, \quad \text{so } r_t = \mu + \varepsilon_t$$

- ▶ μ : drift-ul, randamentul log zilnic așteptat; ε_t : șocul zilei t , cu media 0
- ▶ RW1: ε_t i.i.d.; RW2: independente, dispersia se poate schimba (panoul din mijloc)
- ▶ RW3: doar necorelate, $\text{Cov}(\varepsilon_t, \varepsilon_{t-k}) = 0$, iar ε_t^2 poate fi autocorelat (GARCH, dreapta)

- Toate cele trei panouri au $\hat{\rho}_1 \approx 0$; cel din dreapta are volatility clustering, deci ipoteza nulă relevantă pentru randamentele zilnice este RW3

Noțiuni necesare azi (3/23): două benzi pentru autocorelație



- i.i.d. band $\pm 1.96/\sqrt{T}$
- robust band $\pm 1.96\sqrt{\hat{\tau}_k}$
- $\hat{\rho}_k$ of a GARCH series

- Randamente GARCH simulate, $T = 2\,500$: $\rho_k = 0$ la orice lag
 - ▶ banda i.i.d. $\pm 1.96/\sqrt{T} = \pm 0.039$ (zona colorată)
 - ▶ banda robustă $\pm 1.96\sqrt{\hat{\tau}_k}$, în medie ± 0.061 (linie întreruptă)
- Citirea graficului
 - ▶ 6 din 20 de laguri ies din banda i.i.d.: respingeri false, deoarece toate ρ_k adevărate sînt 0
 - ▶ niciun lag nu iese din banda robustă
 - ▶ aici $\hat{\delta}_k \approx 2.5$: eroarea standard robustă este de $\sqrt{2.5} \approx 1.6$ ori mai mare
- Explicația
 - ▶ $\text{Var}(e_t e_{t-k})$ depășește σ^4 cînd e_t^2 și e_{t-k}^2 sînt corelate pozitiv



Noțiuni necesare azi (4/23): raportul dispersiilor

- Randamente necorelate, cu dispersia constantă σ^2 : dispersia sumei pe q zile este $q\sigma^2$
 - ▶ dispersiile se adună doar dacă toate covarianțele sînt zero
- **Raportul dispersiilor Lo & MacKinlay (1988)**: dispersia randamentului pe q zile raportată la q dispersii zilnice

$$VR(q) = \frac{\text{Var}(r_t + r_{t-1} + \dots + r_{t-q+1})}{q \text{Var}(r_t)}$$

- ▶ $VR(q) = 1$ sub RW1, RW2 și RW3; $VR(1) = 1$ întotdeauna
- ▶ $VR(q) > 1$: persistență, variațiile pe q zile depășesc q zile independente
- ▶ $VR(q) < 1$: inversare, o parte din fiecare variație se anulează în zilele următoare
- Cazul $q = 2$
$$\text{Var}(r_t + r_{t-1}) = 2\sigma^2 + 2\text{Cov}(r_t, r_{t-1}) \Rightarrow VR(2) = 1 + \rho_1$$
 - ▶ exemplu: $\rho_1 = -0,1$ dă $VR(2) = 0,9$; sumele pe două zile variază cu 10% mai puțin decît două zile separate

Noțiuni necesare azi (5/23): raportul dispersiilor ca sumă ponderată



- Dezvoltînd dispersia sumei pe q zile: lagul k apare în $2(q - k)$ covarianțe

$$VR(q) = 1 + 2 \sum_{k=1}^{q-1} \left(1 - \frac{k}{q}\right) \rho_k$$

- Stînga: ponderea $2(1 - k/q)$ scade linear cu lagul; dreapta: $VR(q)$ pentru randamente $AR(1)$, $\rho_k = \phi^k$
 ► exemplu: $\rho_1 = -0,1$, toate celelalte $\rho_k = 0$: $VR(5) = 1 + 2(1 - 1/5)(-0,1) = 0,84$

Noțiuni necesare azi (6/23): estimatorul Lo–MacKinlay

- Dispersia pe o zi, cu $\hat{\mu} = \bar{r}$

$$\hat{\sigma}_a^2 = \frac{1}{T-1} \sum_{t=1}^T (r_t - \hat{\mu})^2$$

- ▶ indicele a marchează estimatorul pe o zi

- Dispersia sumelor **suprapuse** pe q zile, împărțită la q

$$\hat{\sigma}_c^2(q) = \frac{1}{m} \sum_{t=q}^T \left(\sum_{j=0}^{q-1} r_{t-j} - q\hat{\mu} \right)^2, \quad m = q(T - q + 1) \left(1 - \frac{q}{T} \right)$$

- ▶ suprapuse: o nouă sumă pe q zile începe în fiecare zi, în total $T - q + 1$ sume
- ▶ $q\hat{\mu}$: randamentul așteptat pe q zile; m : un divizor care elimină deplasarea în selecții mici

- Estimatorul

$$\widehat{VR}(q) = \frac{\hat{\sigma}_c^2(q)}{\hat{\sigma}_a^2}$$

- ▶ în A1, varianta simplă (numitorii T și $T - 1$, fără corecție de deplasare) urmează aceeași idee, de mînă

Noțiuni necesare azi (7/23): testarea ipotezei $VR(q) = 1$

- Sub RW1 (i.i.d.): statistica clasică

$$z(q) = \frac{\widehat{VR}(q) - 1}{\sqrt{2(2q-1)(q-1)/(3qT)}} \approx N(0, 1)$$

- numitorul este eroarea standard i.i.d. a lui $\widehat{VR}(q)$; pentru $q = 2$ este egal cu $1/\sqrt{T}$

- Sub RW3 (volatility clustering permis): statistica robustă


$$z^*(q) = \frac{\sqrt{T} (\widehat{VR}(q) - 1)}{\sqrt{\hat{\theta}(q)}}, \quad \hat{\theta}(q) = \sum_{k=1}^{q-1} \left(\frac{2(q-k)}{q} \right)^2 \hat{\delta}_k$$

- $\hat{\theta}(q)$: dispersia robustă a lui $\sqrt{T} \widehat{VR}(q)$; ponderile sînt cele ale lui ρ_k în $VR(q)$, la pătrat
- $\hat{\delta}_k = T \hat{\tau}_k$ de pe slide-urile de notații; $|z^*(q)| > 1,96$ respinge RW3 la 5%

- Exemplu: $T = 2\,500$, $\widehat{VR}(2) = 0,95$

- $z(2) = -0,05 \times 50 = -2,5$: respingere la 5%
- cu $\hat{\delta}_1 = 4$: $z^*(2) = -2,5/\sqrt{4} = -1,25$, nu respingem

Noțiuni necesare azi (8/23): distribuțiile lui z și z^* sub ipoteza nulă



- $z(2)$: rejects 18.4%
- $z^*(2)$: rejects 6.2%
- $N(0, 1)$

- 1 000 de selecții GARCH simulate, $T = 2\,500$: fără autocorelație, deci H_0 al RW3 este adevărată
 - ▶ $z(2)$ este prea dispersată (abaterea standard 1,55, nu 1)
 - ▶ $|z(2)| > 1,96$ în 18,4% din selecții, în loc de 5%
 - ▶ $z^*(2)$ urmează $N(0, 1)$: 6,2% respingeri
- Concluzia pentru B1
 - ▶ când există volatility clustering, un $|z|$ mare nu este singur o dovadă: comparați $|z^*|$ cu 1,96
 - ▶ $z^* = z / \sqrt{\hat{\delta}_1}$ pentru $q = 2$: selecția efectivă este de $\hat{\delta}_1$ ori mai mică


Noțiuni necesare azi (9/23): mai multe orizonturi deodată: Chow–Denning

- Patru orizonturi testate separat la 5% resping *un* orizont mai des decât în 5% din cazuri
 - ▶ cu cît sînt mai multe orizonturi, cu atît sînt mai multe șanse de respingere falsă (testare multiplă, slide-ul 17)
- Statistica **Chow–Denning** [Chow & Denning \(1993\)](#): cea mai mare statistică robustă

$$CD = \max_{q \in \{2, 5, 10, 20\}} |z^*(q)|$$


- ▶ valoarea critică c din $(2\Phi(c) - 1)^4 = 0,95$, adică $c = 2,49$ (nu 1,96)
- ▶ p-value: $p = 1 - (2\Phi(CD) - 1)^4$
- ▶ exponentul 4 este numărul orizonturilor: limita le tratează ca independente, deci testul este ușor conservator
- Interpretare
 - ▶ $CD > 2,49$: RW3 este respinsă în comun la 5%; orizontul cu cel mai mare $|z^*|$ arată unde

Noțiuni necesare azi (10/23): exponentul Hurst



- **Exponentul Hurst** $H \in (0, 1)$, din hidrologia Nilului [Hurst \(1951\)](#): rata cu care crește dispersia unei serii cumulate odată cu orizontul
 - ▶ creșteri autosimilare (zgomot gaussian fracționar, fGn): $\text{Var}(r_t + \dots + r_{t-q+1}) = q^{2H} \text{Var}(r_t)$, deci $VR(q) = q^{2H-1}$
 - ▶ $H = 0,5$: fără memorie; $H > 0,5$: traiectorii netede, cu tendințe; $H < 0,5$: antipersistență, traiectorii rugoase (stînga)
- Exponentul implicat la un orizont: $H(q) = 0,5 + \ln VR(q) / (2 \ln q)$; exemplu $VR(20) = 1,2$:
 $H(20) = 0,5 + 0,182/5,991 = 0,530$

Noțiuni necesare azi (11/23): memoria scurtă și memoria lungă



- AR(1), $\phi = 0.4$: $\rho_k = \phi^k$
- fGn, $H = 0.75$: $\rho_k \approx H(2H - 1)k^{2H-2}$

Memorie scurtă, AR(1) (autoregresie de ordinul 1)

$$r_t = \phi r_{t-1} + u_t, \quad \rho_k = \phi^k$$



- ϕ : autocorelația de ordinul 1, $|\phi| < 1$; u_t : un șoc i.i.d.
- scădere geometrică: o dreaptă pe scala logaritmică (albastru)
- $VR(q) \rightarrow (1 + \phi)/(1 - \phi)$, mărginit, deci $H(q) \rightarrow 0,5$ când q crește

Memorie lungă, fGn cu $H > 0,5$

$$\rho_k = \frac{1}{2} (|k+1|^{2H} - 2|k|^{2H} + |k-1|^{2H})$$

- scădere hiperbolică $\rho_k \approx H(2H - 1)k^{2H-2}$ (roșu): la $k = 20$, 0,084 față de 10^{-8} pentru AR(1)
- Un singur orizont q nu le poate deosebi: comparați $H(q)$ pe mai multe valori q (A5, A6)

Noțiuni necesare azi (12/23): analiza fluctuațiilor fără tendință (DFA)




- Profile y_k
- Local linear trend
- i.i.d.: slope $\hat{\alpha}_{DFA} = 0.53$
- fGn, $H = 0.75$: slope $\hat{\alpha}_{DFA} = 0.77$

□ **DFA Peng et al. (1994):** estimează H din creșterea abaterii profilului fără tendință odată cu lungimea segmentului


- ▶ profilul $y_k = \sum_{i \leq k} (r_i - \bar{r})$; îl împărțim în segmente de lungime n și estimăm o dreaptă în fiecare (stînga)
- ▶ $F(n)$: rădăcina mediei pătratelor reziduurilor față de dreptele locale; $F(n) \propto n^{\alpha_{DFA}}$
- ▶ $\hat{\alpha}_{DFA}$: panta OLS a lui $\ln F(n)$ în funcție de $\ln n$ (dreapta); 0,5 fără memorie, peste 0,5 cu memorie lungă

Noțiuni necesare azi (13/23): bootstrap-ul cu schimbări de semn (wild bootstrap)



- **Wild bootstrap Kim (2006):** serii noi $e_t^* = e_t\eta_t$, cu $\eta_t = \pm 1$ cu probabilitatea $1/2$, independente
 - ▶ $|e_t^*| = |e_t|$: volatility clustering se păstrează; semnele aleatoare elimină orice autocorelație, deci H_0 este adevărată în fiecare copie
 - ▶ repetăm de B ori (aici 999), calculăm statistica de fiecare dată; cuantilele de 2,5% și 97,5% formează banda nulă
 - ▶ aici banda pentru $\hat{\rho}_1$ este $[-0,072; 0,074]$, mai largă decât banda i.i.d. $\pm 0,062$

Noțiuni necesare azi (14/23): ferestre mobile și piețe adaptive



band $\pm 1.96/\sqrt{W}$ if $\rho_1 = 0$ -- true ρ_1 ● $\hat{\rho}_1$ on the last $W = 250$ days

- **Fereastra mobilă:** reestimăm pe ultimele W zile, deplasînd fereastra cu un pas fix
 - ▶ simulare: $\rho_1 = 0,25$ timp de 1000 de zile, apoi scade spre 0; $W = 250$, pasul 21 de zile
 - ▶ ferestrele suprapuse au în comun majoritatea datelor: estimațiile vecine sînt corelate, deci numărările sînt descriptive
- **Ipoteza piețelor adaptive (AMH) Lo (2004):** eficiența se schimbă în timp, prin concurență și învățare
 - ▶ un tipar predictibil atrage investitori pînă cînd dispare, ca în simulare după ziua 1000

Noțiuni necesare azi (15/23): efectele de calendar ca regresie

- **Schimbarea lunii (TOM)** [Ariel \(1987\)](#): ultima zi de tranzacționare a lunii și primele trei ale lunii următoare

$$r_t = a + b \text{TOM}_t + u_t$$

- ▶ $\text{TOM}_t = 1$ într-o zi de schimbare a lunii, 0 altfel (variabilă indicator); u_t : reziduul
- ▶ OLS (metoda celor mai mici pătrate) alege $\hat{a}$, $\hat{b}$ care minimizează $\sum_t \hat{u}_t^2$

- Cu un regresor 0/1, OLS compară două medii

$$\hat{a} = \bar{r}_{\text{alte}}, \quad \hat{b} = \bar{r}_{\text{TOM}} - \bar{r}_{\text{alte}}$$

- ▶ $H_0: b = 0$, fără efect TOM; $t = \hat{b} / \text{se}(\hat{b})$

- Celelalte efecte din B6

- ▶ **ianuarie**: randamente lunare pe un indicator al lunii ianuarie, aceeași regresie
- ▶ **ziua săptămânii**: cinci indicatori; un test Wald al egalității mediilor, $W = (R\hat{\beta})'(R\hat{V}R')^{-1}R\hat{\beta} \approx \chi_4^2$
- ▶ $R\hat{\beta}$: cele patru diferențe față de media zilei de luni; $\hat{V}$: covarianța lor HAC (slide-ul următor)


Noțiuni necesare azi (16/23): erorile standard Newey–West (HAC)

- **HAC** (heteroskedasticity- and autocorrelation-consistent) **Newey & West (1987)**: dispersia lui $\hat{\beta}$ când reziduurile își schimbă dispersia și sînt corelate pe L laguri

$$\widehat{\text{Var}}(\hat{\beta}) = (\mathbf{X}'\mathbf{X})^{-1} \hat{\mathbf{S}} (\mathbf{X}'\mathbf{X})^{-1}, \quad \hat{\mathbf{S}} = \sum_{j=-L}^L \left(1 - \frac{|j|}{L+1}\right) \sum_t \mathbf{x}_t \hat{u}_t \hat{u}_{t-j} \mathbf{x}_{t-j}'$$

- ▶ $\mathbf{X}$: matricea $T \times 2$ cu rîndurile $\mathbf{x}_t' = (1, \text{TOM}_t)$; $\hat{u}_t$: reziduurile OLS
- ▶ ponderile $1 - |j|/(L+1)$ (Bartlett): 1 la $j = 0$, scad liniar pînă la 0 după lagul L
- ▶ $L = 0$: erorile White (robuste la heteroscedasticitate); $L = 5$ în B5
- Erorile OLS clasice
 - ▶ $\widehat{\text{Var}}(\hat{\beta}) = \hat{\sigma}_u^2 (\mathbf{X}'\mathbf{X})^{-1}$: dispersie constantă, fără autocorelație
 - ▶ HAC > OLS cînd zilele agitate se grupează sau $\rho_1 > 0$; estimația punctuală rămîne aceeași, se schimbă doar incertitudinea

Noțiuni necesare azi (17/23): testarea multiplă: FWER, Bonferroni și Holm



- **FWER** (family-wise error rate): probabilitatea a cel puțin unei respingeri false din M teste; teste independente la 5%:
 $1 - 0.95^M$ (stînga), $M = 10$: 40,1%
 - ▶ **Bonferroni**: respingem testul i dacă $p_i < \alpha/M$; p_i : p-value-ul lui, α : FWER-ul dorit
 - ▶ **Holm** [Holm \(1979\)](#): ordonăm $p_{(1)} \leq \dots \leq p_{(M)}$, respingem cît timp $p_{(j)} < \alpha/(M - j + 1)$, ne oprim la prima nerespingere
 - ▶ ambele păstrează $\text{FWER} \leq \alpha$; Holm respinge cel puțin la fel de des (dreapta: 4 respingeri față de 2)


Noțiuni necesare azi (18/23): testul secvențelor (pachetul de extindere 1)

- **Secvența:** un bloc maximal de randamente consecutive cu același semn [Wald & Wolfowitz \(1940\)](#)
 - ▶ n_1 : zilele pozitive, n_2 : zilele negative, $n = n_1 + n_2$; R : numărul secvențelor = schimbările de semn +1
- Sub H_0 (semne independente), condiționat de n_1 și n_2

$$\mathbb{E}[R] = \frac{2n_1n_2}{n} + 1, \quad \text{Var}[R] = \frac{2n_1n_2(2n_1n_2 - n)}{n^2(n-1)}, \quad z = \frac{R - \mathbb{E}[R]}{\sqrt{\text{Var}[R]}} \approx N(0, 1)$$

- ▶ prea puține secvențe ($z < 0$): semnele persistă; prea multe ($z > 0$): semnele alternează
 - ▶ pentru n mic folosim distribuția exactă a lui R condiționat de n_1, n_2 , nu aproximarea Normală
- Exemplu: ++--+-: $n_1 = 3$, $n_2 = 3$, $R = 4$
 - ▶ $\mathbb{E}[R] = 2 \cdot 9/6 + 1 = 4$: exact atâtea secvențe câte sînt așteptate

Noțiuni necesare azi (19/23): regresia predictivă și deplasarea Kendall (pachetul 3)



■ OLS $\hat{\rho}$, 20 000 samples

■ true $\rho = 0.95$

■ mean of $\hat{\rho} = 0.859$

■ Kendall: $\rho - (1 + 3\rho)/T = 0.873$

- **Regresia predictivă:** randamentul perioadei următoare în funcție de un predictor x_t cunoscut azi

$$r_{t+1} = \alpha + \beta x_t + u_{t+1}, \quad x_{t+1} = \theta + \rho x_t + v_{t+1}$$

- ▶ x_t : de exemplu raportul log dividend-preț
 $dp_t = \ln D_t - \ln P_t$, foarte persistent (ρ aproape de 1)
- ▶ u, v : șocuri; o creștere a prețului scade x , deci $\text{corr}(u, v) < 0$

- **Deplasarea Kendall:** OLS subestimează un ρ persistent în selecții scurte

$$\mathbb{E}[\hat{\rho} - \rho] \approx -\frac{1 + 3\rho}{T}$$

- ▶ graficul: $\rho = 0.95$, $T = 50$; media lui $\hat{\rho}$ este 0,859, sub valoarea adevărată
- ▶ când u și v sînt corelate, această deplasare trece în $\hat{\beta}$ [Stambaugh \(1999\)](#); A4 arată cum

Noțiuni necesare azi (20/23): prognoze în afara selecției (pachetul 3)

- Prognoză recursivă: la fiecare t estimăm doar pe datele pînă la t , prognozăm $\hat{r}_{t+1}$; reperul este media istorică $\bar{r}_t$
- R^2 în afara selecției [Welch & Goyal \(2008\)](#)

$$R_{OS}^2 = 1 - \frac{\sum_t (r_{t+1} - \hat{r}_{t+1})^2}{\sum_t (r_{t+1} - \bar{r}_t)^2}$$

- ▶ $R_{OS}^2 > 0$: modelul depășește media istorică; poate fi negativ
- **Clark–West** [Clark & West \(2007\)](#): pentru modele imbricate (media este modelul cu $\beta = 0$)

$$\hat{f}_{t+1} = (r_{t+1} - \bar{r}_t)^2 - [(r_{t+1} - \hat{r}_{t+1})^2 - (\bar{r}_t - \hat{r}_{t+1})^2]$$

- ▶ statistica t a mediei lui $\hat{f}_{t+1}$ (HAC), unilaterală: respingem acuratețea egală cînd $t > 1,645$
- ▶ ultimul termen elimină zgomotul estimării lui β , pe care Diebold–Mariano (diferența simplă a erorilor pătratice) îl penalizează
- Restricțiile **Campbell–Thompson** [Campbell & Thompson \(2008\)](#)
 - ▶ $\hat{\beta} = 0$ cînd are semnul greșit, iar o prognoză negativă se înlocuiește cu 0

Noțiuni necesare azi (21/23): studiul de eveniment (pachetul 4)

- **Modelul de piață** pe fereastra de estimare (T_0 zile înaintea evenimentului)

$$r_{i,t} = a_i + b_i r_{m,t} + \varepsilon_{i,t}, \quad AR_{i,t} = r_{i,t} - \hat{a}_i - \hat{b}_i r_{m,t}$$

- ▶ $r_{m,t}$: randamentul pieței (BET); AR : randamentul anormal dintr-o zi a ferestrei evenimentului; $\hat{\sigma}_\varepsilon$: abaterea standard reziduală

- Randamentul anormal cumulat și dispersia lui

$$CAR[\tau_1, \tau_2] = \sum_{t=\tau_1}^{\tau_2} AR_{i,t}, \quad \text{Var}(AR_t) = \hat{\sigma}_\varepsilon^2 (1 + \mathbf{x}_t' (\mathbf{X}_0' \mathbf{X}_0)^{-1} \mathbf{x}_t)$$

- ▶ $\mathbf{x}_t = (1, r_{m,t})'$; $\mathbf{X}_0$: rîndurile $\mathbf{x}_t'$ ale ferestrei de estimare
- ▶ paranteza (eroarea de predicție) depășește 1 când $r_{m,t}$ este departe de valorile obișnuite, de exemplu o prăbușire a pieței în ziua 0

- Mai multe firme la aceeași dată: reziduurile lor sînt corelate (corelația medie $\bar{r}$)

- ▶ Kolari–Pynnönen [Kolari & Pynnönen \(2010\)](#): înmulțim t transversal cu $\sqrt{(1 - \bar{r}) / (1 + (N - 1)\bar{r})}$, N : numărul firmelor

Noțiuni necesare azi (22/23): bootstrap pe blocuri și grup de control (pachetul 5)

- **Bootstrap pe blocuri mobile Künsch (1989):** extragem blocuri de câte ℓ zile consecutive, nu zile izolate
 - ▶ începuturile blocurilor se extrag uniform din $1, \dots, T - \ell + 1$; blocurile se lipesc pînă cînd seria are lungimea T
 - ▶ dependența din interiorul fiecărui bloc (autocorelație, volatility clustering) se păstrează
 - ▶ intervalul percentil: cuantilele de 2,5% și 97,5% ale celor B estimații bootstrap
- **Contrastul înainte/după** pentru un eveniment (o reclasificare)

$$\Delta_i = \hat{\rho}_{1,i}^{\text{după}} - \hat{\rho}_{1,i}^{\text{înainte}}$$

- ▶ i : o piață; alte evenimente din aceiași ani (o pandemie, listări noi) schimbă și ele Δ_i : factori de confuzie

- **Grupul de control:** piețe fără eveniment

$$\Delta_{\text{tratat}} - \bar{\Delta}_{\text{control}}$$

- ▶ valid sub ipoteza *tendințelor paralele*: fără eveniment, piața tratată s-ar fi schimbat ca piețele de control

Noțiuni necesare azi (23/23): mulți predictor: ridge și validare încrucișată (pachetul 5)

- Cu J predictor apropiati ca număr de observații, OLS modelează zgomotul: R^2 mare în selecție, prognoze slabe
- **Regresia ridge**: penalizăm coeficienții mari

$$\hat{h}_\lambda = \arg \min_h \sum_t (y_t - x'_t h)^2 + \lambda \|h\|^2 = (X'X + \lambda I)^{-1} X'y$$

- ▶ $\lambda \geq 0$: penalizarea; $\lambda = 0$ este OLS, $\lambda \rightarrow \infty$ aduce fiecare coeficient la 0
- ▶ predictorii se standardizează întâi (media 0, abaterea standard 1), pentru ca penalizarea să îi trateze la fel
- **Validarea încrucișată**: alegem λ după eroarea de predicție pe datele lăsate în afara estimării
 - ▶ cu câte un an exclus: estimăm fără anul y , prognozăm anul y , repetăm pentru fiecare an și facem media erorilor
- **În selecție față de în afara selecției** [Martin & Nagel \(2022\)](#)
 - ▶ când investitorii învață, testele în selecție resping eficiența deși nimic nu este predictibil în timp real; doar rezultatul în afara selecției este implementabil

A1 [Rezolvat]: raportul dispersiilor, rînd cu rînd — enunț

▣ Întrebări

- ▶ ce calculează $\widehat{VR}(2)$?
- ▶ cum se leagă de $\hat{\rho}_1$?

- ▣ **Date:** opt randamente zilnice în %, în ordine cronologică: 1,0; -0,5; 0,8; 0,3; -1,2; 0,6; 0,9; -0,4; fără alte date; estimatorul simplu, sumele de pătrate împărțite la numărul de termeni

▣ Cerințe

1. Calculați media $\hat{\mu}$, abaterile $e_t = r_t - \hat{\mu}$ și dispersia pe o zi $\hat{\sigma}_1^2 = \frac{1}{8} \sum_t e_t^2$.
2. Calculați autocorelația de ordinul 1 $\hat{\rho}_1 = \sum_{t=2}^8 e_t e_{t-1} / \sum_{t=1}^8 e_t^2$.
3. Formați cele șapte sume suprapuse pe două zile $s_t = r_{t-1} + r_t$ și calculați $\hat{\sigma}_2^2 = \frac{1}{7} \sum_t (s_t - 2\hat{\mu})^2$.
4. Calculați $\widehat{VR}(2) = \hat{\sigma}_2^2 / (2\hat{\sigma}_1^2)$ și comparați-l cu $1 + \hat{\rho}_1$.

- ▣ **De raportat:** o fișă cu coloanele t , r_t , e_t , e_t^2 , $e_t e_{t-1}$, s_t , $(s_t - 2\hat{\mu})^2$ și o frază despre semnul lui $\widehat{VR}(2) - 1$

- ▣ Notebook: secțiunea A1


A1 [Rezolvat]: rezolvare (1/3) — fișa de lucru

t	r_t	e_t	e_t^2	$e_t e_{t-1}$	s_t	$(s_t - 2\hat{\mu})^2$
1	+1,0	+0,8125	0,6602	—	—	—
2	−0,5	−0,6875	0,4727	−0,5586	+0,5	0,0156
3	+0,8	+0,6125	0,3752	−0,4211	+0,3	0,0056
4	+0,3	+0,1125	0,0127	+0,0689	+1,1	0,5256
5	−1,2	−1,3875	1,9252	−0,1561	−0,9	1,6256
6	+0,6	+0,4125	0,1702	−0,5723	−0,6	0,9506
7	+0,9	+0,7125	0,5077	+0,2939	+1,5	1,2656
8	−0,4	−0,5875	0,3452	−0,4186	+0,5	0,0156
sumă			4,4688	−1,7639		4,4044


$$\hat{\mu} = 1,5/8 = 0,1875; \hat{\sigma}_1^2 = 4,4688/8 = 0,5586; \hat{\rho}_1 = -1,7639/4,4688 = -0,395$$

$$\hat{\sigma}_2^2 = 4,4044/7 = 0,6292; \widehat{VR}(2) = 0,6292/(2 \times 0,5586) = 0,563, \text{ față de } 1 + \hat{\rho}_1 = 0,605$$

A1 [Rezolvat]: rezolvare (2/3) — grafic și interpretare



--- Mean $\hat{\mu} = 0.1875$



--- $2\hat{\mu} = 0.375$ $s_t = r_{t-1} + r_t$



A1 [Rezolvat]: rezolvare (3/3) — grafic și interpretare

- $VR(2) = 1 + \rho_1$ este valabil pentru momentele populației; în selecție cele două diferă prin termenii de la capete și prin numitori (7 sume, 8 pătrate): 0,563 față de 0,605 este o diferență de convenție, nu o eroare
- Interpretare: randamentele consecutive se inversează, deci sumele pe două zile variază mai puțin decât două zile separate: revenire la medie. Cu $T = 8$ acesta este un calcul, nu o dovadă: nu facem niciun test

A5 [Rezolvat]: exponentul Hurst implicat pentru BET — enunț

- ▣ **Întrebare:** implică $\widehat{VR}(20) > 1$ al BET memorie lungă?
- ▣ **Date:** BET, randamente log zilnice 2000–2026 (prețuri de închidere): $\widehat{VR}(20) = 1,377$, $\hat{\rho}_1 = 0,109$ (Cursul 2); pentru creșteri (incremente) exact autosimilare (zgomot gaussian fracționar) $VR(q) = q^{2H-1}$
- ▣ **Cerințe**
 1. Logaritmați $VR(q) = q^{2H-1}$ și exprimați $H(q)$ implicat.
 2. Calculați $H(20)$ implicat pentru BET.
 3. Calculați $VR(20)$ și $H(20)$ pentru un AR(1) cu memorie scurtă, cu $\rho_k = 0,109^k$, folosind $VR(q) = 1 + 2 \sum_{k=1}^{q-1} (1 - k/q) \rho_k$.
- ▣ **De raportat:** formula, cele două valori $H(20)$ cu trei zecimale și dacă un singur orizont poate identifica memoria lungă
- ▣ Notebook: secțiunea A5

A5 [Rezolvat]: rezolvare (1/2)



— AR(1), $\rho_1 = 0.109$ (BET) — AR(1), $\rho_1 = -0.1$ ♦ BET, implied $H(20) = 0.553$ ♦ S&P 500, implied $H(20) = 0.453$

A5 [Rezolvat]: rezolvare (2/2)

- (1) $\ln VR(q) = (2H - 1) \ln q$, deci $H(q) = 0,5 + \ln VR(q)/(2 \ln q)$
- (2) $\ln 1,377 = 0,3199$, $2 \ln 20 = 5,991$: $H(20) = 0,5 + 0,3199/5,991 = 0,553$
- (3) AR(1): $VR(20) = 1,231$, $H(20) = 0,535$ și $H(250) = 0,520$ (curba roșie)
- Interpretare: memoria scurtă explică singură cea mai mare parte a lui $H(20)$ pentru BET, iar $H(q)$ revine spre 0,5: un singur orizont nu poate identifica memoria lungă

A6 [Propus]: exponentul Hurst implicat pentru S&P 500 — enunț

- ▣ **Întrebare:** este S&P 500 „anti-persistent” sau doar cu inversări pe termen scurt?
- ▣ **Date:** S&P 500, randamente log zilnice 2000–2026 (prețuri de închidere): $\widehat{VR}(20) = 0,753$; un reper cu memorie scurtă, AR(1) cu $\rho_k = (-0,1)^k$
- ▣ **Cerințe**
 1. Calculați $H(20)$ implicat pentru S&P 500 cu formula din A5.
 2. Calculați $VR(20)$ și $H(20)$ pentru reperul AR(1).
 3. Calculați $VR(250)$, $H(250)$ și limita $VR(\infty) = (1 + \rho)/(1 - \rho)$ pentru AR(1) și citiți curba albastră din graficul A5.
- ▣ **De raportat:** cele cinci cifre și o frază: implică $H(20) < 0,5$ memorie lungă?
- ▣ **Model:** A5 [Rezolvat]
- ▣ **Notebook:** secțiunea A6

B1 [Rezolvat]: raportul dispersiilor clasic și robust — enunț

- ▣ **Întrebare:** resping S&P 500 și BET mersul aleator atunci când permitem volatility clustering?
- ▣ **Date:** S&P 500 și BET, randamente log zilnice 2000–2026, $T = 6\,714$ și $6\,670$; H_0 pentru $z(q)$: RW1 (i.i.d.); H_0 pentru $z^*(q)$: RW3 plus condițiile din [Lo & MacKinlay \(1988\)](#)
- ▣ **Cerințe**
 1. Pentru S&P 500 și $q = 2$, calculați $\hat{\sigma}_a^2$, $\hat{\sigma}_c^2(2)$, $\widehat{VR}(2)$, $\hat{\delta}_1$, $z(2)$ și $z^*(2)$ cu formulele Lo–MacKinlay (slide-ul următor).
 2. Pentru ambele piețe și $q = 2, 5, 10, 20$, calculați $\widehat{VR}(q)$, $z(q)$, $z^*(q)$ și p-value-urile bilaterale cu `variance_ratio(r, q)`.
 3. Calculați statistica Chow–Denning $\max_q |z^*(q)|$ și decideți la 5% cu valoarea critică 2,49; valoarea ei p este $1 - (2\Phi(\text{CD}) - 1)^4$, unde Φ este funcția de repartiție a distribuției Normale standard.
- ▣ **De raportat:** un tabel cu un rând pentru fiecare piață și q ($\widehat{VR}$, z , z^* , p), decizia CD și o frază despre motivul pentru care $|z| > |z^*|$
- ▣ Notebook: secțiunea B1

B1 [Rezolvat]: rezolvare (1/3) — S&P 500, $q = 2$, pas cu pas


- ▣ Randamente în %: $T = 6\,714$, $\hat{\mu} = 0,0247$; dispersia pe o zi $\hat{\sigma}_a^2 = \frac{1}{T-1} \sum_t e_t^2 = 1,4714$
- ▣ 6 713 sume suprapuse $r_t + r_{t-1} - 2\hat{\mu}$; numitorul $m = q(T - q + 1)(1 - q/T) = 13\,422$; $\hat{\sigma}_c^2(2) = 1,3256$
- ▣ $\widehat{VR}(2) = 1,3256/1,4714 = 0,9009$
- ▣ Clasic: $SD = \sqrt{2(2q-1)(q-1)/(3qT)} = \sqrt{1/T} = 0,0122$, deci $z(2) = (-0,0991)/0,0122 = -8,12$
- ▣ Robust: $\hat{\delta}_1 = T \sum_t e_t^2 e_{t-1}^2 / (\sum_t e_t^2)^2 = 4,966$ (circa 1 pentru randamente i.i.d.); pentru $q = 2$, $\hat{\theta}(2) = \hat{\delta}_1$
 - ▶ $z^*(2) = \sqrt{T} (\widehat{VR}(2) - 1) / \sqrt{\hat{\theta}(2)} = 81,94 \times (-0,0991) / \sqrt{4,966} = -3,64$, $p = 0,0003$
- ▣ Statistica robustă este de $1/\sqrt{\hat{\delta}_1}$ ori cea clasică: volatility clustering face selecția efectivă de circa 4,966 ori mai mică

B1 [Rezolvat]: rezolvare (2/3) — ambele piețe, patru orizonturi

	$z(2)$	$z^*(2)$	$z(5)$	$z^*(5)$	$z(10)$	$z^*(10)$	$z(20)$	$z^*(20)$
S&P 500	-8,12	-3,64	-6,37	-2,77	-5,65	-2,50	-4,06	-1,86
BET	8,83	3,84	6,44	2,98	5,44	2,73	6,19	3,31

- ▣ $\widehat{VR}(q)$ pentru $q = 2, 5, 10, 20$: S&P 500 0,901; 0,830; 0,767; 0,753; BET 1,108; 1,173; 1,225; 1,377
- ▣ Chow–Denning: S&P 500 3,64 ($p = 0,0011$), BET 3,84 ($p = 0,0005$): ambele resping RW3 în comun

B1 [Rezolvat]: rezolvare (3/3) — grafic și interpretare



- Interpretare: inversare la S&P 500, persistență la BET; dovezile robuste sînt de două-trei ori mai slabe, iar o respingere nu este o regulă de tranzacționare (costuri, risc, stabilitate: B7)

B7 [Propus]: este inversarea S&P 500 un efect al crizelor? — enunț

- ▣ **Întrebare:** rămîne inversarea S&P 500 din B1 dacă eliminăm cele două perioade de criză?
- ▣ **Date**
 - ▶ S&P 500, randamente log zilnice 2000–2026, $T = 6\,714$; zilele de criză, fixate dinainte: 1 sep. 2008 – 30 iun. 2009 și 15 feb. – 30 iun. 2020
 - ▶ Eliminarea unei perioade lasă segmente contigue. O pereche (r_t, r_{t-1}) cu $t = 1$ iul. 2009 și $t - 1 = 29$ aug. 2008 ar lega două zile aflate la nouă luni distanță: nu este permisă; la fel orice sumă pe 5 zile care traversează un gol
- ▣ **Cerințe**
 1. Pe toate zilele calculați $\hat{\rho}_1$, t i.i.d. $= \hat{\rho}_1/\sqrt{\hat{\tau}_1}$, t robust $= \hat{\rho}_1/\sqrt{\hat{\tau}_1}$ și $z^*(5)$.
 2. Eliminați zilele de criză și repetați în segmentele rămase; raportați randamentele păstrate, perechile valide și sumele valide pe 5 zile.
 3. Raportați intervale robuste de 95% pentru ρ_1 în ambele selecții și decideți la 5%.
- ▣ **De raportat**
 - ▶ un tabel cu două rînduri și o frază
 - ▶ cu cît scade estimația?
 - ▶ este legitimă eliminarea zilelor de criză?
- ▣ **Model:** B1 [Rezolvat]
- ▣ **Notebook:** secțiunea B7

C2 [Propus]: critica unui răspuns AI — răspunsul

- **Cererea** trimisă de un student unui asistent AI: „Testează cu raportul dispersiilor dacă S&P 500 (închideri zilnice, 2000–2026) urmează un mers aleator. Dă-mi cod Python și interpretează rezultatul”

```

1  r = np.log(sp).diff().dropna()           # sp: S&P 500 closes, as in B1
2  T = len(r)
3  def vr(q):
4      rq = r.rolling(q).sum().dropna()     # overlapping q-day returns
5      return rq.var() / (q * r.var())
6  q = 5
7  z = (vr(q) - 1) / np.sqrt(2 * (2*q - 1) * (q - 1) / (3 * q * T))
8  p = 2 * stats.norm.sf(abs(z))

```

- **Interpretarea AI-ului:** (a) „ $VR(2) = 0,901$, $VR(5) = 0,830$, $z(5) = -6,37$, $p < 0,001$: mersul aleator este respins”; (b) „deoarece $VR(2) = 1 + 2\rho_1$, $\rho_1 \approx -0,050$ ”; (c) „ $VR < 1$ înseamnă momentum: cumpărați S&P 500 după zilele de creștere”

C2 [Propus]: critica unui răspuns AI — enunț

- **Întrebare:** ce afirmații ale răspunsului AI sînt susținute efectiv de codul lui?
- **Date:** codul și interpretarea de pe slide-ul anterior; aceleași randamente S&P 500 ca în B1
- **Cerințe**
 1. Verificați patru puncte într-un tabel (numărul liniei, afirmația, corect sau greșit, cum verificați): convenția estimatorului, ipoteza nulă și eroarea ei standard, identitatea VR, interpretarea economică.
 2. Precizați ce cifre raportate calculează efectiv codul (calculează doar $q = 5$).
 3. Efectuați două verificări numerice: $\hat{\rho}_1$ calculat direct și $z^*(5)$ din `variance_ratio`.
 4. Scrieți interpretarea corectată în două fraze.
- **De raportat:** tabelul de verificare, cele două verificări, interpretarea corectată; notați fiecare eroare ca în `AI_ERRORS.md`
- **Model:** A1, B1 [Rezolvat]
- **Notebook:** secțiunea B1

B5 [Rezolvat]: efectul schimbării lunii cu erori HAC — enunț

- **Întrebare:** sînt randamentele din zilele de schimbare a lunii mai mari decît în celelalte zile?
- **Date**
 - ▶ S&P 500 și BET, randamente log zilnice 2000–2026 în puncte de bază, $r_t = 10\,000 \ln(P_t/P_{t-1})$, fiecare pe calendarul propriu de tranzacționare; ultima lună incompletă (septembrie 2026) este eliminată
 - ▶ $TOM_t = 1$ în ultima zi de tranzacționare a lunii și în primele trei zile de tranzacționare ale lunii următoare [Ariel \(1987\)](#), 0 în rest; exemplu: 31 iul. și 3, 4, 5 aug. 2026
- **Cerințe**
 1. Construiți TOM_t din calendarul de tranzacționare (rangul zilei în luna ei, de la început și de la sfîrșit).
 2. Estimați $r_t = a + b TOM_t + u_t$ prin OLS; $\hat{a}$ este media în celelalte zile, $\hat{a} + \hat{b}$ media în zilele TOM.
 3. Calculați erorile standard OLS și HAC Newey–West ale lui $\hat{b}$ cu 5 laguri [Newey & West \(1987\)](#), ambele statistici t și p-value-ul HAC.
 4. Transformați $\hat{b}$ într-un randament log suplimentar aproximativ pe lună (4 zile TOM), înainte de costuri.
- **De raportat:** un tabel (proporția zilelor TOM, $\hat{a}$, $\hat{b}$, ambele SE și t), un grafic cu intervale de 95%, o frază despre motivul diferenței dintre OLS și HAC
- Notebook: secțiunea B5

B5 [Rezolvat]: rezolvare (1/3) — matricea regresorilor

data	r_t (bp)	1	TOM_t
2026-07-27	+1,6	1	0
2026-07-28	+21,0	1	0
2026-07-29	-152,8	1	0
2026-07-30	+164,7	1	0
2026-07-31	+69,8	1	1
2026-08-03	+146,8	1	1
2026-08-04	+177,4	1	1
2026-08-05	-16,8	1	1
2026-08-06	-17,6	1	0
2026-08-07	+61,7	1	0

- Rîndurile S&P 500 în jurul schimbării de lună iulie/august 2026: regresorii sînt o coloană de unu și indicatorul TOM
- OLS: $\hat{b} = \bar{r}_{\text{TOM}} - \bar{r}_{\text{alte}}$; S&P 500 $5,1 - 1,9 = 3,2$ bp; BET $20,4 - 3,1 = 17,3$ bp
- HAC: $\widehat{\text{Var}}(\hat{\beta}) = (X'X)^{-1}\hat{S}(X'X)^{-1}$,
 $\hat{S} = \sum_{|j| \leq 5} (1 - \frac{|j|}{6}) \sum_t x_t \hat{u}_t \hat{u}_{t-j} x'_{t-j}$: permite dispersiei reziduurilor să se schimbe și zilelor vecine să fie corelate
- În cod: `sm.OLS(r, X).fit(cov_type='HAC', cov_kws={'maxlags': 5})`


 MFM_ch2_calendar_anomalies

B5 [Rezolvat]: rezolvare (2/3) — estimări

	Proporția TOM	$\hat{a}$ (bp)	$\hat{b}$ (bp)	SE_{OLS}	t_{OLS}	SE_{HAC}	t_{HAC} (p)
S&P 500	19,1%	1,9	3,2	3,8	0,86	3,5	0,93 (0,35)
BET	19,2%	3,1	17,3	4,3	3,99	4,8	3,62 (0,0003)

- BET: intervalul HAC de 95% $[8,0; 26,7]$ bp; SE HAC depășește SE OLS (volatility clustering și $\rho_1 > 0$), t scade de la 3,99 la 3,62, tot respingere
- S&P 500: $[-3,6; 10,1]$ bp conține 0
- $4\hat{b} \approx 69$ bp (BET): un randament log lunar suplimentar aproximativ față de media celorlalte zile, înainte de costuri, nu randamentul unei strategii

B5 [Rezolvat]: rezolvare (3/3) — grafic și interpretare



- Interpretare: efectul pe o piață a fost selectat dintre multe: corecții pentru efectele testate (B6) înainte de a căuta un mecanism (înrările de salarii și pensii)

B6 [Propus]: cincisprezece teste de calendar și Holm — enunț (1/2)

- **Întrebare:** care dintre cincisprezece efecte de calendar rămân semnificative după o corecție pentru testare multiplă?
- **Date:** cele 15 p-value-uri din tabelul de mai jos: 5 piețe $\times$ 3 efecte (ziua săptămânii: testul Wald al egalității mediilor, HAC 5 laguri; ianuarie: randamente lunare, HAC 3 laguri; TOM: ca în B5), 2000–2026

Piața	Efectul	p	Piața	Efectul	p
S&P 500 (SUA)	ziua săptămânii (medii egale)	0,826	Euro Stoxx 50	schimbarea lunii	0,227
S&P 500 (SUA)	ianuarie	0,426	WIG20 (Polonia)	ziua săptămânii (medii egale)	0,226
S&P 500 (SUA)	schimbarea lunii	0,354	WIG20 (Polonia)	ianuarie	0,686
BET (România)	ziua săptămânii (medii egale)	0,305	WIG20 (Polonia)	schimbarea lunii	0,084
BET (România)	ianuarie	0,137	BUX (Ungaria)	ziua săptămânii (medii egale)	0,933
BET (România)	schimbarea lunii	0,0003	BUX (Ungaria)	ianuarie	0,024
Euro Stoxx 50	ziua săptămânii (medii egale)	0,632	BUX (Ungaria)	schimbarea lunii	0,0003
Euro Stoxx 50	ianuarie	0,774			

B6 [Propus]: cincisprezece teste de calendar și Holm — enunț (2/2)

□ Cerințe

1. Numărați respingerile brute la 5% și calculați FWER pentru 15 teste independente.
2. Aplicați Bonferroni: respingeți dacă $p_i < 0,05/15$.
3. Aplicați Holm: ordonați p-value-urile, comparați $p_{(j)}$ cu $0,05/(16 - j)$ și opriți-vă la prima nerespingere.

□ De raportat: tabelul ordonat cu ranguri, praguri și trei coloane de decizie (brut, Bonferroni, Holm) și o frază despre ianuarie la BUX


□ Model: B5 [Rezolvat]

□ Notebook: secțiunea B6

B3 [Rezolvat]: DFA pe ferestre mobile pentru S&P 500 — enunț


- **Întrebare:** iese vreodată exponentul DFA al S&P 500 dintr-o bandă nulă care permite volatility clustering?
- **Date**
 - ▶ S&P 500, randamente log zilnice 2000–2026; ferestre de 500 de randamente deplasate cu 21 de zile (296 de ferestre); funcția `dfa_hurst(x)`
 - ▶ Grila DFA: 18 lungimi de segment echidistante în $\log n$ de la 10 la circa 125 (un sfert din fereastră; după rotunjire 124), rotunjite la întregi, fără duplicate; restul $T - kn$ al profilului se ignoră; sămînța aleatoare = 42 + indicele ultimei zile a ferestrei
- **Cerințe**
 1. Pentru ultima fereastră (2024-09-20 – 2026-09-18) construiți profilul, eliminați tendința pe segmente și estimați $\log F(n)$ pe $\log n$.
 2. Calculați α_{DFA} în fiecare fereastră.
 3. În fiecare fereastră construiți o bandă cu schimbări de semn: 199 de serii $e_t \eta_t$, $\eta_t = \pm 1$ cu probabilitatea 1/2; păstrați cuantilele de 2,5% și 97,5% ale lui α_{DFA} .
 4. Calculați proporția ferestrelor în afara propriei benzi și în afara unei benzi fixe i.i.d. Student- t_4 (300 de simulări de lungime 500).
- **De raportat:** dreapta pentru o fereastră, graficul pe ferestre mobile, ambele proporții și o frază despre ipotezele benzii
- **Notebook:** secțiunea B3

B3 [Rezolvat]: rezolvare (1/4) — o fereastră, pas cu pas



— Profile $y_k = \sum_{i \leq k} (r_i - \bar{r})$

— Linear trend in each box of $n = 50$ days



● $\log F(n)$, 18 box sizes from 10 to 124

— OLS slope $\hat{\alpha}_{DFA} = 0.457$


— Slope 0.5 (no memory), same start

B3 [Rezolvat]: rezolvare (2/4) — o fereastră, pas cu pas

- Profilul $y_k = \sum_{i \leq k} (r_i - \bar{r})$ (stînga); în fiecare segment de lungime n estimăm o dreaptă și păstrăm reziduurile; $F(n) =$ rădăcina mediei pătratelor reziduurilor
- 18 lungimi de segment de la 10 la 124; panta OLS a lui $\log F(n)$ pe $\log n$ este $\hat{\alpha}_{DFA} = 0,457$ (dreapta), aproape de 0,5

 MFM_ch2_seminar

B3 [Rezolvat]: rezolvare (3/4) — toate ferestrele



B3 [Rezolvat]: rezolvare (4/4) — toate ferestrele

- În afara propriei benzi: 2,0% din 296 de ferestre; în afara benzii fixe Student- t_4 [0,378; 0,614]: 6,4%
- Media $\hat{\alpha}_{DFA} = 0,450$; minimul 0,341 (fereastra încheiată la 2022-03-15), maximul 0,598 (2021-02-12); banda este cea mai largă (0,500) în fereastra încheiată la 2022-02-11
- Interpretare: banda este un reper punctual (semne simetrice și independente condiționat de $|e_t|$), nu un interval de încredere; ferestrele suprapuse sînt corelate, deci proporțiile descriu, nu testează stabilitatea; nu există memorie peste nivelul produs de hazard

B4 [Propus]: eficiența adaptivă a Bitcoin — enunț

- ▣ **Întrebare:** a evoluat Bitcoin spre eficiență din primii ani?
- ▣ **Date:** Bitcoin (USD), prețuri de închidere, randamente log zilnice 7 zile din 7, din 1 ian. 2011 pînă la 18 sep. 2026 (mai devreme decît începutul din 2014 din curs, pentru a include primele bule); ferestre de 365 de zile deplasate cu 30 de zile; H_0 : RW3 [Lo \(2004\)](#)
- ▣ **Cerințe**
 1. Calculați $z^*(5)$ robust în fiecare fereastră.
 2. În fiecare fereastră construiți o bandă cu schimbări de semn pentru $z^*(5)$, cu 999 de replicări (sămînța aleatoare = 42 + indicele ultimei zile a ferestrei), și păstrați cuantilele de 2,5% și 97,5%.
 3. Numărați ferestrele în afara benzii și în afara lui $\pm 1,96$ și comparați cu $0,05 \times$ numărul ferestrelor.
 4. Comparați cu [Urquhart \(2016\)](#): 2010–2016, un set de teste clasice (Ljung–Box, secvențe, Bartels, VR automat, BDS, R/S).
- ▣ **De raportat:** graficul, ferestrele semnalate cu z^* și bandă, ambele numărători și o frază: ce înseamnă „nicio tendință detectată”?
- ▣ **Model:** B3, B1 [Rezolvat]
- ▣ **Notebook:** secțiunea B4

După curs: exerciții și calendar

- Aceste două cerințe folosesc instrumente introduse în [Capitolul 2](#): lucrați-le după curs, înaintea seminarului următor
 - ▶ B3 [Rezolvat]: analiza fluctuațiilor fără tendință (DFA) pe ferestre mobile, cu o bandă nulă obținută prin schimbări de semn (wild bootstrap)
 - ▶ B4 [Propus]: $z^*(5)$ robust din B1 pe ferestre mobile pentru Bitcoin, cu același tip de bandă
- Rezolvarea B4 se discută la seminarul următor

Pachetele de extindere: cerințe prealabile

Pachetul	Exercițiile	Cerințe prealabile
1. Teorie	A2 (distribuția nulă), A3 [Rezolvat] (secvențe), A4 (deplasarea Stambaugh)	A1, B1
2. Mai multe piețe	B2	B1
3. Predictibilitate	B8	A4, B5
4. Studiu de eveniment	B9	Seminarul 0, B7; B5
5. Puncte de plecare pentru proiect	C1, C3	B1, B3; studiul de caz din curs

- Fiecare exercițiu are secțiunea lui în notebook; parcurgeți pachetele în ordine, rezolvările problemelor propuse se discută la seminar

A2 [Propus]: raportul dispersiilor și distribuția lui nulă — enunț

▣ Întrebări

- ▶ de ce $\sqrt{T}(\widehat{VR}(q) - 1)$ are aproximativ distribuția Normală cu dispersia $2(2q - 1)(q - 1)/(3q)$?
- ▶ când nu mai este valabilă această aproximare?

- ▣ **Date:** r_t staționar în covarianță, dispersia γ_0 , autocovarianțele $\gamma_k = \text{Cov}(r_t, r_{t-k})$, $\rho_k = \gamma_k/\gamma_0$; sub RW1 $\sqrt{T}(\hat{\rho}_1, \dots, \hat{\rho}_{q-1})$ tinde la $N(0, I_{q-1})$, I_{q-1} matricea identitate (componente independente, dispersii 1); S&P 500: $T = 6\,714$, $\widehat{VR}(2) = 0,901$

▣ Cerințe

1. Pentru $q = 3$, scrieți $\text{Var}(r_t + r_{t-1} + r_{t-2})$ ca sumă a celor nouă covarianțe și numărați de câte ori apar γ_0 , γ_1 , γ_2 .
2. Generalizați: arătați că $\text{VR}(q) = 1 + \sum_{k=1}^{q-1} a_k \rho_k$ cu $a_k = 2(1 - k/q)$.
3. Sub RW1, cu $a = (a_1, \dots, a_{q-1})'$, calculați $a'la = \sum_k a_k^2$ și simplificați-l la $2(2q - 1)(q - 1)/(3q)$; evaluați-l pentru $q = 2, 5, 20$.
4. Calculați $z(2)$ pentru S&P 500 și explicați de ce I trebuie înlocuit cu $\text{diag}(\delta_k)$, matricea diagonală a dispersiilor robuste δ_k , sub RW3.

- ▣ **De raportat:** numărarea, dispersia în două coloane (asimptotică, a lui $\sqrt{T}(\widehat{VR} - 1)$; în selecție finită, a lui $\widehat{VR}$: împărțită la T) și $z(2)$

- ▣ **Model:** A1 [Rezolvat]


- ▣ **Notebook:** secțiunea A2

A3 [Rezolvat]: testul secvențelor, pas cu pas — enunț

- ▣ **Întrebare:** sînt 20 de semne compatibile cu independența?
- ▣ **Date:** semnele a 20 de randamente zilnice consecutive, fără zerouri: ++-+++--+-+---+-+++; sub H_0 semnele sînt independente, cu o probabilitate constantă a unei zile pozitive [Wald & Wolfowitz \(1940\)](#)
- ▣ **Cerințe**
 1. Numerotați semnele de la 1 la 20, marcați fiecare schimbare de semn și numărați n_1 , n_2 și secvențele R .
 2. Calculați $\mathbb{E}[R] = 2n_1n_2/n + 1$ și $\text{Var}[R] = 2n_1n_2(2n_1n_2 - n)/(n^2(n - 1))$.
 3. Calculați z aproximativ și valoarea lui p bilaterală.
 4. Comparați cu distribuția exactă a lui R condiționată de n_1 și n_2 .
- ▣ **De raportat:** n_1 , n_2 , R , $\mathbb{E}[R]$, $\text{Var}[R]$, z , ambele p -value-uri și ce ar însemna prea puține sau prea multe secvențe
- ▣ Notebook: secțiunea A3

A3 [Rezolvat]: rezolvare (1/2)

Signs of 20 returns: $n_1 = 12$ plus, $n_2 = 8$ minus, $R = 11$ runs (black lines: run boundaries)



A3 [Rezolvat]: rezolvare (2/2)

- ▣ (1) Secvențele: ++ | - | +++ | -- | + | - | ++ | - - - | + | - | +++, deci $n_1 = 12$, $n_2 = 8$, $R = 11$ (10 schimbări de semn)
- ▣ (2) $\mathbb{E}[R] = 2 \cdot 12 \cdot 8/20 + 1 = 10,60$; $\text{Var}[R] = 192 \cdot 172/(400 \cdot 19) = 4,345$; (3) z aproximativ $= 0,40/2,085 = 0,19$, $p = 0,85$
- ▣ (4) Exact: $P(R = 11) = 0,183$, $P(R \geq 11) = 0,520$, $P(R \leq 11) = 0,663$, deci p exact bilateral este 1. Interpretare: nu respingem independența; prea puține secvențe ar însemna semne persistente, prea multe semne alternante

A4 [Propus]: deplasarea Stambaugh — enunț

▣ **Întrebare:** de ce pare un raport de evaluare persistent prea des un predictor semnificativ?

▣ **Date**

- ▶ x_t : raportul log dividend-preț, foarte persistent; când prețurile cresc, x scade, deci inovațiile randamentelor și ale lui x sînt corelate negativ
- ▶ Sistemul: $r_{t+1} = \alpha + \beta x_t + u_{t+1}$, $x_{t+1} = \theta + \rho x_t + v_{t+1}$; scriem $u = \phi v + e$, $\phi = \sigma_{uv} / \sigma_v^2$, cu $\sigma_{uv} = \text{Cov}(u, v)$, σ_u , σ_v abaterile standard ale șocurilor și e partea lui u necorelată cu v ; Kendall: $\mathbb{E}[\hat{\rho} - \rho] \approx -(1 + 3\rho)/T$ [Stambaugh \(1999\)](#)
- ▶ Valori anuale ilustrative (ca fracții, nu în procente): $\rho = 0,98$, $T = 60$ de ani, $\text{corr}(u, v) = -0,9$, $\sigma_u = 0,17$, $\sigma_v = 0,14$

▣ **Cerințe**

1. Cu $\tilde{x}_t = x_t - \bar{x}$ centrat, arătați $\hat{\beta} - \beta = \phi(\hat{\rho} - \rho) + \sum \tilde{x}_t e_{t+1} / \sum \tilde{x}_t^2$ și deduceți $\mathbb{E}[\hat{\beta} - \beta]$.
2. Calculați ϕ , $\mathbb{E}[\hat{\rho} - \rho]$ și deplasarea lui $\hat{\beta}$.
3. Calculați $\text{SE}(\hat{\beta}) \approx \sigma_u / (\sigma_x \sqrt{T})$, $\sigma_x = \sigma_v / \sqrt{1 - \rho^2}$, și deplasarea în erori standard.

▣ **De raportat:** derivarea, ϕ , deplasarea, SE, raportul lor și cum afectează o deplasare pozitivă rata respingerilor false

▣ **Model:** A1 [Rezolvat]

▣ **Notebook:** secțiunea A4

B2 [Propus]: BET-TR și piețele emergente — enunț

- ▣ **Întrebare:** sînt piețele emergente mai puțin eficiente, ca grup?
- ▣ **Date:** BET-TR (din 2014) și WIG20, BUX, PX, BIST 100, Bovespa, IPC, Nifty 50, Shanghai, prețuri de închidere, 2000–2026, fiecare pe calendarul propriu
- ▣ **Cerințe**
 1. Începeți cu BET și BET-TR pe aceleași date (perioada BET-TR): $z(2)$ clasic, $z^*(2)$ robust, Chow–Denning.
 2. Repetați pentru ceilalți opt indici și raportați separat trei decizii: $q = 2$ clasic, $q = 2$ robust, test comun robust pe patru orizonturi.
 3. Înaintea oricărei concluzii despre grup, corectați p-value-urile comune pentru cele nouă piețe testate (Holm).
- ▣ **De raportat:** un tabel (un rînd pe piață), comparația BET pe aceeași perioadă și o frază: diferența se datorează dividendelor sau perioadei?
- ▣ **Model:** B1 [Rezolvat]
- ▣ **Notebook:** secțiunea B2

B8 [Propus]: regresie predictivă și un test în afara selecției — enunț (1/2)

- ▣ **Întrebare:** prezice raportul dividend–preț randamentele în exces ale S&P 500, în selecție și în afara selecției?
- ▣ **Date**
 - ▶ Tabel lunar 1934–2026 ($T = 1111$): P = prețul mediu lunar S&P Composite al lui Shiller (până la 2026-06), prelungit cu închiderile S&P 500 de sfârșit de lună; D = dividendele pe ultimele 12 luni (Shiller, interpolate din totaluri trimestriale), prelungite cu dividendele fondului SPY (ETF pe S&P 500), deduse din diferența dintre prețul de închidere și prețul ajustat pentru dividende, racordate pe perioada comună
 - ▶ $r_{t+1} = \ln((P_{t+1} + D_{t+1}/12)/P_t) - \ln(1 + TB3MS_t/1200)$ (FRED, cunoscută la t); predictorul $dp_t = \ln D_t - \ln P_t$, folosit cu o lună întârziere

B8 [Propus]: regresie predictivă și un test în afara selecției — enunț (2/2)

▣ Cerințe

1. Estimați $r_{t+1} = \alpha + \beta dp_t + u_{t+1}$ prin OLS cu erori Newey–West (12 laguri); estimați AR(1) pentru dp și $\text{corr}(\hat{u}, \hat{v})$; corectați $\hat{\beta}$ pentru deplasarea Stambaugh (A4).
2. Din ianuarie 1970, în fiecare lună reestimați pe datele pînă la luna anterioară și prognozați; reperul este media istorică a acelorași date; calculați R_{OS}^2 [Welch & Goyal \(2008\)](#) (pseudo în afara selecției: dividendele sînt interpolate).
3. Calculați t Clark–West (HAC, 12 laguri, unilateral) [Clark & West \(2007\)](#); impuneți restricțiile Campbell–Thompson (semnul pantei, prognoză nenegativă) [Campbell & Thompson \(2008\)](#).

▣ **De raportat:** $\hat{\beta}$, t , $\hat{\rho}$, deplasarea, R_{OS}^2 , t Clark–West și de ce Diebold–Mariano este testul nepotrivit pentru modele imbricate

▣ **Model:** A4, B5

▣ **Notebook:** secțiunea B8

B9 [Propus]: taxa bancară, TLV și BRD împreună — enunț (1/2)

- ▣ **Întrebare:** cât din scăderea provocată de taxa bancară rămîne semnificativă cu o inferență corectă de studiu de eveniment?
- ▣ **Date**
 - ▶ Banca Transilvania (TLV) și BRD (prețuri ajustate pentru dividende și split-uri) și BET (prețuri de închidere), prețuri aliniate pe zilele comune de tranzacționare, apoi randamente log
 - ▶ Cronologia: taxa anunțată în seara de 18 dec. 2018; ziua 0 = 19 dec.; fereastra de estimare zilele $[-250, -11]$ ($T_0 = 240$); fereastra evenimentului $[0, +5]$
 - ▶ X_0 (240×2) și X_e (6×2): rîndurile $[1, r_{m,t}]$ ale ferestrei de estimare și ale ferestrei evenimentului; ι : un vector 6×1 de unu; I_6 : matricea identitate 6×6 ; N : numărul de firme; $\bar{r}$: corelația medie a reziduurilor lor

B9 [Propus]: taxa bancară, TLV și BRD împreună — enunț (2/2)

▣ Cerințe

1. Pentru TLV estimați modelul de piață pe $[-250, -11]$, calculați AR_0 , t naiv $= AR_0/\hat{\sigma}_\varepsilon$ și t cu dispersia erorii de predicție; repetați pentru BRD.
2. Pentru portofoliul egal ponderat al celor două bănci estimați modelul de piață pe randamentele lui și calculați AR_0 și t ; comparați cu t care presupune bănci independente.
3. Calculați $CAR[0, +5]$ și $CAR[+1, +5]$ cu $\text{Var}(CAR) = \iota' \hat{\sigma}_\varepsilon^2 [I_6 + X_e(X_0'X_0)^{-1}X_e']\iota$ (adaptat ferestrei folosite).
4. Calculați corelația reziduurilor $\bar{r}$ și factorul Kolari–Pynnönen $\sqrt{(1 - \bar{r})/(1 + (N - 1)\bar{r})}$ Kolari & Pynnönen (2010), o corecție pentru testele transversale cu multe firme.

▣ **De raportat:** un tabel (TLV, BRD, portofoliu), graficul AR/CAR și dacă inversarea contrazice eficiența semi-tare; țineți cont că BET conține ambele bănci

▣ **Model:** Seminarul 0, B7; B5

▣ **Notebook:** secțiunea B9

C1 [Propus]: eficiența BVB după reclasificarea FTSE din 2020 — enunț (1/2)

- **Întrebare:** s-a apropiat autocorelația de ordinul 1 a BET de zero după reclasificare, față de WIG20 și BUX?
- **Date**
 - ▶ **FTSE Russell (2019):** anunț la 26 sep. 2019, efectiv la 21 sep. 2020 (din piață de frontieră în piață emergentă secundară); context: [Pele & Mazurencu-Marinescu \(2012\)](#)
 - ▶ BET, WIG20, BUX, prețuri de închidere; înainte: 21 sep. 2015 – 20 sep. 2020; după: 21 sep. 2020 – 21 sep. 2025; datele de după 21 sep. 2025 se folosesc doar într-o extindere raportată separat

C1 [Propus]: eficiența BVB după reclasificarea FTSE din 2020 — enunț (2/2)

▣ Cerințe

1. Pentru fiecare piață calculați $\hat{\rho}_1$ cu SE robustă și $z^*(5)$ în ambele ferestre.
2. Construiți un interval de 95% pentru schimbarea lui $\hat{\rho}_1$ printr-un bootstrap pe blocuri mobile, independent în fiecare perioadă (blocuri de 20 de zile, 999 de replicări, sămînța 42) [Künsch \(1989\)](#).
3. Reprezentați $\hat{\rho}_1$ pe ferestre mobile de 250 de zile, cu intervale robuste, pentru cele trei piețe, marcînd anunțul, data efectivă și sfîrșitul ferestrei formale.
4. Enumerați factorii de confuzie (COVID-19, listarea Hidroelectrică din 2023, lichiditatea) și precizați ce ar necesita un contrast ajustat cu grupul de control.

▣ **De raportat:** un folder Quantlet și un slide: concluzia, principala limită, legătura cu AMH [Lo \(2004\)](#); evaluați apropierea de zero, nu semnul

▣ **Model:** B1, B3 [Rezolvat]

▣ **Notebook:** secțiunea C1

C3 [Propus]: datele masive și eficiența, în selecție și în afara selecției — enunț (1/2)

- ▣ **Întrebare:** cu 238 de predictor, predictibilitatea în selecție a randamentelor sectoriale se regăsește și în afara selecției?
- ▣ **Date**
 - ▶ Studiul de caz din Cursul 2 [Martin & Nagel \(2022\)](#): învățarea rațională face testele în selecție să respingă, deși randamentele în afara selecției nu pot fi prezise; replicați planul empiric din secț. 7 a lucrării Martin & Nagel (2022)
 - ▶ 49 de portofolii sectoriale, [Kenneth French Data Library](#), randamente lunare ponderate cu capitalizarea, iulie 1926 – ultima lună; valorile lipsă –99,99 și –999 eliminate lună de lună; randamentele împărțite la 100
 - ▶ Dimensiuni: în luna t , X_t are $N_t \times 238$ (randamente și pătratele lor la lagurile 2–120), N_t sectoarele cu istoric complet de 120 de luni; h_t coeficienții 238×1

C3 [Propus]: datele masive și eficiența, în selecție și în afara selecției — enunț (2/2)

▣ Cerințe

1. Centrați transversal randamentele și fiecare predictor în fiecare lună, scalați fiecare predictor la abaterea standard transversală 1, atribuiți fiecărei luni aceeași pondere.
2. Estimați OLS comun h_t pe cele 240 de luni încheiate în t (doar date pînă la t); calculați $roos_{t+1} = \frac{1}{N} h_t' X_{t+1}' r_{t+1}$ și rs pe aceeași fereastră; precizați prima lună cu prognoză.
3. Calculați media lui $roos$ pe ferestre de 10 ani, cu benzi descriptive ± 2 SE (ca în Fig. 8 din lucrare).
4. Estimați o regresie ridge din ianuarie 1971 cu predictor standardizați; alegeți penalizarea pe o grilă logaritmică prin validare încrucișată cu cîte un an exclus (poate folosi ani ulteriori: o validare, nu o prognoză); reprezentați coeficienții pe laguri.

▣ **De raportat:** graficul de la pasul 3, mediile timpurii și târzii ale lui rs și $roos$ cu SE, graficul coeficienților și de ce 49 de portofolii pot diferi de mii de acțiuni

▣ **Model:** B5, B8

▣ **Notebook:** secțiunea C3 (Quantlet-ul de curs MFM_ch2_big_data)

Bibliografie (1/2)

- ▣ Ariel, R.A. (1987). [A monthly effect in stock returns](#). *Journal of Financial Economics*, 18(1), 161–174.
- ▣ Campbell, J.Y., Lo, A.W., MacKinlay, A.C. (1997). [The Econometrics of Financial Markets](#). Princeton University Press.
- ▣ Campbell, J.Y., Thompson, S.B. (2008). [Predicting excess stock returns out of sample: can anything beat the historical average?](#). *Review of Financial Studies*, 21(4), 1509–1531.
- ▣ Chow, K.V., Denning, K.C. (1993). [A simple multiple variance ratio test](#). *Journal of Econometrics*, 58(3), 385–401.
- ▣ Clark, T.E., West, K.D. (2007). [Approximately normal tests for equal predictive accuracy in nested models](#). *Journal of Econometrics*, 138(1), 291–311.
- ▣ Franke, J., Härdle, W.K., Hafner, C.M. (2019). [Statistics of Financial Markets: An Introduction](#), ed. a 5-a. Springer.
- ▣ French, K.R. (2026). [Kenneth R. French Data Library](#). Tuck School of Business, Dartmouth College.
- ▣ FTSE Russell (2019). [FTSE Russell announces results of country classification review](#) (comunicat de presă, 26 septembrie 2019).
- ▣ Harvey, C.R., Liu, Y., Zhu, H. (2016). [... and the cross-section of expected returns](#). *Review of Financial Studies*, 29(1), 5–68.
- ▣ Kim, J.H. (2006). [Wild bootstrapping variance ratio tests](#). *Economics Letters*, 92(1), 38–43.
- ▣ Kolari, J.W., Pynnönen, S. (2010). [Event study testing with cross-sectional correlation of abnormal returns](#). *Review of Financial Studies*, 23(11), 3996–4025.
- ▣ Künsch, H.R. (1989). [The jackknife and the bootstrap for general stationary observations](#). *Annals of Statistics*, 17(3), 1217–1241.

Bibliografie (2/2)

- ▣ Lo, A.W. (1991). Long-term memory in stock market prices. *Econometrica*, 59(5), 1279–1313.
- ▣ Lo, A.W. (2004). The adaptive markets hypothesis. *Journal of Portfolio Management*, 30(5), 15–29.
- ▣ Lo, A.W., MacKinlay, A.C. (1988). Stock market prices do not follow random walks: evidence from a simple specification test. *Review of Financial Studies*, 1(1), 41–66.
- ▣ MacKinlay, A.C. (1997). Event studies in economics and finance. *Journal of Economic Literature*, 35(1), 13–39.
- ▣ Martin, I.W.R., Nagel, S. (2022). Market efficiency in the age of big data. *Journal of Financial Economics*, 145(1), 154–177.
- ▣ Newey, W.K., West, K.D. (1987). A simple, positive semi-definite, heteroskedasticity and autocorrelation consistent covariance matrix. *Econometrica*, 55(3), 703–708.
- ▣ Pele, D.T., Mazurencu-Marinescu, M. (2012). Modelling stock market crashes: the case of Bucharest Stock Exchange. *Procedia – Social and Behavioral Sciences*, 58, 533–542.
- ▣ Peng, C.-K., Buldyrev, S.V., Havlin, S., Simons, M., Stanley, H.E., Goldberger, A.L. (1994). Mosaic organization of DNA nucleotides. *Physical Review E*, 49(2), 1685–1689.
- ▣ Romano, J.P., Wolf, M. (2005). Stepwise multiple testing as formalized data snooping. *Econometrica*, 73(4), 1237–1282.
- ▣ Stambaugh, R.F. (1999). Predictive regressions. *Journal of Financial Economics*, 54(3), 375–421.
- ▣ Urquhart, A. (2016). The inefficiency of Bitcoin. *Economics Letters*, 148, 80–82.
- ▣ Wald, A., Wolfowitz, J. (1940). On a test whether two samples are from the same population. *Annals of Mathematical Statistics*, 11(2), 147–162.
- ▣ Welch, I., Goyal, A. (2008). A comprehensive look at the empirical performance of equity premium prediction. *Review of Financial Studies*, 21(4), 1455–1508.