



Modelarea piețelor financiare

Seminarul 4: Optimizarea portofoliului — Aplicații



Daniel Traian PELE

Antoaneta Amza

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognostic Economică

MSCA Digital Finance

Acronime folosite în acest material (1/2)

- ▣ AAPL: Apple Inc. (Nasdaq ticker) (Apple Inc., simbolul bursier Nasdaq)
- ▣ AI: Artificial Intelligence (inteligență artificială)
- ▣ AMZN: Amazon.com, Inc. (Nasdaq ticker) (Amazon.com, Inc. (simbolul bursier Nasdaq))
- ▣ BAC: Bank of America Corporation (NYSE ticker) (Bank of America Corporation (simbolul bursier NYSE))
- ▣ BET: Bucharest Exchange Trading (index) (indicele de referință al Bursei de Valori București)
- ▣ BET-TR: BET Total Return (index) (indicele BET cu dividendele reinvestite)
- ▣ BVB: Bursa de Valori București
- ▣ CSCO: Cisco Systems, Inc. (Nasdaq ticker) (Cisco Systems, Inc. (simbolul bursier Nasdaq))
- ▣ ERC: Equal Risk Contribution portfolio (portofoliul cu contribuții egale la risc)
- ▣ ETF: Exchange-Traded Fund (fond tranzacționat la bursă)
- ▣ GLS: Generalised Least Squares (metoda celor mai mici pătrate generalizate)
- ▣ GME: GameStop Corp. (NYSE ticker) (GameStop Corp. (simbolul bursier NYSE))
- ▣ GMV: Global Minimum-Variance portfolio (portofoliul de varianță minimă globală)
- ▣ GMV-LW: Global Minimum-Variance portfolio with Ledoit–Wolf covariance (portofoliul de varianță minimă globală cu covarianța Ledoit–Wolf)
- ▣ GMV-NL: Global Minimum-Variance portfolio with Nonlinear shrinkage covariance (portofoliul de varianță minimă globală cu covarianța estimată prin shrinkage neliniar)
- ▣ GOOGL: Alphabet Inc., Class A shares (Nasdaq ticker) (Alphabet Inc., acțiuni de clasă A (simbolul bursier Nasdaq))
- ▣ GS: The Goldman Sachs Group, Inc. (NYSE ticker) (The Goldman Sachs Group, Inc. (simbolul bursier NYSE))
- ▣ HAC: Heteroskedasticity and Autocorrelation Consistent (standard errors) (erori standard robuste la heteroscedasticitate și autocorelație)
- ▣ HRP: Hierarchical Risk Parity (paritatea ierarhică a riscului)
- ▣ HYG: iShares iBoxx High Yield Corporate Bond ETF (ETF de obligațiuni corporative americane cu randament ridicat, sub rating investițional)
- ▣ IEF: iShares 7–10 Year Treasury Bond ETF (ETF de obligațiuni de stat americane cu scadența 7–10 ani)
- ▣ JPM: JPMorgan Chase & Co. (NYSE ticker) (JPMorgan Chase & Co. (simbolul bursier NYSE))
- ▣ LQD: iShares iBoxx Investment Grade Corporate Bond ETF (ETF de obligațiuni corporative americane cu rating investițional)
- ▣ MS: Morgan Stanley (NYSE ticker) (Morgan Stanley (simbolul bursier NYSE))
- ▣ MSFT: Microsoft Corporation (Nasdaq ticker) (Microsoft Corporation (simbolul bursier Nasdaq))
- ▣ MSTR: Strategy Inc., formerly MicroStrategy (Nasdaq ticker) (Strategy Inc., fosta MicroStrategy (simbolul bursier Nasdaq))

Acronime folosite în acest material (2/2)

- MV: Mean–Variance tangency portfolio estimated from sample moments (portofoliul tangent medie–varianță estimat din momentele de eșantion)
- MV-LO: Mean–Variance tangency portfolio, Long-Only (portofoliul tangent medie–varianță, doar poziții long)
- NVDA: NVIDIA Corporation (Nasdaq ticker) (NVIDIA Corporation, simbolul bursier Nasdaq)
- OLS: Ordinary Least Squares (metoda celor mai mici pătrate)
- SE: Standard Error (eroare standard)
- SUA: Statele Unite ale Americii
- WFC: Wells Fargo & Company (NYSE ticker) (Wells Fargo & Company (simbolul bursier NYSE))

Întrebările de azi și traseul

- ▣ Întrebările seminarului
 - ▶ poate un portofoliu optimizat să bată ponderile egale ($1/N$) în afara eșantionului?
 - ▶ cum am ști că reușește?
- ▣ Traseul seminarului
 - ▶ ce vă trebuie azi: patru slide-uri introductive (cursul are loc după acest seminar)
 - ▶ A1, A3, A4: GMV și risk parity cu două active, pe hîrtie
 - ▶ B1: backtest-ul pe ferestre mobile al celor patru reguli pe nouă sectoare, apoi A7–A8: testăm diferențele de Sharpe pe care le produce; B8: costul-prag
 - ▶ C2: găsiți erorile dintr-un răspuns A1
 - ▶ după curs: B2 (reduce shrinkage-ul riscul?), B3 (ERC și HRP pas cu pas); C1 este proiectul pentru acasă
- ▣ Ce realizați: răspunsurile de la A, un tabel și o figură pentru fiecare exercițiu B, codul corectat de la C2, o propoziție de interpretare pentru fiecare exercițiu
- ▣ Notebook-ul de azi: [deschideți notebook-ul seminarului în Colab](#); fiecare exercițiu are secțiunea lui
- ▣ Seminar: Drd. Antoaneta Amza, antoaneta.amza@csie.ase.ro

Harta exercițiilor

Exercițiu	Întrebare	Tip	Model
A1	unde este combinația de varianță minimă dintre SPY și TLT?	Rezolvat	–
A3, A4	cine poartă riscul: ERC versus 60/40	Rezolvat, Propus	A4: A3
B1 A7, A8	bat regulile Markowitz ponderile 1/N pe sectoare? este semnificativă o diferență de Sharpe?	Rezolvat Rezolvat, Propus	– A8: A7
B8 C2	la ce cost nu mai merită MV-LO? ce e greșit într-un backtest scris de AI?	Propus Propus	B1 B1, A7
După curs	B2 [Rezolvat], B3 [Rezolvat]: shrinkage-ul covarianței, ERC și HRP	temă	B1
C1	un portofoliu BVB în lei (proiect pentru acasă)	Propus	B1, B3
Pachete de extindere	A2, A4 extins, A5, A6, A9, B2 extins, B4–B7, B9, C3 (opționale)	Rezolvat sau Propus	indicat la fiecare cerință

- **[Rezolvat]:** rezolvarea completă în slide-uri și în notebook, un model de urmat; **[Propus]:** îl rezolvați voi, rezolvarea se discută la seminar
- Partea A: derivări pe hîrtie; Partea B: backtest-uri și inferență pe date reale, fiecare cu o întrebare de interpretare; Partea C: întrebări deschise și critica unui răspuns AI

Datele folosite

Univers	Active (preț folosit)	Monedă	Randamente lunare	Luni
Sectoare	XLB, XLE, XLF, XLI, XLK, XLP, XLU, XLV, XLY (închidere ajustată)	USD	ian. 1999 – iul. 2026	331
Multi-active	SPY, EFA, EEM, TLT, IEF, LQD, HYG, GLD (închidere ajustată)	USD	mai 2007 – iul. 2026	231
Combinat	9 sectoare + cele 7 ETF-uri multi-active, fără SPY	USD	mai 2007 – iul. 2026	231
Bitcoin	Bitcoin (BTC/USD, închidere)	USD	sep. 2010 – iul. 2026	doar B5
BVB	TLV, SNP, BRD, TGN, SNG, SNN, EL, TEL; indicele BET-TR (închidere)	RON	oct. 2014 – aug. 2026	doar C1

- Prețurile zilnice din datele cursului, câte o serie pe activ (câmpul folosit: close / adjusted close)
- Aliniați *prețurile* unui univers pe zilele comune de tranzacționare, păstrați ultimul preț din fiecare lună, apoi calculați randamentele simple în zecimale ($0,01 = 1\%$)
- Rata fără risc: titlul de stat la o lună, [Kenneth French Data Library](#), zecimale lunare aliniate pe data de sfârșit de lună; randament în exces $r_t^e = r_t - r_{f,t}$; USD/RON: cursul de referință [BNR](#) (C1)

Pregătire: rulați și verificați

```
# notebook section "Setup" defines the helpers
r, rex, rf = us_monthly(SECTORS)
# r: monthly simple returns (T x 9)
# rex = r - rf: excess returns; rf: T-bill
print(r.shape, r.index[0], r.index[-1])
print(r.iloc[0][['XLB', 'XLK', 'XLU']], rf.iloc[0])
ret, to, W = backtest(r, rex)
# ret: OOS excess returns of each rule
# to: monthly turnover; W: weights per rule
```

- Rezultat așteptat: 331 de luni, primul randament 1999-01-31, ultimul 2026-07-31
- Primul rând (ianuarie 1999): XLB -3,70%, XLK 15,90%, XLU -2,48%; titlul de stat 0,35% pe lună
- backtest folosește lunile $t - 60, \dots, t - 1$ pentru ponderile lunii t : 271 de luni în afara eșantionului, 2004-01 - 2026-07
- Alte funcții: `sr_diff_hac(r1, r2)` întoarce diferența anualizată, eroarea ei standard HAC și p ; `sr_diff_boot(r1, r2, block)` testul bootstrap studentizat; `lw_cc(X)` covarianța cu shrinkage și δ
- Dacă un număr de observații sau o primă valoare diferă, opriți-vă și verificați simbolurile, tipul de preț (ajustat sau de închidere) și alinierea datelor

Notăția folosită în toate exercițiile

- ▣ w : ponderi, $w^\top 1 = 1$; μ , Σ : vectorul mediilor și matricea de covarianță a randamentelor în exces; $\sigma_p^2 = w^\top \Sigma w$
- ▣ GMV $w = \Sigma^{-1} 1 / 1^\top \Sigma^{-1} 1$; tangent (MV) $w = \Sigma^{-1} \mu / 1^\top \Sigma^{-1} \mu$; MV-LO: tangent cu $0 \leq w_i \leq 1$
- ▣ Contribuția la risc $RC_i = w_i (\Sigma w)_i / \sigma_p$; cota de risc RC_i / σ_p ; ERC (Maillard, Roncalli & Teïletche (2010)): RC_i egale; HRP (López de Prado (2016))
- ▣ Raportul Sharpe $SR = \bar{r}^e / s(r^e)$, lunar, anualizat $\times \sqrt{12}$; $\hat{\Delta} = \widehat{SR}_1 - \widehat{SR}_2$
- ▣ Ponderi după drift (modificate de randamente) $w_{i,t}^+ = w_{i,t} (1 + R_{i,t}) / \sum_j w_{j,t} (1 + R_{j,t})$; turnover $TO_{t+1} = \sum_i |w_{i,t+1} - w_{i,t}^+|$
- ▣ Randament net $r_t^{\text{net}} = r_t - c TO_t$, c costul pe unitate tranzacționată; 1 punct de bază (bp) = 10^{-4} , deci 20 bp înseamnă $c = 0,002$
- ▣ Exemplu numeric: $\sigma_1 = 20\%$, $\sigma_2 = 10\%$, $\rho = 0$, $w = (0,5; 0,5)$: $\sigma_p^2 = 0,25(0,04) + 0,25(0,01) = 0,0125$, $\sigma_p = 11,2\%$

Ce vă trebuie azi (1/4): GMV, portofoliul tangent și 1/N

- ▣ Seminarul are loc **înaintea** cursului: aceste patru slide-uri dau doar ce folosesc cerințele de la seminar; detaliile în [Capitolul 4](#), cursul de după seminar
- ▣ Varianța portofoliului $\sigma_p^2 = \mathbf{w}^\top \Sigma \mathbf{w}$ [Markowitz \(1952\)](#); patru reguli pentru ponderi, toate cu $\mathbf{w}^\top \mathbf{1} = 1$
 - ▶ **GMV** (global minimum variance, portofoliul de varianță minimă globală): $\min_{\mathbf{w}} \mathbf{w}^\top \Sigma \mathbf{w}$, cu soluția $\Sigma^{-1} \mathbf{1} / (\mathbf{1}^\top \Sigma^{-1} \mathbf{1})$; nu are nevoie de randamentele așteptate
 - ▶ **MV**: portofoliul tangent din [Capitolul 3](#), $\Sigma^{-1} \boldsymbol{\mu} / (\mathbf{1}^\top \Sigma^{-1} \boldsymbol{\mu})$; **MV-LO**: același raport Sharpe maxim, cu $0 \leq w_i \leq 1$, rezolvat numeric
 - ▶ **1/N**: ponderi egale, nimic estimat [DeMiguel, Garlappi & Uppal \(2009\)](#)
- ▣ Exemplu: două active necorelate, $\sigma_1 = 20\%$, $\sigma_2 = 10\%$: $\Sigma^{-1} \mathbf{1} = (25, 100)$, GMV $\mathbf{w} = (0,2; 0,8)$, $\sigma_{\text{GMV}} = 1/\sqrt{125} = 8,94\%$, sub ambele volatilități
- ▣ De ce 1/N este greu de bătut: $\boldsymbol{\mu}$ se estimează cu erori mari, iar Σ^{-1} le amplifică în ponderi extreme

Ce vă trebuie azi (2/4): contribuții la risc și ERC

- Descompunerea Euler: $\sigma_p = \sum_i RC_i$, cu $RC_i = w_i(\Sigma w)_i / \sigma_p$, contribuția activului i la volatilitate; cotele de risc RC_i / σ_p însumează 100%
- Exemplu ($\sigma_1 = 20\%$, $\sigma_2 = 10\%$, $\rho = 0$, $w = (0,5; 0,5)$): $\Sigma w = (0,020; 0,005)$, $\sigma_p^2 = 0,0125$
 - ▶ cotele $0,5 \times 0,020 / 0,0125 = 80\%$ și $0,5 \times 0,005 / 0,0125 = 20\%$: jumătate din bani, patru cincimi din risc
- **ERC** (equal risk contribution, contribuții egale la risc; risk parity) [Maillard, Roncalli & Teiletche \(2010\)](#): alegem w astfel încât toate RC_i să fie egale; cu $\rho = 0$ și două active, $w_i \propto 1/\sigma_i$, aici $(1/3, 2/3)$
- Ponderile în capital și ponderile în risc sînt lucruri diferite: un portofoliu „echilibrat” ca bani poate fi concentrat ca risc (A4)

Ce vă trebuie azi (3/4): un backtest onest

- ▣ **Fereastra mobilă:** ponderile deținute în luna t folosesc doar lunile $t - 60, \dots, t - 1$; orice estimare care folosește luna t înseamnă look-ahead
- ▣ **Deriva:** în timpul lunii ponderile se mișcă odată cu randamentele, $w_i^+ = w_i(1 + R_i) / \sum_j w_j(1 + R_j)$; **turnover-ul** este tranzacția necesară pentru revenirea la noua țintă, $TO = \sum_i |w_{i,\text{nou}} - w_i^+|$
 - ▶ exemplu, 1/N cu randamente $+10\%$ și -10% : $w^+ = (0,55; 0,45)$, $TO = 0,05 + 0,05 = 0,10$; la 20 bp pe unitatea tranzacționată: $0,002 \times 0,10 = 2$ bp din avere
- ▣ Randamentul net $r_t - c TO_t$; **drawdown-ul maxim:** cea mai mare scădere a averii față de un vîrf anterior
- ▣ Raportul Sharpe al randamentelor lunare în exces se anualizează cu $\sqrt{12}$ (nu cu $\sqrt{252}$, care este pentru date zilnice)

Ce vă trebuie azi (4/4): este semnificativă o diferență de Sharpe?

- ▣ $\hat{\Delta} = \widehat{SR}_1 - \widehat{SR}_2$ pe aceleași luni; cele două estimatii sînt corelate, deci testul folosește perechea
- ▣ **Metoda delta:** dacă $\sqrt{T}(\hat{\theta} - \theta) \rightarrow N(0, \Psi)$, atunci $\sqrt{T}(f(\hat{\theta}) - f(\theta)) \rightarrow N(0, \nabla f^\top \Psi \nabla f)$ pentru o funcție f netedă
- ▣ Randamente i.i.d. cu distribuția Normală [Jobson & Korkie \(1981\)](#), forma corectată în [Ledoit & Wolf \(2008\)](#):
 $T \text{Var}(\hat{\Delta}) \rightarrow 2 - 2\rho + \frac{1}{2}(SR_1^2 + SR_2^2 - 2SR_1SR_2\rho^2)$
 - ▶ exemplu: $SR_1 = SR_2 = 0,2$ pe lună, $\rho = 0,5$, $T = 240$: paranteza 1,03, SE $\sqrt{1,03/240} = 0,066$ pe lună, 0,23 pe an: diferențele sub circa 0,45 pe an nu pot fi detectate în 20 de ani
- ▣ Variantele robuste [Ledoit & Wolf \(2008\)](#): erori standard HAC (cozi groase, autocorelație) și un bootstrap pe blocuri studentizat; funcțiile `sr_diff_hac`, `sr_diff_boot`
- ▣ După curs: shrinkage-ul covarianței (B2) și hierarchical risk parity (B3)

A1 [Rezolvat]: portofoliul GMV — Cerință

□ Întrebări

- ▶ ce combinație de SPY și TLT are varianța minimă?
- ▶ ce randament aduce?

□ **Ipoteze:** N active riscante, Σ cunoscută și pozitiv definită, vânzări în lipsă permise, $w^\top 1 = 1$

□ **Date de intrare** (randamente totale lunare august 2002 – iulie 2026, $T = 288$, anualizate; numerele de mai jos sînt suficiente)


	medie	volatilitate	varianță
SPY	11,73%	14,72%	0,02166
TLT	4,32%	13,49%	0,01820
corelația $\rho = -0,100$, covarianța $\sigma_{12} = -0,00199$			

1. Scrieți lagrangianul problemei $\min_w w^\top \Sigma w$ cu $w^\top 1 = 1$ și deduceți $w_{\text{GMV}} = \Sigma^{-1} 1 / A$, $A = 1^\top \Sigma^{-1} 1$.
2. Arătați că varianța minimă este $1/A$.
3. Inversați matricea 2×2 și obțineți $w^* = (\sigma_2^2 - \sigma_{12}) / (\sigma_1^2 + \sigma_2^2 - 2\sigma_{12})$.
4. Calculați A , w^* , σ_{GMV} și media combinației; **raportați** cele patru numere și o propoziție despre motivul pentru care σ_{GMV} este sub ambele volatilități.

A1 [Rezolvat]: Rezolvare (1/2) — Derivarea

- ▣ Pasul 1: $\mathcal{L} = \mathbf{w}^\top \Sigma \mathbf{w} - \lambda(\mathbf{w}^\top \mathbf{1} - 1)$; condiția de ordinul întâi $2\Sigma \mathbf{w} - \lambda \mathbf{1} = 0$, deci $\mathbf{w} = \frac{\lambda}{2} \Sigma^{-1} \mathbf{1}$
- ▣ Impunând $\mathbf{1}^\top \mathbf{w} = 1$: $\frac{\lambda}{2} A = 1$, de unde $\mathbf{w}_{\text{GMV}} = \Sigma^{-1} \mathbf{1} / A$; funcția obiectiv este strict convexă, deci minimumul este unic
- ▣ Pasul 2: $\sigma_{\text{GMV}}^2 = \mathbf{1}^\top \Sigma^{-1} \Sigma \Sigma^{-1} \mathbf{1} / A^2 = A / A^2 = 1 / A$
- ▣ Pasul 3: $\Sigma^{-1} = \frac{1}{\det \Sigma} \begin{pmatrix} \sigma_2^2 & -\sigma_{12} \\ -\sigma_{12} & \sigma_1^2 \end{pmatrix}$, deci $\Sigma^{-1} \mathbf{1} = \frac{1}{\det \Sigma} (\sigma_2^2 - \sigma_{12}, \sigma_1^2 - \sigma_{12})^\top$
- ▣ Împărțind primul element la suma celor două: $w^* = (\sigma_2^2 - \sigma_{12}) / (\sigma_1^2 + \sigma_2^2 - 2\sigma_{12})$; $\det \Sigma$ se simplifică

A1 [Rezolvat]: Rezolvare (2/2) — Numerele și minimul



▣ Pasul 4, numerele:

- ▶ $\det \Sigma = 0,02166 \times 0,01820 - 0,00199^2 = 0,000390$; $\Sigma^{-1} \mathbf{1} = (0,02019; 0,02366) / 0,000390 = (51,7; 60,6)$
- ▶ $A = 112,4$; $w^* = 51,7 / 112,4 = 0,461$ în SPY, $0,539$ în TLT; $\sigma_{\text{GMV}} = 1 / \sqrt{A} = 9,43\%$; media $0,461 \times 11,73\% + 0,539 \times 4,32\% = 7,73\%$

- ▣ Interpretare: cu $\rho < 0$ cele două riscuri se compensează parțial; combinația este cu 36% mai puțin volatilă decât SPY și păstrează două treimi din media lui; la $\rho = +0,5$ minimul este 12,2%

A3 [Rezolvat]: ERC cu două active — Cerință

- ▣ **Întrebare:** ce combinație SPY–IEF dă celor două active aceeași contribuție la risc?
- ▣ **Date de intrare:** SPY și IEF (obligațiuni de stat SUA cu scadențe de 7–10 ani), lunar august 2002 – iulie 2026, anualizat


$$\Sigma = \begin{pmatrix} 0,02166 & -0,00098 \\ -0,00098 & 0,00441 \end{pmatrix}, \quad \sigma_1 = 14,72\%, \quad \sigma_2 = 6,64\%, \quad \rho = -0,101$$

- ▣ Trei mărimi diferite: $RC_i\sigma_p = w_i(\Sigma w)_i$ (contribuția la varianță), RC_i (la volatilitate), RC_i/σ_p (cota, în %)
- ▣ **Cerințe**
 1. Scrieți explicit $RC_1\sigma_p$ și $RC_2\sigma_p$ pentru două active, cu ponderi pozitive $w_1 + w_2 = 1$.
 2. Demonstrați că $RC_1 = RC_2$ dacă și numai dacă $w_1\sigma_1 = w_2\sigma_2$, pentru orice $\rho \in (-1, 1)$.
 3. Calculați ponderea ERC a SPY, apoi σ_{ERC} , apoi cele două cote de risc.
- ▣ **Raportați:** demonstrația, w_1 , σ_{ERC} și cele două cote

A3 [Rezolvat]: Rezolvare (1/2) — Demonstrația și numerele

- (1) $RC_1\sigma_p = w_1^2\sigma_1^2 + w_1w_2\sigma_{12}$, $RC_2\sigma_p = w_2^2\sigma_2^2 + w_1w_2\sigma_{12}$
- (2) Termenii încrucișați, colorați, sînt identici și se reduc: $RC_1 = RC_2 \iff w_1^2\sigma_1^2 = w_2^2\sigma_2^2 \iff w_1\sigma_1 = w_2\sigma_2$;
 ρ dispare din ponderi, nu și din σ_p
- (3) $w_1 = \sigma_1^{-1}/(\sigma_1^{-1} + \sigma_2^{-1}) = 6,79/(6,79 + 15,06) = 0,311$;
 $\sigma_p^2 = 0,311^2(0,02166) + 0,689^2(0,00441) + 2(0,311)(0,689)(-0,00098) = 0,00377$, $\sigma_{ERC} = 6,14\%$; cotele 50% și 50%
- Interpretare: riscul egal cere de peste două ori mai mult din ETF-ul de obligațiuni, care e de peste două ori mai puțin volatil

A3 [Rezolvat]: Rezolvare (2/2) — Ponderi, cote de risc și corelație



- Stînga: ponderile de capital față de cotele din varianță; dreapta: ponderea ERC a SPY este aceeași pentru orice ρ , volatilitatea ERC nu (6,14% la ρ efectiv)

A4 [Propus]: cine poartă riscul în 60/40? — Cerință

- ▣ **Model:** A3 [Rezolvat]
- ▣ **Întrebare:** un portofoliu „echilibrat” 60/40 ține 40% în obligațiuni; cât din riscul lui poartă obligațiunile?
- ▣ **Date de intrare:** Σ din A3; $w = (0,6; 0,4)$ în SPY și IEF
- ▣ **Cerințe**
 1. Calculați Σw rînd cu rînd: $(\Sigma w)_1 = 0,6\sigma_1^2 + 0,4\sigma_{12}$ și $(\Sigma w)_2 = 0,6\sigma_{12} + 0,4\sigma_2^2$.
 2. Calculați $\sigma_p^2 = w^\top (\Sigma w)$, σ_p și cotele $w_i(\Sigma w)_i/\sigma_p^2$.
 3. Comparați σ_p cu volatilitatea ERC din A3 și reprezentați alăturat cotele de capital și de risc ale celor două portofolii.
- ▣ **Interpretare:** este 60/40 un portofoliu echilibrat din punctul de vedere al riscului?

B1 [Rezolvat]: 1/N versus Markowitz pe sectoare — Cerință


- ▣ **Întrebare:** bat regulile Markowitz estimate ponderile 1/N în afara eșantionului, pe nouă ETF-uri sectoriale?
- ▣ **Date:** panelul de sectoare din pregătire; randamente lunare în exces ianuarie 1999 – iulie 2026
- ▣ **Cerințe**
 1. În fiecare lună t estimați 1/N, MV (tangent), MV-LO (Sharpe maxim cu $0 \leq w_i \leq 1$, rezolvat numeric) și GMV doar pe lunile $t - 60, \dots, t - 1$; dețineți-le în luna t : ianuarie 2004 – iulie 2026 ($T = 271$).
 2. Calculați pas cu pas prima lună: fereastra, ponderile, randamentul din ianuarie 2004, ponderile după drift și turnover-ul din februarie 2004.
 3. Calculați media, volatilitatea, raportul Sharpe (anualizate), turnover-ul mediu și drawdown-ul maxim ale fiecărei reguli.
 4. Testați $H_0: SR_{\text{regulă}} = SR_{1/N}$ cu sr_diff_hac (Ledoit & Wolf (2008), Secțiunea 3.1; nucleu Bartlett, 4 laguri) și sr_diff_boot (bootstrap circular pe blocuri, studentizat, 4999 de extrageri; lungimile de bloc calibrate (se dau): MV 6, MV-LO 1, GMV 1), $\alpha = 5\%$.
- ▣ **Raportați:** tabelul de mai jos și un grafic al averii

	Sharpe	Volatilitate	Turnover	Drawdown maxim	$\hat{\Delta}$	p HAC / p bootstrap
1/N, MV, MV-LO, GMV	...	...	...	...	...	...

- ▣ **Interpretare:** MV-LO bate 1/N cu câteva sutimi: este aceasta o dovadă de abilitate?

B1 [Rezolvat]: Rezolvare (1/4) — Prima lună în afara eșantionului

Rolling 60-month estimation, one-month holding: 271 out-of-sample months




- Fereastra 1999-01 – 2003-12 (60 de luni) dă ponderile deținute în 2004-01; MV-LO ține XLB 81,8%, XLE 14,3%, XLF 3,9%, restul 0; MV are expunerea brută 8,3
- Randamente în exces în ianuarie 2004: $1/N \sum_i w_i r_i^e = 1,11\%$, MV-LO $-3,24\%$, GMV $1,36\%$, MV $1,12\%$ (titlul de stat $0,07\%$)
- Drift-ul: XLB a avut $-4,4\%$, XLK $4,3\%$; la sfârșitul lui ianuarie ponderile $1/N$ de $11,11\%$ devin $10,50\%$ (XLB) și $11,45\%$ (XLK)
- Turnover-ul din februarie 2004, $\sum_i |w_{i,\text{feb}} - w_{i,\text{ian}}^+|$: $1/N$ $0,0191$, MV-LO $0,748$ (ponderi reestimate)

B1 [Rezolvat]: Rezolvare (2/4) — Rezultate și teste

	1/N	MV	MV-LO	GMV
Sharpe	0,66	0,26	0,72	0,71
Volatilitate	14,3%	69,0%	14,7%	11,9%
Turnover	0,02	3,86	0,23	0,23
Drawdown maxim	−49%	−100%	−42%	−33%
$\hat{\Delta}$ față de 1/N	−	−0,40	+0,06	+0,05
p HAC	−	0,22	0,60	0,75
p bootstrap	−	0,30	0,63	0,76


- MV: expunere brută mediană 4,9, turnover de aproape patru ori averea pe lună; o pierdere lunară de peste 100% în 2009-03 îi încheie averea investibilă: Sharpe-ul lui descrie o serie ipotetică de randamente
- Celelalte trei reguli ajung la cel mult 0,06 de 1/N; nicio valoare p nu este sub 0,05

B1 [Rezolvat]: Rezolvare (3/4) — Avere, drawdown, expunere și turnover



- Sus: averea unui dolar în randamente totale și drawdown-ul ei; jos: expunerea brută $\sum_i |w_i|$ și turnover-ul, ambele pe scară logaritmică; MV-LO și 1/N au prin construcție expunerea brută 1

B1 [Rezolvat]: Rezolvare (4/4) — Inferență



- MV-LO: $\hat{\Delta} = 0,063$, eroare standard HAC 0,120, p HAC = 0,60; bootstrap studentizat (bloc 1) $p = 0,63$, intervalul de 95% $[-0,19; 0,31]$ conține zero: nu respingem
- Extrapolare (dreapta): dacă diferența adevărată ar fi egală cu estimația și eroarea standard ar scădea ca $1/\sqrt{\text{ani}}$, $|z| = 1,96$ ar cere 311 de ani de date; un calcul condiționat de semnificație, nu un calcul de putere
- Interpretare: intervalul admite pierderi și câștiguri de pînă la 0,31; nerespingerea nu dovedește egalitatea

A7 [Rezolvat]: varianța unei diferențe de Sharpe — Cerință

- ▣ **Întrebare:** este diferența $GMV - 1/N$ din B1 mai mare decât zgomotul de eșantionare, în ipotezele cele mai simple?
- ▣ **Date de intrare:** randamentele lunare în exces ale GMV și $1/N$ din B1, $T = 271$; Sharpe lunar $SR_{GMV} = 0,2051$, $SR_{1/N} = 0,1908$, corelația $\rho = 0,694$
- ▣ **Ipoteză:** randamente i.i.d. din distribuția Normală bivariată; Φ este funcția de repartiție a distribuției Normale standard
- ▣ **Cerințe**
 1. Scrieți matricea de covarianță asimptotică 4×4 a lui $\sqrt{T}(\hat{\mu}_1 - \mu_1, \hat{\mu}_2 - \mu_2, \hat{\sigma}_1^2 - \sigma_1^2, \hat{\sigma}_2^2 - \sigma_2^2)$.
 2. Scrieți gradientul lui $f = \mu_1/\sigma_1 - \mu_2/\sigma_2$ și aplicați metoda delta pentru a obține

$$T \text{Var}(\hat{\Delta}) \rightarrow 2 - 2\rho + \frac{1}{2}(SR_1^2 + SR_2^2 - 2SR_1SR_2\rho^2)$$
 3. Testați $H_0: SR_{GMV} = SR_{1/N}$ cu un test z bilateral la 5%; comparați cu valoarea p HAC 0,75.
- ▣ **Raportați:** matricea, formula, z , p și decizia

A7 [Rezolvat]: Rezolvare (1/2) — Metoda delta

- ▣ (1) Sub distribuția Normală, mediile și varianțele de eșantion sînt asimptotic independente, $\sigma_{12} = \rho\sigma_1\sigma_2$:

$$\Psi = \begin{pmatrix} \sigma_1^2 & \sigma_{12} & 0 & 0 \\ \sigma_{12} & \sigma_2^2 & 0 & 0 \\ 0 & 0 & 2\sigma_1^4 & 2\sigma_{12}^2 \\ 0 & 0 & 2\sigma_{12}^2 & 2\sigma_2^4 \end{pmatrix}, \quad \nabla f = \begin{pmatrix} 1/\sigma_1 \\ -1/\sigma_2 \\ -SR_1/(2\sigma_1^2) \\ +SR_2/(2\sigma_2^2) \end{pmatrix}$$

- ▣ (2) $\nabla f^\top \Psi \nabla f$ se desparte în două blocuri


► Mediile: $\sigma_1^2/\sigma_1^2 + \sigma_2^2/\sigma_2^2 - 2\sigma_{12}/(\sigma_1\sigma_2) = 2 - 2\rho$

► Varianțele: $\frac{SR_1^2}{4\sigma_1^4} 2\sigma_1^4 + \frac{SR_2^2}{4\sigma_2^4} 2\sigma_2^4 - 2 \frac{SR_1 SR_2}{4\sigma_1^2 \sigma_2^2} 2\sigma_{12}^2 = \frac{1}{2}(SR_1^2 + SR_2^2 - 2SR_1 SR_2 \rho^2)$

- ▣ Suma blocurilor dă formula ([Jobson & Korkie \(1981\)](#); forma corectată în [Ledoit & Wolf \(2008\)](#))

A7 [Rezolvat]: Rezolvare (2/2) — Testul

- ▣ (3) Paranteza: $2 - 2(0,694) + 0,5(0,2051^2 + 0,1908^2 - 2 \times 0,2051 \times 0,1908 \times 0,694^2)$
 $= 0,612 + 0,5(0,0421 + 0,0364 - 0,0377) = 0,6324$
- ▣ Eroarea standard $\sqrt{0,6324/271} = 0,0483$;
 $z = (0,2051 - 0,1908)/0,0483 = 0,30$;
 $p = 2[1 - \Phi(0,30)] = 0,77$
- ▣ Decizie: nu respingem H_0 la 5%; testul HAC confirmă ($p = 0,75$)
- ▣ Interpretare: diferența anualizată, 0,71 față de 0,66, se încadrează larg în zgomotul de eşantionare; 22 de ani nu pot ordona GMV și $1/N$



A8 [Propus]: ERC versus 1/N — Cerință

- ▣ **Model:** A7 [Rezolvat]
- ▣ **Întrebare:** ERC bate 1/N cu mai puțin decît GMV; poate diferența mai mică să fie mai aproape de semnificație?
- ▣ **Date de intrare:** backtest-ul B1 cu ERC adăugat, $T = 271$; Sharpe lunar $SR_{\text{ERC}} = 0,2018$, $SR_{1/N} = 0,1908$, corelația 0,9927; păstrați patru zecimale pînă la final (paranteza este mică atunci cînd ρ este aproape de 1)
- ▣ Reper: $T \text{Var}(\hat{\Delta}) \rightarrow 2 - 2\rho + \frac{1}{2}(SR_1^2 + SR_2^2 - 2SR_1SR_2\rho^2)$
- ▣ **Cerințe**
 1. Calculați paranteza, eroarea standard, z și valoarea p bilaterală; decideți la 5%.
 2. Arătați că paranteza tinde la $\frac{1}{2}(SR_1 - SR_2)^2$ cînd $\rho \rightarrow 1$.
 3. Completați un tabel comparativ (diferență, ρ , eroare standard, z) pentru A7 și A8 și reprezentați ambele intervale de 95%.
- ▣ **Interpretare**
 - ▶ de ce este aici o diferență mai mică mai aproape de semnificație?
 - ▶ ce se întîmplă dacă cele două serii de randamente sînt identice?

B8 [Propus]: costul-prag — Cerință

- ▣ **Model:** B1 [Rezolvat]
- ▣ **Întrebare:** MV-LO bate $1/N$ brut pe 16 ETF-uri; la ce cost de tranzacționare dispăre avantajul?
- ▣ **Date:** universul combinat (16 ETF-uri), în afara eșantionului mai 2012 – iulie 2026 ($T = 171$); strategia 1 = MV-LO, strategia 2 = $1/N$; turnover ca în B1
- ▣ Randamentul net $r_t - c TO_t$, c pe unitate tranzacționată, în zecimale: o lună cu $TO = 0,25$ la 20 bp costă $0,002 \times 0,25 = 0,0005$, adică 5 bp din avere
- ▣ **Cerințe**
 1. Calculați rapoartele Sharpe brute, valoarea p HAC a diferenței lor și turnover-urile medii.
 2. Pe o grilă de 0–200 bp (pas 0,1 bp) recalculați media și abaterea standard a ambelor serii nete și găsiți costul c^* la care rapoartele Sharpe nete se intersectează; reprezentați ambele curbe.
 3. Deduceți aproximarea cu volatilitate fixă $c^* \approx \Delta SR / [12(TO_1/\sigma_1 - TO_2/\sigma_2)]$ (σ anual) și comparați-o cu valoarea de pe grilă.
- ▣ **Interpretare:** la costurile unui investitor individual pe BVB sau pe ETF-uri americane, merită implementat MV-LO?

C2 [Propus]: critica unui răspuns AI — Cerință

- ▣ **Model:** B1 și A7 [Rezolvat]. **Cererea:** „prices conține prețurile zilnice ajustate ale celor nouă ETF-uri sectoriale din B1 (decembrie 1998 – iulie 2026). Scrie cod Python pentru un backtest GMV în afara eșantionului, cu reechilibrare lunară, și dă-mi raportul Sharpe anualizat.”

```
1 import numpy as np
2 r = prices.resample('ME').last().pct_change().dropna() # monthly simple returns
3 S = r.cov().values # covariance matrix
4 w = np.linalg.solve(S, np.ones(len(S))) # Sigma^{-1} 1
5 w = w / w.sum() # GMV weights, sum to one
6 port = r.dot(w) # portfolio return
7 sr = port.mean() / port.std() * np.sqrt(252)
8 print(f"Annualised Sharpe ratio: {sr:.2f}")
```

- ▣ **Cerințe** (rf: rata lunară a titlului de stat din pregătire, în zecimale, aliniată pe datele de sfârșit de lună)
1. Găsiți cele trei erori intenționate; numiți linia, explicați de ce este greșită și cum ați detecta-o (o verificare a datelor, un număr din B1 sau A7, o definiție). Alte observații argumentate sînt binevenite.
 2. Scrieți codul corectat și raportați raportul Sharpe; verificați decalajul datelor, valorile lipsă, suma ponderilor și anualizarea.
 3. Notați fiecare eroare în formatul AI_ERRORS.md: cererea, răspunsul, eroarea, cum a fost găsită, corecția.
- ▣ **Interpretare**
- ▶ cît de departe este numărul AI de unul care poate fi susținut?
 - ▶ care eroare contează cel mai mult?


B2 [Rezolvat]: reduce shrinkage-ul riscul GMV? — Cerință

- ▣ **Întrebare:** reduce estimatorul Ledoit–Wolf riscul GMV în afara eșantionului, pe sectoare?
- ▣ **Date:** backtest-ul B1; GMV cu covarianța de eșantion versus GMV-LW, cu ținta de corelație constantă din [Ledoit & Wolf \(2004\)](#) (funcția `lw_cc(X)`: intrare o fereastră 60×9 de randamente în exces, ieșire $\hat{\Sigma}_{\text{LW}}$ și δ)
- ▣ **Cerințe**
 1. Pe ultima fereastră urmăriți lanțul: $S \rightarrow$ ținta F ($f_{ij} = \bar{r}\sqrt{s_{ii}s_{jj}}$) $\rightarrow \delta \rightarrow \hat{\Sigma}_{\text{LW}} = \delta F + (1 - \delta)S \rightarrow$ ponderile GMV; raportați $\bar{r}$, δ , ambele numere de condiționare și expunerile brute.
 2. Calculați volatilitățile în afara eșantionului ale GMV, GMV-LW și $1/N$.
 3. Calculați $\text{Var}(\text{GMV-LW})/\text{Var}(\text{GMV})$ cu un interval percentil de 95% dintr-un bootstrap circular pe blocuri ([Künsch \(1989\)](#); blocuri de 6 luni, 5000 de extrageri); ambele serii folosesc **aceleași** luni reeșantionate.
 4. Comparați turnover-ul lunar mediu al celor două reguli.
- ▣ **Interpretare**
 - ▶ de ce este câștigul mic cu 9 active și 60 de luni?
 - ▶ când ar fi mai mare?

B2 [Rezolvat]: Rezolvare (1/2) — De la S la ponderi

- ▣ Ultima fereastră 2021-08 – 2026-07, $T = 60$, $N = 9$
- ▣ Pasul 1: corelația medie de eşantion $\bar{r} = 0,511$; de exemplu corelația XLK–XLU, 0,31, este înlocuită cu $\bar{r}$ în F, varianțele se păstrează
- ▣ Pasul 2: $\delta = 0,24$: $\hat{\Sigma}_{LW}$ este 24% țintă, 76% eşantion
- ▣ Pasul 3: numărul de condiționare $51,6 \rightarrow 32,5$: cele mai mici valori proprii sînt ridicate
- ▣ Pasul 4: ponderile GMV; expunerea brută $\sum_i |w_i|$ 2,64 (eşantion) $\rightarrow$ 1,91 (shrinkage); XLP 66,8% $\rightarrow$ 57,8%, XLK 10,1% $\rightarrow$ 6,4%
- ▣ O reeşantionare pereche: extrageți 46 de luni de start aleatoare, luați cîte 6 luni consecutive (circular), tăiați la $T = 271$ și calculați varianța ambelor strategii pe aceleași luni

B2 [Rezolvat]: Rezolvare (2/2) — Risc și turnover



- Volatilitate: GMV 11,90%, GMV-LW 11,80%, 1/N 14,28%: ambele reguli GMV reduc riscul cu circa o șesime
- Raportul varianțelor 0,984, intervalul [0,918; 1,062] conține 1: nicio reducere semnificativă; turnover 0,234 $\rightarrow$ 0,137 (−41%): beneficiul este aici stabilitatea, nu riscul
- Interpretare: cu $N/T = 0,15$ matricea de eșantion este deja acceptabilă; câștigul crește cu N/T și cu o țintă apropiată de adevăr

B3 [Rezolvat]: ERC și HRP pe sectoare — Cerință

▣ Întrebări

- ▶ cum alocă cele două reguli bazate pe risc?
- ▶ bat ele $1/N$?

▣ **Partea 1, calculul ponderilor** (ultima fereastră august 2021 – iulie 2026, covarianța de eşantion)

1. Aplicați HRP pas cu pas pe exemplul cu patru active de pe slide-ul următor: distanțe, arbore, ordine, bisecție.
2. Calculați cele nouă ponderi ERC ($w_{erc}(S)$, problema convexă din [Maillard, Roncalli & Teïletche \(2010\)](#)) și ponderile HRP ($w_{hrp}(S)$: $d_{ij} = \sqrt{(1 - \rho_{ij})/2}$, distanța euclidiană dintre coloanele lui D , legătura simplă, bisecția recursivă a listei ordonate).
3. Calculați cotele de risc pentru $1/N$, ERC și HRP.


▣ **Partea 2, backtest** (ianuarie 2004 – iulie 2026, fereastră mobilă de 60 de luni, ca în B1)

4. Testați rapoartele Sharpe ale ERC și HRP față de $1/N$ cu testul HAC la 5%; raportați turnover-ul și corelația cu $1/N$.


▣ **Interpretare:** ERC și $1/N$ au corelația 0,993: este ERC o altă strategie sau doar o mică înclinare?

B3 [Rezolvat]: Rezolvare (1/3) — HRP pe patru active

- Volatilități 10%, 12%, 20%, 25%; corelații A–B 0,8, C–D 0,7, toate perechile încrucișate 0,2
- Pasul 1: $d_{AB} = \sqrt{(1 - 0,8)/2} = 0,316$, $d_{CD} = 0,387$, perechile încrucișate 0,632; distanțele dintre coloanele lui D: $\tilde{d}_{AB} = 0,447$, $\tilde{d}_{CD} = 0,548$; legătura simplă unește A–B, apoi C–D, apoi cele două grupuri
- Pasul 2: ordinea A, B, C, D; împărțim în $\{A, B\}$ și $\{C, D\}$
- Pasul 3: ponderi invers proporționale cu varianța în fiecare jumătate, (0,59; 0,41) și (0,61; 0,39); varianțele grupurilor $V_1 = 0,01055$, $V_2 = 0,04105$; $\alpha = 1 - V_1/(V_1 + V_2) = 0,796$ pentru $\{A, B\}$
- Apoi fiecare pereche se împarte din nou după inversul varianței: A 47,0%, B 32,6%, C 12,5%, D 8,0%



B3 [Rezolvat]: Rezolvare (2/3) — Nouă sectoare, ultima fereastră



- Ordinea din arbore XLE, XLK, XLY, XLU, XLV, XLP, XLF, XLB, XLI; ERC: XLP 14,8%, XLV 13,9% ... XLB 8,6%; HRP: XLP 18,4%, XLU 17,1% ... XLB 4,5%; cotele de risc 1/N de la 7,8% (XLP) la 13,8% (XLB)

B3 [Rezolvat]: Rezolvare (3/3) — Backtest

- ▣ În afara eșantionului ianuarie 2004 – iulie 2026, fereastră mobilă de 60 de luni, testul HAC față de $1/N$
- ▣ Backtest: Sharpe ERC 0,70 față de 0,66, $p = 0,09$; HRP 0,70, $p = 0,32$; turnover $1/N$ 0,024, ERC 0,028, HRP 0,082; corelația cu $1/N$: ERC 0,993, HRP 0,979
- ▣ Interpretare: ERC este o înclinare mică și ieftină spre sectoarele cu volatilitate redusă; HRP o înclinare mai mare, care tranzacționează de trei ori mai mult; niciuna nu respinge H_0

După curs: ce și când

- Aceste două cerințe folosesc instrumente introduse în [Capitolul 4](#): lucrați-le după curs, înaintea seminarului următor
 - ▶ B2 [Rezolvat]: shrinkage-ul Ledoit–Wolf al matricei de covarianță și riscul portofoliului GMV
 - ▶ B3 [Rezolvat]: ponderile ERC și HRP (hierarchical risk parity), pas cu pas, și backtest-ul lor
- Proiectul pentru acasă C1 le folosește pe amândouă: începeți-l după aceste două cerințe

C1 [Propus]: un portofoliu BVB în lei — proiectul pentru acasă

- ▣ **Model:** B1, B3 și A7 [Rezolvat]. **Întrebare:** merită unui investitor român diversificarea dincolo de BVB?
- ▣ **Date și monedă:** TLV, SNP, BRD, TGN, SNG, SNN, EL, TEL și indicele BET-TR (octombrie 2014 – august 2026); SPY, EFA, IEF, GLD convertite în lei în zilele comune, $P_{\text{RON}} = P_{\text{USD}} \times \text{USD/RON}$ (BNR); de exemplu 2017-10-02: SPY 219,84 USD $\times$ 3,9086 = 859,25 lei
- ▣ **Cazul de bază:** randamente lunare în lei, fereastră de 36 de luni, primul portofoliu în octombrie 2017, $R_f = 0$
- ▣ **Cerințe**
 1. Faceți backtest pentru 1/N, GMV-LW, ERC și HRP pe cele opt acțiuni, apoi pe acțiuni plus cele patru ETF-uri străine.
 2. Comparați fiecare portofoliu cu BET-TR (niciodată cu BET): raport Sharpe, volatilitate, drawdown maxim; reprezentați averea și drawdown-ul.
 3. Testați fiecare regulă globală față de BET-TR și față de varianta ei doar cu BVB (HAC), cu ajustare Holm pe această familie de opt teste.
 4. Sensibilitate: o rată în lei de 5% pe an, 0,05/12 pe lună, scăzută din toate randamentele.
- ▣ **Livrabile:** un folder Quantlet în repository-ul echipei, un tabel cu cele opt teste (p brut și Holm), un slide cu concluzia și principala ei limită (riscul valutar, costuri, impozite)

Pachete de extindere: ce cere fiecare

Pachet	Exerciții	Cunoștințe necesare
1. Teoria risk parity	A4 extins	A3, A4
2. Black–Litterman	A5 [Rezolvat], A6, B7	cursul, Black–Litterman
3. Deplasare și inferență prin regresie	A9, A2, B9	A1, A7, B1
4. Estimarea covarianței	B2 extins [Rezolvat], B4	B2
5. Dincolo de sectoare	B5, B6	B1, B3
6. Proiecte de cercetare	C3 (C1 este tema de bază)	B1, A7, studiul de caz din curs

- Fiecare pachet are secțiunea lui în notebook; rezolvați exercițiile unui pachet în ordine
- Studiu suplimentar:  Hierarchical Clustering,  Minimum Spanning Tree

A4 extins [Propus]: Euler și unicitatea ERC — Cerință

▣ **Model:** A3 și A4

▣ **Cerințe**

1. Arătați că $\sigma_p(cw) = c \sigma_p(w)$ pentru $c > 0$ și deduceți $\sum_i RC_i = \sigma_p$ din teorema lui Euler pentru funcții omogene de gradul întâi.
2. Pentru Σ pozitiv definită, fie $f(y) = \frac{1}{2}y^\top \Sigma y - \frac{1}{N} \sum_i \ln y_i$ pe $y > 0$. Calculați hessiana și arătați că f este strict convexă.
3. Arătați că $f \rightarrow +\infty$ când un $y_i \rightarrow 0$ și când $\|y\| \rightarrow \infty$; deduceți că minimum există și este unic.
4. Scrieți condiția de ordinul întâi și arătați că egalizează contribuțiile la risc, înainte și după normalizarea $w = y/1^\top y$.


▣ **Raportați:** cele două demonstrații în cel mult zece rînduri

A5 [Rezolvat]: Black–Litterman cu un activ — Cerință

- ▣ **Întrebare:** cât de mult ar trebui o opinie precisă să modifice o medie a priori incertă?
- ▣ **Date de intrare:** un activ, volatilitatea randamentelor $\sigma = 16\%$, $\tau = 0,05$; a priori pentru randamentul **așteptat** $\mu \sim N(\pi, \tau\sigma^2)$ cu $\pi = 5\%$; opinia $q = 8\%$ cu abaterea standard 2%
 - ▶ Ambele varianțe măsoară incertitudinea despre media μ , nu volatilitatea randamentelor; pentru densitatea a posteriori presupunem distribuția Normală
- ▣ **Cerințe**
 1. Calculați varianța a priori $\tau\sigma^2$ și cele două precizii (inversele varianțelor).
 2. Calculați μ_{BL} ca medie ponderată cu preciziile, ponderea opiniei și abaterea standard a posteriori; reprezentați cele trei densități.
 3. Generalizați: scrieți $\pi = \mu + e_1$ și $q = P\mu + e_2$ ca $y = Z\mu + e$ și deduceți estimatorul GLS (Theil & Goldberger (1961)); arătați că $P = I$, $\Omega = \tau\Sigma$ dă $(\pi + q)/2$.

A5 [Rezolvat]: Rezolvare (1/2) — Un activ

- (1) Varianța a priori $0,05 \times 0,16^2 = 0,00128$, precizia 781; varianța opiniei $0,02^2 = 0,0004$, precizia 2500
- (2) $\mu_{BL} = (781 \times 5\% + 2500 \times 8\%)/3281 = 7,29\%$; ponderea opiniei $2500/3281 = 0,76$; abaterea standard a posteriori $1/\sqrt{3281} = 1,75\%$
- Opinia este de trei ori mai precisă decât distribuția a priori, deci primește trei sferturi din pondere; distribuția a posteriori este mai precisă decât oricare sursă



A5 [Rezolvat]: Rezolvare (2/2) — Black–Litterman ca GLS

- ▣ (3) Dimensiuni: μ este $N \times 1$, q este $K \times 1$, P este $K \times N$

$$\underbrace{\begin{pmatrix} \pi \\ q \end{pmatrix}}_{y \ ((N+K) \times 1)} = \underbrace{\begin{pmatrix} I_N \\ P \end{pmatrix}}_Z \mu + e, \quad V = \text{Var}(e) = \begin{pmatrix} \tau \Sigma & 0 \\ 0 & \Omega \end{pmatrix}$$

- ▣ GLS: $\hat{\mu} = (Z^\top V^{-1} Z)^{-1} Z^\top V^{-1} y$; o înmulțire pe blocuri: $Z^\top V^{-1} = ((\tau \Sigma)^{-1}, P^\top \Omega^{-1})$, deci

$$\mu_{\text{BL}} = [(\tau \Sigma)^{-1} + P^\top \Omega^{-1} P]^{-1} [(\tau \Sigma)^{-1} \pi + P^\top \Omega^{-1} q]$$

- ▣ Covarianța $[(\tau \Sigma)^{-1} + P^\top \Omega^{-1} P]^{-1}$: distribuția a posteriori Black–Litterman din curs
- ▣ $P = I$, $\Omega = \tau \Sigma$: $[2(\tau \Sigma)^{-1}]^{-1} (\tau \Sigma)^{-1} (\pi + q) = (\pi + q)/2$: precizii egale, ponderi egale

A6 [Propus]: opinia sectorială din curs — Cerință

- ▣ **Model:** A5 [Rezolvat]
- ▣ **Date de intrare:** nouă sectoare în ordinea XLB, XLE, XLF, XLI, XLK, XLP, XLU, XLV, XLY; randamente lunare în exces august 2016 – iulie 2026, Σ anualizată; reper $1/N$, $\delta_{RA} = 2,5$, $\tau = 0,05$
- ▣ Opinia XLK minus XLU = 3% pe an: $P = (0, 0, 0, 0, +1, 0, -1, 0, 0)$; implicit $P\pi = 2,22\%$; varianța spread-ului $P\Sigma P^T = 0,0477$ (suficientă: întreaga Σ trebuie doar pentru verificare)
- ▣ **Cerințe**
 1. Scrieți distribuția a priori a lui $P\mu$ implicată de $\mu \sim N(\pi, \tau\Sigma)$.
 2. Cu $\Omega = \tau P\Sigma P^T$ (He & Litterman (2002)), arătați că opinia a posteriori este media simplă dintre a priori și opinie și calculați-o.
 3. Arătați că $\Delta w = P^T(q - P\pi)/(2\delta_{RA}P\Sigma P^T)$; calculați scalarul, noile ponderi XLK și XLU și verificați că înclinarea are suma zero.
- ▣ **Interpretare:** cum se schimbă înclinarea dacă încrederea în opinie se înjumătățește?

B7 [Propus]: Black–Litterman pe un set multi-active — Cerință

- ▣ **Model:** A5 și A6
- ▣ **Date de intrare:** SPY, EFA, EEM, TLT, IEF, LQD, HYG, GLD (în această ordine), randamente lunare în exces august 2016 – iulie 2026 ($T = 120$), Σ anualizată; reper $1/N$, $\delta_{RA} = 2,5$, $\tau = 0,05$; opinia GLD minus TLT = 4% pe an, $P = (0, 0, 0, -1, 0, 0, 0, +1)$, $\Omega = \tau P \Sigma P^T$
- ▣ Alocare statică fără restricții: o pondere negativă este o poziție short
- ▣ **Cerințe**
 1. Calculați $\pi = \delta_{RA} \Sigma w_b$ și diferența implicită GLD minus TLT.
 2. Calculați varianța spread-ului, surpriza $q - P\pi$, scalarul de înclinare din A6 și noile ponderi; reprezentați-le alături de reper.
 3. Comparați cu media de eșantion a lui GLD minus TLT, cu o încredere de zece ori mai mică ($\Omega \times 10$) și cu o variantă long-only.
- ▣ **Interpretare:** ponderile se schimbă mult deși opinia este modestă: de ce?

A9 [Propus]: deplasarea raportului Sharpe în eșantion — Cerință

- ▣ **Model:** A7 [Rezolvat] (pentru momente), cursul despre riscul de estimare
- ▣ **Ipoteze:** randamente i.i.d. $N(\mu, \Sigma)$; $\hat{\mu}$, $\hat{\Sigma}$ de verosimilitate maximă (împărțire la T); se dau: $\hat{\mu} \sim N(\mu, \Sigma/T)$, $\mathbb{E}[\hat{\Sigma}^{-1}] = \frac{T}{T-N-2}\Sigma^{-1}$ pentru $T > N + 2$, $\hat{\mu}$ independent de $\hat{\Sigma}$ și $\mathbb{E}[x^\top A x] = \text{tr}(A \text{Var}(x)) + \mathbb{E}[x]^\top A \mathbb{E}[x]$
- ▣ **Cerințe**
 1. Calculați $\mathbb{E}[\hat{\theta}^2 \mid \hat{\mu}]$ pentru $\hat{\theta}^2 = \hat{\mu}^\top \hat{\Sigma}^{-1} \hat{\mu}$.
 2. Luați media după $\hat{\mu}$ și deduceți $\mathbb{E}[\hat{\theta}^2] = (T\theta^2 + N)/(T - N - 2)$ (Kan & Zhou (2007)).
 3. Evaluați pentru $N = 9$, $T = 60$, $\theta = 0,66/\sqrt{12}$ lunar; raportați $\sqrt{12 \mathbb{E}[\hat{\theta}^2]}$, rădăcina mediei pătratice anualizate a estimației (nu media ei), și comparați cu o simulare.
 4. Dați estimatorul nedeplasat al lui θ^2 implicat de formulă.

A2 [Propus]: ponderile tangente prin regresie — Cerință

- ▣ **Model:** A1 [Rezolvat] (algebră matriceală); anexa cursului despre [Britten-Jones \(1999\)](#)
- ▣ **Cadru:** X este matricea $T \times N$ a randamentelor în exces, cu rîndurile $r_t^\top$; 1_T variabila dependentă (o coloană de 1), 1_N vectorul de normalizare; $\hat{\mu} = X^\top 1_T / T$, $\hat{\Sigma} = X^\top X / T - \hat{\mu} \hat{\mu}^\top$, inversabilă
- ▣ **Cerințe**
 1. Arătați că $X^\top X / T = \hat{\Sigma} + \hat{\mu} \hat{\mu}^\top$ și scrieți estimatorul OLS al regresiei $1 = b^\top r_t + u_t$ (fără termen liber) în funcție de $\hat{\mu}$, $\hat{\Sigma}$.
 2. Aplicați Sherman–Morrison, $(A + uu^\top)^{-1} = A^{-1} - A^{-1}uu^\top A^{-1} / (1 + u^\top A^{-1}u)$, pentru a arăta că $\hat{b} = \hat{\Sigma}^{-1} \hat{\mu} / (1 + \hat{\theta}^2)$.
 3. Arătați că $\hat{b} / 1_N^\top \hat{b}$ sînt ponderile tangente de eșantion cînd $1_N^\top \hat{\Sigma}^{-1} \hat{\mu} > 0$.
 4. Opțional: pentru $N = 3$ scrieți matricea de restricții a ipotezei „tangent = $1/N$ ”, apoi generalizați.

B9 [Propus]: este portofoliul tangent 1/N? — Cerință


- ▣ **Model:** A2 și B1
- ▣ **Date:** nouă sectoare, randamente lunare în exces ianuarie 1999 – iulie 2026 ($T = 331$) și cele două jumătăți, ianuarie 1999 – septembrie 2012 și octombrie 2012 – iulie 2026
- ▣ **Testele** pentru H_0 : $R_b = 0$, $R = [1_8, -1_8]$, 8 restricții
 - ▶ Exact: $F = (R\hat{b})^\top [R(X^\top X)^{-1}R^\top]^{-1}(R\hat{b})/(8s^2) \sim F(8, T - 9)$, $s^2 = \hat{u}^\top \hat{u}/(T - 9)$
 - ▶ Wald HAC: $W = (R\hat{b})^\top (R\hat{V}R^\top)^{-1}R\hat{b} \rightarrow \chi_8^2$, $\hat{V} = T(X^\top X)^{-1}\hat{\Omega}(X^\top X)^{-1}$, $\hat{\Omega}$ Newey–West pentru $r_t \hat{u}_t$, Bartlett, $\lfloor 4(T/100)^{2/9} \rfloor$ laguri
- ▣ **Cerințe**
 1. Completați un tabel 3×2 cu statistici și valori p (trei eșantioane, două teste); reprezentați coeficienții cu intervalele OLS și HAC.
 2. Simulați 2000 de eșantioane de $T = 166$ dintr-un model Normal cu $\mu \propto \Sigma 1$ (deci H_0 adevărată, Σ din a doua jumătate) și raportați rata de respingere a fiecărui test la 5%.
- ▣ **Interpretare**
 - ▶ când testele nu sînt de acord, în care aveți încredere?
 - ▶ înseamnă nerespingerea că portofoliul tangent este 1/N?

B2 extins [Rezolvat]: valorile proprii ale ultimei ferestre — Cerință

- ▣ **Întrebare:** câte valori proprii ale matricei de corelație a sectoarelor se pot distinge de zgomot?
- ▣ **Date:** ultima fereastră din B2, august 2021 – iulie 2026, $N = 9$, $T = 60$
- ▣ **Cerințe**
 1. Calculați cele nouă valori proprii ale matricei de corelație de eșantion.
 2. Calculați banda Marchenko–Pastur $[(1 - \sqrt{c})^2, (1 + \sqrt{c})^2]$, $c = N/T$, și numărați valorile proprii de deasupra și de dedesubtul ei.
 3. Repetați cu varianța zgomotului rescalată la $\sigma^2 = 1 - \lambda_1/N$ (Laloux et al. (1999)).
- ▣ **Interpretare:** de ce contează pentru GMV mai ales valorile proprii *de sub* bandă?

B2 extins [Rezolvat]: Rezolvare

- (1)
5,25; 1,35; 0,84; 0,50; 0,32; 0,29; 0,21; 0,14; 0,11
- (2) $c = 0,15$, banda $[0,38; 1,92]$: 1 deasupra (modul pieței), 5 dedesubt
- (3) $\sigma^2 = 0,42$, banda $[0,16; 0,80]$: 3 deasupra, 2 dedesubt
- Interpretare: GMV pune ponderi mari pe direcțiile cu cele mai mici valori proprii, combinațiile aproape fără risc; dacă acestea sînt subestimate, la fel este și riscul GMV; shrinkage-ul le ridică



B4 [Propus]: shrinkage pe 16 ETF-uri — Cerință

- ▣ **Model:** B2 [Rezolvat]
- ▣ **Date:** universul combinat (nouă sectoare plus EFA, EEM, TLT, IEF, LQD, HYG, GLD), lunile comune mai 2007 – iulie 2026; fereastră de 60 de luni, în afara eșantionului mai 2012 – iulie 2026 ($T = 171$)
- ▣ **Cerințe** (rezultat: un tabel cu rîndurile GMV, GMV-LW, GMV-NL, $1/N$ și coloanele volatilitate, turnover, raportul varianțelor cu interval)
 1. Volatilitatea în afara eșantionului a GMV, GMV-LW și $1/N$; raportul varianțelor GMV-LW/GMV cu bootstrap-ul pereche pe blocuri din B2; turnover-urile medii.
 2. δ mediu și numerele de condiționare ale matricei de eșantion și ale celei cu shrinkage pe ultima fereastră.
 3. Extindere: shrinkage neliniar ([Ledoit & Wolf \(2020\)](#)); funcția `nl_shrink(X)`, backtest-ul GMV-NL și rapoartele varianțelor sale față de GMV și GMV-LW.
- ▣ **Interpretare:** este corelația constantă o țintă rezonabilă pentru acțiuni și obligațiuni de stat împreună? Deosebiți o schimbare semnificativă de o estimăție punctuală

B5 [Propus]: risk parity cu Bitcoin — Cerință

- ▣ **Model:** B3 [Rezolvat]; literatură: [Petukhina, Trimborn, Härdle & Elendner \(2021\)](#), [Pele et al. \(2023\)](#)
- ▣ **Date:** cele opt ETF-uri multi-active cu și fără Bitcoin (BTC/USD), prețuri aliniate pe zilele comune de tranzacționare (fără weekenduri), randamente de sfârșit de lună din august 2010; ambele universuri pe **aceleași** luni
- ▣ **Cerințe**
 1. Descriptiv, august 2010 – iulie 2026: volatilitatea Bitcoin și cota lui de risc în $1/N$ cu nouă active.
 2. În afara eșantionului, fereastră de 60 de luni, august 2015 – iulie 2026 ($T = 132$): backtest pentru $1/N$, ERC și HRP cu și fără Bitcoin; rapoarte Sharpe, volatilități, drawdown-uri; testul HAC al diferenței „cu Bitcoin” minus „fără Bitcoin” pentru fiecare regulă.
 3. Reprezentați în timp ponderea Bitcoin în ERC și HRP și cota lui de risc în $1/N$.
 4. Tratați cele trei teste ca o familie: raportați valorile p brute și ajustate Holm.
- ▣ **Interpretare**
 - ▶ v-ați aștepta ca prima Bitcoin din trecut să persiste?
 - ▶ dar alegerea ex post a lui Bitcoin?

B6 [Propus]: HRP versus GMV pe 16 ETF-uri — Cerință

- ▣ **Model:** B1 [Rezolvat]
- ▣ **Date:** universul combinat și backtest-ul din B4 (în afara eșantionului mai 2012 – iulie 2026, $T = 171$)
- ▣ **Cerințe**
 1. Raportați raportul Sharpe, volatilitatea și turnover-ul pentru HRP și GMV, brut și net de 50 bp pe unitate de turnover; reprezentați punctele brute și nete.
 2. Testul principal pe randamentele **brute** în exces: $H_0: SR_{HRP} = SR_{GMV}$ cu testul HAC și cu bootstrap-ul studentizat (bloc 1), la 5% și 10%; raportați intervalul bootstrap.
 3. Completați un tabel de decizie (test $\times$ nivel).
- ▣ **Interpretare**
 - ▶ GMV câștigă la volatilitate, HRP la raportul Sharpe: ce criteriu se potrivește cărui investitor?
 - ▶ ce ar cere o comparație la volatilitate egală?

C3 [Propus]: frontiera implementabilă pe datele noastre — Întrebarea

- ▣ **Întrebare:** se păstrează ierarhia regulilor care țin cont de costuri din [Jensen, Kelly, Malamud & Pedersen \(2026\)](#) (Tabelul 2; studiul de caz din curs) pe un univers mic?
- ▣ **Un proiect de mai multe săptămîni**, alternativă la C1; cod de pornire: `jkmp_replication` din Quantlet-ul `MFM_ch4_implementable_frontier`
- ▣ **Notăție**
 - ▶ π_t : ponderile riscante; tranzacția $\pi_t - g_t\pi_{t-1}$, cu g_t drift-ul ponderilor din luna trecută; costul $\frac{W_t}{2}(\pi_t - g_t\pi_{t-1})^\top \Lambda(\pi_t - g_t\pi_{t-1})$, $\Lambda_i = 0,2/V_i$, V_i volumul zilnic mediu în dolari pe 6 luni
 - ▶ Utilitatea lunară: randamentul net în exces $-\frac{\gamma}{2} \times$ varianța lui, $\gamma = 10$; regula din articol parcurge prin tranzacții doar o parte (m) din distanța pînă la un portofoliu-țintă învățat din semnale
- ▣ **Date:** JPM, BAC, C (Citigroup), GS, MS, WFC, NVDA, AAPL, MSFT, AMZN, GOOGL, GME, CSCO, MSTR și cele nouă ETF-uri sectoriale, prețuri aliniate pe zilele comune (din 19 august 2004); titlul de stat din pregătire
- ▣ Semnalele la fiecare sfîrșit de lună, ordonate în $[0, 1]$: $\ln(P_t/P_{t-1})$, $\ln(P_{t-1}/P_{t-6})$, $\ln(P_{t-1}/P_{t-12})$, volatilitatea pe un an a randamentelor zilnice, logaritmul volumului în dolari pe 6 luni

C3 [Propus]: frontiera implementabilă pe datele noastre — Cerințe

- **Calendar:** semnalele și covarianțele folosesc doar date trecute; ferestrele de covarianță cresc din august 2004 pînă ajung la 10 ani (august 2014); hiperparametrii se aleg anual doar pe anii de validare de după 2011; primele ponderi de test la sfîrșitul lui ianuarie 2014, randamentele de test februarie 2014 – august 2026
- **Cerințe**
 1. Întîi un caz de bază: construiți Portfolio-ML cu un singur set fix de hiperparametri; verificați pas cu pas costul unei luni (W_t , vectorul tranzacțiilor, Λ).
 2. Calibrați pe grila din articol (Tabelul 1) și raportați, pentru Portfolio-ML, 1/N, varianță minimă, Markowitz-ML și Static-ML: randament, volatilitate, Sharpe brut și net, cost, utilitate, turnover, levier (formatul Tabelului 2).
 3. Probabilitatea a posteriori a unei utilități mai mari, $\Phi(\bar{d}/(s_d/\sqrt{T}))$ pentru diferențele lunare de utilitate d_t (distribuția Normală, a priori plată, dependența serială ignorată).
 4. Extindere: avere de 1, 10, 100 de miliarde de dolari $\times \gamma \in \{1, 5, 10, 20, 100\}$; reprezentați frontierele implementabile, cu costurile lui 1/N calculate la fiecare nivel de avere.
- **Raportați:** două tabele, figura frontierelor, un folder Quantlet; separați ce urmează articolul de orice simplificare făcută
- **Interpretare**
 - ▶ dacă Portfolio-ML are un raport Sharpe net mai mic decît 1/N, dar o utilitate mai mare, ce criteriu se potrivește investitorului cu $\gamma = 10$?
 - ▶ pentru ce γ s-ar inversa ierarhia?

Bibliografie (1/2)

- ▣ Black, F., Litterman, R. (1992). Global portfolio optimization. *Financial Analysts Journal*, 48(5), 28–43.
- ▣ Britten-Jones, M. (1999). The sampling error in estimates of mean-variance efficient portfolio weights. *Journal of Finance*, 54(2), 655–671.
- ▣ DeMiguel, V., Garlappi, L., Uppal, R. (2009). Optimal versus naive diversification: how inefficient is the 1/N portfolio strategy?. *Review of Financial Studies*, 22(5), 1915–1953.
- ▣ Franke, J., Härdle, W.K., Hafner, C.M. (2019). *Statistics of Financial Markets: An Introduction*, ed. a 5-a. Springer.
- ▣ He, G., Litterman, R. (2002). The intuition behind Black-Litterman model portfolios. SSRN Working Paper 334304.
- ▣ Jensen, T.I., Kelly, B., Malamud, S., Pedersen, L.H. (2026). Machine learning and the implementable efficient frontier. *Review of Financial Studies*, 39(10), 3035–3078.
- ▣ Jobson, J.D., Korkie, B.M. (1981). Performance hypothesis testing with the Sharpe and Treynor measures. *Journal of Finance*, 36(4), 889–908.
- ▣ Kan, R., Zhou, G. (2007). Optimal portfolio choice with parameter uncertainty. *Journal of Financial and Quantitative Analysis*, 42(3), 621–656.
- ▣ Laloux, L., Cizeau, P., Bouchaud, J.-P., Potters, M. (1999). Noise dressing of financial correlation matrices. *Physical Review Letters*, 83(7), 1467–1470.
- ▣ Künsch, H.R. (1989). The jackknife and the bootstrap for general stationary observations. *Annals of Statistics*, 17(3), 1217–1241.
- ▣ Ledoit, O., Wolf, M. (2004). Honey, I shrunk the sample covariance matrix. *Journal of Portfolio Management*, 30(4), 110–119.
- ▣ Ledoit, O., Wolf, M. (2008). Robust performance hypothesis testing with the Sharpe ratio. *Journal of Empirical Finance*, 15(5), 850–859.

Bibliografie (2/2)

- ▣ Ledoit, O., Wolf, M. (2017). Nonlinear shrinkage of the covariance matrix for portfolio selection: Markowitz meets Goldilocks. *Review of Financial Studies*, 30(12), 4349–4388.
- ▣ Ledoit, O., Wolf, M. (2020). Analytical nonlinear shrinkage of large-dimensional covariance matrices. *Annals of Statistics*, 48(5), 3043–3065.
- ▣ López de Prado, M. (2016). Building diversified portfolios that outperform out of sample. *Journal of Portfolio Management*, 42(4), 59–69.
- ▣ Maillard, S., Roncalli, T., Teïletche, J. (2010). The properties of equally weighted risk contribution portfolios. *Journal of Portfolio Management*, 36(4), 60–70.
- ▣ Markowitz, H. (1952). Portfolio selection. *Journal of Finance*, 7(1), 77–91.
- ▣ Pele, D.T., Wesselhöfft, N., Härdle, W.K., Kolossiatis, M., Yatracos, Y.G. (2023). Are cryptos becoming alternative assets?. *The European Journal of Finance*, 29(10), 1064–1105.
- ▣ Petukhina, A., Trimborn, S., Härdle, W.K., Elendner, H. (2021). Investing with cryptocurrencies – evaluating their potential for portfolio allocation strategies. *Quantitative Finance*, 21(11), 1825–1853.
- ▣ Theil, H., Goldberger, A.S. (1961). On pure and mixed statistical estimation in economics. *International Economic Review*, 2(1), 65–78.
- ▣ Date: Kenneth R. French Data Library; cursurile de referință BNR, www.bnr.ro.