



Modelarea piețelor financiare

Seminarul 5: Volatilitate condiționată — modele GARCH



Daniel Traian PELE

Drd. Antoaneta Amza, antoaneta.amza@csie.ase.ro

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

Acronime folosite în acest material (1/2)

- ACF: AutoCorrelation Function (funcția de autocorelație)
- AI: Artificial Intelligence (inteligență artificială)
- AIC: Akaike Information Criterion (criteriul informațional Akaike)
- AR: AutoRegressive (model) (model autoregresiv)
- ARCH: AutoRegressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă)
- ARMA: AutoRegressive Moving Average (model autoregresiv cu medie mobilă)
- BET: Bucharest Exchange Trading (index) (indicele de referință al Bursei de Valori București)
- BIC: Bayesian Information Criterion (criteriul informațional bayesian)
- DM: Diebold–Mariano (test) (testul Diebold–Mariano de comparare a prognozelor)
- EGARCH: Exponential GARCH (GARCH exponențial)
- EWMA: Exponentially Weighted Moving Average (medie mobilă ponderată exponențial)
- GARCH: Generalised AutoRegressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă generalizată)
- GARCH-N: GARCH with Normal innovations (GARCH cu inovații Normale)
- GED: Generalised Error Distribution (distribuția generalizată a erorilor)
- GJR: Glosten–Jagannathan–Runkle (asymmetric GARCH) (GARCH asimetric Glosten–Jagannathan–Runkle)
- GJR-GARCH: Glosten–Jagannathan–Runkle GARCH (GARCH asimetric Glosten–Jagannathan–Runkle)
- GW: Giacomini–White (test) (testul Giacomini–White)
- HAC: Heteroskedasticity and Autocorrelation Consistent (standard errors) (erori standard robuste la heteroscedasticitate și autocorelație)
- IGARCH: Integrated GARCH (GARCH integrat)
- LM: Lagrange Multiplier (multiplicatorul Lagrange)
- LR: Likelihood Ratio (test) (testul raportului de verosimilitate)
- MCS: Model Confidence Set (mulțimea de modele de încredere)
- MLE: Maximum Likelihood Estimation (estimarea prin metoda verosimilității maxime)
- MZ: Mincer–Zarnowitz (regression) (regresia Mincer–Zarnowitz)
- QLIKE: Quasi-LIKelihood (loss function) (funcția de pierdere de tip cvasi-verosimilitate)
- QMLE: Quasi-Maximum Likelihood Estimator (estimatorul de cvasi-verosimilitate maximă)

Acronime folosite în acest material (2/2)

- SUA: **Statele Unite ale Americii**

Cuprins

Introducere

Partea A: derivări

Partea B: calcul și inferență

Partea C: întrebare deschisă

Încheiere

Bibliografie

Obiectivele seminarului

La finalul seminarului puteți

- ▣ Rula pas cu pas recursia dispersiei GARCH și prognozele ei
- ▣ Estima GARCH, GJR-GARCH și variante cu cozi groase și diagnostica reziduurile
- ▣ Compara modele prin rapoarte de verosimilitate, criterii informaționale și pierderi în afara eșantionului
- ▣ Măsura incertitudinea estimării cu metoda delta și un bootstrap parametric și testa la frontieră

Structura

- ▣ **Partea A:** șase derivări (A1–A6): dispersia pe mai mulți pași, persistența GJR, metoda delta, momente, dispersia robustă și clasică a QMLE, ACF a pătratelor
- ▣ **Partea B:** opt exerciții pe calculator, cu inferență (B1–B8)
- ▣ **Partea C:** o întrebare deschisă, punct de plecare pentru proiectul de echipă (C1), și critica unui răspuns AI (C2)

- ▣ Suport: Cursul 5; manualul Franke, Härdle & Hafner (2019)

Cum lucrăm la acest seminar

- ▣ Problemele **[Rezolvat]** au rezolvarea completă; problemele **[Propus]** au doar cerința: rezolvările se discută la seminar
- ▣ Fiecare problemă propusă indică **modelul**: problema rezolvată care folosește aceeași tehnică
 - ▶ Fiecare exercițiu din Partea B se încheie cu întrebări de interpretare: întrebați-vă ce ar schimba concluzia
- ▣ Raportați orice estimare împreună cu incertitudinea ei: eroare standard robustă, interval bootstrap sau valoare p
- ▣ Verificați orice model estimat: convergența, parametrii aflați la frontieră, reziduurile standardizate

Probleme rezolvate și propuse

Rezolvate: exemple lucrate în acest material

- ▣ Partea A: A1 (dispersia pe mai mulți pași: derivare și cifre), A3 (dispersia de termen lung, timpul de înjumătățire, metoda delta)
- ▣ Partea B: B1 (GARCH-t cu diagnostic), B2 (GJR vs GARCH, testul LR), B5 (QLIKE, DM, MZ, Giacomini–White, MCS), B7 (bootstrap parametric, testul IGARCH sub H_0)

Propuse: le rezolvați voi

- ▣ Partea A: A2 (model: A1), A4 (model: A3), A5 (model: A3), A6 (model: A1)
- ▣ Partea B: B3 (model: B2), B4 (model: B1, B2), B6 (model: B5), B8 (model: B7)
- ▣ Partea C: C1, întrebare deschisă și punct de plecare pentru un proiect; C2, critica unui răspuns A1 (model: A3)

Pregătire: mediul Python și datele

- ▣  **Deschide în Colab:** `capitol5_notebook_seminar.ipynb`
- ▣ Google Colab (recomandat) sau Python local ≥ 3.10 cu `numpy`, `pandas`, `scipy`, `statsmodels`, `matplotlib` și `arch`
- ▣ Serii: S&P 500, BET, Bitcoin; prețuri zilnice de închidere până la 18 septembrie 2026
- ▣ Randamente în %: $r_t = 100 (\ln P_t - \ln P_{t-1})$; indicii bursieri în zilele lucrătoare, Bitcoin 7 zile din 7
- ▣ Partea C îmbină întâi prețurile BET și S&P 500 în zilele comune, apoi calculează randamentele

Formulele folosite azi

- GARCH(1,1) [Bollerslev \(1986\)](#): $\sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2 + \beta \sigma_{t-1}^2$; GJR [Glosten, Jagannathan & Runkle \(1993\)](#): adăugăm $\gamma I(\varepsilon_{t-1} < 0) \varepsilon_{t-1}^2$
- Dispersia de termen lung $\sigma^2 = \omega / (1 - \alpha - \beta)$; prognoza $\mathbb{E}_t \sigma_{t+h}^2 = \sigma^2 + (\alpha + \beta)^{h-1} (\sigma_{t+1}^2 - \sigma^2)$
- Timpul de înjumătățire $h_{1/2} = \ln 0,5 / \ln(\alpha + \beta)$; $LR = 2(\ell_1 - \ell_0) \sim \chi_m^2$ sau $\frac{1}{2}\chi_0^2 + \frac{1}{2}\chi_1^2$ pentru un parametru pe frontieră (verosimilitate regulată, parametri de nuisanță identificați)
- Metoda delta: $\widehat{e.s.} g(\hat{\theta}) = \sqrt{\nabla g' \hat{V} \nabla g}$; QMLE Gaussian pentru (ω, α, β) , media cunoscută: $\text{avar} = (\kappa_z - 1)J^{-1}$
- Pierderea QLIKE $r_t^2/h_t + \ln h_t$ [Patton \(2011\)](#); statistica t Diebold–Mariano pe diferența de pierderi [Diebold & Mariano \(1995\)](#)
- Regresia de asimetrie $\hat{z}_t^2$ pe S_{t-1}^- , $S_{t-1}^- \hat{\varepsilon}_{t-1}$, $S_{t-1}^+ \hat{\varepsilon}_{t-1}$ [Engle & Ng \(1993\)](#)

A1: prognoza dispersiei pe mai mulți pași (1/2) [Rezolvat]

Context și date

- ▣ GARCH(1,1): $\varepsilon_t = \sigma_t z_t$, $\sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2 + \beta \sigma_{t-1}^2$, cu z_t i.i.d., de medie 0 și dispersie 1, independent de trecut
- ▣ Persistența $p = \alpha + \beta < 1$, dispersia de termen lung $\bar{\sigma}^2 = \omega / (1 - p)$; $\mathbb{E}_t$ este media condiționată de informația de la închiderea zilei t
- ▣ Cifre (randamente în %): $\omega = 0,05$, $\alpha = 0,10$, $\beta = 0,85$, pornire $\sigma_1^2 = \bar{\sigma}^2$; șocurile $\varepsilon_1 = -2,0$, $\varepsilon_2 = 0,5$, $\varepsilon_3 = 3,0$, $\varepsilon_4 = -1,0$

Ce aveți de făcut

- ▣ (a) Luați valoarea așteptată condiționată în recursie și deduceți $\mathbb{E}_t \sigma_{t+h}^2 = \bar{\sigma}^2 + p^{h-1}(\sigma_{t+1}^2 - \bar{\sigma}^2)$ pentru $h \geq 1$.
- ▣ (b) Însușați prognozele și deduceți forma explicită a dispersiei pe H zile, $V_H = \sum_{h=1}^H \mathbb{E}_t \sigma_{t+h}^2$.
- ▣ (c) Deduceți semnul lui $V_H - H\sigma_{t+1}^2$, eroarea regulii rădăcinii pătrate a timpului, în funcție de $\sigma_{t+1}^2 - \bar{\sigma}^2$.
- ▣ (d) Calculați pas cu pas $\sigma_2^2, \dots, \sigma_5^2$ și prognozele $\mathbb{E}_4 \sigma_{4+h}^2$ pentru $h = 1, \dots, 5$.

A1: prognoza dispersiei pe mai mulți pași (2/2) [Rezolvat]

Ce aveți de făcut

- (e) Calculați V_5 din sumă și din formula de la (b); comparați-l cu $5\sigma_5^2$. (f) Calculați timpul de înjumătățire $\ln 0,5 / \ln p$.

Ce raportați și interpretați

- Raportați cele două formule, cele patru dispersii, cele cinci prognoze, V_5 cu volatilitatea pe 5 zile $\sqrt{V_5}$ și timpul de înjumătățire.
- Interpretare: după șocul de +3%, regula rădăcinii pătrate a timpului supraestimează sau subestimează riscul pe 5 zile și de ce?

A1: prognoza dispersiei pe mai mulți pași: Rezolvare (1/2) [Rezolvat]

- (a) Pasul 1: decalăm recursia, $\sigma_{t+h}^2 = \omega + \alpha \varepsilon_{t+h-1}^2 + \beta \sigma_{t+h-1}^2$, și aplicăm $\mathbb{E}_t$.
- Pasul 2: pentru $h \geq 2$, $\mathbb{E}_t \varepsilon_{t+h-1}^2 = \mathbb{E}_t[\sigma_{t+h-1}^2 \mathbb{E}(z_{t+h-1}^2)] = \mathbb{E}_t \sigma_{t+h-1}^2$, deci $\mathbb{E}_t \sigma_{t+h}^2 = \omega + p \mathbb{E}_t \sigma_{t+h-1}^2$.
- Pasul 3: scădem $\bar{\sigma}^2 = \omega + p \bar{\sigma}^2$; distanța față de nivelul pe termen lung scade cu factorul p la fiecare pas, iar iterând de la σ_{t+1}^2 , cunoscută, obținem formula.
- (b) Însușind, $V_H = H \bar{\sigma}^2 + (\sigma_{t+1}^2 - \bar{\sigma}^2) \sum_{j=0}^{H-1} p^j = H \bar{\sigma}^2 + (\sigma_{t+1}^2 - \bar{\sigma}^2) \frac{1 - p^H}{1 - p}$.
- (c) Scăzând $H \sigma_{t+1}^2$: $V_H - H \sigma_{t+1}^2 = (\bar{\sigma}^2 - \sigma_{t+1}^2) \left[H - \frac{1 - p^H}{1 - p} \right]$, iar paranteza este $\sum_{j=0}^{H-1} (1 - p^j) > 0$ pentru $H \geq 2$.
- Interpretare: regula $H \sigma_{t+1}^2$ subestimează dispersia pe H zile când azi este mai calm decât pe termen lung și o supraestimează după zile agitate, deoarece dispersia revine la $\bar{\sigma}^2$.

A1: prognoza dispersiei pe mai mulți pași: Rezolvare (2/2) [Rezolvat]

- (d) Pornire: $\sigma_1^2 = 0,05/(1 - 0,95) = 1,0000$; apoi
 $\sigma_2^2 = \omega + \alpha \varepsilon_1^2 + \beta \sigma_1^2 = 0,05 + 0,10 \times (-2,0)^2 + 0,85 \times 1,0000 = 0,05 + 0,4000 + 0,8500 = 1,3000$.
- La fel, $\sigma_3^2 = 0,05 + 0,0250 + 1,1050 = 1,1800$, $\sigma_4^2 = 0,05 + 0,9000 + 1,0030 = 1,9530$ și
 $\sigma_5^2 = 0,05 + 0,1000 + 1,6600 = 1,8100$.
- Prognozele: distanța $\sigma_5^2 - \bar{\sigma}^2 = 0,8101$ scade cu 0,95 pe zi, deci $\mathbb{E}_4 \sigma_{4+h}^2 = 1,8100, 1,7695, 1,7311, 1,6945, 1,6598$ pentru $h = 1, \dots, 5$.
- (e) Formula: $V_5 = 5 \times 1,0000 + 0,8101 \times (1 - 0,95^5)/(1 - 0,95) = 5 + 0,8101 \times 4,524 = 8,665$, la fel ca suma; volatilitatea pe 5 zile $\sqrt{8,665} = 2,944\%$.
- Regula rădăcinii pătrate a timpului dă $5\sigma_5^2 = 9,050 > V_5$: după zilele agitate supraestimează dispersia pe 5 zile, cum prezice (c) pentru $\sigma_5^2 > \bar{\sigma}^2$.
- (f) Timpul de înjumătățire = $\ln 0,5 / \ln 0,95 = -0,6931 / (-0,0513) = 13,5$ zile: jumătate din orice șoc de dispersie dispare după circa două săptămâni de tranzacționare.

A2: persistența GJR cu inovații asimetrice (1/2) [Propus]

Rezolvarea se discută la seminar

Context și date

- GJR-GARCH(1,1) [Glosten, Jagannathan & Runkle \(1993\)](#): $\sigma_t^2 = \omega + (\alpha + \gamma l_{t-1})\varepsilon_{t-1}^2 + \beta\sigma_{t-1}^2$, $l_{t-1} = 1(\varepsilon_{t-1} < 0)$; z_t i.i.d., de medie 0, dispersie 1, nu neapărat simetric
- Date pentru (c): S&P 500 (data/market/GSPC.INDX.csv), închideri zilnice 2000–2026, 6 714 randamente log zilnice în %, $r_t = 100(\ln P_t - \ln P_{t-1})$; GJR-GARCH(1,1) cu inovații t asimetrice [Hansen \(1994\)](#): $\hat{\alpha} = 0,00000$, $\hat{\gamma} = 0,21116$, $\hat{\beta} = 0,87965$, $\hat{\eta} = 7,70$, $\hat{\lambda} = -0,150$

Ce aveți de făcut

- (a) Aplicați media în recursie și arătați că persistența este $\alpha + \gamma m_- + \beta$, cu $m_- = \mathbb{E}[z_t^2 1(z_t < 0)]$.
- (b) Arătați că $m_- = 1/2$ când z_t este simetric și explicați de ce m_- diferă în general de $P(z_t < 0)$.
- (c) Calculați m_- și $P(z_t < 0)$ prin integrarea numerică a densității t asimetrice estimate; calculați persistența și timpul de înjumătățire cu m_- și cu $1/2$.

A2: persistența GJR cu inovații asimetrice (2/2) [Propus]

Rezolvarea se discută la seminar

Ce raportați și interpretați

- Raportați m_- , $P(z_t < 0)$, ambele persistențe și ambii timpi de înjumătățire. Interpretare: ce se întâmplă dacă se folosește formula $\alpha + \gamma/2 + \beta$ cu inovații asimetrice?
- Model: A1

A3: volatilitatea de termen lung, timpul de înjumătățire și metoda delta (1/2) [Rezolvat]

Context și date

- S&P 500 (data/market/GSPC.INDX.csv), închideri zilnice 2000–2026, 6 714 randamente log zilnice în %, $r_t = 100 (\ln P_t - \ln P_{t-1})$
- GARCH(1,1) cu inovații Student-t (Cursul 5): $\hat{\omega} = 0,015714$, $\hat{\alpha} = 0,122573$, $\hat{\beta} = 0,872139$; covarianța robustă a lui $(\hat{\omega}, \hat{\alpha}, \hat{\beta})$ din estimare, cu $\widehat{\text{e.s.}}(\hat{\alpha} + \hat{\beta}) = 0,0047$; 251,4 zile de tranzacționare pe an

Ce aveți de făcut

- (a) Deduceți dispersia de termen lung $\sigma^2 = \omega / (1 - \alpha - \beta)$ aplicând media necondiționată în recursie.
- (b) Calculați volatilitatea de termen lung zilnică și anuală și timpul de înjumătățire; comparați cu volatilitatea de selecție 19,2% anual.
- (c) Calculați gradientul lui $\sigma^2(\omega, \alpha, \beta)$ și, prin metoda delta, eroarea standard a volatilității anuale de termen lung.
- (d) Calculați eroarea standard prin metoda delta a timpului de înjumătățire $h = \ln 0,5 / \ln p$, $p = \alpha + \beta$, și construiți un interval de 95% pentru h care respectă $h > 0$.

A3: volatilitatea de termen lung, timpul de înjumătățire și metoda delta (2/2) [Rezolvat]

Ce raportați și interpretați

- Raportați volatilitatea de termen lung cu eroarea ei standard, timpul de înjumătățire cu eroarea lui standard și intervalul transformat.
- Interpretare: de ce este metoda delta inutilă pentru timpul de înjumătățire și ce înseamnă asta pentru întrebarea $p = 1$ (B7)?

A3: volatilitatea de termen lung, timpul de înjumătățire și metoda delta: Rezolvare (1/2) [Rezolvat]

- (a) Sub staționaritatea în covarianță $\mathbb{E}\sigma_t^2 = \mathbb{E}\sigma_{t-1}^2 = \mathbb{E}\varepsilon_{t-1}^2 = \sigma^2$, deci $\sigma^2 = \omega + (\alpha + \beta)\sigma^2$ și $\sigma^2 = \omega/(1 - \alpha - \beta)$.
- (b) $\hat{\rho} = \hat{\alpha} + \hat{\beta} = 0,994712$; $\hat{\sigma}^2 = 0,015714/(1 - 0,994712) = 2,972$ (%² pe zi).
- Volatilitatea zilnică $\sqrt{2,972} = 1,724\%$; anuală $1,724 \times \sqrt{251,4} = 27,3\%$, față de valoarea de selecție 19,2%.
- Timpul de înjumătățire $\ln 0,5 / \ln 0,994712 = -0,6931/(-0,005302) = 130,7$ zile.
- Interpretare: volatilitatea de termen lung depășește valoarea de selecție deoarece împărțirea la $1 - \hat{\rho} = 0,005288$ amplifică erorile mici din $\hat{\rho}$; pasul următor măsoară cât.

A3: volatilitatea de termen lung, timpul de înjumătățire și metoda delta: Rezolvare (2/2) [Rezolvat]

- (c) Gradientul $\nabla \sigma^2 = \left(\frac{1}{1-p}, \frac{\omega}{(1-p)^2}, \frac{\omega}{(1-p)^2} \right) = (189,1, 562,0, 562,0)$; $\widehat{e.s.}(\hat{\sigma}^2) = \sqrt{\nabla' \hat{V} \nabla} = 2,35$.
- Volatilitatea anuală $v = \sqrt{251,4 \sigma^2}$ are $\partial v / \partial \sigma^2 = 251,4 / (2v)$, deci $\widehat{e.s.}(\hat{v}) = 10,8$ puncte în jurul a 27,3%: o bandă de 95% de circa ± 21 de puncte.
- (d) $|\partial h / \partial p| = -\ln 0,5 / [p(\ln p)^2] = 24\,789$, deci $\widehat{e.s.}(\hat{h}) = 24\,789 \times 0,0047 = 116$ zile pentru $\hat{h} = 130,7$ zile.
- Un interval simetric $\hat{h} \pm 1,96 \times 116$ ar include timpi de înjumătățire negativi: liniarizarea eșuează deoarece $h(p)$ explodează când $p \rightarrow 1$.
- În schimb, h este crescătoare în p : transformăm $\hat{p} \pm 1,96 \times 0,0047 = [0,9855; 1,0039]$ în $h \in [48; \infty)$, deoarece capătul superior depășește $p = 1$.
- Interpretare: datele mărginesc timpul de înjumătățire doar inferior; evaluarea plauzibilității ipotezei $p = 1$ necesită un test corect la frontieră (B7).

A4: finitudinea momentului de ordin patru (1/2) [Propus]

Rezolvarea se discută la seminar

Context și date

- ▣ S&P 500 (data/market/GSPC.INDX.csv), închideri zilnice 2000–2026, 6 714 randamente log zilnice în %, $r_t = 100 (\ln P_t - \ln P_{t-1})$
- ▣ GARCH(1,1) cu inovații Normale (GARCH-N): $\hat{\alpha} = 0,120604$, $\hat{\beta} = 0,859878$; applatizarea de selecție a randamentelor 13,7
- ▣ GARCH(1,1)-t: $\hat{\alpha} = 0,1226$, $\hat{\beta} = 0,8721$, $\hat{\nu} = 6,26$; cu z_t Normal, $K = 3[1 - (\alpha + \beta)^2]/[1 - (\alpha + \beta)^2 - 2\alpha^2]$ dacă numitorul este pozitiv (Seminarul 1, A9)

Ce aveți de făcut

- ▣ (a) Verificați condiția $(\alpha + \beta)^2 + 2\alpha^2 < 1$ pentru GARCH-N și calculați applatizarea implicată K .
- ▣ (b) Repetați (a) cu $\hat{\alpha}$ și $\hat{\beta}$ rotunjite la 3 zecimale și comparați ambele valori ale lui K cu applatizarea de selecție.
- ▣ (c) Pentru inovații Student-t, calculați $\kappa_z = 3(\nu - 2)/(\nu - 4)$ și verificați condiția $(\alpha + \beta)^2 + (\kappa_z - 1)\alpha^2 < 1$ pentru estimările GARCH-t.

A4: finitudinea momentului de ordin patru (2/2) [Propus]

Rezolvarea se discută la seminar

Ce raportați și interpretați

- Raportați ambele condiții, cele două valori ale lui K și κ_z . Interpretare: se poate folosi aplatizarea randamentelor pentru a valida un GARCH-t estimat?
- Model: A3

A5: dispersia robustă și cea clasică a QMLE Gaussian, ARCH(1) (1/2) [Propus]

Rezolvarea se discută la seminar

Context și date

- ▣ ARCH(1): $\varepsilon_t = \sigma_t z_t$, $\sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2$ cu ω cunoscut; z_t i.i.d., de medie 0, dispersie 1, applatizare $\kappa_z = \mathbb{E}z_t^4 < \infty$, nu neapărat Normal
- ▣ Cvasi-log-verosimilitatea Gaussiană pe zi $\ell_t(\alpha) = -\frac{1}{2}(\ln \sigma_t^2 + \varepsilon_t^2/\sigma_t^2)$; notație $x_t = \varepsilon_{t-1}^2/\sigma_t^2$. Date pentru (d): applatizarea reziduurilor GARCH-N pentru S&P 500, 4,73 (Cursul 5)

Ce aveți de făcut

- ▣ (a) Deduceți scorul $s_t = \partial \ell_t / \partial \alpha$ și dispersia lui $B = \mathbb{E}s_t^2$.
- ▣ (b) Deduceți derivata a doua $\partial^2 \ell_t / \partial \alpha^2$ și $A = -\mathbb{E} \partial^2 \ell_t / \partial \alpha^2$.
- ▣ (c) Arătați că dispersia „sandviș” $A^{-1}BA^{-1}$ este $\frac{\kappa_z - 1}{2}A^{-1}$, unde A^{-1} este dispersia clasică (inversa hessianei).
- ▣ (d) Calculați raportul dintre erorile standard robuste și clasice pentru inovații Student-t cu $\nu = 6,26$ și pentru $\hat{\kappa}_z = 4,73$.

A5: dispersia robustă și cea clasică a QMLE Gaussian, ARCH(1) (2/2) [Propus]

Rezolvarea se discută la seminar

Ce raportați și interpretați

- Raportați s_t , A , B , raportul dispersiilor și cele două rapoarte numerice; comparați cu raportul observat 1,37 din Cursul 5.
- Interpretare: ce se întâmplă cu acest raport și cu teoria în $\sqrt{n}$ când $\kappa_z = \infty$? Model: A3

A6: autocorelația pătratelor șocurilor (1/2) [Propus]

Rezolvarea se discută la seminar

Context și date

- ▣ GARCH(1,1) cu $\mathbb{E}\varepsilon_t^4 < \infty$ este un ARMA(1,1) în ε_t^2 : $\varepsilon_t^2 = \omega + (\alpha + \beta)\varepsilon_{t-1}^2 + \nu_t - \beta\nu_{t-1}$, cu $\nu_t = \varepsilon_t^2 - \sigma_t^2$ (Cursul 5)
- ▣ Pentru un ARMA(1,1) $y_t = \phi y_{t-1} + u_t + \theta u_{t-1}$: $\rho_1 = (1 + \phi\theta)(\phi + \theta)/(1 + 2\phi\theta + \theta^2)$ și $\rho_k = \phi^{k-1}\rho_1$
- ▣ Date pentru (b): GARCH-N pentru S&P 500, $\hat{\alpha} = 0,1206$, $\hat{\beta} = 0,8599$; autocorelațiile de selecție ale pătratelor randamentelor centrate 0,313 (decalajul 1) și 0,248 (decalajul 10)

Ce aveți de făcut

- ▣ (a) Înlocuiți $\phi = \alpha + \beta$ și $\theta = -\beta$ și deduceți $\rho_1(\varepsilon^2) = \alpha(1 - \beta^2 - \alpha\beta)/(1 - \beta^2 - 2\alpha\beta)$ și $\rho_k = \rho_1(\alpha + \beta)^{k-1}$.
- ▣ (b) Evaluați ρ_1 și ρ_{10} pentru estimările S&P 500 și comparați-le cu valorile de selecție.
- ▣ (c) Explicați de ce diferența poate fi mare chiar dacă modelul este corect, folosind condiția de moment din A4.

A6: autocorelația pătratelor șocurilor (2/2) [Propus]

Rezolvarea se discută la seminar

Ce raportați și interpretați

- Raportați formula, ρ_1 , ρ_{10} și valorile de selecție. Interpretare: este potrivirea funcției de autocorelație a lui r_t^2 o verificare puternică sau slabă a unui GARCH?
- Model: A1

B1: GARCH-t pe S&P 500 cu diagnostic (1/2) [Rezolvat]

Context și date

- S&P 500 (data/market/GSPC.INDX.csv), închideri zilnice 2000–2026, 6 714 randamente log zilnice în %, $r_t = 100 (\ln P_t - \ln P_{t-1})$
- Ecuația mediei $r_t = \mu + \varepsilon_t$; ecuația dispersiei GARCH(1,1) [Bollerslev \(1986\)](#); inovații Student-t cu ν grade de libertate, scalate la dispersie unitară

Ce aveți de făcut

- (a) Testați efectele ARCH înainte de modelare: Ljung–Box $Q(10)$ pe r_t^2 și testul LM al lui Engle cu 5 decalaje pe randamentele centrate, la pragul de 5%.
- (b) Estimați GARCH(1,1)-t prin verosimilitate maximă (`arch_model(r, p=1, q=1, dist='t')`); raportați erorile standard robuste [Bollerslev & Wooldridge \(1992\)](#) și clasice și raportul lor.
- (c) Diagnosticați $\hat{z}_t = \hat{\varepsilon}_t / \hat{\sigma}_t$ la 5%: $Q(10)$ pe $\hat{z}_t$ și $\hat{z}_t^2$, LM(5) și cele trei teste t de asimetrie plus testul lor comun χ^2_3 [Engle & Ng \(1993\)](#).

B1: GARCH-t pe S&P 500 cu diagnostic (2/2) [Rezolvat]

Ce raportați și interpretați

- ☐ Raportați un tabel al estimărilor cu ambele erori standard și un tabel al statisticilor de test cu valorile p și deciziile.
- ☐ Interpretare: ce diagnostice trec și care pică, ce sugerează eșecul și de ce sunt erorile standard robuste mai mari?

B1: GARCH-t pe S&P 500 cu diagnostic: Rezolvare (1/2) [Rezolvat]

	$\hat{\omega}$	$\hat{\alpha}$	$\hat{\beta}$	$\hat{\nu}$	$\hat{\alpha} + \hat{\beta}$
Estimare	0,0157	0,1226	0,8721	6,26	0,9947
E.s. robustă		0,0107	0,0103	0,48	
E.s. clasică		0,0101	0,0096		

- (a) Înainte de modelare, $Q(10) = 6133$ și $LM(5) = 1684$, față de valorile critice de 5% 18,3 (χ_{10}^2) și 11,1 (χ_5^2); ambele $p < 0,001$, deci absența efectelor ARCH este respinsă.
- (b) Citirea tabelului: $\hat{\beta} = 0,8721$ preia dispersia de ieri, $\hat{\alpha} = 0,1226$ adaugă știrile, $\hat{\nu} = 6,26$ semnalează cozi groase; persistența 0,9947.
- Raportul robust/clasic este 1,06 pentru $\hat{\alpha}$ și 1,08 pentru $\hat{\beta}$: verosimilitatea Student-t este ea însăși greșit specificată (asimetrie -0,58), deci „sandvișul” este mai mare.

B1: GARCH-t pe S&P 500 cu diagnostic: Rezolvare (2/2) [Rezolvat]

- (c) Ecuația dispersiei: $Q(10)$ pe $\hat{z}_t^2 = 13,6$ ($p = 0,192$) și $LM(5) = 5,8$ ($p = 0,326$): nerespinse la 5%: nu se detectează grupare rămasă (legi χ^2 naive, vezi atenționarea de mai jos).
- Ecuația mediei: $Q(10)$ pe $\hat{z}_t = 21,9$ ($p = 0,016$): respins la 5%; rămâne o mică autocorelație pe care media constantă o ignoră.
- Asimetria: asimetria de semn $t = 3,56$, de mărime negativă $t = 1,13$, de mărime pozitivă $t = -2,61$; comun $\chi^2_3 = 40,7$ față de 7,81: respins, în reziduuri rămâne asimetrie.
- Atenție: cu parametri estimați aceste legi χ^2 sunt doar aproximative [Li & Mak \(1994\)](#); aici respingerile sunt departe de valorile critice, deci deciziile rămân.
- Interpretare: dinamica dispersiei este surprinsă, dar un GARCH simetric ratează efectul de levier; pasul următor este GJR-GARCH (B2).

B2: GJR vs GARCH pe S&P 500 (1/2) [Rezolvat]

Context și date

- S&P 500 (data/market/GSPC.INDX.csv), închideri zilnice 2000–2026, 6 714 randamente log zilnice în %, $r_t = 100 (\ln P_t - \ln P_{t-1})$
- GJR-GARCH(1,1)-t [Glosten, Jagannathan & Runkle \(1993\)](#): $\sigma_t^2 = \omega + (\alpha + \gamma I_{t-1}) \varepsilon_{t-1}^2 + \beta \sigma_{t-1}^2$, $I_{t-1} = 1(\varepsilon_{t-1} < 0)$; GARCH(1,1)-t din B1 este cazul particular $\gamma = 0$

Ce aveți de făcut

- (a) Estimați GJR-GARCH(1,1)-t și raportați $\hat{\alpha}$, $\hat{\gamma}$ cu statistica t robustă și $\hat{\beta}$.
- (b) Testați $H_0: \gamma = 0$ cu $LR = 2(\ell_{GJR} - \ell_{GARCH})$ față de χ_1^2 la 5%.
- (c) Comparați AIC și BIC ale celor două modele și repetați testul comun de asimetrie din B1 pe reziduurile GJR.
- (d) Măsurați mărimea economică a asimetriei cu curba de impact a știrilor: dispersia de a doua zi după șocuri de -3% și $+3\%$.

Ce raportați și interpretați

- Raportați estimările, testul LR (statistica, valoarea p , decizia), ΔAIC , ΔBIC și cele două valori de impact al știrilor.

B2: GJR vs GARCH pe S&P 500 (2/2) [Rezolvat]

Ce raportați și interpretați

- ☐ Interpretare: de ce este $\hat{\alpha}$ exact 0 și mai este validă legea χ^2_1 a testului LR?

B2: GJR vs GARCH pe S&P 500: Rezolvare [Rezolvat]

- (a) $\hat{\alpha} = 0,000$, $\hat{\gamma} = 0,205$ (t robust = 10,03), $\hat{\beta} = 0,881$: știrile bune au panta $\hat{\alpha}$, cele proaste $\hat{\alpha} + \hat{\gamma}$.
- (b) $LR = 2(-8944,6 - (-9062,5)) = 235,65$, $p < 0,001$, mult peste 3,84: H_0 este respinsă la 5%; legea χ^2_1 presupune o densitate Student-t corectă (B1 găsește asimetrie), dar t robust de la (a) dă același verdict.
- (c) $\Delta AIC = -233,7$ și $\Delta BIC = -226,8$ (GJR minus GARCH): ambele preferă GJR; testul comun de asimetrie χ^2_3 scade de la 40,7 la 28,1, încă peste 7,81.
- (d) Pornind de la dispersia de selecție 1,47, un șoc de -3% dă dispersia de a doua zi 3,16, iar unul de $+3\%$ dă 1,31: prognoza după știri proaste este de 2,4 ori cea după știri bune, iar șocul de $+3\%$ chiar scade dispersia ($\hat{\alpha} = 0$).
- $\hat{\alpha} = 0$ este la limita $\alpha \geq 0$: șocurile pozitive nu cresc volatilitatea; $\gamma = 0$ este interior, deci χ^2_1 este valabilă dacă adevăratul $\alpha > 0$, iar dacă $\alpha_0 = 0$ legea este nestandard [Andrews \(2001\)](#), dar $LR = 235,65$ respinge sub orice lege rezonabilă

B3: GJR vs GARCH pe BET [Propus]

Rezolvarea se discută la seminar

Context și date

- BET (data/market/BET.csv), închideri zilnice 2000–2026, 6 670 randamente log zilnice în %
- Aceleași două modele ca în B2: GARCH(1,1)-t și GJR-GARCH(1,1)-t, medie constantă, inovații Student-t

Ce aveți de făcut

- (a) Estimați ambele modele și raportați $\hat{\gamma}$ cu statistica t robustă.
- (b) Testați $H_0: \gamma = 0$ prin LR față de χ^2_1 la pragurile de 5% și 1%.
- (c) Calculați ΔAIC și ΔBIC (GJR minus GARCH) și penalizarea BIC pe parametru, $\ln n$.

Ce raportați și interpretați

- Raportați estimările, decizia LR la ambele praguri și cele două criterii. Interpretare: sunt de acord LR și BIC, de ce pot fi în dezacord și este efectul de levier mai slab la BET decât la S&P 500?
- Model: B2

B4: distribuția inovațiilor pentru Bitcoin (1/2) [Propus]

Rezolvarea se discută la seminar

Context și date

- Bitcoin (data/market/BTC-USD.CC.csv), închideri zilnice 2014–2026, 4 384 randamente log zilnice în %, 365 de zile pe an
- GARCH(1,1) cu medie constantă; patru distribuții ale inovațiilor: distribuția Normală, distribuția Student-t, distribuția t asimetrică Hansen (1994) (asimetria λ) și GED

Ce aveți de făcut

- (a) Estimați cele patru modele și comparați log-verosimilitățile și BIC.
- (b) Testați $H_0: \lambda = 0$ (t asimetrică față de Student-t) prin LR față de χ^2_1 la 5%.
- (c) Raportați parametrii de formă și de asimetrie aplicabili, cu erorile lor standard, și $\hat{\alpha} + \hat{\beta}$ pentru fiecare lege; distribuția Normală nu are astfel de parametri, iar forma GED nu este un număr de grade de libertate; precizați ce parametri sunt la o limită.
- (d) Testați distribuția Normală ($1/\nu = 0$) față de distribuția Student-t prin LR cu legea la frontieră $\frac{1}{2}\chi^2_0 + \frac{1}{2}\chi^2_1$ (valoarea critică la 5%: 2,71).

B4: distribuția inovațiilor pentru Bitcoin (2/2) [Propus]

Rezolvarea se discută la seminar

Ce raportați și interpretați

- Raportați un tabel cu ℓ , BIC și persistența și cele două teste LR. Interpretare: asimetria de selecție a lui $\hat{z}_t$ este negativă, de ce nu găsește verosimilitatea asimetrie? Cu $\hat{\nu} < 4$, este validă inferența QMLE Gaussian pentru Bitcoin [Hall & Yao \(2003\)](#) și prin ce diferă de inferența pentru MLE Student-t din B1?
- Model: B1, B2

B5: compararea prognozelor pe S&P 500 (1/2) [Rezolvat]

Context și date

- S&P 500 (data/market/GSPC.INDX.csv), închideri zilnice 2000–2026, 6 714 randamente log zilnice în %, $r_t = 100 (\ln P_t - \ln P_{t-1})$; perioada de prognoză 2016–2026 (2 692 prognoze pentru ziua următoare)
- Modele: GARCH-N, GARCH-t, GJR-t, EGARCH-t reestimate în fiecare ianuarie pe toate datele din 2000 (fereastră în expansiune); EWMA cu $\lambda = 0,94$ J.P. Morgan/Reuters (1996); Hist-20, media ultimelor 20 de pătrate ale randamentelor
- Aproximarea dispersiei adevărate: r_t^2 , ignorând media ($\hat{\mu}^2 = 0,0062$ față de o dispersie medie de 1,47); pierderea QLIKE $= r_t^2 / h_t + \ln h_t$ Patton (2011), cu h_t prognoza dispersiei

Ce aveți de făcut

- (a) Calculați QLIKE mediu pentru fiecare model.
- (b) Testați acuratețea egală față de GARCH-t cu statistica t Diebold–Mariano pe $d_t = L_t^m - L_t^{GARCH-t}$, eroare standard HAC cu 5 decalaje, la 5% Diebold & Mariano (1995).
- (c) Estimați regresia Mincer–Zarnowitz $r_t^2 = a + b h_t + u_t$ Mincer & Zarnowitz (1969) cu erori HAC și testul Wald pentru $a = 0$, $b = 1$.

B5: compararea prognozelor pe S&P 500 (2/2) [Rezolvat]

Ce aveți de făcut

- (d) Repetați comparația cu o fereastră mobilă de 1 000 de zile, reestimată în fiecare ianuarie, și testul Giacomini–White [Giacomini & White \(2006\)](#) (instrumente 1, d_t).
- (e) Calculați Model Confidence Set 90% [Hansen, Lunde & Nason \(2011\)](#) pe pierderile QLIKE ale prognozelor cu fereastră în expansiune de la (a): statistica T_R , bootstrap staționar cu lungimea medie a blocului 10, 10 000 de extrageri, valoare de inițializare fixată.

Ce raportați și interpretați

- Raportați două tabele: QLIKE, t DM, b MZ, R^2 și p Wald; apoi statistica GW, valoarea p și valoarea p MCS.
- Interpretare: ce modele sunt semnificativ mai slabe decât GARCH-t, de ce este R^2 mic, de ce nu este valid DM pentru GJR-t vs GARCH-t și sunt de acord DM și MCS?

B5: compararea prognozelor pe S&P 500: Rezolvare (1/2) [Rezolvat]

Model	QLIKE	DM t	MZ b	MZ R^2	Wald p
GARCH-N	0,7510	-1,47	0,97	0,250	0,995
GARCH-t	0,7570	—	0,88	0,238	0,804
GJR-t	0,7319	-1,22	0,84	0,276	0,680
EGARCH-t	0,7454	-0,36	1,24	0,293	0,713
EWMA	0,8149	3,48	0,89	0,172	0,685
Hist-20	0,8888	4,10	0,68	0,152	0,028

- Procedura: prognozăm h_t în fiecare zi cu parametrii din ianuarie precedent, calculăm L_t , facem media pe 2 692 zile și regresăm d_t pe o constantă cu erori HAC.
- (a–b) Cel mai mic QLIKE: GJR-t; doar EWMA ($t = 3,48$) și Hist-20 ($t = 4,10$) depășesc 1,96: sunt semnificativ mai slabe la 5%.
- (c) Nedeplasarea nu este respinsă pentru modelele GARCH (Wald $p > 0,6$), dar este respinsă pentru Hist-20 ($p = 0,028$); R^2 este mic deoarece $r_t^2 \approx \sigma_t^2 z_t^2$ este o aproximare zgomotoasă.

B5: compararea prognozelor pe S&P 500: Rezolvare (2/2) [Rezolvat]

Model	t (mobil)	GW	p	MCS p
GARCH-N	1,87	5,85	0,054	0,586
GARCH-t	–	–	–	0,353
GJR-t	–0,18	2,49	0,288	1,000
EGARCH-t	0,07	3,21	0,201	0,586
EWMA	3,20	11,40	0,003	0,008
Hist-20	3,87	16,41	< 0,001	0,001

- (d) De ce GW: cu modele imbricate, parametri estimați și fereastră în expansiune, diferența DM degenerează sub H_0 , deci DM nu este $N(0, 1)$; o fereastră mobilă păstrează zgomotul estimării și face GW valid.
- $GW = n\bar{Z}'\hat{\Omega}^{-1}\bar{Z} \sim \chi^2_2$ (valoarea critică 5,99): respins doar pentru EWMA și Hist-20; GARCH-N este la limită ($p = 0,054$).
- (e) MCS pe prognozele cu fereastră în expansiune: un model rămâne în mulțimea de 90% dacă valoarea p MCS depășește 0,10; mulțimea este GARCH-N, GARCH-t, GJR-t, EGARCH-t, același verdict ca DM, acum cu rata erorii controlată pentru șase modele.

B6: compararea prognozelor pe BET (1/2) [Propus]

Rezolvarea se discută la seminar

Context și date

- BET (data/market/BET.csv), închideri zilnice 2000–2026, 6 670 randamente log zilnice în %; perioada de prognoză 2016–2026 (2 675 prognoze pentru ziua următoare)
- Aceleași șase modele, aceeași schemă de reestimare, aproximarea r_t^2 și pierderea QLIKE ca în B5

Ce aveți de făcut

- (a) Calculați QLIKE mediu al fiecărui model și statistica t Diebold–Mariano față de GARCH-t (HAC, 5 decalaje), la 5%.
- (b) Estimați regresia Mincer–Zarnowitz și testul Wald pentru $a = 0$, $b = 1$ pentru fiecare model.
- (c) Calculați testul Giacomini–White cu fereastră mobilă de 1 000 de zile și, ca în B5 (e), Model Confidence Set 90% pe pierderile QLIKE ale prognozelor cu fereastră în expansiune.

Ce raportați și interpretați

- Raportați cele două tabele din B5 pentru BET. Interpretare: se schimbă ordinea între S&P 500 și BET, dau DM și MCS același verdict pentru EWMA și ce parte a modelului pentru BET ați îmbunătăți întâi?

B6: compararea prognozelor pe BET (2/2) [Propus]

Rezolvarea se discută la seminar

Ce raportați și interpretați

☐ Model: B5

B7: cât de precis este timpul de înjumătățire? Bootstrap și testul IGARCH (1/2) [Rezolvat]

Context și date

- ▣ S&P 500 (data/market/GSPC.INDX.csv), închideri zilnice 2000–2026, 6 714 randamente log zilnice în %, $r_t = 100 (\ln P_t - \ln P_{t-1})$
- ▣ GARCH(1,1)-t din B1: $\hat{\rho} = \hat{\alpha} + \hat{\beta} = 0,9947$, timp de înjumătățire 131 zile; estimarea impune $\alpha + \beta \leq 1$; valoarea de inițializare a generatorului de numere aleatoare fixată pentru reproductibilitate

Ce aveți de făcut


- ▣ (a) Simulați $B = 999$ traiectorii de 6 714 zile (500 de zile de încălzire) din GARCH(1,1)-t estimat și reestimați modelul pe fiecare traiectorie.
- ▣ (b) Calculați intervalele de 95% bazate pe percentile pentru $\hat{\rho}^*$ și pentru timpul de înjumătățire, abaterea standard bootstrap a lui $\hat{\rho}^*$ și proporția extragerilor la limita $p = 1$; comparați cu eroarea standard robustă.
- ▣ (c) Testați $H_0: \alpha + \beta = 1$: estimați IGARCH(1,1)-t, calculați $LR = 2(\ell_{GARCH} - \ell_{IGARCH})$, simulați $B = 999$ traiectorii sub H_0 , reestimați ambele modele pe fiecare și calculați valoarea p bootstrap $(1 + \#\{LR^* \geq LR\})/(B + 1)$.
- ▣ (d) Comparați această valoare p cu valorile p calculate folosind distribuția χ_1^2 neajustată și amestecul la frontieră $\frac{1}{2}\chi_0^2 + \frac{1}{2}\chi_1^2$; decideți la 5% și la 10%.

B7: cât de precis este timpul de înjumătățire? Bootstrap și testul IGARCH (2/2) [Rezolvat]

Ce raportați și interpretați

- ☐ Raportați histograma lui $\hat{p}^*$ sub ambele scheme, intervalele, cele trei valori p și decizia.
- ☐ Interpretare: de ce este intervalul timpului de înjumătățire atât de asimetric și de ce „intervalul bazat pe percentile atinge 1” nu este un test pentru IGARCH?

B7: cât de precis este timpul de înjumătățire? Bootstrap și testul IGARCH: Rezolvare (1/2) [Rezolvat]



- (a–b) Albastru: $\hat{\rho}^*$ din modelul estimat; interval de 95% [0,9833; 1,0000]; abaterea standard bootstrap 0,0047 față de e.s. robustă 0,0047: apropiate.
- Timpul de înjumătățire de la 41 zile la ∞ : $\ln 0,5 / \ln x$ explodează când $x \rightarrow 1$ (e.s. prin metoda delta 116 zile, A3); 8,9% din extrageri sunt la limită, deci intervalul este trunchiat la 1 [Andrews \(2000\)](#).

B7: cât de precis este timpul de înjumătățire? Bootstrap și testul IGARCH: Rezolvare (2/2) [Rezolvat]

- (c) Estimarea IGARCH-t: $\hat{\alpha}_0 = 0,127$, $\hat{\nu}_0 = 6,03$; $LR = 1,11$.
- Sub H_0 (histograma chihlimbarie), 52% din reestimări sunt la $p = 1$, aproape de jumătatea prezisă de legea amestecului; valoarea critică simulată de 95% a LR este 3,36.
- (d) Valori p : 0,29 (χ^2_1 naiv), 0,15 (amestec), 0,17 (LR bootstrap) și 0,17 ($\hat{p}$ bootstrap).
- Decizia: H_0 nu este respinsă nici la 5%, nici la 10%; χ^2_1 naiv aproape dublează valoarea p , iar amestecul și bootstrap-ul sunt de acord.
- Concluzia economică: 27 de ani de date nu pot deosebi un timp de înjumătățire de circa 130 de zile de unul infinit; simularea din $\hat{\theta}$ descrie precizia, simularea din modelul nul este ceea ce îi trebuie unui test.

B8: bootstrap și testul IGARCH pentru BET [Propus]

Rezolvarea se discută la seminar

Context și date

- ▣ BET (data/market/BET.csv), închideri zilnice 2000–2026, 6 670 randamente log zilnice în %
- ▣ GARCH(1,1)-t cu $\hat{p} = 0,9907$ (timp de înjumătățire 74 zile); aceeași procedură și același număr de extrageri ca în B7

Ce aveți de făcut

- ▣ (a) Rulați bootstrap-ul parametric cu $B = 999$ din modelul estimat; raportați intervalele de 95% pentru p și pentru timpul de înjumătățire și proporția extragerilor la $p = 1$.
- ▣ (b) Comparați abaterea standard bootstrap a lui $\hat{p}^*$ cu eroarea standard robustă a lui $\hat{\alpha} + \hat{\beta}$.
- ▣ (c) Testați IGARCH prin simulare sub H_0 ($B = 999$) și comparați cu valoarea p din amestec, la 5%.

Ce raportați și interpretați

- ▣ Raportați intervalele, cele două erori standard și testul. Interpretare: este timpul de înjumătățire al BET semnificativ mai scurt din punct de vedere statistic decât al S&P 500 și de ce ar avea nevoie un test formal al diferenței?
- ▣ Model: B7

C1: este volatilitatea pieței românești determinată de SUA? [Propus]

Rezolvarea se discută la seminar

Întrebarea

- Wall Street închide după Bursa de Valori București: șocul S&P 500 de ieri este o știre pentru BET-ul de azi
- u_{t-1}^2 , pătratul randamentului S&P 500 din ziua precedentă, crește dispersia condiționată a BET?
- Model: $\sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2 + \beta \sigma_{t-1}^2 + \delta u_{t-1}^2$, cu $r_t = \mu + \phi u_{t-1} + \varepsilon_t$

Livrabil

- Un folder Quantlet în repository-ul echipei și un slide cu concluzia și principala limită

Răspunsul ar trebui să conțină

- Prețurile îmbinate întâi în zilele comune de tranzacționare, apoi randamentele
- Verosimilitatea scrisă pas cu pas (Student-t), estimată prin optimizare numerică
- Un test LR pentru $\delta = 0$; atenție, $\delta \geq 0$ pune ipoteza nulă pe frontieră
- Stabilitatea: două subperioade (de ex. înainte și după 2013)
- Partea din dispersia BET generată în model de termenul american, $\sum_{j \geq 0} \beta^j \delta u_{t-1-j}^2 / \sigma_t^2$, și cum se schimbă în timp

C2: critica unui răspuns AI [Propus]

Rezolvarea se discută la seminar

Cererea trimisă unui asistent de inteligență artificială (AI)

- „px conține închiderile zilnice S&P 500. Estimează un GARCH(1,1) cu inovații Student- t cu arch și dă-mi volatilitatea anualizată de termen lung și timpul de înjumătățire al unui șoc.”

Răspunsul asistentului

```
import numpy as np
from arch import arch_model
r = np.log(px).diff().dropna() # daily log returns
am = arch_model(r, vol='GARCH', p=1, q=1, dist='t')
res = am.fit(displ='off')
om = res.params['omega']
a, b = res.params['alpha[1]'], res.params['beta[1]']
lr_var = om / (1 - a - b) # long-run daily variance
ann_vol = lr_var * 252 # annualised volatility
half_life = np.log(0.5) / np.log(b) # half-life in days
```

- „Pentru S&P 500 rezultă $\text{ann_vol} = 0,075$ (7,5% pe an) și un timp de înjumătățire de 5,1 zile.”

C2: critica unui răspuns AI, cerința [Propus]

Rezolvarea se discută la seminar

- Codul rulează, dar răspunsul conține **trei** greșeli tipice pentru lucrul cu GARCH
 - ▶ Tot restul răspunsului este corect
- Pentru fiecare greșeală
 - ▶ Indicați linia și explicați de ce este greșită
 - ▶ Spuneți cum ați depista-o: un avertisment, o cifră din A3, un slide din curs
 - ▶ Scrieți varianta corectă a liniei (liniilor) și cifrele corecte
- Notați fiecare greșeală ca în AI_ERRORS.md
 - ▶ Ce ați întrebat, ce a răspuns AI-ul, ce era greșit, cum v-ați dat seama, varianta corectă
- Indiciu: comparați cu A3 și cu slide-ul „Greșeli frecvente”

Greșeli frecvente

- ▣ Estimarea GARCH pe randamente în zecimale: optimizatorul se poate opri departe de maxim; folosiți % sau rescalați
- ▣ Citirea erorilor standard clasice când inovațiile nu sunt Normale; folosiți-le pe cele robuste
- ▣ Încrederea în volatilitatea de termen lung și în timpul de înjumătățire când $\alpha + \beta \approx 1$, fără un interval
- ▣ Evaluarea prognozelor în eșantion sau cu pierderi nerobuste la o aproximare zgomotoasă
- ▣ Folosirea testului LR pentru un parametru pe frontieră (de ex. $\delta = 0$ cu $\delta \geq 0$) cu valoarea critică χ^2 obișnuită sau citirea unui interval bootstrap trunchiat drept test
- ▣ Îmbinarea a două piețe pe randamente în loc de prețuri: creează randamente false pe mai multe zile

Temă pentru acasă (proiect de echipă)

- ▣ Alegeți o serie nediscutată la seminar (alt indice, un curs de schimb, o marfă sau un cripto-activ)
- ▣ Testați efectele ARCH; estimați GARCH, GJR și EGARCH cu trei distribuții ale inovațiilor; alegeți prin BIC și diagnostic
- ▣ Evaluați prognozele pe o zi și pe o lună în afara eșantionului față de EWMA, cu QLIKE și Diebold–Mariano
- ▣ Raportați timpul de înjumătățire cu un interval bootstrap; pentru o alternativă bazată pe entropie, vedeți [Pele, Lazar & Dufour \(2017\)](#)
- ▣ Notați fiecare eroare AI pe care o prindeți în `AI_ERRORS.md` (cel puțin trei pe proiect)
- ▣ Livrați un folder Quantlet (cod, Metainfo, grafice) și trei slide-uri: dovezi, interpretare, limite

Studiu suplimentar pe Quantinar

Cursuri avansate pe quantinar.com

- ☐  Statistics of Financial Markets
- ☐  Applied Time Series Analysis with Python

Cod și date

- ☐ Notebook-ul seminarului (Colab); Quantlets: github.com/danpele/MFM/tree/main/Quantlets/Ch_05

Bibliografie (1/3)

- ▣ Andrews, D.W.K. (2000). Inconsistency of the bootstrap when a parameter is on the boundary of the parameter space. *Econometrica*, 68(2), 399–405.
- ▣ Andrews, D.W.K. (2001). Testing when a parameter is on the boundary of the maintained hypothesis. *Econometrica*, 69(3), 683–734.
- ▣ Bollerslev, T. (1986). Generalized autoregressive conditional heteroskedasticity. *Journal of Econometrics*, 31(3), 307–327.
- ▣ Bollerslev, T., Wooldridge, J.M. (1992). Quasi-maximum likelihood estimation and inference in dynamic models with time-varying covariances. *Econometric Reviews*, 11(2), 143–172.
- ▣ Diebold, F.X., Mariano, R.S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3), 253–263.
- ▣ Engle, R.F., Ng, V.K. (1993). Measuring and testing the impact of news on volatility. *Journal of Finance*, 48(5), 1749–1778.
- ▣ Franke, J., Härdle, W.K., Hafner, C.M. (2019). *Statistics of Financial Markets: An Introduction*, 5th ed. Springer.

Bibliografie (2/3)

- ▣ Giacomini, R., White, H. (2006). Tests of conditional predictive ability. *Econometrica*, 74(6), 1545–1578.
- ▣ Glosten, L.R., Jagannathan, R., Runkle, D.E. (1993). On the relation between the expected value and the volatility of the nominal excess return on stocks. *Journal of Finance*, 48(5), 1779–1801.
- ▣ Hall, P., Yao, Q. (2003). Inference in ARCH and GARCH models with heavy-tailed errors. *Econometrica*, 71(1), 285–317.
- ▣ Hansen, B.E. (1994). Autoregressive conditional density estimation. *International Economic Review*, 35(3), 705–730.
- ▣ Hansen, P.R., Lunde, A., Nason, J.M. (2011). The model confidence set. *Econometrica*, 79(2), 453–497.
- ▣ J.P. Morgan/Reuters (1996). RiskMetrics — Technical Document, 4th ed. New York.
- ▣ Li, W.K., Mak, T.K. (1994). On the squared residual autocorrelations in non-linear time series with conditional heteroskedasticity. *Journal of Time Series Analysis*, 15(6), 627–636.

Bibliografie (3/3)

- ▣ Mincer, J., Zarnowitz, V. (1969). [The evaluation of economic forecasts](#). In J. Mincer (ed.), *Economic Forecasts and Expectations: Analysis of Forecasting Behavior and Performance*, NBER.
- ▣ Patton, A.J. (2011). [Volatility forecast comparison using imperfect volatility proxies](#). *Journal of Econometrics*, 160(1), 246–256.
- ▣ Pele, D.T., Lazar, E., Dufour, A. (2017). [Information entropy and measures of market risk](#). *Entropy*, 19(5), 226.