



Modelarea piețelor financiare

Seminarul 5: Volatilitate condiționată — modele GARCH



Daniel Traian PELE

Drd. Antoaneta Amza, antoaneta.amza@csie.ase.ro

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

Acronime folosite în acest material (1/2)

- ACF: AutoCorrelation Function (funcția de autocorelație)
- AI: Artificial Intelligence (inteligență artificială)
- AIC: Akaike Information Criterion (criteriul informațional Akaike)
- AR: AutoRegressive (model) (model autoregresiv)
- ARCH: AutoRegressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă)
- ARMA: AutoRegressive Moving Average (model) (model autoregresiv cu medie mobilă)
- BET: Bucharest Exchange Trading (index) (indicele de referință al Bursei de Valori București)
- BIC: Bayesian Information Criterion (criteriul informațional bayesian)
- BVB: Bursa de Valori București
- DM: Diebold–Mariano (test) (testul Diebold–Mariano de comparare a prognozelor)
- EGARCH: Exponential GARCH (GARCH exponențial)
- EWMA: Exponentially Weighted Moving Average (medie mobilă ponderată exponențial)
- GARCH: Generalised AutoRegressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă generalizată)
- GARCH-N: GARCH with Normal innovations (GARCH cu inovații Normale)
- GED: Generalised Error Distribution (distribuția generalizată a erorilor)
- GJR: Glosten–Jagannathan–Runkle (asymmetric GARCH) (GARCH asimetric Glosten–Jagannathan–Runkle)
- GJR-GARCH: Glosten–Jagannathan–Runkle GARCH (GARCH asimetric Glosten–Jagannathan–Runkle)
- GW: Giacomini–White (test) (testul Giacomini–White)
- HAC: Heteroskedasticity and Autocorrelation Consistent (standard errors) (erori standard robuste la heteroscedasticitate și autocorelație)
- IGARCH: Integrated GARCH (GARCH integrat)
- LM: Lagrange Multiplier (multiplicatorul Lagrange)
- LR: Likelihood Ratio (test) (testul raportului de verosimilitate)
- MCS: Model Confidence Set (mulțimea de modele de încredere)
- MLE: Maximum Likelihood Estimation (estimarea prin metoda verosimilității maxime)
- MZ: Mincer–Zarnowitz (regression) (regresia Mincer–Zarnowitz)
- PIT: Probability Integral Transform (transformarea integrală de probabilitate)

Acronime folosite în acest material (2/2)

- ▣ QLIKE: Quasi-LIKelihood (loss function) (funcția de pierdere de tip cvasi-verosimilitate)
- ▣ QMLE: Quasi-Maximum Likelihood Estimator (estimatorul de cvasi-verosimilitate maximă)
- ▣ QQ: Quantile-Quantile (plot) (graficul cuantilă-cuantilă)
- ▣ QSD: Quasi Score-Driven (model) (model bazat pe un cvasi-scor)
- ▣ SUA: Statele Unite ale Americii
- ▣ VIX: CBOE Volatility IndeX (indicele de volatilitate CBOE)

Întrebarea de azi și ce trebuie predat

- ▣ Întrebarea seminarului: **ne putem baza pe o volatilitate GARCH estimată, pe incertitudinea ei și pe prognozele ei?**
- ▣ Etapa 1
 - ▶ A1: recursia dispersiei și o prognoză pe 5 zile pe hârtie; B1: estimarea și diagnosticul GARCH-t; B2–B3: adăugăm asimetria, S&P 500, apoi BET; C2: verificarea unui răspuns A1
- ▣ Etapa 2
 - ▶ A3: incertitudinea volatilității de termen lung și a timpului de înjumătățire; B7: un bootstrap și un test la frontieră; B5: evaluarea prognozelor
- ▣ O singură întâlnire: A1, B1, B2, B3, C2 la seminar; A3, B7, B5 acasă
- ▣ Ce predați (lista de pe ultimul slide al părții obligatorii): răspunsurile A, câte o figură și un tabel pentru fiecare exercițiu B, codul C2 corectat, câte o propoziție de interpretare pentru fiecare exercițiu
- ▣ Notebook: [deschideți notebook-ul seminarului în Colab](#); fiecare cerință indică secțiunea din notebook

Harta exercițiilor

Exercițiu	Întrebare	Tip	Model
A1	cum se actualizează dispersia și care este riscul pe 5 zile?	Rezolvat	–
B1	se potrivește GARCH-t pentru S&P 500 și trec reziduurile verificările?	Rezolvat	–
B2	cresc știrile proaste mai mult volatilitatea S&P 500?	Rezolvat	–
B3	aceeași întrebare pentru BET	Propus	B2
C2	ce este greșit într-un răspuns A1?	Propus	A3, B1
A3	cât de precise sunt volatilitatea de termen lung și timpul de înjumătățire?	Rezolvat	–
B7	este $\alpha + \beta = 1$? un bootstrap și un test la frontieră	Rezolvat	–
B5	prognozează ceva mai bine decât GARCH-t?	Rezolvat	–
Temă	un exercițiu de transfer: B4, B6 sau B8	Propus	B1, B5, B7
Pachete de extensie	A2, A4, A5, A6, B5 extins, C1, C3 (opțional)	ambele	pe fiecare cerință

- **[Rezolvat]:** rezolvarea completă în slide-uri și în notebook, un model de urmat; **[Propus]:** îl rezolvați voi, rezolvarea se discută la seminar
- Partea A: derivări pe hârtie; Partea B: estimare și inferență pe date reale, fiecare cu o întrebare de interpretare; Partea C: întrebări deschise și critica unui răspuns A1

Datele folosite

Serie	Fișier, câmp	Eșantion	Calendar, filtru	Randamente
S&P 500	GSPC.INDX, close	2000-01-03 – 2026-09-18	zile lucrătoare; 3 închideri neschimbate eliminate	6 714
BET	BET, close	2000-01-05 – 2026-09-18	zile lucrătoare; 0 închideri neschimbate eliminate	6 670
Bitcoin	BTC-USD.CC, close	2014-09-17 – 2026-09-18	7 zile din 7, fără filtru	4 384
VIX	VIX.INDX, close	doar C3	zile lucrătoare	–
11 acțiuni SUA	<TICKER>.US, adjusted close	doar C3, 1995–2019	îmbinate cu VIX în zilele comune	–

- Fișiere: data/market/<SIMBOL>.csv, coloanele date, open, high, low, close, adjusted_close, volume; randamente $r_t = 100 (\ln P_t - \ln P_{t-1})$ în %, fiecare serie pe calendarul ei
- „Închideri neschimbate”: zile lucrătoare cu închiderea egală cu cea precedentă, adică sărbători completate cu ultimul preț; după filtru nu rămân valori lipsă
- Anualizare cu frecvența observată q : 251,4 (S&P 500), 249,8 (BET), 365,3 (Bitcoin) randamente pe an

Pregătire: rulați și verificați

```
# notebook section "Data" defines
# load_close(name) and pct_returns(name)
r = pct_returns('sp500')      # 100 * diff(log P)
print(len(r), r.index[0], r.index[-1])
print(r.head(3).round(4))

from arch import arch_model
res = arch_model(r, p=1, q=1,
                 dist='t').fit(dispatch='off')
print(res.params)
```

- Rezultat așteptat: 6 714 randamente, 2000-01-04 – 2026-09-18
- Primele trei randamente (%): -3,9099, 0,1920, 0,0955
- GARCH-t: $\hat{\alpha} = 0,1226$, $\hat{\beta} = 0,8721$, $\hat{\nu} = 6,26$
- Dacă un număr sau o valoare diferă, opriți-vă și verificați fișierul, câmpul, datele și filtrul
- Pachete: numpy, pandas, scipy, statsmodels, matplotlib, arch

Notăția folosită în toate exercițiile

- ▣ $r_t = \mu + \varepsilon_t$, $\varepsilon_t = \sigma_t z_t$, z_t i.i.d. cu media 0 și dispersia 1; $\mathcal{F}_t$: informația de la închiderea zilei t , $\mathbb{E}_t = \mathbb{E}[\cdot \mid \mathcal{F}_t]$
- ▣ GARCH(1,1) [Bollerslev \(1986\)](#): $\sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2 + \beta \sigma_{t-1}^2$; persistența $p = \alpha + \beta$; dispersia de termen lung $\bar{\sigma}^2 = \omega / (1 - p)$; timpul de înjumătățire $h_{1/2} = \ln 0,5 / \ln p$
- ▣ GJR [Glosten, Jagannathan & Runkle \(1993\)](#): adăugăm $\gamma I_{t-1} \varepsilon_{t-1}^2$, $I_{t-1} = 1(\varepsilon_{t-1} < 0)$; inovații Student-t cu ν grade de libertate, scalate la dispersia 1
- ▣ Reziduul standardizat $\hat{z}_t = \hat{\varepsilon}_t / \hat{\sigma}_t$; $LR = 2(\ell_1 - \ell_0)$; $AIC = -2\ell + 2k$, $BIC = -2\ell + k \ln n$ (k parametri)
- ▣ Prognoza h_t a dispersiei zilei t , făcută la închiderea zilei $t - 1$; pierderea QLIKE $= r_t^2 / h_t + \ln h_t$ [Patton \(2011\)](#)
- ▣ Un exemplu: $\omega = 0,05$, $\alpha = 0,10$, $\beta = 0,85$, $\varepsilon_{t-1} = 2$, $\sigma_{t-1}^2 = 1$: $\sigma_t^2 = 0,05 + 0,40 + 0,85 = 1,30$

A1 [Rezolvat]: recursia dispersiei — cerința (1/2)

- ▣ **Întrebarea:** cum transformă GARCH(1,1) patru șocuri în patru dispersii zilnice?
- ▣ **Date:** $\omega = 0,05$, $\alpha = 0,10$, $\beta = 0,85$ (randamente în %); pornire $\sigma_1^2 = \bar{\sigma}^2$; șocurile $\varepsilon_1, \dots, \varepsilon_4 = -2,0, 0,5, 3,0, -1,0$; fără fișier de date
- ▣ **Cerințe**
 1. Calculați persistența p și dispersia de termen lung $\bar{\sigma}^2 = \omega/(1-p)$.
 2. Completați tabelul de mai jos rând cu rând: termenul de știri $\alpha\varepsilon_{t-1}^2$, termenul de memorie $\beta\sigma_{t-1}^2$ și σ_t^2 pentru $t = 2, \dots, 5$.
 3. Spuneți care șoc mișcă cel mai mult dispersia și de ce dispersia zilei 5 este cunoscută la închiderea zilei 4.
- ▣ **Raportați:** tabelul completat și o propoziție
- ▣ Notebook: secțiunea A1

t	ε_{t-1}	$\alpha\varepsilon_{t-1}^2$	$\beta\sigma_{t-1}^2$	σ_t^2
1	—	—	—	1,0000
2	-2,0	0,4000	0,8500	1,3000
3	0,5	...	...	...
4	3,0	...	...	...
5	-1,0	...	...	...



A1 [Rezolvat]: rezolvare (1/2) — dispersiile filtrate

t	ε_{t-1}	$\alpha \varepsilon_{t-1}^2$	$\beta \sigma_{t-1}^2$	σ_t^2
1	—	—	—	1,0000
2	-2,0	0,4000	0,8500	1,3000
3	0,5	0,0250	1,1050	1,1800
4	3,0	0,9000	1,0030	1,9530
5	-1,0	0,1000	1,6600	1,8100

- $p = 0,95$, $\bar{\sigma}^2 = 0,05/0,05 = 1$; fiecare rând adaugă $\omega = 0,05$ celor doi termeni
- Rândul 2: $0,05 + 0,10 \times 4 + 0,85 \times 1 = 1,3000$

- Șocul de +3% adaugă 0,90: dispersia sare la 1,9530 în ziua 4 și apoi scade cu factorul β
- σ_5^2 folosește doar ε_4 și σ_4^2 , ambele cunoscute la închiderea zilei 4: prognoza pe un pas este exactă în model
- Interpretare: semnul nu contează, mărimea da; un singur șoc mare crește dispersia multe zile

A1 [Rezolvat]: recursia într-un grafic



■ Negative shock ε_t
■ Positive shock ε_t
● Filtered variance σ_t^2
---- Long-run variance $\bar{\sigma}^2 = 1$

- Fiecare bară este un șoc; fiecare punct este dispersia pe care o produce a doua zi; σ_5^2 este prognoza pe un pas făcută la închiderea zilei 4


A1 [Rezolvat]: prognoza din ziua 4 — cerința (2/2)

- ▣ **Întrebarea:** care este dispersia pe 5 zile după aceste șocuri și este corectă regula rădăcinii pătrate a timpului?
- ▣ **Date:** modelul și $\sigma_5^2 = 1,8100$ din cerința 1; originea prognozei: închiderea zilei 4
- ▣ **Cerințe**
 1. Aplicați $\mathbb{E}_4$ recursiei și folosiți $\mathbb{E}_4 \varepsilon_t^2 = \mathbb{E}_4 \sigma_t^2$ pentru $t \geq 5$ pentru a deduce $\mathbb{E}_4 \sigma_{4+h}^2 = \bar{\sigma}^2 + p^{h-1}(\sigma_5^2 - \bar{\sigma}^2)$.
 2. Calculați cele cinci prognoze pentru $h = 1, \dots, 5$.
 3. Explicați de ce dispersia randamentului pe 5 zile este suma $V_5 = \sum_{h=1}^5 \mathbb{E}_4 \sigma_{4+h}^2$ (indiciu: ε_t sunt necorelate, o diferență de martingală) și calculați V_5 și $\sqrt{V_5}$.
 4. Comparați V_5 cu $5\sigma_5^2$ și deduceți semnul lui $V_H - H\sigma_5^2$ în funcție de $\sigma_5^2 - \bar{\sigma}^2$.
 5. Calculați timpul de înjumătățire $\ln 0,5 / \ln p$.
- ▣ **Raportați:** formula prognozei, cele cinci prognoze, V_5 și $\sqrt{V_5}$, timpul de înjumătățire; interpretare: după un șoc de +3%, regula rădăcinii pătrate a timpului supraestimează sau subestimează riscul pe 5 zile?
- ▣ Notebook: secțiunea A1

A1 [Rezolvat]: rezolvare (2/2) — prognoze și riscul pe cinci zile

- Derivare: $\mathbb{E}_4 \sigma_{4+h}^2 = \omega + p \mathbb{E}_4 \sigma_{4+h-1}^2$; scădem $\bar{\sigma}^2 = \omega + p \bar{\sigma}^2$: distanța scade cu p pe zi, pornind de la σ_5^2 , cunoscută
- Distanța 0,8101; prognoze 1,8100, 1,7695, 1,7311, 1,6945, 1,6598; $V_5 = 5 + 0,8101 \times (1 - 0,95^5)/0,05 = 8,665$, $\sqrt{V_5} = 2,944\%$; timp de înjumătățire $-0,6931/(-0,0513) = 13,5$ zile
- $V_H - H\sigma_5^2 = (\bar{\sigma}^2 - \sigma_5^2) \sum_{j < H} (1 - p^j)$: aici $5\sigma_5^2 = 9,050 > V_5$. Interpretare: după turbulență regula supraestimează riscul pe 5 zile, în perioade calme îl subestimează, deoarece dispersia revine la $\bar{\sigma}^2$

A1 [Rezolvat]: prognozele și riscul pe cinci zile într-un grafic



□ Stânga: prognozele converg spre $\bar{\sigma}^2 = 1$; dreapta: V_H rămâne sub $H\bar{\sigma}_5^2$ deoarece dispersia revine la medie

B1 [Rezolvat]: GARCH-t pe S&P 500 — cerința (1/2)

- **Întrebarea:** există grupare de modelat și ce spune despre ea o estimare GARCH(1,1)-t?
- **Date:** S&P 500, 6 714 randamente zilnice (Datele folosite); media $r_t = \mu + \varepsilon_t$, inovații Student-t
- **Cerințe**
 1. Testați H_0 : fără efecte ARCH cu Ljung–Box $Q(10)$ pe r_t^2 și testul LM al lui Engle cu 5 decalaje pe $r_t - \bar{r}$, la 5%.
 2. Estimați GARCH(1,1)-t prin verosimilitate maximă și verificați convergența optimizatorului.
 3. Raportați fiecare parametru cu eroarea standard robustă Bollerslev & Wooldridge (1992) și clasică și reprezentați r_t cu benzile $\pm 2\hat{\sigma}_t$.
- **Raportați:** cele două decizii de test, tabelul estimărilor, graficul
- Notebook: secțiunea B1


```
from arch import arch_model
am = arch_model(r, mean='Constant',
                vol='GARCH', p=1, q=1,
                dist='t')
res = am.fit(dispatch='off')
print(res.convergence_flag) # 0 = ok
rob = res.std_err           # robust
cl = am.fit(dispatch='off',
            cov_type='classic').std_err
sig = res.conditional_volatility
```

B1 [Rezolvat]: rezolvare (1/2) — teste, estimări, ajustare

Parametru	Estimare	E.s. robustă	E.s. clasică
μ	0,0788	0,0089	0,0090
ω	0,0157	0,0032	0,0029
α	0,1226	0,0107	0,0101
β	0,8721	0,0103	0,0096
ν	6,26	0,48	0,48

- (1) $Q(10) = 6133$ și $LM(5) = 1684$ față de 18,3 și 11,1: absența efectelor ARCH este respinsă ($p < 0,001$)
- (2) Convergență după 14 iterații, $\ell = -9062,5$; persistența 0,9947
- (3) Rapoartele robust/clasic 1,06 (α), 1,08 (β): densitatea Student-t este ea însăși greșit specificată (asimetrie -0,58); estimatorul sandwich acoperă asta

B1 [Rezolvat]: volatilitatea estimată



□ Interpretare: $\hat{\beta}$ preia dispersia de ieri, $\hat{\alpha}$ adaugă știrile, $\hat{\nu}$ semnalează cozi groase; 5,1% din zile cad în afara benzii $\pm 2\hat{\sigma}_t$

B1 [Rezolvat]: diagnosticul reziduurilor — cerința (2/2)




- ▣ **Întrebarea:** lasă GARCH-t estimat vreo structură în $\hat{z}_t = (r_t - \hat{\mu})/\hat{\sigma}_t$?
- ▣ **Date:** estimarea din cerința 1; fiecare test are H_0 : modelul surprinde acea proprietate
- ▣ **Cerințe**
 1. Testați ecuația mediei cu Ljung–Box $Q(10)$ pe $\hat{z}_t$ (H_0 : fără autocorelație până la decalajul 10).
 2. Testați ecuația dispersiei cu $Q(10)$ pe $\hat{z}_t^2$ și testul LM(5) (H_0 : fără grupare rămasă).
 3. Estimați regresia de asimetrie [Engle & Ng \(1993\)](#) $\hat{z}_t^2 = b_0 + b_1 S_{t-1}^- + b_2 S_{t-1}^- \hat{e}_{t-1} + b_3 S_{t-1}^+ \hat{e}_{t-1}$, cu $S_{t-1}^- = 1(\hat{e}_{t-1} < 0)$ și $S^+ = 1 - S^-$; raportați cele trei statistici t și testul comun $nR^2 \sim \chi_3^2$ (H_0 : fără asimetrie rămasă).
 4. Reprezentați ACF pentru $\hat{z}_t$ și $\hat{z}_t^2$ și un grafic QQ al lui $\hat{z}_t$ față de distribuția Student-t standardizată estimată.
- ▣ **Raportați:** un tabel cu statistica, valoarea p și decizia pentru fiecare test și cele trei grafice; interpretare: ce parte a modelului nu trece verificarea și ce ați schimba întâi?
- ▣ Notebook: secțiunea B1

B1 [Rezolvat]: rezolvare (2/2) — diagnostic

Partea	Test	p	Decizia la 5%
Media	$Q(10)$, $\hat{z}$: 21,9	0,016	respins
Dispersia	$Q(10)$, $\hat{z}^2$: 13,6	0,192	nerespins
	$LM(5)$: 5,8	0,326	nerespins
Asimetria	comun χ^2_3 : 40,7	$< 0,001$	respins

- Asimetria de semn $t = 3,56$, mărime negativă $t = 1,13$, mărime pozitivă $t = -2,61$
- QQ: 16 reziduuri sub -4 , față de 8,5 așteptate; coada stângă este mai lungă decât cea a distribuției t estimate

B1 [Rezolvat]: ACF ale reziduurilor și graficul QQ



±1.96/√n
ACF of $\hat{z}_t$ (mean equation)
ACF of $\hat{z}_t^2$ (variance equation)
• $\hat{z}_t$ vs fitted Student-t, $\hat{\nu} = 6.26$

- ☐ Toate valorile p folosesc legile χ^2 naive, aproximative cu parametri estimați Li & Mak (1994). Interpretare: gruparea este surprinsă, asimetria nu: adăugăm un termen de semn (B2)

B2 [Rezolvat]: GJR față de GARCH pe S&P 500 — cerința


- ▣ **Întrebarea:** cresc știrile proaste volatilitatea S&P 500 mai mult decât cele bune și cu cât?
- ▣ **Date:** datele din B1; `arch_model(r, p=1, o=1, q=1, dist='t')` estimează GJR-GARCH(1,1)-t, care include GARCH-t pentru $\gamma = 0$; impactul știrilor la $\sigma_{t-1}^2 =$ dispersia de selecție 1,47
- ▣ **Cerințe**
 1. Estimați GJR-GARCH(1,1)-t și raportați $\hat{\alpha}$, $\hat{\gamma}$ cu t robust și $\hat{\beta}$.
 2. Construiți tabelul de comparație: numărul de parametri k , ℓ , AIC, BIC pentru GARCH-t și GJR-t.
 3. Testați $H_0: \gamma = 0$ cu $LR = 2(\ell_{GJR} - \ell_{GARCH})$ față de χ_1^2 și precizați ipotezele din spatele acestei legi.
 4. Calculați dispersia de a doua zi după șocuri de -3% și $+3\%$ în ambele modele și reprezentați cele două curbe de impact al știrilor.
- ▣ **Raportați:** estimările, tabelul de comparație, decizia LR și graficul impactului știrilor; interpretare: de ce este $\hat{\alpha} = 0$ și ce efect are asupra legii χ_1^2 ?
- ▣ Notebook: secțiunea B2

B2 [Rezolvat]: rezolvare (1/2) — comparația modelelor imbricate

Model	k	ℓ	AIC	BIC
GARCH(1,1)-t	5	-9062,473	18134,9	18169,0
GJR-GARCH(1,1)-t	6	-8944,647	17901,3	17942,2

- (1) $\hat{\alpha} = 0,000$, $\hat{\gamma} = 0,205$ ($t_{\text{robust}} = 10,03$), $\hat{\beta} = 0,881$, $\hat{\omega} = 0,0187$, $\hat{\nu} = 6,96$: panta știrilor bune $\hat{\alpha}$, a celor proaste $\hat{\alpha} + \hat{\gamma}$
- (2) $\Delta\text{AIC} = -233,7$, $\Delta\text{BIC} = -226,8$ (GJR minus GARCH): ambele preferă GJR
- (3) $LR = 2(-8944,647 - (-9062,473)) = 235,65$, mult peste 3,84
- Ipotezele legii χ^2_1 : o densitate Student-t corectă și toți ceilalți parametri interiori
 - Ambele sunt îndoielnice aici: B1 a găsit asimetrie, iar $\hat{\alpha} = 0$ este la limita $\alpha \geq 0$, deci legea este nestandard [Andrews \(2001\)](#)
 - Concluzie nuanțată: un LR de 235,65 este de circa 60 de ori valoarea critică la 5%; o verificare calibrată ar simula LR sub GARCH-t estimat (cum face B7 pentru IGARCH)

B2 [Rezolvat]: rezolvare (2/2) — impactul știrilor



- (4) S&P 500, GJR: -3% dă 3,16, $+3\%$ dă 1,31 (de 2,40 ori mai puțin); GARCH: 2,40 pentru ambele semne
- Cu $\hat{\alpha} = 0$ un șoc de $+3\%$ chiar scade dispersia, de la 1,47 la 1,31. Interpretare: la S&P 500, doar știrile proaste cresc dispersia de mâine; panoul BET este B3

B3 [Propus]: GJR față de GARCH pe BET — cerința

- ▣ **Întrebarea:** este asimetria bursei de la București la fel de puternică precum cea a S&P 500?
- ▣ **Date:** BET, 6 670 randamente zilnice (Datele folosite); aceleași două modele și același cod ca în B2; $\ln n = 8,81$
- ▣ **Cerințe**
 1. Estimați ambele modele și completați tabelul de comparație din B2 (k , ℓ , AIC, BIC) pentru BET.
 2. Calculați LR și comparați-l cu cele patru praguri: 2 (AIC), 3,84 și 6,63 (χ^2_1 la 5% și 1%) și $\ln n$ (BIC); precizați fiecare decizie.
 3. Calculați impactul știrilor pentru BET la $\pm 3\%$ pornind de la dispersia de selecție, ca în B2.
- ▣ **Raportați:** tabelul, cele patru decizii, cele două valori de impact; interpretare: de ce pot fi LR și BIC în dezacord și dovedește un $\hat{\gamma}$ mai mic că BET este mai puțin asimetric decât S&P 500?
- ▣ Model: B2
- ▣ Notebook: secțiunea B3

C2 [Propus]: critica unui răspuns AI — cerința

- ▣ **Cererea:** „px conține închiderile zilnice S&P 500. Estimează un GARCH(1,1) cu inovații Student-*t* cu arch și dă-mi volatilitatea anualizată de termen lung și timpul de înjumătățire al unui șoc.”
- ▣ **Date:** px = load_close('sp500'), 6 715 închideri, 2000-01-03 – 2026-09-18
- ▣ **Rezultatul răspunsului:** ann_vol = 66,46, half_life = 0,74 zile și un DataScaleWarning
- ▣ **Cerințe**
 1. Rulați codul și reproduceți rezultatul.
 2. Găsiți erorile de formulă, erorile de unitate și riscurile numerice, fiecare cu numărul liniei.
 3. Pentru fiecare, dați dovada care o expune (un avertisment, o cifră din A3 sau B1) și linia corectată.
 4. Rulați codul corectat și notați fiecare eroare ca în AI_ERRORS.md.
- ▣ **Model:** A3, B1

```
1 import numpy as np
2 from arch import arch_model
3 r = np.log(px).diff().dropna()
4 am = arch_model(r, vol='GARCH', p=1,
5                 q=1, dist='t')
6 res = am.fit(disp='off')
7 om = res.params['omega']
8 a = res.params['alpha[1]']
9 b = res.params['beta[1]']
10 lr_var = om / (1 - a - b)
11 ann_vol = lr_var * 252
12 half_life = np.log(0.5) / np.log(b)
```

A3 [Rezolvat]: volatilitatea de termen lung și timpul de înjumătățire — cerința


- **Întrebarea:** cât de precis determină estimarea din B1 volatilitatea de termen lung și timpul de înjumătățire?
- **Date:** B1: $\hat{\omega} = 0,015714$, $\hat{\alpha} = 0,122573$, $\hat{\beta} = 0,872139$, $q = 251,4$; covarianța robustă a lui $(\hat{\omega}, \hat{\alpha}, \hat{\beta})$, în această ordine:

$$\hat{V} = \begin{pmatrix} 1,001 \times 10^{-5} & 1,421 \times 10^{-5} & -2,242 \times 10^{-5} \\ \cdot & 1,153 \times 10^{-4} & -1,002 \times 10^{-4} \\ \cdot & \cdot & 1,069 \times 10^{-4} \end{pmatrix} \text{ (res.param_cov)}$$
- **Cerințe**
 1. Deduceți $\bar{\sigma}^2 = \omega / (1 - \alpha - \beta)$ din recursie și calculați volatilitatea anuală de termen lung $v = \sqrt{q \bar{\sigma}^2}$ și timpul de înjumătățire.
 2. Calculați $\nabla \bar{\sigma}^2$, forma pătratică $\nabla' \hat{V} \nabla$ și, cu $\partial v / \partial \bar{\sigma}^2 = q / (2v)$, eroarea standard a lui v .
 3. Calculați $\widehat{e.s.}(\hat{p})$ din $\hat{V}$ și eroarea standard prin metoda delta a lui $h(p) = \ln 0,5 / \ln p$, definită pentru $0 < p < 1$.
 4. Transformați intervalul de 95% pentru p într-un interval pentru h și spuneți ce se întâmplă când depășește 1.
- **Raportați:** v cu e.s., h cu e.s. și intervalul transformat; interpretare: de ce eșuează liniarizarea pentru h ?
- **Notebook:** secțiunea A3

A3 [Rezolvat]: rezolvare — gradienti și intervalul timpului de înjumătățire

- (1) $\hat{p} = 0,994712$, $\hat{\sigma}^2 = 2,972$, $v = 1,724 \times \sqrt{251,4} = 27,3\%$ (în eșantion: 19,2%); $h = -0,6931/(-0,005302) = 130,7$ zile
- (2) $\nabla \hat{\sigma}^2 = (1/(1-p), \omega/(1-p)^2, \omega/(1-p)^2) = (189,1, 562,0, 562,0)$; $\widehat{e.s.}(\hat{\sigma}^2) = 2,35$; $\widehat{e.s.}(v) = 10,8$ puncte în jurul a 27,3%
- (3) $\widehat{e.s.}(\hat{p}) = \sqrt{V_{\alpha\alpha} + 2V_{\alpha\beta} + V_{\beta\beta}} = 0,0047$; $\partial h / \partial p = 24\,789$, deci $\widehat{e.s.}(\hat{h}) = 116$ zile
- (4) $[0,9855; 1,0039]$ depășește 1: $h \in [48; \infty)$, fără limită superioară finită în modelul staționar. Interpretare: $h(p)$ este atât de curbată lângă 1 încât tangenta ei nu are sens; întrebarea $p = 1$ cere un test (B7)

A3 [Rezolvat]: curba timpului de înjumătățire




- Tangenta (metoda delta) trece prin zero în interiorul intervalului pentru p ; transformarea exactă $h(p)$ nu are capăt superior finit

B7 [Rezolvat]: este $\alpha + \beta = 1$? bootstrap și test la frontieră — cerința


- ▣ **Întrebarea:** cât de variabil este $\hat{p} = \hat{\alpha} + \hat{\beta}$ și poate dispersia S&P 500 să aibă o rădăcină unitară?
- ▣ **Date:** estimarea B1, $\hat{p} = 0,9947$; cod `param_bootstrap`, `igarch_test` (notebook); valoare de inițializare 42 (43 sub H_0); fiecare traiectorie: 6 714 zile după 500 de zile eliminate, pornind de la dispersia de selecție; fiecare estimare impune $\alpha + \beta \leq 1$ și păstrează cea mai bună din două puncte de pornire
- ▣ **Cerințe**
 1. Algoritmul 1 (variabilitatea estimatorului): simulați $B = 999$ traiectorii din GARCH-t **estimat**, reestimați p pe fiecare și raportați percentilele de 2,5% și 97,5% și proporția extragerilor la $p = 1$.
 2. Algoritmul 2 (test): estimați IGARCH-t ($\alpha + \beta = 1$), calculați $LR = 2(\ell_{GARCH} - \ell_{IGARCH})$, simulați B traiectorii **sub** H_0 , reestimați ambele modele pe fiecare și calculați $p = (1 + \#\{LR^* \geq LR\})/(B + 1)$.
 3. Comparați această valoare p cu valorile din χ_1^2 și $\frac{1}{2}\chi_0^2 + \frac{1}{2}\chi_1^2$ și decideți la 5% și 10%.
- ▣ **Raportați:** două histograme, intervalul, trei valori p și decizia; interpretare: de ce „intervalul bazat pe percentile atinge 1” nu este un test pentru $p = 1$ [Andrews \(2000\)](#)?
- ▣ Notebook: secțiunea B7

B7 [Rezolvat]: rezolvare (1/2) — variabilitatea estimatorului



- Interval de 95% bazat pe percentile [0,9833; 1,0000]; abaterea standard bootstrap 0,0047 față de e.s. robustă 0,0047: apropiate; 8,9% din extrageri sunt exact la limita $p = 1$
- Timpul de înjumătățire de la 41 zile la ∞ (metoda delta: 116 zile, A3). Interpretare: lângă o limită intervalul bazat pe percentile descrie dispersia, nu este automat un interval de încredere valid [Andrews \(2000\)](#)

B7 [Rezolvat]: rezolvare (2/2) — testul sub ipoteza nulă




- IGARCH-t: $\hat{\alpha}_0 = 0,127$, $\hat{\nu}_0 = 6,03$;
 $LR = 1,11$; $LR^* = 0$ pentru 44,2% din extrageri (aproape de jumătatea prezisă de amestec); 174 din 999 extrageri depășesc LR
- $p = 0,17$ (bootstrap), 0,15 (amestec), 0,29 (χ_1^2 naiv): H_0 nu este respinsă nici la 5%, nici la 10%. Interpretare: 27 de ani nu pot deosebi un timp de înjumătățire de circa 130 de zile de unul infinit

B5 [Rezolvat]: compararea prognozelor pe S&P 500 — cerința (1/2)

- ▣ **Întrebarea:** prognozează vreun model dispersia de mâine a S&P 500 mai bine decât GARCH-t?
- ▣ **Date:** 2692 zile de prognoză, 2016-01-04 – 2026-09-18; GARCH-N, GARCH-t, GJR-t, EGARCH-t reestimate în fiecare ianuarie (fereastră în expansiune); EWMA ($\lambda = 0,94$) [J.P. Morgan/Reuters \(1996\)](#); Hist-20 (media ultimelor 20 de r_t^2); aproximarea r_t^2
- ▣ **Cerințe**
 1. Pe graficul cronologic, verificați că h_t folosește doar date până la închiderea zilei $t - 1$ și că parametrii sunt ficși în cursul unui an.
 2. Calculați QLIKE = $r_t^2/h_t + \ln h_t$ pas cu pas pentru GARCH-t și EWMA pe 2020-03-13, 2020-03-16 și 2020-03-17 (tabelul de mai jos).
 3. Calculați QLIKE mediu pentru toate cele șase modele și t DM pentru $d_t = L_t^m - L_t^{GARCH-t}$ (HAC, 5 decalaje) [Diebold & Mariano \(1995\)](#); reprezentați $\sum d_t$ cumulat.
- ▣ **Raportați:** cele trei rânduri QLIKE, un tabel cu QLIKE mediu și t DM, graficul pierderilor; interpretare: ce diferențe pot fi citite ca semnificative?
- ▣ Notebook: secțiunea B5

Ziua	r_t	r_t^2	h_t GARCH-t	h_t EWMA	QLIKE
2020-03-13	8,88	78,87	25,38	15,66	...
2020-03-16	-12,77	162,95	31,18	19,45	...
2020-03-17	5,82	33,90	46,06	28,06	...



B5 [Rezolvat]: rezolvare (1/3) — momentul prognozei și QLIKE pas cu pas



Ziua	L GARCH-t	L EWMA
2020-03-13	6,342	7,789
2020-03-16	8,666	11,346
2020-03-17	4,566	4,543

- de ex. 2020-03-16:
 $162,95/31,18 + \ln 31,18 = 8,666$; prognoza EWMA este mai mică, deci pierderea este mai mare: subestimarea este penalizată
- Prima țintă 2016-01-04, originea 2015-12-31: reestimare pe datele până la 31 decembrie, fără look-ahead (informație din viitor)

B5 [Rezolvat]: rezolvare (2/3) — diferențele de pierderi




— GARCH-N minus GARCH-t — GJR-t minus GARCH-t — EGARCH-t minus GARCH-t — EWMA minus GARCH-t — Hist-20 minus GARCH-t

- QLIKE mediu: GJR-t 0,7319, GARCH-t 0,7570; EWMA ($t_{DM} = 3,48$) și Hist-20 ($t = 4,10$) sunt mai slabe, diferența lor crește în martie 2020; t din familia GARCH sunt descriptive (modele imbricate, fereastră în expansiune: B5 extins)

B5 [Rezolvat]: calibrarea — cerința (2/2)

- ▣ **Întrebarea:** sunt prognozele GARCH-t nedepasate în niveluri și ce zile determină răspunsul?
- ▣ **Date:** cele 2 692 perechi (h_t, r_t^2) din cerința 1
- ▣ **Cerințe**
 1. Estimați regresia Mincer–Zarnowitz $r_t^2 = a + b h_t + u_t$ Mincer & Zarnowitz (1969) cu erori HAC (5 decalaje) și testați comun $a = 0$, $b = 1$.
 2. Reprezentați r_t^2 față de h_t , cu dreapta estimată și dreapta de 45 de grade, și o vedere pe 20 de grupe de h_t .
 3. Reestimați fără cele mai mari trei valori r_t^2 și comparați b .
- ▣ **Raportați:** a , b cu e.s., R^2 , p Wald, graficul, b fără cele trei zile; interpretare: este un R^2 mic semnul unei prognoze proaste?
- ▣ Notebook: secțiunea B5

B5 [Rezolvat]: rezolvare (3/3) — calibrarea



- $a = 0,08$ (e.s. 0,24), $b = 0,88$ (e.s. 0,25), $R^2 = 0,238$, p Wald = 0,804: nedeplasarea nu este respinsă; mediile pe grupe sunt aproape de dreapta de 45 de grade
- Fără 2020-03-16, 2020-03-12, 2025-04-09: $b = 0,64$ (e.s. 0,09), p Wald < 0,001. Interpretare: trei zile de criză determină regresia în niveluri; R^2 mic reflectă aproximarea zgomotoasă r_t^2 , nu un model prost [Patton \(2011\)](#)

Temă de transfer: alegeți B4, B6 sau B8

- ▣ Alegeți un exercițiu din pachetele de extensie și rezolvați-l cu codul modelului său
 - ▶ B4: distribuțiile inovațiilor pentru Bitcoin (model: B1, B2); B6: compararea prognozelor pe BET (model: B5); B8: bootstrap și testul IGARCH pe BET (model: B7)
- ▣ Livrabil: un folder Quantlet (cod, Metainfo.txt, un grafic) și două slide-uri
 - ▶ Slide-ul 1: tabelul și graficul cerute; slide-ul 2: răspunsul la întrebarea de interpretare și o limită
- ▣ Evaluare (10 puncte)
 - ▶ Reproducibilitate (3): notebook-ul rulează de la început la sfârșit și reproduce fiecare cifră raportată
 - ▶ Inferență corectă (4): legea nulă potrivită (frontieră, modele imbricate), incertitudinea raportată pentru fiecare estimare
 - ▶ Interpretare (3): o afirmație susținută de cifre, cu limita ei
- ▣ Utilizarea AI este permisă și declarată în AI_USE.md; documentați în AI_ERRORS.md erorile pe care le-ați găsit efectiv (fără un număr minim)

Lista de predare și verificarea finală

Predați

- ▣ A1: tabelul, cele cinci prognoze, V_5 și o propoziție
- ▣ B1–B3: tabelele estimărilor, deciziile de diagnostic, cele două grafice de impact al știrilor
- ▣ C2: tabelul erorilor și codul corectat cu rezultatul lui
- ▣ A3, B7, B5: intervalele, cele trei valori p , graficele pierderilor și calibrării
- ▣ Câte o propoziție de interpretare pentru fiecare exercițiu

Verificare finală (răspuns în două rânduri)

- ▣ O concluzie justificată: ce model ați folosi pentru S&P 500 și de ce?
- ▣ O limită nerezolvată: ce nu pot decide datele (de ex. $p = 1$)?
- ▣ Seminar: Drd. Antoaneta Amza, antoaneta.amza@csie.ase.ro

Pachetele de extensie: ce cere fiecare

Exercițiu	Întrebare	Tip	Model
A2	persistența GJR când inovațiile sunt asimetrice	Propus	A1
A4	este momentul de ordin patru finit?	Propus	A1, A3
A5	dispersia robustă și clasică a QMLE Gaussian	Propus	A3
A6	autocorelația pătratelor șocurilor	Propus	A1
B4	distribuțiile inovațiilor pentru Bitcoin	Propus	B1, B2
B5 extins	Giacomini–White și Model Confidence Set	Rezolvat	–
B6	compararea prognozelor pe BET	Propus	B5
B8	bootstrap și testul IGARCH pe BET	Propus	B7
C1	determină știrile din SUA volatilitatea BET? (proiect)	Propus	B1, B2
C3	GARCH bazat pe un cvasi-scor pe acțiuni americane (proiect)	Propus	B1, B2

- Fiecare pachet are același format: întrebare, date, cerințe numerotate, ce se raportează; rezolvările exercițiilor propuse se discută la seminar

A2 [Propus]: persistența GJR cu inovații asimetrice — cerința

- ▣ **Întrebarea:** care este persistența GJR-GARCH când z_t este asimetric?
- ▣ **Date:** S&P 500, GJR-GARCH(1,1) cu inovații t asimetrice Hansen [Hansen \(1994\)](#): $\hat{\alpha} = 0,00000$, $\hat{\gamma} = 0,21116$, $\hat{\beta} = 0,87965$, $\hat{\eta} = 7,70$, $\hat{\lambda} = -0,150$; densitatea standardizată este `SkewStudent().loglikelihood` din `arch`
- ▣ **Cerințe**
 1. Aplicați speranța matematică în recursie și arătați că persistența este $\alpha + \gamma m_- + \beta$, cu $m_- = \mathbb{E}[z_t^2 1(z_t < 0)]$.
 2. Arătați că $m_- = 1/2$ pentru z_t simetric și explicați de ce m_- diferă în general de $P(z_t < 0)$.
 3. Integrați numeric `quad(f, -inf, 0)` și `quad(lambda z: z**2*f(z), -inf, 0)`; verificați $\int f = 1$ și $\int z^2 f = 1$ pe toată axa.
 4. Calculați persistența și timpul de înjumătățire cu m_- și cu $1/2$.
- ▣ **Raportați:** m_- , $P(z < 0)$, ambele persistențe și ambii timpi de înjumătățire; interpretare: ce se întâmplă dacă se folosește $\alpha + \gamma/2 + \beta$ cu inovații asimetrice?
- ▣ Model: A1
- ▣ Notebook: secțiunea A2

A4 [Propus]: este momentul de ordin patru finit? — cerința

- ▣ **Întrebarea:** au modelele estimate pentru S&P 500 o aplatizare finită și o poate valida aplatizarea de selecție?
- ▣ **Date:** GARCH-N: $\hat{\alpha} = 0,120604$, $\hat{\beta} = 0,859878$; GARCH-t: $\hat{\alpha} = 0,1226$, $\hat{\beta} = 0,8721$, $\hat{\nu} = 6,256$; aplatizarea de selecție a randamentelor 13,7 (totală, nu exces)
- ▣ **Cerințe**
 1. Arătați că $\mathbb{E}\varepsilon_t^4 = \kappa_z \mathbb{E}\sigma_t^4$ și $\mathbb{E}\sigma_t^4 < \infty$ dacă și numai dacă $\mathbb{E}(\alpha z_t^2 + \beta)^2 = (\alpha + \beta)^2 + (\kappa_z - 1)\alpha^2 < 1$.
 2. Pentru GARCH-N ($\kappa_z = 3$) calculați condiția și aplatizarea totală $K = 3[1 - (\alpha + \beta)^2]/[1 - (\alpha + \beta)^2 - 2\alpha^2]$, cu numitorul afișat; repetați cu estimările rotunjite la 3 zecimale.
 3. Pentru GARCH-t calculați $\kappa_z = 3(\nu - 2)/(\nu - 4)$ și condiția.
- ▣ **Raportați:** un rând pentru fiecare model: κ_z , condiția, finit sau nu, K ; interpretare: este concordanța cu aplatizarea de selecție un test al modelului?
- ▣ Model: A1, A3
- ▣ Notebook: secțiunea A4

A5 [Propus]: dispersia robustă și clasică, ARCH(1) — cerința

- ▣ **Întrebarea:** cu cât greșește inversa hessianei dispersia QMLE Gaussian când z_t nu este Normal?
- ▣ **Date:** ARCH(1), $\sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2$, ω cunoscut; $\ell_t = -\frac{1}{2}(\ln \sigma_t^2 + \varepsilon_t^2/\sigma_t^2)$; $x_t = \varepsilon_{t-1}^2/\sigma_t^2$ este cunoscut la $t-1$ și independent de z_t ; identități $\partial \sigma_t^2/\partial \alpha = \varepsilon_{t-1}^2$, $\varepsilon_t^2/\sigma_t^2 = z_t^2$
- ▣ **Cerințe**
 1. Arătați că scorul este $s_t = \frac{1}{2}(z_t^2 - 1)x_t$ și că $B = \mathbb{E}s_t^2 = \frac{1}{4}(\kappa_z - 1)\mathbb{E}x_t^2$.
 2. Arătați că $\partial^2 \ell_t/\partial \alpha^2 = \frac{1}{2}x_t^2(1 - 2z_t^2)$ și $A = \frac{1}{2}\mathbb{E}x_t^2$.
 3. Arătați că dispersia asimptotică a lui $\sqrt{n}(\hat{\alpha} - \alpha)$ este $A^{-1}BA^{-1} = \frac{\kappa_z - 1}{2}A^{-1}$; dispersia în eșantion finit o împarte la n .
 4. Calculați raportul e.s. $\sqrt{(\kappa_z - 1)/2}$ pentru Student-t cu $\nu = 6,26$ și pentru $\hat{\kappa}_z = 4,73$.
- ▣ **Raportați:** s_t , A , B , raportul, două cifre; interpretare: ce se întâmplă cu teoria în $\sqrt{n}$ când $\kappa_z = \infty$?
- ▣ Model: A3
- ▣ Notebook: secțiunea A5

A6 [Propus]: autocorelația pătratelor șocurilor — cerința

- ▣ **Întrebarea:** se potrivește ACF a lui r_t^2 implicată de GARCH-N cu datele și cât de precisă este ACF de selecție?
- ▣ **Date:** forma ARMA(1,1) $\varepsilon_t^2 = \omega + (\alpha + \beta)\varepsilon_{t-1}^2 + \nu_t - \beta\nu_{t-1}$ (curs); ARMA(1,1): $\rho_1 = (1 + \phi\theta)(\phi + \theta)/(1 + 2\phi\theta + \theta^2)$, $\rho_k = \phi^{k-1}\rho_1$; S&P 500 GARCH-N: $\hat{\omega} = 0,0254$, $\hat{\alpha} = 0,1206$, $\hat{\beta} = 0,8599$
- ▣ **Cerințe**
 1. Înlocuiți $\phi = \alpha + \beta$, $\theta = -\beta$ și deduceți $\rho_1(\varepsilon^2)$.
 2. Calculați ρ_1 , ρ_{10} și reprezentați ACF teoretică față de ACF de selecție a lui $(r_t - \bar{r})^2$, decalajele 1–50.
 3. Simulați 200 traiectorii GARCH-N de lungimea eșantionului (500 de zile eliminate, valoare de inițializare 44) și adăugați anvelopa de 95% a ACF de selecție.
- ▣ **Raportați:** formula, ρ_1 , ρ_{10} , graficul; interpretare: este potrivirea ACF a lui r_t^2 o verificare puternică sau slabă?
- ▣ Model: A1
- ▣ Notebook: secțiunea A6

B4 [Propus]: distribuțiile inovațiilor pentru Bitcoin — cerința

- ▣ **Întrebarea:** ce distribuție a inovațiilor descrie Bitcoin și este validă inferența QMLE Gaussian în acest caz?
- ▣ **Date:** Bitcoin, BTC-USD.CC close, 2014-09-18 – 2026-09-18 (notebook-ul pornește prețurile din 2014-09-17), 4 384 randamente, 365 de zile pe an; GARCH(1,1), medie constantă
- ▣ **Cerințe**
 1. Estimați cu inovații Normale și Student-t; comparați ℓ și BIC și reprezentați graficele QQ ale lui $\hat{z}_t$ față de fiecare lege estimată.
 2. Testați distribuția Normală ($1/\nu = 0$) față de Student-t prin LR cu legea la frontieră $\frac{1}{2}\chi_0^2 + \frac{1}{2}\chi_1^2$ (valoarea critică la 5%: 2,71).
 3. Opțional: adăugați t asimetric (η, λ) și GED (forma ν_G); testați $\lambda = 0$ prin LR; raportați fiecare parametru de formă cu e.s. și semnalați limitele active.
- ▣ **Raportați:** un tabel cu ℓ , BIC, persistență și parametrii de formă, graficul QQ, testele LR; interpretare: cu $\hat{\nu} < 4$, este validă inferența QMLE Gaussian [Hall & Yao \(2003\)](#) și prin ce diferă pentru MLE Student-t?
- ▣ Model: B1, B2
- ▣ Notebook: secțiunea B4

B5 extins [Rezolvat]: Giacomini–White și Model Confidence Set — cerința


- ▣ **Întrebarea:** care comparații din B5 rezistă după ce ținem cont de parametrii estimați, de modelele imbricate și de cei șase concurenți?
- ▣ **Date:** S&P 500 și BET; fereastră mobilă de $W = 1\,000$ de zile, reestimată în fiecare ianuarie (GW); pierderile QLIKE cu fereastră în expansiune din B5 (MCS)
- ▣ **Cerințe**
 1. Pentru fiecare model m , formați $d_{t+1} = L_{t+1}^m - L_{t+1}^{GARCH-t}$ și $Z_{t+1} = (1, d_t)' d_{t+1}$; calculați $GW = n\bar{Z}'\hat{\Omega}^{-1}\bar{Z}$ cu $\hat{\Omega} = n^{-1} \sum Z_{t+1}Z_{t+1}'$ și comparați cu $\chi_2^2(5,99)$ [Giacomini & White \(2006\)](#).
 2. Calculați Model Confidence Set 90% [Hansen, Lunde & Nason \(2011\)](#): statistica T_R , bootstrap staționar cu bloc mediu 10, 10 000 de extrageri, valoarea de inițializare 42 (arch.bootstrap.MCS).
 3. Raportați ordinea eliminării și modelele păstrate, pentru ambele piețe.
- ▣ **Raportați:** statisticile GW și valorile p , valorile p MCS, graficul; interpretare: de ce nu este valid DM pentru GJR-t față de GARCH-t [West \(1996\)](#), [Clark & McCracken \(2001\)](#) și sunt de acord DM și MCS?
- ▣ Notebook: secțiunea B5

B5 extins [Rezolvat]: rezolvare

Model	GW S&P	p	MCS p S&P	MCS p BET
GARCH-N	5,85	0,054	0,586	0,658
GARCH-t	—	—	0,353	0,108
GJR-t	2,49	0,288	1,000	1,000
EGARCH-t	3,21	0,201	0,586	0,658
EWMA	11,40	0,003	0,008	0,108
Hist-20	16,41	< 0,001	0,001	0,026

- S&P 500: GW respinge doar EWMA și Hist-20; ordinea eliminării Hist-20, EWMA, GARCH-t, GARCH-N, EGARCH-t, GJR-t; păstrate: cele patru modele GARCH. BET: ordinea Hist-20, GARCH-t, EWMA, GARCH-N, EGARCH-t, GJR-t; MCS păstrează și EWMA ($p = 0,108$)

B5 extins [Rezolvat]: GW și MCS într-un grafic



- Interpretare: sub H_0 , diferența DM pentru modele imbricate cu fereastră în expansiune degenerază; GW testează metoda și rămâne valid; MCS controlează eroarea pentru șase modele, ceea ce testele DM pe perechi nu fac

B6 [Propus]: compararea prognozelor pe BET — cerința

- ▣ **Întrebarea:** se transferă concluziile din B5 la bursa de la București?
- ▣ **Date:** BET, 2 675 zile de prognoză, 2016–2026; aceleași șase modele, fereastră în expansiune, aproximare și cod ca în B5
- ▣ **Cerințe**
 1. Calculați QLIKE mediu, t DM față de GARCH-t și $\sum d_t$ cumulat.
 2. Estimați regresia MZ pentru GARCH-t cu erori HAC; raportați a , b , e.s., R^2 și p Wald și reprezentați graficul de calibrare.
 3. Puneți rezultatele S&P 500 și BET alături, cu fereastra de estimare a fiecărei cifre.
- ▣ **Raportați:** două tabele și două grafice; interpretare: sunt calibrate prognozele pentru BET și ce ați testa în continuare?
- ▣ Model: B5
- ▣ Notebook: secțiunea B6


B8 [Propus]: bootstrap și testul IGARCH pentru BET — cerința

- ▣ **Întrebarea:** cât de precisă este persistența BET și poate dispersia ei să aibă o rădăcină unitară?
- ▣ **Date:** BET GARCH-t, $\hat{\rho} = 0,9907$ (timp de înjumătățire 74 zile); cei doi algoritmi și funcțiile din B7, $B = 999$
- ▣ **Cerințe**
 1. Rulați algoritmul 1 și raportați intervalul bazat pe percentile pentru p , intervalul timpului de înjumătățire și proporția extragerilor la $p = 1$.
 2. Comparați abaterea standard bootstrap a lui $\hat{\rho}^*$ cu e.s. robustă a lui $\hat{\alpha} + \hat{\beta}$.
 3. Rulați algoritmul 2 și comparați valorile p bootstrap, din amestec și din χ^2_1 , la 5%.
- ▣ **Raportați:** intervalele, cele două e.s., testul și graficul cu două panouri; interpretare: ordonează intervalele separate pentru BET și S&P 500 cei doi timpi de înjumătățire?
- ▣ Model: B7
- ▣ Notebook: secțiunea B8

C1 [Propus]: determină știrile din SUA volatilitatea BET? — cerința (1/2): date și momentul observațiilor

- ▣ **Întrebarea:** crește șocul S&P 500 de ieri dispersia BET de azi și cu cât?
- ▣ **Date:** BET.csv și GSPC.INDX.csv, close, 2000-01-07 – 2026-09-18; îmbinăm *prețurile* în zilele comune, apoi calculăm randamentele; t indexează zilele îmbinate
- ▣ **Cerințe**
 1. Construiți eșantionul îmbinat și u_{t-1} , randamentul S&P 500 din ziua îmbinată precedentă (Wall Street închide după București).
 2. Verificați săptămâna cu sărbători de mai jos: pe 2 decembrie 2025, u_{t-1} este randamentul S&P 500 de la 26 la 28 noiembrie (0,69%); spuneți ce ședință americană lipsește și unde ajunge.
- ▣ **Raportați:** numărul zilelor îmbinate și verificarea momentului
- ▣ Model: B1, B2
- ▣ Notebook: secțiunea C

C1 [Propus]: calendarul îmbinat în jurul unei sărbători



- Marcaje pline: zile de tranzacționare; pătrate: zilele păstrate după îmbinarea prețurilor; cifrele sunt u_{t-1} pentru fiecare zi îmbinată

C1 [Propus]: cerința (2/2): model, test, contribuție

- ▣ **Întrebarea:** aceeași întrebare, acum ca model estimat
- ▣ **Date:** $r_t = \mu + \phi u_{t-1} + \varepsilon_t$, $\sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2 + \beta \sigma_{t-1}^2 + \delta u_{t-1}^2$, $\varepsilon_t = \sigma_t z_t$ cu z_t Student-t standardizat; funcțiile din notebook `spill_negll`, `fit_spill`
- ▣ **Cerințe**
 1. Scrieți log-verosimilitatea pas cu pas (pornire $\sigma_1^2 =$ dispersia de selecție) și estimați modelul nerestricționat și modelul cu $\delta = 0$.
 2. Testați $\delta = 0$ prin LR; deoarece $\delta \geq 0$, folosiți $\frac{1}{2}\chi_0^2 + \frac{1}{2}\chi_1^2$; repetați pe 2000–2012 și 2013–2026.
 3. Calculați termenul american cumulat $s_t = \beta s_{t-1} + \delta u_{t-1}^2$ cu $s_1 = 0$, partea s_t/σ_t^2 și volatilitatea fără el, $\sqrt{\sigma_t^2 - s_t}$; reprezentați-le.
- ▣ **Raportați:** estimările pe trei eșantioane, testele LR, graficul contribuției; un folder Quantlet și un slide cu concluzia și principala limită; interpretare: legătura este cauzală sau predictivă?

C3 [Propus]: GARCH bazat pe un cvasi-scor pe acțiuni americane — cerința (1/2)

- ▣ **Întrebarea:** este grosimea cozilor randamentelor același lucru cu atenuarea șocurilor mari în actualizarea dispersiei [Blasques, Francq & Laurent \(2023\)](#)?
- ▣ **Date:** începeți cu JPMorgan (JPM.US, adjusted close) și VIX (VIX.INDX, close), îmbinate în zilele comune, 3 ianuarie 1995 – 28 februarie 2019; $r_t = 100 \Delta \ln P_t$, $X_t = \text{VIX}_t^2 / 252$ (VIX din ziua t intră în f_{t+1})
- ▣ **Cerințe**
 1. Modelul (recursia estimată): $y_t = r_t - \mu - \phi r_{t-1} = \sqrt{f_t} \epsilon_t$, ϵ_t Student-t standardizat cu $1/\xi$ grade de libertate;
 $f_{t+1} = \omega + \varpi X_t + \alpha \Psi\left(\frac{1+\zeta}{1-2\zeta+\zeta\epsilon_t^2}\right) \epsilon_t^2 f_t + \beta f_t$, $\Psi(x) = x \tanh(cx/2)$, $c = 1000$, $\zeta \in (-1, 1/2)$, f_1 = dispersia lui y_t .
 2. Parametri: ξ = grosimea cozilor, ζ = atenuarea; $\zeta = 0$: GARCH(1,1)-t; $\zeta = \xi$: Beta-t-GARCH. Estimați cele trei modele prin verosimilitate maximă (notebook-ul MFM_ch5_quasi_score_driven: qsd_negll, fit_qsd).
 3. Testați $\zeta = 0$ și $\xi = \zeta$ prin LR față de χ_1^2 ($\zeta = 0$ este interior datorită lui Ψ).
- ▣ **Raportați:** estimările, log-verosimilitățile, cele două teste LR
- ▣ Model: B1, B2

C3 [Propus]: cerința (2/2): diagnostic și extindere

- ▣ **Întrebarea:** se potrivesc cele trei modele și rămâne răspunsul valabil dincolo de o acțiune?
- ▣ **Date:** estimările din cerința 1; PIT $u_t = F(\epsilon_t)$, i.i.d. $U(0, 1)$ dacă modelul este corect [Diebold, Gunther & Tay \(1998\)](#)
- ▣ **Cerințe**
 1. Reprezentați $\sqrt{f_t}$ pentru cele trei modele în jurul celui mai mare șoc și histogramele PIT.
 2. Calculați statistica naivă $(\sum_t u_t - T/2)/\sqrt{T/12}$ și explicați de ce ignoră eroarea de estimare (corecția din [Pierce \(1982\)](#) scade dispersia sub $T/12$).
 3. Opțional: extindeți la cele 11 acțiuni ale cursului și până la 18 septembrie 2026; raportați frecvențele de respingere cu un interval binomial care presupune, ipotetic, respingeri independente.
- ▣ **Raportați:** un folder Quantlet și un slide cu tabelul, testele și principala limită; interpretare: de ce nu pot 11 companii selectate, încă listate, confirma cele 89,5% din lucrare?

Bibliografie (1/3)

- ▣ Andrews, D.W.K. (2000). Inconsistency of the bootstrap when a parameter is on the boundary of the parameter space. *Econometrica*, 68(2), 399–405.
- ▣ Andrews, D.W.K. (2001). Testing when a parameter is on the boundary of the maintained hypothesis. *Econometrica*, 69(3), 683–734.
- ▣ Blasques, F., Francq, C., Laurent, S. (2023). Quasi score-driven models. *Journal of Econometrics*, 234(1), 251–275.
- ▣ Bollerslev, T. (1986). Generalized autoregressive conditional heteroskedasticity. *Journal of Econometrics*, 31(3), 307–327.
- ▣ Bollerslev, T., Wooldridge, J.M. (1992). Quasi-maximum likelihood estimation and inference in dynamic models with time-varying covariances. *Econometric Reviews*, 11(2), 143–172.
- ▣ Clark, T.E., McCracken, M.W. (2001). Tests of equal forecast accuracy and encompassing for nested models. *Journal of Econometrics*, 105(1), 85–110.
- ▣ Diebold, F.X., Gunther, T.A., Tay, A.S. (1998). Evaluating density forecasts with applications to financial risk management. *International Economic Review*, 39(4), 863–883.

Bibliografie (2/3)

- ▣ Diebold, F.X., Mariano, R.S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3), 253–263.
- ▣ Engle, R.F., Ng, V.K. (1993). Measuring and testing the impact of news on volatility. *Journal of Finance*, 48(5), 1749–1778.
- ▣ Franke, J., Härdle, W.K., Hafner, C.M. (2019). *Statistics of Financial Markets: An Introduction*, 5th ed. Springer.
- ▣ Giacomini, R., White, H. (2006). Tests of conditional predictive ability. *Econometrica*, 74(6), 1545–1578.
- ▣ Glosten, L.R., Jagannathan, R., Runkle, D.E. (1993). On the relation between the expected value and the volatility of the nominal excess return on stocks. *Journal of Finance*, 48(5), 1779–1801.
- ▣ Hall, P., Yao, Q. (2003). Inference in ARCH and GARCH models with heavy-tailed errors. *Econometrica*, 71(1), 285–317.
- ▣ Hansen, B.E. (1994). Autoregressive conditional density estimation. *International Economic Review*, 35(3), 705–730.

Bibliografie (3/3)

- ▣ Hansen, P.R., Lunde, A., Nason, J.M. (2011). *The model confidence set*. *Econometrica*, 79(2), 453–497.
- ▣ J.P. Morgan/Reuters (1996). *RiskMetrics — Technical Document*, 4th ed. New York.
- ▣ Li, W.K., Mak, T.K. (1994). *On the squared residual autocorrelations in non-linear time series with conditional heteroskedasticity*. *Journal of Time Series Analysis*, 15(6), 627–636.
- ▣ Mincer, J., Zarnowitz, V. (1969). *The evaluation of economic forecasts*. In J. Mincer (ed.), *Economic Forecasts and Expectations: Analysis of Forecasting Behavior and Performance*, NBER.
- ▣ Patton, A.J. (2011). *Volatility forecast comparison using imperfect volatility proxies*. *Journal of Econometrics*, 160(1), 246–256.
- ▣ Pierce, D.A. (1982). *The asymptotic effect of substituting estimators for parameters in certain types of statistics*. *The Annals of Statistics*, 10(2), 475–478.
- ▣ West, K.D. (1996). *Asymptotic inference about predictive ability*. *Econometrica*, 64(5), 1067–1084.