



## Modelarea piețelor financiare

### Seminarul 5: Volatilitate condiționată — modele GARCH



Daniel Traian PELE

Drd. Antoaneta Amza, [antoaneta.amza@csie.ase.ro](mailto:antoaneta.amza@csie.ase.ro)

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

## Acronime folosite în acest material (1/2)

- ACF: AutoCorrelation Function (funcția de autocorelație)
- AI: Artificial Intelligence (inteligență artificială)
- AIC: Akaike Information Criterion (criteriul informațional Akaike)
- AR: AutoRegressive (model) (model autoregresiv)
- ARCH: AutoRegressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă)
- ARMA: AutoRegressive Moving Average (model) (model autoregresiv cu medie mobilă)
- BET: Bucharest Exchange Trading (index) (indicele de referință al Bursei de Valori București)
- BIC: Bayesian Information Criterion (criteriul informațional bayesian)
- DM: Diebold–Mariano (test) (testul Diebold–Mariano de comparare a prognozelor)
- EGARCH: Exponential GARCH (GARCH exponențial)
- EWMA: Exponentially Weighted Moving Average (medie mobilă ponderată exponențial)
- GARCH: Generalised AutoRegressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă generalizată)
- GARCH-N: GARCH with Normal innovations (GARCH cu inovații Normale)
- GED: Generalised Error Distribution (distribuția generalizată a erorilor)
- GJR: Glosten–Jagannathan–Runkle (asymmetric GARCH) (GARCH asimetric Glosten–Jagannathan–Runkle)
- GJR-GARCH: Glosten–Jagannathan–Runkle GARCH (GARCH asimetric Glosten–Jagannathan–Runkle)
- GW: Giacomini–White (test) (testul Giacomini–White)
- HAC: Heteroskedasticity and Autocorrelation Consistent (standard errors) (erori standard robuste la heteroscedasticitate și autocorelație)
- IGARCH: Integrated GARCH (GARCH integrat)
- LGARCH: Logarithmic GARCH (GARCH logaritmic)
- LM: Lagrange Multiplier (multiplicatorul Lagrange)
- LR: Likelihood Ratio (test) (testul raportului de verosimilitate)
- MCS: Model Confidence Set (mulțimea de modele de încredere)
- MLE: Maximum Likelihood Estimation (estimarea prin metoda verosimilității maxime)
- MZ: Mincer–Zarnowitz (regression) (regresia Mincer–Zarnowitz)
- QLIKE: Quasi-LIKelihood (loss function) (funcția de pierdere de tip cvasi-verosimilitate)

## Acronime folosite în acest material (2/2)

- QMLE: Quasi-Maximum Likelihood Estimator (estimatorul de cvasi-verosimilitate maximă)
- RG: Realized GARCH (modelul Realized GARCH (GARCH cu măsuri realizate))
- SUA: Statele Unite ale Americii
- UTC: Coordinated Universal Time (Temps Universel Coordonné) (timpul universal coordonat)

# Cuprins

Introducere

Partea A: derivări

Partea B: calcul și inferență

Partea C: întrebare deschisă

Încheiere

Bibliografie

## Obiectivele seminarului

### La finalul seminarului puteți

- ▣ Rula pas cu pas recursia dispersiei GARCH și prognozele ei
- ▣ Estima GARCH, GJR-GARCH și variante cu cozi groase și diagnostica reziduurile
- ▣ Compara modele prin rapoarte de verosimilitate, criterii informaționale și pierderi în afara eșantionului
- ▣ Măsura incertitudinea estimării cu metoda delta și un bootstrap parametric și testa la frontieră

### Structura

- ▣ **Partea A:** șase derivări (A1–A6): dispersia pe mai mulți pași, persistența GJR, metoda delta, momente, dispersia robustă și clasică a QMLE, ACF a pătratelor
- ▣ **Partea B:** opt exerciții pe calculator, cu inferență (B1–B8)
- ▣ **Partea C:** o întrebare deschisă, punct de plecare pentru proiectul de echipă (C1), critica unui răspuns AI (C2) și un punct de plecare pentru proiect din studiul de caz al cursului (C3)

- ▣ Suport: Cursul 5; manualul Franke, Härdle & Hafner (2019)

## Cum lucrăm la acest seminar

- ▣ Problemele **[Rezolvat]** au rezolvarea completă; problemele **[Propus]** au doar cerința: rezolvările se discută la seminar
- ▣ Fiecare problemă propusă indică **modelul**: problema rezolvată care folosește aceeași tehnică
  - ▶ Fiecare exercițiu din Partea B se încheie cu întrebări de interpretare: întrebați-vă ce ar schimba concluzia
- ▣ Raportați orice estimare împreună cu incertitudinea ei: eroare standard robustă, interval bootstrap sau valoare  $p$
- ▣ Verificați orice model estimat: convergența, parametrii aflați la frontieră, reziduurile standardizate

## Probleme rezolvate și propuse

### Rezolvate: exemple lucrate în acest material

- ▣ Partea A: A1 (dispersia pe mai mulți pași: derivare și cifre), A3 (dispersia de termen lung, timpul de înjumătățire, metoda delta)
- ▣ Partea B: B1 (GARCH-t cu diagnostic), B2 (GJR vs GARCH, testul LR), B5 (QLIKE, DM, MZ, Giacomini–White, MCS), B7 (bootstrap parametric, testul IGARCH sub  $H_0$ )

### Propuse: le rezolvați voi

- ▣ Partea A: A2 (model: A1), A4 (model: A3), A5 (model: A3), A6 (model: A1)
- ▣ Partea B: B3 (model: B2), B4 (model: B1, B2), B6 (model: B5), B8 (model: B7)
- ▣ Partea C: C1, întrebare deschisă și punct de plecare pentru un proiect; C2, critica unui răspuns A1 (model: A3); C3, Realized GARCH pe SPY (studiul de caz din curs; model: B1, B2)

## Pregătire: mediul Python și datele

- ▣  **Deschide în Colab:** `capitol5_notebook_seminar.ipynb`
- ▣ Google Colab (recomandat) sau Python local  $\geq 3.10$  cu `numpy`, `pandas`, `scipy`, `statsmodels`, `matplotlib` și `arch`
- ▣ Serii: S&P 500, BET, Bitcoin; prețuri zilnice de închidere până la 18 septembrie 2026
- ▣ Randamente în %:  $r_t = 100 (\ln P_t - \ln P_{t-1})$ ; indicii bursieri în zilele lucrătoare, Bitcoin 7 zile din 7
- ▣ Partea C îmbină întâi prețurile BET și S&P 500 în zilele comune, apoi calculează randamentele

## Formulele folosite azi

- GARCH(1,1) [Bollerslev \(1986\)](#):  $\sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2 + \beta \sigma_{t-1}^2$ ; GJR [Glosten, Jagannathan & Runkle \(1993\)](#): adăugăm  $\gamma I(\varepsilon_{t-1} < 0) \varepsilon_{t-1}^2$
- Dispersia de termen lung  $\sigma^2 = \omega / (1 - \alpha - \beta)$ ; prognoza  $\mathbb{E}_t \sigma_{t+h}^2 = \sigma^2 + (\alpha + \beta)^{h-1} (\sigma_{t+1}^2 - \sigma^2)$
- Timpul de înjumătățire  $h_{1/2} = \ln 0,5 / \ln(\alpha + \beta)$ ;  $LR = 2(\ell_1 - \ell_0) \sim \chi_m^2$  sau  $\frac{1}{2}\chi_0^2 + \frac{1}{2}\chi_1^2$  pentru un parametru pe frontieră (verosimilitate regulată, parametri de nuisanță identificați)
- Metoda delta:  $\widehat{\text{e.s.}} g(\hat{\theta}) = \sqrt{\nabla g' \hat{V} \nabla g}$ ; QMLE Gaussian pentru  $(\omega, \alpha, \beta)$ , media cunoscută:  $\text{avar} = (\kappa_z - 1)J^{-1}$
- Pierderea QLIKE  $r_t^2/h_t + \ln h_t$  [Patton \(2011\)](#); statistica  $t$  Diebold–Mariano pe diferența de pierderi [Diebold & Mariano \(1995\)](#)
- Regresia de asimetrie  $\hat{z}_t^2$  pe  $S_{t-1}^-$ ,  $S_{t-1}^- \hat{\varepsilon}_{t-1}$ ,  $S_{t-1}^+ \hat{\varepsilon}_{t-1}$  [Engle & Ng \(1993\)](#)

## A1: prognoza dispersiei pe mai mulți pași (1/2) [Rezolvat]

### Context și date

- ▣ GARCH(1,1):  $\varepsilon_t = \sigma_t z_t$ ,  $\sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2 + \beta \sigma_{t-1}^2$ , cu  $z_t$  i.i.d., de medie 0 și dispersie 1, independent de trecut
- ▣ Persistența  $p = \alpha + \beta < 1$ , dispersia de termen lung  $\bar{\sigma}^2 = \omega / (1 - p)$ ;  $\mathbb{E}_t$  este media condiționată de informația de la închiderea zilei  $t$
- ▣ Cifre (randamente în %):  $\omega = 0,05$ ,  $\alpha = 0,10$ ,  $\beta = 0,85$ , pornire  $\sigma_1^2 = \bar{\sigma}^2$ ; șocurile  $\varepsilon_1 = -2,0$ ,  $\varepsilon_2 = 0,5$ ,  $\varepsilon_3 = 3,0$ ,  $\varepsilon_4 = -1,0$

### Ce aveți de făcut

- ▣ (a) Luați valoarea așteptată condiționată în recursie și deduceți  $\mathbb{E}_t \sigma_{t+h}^2 = \bar{\sigma}^2 + p^{h-1}(\sigma_{t+1}^2 - \bar{\sigma}^2)$  pentru  $h \geq 1$ .
- ▣ (b) Însușați prognozele și deduceți forma explicită a dispersiei pe  $H$  zile,  $V_H = \sum_{h=1}^H \mathbb{E}_t \sigma_{t+h}^2$ .
- ▣ (c) Deduceți semnul lui  $V_H - H\sigma_{t+1}^2$ , eroarea regulii rădăcinii pătrate a timpului, în funcție de  $\sigma_{t+1}^2 - \bar{\sigma}^2$ .
- ▣ (d) Calculați pas cu pas  $\sigma_2^2, \dots, \sigma_5^2$  și prognozele  $\mathbb{E}_4 \sigma_{4+h}^2$  pentru  $h = 1, \dots, 5$ .

## A1: prognoza dispersiei pe mai mulți pași (2/2) [Rezolvat]

### Ce aveți de făcut

- (e) Calculați  $V_5$  din sumă și din formula de la (b); comparați-l cu  $5\sigma_5^2$ . (f) Calculați timpul de înjumătățire  $\ln 0,5 / \ln p$ .

### Ce raportați și interpretați

- Raportați cele două formule, cele patru dispersii, cele cinci prognoze,  $V_5$  cu volatilitatea pe 5 zile  $\sqrt{V_5}$  și timpul de înjumătățire.
- Interpretare: după șocul de +3%, regula rădăcinii pătrate a timpului supraestimează sau subestimează riscul pe 5 zile și de ce?

## A1: prognoza dispersiei pe mai mulți pași: Rezolvare (1/2) [Rezolvat]

- (a) Pasul 1: decalăm recursia,  $\sigma_{t+h}^2 = \omega + \alpha \varepsilon_{t+h-1}^2 + \beta \sigma_{t+h-1}^2$ , și aplicăm  $\mathbb{E}_t$ .
- Pasul 2: pentru  $h \geq 2$ ,  $\mathbb{E}_t \varepsilon_{t+h-1}^2 = \mathbb{E}_t[\sigma_{t+h-1}^2 \mathbb{E}(z_{t+h-1}^2)] = \mathbb{E}_t \sigma_{t+h-1}^2$ , deci  $\mathbb{E}_t \sigma_{t+h}^2 = \omega + p \mathbb{E}_t \sigma_{t+h-1}^2$ .
- Pasul 3: scădem  $\bar{\sigma}^2 = \omega + p \bar{\sigma}^2$ ; distanța față de nivelul pe termen lung scade cu factorul  $p$  la fiecare pas, iar iterând de la  $\sigma_{t+1}^2$ , cunoscută, obținem formula.
- (b) Însușind,  $V_H = H \bar{\sigma}^2 + (\sigma_{t+1}^2 - \bar{\sigma}^2) \sum_{j=0}^{H-1} p^j = H \bar{\sigma}^2 + (\sigma_{t+1}^2 - \bar{\sigma}^2) \frac{1 - p^H}{1 - p}$ .
- (c) Scăzând  $H \sigma_{t+1}^2$ :  $V_H - H \sigma_{t+1}^2 = (\bar{\sigma}^2 - \sigma_{t+1}^2) \left[ H - \frac{1 - p^H}{1 - p} \right]$ , iar paranteza este  $\sum_{j=0}^{H-1} (1 - p^j) > 0$  pentru  $H \geq 2$ .
- Interpretare: regula  $H \sigma_{t+1}^2$  subestimează dispersia pe  $H$  zile când azi este mai calm decât pe termen lung și o supraestimează după zile agitate, deoarece dispersia revine la  $\bar{\sigma}^2$ .

## A1: prognoza dispersiei pe mai mulți pași: Rezolvare (2/2) [Rezolvat]

- (d) Pornire:  $\sigma_1^2 = 0,05/(1 - 0,95) = 1,0000$ ; apoi  
 $\sigma_2^2 = \omega + \alpha \varepsilon_1^2 + \beta \sigma_1^2 = 0,05 + 0,10 \times (-2,0)^2 + 0,85 \times 1,0000 = 0,05 + 0,4000 + 0,8500 = 1,3000$ .
- La fel,  $\sigma_3^2 = 0,05 + 0,0250 + 1,1050 = 1,1800$ ,  $\sigma_4^2 = 0,05 + 0,9000 + 1,0030 = 1,9530$  și  
 $\sigma_5^2 = 0,05 + 0,1000 + 1,6600 = 1,8100$ .
- Prognozele: distanța  $\sigma_5^2 - \bar{\sigma}^2 = 0,8101$  scade cu 0,95 pe zi, deci  $\mathbb{E}_4 \sigma_{4+h}^2 = 1,8100, 1,7695, 1,7311, 1,6945, 1,6598$  pentru  $h = 1, \dots, 5$ .
- (e) Formula:  $V_5 = 5 \times 1,0000 + 0,8101 \times (1 - 0,95^5)/(1 - 0,95) = 5 + 0,8101 \times 4,524 = 8,665$ , la fel ca suma; volatilitatea pe 5 zile  $\sqrt{8,665} = 2,944\%$ .
- Regula rădăcinii pătrate a timpului dă  $5\sigma_5^2 = 9,050 > V_5$ : după zilele agitate supraestimează dispersia pe 5 zile, cum prezice (c) pentru  $\sigma_5^2 > \bar{\sigma}^2$ .
- (f) Timpul de înjumătățire =  $\ln 0,5 / \ln 0,95 = -0,6931 / (-0,0513) = 13,5$  zile: jumătate din orice șoc de dispersie dispare după circa două săptămâni de tranzacționare.

## A2: persistența GJR cu inovații asimetrice (1/2) [Propus]

Rezolvarea se discută la seminar

### Context și date

- GJR-GARCH(1,1) [Glosten, Jagannathan & Runkle \(1993\)](#):  $\sigma_t^2 = \omega + (\alpha + \gamma l_{t-1})\varepsilon_{t-1}^2 + \beta\sigma_{t-1}^2$ ,  $l_{t-1} = 1(\varepsilon_{t-1} < 0)$ ;  $z_t$  i.i.d., de medie 0, dispersie 1, nu neapărat simetric
- Date pentru (c): S&P 500 (data/market/GSPC.INDX.csv), închideri zilnice 2000–2026, 6 714 randamente log zilnice în %,  $r_t = 100(\ln P_t - \ln P_{t-1})$ ; GJR-GARCH(1,1) cu inovații t asimetrice [Hansen \(1994\)](#):  $\hat{\alpha} = 0,00000$ ,  $\hat{\gamma} = 0,21116$ ,  $\hat{\beta} = 0,87965$ ,  $\hat{\eta} = 7,70$ ,  $\hat{\lambda} = -0,150$

### Ce aveți de făcut

- (a) Aplicați media în recursie și arătați că persistența este  $\alpha + \gamma m_- + \beta$ , cu  $m_- = \mathbb{E}[z_t^2 1(z_t < 0)]$ .
- (b) Arătați că  $m_- = 1/2$  când  $z_t$  este simetric și explicați de ce  $m_-$  diferă în general de  $P(z_t < 0)$ .
- (c) Calculați  $m_-$  și  $P(z_t < 0)$  prin integrarea numerică a densității t asimetrice estimate; calculați persistența și timpul de înjumătățire cu  $m_-$  și cu  $1/2$ .

## A2: persistența GJR cu inovații asimetrice (2/2) [Propus]

Rezolvarea se discută la seminar

### Ce raportați și interpretați

- Raportați  $m_-$ ,  $P(z_t < 0)$ , ambele persistențe și ambii timpi de înjumătățire. Interpretare: ce se întâmplă dacă se folosește formula  $\alpha + \gamma/2 + \beta$  cu inovații asimetrice?
- Model: A1

## A3: volatilitatea de termen lung, timpul de înjumătățire și metoda delta (1/2) [Rezolvat]

### Context și date

- S&P 500 (data/market/GSPC.INDX.csv), închideri zilnice 2000–2026, 6 714 randamente log zilnice în %,  $r_t = 100 (\ln P_t - \ln P_{t-1})$
- GARCH(1,1) cu inovații Student-t (Cursul 5):  $\hat{\omega} = 0,015714$ ,  $\hat{\alpha} = 0,122573$ ,  $\hat{\beta} = 0,872139$ ; covarianța robustă a lui  $(\hat{\omega}, \hat{\alpha}, \hat{\beta})$  din estimare, cu  $\widehat{\text{e.s.}}(\hat{\alpha} + \hat{\beta}) = 0,0047$ ; 251,4 zile de tranzacționare pe an

### Ce aveți de făcut

- (a) Deduceți dispersia de termen lung  $\sigma^2 = \omega / (1 - \alpha - \beta)$  aplicând media necondiționată în recursie.
- (b) Calculați volatilitatea de termen lung zilnică și anuală și timpul de înjumătățire; comparați cu volatilitatea de selecție 19,2% anual.
- (c) Calculați gradientul lui  $\sigma^2(\omega, \alpha, \beta)$  și, prin metoda delta, eroarea standard a volatilității anuale de termen lung.
- (d) Calculați eroarea standard prin metoda delta a timpului de înjumătățire  $h = \ln 0,5 / \ln p$ ,  $p = \alpha + \beta$ , și construiți un interval de 95% pentru  $h$  care respectă  $h > 0$ .

## A3: volatilitatea de termen lung, timpul de înjumătățire și metoda delta (2/2) [Rezolvat]

### Ce raportați și interpretați

- Raportați volatilitatea de termen lung cu eroarea ei standard, timpul de înjumătățire cu eroarea lui standard și intervalul transformat.
- Interpretare: de ce este metoda delta inutilă pentru timpul de înjumătățire și ce înseamnă asta pentru întrebarea  $p = 1$  (B7)?

### A3: volatilitatea de termen lung, timpul de înjumătățire și metoda delta: Rezolvare (1/2) [Rezolvat]

- (a) Sub staționaritatea în covarianță  $\mathbb{E}\sigma_t^2 = \mathbb{E}\sigma_{t-1}^2 = \mathbb{E}\varepsilon_{t-1}^2 = \sigma^2$ , deci  $\sigma^2 = \omega + (\alpha + \beta)\sigma^2$  și  $\sigma^2 = \omega/(1 - \alpha - \beta)$ .
- (b)  $\hat{\rho} = \hat{\alpha} + \hat{\beta} = 0,994712$ ;  $\hat{\sigma}^2 = 0,015714/(1 - 0,994712) = 2,972$  (%<sup>2</sup> pe zi).
- Volatilitatea zilnică  $\sqrt{2,972} = 1,724\%$ ; anuală  $1,724 \times \sqrt{251,4} = 27,3\%$ , față de valoarea de selecție 19,2%.
- Timpul de înjumătățire  $\ln 0,5 / \ln 0,994712 = -0,6931/(-0,005302) = 130,7$  zile.
- Interpretare: volatilitatea de termen lung depășește valoarea de selecție deoarece împărțirea la  $1 - \hat{\rho} = 0,005288$  amplifică erorile mici din  $\hat{\rho}$ ; pasul următor măsoară cât.

## A3: volatilitatea de termen lung, timpul de înjumătățire și metoda delta: Rezolvare (2/2) [Rezolvat]

- (c) Gradientul  $\nabla \sigma^2 = \left( \frac{1}{1-p}, \frac{\omega}{(1-p)^2}, \frac{\omega}{(1-p)^2} \right) = (189,1, 562,0, 562,0)$ ;  $\widehat{e.s.}(\hat{\sigma}^2) = \sqrt{\nabla' \hat{V} \nabla} = 2,35$ .
- Volatilitatea anuală  $v = \sqrt{251,4 \sigma^2}$  are  $\partial v / \partial \sigma^2 = 251,4 / (2v)$ , deci  $\widehat{e.s.}(\hat{v}) = 10,8$  puncte în jurul a 27,3%: o bandă de 95% de circa  $\pm 21$  de puncte.
- (d)  $|\partial h / \partial p| = -\ln 0,5 / [p(\ln p)^2] = 24\,789$ , deci  $\widehat{e.s.}(\hat{h}) = 24\,789 \times 0,0047 = 116$  zile pentru  $\hat{h} = 130,7$  zile.
- Un interval simetric  $\hat{h} \pm 1,96 \times 116$  ar include timpi de înjumătățire negativi: liniarizarea eșuează deoarece  $h(p)$  explodează când  $p \rightarrow 1$ .
- În schimb,  $h$  este crescătoare în  $p$ : transformăm  $\hat{p} \pm 1,96 \times 0,0047 = [0,9855; 1,0039]$  în  $h \in [48; \infty)$ , deoarece capătul superior depășește  $p = 1$ .
- Interpretare: datele mărginesc timpul de înjumătățire doar inferior; evaluarea plauzibilității ipotezei  $p = 1$  necesită un test corect la frontieră (B7).

## A4: finitudinea momentului de ordin patru (1/2) [Propus]

Rezolvarea se discută la seminar

### Context și date

- ▣ S&P 500 (data/market/GSPC.INDX.csv), închideri zilnice 2000–2026, 6 714 randamente log zilnice în %,  $r_t = 100 (\ln P_t - \ln P_{t-1})$
- ▣ GARCH(1,1) cu inovații Normale (GARCH-N):  $\hat{\alpha} = 0,120604$ ,  $\hat{\beta} = 0,859878$ ; aplatizarea de selecție a randamentelor 13,7
- ▣ GARCH(1,1)-t:  $\hat{\alpha} = 0,1226$ ,  $\hat{\beta} = 0,8721$ ,  $\hat{\nu} = 6,26$ ; cu  $z_t$  Normal,  $K = 3[1 - (\alpha + \beta)^2]/[1 - (\alpha + \beta)^2 - 2\alpha^2]$  dacă numitorul este pozitiv (Seminarul 1, A9)

### Ce aveți de făcut

- ▣ (a) Verificați condiția  $(\alpha + \beta)^2 + 2\alpha^2 < 1$  pentru GARCH-N și calculați aplatizarea implicată  $K$ .
- ▣ (b) Repetați (a) cu  $\hat{\alpha}$  și  $\hat{\beta}$  rotunjite la 3 zecimale și comparați ambele valori ale lui  $K$  cu aplatizarea de selecție.
- ▣ (c) Pentru inovații Student-t, calculați  $\kappa_z = 3(\nu - 2)/(\nu - 4)$  și verificați condiția  $(\alpha + \beta)^2 + (\kappa_z - 1)\alpha^2 < 1$  pentru estimările GARCH-t.

## A4: finitudinea momentului de ordin patru (2/2) [Propus]

Rezolvarea se discută la seminar

### Ce raportați și interpretați

- ☐ Raportați ambele condiții, cele două valori ale lui  $K$  și  $\kappa_z$ . Interpretare: se poate folosi aplatizarea randamentelor pentru a valida un GARCH-t estimat?
- ☐ Model: A3

## A5: dispersia robustă și cea clasică a QMLE Gaussian, ARCH(1) (1/2) [Propus]

Rezolvarea se discută la seminar

### Context și date

- ▣ ARCH(1):  $\varepsilon_t = \sigma_t z_t$ ,  $\sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2$  cu  $\omega$  cunoscut;  $z_t$  i.i.d., de medie 0, dispersie 1, applatizare  $\kappa_z = \mathbb{E} z_t^4 < \infty$ , nu neapărat Normal
- ▣ Cvasi-log-verosimilitatea Gaussiană pe zi  $\ell_t(\alpha) = -\frac{1}{2}(\ln \sigma_t^2 + \varepsilon_t^2/\sigma_t^2)$ ; notație  $x_t = \varepsilon_{t-1}^2/\sigma_t^2$ . Date pentru (d): applatizarea reziduurilor GARCH-N pentru S&P 500, 4,73 (Cursul 5)

### Ce aveți de făcut

- ▣ (a) Deduceți scorul  $s_t = \partial \ell_t / \partial \alpha$  și dispersia lui  $B = \mathbb{E} s_t^2$ .
- ▣ (b) Deduceți derivata a doua  $\partial^2 \ell_t / \partial \alpha^2$  și  $A = -\mathbb{E} \partial^2 \ell_t / \partial \alpha^2$ .
- ▣ (c) Arătați că dispersia „sandviș”  $A^{-1} B A^{-1}$  este  $\frac{\kappa_z - 1}{2} A^{-1}$ , unde  $A^{-1}$  este dispersia clasică (inversa hessianei).
- ▣ (d) Calculați raportul dintre erorile standard robuste și clasice pentru inovații Student-t cu  $\nu = 6,26$  și pentru  $\hat{\kappa}_z = 4,73$ .

## A5: dispersia robustă și cea clasică a QMLE Gaussian, ARCH(1) (2/2) [Propus]

Rezolvarea se discută la seminar

### Ce raportați și interpretați

- Raportați  $s_t$ ,  $A$ ,  $B$ , raportul dispersiilor și cele două rapoarte numerice; comparați cu raportul observat 1,37 din Cursul 5.
- Interpretare: ce se întâmplă cu acest raport și cu teoria în  $\sqrt{n}$  când  $\kappa_z = \infty$ ? Model: A3

## A6: autocorelația pătratelor șocurilor (1/2) [Propus]

Rezolvarea se discută la seminar

### Context și date

- ▣ GARCH(1,1) cu  $\mathbb{E}\varepsilon_t^4 < \infty$  este un ARMA(1,1) în  $\varepsilon_t^2$ :  $\varepsilon_t^2 = \omega + (\alpha + \beta)\varepsilon_{t-1}^2 + \nu_t - \beta\nu_{t-1}$ , cu  $\nu_t = \varepsilon_t^2 - \sigma_t^2$  (Cursul 5)
- ▣ Pentru un ARMA(1,1)  $y_t = \phi y_{t-1} + u_t + \theta u_{t-1}$ :  $\rho_1 = (1 + \phi\theta)(\phi + \theta)/(1 + 2\phi\theta + \theta^2)$  și  $\rho_k = \phi^{k-1}\rho_1$
- ▣ Date pentru (b): GARCH-N pentru S&P 500,  $\hat{\alpha} = 0,1206$ ,  $\hat{\beta} = 0,8599$ ; autocorelațiile de selecție ale pătratelor randamentelor centrate 0,313 (decalajul 1) și 0,248 (decalajul 10)

### Ce aveți de făcut

- ▣ (a) Înlocuiți  $\phi = \alpha + \beta$  și  $\theta = -\beta$  și deduceți  $\rho_1(\varepsilon^2) = \alpha(1 - \beta^2 - \alpha\beta)/(1 - \beta^2 - 2\alpha\beta)$  și  $\rho_k = \rho_1(\alpha + \beta)^{k-1}$ .
- ▣ (b) Evaluați  $\rho_1$  și  $\rho_{10}$  pentru estimările S&P 500 și comparați-le cu valorile de selecție.
- ▣ (c) Explicați de ce diferența poate fi mare chiar dacă modelul este corect, folosind condiția de moment din A4.

## A6: autocorelația pătratelor șocurilor (2/2) [Propus]

Rezolvarea se discută la seminar

### Ce raportați și interpretați

- Raportați formula,  $\rho_1$ ,  $\rho_{10}$  și valorile de selecție. Interpretare: este potrivirea funcției de autocorelație a lui  $r_t^2$  o verificare puternică sau slabă a unui GARCH?
- Model: A1

## B1: GARCH-t pe S&P 500 cu diagnostic (1/2) [Rezolvat]

### Context și date

- S&P 500 (data/market/GSPC.INDX.csv), închideri zilnice 2000–2026, 6 714 randamente log zilnice în %,  $r_t = 100 (\ln P_t - \ln P_{t-1})$
- Ecuația mediei  $r_t = \mu + \varepsilon_t$ ; ecuația dispersiei GARCH(1,1) [Bollerslev \(1986\)](#); inovații Student-t cu  $\nu$  grade de libertate, scalate la dispersie unitară

### Ce aveți de făcut

- (a) Testați efectele ARCH înainte de modelare: Ljung–Box  $Q(10)$  pe  $r_t^2$  și testul LM al lui Engle cu 5 decalaje pe randamentele centrate, la pragul de 5%.
- (b) Estimați GARCH(1,1)-t prin verosimilitate maximă (`arch_model(r, p=1, q=1, dist='t')`); raportați erorile standard robuste [Bollerslev & Wooldridge \(1992\)](#) și clasice și raportul lor.
- (c) Diagnosticați  $\hat{z}_t = \hat{\varepsilon}_t / \hat{\sigma}_t$  la 5%:  $Q(10)$  pe  $\hat{z}_t$  și  $\hat{z}_t^2$ , LM(5) și cele trei teste  $t$  de asimetrie plus testul lor comun  $\chi^2_3$  [Engle & Ng \(1993\)](#).

## B1: GARCH-t pe S&P 500 cu diagnostic (2/2) [Rezolvat]

### Ce raportați și interpretați

- ☐ Raportați un tabel al estimărilor cu ambele erori standard și un tabel al statisticilor de test cu valorile  $p$  și deciziile.
- ☐ Interpretare: ce diagnostice trec și care pică, ce sugerează eșecul și de ce sunt erorile standard robuste mai mari?

## B1: GARCH-t pe S&P 500 cu diagnostic: Rezolvare (1/2) [Rezolvat]

|              | $\hat{\omega}$ | $\hat{\alpha}$ | $\hat{\beta}$ | $\hat{\nu}$ | $\hat{\alpha} + \hat{\beta}$ |
|--------------|----------------|----------------|---------------|-------------|------------------------------|
| Estimare     | 0,0157         | 0,1226         | 0,8721        | 6,26        | 0,9947                       |
| E.s. robustă |                | 0,0107         | 0,0103        | 0,48        |                              |
| E.s. clasică |                | 0,0101         | 0,0096        |             |                              |

- (a) Înainte de modelare,  $Q(10) = 6133$  și  $LM(5) = 1684$ , față de valorile critice de 5% 18,3 ( $\chi^2_{10}$ ) și 11,1 ( $\chi^2_5$ ); ambele  $p < 0,001$ , deci absența efectelor ARCH este respinsă.
- (b) Citirea tabelului:  $\hat{\beta} = 0,8721$  preia dispersia de ieri,  $\hat{\alpha} = 0,1226$  adaugă știrile,  $\hat{\nu} = 6,26$  semnalează cozi groase; persistența 0,9947.
- Raportul robust/clasic este 1,06 pentru  $\hat{\alpha}$  și 1,08 pentru  $\hat{\beta}$ : verosimilitatea Student-t este ea însăși greșit specificată (asimetrie -0,58), deci „sandvișul” este mai mare.

## B1: GARCH-t pe S&P 500 cu diagnostic: Rezolvare (2/2) [Rezolvat]

- (c) Ecuația dispersiei:  $Q(10)$  pe  $\hat{z}_t^2 = 13,6$  ( $p = 0,192$ ) și  $LM(5) = 5,8$  ( $p = 0,326$ ): nerespinse la 5%: nu se detectează grupare rămasă (legi  $\chi^2$  naive, vezi atenționarea de mai jos).
- Ecuația mediei:  $Q(10)$  pe  $\hat{z}_t = 21,9$  ( $p = 0,016$ ): respins la 5%; rămâne o mică autocorelație pe care media constantă o ignoră.
- Asimetria: asimetria de semn  $t = 3,56$ , de mărime negativă  $t = 1,13$ , de mărime pozitivă  $t = -2,61$ ; comun  $\chi_3^2 = 40,7$  față de 7,81: respins, în reziduuri rămâne asimetrie.
- Atenție: cu parametri estimați aceste legi  $\chi^2$  sunt doar aproximative [Li & Mak \(1994\)](#); aici respingerile sunt departe de valorile critice, deci deciziile rămân.
- Interpretare: dinamica dispersiei este surprinsă, dar un GARCH simetric ratează efectul de levier; pasul următor este GJR-GARCH (B2).

## B2: GJR vs GARCH pe S&P 500 (1/2) [Rezolvat]

### Context și date

- S&P 500 (data/market/GSPC.INDX.csv), închideri zilnice 2000–2026, 6 714 randamente log zilnice în %,  $r_t = 100 (\ln P_t - \ln P_{t-1})$
- GJR-GARCH(1,1)-t [Glosten, Jagannathan & Runkle \(1993\)](#):  $\sigma_t^2 = \omega + (\alpha + \gamma I_{t-1}) \varepsilon_{t-1}^2 + \beta \sigma_{t-1}^2$ ,  $I_{t-1} = 1(\varepsilon_{t-1} < 0)$ ; GARCH(1,1)-t din B1 este cazul particular  $\gamma = 0$

### Ce aveți de făcut

- (a) Estimați GJR-GARCH(1,1)-t și raportați  $\hat{\alpha}$ ,  $\hat{\gamma}$  cu statistica  $t$  robustă și  $\hat{\beta}$ .
- (b) Testați  $H_0: \gamma = 0$  cu  $LR = 2(\ell_{GJR} - \ell_{GARCH})$  față de  $\chi_1^2$  la 5%.
- (c) Comparați AIC și BIC ale celor două modele și repetați testul comun de asimetrie din B1 pe reziduurile GJR.
- (d) Măsurați mărimea economică a asimetriei cu curba de impact a știrilor: dispersia de a doua zi după șocuri de  $-3\%$  și  $+3\%$ .

### Ce raportați și interpretați

- Raportați estimările, testul LR (statistica, valoarea  $p$ , decizia),  $\Delta AIC$ ,  $\Delta BIC$  și cele două valori de impact al știrilor.

## B2: GJR vs GARCH pe S&P 500 (2/2) [Rezolvat]

### Ce raportați și interpretați

- ☐ Interpretare: de ce este  $\hat{\alpha}$  exact 0 și mai este validă legea  $\chi^2_1$  a testului LR?

## B2: GJR vs GARCH pe S&P 500: Rezolvare [Rezolvat]

- (a)  $\hat{\alpha} = 0,000$ ,  $\hat{\gamma} = 0,205$  ( $t$  robust = 10,03),  $\hat{\beta} = 0,881$ : știrile bune au panta  $\hat{\alpha}$ , cele proaste  $\hat{\alpha} + \hat{\gamma}$ .
- (b)  $LR = 2(-8944,6 - (-9062,5)) = 235,65$ ,  $p < 0,001$ , mult peste 3,84:  $H_0$  este respinsă la 5%; legea  $\chi^2_1$  presupune o densitate Student-t corectă (B1 găsește asimetrie), dar  $t$  robust de la (a) dă același verdict.
- (c)  $\Delta AIC = -233,7$  și  $\Delta BIC = -226,8$  (GJR minus GARCH): ambele preferă GJR; testul comun de asimetrie  $\chi^2_3$  scade de la 40,7 la 28,1, încă peste 7,81.
- (d) Pornind de la dispersia de selecție 1,47, un șoc de  $-3\%$  dă dispersia de a doua zi 3,16, iar unul de  $+3\%$  dă 1,31: prognoza după știri proaste este de 2,4 ori cea după știri bune, iar șocul de  $+3\%$  chiar scade dispersia ( $\hat{\alpha} = 0$ ).
- $\hat{\alpha} = 0$  este la limita  $\alpha \geq 0$ : șocurile pozitive nu cresc volatilitatea;  $\gamma = 0$  este interior, deci  $\chi^2_1$  este valabilă dacă adevăratul  $\alpha > 0$ , iar dacă  $\alpha_0 = 0$  legea este nestandard [Andrews \(2001\)](#), dar  $LR = 235,65$  respinge sub orice lege rezonabilă

## B3: GJR vs GARCH pe BET [Propus]

Rezolvarea se discută la seminar

### Context și date

- BET (data/market/BET.csv), închideri zilnice 2000–2026, 6 670 randamente log zilnice în %
- Aceleași două modele ca în B2: GARCH(1,1)-t și GJR-GARCH(1,1)-t, medie constantă, inovații Student-t

### Ce aveți de făcut

- (a) Estimați ambele modele și raportați  $\hat{\gamma}$  cu statistica  $t$  robustă.
- (b) Testați  $H_0: \gamma = 0$  prin LR față de  $\chi^2_1$  la pragurile de 5% și 1%.
- (c) Calculați  $\Delta\text{AIC}$  și  $\Delta\text{BIC}$  (GJR minus GARCH) și penalizarea BIC pe parametru,  $\ln n$ .

### Ce raportați și interpretați

- Raportați estimările, decizia LR la ambele praguri și cele două criterii. Interpretare: sunt de acord LR și BIC, de ce pot fi în dezacord și este efectul de levier mai slab la BET decât la S&P 500?
- Model: B2

## B4: distribuția inovațiilor pentru Bitcoin (1/2) [Propus]

Rezolvarea se discută la seminar

### Context și date

- Bitcoin (data/market/BTC-USD.CC.csv), închideri zilnice 2014–2026, 4 384 randamente log zilnice în %, 365 de zile pe an
- GARCH(1,1) cu medie constantă; patru distribuții ale inovațiilor: distribuția Normală, distribuția Student-t, distribuția t asimetrică Hansen (1994) (asimetria  $\lambda$ ) și GED

### Ce aveți de făcut

- (a) Estimați cele patru modele și comparați log-verosimilitățile și BIC.
- (b) Testați  $H_0: \lambda = 0$  (t asimetrică față de Student-t) prin LR față de  $\chi^2_1$  la 5%.
- (c) Raportați parametrii de formă și de asimetrie aplicabili, cu erorile lor standard, și  $\hat{\alpha} + \hat{\beta}$  pentru fiecare lege; distribuția Normală nu are astfel de parametri, iar forma GED nu este un număr de grade de libertate; precizați ce parametri sunt la o limită.
- (d) Testați distribuția Normală ( $1/\nu = 0$ ) față de distribuția Student-t prin LR cu legea la frontieră  $\frac{1}{2}\chi^2_0 + \frac{1}{2}\chi^2_1$  (valoarea critică la 5%: 2,71).

## B4: distribuția inovațiilor pentru Bitcoin (2/2) [Propus]

Rezolvarea se discută la seminar

### Ce raportați și interpretați

- Raportați un tabel cu  $\ell$ , BIC și persistența și cele două teste LR. Interpretare: asimetria de selecție a lui  $\hat{z}_t$  este negativă, de ce nu găsește verosimilitatea asimetrie? Cu  $\hat{\nu} < 4$ , este validă inferența QMLE Gaussian pentru Bitcoin [Hall & Yao \(2003\)](#) și prin ce diferă de inferența pentru MLE Student-t din B1?
- Model: B1, B2

## B5: compararea prognozelor pe S&P 500 (1/2) [Rezolvat]

### Context și date

- S&P 500 (data/market/GSPC.INDX.csv), închideri zilnice 2000–2026, 6 714 randamente log zilnice în %,  $r_t = 100 (\ln P_t - \ln P_{t-1})$ ; perioada de prognoză 2016–2026 (2 692 prognoze pentru ziua următoare)
- Modele: GARCH-N, GARCH-t, GJR-t, EGARCH-t reestimate în fiecare ianuarie pe toate datele din 2000 (fereastră în expansiune); EWMA cu  $\lambda = 0,94$  J.P. Morgan/Reuters (1996); Hist-20, media ultimelor 20 de pătrate ale randamentelor
- Aproximarea dispersiei adevărate:  $r_t^2$ , ignorând media ( $\hat{\mu}^2 = 0,0062$  față de o dispersie medie de 1,47); pierderea QLIKE  $= r_t^2 / h_t + \ln h_t$  Patton (2011), cu  $h_t$  prognoza dispersiei

### Ce aveți de făcut

- (a) Calculați QLIKE mediu pentru fiecare model.
- (b) Testați acuratețea egală față de GARCH-t cu statistica  $t$  Diebold–Mariano pe  $d_t = L_t^m - L_t^{GARCH-t}$ , eroare standard HAC cu 5 decalaje, la 5% Diebold & Mariano (1995).
- (c) Estimați regresia Mincer–Zarnowitz  $r_t^2 = a + b h_t + u_t$  Mincer & Zarnowitz (1969) cu erori HAC și testul Wald pentru  $a = 0$ ,  $b = 1$ .

## B5: compararea prognozelor pe S&P 500 (2/2) [Rezolvat]

### Ce aveți de făcut

- (d) Repetați comparația cu o fereastră mobilă de 1 000 de zile, reestimată în fiecare ianuarie, și testul Giacomini–White [Giacomini & White \(2006\)](#)(instrumente 1,  $d_t$ ).
- (e) Calculați Model Confidence Set 90% [Hansen, Lunde & Nason \(2011\)](#) pe pierderile QLIKE ale prognozelor cu fereastră în expansiune de la (a): statistica  $T_R$ , bootstrap staționar cu lungimea medie a blocului 10, 10 000 de extrageri, valoare de inițializare fixată.

### Ce raportați și interpretați

- Raportați două tabele: QLIKE,  $t$  DM,  $b$  MZ,  $R^2$  și  $p$  Wald; apoi statistica GW, valoarea  $p$  și valoarea  $p$  MCS.
- Interpretare: ce modele sunt semnificativ mai slabe decât GARCH-t, de ce este  $R^2$  mic, de ce nu este valid DM pentru GJR-t vs GARCH-t și sunt de acord DM și MCS?

## B5: compararea prognozelor pe S&amp;P 500: Rezolvare (1/2) [Rezolvat]

| Model    | QLIKE  | DM $t$ | MZ $b$ | MZ $R^2$ | Wald $p$ |
|----------|--------|--------|--------|----------|----------|
| GARCH-N  | 0,7510 | -1,47  | 0,97   | 0,250    | 0,995    |
| GARCH-t  | 0,7570 | —      | 0,88   | 0,238    | 0,804    |
| GJR-t    | 0,7319 | -1,22  | 0,84   | 0,276    | 0,680    |
| EGARCH-t | 0,7454 | -0,36  | 1,24   | 0,293    | 0,713    |
| EWMA     | 0,8149 | 3,48   | 0,89   | 0,172    | 0,685    |
| Hist-20  | 0,8888 | 4,10   | 0,68   | 0,152    | 0,028    |

- Procedura: prognozăm  $h_t$  în fiecare zi cu parametrii din ianuarie precedent, calculăm  $L_t$ , facem media pe 2 692 zile și regresăm  $d_t$  pe o constantă cu erori HAC.
- (a–b) Cel mai mic QLIKE: GJR-t; doar EWMA ( $t = 3,48$ ) și Hist-20 ( $t = 4,10$ ) depășesc 1,96: sunt semnificativ mai slabe la 5%.
- (c) Nedeplasarea nu este respinsă pentru modelele GARCH (Wald  $p > 0,6$ ), dar este respinsă pentru Hist-20 ( $p = 0,028$ );  $R^2$  este mic deoarece  $r_t^2 \approx \sigma_t^2 z_t^2$  este o aproximare zgomotoasă.

## B5: compararea prognozelor pe S&amp;P 500: Rezolvare (2/2) [Rezolvat]

| Model    | $t$ (mobil) | $GW$  | $p$     | MCS $p$ |
|----------|-------------|-------|---------|---------|
| GARCH-N  | 1,87        | 5,85  | 0,054   | 0,586   |
| GARCH-t  | –           | –     | –       | 0,353   |
| GJR-t    | –0,18       | 2,49  | 0,288   | 1,000   |
| EGARCH-t | 0,07        | 3,21  | 0,201   | 0,586   |
| EWMA     | 3,20        | 11,40 | 0,003   | 0,008   |
| Hist-20  | 3,87        | 16,41 | < 0,001 | 0,001   |

- (d) De ce GW: cu modele imbricate, parametri estimați și fereastră în expansiune, diferența DM degenerază sub  $H_0$ , deci DM nu este  $N(0, 1)$ ; o fereastră mobilă păstrează zgomotul estimării și face GW valid.
- $GW = n\bar{Z}'\hat{\Omega}^{-1}\bar{Z} \sim \chi_2^2$  (valoarea critică 5,99): respins doar pentru EWMA și Hist-20; GARCH-N este la limită ( $p = 0,054$ ).
- (e) MCS pe prognozele cu fereastră în expansiune: un model rămâne în mulțimea de 90% dacă valoarea  $p$  MCS depășește 0,10; mulțimea este GARCH-N, GARCH-t, GJR-t, EGARCH-t, același verdict ca DM, acum cu rata erorii controlată pentru șase modele.

## B6: compararea prognozelor pe BET (1/2) [Propus]

Rezolvarea se discută la seminar

### Context și date

- BET (data/market/BET.csv), închideri zilnice 2000–2026, 6 670 randamente log zilnice în %; perioada de prognoză 2016–2026 (2 675 prognoze pentru ziua următoare)
- Aceleași șase modele, aceeași schemă de reestimare, aproximarea  $r_t^2$  și pierderea QLIKE ca în B5

### Ce aveți de făcut

- (a) Calculați QLIKE mediu al fiecărui model și statistica  $t$  Diebold–Mariano față de GARCH-t (HAC, 5 decalaje), la 5%.
- (b) Estimați regresia Mincer–Zarnowitz și testul Wald pentru  $a = 0$ ,  $b = 1$  pentru fiecare model.
- (c) Calculați testul Giacomini–White cu fereastră mobilă de 1 000 de zile și, ca în B5 (e), Model Confidence Set 90% pe pierderile QLIKE ale prognozelor cu fereastră în expansiune.

### Ce raportați și interpretați

- Raportați cele două tabele din B5 pentru BET. Interpretare: se schimbă ordinea între S&P 500 și BET, dau DM și MCS același verdict pentru EWMA și ce parte a modelului pentru BET ați îmbunătăți întâi?

## B6: compararea prognozelor pe BET (2/2) [Propus]

Rezolvarea se discută la seminar

Ce raportați și interpretați

☐ Model: B5

## B7: cât de precis este timpul de înjumătățire? Bootstrap și testul IGARCH (1/2) [Rezolvat]

### Context și date

- ▣ S&P 500 (data/market/GSPC.INDX.csv), închideri zilnice 2000–2026, 6 714 randamente log zilnice în %,  $r_t = 100 (\ln P_t - \ln P_{t-1})$
- ▣ GARCH(1,1)-t din B1:  $\hat{\rho} = \hat{\alpha} + \hat{\beta} = 0,9947$ , timp de înjumătățire 131 zile; estimarea impune  $\alpha + \beta \leq 1$ ; valoarea de inițializare a generatorului de numere aleatoare fixată pentru reproductibilitate

### Ce aveți de făcut


- ▣ (a) Simulați  $B = 999$  traiectorii de 6 714 zile (500 de zile de încălzire) din GARCH(1,1)-t estimat și reestimați modelul pe fiecare traiectorie.
- ▣ (b) Calculați intervalele de 95% bazate pe percentile pentru  $\hat{\rho}^*$  și pentru timpul de înjumătățire, abaterea standard bootstrap a lui  $\hat{\rho}^*$  și proporția extragerilor la limita  $p = 1$ ; comparați cu eroarea standard robustă.
- ▣ (c) Testați  $H_0: \alpha + \beta = 1$ : estimați IGARCH(1,1)-t, calculați  $LR = 2(\ell_{GARCH} - \ell_{IGARCH})$ , simulați  $B = 999$  traiectorii sub  $H_0$ , reestimați ambele modele pe fiecare și calculați valoarea  $p$  bootstrap  $(1 + \#\{LR^* \geq LR\})/(B + 1)$ .
- ▣ (d) Comparați această valoare  $p$  cu valorile  $p$  calculate folosind distribuția  $\chi_1^2$  neajustată și amestecul la frontieră  $\frac{1}{2}\chi_0^2 + \frac{1}{2}\chi_1^2$ ; decideți la 5% și la 10%.

## B7: cât de precis este timpul de înjumătățire? Bootstrap și testul IGARCH (2/2) [Rezolvat]

### Ce raportați și interpretați

- ☐ Raportați histograma lui  $\hat{p}^*$  sub ambele scheme, intervalele, cele trei valori  $p$  și decizia.
- ☐ Interpretare: de ce este intervalul timpului de înjumătățire atât de asimetric și de ce „intervalul bazat pe percentile atinge 1” nu este un test pentru IGARCH?

## B7: cât de precis este timpul de înjumătățire? Bootstrap și testul IGARCH: Rezolvare (1/2) [Rezolvat]



- (a–b) Albastru:  $\hat{\rho}^*$  din modelul estimat; interval de 95% [0,9833; 1,0000]; abaterea standard bootstrap 0,0047 față de e.s. robustă 0,0047: apropiate.
- Timpul de înjumătățire de la 41 zile la  $\infty$ :  $\ln 0,5 / \ln x$  explodează când  $x \rightarrow 1$  (e.s. prin metoda delta 116 zile, A3); 8,9% din extrageri sunt la limită, deci intervalul este trunchiat la 1 [Andrews \(2000\)](#).

## B7: cât de precis este timpul de înjumătățire? Bootstrap și testul IGARCH: Rezolvare (2/2) [Rezolvat]

- (c) Estimarea IGARCH-t:  $\hat{\alpha}_0 = 0,127$ ,  $\hat{\nu}_0 = 6,03$ ;  $LR = 1,11$ .
- Sub  $H_0$  (histograma chihlimbarie), 52% din reestimări sunt la  $p = 1$ , aproape de jumătatea prezisă de legea amestecului; valoarea critică simulată de 95% a  $LR$  este 3,36.
- (d) Valori  $p$ : 0,29 ( $\chi^2_1$  naiv), 0,15 (amestec), 0,17 (LR bootstrap) și 0,17 ( $\hat{p}$  bootstrap).
- Decizia:  $H_0$  nu este respinsă nici la 5%, nici la 10%;  $\chi^2_1$  naiv aproape dublează valoarea  $p$ , iar amestecul și bootstrap-ul sunt de acord.
- Concluzia economică: 27 de ani de date nu pot deosebi un timp de înjumătățire de circa 130 de zile de unul infinit; simularea din  $\hat{\theta}$  descrie precizia, simularea din modelul nul este ceea ce îi trebuie unui test.

## B8: bootstrap și testul IGARCH pentru BET [Propus]

Rezolvarea se discută la seminar

### Context și date

- BET (data/market/BET.csv), închideri zilnice 2000–2026, 6 670 randamente log zilnice în %
- GARCH(1,1)-t cu  $\hat{p} = 0,9907$  (timp de înjumătățire 74 zile); aceeași procedură și același număr de extrageri ca în B7

### Ce aveți de făcut

- (a) Rulați bootstrap-ul parametric cu  $B = 999$  din modelul estimat; raportați intervalele de 95% pentru  $p$  și pentru timpul de înjumătățire și proporția extragerilor la  $p = 1$ .
- (b) Comparați abaterea standard bootstrap a lui  $\hat{p}^*$  cu eroarea standard robustă a lui  $\hat{\alpha} + \hat{\beta}$ .
- (c) Testați IGARCH prin simulare sub  $H_0$  ( $B = 999$ ) și comparați cu valoarea  $p$  din amestec, la 5%.

### Ce raportați și interpretați

- Raportați intervalele, cele două erori standard și testul. Interpretare: este timpul de înjumătățire al BET semnificativ mai scurt din punct de vedere statistic decât al S&P 500 și de ce ar avea nevoie un test formal al diferenței?
- Model: B7

## C1: este volatilitatea pieței românești determinată de SUA? [Propus]

Rezolvarea se discută la seminar

### Întrebarea

- Wall Street închide după Bursa de Valori București: șocul S&P 500 de ieri este o știre pentru BET-ul de azi
- $u_{t-1}^2$ , pătratul randamentului S&P 500 din ziua precedentă, crește dispersia condiționată a BET?
- Model:  $\sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2 + \beta \sigma_{t-1}^2 + \delta u_{t-1}^2$ , cu  $r_t = \mu + \phi u_{t-1} + \varepsilon_t$

### Livrabil

- Un folder Quantlet în repository-ul echipei și un slide cu concluzia și principala limită

### Răspunsul ar trebui să conțină

- Prețurile îmbinate întâi în zilele comune de tranzacționare, apoi randamentele
- Verosimilitatea scrisă pas cu pas (Student-t), estimată prin optimizare numerică
- Un test LR pentru  $\delta = 0$ ; atenție,  $\delta \geq 0$  pune ipoteza nulă pe frontieră
- Stabilitatea: două subperioade (de ex. înainte și după 2013)
- Partea din dispersia BET generată în model de termenul american,  $\sum_{j \geq 0} \beta^j \delta u_{t-1-j}^2 / \sigma_t^2$ , și cum se schimbă în timp

## C2: critica unui răspuns AI [Propus]

Rezolvarea se discută la seminar

### Cererea trimisă unui asistent de inteligență artificială (AI)

- „px conține închiderile zilnice S&P 500. Estimează un GARCH(1,1) cu inovații Student- $t$  cu arch și dă-mi volatilitatea anualizată de termen lung și timpul de înjumătățire al unui șoc.”

### Răspunsul asistentului

```
import numpy as np
from arch import arch_model
r = np.log(px).diff().dropna()                # daily log returns
am = arch_model(r, vol='GARCH', p=1, q=1, dist='t')
res = am.fit(disp='off')
om = res.params['omega']
a, b = res.params['alpha[1]'], res.params['beta[1]']
lr_var = om / (1 - a - b)                     # long-run daily variance
ann_vol = lr_var * 252                        # annualised volatility
half_life = np.log(0.5) / np.log(b)          # half-life in days
```

- „Pentru S&P 500 rezultă  $\text{ann\_vol} = 0,075$  (7,5% pe an) și un timp de înjumătățire de 5,1 zile.”

## C2: critica unui răspuns AI, cerința [Propus]

Rezolvarea se discută la seminar

- Codul rulează, dar răspunsul conține **trei** greșeli tipice pentru lucrul cu GARCH
  - ▶ Tot restul răspunsului este corect
- Pentru fiecare greșeală
  - ▶ Indicați linia și explicați de ce este greșită
  - ▶ Spuneți cum ați depista-o: un avertisment, o cifră din A3, un slide din curs
  - ▶ Scrieți varianta corectă a liniei (liniilor) și cifrele corecte
- Notați fiecare greșeală ca în AI\_ERRORS.md
  - ▶ Ce ați întrebat, ce a răspuns AI-ul, ce era greșit, cum v-ați dat seama, varianta corectă
- Indiciu: comparați cu A3 și cu slide-ul „Greșeli frecvente”

## C3: Realized GARCH pe SPY [Propus]

Rezolvarea se discută la seminar

### Cerință

- ▣ Studiul de caz [Hansen, Huang & Shek \(2012\)](#); date: barele SPY la 5 minute, data/market/intraday, octombrie 2020 – septembrie 2026. Model: B1, B2.
- ▣ 1. Păstrați sesiunea 9:30–16:00 (ora New York-ului), eliminați zilele în care barele acoperă sub 90% din cele 6,5 ore (Secțiunea 5.1) și calculați  $r_t = 100 \ln(P_t^{\text{close}}/P_t^{\text{open}})$  și  $x_t = \sum_i (100 \Delta \ln P_{t,i})^2$ .
- ▣ 2. Scrieți pas cu pas log-verosimilitatea comună  $\ell(r, x) = \ell(r) + \ell(x | r)$  pentru Realized GARCH(1,2) log-liniar, RG(1,2), cu  $\tau(z) = \tau_1 z + \tau_2 (z^2 - 1)$  și estimați-o prin QMLE Gaussian pe 2021–2025, apoi LGARCH(1,1) pe aceleași zile.
- ▣ 3. Raportați  $\hat{\beta}$ ,  $\hat{\gamma}_1$ ,  $\hat{\gamma}_2$ ,  $\hat{\xi}$ ,  $\hat{\phi}$ ,  $\hat{\tau}_1$ ,  $\hat{\tau}_2$ ,  $\hat{\sigma}_u$  cu erori standard robuste, persistența  $\hat{\pi} = \hat{\beta} + \hat{\phi}(\hat{\gamma}_1 + \hat{\gamma}_2)$  și  $\rho^-$ ,  $\rho^+$ , alături de coloana SPY deschidere–închidere din Tabelele II–III.
- ▣ 4. Testați  $\tau_1 = \tau_2 = 0$  prin LR, comparați  $\ell(r)$  pentru RG(1,2) cu cea pentru LGARCH(1,1), apoi, cu estimările din 2021–2025, raportați pentru 2026 LR parțial și QLIKE pentru  $h_t$  față de GARCH(1,1)-t, cu un test DM.

### Interpretare

- ▣ Este  $\hat{\phi}$  apropiat de 1, ca în 2002–2008 (1,04, Tabelul II)? Ce ar arăta  $\hat{\phi} < 1$  despre dispersia realizată la 5 minute ca măsură a lui  $h_t$ ?
- ▣ Este asimetria ( $\rho^-$  față de  $\rho^+$ ) la fel de puternică precum pentru SPY în Tabelul III (−0,32 și 0,13)?
- ▣ Se păstrează câștigul față de LGARCH în 2026? Numiți un motiv pentru care ar putea fi mai mic decât 40,8 din Tabelul IV, Panoul C, și un test care l-ar evidenția.
- ▣ Livrabil: un folder Quantlet și un slide cu tabelul, testele și principala limită.

## Greșeli frecvente

- ▣ Estimarea GARCH pe randamente în zecimale: optimizatorul se poate opri departe de maxim; folosiți % sau rescalați
- ▣ Citirea erorilor standard clasice când inovațiile nu sunt Normale; folosiți-le pe cele robuste
- ▣ Încrederea în volatilitatea de termen lung și în timpul de înjumătățire când  $\alpha + \beta \approx 1$ , fără un interval
- ▣ Evaluarea prognozelor în eșantion sau cu pierderi nerobuste la o aproximare zgomotoasă
- ▣ Folosirea testului LR pentru un parametru pe frontieră (de ex.  $\delta = 0$  cu  $\delta \geq 0$ ) cu valoarea critică  $\chi^2$  obișnuită sau citirea unui interval bootstrap trunchiat drept test
- ▣ Îmbinarea a două piețe pe randamente în loc de prețuri: creează randamente false pe mai multe zile

## Temă pentru acasă (proiect de echipă)

- ▣ Alegeți o serie nediscutată la seminar (alt indice, un curs de schimb, o marfă sau un cripto-activ)
- ▣ Testați efectele ARCH; estimați GARCH, GJR și EGARCH cu trei distribuții ale inovațiilor; alegeți prin BIC și diagnostic
- ▣ Evaluați prognozele pe o zi și pe o lună în afara eșantionului față de EWMA, cu QLIKE și Diebold–Mariano
- ▣ Raportați timpul de înjumătățire cu un interval bootstrap; pentru o alternativă bazată pe entropie, vedeți [Pele, Lazar & Dufour \(2017\)](#)
- ▣ Notați fiecare eroare AI pe care o prindeți în `AI_ERRORS.md` (cel puțin trei pe proiect)
- ▣ Livrați un folder Quantlet (cod, Metainfo, grafice) și trei slide-uri: dovezi, interpretare, limite

## Studiu suplimentar pe Quantinar

### Cursuri avansate pe quantinar.com

- ☐  Statistics of Financial Markets
- ☐  Applied Time Series Analysis with Python

### Cod și date

- ☐ Notebook-ul seminarului (Colab); Quantlets: [github.com/danpele/MFM/tree/main/Quantlets/Ch\\_05](https://github.com/danpele/MFM/tree/main/Quantlets/Ch_05)

## Bibliografie (1/3)

- ▣ Andrews, D.W.K. (2000). Inconsistency of the bootstrap when a parameter is on the boundary of the parameter space. *Econometrica*, 68(2), 399–405.
- ▣ Andrews, D.W.K. (2001). Testing when a parameter is on the boundary of the maintained hypothesis. *Econometrica*, 69(3), 683–734.
- ▣ Bollerslev, T. (1986). Generalized autoregressive conditional heteroskedasticity. *Journal of Econometrics*, 31(3), 307–327.
- ▣ Bollerslev, T., Wooldridge, J.M. (1992). Quasi-maximum likelihood estimation and inference in dynamic models with time-varying covariances. *Econometric Reviews*, 11(2), 143–172.
- ▣ Diebold, F.X., Mariano, R.S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3), 253–263.
- ▣ Engle, R.F., Ng, V.K. (1993). Measuring and testing the impact of news on volatility. *Journal of Finance*, 48(5), 1749–1778.
- ▣ Franke, J., Härdle, W.K., Hafner, C.M. (2019). *Statistics of Financial Markets: An Introduction*, 5th ed. Springer.

## Bibliografie (2/3)

- ▣ Giacomini, R., White, H. (2006). Tests of conditional predictive ability. *Econometrica*, 74(6), 1545–1578.
- ▣ Glosten, L.R., Jagannathan, R., Runkle, D.E. (1993). On the relation between the expected value and the volatility of the nominal excess return on stocks. *Journal of Finance*, 48(5), 1779–1801.
- ▣ Hall, P., Yao, Q. (2003). Inference in ARCH and GARCH models with heavy-tailed errors. *Econometrica*, 71(1), 285–317.
- ▣ Hansen, B.E. (1994). Autoregressive conditional density estimation. *International Economic Review*, 35(3), 705–730.
- ▣ Hansen, P.R., Huang, Z., Shek, H.H. (2012). Realized GARCH: a joint model for returns and realized measures of volatility. *Journal of Applied Econometrics*, 27(6), 877–906.
- ▣ Hansen, P.R., Lunde, A., Nason, J.M. (2011). The model confidence set. *Econometrica*, 79(2), 453–497.
- ▣ J.P. Morgan/Reuters (1996). *RiskMetrics — Technical Document*, 4th ed. New York.

## Bibliografie (3/3)

- ▣ Li, W.K., Mak, T.K. (1994). [On the squared residual autocorrelations in non-linear time series with conditional heteroskedasticity](#). *Journal of Time Series Analysis*, 15(6), 627–636.
- ▣ Mincer, J., Zarnowitz, V. (1969). [The evaluation of economic forecasts](#). In J. Mincer (ed.), *Economic Forecasts and Expectations: Analysis of Forecasting Behavior and Performance*, NBER.
- ▣ Patton, A.J. (2011). [Volatility forecast comparison using imperfect volatility proxies](#). *Journal of Econometrics*, 160(1), 246–256.
- ▣ Pele, D.T., Lazar, E., Dufour, A. (2017). [Information entropy and measures of market risk](#). *Entropy*, 19(5), 226.