



Modelarea piețelor financiare

Seminarul 5: Volatilitate condiționată — modele GARCH



Daniel Traian PELE

Drd. Antoaneta Amza, antoaneta.amza@csie.ase.ro

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

Acronime folosite în acest material (1/2)

- ▣ ACF: AutoCorrelation Function (funcția de autocorelație)
- ▣ AI: Artificial Intelligence (inteligență artificială)
- ▣ AIC: Akaike Information Criterion (criteriul informațional Akaike)
- ▣ AR: AutoRegressive (model); in event studies: Abnormal Return (model autoregresiv; în studiile de eveniment: randament anormal)
- ▣ ARCH: AutoRegressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă)
- ▣ ARMA: AutoRegressive Moving Average (model) (model autoregresiv cu medie mobilă)
- ▣ BET: Bucharest Exchange Trading (index) (indicele de referință al Bursei de Valori București)
- ▣ BIC: Bayesian Information Criterion (criteriul informațional bayesian)
- ▣ BVB: Bursa de Valori București
- ▣ DM: Diebold–Mariano (test) (testul Diebold–Mariano de comparare a prognozelor)
- ▣ EGARCH: Exponential GARCH (GARCH exponențial)
- ▣ EWMA: Exponentially Weighted Moving Average (medie mobilă ponderată exponențial)
- ▣ GARCH: Generalised AutoRegressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă generalizată)
- ▣ GARCH-N: GARCH with Normal innovations (GARCH cu inovații Normale)
- ▣ GED: Generalised Error Distribution (distribuția generalizată a erorilor)
- ▣ GJR: Glosten–Jagannathan–Runkle (asymmetric GARCH) (GARCH asimetric Glosten–Jagannathan–Runkle)
- ▣ GJR-GARCH: Glosten–Jagannathan–Runkle GARCH (GARCH asimetric Glosten–Jagannathan–Runkle)
- ▣ GW: Giacomini–White (test) (testul Giacomini–White)
- ▣ HAC: Heteroskedasticity and Autocorrelation Consistent (standard errors) (erori standard robuste la heteroscedasticitate și autocorelație)
- ▣ IGARCH: Integrated GARCH (GARCH integrat)
- ▣ LM: Lagrange Multiplier (multiplicatorul Lagrange)
- ▣ LR: Likelihood Ratio (test) (testul raportului de verosimilitate)
- ▣ MCS: Model Confidence Set (mulțimea de încredere a modelelor)
- ▣ MLE: Maximum Likelihood Estimation (estimarea prin metoda verosimilității maxime)
- ▣ MZ: Mincer–Zarnowitz (regression) (regresia Mincer–Zarnowitz)
- ▣ PIT: Probability Integral Transform (transformarea integrală de probabilitate)

Acronime folosite în acest material (2/2)

- ▣ QLIKE: Quasi-LIKelihood (loss function) (funcția de pierdere de tip cvasi-verosimilitate)
- ▣ QMLE: Quasi-Maximum Likelihood Estimator (estimatorul de cvasi-verosimilitate maximă)
- ▣ QQ: Quantile-Quantile (plot) (graficul cuantilă-cuantilă)
- ▣ QSD: Quasi Score-Driven (model) (model bazat pe un cvasi-scor)
- ▣ SUA: Statele Unite ale Americii
- ▣ VIX: CBOE Volatility IndeX (indicele de volatilitate CBOE)

Întrebarea seminarului și traseul

- ▣ Întrebarea seminarului: **ne putem baza pe o volatilitate GARCH estimată, pe incertitudinea ei și pe prognozele ei?**
- ▣ Etapa 1
 - ▶ A1: recursia dispersiei și o prognoză pe 5 zile pe hîrtie; B1: estimarea și diagnosticul GARCH-t; B2–B3: adăugăm asimetria, S&P 500, apoi BET; C2: verificarea unui răspuns A1
- ▣ Etapa 2
 - ▶ A3: incertitudinea volatilității de termen lung și a timpului de înjumătățire; B7: un bootstrap și un test la frontieră; B5: evaluarea prognozelor
- ▣ La seminar: A1, B1, B2, B3, C2; acasă: A3, B7, B5
- ▣ Seminarul are loc înaintea cursului 5: începeți cu secțiunea „Noțiuni necesare azi” (trei slide-uri); A3, B7 și B5 se sprijină pe curs
- ▣ Livrabile: răspunsurile A, cîte o figură și un tabel pentru fiecare exercițiu B, codul C2 corectat, cîte o propoziție de interpretare pentru fiecare exercițiu
- ▣ Notebook: [deschideți notebook-ul seminarului în Colab](#); fiecare cerință indică secțiunea din notebook
- ▣ Seminar: Drd. Antoaneta Amza, antoaneta.amza@csie.ase.ro

Harta exercițiilor

Exercițiu	Întrebare	Tip	Model
A1	cum se actualizează dispersia și care este riscul pe 5 zile?	Rezolvat	–
B1	este GARCH-t adecvat pentru S&P 500 și trec reziduurile testele de diagnostic?	Rezolvat	–
B2	cresc știrile proaste mai mult volatilitatea S&P 500?	Rezolvat	–
B3	aceeași întrebare pentru BET	Propus	B2
C2	ce este greșit într-un răspuns A1?	Propus	A1, B1
A3	cît de precise sînt volatilitatea de termen lung și timpul de înjumătățire?	Rezolvat	–
B7	este $\alpha + \beta = 1$? un bootstrap și un test la frontieră	Rezolvat	–
B5	există un model cu prognoze mai bune decît GARCH-t?	Rezolvat	–
Temă	un exercițiu de transfer: B4, B6 sau B8	Propus	B1, B5, B7
Pachete de extensie	A2, A4, A5, A6, B5 extins, C1, C3 (opțional)	Rezolvat sau Propus	indicat la fiecare cerință

- **[Rezolvat]:** rezolvarea completă în slide-uri și în notebook, un model de urmat; **[Propus]:** îl rezolvați dumneavoastră, rezolvarea se discută la seminar
- Partea A: derivări pe hîrtie; Partea B: estimare și inferență pe date reale, fiecare cu o întrebare de interpretare; Partea C: întrebări deschise și critica unui răspuns A1

Datele folosite

Serie	Preț folosit	Eșantion	Calendar, filtru	Randamente
S&P 500	închidere	2000-01-03 – 2026-09-18	zile lucrătoare; 3 închideri neschimbate eliminate	6 714
BET	închidere	2000-01-05 – 2026-09-18	zile lucrătoare; 0 închideri neschimbate eliminate	6 670
Bitcoin	închidere (BTC/USD)	2014-09-17 – 2026-09-18	toate zilele săptămânii, fără filtru	4 384
VIX	închidere	doar C3	zile lucrătoare	–
11 acțiuni SUA	închidere ajustată	doar C3, 1995–2019	aliniat cu VIX pe zilele comune	–

- Prețurile zilnice din datele cursului, câte o serie pe activ (câmpul folosit: close / adjusted close); randamente $r_t = 100 (\ln P_t - \ln P_{t-1})$ în %, fiecare serie pe calendarul ei
- „Închideri neschimbate”: zile lucrătoare cu închiderea egală cu cea precedentă, adică sărbători completate cu ultimul preț; după filtru nu rămân valori lipsă
- Anualizare cu frecvența observată q : 251,4 (S&P 500), 249,8 (BET), 365,3 (Bitcoin) randamente pe an

Pregătire: rulați și verificați

```
# notebook section "Data" defines
# load_close(name) and pct_returns(name)
r = pct_returns('sp500')      # 100 * diff(log P)
print(len(r), r.index[0], r.index[-1])
print(r.head(3).round(4))

from arch import arch_model
res = arch_model(r, p=1, q=1,
                 dist='t').fit(dispatch='off')
print(res.params)
```

- Rezultat așteptat: 6 714 randamente, 2000-01-04 – 2026-09-18
- Primele trei randamente (%): -3,9099, 0,1920, 0,0955
- GARCH-t: $\hat{\alpha} = 0,1226$, $\hat{\beta} = 0,8721$, $\hat{\nu} = 6,26$
- Dacă un număr sau o valoare diferă, opriți-vă și verificați fișierul, câmpul, datele și filtrul
- Pachete: numpy, pandas, scipy, statsmodels, matplotlib, arch

Noțiuni necesare azi (1/3): de la volatility clustering la o ecuație a dispersiei

- Seminarul are loc înaintea cursului: aceste trei slide-uri prezintă doar noțiunile necesare pentru A1, B1–B3 și C2; detaliile în **Capitolul 5**, secțiunile „Dinamica dispersiei: ARCH și GARCH” și „Proгноze și rezultate pe piețe” (cursul de după seminar)
- **Capitolul 1**: randamentele zilnice sînt aproape necorelate, dar $|r_t|$ și r_t^2 sînt autocorelate (volatility clustering); de aceea modelăm **dispersia condiționată** $\sigma_t^2 = \text{Var}(r_t \mid \mathcal{F}_{t-1})$
- **ARCH(1) Engle (1982)**: $\sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2$; **GARCH(1,1) Bollerslev (1986)** adaugă memorie: $\sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2 + \beta \sigma_{t-1}^2$, cu $\omega > 0, \alpha, \beta \geq 0$
 - ▶ α : reacția la știrile de ieri; β : memoria dispersiei de ieri; persistența $p = \alpha + \beta$; dacă $p < 1$, dispersia de termen lung este $\bar{\sigma}^2 = \omega / (1 - p)$
- **Proгноze**: $\mathbb{E}_t \sigma_{t+h}^2 = \bar{\sigma}^2 + p^{h-1}(\sigma_{t+1}^2 - \bar{\sigma}^2)$: distanța față de $\bar{\sigma}^2$ scade cu factorul p în fiecare zi
 - ▶ Timpul de înjumătățire al unui șoc: $h_{1/2} = \ln 0,5 / \ln p$; de ex. $p = 0,95$ dă $-0,693 / (-0,0513) = 13,5$ zile
- **Unități**: randamente în %, deci dispersii în %²; volatilitatea anuală $\sqrt{q \bar{\sigma}^2}$, cu q randamente pe an (rădăcina unei dispersii, niciodată $q \bar{\sigma}^2$): $\bar{\sigma}^2 = 1$ și $q = 252$ dau 15,9%

Noțiuni necesare azi (2/3): testul ARCH, estimarea GARCH, verificarea modelului

- Testul ARCH Engle (1982): regresăm $\hat{\varepsilon}_t^2$ pe o constantă și pe $\hat{\varepsilon}_{t-1}^2, \dots, \hat{\varepsilon}_{t-q}^2$; $LM = nR^2 \sim \chi_q^2$ sub H_0 : fără efecte ARCH; Ljung–Box $Q(m)$ pe r_t^2 (Capitolul 1) verifică aceeași H_0 ; valori critice la 5%: χ_5^2 11,07, χ_{10}^2 18,31
- Estimarea prin verosimilitate maximă: calculăm recursiv $\sigma_t^2(\theta)$, apoi maximizăm $\ell(\theta) = \sum_t [\ln f(\varepsilon_t/\sigma_t) - \ln \sigma_t]$
 - f : densitatea Normală sau Student-t cu ν grade de libertate, scalată la dispersia 1 (un $\hat{\nu}$ mic înseamnă cozi groase)
 - Cvasi-verosimilitate: dacă σ_t^2 este corectă, dar f greșită, estimările rămân consistente; folosim covarianța robustă (sandwich) $A^{-1}BA^{-1}$ Bollerslev & Wooldridge (1992) (A : hessiana, B : produsul exterior al scorurilor), nu pe cea clasică A^{-1})
- Diagnostic: dacă modelul este corect, $\hat{z}_t = \hat{\varepsilon}_t/\hat{\sigma}_t$ este i.i.d. cu media 0 și dispersia 1: Ljung–Box pe $\hat{z}_t$ (media), pe $\hat{z}_t^2$ și testul LM (dispersia), un grafic QQ față de f estimată (cozile)
- Testul de asimetrie Engle & Ng (1993): regresăm $\hat{z}_t^2$ pe $S_{t-1}^- = 1(\hat{\varepsilon}_{t-1} < 0)$, $S_{t-1}^- \hat{\varepsilon}_{t-1}$, $S_{t-1}^+ \hat{\varepsilon}_{t-1}$; pante semnificative înseamnă că semnul șocului de ieri încă contează (asimetrie rămasă), testul comun $nR^2 \sim \chi_3^2$
- Detalii: Capitolul 5, secțiunile „Estimare și incertitudine” și „Inovații și diagnostic”

Noțiuni necesare azi (3/3): asimetrie, impactul știrilor și modele imbricate

- Efectul de levier (**Capitolul 1**): știrile proaste cresc volatilitatea mai mult decât cele bune; GJR [Glosten, Jagannathan & Runkle \(1993\)](#): $\sigma_t^2 = \omega + (\alpha + \gamma I_{t-1})\varepsilon_{t-1}^2 + \beta\sigma_{t-1}^2$, $I_{t-1} = 1(\varepsilon_{t-1} < 0)$
 - ▶ Panta α pentru știrile bune, $\alpha + \gamma$ pentru cele proaste; cu inovații simetrice, persistența $p = \alpha + \gamma/2 + \beta$
- Curba impactului știrilor [Engle & Ng \(1993\)](#): σ_t^2 ca funcție de ε_{t-1} , cu σ_{t-1}^2 fixată (de ex. la dispersia de selecție): simetrică la GARCH, mai abruptă în stînga la GJR
 - ▶ Exemplu: $\omega = 0,02$, $\alpha = 0,02$, $\gamma = 0,15$, $\beta = 0,88$, $\sigma_{t-1}^2 = 1$: $\varepsilon_{t-1} = -3$ dă $0,02 + 0,17 \times 9 + 0,88 = 2,43$, $\varepsilon_{t-1} = +3$ dă $0,02 + 0,02 \times 9 + 0,88 = 1,08$
- Modele imbricate: GARCH este GJR cu $\gamma = 0$; $LR = 2(\ell_1 - \ell_0) \sim \chi_1^2$ sub H_0 dacă densitatea este corectă și toți ceilalți parametri sînt interiori (valori critice 3,84 la 5%, 6,63 la 1%)
 - ▶ Un parametru aflat la limita lui (de ex. $\hat{\alpha} = 0$, deoarece $\alpha \geq 0$) face ca distribuția sub H_0 să fie nestandard [Andrews \(2001\)](#); B2 arată cum se nuanțează concluzia
 - ▶ $AIC = -2\ell + 2k$, $BIC = -2\ell + k \ln n$ (**Capitolul 2**): cu un parametru în plus, AIC preferă modelul mai mare cînd $LR > 2$, BIC cînd $LR > \ln n$
- Detalii: **Capitolul 5**, secțiunea „Asimetrie și alegerea modelului”; rezumatul tuturor notațiilor este pe slide-ul următor

Notăția folosită în toate exercițiile

- ▣ $r_t = \mu + \varepsilon_t$, $\varepsilon_t = \sigma_t z_t$, z_t i.i.d. cu media 0 și dispersia 1; $\mathcal{F}_t$: informația de la închiderea zilei t , $\mathbb{E}_t = \mathbb{E}[\cdot \mid \mathcal{F}_t]$
- ▣ GARCH(1,1) [Bollerslev \(1986\)](#): $\sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2 + \beta \sigma_{t-1}^2$; persistența $p = \alpha + \beta$; dispersia de termen lung $\bar{\sigma}^2 = \omega / (1 - p)$; timpul de înjumătățire $h_{1/2} = \ln 0,5 / \ln p$
- ▣ GJR [Glosten, Jagannathan & Runkle \(1993\)](#): adăugăm $\gamma I_{t-1} \varepsilon_{t-1}^2$, $I_{t-1} = 1(\varepsilon_{t-1} < 0)$; inovații Student-t cu ν grade de libertate, scalate la dispersia 1
- ▣ Reziduul standardizat $\hat{z}_t = \hat{\varepsilon}_t / \hat{\sigma}_t$; $LR = 2(\ell_1 - \ell_0)$; $AIC = -2\ell + 2k$, $BIC = -2\ell + k \ln n$ (k parametri)
- ▣ Prognoza h_t a dispersiei zilei t , făcută la închiderea zilei $t - 1$; pierderea QLIKE $= r_t^2 / h_t + \ln h_t$ [Patton \(2011\)](#)
- ▣ Un exemplu: $\omega = 0,05$, $\alpha = 0,10$, $\beta = 0,85$, $\varepsilon_{t-1} = 2$, $\sigma_{t-1}^2 = 1$: $\sigma_t^2 = 0,05 + 0,40 + 0,85 = 1,30$

A1 [Rezolvat]: recursia dispersiei — cerința (1/2)

- ▣ **Întrebarea:** cum transformă GARCH(1,1) patru șocuri în patru dispersii zilnice?
- ▣ **Date:** $\omega = 0,05$, $\alpha = 0,10$, $\beta = 0,85$ (randamente în %); pornire $\sigma_1^2 = \bar{\sigma}^2$; șocurile $\varepsilon_1, \dots, \varepsilon_4 = -2,0; 0,5; 3,0; -1,0$; fără fișier de date
- ▣ **Cerințe**
 1. Calculați persistența p și dispersia de termen lung $\bar{\sigma}^2 = \omega/(1-p)$.
 2. Completați tabelul de mai jos rînd cu rînd: termenul de știri $\alpha\varepsilon_{t-1}^2$, termenul de memorie $\beta\sigma_{t-1}^2$ și σ_t^2 pentru $t = 2, \dots, 5$.
 3. Precizați care șoc modifică cel mai mult dispersia și de ce dispersia zilei 5 este cunoscută la închiderea zilei 4.
- ▣ **Raportați:** tabelul completat și o propoziție
- ▣ **Notebook:** secțiunea A1

t	ε_{t-1}	$\alpha\varepsilon_{t-1}^2$	$\beta\sigma_{t-1}^2$	σ_t^2
1	—	—	—	1,0000
2	-2,0	0,4000	0,8500	1,3000
3	0,5	...	...	...
4	3,0	...	...	...
5	-1,0	...	...	...



A1 [Rezolvat]: rezolvare (1/2) — dispersiile filtrate

t	ε_{t-1}	$\alpha \varepsilon_{t-1}^2$	$\beta \sigma_{t-1}^2$	σ_t^2
1	—	—	—	1,0000
2	-2,0	0,4000	0,8500	1,3000
3	0,5	0,0250	1,1050	1,1800
4	3,0	0,9000	1,0030	1,9530
5	-1,0	0,1000	1,6600	1,8100

- $p = 0,95$, $\bar{\sigma}^2 = 0,05/0,05 = 1$; fiecare rând adaugă $\omega = 0,05$ celor doi termeni
- Rîndul 2: $0,05 + 0,10 \times 4 + 0,85 \times 1 = 1,3000$

- Șocul de +3% adaugă 0,90: dispersia sare la 1,9530 în ziua 4 și apoi scade cu factorul β
- σ_5^2 folosește doar ε_4 și σ_4^2 , ambele cunoscute la închiderea zilei 4: prognoza pe un pas este exactă în model
- Interpretare: contează mărimea șocului, nu semnul; un singur șoc mare crește dispersia multe zile

A1 [Rezolvat]: recursia într-un grafic



■ Negative shock ε_t
■ Positive shock ε_t
● Filtered variance σ_t^2
---- Long-run variance $\bar{\sigma}^2 = 1$

- Fiecare bară este un șoc; fiecare punct este dispersia pe care o produce a doua zi; σ_5^2 este prognoza pe un pas făcută la închiderea zilei 4

A1 [Rezolvat]: prognoza din ziua 4 — cerința (2/2)

▣ Întrebările

- ▶ care este dispersia pe 5 zile după aceste șocuri?
- ▶ este corectă regula rădăcinii pătrate a timpului?

▣ **Date:** modelul și $\sigma_5^2 = 1,8100$ din cerința 1; originea prognozei: închiderea zilei 4


▣ Cerințe

1. Aplicați $\mathbb{E}_4$ recursiei și folosiți $\mathbb{E}_4 \varepsilon_t^2 = \mathbb{E}_4 \sigma_t^2$ pentru $t \geq 5$ pentru a deduce $\mathbb{E}_4 \sigma_{4+h}^2 = \bar{\sigma}^2 + p^{h-1}(\sigma_5^2 - \bar{\sigma}^2)$.
 2. Calculați cele cinci prognoze pentru $h = 1, \dots, 5$.
 3. Explicați de ce dispersia randamentului pe 5 zile este suma $V_5 = \sum_{h=1}^5 \mathbb{E}_4 \sigma_{4+h}^2$ (indiciu: ε_t sînt necorelate, o diferență de martingală) și calculați V_5 și $\sqrt{V_5}$.
 4. Comparați V_5 cu $5\sigma_5^2$ și deduceți semnul lui $V_H - H\sigma_5^2$ în funcție de $\sigma_5^2 - \bar{\sigma}^2$.
 5. Calculați timpul de înjumătățire $\ln 0,5 / \ln p$.
- ▣ **Raportați:** formula prognozei, cele cinci prognoze, V_5 și $\sqrt{V_5}$, timpul de înjumătățire; interpretare: după un șoc de +3%, regula rădăcinii pătrate a timpului supraestimează sau subestimează riscul pe 5 zile?
- ▣ Notebook: secțiunea A1

A1 [Rezolvat]: rezolvare (2/2) — prognoze și riscul pe cinci zile

- Derivare: $\mathbb{E}_4 \sigma_{4+h}^2 = \omega + p \mathbb{E}_4 \sigma_{4+h-1}^2$; scădem $\bar{\sigma}^2 = \omega + p \bar{\sigma}^2$: distanța scade cu p pe zi, pornind de la σ_5^2 , cunoscută
- Distanța 0,8101; prognoze 1,8100; 1,7695; 1,7311; 1,6945; 1,6598; $V_5 = 5 + 0,8101 \times (1 - 0,95^5)/0,05 = 8,665$, $\sqrt{V_5} = 2,944\%$; timp de înjumătățire $-0,6931/(-0,0513) = 13,5$ zile
- $V_H - H\sigma_5^2 = (\bar{\sigma}^2 - \sigma_5^2) \sum_{j < H} (1 - p^j)$: aici $5\sigma_5^2 = 9,050 > V_5$. Interpretare: după o perioadă de volatilitate ridicată regula supraestimează riscul pe 5 zile, în perioade calme îl subestimează, deoarece dispersia revine la $\bar{\sigma}^2$

A1 [Rezolvat]: prognozele și riscul pe cinci zile într-un grafic



□ Stînga: prognozele converg spre $\bar{\sigma}^2 = 1$; dreapta: V_H rămîne sub $H\sigma_5^2$ deoarece dispersia revine la medie

B1 [Rezolvat]: GARCH-t pe S&P 500 — cerința (1/2)

▣ Întrebările

- ▶ există volatility clustering de modelat?
- ▶ ce indică despre acesta o estimare GARCH(1,1)-t?

▣ **Date:** S&P 500, 6 714 randamente zilnice (Datele folosite); media $r_t = \mu + \varepsilon_t$, inovații Student-t

▣ Cerințe

1. Testați H_0 : fără efecte ARCH cu Ljung–Box $Q(10)$ pe r_t^2 și testul LM al lui Engle cu 5 decalaje pe $r_t - \bar{r}$, la 5%.
2. Estimați GARCH(1,1)-t prin verosimilitate maximă și verificați convergența optimizatorului.
3. Raportați fiecare parametru cu eroarea standard robustă [Bollerslev & Wooldridge \(1992\)](#) și clasică și reprezentați r_t cu benzile $\pm 2\hat{\sigma}_t$.

▣ **Raportați:** cele două decizii de test, tabelul estimărilor, graficul

▣ Notebook: secțiunea B1


```
from arch import arch_model
am = arch_model(r, mean='Constant',
                vol='GARCH', p=1, q=1,
                dist='t')
res = am.fit(dispatch='off')
print(res.convergence_flag) # 0 = ok
rob = res.std_err           # robust
cl = am.fit(dispatch='off',
            cov_type='classic').std_err
sig = res.conditional_volatility
```

B1 [Rezolvat]: rezolvare (1/2) — teste, estimări, ajustare

Parametru	Estimare	E.s. robustă	E.s. clasică
μ	0,0788	0,0089	0,0090
ω	0,0157	0,0032	0,0029
α	0,1226	0,0107	0,0101
β	0,8721	0,0103	0,0096
ν	6,26	0,48	0,48

- (1) $Q(10) = 6133$ și $LM(5) = 1684$ față de 18,3 și 11,1: absența efectelor ARCH este respinsă ($p < 0,001$)
- (2) Convergență după 14 iterații, $\ell = -9062,5$; persistența 0,9947
- (3) Rapoartele robust/clasic 1,06 (α), 1,08 (β): densitatea Student-t este ea însăși greșit specificată (asimetrie -0,58); estimatorul sandwich ține cont de acest lucru

B1 [Rezolvat]: volatilitatea estimată



□ Interpretare: $\hat{\beta}$ preia dispersia de ieri, $\hat{\alpha}$ adaugă știrile, $\hat{\nu}$ semnalează cozi groase; 5,1% din zile cad în afara benzii $\pm 2\hat{\sigma}_t$

B1 [Rezolvat]: diagnosticul reziduurilor — cerința (2/2)


- ▣ **Întrebarea:** după estimarea GARCH-t, rămîne vreo structură în $\hat{z}_t = (r_t - \hat{\mu})/\hat{\sigma}_t$?
- ▣ **Date:** estimarea din cerința 1; fiecare test are H_0 : modelul reproduce proprietatea respectivă
- ▣ **Cerințe**
 1. Testați ecuația mediei cu Ljung–Box $Q(10)$ pe $\hat{z}_t$ (H_0 : fără autocorelație pînă la decalajul 10).
 2. Testați ecuația dispersiei cu $Q(10)$ pe $\hat{z}_t^2$ și testul LM(5) (H_0 : fără volatility clustering rămas).
 3. Estimați regresia de asimetrie [Engle & Ng \(1993\)](#) $\hat{z}_t^2 = b_0 + b_1 S_{t-1}^- + b_2 S_{t-1}^- \hat{e}_{t-1} + b_3 S_{t-1}^+ \hat{e}_{t-1}$, cu $S_{t-1}^- = 1(\hat{e}_{t-1} < 0)$ și $S^+ = 1 - S^-$; raportați cele trei statistici t și testul comun $nR^2 \sim \chi_3^2$ (H_0 : fără asimetrie rămasă).
 4. Reprezentați ACF pentru $\hat{z}_t$ și $\hat{z}_t^2$ și un grafic QQ al lui $\hat{z}_t$ față de distribuția Student-t standardizată estimată.
- ▣ **Raportați:** un tabel cu statistica, valoarea p și decizia pentru fiecare test și cele trei grafice; interpretare:
 - ▶ ce componentă a modelului nu trece testele de diagnostic?
 - ▶ ce ați schimba întîi?
- ▣ Notebook: secțiunea B1

B1 [Rezolvat]: rezolvare (2/2) — diagnostic

Partea	Test	p	Decizia la 5%
Media	$Q(10)$, $\hat{z}$: 21,9	0,016	respins
Dispersia	$Q(10)$, $\hat{z}^2$: 13,6	0,192	nerespins
	$LM(5)$: 5,8	0,326	nerespins
Asimetria	comun χ^2_3 : 40,7	< 0,001	respins

- Asimetria de semn $t = 3,56$, mărime negativă $t = 1,13$, mărime pozitivă $t = -2,61$
- QQ: 16 reziduuri sub -4 , față de 8,5 așteptate; coada stîngă este mai lungă decît cea a distribuției t estimate

B1 [Rezolvat]: ACF ale reziduurilor și graficul QQ



- ☐ Toate valorile p folosesc legile χ^2 naive, aproximative cu parametri estimați Li & Mak (1994). Interpretare: volatility clustering este reprodus de model, asimetria nu: se adaugă un termen de semn (B2)

B2 [Rezolvat]: GJR față de GARCH pe S&P 500 — cerința

▣ Întrebările

- ▶ cresc știrile proaste volatilitatea S&P 500 mai mult decât cele bune?
- ▶ cu cât?

- ▣ **Date:** datele din B1; `arch_model(r, p=1, o=1, q=1, dist='t')` estimează GJR-GARCH(1,1)-t, care include GARCH-t pentru $\gamma = 0$; impactul știrilor la $\sigma_{t-1}^2 =$ dispersia de selecție 1,47

▣ Cerințe

1. Estimați GJR-GARCH(1,1)-t și raportați $\hat{\alpha}$, $\hat{\gamma}$ cu t robust și $\hat{\beta}$.
2. Construiți tabelul de comparație: numărul de parametri k , ℓ , AIC, BIC pentru GARCH-t și GJR-t.
3. Testați $H_0: \gamma = 0$ cu $LR = 2(\ell_{GJR} - \ell_{GARCH})$ față de χ_1^2 și precizați ipotezele din spatele acestei legi.
4. Calculați dispersia de a doua zi după șocuri de -3% și $+3\%$ în ambele modele și reprezentați cele două curbe de impact al știrilor.

- ▣ **Raportați:** estimările, tabelul de comparație, decizia LR și graficul impactului știrilor; interpretare:

- ▶ de ce este $\hat{\alpha} = 0$?
- ▶ ce efect are asupra legii χ_1^2 ?



- ▣ Notebook: secțiunea B2

B2 [Rezolvat]: rezolvare (1/2) — comparația modelelor imbricate

Model	k	ℓ	AIC	BIC
GARCH(1,1)-t	5	-9062,473	18134,9	18169,0
GJR-GARCH(1,1)-t	6	-8944,647	17901,3	17942,2

- (1) $\hat{\alpha} = 0,000$, $\hat{\gamma} = 0,205$ ($t_{\text{robust}} = 10,03$), $\hat{\beta} = 0,881$, $\hat{\omega} = 0,0187$, $\hat{\nu} = 6,96$: panta știrilor bune $\hat{\alpha}$, a celor proaste $\hat{\alpha} + \hat{\gamma}$
- (2) $\Delta\text{AIC} = -233,7$, $\Delta\text{BIC} = -226,8$ (GJR minus GARCH): ambele preferă GJR
- (3) $LR = 2(-8944,647 - (-9062,473)) = 235,65$, mult peste 3,84
- Ipotezele legii χ^2_1 : o densitate Student-t corectă și toți ceilalți parametri interiori
 - Ambele sînt îndoielnice aici: B1 a găsit asimetrie, iar $\hat{\alpha} = 0$ este la limita $\alpha \geq 0$, deci legea este nestandard [Andrews \(2001\)](#)
 - Concluzie nuanțată: un LR de 235,65 este de circa 60 de ori valoarea critică la 5%; o verificare calibrată ar simula LR sub GARCH-t estimat (cum face B7 pentru IGARCH)

B2 [Rezolvat]: rezolvare (2/2) — impactul știrilor



— GARCH(1,1)-t — GJR-GARCH(1,1)-t Starting variance σ_{t-1}^2 = sample variance

- (4) S&P 500, GJR: -3% dă 3,16, +3% dă 1,31 (de 2,40 ori mai puțin); GARCH: 2,40 pentru ambele semne
- Cu $\hat{\alpha} = 0$ un șoc de +3% chiar scade dispersia, de la 1,47 la 1,31. Interpretare: la S&P 500, doar știrile proaste cresc dispersia de mâine; panoul pentru BET corespunde exercițiului B3

B3 [Propus]: GJR față de GARCH pe BET — cerința

- **Întrebarea:** este asimetria bursei de la București la fel de puternică precum cea a S&P 500?
- **Date:** BET, 6 670 de randamente zilnice (Datele folosite); aceleași două modele și același cod ca în B2; $\ln n = 8,81$
- **Cerințe**
 1. Estimați ambele modele și completați tabelul de comparație din B2 (k , ℓ , AIC, BIC) pentru BET.
 2. Calculați LR și comparați-l cu cele patru praguri: 2 (AIC), 3,84 și 6,63 (χ^2_1 la 5% și 1%) și $\ln n$ (BIC); precizați fiecare decizie.
 3. Calculați impactul știrilor pentru BET la $\pm 3\%$ pornind de la dispersia de selecție, ca în B2.
- **Raportați:** tabelul, cele patru decizii, cele două valori de impact; interpretare:
 - ▶ de ce pot LR și BIC să conducă la decizii diferite?
 - ▶ dovedește un $\hat{\gamma}$ mai mic că BET este mai puțin asimetric decât S&P 500?
- Model: B2
- Notebook: secțiunea B3

C2 [Propus]: critica unui răspuns AI — cerința

- ▣ **Cererea:** „px conține închiderile zilnice S&P 500. Estimează un GARCH(1,1) cu inovații Student-*t* cu arch și dă-mi volatilitatea anualizată de termen lung și timpul de înjumătățire al unui șoc.”
- ▣ **Date:** px = load_close('sp500'), 6 715 închideri, 2000-01-03 – 2026-09-18
- ▣ **Rezultatul răspunsului:** ann_vol = 66,46, half_life = 0,74 zile și un DataScaleWarning
- ▣ **Cerințe**
 1. Rulați codul și reproduceți rezultatul.
 2. Găsiți erorile de formulă, erorile de unitate și riscurile numerice, fiecare cu numărul liniei.
 3. Pentru fiecare, indicați dovada care o evidențiază (un avertisment, o cifră din A1 sau B1) și linia corectată.
 4. Rulați codul corectat și notați fiecare eroare ca în AI_ERRORS.md.
- ▣ **Model:** A1, B1; anualizarea: secțiunea „Noțiuni necesare azi” și slide-ul „Datele folosite”

```
1 import numpy as np
2 from arch import arch_model
3 r = np.log(px).diff().dropna()
4 am = arch_model(r, vol='GARCH', p=1,
5                 q=1, dist='t')
6 res = am.fit(disp='off')
7 om = res.params['omega']
8 a = res.params['alpha[1]']
9 b = res.params['beta[1]']
10 lr_var = om / (1 - a - b)
11 ann_vol = lr_var * 252
12 half_life = np.log(0.5) / np.log(b)
```

A3 [Rezolvat]: volatilitatea de termen lung și timpul de înjumătățire — cerința


- ▣ **Întrebarea:** cât de precis determină estimarea din B1 volatilitatea de termen lung și timpul de înjumătățire?
- ▣ **Date:** B1: $\hat{\omega} = 0,015714$, $\hat{\alpha} = 0,122573$, $\hat{\beta} = 0,872139$, $q = 251,4$; covarianța robustă a lui $(\hat{\omega}, \hat{\alpha}, \hat{\beta})$, în această ordine:

$$\hat{V} = \begin{pmatrix} 1,001 \times 10^{-5} & 1,421 \times 10^{-5} & -2,242 \times 10^{-5} \\ . & 1,153 \times 10^{-4} & -1,002 \times 10^{-4} \\ . & . & 1,069 \times 10^{-4} \end{pmatrix} \text{ (res.param_cov)}$$
- ▣ **Cerințe**
 1. Deduceți $\bar{\sigma}^2 = \omega / (1 - \alpha - \beta)$ din recursie și calculați volatilitatea anuală de termen lung $v = \sqrt{q \bar{\sigma}^2}$ și timpul de înjumătățire.
 2. Calculați $\nabla \bar{\sigma}^2$, forma pătratică $\nabla' \hat{V} \nabla$ și, cu $\partial v / \partial \bar{\sigma}^2 = q / (2v)$, eroarea standard a lui v .
 3. Calculați $\widehat{e.s.}(\hat{p})$ din $\hat{V}$ și eroarea standard prin metoda delta a lui $h(p) = \ln 0,5 / \ln p$, definită pentru $0 < p < 1$.
 4. Transformați intervalul de 95% pentru p într-un interval pentru h și precizați ce se întâmplă când intervalul depășește 1.
- ▣ **Raportați:** v cu e.s., h cu e.s. și intervalul transformat; interpretare: de ce eșuează liniarizarea pentru h ?
- ▣ **Notebook:** secțiunea A3

A3 [Rezolvat]: rezolvare — gradienti și intervalul timpului de înjumătățire

- (1) $\hat{p} = 0,994712$, $\bar{\sigma}^2 = 2,972$, $v = 1,724 \times \sqrt{251,4} = 27,3\%$ (în eșantion: 19,2%); $h = -0,6931/(-0,005302) = 130,7$ zile
- (2) $\nabla \bar{\sigma}^2 = (1/(1-p), \omega/(1-p)^2, \omega/(1-p)^2) = (189,1, 562,0, 562,0)$; $\widehat{e.s.}(\bar{\sigma}^2) = 2,35$; $\widehat{e.s.}(v) = 10,8$ puncte în jurul a 27,3%
- (3) $\widehat{e.s.}(\hat{p}) = \sqrt{V_{\alpha\alpha} + 2V_{\alpha\beta} + V_{\beta\beta}} = 0,0047$; $\partial h / \partial p = 24\,789$, deci $\widehat{e.s.}(\hat{h}) = 116$ zile
- (4) $[0,9855; 1,0039]$ depășește 1: $h \in [48; \infty)$, fără limită superioară finită în modelul staționar. Interpretare: $h(p)$ este atât de curbată lângă 1 încât aproximarea liniară nu mai este informativă; ipoteza $p = 1$ necesită un test (B7)

A3 [Rezolvat]: curba timpului de înjumătățire



- Tangenta (metoda delta) trece prin zero în interiorul intervalului pentru p ; transformarea exactă $h(p)$ nu are capăt superior finit

B7 [Rezolvat]: ipoteza $\alpha + \beta = 1$, bootstrap și test la frontieră — cerința

▣ Întrebările

- ▶ cât de variabil este $\hat{p} = \hat{\alpha} + \hat{\beta}$?
- ▶ poate dispersia S&P 500 să aibă o rădăcină unitară?


- ▣ **Date:** estimarea B1, $\hat{p} = 0,9947$; cod `param_bootstrap`, `igarch_test` (notebook); valoare de inițializare 42 (43 sub H_0); fiecare traiectorie: 6 714 zile după 500 de zile de burn-in (eliminate la început), pornind de la dispersia de selecție; fiecare estimare impune $\alpha + \beta \leq 1$ și păstrează cea mai bună din două puncte de pornire

▣ Cerințe

1. Algoritmul 1 (variabilitatea estimatorului): simulați $B = 999$ traiectorii din GARCH-t **estimat**, reestimați p pe fiecare și raportați percentilele de 2,5% și 97,5% și proporția extragerilor la $p = 1$.
2. Algoritmul 2 (test): estimați IGARCH-t ($\alpha + \beta = 1$), calculați $LR = 2(\ell_{GARCH} - \ell_{IGARCH})$, simulați B traiectorii **sub** H_0 , reestimați ambele modele pe fiecare și calculați $p = (1 + \#\{LR^* \geq LR\})/(B + 1)$.
3. Comparați această valoare p cu valorile din χ_1^2 și $\frac{1}{2}\chi_0^2 + \frac{1}{2}\chi_1^2$ și decideți la 5% și 10%.


- ▣ **Raportați:** două histograme, intervalul, trei valori p și decizia; interpretare: de ce „intervalul bazat pe percentile atinge 1” nu este un test pentru $p = 1$ [Andrews \(2000\)](#)?
- ▣ Notebook: secțiunea B7

B7 [Rezolvat]: rezolvare (1/2) — variabilitatea estimatorului



- Interval de 95% bazat pe percentile [0,9833; 1,0000]; abaterea standard bootstrap 0,0047 față de e.s. robustă 0,0047: apropiate; 8,9% din extrageri sînt exact la limita $p = 1$
- Timpul de înjumătățire de la 41 de zile la ∞ (metoda delta: 116 zile, A3). Interpretare: lîngă o limită intervalul bazat pe percentile descrie dispersia, nu este automat un interval de încredere valid [Andrews \(2000\)](#)

B7 [Rezolvat]: rezolvare (2/2) — testul sub ipoteza nulă




- IGARCH-t: $\hat{\alpha}_0 = 0,127$, $\hat{\nu}_0 = 6,03$;
 $LR = 1,11$; $LR^* = 0$ exact pentru 44,2% din extrageri (aproape de jumătatea implicată de distribuția de tip amestec; cursul raportează ponderea reestimărilor cu $\hat{\alpha} + \hat{\beta} \geq 0,999$, 52%); 174 din 999 de extrageri depășesc LR
- $p = 0,17$ (bootstrap), 0,15 (amestec), 0,29 (χ_1^2 naiv): H_0 nu este respinsă nici la 5%, nici la 10%. Interpretare: 27 de ani de date nu permit distingerea unui timp de înjumătățire de circa 130 de zile de unul infinit

B5 [Rezolvat]: compararea prognozelor pe S&P 500 — cerința (1/2)

- ▣ **Întrebarea:** prognozează vreun model dispersia de mâine a S&P 500 mai bine decât GARCH-t?
- ▣ **Date:** 2692 de zile de prognoză, 2016-01-04 – 2026-09-18; GARCH-N, GARCH-t, GJR-t, EGARCH-t reestimate în fiecare ianuarie (fereastră în expansiune); EWMA ($\lambda = 0,94$) [J.P. Morgan/Reuters \(1996\)](#); Hist-20 (media ultimelor 20 de r_t^2); aproximarea r_t^2
- ▣ **Cerințe**
 1. Pe graficul cronologic, verificați că h_t folosește doar date pînă la închiderea zilei $t - 1$ și că parametrii sînt ficși în cursul unui an.
 2. Calculați QLIKE = $r_t^2/h_t + \ln h_t$ pas cu pas pentru GARCH-t și EWMA pe 2020-03-13, 2020-03-16 și 2020-03-17 (tabelul de mai jos).
 3. Calculați QLIKE mediu pentru toate cele șase modele și t DM pentru $d_t = L_t^m - L_t^{GARCH-t}$ (HAC, 5 decalaje) [Diebold & Mariano \(1995\)](#); reprezentați $\sum d_t$ cumulat.
- ▣ **Raportați:** cele trei rînduri QLIKE, un tabel cu QLIKE mediu și t DM, graficul pierderilor; interpretare: ce diferențe pot fi considerate semnificative?
- ▣ Notebook: secțiunea B5

Ziua	r_t	r_t^2	h_t GARCH-t	h_t EWMA	QLIKE
2020-03-13	8,88	78,87	25,38	15,66	...
2020-03-16	-12,77	162,95	31,18	19,45	...
2020-03-17	5,82	33,90	46,06	28,06	...



B5 [Rezolvat]: rezolvare (1/3) — momentul prognozei și QLIKE pas cu pas



Ziua	L GARCH-t	L EWMA
2020-03-13	6,342	7,789
2020-03-16	8,666	11,346
2020-03-17	4,566	4,543

- de ex. 2020-03-16:
 $162,95/31,18 + \ln 31,18 = 8,666$; prognoza EWMA este mai mică, deci pierderea este mai mare: subestimarea este penalizată
- Prima țintă 2016-01-04, originea 2015-12-31: reestimare pe datele pînă la 31 decembrie, fără look-ahead (informație din viitor)

B5 [Rezolvat]: rezolvare (2/3) — diferențele de pierderi



— GARCH-N minus GARCH-t — GJR-t minus GARCH-t — EGARCH-t minus GARCH-t — EWMA minus GARCH-t — Hist-20 minus GARCH-t

- QLIKE mediu: GJR-t 0,7319, GARCH-t 0,7570; EWMA ($t_{DM} = 3,48$) și Hist-20 ($t = 4,10$) sînt mai slabe, diferența lor crește în martie 2020; statisticile t din familia GARCH sînt descriptive (modele imbricate, fereastră în expansiune: B5 extins)

B5 [Rezolvat]: calibrarea — cerința (2/2)

▣ Întrebările


- ▶ sînt prognozele GARCH-t nedeplasate în niveluri?
- ▶ ce zile determină răspunsul?

▣ **Date:** cele 2692 de perechi (h_t, r_t^2) din cerința 1

▣ Cerințe

1. Estimați regresia Mincer–Zarnowitz $r_t^2 = a + b h_t + u_t$ Mincer & Zarnowitz (1969) cu erori HAC (5 decalaje) și testați comun $a = 0$, $b = 1$.
 2. Reprezentați r_t^2 față de h_t , cu dreapta estimată și dreapta de 45 de grade, și un grafic cu mediile pe 20 de grupe de h_t .
 3. Reestimați fără cele mai mari trei valori r_t^2 și comparați b .
- ▣ **Raportați:** a , b cu e.s., R^2 , p Wald, graficul, b fără cele trei zile; interpretare: este un R^2 mic semnul unei prognoze proaste?
- ▣ Notebook: secțiunea B5

B5 [Rezolvat]: rezolvare (3/3) — calibrarea



- $a = 0,08$ (e.s. 0,24), $b = 0,88$ (e.s. 0,25), $R^2 = 0,238$, p Wald = 0,804: nedeplasarea nu este respinsă; mediile pe grupe sînt aproape de dreapta de 45 de grade
- Fără 2020-03-16, 2020-03-12, 2025-04-09: $b = 0,64$ (e.s. 0,09), p Wald < 0,001. Interpretare: trei zile de criză domină regresia în niveluri; R^2 mic reflectă aproximarea zgometoasă r_t^2 , nu un model inadecvat [Patton \(2011\)](#)

Exercițiu de transfer: alegeți B4, B6 sau B8

- ▣ Alegeți un exercițiu din pachetele de extensie și rezolvați-l cu codul modelului său
 - ▶ B4: distribuțiile inovațiilor pentru Bitcoin (model: B1, B2); B6: compararea prognozelor pe BET (model: B5); B8: bootstrap și testul IGARCH pe BET (model: B7)
- ▣ Livrabil
▶ Tabelul și graficul cerute, răspunsul la întrebarea de interpretare și o limită
- ▣ Autoevaluare
 - ▶ Reproducibilitate: notebook-ul rulează de la început la sfârșit și reproduce fiecare cifră raportată
 - ▶ Inferență corectă: distribuția potrivită sub H_0 (frontieră, modele imbricate), incertitudinea raportată pentru fiecare estimare
 - ▶ Interpretare: o afirmație susținută de cifre, cu limita ei
- ▣ Folosirea AI este permisă; notați erorile depistate efectiv, în formatul din `AI_ERRORS.md`

Verificare finală

Verificare finală (răspuns în două rînduri)

- ▣ O concluzie justificată: ce model ați folosi pentru S&P 500 și de ce?
- ▣ O limită nerezolvată: ce nu pot decide datele (de ex. $p = 1$)?

Pachetele de extensie: conținut și cerințe

Exercițiu	Întrebare	Tip	Model
A2	persistența GJR când inovațiile sînt asimetrice	Propus	A1
A4	este momentul de ordin patru finit?	Propus	A1, A3
A5	dispersia robustă și clasică a QMLE Gaussian	Propus	A3
A6	autocorelația pătratelor șocurilor	Propus	A1
B4	distribuțiile inovațiilor pentru Bitcoin	Propus	B1, B2
B5 extins	Giacomini–White și Model Confidence Set	Rezolvat	–
B6	compararea prognozelor pe BET	Propus	B5
B8	bootstrap și testul IGARCH pe BET	Propus	B7
C1	determină știrile din SUA volatilitatea BET? (proiect)	Propus	B1, B2
C3	GARCH bazat pe un cvasi-scor pe acțiuni americane (proiect)	Propus	B1, B2

- Fiecare pachet are același format: întrebare, date, cerințe numerotate, ce se raportează; rezolvările exercițiilor propuse se discută la seminar

A2 [Propus]: persistența GJR cu inovații asimetrice — cerința

- ▣ **Întrebarea:** care este persistența GJR-GARCH când z_t este asimetric?
- ▣ **Date:** S&P 500, GJR-GARCH(1,1) cu inovații t asimetrice Hansen [Hansen \(1994\)](#): $\hat{\alpha} = 0,00000$, $\hat{\gamma} = 0,21116$, $\hat{\beta} = 0,87965$, $\hat{\nu} = 7,70$, $\hat{\lambda} = -0,150$; densitatea standardizată este `SkewStudent().loglikelihood` din `arch`
- ▣ **Cerințe**
 1. Aplicați speranța matematică în recursie și arătați că persistența este $\alpha + \gamma m_- + \beta$, cu $m_- = \mathbb{E}[z_t^2 1(z_t < 0)]$.
 2. Arătați că $m_- = 1/2$ pentru z_t simetric și explicați de ce m_- diferă în general de $P(z_t < 0)$.
 3. Integrați numeric `quad(f, -inf, 0)` și `quad(lambda z: z**2*f(z), -inf, 0)`; verificați $\int f = 1$ și $\int z^2 f = 1$ pe toată axa.
 4. Calculați persistența și timpul de înjumătățire cu m_- și cu $1/2$.
- ▣ **Raportați:** m_- , $P(z < 0)$, ambele persistențe și ambii timpi de înjumătățire; interpretare: ce se întâmplă dacă se folosește $\alpha + \gamma/2 + \beta$ cu inovații asimetrice?
- ▣ Model: A1
- ▣ Notebook: secțiunea A2

A4 [Propus]: existența momentului de ordin patru — cerința

▣ Întrebările

- ▶ au modelele estimate pentru S&P 500 un kurtosis finit?
- ▶ le poate valida kurtosis-ul de selecție?

- ▣ **Date:** GARCH-N: $\hat{\alpha} = 0,120604$, $\hat{\beta} = 0,859878$; GARCH-t: $\hat{\alpha} = 0,1226$, $\hat{\beta} = 0,8721$, $\hat{\nu} = 6,256$; kurtosis-ul de selecție al randamentelor 13,7 (total, nu exces)

▣ Cerințe

1. Arătați că $\mathbb{E}\varepsilon_t^4 = \kappa_z \mathbb{E}\sigma_t^4$ și $\mathbb{E}\sigma_t^4 < \infty$ dacă și numai dacă $\mathbb{E}(\alpha z_t^2 + \beta)^2 = (\alpha + \beta)^2 + (\kappa_z - 1)\alpha^2 < 1$.
 2. Pentru GARCH-N ($\kappa_z = 3$) calculați condiția și kurtosis-ul total $K = 3[1 - (\alpha + \beta)^2]/[1 - (\alpha + \beta)^2 - 2\alpha^2]$, cu numitorul afișat; repetați cu estimările rotunjite la 3 zecimale.
 3. Pentru GARCH-t calculați $\kappa_z = 3(\nu - 2)/(\nu - 4)$ și condiția.
- ▣ **Raportați:** un rînd pentru fiecare model: κ_z , condiția, finit sau nu, K ; interpretare: este concordanța cu kurtosis-ul de selecție un test al modelului?
- ▣ Model: A1, A3
- ▣ Notebook: secțiunea A4

A5 [Propus]: dispersia robustă și clasică, ARCH(1) — cerința

- ▣ **Întrebarea:** cât de mare este eroarea inversei hessienei ca estimator al dispersiei QMLE Gaussian când z_t nu este Normal?
- ▣ **Date:** ARCH(1), $\sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2$, ω cunoscut; $\ell_t = -\frac{1}{2}(\ln \sigma_t^2 + \varepsilon_t^2/\sigma_t^2)$; $x_t = \varepsilon_{t-1}^2/\sigma_t^2$ este cunoscut la $t-1$ și independent de z_t ; identități $\partial \sigma_t^2/\partial \alpha = \varepsilon_{t-1}^2$, $\varepsilon_t^2/\sigma_t^2 = z_t^2$
- ▣ **Cerințe**
 1. Arătați că scorul este $s_t = \frac{1}{2}(z_t^2 - 1)x_t$ și că $B = \mathbb{E}s_t^2 = \frac{1}{4}(\kappa_z - 1)\mathbb{E}x_t^2$.
 2. Arătați că $\partial^2 \ell_t/\partial \alpha^2 = \frac{1}{2}x_t^2(1 - 2z_t^2)$ și $A = \frac{1}{2}\mathbb{E}x_t^2$.
 3. Arătați că dispersia asimptotică a lui $\sqrt{n}(\hat{\alpha} - \alpha)$ este $A^{-1}BA^{-1} = \frac{\kappa_z - 1}{2}A^{-1}$; dispersia în eșantion finit o împarte la n .
 4. Calculați raportul e.s. $\sqrt{(\kappa_z - 1)/2}$ pentru Student-t cu $\nu = 6,26$ și pentru $\hat{\kappa}_z = 4,73$.
- ▣ **Raportați:** s_t , A , B , raportul, două cifre; interpretare: ce se întâmplă cu teoria în $\sqrt{n}$ când $\kappa_z = \infty$?
- ▣ Model: A3
- ▣ Notebook: secțiunea A5

A6 [Propus]: autocorelația pătratelor șocurilor — cerința

▣ Întrebările

- ▶ este ACF a lui r_t^2 implicată de GARCH-N compatibilă cu datele?
- ▶ cât de precisă este ACF de selecție?

- ▣ **Date:** forma ARMA(1,1) $\varepsilon_t^2 = \omega + (\alpha + \beta)\varepsilon_{t-1}^2 + \nu_t - \beta\nu_{t-1}$ (curs); ARMA(1,1): $\rho_1 = (1 + \phi\theta)(\phi + \theta)/(1 + 2\phi\theta + \theta^2)$, $\rho_k = \phi^{k-1}\rho_1$; S&P 500 GARCH-N: $\hat{\omega} = 0,0254$, $\hat{\alpha} = 0,1206$, $\hat{\beta} = 0,8599$

▣ Cerințe

1. Înlocuiți $\phi = \alpha + \beta$, $\theta = -\beta$ și deduceți $\rho_1(\varepsilon^2)$.
2. Calculați ρ_1 , ρ_{10} și reprezentați ACF teoretică față de ACF de selecție a lui $(r_t - \bar{r})^2$, decalajele 1–50.
3. Simulați 200 de traiectorii GARCH-N de lungimea eșantionului (500 de zile de burn-in, eliminate la început; valoare de inițializare 44) și adăugați anvelopa de 95% a ACF de selecție.

- ▣ **Raportați:** formula, ρ_1 , ρ_{10} , graficul; interpretare: este concordanța ACF a lui r_t^2 o verificare puternică sau slabă?

- ▣ Model: A1

- ▣ Notebook: secțiunea A6

B4 [Propus]: distribuțiile inovațiilor pentru Bitcoin — cerința

▣ Întrebările

- ▶ ce distribuție a inovațiilor descrie Bitcoin?
- ▶ este validă inferența QMLE Gaussian în acest caz?

- ▣ **Date:** prețurile de închidere ale Bitcoin (BTC/USD) din 2014-09-17; randamente 2014-09-18 – 2026-09-18, 4 384 de randamente, 365 de zile pe an; GARCH(1,1), medie constantă

▣ Cerințe

1. Estimați cu inovații Normale și Student-t; comparați ℓ și BIC și reprezentați graficele QQ ale lui $\hat{z}_t$ față de fiecare lege estimată.
2. Testați distribuția Normală ($1/\nu = 0$) față de Student-t prin LR cu legea la frontieră $\frac{1}{2}\chi_0^2 + \frac{1}{2}\chi_1^2$ (valoarea critică la 5%: 2,71).
3. Opțional: adăugați t asimetric (ν, λ) și GED (forma ν_G); testați $\lambda = 0$ prin LR; raportați fiecare parametru de formă cu e.s. și semnalați limitele active.

- ▣ **Raportați:** un tabel cu ℓ , BIC, persistență și parametrii de formă, graficul QQ, testele LR; interpretare:

- ▶ cu $\hat{\nu} < 4$, este validă inferența QMLE Gaussian [Hall & Yao \(2003\)](#)?
- ▶ prin ce diferă pentru MLE Student-t?

- ▣ Model: B1, B2

- ▣ Notebook: secțiunea B4

B5 extins [Rezolvat]: Giacomini–White și Model Confidence Set — cerința


- ▣ **Întrebarea:** care comparații din B5 rămân valabile după luarea în calcul a parametrilor estimați, a modelelor imbricate și a celor șase modele concurente?
- ▣ **Date:** S&P 500 și BET; fereastră mobilă de $W = 1\,000$ de zile, reestimată în fiecare ianuarie (GW); pierderile QLIKE cu fereastră în expansiune din B5 (MCS)
- ▣ **Cerințe**
 1. Pentru fiecare model m , formați $d_{t+1} = L_{t+1}^m - L_{t+1}^{GARCH-t}$ și $Z_{t+1} = (1, d_t)' d_{t+1}$; calculați $GW = n\bar{Z}'\hat{\Omega}^{-1}\bar{Z}$ cu $\hat{\Omega} = n^{-1} \sum Z_{t+1}Z_{t+1}'$ și comparați cu $\chi_2^2(5,99)$ [Giacomini & White \(2006\)](#).
 2. Calculați Model Confidence Set 90% [Hansen, Lunde & Nason \(2011\)](#): statistica T_R , bootstrap staționar cu bloc mediu 10, 10 000 de extrageri, valoarea de inițializare 42 (arch.bootstrap.MCS).
 3. Raportați ordinea eliminării și modelele păstrate, pentru ambele piețe.
- ▣ **Raportați:** statisticile GW și valorile p , valorile p MCS, graficul; interpretare:
 - ▶ de ce nu este valid DM pentru GJR-t față de GARCH-t [West \(1996\)](#), [Clark & McCracken \(2001\)](#)?
 - ▶ concordă DM și MCS?
- ▣ Notebook: secțiunea B5

B5 extins [Rezolvat]: rezolvare

Model	GW S&P	p	MCS p S&P	MCS p BET
GARCH-N	5,85	0,054	0,586	0,658
GARCH-t	—	—	0,353	0,108
GJR-t	2,49	0,288	1,000	1,000
EGARCH-t	3,21	0,201	0,586	0,658
EWMA	11,40	0,003	0,008	0,108
Hist-20	16,41	< 0,001	0,001	0,026

- S&P 500: GW respinge doar EWMA și Hist-20; ordinea eliminării Hist-20, EWMA, GARCH-t, GARCH-N, EGARCH-t, GJR-t; păstrate: cele patru modele GARCH. BET: ordinea Hist-20, GARCH-t, EWMA, GARCH-N, EGARCH-t, GJR-t; MCS păstrează și EWMA ($p = 0,108$)

B5 extins [Rezolvat]: GW și MCS într-un grafic



- Interpretare: sub H_0 , diferența DM pentru modele imbricate cu fereastră în expansiune degenerază; GW testează metoda și rămîne valid; MCS controlează eroarea pentru șase modele, ceea ce testele DM pe perechi nu fac

B6 [Propus]: compararea prognozelor pe BET — cerința

- ▣ **Întrebarea:** rămân valabile concluziile din B5 pentru bursa de la București?
- ▣ **Date:** BET, 2 675 de zile de prognoză, 2016–2026; aceleași șase modele, fereastră în expansiune, aproximare și cod ca în B5
- ▣ **Cerințe**
 1. Calculați QLIKE mediu, t DM față de GARCH-t și $\sum d_t$ cumulat.
 2. Estimați regresia MZ pentru GARCH-t cu erori HAC; raportați a , b , e.s., R^2 și p Wald și reprezentați graficul de calibrare.
 3. Puneți rezultatele S&P 500 și BET alături, cu fereastra de estimare a fiecărei cifre.
- ▣ **Raportați:** două tabele și două grafice; interpretare:
 - ▶ sînt calibrate prognozele pentru BET?
 - ▶ ce ați testa în continuare?
- ▣ Model: B5
- ▣ Notebook: secțiunea B6

B8 [Propus]: bootstrap și testul IGARCH pentru BET — cerința

▣ Întrebările

- ▶ cât de precisă este persistența BET?
- ▶ poate dispersia ei să aibă o rădăcină unitară?

▣ **Date:** BET GARCH-t, $\hat{p} = 0,9907$ (timp de înjumătățire 74 de zile); cei doi algoritmi și funcțiile din B7, $B = 999$

▣ Cerințe

1. Rulați algoritmul 1 și raportați intervalul bazat pe percentile pentru p , intervalul timpului de înjumătățire și proporția extragerilor la $p = 1$.
2. Comparați abaterea standard bootstrap a lui $\hat{p}^*$ cu e.s. robustă a lui $\hat{\alpha} + \hat{\beta}$.
3. Rulați algoritmul 2 și comparați valorile p bootstrap, din amestec și din χ_1^2 , la 5%.

▣ **Raportați:** intervalele, cele două e.s., testul și graficul cu două panouri; interpretare: ordonează intervalele separate pentru BET și S&P 500 cei doi timpi de înjumătățire?

▣ Model: B7

▣ Notebook: secțiunea B8

C1 [Propus]: efectul știrilor din SUA asupra volatilității BET — cerința (1/2): date și momentul observațiilor

▣ Întrebările

- ▶ crește șocul S&P 500 de ieri dispersia BET de azi?
- ▶ cu cât?

- ▣ **Date:** prețurile de închidere BET și S&P 500, 2000-01-07 – 2026-09-18; se aliniază *prețurile* pe zilele comune, apoi se calculează randamentele; t indexează zilele comune

▣ Cerințe


1. Construiți eșantionul zilelor comune și u_{t-1} , randamentul S&P 500 din ziua comună precedentă (Wall Street închide după București).
2. Verificați săptămîna cu sărbători de mai jos: pe 2 decembrie 2025, u_{t-1} este randamentul S&P 500 de la 26 la 28 noiembrie (0,69%); precizați ce ședință americană lipsește și în ce randament este inclusă.

- ▣ **Raportați:** numărul zilelor comune și verificarea momentului

- ▣ Model: B1, B2

- ▣ Notebook: secțiunea C1

C1 [Propus]: calendarul zilelor comune în jurul unei sărbători



- Marcaje pline: zile de tranzacționare; pătrate: zilele păstrate după alinierea prețurilor; cifrele sînt u_{t-1} pentru fiecare zi comună

C1 [Propus]: cerința (2/2): model, test, contribuție

- ▣ **Întrebările:** aceleași întrebări, acum ca model estimat
- ▣ **Date:** $r_t = \mu + \phi u_{t-1} + \varepsilon_t$, $\sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2 + \beta \sigma_{t-1}^2 + \delta u_{t-1}^2$, $\varepsilon_t = \sigma_t z_t$ cu z_t Student-t standardizat; funcțiile din notebook `spill_negll`, `fit_spill`
- ▣ **Cerințe**
 1. Scrieți log-verosimilitatea pas cu pas (pornire $\sigma_1^2 =$ dispersia de selecție) și estimați modelul nerestricționat și modelul cu $\delta = 0$.
 2. Testați $\delta = 0$ prin LR; deoarece $\delta \geq 0$, folosiți $\frac{1}{2}\chi_0^2 + \frac{1}{2}\chi_1^2$; repetați pe 2000–2012 și 2013–2026.
 3. Calculați termenul american cumulat $s_t = \beta s_{t-1} + \delta u_{t-1}^2$ cu $s_1 = 0$, partea s_t/σ_t^2 și volatilitatea fără el, $\sqrt{\sigma_t^2 - s_t}$; reprezentați-le.
- ▣ **Raportați:** estimările pe trei eșantioane, testele LR, graficul contribuției; un folder Quantlet și un slide cu concluzia și principala limită; interpretare: legătura este cauzală sau predictivă?

C3 [Propus]: GARCH bazat pe un cvasi-scor pe acțiuni americane — cerința (1/2)

- ▣ **Întrebarea:** este grosimea cozilor randamentelor același lucru cu atenuarea șocurilor mari în actualizarea dispersiei Blasques, Francq & Laurent (2023)?
- ▣ **Date:** începeți cu JPMorgan (prețuri de închidere ajustate) și VIX (valori de închidere), aliniate pe zilele comune, 3 ianuarie 1995 – 28 februarie 2019; $r_t = 100 \Delta \ln P_t$, $X_t = \text{VIX}_t^2 / 252$ (VIX din ziua t intră în f_{t+1})
- ▣ **Cerințe**
 1. Modelul (recursia estimată): $y_t = r_t - \mu - \phi r_{t-1} = \sqrt{f_t} \epsilon_t$, ϵ_t Student-t standardizat cu $1/\xi$ grade de libertate; $f_{t+1} = \omega + \varpi X_t + \alpha \Psi\left(\frac{1+\zeta}{1-2\zeta+\zeta\epsilon_t^2}\right) \epsilon_t^2 f_t + \beta f_t$, $\Psi(x) = x \tanh(cx/2)$, $c = 1000$, $\zeta \in (-1, 1/2)$, f_1 = dispersia lui y_t .
 2. Parametri: ξ = grosimea cozilor, ζ = atenuarea; $\zeta = 0$: GARCH(1,1)-t; $\zeta = \xi$: Beta-t-GARCH. Estimați cele trei modele prin verosimilitate maximă (notebook-ul MFM_ch5_quasi_score_driven: qsd_negll, fit_qsd).
 3. Testați $\zeta = 0$ și $\xi = \zeta$ prin LR față de χ_1^2 ($\zeta = 0$ este interior datorită lui Ψ).
- ▣ **Raportați:** estimările, log-verosimilitățile, cele două teste LR
- ▣ Model: B1, B2

C3 [Propus]: cerința (2/2): diagnostic și extindere

▣ Întrebările

- ▶ sînt adecvate cele trei modele?
- ▶ rămîne răspunsul valabil dincolo de o acțiune?

▣ **Date:** estimările din cerința 1; PIT $u_t = F(\epsilon_t)$, i.i.d. $U(0, 1)$ dacă modelul este corect [Diebold, Gunther & Tay \(1998\)](#)

▣ Cerințe

1. Reprezentați $\sqrt{f_t}$ pentru cele trei modele în jurul celui mai mare șoc și histogramele PIT.
2. Calculați statistica naivă $(\sum_t u_t - T/2)/\sqrt{T/12}$ și explicați de ce ignoră eroarea de estimare (corecția din [Pierce \(1982\)](#) scade dispersia sub $T/12$).
3. Opțional: extindeți la cele 11 acțiuni ale cursului și pînă la 18 septembrie 2026; raportați frecvențele de respingere cu un interval binomial care presupune, ipotetic, respingeri independente.

▣ **Raportați:** un folder Quantlet și un slide cu tabelul, testele și principala limită; interpretare: de ce nu pot 11 companii selectate, încă listate, confirma cele 89,5% din lucrare?

Bibliografie (1/3)

- ▣ Andrews, D.W.K. (2000). Inconsistency of the bootstrap when a parameter is on the boundary of the parameter space. *Econometrica*, 68(2), 399–405.
- ▣ Andrews, D.W.K. (2001). Testing when a parameter is on the boundary of the maintained hypothesis. *Econometrica*, 69(3), 683–734.
- ▣ Blasques, F., Francq, C., Laurent, S. (2023). Quasi score-driven models. *Journal of Econometrics*, 234(1), 251–275.
- ▣ Bollerslev, T. (1986). Generalized autoregressive conditional heteroskedasticity. *Journal of Econometrics*, 31(3), 307–327.
- ▣ Bollerslev, T., Wooldridge, J.M. (1992). Quasi-maximum likelihood estimation and inference in dynamic models with time-varying covariances. *Econometric Reviews*, 11(2), 143–172.
- ▣ Clark, T.E., McCracken, M.W. (2001). Tests of equal forecast accuracy and encompassing for nested models. *Journal of Econometrics*, 105(1), 85–110.
- ▣ Diebold, F.X., Gunther, T.A., Tay, A.S. (1998). Evaluating density forecasts with applications to financial risk management. *International Economic Review*, 39(4), 863–883.

Bibliografie (2/3)

- ▣ Diebold, F.X., Mariano, R.S. (1995). *Comparing predictive accuracy*. *Journal of Business & Economic Statistics*, 13(3), 253–263.
- ▣ Engle, R.F., Ng, V.K. (1993). *Measuring and testing the impact of news on volatility*. *Journal of Finance*, 48(5), 1749–1778.
- ▣ Franke, J., Härdle, W.K., Hafner, C.M. (2019). *Statistics of Financial Markets: An Introduction*, ed. a 5-a. Springer.
- ▣ Giacomini, R., White, H. (2006). *Tests of conditional predictive ability*. *Econometrica*, 74(6), 1545–1578.
- ▣ Glosten, L.R., Jagannathan, R., Runkle, D.E. (1993). *On the relation between the expected value and the volatility of the nominal excess return on stocks*. *Journal of Finance*, 48(5), 1779–1801.
- ▣ Hall, P., Yao, Q. (2003). *Inference in ARCH and GARCH models with heavy-tailed errors*. *Econometrica*, 71(1), 285–317.
- ▣ Hansen, B.E. (1994). *Autoregressive conditional density estimation*. *International Economic Review*, 35(3), 705–730.

Bibliografie (3/3)

- ▣ Hansen, P.R., Lunde, A., Nason, J.M. (2011). *The model confidence set*. *Econometrica*, 79(2), 453–497.
- ▣ J.P. Morgan/Reuters (1996). *RiskMetrics — Technical Document*, ed. a 4-a. New York.
- ▣ Li, W.K., Mak, T.K. (1994). *On the squared residual autocorrelations in non-linear time series with conditional heteroskedasticity*. *Journal of Time Series Analysis*, 15(6), 627–636.
- ▣ Mincer, J., Zarnowitz, V. (1969). *The evaluation of economic forecasts*. În J. Mincer (ed.), *Economic Forecasts and Expectations: Analysis of Forecasting Behavior and Performance*, NBER.
- ▣ Patton, A.J. (2011). *Volatility forecast comparison using imperfect volatility proxies*. *Journal of Econometrics*, 160(1), 246–256.
- ▣ Pierce, D.A. (1982). *The asymptotic effect of substituting estimators for parameters in certain types of statistics*. *The Annals of Statistics*, 10(2), 475–478.
- ▣ West, K.D. (1996). *Asymptotic inference about predictive ability*. *Econometrica*, 64(5), 1067–1084.