



Modelarea piețelor financiare

Seminarul 5: Volatilitate condiționată — modele GARCH



Daniel Traian PELE

Drd. Antoaneta Amza, antoaneta.amza@csie.ase.ro

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

Acronime folosite în acest material

- ▣ AI: Artificial Intelligence (intelență artificială)
- ▣ AIC: Akaike Information Criterion (criteriul informațional Akaike)
- ▣ AR: AutoRegressive (model) (model autoregresiv)
- ▣ ARCH: AutoRegressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă)
- ▣ BET: Bucharest Exchange Trading (index) (indicele de referință al Bursei de Valori București)
- ▣ BIC: Bayesian Information Criterion (criteriul informațional bayesian)
- ▣ DM: Diebold–Mariano (test) (testul Diebold–Mariano de comparare a prognozelor)
- ▣ EGARCH: Exponential GARCH (GARCH exponențial)
- ▣ EWMA: Exponentially Weighted Moving Average (medie mobilă ponderată exponențial)
- ▣ GARCH: Generalised AutoRegressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă generalizată)
- ▣ GARCH-N: GARCH with Normal innovations (GARCH cu inovații Normale)
- ▣ GED: Generalised Error Distribution (distribuția generalizată a erorilor)
- ▣ GJR: Glosten–Jagannathan–Runkle (asymmetric GARCH) (GARCH asimetric Glosten–Jagannathan–Runkle)
- ▣ GJR-GARCH: Glosten–Jagannathan–Runkle GARCH (GARCH asimetric Glosten–Jagannathan–Runkle)
- ▣ HAC: Heteroskedasticity and Autocorrelation Consistent (standard errors) (erori standard robuste la heteroscedasticitate și autocorelație)
- ▣ IGARCH: Integrated GARCH (GARCH integrat)
- ▣ LM: Lagrange Multiplier (multiplicatorul Lagrange)
- ▣ LR: Likelihood Ratio (test) (testul raportului de verosimilitate)
- ▣ MZ: Mincer–Zarnowitz (regression) (regresia Mincer–Zarnowitz)
- ▣ QLIKE: Quasi-LIKelihood (loss function) (funcția de pierdere de tip cvasi-verosimilitate)
- ▣ SUA: Statele Unite ale Americii

Cuprins

Introducere

Partea A: pe hârtie

Partea B: calcul și inferență

Partea C: întrebare deschisă

Încheiere

Bibliografie

Obiectivele seminarului

La finalul seminarului puteți

- ▣ Rula pas cu pas recursia dispersiei GARCH și prognozele ei
- ▣ Estima GARCH, GJR-GARCH și variante cu cozi groase și diagnostica reziduurile
- ▣ Compara modele prin rapoarte de verosimilitate, criterii informaționale și pierderi în afara eșantionului
- ▣ Măsura incertitudinea estimării cu un bootstrap parametric

- ▣ Suport: Cursul 5; manualul [Franke, Härdle & Hafner \(2019\)](#)

Structura

- ▣ **Partea A:** cinci exerciții pe hârtie (A1–A5)
- ▣ **Partea B:** opt exerciții pe calculator, cu inferență (B1–B8)
- ▣ **Partea C:** o întrebare deschisă, punct de plecare pentru proiectul de echipă (C1), și critica unui răspuns AI (C2)

Cum lucrăm la acest seminar

- Problemele **[Rezolvat]** au rezolvarea completă; problemele **[Propus]** au doar cerința: rezolvările se discută la seminar
- Fiecare problemă propusă indică **modelul**: problema rezolvată care folosește aceeași tehnică
 - ▶ Fiecare exercițiu din Partea B se încheie cu întrebări de interpretare: întrebați-vă ce ar schimba concluzia
- Raportați orice estimare împreună cu incertitudinea ei: eroare standard robustă, interval bootstrap sau valoare p
- Verificați orice model estimat: convergența, parametrii aflați la frontieră, reziduurile standardizate

Probleme rezolvate și propuse

Rezolvate: exemple lucrate în acest material

- ▣ Partea A: A1 (recursia GARCH și prognoza, pas cu pas), A3 (dispersia de termen lung și timpul de înjumătățire)
- ▣ Partea B: B1 (GARCH-t pe S&P 500 cu diagnostic), B2 (GJR vs GARCH, testul LR), B5 (QLIKE, Diebold–Mariano, Mincer–Zarnowitz), B7 (bootstrap parametric)

Propuse: le rezolvați voi

- ▣ Partea A: A2 (model: A1), A4 (model: A3), A5 (model: A1, A3)
- ▣ Partea B: B3 (model: B2), B4 (model: B1, B2), B6 (model: B5), B8 (model: B7)
- ▣ Partea C: C1, întrebare deschisă și sămânță de proiect; C2, critica unui răspuns AI (model: A3)

Pregătire: mediul Python și datele

- ▣  **Deschide în Colab:** `capitol5_notebook_seminar.ipynb`
- ▣ Google Colab (recomandat) sau Python local ≥ 3.10 cu `numpy`, `pandas`, `scipy`, `statsmodels`, `matplotlib` și `arch`
- ▣ Serii: S&P 500, BET, Bitcoin; închideri zilnice până la 18 septembrie 2026
- ▣ Randamente în %: $r_t = 100 (\ln P_t - \ln P_{t-1})$; indicii bursieri în zilele lucrătoare, Bitcoin 7 zile din 7
- ▣ Partea C îmbină întâi prețurile BET și S&P 500 în zilele comune, apoi calculează randamentele

Formulele folosite azi

- GARCH(1,1) [Bollerslev \(1986\)](#): $\sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2 + \beta \sigma_{t-1}^2$; GJR [Glosten, Jagannathan & Runkle \(1993\)](#): adăugăm $\gamma I(\varepsilon_{t-1} < 0) \varepsilon_{t-1}^2$
- Dispersia de termen lung $\sigma^2 = \omega / (1 - \alpha - \beta)$; prognoza $\mathbb{E}_t \sigma_{t+h}^2 = \sigma^2 + (\alpha + \beta)^{h-1} (\sigma_{t+1}^2 - \sigma^2)$
- Timpul de înjumătățire $h_{1/2} = \ln 0,5 / \ln(\alpha + \beta)$; raportul de verosimilitate $LR = 2(\ell_1 - \ell_0) \sim \chi_m^2$
- Pierderea QLIKE $r_t^2 / h_t + \ln h_t$ [Patton \(2011\)](#); statistica t Diebold–Mariano pe diferența de pierderi [Diebold & Mariano \(1995\)](#)
- Regresia de asimetrie $\hat{z}_t^2$ pe S_{t-1}^- , $S_{t-1}^- \hat{z}_{t-1}$, $S_{t-1}^+ \hat{z}_{t-1}$ [Engle & Ng \(1993\)](#)

A1: recursia GARCH și prognoza, pas cu pas [Rezolvat]

Cerință

- ▣ GARCH(1,1) cu $\omega = 0,05$, $\alpha = 0,10$, $\beta = 0,85$; pornim de la $\sigma_1^2 = \omega / (1 - \alpha - \beta)$
- ▣ Șocuri (%): $\varepsilon_1 = -2,0$, $\varepsilon_2 = 0,5$, $\varepsilon_3 = 3,0$, $\varepsilon_4 = -1,0$
- ▣ (a) $\sigma_2^2, \dots, \sigma_5^2$
- ▣ (b) Prognozele $\mathbb{E}_4 \sigma_{5+h}^2$ pentru $h = 0, \dots, 4$ și dispersia pe 5 zile
- ▣ (c) Timpul de înjumătățire al unui șoc de dispersie

Rezolvare

- ▣ $\sigma_1^2 = 0,05 / 0,05 = 1,0000$
- ▣ $\sigma_2^2 = 0,05 + 0,4000 + 0,8500 = 1,3000$;
 $\sigma_3^2 = 0,05 + 0,0250 + 1,1050 = 1,1800$
- ▣ $\sigma_4^2 = 0,05 + 0,9000 + 1,0030 = 1,9530$;
 $\sigma_5^2 = 0,05 + 0,1000 + 1,6600 = 1,8100$
- ▣ (b) Distanța față de termenul lung, 0,8101, scade cu 0,95 pe zi:
1,8100, 1,7695, 1,7311, 1,6945, 1,6598
► Dispersia pe 5 zile 8,665, volatilitatea 2,944%
- ▣ (c) $\ln 0,5 / \ln 0,95 = 13,5$ zile

A2: aceleași șocuri într-un GJR-GARCH [Propus]

Rezolvarea se discută la seminar

Cerință

- ▣ GJR-GARCH(1,1): $\omega = 0,05$, $\alpha = 0,05$, $\gamma = 0,10$, $\beta = 0,85$; aceleași șocuri ca în A1
- ▣ (a) Persistența $\alpha + \gamma/2 + \beta$ și dispersia de termen lung, pentru z_t simetric
- ▣ (b) $\sigma_2^2, \dots, \sigma_5^2$ pornind de la dispersia de termen lung
- ▣ (c) Comparați cu A1 după șocurile -2 și $+3$: care model reacționează mai mult și de ce?
- ▣ Model: A1

A3: volatilitatea de termen lung și timpul de înjumătățire din estimări [Rezolvat]

Cerință

- GARCH(1,1)-t, randamente zilnice în %, 2000–2026 (Cursul 5)
- S&P 500: $\hat{\omega} = 0,0157$, $\hat{\alpha} = 0,1226$, $\hat{\beta} = 0,8721$
- (a) Deduceți $\sigma^2 = \omega / (1 - \alpha - \beta)$ din recursie
- (b) Volatilitatea de termen lung zilnică și anuală (251,4 zile pe an)
- (c) Timpul de înjumătățire; comparați cu volatilitatea de selecție 19,2%

Rezolvare

- (a) Staționaritate: $\mathbb{E}\sigma_t^2 = \mathbb{E}\sigma_{t-1}^2 = \sigma^2$ și $\mathbb{E}\varepsilon_{t-1}^2 = \sigma^2$, deci $\sigma^2 = \omega + (\alpha + \beta)\sigma^2$
- (b) $\hat{\alpha} + \hat{\beta} = 0,9947$; $\hat{\sigma}^2 = 0,0157 / (1 - 0,9947) = 2,972$, adică 1,724% pe zi și 27,3% pe an
- (c) $\ln 0,5 / (-0,00530) = 130,7$ zile
- Volatilitatea de termen lung o depășește pe cea de selecție: împărțirea la $1 - 0,9947$ amplifică erorile mici din $\hat{\alpha} + \hat{\beta}$

A4: este finit momentul de ordin patru? [Propus]

Rezolvarea se discută la seminar

Cerință

- Cu z_t Normal, $K = 3[1 - (\alpha + \beta)^2]/[1 - (\alpha + \beta)^2 - 2\alpha^2]$ (Seminarul 1, A9)
- (a) S&P 500, GARCH-N: $\hat{\alpha} = 0,121$, $\hat{\beta} = 0,860$; verificați condiția și calculați K
- (b) Comparați cu aplatizarea de selecție 13,7
- (c) Inovațiile Student-t cu $\nu = 6,26$ au aplatizarea $\kappa_z = 3(\nu - 2)/(\nu - 4)$; condiția devine $(\alpha + \beta)^2 + (\kappa_z - 1)\alpha^2 < 1$. Verificați-o pentru $\hat{\alpha} = 0,123$, $\hat{\beta} = 0,872$
- Model: A3

A5: EWMA ca un caz particular de GARCH [Propus]

Rezolvarea se discută la seminar

Cerință

- ▣ EWMA J.P. Morgan/Reuters (1996): $\sigma_t^2 = \lambda \sigma_{t-1}^2 + (1 - \lambda) r_{t-1}^2$, $\lambda = 0,94$
- ▣ (a) Scrieți σ_t^2 ca sumă ponderată a r_{t-j}^2 trecute; dați ponderile pentru $j = 1, 10, 50$
- ▣ (b) Ce parte din ponderea totală revine ultimelor 20 de zile?
- ▣ (c) Ce parametri GARCH dau EWMA? Timpul de înjumătățire al ponderilor; prognoza pentru h zile înainte
- ▣ Model: A1, A3

B1: GARCH-t pe S&P 500 cu diagnostic [Rezolvat]

Cerință

- ▣ S&P 500, randamente zilnice în %, 2000–2026
- ▣ (a) Testați efectele ARCH: $Q(10)$ pe r_t^2 și $LM(5)$
- ▣ (b) Estimați GARCH(1,1) cu inovații Student-t; raportați erorile standard robuste [Bollerslev & Wooldridge \(1992\)](#) și clasice
- ▣ (c) Diagnosticați $\hat{z}_t$: $Q(10)$ pe $\hat{z}_t$ și $\hat{z}_t^2$, $LM(5)$, testele de asimetrie [Engle & Ng \(1993\)](#)
- ▣ Cod: `arch_model(r, p=1, q=1, dist='t')`

Interpretare

- ▣ Ce diagnostice trec și care pică?
- ▣ Ce sugerează eșecul despre model?
- ▣ De ce sunt erorile standard robuste mai mari?

B1: rezultate [Rezolvat]

	$\hat{\omega}$	$\hat{\alpha}$	$\hat{\beta}$	$\hat{\nu}$	$\hat{\alpha} + \hat{\beta}$
Estimare	0,0157	0,1226	0,8721	6,26	0,9947
E.s. robustă		0,0107	0,0103	0,48	
E.s. clasică		0,0101	0,0096		

- (a) Înainte de model: $Q(10)$ pe $r_t^2 = 6133$, $LM(5) = 1679$: efecte ARCH puternice
- (c) După: $Q(10)$ pe $\hat{z}_t^2 = 13,6$ ($p = 0,192$), $LM(5) = 5,8$ ($p = 0,326$): gruparea a dispărut
 - ▶ Asimetria de semn $t = 2,47$, de mărime pozitivă $t = -2,56$, comun $\chi_3^2 = 39,3$: asimetrie rămasă; încercați GJR (B2)
 - ▶ $Q(10)$ pe $\hat{z}_t = 21,9$ ($p = 0,016$): o mică autocorelație în medie
- Erorile robuste sunt mai mari deoarece z_t nu este exact Student-t (asimetrie -0,58)

B2: GJR vs GARCH pe S&P 500 [Rezolvat]

Cerință

- ▣ (a) Estimați GJR-GARCH(1,1)-t [Glosten, Jagannathan & Runkle \(1993\)](#); raportați $\hat{\gamma}$ cu statistica t robustă
- ▣ (b) Testul LR pentru $\gamma = 0$ față de GARCH(1,1)-t (B1)
- ▣ (c) Comparați AIC și BIC; repetați testul de asimetrie pe reziduurile GJR

Interpretare

- ▣ Este asimetria mare din punct de vedere economic? Folosiți curba de impact a știrilor
- ▣ De ce este $\hat{\alpha}$ exact 0? Mai este valid testul LR?

B2: rezultate [Rezolvat]

- (a) $\hat{\alpha} = 0,000$, $\hat{\gamma} = 0,205$ ($t = 10,03$), $\hat{\beta} = 0,881$
- (b) $\ell_{GARCH} = -9062,5$, $\ell_{GJR} = -8944,6$: $LR = 235,65$, $p < 0,001$
 - Valoarea critică de 5% pentru χ^2_1 : 3,84; respinsă cu o marjă mare
- (c) $\Delta AIC = -233,7$, $\Delta BIC = -226,8$ (GJR minus GARCH): toate criteriile preferă GJR; testul comun de asimetrie χ^2_3 scade de la 39,3 la 23,5
- $\hat{\alpha} = 0$: șocurile pozitive nu cresc volatilitatea; estimarea este la frontieră, dar $\gamma = 0$ este o restricție interioară, deci testul LR rămâne valid

B3: GJR vs GARCH pe BET [Propus]

Rezolvarea se discută la seminar

Cerință

- ▣ BET, randamente zilnice în %, 2000–2026
- ▣ (a) Estimați GARCH(1,1)-t și GJR-GARCH(1,1)-t; raportați $\hat{\gamma}$ și t -ul robust
- ▣ (b) Testul LR pentru $\gamma = 0$; (c) AIC și BIC
- ▣ Model: B2

Interpretare

- ▣ Sunt de acord testul LR și BIC? De ce pot fi în dezacord?
- ▣ Este efectul de levier mai slab la BET decât la S&P 500? Dați un motiv economic

B4: ce inovații pentru Bitcoin? [Propus]

Rezolvarea se discută la seminar

Cerință

- ▣ Bitcoin, randamente zilnice în %, 2014–2026 (365 de zile pe an)
- ▣ (a) Estimați GARCH(1,1) cu inovații Normale, Student-t, t asimetrice Hansen (1994) și GED; comparați BIC
- ▣ (b) Testul LR pentru $\lambda = 0$ (t asimetric față de Student-t)
- ▣ (c) Raportați $\hat{\nu}$ și $\hat{\alpha} + \hat{\beta}$; vreun parametru la frontieră?
- ▣ Model: B1, B2

Interpretare

- ▣ Asimetria de selecție a lui $\hat{z}_t$ este negativă; este de acord verosimilitatea? De ce nu?
- ▣ Ce implică $\hat{\nu} < 4$ pentru aplatizare și pentru măsurile de risc?

B5: compararea prognozelor pe S&P 500 [Rezolvat]

Cerință

- ▣ În afara eșantionului 2016–2026: reestimare în fiecare ianuarie pe toate datele din 2000; prognoze h_t pentru ziua următoare
- ▣ Modele: GARCH-N, GARCH-t, GJR-t, EGARCH-t, EWMA ($\lambda = 0,94$), Hist-20 (media ultimelor 20 de r_t^2)
- ▣ (a) QLIKE mediu [Patton \(2011\)](#); (b) statistica t Diebold–Mariano față de GARCH-t, HAC cu 5 decalaje [Diebold & Mariano \(1995\)](#)
- ▣ (c) Regresia Mincer–Zarnowitz $r_t^2 = a + bh_t$ [Mincer & Zarnowitz \(1969\)](#), testul Wald pentru $a = 0$, $b = 1$

Interpretare

- ▣ Care modele sunt semnificativ mai slabe decât GARCH-t?
- ▣ De ce este R^2 mic chiar pentru prognoze bune?

B5: rezultate [Rezolvat]

Model	QLIKE	DM t	MZ b	MZ R^2	Wald p
GARCH-N	0,7510	-1,47	0,97	0,250	0,995
GARCH-t	0,7570	—	0,88	0,238	0,804
GJR-t	0,7319	-1,22	0,84	0,276	0,680
EGARCH-t	0,7454	-0,36	1,24	0,293	0,713
EWMA	0,8149	3,48	0,89	0,172	0,685
Hist-20	0,8888	4,10	0,68	0,152	0,028

- (a–b) 2 692 zile; cel mai mic QLIKE: GJR-t; doar EWMA și Hist-20 sunt semnificativ mai slabe ($t = 3,48, 4,10$)
- (c) Nedepasarea nu este respinsă pentru modelele GARCH; este respinsă pentru Hist-20
- R^2 este mic pentru că $r_t^2 = \sigma_t^2 z_t^2$: aproximarea este zgomotoasă chiar când $h_t = \sigma_t^2$

B6: compararea prognozelor pe BET [Propus]

Rezolvarea se discută la seminar

Cerință

- Repetați B5 pentru BET, cu același design și aceeași perioadă (2016–2026)
- Raportați QLIKE, statistica t Diebold–Mariano față de GARCH- t și panta Mincer–Zarnowitz
- Model: B5

Interpretare

- Se schimbă ordinea modelelor între S&P 500 și BET?
- Ce parte a modelului pentru BET ați îmbunătăți întâi (amintiți-vă diagnosticele din Cursul 5)?

B7: cât de precis este timpul de înjumătățire? Un bootstrap parametric [Rezolvat]


Cerință

- ▣ S&P 500, GARCH(1,1)-t estimat în B1
- ▣ (a) Simulați 200 traiectorii de aceeași lungime din modelul estimat
- ▣ (b) Reestimați GARCH-t pe fiecare traiectorie; rețineți $\hat{\alpha} + \hat{\beta}$ și timpul de înjumătățire
- ▣ (c) Intervale percentile de 95%; comparați abaterea standard bootstrap cu eroarea standard robustă (metoda delta)

Interpretare

- ▣ De ce este intervalul pentru timpul de înjumătățire atât de asimetric?
- ▣ Putem respinge IGARCH ($\alpha + \beta = 1$)?

B7: rezultate [Rezolvat]



- Estimarea 0,9947 (timp de înjumătățire 131 zile); interval bootstrap de 95% [0,9839; 1,0000]
- Abaterea standard bootstrap 0,0044 față de e.s. robustă a lui $\hat{\alpha} + \hat{\beta}$ 0,0047: apropiate
- Timpul de înjumătățire: de la 43 zile la infinit; 5,5% din replicări ating $\alpha + \beta = 1$
 - $\ln 0,5 / \ln x$ explodează când $x \rightarrow 1$: un interval simetric pentru x devine unul foarte asimetric pentru timpul de înjumătățire
- IGARCH nu poate fi respins la 5%: limita superioară a intervalului atinge 1

B8: bootstrap pentru BET [Propus]

Rezolvarea se discută la seminar

Cerință

- Repetați B7 pentru BET (GARCH(1,1)-t, 2000–2026), cu același număr de replicări
- Raportați intervalul pentru $\alpha + \beta$ și pentru timpul de înjumătățire, și proporția replicărilor cu $\alpha + \beta = 1$
- Model: B7

Interpretare

- Este timpul de înjumătățire al BET mai scurt decât al S&P 500 cu certitudine? De ce ar avea nevoie un test formal?

C1: este volatilitatea pieței românești determinată de SUA? [Propus]

Rezolvarea se discută la seminar

Întrebarea

- Wall Street închide după Bursa de Valori București: șocul S&P 500 de ieri este o știre pentru BET-ul de azi
- u_{t-1}^2 , pătratul randamentului S&P 500 din ziua precedentă, crește dispersia condiționată a BET?
- Model: $\sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2 + \beta \sigma_{t-1}^2 + \delta u_{t-1}^2$, cu $r_t = \mu + \phi u_{t-1} + \varepsilon_t$

Livrabil

- Un folder Quantlet în repository-ul echipei și un slide cu concluzia și principala limită

Răspunsul ar trebui să conțină

- Prețurile îmbinate întâi în zilele comune de tranzacționare, apoi randamentele
- Verosimilitatea scrisă pas cu pas (Student-t), estimată prin optimizare numerică
- Un test LR pentru $\delta = 0$; atenție, $\delta \geq 0$ pune ipoteza nulă pe frontieră
- Stabilitatea: două subperioade (de ex. înainte și după 2013)
- Partea din dispersia BET atribuibilă șocurilor din SUA și cum se schimbă în timp

C2: critica unui răspuns AI [Propus]

Rezolvarea se discută la seminar

Cererea trimisă unui asistent de inteligență artificială (AI)

- „px conține închiderile zilnice S&P 500. Estimează un GARCH(1,1) cu inovații Student- t cu arch și dă-mi volatilitatea anualizată de termen lung și timpul de înjumătățire al unui șoc.”

Răspunsul asistentului

```
import numpy as np
from arch import arch_model
r = np.log(px).diff().dropna() # daily log returns
am = arch_model(r, vol='GARCH', p=1, q=1, dist='t')
res = am.fit(displ='off')
om = res.params['omega']
a, b = res.params['alpha[1]'], res.params['beta[1]']
lr_var = om / (1 - a - b) # long-run daily variance
ann_vol = lr_var * 252 # annualised volatility
half_life = np.log(0.5) / np.log(b) # half-life in days
```

- „Pentru S&P 500 rezultă $\text{ann_vol} = 0,075$ (7,5% pe an) și un timp de înjumătățire de 5,1 zile.”

C2: critica unui răspuns AI, cerința [Propus]

Rezolvarea se discută la seminar

- Codul rulează, dar răspunsul conține **trei** greșeli tipice pentru lucrul cu GARCH
 - ▶ Tot restul răspunsului este corect
- Pentru fiecare greșeală
 - ▶ Indicați linia și explicați de ce este greșită
 - ▶ Spuneți cum ați depista-o: un avertisment, o cifră din A3, un slide din curs
 - ▶ Scrieți varianta corectă a liniei (liniilor) și cifrele corecte
- Notați fiecare greșeală ca în `AI_ERRORS.md`
 - ▶ Ce ați întrebat, ce a răspuns AI-ul, ce era greșit, cum v-ați dat seama, varianta corectă
- Indiciu: comparați cu A3 și cu slide-ul „Greșeli frecvente”

Greșeli frecvente

- ▣ Estimarea GARCH pe randamente în zecimale: optimizatorul se poate opri departe de maxim; folosiți % sau rescalați
- ▣ Citirea erorilor standard clasice când inovațiile nu sunt Normale; folosiți-le pe cele robuste
- ▣ Încrederea în volatilitatea de termen lung și în timpul de înjumătățire când $\alpha + \beta \approx 1$, fără un interval
- ▣ Evaluarea prognozelor în eșantion sau cu pierderi nerobuste la o aproximare zgomotoasă
- ▣ Folosirea testului LR pentru un parametru pe frontieră (de ex. $\delta = 0$ cu $\delta \geq 0$) cu valoarea critică χ^2 obișnuită
- ▣ Îmbinarea a două piețe pe randamente în loc de prețuri: creează randamente false pe mai multe zile

Temă pentru acasă (proiect de echipă)

- ▣ Alegeți o serie nediscutată la seminar (alt indice, un curs de schimb, o marfă sau un cripto-activ)
- ▣ Testați efectele ARCH; estimați GARCH, GJR și EGARCH cu trei distribuții ale inovațiilor; alegeți prin BIC și diagnostic
- ▣ Evaluați prognozele pe o zi și pe o lună în afara eșantionului față de EWMA, cu QLIKE și Diebold–Mariano
- ▣ Raportați timpul de înjumătățire cu un interval bootstrap; pentru o alternativă bazată pe entropie, vedeți [Pele, Lazar & Dufour \(2017\)](#)
- ▣ Notați fiecare eroare AI pe care o prindeți în `AI_ERRORS.md` (cel puțin trei pe proiect)
- ▣ Livrați un folder Quantlet (cod, Metainfo, grafice) și trei slide-uri: dovezi, interpretare, limite

Studiu suplimentar pe Quantinar

Cursuri avansate pe quantinar.com

- ☐  Statistics of Financial Markets
- ☐  Applied Time Series Analysis with Python

Cod și date

- ☐ Notebook-ul seminarului (Colab); Quantlets: github.com/danpele/MFM/tree/main/Quantlets/Ch_05

Bibliografie (1/2)

- ▣ Bollerslev, T. (1986). Generalized autoregressive conditional heteroskedasticity. *Journal of Econometrics*, 31(3), 307–327.
- ▣ Bollerslev, T., Wooldridge, J.M. (1992). Quasi-maximum likelihood estimation and inference in dynamic models with time-varying covariances. *Econometric Reviews*, 11(2), 143–172.
- ▣ Diebold, F.X., Mariano, R.S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3), 253–263.
- ▣ Engle, R.F., Ng, V.K. (1993). Measuring and testing the impact of news on volatility. *Journal of Finance*, 48(5), 1749–1778.
- ▣ Franke, J., Härdle, W.K., Hafner, C.M. (2019). *Statistics of Financial Markets: An Introduction*, 5th ed. Springer.
- ▣ Glosten, L.R., Jagannathan, R., Runkle, D.E. (1993). On the relation between the expected value and the volatility of the nominal excess return on stocks. *Journal of Finance*, 48(5), 1779–1801.

Bibliografie (2/2)

- ▣ Hansen, B.E. (1994). Autoregressive conditional density estimation. *International Economic Review*, 35(3), 705–730.
- ▣ J.P. Morgan/Reuters (1996). *RiskMetrics — Technical Document*, 4th ed. New York.
- ▣ Mincer, J., Zarnowitz, V. (1969). The evaluation of economic forecasts. In J. Mincer (ed.), *Economic Forecasts and Expectations: Analysis of Forecasting Behavior and Performance*, NBER.
- ▣ Patton, A.J. (2011). Volatility forecast comparison using imperfect volatility proxies. *Journal of Econometrics*, 160(1), 246–256.
- ▣ Pele, D.T., Lazar, E., Dufour, A. (2017). Information entropy and measures of market risk. *Entropy*, 19(5), 226.