









Modelarea piețelor financiare

Seminarul 7: VaR și Expected Shortfall — aplicații



Daniel Traian PELE
Drd. Antoaneta Amza, antoaneta.amza@csie.ase.ro

Academia de Studii Economice din București
IDA Institute Digital Assets
Blockchain Research Center
AI4EFin Artificial Intelligence for Energy Finance
Academia Română, Institutul de Prognoză Economică
MSCA Digital Finance

Cît de mare poate fi pierderea de mîine?

- Întrebarea seminarului
  - **cît de mari sînt pierderile extreme de mîine și cu ce precizie le putem estima?**
- Rezultate de obținut
  - răspunsurile la exercițiile A
  - un tabel și o figură pentru fiecare exercițiu B
  - codul corectat din C1
  - o frază de interpretare pentru fiecare exercițiu
- Notebook-ul de azi: deschideți notebook-ul seminarului în Colab
  - fiecare cerință indică secțiunea din notebook
- Exercițiile, tipurile și ordinea lor: harta exercițiilor de după definiții
  - B4, A5 și B5 folosesc teoria valorilor extreme și contribuțiile Euler la risc, dezvoltate în cursul 7: rezolvați-le după curs
- Seminar: prof. Daniel Traian Pele, danpele@ase.ro; drd. Antoaneta Amza, antoaneta.amza@csie.ase.ro

Ce piețe și unități folosim pentru randamente?

- BET este indicele Bucharest Exchange Trading; BVB este Bursa de Valori București. BNR este Banca Națională a României, sursa cursului de referință EUR/RON: lei (RON) pentru un euro (EUR).
- Un Exchange-Traded Fund (ETF) se tranzacționează la bursă. SPY urmărește S&P 500; TLT deține obligațiuni de stat americane pe termen lung; GLD oferă expunere pe aur. US înseamnă United States (SUA); USD desemnează dolarul american.
- Pierderile unui activ folosesc randamente logaritmice procentuale. De la 100 la 90, randamentul simplu este -10%, cel logaritmic aproximativ -10,54%; pierderea log este pozitivă, 10,54%. Randamentele portofoliilor folosesc randamente simple și ponderile activelor.
- C1 verifică un răspuns de inteligență artificială (AI). O explicație plauzibilă trebuie să respecte semnul, unitățile și eșantionul exercițiului.

Datele folosite

Seria	Prețul folosit	Perioada	Calendarul	Folosită în
BET	închiderea zilnică	2000–2026	zile lucrătoare	B1, B2, B4, C1
S&P 500	închiderea zilnică	2000–2026	zile de tranzacționare SUA	B2
Bitcoin	închiderea zilnică (USD)	2014–2026	în fiecare zi	B3
SPY, TLT, GLD	închiderea ajustată	2014–2026	zile comune cu Bitcoin	B5
Aur; EUR/RON	aur: închiderea zilnică (USD pe uncie); EUR/RON: cursul de referință BNR	2000–2026; 2005–2026	zile lucrătoare; zile lucrătoare în România	B6
Acțiuni BVB	Banca Transilvania, OMV Petrom și alte șase acțiuni mari de la BVB, închiderea ajustată	2016–2026	zile de tranzacționare BVB	C2

- Prețurile zilnice din datele cursului, cîte o serie pe activ (cîmpul folosit: close sau adjusted close, ca în tabel); toate selecțiile se încheie la 18 septembrie 2026
- EUR/RON: cursul oficial de referință BNR, nu seria EUR/RON a furnizorului de date de piață (conține cotații eronate, vezi Seminarul 0)
- Două sau mai multe active: întîi aliniem *prețurile* pe zilele comune de tranzacționare, apoi calculăm randamentele

Pregătire: rulați și verificați

```
import numpy as np, pandas as pd
URL = ('https://raw.githubusercontent.com/'
       'danpele/MFM/main/data/market/')
px = pd.read_csv(URL + 'BET.csv', index_col='date',
                 parse_dates=True)['close']
px = px.loc['2000-01-01':'2026-09-18']
px = px[px.index.dayofweek < 5]
r = 100 * np.log(px).diff().dropna()    # % log returns
L = -r                                  # losses
print(px.head(3)); print(len(r), r.index[-1])
```

- Codul din secțiunea „Date" a notebook-ului
- Rezultatul așteptat: $n = 6\,670$ randamente, ultima dată 2026-09-18

date	close	r_t (%)
2000-01-05	460,67	–
2000-01-06	484,04	4,95
2000-01-07	526,34	8,38

- Ultima închidere: 32 757,81 la 2026-09-18
- Dacă numărul sau prima valoare diferă, verificați seria, coloana de preț (close sau adjusted close) și filtrul zilelor lucrătoare
- Celelalte serii: folosiți fișierele și coloanele de preț din Ce fișiere definesc eșantionul?

VaR și ES

- Detalii: Capitolul 7
- Randamentul X, pierderea $L = -X$; nivelul α este o **probabilitate a cozii**: VaR 1%, ES 2,5%
- **Value-at-Risk** (VaR): pierderea depășită cu probabilitatea α, adică cuantila de ordin α a randamentului, cu semn schimbat

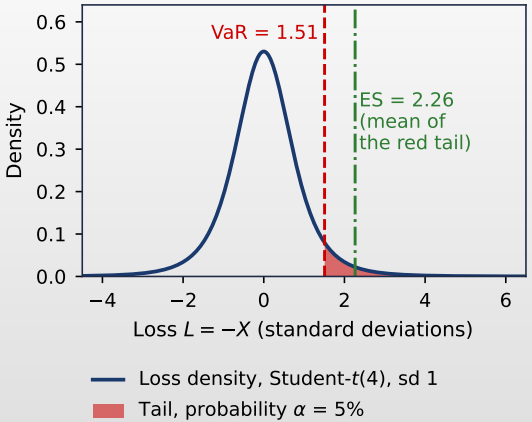
$$\mathrm{VaR}_\alpha = -q_\alpha(X) = q_{1-\alpha}(L), \qquad q_\alpha(X) = \inf\{x : \ P(X \le x) > \alpha\}$$

  - $q_\alpha(X)$: cuantila de ordin α, cel mai mic x (infimumul) în care funcția de repartiție $P(X \le x)$ depășește α; VaR indică frecvența depășirii unui prag de pierdere, nu mărimea ei
- **Expected Shortfall** (ES): pierderea medie în cele mai rele α dintre rezultate

$$\mathrm{ES}_\alpha = -\frac{1}{\alpha}\int_0^\alpha q_u(X)\,du \ = \ \mathbb{E}[L \mid L \ge \mathrm{VaR}_\alpha] \ \text{ (pentru } L \text{ continuu)}$$

  - O medie a valorilor VaR la toate nivelurile $u \le \alpha$, deci $\mathrm{ES}_\alpha \ge \mathrm{VaR}_\alpha$; $\mathbb{E}[\cdot \mid \cdot]$: media pe rezultatele care satisfac condiția
  - Exemplu: zece pierderi egal probabile $-2, -1, 0, 0, 1, 1, 2, 3, 5, 9$, $\alpha = 20\%$: $P(L \ge 5) = 20\%$ nu depășește α, $P(L \ge 3) = 30\%$ da, deci $\mathrm{VaR}_{20\%} = 3$; cele mai rele 20% sînt $\{9, 5\}$, deci $\mathrm{ES}_{20\%} = 7$
  - Reglementare: regulile Basel pentru riscul de piață au înlocuit VaR 1% cu ES 2,5% Basel Committee (2019)

VaR și ES pe densitatea pierderii



- O pierdere cu distribuția Student-$t(4)$ rescalată la abaterea standard 1; probabilitatea cozii $\alpha = 5\%$ în roșu
- VaR: punctul în care începe coada roșie, $P(L > \mathrm{VaR}_\alpha) = \alpha$
  - Aici $\mathrm{VaR}_{5\%} = 1{,}51$ abateri standard
- ES: centrul de greutate al cozii roșii, deci mereu la dreapta lui VaR
  - Aici $\mathrm{ES}_{5\%} = 2{,}26$; două cozi cu același VaR pot avea valori ES foarte diferite
- Semnele: VaR și ES se raportează ca numere **pozitive** atunci cînd sînt pierderi

VaR și ES pentru distribuția Normală

- Randamente Normale: $X = \mu + \sigma Z$, $Z \sim N(0,1)$

$$\mathrm{VaR}_\alpha = -(\mu + \sigma z_\alpha), \qquad \mathrm{ES}_\alpha = -\mu + \sigma \frac{\varphi(z_\alpha)}{\alpha}$$

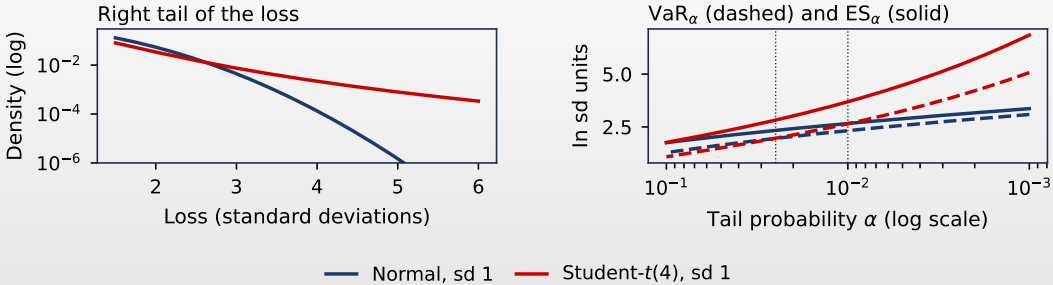
  - μ: media; σ: abaterea standard; Φ, φ: funcția de repartiție și densitatea lui $N(0,1)$; $z_\alpha = \Phi^{-1}(\alpha) < 0$: cuantila ei de ordin α
  - VaR se află la $|z_\alpha|$ abateri standard sub medie; ES folosește factorul mai mare $\varphi(z_\alpha)/\alpha$, media lui $-Z$ în coadă (A1 îl derivă)
  - $z_{1\%} = -2{,}326$, $\varphi(z_{1\%})/0{,}01 = 2{,}665$; $z_{2{,}5\%} = -1{,}960$, $\varphi(z_{2{,}5\%})/0{,}025 = 2{,}338$; cu $\mu = 0$, $\sigma = 1\%$: VaR 1% = 2,33%, ES 2,5% = 2,34%

- Randamente Student-t: $X = m + sT$, $T \sim t_\nu$ cu densitatea g_ν și cuantila $t_\alpha = t_\nu^{-1}(\alpha)$

$$\mathrm{VaR}_\alpha = -(m + s\, t_\alpha), \qquad \mathrm{ES}_\alpha = -m + s \frac{g_\nu(t_\alpha)}{\alpha} \frac{\nu + t_\alpha^2}{\nu - 1} \quad (\nu > 1)$$

  - m: poziția; $s > 0$: scala; ν: gradele de libertate, ν mai mic = cozi mai grele; $\mathrm{Var}(T) = \nu/(\nu-2)$ pentru $\nu > 2$, deci o abatere standard σ cere $s = \sigma\sqrt{(\nu-2)/\nu}$ (A2)

Distribuția Normală și distribuția Student-t



- Ambele distribuții au abaterea standard 1; stînga: coada dreaptă a pierderii pe scală logaritmică, unde densitatea Student-$t(4)$ este de multe ori mai mare dincolo de 3 abateri standard
- Dreapta: VaR (întrerupt) și ES (continuu) în abateri standard, pentru α de la 10% la 0,1%; punctat: $\alpha = 2{,}5\%$ și 1%
  - La niveluri moderate cele două modele sînt apropiate (pentru α în jur de 5%, VaR Student-t este chiar mai mic); diferența apare în extremitatea cozii și crește mai repede pentru ES decît pentru VaR

Măsuri de risc coerente

- **Măsură de risc coerentă** ρ Artzner et al. (1999): o regulă care asociază unei pierderi L capitalul necesar și satisface patru axiome

$$L_1 \leq L_2 \Rightarrow \rho(L_1) \leq \rho(L_2), \qquad \rho(L + c) = \rho(L) + c,$$
$$\rho(\lambda L) = \lambda\, \rho(L)\ (\lambda > 0), \qquad \rho(L_1 + L_2) \leq \rho(L_1) + \rho(L_2)$$

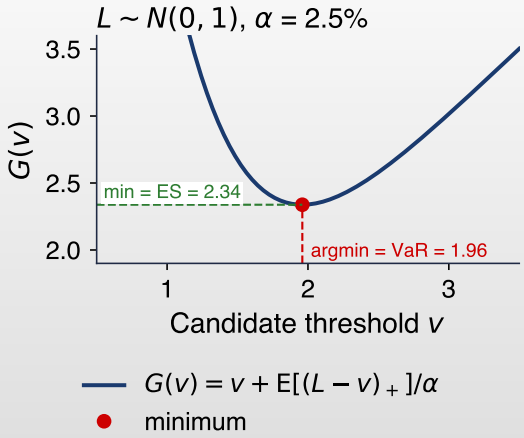
  - Monotonă (pierderi mai mari, mai mult capital); invariantă la translații (o pierdere sigură c adaugă c); pozitiv omogenă (poziție dublă, capital dublu)
  - **Subaditivă**: combinarea a două poziții L_1, L_2 nu cere niciodată mai mult capital decît păstrarea lor separată, deci diversificarea nu este penalizată

- ES este coerent; VaR satisface primele trei axiome, dar poate să nu fie subaditiv
  - Cazuri tipice: pierderi discrete (neplăți, A4) și cozi foarte grele; pentru pierderi cu distribuție Normală comună și o probabilitate a cozii sub 50%, VaR este subaditiv

Ce funcție minimizăm și cum scalăm riscul?

- Funcția obiectiv Rockafellar–Uryasev de mai jos este funcția numită F în Capitolul 7. Litera G desemnează aici un obiectiv, nu Generalised Pareto Distribution (GPD), introdusă ulterior.
- Omogenitatea pozitivă se aplică factorilor strict pozitivi; la expunere zero dispar atît pierderea, cît și capitalul pentru risc.
- De exemplu, dublarea poziției dublează VaR și ES. Diversificarea este o altă întrebare: comparăm riscul portofoliului combinat cu suma riscurilor separate.
- Extragerile independente și identic distribuite (i.i.d.) au aceeași distribuție și nu depind unele de altele. Standard Error (SE) măsoară incertitudinea de eșantionare; un Confidence Interval (CI) este un interval construit să acopere parametrul la nivelul de încredere precizat.

ES ca minim



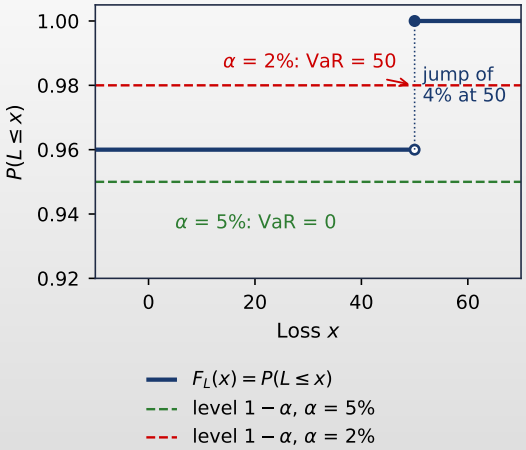
- **Rockafellar–Uryasev** Rockafellar & Uryasev (2000): ES este minimul unei funcții convexe de un prag candidat v

$$G_\alpha(v) = v + \frac{\mathbb{E}[(L-v)_+]}{\alpha}, \qquad \mathrm{ES}_\alpha = \min_v G_\alpha(v)$$

  - $(x)_+ = \max(x, 0)$; $\mathbb{E}[(L-v)_+]$: pierderea medie peste v (zero sub v)
  - Graficul ($L \sim N(0,1)$, $\alpha = 2{,}5\%$): minimul este atins în $v = \mathrm{VaR}_\alpha = 1{,}96$ și este egal cu $\mathrm{ES}_\alpha = 2{,}34$

- Utilizări: estimarea ES ca problemă de optimizare (A7), contribuțiile la ES prin derivare (A5 extins)

Pierderi cu un atom

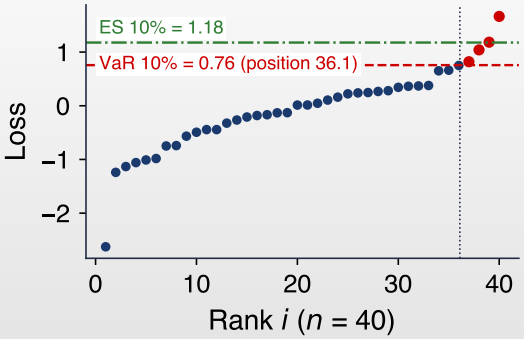


- Un atom: o valoare a pierderii cu probabilitate pozitivă, de ex. o neplată; funcția de repartiție are acolo un salt
- VaR din definiția cu infimum: primul x în care $P(L \le x) \ge 1-\alpha$
  - Graficul (pierdere 50 cu probabilitatea 4%): $\alpha = 5\%$ dă VaR = 0; $\alpha = 2\%$ dă VaR = 50
- ES trebuie să acopere o coadă de probabilitate exact α Acerbi & Tasche (2002)

$$\mathrm{ES}_\alpha = \frac{1}{\alpha}\Big(\mathbb{E}\big[L\,1\{L > \mathrm{VaR}_\alpha\}\big] + \mathrm{VaR}_\alpha\big(\alpha - P(L > \mathrm{VaR}_\alpha)\big)\Big)$$

  - $1\{\cdot\}$: 1 dacă are loc condiția, 0 altfel; primul termen: pierderile strict dincolo de VaR; al doilea: probabilitatea care lipsește din coadă, plasată în VaR
  - Graficul, $\alpha = 5\%$: $(50 \times 0{,}04 + 0 \times 0{,}01)/0{,}05 = 40$

Simularea istorică



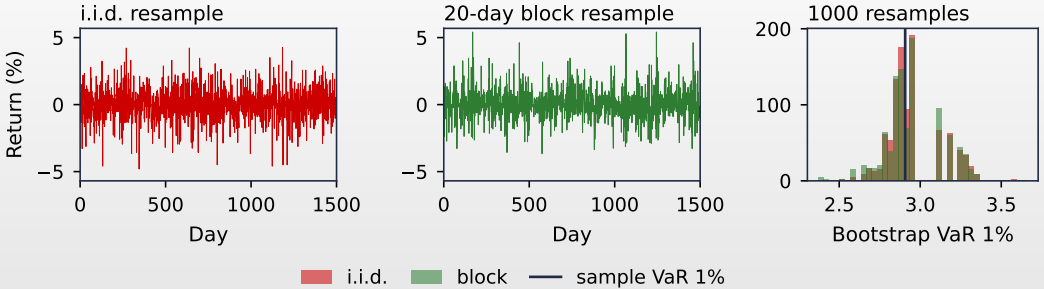
- sorted losses $L_{(1)} \leq \ldots \leq L_{(n)}$
- the $k = 4$ losses $\geq$ VaR

- Simularea istorică (HS): niciun model, doar pierderile trecute ordonate, $L_{(\mathbf{1})} \leq \cdots \leq L_{(n)}$

$$\widehat{\mathrm{VaR}}_\alpha = L_{(j)} + (p-j)\big(L_{(j+\mathbf{1})} - L_{(j)}\big),$$
$$p = 1 + (n-1)(1-\alpha), \quad j = \lfloor p \rfloor$$

  - p: poziția între pierderile ordonate (`np.quantile`, interpolare liniară); $j = \lfloor p \rfloor$: partea ei întreagă
- $\widehat{\mathrm{ES}}_\alpha$: media celor k pierderi $\geq \widehat{\mathrm{VaR}}_\alpha$, $k \approx n\alpha$
  - Graficul: $n = 40$, $\alpha = 10\%$, $p = 36{,}1$, $k = 4$
  - Numărul din coadă $n\alpha$ determină precizia: $n = 500$, $\alpha = 1\%$ lasă cinci pierderi
- HS este necondiționată: o fereastră calmă dă un VaR mic chiar dacă azi piața este volatilă

Intervale bootstrap



- **Bootstrap** Efron (1979): extragem n pierderi cu revenire, recalculăm statistica $\hat{\theta}^{(b)}$, repetăm pentru $b = 1, \ldots, B$
  - Intervalul percentil de 95%: $[q_{\mathbf{2.5\%}},\ q_{\mathbf{97.5\%}}]$ ale valorilor $\hat{\theta}^{(b)}$; lățimea lui măsoară incertitudinea de selecție
- Extragerile i.i.d. rup volatility clustering (stînga); **bootstrap-ul pe blocuri mobile** Künsch (1989) extrage blocuri de, de ex., 20 de zile consecutive, concatenate și tăiate la lungimea n (mijloc)
  - Dreapta: cînd crizele sînt grupate, distribuția bootstrap pe blocuri a lui VaR 1% este mai largă decît cea i.i.d.

Precizia VaR

- **Eroarea standard asimptotică a VaR istoric** (pierderi i.i.d.)

$$\mathrm{SE}(\widehat{\mathrm{VaR}}_\alpha) \approx \frac{\sqrt{\alpha(1-\alpha)/n}}{f(\mathrm{VaR}_\alpha)}$$

  - f: densitatea lui L în VaR; puține observații în jurul lui VaR (f mic) = VaR imprecis; $\sqrt{\alpha(1-\alpha)/n}$: eroarea standard a proporției pierderilor de peste VaR
  - $\hat{f}$: densitate nucleu Gaussian, lățimea de bandă (Silverman) $h = 0{,}9\,\min(\hat{\sigma},\ \mathrm{IQR}/1{,}34)\,n^{-\mathbf{1/5}}$, IQR: abaterea intercuartilă

- Varianta **HAC** (consistentă la heteroscedasticitate și autocorelație): înlocuim $\alpha(1-\alpha)$ cu dispersia de termen lung a lui $I_t = 1\{L_t > \widehat{\mathrm{VaR}}\}$

$$\hat{\Omega} = \hat{\gamma}_{\mathbf{0}} + 2\sum_{j=\mathbf{1}}^{m}\Big(1 - \frac{j}{m+1}\Big)\hat{\gamma}_j$$

  - $\hat{\gamma}_j$: autocovarianța de selecție a lui I_t la lagul j; ponderi Bartlett $1 - j/(m+1)$; lagul Newey–West $m = \lfloor 4(n/100)^{\mathbf{2/9}} \rfloor$; depășirile grupate dau $\hat{\Omega} > \alpha(1-\alpha)$

Precizia ES

- **ES**: funcția de influență Chen (2008) și dispersia ei

$$\mathrm{IF}(x) = \mathrm{VaR}_\alpha + \frac{(x - \mathrm{VaR}_\alpha)_+}{\alpha} - \mathrm{ES}_\alpha, \qquad \mathrm{Var}(\widehat{\mathrm{ES}}_\alpha) \approx \frac{\mathrm{Var}(\mathrm{IF}(L))}{n}$$

  - $\mathrm{IF}(x)$: efectul unei observații suplimentare x asupra estimării; doar pierderile de dincolo de VaR o modifică, fiecare cu ponderea $1/\alpha$
  - Deci precizia lui $\widehat{\mathrm{ES}}_\alpha$ este determinată de cele mai mari cîteva pierderi: numărul din coadă $n\alpha$ și cît de grea este coada dincolo de VaR
- Regulă practică: eroarea standard relativă a unei estimări ES i.i.d. este aproximativ $\propto 1/\sqrt{n\alpha}$
  - $n = 250$, $\alpha = 2{,}5\%$: doar 6,25 pierderi în coadă; un bootstrap pe blocuri lărgește și mai mult intervalul cînd zilele din coadă sînt grupate

Ce elimină filtrarea?

- Un model autoregresiv, AR(1), descrie media condiționată folosind randamentul anterior. Generalised Autoregressive Conditional Heteroskedasticity (GARCH) descrie varianța condiționată variabilă.
- Filtered Historical Simulation (FHS) rescalează șocurile standardizate trecute cu volatilitatea prognozată pentru mîine. Historical Simulation (HS) folosește direct randamentele trecute.
- Un randament rezidual foarte negativ înseamnă o pierdere reziduală foarte pozitivă. Media cozii inferioare a randamentelor, cu semn schimbat, este media cozii superioare a pierderilor.
- Extreme Value Theory (EVT) modelează coada extremă dincolo de un prag. Se poate aplica după filtrare; nu înlocuiește modelul variației condiționate.

Simularea istorică filtrată

- FHS Barone-Adesi et al. (1999): estimăm un AR(1)-GARCH(1,1) (Capitolul 5) prin cvasi-verosimilitate Normală (QML), cu intercept în AR și standardizăm randamentele

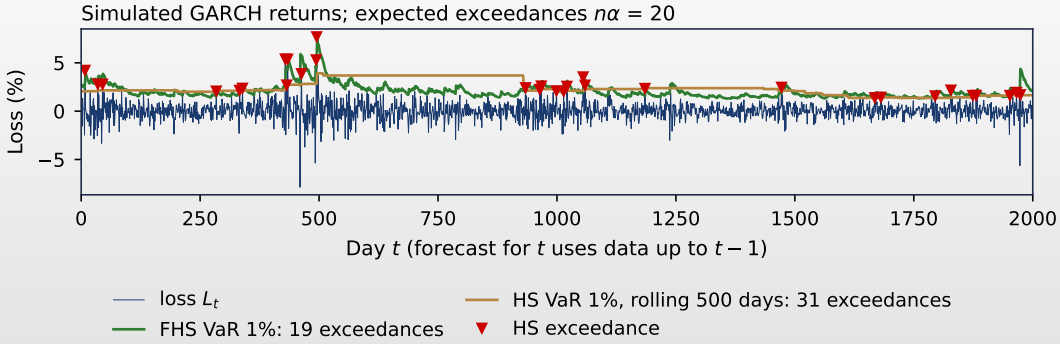
$$r_t = \mu_t + \sigma_t z_t, \quad \mu_t = c + \phi\, r_{t-\mathbf{1}}, \quad \sigma_t^{\mathbf{2}} = \omega + \alpha_{\mathbf{1}}(r_{t-\mathbf{1}} - \mu_{t-\mathbf{1}})^{\mathbf{2}} + \beta_{\mathbf{1}}\sigma_{t-\mathbf{1}}^{\mathbf{2}}, \quad \hat{z}_t = \frac{r_t - \hat{\mu}_t}{\hat{\sigma}_t}$$

  - μ_t: media condiționată (AR(1): c constanta, ϕ coeficientul autoregresiv); σ_t: volatilitatea condiționată; z_t: șoc i.i.d. cu media 0 și dispersia 1; $\hat{z}_t$: reziduul standardizat
  - $\omega > 0$; $\alpha_{\mathbf{1}}$: reacția la șocul de ieri; $\beta_{\mathbf{1}}$: memoria; $\alpha_{\mathbf{1}} + \beta_{\mathbf{1}} < 1$
- VaR și ES de mîine: scala prognozată înmulțită cu o statistică a cozii reziduurilor, minus media prognozată

$$\mathrm{VaR}_{t+\mathbf{1}} = -\hat{\mu}_{t+\mathbf{1}} + \hat{\sigma}_{t+\mathbf{1}}\,\hat{\xi}_\alpha, \qquad \hat{\xi}_\alpha = -q_\alpha(\hat{z}), \qquad \mathrm{ES}_{t+\mathbf{1}} = -\hat{\mu}_{t+\mathbf{1}} + \hat{\sigma}_{t+\mathbf{1}}\,\overline{(-\hat{z})}_{\geq \hat{\xi}_\alpha}$$

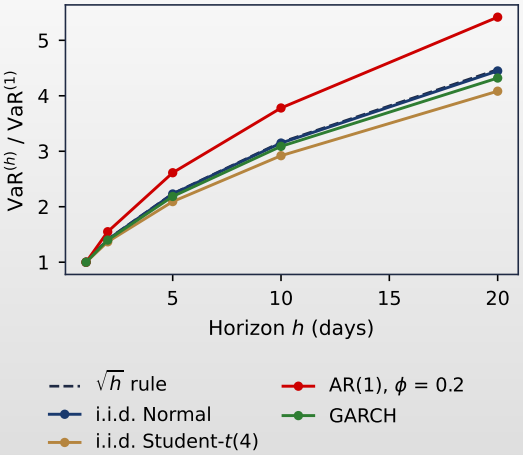
  - $\overline{(-\hat{z})}_{\geq \hat{\xi}_\alpha}$: media pierderilor reziduale $-\hat{z}_t$ egale cu $\hat{\xi}_\alpha$ sau mai mari
  - Exemplu: $\hat{\mu}_{t+\mathbf{1}} = 0{,}1\%$, $\hat{\sigma}_{t+\mathbf{1}} = 3\%$, $\hat{\xi}_{\mathbf{1}\%} = 2{,}8$: $\mathrm{VaR}_{\mathbf{1}\%} = -0{,}1 + 3 \times 2{,}8 = 8{,}3\%$

VaR filtrat și depășirile



- Depășire în ziua t: $L_t > \mathrm{VaR}_t$, cu VaR_t calculat doar din datele pînă în ziua $t-1$ (în afara eșantionului)
  - Sub un model corect, numărul N din n zile este $\mathrm{Bin}(n, \alpha)$: media $n\alpha$, abaterea standard $\sqrt{n\alpha(1-\alpha)}$; $n = 2\,000$, $\alpha = 1\%$: $20 \pm 4{,}4$
  - Graficul (GARCH simulat): FHS urmează volatilitatea și dă 19 depășiri; VaR HS pe fereastră mobilă reacționează tîrziu și dă 31, grupate după salturile volatilității

Orizonturi mai lungi



- Orizont de h zile: pierderile log se adună

$$L_t^{(h)} = L_t + L_{t-1} + \cdots + L_{t-h+1}$$

  - $\mathrm{VaR}^{(h)}$: cuantila acestor sume; sumele consecutive au $h-1$ zile comune (se suprapun)
  - Randamentele simple se compun: $100\big[1 - \prod_{i=1}^{h}(1 + R_{t+i}/100)\big]$, R în %

- Regula rădăcinii pătrate a timpului: $\mathrm{VaR}^{(h)} = \sqrt{h}\,\mathrm{VaR}^{(1)}$

  - Exactă doar pentru pierderi i.i.d. Normale cu media zero: dispersia sumei a h zile independente este de h ori dispersia zilnică
  - Graficul (simulat): autocorelația pozitivă duce raportul peste $\sqrt{h}$; cozile groase îl coboară sub $\sqrt{h}$

Depășiri de prag: distribuția GPD

- Excesele $Y = L - u$ peste un prag ridicat u urmează aproximativ o **distribuție Pareto generalizată** (GPD) McNeil, Frey & Embrechts (2015)

$$P(Y \leq y \mid L > u) \approx G_{\xi,\beta}(y) = 1 - \Big(1 + \frac{\xi y}{\beta}\Big)^{-1/\xi}, \qquad y \geq 0$$

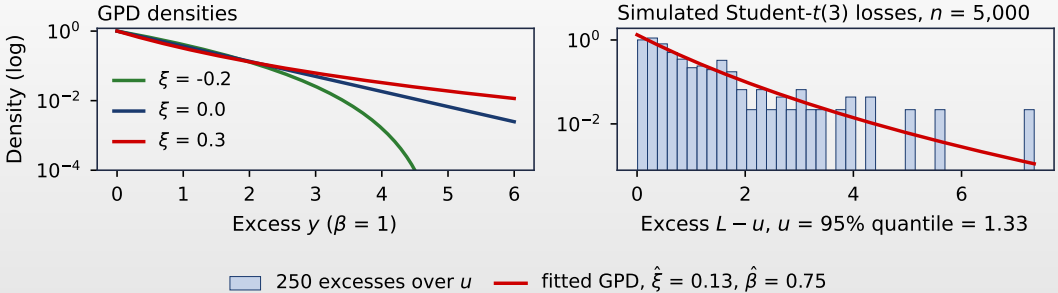
  - ξ: forma; $\xi > 0$: coadă grea, de tip putere (momentele de ordin $\geq 1/\xi$ sînt infinite); $\xi = 0$: coadă exponențială ($1 - e^{-y/\beta}$), ca la distribuția Normală; $\xi < 0$: coadă mărginită; $\beta > 0$: scala

- VaR și ES din coadă (n: mărimea selecției, N_u: numărul de depășiri, $\xi < 1$)

$$\mathrm{VaR}_\alpha = u + \frac{\beta}{\xi}\Big[\Big(\frac{n}{N_u}\,\alpha\Big)^{-\xi} - 1\Big], \qquad \mathrm{ES}_\alpha = \frac{\mathrm{VaR}_\alpha + \beta - \xi u}{1 - \xi}$$

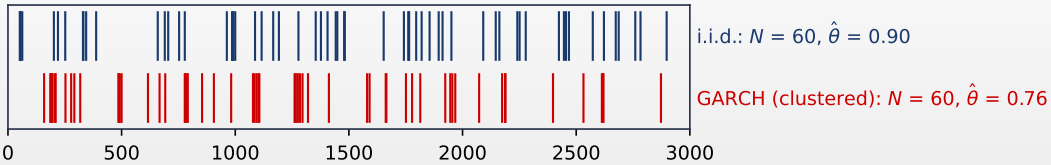
  - N_u/n estimează $P(L > u)$; GPD extrapolează dincolo de cele mai mari pierderi observate, unde HS nu are date
  - Erorile standard i.i.d. ale estimărilor de verosimilitate maximă: $\mathrm{SE}(\hat\xi) = (1 + \hat\xi)/\sqrt{N_u}$, $\mathrm{SE}(\hat\beta) = \hat\beta\sqrt{2(1 + \hat\xi)/N_u}$; alegerea lui u: deplasare (prag prea mic) față de dispersie (prag prea mare)

Distribuția GPD pe pierderi simulate



- Stînga: densități GPD cu $\beta = 1$ pe scală logaritmică: $\xi = -0{,}2$ se termină în $y = 5$, $\xi = 0$ este o dreaptă (exponențială), $\xi = 0{,}3$ scade ca o putere
- Dreapta: 5 000 de pierderi Student-t(3), pragul la cuantila de 95%, 250 de excese; $\hat{\xi} = 0{,}13$ estimat este sub valoarea adevărată a cozii, 1/3: cu 250 de excese $\mathrm{SE}(\hat{\xi}) \approx 0{,}07$, iar un prag insuficient de ridicat deplasează $\hat{\xi}$

Depășiri grupate: indicele extremal

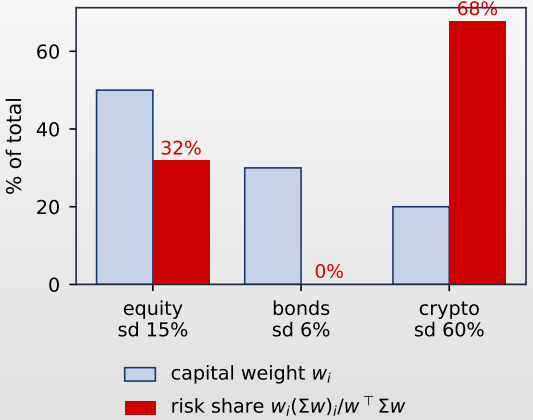


- **Indicele extremal** $\theta \in (0, 1]$: inversul mărimii medii a grupurilor de depășiri; $\theta = 1$: depășiri izolate (i.i.d.), $\theta = 0{,}5$: grupuri de cîte două în medie

$$\hat{\theta} = \min\left\{1, \frac{2\left(\sum_i (T_i - 1)\right)^2}{(N-1)\sum_i (T_i - 1)(T_i - 2)}\right\} \quad \text{dacă } \max_i T_i > 2$$

  - Estimatorul pe intervale Ferro & Segers (2003): $S_1 < \cdots < S_N$: zilele celor N depășiri; $T_i = S_{i+1} - S_i$: intervalele dintre ele; graficul: depășiri ale cuantilei de 98%, i.i.d. față de GARCH
  - Circa θN grupuri independente: erorile standard i.i.d. calculate din N depășiri sînt prea mici cînd $\theta < 1$

Contribuțiile la risc (alocarea Euler)



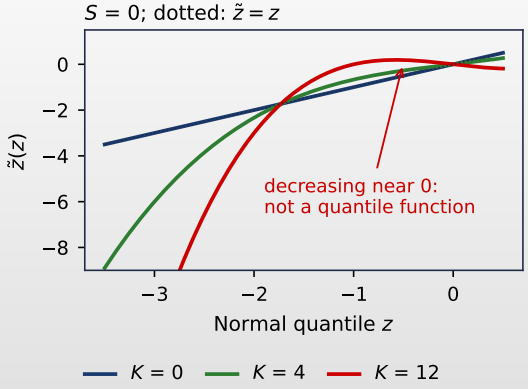
- Portofoliu Normal: expunerile w, matricea de covarianță Σ, media neglijată

$$\sigma_p = \sqrt{w^\top \Sigma w}, \qquad \mathrm{VaR} = z_{\mathbf{1}-\alpha}\sigma_p,$$
$$\frac{\partial \mathrm{VaR}}{\partial w_i} = z_{\mathbf{1}-\alpha}\frac{(\Sigma w)_i}{\sigma_p}, \qquad C_i = w_i \frac{\partial \mathrm{VaR}}{\partial w_i}$$

  - VaR marginal $\partial \mathrm{VaR}/\partial w_i$: variația VaR la o unitate în plus în activul i; VaR pe componente C_i Tasche (2008): $\sum_i C_i = \mathrm{VaR}$ (Euler: VaR este omogen de gradul 1)
  - Contribuțiile la ES: $\mathbb{E}[-w_i R_i \mid L_p \geq \mathrm{VaR}]$, media pierderii activului i în zilele din coada portofoliului

- Beneficiul diversificării: $\sum_i z_{\mathbf{1}-\alpha} w_i \sigma_i - \mathrm{VaR} \geq 0$
  - Paritatea riscului: ponderi cu cote egale, $w_i(\Sigma w)_i = w_j(\Sigma w)_j$ pentru orice i, j
  - Date (acțiuni, obligațiuni, cripto): ponderi 50/30/20%, SD 15/6/60% pe același orizont; corelații $\rho_{\mathbf{12}} = -0{,}2$, $\rho_{\mathbf{13}} = 0{,}3$, $\rho_{\mathbf{23}} = 0$. Cripto: 20% din capital, circa două treimi din risc

Dezvoltarea Cornish–Fisher (CF)



- Ajustează cuantila Normală pentru asimetria S și excesul de kurtosis K Cornish & Fisher (1938)

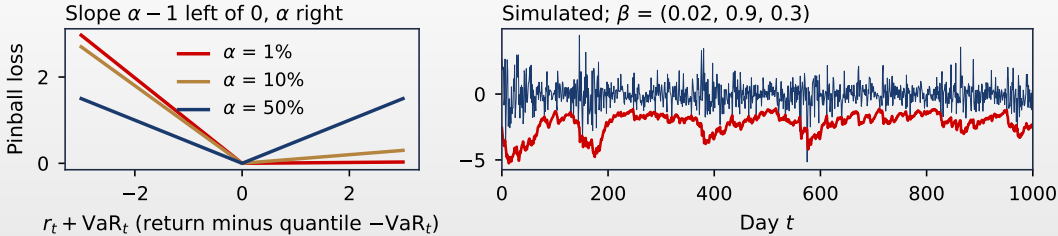
$$\tilde{z} = z + \frac{(z^2-1)S}{6} + \frac{(z^3-3z)K}{24} - \frac{(2z^3-5z)S^2}{36}$$

  - $S = \mathbb{E}[(X-\mu)^3]/\sigma^3$; $K = \mathbb{E}[(X-\mu)^4]/\sigma^4 - 3$ (0 pentru distribuția Normală); $\mathrm{VaR}_\alpha = -(\mu + \sigma\tilde{z}(z_\alpha))$
  - $K > 0$ împinge cuantila din extremitatea cozii mai departe; $S < 0$ lungește coada stîngă
- O funcție cuantilă validă trebuie să fie crescătoare în z; graficul ($S = 0$): pentru K mare, $\tilde{z}$ scade în jurul lui 0, deci dezvoltarea nu mai este o funcție cuantilă

Cum reacționează o cuantilă la randamente noi?

- Conditional Autoregressive Value at Risk (CAViaR) prognozează direct cuantila. Specificația Symmetric Absolute Value (SAV) reacționează la randamentul absolut, indiferent de semn.
- Condiția de stabilitate de mai jos permite persistență negativă sau pozitivă, cu modul sub unu. Cursul și estimarea empirică folosesc subcazul cu persistență pozitivă, între zero și unu.
- Cu persistență pozitivă, o prognoză de risc ridicată astăzi tinde să rămînă ridicată mîine. Coeficientul de reacție controlează creșterea suplimentară după un randament absolut mare.

Regresia cuantilă, pierderea pinball și CAViaR



- **Pierderea pinball**: pierderea a cărei medie este minimizată de cuantila adevărată de ordin α, $-\mathrm{VaR}_t$

$$\ell_\alpha(r_t, \mathrm{VaR}_t) = \big(\alpha - 1\{r_t < -\mathrm{VaR}_t\}\big)\,(r_t + \mathrm{VaR}_t)$$

  - O depășire costă $(1-\alpha)$ pe unitate, o zi deasupra cuantilei costă α pe unitate (stînga); o pierdere pinball medie mai mică = prognoze VaR mai bune
- **CAViaR** SAV Engle & Manganelli (2004): VaR urmează o recursie proprie, estimată prin minimizarea lui $\sum_t \ell_\alpha$
  - $\mathrm{VaR}_t = \beta_\mathbf{0} + \beta_\mathbf{1}\mathrm{VaR}_{t-\mathbf{1}} + \beta_\mathbf{2}|r_{t-\mathbf{1}}|$; $|\beta_\mathbf{1}| < 1$: persistența; $\beta_\mathbf{2}$: reacția la randamentul absolut de ieri (dreapta, simulat)

Ce măsoară scorurile prognozelor și regulile de capital?

- Testul Diebold–Mariano (DM) compară pierderile medii de prognoză. Incertitudinea Heteroskedasticity and Autocorrelation Consistent (HAC) ține cont de varianța variabilă și dependența între zile.
- Pierderea Fissler–Ziegel omogenă de grad zero (FZ0) evaluează împreună VaR și ES. Un scor mediu mai mic este mai bun; nu este o pierdere monetară realizată.
- Fundamental Review of the Trading Book (FRTB) este cadrul Basel pentru riscul de piață. Exercițiul izolează un calcul simplificat de capital; acuratețea prognozei și capitalul cerut sînt mărimi diferite.

Compararea prognozelor și capitalul reglementat

- **Testul Diebold–Mariano** Diebold & Mariano (1995): au două prognoze aceeași acuratețe?

$$d_t = \ell_t^A - \ell_t^B, \qquad DM = \frac{\bar{d}}{\sqrt{\hat{\Omega}_d / n}} \approx N(0,1) \text{ sub } H_0 : \mathbb{E}[d_t] = 0$$

  - ℓ_t^A, ℓ_t^B: pierderile (de ex. pinball) modelelor A și B în ziua t; $\bar{d}$: diferența medie; $\hat{\Omega}_d$: dispersia HAC de termen lung a lui d_t; $DM < -1{,}96$: A semnificativ mai bun la 5%

- **Pierderea comună VaR–ES** FZ0 Patton, Ziegel & Chen (2019): evaluează o pereche (v_t, e_t) = (cuantila randamentului, media cozii), $e_t \le v_t < 0$

$$\mathrm{FZ0} = -\frac{1\{r_t \le v_t\}\,(v_t - r_t)}{\alpha\, e_t} + \frac{v_t}{e_t} + \ln(-e_t) - 1$$

- **Capital de tip FRTB** (C2, simplificat) Basel Committee (2019): ES dintr-o fereastră de stres de 250 de zile, scalat la orizontul de lichiditate

$$\text{Capital} = m_c \times \mathrm{ES}_{\mathbf{10}}^{stres} \times \sqrt{LH/10} \times \text{suma}$$

  - $m_c = 1{,}5$: multiplicatorul; $\mathrm{ES}_{\mathbf{10}}^{stres}$: ES 2,5% pe 10 zile în cea mai rea fereastră; LH: orizontul de lichiditate în zile (10 sau 20)

Harta exercițiilor

Exercițiul	Întrebarea	Tipul	Reper sau exemplu
A1, A2	VaR și ES sub distribuțiile Normală și Student-t	Rezolvat	–
A3	VaR și ES pentru o pierdere discretă de neplată	Rezolvat	–
A4	penalizarea diversificării de către VaR	Propus	A3
B1	VaR și ES istorice pentru BET, cu intervale bootstrap	Rezolvat	–
B2	cît de precisă este o estimare ES?	Propus	B1
B3	VaR filtrat de mîine pentru Bitcoin	Propus	B1
C1	ce este greșit într-un răspuns AI?	Propus	B1
B4	o coadă GPD pentru BET (după curs)	Rezolvat	–
A5, B5	contribuțiile la risc a două active și într-un portofoliu cu patru active (după curs)	Rezolvat; Propus	A5
Pachete de extensie	A2, A4, A5, B1, B3, B4, B5 extinse; A6–A8, B6, B7; proiectele C2, C3 (opționale, după seminar)	Rezolvat și Propus	indicat la fiecare cerință

- **[Rezolvat]**: rezolvarea completă în slide-uri și în notebook, un model de urmat; **[Propus]**: o rezolvați individual, iar rezolvarea se discută la seminar; **[Deschis]**: o temă de proiect fără un singur răspuns corect (C2, C3)
- Partea A: derivări pe hîrtie; Partea B: estimare și inferență pe date reale, fiecare încheiată cu o întrebare de interpretare; Partea C: critica unui răspuns AI și proiecte deschise

Notații și convenții folosite în toate exercițiile

- Randamentul X (în %), pierderea $L = -X$; nivelul α = probabilitatea cozii; VaR și ES sînt numere **pozitive** atunci cînd sînt pierderi (definițiile: „VaR și ES")
- Convenția empirică (toate exercițiile B): `np.quantile(L, 1 - alpha)` și media cozii din secțiunea „Simularea istorică"
  - $\widehat{\mathrm{ES}}_\alpha$ mediază $k \approx n\alpha$ pierderi: o aproximare a ES exact, egală cu el cînd $n\alpha$ este întreg
- Unități: pierderi log în % din poziție pentru un activ; randamente simple pentru portofolii (se adună între active); puncte procentuale (pp) pentru erori standard și lățimi de intervale
- Simboluri asemănătoare: α = probabilitatea cozii, α_1 = coeficient GARCH; ξ = forma GPD, $\hat{\xi}_\alpha$ = cuantila reziduurilor (B3); w = expuneri monetare (A5) sau ponderi de portofoliu (B5)

A1 [Rezolvat]: VaR și ES pentru distribuția Normală — cerința

- **Întrebare**: care sînt valorile VaR și ES pentru o poziție cu randament zilnic Normal?
- **Date**
  - $X \sim N(\mu, \sigma^2)$, randamentul log zilnic în % din poziție, $\mu = 0{,}04\%$, $\sigma = 1{,}2\%$; pierderea $L = -X$, cu densitatea f
  - $z_\alpha = \Phi^{-1}(\alpha) < 0$; Φ, φ: funcția de repartiție și densitatea distribuției Normale standard
- **Cerințe**
  1. Derivați $\mathrm{ES}_\alpha = -\mu + \sigma\varphi(z_\alpha)/\alpha$ din $\mathrm{ES}_\alpha = -\mathbb{E}[X \mid X \le q_\alpha(X)]$.
  2. Calculați z_α și $\varphi(z_\alpha)$ la $\alpha = 1\%$ și $\alpha = 2{,}5\%$.
  3. Calculați VaR și ES la ambele niveluri, în % din poziție.
- **Raportați**: un tabel cu patru celule (VaR, ES $\times$ 1%, 2,5%)
- **Interpretare**
  - care dintre cele patru cifre sînt aproape egale?
  - de ce contează acest lucru pentru reglementare?
- Notebook: secțiunea A1

◂ Înapoi ▸ Lista exercițiilor

A1 [Rezolvat]: rezolvare — VaR și ES pentru distribuția Normală

- **1. Derivare.** Scriem $X = \mu + \sigma Z$; $X \le q_\alpha$ înseamnă $Z \le z_\alpha$, de probabilitate α
  - Deoarece $\varphi'(u) = -u\varphi(u)$: $\int_{-\infty}^{z} u\varphi(u)\,du = [-\varphi(u)]_{-\infty}^{z} = -\varphi(z)$
  - $\mathbb{E}[X \mid X \le q_\alpha] = \mu + \dfrac{\sigma}{\alpha}\displaystyle\int_{-\infty}^{z_\alpha} u\varphi(u)\,du = \mu - \sigma\dfrac{\varphi(z_\alpha)}{\alpha}$; schimbăm semnul
- **2–3.** $\mathrm{VaR}_\alpha = -(\mu + \sigma z_\alpha)$, de ex. $-(0{,}04 + 1{,}2 \cdot (-2{,}326)) = 2{,}75$; $\mathrm{ES}_{\mathbf{1\%}} = -0{,}04 + 1{,}2 \cdot 2{,}665 = 3{,}16$

α	z_α	$\varphi(z_\alpha)$	φ/α	VaR_α	ES_α
1%	−2,326	0,0267	2,665	2,75	3,16
2,5%	−1,960	0,0584	2,338	2,31	2,77

- VaR și ES în % din poziție; pentru o poziție de 1 milion de unități monetare: VaR 1% $\approx$ 27 516, ES 1% $\approx$ 31 583
- Interpretare: ES 2,5% (2,77%) $\approx$ VaR 1% (2,75%): sub distribuția Normală trecerea la ES 2,5% lasă capitalul practic neschimbat; de aceea FRTB a ales acest nivel

A2 [Rezolvat]: ES pentru distribuția Student-t — cerința

- **Întrebare**: în ce măsură modifică cozile grele VaR și ES cînd abaterea standard este aceeași ca în A1?
- **Date**
  - $X = m + sT$, $T \sim t_\nu$ cu densitatea g_ν, $t_\alpha = t_\nu^{-1}(\alpha) < 0$; $\nu = 4$, $m = 0{,}04\%$, abaterea standard 1,2%
  - Integrala cozii (demonstrația în pachetul de extensie 1): $\int_{-\infty}^{t} x g_\nu(x)\,dx = -g_\nu(t)\,\dfrac{\nu + t^2}{\nu - 1}$ pentru $\nu > 1$
- **Cerințe**
  1. Folosiți integrala cozii pentru a scrie $\mathrm{ES}_\alpha = -m + s\,\dfrac{g_\nu(t_\alpha)}{\alpha}\,\dfrac{\nu + t_\alpha^2}{\nu - 1}$.
  2. Găsiți scala s care dă o abatere standard de 1,2%, folosind $\mathrm{Var}(T) = \nu/(\nu - 2)$ (finită doar pentru $\nu > 2$).
  3. Calculați VaR și ES la 1% și 2,5% și puneți-le lîngă A1.
- **Raportați**: tabelul din A1 cu o coloană Student-t
- **Interpretare**
  - la ce nivel diferă cel mai mult cele două modele?
  - de ce surprinde ES diferența primul?
- Greșeală frecventă: folosirea lui $\sigma = 1{,}2$ în loc de s ca scală

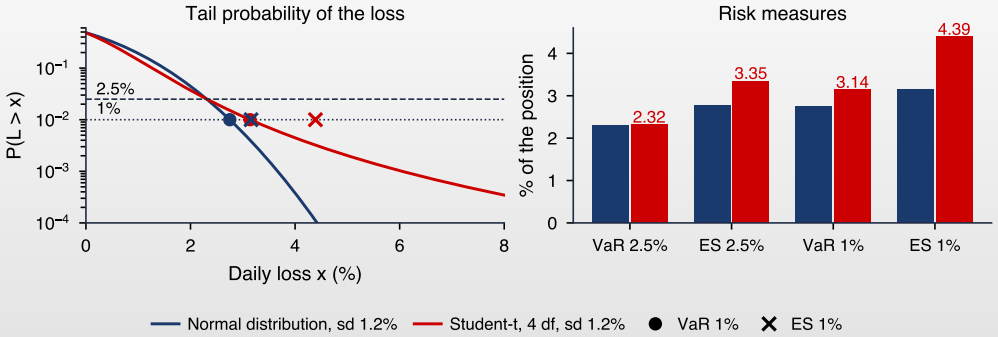
◂ Înapoi ▸ Lista exercițiilor

A2 [Rezolvat]: rezolvare — ES pentru distribuția Student-t (1/2)

- **1.** Împărțim integrala cozii la α și rescalăm cu $X = m + sT$, ca în A1
- **2.** $s^2 \cdot 4/2 = 1{,}2^2$, deci $s = 1{,}2\sqrt{2/4} = 0{,}849$
- **3.** La 1%: $t_{1\%} = -3{,}747$, $g_4(t_{1\%}) = 0{,}0087$, factorul ES $\dfrac{0{,}0087}{0{,}01} \cdot \dfrac{4 + 14{,}04}{3} = 5{,}221$
  - $\mathrm{VaR}_{1\%} = -(0{,}04 + 0{,}849 \cdot (-3{,}747)) = 3{,}14$; $\mathrm{ES}_{1\%} = -0{,}04 + 0{,}849 \cdot 5{,}221 = 4{,}39$

	$\mathrm{VaR}_{2{,}5\%}$	$\mathrm{ES}_{2{,}5\%}$	$\mathrm{VaR}_{1\%}$	$\mathrm{ES}_{1\%}$
Normală	2,31	2,77	2,75	3,16
t_4	2,32	3,35	3,14	4,39

A2 [Rezolvat]: rezolvare — ES pentru distribuția Student-t (2/2)



- Interpretare: VaR 2,5% este același în ambele modele; VaR 1% și ambele ES sînt mult mai mari sub t_4: efectul cozilor grele apare doar în extremitatea cozii, iar ES îl surprinde primul

MFM_ch7_seminar

A3 [Rezolvat]: VaR și ES pentru o pierdere discretă — cerința

- **Întrebare**: care sînt valorile VaR și ES cînd pierderea are un atom (o neplată)?
- **Date**: o obligațiune pierde 60 de unități monetare (pierderea în caz de neplată, LGD) cu probabilitatea $p = 3\%$ și 0 altfel
- **Cerințe**
  1. Calculați VaR 5% și VaR 2,5% din definiția VaR cu infimum („VaR și ES").
  2. Calculați ES 5% și ES 2,5% cu formula pentru o pierdere cu atom („Pierderi cu un atom") Acerbi & Tasche (2002).
  3. Explicați de ce $\mathrm{ES}_{5\%}$ diferă de $\mathbb{E}[L \mid L \geq \mathrm{VaR}_{5\%}]$.
- **Raportați**: patru cifre și o frază

Pierderea L	0	60
$P(L)$	97%	3%
$P(L \geq \cdot)$	100%	3%

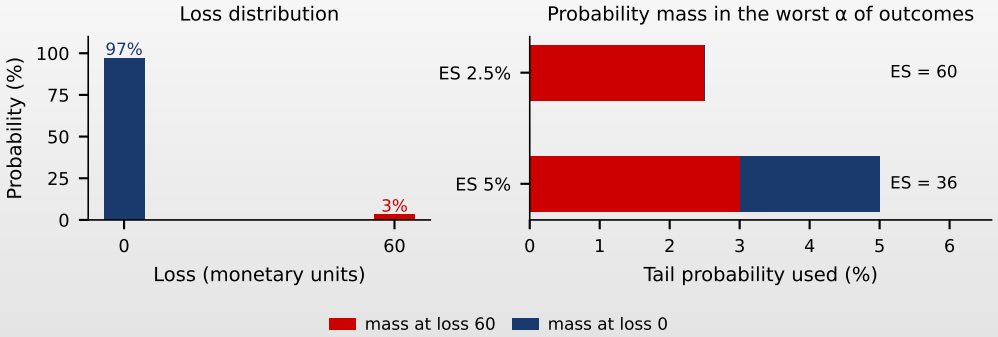
- Coada de probabilitate α trebuie acoperită cu masă de probabilitate; la $\alpha = 5\%$ masa de 3% a neplății nu este suficientă

◂ Înapoi ▸ Lista exercițiilor

A3 [Rezolvat]: rezolvare — VaR și ES pentru o pierdere discretă (1/2)

- **1.** $P(X \le -60) = 3\% \le 5\%$, $P(X \le 0) = 100\% > 5\%$: $q_{\mathbf{5\%}} = 0$, $\mathrm{VaR}_{\mathbf{5\%}} = 0$; $P(X \le -60) = 3\% > 2{,}5\%$: $\mathrm{VaR}_{\mathbf{2{,}5\%}} = 60$
- **2.** $\mathrm{ES}_{\mathbf{5\%}} = \dfrac{60 \cdot 0{,}03 + 0 \cdot (0{,}05 - 0{,}03)}{0{,}05} = 36$; $\mathrm{ES}_{\mathbf{2{,}5\%}} = \dfrac{0 + 60 \cdot (0{,}025 - 0)}{0{,}025} = 60$
- **3.** $\mathbb{E}[L \mid L \ge 0] = 1{,}8$ este media pe **toate** rezultatele; ES 5% folosește masa de 3% a neplății plus 2% din atomul pierderii zero (graficul)
- Interpretare: această masă fracționară este versiunea exactă a mediei din coadă folosite în B1, cu $k \approx n\alpha$ pierderi

A3 [Rezolvat]: rezolvare — VaR și ES pentru o pierdere discretă (2/2)



MFM_ch7_seminar

A4 [Propus]: penalizarea diversificării de către VaR — cerința

- **Întrebare**: poate o limită VaR să facă un portofoliu diversificat să pară mai riscant decît componentele lui?
- **Date**: două obligațiuni independente A și B; fiecare pierde 100 cu probabilitatea $p = 0{,}7\%$ (cursul a folosit 0,9%) și 0 altfel; portofoliul A + B Artzner et al. (1999)
- **Cerințe**
  1. Scrieți distribuția pierderii portofoliului: valorile 0, 100, 200 și probabilitățile lor.
  2. Calculați VaR 1% și ES 1% pentru o obligațiune și pentru portofoliu, cu formula discretă din A3.
  3. Arătați că VaR 1% nu este subaditiv aici, iar ES 1% este.
  4. Recalculați ambele măsuri de risc și decideți dacă subadditivitatea se păstrează la $\alpha = 1{,}5\%$.
- **Raportați**: un tabel cu VaR și ES pentru A, B și A + B la ambele niveluri
- **Interpretare**: ce ar recompensa o limită bazată pe VaR?
- **Repere și exemple**: A3

Înapoi Lista exercițiilor

Ce fișiere definesc eșantionul?

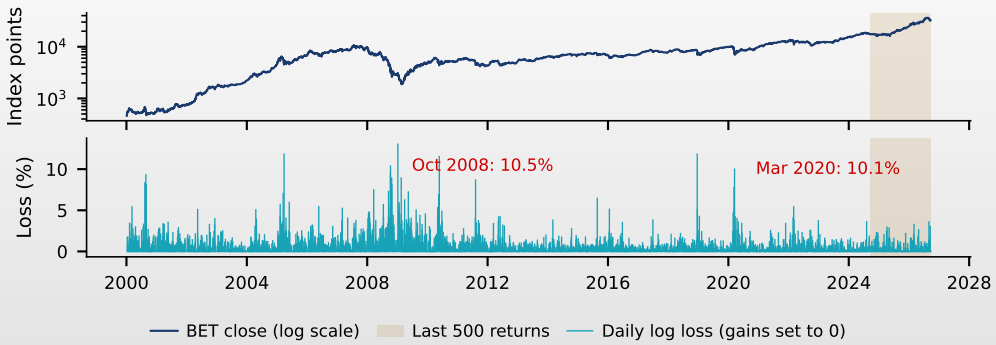
- Fișierele au indexul `date`. Pentru BET, S&P 500, Bitcoin și aur folosiți `close` din `BET.csv`, `GSPC.INDX.csv`, `BTC-USD.CC.csv`, `XAUUSD.FOREX.csv`, în data/market.
- ETF-urile folosesc `adjusted_close`: `SPY.US.csv`, `TLT.US.csv`, `GLD.US.csv`. Bitcoin păstrează închiderea; aliniați prețurile pe date comune observate înainte de diferențiere.
- Coșul BVB folosește închiderile ajustate TLV, SNP, BRD, TGN, SNG, SNN, EL și TEL, fiecare în `SIMBOL.RO.csv`. Ponderile egale se aplică randamentelor simple, nu logaritmilor lor.
- EUR/RON provine din arhiva XML anuală BNR, cîmpul EUR, pentru 2005–2026; descărcați cîte un fișier pentru fiecare an 2005–2026, înlocuind 2026 în URL. Păstrați capetele de eșantion precizate în fiecare cerință.

B1 [Rezolvat]: VaR și ES istorice pentru BET — cerința

- **Întrebări**
  - cît de mari sînt pierderile din coada pieței românești de acțiuni?
  - cît de precise sînt estimările?
- **Date**
  - Indicele BET, închideri zilnice 2000-01-05 – 2026-09-18, doar zilele lucrătoare; $n = 6\,670$ randamente log zilnice în %, $r_t = 100\,(\ln P_t - \ln P_{t-1})$, pierderea $L_t = -r_t$
  - Două selecții: întreaga perioadă și ultimele 500 de randamente (de la 2024-09-12, hașurate în grafic)
- **Cerințe**
  1. Calculați VaR și ES istorice la 1% și 2,5% pe ambele selecții și numărați pierderile de dincolo de VaR 1%.
  2. Construiți un interval bootstrap percentil de 95% pentru VaR 1% cu 2 000 de reeșantionări i.i.d., sămînța 42 Efron (1979).
  3. Repetați pasul 2 cu bootstrap pe blocuri mobile: blocuri de 20 de zile extrase cu revenire, concatenate și tăiate la lungimea n Künsch (1989).
- **Raportați**: un tabel cu cele opt cifre VaR/ES și cele două intervale pentru fiecare selecție
- **Interpretare**
  - ce estimare ați prezenta unui comitet de risc?
  - de ce este intervalul pe blocuri mai larg pe întreaga selecție?

◂ Înapoi ▸ Lista exercițiilor

B1 [Rezolvat]: VaR și ES istorice pentru BET — datele



- Observați: cele mai mari pierderi (octombrie 2008: 10,45%; martie 2020: 10,08%) apar grupat

MFM_ch7_seminar

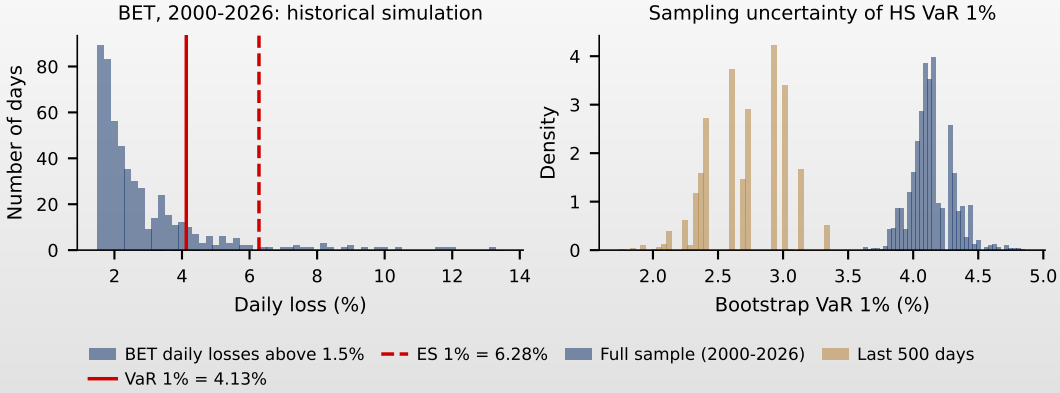
B1 [Rezolvat]: rezolvare (1/4) — pas cu pas

- **1. Ultimele 500 de zile.** Ordonăm pierderile; VaR 1% se află în poziția $1 + 499 \cdot 0{,}99 = 495{,}01$; $L_{(i)}$: a i-a cea mai mică pierdere
  - $\widehat{\mathrm{VaR}}_{1\%} = L_{(495)} + 0{,}01\,(L_{(496)} - L_{(495)}) = 2{,}710 + 0{,}01\,(2{,}925 - 2{,}710) = 2{,}712\%$
  - Cele cinci pierderi de dincolo: 3,68, 3,35, 3,12, 3,03, 2,93: media lor este $\widehat{\mathrm{ES}}_{1\%} = 3{,}22\%$

	n	$\mathrm{VaR}_{1\%}$	$\mathrm{ES}_{1\%}$	$\mathrm{VaR}_{2{,}5\%}$	$\mathrm{ES}_{2{,}5\%}$	dincolo de VaR 1%
2000–2026	6 670	4,13	6,28	2,80	4,57	67
Ultimele 500 de zile	500	2,71	3,22	2,05	2,69	5

- ES 1% pe 500 de zile este media a doar cinci numere: îl raportăm împreună cu acest număr
- Ambele sînt rezumate necondiționate: selecția completă descrie 26 de ani, ultimele 500 de zile o perioadă calmă; riscul de mîine cere o prognoză condiționată (B3)

B1 [Rezolvat]: rezolvare (2/4) — coada și bootstrap-ul



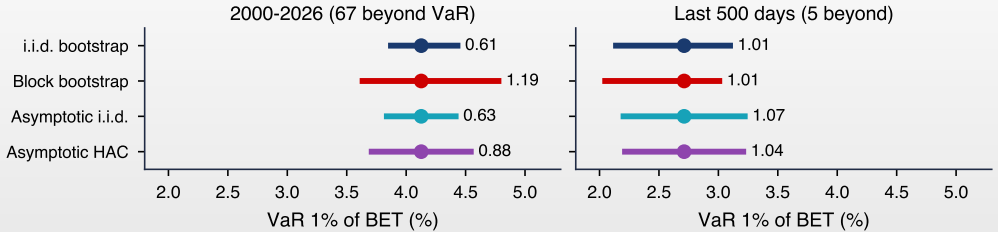
MFM_ch7_seminar

B1 [Rezolvat]: rezolvare (3/4) — coada și bootstrap-ul

- Stînga: pierderile BET de peste 1,5% cu VaR 1% și ES 1% istorice; dreapta: cele 2 000 de valori bootstrap i.i.d. ale VaR 1% pentru fiecare selecție
- Fiecare reeșantionare recalculează atît cuantila, cît și pierderile de dincolo de ea; percentilele de 2,5% și 97,5% ale celor 2 000 de valori dau intervalul
- Cele două distribuții bootstrap nu se suprapun: perioada recentă este mai puțin volatilă decît media celor 26 de ani

MFM_ch7_seminar

B1 [Rezolvat]: rezolvare (4/4) — intervale



Dot: historical VaR 1%; bar: 95% interval; number: interval width in percentage points

- **2.** Bootstrap i.i.d.: complet [3,85; 4,46], ultimele 500 de zile [2,11; 3,12]
- **3.** Bootstrap pe blocuri: [3,61; 4,80] și [2,02; 3,03]

- Interpretare: depășirile sînt grupate în 2008 și 2020, deci blocurile care păstrează o criză întreagă aproape dublează lățimea intervalului bootstrap pe întreaga selecție (în B1 extins: asimptotic și HAC); ultimele 500 de zile, calme, nu arată acest efect

MFM_ch7_seminar

B2 [Propus]: precizia unei estimări ES — cerința

- **Întrebare**: estimează un ES 2,5% istoric pe 500 de zile riscul din coadă cu o precizie de $\pm 0{,}3$ pp Pele & Mazurencu-Marinescu-Pele (2026)?
- **Date**
  - S&P 500 (închideri zilnice) și BET, pierderi log zilnice în %, 2000–2026; selecții: completă și ultimele 500 de zile
  - Folosiți funcția de reeșantionare din B1 (2 000 de reeșantionări, sămînța 42, blocuri de 20 de zile), cu ES 2,5% ca statistică
- **Cerințe**
  1. Calculați ES 2,5%, numărul de observații din coadă $n\alpha$ și numărul k de pierderi incluse efectiv în media din coadă.
  2. Extrageți o reeșantionare i.i.d. și una pe blocuri pentru ultimele 500 de zile ale S&P 500 și recalculați pe fiecare VaR 2,5%, pierderile din coadă și ES.
  3. Construiți intervalele de 95% i.i.d. și pe blocuri pentru toate cele patru selecții și comparați lățimile lor cu 0,6 pp ($\pm 0{,}3$).
- **Raportați**: un tabel ($n\alpha$, k, ES, două intervale) și un grafic cu intervalele
- **Interpretare**
  - care selecții ating ținta de $\pm 0{,}3$ pp?
  - ce determină lățimea?
- **Repere și exemple**: B1

◂ Înapoi ▸ Lista exercițiilor

De la șocurile istorice la prognoza pentru mîine

- B1 estimează o coadă istorică necondiționată. B3 elimină întîi media și volatilitatea variabile, apoi reaplică scala de mîine. Cuantila reziduurilor nu are unitate; prognoza este procentuală.
- Datele exemplului: $\hat{\mu} = 0{,}10\%$, $\hat{\sigma} = 2\%$, cuantila inferioară a reziduurilor -2 și media lor în coada inferioară $-2{,}6$.
- Obținem $\mathrm{VaR} = -0{,}10 + 2 \times 2 = 3{,}90\%$ și $\mathrm{ES} = -0{,}10 + 2 \times 2{,}6 = 5{,}10\%$. Verificăm că ES depășește VaR și că o medie prognozată pozitivă reduce ambele pierderi.
- Pentru prognoza punctuală de mîine folosim eșantionul încheiat astăzi. Pentru backtest-ul de doi ani urmăm separat reestimarea din ianuarie: nici parametrii estimați, nici coada reziduurilor nu pot folosi observații din anul prognozat. Starea variației se actualizează după fiecare randament nou observat.

Estimarea filtrului și prognoza pe o zi

- Folosiți funcția furnizată `garch_filter(r)` cu randamente log zilnice în procente. Estimează AR(1) cu intercept și GARCH(1,1) prin QML Normal; `garch_next(r, params)` dă media și volatilitatea următoare.
- Apelul de estimare este `arch_model(r, mean="AR", lags=1, vol="GARCH", p=1, q=1, dist="normal", rescale=False).fit()`. QML Normal nu impune cozi Normale reziduurilor din FHS.
- Calculați reziduurile standardizate doar unde există media și volatilitatea ajustate; eliminați rîndul inițial nedefinit. Estimați coada empirică și aplicați exemplul numeric precedent.
- În C2 transformați mai întîi randamentul simplu al coșului în $r_t = 100 \ln(1 + R_t/100)$. Filtrați această serie; convertiți pierderile log simulate în pierderi simple înainte de raportarea sumelor.

B3 [Propus]: VaR filtrat de mîine pentru Bitcoin — cerința

- **Întrebare**: VaR 1% pentru Bitcoin pe 19 septembrie 2026: filtrat sau istoric?
- **Date**
  - Bitcoin (USD), închideri zilnice, 17 septembrie 2014 – 18 septembrie 2026, 7 zile pe săptămînă; randamente log zilnice în %
  - AR(1)-GARCH(1,1) prin cvasi-verosimilitate Normală (QML), cu intercept în AR: $r_t = \mu_t + \sigma_t z_t$ Barone-Adesi et al. (1999)
- **Cerințe**
  1. Estimați modelul pe întreaga selecție și prognozați $\hat{\mu}_{t+\mathbf{1}}$, $\hat{\sigma}_{t+\mathbf{1}}$.
  2. Calculați $\hat{\xi}_{\mathbf{1\%}} = -q_{\mathbf{1\%}}(\hat{z})$ din reziduurile standardizate și VaR 1% și ES 1% filtrate.
  3. Comparați cu VaR și ES istorice pe ultimele 500 de zile și pe întreaga selecție.
  4. Cu prognozele din cronologie (dreapta), numărați zilele de la 18 septembrie 2024 pînă la 18 septembrie 2026 cu pierdere peste VaR FHS și peste un VaR HS pe fereastră mobilă de 500 de zile.
- **Raportați**: trei perechi VaR/ES, două numere de depășiri și numărul așteptat $n\alpha$ sub calibrare pentru cele 731 de zile de evaluare
- **Repere și exemple**: B1 (cuantile istorice); estimarea filtrului și prognoza pe o zi

Cronologia prognozelor (pasul 4)



în fiecare ianuarie: GARCH pe toate datele anterioare
în fiecare zi: $\hat{\sigma}_{t+\mathbf{1}}$ din datele pînă la t
reziduurile folosite: cele de dinainte de acel ianuarie

- Nicio prognoză nu folosește informație din ziua ei sau de mai tîrziu: un prag din întreaga selecție nu este o prognoză în afara eșantionului
- **Interpretare**
  - de ce diferă cele trei VaR?
  - care metodă greșește mai des?

◂ Înapoi ▸ Lista exercițiilor

C1 [Propus]: critica unui răspuns AI — răspunsul

- **Cererea**: „px conține închiderile zilnice BET, 2000–2026. Dă-mi VaR 1% și ES 2,5% istorice pe o zi, ca pierderi log pozitive în %, și VaR 1% pe 10 zile."
- **Răspunsul**: codul de mai jos, care rulează fără niciun mesaj de eroare

```
import numpy as np
r = 100 * np.log(px).diff().dropna()                # daily log returns, %
loss = -r                                           # log loss, %
var1 = np.percentile(r, 99)                         # VaR 1%
es25 = loss[loss >= np.percentile(loss, 99)].mean()  # ES 2.5%
var10 = 10 * var1                                   # 10-day VaR 1%
```

- **Concluzia AI**: „VaR 1% = 3,95%, ES 2,5% = 6,28%, VaR 1% pe 10 zile = 39,46%."

Înapoi Lista exercițiilor

C1 [Propus]: critica unui răspuns AI — cerința

- **Întrebări**
  - ce linii din răspunsul AI sînt greșite?
  - care sînt cifrele corecte?
- **Date**: datele BET din B1; răspunsul conține **trei** greșeli tipice pentru VaR și ES, restul este corect
- **Cerințe**
  1. Pentru fiecare greșeală, indicați numărul liniei și explicați într-o frază de ce este greșită, folosind $\mathrm{VaR}_\alpha = -q_\alpha(r) = q_{1-\alpha}(L)$.
  2. Precizați cum ați depista-o: o numărătoare a observațiilor, o cifră din B1 sau un slide din curs.
  3. Scrieți liniile corectate, inclusiv VaR pe 10 zile din pierderile suprapuse pe 10 zile, și recalculați cele trei cifre.
  4. Verificați ES 2,5% corectat: pe cîte pierderi se calculează media? Pe cîte ar trebui calculată?
- **Raportați**: un tabel al erorilor (linia, eroarea, depistarea, corecția) și cifrele corectate; notați fiecare eroare găsită efectiv în `AI_ERRORS.md`
- **Interpretare**: de ce rulează codul fără mesaj de eroare, deși răspunsul este greșit?
- **Repere și exemple**: B1

B4 [Rezolvat]: o coadă GPD pentru BET — cerința

- **Întrebare**: ce aduce în plus un model de valori extreme pentru coadă față de simularea istorică, în extremitatea cozii?
- **Date**
  - Pierderile BET din B1 ($n = 6\,670$)
  - Depășiri de prag McNeil, Frey & Embrechts (2015): GPD cu forma ξ și scala β, erorile ei standard și VaR și ES pentru coadă (formulele: „Depășiri de prag: distribuția GPD"); N_u = numărul de depășiri
- **Cerințe**
  1. Fixați u = cuantila empirică de 95% a lui L și formați excesele $L - u$ ale pierderilor de peste el.
  2. Estimați GPD prin verosimilitate maximă cu locația fixată la 0: `scipy.stats.genpareto.fit(excese, floc=0)`.
  3. Calculați erorile standard i.i.d. $\mathrm{SE}(\hat{\xi})$ și $\mathrm{SE}(\hat{\beta})$.
  4. Calculați VaR și ES GPD la 1%, 0,5% și 0,1% și comparați cu simularea istorică.
  5. Re-estimați pentru praguri depășite de 10% pînă la 1,5% dintre pierderi și reprezentați $\hat{\xi}$ cu benzi de 95%.
- **Raportați**: estimarea cu erorile standard, un tabel VaR/ES cu șase rînduri și numărul de observații din coadă, graficul de stabilitate
- **Interpretare**
  - este coada BET mai grea decît distribuția Normală?
  - cît de precisă este această concluzie?

Înapoi Lista exercițiilor

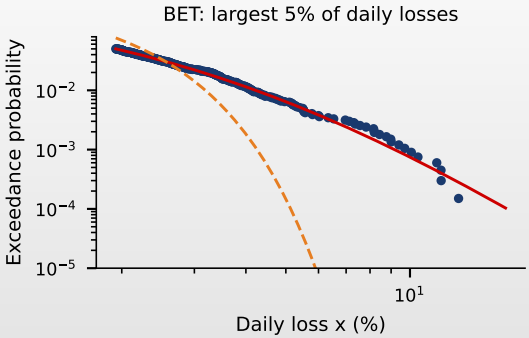
B4 [Rezolvat]: rezolvare (1/3) — estimarea și tabelul

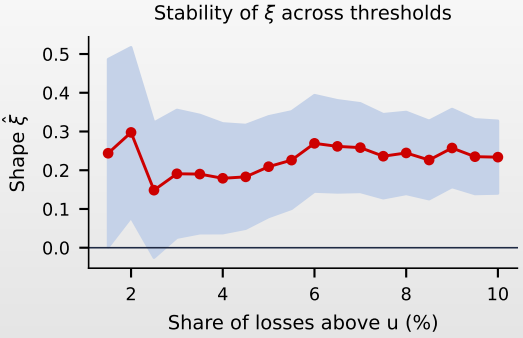
- **1–2.** $u = 1{,}93\%$ lasă deasupra $N_u = 334$ din $n = 6\,670$ pierderi; $\hat{\xi} = 0{,}209$, $\hat{\beta} = 1{,}20$
- **3.** $\mathrm{SE}(\hat{\xi}) = (1 + 0{,}209)/\sqrt{334} = 0{,}066$, $\mathrm{SE}(\hat{\beta}) = 0{,}10$; $\hat{\xi}/\mathrm{SE} = 3{,}2$
- **4.** VaR 1%: $N_u/n = 0{,}050$, $(0{,}01/0{,}050)^{-\mathbf{0{,}209}} = 1{,}401$
  - $\mathrm{VaR}_{\mathbf{1\%}} = 1{,}93 + \frac{\mathbf{1{,}20}}{\mathbf{0{,}209}}(1{,}401 - 1) = 4{,}22\%$

	VaR GPD	VaR ist.	ES GPD	ES ist.
1%	4,22	4,13	6,34	6,28
0,5%	5,47	5,38	7,92	7,86
0,1%	9,18	9,50	12,61	11,25

- Pierderi dincolo de VaR istoric: 67 la 1%, 34 la 0,5%, 7 la 0,1%
- Cele două metode coincid pînă la 0,5%; la 0,1% ES istoric este media a 7 numere, în timp ce GPD folosește toate cele 334 de excese printr-o coadă estimată

B4 [Rezolvat]: rezolvare (2/3) — diagnostic





Empirical P(L >= x) — GPD fit, xi = 0.21 — Normal distribution — 95% confidence band — Estimated xi

MFM_ch7_seminar

B4 [Rezolvat]: rezolvare (3/3) — diagnostic

- Stînga: GPD urmează coada empirică, coada Normală cade mult sub ea; dreapta: $\hat{\xi}$ variază între 0,15 și 0,30 pe praguri, iar VaR 0,1% doar între 9,04% și 9,51%
- Interpretare: coada este mai grea decît cea Normală, dar SE i.i.d. presupune depășiri independente; pierderile BET sînt grupate, deci incertitudinea reală este mai mare (B4 extins: indicele extremal)

MFM_ch7_seminar

A5 [Rezolvat]: contribuțiile la risc a două active — cerința

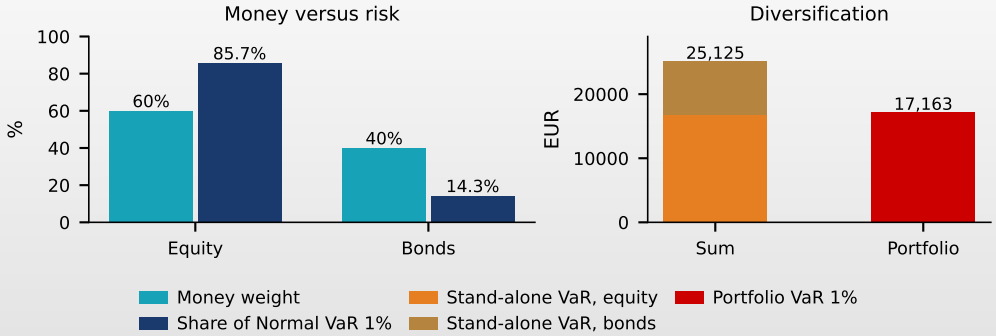
- **Întrebare**: contribuie fiecare activ la risc proporțional cu capitalul investit în el?
- **Date**
  - Expuneri monetare $w = (600\,000,\ 400\,000)$ EUR în acțiuni și obligațiuni; randamente simple zilnice R în zecimale, abateri standard $\sigma_1 = 0{,}012$, $\sigma_2 = 0{,}009$, corelația $\rho = -0{,}2$
  - $\Sigma = \begin{pmatrix} 0{,}000144 & -0{,}0000216 \\ -0{,}0000216 & 0{,}000081 \end{pmatrix}$; (Σ: matricea de covarianță) randamente cu distribuție Normală comună, media neglijată, $\alpha = 1\%$, $z_{99\%} = 2{,}326$ (cuantila de 99% a distribuției Normale standard)
- **Cerințe**
  1. Calculați abaterea standard a portofoliului σ_p în EUR și VaR 1% al portofoliului (formulele: „Contribuțiile la risc (alocarea Euler)").
  2. Calculați Σw, VaR marginal pe EUR și VaR pe componente C_i; verificați $C_1 + C_2 = \mathrm{VaR}$ Tasche (2008).
  3. Calculați beneficiul diversificării: suma VaR-urilor individuale minus VaR-ul portofoliului.
  4. Sub distribuția Normală, rescalați fiecare C_i cu $\dfrac{\varphi(z_{1\%})/0{,}01}{z_{99\%}}$ pentru a obține contribuțiile la ES 1%.
- **Raportați**: un tabel cu C_i, C_i^{ES} și cotele lor și beneficiul diversificării în EUR
- **Interpretare**: contribuie obligațiunile la risc proporțional cu ponderea lor de 40% din capital?

înapoi Lista exercițiilor

A5 [Rezolvat]: rezolvare — contribuțiile la risc a două active (1/2)

- **1.** $\sigma_p^2 = 7\,200^2 + 3\,600^2 + 2(-0{,}2)(7\,200)(3\,600) = 54\,432\,000$, $\sigma_p = 7\,378$ EUR, $\mathrm{VaR}_{1\%} = 2{,}326 \cdot 7\,378 = 17\,163$ EUR
- **2.** $\Sigma w = (77{,}76;\, 19{,}44)$; VaR marginal pe EUR $(0{,}0245;\, 0{,}0061)$; $C_1 = 14\,711$ (85,7%), $C_2 = 2\,452$ (14,3%), suma 17 163 EUR
- **3.** Individual $16\,750 + 8\,375 = 25\,125$ EUR față de 17 163 EUR
- **4.** Factorul 1,146: $C_1^{ES} = 16\,854$, $C_2^{ES} = 2\,809$, total 19 663 EUR = ES 1%; aceleași cote ca VaR sub distribuția Normală

A5 [Rezolvat]: rezolvare — contribuțiile la risc a două active (2/2)



- Interpretare: obligațiunile au 40% din capital, dar 14,3% din risc: corelația negativă le transformă într-o acoperire parțială (hedge)

MFM_ch7_seminar

B5 [Propus]: contribuțiile la risc într-un portofoliu cu patru active — cerința

- **Întrebare**: într-un portofoliu cu ponderi egale în SPY, TLT, GLD și Bitcoin, ce active generează riscul?
- **Date**
  - SPY, TLT, GLD (închideri ajustate) și Bitcoin (închideri în USD), 18 septembrie 2014 – 18 septembrie 2026; aliniați mai întîi prețurile, apoi păstrați 3 017 randamente simple zilnice comune R în %
  - Ponderi fracționare $w_i = 25\%$, rebalansare zilnică; Σ = covarianța de selecție a lui R (în $\%^2$); VaR 1% Normal cu media neglijată; ES 2,5% istoric
- **Cerințe**
  1. Calculați VaR 1% Normal, VaR marginal și VaR pe componente pentru fiecare activ, ca în A5.
  2. Calculați ES 2,5% istoric al pierderii portofoliului $L_p = -w^\top R$ și contribuțiile $\mathbb{E}[-w_i R_i \mid L_p \geq \mathrm{VaR}_{\mathbf{2,5\%}}]$ ca medii pe zilele din coadă.
  3. Calculați VaR nediversificat $\sum_i z_{\mathbf{99\%}} w_i \sigma_i$.
- **Raportați**: un tabel cu ponderi, contribuții și cote și un grafic al ponderilor în capital față de cotele de risc
- **Interpretare**: implică ponderi egale în capital contribuții egale la risc? (compararea VaR 1% Normal cu ES 2,5% istoric schimbă atît modelul, cît și nivelul)
- **Repere și exemple**: A5

◂ Înapoi ▸ Lista exercițiilor

Verificarea finală și proiectul de echipă

Verificare finală: puteți explica de ce

- un ES 1% pe 500 de zile trebuie raportat împreună cu numărul 5?
- scalarea cu $\sqrt{10}$ este prea mică pentru BET?
- o poziție de 25% poate genera cea mai mare parte din risc (B5, după curs)?
- pierderile portofoliului cer randamente simple, nu log?

Proiectul de echipă

- Alegeți unul dintre C2 și C3 (pachetul de extensie 4), cu grila comună
- Notați folosirea AI în `AI_USE.md` și fiecare eroare prinsă efectiv în `AI_ERRORS.md` (fără un număr minim)

Pachetele de extensie: conținut și cerințe prealabile

Pachetul	Exercițiile	Cerințe prealabile
1. Algebra cozii	A2 extins [Rezolvat], A4 extins, A6, A7, A5 extins [Rezolvat], A8	A1–A5
2. Inferență	B1 extins [Rezolvat], B3 extins, B6, B5 extins	B1, B3, B5
3. Extreme și dinamică	B4 extins [Rezolvat], B7	B3, B4
4. Proiecte	C2 (capitalul ES, BVB față de S&P 500), C3 (deep quantile regression); grila	studiul de caz din curs, B1–B3

- Fiecare exercițiu are în notebook o secțiune cu aceeași etichetă și indică exemplul de urmat; rezolvați-le în ordine în cadrul unui pachet

A2 extins [Rezolvat]: integrala cozii Student-t — cerința și rezolvarea

- **Întrebare**: cum se obține factorul ES Student-t din A2?
- **Date**: $g_\nu(x) = c_\nu(1 + x^2/\nu)^{-(\nu+1)/2}$, densitatea t_ν; c_ν: constanta care face ca integrala ei să fie 1
- **Cerințe**
  1. Derivați $(1 + x^2/\nu)^{-(\nu-1)/2}$.
  2. Deduceți $\int_{-\infty}^{t} x g_\nu(x)\,dx = -g_\nu(t)\frac{\nu+t^2}{\nu-1}$ și precizați unde este nevoie de $\nu > 1$.
- **Raportați**: demonstrația în două rînduri

Rezolvare

- **1.** $\frac{d}{dx}(1 + x^2/\nu)^{-(\nu-1)/2} = -\frac{\nu-1}{\nu}\, x\,(1 + x^2/\nu)^{-(\nu+1)/2}$, deci $x g_\nu(x) = -\frac{\nu c_\nu}{\nu-1}\frac{d}{dx}(1 + x^2/\nu)^{-(\nu-1)/2}$
- **2.** Integrînd de la $-\infty$ la t: $-\frac{\nu}{\nu-1} g_\nu(t)(1 + t^2/\nu) = -g_\nu(t)\frac{\nu+t^2}{\nu-1}$; termenul de la $-\infty$ se anulează doar dacă $\nu > 1$
- ES cere $\nu > 1$; pentru o dispersie finită este necesar $\nu > 2$

Înapoi Lista exercițiilor

A4 extins [Propus]: nivelurile la care VaR nu este subaditiv — cerința

- **Întrebare**: pentru ce probabilități ale cozii α nu este VaR subaditiv în A4?
- **Date**: obligațiunile din A4, $p = 0{,}7\%$, și definiția VaR din secțiunea „VaR și ES"
- **Cerințe**
  1. Scrieți $\mathrm{VaR}_\alpha(A)$ și $\mathrm{VaR}_\alpha(A+B)$ ca funcții în trepte de α.
  2. Găsiți intervalul lui α în care $\mathrm{VaR}_\alpha(A+B) > 2\mathrm{VaR}_\alpha(A)$ și explicați ambele capete.
- **Raportați**: intervalul și cîte o frază pentru fiecare capăt
- **Repere și exemple**: A4

◂ Înapoi ▸ Lista exercițiilor

A6 [Propus]: validitatea transformării Cornish–Fisher ca funcție cuantilă — cerința

- **Întrebare**: pentru ce exces de kurtosis mai este transformarea Cornish–Fisher o funcție cuantilă?
- **Date**
  - $\mu = 0$, $\sigma = 1{,}2\%$, asimetria $S = -0{,}5$, excesul de kurtosis K Cornish & Fisher (1938)
  - Transformarea Cornish–Fisher $\tilde{z}(z)$ din secțiunea „Dezvoltarea Cornish–Fisher (CF)"; $\mathrm{VaR}_\alpha = -\sigma\tilde{z}(z_\alpha)$
- **Cerințe**
  1. Cu $K = 3$, calculați cei trei termeni de corecție în $z_{1\%}$, $\tilde{z}_{1\%}$ și VaR 1% Cornish–Fisher.
  2. Scrieți $d\tilde{z}/dz = Az^2 + Bz + C$ și găsiți vîrful acestei parabole.
  3. Găsiți cel mai mare K pentru care $\tilde{z}$ este crescătoare pe $[z_{0,1\%}, 0]$ și decideți dacă $K = 10$ este admisibil.
- **Raportați**: VaR, limita pentru K și un grafic al lui $\tilde{z}$ și $d\tilde{z}/dz$ pentru $K = 3$ și $K = 10$
- **Interpretare**: garantează o transformare cuantilă validă și un VaR precis?
- **Repere și exemple**: A1

înapoi Lista exercițiilor

A7 [Propus]: ES ca minim și subaditivitatea — cerința

- **Întrebare**: de ce nu poate ES recompensa niciodată divizarea unui portofoliu?
- **Date**
  - Pierdere integrabilă L; funcția obiectiv $G_\alpha(v)$ Rockafellar & Uryasev (2000) din secțiunea „ES ca minim"
  - Cifre: portofoliul din A4 (două obligațiuni, $p = 0{,}7\%$) la $\alpha = 1\%$
- **Cerințe**
  1. Pentru portofoliul din A4, calculați pantele lui G pe $(0, 100)$ și $(100, 200)$, punctul de minim și minimul.
  2. Arătați că derivata la dreapta a lui G este $1 - P(L > v)/\alpha$ și deduceți că VaR_α minimizează G, cu minimul ES_α.
  3. Deduceți $\mathrm{ES}_\alpha(L_1 + L_2) \leq \mathrm{ES}_\alpha(L_1) + \mathrm{ES}_\alpha(L_2)$ din $(a + b)_+ \leq a_+ + b_+$.
- **Raportați**: cele trei cifre de la pasul 1 și două demonstrații scurte
- **Repere și exemple**: A3, A4

◂ Înapoi ▸ Lista exercițiilor

A5 extins [Rezolvat]: contribuțiile la ES din minim — cerința și rezolvarea

- **Întrebare**: de ce sînt contribuțiile istorice la ES din B5 medii pe zilele din coadă?
- **Date**: $\mathrm{ES}_\alpha(w) = \min_v G(w, v)$, $G(w, v) = v + \mathbb{E}[(L_p - v)_+]/\alpha$, $L_p = -w^\top R$ (A7)
- **Cerințe**
  1. Folosiți argumentul înfășurătoarei în $v^* = \mathrm{VaR}_\alpha$ pentru a calcula $\partial \mathrm{ES}_\alpha / \partial w_i$.
  2. Arătați că $w_i\, \partial \mathrm{ES}_\alpha / \partial w_i = \mathbb{E}[-w_i R_i \mid L_p \geq \mathrm{VaR}_\alpha]$ pentru L_p continuu.
- **Raportați**: o demonstrație scurtă
- **Repere și exemple**: A7

Rezolvare

- $\partial G / \partial v = 0$ în v^*, deci $\partial \mathrm{ES}_\alpha / \partial w_i = \partial G / \partial w_i (w, v^*) = \mathbb{E}[-R_i 1\{L_p > v^*\}]/\alpha$
- Pentru L_p continuu, $P(L_p > v^*) = \alpha$: aceasta este $\mathbb{E}[-R_i \mid L_p \geq \mathrm{VaR}_\alpha]$; suma lui $w_i \times$ ea dă ES_α (Euler)
- Estimarea istorică: media lui $-w_i R_i$ pe zilele din coadă (B5); sub distribuția Normală este egală cu rescalarea VaR din A5

◂ Înapoi ▸ Lista exercițiilor

A8 [Propus]: dispersia de selecție a ES istoric — cerința

- **Întrebare**: cît de imprecis este un ES 2,5% istoric pe 500 de zile, chiar pentru pierderi Normale?
- **Date**
  - n pierderi i.i.d., continue, densitate pozitivă în VaR_α, $\mathbb{E}[L^2] < \infty$; $Y = (L - \mathrm{VaR}_\alpha)_+$, excesul pierderii peste VaR (0 sub el)
  - Funcția de influență IF Chen (2008) și $\mathrm{Var}(\widehat{\mathrm{ES}}_\alpha) \approx \mathrm{Var}(\mathrm{IF}(L))/n$ din secțiunea „Precizia ES"
- **Cerințe**
  1. Arătați că $\mathrm{Var}(\mathrm{IF}(L)) = \mathrm{Var}(Y)/\alpha^2$ și explicați, cu A7, de ce estimarea VaR nu adaugă niciun termen de ordinul întîi.
  2. Pentru $L \sim N(0,1)$, $\alpha = 2{,}5\%$, integrați, cu $v = \mathrm{VaR}_\alpha = -z_\alpha$, $\mathbb{E}[Y] = \int_v^\infty (x - v)\varphi(x)\,dx$ și $\mathbb{E}[Y^2]$ în formă închisă.
  3. Calculați SE a lui $\widehat{\mathrm{ES}}_{2{,}5\%}$ pentru $n = 500$ și $\sigma = 1{,}2\%$ și verificați-o cu 4 000 de selecții independente (NumPy default_rng(42)); folosiți interpolarea liniară a cuantilei, media pierderilor cel puțin egale cu ea și ddof=1 pentru abaterea standard simulată.
- **Raportați**: cele două momente, SE în pp și abaterea standard simulată
- **Interpretare**: de ce este valoarea pentru S&P 500 (B2) mult mai mare?
- **Repere și exemple**: A1, A7

◂ Înapoi ▸ Lista exercițiilor

B1 extins [Rezolvat]: intervale asimptotice și HAC pentru VaR — cerința

- **Întrebare**: coincid formulele asimptotice cu bootstrap-ul din B1?
- **Date**
  - Pierderile BET din B1; erorile standard i.i.d. și HAC din secțiunea „Precizia VaR" (densitatea nucleu $\hat{f}$, lagul Newey–West $\lfloor 4(n/100)^{2/9} \rfloor$)
- **Cerințe**
  1. Reperul Normal (din A1): cu $f(\mathrm{VaR}_{1\%}) = \varphi(z_{1\%})/1{,}2$, calculați SE pentru $n = 500$ și $n = 6\,670$.
  2. Pentru BET, calculați $\hat{f}$, SE i.i.d. și HAC și cele două intervale de 95% pe ambele selecții.
- **Raportați**: cele patru intervale pentru VaR 1% lîngă cele două intervale bootstrap din B1
- **Interpretare**: de ce sînt intervalele BET mai largi decît reperul Normal?

Înapoi Lista exercițiilor

B1 extins [Rezolvat]: rezolvare — intervale asimptotice și HAC pentru VaR

- **1.** $f = 0{,}0267/1{,}2 = 0{,}0222$: SE 0,20 pp ($n = 500$, lățime 0,79), 0,055 pp ($n = 6\,670$, lățime 0,22)
- **2.** BET complet: $\hat{f} = 0{,}0076$, SE 0,16 (i.i.d.), 0,23 (HAC); intervale $[3{,}81; 4{,}44]$, $[3{,}69; 4{,}57]$
- Ultimele 500 de zile: $\hat{f} = 0{,}0163$, SE 0,27 și 0,27
- Interpretare: coada BET este mai grea decît cea Normală, deci densitatea în VaR este mai mică și cuantila mai puțin precisă; HAC și blocurile confirmă că volatility clustering lărgește intervalul pe întreaga selecție
- Graficul celor patru intervale pentru fiecare selecție: B1, rezolvare — intervale

MFM_ch7_seminar

B3 extins [Propus]: un interval bootstrap pentru VaR FHS de mîine — cerința

- **Întrebare**: cît de incert este VaR filtrat din B3?
- **Date**: modelul și datele din B3; bootstrap pe reziduuri Christoffersen & Gonçalves (2005) cu 999 de traiectorii, sămînța 42, funcția `fhs_bootstrap` din Quantlet-ul seminarului
- **Cerințe**
  1. Pentru fiecare traiectorie, simulați o serie AR(1)-GARCH(1,1) de lungimea selecției cu $\hat{z}$ reeșantionate și re-estimați $\theta^* = (c^*, \phi^*, \omega^*, \alpha_1^*, \beta_1^*)$.
  2. Calculați μ_{t+1}^* și σ_{t+1}^* trecînd randamentele Bitcoin **originale** prin θ^* și $\hat{\xi}_{1\%}^*$ din reziduurile traiectoriei.
  3. Raportați intervalul percentil de 90% al lui $\mathrm{VaR}^* = -\mu_{t+1}^* + \sigma_{t+1}^* \hat{\xi}_{1\%}^*$ și intervalele celor două surse.
- **Raportați**: histograma celor 999 de prognoze cu intervalul
- **Interpretare**
  - include intervalul VaR istoric pe 500 de zile?
  - este aceasta un test?
- **Repere și exemple**: B3

Înapoi Lista exercițiilor

B6 [Propus]: Cornish–Fisher față de cuantilele empirice — cerința

- **Întrebare**: corectează dezvoltarea Cornish–Fisher VaR Normal pe date reale?
- **Date**
  - BET (obligatoriu): datele din B1; extindere: S&P 500, Bitcoin și aur (închideri zilnice, zile lucrătoare pentru aur) și cursul de referință BNR EUR/RON (2005–2026), toate pînă la 18 septembrie 2026
  - Momentele randamentelor X: media, abaterea standard cu `ddof=1`, `scipy.stats.skew` și `scipy.stats.kurtosis` (exces, deplasat)
- **Cerințe**
  1. Calculați S și K pentru BET.
  2. Calculați VaR 1% și VaR 2,5% prin distribuția Normală, Cornish–Fisher (A6) și simularea istorică.
  3. Construiți intervale bootstrap i.i.d. de 95% (1 000 de reeșantionări) pentru cele două VaR istorice și verificați dacă valorile Cornish–Fisher cad în interior.
  4. Separat, verificați dacă K depășește limita de monotonie din A6.
- **Raportați**: un tabel mic pe activ și un grafic cu cele trei metode și intervalele bootstrap
- **Interpretare**: la ce nivel al cozii se apropie Cornish–Fisher mai mult de reperul istoric? Se păstrează concluzia pentru fiecare activ?
- **Repere și exemple**: A1, A6, B1

◂ Înapoi ▸ Lista exercițiilor

B5 extins [Propus]: ponderi de paritate a riscului — cerința

- **Întrebare**: ce ponderi nenegative, cu investiție integrală, dau fiecărui activ din B5 aceeași cotă din VaR Normal?
- **Date**: randamentele și covarianța Σ din B5
- **Cerințe**
  1. Rezolvați numeric $w_i(\Sigma w)_i = w_j(\Sigma w)_j$ pentru toți i, j, cu $w \geq 0$ și $\sum_i w_i = 1$.
  2. Comparați cu ponderile invers proporționale cu volatilitatea, $w_i \propto 1/\sigma_i$.
  3. La ponderile de paritate a riscului, calculați VaR 1% Normal, ES 2,5% istoric și cotele ES.
- **Raportați**: ponderile, VaR, ES și cotele
- **Interpretare**: implică cotele egale din VaR cote egale din ES?
- **Repere și exemple**: B5

◂ Înapoi ▸ Lista exercițiilor

B4 extins [Rezolvat]: depășiri grupate și indicele extremal — cerința

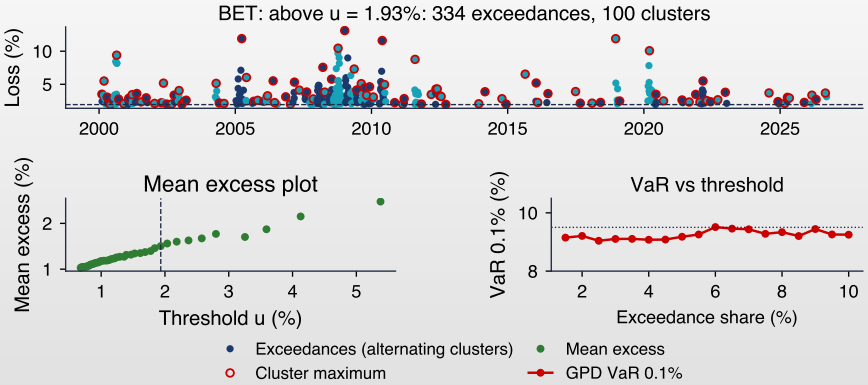
- **Întrebare**: cîte informații independente despre coadă conțin cele 334 de depășiri BET din B4?
- **Date**
  - Momentele de depășire $S_{\mathbf{1}} < \cdots < S_N$ ale lui u (B4), intervalele $T_i = S_{i+\mathbf{1}} - S_i$
  - Estimatorul pe intervale $\hat{\theta}$ Ferro & Segers (2003) din secțiunea „Depășiri grupate: indicele extremal"
- **Cerințe**
  1. Calculați $\hat{\theta}$ cu precizia completă (rotunjiți doar valoarea afișată) și numărul țintă de grupuri $C = \lfloor \hat{\theta} N \rfloor + 1$.
  2. Împărțiți depășirile la cele mai mari $C - 1$ intervale; dacă al $(C-1)$-lea și al C-lea cel mai mare interval sînt egale, reduceți C pînă cînd diferă.
  3. Estimați GPD pe maximele grupurilor și comparați $\hat{\xi}/\mathrm{SE}$ cu B4.
- **Raportați**: $\hat{\theta}$, numărul de grupuri, estimarea pe maximele grupurilor și un grafic cronologic
- **Interpretare**: este credibilă SE i.i.d. din B4?

◂ Înapoi ▸ Lista exercițiilor

B4 extins [Rezolvat]: rezolvare — depășiri grupate și indicele extremal (1/2)

- **1.** $\hat{\theta} = 0{,}32$, $C = 108$
- **2.** Egalitate la pragul de separare ($T = 12$ zile): 100 de grupuri de cîte 3,3 depășiri în medie; cel mai mare grup 33, 47 depășiri izolate
- **3.** $\hat{\xi} = 0{,}269$ (SE 0,127) față de 0,209 (SE 0,066); $\hat{\xi}/\mathrm{SE}$ scade de la 3,2 la 2,1; la pragul VaR 1% $\hat{\theta} = 0{,}40$
- Interpretare: coada rămîne grea, dar SE i.i.d. nu este credibilă; raportăm estimarea pe maximele grupurilor sau filtrăm întîi cu GARCH (EVT condiționată)

B4 extins [Rezolvat]: rezolvare — depășiri grupate și indicele extremal (2/2)



MFM_ch7_seminar

B7 [Propus]: CAViaR pentru BET — cerința

- **Întrebare**: oferă modelarea directă a cuantilei BET prognoze mai bune decît simularea filtrată și cea istorică în afara eșantionului?
- **Date**
  - Randamentele BET din B1 ($n = 6\,670$)
  - CAViaR SAV Engle & Manganelli (2004) și pierderea pinball din secțiunea „Regresia cuantilă, pierderea pinball și CAViaR"; $\mathrm{VaR}_{\mathbf{1}} = -\hat{q}_{\mathbf{1\%}}$ din primele 300 de randamente; funcțiile `caviar_path`, `caviar_fit` (Quantlet-ul seminarului): $10^{\mathbf{4}}$ puncte de start în $(0, 1)^{\mathbf{3}}$, sămînța 42, cele mai bune 10 rafinate
- **Cerințe**
  1. Estimați β pe 2000–2015 prin minimizarea sumei pierderilor pinball la $\alpha = 1\%$.
  2. Calculați pas cu pas un termen al pierderii pinball pentru prima zi din afara eșantionului și verificați că prognoza pentru ziua t folosește doar $r_{t-\mathbf{1}}$.
  3. Cu β fixat, prognozați VaR pentru 2016–2026 și comparați depășirile și pierderea pinball medie cu FHS (re-estimat în fiecare ianuarie) și HS pe 500 de zile.
  4. Pentru 20 februarie – 30 aprilie 2020 numărați depășirile și raportați VaR maxim al fiecărei metode.
- **Raportați**: estimările, un tabel de comparație și un grafic cu detaliu pe COVID-19
- **Interpretare**: poate fi atribuită diferența tipului de model cînd CAViaR este estimat o dată, iar FHS în fiecare an?
- **Repere și exemple**: B3; cursul, CAViaR pentru S&P 500

◂ Înapoi ▸ Lista exercițiilor

C2 [Deschis]: capitalul ES, BVB față de S&P 500 — cerința (1/2)

- **Întrebare**: care portofoliu cere mai mult capital ES pe unitatea investită: acțiunile blue-chip de la București sau S&P 500?
- **Date**
  - Coșul BVB: Banca Transilvania, OMV Petrom, BRD–Groupe Société Générale, Transgaz, Romgaz, Nuclearelectrica, Electrica, Transelectrica (închideri ajustate), ponderi egale, rebalansare zilnică; păstrați datele comune cu prețuri observate și randamentele individuale zero; eliminați zilele în care toate cele opt randamente sînt zero
  - Portofoliul S&P 500: SPY, ETF-ul pe S&P 500 (închideri ajustate); ambele de la 2016-09-20 pînă la 18 septembrie 2026; randamente simple zilnice R_t în %, în moneda locală
- **Cerințe**
  1. Construcție: calculați ES 2,5% istoric pe o zi al fiecărui portofoliu (pierderea $-R_t$) și numărul de observații din coadă.
  2. Orizontul: calculați ES 2,5% pe 10 zile prin scalare cu $\sqrt{10}$, din pierderi compuse suprapuse $100[1 - \prod_{i=1}^{10}(1 + R_{t+i}/100)]$ și prin Monte Carlo filtrat (AR(1)-GARCH(1,1) pe randamente log, starea de azi, 100 000 de traiectorii, sămînța 42, fiecare traiectorie convertită într-o pierdere simplă).
- **Raportați**: continuarea pe slide-ul următor
- **Repere și exemple**: B1, B3; cursul, secțiunile despre orizont și Basel

◂ Înapoi ▸ Lista exercițiilor

C2 [Deschis]: capitalul ES, BVB față de S&P 500 — cerința (2/2)

- **Cerințe (continuare)**

3. Stres: găsiți cele 250 de zile consecutive cu cel mai mare ES 2,5% istoric pe o zi, reprezentați ES pe fereastră mobilă cu fereastra hașurată și raportați ES de stres pe o zi și, prin $\sqrt{10}$, pe 10 zile.
4. Capital: capitalul la 1 000 000 investit $= 1\,000\,000 \times 1{,}5 \times \mathrm{ES}_{\mathbf{10}}^{stres}$ (%)/100 (1,5: multiplicatorul FRTB m_c; $\mathrm{ES}_{\mathbf{10}}^{stres}$: ES de stres pe 10 zile), pentru un orizont de lichiditate de 10 și de 20 de zile (încă un factor $\sqrt{2}$); sumele în RON pentru BVB și în USD pentru SPY, rapoartele sînt comparabile.
5. Incertitudine: intervale bootstrap de 95% pe blocuri mobile (blocuri de 20 de zile, 2 000 de reeșantionări) pentru ES pe o zi și pentru ES de stres, cu fereastra ținută fixă.

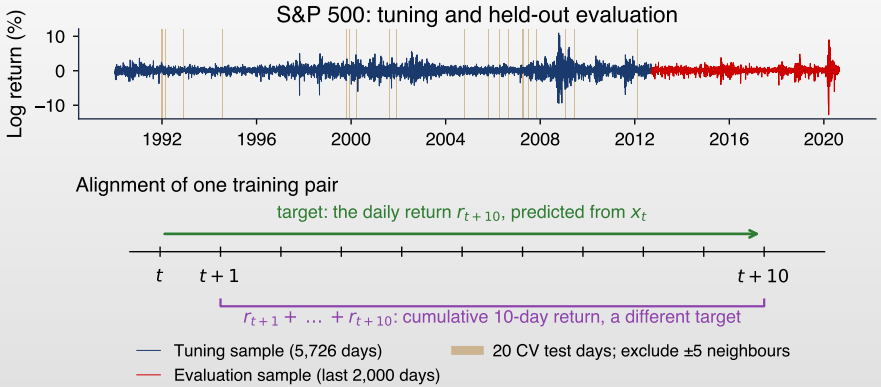
- **Raportați**: un tabel cu toate cifrele și intervalele și o argumentație de o pagină
  - care portofoliu cere mai mult capital?
  - cum schimbă răspunsul tranzacționarea rară și moneda?
- O ilustrare simplificată inspirată de FRTB Basel Committee (2019), nu calculul complet al capitalului din Basel Committee, MAR33

C3 [Deschis]: VaR prin regresie cuantilă cu rețele neuronale — cerința (1/2), versiunea minimă

- **Întrebare**: oferă o rețea neuronală mică prognoze mai bune decît regresia cuantilă liniară pentru VaR 1% al S&P 500, ca în studiul de caz din curs Chronopoulos, Raftapostolos & Kapetanios (2024)?
- **Date**
  - S&P 500, închideri zilnice, 1990-01-03 – 31 august 2020 (articolul începe în 1985); randamente log zilnice nescalate r_t; calibrare: primele 5 726 de zile, evaluare: ultimele 2 000 (de la 2012-09-19)
  - Un singur set de predictori: σ_t GARCH(1,1) (estimat doar pe eșantionul de calibrare); $\alpha = 1\%$
- **Cerințe**
  1. Construiți perechi de antrenare $(x_t, r_{t+\mathbf{10}})$ ale căror ținte se află toate în eșantionul de calibrare, ca în grafic; ținta este randamentul zilnic $r_{t+\mathbf{10}}$, nu randamentul cumulat pe 10 zile.
  2. Estimați o regresie cuantilă liniară și o rețea (un strat ascuns ReLU cu 5 unități, penalizare ridge 0,01, Adam (algoritm de optimizare stocastică cu pas adaptiv), oprire timpurie) prin pierderea pinball; standardizați predictorii doar pe partea de antrenare a fiecărei partiții de validare încrucișată.
  3. Înainte de evaluare, fixați în protocol rata de învățare, batch size, maximul de epoci, validarea cronologică, numărul de epoci fără îmbunătățire permis de early stopping și cele cinci seeds. Comparați pierderile pinball medii pe eșantionul de evaluare cu un test Diebold–Mariano (HAC, 10 laguri) Diebold & Mariano (1995), pentru 5 valori seed.
- **Raportați**: un tabel cu pierderile pinball medii, statisticile DM și numărul de depășiri, pe sămînță

Înapoi Lista exercițiilor

C3 [Deschis]: VaR prin regresie cuantilă cu rețele neuronale — datele



MFM_ch7_seminar

C3 [Deschis]: VaR prin regresie cuantilă cu rețele neuronale — cerința (2/2), extinderi

- **Extinderea de replicare**: cele patru seturi de predictori și grila de validare încrucișată din articol (Anexa cursului); Root Mean Squared Forecast Error (RMSFE) relativ doar pentru a reproduce Tabelul 6, deoarece RMSFE este minimizat de media condiționată, nu de cuantilă
- **Extinderea pe fereastră mobilă**: reestimați o dată pe an, pe fereastră mobilă, și prognozați septembrie 2020 – 2026 pentru S&P 500 și BET
- **Extinderea comună**: două ieșiri (v_t, e_t) antrenate pe pierderea FZ0 Patton, Ziegel & Chen (2019), (v_t: cuantila randamentului, e_t: media cozii, ca în curs) cu $e_t = -\exp(a_t)$ și $v_t = e_t + \exp(b_t)$, a_t, b_t ieșiri nerestricționate ale rețelei, astfel încît $e_t < 0$ și $e_t \leq v_t$
- **Interpretare** (o pagină): poate fi atribuit un cîștig neliniarității cînd arhitectura, penalizarea și calibrarea se schimbă simultan?

Alegerea proiectului și grila comună

Alegeți unul

- C2: comparați capitalul ES pentru coșul BVB și SPY precizate, urmînd toate cele cinci cerințe; un portofoliu suplimentar cu cel puțin trei active este o extensie opțională
- C3: versiunea minimă, apoi o extindere
- Predați un folder Quantlet (cod, `Metainfo.txt`, grafice) și trei slide-uri: cifre, interpretare, limite

Grila

- Reproductibilitate: date încărcate prin cod, valori seed fixe, orice cifră dintr-un script (30%)
- Convenții corecte: semn, nivel, orizont, tipul randamentului (20%)
- Incertitudine: numărul de observații din coadă și intervale pentru orice estimare din coadă (25%)
- Interpretare și limite, inclusiv folosirea AI notată și erorile AI găsite efectiv (25%)

Acronime folosite în acest material (1/2)

- **AI**: Artificial Intelligence — *inteligență artificială*
- **AR**: AutoRegressive (model) — *model autoregresiv*
- **BET**: Bucharest Exchange Trading (index) — *indicele de referință al Bursei de Valori București*
- **BNR**: Banca Națională a României
- **BVB**: Bursa de Valori București
- **CF**: Cornish–Fisher (expansion) — *dezvoltarea Cornish–Fisher*
- **CI**: Confidence Interval — *interval de încredere*
- **COVID-19**: COronaVIrus Disease 2019 — *boala provocată de coronavirus, 2019*
- **DM**: Diebold–Mariano (test) — *testul Diebold–Mariano de comparare a prognozelor*
- **ES**: Expected Shortfall — *pierderea așteptată în coadă*
- **ETF**: Exchange-Traded Fund — *fond tranzacționat la bursă*
- **EVT**: Extreme Value Theory — *teoria valorilor extreme*
- **FHS**: Filtered Historical Simulation — *simulare istorică filtrată*
- **FRTB**: Fundamental Review of the Trading Book — *revizuirea fundamentală a portofoliului de tranzacționare*
- **FZ0**: Fissler–Ziegel loss, zero-homogeneous version — *funcția de pierdere Fissler–Ziegel, varianta omogenă de grad zero*

Acronime folosite în acest material (2/2)

- **GARCH**: Generalised AutoRegressive Conditional Heteroskedasticity — *heteroscedasticitate condiționată autoregresivă generalizată*
- **GPD**: Generalised Pareto Distribution — *distribuția Pareto generalizată*
- **HAC**: Heteroskedasticity and Autocorrelation Consistent (standard errors) — *erori standard robuste la heteroscedasticitate și autocorelație*
- **HS**: Historical Simulation — *simulare istorică*
- **LGD**: Loss Given Default — *pierderea în caz de nerambursare*
- **MAR33**: Basel Framework, chapter MAR33 (internal models approach: capital requirements calculation) — *cadrul Basel, capitolul MAR33 (abordarea pe modele interne: calculul cerințelor de capital)*
- **OMV**: Österreichische Mineralölverwaltung — *Administrația austriacă a uleiurilor minerale (grupul OMV)*
- **QML**: Quasi-Maximum Likelihood — *cvasi-verosimilitate maximă*
- **RMSFE**: Root Mean Squared Forecast Error — *rădăcina erorii pătratice medii de prognoză*
- **SAV**: Symmetric Absolute Value (CAViaR specification) — *specificația CAViaR cu valoare absolută simetrică*
- **SD**: Standard Deviation — *abatere standard*
- **SE**: Standard Error — *eroare standard*
- **SUA**: Statele Unite ale Americii
- **US**: United States — *Statele Unite ale Americii*

Bibliografie (1/2)

- Acerbi, C., Tasche, D. (2002). On the coherence of expected shortfall. *Journal of Banking & Finance*, 26(7), 1487–1503.
- Artzner, P., Delbaen, F., Eber, J.-M., Heath, D. (1999). Coherent measures of risk. *Mathematical Finance*, 9(3), 203–228.
- Barone-Adesi, G., Giannopoulos, K., Vosper, L. (1999). VaR without correlations for portfolios of derivative securities. *Journal of Futures Markets*, 19(5), 583–602.
- Basel Committee on Banking Supervision (2019). Minimum capital requirements for market risk. Bank for International Settlements.
- Chen, S.X. (2008). Nonparametric estimation of expected shortfall. *Journal of Financial Econometrics*, 6(1), 87–107.
- Christoffersen, P., Gonçalves, S. (2005). Estimation risk in financial risk management. *Journal of Risk*, 7(3), 1–28.
- Chronopoulos, I., Raftapostolos, A., Kapetanios, G. (2024). Forecasting Value-at-Risk using deep neural network quantile regression. *Journal of Financial Econometrics*, 22(3), 636–669.
- Cornish, E.A., Fisher, R.A. (1938). Moments and cumulants in the specification of distributions. *Revue de l'Institut International de Statistique*, 5(4), 307–320.
- Diebold, F.X., Mariano, R.S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3), 253–263.
- Efron, B. (1979). Bootstrap methods: another look at the jackknife. *Annals of Statistics*, 7(1), 1–26.
- Engle, R.F., Manganelli, S. (2004). CAViaR: conditional autoregressive value at risk by regression quantiles. *Journal of Business & Economic Statistics*, 22(4), 367–381.
- Ferro, C.A.T., Segers, J. (2003). Inference for clusters of extreme values. *Journal of the Royal Statistical Society: Series B*, 65(2), 545–556.

Bibliografie (2/2)

- Franke, J., Härdle, W.K., Hafner, C.M. (2019). Statistics of Financial Markets: An Introduction, 5th ed. Springer.
- Harvey, D., Leybourne, S., Newbold, P. (1997). Testing the equality of prediction mean squared errors. *International Journal of Forecasting*, 13(2), 281–291.
- Künsch, H.R. (1989). The jackknife and the bootstrap for general stationary observations. *Annals of Statistics*, 17(3), 1217–1241.
- McNeil, A.J., Frey, R. (2000). Estimation of tail-related risk measures for heteroscedastic financial time series: an extreme value approach. *Journal of Empirical Finance*, 7(3–4), 271–300.
- McNeil, A.J., Frey, R., Embrechts, P. (2015). Quantitative Risk Management: Concepts, Techniques and Tools, revised ed. Princeton University Press.
- Patton, A.J., Ziegel, J.F., Chen, R. (2019). Dynamic semiparametric models for expected shortfall (and Value-at-Risk). *Journal of Econometrics*, 211(2), 388–413.
- Pele, D.T., Mazurencu-Marinescu-Pele, M. (2026). Finite-sample precision limits for expected shortfall forecast comparisons. *Mathematics*, 14(13), 2316.
- Rockafellar, R.T., Uryasev, S. (2000). Optimization of conditional value-at-risk. *Journal of Risk*, 2(3), 21–41.
- Tasche, D. (2008). Capital allocation to business units and sub-portfolios: the Euler principle. arXiv:0708.2542.