



Modelarea piețelor financiare

Seminarul 7: VaR și Expected Shortfall — aplicații



Daniel Traian PELE

Drd. Antoaneta Amza, antoaneta.amza@csie.ase.ro

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognostic Economică

MSCA Digital Finance

Acronime folosite în acest material

- AI: Artificial Intelligence (inteligență artificială)
- AR: AutoRegressive (model) (model autoregresiv)
- BET: Bucharest Exchange Trading (index) (indicele de referință al Bursei de Valori București)
- BNR: Banca Națională a României
- BVB: Bursa de Valori București
- CF: Cornish–Fisher (expansion) (dezvoltarea Cornish–Fisher)
- CI: Confidence Interval (interval de încredere)
- COVID-19: COronaVirus Disease 2019 (boala provocată de coronavirus, 2019)
- CV: Cross-Validation (validare încrucișată)
- DM: Diebold–Mariano (test) (testul Diebold–Mariano de comparare a prognozelor)
- ES: Expected Shortfall (pierdere așteptată în coadă)
- EVT: Extreme Value Theory (teoria valorilor extreme)
- FHS: Filtered Historical Simulation (simulare istorică filtrată)
- FRTB: Fundamental Review of the Trading Book (revizuirea fundamentală a portofoliului de tranzacționare)
- FZ0: Fissler–Ziegel loss, zero-homogeneous version (funcția de pierdere Fissler–Ziegel, varianta omogenă de grad zero)
- GARCH: Generalised AutoRegressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă generalizată)
- GPD: Generalised Pareto Distribution (distribuția Pareto generalizată)
- HAC: Heteroskedasticity and Autocorrelation Consistent (standard errors) (erori standard robuste la heteroscedasticitate și autocorelație)
- LGD: Loss Given Default (pierdere în caz de nerambursare)
- OMV: Österreichische Mineralölverwaltung (Administrația austriacă a uleiurilor minerale (grupul OMV))
- QML: Quasi-Maximum Likelihood (cvasi-verosimilitate maximă)
- RMSFE: Root Mean Squared Forecast Error (rădăcina erorii pătratice medii de prognoză)
- SAV: Symmetric Absolute Value (CAViaR specification) (specificația CAViaR cu valoare absolută simetrică)
- SE: Standard Error (eroare standard)
- XFG: Quantlet prefix of Applied Quantitative Finance (Härdle, Chen & Overbeck) (prefixul Quantlet-urilor din Applied Quantitative Finance (Härdle, Chen & Overbeck))

Cuprins

Introducere

Partea A: derivări

Partea B: estimare și inferență

Partea C: întrebări deschise

Încheiere

Bibliografie

Obiectivele seminarului

La finalul seminarului puteți

- ▣ Deriva VaR și ES pentru distribuțiile Normală și Student- t și dispersia de selecție a estimărilor lor istorice
- ▣ Demonstra subaditivitatea ES din reprezentarea Rockafellar–Uryasev
- ▣ Estima VaR/ES istorice, filtrate, din valori extreme și CAViaR cu intervale corecte (HAC, bootstrap pe blocuri și pe reziduuri, declusterizare)
- ▣ Împărți riscul unui portofoliu în contribuții Euler

- ▣ Suport: Cursul 7; manuale McNeil, Frey & Embrechts (2015) și Franke, Härdle & Hafner (2019)

Structura

- ▣ **Partea A:** derivări (A1–A8)
- ▣ **Partea B:** șapte exerciții pe calculator, cu inferență (B1–B7)
- ▣ **Partea C:** două întrebări deschise, puncte de plecare pentru proiectul de echipă (C1, C3), și critica unui răspuns AI (C2)

Cum lucrăm la acest seminar

- ▣ Problemele **[Rezolvat]** au rezolvarea completă; problemele **[Propus]** au doar cerința: rezolvările se discută la seminar
- ▣ Fiecare problemă propusă indică **modelul**: problema rezolvată care folosește aceeași tehnică
 - ▶ Fiecare exercițiu din Partea B se încheie cu întrebări de interpretare
- ▣ Convenția de semn: pierderea $L = -r$, o pierdere logaritmică în % (în % din valoarea poziției: $100(1 - e^{-L/100})$); VaR și ES sunt numere pozitive
- ▣ Raportați orice estimare din coadă împreună cu incertitudinea ei: câte observații se află dincolo de ea?

Probleme rezolvate și propuse

Rezolvate: exemple lucrate în acest material

- ▣ Partea A: A1 (derivarea ES Normal, SE a VaR istoric), A2 (derivarea ES Student- t), A3 (o pierdere discretă), A5 (VaR pe componente; (d) contribuții la ES)
- ▣ Partea B: B1 (VaR și ES istorice pentru BET; intervale bootstrap, asimptotice și HAC), B2 (estimarea GPD pe BET; indicele extremal)

Propuse: le rezolvați voi

- ▣ Partea A: A4 (încălcarea subaditivității; model: A3), A6 (validitatea Cornish–Fisher; model: A1), A7 (ES ca minim; model: A3, A4), A8 (dispersia ES istoric; model: A1)
- ▣ Partea B: B3 (filtrată vs istorică pe Bitcoin; model: B1), B4 (Cornish–Fisher vs empiric; model: A1, B1), B5 (VaR pe componente pentru un portofoliu; model: A5), B6 (interval bootstrap pentru ES; model: B1), B7 (CAViaR pentru BET; model: B3)
- ▣ Partea C: C1, întrebare deschisă și punct de plecare pentru proiect; C2, critica unui răspuns AI (model: B1); C3, regresie cuantilă cu rețele neuronale adânci pentru VaR, punct de plecare pentru proiect din studiul de caz al cursului

Pregătire: mediul Python și datele

- ▣  **Deschide în Colab:** `capitol7_notebook_seminar.ipynb`
- ▣ Google Colab (recomandat) sau Python local ≥ 3.10 cu `numpy`, `pandas`, `scipy`, `arch`, `matplotlib`
- ▣ Serii: BET (2000–2026), S&P 500, Bitcoin (2014–2026), EUR/RON (cursul de referință BNR), aur; SPY, TLT, GLD; opt acțiuni blue-chip de la BVB; închideri zilnice până la 18 septembrie 2026
- ▣ Indici bursieri: doar zilele lucrătoare; eliminăm înregistrările de sărbătoare (închidere neschimbată, volum zero), păstrăm închiderile neschimbate reale ca randamente zero; crypto păstrează toate cele 7 zile ale săptămânii
- ▣ Portofolii: întâi îmbinăm prețurile în zilele comune de tranzacționare, apoi calculăm randamentele simple

Formulele folosite azi

- ▣ Nivelul α = probabilitatea cozii (VaR 1%, ES 2,5%); randamentul X , pierderea $L = -X$:

$$\text{VaR}_\alpha(X) = -\inf\{x : P(X \leq x) > \alpha\} = -q_\alpha(X), \text{ES}_\alpha(X) = -\frac{1}{\alpha} \int_0^\alpha q_u(X) du$$
- ▣ Cazul discret [Acerbi & Tasche \(2002\)](#): $\text{ES}_\alpha = \frac{1}{\alpha} (\mathbb{E}[L1\{L > \text{VaR}_\alpha\}] + \text{VaR}_\alpha(\alpha - P(L > \text{VaR}_\alpha)))$
- ▣ Distribuția Normală, $z_\alpha = \Phi^{-1}(\alpha) < 0$: $\text{VaR}_\alpha = -(\mu + \sigma z_\alpha)$, $\text{ES}_\alpha = -\mu + \sigma \varphi(z_\alpha)/\alpha$
- ▣ Student- t : $\text{VaR}_\alpha = -(m + s t_\alpha)$, $\text{ES}_\alpha = -m + s \frac{s\nu(t_\alpha)}{\alpha} \frac{\nu+t_\alpha^2}{\nu-1}$; dispersia σ^2 când $s = \sigma\sqrt{(\nu-2)/\nu}$
- ▣ Coadă GPD a pierderilor: $\text{VaR}_\alpha = u + \frac{\beta}{\xi} \left[\left(\frac{n}{N_u} \alpha \right)^{-\xi} - 1 \right]$, $\text{ES}_\alpha = \frac{\text{VaR}_\alpha + \beta - \xi u}{1-\xi}$ ($\alpha < N_u/n$; ES cere $\xi < 1$)
- ▣ Euler: $C_i = w_i \partial \text{VaR} / \partial w_i = \mathbf{z}_{1-\alpha} w_i (\Sigma w)_i / \sigma_p$, $\sum_i C_i = \text{VaR}$ [Tasche \(2008\)](#)

A1: VaR și ES pentru distribuția Normală [Rezolvat]: Cerință

□ Date și ipoteze

- ▶ Randamentele zilnice ale unei poziții sunt Normale, $X \sim N(\mu, \sigma^2)$, cu $\mu = 0,04\%$ și $\sigma = 1,2\%$; pierderea este $L = -X$.
- ▶ Notăm $z_\alpha = \Phi^{-1}(\alpha) < 0$, iar Φ , φ sunt funcția de repartiție și densitatea distribuției Normale standard.

□ Cerințe

- ▶ (a) Derivați $ES_\alpha = -\mu + \sigma\varphi(z_\alpha)/\alpha$ pornind de la definiția $ES_\alpha = -\mathbb{E}[X \mid X \leq q_\alpha(X)]$.
- ▶ (b) Calculați VaR și ES la $\alpha = 1\%$ și la $\alpha = 2,5\%$, în % din poziție.
- ▶ (c) Calculați eroarea standard asimptotică a VaR 1% istoric, $SE = \sqrt{\alpha(1-\alpha)/n} / f(\text{VaR}_\alpha)$, pentru $n = 500$ și pentru $n = 6\,670$ de zile, și lățimea intervalului de 95%.

□ Raportați

- ▶ Cele patru valori de la (b), cele două erori standard de la (c) și o comparație cu lățimile intervalelor bootstrap din B1: de ce sunt intervalele din B1 mai largi?

A1: VaR și ES pentru distribuția Normală [Rezolvat]: Rezolvare (1/2)

- (a) **Derivare.** Scriem $X = \mu + \sigma Z$; evenimentul $X \leq q_\alpha$ este $Z \leq z_\alpha$, de probabilitate α .
 - Deoarece $\varphi'(u) = -u\varphi(u)$, obținem $\int_{-\infty}^z u\varphi(u) du = [-\varphi(u)]_{-\infty}^z = -\varphi(z)$.
 - Deci $\mathbb{E}[X \mid X \leq q_\alpha] = \mu + \frac{\sigma}{\alpha} \int_{-\infty}^{z_\alpha} u\varphi(u) du = \mu - \sigma \frac{\varphi(z_\alpha)}{\alpha}$, iar schimbarea semnului dă formula.
- (b) **Cifrele la 1%.** Cuantila este $z_{1\%} = -2,326$, iar densitatea în ea este $\varphi(z_{1\%}) = 0,0267$, deci $\varphi/\alpha = 2,665$.
 - $\text{VaR}_{1\%} = -(0,04 + 1,2 \cdot (-2,326)) = 2,75\%$ și $\text{ES}_{1\%} = -0,04 + 1,2 \cdot 2,665 = 3,16\%$.
- (b) **Cifrele la 2,5%.** Aici $z_{2,5\%} = -1,960$ și $\varphi/\alpha = 2,338$.
 - $\text{VaR}_{2,5\%} = 2,31\%$ și $\text{ES}_{2,5\%} = -0,04 + 1,2 \cdot 2,338 = 2,77\%$.
 - Interpretare: ES 2,5% (2,77%) este aproape egal cu VaR 1% (2,75%); această egalitate aproximativă în cazul distribuției Normale explică alegerea ES 2,5% în FRTB.

A1: VaR și ES pentru distribuția Normală [Rezolvat]: Rezolvare (2/2)

- **(c) Densitatea în cuantilă.** Densitatea pierderii în VaR 1% este $f(\text{VaR}_{1\%}) = \varphi(z_{1\%})/\sigma = 0,0267/1,2 = 0,0222$.
 - ▶ $n = 500$: $\text{SE} = \sqrt{0,01 \cdot 0,99/500} / 0,0222 = 0,20$ puncte procentuale, deci intervalul de 95% are o lățime de 0,79 puncte.
 - ▶ $n = 6\,670$: $\text{SE} = 0,055$, iar lățimea de 95% este 0,22 puncte.
- **Comparație cu B1.** Intervalele bootstrap pentru VaR 1% BET au 1,01 puncte (500 de zile) și 0,61 puncte (întreaga selecție).
 - ▶ Interpretare: pierderile BET au o coadă mai grea decât distribuția Normală, deci densitatea în VaR este mai mică și cuantila este estimată mai puțin precis.
 - ▶ Eroarea standard scade ca $1/\sqrt{n}$: de treisprezece ori mai multe date fac intervalul de circa $\sqrt{13,3} \approx 3,7$ ori mai îngust.

A2: ES Student- t [Rezolvat]: Cerință

□ Date și ipoteze

- ▶ Randamentele sunt $X = m + sT$, unde T urmează distribuția Student- t cu ν grade de libertate și densitatea $g_\nu(x) = c_\nu(1 + x^2/\nu)^{-(\nu+1)/2}$.
- ▶ Cuantila este $t_\alpha = t_\nu^{-1}(\alpha) < 0$; pentru cifre folosiți $\nu = 4$, $m = 0,04\%$ și aceeași abatere standard de 1,2% ca în A1.

□ Cerințe

- ▶ (a) Arătați că $\int_{-\infty}^t x g_\nu(x) dx = -g_\nu(t) \frac{\nu + t^2}{\nu - 1}$ pentru $\nu > 1$ și deduceți $ES_\alpha = -m + s \frac{g_\nu(t_\alpha)}{\alpha} \frac{\nu + t_\alpha^2}{\nu - 1}$.
- ▶ (b) Găsiți scala s care dă o abatere standard de 1,2%, folosind $\text{Var}(T) = \nu/(\nu - 2)$.
- ▶ (c) Calculați VaR și ES la $\alpha = 1\%$ și $\alpha = 2,5\%$.

□ Raportați

- ▶ Cele patru valori de la (c) alături de cele din A1; întrebare de interpretare: la ce nivel diferă cel mai mult cele două modele și de ce?

A2: ES Student- t [Rezolvat]: Rezolvare

- (a) **Primitiva.** Derivăm $(1 + x^2/\nu)^{-(\nu-1)/2}$: rezultatul este $-\frac{\nu-1}{\nu} \times (1 + x^2/\nu)^{-(\nu+1)/2}$.
- Prin urmare $xg_\nu(x) = -\frac{\nu c_\nu}{\nu-1} \frac{d}{dx} (1 + x^2/\nu)^{-(\nu-1)/2}$, iar integrarea de la $-\infty$ la t dă $-\frac{\nu}{\nu-1} g_\nu(t)(1 + t^2/\nu)$.
- Aceasta este $-g_\nu(t)(\nu + t^2)/(\nu-1)$; limita la $-\infty$ este zero doar dacă $\nu > 1$. Împărțim la α și rescalăm prin $m + sT$ ca în A1.
- (b) **Scala.** $s^2\nu/(\nu-2) = 1,2^2$, deci $s = 1,2\sqrt{2/4} = 0,849$.
- (c) **La 1%.** $t_{1\%} = -3,747$ și $g_4(t_{1\%}) = 0,0087$, deci factorul ES este $\frac{0,0087}{0,01} \cdot \frac{4 + 14,04}{3} = 5,221$.
- $\text{VaR}_{1\%} = -(0,04 + 0,849 \cdot (-3,747)) = 3,14\%$ și $\text{ES}_{1\%} = -0,04 + 0,849 \cdot 5,221 = 4,39\%$.
- (c) **La 2,5%.** $t_{2,5\%} = -2,776$ dă $\text{VaR}_{2,5\%} = 2,32\%$ și $\text{ES}_{2,5\%} = 3,35\%$.
- Interpretare: VaR 2,5% este aproape același în ambele modele (2,32 vs 2,31), în timp ce VaR 1% și ambele ES sunt mult mai mari sub t_4 : cozile grele apar doar adânc în coadă, iar ES le vede primul.

A3: VaR și ES pentru o pierdere discretă [Rezolvat]: Cerință

□ Date și ipoteze

- ▶ O obligațiune pierde 60 (pierderea în caz de neplată, LGD) cu probabilitatea $p = 3\%$ și 0 altfel, deci randamentul este $X = -60$ sau $X = 0$.
- ▶ Folosiți definițiile generale $\text{VaR}_\alpha = -\inf\{x : P(X \leq x) > \alpha\}$ și formula ES discretă din curs [Acerbi & Tasche \(2002\)](#).

□ Cerințe

- ▶ (a) Calculați VaR 5% și VaR 2,5% direct din definiție.
- ▶ (b) Calculați ES 5% și ES 2,5% cu $\text{ES}_\alpha = \frac{1}{\alpha} (\mathbb{E}[L1\{L > \text{VaR}_\alpha\}] + \text{VaR}_\alpha(\alpha - P(L > \text{VaR}_\alpha)))$.
- ▶ (c) Explicați de ce $\text{ES}_{5\%}$ nu este egal cu $\mathbb{E}[L \mid L \geq \text{VaR}_{5\%}]$.

□ Raportați

- ▶ Cele patru cifre și un răspuns de o frază la (c).

A3: VaR și ES pentru o pierdere discretă [Rezolvat]: Rezolvare

- (a) **VaR 5%.** $P(X \leq -60) = 3\%$ nu este peste 5%, iar $P(X \leq 0) = 100\% > 5\%$; deci $q_{5\%} = 0$ și $\text{VaR}_{5\%} = 0$.
 - VaR 2,5%: $P(X \leq -60) = 3\% > 2,5\%$, deci $q_{2,5\%} = -60$ și $\text{VaR}_{2,5\%} = 60$.
- (b) **ES 5%.** $\mathbb{E}[L1\{L > 0\}] = 60 \cdot 0,03 = 1,8$ și $P(L > 0) = 3\%$, deci $\text{ES}_{5\%} = \frac{1,8 + 0 \cdot (0,05 - 0,03)}{0,05} = 36$.
 - ES 2,5%: nimic nu se află peste 60, deci $\text{ES}_{2,5\%} = \frac{0 + 60 \cdot (0,025 - 0)}{0,025} = 60$.
- (c) **De ce termenul de corecție.** $\mathbb{E}[L \mid L \geq 0] = 1,8$ face media pe **toate** zilele, nu pe cele mai rele 5%.
 - Interpretare: cu atomi, cele mai rele 5% dintre rezultate sunt masa de 3% a neplății plus 2% din masa pierderii zero; formula le ponderează exact, iar ES este atunci 36.

A4: când VaR penalizează diversificarea [Propus]: Cerință

Rezolvarea se discută la seminar

□ Date și ipoteze

- ▶ Două obligațiuni independente A și B; fiecare pierde 100 cu probabilitatea $p = 0,7\%$ și 0 altfel [Artzner et al. \(1999\)](#). Portofoliul este $A + B$.

□ Cerințe

- ▶ (a) Scrieți distribuția pierderii portofoliului (valorile 0, 100, 200 și probabilitățile lor).
- ▶ (b) Calculați VaR 1% și ES 1% pentru o obligațiune și pentru portofoliu, cu formula discretă din A3.
- ▶ (c) Arătați că VaR 1% nu este subaditiv aici, iar ES 1% este.
- ▶ (d) Repetați (b)–(c) la $\alpha = 1,5\%$ și găsiți intervalul lui α pentru care VaR eșuează.

□ Raportați

- ▶ Un tabel mic cu VaR și ES pentru A, B și $A + B$ la ambele niveluri și o frază despre ce ar recompensa o limită bazată pe VaR.
- ▶ Model: A3.

A5: VaR și ES pe componente pentru două active [Rezolvat]: Cerință

□ Date și ipoteze

- ▶ Acțiuni 600 000 EUR cu $\sigma_1 = 1,2\%$ zilnic; obligațiuni 400 000 EUR cu $\sigma_2 = 0,9\%$; corelația $\rho = -0,2$; distribuția Normală, medie zero, $\alpha = 1\%$.

□ Cerințe

- ▶ (a) Calculați abaterea standard a portofoliului în EUR și VaR 1% al portofoliului.
- ▶ (b) Calculați VaR marginal $z_{1-\alpha}(\Sigma w)_i / \sigma_p$ și VaR pe componente C_i pentru fiecare activ și verificați $C_1 + C_2 = \text{VaR}$ Tasche (2008).
- ▶ (c) Calculați beneficiul diversificării (suma VaR-urilor individuale minus VaR-ul portofoliului).
- ▶ (d) Folosind $ES_\alpha(w) = \min_v \{v + \mathbb{E}[(L_p - v)_+]/\alpha\}$ Rockafellar & Uryasev (2000), arătați că $w_i \partial ES_\alpha / \partial w_i = \mathbb{E}[-w_i R_i \mid L_p \geq \text{VaR}_\alpha]$ și calculați aceste contribuții la ES aici.

□ Raportați

- ▶ Un tabel cu C_i și C_i^{ES} și cotele lor; interpretare: contribuția obligațiunilor la risc este proporțională cu ponderea capitalului investit în ele?

A5: VaR și ES pe componente pentru două active [Rezolvat]: Rezolvare (1/2)

- (a) **Riscul portofoliului.** Abaterile standard individuale: $600\,000 \cdot 1,2\% = 7\,200$ EUR și $400\,000 \cdot 0,9\% = 3\,600$ EUR.
 - ▶ $\sigma_p^2 = 7\,200^2 + 3\,600^2 + 2(-0,2)(7\,200)(3\,600) = 54\,432\,000$, deci $\sigma_p = 7\,378$ EUR și $\text{VaR}_{1\%} = 2,326 \cdot 7\,378 = 17\,163$ EUR.
- (b) **VaR marginal și pe componente.** $(\Sigma w) = (77,76, 19,44)$ (în EUR, cu Σ în unități zecimale), ceea ce dă VaR marginal pe EUR de expunere $(0,0245, 0,0061)$.
 - ▶ $C_1 = 14\,711$ EUR (85,7%) și $C_2 = 2\,452$ EUR (14,3%); suma lor este 17 163 EUR, exact VaR-ul portofoliului.
- (c) **Diversificarea.** VaR individuale $16\,750 + 8\,375 = 25\,125$ EUR față de un VaR al portofoliului de 17 163 EUR.
 - ▶ Interpretare: obligațiunile reprezintă 40% din capitalul investit, dar contribuie cu doar 14,3% la risc, deoarece corelația negativă oferă o acoperire parțială a riscului acțiunilor.

A5: VaR și ES pe componente pentru două active [Rezolvat]: Rezolvare (2/2)

- **(d) Argumentul înfășurătoarei.** $v^* = \text{VaR}_\alpha$ minimizează $G(w, v) = v + \mathbb{E}[(L_p - v)_+]/\alpha$, deci $\partial \text{ES}_\alpha / \partial w_i = \partial G / \partial w_i$ în v^* .
- ▶ Derivând sub semnul valorii așteptate: $\partial G / \partial w_i = \mathbb{E}[-R_i 1\{L_p > v^*\}]/\alpha$.
 - ▶ Pentru L_p continuu, $P(L_p > \text{VaR}_\alpha) = \alpha$, deci aceasta este $\mathbb{E}[-R_i \mid L_p \geq \text{VaR}_\alpha]$; înmulțind cu w_i și însumând obținem $\mathbb{E}[L_p \mid L_p \geq \text{VaR}_\alpha] = \text{ES}_\alpha$.
- **(d) Cifre.** Sub distribuția Normală $\text{ES}_\alpha = \sigma_p \varphi(z_\alpha) / \alpha$, deci fiecare contribuție se scalează cu $\frac{\varphi(z_\alpha) / \alpha}{z_{1-\alpha}} = 1,146$.
- ▶ $C_1^{ES} = 16\,854$ EUR și $C_2^{ES} = 2\,809$ EUR; împreună 19\,663 EUR, ES 1% al portofoliului.
 - ▶ Interpretare: sub distribuția Normală cotele ES sunt egale cu cotele VaR, deci ES nu aduce informație nouă de alocare; cu cozi grele aduce (vezi B5).

A6: când este Cornish–Fisher o cuantilă validă? [Propus]: Cerință

Rezolvarea se discută la seminar

□ Date și ipoteze

- ▶ Randamente cu $\mu = 0$, $\sigma = 1,2\%$, asimetria $S = -0,5$ și excesul de aplatizare K [Cornish & Fisher \(1938\)](#).
- ▶ Transformarea Cornish–Fisher este $\tilde{z}(z) = z + \frac{(z^2 - 1)S}{6} + \frac{(z^3 - 3z)K}{24} - \frac{(2z^3 - 5z)S^2}{36}$, iar $\text{VaR}_\alpha = -\sigma\tilde{z}(z_\alpha)$.

□ Cerințe

- ▶ (a) Cu $K = 3$, calculați cei trei termeni de corecție în $z_{1\%}$, apoi $\tilde{z}_{1\%}$ și VaR 1% Cornish–Fisher; comparați cu VaR Normal.
- ▶ (b) Derivați $d\tilde{z}/dz$ și găsiți unde este minimă pe $[z_{0,1\%}, 0]$.
- ▶ (c) Găsiți cel mai mare K pentru care $\tilde{z}$ este crescătoare pe acest interval și decideți dacă $K = 10$ (aproape de S&P 500) este admisibil.

□ Raportați

- ▶ VaR de la (a), limita pentru K și dacă un VaR calculat cu $K = 10$ este o estimare validă. Model: A1.

A7: ES ca minim și subaditivitatea [Propus]: Cerință

Rezolvarea se discută la seminar

□ Date și ipoteze

- L este o pierdere integrabilă oarecare; definim $F_L(v) = v + \mathbb{E}[(L - v)_+]/\alpha$ Rockafellar & Uryasev (2000). Pentru cifre folosiți portofoliul din A4 (două obligațiuni, $p = 0,7\%$) la $\alpha = 1\%$.

□ Cerințe

- (a) Demonstrați că F_L este convexă și că minimum ei după v este $ES_\alpha(L)$, atins în $v = \text{VaR}_\alpha(L)$.
- (b) Deduceți $ES_\alpha(L_1 + L_2) \leq ES_\alpha(L_1) + ES_\alpha(L_2)$ din $(a + b)_+ \leq a_+ + b_+$.
- (c) Pentru portofoliul din A4, calculați panta lui F pe $(0, 100)$ și pe $(100, 200)$, punctul de minim și minimum.

□ Raportați

- Cele două demonstrații în câteva rânduri și cele trei cifre de la (c), comparate cu $ES_{1\%}(A + B)$ din A4. Model: A3, A4.

A8: dispersia de selecție a ES istoric [Propus]: Cerință

Rezolvarea se discută la seminar

□ Date și ipoteze

- ▶ n pierderi i.i.d. cu distribuție continuă, densitate pozitivă în VaR_α și $\mathbb{E}[L^2] < \infty$; ES istoric este media pierderilor de dincolo de VaR empiric. Funcția sa de influență este $\text{IF}(x) = \text{VaR}_\alpha + (x - \text{VaR}_\alpha)_+ / \alpha - \text{ES}_\alpha$ [Chen \(2008\)](#).

□ Cerințe

- ▶ (a) Arătați că dispersia limitei lui $\sqrt{n}(\widehat{\text{ES}}_\alpha - \text{ES}_\alpha)$ este $\text{avar}(\widehat{\text{ES}}_\alpha) = \text{Var}(\text{IF}(L)) = \text{Var}((L - \text{VaR}_\alpha)_+) / \alpha^2$ și explicați de ce estimarea VaR nu adaugă niciun termen.
- ▶ (b) Pentru $L \sim N(0, 1)$ și $\alpha = 2,5\%$, calculați în formă închisă $\mathbb{E}[(L - v)_+]$ și $\mathbb{E}[(L - v)_+^2]$ în $v = \text{VaR}_\alpha$.
- ▶ (c) Calculați eroarea standard a lui $\widehat{\text{ES}}_{2,5\%}$ pentru $n = 500$, cu $\sigma = 1$ și cu $\sigma = 1,2\%$, și comparați cu S&P 500 în ultimele sale 500 de zile.

□ Raportați

- ▶ Cele două momente, dispersia asimptotică și cele două erori standard; interpretare: de ce este valoarea pentru S&P 500 mult mai mare? Model: A1.

B1: VaR și ES istorice pentru BET [Rezolvat]: Cerință

□ Date și ipoteze

- ▶ Indicele BET (Bursa de Valori București), data/market/BET.csv, închideri zilnice 6 ianuarie 2000 – 18 septembrie 2026; randamente log zilnice în %, $r_t = 100 (\ln P_t - \ln P_{t-1})$, pierderea $L = -r$; doar zilele lucrătoare (fișierul nu conține înregistrări de sărbătoare).
- ▶ Două selecții: întreaga perioadă ($n = 6\,670$) și ultimele 500 de zile (de la 2024-09-12).


□ Cerințe

- ▶ (a) Calculați VaR și ES istorice la $\alpha = 1\%$ și $\alpha = 2,5\%$ pe ambele selecții (VaR = cuantila empirică $(1 - \alpha)$ a lui L , ES = media pierderilor mai mari sau egale cu ea).
- ▶ (b) Construiți un interval bootstrap percentil de 95% pentru VaR 1% cu 2 000 de reeșantionări i.i.d. [Efron \(1979\)](#).
- ▶ (c) Construiți încă trei intervale de 95% pentru VaR 1%: asimptotic i.i.d. ($\widehat{\text{VaR}} \pm 1,96 \sqrt{\alpha(1 - \alpha)/n/\hat{f}}$, densitate estimată cu un nucleu gaussian și lățime de bandă Silverman), asimptotic HAC (nucleu Bartlett, decalaj $\lfloor 4(n/100)^{2/9} \rfloor$) și un bootstrap pe blocuri mobile de 20 de zile [Künsch \(1989\)](#).

□ Raportați

- ▶ Un tabel cu cele opt cifre VaR/ES și cele patru intervale pentru fiecare eșantion. Interpretare: câte pierderi se află dincolo de VaR 1% în fiecare selecție, ce estimare ați raporta unui comitet de risc și care interval este cel mai larg și de ce?

B1: VaR și ES istorice pentru BET [Rezolvat]: Rezolvare (1/3)



	n	$\text{VaR}_{1\%}$	$\text{ES}_{1\%}$	$\text{VaR}_{2,5\%}$	$\text{ES}_{2,5\%}$
2000–2026	6 670	4,13	6,28	2,80	4,57
Ultimele 500 de zile	500	2,71	3,22	2,05	2,69

- (a) **Procedura.** Ordonăm pierderile, luăm cuantila empirică de 99% (97,5%) ca VaR și facem media pierderilor mai mari sau egale cu ea pentru ES; graficul arată coada și distribuțiile bootstrap ale VaR 1%.

B1: VaR și ES istorice pentru BET [Rezolvat]: Rezolvare (2/3)

- (a) **Numărul de pierderi din coadă.** Dincolo de VaR 1% se află 67 de pierderi în întregul eșantion, dar doar 5 în ultimele 500 de zile.
 - ▶ Deci ES 1% pe 500 de zile este media a doar cinci numere și trebuie raportat cu o avertizare.
- (b) **Intervale bootstrap.** Întreaga selecție [3,85; 4,46]; ultimele 500 de zile [2,11; 3,12].
 - ▶ Cele două intervale nu se suprapun: piața recentă este mai calmă decât media pe 26 de ani.
 - ▶ Interpretare: ambele valori sunt rezumate necondiționate; riscul de azi cere o prognoză condiționată (FHS, Cursul 7), iar analiza de stres o perioadă de stres aleasă explicit.

B1: VaR și ES istorice pentru BET [Rezolvat]: Rezolvare (3/3)

	bootstrap i.i.d.	asimpt., i.i.d.	asimpt., HAC	bootstrap pe blocuri
2000–2026	[3,85; 4,46]	[3,81; 4,44]	[3,69; 4,57]	[3,61; 4,80]
Ultimele 500 de zile	[2,11; 3,12]	[2,18; 3,25]	[2,19; 3,23]	[2,02; 3,03]

- **(c) Pasul asimptotic.** $\hat{f}(\widehat{\text{VaR}}) = 0,0076$ (complet) și $0,0163$ (500 de zile), deci $\text{SE} = \sqrt{0,01 \cdot 0,99/n/\hat{f}} = 0,16$ și $0,27$; erorile standard HAC sunt $0,23$ și $0,27$.
- **Citirea tabelului.** Lățimile pe întreaga selecție: $0,61, 0,63, 0,88, 1,19$; depășirile sunt grupate în 2008 și 2020, deci HAC și blocurile măresc intervalul de la o dată și jumătate până la de două ori.
- Ultimele 500 de zile: toate cele patru lățimi sunt în jur de 1; perioada este calmă, cu grupare redusă, deci răspunsul i.i.d. este adecvat acolo.

B2: estimarea GPD și VaR din valori extreme pentru BET [Rezolvat]: Cerință

□ Date și ipoteze

- ▶ Indicele BET (Bursa de Valori București), data/market/BET.csv, închideri zilnice 6 ianuarie 2000 – 18 septembrie 2026; randamente log zilnice în %, $r_t = 100 (\ln P_t - \ln P_{t-1})$, pierderea $L = -r$; doar zilele lucrătoare (fișierul nu conține înregistrări de sărbătoare).
- ▶ Depășiri de prag: excesele $L - u$ peste un prag ridicat u urmează o distribuție Pareto generalizată (GPD) cu forma ξ și scala β McNeil, Frey & Embrechts (2015).

□ Cerințe

- ▶ (a) Fixați u astfel încât cele mai mari 5% dintre pierderi să fie deasupra lui și estimați GPD pe excese prin verosimilitate maximă.
- ▶ (b) Calculați erorile standard i.i.d. $SE(\hat{\xi}) = (1 + \hat{\xi})/\sqrt{N_u}$ și $SE(\hat{\beta}) = \hat{\beta}\sqrt{2(1 + \hat{\xi})/N_u}$.
- ▶ (c) Calculați VaR și ES GPD la $\alpha = 1\%$, $0,5\%$ și $0,1\%$ și comparați cu simularea istorică.
- ▶ (d) Re-estimați pentru praguri depășite de proporții ale pierderilor cuprinse între 10% și 1,5% și reprezentați $\hat{\xi}$ cu benzi de 95%.
- ▶ (e) Estimați indicele extremal θ al depășirilor lui u cu estimatorul pe intervale Ferro & Segers (2003), declusterizați și re-estimați GPD pe maximele grupurilor.


□ Raportați

- ▶ Estimarea, tabelul VaR/ES, graficul de stabilitate și estimarea declusterizată. Interpretare: este coada BET mai grea decât distribuția Normală, cât de siguri suntem și este credibilă SE i.i.d. a lui $\hat{\xi}$?

B2: estimarea GPD și VaR din valori extreme pentru BET [Rezolvat]: Rezolvare (1/3)

- (a) **Estimarea.** $u = 1,93\%$ lasă deasupra $N_u = 334$ din $n = 6\,670$ pierderi; verosimilitatea maximă dă $\hat{\xi} = 0,209$ și $\hat{\beta} = 1,20$.
- (b) **Erori standard.** $SE(\hat{\xi}) = (1 + 0,209)/\sqrt{334} = 0,066$ și $SE(\hat{\beta}) = 0,10$.
 - ▶ $\hat{\xi}/SE = 3,2$: sub independență, coada este semnificativ mai grea decât una exponențială (de tip Normal); (e) verifică ipoteza de independență.
- (c) **VaR 1%, pas cu pas.** $N_u/n = 0,050$, deci $(0,01/0,050)^{-0,209} = 1,401$.
 - ▶ $VaR_{1\%} = 1,93 + \frac{1,20}{0,209}(1,401 - 1) = 4,22\%$ (istoric 4,13%); $ES_{1\%} = 6,34\%$ (istoric 6,28%).
 - ▶ Mai adânc: VaR 0,5% 5,47 vs 5,38; VaR 0,1% 9,18 vs 9,50, cu doar 7 observații dincolo; ES 0,1% 12,61 vs 11,25.
 - ▶ Interpretare: cele două metode coincid până la 0,5%; la 0,1% ES istoric este media a șapte numere și doar GPD dă o valoare stabilă.

B2: estimarea GPD și VaR din valori extreme pentru BET [Rezolvat]: Rezolvare (2/3)



- (d) **Stabilitatea.** Pe praguri, $\hat{\xi}$ variază între 0,15 și 0,30, dar VaR 0,1% doar între 9,04% și 9,51%.
- Citirea graficului: stânga, GPD urmează coada empirică, iar coada Normală cade mult sub ea; dreapta, banda se lărgeste pe măsură ce rămân mai puține pierderi. Cuantila este mai stabilă decât parametrul de formă.

B2: estimarea GPD și VaR din valori extreme pentru BET [Rezolvat]: Rezolvare (3/3)

- (e) **Indicele extremal.** Din intervalele T_i dintre cele 334 depășiri: $\hat{\theta} = \frac{2(\sum_i (T_i - 1))^2}{(N - 1) \sum_i (T_i - 1)(T_i - 2)} = 0,32$.
- ▶ Declusterizare [Ferro & Segers \(2003\)](#): ținta este $C = \lfloor \hat{\theta} N \rfloor + 1 = 108$ grupuri, separate la cele mai mari $C - 1$ intervale; al $(C - 1)$ -lea și al C -lea cel mai mare interval sunt egale, deci C se reduce până când diferă, rămânând 100 grupuri de câte 3,3 depășiri în medie.
 - ▶ La pragul VaR 1%, $\hat{\theta} = 0,40$.
- **Estimarea declusterizată.** GPD pe cele 100 maxime ale grupurilor: $\hat{\xi} = 0,269$ (SE 0,127) față de 0,209 (SE 0,066) pe toate depășirile.
- ▶ $\hat{\xi}/\text{SE}$ scade de la 3,2 la 2,1: doar circa 100 din cele 334 excese poartă informație independentă.
 - ▶ Interpretare: coada rămâne grea, dar SE i.i.d. de 0,066 nu este credibilă; raportăm estimarea declusterizată sau filtrăm întâi cu GARCH (EVT condiționată).

B3: simulare filtrată vs istorică pentru Bitcoin [Propus]: Cerință

Rezolvarea se discută la seminar

□ Date și ipoteze

- ▶ Bitcoin în USD, data/market/BTC-USD.CC.csv, închideri zilnice 17 septembrie 2014 – 18 septembrie 2026, 7 zile din 7; randamente log zilnice în %.
- ▶ Model: $r_t = \mu_t + \sigma_t z_t$, cu medie AR(1) și dispersie GARCH(1,1), estimat prin cvasi-verosimilitate maximă [Barone-Adesi et al. \(1999\)](#).

□ Cerințe

- ▶ (a) Estimați modelul pe întreaga selecție și prognozați $\hat{\mu}_{t+1}$ și $\hat{\sigma}_{t+1}$ pentru 19 septembrie 2026.
- ▶ (b) Calculați VaR 1% și ES 1% filtrate din cuantila empirică a reziduurilor standardizate și comparați cu simularea istorică pe 500 de zile și pe întreaga selecție.
- ▶ (c) Folosind prognoze pentru ziua următoare (GARCH re-estimat în fiecare ianuarie), numărați zilele din ultimii doi ani cu pierdere peste fiecare VaR.
- ▶ (d) Construiți un interval de 90% prin bootstrap pe reziduuri pentru VaR 1% filtrat de azi, cu 999 de traiectorii, re-estimând GARCH pe fiecare traiectorie [Christoffersen & Gonçalves \(2005\)](#).

□ Raportați

- ▶ Cele trei perechi VaR/ES, numărul depășirilor și intervalul. Interpretare: de ce poate raportul dintre două dintre cele trei estimări VaR să ajungă la doi, care metodă greșește mai des și se suprapune intervalul de la (d) cu VaR istoric pe 500 de zile? Model: B1.

B4: Cornish–Fisher vs cuantile empirice [Propus]: Cerință

Rezolvarea se discută la seminar

□ Date și ipoteze

- ▶ Randamente log zilnice în % (data/market): S&P 500 și aur 2000–2026, BET 2000–2026, Bitcoin 2014–2026, EUR/RON (cursul de referință BNR) 2005–2026; selecțiile complete.

□ Cerințe

- ▶ (a) Calculați asimetria S și excesul de aplatizare K ale randamentelor fiecărei serii.
- ▶ (b) Calculați VaR 1% și VaR 2,5% folosind distribuția Normală, dezvoltarea Cornish–Fisher (formula din A6) și simularea istorică.
- ▶ (c) Construiți un interval bootstrap percentil de 95% (1 000 de reeșantionări i.i.d.) pentru VaR 1% istoric și verificați dacă valoarea Cornish–Fisher se află în el.

□ Raportați

- ▶ Un tabel cu toate cifrele. Interpretare: este Cornish–Fisher în interval pentru vreo serie, de ce funcționează mai bine la 2,5% decât la 1% și ar ajuta momentele din ultimul an? Model: A1, A6, B1.

B5: VaR pe componente pentru un portofoliu cu patru active [Propus]: Cerință

Rezolvarea se discută la seminar

□ Date și ipoteze

- ▶ SPY, TLT, GLD (prețuri ajustate) și Bitcoin, data/market, 18 septembrie 2014 – 18 septembrie 2026; întâi îmbinăm prețurile în cele 3017 zile comune, apoi randamente simple zilnice în %.
- ▶ Ponderi egale de 25%, rebalansate zilnic; $\alpha = 1\%$ pentru VaR și $\alpha = 2,5\%$ pentru ES.

□ Cerințe

- ▶ (a) Calculați VaR 1% Normal $z_{1-\alpha} \sqrt{w^T \Sigma w}$, VaR marginal și VaR pe componente pentru fiecare activ [Tasche \(2008\)](#).
- ▶ (b) Calculați ES 2,5% istoric al portofoliului și contribuțiile $\mathbb{E}[-w_i R_i \mid L_p \geq \text{VaR}_{2,5\%}]$ ca medii pe zilele din coadă.
- ▶ (c) Calculați VaR nediversificat $\sum_i z_{1-\alpha} w_i \sigma_i$.

□ Raportați

- ▶ Un tabel cu contribuțiile și cotele. Interpretare: este un portofoliu cu ponderi egale la fel de riscant în fiecare activ, cum se compară cu portofoliul 40/30/20/10 din curs și ce ponderi nenegative, cu investiție integrală, ar egaliza aproximativ contribuțiile la VaR Normal (o primă aproximare este suficientă)? Model: A5.

B6: cât de precisă este o estimare ES? [Propus]: Cerință

Rezolvarea se discută la seminar

□ Date și ipoteze

- ▶ S&P 500 (data/market/GSPC.INDX.csv) și BET, randamente log zilnice în %, 2000–2026; câte două selecții: completă și ultimele 500 de zile.

□ Cerințe

- ▶ (a) Calculați ES 2,5% istoric (convenția din curs), numărul $n\alpha$ din coadă și numărul k de pierderi incluse efectiv în calculul mediei din coadă.
- ▶ (b) Construiți un interval percentil de 95% cu bootstrap i.i.d. [Efron \(1979\)](#), 2 000 de reeșantionări.
- ▶ (c) Repetați (b) cu bootstrap pe blocuri mobile, blocuri de 20 de zile [Künsch \(1989\)](#).

□ Raportați

- ▶ Un tabel cu $n\alpha$, ES și ambele intervale. Interpretare: de ce este intervalul pe blocuri mai larg pe întreaga selecție și fixează o estimare ES necondiționată din 500 de zile nivelul ES cu o precizie de 0,3 puncte procentuale [Pele & Mazurencu-Marinescu-Pele \(2026\)](#)? Model: B1.

B7: CAViaR pentru BET [Propus]: Cerință

Rezolvarea se discută la seminar

□ Date și ipoteze

- ▶ Indicele BET (Bursa de Valori București), data/market/BET.csv, închideri zilnice 6 ianuarie 2000 – 18 septembrie 2026; randamente log zilnice în %, $r_t = 100 (\ln P_t - \ln P_{t-1})$, pierderea $L = -r$; doar zilele lucrătoare (fișierul nu conține înregistrări de sărbătoare).
- ▶ CAViaR cu valoare absolută simetrică: $\text{VaR}_t = \beta_0 + \beta_1 \text{VaR}_{t-1} + \beta_2 |r_{t-1}|$, $\alpha = 1\%$, $\text{VaR}_1 = -\hat{q}_\alpha$ al primelor 300 de randamente (cuantila superioară a pierderilor), zile păstrate în eșantionul de estimare Engle & Manganelli (2004).

□ Cerințe

- ▶ (a) Estimați β pe 2000–2015 prin minimizarea pierderii pinball $\sum_t (\alpha - 1\{r_t < -\text{VaR}_t\})(r_t + \text{VaR}_t)$: 10^4 puncte de start aleatoare în $(0, 1)^3$, cele mai bune 10 rafinate prin pași simplex și quasi-Newton.
- ▶ (b) Cu β fixat, prognozați VaR pentru 2016–2026 și calculați rata de depășire și pierderea pinball medie; comparați cu FHS (GARCH re-estimat în fiecare ianuarie) și cu simularea istorică pe 500 de zile.
- ▶ (c) Pentru 20 februarie – 30 aprilie 2020 numărați depășirile și raportați VaR maxim al fiecărei metode.

□ Raportați

- ▶ Estimările, un tabel de comparație și cifrele din pandemia COVID-19. Interpretare: ce spune $\hat{\beta}_1$ despre memoria riscului BET, cum reacționează CAViaR la prăbușire față de FHS și diferă numerele de depășiri între metode? (teste formale în Capitolul 8). Model: B3; cursul, CAViaR pentru S&P 500.

C1: capitalul ES, BVB vs S&P 500 [Deschis]: Cerință

□ Date și ipoteze

- ▶ Coșul BVB: Banca Transilvania, OMV Petrom, BRD, Transgaz, Romgaz, Nuclearelectrica, Electrica, Transelectrica (data/market, prețuri ajustate), ponderi egale, rebalansare zilnică; portofoliul S&P 500: SPY.
- ▶ Ultimii zece ani (de la 2016-09-20), randamente simple zilnice R_t în %, în moneda locală, 1 milion investit; o ilustrare simplificată inspirată de FRTB [Basel Committee \(2019\)](#), nu calculul complet al capitalului din [Basel Committee, MAR33](#).

□ Cerințe

- ▶ (a) Calculați ES 2,5% istoric pe o zi pentru fiecare portofoliu (pierderea $-R_t$).
- ▶ (b) Calculați ES 2,5% pe 10 zile în trei moduri: scalarea cu $\sqrt{10}$; pierderi compuse suprapuse $100[1 - \prod_{i=1}^{10}(1 + R_{t+i}/100)]$; Monte Carlo filtrat din starea AR(1)-GARCH(1,1) de azi pe randamentele log, fiecare traiectorie convertită într-o pierdere simplă.
- ▶ (c) Fereastra de stres: cele 250 de zile consecutive cu cel mai mare ES 2,5% istoric pe o zi; calculați ES de stres în ea pe o zi și, prin scalarea cu $\sqrt{10}$, pe 10 zile.
- ▶ (d) Capitalul la un milion $= m_c \times$ ES de stres, $m_c = 1,5$, pentru un orizont de lichiditate de 10 zile (capitalizare mare) și de 20 de zile (capitalizare mică, încă un factor $\sqrt{20/10}$).
- ▶ (e) Intervale bootstrap de 95% pe blocuri mobile (blocuri de 20 de zile, 2000 de reeșantionări) pentru (a) și pentru ES de stres pe o zi din (c), cu fereastra de stres ținută fixă.

□ Raportați

- ▶ Un tabel cu toate cifrele și intervalele de la (e) și o argumentație de o pagină: care portofoliu cere mai mult capital și cum schimbă răspunsul tranzacționarea rară și moneda (RON vs USD)?

C2: critica unui răspuns AI [Propus]

Rezolvarea se discută la seminar

Cererea trimisă unui asistent de inteligență artificială (AI)

- „px conține închiderile zilnice BET, 2000–2026. Dă-mi VaR 1% și ES 2,5% istorice pe o zi, ca pierderi logaritmice pozitive în %, și VaR 1% pe 10 zile.”

Răspunsul asistentului

```
import numpy as np
r = 100 * np.log(px).diff().dropna()          # daily log returns, %
loss = -r                                     # log loss, %
var1 = np.percentile(r, 99)                  # VaR 1%
es25 = loss[loss >= np.percentile(loss, 99)].mean() # ES 2.5%
var10 = 10 * var1                            # 10-day VaR 1%
```

- „VaR 1% = 3,95%, ES 2,5% = 6,28%, VaR 1% pe 10 zile = 39,46% (pierderi logaritmice).”

C2: critica unui răspuns AI [Propus]: Cerință

Rezolvarea se discută la seminar

□ Date și ipoteze

- ▶ Aceleași date BET ca în B1 (2000–2026, randamente log zilnice în %); codul de pe slide-ul anterior rulează fără erori, dar răspunsul conține **trei** greșeli tipice pentru VaR și ES; tot restul este corect.

□ Cerințe

- ▶ (a) Pentru fiecare greșeală, indicați linia și explicați într-o frază de ce este greșită, folosind definițiile $\text{VaR}_\alpha = -q_\alpha(r)$ și $\text{ES}_\alpha = \text{pierdere medie dincolo de } \text{VaR}_\alpha$.
- ▶ (b) Spuneți cum ați depista-o: o numărătoare a observațiilor, o cifră din B1 sau un slide din curs.
- ▶ (c) Scrieți varianta corectă a liniei (liniilor) și recalculați cele trei cifre.
- ▶ Indiciu: numărați câte pierderi zilnice mediază es25 și câte ar trebui să medieze.

□ Raportați

- ▶ Notați fiecare greșeală ca în AI_ERRORS.md: ce ați întrebat, ce a răspuns AI-ul, ce era greșit, cum v-ați dat seama și varianta corectă. Model: B1.

C3: VaR prin regresie cuantilă cu rețele neuronale [Deschis]: Cerință (1/3)

▣ Context și date

- ▶ Studiul de caz din Cursul 7: [Chronopoulos, Raftapostolos & Kapetanios \(2024\)](#) folosesc o rețea cu propagare înainte $G_\alpha(x_t, w)$, cu straturi ascunse ReLU, pentru regresia cuantilă. Rețeaua minimizează pierderea pinball penalizată (Ec. 10). Evaluarea pe ultimele 2 000 de zile până în august 2020 pentru S&P 500 arată un RMSFE mult mai mic pentru toate rețelele adânci penalizate decât pentru regresia cuantilă liniară, la $\alpha = 1\%$ (Tabelul 6).
- ▶ Randamente log zilnice $r_t = \ln(P_t/P_{t-1})$, nescalate, ca în articol (Secțiunea 3.1), pentru ca grila penalizării să își păstreze sensul; prognozele se transformă în % doar la raportare. Date din data/market: S&P 500 între 2 ianuarie 1990 și 31 august 2020 (eșantionul din articol începe în septembrie 1985) și BET pentru extindere, fiecare serie pe propriul calendar de tranzacționare.

▣ Cerințe

- ▶ (a) Păstrați ultimele 2 000 de randamente ca eșantion de evaluare și pe cele anterioare ca eșantion de calibrare. Estimați doar pe eșantionul de calibrare GARCH(1,1) din Ec. 14 prin QML și CAViaR SAV din Ec. 16 prin pierderea pinball [Engle & Manganelli \(2004\)](#); apoi, cu acești parametri fixați, continuați ambele recursii pe eșantionul de evaluare pentru a obține σ_t și $(\text{VaR}_{t-1}, |r_{t-1}|)$ pentru fiecare zi.

C3: VaR prin regresie cuantilă cu rețele neuronale [Deschis]: Cerință (2/3)

□ Cerințe (continuare)

- ▶ (b) La $\alpha = 1\%$ și 5% , estimați pe perechile (x_t, r_t) din Ec. 8 o regresie cuantilă liniară (reperul) și o rețea cuantilă adâncă cu straturi ascunse ReLU, ieșire liniară și penalizare ridge; selectați prin CV pentru serii de timp (Ec. 12; $\delta = 5$, $\kappa = 20$) adâncimea și lățimea din $\{1, 5, 10\}$, rata de învățare și λ din câte cinci valori în $[0,001; 0,01]$ și dimensiunea lotului din $\{10, 20\}$; antrenați cu Adam, dropout de cel mult 20% și cel mult $5\,000$ de epoci, cu oprire timpurie (Secțiunea 1.4). Articolul nu dă valorile exacte ale grilelor și nici regula de oprire timpurie: precizați-le pe ale voastre.
- ▶ (c) Cu parametrii fixați, $G_\alpha(x_t, w^*)$ prognozează cuantila randamentului zilnic de la $t + 10$, iar $\widehat{\text{VaR}}_{t+10|\mathcal{F}_t} = -G_\alpha(x_t, w^*)$ (Ec. 23 raportează cuantila însăși). Ec. 23 asociază originea t cu ținta $t + 10$, iar RMSFE din Secțiunea 3.3 este scris cu x_{t+h} : precizați alinierea aleasă; noi indexăm cele $2\,000$ de zile de evaluare după data țintă.
- ▶ RMSFE relativ (Secțiunea 3.3): $\sqrt{\frac{1}{T} \sum_t (r_{t+10} - \hat{G}_\alpha)^2}$ al rețelei împărțit la cel al reperului liniar; aplicați și testul DM Diebold & Mariano (1995) pierderilor pinball, cu corecția Harvey, Leybourne & Newbold (1997), și comparați cu rândurile GARCH și SAV din Tabelul 6.
- ▶ Atenție: $\mathbb{E}[(r - q)^2 | x] = \text{Var}(r | x) + (\mathbb{E}[r | x] - q)^2$ este minimizată de media condiționată, nu de cuantilă; folosiți RMSFE doar pentru a reproduce Tabelul 6, iar concluziile despre precizia cuantilelor se bazează pe pierderea pinball.

C3: VaR prin regresie cuantilă cu rețele neuronale [Deschis]: Cerință (3/3)

□ Cerințe (continuare)

- ▶ (d) Extindere: reestimați ambele modele o dată pe an, pe fereastră mobilă, și prognozați septembrie 2020 – 2026 pentru S&P 500 și BET.
- ▶ (e) Direcție deschisă: antrenați aceeași rețea cu două ieșiri (v_t, e_t) folosind funcția de pierdere FZ0 din [Patton, Ziegel & Chen \(2019\)](#) pentru prognoza comună a VaR și ES, la același nivel și orizont. Ieșirile sunt prognoze pe scala randamentelor, $v_t = -\text{VaR}_{\alpha,t}$ și $e_t = -\text{ES}_{\alpha,t}$; FZ0 conține $\ln(-e_t)$ și $1/e_t$ și cere $e_t < 0$ și $e_t \leq v_t$, deci impuneți ambele condiții, de exemplu $e_t = -\exp(a_t)$ și $v_t = e_t + \exp(b_t)$.

□ Raportați

- ▶ Un tabel pe indice, set de predictor, nivel și perioadă: arhitectura aleasă, RMSFE relativ, statistica DM, pierderea pinball medie, rata de depășire și numărul de depășiri.
- ▶ Interpretare (o pagină): se păstrează avantajul rețelei față de regresia cuantilă liniară când eșantionul de calibrare este mai scurt, după 2020 și pentru BET? Poate fi atribuit câștigul neliniarității, când arhitectura, penalizarea și CV se schimbă simultan?

Greșeli frecvente

- ▣ Amestecarea convențiilor de semn: un VaR raportat ca randament negativ într-un tabel și ca pierdere pozitivă în altul
- ▣ Folosirea distribuției Normale sau a dezvoltării Cornish–Fisher cu o aplatizare zilnică de 10
- ▣ Raportarea unui ES 1% din 500 de zile fără a spune că este media a 5 numere
- ▣ Scalarea cu $\sqrt{10}$ a unei serii cu autocorelație pozitivă (BET, coșul BVB)
- ▣ Citirea ponderilor în bani ca ponderi de risc: o poziție crypto de 10% poate purta peste o treime din risc
- ▣ Randamente log adunate între active: pierderile portofoliului cer randamente simple

Temă pentru acasă (proiect de echipă)

- ▣ Alegeți un portofoliu de cel puțin trei active nediscutate la seminar (acțiuni BVB, o monedă, un crypto-activ)
- ▣ Estimați $\text{VaR}_{1\%}$ și $\text{ES}_{2,5\%}$ pe o zi cu metode istorice, filtrate și din valori extreme, fiecare cu interval bootstrap
- ▣ Împărțiți ES în contribuții Euler; pornind de la ponderi egale (fără vânzări în lipsă, integral investit, ES 2,5% istoric, randament așteptat = media de selecție), minimizați ES la același randament așteptat, cu ținta unei reduceri de 20%; dacă este imposibilă, raportați ES minim atins
- ▣ Notați fiecare eroare AI pe care o prindeți în `AI_ERRORS.md` (cel puțin trei pe proiect)
- ▣ Livrați un folder Quantlet (cod, Metainfo, grafice) și trei slide-uri: cifre, interpretare, limite

Studiu suplimentar pe Quantinar

Cursuri avansate pe quantinar.com

- ☐  Measuring Statistical Risk
- ☐  XFG Advanced Methods in Quantitative Finance

Cod și date

- ☐ Notebook-ul seminarului (Colab); Quantlets: github.com/danpele/MFM/tree/main/Quantlets/Ch_07

Bibliografie (1/3)

- ▣ Acerbi, C., Tasche, D. (2002). *On the coherence of expected shortfall*. *Journal of Banking & Finance*, 26(7), 1487–1503.
- ▣ Artzner, P., Delbaen, F., Eber, J.-M., Heath, D. (1999). *Coherent measures of risk*. *Mathematical Finance*, 9(3), 203–228.
- ▣ Barone-Adesi, G., Giannopoulos, K., Vosper, L. (1999). *VaR without correlations for portfolios of derivative securities*. *Journal of Futures Markets*, 19(5), 583–602.
- ▣ Basel Committee on Banking Supervision (2019). *Minimum capital requirements for market risk*. Bank for International Settlements.
- ▣ Chen, S.X. (2008). *Nonparametric estimation of expected shortfall*. *Journal of Financial Econometrics*, 6(1), 87–107.
- ▣ Christoffersen, P., Gonçalves, S. (2005). *Estimation risk in financial risk management*. *Journal of Risk*, 7(3), 1–28.
- ▣ Chronopoulos, I., Raftapostolos, A., Kapetanios, G. (2024). *Forecasting Value-at-Risk using deep neural network quantile regression*. *Journal of Financial Econometrics*, 22(3), 636–669.
- ▣ Cornish, E.A., Fisher, R.A. (1938). *Moments and cumulants in the specification of distributions*. *Revue de l'Institut International de Statistique*, 5(4), 307–320.
- ▣ Diebold, F.X., Mariano, R.S. (1995). *Comparing predictive accuracy*. *Journal of Business & Economic Statistics*, 13(3), 253–263.

Bibliografie (2/3)

- ▣ Efron, B. (1979). [Bootstrap methods: another look at the jackknife](#). *Annals of Statistics*, 7(1), 1–26.
- ▣ Engle, R.F., Manganelli, S. (2004). [CAViaR: conditional autoregressive value at risk by regression quantiles](#). *Journal of Business & Economic Statistics*, 22(4), 367–381.
- ▣ Ferro, C.A.T., Segers, J. (2003). [Inference for clusters of extreme values](#). *Journal of the Royal Statistical Society: Series B*, 65(2), 545–556.
- ▣ Franke, J., Härdle, W.K., Hafner, C.M. (2019). [Statistics of Financial Markets: An Introduction](#), 5th ed. Springer.
- ▣ Harvey, D., Leybourne, S., Newbold, P. (1997). [Testing the equality of prediction mean squared errors](#). *International Journal of Forecasting*, 13(2), 281–291.
- ▣ Künsch, H.R. (1989). [The jackknife and the bootstrap for general stationary observations](#). *Annals of Statistics*, 17(3), 1217–1241.
- ▣ McNeil, A.J., Frey, R. (2000). [Estimation of tail-related risk measures for heteroscedastic financial time series: an extreme value approach](#). *Journal of Empirical Finance*, 7(3–4), 271–300.
- ▣ McNeil, A.J., Frey, R., Embrechts, P. (2015). [Quantitative Risk Management: Concepts, Techniques and Tools](#), revised ed. Princeton University Press.
- ▣ Patton, A.J., Ziegel, J.F., Chen, R. (2019). [Dynamic semiparametric models for expected shortfall \(and Value-at-Risk\)](#). *Journal of Econometrics*, 211(2), 388–413.

Bibliografie (3/3)

- Pele, D.T., Mazurencu-Marinescu-Pele, M. (2026). Finite-sample precision limits for expected shortfall forecast comparisons. *Mathematics*, 14(13), 2316.
- Rockafellar, R.T., Uryasev, S. (2000). Optimization of conditional value-at-risk. *Journal of Risk*, 2(3), 21–41.
- Tasche, D. (2008). Capital allocation to business units and sub-portfolios: the Euler principle. arXiv:0708.2542.