



Modelarea piețelor financiare

Seminarul 9: Volatilitate realizată — aplicații



Daniel Traian PELE

Drd. Antoaneta Amza, antoaneta.amza@csie.ase.ro

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

Acronime folosite în acest material (1/2)

- ▣ AI: Artificial Intelligence (inteligență artificială)
- ▣ AR: AutoRegressive (model) (model autoregresiv)
- ▣ BH: Benjamini–Hochberg (procedure) (procedura Benjamini–Hochberg)
- ▣ BV: Bipower Variation (variația bipower)
- ▣ BVB: Bursa de Valori București
- ▣ CI: Confidence Interval (interval de încredere)
- ▣ CLT: Central Limit Theorem (teorema limită centrală)
- ▣ DM: Diebold–Mariano (test) (testul Diebold–Mariano de comparare a prognozelor)
- ▣ EWMA: Exponentially Weighted Moving Average (medie mobilă ponderată exponențial)
- ▣ FDR: False Discovery Rate (rata descoperirilor false)
- ▣ FRED: Federal Reserve Economic Data (baza de date economice a Rezervei Federale (St. Louis))
- ▣ GARCH: Generalised AutoRegressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă generalizată)
- ▣ HAC: Heteroskedasticity and Autocorrelation Consistent (standard errors) (erori standard robuste la heteroscedasticitate și autocorelație)
- ▣ HAR: Heterogeneous AutoRegressive (model) (model autoregresiv heterogen)
- ▣ HAR-CJ: HAR model with Continuous and Jump components (model HAR cu componentă continuă și componentă de salt)
- ▣ HARQ: HAR model with Realised Quarticity (model HAR cu cvarticitatea realizată)
- ▣ IQ: Integrated Quarticity (cvarticitatea integrată)
- ▣ JB: Jarque–Bera (test) (testul de normalitate Jarque–Bera)
- ▣ MAE: Mean Absolute Error (eroarea absolută medie)
- ▣ MCS: Model Confidence Set (mulțimea de încredere a modelelor)
- ▣ ML: Machine Learning (învățare automată)
- ▣ MSE: Mean Squared Error (eroarea pătratică medie)
- ▣ MZ: Mincer–Zarnowitz (regression) (regresia Mincer–Zarnowitz)
- ▣ NW: Newey–West (standard errors) (erori standard Newey–West)
- ▣ OLS: Ordinary Least Squares (metoda celor mai mici pătrate)
- ▣ QLIKE: Quasi-LIKelihood (loss function) (funcția de pierdere de tip cvasi-verosimilitate)

Acronime folosite în acest material (2/2)

- ▣ RF: Random Forest (pădure aleatoare)
- ▣ RQ: Realised Quarticity (cvarticitatea realizată)
- ▣ RV: Realised Variance (varianța realizată)
- ▣ SE: Standard Error (eroare standard)
- ▣ SHAR: Semivariance HAR model (model HAR cu semivarianțe)
- ▣ SUA: Statele Unite ale Americii
- ▣ TQ: Tripower Quarticity (cvarticitatea tripower)
- ▣ TSRV: Two-Scale Realised Variance (varianța realizată pe două scări)
- ▣ UTC: Coordinated Universal Time (Temps Universel Coordonné)
(timpul universal coordonat)
- ▣ VIX: CBOE Volatility Index (indicele de volatilitate CBOE)

Cuprins

Introducere

Partea A: derivări

Partea B: calcul și inferență

Partea C: întrebare deschisă și critica unui răspuns AI

Încheiere

Bibliografie

Obiectivele seminarului

La finalul seminarului puteți

- ▣ Deriva momentele și CLT fezabilă pentru RV, deplasarea din zgomet și robustețea BV la salturi
- ▣ Testa salturile în multe zile cu control FDR și corecție de periodicitate
- ▣ Testa HAR ca AR(22) restricționat și explica HARQ prin erori în variabile
- ▣ Compara prognoze de varianță cu QLIKE, Diebold–Mariano, Giacomini–White și mulțimea de încredere a modelelor

- ▣ Suport: Cursul 9; manualul Franke, Härdle & Hafner (2019)

Structura

- ▣ **Partea A:** opt derivări (A1–A8)
- ▣ **Partea B:** nouă exerciții pe calculator, cu inferență, pe SPY și Bitcoin (B1–B9)
- ▣ **Partea C:** o întrebare deschisă, punct de plecare pentru proiectul de echipă (C1), critica unui răspuns AI (C2) și un punct de plecare pentru proiect din studiul de caz al cursului (C3)

Cum lucrăm la acest seminar

- ▣ Problemele **[Rezolvat]** au rezolvarea completă; problemele **[Propus]** au doar cerința: rezolvările se discută la seminar
- ▣ Fiecare problemă propusă indică **modelul**: problema rezolvată care folosește aceeași tehnică
 - ▶ Fiecare exercițiu din Partea B se încheie cu întrebări de interpretare
- ▣ Unități: randamente în %, varianțe zilnice în $\%^2$; anualizăm cu 252 de zile (SPY) sau 365 de zile (Bitcoin)
- ▣ Fiecare măsură realizată zilnică este ea însăși o estimare: raportați cât de precisă este

Probleme rezolvate și propuse

Rezolvate: exemple lucrate în acest material

- ▣ Partea A: A1 (momentele RV, CLT fezabilă), A3 (deplasarea din zgomot, eșantionarea optimă), A5 (HAR ca AR(22) restricționat), A6 (robustețea QLIKE)
- ▣ Partea B: B1 (testul de salturi pe SPY), B3 (frecvența de eșantionare cu bootstrap pe blocuri), B5 (log-HAR cu erori Newey–West)

Propuse: le rezolvați voi

- ▣ Partea A: A2 (BV în prezența unui salt; model: A1), A4 (RV pe două scări și rata ei; model: A3), A7 (atenuarea și HARQ; model: A5), A8 (testul Wald comun în MZ; model: A6)
- ▣ Partea B: B2 (salturi Bitcoin; model: B1), B4 (randamente standardizate; model: B3), B6 (prognoze pe 5 zile; model: B5, A8), B7 (HAR-CJ; model: B5, B1), B8 (asprimea; model: B3), B9 (mulțimea de încredere a modelelor; model: B5, B6)
- ▣ Partea C: C1, întrebare deschisă și punct de plecare pentru proiect; C2, critica unui răspuns AI; C3, învățare automată vs HAR pe SPY (studiul de caz din curs; model: B5, A6)

Pregătire: mediul Python și datele

- ▣  **Deschide în Colab:** `capitol9_notebook_seminar.ipynb`
- ▣ Google Colab (recomandat) sau Python local ≥ 3.10 cu `numpy`, `pandas`, `scipy`, `statsmodels`, `arch`, `matplotlib`
- ▣ SPY, bare de 5 minute din sesiunea regulată din SUA, octombrie 2020 – septembrie 2026; Bitcoin, bare de 5 minute, zile UTC de 24 de ore, septembrie 2024 – septembrie 2026
- ▣ Prețuri zilnice de închidere pentru SPY (ajustate) și Bitcoin, pentru GARCH; varianța zilnică totală $SPY = RV_{intraday} + \text{randamentul peste noapte la pătrat}$

Formulele folosite azi

- $RV_t = \sum_{i=1}^M r_{t,i}^2$; $BV_t = \frac{\pi}{2} \frac{M}{M-1} \sum_{i=2}^M |r_{t,i}| |r_{t,i-1}|$; $se(RV_t) = \sqrt{\frac{2}{3} \sum_i r_{t,i}^4}$
- Testul de salturi [Huang & Tauchen \(2005\)](#): $z_t = \frac{(RV_t - BV_t)/RV_t}{\sqrt{\theta M^{-1} \max(\mathbf{1}, \mathbf{T} \mathbf{Q}_t / BV_t^2)}}$, $\theta = \pi^2/4 + \pi - 5$
- Zgomot: $\mathbb{E}[RV^{(n)} | \sigma] = IV + 2n\omega^2$; $n^* = (IQ/(4\omega^4))^{1/3}$ [Bandi & Russell \(2008\)](#); RV pe două scări = $RV^{avg} - \frac{\bar{n}}{n} RV^{all}$ [Zhang, Mykland & Aït-Sahalia \(2005\)](#)
- log-HAR [Corsi \(2009\)](#): $\ln RV_{t+1} = \beta_0 + \beta_d \ln RV_t + \beta_w \overline{\ln RV_t^{(5)}} + \beta_m \overline{\ln RV_t^{(22)}} + \varepsilon_{t+1}$
- QLIKE = $RV/F - \ln(RV/F) - 1$ [Patton \(2011\)](#); DM: $t = \bar{d}/se_{NW}(\bar{d})$ [Diebold & Mariano \(1995\)](#); MZ: $RV_t = a + bF_t + u_t$, $H_0 : a = 0, b = 1$

A1: momentele RV și CLT fezabilă [Rezolvat]

Cerință

- ▣ Context: o zi de tranzacționare este împărțită în M intervale de lungime $\Delta = 1/M$; volatilitatea este constantă, deci randamentele intraday sunt $r_i = \sigma\sqrt{\Delta} Z_i$ cu Z_i i.i.d. $N(0,1)$, iar varianța zilnică este $IV = \sigma^2$.
- ▣ (a) Derivați media și varianța lui $RV = \sum_{i=1}^M r_i^2$, folosind $\mathbb{E}Z^2 = 1$ și $\text{Var}(Z^2) = 2$.
- ▣ (b) Arătați că cvarticitatea realizată $RQ = \frac{M}{3} \sum_i r_i^4$ este un estimator nedeplasat al lui $IQ = \sigma^4$, folosind $\mathbb{E}Z^4 = 3$.
- ▣ (c) Aplicați metoda delta pentru a obține erorile standard ale lui $\sqrt{RV}$ și $\ln RV$ și scrieți intervalul de încredere de 95% pentru IV construit pe scara log.
- ▣ (d) Calculați lățimea relativă a acestui interval pentru $M = 78$ (randamente de 5 minute într-o sesiune de 6,5 ore).
- ▣ Raportați: cele patru formule, factorul CI pentru $M = 78$ și o propoziție care explică de ce același CI rămâne valid când σ variază în cursul zilei.

A1: momentele RV și CLT fezabilă – Rezolvare [Rezolvat]

Rezolvare

- ▣ (a) Media: $\mathbb{E}[RV] = \sum_i \sigma^2 \Delta \mathbb{E}Z_i^2 = M\sigma^2/M = \sigma^2$, deci RV este nedeplasată pentru IV.
- ▣ (a) Variația: termenii sunt independenți, deci $\text{Var}(RV) = M\sigma^4\Delta^2 \text{Var}(Z^2) = M \cdot \sigma^4/M^2 \cdot 2 = 2\sigma^4/M$.
- ▣ (b) $\mathbb{E}[r_i^4] = \sigma^4\Delta^2\mathbb{E}Z^4 = 3\sigma^4/M^2$, deci $\mathbb{E}[RQ] = \frac{M}{3} \cdot M \cdot 3\sigma^4/M^2 = \sigma^4 = IQ$; prin urmare $\widehat{\text{Var}}(RV) = 2RQ/M = \frac{2}{3} \sum_i r_i^4$.
- ▣ (c) Cu $g(x) = \sqrt{x}$: $\text{se}(\sqrt{RV}) \approx \text{se}(RV)/(2\sqrt{RV})$; cu $g(x) = \ln x$: $\text{se}(\ln RV) \approx \sqrt{2RQ/M}/RV$.
- ▣ (c) CI de 95% este RV $\exp(\pm 1,96 \text{se}(\ln RV))$: este întotdeauna pozitiv și asimetric pe niveluri.
- ▣ (d) Cu volatilitate constantă $RQ/RV^2 \approx 1$, deci $\text{se}(\ln RV) \approx \sqrt{2/78} = 0,160$, iar factorul CI este $e^{\pm 0,314} = [0,73, 1,37]$.
- ▣ Interpretare: o zi de date la 5 minute permite estimarea IV cu abateri relative de aproximativ -27% și $+37\%$ față de RV; cu σ stochastic limita studentizată rămâne valabilă deoarece convergența este stabilă (Cursul 9), deci RQ poate înlocui IQ aleator.

A2: variația bipower în prezența unui salt [Propus]

Rezolvarea se discută la seminar

Cerință

- ▣ Context: variația bipower $BV = \frac{\pi}{2} \frac{M}{M-1} \sum_{i=2}^M |r_i| |r_{i-1}|$ și statistica raportului $z = \frac{(RV - BV)/RV}{\sqrt{\theta M^{-1} \max(1, TQ/BV^2)}}$, $\theta = \pi^2/4 + \pi - 5 = 0,609$ Huang & Tauchen (2005).
- ▣ (a) Presupuneți un salt de mărime κ într-un interval interior j ($1 < j < M$), deci $r_j = \kappa + r_j^c$; arătați că, la ordinul principal, saltul intră în BV doar prin cele două produse $|r_{j-1}||\kappa| + |\kappa||r_{j+1}|$ (un singur produs dacă $j = 1$ sau $j = M$), că acestea sunt $O_p(\Delta^{1/2})$, și deduceți că $BV \rightarrow IV$, iar $RV \rightarrow IV + \kappa^2$.
- ▣ (b) Pentru cele șase randamente de 5 minute (%) 0,08, -0,15, 0,03, 0,10, -0,04, -0,90 (ultimul este un salt produs de o știre), calculați RV, BV, partea de salt $RV - BV$ și ponderea ei în RV.
- ▣ (c) Calculați z cu $M = 6$ și $TQ = 0,0097$ dat, aplicând pragul $\max(1, TQ/BV^2)$, și decideți la nivelul de 0,1% (valoarea critică 3,09).
- ▣ (d) Derivați cea mai mare valoare pe care o poate lua z cu $M = 6$ și explicați ce spune aceasta despre puterea testului pe o fereastră atât de scurtă.
- ▣ Raportați: derivarea de la (a), un mic tabel cu cifrele de la (b)–(c), limita de la (d) și o propoziție de interpretare. Model: A1.

A3: deplasarea din zgomot și frecvența optimă [Rezolvat]

Cerință

- Context: logaritmii prețurilor observate sunt $p_i^{\text{obs}} = p_i^* + \varepsilon_i$, cu ε_i i.i.d. $(0, \omega^2)$ și independent de prețul eficient p^* ; o zi conține n randamente.
- (a) Scrieți randamentul observat în funcție de r_i^* și de zgomot și derivați $\mathbb{E}[\text{RV}^{(n)}] = \text{IV} + 2n\omega^2$ și $\text{cov}(r_i, r_{i-1}) = -\omega^2$.
- (b) Luați aproximarea $\text{MSE}(n) \approx 2 \text{IQ}/n + 4n^2\omega^4$ Bandi & Russell (2008) și derivați numărul de randamente optim după MSE, n^* , din condiția de ordinul întâi.
- (c) Propuneți doi estimatori consistenți pentru ω^2 și precizați limita în care fiecare este consistent.
- (d) Cu $\text{IV} = 1\%^2$, $\text{IQ} = 1$, $\omega = 0,01\%$ și o sesiune de 23 400 de secunde, calculați $\mathbb{E}[\text{RV}]$ la 5 minute, 1 minut și 1 secundă, precum și n^* cu intervalul de eșantionare corespunzător.
- Raportați: derivările, cele trei valori așteptate, n^* și ce interval ați folosi în practică și de ce.

A3: deplasarea din zgomot și frecvența optimă – Rezolvare [Rezolvat] (1/2)

Rezolvare

- (a) $r_i = r_i^* + \varepsilon_i - \varepsilon_{i-1}$; dată fiind traiectoria lui σ (derivă nulă), termenii încrucișați au media 0, deci $\mathbb{E}[r_i^2 \mid \sigma] = \mathbb{E}[r_i^{*2} \mid \sigma] + 2\omega^2$; însumând pe n randamente obținem $\mathbb{E}[\text{RV}^{(n)} \mid \sigma] = \text{IV} + 2n\omega^2$.
- (a) Randamentele alăturate au în comun doar ε_{i-1} (cu semne opuse), deci $\text{cov}(r_i, r_{i-1}) = \text{cov}(-\varepsilon_{i-1}, \varepsilon_{i-1}) = -\omega^2$.
- (b) $\frac{d}{dn} \text{MSE} = -2\text{IQ}/n^2 + 8n\omega^4 = 0$ dă $n^3 = \text{IQ}/(4\omega^4)$, adică $n^* = (\text{IQ}/(4\omega^4))^{1/3}$; derivata a doua este pozitivă, deci este un minim.
- (c) $\hat{\omega}^2 = \text{RV}^{\text{all}}/(2n)$: $\mathbb{E}[\hat{\omega}^2 \mid \sigma] = \omega^2 + \text{IV}/(2n)$, iar legea numerelor mari pentru termenii de zgomot dă $\hat{\omega}^2 \xrightarrow{P} \omega^2$ când $n \rightarrow \infty$; alternativ $-\widehat{\text{cov}}(r_i, r_{i-1})$, consistent când numărul de randamente crește.

A3: deplasarea din zgomot și frecvența optimă – Rezolvare [Rezolvat] (2/2)

Rezolvare

- (d) $\mathbb{E}[RV] = 1 + 2 \cdot 78 \cdot 0,0001 = 1,0156$ la 5 minute, 1,0780 la 1 minut ($n = 390$) și 5,6800 la 1 secundă ($n = 23\,400$): la o secundă RV este de aproape șase ori IV.
- (d) $n^* = (1/(4 \times 10^{-8}))^{1/3} = 292$, adică un randament la fiecare $23\,400/292 = 80$ de secunde.
- Interpretare: în acest model 1 minut este aproape de optim (MSE 0,0112 față de 0,0103 în n^*), în timp ce la 5 minute MSE este de 2,5 ori cea minimă (0,0259).
- Alegerea uzuală de 5 minute se sprijină pe un argument din afara acestui model: ω este incert, zgomotul real nu este i.i.d., iar RV pe 5 minute este greu de întrecut empiric [Liu, Patton & Sheppard \(2015\)](#).

A4: RV pe două scări și rata ei [Propus]

Rezolvarea se discută la seminar

Cerință

- Context: o acțiune BVB mai puțin lichidă cu $IV = 1\%^2$ și abaterea standard a zgomotului $\omega = 0,03\%$ (spread mai mare, pas de cotare mai mare); într-o zi, randamentele de 1 minut ($n = 390$) dau $RV^{all} = 1,70$, iar media pe $K = 5$ grile decalate de 5 minute este $RV^{avg} = 1,10$.
- (a) Calculați deplasarea din zgomot $2n\omega^2$ la 5 minute și la 1 minut, precum și n^* optim din A3 cu $IQ = 1$ și intervalul de eșantionare în secunde.
- (b) Calculați RV pe două scări, $TSRV = RV^{avg} - \frac{\bar{n}}{n}RV^{all}$ cu $\bar{n} = (n - K + 1)/K$, cu și fără factorul pentru eșantioane mici $1/(1 - \bar{n}/n)$, și estimați ω^2 din RV^{all} .
- (c) Arătați algebric că TSRV elimină deplasarea din zgomot la ordinul întâi.
- (d) Explicați euristic de ce eroarea TSRV este de ordinul $n^{-1/6}$ și nu $n^{-1/2}$, echilibrând cei doi termeni de varianță în funcție de K .
- Raportați: cifrele de la (a)–(b), cele două derivări și o propoziție despre când merită folosită TSRV. Model: A3.

A5: HAR ca AR(22) restricționat [Rezolvat]

Cerință

- Context: log-HAR Corsi (2009), $y_{t+1} = \beta_0 + \beta_d y_t + \beta_w \bar{y}_t^{(5)} + \beta_m \bar{y}_t^{(22)} + \varepsilon_{t+1}$, cu $y_t = \ln RV_t$, $\bar{y}_t^{(5)}$ media lui $y_t, \dots, y_{t-4}$ și $\bar{y}_t^{(22)}$ media lui $y_t, \dots, y_{t-21}$.
- (a) Scrieți coeficienții implicați $\phi_1, \dots, \phi_{22}$ ai modelului AR(22) echivalent.
- (b) Scrieți matricea de restricții R astfel încât HAR să fie $R\phi = 0$ în AR(22) cu termen liber și numărați restricțiile.
- (c) Scrieți statistica Wald cu o covarianță Newey–West (HAC) și dați distribuția ei limită sub HAR.
- (d) Pentru estimările SPY rotunjite $\hat{\beta} = (-0,08, 0,36, 0,34, 0,17)$, calculați $\phi_1, \phi_{2..5}, \phi_{6..22}$ și persistența $\sum_k \phi_k$.
- Raportați: cele trei formule, structura matricei, cifrele de la (d) și ce implică persistența pentru șocuri.

A5: HAR ca AR(22) restricționat – Rezolvare [Rezolvat]

Rezolvare

- (a) Întârzierea 1 apare în toate cele trei componente: $\phi_1 = \beta_d + \beta_w/5 + \beta_m/22$; întârzierile 2–5 în cea săptămânală și lunară: $\phi_k = \beta_w/5 + \beta_m/22$; întârzierile 6–22 doar în cea lunară: $\phi_k = \beta_m/22$.
- (b) Rândurile $e_k - e_{k+1}$ pentru $k = 2, 3, 4$ (3 rânduri: $\phi_2 = \dots = \phi_5$) și $k = 6, \dots, 21$ (16 rânduri: $\phi_6 = \dots = \phi_{22}$); cu coloana nulă a termenului liber, R are 19×23 : 22 de întârzieri minus 3 pante libere.
- (c) $W = (R\hat{\phi})^\top (R\hat{V}_{\mathbf{NW}}R^\top)^{-1}R\hat{\phi} \rightarrow \chi_{19}^2$; HAC deoarece erorile regresiei pe log RV sunt heteroscedastice și posibil autocorelate.
- (d) $\phi_1 = 0,36 + 0,34/5 + 0,17/22 = 0,436$; $\phi_{2..5} = 0,34/5 + 0,17/22 = 0,076$; $\phi_{6..22} = 0,17/22 = 0,008$; $\sum \phi_k = \beta_d + \beta_w + \beta_m = 0,87$.
- Interpretare: o persistență de 0,87 înseamnă că șocurile asupra log RV se sting lent, dar procesul este staționar; testul pe date al celor 19 restricții este B5(d).

A6: de ce QLIKE este robustă, iar MSE pe volatilitate nu [Rezolvat]

Cerință

- ▣ Context: prognoza F este evaluată față de proxy-ul RV_t , nedeplasat condiționat: $\mathbb{E}[RV_t | \mathcal{F}_{t-1}] = \mathbb{E}[IV_t | \mathcal{F}_{t-1}]$ Patton (2011); $QLIKE(RV, F) = RV/F - \ln(RV/F) - 1$.
- ▣ (a) Minimizați $\mathbb{E}[QLIKE(RV_t, F) | \mathcal{F}_{t-1}]$ în raport cu F și arătați că minimumul este în $\mathbb{E}[IV_t | \mathcal{F}_{t-1}]$, același ca pentru varianța adevărată.
- ▣ (b) Minimizați $\mathbb{E}(\sqrt{RV} - \sqrt{F})^2$ (MSE pe volatilitate) în raport cu F și folosiți inegalitatea lui Jensen pentru a compara valoarea lui F care minimizează pierderea cu $\mathbb{E}RV$.
- ▣ (c) Cu IV constantă și $RV = IV \chi_M^2/M$, calculați $F^*/IV = (\mathbb{E}\sqrt{RV})^2/IV$ pentru $M = 1$ (randamentul zilnic la pătrat), $M = 6$ și $M = 78$.
- ▣ (d) Cu varianța adevărată 1, calculați QLIKE pentru prognozele $F = 0,5$ și $F = 2,0$ și comparați-le cu valorile MSE corespunzătoare.
- ▣ Raportați: cele două condiții de ordinul întâi, cele trei rapoarte, cele două pierderi și ce funcție de pierdere ați folosi pentru a ordona prognozele de varianță.

A6: de ce QLIKE este robustă, iar MSE pe volatilitate nu – Rezolvare [Rezolvat]

Rezolvare

- (a) $\partial_F \mathbb{E}[\text{RV}/F - \ln \text{RV} + \ln F - 1] = -\mathbb{E}\text{RV}/F^2 + 1/F = 0$ dacă $F = \mathbb{E}[\text{RV} \mid \mathcal{F}_{t-1}] = \mathbb{E}[\text{IV}_t \mid \mathcal{F}_{t-1}]$; derivata a doua $2\mathbb{E}\text{RV}/F^3 - 1/F^2 = 1/F^2 > 0$ în acel punct.
- (b) $\mathbb{E}(\sqrt{\text{RV}} - \sqrt{F})^2 = \mathbb{E}\text{RV} - 2\sqrt{F} \mathbb{E}\sqrt{\text{RV}} + F$, minim în $\sqrt{F} = \mathbb{E}\sqrt{\text{RV}}$; din Jensen $(\mathbb{E}\sqrt{\text{RV}})^2 < \mathbb{E}\text{RV}$, deci prognoza optimă este deplasată în jos.
- (c) $F^*/\text{IV} = \frac{2}{M} (\Gamma(\frac{M+1}{2})/\Gamma(\frac{M}{2}))^2 = 0,637$ pentru $M = 1$, 0,920 pentru $M = 6$, 0,994 pentru $M = 78$.
- (d) QLIKE: $F = 0,5$ dă $2 - \ln 2 - 1 = 0,307$, $F = 2,0$ dă $0,5 + \ln 2 - 1 = 0,193$; MSE este 0,25 și 1, ordinea inversă.
- Interpretare: față de randamentele zilnice la pătrat, MSE pe volatilitate răsplătește o prognoză cu 36% prea mică; QLIKE păstrează ordonarea după varianța adevărată și penalizează subestimarea, ceea ce contează pentru risc.

A7: atenuarea în HAR și argumentul pentru HARQ [Propus]

Rezolvarea se discută la seminar

Cerință

- ▣ Context: $RV_t = IV_t + u_t$ cu $\mathbb{E}[u_t | \sigma] = 0$ și $\text{Var}(u_t | \sigma) = 2IQ_t/M$ (aproximarea asimptotică din CLT, A1); erorile de măsurare sunt necorelate între zile, necorelate cu IV și cu inovațiile η (momente încrucișate nule; independența completă față de IV ar contrazice o varianță care depinde de IQ_t); varianța latentă urmează $IV_{t+1} = \beta_0 + \beta IV_t + \eta_{t+1}$ cu $\beta > 0$.
- ▣ (a) Derivați limita în probabilitate a pantei OLS în regresia lui RV_{t+1} pe RV_t și arătați că este mai mică decât β .
- ▣ (b) Condiționat de IQ_t și sub ipoteza de lucru că IV_t are media μ și varianța σ_{IV}^2 care nu depind de IQ_t , derivați ponderea liniară optimă pe RV_t pentru a prezice IV_t ; arătați că scade cu IQ_t și că aceasta motivează panta HARQ $\beta_d + \beta_Q \sqrt{RQ_t}$ cu $\beta_Q < 0$ [Bollerslev, Patton & Quaedvlieg \(2016\)](#).
- ▣ (c) Propuneți un estimator prin variabile instrumentale care elimină atenuarea, numiți instrumentul și precizați ipotezele pentru validitate și relevanță.
- ▣ Raportați: formula plim, ponderea condiționată, estimatorul IV și o propoziție despre ce spune estimarea SPY a lui β_Q din B5(e). Model: A5.

A8: testul Wald comun în regresia Mincer–Zarnowitz [Propus]

Rezolvarea se discută la seminar

Cerință

- ▣ Context: Cursul 9, prognoze SPY pe o zi, ianuarie 2022 – septembrie 2026; diferența de pierdere $d_t = \text{QLIKE}(\log\text{-HAR}) - \text{QLIKE}(\text{GARCH})$ are media $\bar{d} = -0,0327$ și eroarea standard Newey–West 0,0142.
- ▣ Regresia $MZ\ RV_t = a + bF_t + u_t$ pentru GARCH dă $\hat{a} = 0,2418$ (SE 0,2310), $\hat{b} = 0,7046$ (SE 0,2382), cu corelația estimată $\text{corr}(\hat{a}, \hat{b}) = -0,9750$ (covarianță HAC); păstrați toate cele patru zecimale, deoarece cu o corelație apropiată de -1 statistica Wald este sensibilă la rotunjire.
- ▣ (a) Calculați statistica Diebold–Mariano și valoarea p bilaterală și decideți la 5%.
- ▣ (b) Calculați statisticile t separate pentru $a = 0$ și pentru $b = 1$ și decideți la 5%.
- ▣ (c) Construiți matricea de covarianță a lui $(\hat{a}, \hat{b})$ din erorile standard și corelație, calculați statistica Wald comună pentru $(a, b) = (0, 1)$ și valoarea p din χ^2_2 .
- ▣ (d) Schițați elipsa de încredere de 95% și explicați când testele separate și cel comun pot fi în dezacord. Raportați cele trei statistici, deciziile și interpretarea. Model: A6.

B1: salturi în SPY [Rezolvat] (1/2)

Cerință


- Date: bare SPY de 5 minute din sesiunea regulată din SUA, `data/market/intraday/SPY.US_5m.csv`, octombrie 2020 – septembrie 2026, 1 489 zile, 78 de randamente într-o zi completă (42 în zilele cu program redus), randamente $r_{t,i} = 100 \Delta \ln P$ în %.
- Metoda: statistica raportului z_t din [Huang & Tauchen \(2005\)](#) (foaia de formule) pentru fiecare zi, cu valori p unilaterale $p_t = 1 - \Phi(z_t)$.
- (a) Numărați zilele pentru care testul respinge ipoteza nulă la 5%, 1% și 0,1% și comparați fiecare număr cu $\alpha \times$ numărul de zile așteptat fără salturi.
- (b) În zilele cu salt la 0,1%, găsiți intervalul de 5 minute cu cel mai mare randament absolut și reprezentați histograma acestor ore.
- (c) Calculați ponderea salturilor în RV totală, $\sum_t J_t / \sum_t RV_t$, cu $J_t = RV_t - BV_t$ în zilele cu salt la 0,1% și 0 în rest.

B1: salturi în SPY [Rezolvat] (2/2)

Cerință (continuare)

- (d) Aplicați Benjamini–Hochberg la o rată a descoperirilor false de 5% și 1% Benjamini & Hochberg (1995) și Bonferroni la 5% ($p_t < 0,05/N$) pe cele N valori p zilnice; numărați zilele cu salt în fiecare caz (BH controlează FDR pentru valori p valide, independente sau pozitiv dependente Benjamini & Yekutieli (2001)).
- (e) Împărțiți fiecare randament la factorul de periodicitate intraday f_i (estimatorul abaterii standard din Boudt, Croux & Laurent (2011), randamentele fiind întâi scalate cu $\sqrt{BV_t/M_t}$) și repetați (a) și (d).
- Raportați: un tabel cu numărul de respingeri (brut, FDR, Bonferroni, cu și fără periodicitate), histograma și ponderea salturilor.
- Interpretare: sunt mai multe respingeri decât ar produce nivelul singur? Indică orele salturilor știri programate? Ce criteriu de identificare a zilelor cu salt ați folosi pentru a construi un regresor de salt?

B1: salturi în SPY – Rezolvare [Rezolvat] (1/2)



Rezolvare

- (a) Respingeri: 235 la 5% (așteptat 74,5), 110 la 1% (așteptat 14,9), 35 la 0,1% (așteptat 1,5); media lui z_t este 0,50, iar abaterea standard 1,14, în loc de 0 și 1.
- (b) Zilele cu cele mai mari valori ale statisticii: 2021-08-27 ($z = 5,22$, saltul 49% din RV, intervalul care se încheie la 10:05), 2022-01-03 ($z = 5,21$, la 09:50), 2025-08-25 ($z = 4,77$, la 16:00); histograma are vârful după deschidere.
- (c) Cu zilele cu salt la 0,1%, componenta de salt reprezintă 2,8% din RV totală.

B1: salturi în SPY – Rezolvare [Rezolvat] (2/2)

Rezolvare

- (d) FDR 5%: 42 zile cu salt; FDR 1%: 9; Bonferroni 5%: 7.
- (e) Cu randamentele corectate de periodicitate: 167 respingeri la 5%, 20 la 0,1% și 17 sub FDR 5%.
- Interpretare: numerele brute depășesc mult α/N din cauza salturilor reale și pentru că forma de U face randamentele alăturate inegale, ceea ce deplasează BV în jos; după controlul FDR și corecția de periodicitate rămân doar 17 zile.
- Decizie: construim regresorul de salt din zilele cu control FDR și corecție de periodicitate; cele mai mari dintre cele rămase indică știri programate, de ex. 2021-08-27 la 10:00–10:05, când a fost publicat discursul președintelui Rezervei Federale de la Jackson Hole.

B2: salturi în Bitcoin [Propus]

Rezolvarea se discută la seminar

Cerință

- Date: bare Bitcoin de 5 minute, `data/market/intraday/BTC-USD.CC_5m.csv`, zile UTC de 24 de ore cu cel puțin 95% din bare, septembrie 2024 – septembrie 2026, 659 zile, 288 de randamente pe zi.
- (a) Aplicați testul raportului din B1 la 0,1% fiecărei zile, numărați zilele cu salt și testați cu un test binomial unilateral dacă ponderea lor depășește nivelul 0,001 (testul tratează respingerile zilnice ca extrageri Bernoulli(0,001) independente sub ipoteza nulă).
- (b) Împărțiți zilele în weekend și zile lucrătoare și comparați ponderea zilelor cu salt și media raportului BV/RV în cele două grupuri.
- (c) Calculați ponderea salturilor în variația totală, ca la B1(c).
- Raportați: numărul de zile, valoarea p binomială, tabelul weekend/zile lucrătoare și ponderea salturilor.
- Interpretare: de ce sunt zilele cu salt mai frecvente decât la SPY, în timp ce salturile aduc mai puțină varianță? Ce face o zi liniștită de weekend să pară „cu salturi”? Ați modela împreună weekendurile și zilele lucrătoare? Model: B1.

B3: ce frecvență de eșantionare? [Rezolvat] (1/2)

Cerință


- Date: bare SPY de 5 minute din sesiunea regulată din SUA, `data/market/intraday/SPY.US_5m.csv`, octombrie 2020 – septembrie 2026, 1 489 zile, 78 de randamente într-o zi completă (42 în zilele cu program redus), randamente $r_{t,i} = 100 \Delta \ln P$ în %.
- (a) Calculați RV zilnică din randamente la fiecare 5, 15, 30 și 65 de minute, atât pe o singură grilă, cât și ca medie pe toate grilele decalate (subeșantionare), și raportați volatilitatea anualizată din RV medie, $\sqrt{252 \overline{RV}}$.
- (b) Pentru fiecare frecvență, calculați raportul dintre RV medie și RV medie pe 5 minute și un CI de 95% prin bootstrap pe blocuri mobile [Künsch \(1989\)](#) (blocuri de 20 de zile, 2 000 de reeșantionări).
- (c) Calculați corelația dintre log RV de azi la fiecare frecvență și log RV pe 5 minute de mâine.
- (d) Calculați nucleul realizat Parzen [Barndorff-Nielsen et al. \(2008\)](#) pe randamentele de 5 minute și raportul dintre media lui și media RV, cu același bootstrap; datele cursului sunt bare de 5 minute, deci estimatorii pe 1 minut sau tick cu tick sunt o extensie de proiect.

B3: ce frecvență de eșantionare? [Rezolvat] (2/2)

Cerință (continuare)

- Raportați: un tabel cu volatilitatea, raportul [CI] și corelația predictivă pe frecvențe, raportul nucleului [CI] și o histogramă a lui $\ln(RV^{(k)}/RV^{(5)})$.
- Interpretare: există o deplasare din zgomot măsurabilă la 5 minute? De ce bootstrap pe blocuri și nu i.i.d.? Ce frecvență dă măsurarea cea mai utilă pentru prognoză?

B3: ce frecvență de eșantionare? – Rezolvare [Rezolvat]



Interval	Vol. (o grilă)	Vol. (media grilelor)	Raport [CI 95%]	Corel. ziua următoare	Corel. (media grilelor)
5 min	12,93	12,93	1,000 [1,000, 1,000]	0,73	0,73
15 min	12,88	12,79	0,992 [0,954, 1,035]	0,71	0,72
30 min	12,75	12,77	0,973 [0,933, 1,015]	0,70	0,72
65 min	12,76	12,88	0,974 [0,913, 1,037]	0,64	0,70

Rezolvare

- Procedura: construim grila de prețuri pe zile, calculăm RV pe fiecare grilă, facem media pe grilele decalate, reeșantionăm blocuri de 20 de zile ale seriilor zilnice pereche, recalculăm raportul mediilor în fiecare reeșantionare și luăm percentile de 2,5% și 97,5%.

B3: ce frecvență de eșantionare? (interpretare) – Rezolvare [Rezolvat]

Rezolvare

- (a)–(b) Toate intervalele conțin 1, deci nu există o deplasare din zgomot măsurabilă pentru SPY la 5 minute, în acord cu graficul de semnătură plat.
- Bootstrap pe blocuri: RV zilnice sunt puternic autocorelate; reeșantionarea i.i.d. ar distruge această dependență și ar face CI prea îngust.
- (c) Corelația predictivă scade de la 0,73 (5 min) la 0,64 (65 min, o grilă): RV rară este mai zgomotoasă; media pe grilele decalate recuperează o parte (0,70).
- (d) Nucleu / $RV = 0,952$ cu CI $[0,910, 0,987]$ (lățimea mediană $H = 7$): nucleul adaugă autocorelațiile negative mici la 5–35 de minute ($\hat{\rho}_1 = -0,008$); semnificativ, dar mic economic.
- Răspuns: RV pe 5 minute este măsurarea cea mai utilă aici; estimatorii robuști la zgomot aduc câștig când zgomotul este mare față de semnal (date tick cu tick sau la nivel de secundă, acțiuni nelichide).

B4: randamente standardizate cu volatilitatea realizată [Propus]

Rezolvarea se discută la seminar

Cerință

- Date: randamentele SPY deschidere-închidere (1 489 zile, 2020–2026) și randamentele Bitcoin pe 24 de ore (659 zile, 2024–2026), cu RV din aceeași zi din bare de 5 minute Andersen et al. (2001).
- (a) Calculați aplatizarea lui $u_t = r_t/\text{sd}(r)$ și a lui $z_t = r_t/\sqrt{\text{RV}_t}$, fiecare cu un CI de 95% prin bootstrap pe blocuri mobile (blocuri de 20 de zile, 2 000 de reeșantionări).
- (b) Aplicați testul Jarque–Bera pe z_t și decideți la 5%; precizați că distribuția sa de referință χ^2_2 presupune date i.i.d.
- (c) Calculați ponderea $|z_t| > 3$ și comparați-o cu valoarea corespunzătoare distribuției Normale, 0,27%.
- Raportați: un tabel cu aplatizarea [CI] pentru u și z , JB (p) și ponderea din coadă pentru ambele active.
- Interpretare: de unde provin cozile grele ale randamentelor zilnice? De ce este aplatizarea lui z_t ușor sub 3? Ce implică aceasta pentru un model VaR (Capitolul 7)? Model: B3.

B5: log-HAR pentru SPY cu inferență robustă [Rezolvat] (1/2)

Cerință

- Date: varianța zilnică totală SPY $RV_t + r_{\text{noapte},t}^2$ (RV pe 5 minute plus pătratul randamentului închidere-deschidere), 1 467 zile după prima lună [Corsi \(2009\)](#).
- (a) Estimați log-HAR prin OLS pe întregul eșantion și raportați erorile standard obișnuite și Newey–West cu 7 întârzieri (regula $\lfloor 4(T/100)^{2/9} \rfloor$).
- (b) Testați $\beta_w = \beta_m$ cu un test Wald folosind covarianța NW.
- (c) Aplicați testul Ljung–Box cu 22 de întârzieri pe reziduuri și pe log RV însăși și comparați R^2 cu un AR(1).
- (d) Estimați AR(22) nerestricționat și testați cele 19 restricții HAR din A5 cu un test Wald NW.

B5: log-HAR pentru SPY cu inferență robustă [Rezolvat] (2/2)

Cerință (continuare)

- (e) Estimați HARQ pe niveluri Bollerslev, Patton & Quaedvlieg (2016),
$$RV_{t+1} = \beta_0 + (\beta_d + \beta_Q \sqrt{RQ_t})RV_t + \beta_w RV_t^{(w)} + \beta_m RV_t^{(m)} + \varepsilon$$
, pe RV intraday și pe varianța totală; apoi realizați prognoze începând din ianuarie 2022, pe o fereastră de estimare care se extinde zilnic (prognozele din afara intervalului din eșantion înlocuite cu media) și aplicați un test DM față de HAR pe niveluri după QLIKE.
- Raportați: tabelul coeficienților cu ambele SE, statisticile Wald, Ljung–Box și AR(22) cu valorile p , $\hat{\beta}_Q$ cu SE și rezultatul DM.
- Interpretare: care componentă contează cel mai mult? Schimbă erorile standard robuste vreo concluzie? A surprins HAR memoria lungă? Aduce corecția erorii de măsurare câștig în afara eșantionului?

B5: log-HAR pentru SPY cu inferență robustă – Rezolvare [Rezolvat]

	$\hat{\beta}$	SE OLS	SE NW	t_{NW}
β_o	-0,079	0,025	0,027	-3,0
β_d	0,362	0,031	0,037	9,8
β_w	0,337	0,049	0,048	7,0
β_m	0,167	0,046	0,044	3,8

Rezolvare

- (a) Toate pantele sunt semnificative cu erori NW ($t = 9,8, 7,0, 3,8$); erorile NW sunt cu până la 20% mai mari decât cele OLS, dar nicio concluzie nu se schimbă; $R^2 = 0,470$ față de 0,413 pentru un AR(1) ($\hat{\phi} = 0,643$); persistența 0,866.
- (b) Wald $\beta_w = \beta_m$: 4,17, $p = 0,041$: respinsă la 5%, ponderea săptămânală este mai mare.
- (c) Ljung–Box(22): log RV 4641, reziduuri 17,5 ($p = 0,73$): trei coeficienți absorb memoria lungă.

B5: log-HAR pentru SPY cu inferență robustă (extensii) – Rezolvare [Rezolvat]

Rezolvare

- (d) $W = 18,1$, $p = 0,51$ (χ^2_{19}); R^2 0,477 (AR(22)) vs 0,470 (HAR): cele 19 restricții nu sunt respinse, deci HAR nu pierde aproape nimic și economisește 19 parametri.
- (e) $\hat{\beta}_Q = -0,0088$ (SE 0,0042) pe RV intraday, semnificativ la 5%; $-0,0022$ (SE 0,0024) pe varianța totală, nesemnificativ.
- (e) În afara eșantionului: QLIKE 0,344 (HARQ) vs 0,326 (HAR), DM $t = 1,23$, $p = 0,22$: nicio diferență semnificativă.
- Interpretare: semnul prezis de A7 apare, dar cu RV pe 5 minute eroarea de măsurare este mică, iar randamentul peste noapte (neacoperit de RQ) domină zgomotul din varianța totală, deci HARQ nu aduce câștig de prognoză aici.

B6: prognoza săptămânii următoare [Propus]

Rezolvarea se discută la seminar

Cerință

- Date: varianța zilnică totală SPY (ca la B5) și închiderile zilnice ajustate SPY din 2000 pentru GARCH; ținta $Y_t = \sum_{j=0}^4 RV_{t+j}$, prognozată în seara dinaintea lui t , din ianuarie 2022 (1 176 prognoze).
- (a) Prognozați Y_t cu o regresie log-HAR directă a lui $\ln Y$ pe regresorii HAR, reestimată zilnic pe o fereastră extinsă folosind doar ținte complet observate; adăugați $\hat{s}^2/2$ înainte de exponențiere (aproximare lognormală; factorul de smearing din [Duan \(1983\)](#) este alternativa care nu presupune o distribuție).
- (b) Prognozați Y_t cu GARCH(1,1)- t (reestimat la fiecare 21 de zile): $\sum_{h=0}^4 [\bar{\sigma}^2 + (\alpha + \beta)^h (\sigma_t^2 - \bar{\sigma}^2)]$.
- (c) Calculați QLIKE și MSE, un test DM pe QLIKE cu erori HAC și regresiile MZ cu testul Wald comun pentru $(a, b) = (0, 1)$.
- (d) Aplicați testul condiționat Giacomini–White [Giacomini & White \(2006\)](#) cu instrumentele $(1, d_{t-5})$; teoria lui cere ferestre de estimare de lungime fixă, deci reestimați ambele metode pe ferestre mobile (log-HAR: ultimele 250 ținte; GARCH: ultimele 1 000 randamente); sub ipoteza nulă $Z_t d_{t+5}$ este necorelat dincolo de întârzierea 4, deci folosiți autocovarianțele neponderate de ordinele 0–4.
- Raportați pierderile, statisticile de test și valorile p . Interpretare: se păstrează avantajul log-HAR la un orizont săptămânal, ce efect au țintele suprapuse asupra testului DM și care model este deplasat? Model: B5, A8.

B7: ajută salturile? Modelul HAR-CJ [Propus]

Rezolvarea se discută la seminar

Cerință

- Date: SPY ca la B5; partea continuă $C_t = RV$ fără salturile semnificative din B1 (0,1%) plus pătratul randamentului peste noapte (o convenție de modelare: mișcarea de peste noapte nu este descompusă în parte continuă și parte de salt); partea de salt J_t Andersen, Bollerslev & Diebold (2007).
- (a) Estimați specificația pe log din Andersen, Bollerslev & Diebold (2007): ln din varianța totală a zilei $t + 1$ pe $\ln C_t$, $\ln C_t^{(w)}$, $\ln C_t^{(m)}$ și $\ln(1 + J_t)$, $\ln(1 + J_t^{(w)})$, $\ln(1 + J_t^{(m)})$ (medii aritmetice pe 5 și 22 de zile, logaritmuate după mediere), cu SE Newey–West; testați $\beta_{Jd} = \beta_{Jw} = \beta_{Jm} = 0$ la 5%.
- (b) Realizați prognoze începând din ianuarie 2022, pe o fereastră de estimare care se extinde zilnic, și comparați pierderile QLIKE ale HAR-CJ și log-HAR printr-un test DM.
- Raportați: coeficienții cu SE, cele două R^2 , cele două valori QLIKE și statistica DM.
- Interpretare: este coeficientul salturilor semnificativ și ce semn vă așteptați să aibă? De ce un coeficient semnificativ poate să nu aducă niciun câștig de prognoză? Model: B5, B1.

B8: cât de aspră este volatilitatea? [Propus]

Rezolvarea se discută la seminar

Cerință

- Date: serii zilnice SPY 2020–2026 pentru patru măsuri: varianța totală, RV intraday, BV și RV subeșantionată la 30 de minute; $\ln \sigma_t = \frac{1}{2} \ln(\text{măsura})$ Gatheral, Jaisson & Rosenbaum (2018).
- (a) Estimați H din legea de scalare $m(q, \Delta) \propto \Delta^{qH}$ cu $q \in \{0,5, 1, 1,5, 2, 3\}$ și $\Delta = 1, \dots, 30$ de zile: panta ζ_q pentru fiecare q , apoi H ca panta lui ζ_q față de q .
- (b) Construiți un CI de 95% pentru fiecare $\hat{H}$ prin bootstrap pe blocuri mobile (blocuri de 60 de zile, 300 de reeșantionări), calculând incrementele doar în interiorul fiecărui bloc reeșantionat, astfel încât niciun increment să nu treacă peste o îmbinare artificială.
- (c) Simulați un mers aleator Gaussian de aceeași lungime (incremente $N(0, 0,1^2)$, valoarea de inițializare 42 a generatorului aleator), scădeți dreapta care îi unește capetele (o punte browniană, tot cu $H = 0,5$), estimați H , apoi adăugați zgomot i.i.d. $N(0, 0,25^2)$ și estimați din nou; o singură traiectorie, o ilustrare, nu un studiu Monte Carlo.
- Raportați tabelul $\hat{H}$ [CI] și cele două estimări simulate. Interpretare: este H sub 0,5 pentru fiecare măsură și ce efect are eroarea de măsurare asupra lui $\hat{H}$? Model: B3.

B9: ce modele supraviețuiesc? Mulțimea de încredere a modelelor [Propus]

Rezolvarea se discută la seminar

Cerință

- Date: prognoze SPY pe o zi ale varianței totale, ianuarie 2022 – septembrie 2026 (1 180 zile), din log-HAR, HAR, GARCH(1,1)-t, EWMA și RV de ieri (Cursul 9).
- (a) Adăugați HARQ (B5(e)) și SHAR [Patton & Sheppard \(2015\)](#): înlocuiți $\beta_d RV_t$ cu $\beta^+ RS_t^+ + \beta^- RS_t^-$, cu semivarianțele $RS_t^\pm = \sum_i r_{t,i}^2 1\{r_{t,i} \gtrless 0\}$ și randamentul peste noapte socotit ca încă un randament; estimați pe niveluri, pe o fereastră extinsă.
- (b) Calculați QLIKE medie pentru cele șapte modele.
- (c) Calculați mulțimea de încredere a modelelor la 90% [Hansen, Lunde & Nason \(2011\)](#) cu statistica amplitudinii și bootstrap pe blocuri (blocuri de 20 de zile, 10 000 de reeșantionări) și raportați valoarea p MCS a fiecărui model.
- Raportați tabelul. Interpretare: câte modele supraviețuiesc, se schimbă răspunsul la 75% și de ce este MCS preferabilă celor 21 de teste DM pe perechi? Model: B5, B6.

C1: este volatilitatea Bitcoin mai previzibilă decât cea a S&P 500? [Propus]

Rezolvarea se discută la seminar

Cerință

- Date: aceeași fereastră în afara eșantionului pentru ambele active, martie 2025 – septembrie 2026: varianța totală SPY (389 zile) și RV Bitcoin pe 24 de ore (422 zile), cu prognozele log-HAR, GARCH(1,1)-t și RV de ieri din Cursul 9.
- (a) Definiți „previzibil” prin trei măsuri și calculați-le: R^2 al log RV pe prognoza log, câștigul QLIKE al log-HAR față de RV de ieri și câștigul față de GARCH.
- (b) Construiți un CI de 95% pentru diferența de R^2 (Bitcoin minus SPY) prin bootstrap pe blocuri mobile în timp calendaristic: aceleași blocuri de 28 de zile calendaristice (aproximativ 20 de zile de tranzacționare SPY) pentru ambele active, 2 000 de reeșantionări, astfel încât să se păstreze dependența dintre ele.
- (c) Adăugați o variabilă de weekend în log-HAR pentru Bitcoin (ce ați aflat la B2), prognozați din nou și aplicați un test DM după QLIKE cu și fără variabilă.
- Raportați tabelul, CI și rezultatul DM și răspundeți la întrebare în două propoziții. Extensie de proiect: adăugați Ethereum sau o acțiune BVB și măsura de entropie din [Pele & Mazurencu-Marinescu-Pele \(2019\)](#) ca regresor.

C2: critica unui răspuns AI (1/3) [Propus]

Rezolvarea se discută la seminar

Studentul întreabă un asistent AI

- „Am prețurile tranzacțiilor SPY, fiecare tranzacție între 09:30 și 16:00, într-o serie pandas `px` cu index de timp. Calculează varianța realizată zilnică, volatilitatea anualizată și regresorii HAR.”

Răspunsul AI: text

- $RV_t = \sum_i r_{t,i}^2$, cu $r_{t,i}$ randamentele log intraday din ziua t Andersen et al. (2001)
- Folosiți fiecare tranzacție: mai multe randamente fac întotdeauna RV_t mai precisă
- RV_t este varianța zilnică a SPY: comparați-o direct cu pătratul randamentelor de la o închidere la alta și cu varianța GARCH
- HAR: regresia lui RV_{t+1} pe RV_t și pe mediile lui pe 5 și pe 22 de zile Corsi (2009)

C2: critica unui răspuns AI (2/3) [Propus]

Rezolvarea se discută la seminar

Răspunsul AI: codul primit împreună cu textul

```
import numpy as np, pandas as pd
lp = np.log(px)
r = lp.groupby(lp.index.date).diff().dropna()
RV = (r**2).groupby(r.index.date).sum()
vol_ann = np.sqrt(RV) * 252
H = pd.DataFrame({'d': RV,
                  'w': RV.rolling(5).mean(),
                  'm': RV.rolling(22).mean(),
                  'y': RV.shift(-1)}).dropna()
```

C2: critica unui răspuns AI (3/3) [Propus]

Rezolvarea se discută la seminar

Cerință

- ▣ Răspunsul conține trei erori; restul este corect: găsiți-le
- ▣ Pentru fiecare eroare, spuneți cum ați detecta-o: un test, o cifră publicată, cursul
- ▣ Dați varianta corectă: formula, linia de cod și cifra
- ▣ Consemnați fiecare eroare ca în `AI_ERRORS.md`
 - ▶ Ce ați întrebat, ce a răspuns AI-ul, ce era greșit, cum v-ați dat seama, varianta corectă

Indicații

- ▣ Ce spune A3 despre $\mathbb{E}[RV^{(n)}]$ când prețurile conțin zgomot?
- ▣ Ce se întâmplă cu SPY între 16:00 și 09:30 a doua zi?
- ▣ Introduceți în formulă valoarea pentru o zi obișnuită, $RV_t = 1,0 \times 10^{-4}$ (1%²): este plauzibilă volatilitatea anualizată pentru SPY?

C3: învățarea automată sau HAR pentru SPY? [Propus] (1/3)

Rezolvarea se discută la seminar

Cerință

- Context: Christensen, Siggaard & Veliyev (2023) arată că pădurile aleatoare și rețelele neuronale întrec HAR când se adaugă predictorii la valorile trecute ale RV și că avantajul crește odată cu orizontul de prognoză (Cursul 9, studiul de caz). Testați acest rezultat pe SPY, cu împărțirea eșantionului și setările modelelor din lucrare.
- (a) Construiți RV zilnică SPY de la deschidere la închidere din barele de 5 minute ale sesiunii obișnuite de tranzacționare (78 de randamente pe zi, ca la B1) și trei ținte: RV_{t+1} , media RV pe următoarele 5 zile și media pe următoarele 22 de zile (Secțiunea 4 a lucrării).
- (b) Construiți două seturi de predictorii disponibili la momentul t : $\mathcal{M}_{\text{HAR}}$ cu RV zilnică, săptămânală și lunară și $\mathcal{M}_{\text{ALL}}$, care adaugă VIX, pătratul randamentului log zilnic al indicelui Hang Seng (ambele în data/market), momentumul SPY pe o săptămână, diferența de ordinul întâi a logaritmului volumului în dolari, diferența de ordinul întâi a ratei titlurilor de stat la 3 luni (FRED, DTB3), indicele zilnic al incertitudinii politicii economice (FRED, USEPUINXD) și indicele condițiilor de afaceri Aruoba–Diebold–Scotti (Federal Reserve Bank of Philadelphia). Datați fiecare predictor după data publicării, nu după data la care se referă: folosiți doar valorile publicate până la închiderea zilei t (pentru indicele Aruoba–Diebold–Scotti, care este revizuit, versiunile în timp real ale Philadelphia Fed) și precizați seriile pentru care aceste versiuni nu sunt disponibile.
- Precizați care dintre predictorii lucrării (Tabelul 1) nu pot fi construiți pentru un fond indexat și de ce: aceasta este o limitare a datelor, nu un motiv pentru a schimba metoda.

C3: învățarea automată sau HAR pentru SPY? [Propus] (2/3)

Rezolvarea se discută la seminar

Cerință (continuare)

- (c) Împărțiți eșantionul ca în Anexa A.1 a lucrării: primele 1 000 de zile utilizabile pentru antrenare, următoarele 200 pentru validare, restul pentru test; un rând aparține unui subset doar dacă întreaga fereastră a țintei se află în acel subset (eliminați ultimele $h - 1$ rânduri dinaintea fiecărei granițe) și raportați numărul de observații utilizabile pentru fiecare orizont; standardizați fiecare predictor doar cu media și varianța din setul de antrenare.
- (d) Estimați HAR, log-HAR (proгноza $\exp(\hat{f} + \hat{\sigma}^2/2)$) și OLS pe toți predictorii pe o fereastră mobilă care reunește seturile de antrenare și validare; elastic net pe o fereastră mobilă de antrenare, fără reunire, cu λ și ponderea de combinare alese pe setul de validare (Secțiunea 2); o pădure aleatoare cu 500 de arbori pe fereastra reunită, $\lfloor J/3 \rfloor$ predictorii candidați la fiecare ramificare (J : numărul de predictorii) și cel puțin 5 observații într-un nod (Tabelul A.6); și NN_2^{10} : straturi de 4 și 2 neuroni, leaky ReLU, Adam cu rata de învățare 0,001, dropout 0,8, oprire timpurie după 100 de epoci fără îmbunătățirea erorii pe setul de validare, media celor mai bune 10 din 100 de inițializări, antrenată o singură dată pe o fereastră fixă (celelalte setări ca în Tabelul A.6). HAR își păstrează cei trei regresori RV în ambele mulțimi de informații. Înlocuiți prognozele negative cu cea mai mică RV din eșantion.

C3: învățarea automată sau HAR pentru SPY? [Propus] (3/3)

Rezolvarea se discută la seminar

Cerință (continuare)

- (e) Raportați un tabel cu MSE și QLIKE pe setul de test, relative la HAR, pentru cele trei orizonturi și ambele mulțimi de informații, valorile p ale testului DM unilateral față de HAR (erori HAC pentru țintele suprapuse de 5 și 22 de zile, cu o lățime de bandă mai mare decât $h - 1$, deoarece ponderile Bartlett micșorează întârzierea $h - 1$, și o analiză de sensibilitate după lățimea de bandă) și MCS de 90%, ca la B9.
- Interpretare: se păstrează clasamentul din Tabelele 2, 3 și 7 ale lucrării pe SPY, crește avantajul ML cu orizontul și se păstrează după QLIKE? Cu un set de test de această lungime, ce vă poate spune un test DM nesemnificativ? Model: B5, A6.
- Extensie de proiect: repetați pe RV Bitcoin pe 24 de ore și comparați între modele importanța RV și a VIX, măsurată prin efectele locale acumulate (Figura 7 a lucrării).

Greșeli frecvente

- ▣ Eșantionarea fiecărei tranzacții fără a verifica graficul semnăturii
- ▣ Omiterea randamentului peste noapte: RV intraday subestimează varianța zilnică SPY cu aproximativ o treime
- ▣ Tratarea RV ca varianță adevărată: are o eroare standard și face ca R^2 al prognozelor să pară mic
- ▣ Compararea prognozelor de volatilitate cu MAE sau cu MSE pe volatilitate: nu sunt robuste la proxy-ul zgomotos
- ▣ Erori standard OLS obișnuite în HAR și bootstrap i.i.d. pentru RV zilnică: ambele ignoră autocorelația
- ▣ Citirea oricărui test de salt semnificativ ca un salt produs de știri: mii de teste dau alarme false

Temă pentru acasă (proiect de echipă)

- ▣ Alegeți un activ cu date intraday nediscutat la seminar (Ethereum, o pereche valutară, o acțiune)
- ▣ Construiți RV, BV și o componentă de salt zilnice; arătați graficul semnăturii și tiparul intraday
- ▣ Comparați log-HAR (cu cel puțin o extensie) și GARCH în afara eșantionului cu QLIKE, DM și MZ
- ▣ Livrați un folder Quantlet (cod, Metainfo, grafice) și trei slide-uri: cifre, interpretare, limite
- ▣ Consemnați fiecare eroare AI pe care o identificați (cel puțin trei pe proiect) în `AI_ERRORS.md` și declarați folosirea AI în `AI_USE.md`

Studiu suplimentar pe Quantinar

Cursuri avansate pe quantinar.com

- ☐  Nonparametric and Semiparametric Models
- ☐  Applied Time Series Analysis with Python

Cod și date

- ☐ Notebook-ul seminarului (Colab); Quantlets: github.com/danpele/MFM/tree/main/Quantlets/Ch_09

Bibliografie

- ▣ Andersen, T.G., Bollerslev, T., Diebold, F.X. (2007). [Roughing it up: including jump components in the measurement, modeling, and forecasting of return volatility](#). *Review of Economics and Statistics*, 89(4), 701–720.
- ▣ Andersen, T.G., Bollerslev, T., Diebold, F.X., Labys, P. (2001). [The distribution of realized exchange rate volatility](#). *Journal of the American Statistical Association*, 96(453), 42–55.
- ▣ Bandi, F.M., Russell, J.R. (2008). [Microstructure noise, realized variance, and optimal sampling](#). *Review of Economic Studies*, 75(2), 339–369.
- ▣ Barndorff-Nielsen, O.E., Shephard, N. (2004). [Power and bipower variation with stochastic volatility and jumps](#). *Journal of Financial Econometrics*, 2(1), 1–37.
- ▣ Christensen, K., Siggaard, M., Veliyev, B. (2023). [A machine learning approach to volatility forecasting](#). *Journal of Financial Econometrics*, 21(5), 1680–1727.
- ▣ Corsi, F. (2009). [A simple approximate long-memory model of realized volatility](#). *Journal of Financial Econometrics*, 7(2), 174–196.
- ▣ Diebold, F.X., Mariano, R.S. (1995). [Comparing predictive accuracy](#). *Journal of Business & Economic Statistics*, 13(3), 253–263.
- ▣ Franke, J., Härdle, W.K., Hafner, C.M. (2019). [Statistics of Financial Markets: An Introduction](#), 5th ed. Springer.
- ▣ Gatheral, J., Jaisson, T., Rosenbaum, M. (2018). [Volatility is rough](#). *Quantitative Finance*, 18(6), 933–949.
- ▣ Huang, X., Tauchen, G. (2005). [The relative contribution of jumps to total price variance](#). *Journal of Financial Econometrics*, 3(4), 456–499.
- ▣ Künsch, H.R. (1989). [The jackknife and the bootstrap for general stationary observations](#). *Annals of Statistics*, 17(3), 1217–1241.
- ▣ Patton, A.J. (2011). [Volatility forecast comparison using imperfect volatility proxies](#). *Journal of Econometrics*, 160(1), 246–256.
- ▣ Pele, D.T., Mazurencu-Marinescu-Pele, M. (2019). [Using high-frequency entropy to forecast Bitcoin's daily value at risk](#). *Entropy*, 21(2), 102.
- ▣ Zhang, L., Mykland, P.A., Aït-Sahalia, Y. (2005). [A tale of two time scales: determining integrated volatility with noisy high-frequency data](#). *Journal of the American Statistical Association*, 100(472), 1394–1411.