



Modelarea piețelor financiare

Seminarul 9: Volatilitate realizată — aplicații



Daniel Traian PELE

Drd. Antoaneta Amza, antoaneta.amza@csie.ase.ro

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

Acronime folosite în acest material (1/2)

- AI: Artificial Intelligence (inteligență artificială)
- AR: AutoRegressive (model); in event studies: Abnormal Return (model autoregresiv; în studiile de eveniment: randament anormal)
- BH: Benjamini–Hochberg (procedure) (procedura Benjamini–Hochberg)
- BV: Bipower Variation (variația bipower)
- BVB: Bursa de Valori București
- CI: Confidence Interval (interval de încredere)
- DM: Diebold–Mariano (test) (testul Diebold–Mariano de comparare a prognozelor)
- EWMA: Exponentially Weighted Moving Average (medie mobilă ponderată exponențial)
- FDR: False Discovery Rate (rata descoperirilor false)
- FRED: Federal Reserve Economic Data (baza de date economice a Rezervei Federale (St. Louis))
- GARCH: Generalised AutoRegressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă generalizată)
- HAC: Heteroskedasticity and Autocorrelation Consistent (standard errors) (erori standard robuste la heteroscedasticitate și autocorelație)
- HAR: Heterogeneous AutoRegressive (model) (model autoregresiv heterogen)
- HAR-CJ: HAR model with Continuous and Jump components (model HAR cu componentă continuă și componentă de salt)
- HARQ: HAR model with Realised Quarticity (model HAR cu cvarticitatea realizată)
- IQ: Integrated Quarticity (cvarticitatea integrată)
- JB: Jarque–Bera (test) (testul de normalitate Jarque–Bera)
- MCS: Model Confidence Set (mulțimea de încredere a modelelor)
- ML: Machine Learning (învățare automată)
- MSE: Mean Squared Error (eroarea pătratică medie)
- MZ: Mincer–Zarnowitz (regression) (regresia Mincer–Zarnowitz)
- NW: Newey–West (standard errors) (erori standard Newey–West)
- OLS: Ordinary Least Squares (metoda celor mai mici pătrate)
- QLIKE: Quasi-LIKelihood (loss function) (funcția de pierdere de tip cvasi-verosimilitate)
- QQ: Quantile–Quantile (plot) (graficul cuantilă–cuantilă)
- RF: Random Forest (pădure aleatoare)

Acronime folosite în acest material (2/2)

- ▣ RQ: Realised Quarticity (cvarticitatea realizată)
- ▣ RV: Realised Variance (varianța realizată)
- ▣ SE: Standard Error (eroare standard)
- ▣ SHAR: Semivariance HAR model (model HAR cu semivarianțe)
- ▣ TQ: Tripower Quarticity (cvarticitatea tripower)
- ▣ TSRV: Two-Scale Realised Variance (varianța realizată pe două scări)
- ▣ UTC: Coordinated Universal Time (Temps Universel Coordonné)
(timpul universal coordonat)
- ▣ VIX: CBOE Volatility Index (indicele de volatilitate CBOE)

Întrebările de azi și traseul

- ▣ Întrebările seminarului
 - ▶ **cît de precis măsoară prețurile intraday dintr-o zi volatilitatea?**
 - ▶ **îmbunătățește această măsurare o prognoză?**
- ▣ Traseul seminarului
 - ▶ Ce vă trebuie azi din [Capitolul 9](#) (cursul vine după acest seminar): RV, zgomot, salturi, HAR, evaluarea prognozelor
 - ▶ Partea I, măsurare și diagnostic: A1 precizia RV, A3 zgomot și eşantionare, B3 grile de eşantionare pe SPY, B1 zile cu salt pentru SPY, A2 un salt în şase randamente
 - ▶ Partea a II-a, modele şi prognoze: A5 HAR ca AR(22) restricţionat, B5 log-HAR cu inferenţă robustă, A6 funcţii de pierdere, evaluarea prognozelor, A8 acurateţe versus calibrare, C2 un răspuns AI
- ▣ Ce realizați: răspunsurile A, cîte un grafic şi un tabel pentru fiecare exerciţiu B, tabelul de corecţii C2, cîte o frază de interpretare pentru fiecare exerciţiu
- ▣ Notebook-ul de azi: [deschideți notebook-ul seminarului în Colab](#); fiecare cerinţă indică secţiunea din notebook; materiale de sprijin: [Capitolul 9](#) şi [Franke, Härdle & Hafner \(2019\)](#)
- ▣ Seminar: drd. Antoaneta Amza, antoaneta.amza@csie.ase.ro

Harta exercițiilor

Exercițiu	Întrebare	Tip	Exemplu de urmat
A1	cît de precisă este RV dintr-o zi?	Rezolvat	–
A3	cît de des eșantionăm un preț cu zgomot?	Rezolvat	–
B3	are SPY o deplasare din zgomot la 5 minute?	Rezolvat	A3
B1	ce zile SPY conțin un salt?	Rezolvat	–
A2	pot șase randamente să dezvăluie un salt?	Propus	B1, A1
A5	ce impune HAR unui AR(22)?	Rezolvat	–
B5	cît de persistentă este log-varianța SPY?	Rezolvat	A5
A6	ce funcție de pierdere ordonează corect prognozele de varianță?	Rezolvat	–
A8	este GARCH mai puțin precis, deplasat sau ambele?	Propus	A5, A6
C2	ce este greșit într-un răspuns A1?	Propus	A3, B5
Pachete de extindere	A2, A3, A5, A6, B1, B3, B5 extinse; A4, A7, B2, B4, B6–B9, C1, C3 (opționale, după seminar)	Rezolvat și Propus	indicat la fiecare cerință

- **[Rezolvat]:** rezolvarea completă în slide-uri și în notebook, un model de urmat; **[Propus]:** îl rezolvați voi, rezolvarea se discută la seminar
- Partea A: derivări pe hîrtie; Partea B: calcul și inferență pe SPY și Bitcoin, fiecare cu o întrebare de interpretare la final; Partea C: întrebări deschise și critica unui răspuns A1

Datele folosite

Seria	Conținut	Eșantion
SPY, bare de 5 minute	prețurile sesiunii regulate, ora UTC, fiecare bară etichetată cu începutul ei	2020-10-12 – 2026-09-18, 1 489 de zile
Bitcoin (USD), bare de 5 minute SPY și Bitcoin, prețuri zilnice	zile UTC de 24 de ore prețuri de închidere ajustate (SPY) și prețuri de închidere (Bitcoin), pentru GARCH	659 din 747 de zile păstrate din 2000 (SPY), 2014 (Bitcoin)
Varianțele zilnice SPY (calculate)	RV intraday, randamentul peste noapte și varianța totală V_t ($\%^2$, $\%$)	un rând pentru fiecare zi SPY
Prognoze pe o zi (calculate)	log-HAR, HAR, GARCH(1,1)-t, EWMA, RV de ieri (coloana RW) și ținta V_t	din 3 ian. 2022 (SPY), 1 mar. 2025 (Bitcoin)


- SPY: ora UTC convertită în ora New York; barele 09:30–15:55; barele lipsă din timpul zilei preiau ultimul preț; 78 de randamente pe zi, 43 în cele 12 zile cu program redus
- Bitcoin: zilele cu mai puțin de 95% din cele 288 de bare sînt eliminate; golurile scurte preiau ultimul preț
- Unități: randamente $r = 100 \Delta \ln P$ în %, varianțe în $\%^2$; analizăm cu 252 (SPY) sau 365 (Bitcoin) de zile; toate datele se opresc la 18 septembrie 2026

Pregătire: rulați și verificați

```
# secțiunea "Date" din notebook definește  
# spy_intraday, btc_intraday,  
# intraday_returns, spy_overnight  
P = spy_intraday()          # day x 79 prices  
R = intraday_returns(P)     # day x 78 returns, %  
print(P.shape)  
print(R.notna().sum(axis=1).value_counts())  
Pb = btc_intraday()         # day x 289 prices, UTC  
print(Pb.shape, Pb.index[0], Pb.index[-1])
```

- Rezultatul așteptat
 - ▶ (1489, 79): zile SPY, de la 2020-10-12 la 2026-09-18
 - ▶ 1477 de zile cu 78 de randamente, 12 cu 43
 - ▶ (659, 289): Bitcoin, de la 2024-09-01 la 2026-09-17
- Coloana 0 din P este prețul de deschidere al barei de 09:30; coloanele 1–78 sînt prețurile de închidere ale barelor
- Dacă numerele diferă, opriți-vă și verificați fusul orar, filtrul sesiunii și data de final

De la bare la randamente: o zi SPY



- 7 aprilie 2025: prețul de deschidere $P_0 = 489,19$, apoi închiderile barelor $P_1 = 487,60$, $P_2 = 485,88$, $\dots$, $P_{78} = 504,54$: 79 de prețuri dau 78 de randamente; doar din cele 78 de închideri am obține 77
- $r_1 = 100 \ln(P_1/P_0) = -0,33\%$, $r_2 = -0,35\%$; $RV = \sum_i r_i^2 = 45,1\%^2$; randamentul peste noapte $-3,27\%$ este în afara barelor, varianța totală $V = RV + r_{\text{on}}^2 = 55,8\%^2$
- Randamentul peste noapte: randamentul ajustat de la o închidere la alta minus randamentul de la deschidere la închidere, deci dividendele intră în partea de peste noapte

Notății folosite în toate exercițiile

- ▣ Ziua t are M randamente intraday $r_{t,i}$ (%); $RV_t = \sum_i r_{t,i}^2$; cvarticitatea realizată $RQ_t = \frac{M}{3} \sum_i r_{t,i}^4$
- ▣ Variația bipower [Barndorff-Nielsen & Shephard \(2004\)](#) $BV_t = \frac{\pi}{2} \frac{M}{M-1} \sum_{i \geq 2} |r_{t,i}| |r_{t,i-1}|$; cvarticitatea tripower $TQ_t = M \mu_{4/3}^{-3} \frac{M}{M-2} \sum_{i \geq 3} |r_{t,i}|^{4/3} |r_{t,i-1}|^{4/3} |r_{t,i-2}|^{4/3}$, o estimare a lui IQ_t robustă la salturi, $\mu_{4/3} = \mathbb{E}|Z|^{4/3}$
- ▣ IV_t : varianța integrată, IQ_t : cvarticitatea integrată; ω^2 : varianța zgomotului de microstructură
- ▣ Varianța zilnică totală $V_t = RV_t + r_{on,t}^2$ pentru SPY; $V_t = RV_t$ pentru Bitcoin (24 de ore)
- ▣ Prognoza F_t pentru V_t , făcută la închiderea zilei $t-1$; $QLIKE(V, F) = V/F - \ln(V/F) - 1$; $MSE = (V - F)^2$, pe varianță

Varianța realizată: volatilitatea măsurată după fapt

- GARCH ([Capitolul 5](#)) deduce varianța de azi din randamentele zilnice; cu prețuri intraday o putem **măsura**: adunăm pătratele randamentelor de 5 minute [Andersen et al. \(2001\)](#)
- Varianța integrată $IV_t = \int_{t-1}^t \sigma_s^2 ds$: varianța pe care ziua a produs-o efectiv, cu σ_s volatilitatea instantanee din timpul zilei
- Varianța realizată $RV_t = \sum_{i=1}^M r_{t,i}^2 \rightarrow IV_t$ când $M \rightarrow \infty$ (preț continuu, fără zgomot); SPY: $M = 78$ de randamente de 5 minute pe sesiune
- Eroarea de măsurare: $RV_t - IV_t \approx N(0, 2 IQ_t/M)$, cu cvarticitatea integrată $IQ_t = \int \sigma_s^4 ds$ estimată prin RQ_t (slide-ul de notații)
 - ▶ Cu volatilitate constantă eroarea standard relativă este $\sqrt{2/M}$: $\sqrt{2/78} = 0,16$, deci RV dintr-o zi este o măsurare cu zgomot
- Exemplu mic: randamentele 0,10, -0,20, 0,10, 0,20 (%): $RV = 0,01 + 0,04 + 0,01 + 0,04 = 0,10\%^2$, volatilitatea zilnică $\sqrt{0,10} = 0,32\%$, anualizată $\sqrt{252} \times 0,10 = 5,0\%$
- Detalii: [Capitolul 9](#), după seminar

Două lucruri care distorsionează RV: zgomotul și salturile

- Zgomotul de microstructură: log-prețul observat este prețul eficient plus o eroare, $p_i^{\text{obs}} = p_i^* + \varepsilon_i$, $\text{Var}(\varepsilon_i) = \omega^2$ (oscilația între bid și ask, pasul de preț)
 - ▶ Fiecare randament conține doi termeni de zgomot, deci cu n randamente $\mathbb{E}[\text{RV}^{(n)}] = \text{IV} + 2n\omega^2$: deplasarea crește cu n , iar varianța erorii de eșantionare scade ca $1/n$
 - ▶ De aici o frecvență optimă de eșantionare [Bandi & Russell \(2008\)](#); în practică 5 minute este greu de întrecut [Liu, Patton & Sheppard \(2015\)](#); signature plot: RV medie în funcție de intervalul de eșantionare, plat când deplasarea din zgomot este neglijabilă
- Salturile: RV adună și pătratele salturilor, $\text{RV}_t \rightarrow \text{IV}_t + \sum J^2$; variația bipower [Barndorff-Nielsen & Shephard \(2004\)](#)

$$\text{BV}_t = \frac{\pi}{2} \frac{M}{M-1} \sum_{i \geq 2} |r_{t,i}| |r_{t,i-1}| \rightarrow \text{IV}_t$$
 - ▶ Intuiția: un salt intră în BV doar înmulțit cu un randament vecin mic; $\pi/2 = 1/(\mathbb{E}|Z|)^2$ rescalează produsele de randamente absolute cu distribuție Normală
 - ▶ Exemplu mic, $M = 4$, randamentele 0,1, 0,1, 0,1, 1,0 (%): $\text{RV} = 1,03$; $\text{BV} = \frac{\pi}{2} \cdot \frac{4}{3} (0,01 + 0,01 + 0,10) = 0,25$; partea de salt $\text{RV} - \text{BV} = 0,78$
- Detalii: [Capitolul 9](#), după seminar

Testarea unui salt: statistica raportului

- ▣ H_0 : nu există salt în ziua t ; măsura relativă a saltului $(RV_t - BV_t)/RV_t$ este aproape de 0 sub H_0 și mare într-o zi cu salt
- ▣ Statistica raportului [Huang & Tauchen \(2005\)](#): $z_t = \frac{(RV_t - BV_t)/RV_t}{\sqrt{\theta M^{-1} \max(1, TQ_t/BV_t^2)}}$, cu $\theta = \pi^2/4 + \pi - 5 = 0,609$
- ▣ TQ_t (cvarticitatea tripower, slide-ul de notații) estimează IQ_t fără să fie mărită artificial de un salt; TQ_t/BV_t^2 măsoară cât de neuniformă a fost volatilitatea în timpul zilei și are pragul inferior 1, valoarea sa la volatilitate constantă
- ▣ Sub H_0 , $z_t \approx N(0, 1)$; testul este unilateral: respingem când $z_t > 1,645$, $2,326$ sau $3,09$ la 5%, 1% sau 0,1%; $p_t = 1 - \Phi(z_t)$
- ▣ Cu N zile testate, aproximativ αN respingeri apar doar din întâmplare: comparați numărul lor cu αN (testare multiplă, [Capitolul 3](#))
- ▣ Detalii: [Capitolul 9](#), după seminar

HAR: o cascadă de trei orizonturi

- ▣ Fapt stilizat ([Capitolul 1](#)): volatilitatea are memorie lungă, autocorelația lui $|r_t|$ scade lent; prognoza GARCH(1,1) revine la medie cu o rată exponențială ([Capitolul 5](#))
- ▣ HAR [Corsi \(2009\)](#): $RV_{t+1} = \beta_0 + \beta_d RV_t + \beta_w RV_t^{(5)} + \beta_m RV_t^{(22)} + \varepsilon_{t+1}$, cu $RV_t^{(5)}$, $RV_t^{(22)}$ mediile pe ultimele 5 și 22 de zile
- ▣ Intuiția: participanți cu orizonturi de o zi, o săptămână și o lună; trei pante reproduc o memorie care scade lent; log-HAR folosește $y_t = \ln V_t$ în locul lui RV_t (prognoze pozitive, reziduuri mai apropiate de distribuția Normală)
- ▣ Se estimează prin OLS; erorile sînt autocorelate și heteroscedastice, deci folosim erori standard Newey–West (HAC) ([Capitolul 3](#))
- ▣ Exemplu mic: $\hat{\beta} = (0,1, 0,4, 0,3, 0,2)$, $RV_t = 2$, $RV_t^{(5)} = 1,5$, $RV_t^{(22)} = 1$: prognoza $0,1 + 0,8 + 0,45 + 0,2 = 1,55\%^2$; persistența $\beta_d + \beta_w + \beta_m = 0,9$
- ▣ Detalii: [Capitolul 9](#), după seminar

Evaluarea prognozelor de varianță: instrumentele din Capitolul 5

- Varianța adevărată nu se observă niciodată: prognozele se compară cu un indicator, aici $V_t = RV_t + r_{\text{on},t}^2$ pentru SPY, cu zgomot, dar condiționat nedeplasat
- Funcții de pierdere robuste [Patton \(2011\)](#): cu un astfel de indicator, MSE pe varianță $(V - F)^2$ și $\text{QLIKE}(V, F) = V/F - \ln(V/F) - 1$ ordonează prognozele ca varianța adevărată; QLIKE penalizează mai mult subestimarea
- Acuratețe: Diebold–Mariano [Diebold & Mariano \(1995\)](#) $t = \bar{d}/\text{se}_{\text{HAC}}(\bar{d})$ pe diferența de pierderi $d_t = L(V_t, F_t^A) - L(V_t, F_t^B)$
- Calibrare: regresia Mincer–Zarnowitz $V_t = a + bF_t + u_t$; o prognoză nedeplasată are $a = 0$ și $b = 1$, testate împreună cu un test Wald
- În afara eșantionului: la fiecare origine $t - 1$ modelul se reestimează doar pe datele de pînă la $t - 1$, apoi F_t se compară cu V_t
- Detalii: [Capitolul 9](#), după seminar


A1 [Rezolvat]: precizia varianței realizate — enunț

- ▣ **Întrebare:** cât de precis măsoară randamentele de 5 minute dintr-o zi varianța integrată?
- ▣ **Date de intrare:** volatilitate constantă, M intervale de lungime $\Delta = 1/M$, $r_i = \sigma\sqrt{\Delta} Z_i$ cu Z_i i.i.d. $N(0, 1)$, $IV = \sigma^2$; folosiți $\mathbb{E}Z^2 = 1$, $\text{Var}(Z^2) = 2$, $\mathbb{E}Z^4 = 3$; fără fișier de date
- ▣ **Cerințe**
 1. Arătați că $RV = \sigma^2 \chi_M^2 / M$ și derivați $\mathbb{E}[RV]$ și $\text{Var}(RV)$.
 2. Arătați că $RQ = \frac{M}{3} \sum_i r_i^4$ este nedeplasat pentru $IQ = \sigma^4$ și scrieți eroarea standard estimată a RV .
 3. Folosiți metoda delta pentru $\ln RV$ și scrieți intervalul de 95% pentru IV construit pe scara log.
 4. Calculați factorii intervalului $e^{\pm 1,96\sqrt{2/M}}$ pentru $M = 78$ și $M = 6$, precum și lățimea relativă pentru $M = 78$.
- ▣ **Raportați:** formulele, cele două perechi de factori și o propoziție despre cât de precisă este RV dintr-o zi
- ▣ Notebook: secțiunea A1

A1 [Rezolvat]: rezolvare (1/2) — derivarea

- ▣ $RV = \sum_i \sigma^2 \Delta Z_i^2 = \sigma^2 \frac{1}{M} \sum_i Z_i^2 = \sigma^2 \chi_M^2 / M$, deci $\mathbb{E}[RV] = \sigma^2$ (nedeplasată) și $\text{Var}(RV) = \sigma^4 \cdot 2M / M^2 = 2\sigma^4 / M$
- ▣ $\mathbb{E}[r_i^4] = \sigma^4 \Delta^2 \mathbb{E}Z^4 = 3\sigma^4 / M^2$, deci $\mathbb{E}[RQ] = \frac{M}{3} \cdot M \cdot 3\sigma^4 / M^2 = \sigma^4$; prin urmare $\widehat{\text{Var}}(RV) = 2 RQ / M$ și $\text{se}(RV) = \sqrt{\frac{2}{3} \sum_i r_i^4}$
- ▣ Metoda delta cu $g(x) = \ln x$, $g'(x) = 1/x$: $\text{se}(\ln RV) \approx \text{se}(RV) / RV = \sqrt{2 RQ / M} / RV$
- ▣ Intervalul de 95%: $RV \exp(\pm 1,96 \text{se}(\ln RV))$, întotdeauna pozitiv și asimetric pe niveluri; cu volatilitate constantă $RQ / RV^2 \approx 1$, deci factorii sînt $e^{\pm 1,96 \sqrt{2/M}}$
- ▣ Pentru volatilitatea $\sqrt{RV}$, $g'(x) = 1/(2\sqrt{x})$ înjumătățește eroarea standard relativă: intervalul pentru volatilitate este mai îngust decît cel pentru varianță

A1 [Rezolvat]: rezolvare (2/2) — factorii intervalului și acoperirea



- $M = 78$: $\sqrt{2/78} = 0,160$, factorii $[0,73, 1,37]$: IV se află între 0,73 RV și 1,37 RV, o lățime relativă totală de 0,64
- $M = 6$ (randamente de 30 de minute): factorii $[0,32, 3,10]$: aproape neinformativ
- Acoperirea simulată a intervalului nominal de 95% cu RQ (200 000 de zile): 94,2% pentru $M = 78$, 86,7% pentru $M = 6$: nivelul de 95% este un rezultat asimptotic
- Cu volatilitate stochastică aceeași limită studentizată rămâne valabilă asimptotic, pentru un preț continuu și zgomot neglijabil, deoarece convergența este stabilă (Capitolul 9)
- **Interpretare:** o zi de date la 5 minute determină IV cu o precizie de aproximativ $-27\%/+37\%$


A3 [Rezolvat]: deplasarea din zgomot și frecvența optimă — enunț

- ▣ **Întrebare:** cât de des eșantionăm un preț care conține zgomot?
- ▣ **Date de intrare:** $p_i^{\text{obs}} = p_i^* + \varepsilon_i$, ε_i i.i.d. $(0, \omega^2)$ independent de p^* ; drift nul, volatilitate constantă; $IV = 1\%$, $IQ = 1$, $\omega = 0,01\%$, deci $\omega^2 = 0,0001\%^2$; sesiune de 23 400 de secunde
- ▣ **Cerințe**
 1. Scrieți randamentul observat, dezvoltăți $\mathbb{E}[r_i^2]$ și derivați $\mathbb{E}[RV^{(n)}] = IV + 2n\omega^2$ pentru n randamente.
 2. Derivați $\text{cov}(r_i, r_{i-1}) = -\omega^2$.
 3. Din $MSE(n) \approx 2IQ/n + 4n^2\omega^4$ [Bandi & Russell \(2008\)](#), derivați n^* optim după MSE și intervalul de eșantionare corespunzător.
 4. Completați un tabel pentru 5 minute, 1 minut, 1 secundă și n^* : n , deplasarea $2n\omega^2$, $\mathbb{E}[RV]$, MSE.
- ▣ **Raportați:** derivările, tabelul și ce interval ați folosi în practică, cu motivul
- ▣ Notebook: secțiunea A3

A3 [Rezolvat]: rezolvare (1/2) — derivarea

- ▣ $r_i = p_i^{\text{obs}} - p_{i-1}^{\text{obs}} = r_i^* + \varepsilon_i - \varepsilon_{i-1}$
- ▣ $\mathbb{E}[r_i^2] = \mathbb{E}[r_i^{*2}] + \mathbb{E}[\varepsilon_i^2] + \mathbb{E}[\varepsilon_{i-1}^2] = \mathbb{E}[r_i^{*2}] + 2\omega^2$ (termenii încrucișați au media 0 prin independență); însumînd pe n randamente: $\mathbb{E}[\text{RV}^{(n)}] = \text{IV} + 2n\omega^2$
- ▣ Randamentele alăturate au în comun doar ε_{i-1} , cu semne opuse: $\text{cov}(r_i, r_{i-1}) = \text{cov}(-\varepsilon_{i-1}, \varepsilon_{i-1}) = -\omega^2$
- ▣ $\frac{d}{dn} \text{MSE} = -2\text{IQ}/n^2 + 8n\omega^4 = 0$ dă $n^3 = \text{IQ}/(4\omega^4)$, $n^* = (\text{IQ}/(4\omega^4))^{1/3}$; derivata a doua este pozitivă: un minim
- ▣ Cifre: $n^* = (1/(4 \times 10^{-8}))^{1/3} = 292$, un randament la fiecare $23\,400/292 = 80$ de secunde

A3 [Rezolvat]: rezolvare (2/2) — tabel și grafic



Interval	n	$2n\omega^2$	$\mathbb{E}[RV]$	MSE
5 minute	78	0,0156	1,0156	0,0259
1 minut	390	0,0780	1,0780	0,0112
1 secundă	23 400	4,6800	5,6800	21,9025
n^* , la fiecare 80 s	292	0,0585	1,0585	0,0103

- $MSE = 2/n + 4n^2 \times 10^{-8}$ în $\%^4$; la o secundă RV este de aproape șase ori IV
- În acest model 1 minut este aproape de optim; la 5 minute MSE este de 2,5 ori cea minimă
- **Interpretare:** alegerea uzuală de 5 minute se sprijină pe argumente din afara acestui model: ω este incert, zgomotul real nu este i.i.d., iar RV pe 5 minute este greu de întrecut empiric [Liu, Patton & Sheppard \(2015\)](#)

B3 [Rezolvat]: ce frecvență de eșantionare? — enunț

▣ **Exemplu de urmat:** A3 [Rezolvat]

▣ **Întrebări**

- ▶ are SPY o deplasare din zgomot măsurabilă la 5 minute?
- ▶ ce grilă dă cea mai utilă măsură zilnică?

▣ **Date:** matricea de prețuri SPY P din pregătire (1 489 de zile); grilă de $k \times 5$ minute, $k = 1, 3, 6, 13$ (5, 15, 30, 65 de minute): prețurile din coloanele $o, o + k, o + 2k, \dots$ plus deschiderea și închiderea, pentru decalajele $o = 0, \dots, k - 1$ (funcția `sparse_points`)

▣ **Cerințe**

1. Calculați RV zilnică pe o singură grilă ($o = 0$) și media pe cele k grile decalate și raportați $\sqrt{252 \overline{RV}}$ pentru fiecare interval.
2. Pentru fiecare interval calculați raportul dintre media RV pe o grilă și media RV pe 5 minute și un interval de 95% prin bootstrap pe blocuri mobile [Künsch \(1989\)](#): reeșantionați de 2 000 de ori blocuri de 20 de zile ale seriilor zilnice pereche și recalculați raportul mediilor.
3. Calculați corelația dintre log RV de azi (o grilă și media grilelor) și log RV pe 5 minute de mâine.

▣ **Raportați:** un tabel (volatilitate, raport [CI], corelație pe interval) și un grafic

▣ **Interpretare**

- ▶ există o deplasare din zgomot măsurabilă la 5 minute?
- ▶ de ce bootstrap pe blocuri și nu i.i.d.?
- ▶ ce grilă este cea mai utilă pentru prognoză?

▣ **Notebook:** secțiunea B3


B3 [Rezolvat]: rezolvare (1/2) — procedura și tabelul

- Procedura: pentru fiecare zi luăm prețurile grilei, calculăm $RV^{(o)} = \sum (100 \Delta \ln P)^2$ pe fiecare decalaj o și facem media după o ; pentru bootstrap alegem aleator începuturi de blocuri, alăturăm blocuri de 20 de zile ale seriei pereche $(RV_t^{(k)}, RV_t^{(5)})$ pînă la lungimea inițială, calculăm $\sum RV^{(k)} / \sum RV^{(5)}$ și citim percentilele de 2,5% și 97,5%

Interval	Vol. (o grilă)	Vol. (media grilelor)	Raport [CI 95%]	Corel. ziua următoare	Corel. (medie)
5 min	12,93	12,93	1,000 [1,000, 1,000]	0,73	0,73
15 min	12,88	12,79	0,992 [0,954, 1,035]	0,71	0,72
30 min	12,75	12,77	0,973 [0,933, 1,015]	0,70	0,72
65 min	12,76	12,88	0,974 [0,913, 1,037]	0,64	0,70

- Bootstrap pe blocuri: RV zilnice sînt puternic autocorelate; reeșantionarea i.i.d. ar distruge această dependență și ar face intervalul prea îngust

B3 [Rezolvat]: rezolvare (2/2) — grafic și răspuns



- Toate intervalele conțin 1: grilele rare nu detectează nicio diferență față de RV pe 5 minute; signature plot-ul este plat
- Corelația predictivă scade de la 0,73 (5 minute) la 0,64 (65 de minute, o grilă): RV rară este mai zgomotoasă; media grilelor decalate recuperează o parte (0,70)
- **Interpretare:** RV pe 5 minute este măsura cea mai utilă aici; în comparația cu nucleul realizat (pachet de extindere), nucleul realizat reprezintă în medie 0,952 din RV pe 5 minute (CI de 95% [0,910, 0,987]): o diferență mică, dar semnificativă

B1 [Rezolvat]: zile cu salt pentru SPY — enunț

▣ Întrebări

- ▶ în ce zile SPY respinge testul raportului?
- ▶ câte respingeri ar produce doar întâmplarea?

- ▣ **Date:** matricea de randamente SPY R (1 489 de zile; $M_t = 78$ sau 43 în zilele cu program redus); testul raportului [Huang & Tauchen \(2005\)](#), formulele de pe slide-ul de notații; funcția `jump_test`

▣ Cerințe

1. Pentru fiecare zi calculați RV , BV , TQ , z_t și valoarea p unilaterală $p_t = 1 - \Phi(z_t)$; lucrați pas cu pas ziua de 27 august 2021.
2. Numărați zilele în care testul respinge la 5%, 1% și 0,1% și comparați fiecare număr cu αN .
3. În zilele respinse la 0,1% găsiți intervalul cu cel mai mare $|r_{t,i}|$ și reprezentați histograma orei la care se încheie.
4. Calculați ponderea salturilor $\sum_t J_t / \sum_t RV_t$, cu $J_t = RV_t - BV_t$ în zilele respinse la 0,1% și 0 în rest.

- ▣ **Raportați:** ziua lucrată, un tabel cu numărul de respingeri față de αN , histograma și ponderea salturilor

▣ Interpretare

- ▶ sînt mai multe respingeri decît ar produce doar nivelul?
- ▶ ce le-ar putea explica?

- ▣ Notebook: secțiunea B1

B1 [Rezolvat]: rezolvare (1/3) — o zi pas cu pas


- ▣ 27 august 2021, $M = 78$: $RV = 0,1354$, $BV = 0,0687$, $TQ = 0,00539$ ($\%^2$, $\%^2$, $\%^4$)
- ▣ $(RV - BV)/RV = 0,493$; $TQ/BV^2 = 1,143 > 1$, deci pragul nu este activ
- ▣ $z = 0,493/\sqrt{0,609 \times 1,143/78} = 5,22$, $p = 9,0 \times 10^{-8}$: respingem la 0,1%
- ▣ Cel mai mare randament, +0,24% în intervalul care se încheie la 10:05, reprezintă 44% din RV: la 10:00–10:05 a fost publicat discursul președintelui Rezervei Federale de la Jackson Hole
- ▣ Aceiași patru pași, vectorizați pe zile, sînt `jump_test(R)`

B1 [Rezolvat]: rezolvare (2/3) — numărul de respingeri și ponderea salturilor

Nivel	Respingeri	αN
5%	235	74,5
1%	110	14,9
0,1%	35	1,5

- z_t are media 0,50 și abaterea standard 1,14 în loc de 0 și 1: mult mai multe respingeri decât implică nivelul
- Ponderea salturilor în RV totală, cu zilele de la 0,1%: 2,8%
- Explicații: salturi reale și forma de U din cursul zilei, care deplasează BV în jos (pachet de extindere: controlul FDR și corecția de periodicitate)

B1 [Rezolvat]: rezolvare (3/3) — când apar cele mai mari randamente?



- Ora celui mai mare $|r|$ în zilele semnalate: vârful este după deschidere; atribuirea unei știri cere dovezi separate

A2 [Propus]: șase randamente și un salt — enunț


- ▣ **Exemplu de urmat:** B1 [Rezolvat] (o zi pas cu pas) și A1
- ▣ **Întrebare:** pot șase randamente de 5 minute să dezvăluie un salt?
- ▣ **Date de intrare:** randamentele din tabel (%); ultimul este un salt produs de o știre în **ultimul** interval; $TQ = 0,0097$ (cvarticitatea tripower, dată); $\theta = \pi^2/4 + \pi - 5 = 0,609$; valoarea critică la 0,1%: 3,09
- ▣ **Cerințe**
 1. Completați tabelul și calculați RV și $BV = \frac{\pi}{2} \frac{M}{M-1} \sum_{i \geq 2} |r_i r_{i-1}|$ cu $M = 6$.
 2. Calculați partea de salt $RV - BV$ și ponderea ei în RV.
 3. Calculați TQ/BV^2 , aplicați pragul $\max(1, TQ/BV^2)$ și calculați
$$z = \frac{(RV - BV)/RV}{\sqrt{\theta M - 1} \max(1, TQ/BV^2)}.$$
 4. Decideți la 0,1% și comparați z cu cea mai mare valoare posibilă, $\sqrt{M/\theta}$.
- ▣ **Raportați:** tabelul completat, RV, BV, z , decizia și o propoziție de interpretare

i	r_i	r_i^2	$ r_i r_{i-1} $
1	0,08	0,0064	–
2	–0,15		
3	0,03		
4	0,10		
5	–0,04		
6	–0,90		

A5 [Rezolvat]: HAR ca AR(22) restricționat — enunț

- ▣ **Întrebare:** ce restricții impune HAR unui AR(22) pentru log-varianță?
- ▣ **Date de intrare:** log-HAR [Corsi \(2009\)](#) $y_{t+1} = \beta_0 + \beta_d y_t + \beta_w \bar{y}_t^{(5)} + \beta_m \bar{y}_t^{(22)} + \varepsilon_{t+1}$, $y_t = \ln V_t$, $\bar{y}_t^{(5)}$ media lui $y_t, \dots, y_{t-4}$, $\bar{y}_t^{(22)}$ media lui $y_t, \dots, y_{t-21}$; estimările SPY rotunjite $\hat{\beta} = (-0,08, 0,36, 0,34, 0,17)$
- ▣ **Cerințe**
 1. Dezvoltați cele două medii și scrieți coeficienții AR implicați $\phi_1, \phi_2 = \dots = \phi_5$ și $\phi_6 = \dots = \phi_{22}$.
 2. Cu $\theta = (\phi_0, \phi_1, \dots, \phi_{22})$, scrieți două rînduri ale matricei R din $R\theta = 0$ și numărați restricțiile.
 3. Calculați $\phi_1, \phi_{2..5}, \phi_{6..22}$ și persistența $\sum_k \phi_k$ pentru $\hat{\beta}$ și desenați cele 22 de ponderi.
- ▣ **Raportați:** cele trei formule ale ponderilor, două rînduri din R , cifrele și ce implică persistența pentru șocuri
- ▣ Notebook: secțiunea A5

A5 [Rezolvat]: rezolvare



- Întârzierea 1 apare în toate cele trei componente: $\phi_1 = \beta_d + \beta_w/5 + \beta_m/22$; întârzierile 2–5 în cea săptămînală și în cea lunară: $\phi_k = \beta_w/5 + \beta_m/22$; întârzierile 6–22 doar în cea lunară: $\phi_k = \beta_m/22$
- Rînduri din R (coloana 0: termenul liber): $(0, 0, 1, -1, 0, \dots, 0)$ pentru $\phi_2 = \phi_3$; $(0, \dots, 0, 1, -1, 0, \dots)$ în coloanele 6, 7 pentru $\phi_6 = \phi_7$
- Numărul: 3 egalități între $\phi_2, \dots, \phi_5$ plus 16 între $\phi_6, \dots, \phi_{22}$: 19 rînduri, R are 19×23 (22 de întârzieri minus 3 pante libere)
- $\phi_1 = 0,36 + 0,34/5 + 0,17/22 = 0,436$; $\phi_{2..5} = 0,076$; $\phi_{6..22} = 0,008$; $\sum_k \phi_k = \beta_d + \beta_w + \beta_m = 0,87$
- **Interpretare:** persistența $0,87 < 1$: șocurile asupra log-varianței se sting lent, dar dispar; testul pe date al celor 19 restricții este în pachetul de extindere

B5 [Rezolvat]: log-HAR pentru SPY cu inferență robustă — enunț

▣ **Exemplu de urmat:** A5 [Rezolvat]

▣ **Întrebări**

- ▶ cât de persistentă este log-varianța totală a SPY?
- ▶ schimbă erorile standard robuste vreo concluzie?

▣ **Date:** varianța zilnică totală SPY din pregătire, $V_t = RV_t + r_{\text{on},t}^2$, 1 489 de zile; regresorii datați $t - 1$: $\ln V_{t-1}$ și mediile lui $\ln V$ pe zilele $t - 5..t - 1$ și $t - 22..t - 1$ (media logaritmulor); primele 22 de zile se pierd

▣ **Cerințe**

1. Construiți matricea de design și verificați rîndul pentru 8 aprilie 2025 cu rezolvarea.
2. Estimați log-HAR prin OLS; raportați erorile standard obișnuite și Newey–West (HAC) cu 7 întârzieri, regula $\lfloor 4(T/100)^{2/9} \rfloor$.
3. Testați $\beta_w = \beta_m$ cu un test Wald folosind covarianța Newey–West.
4. Aplicați testul Ljung–Box cu 22 de întârzieri pe $\ln V_t$ și pe reziduuri, reprezentați ambele funcții de autocorelație și comparați R^2 cu un AR(1).

▣ **Raportați:** tabelul coeficienților cu ambele erori standard, testele cu valorile p și graficul

▣ **Interpretare**

- ▶ ce componentă contează cel mai mult?
- ▶ schimbă erorile robuste vreo concluzie?
- ▶ reușește HAR să explice persistența?

▣ **Notebook:** secțiunea B5


B5 [Rezolvat]: rezolvare (1/2) — un rînd din matricea de design și estimările

- Rîndul pentru 8 aprilie 2025: $y_t = \ln V_t = 2,976$; regresorii $\ln V_{t-1} = 4,022$ (7 aprilie), media săptămînală 2,068, media lunară 0,612
- Valoarea ajustată $\hat{y}_t = 2,177$: modelul anticipă o revenire parțială spre nivelul lunar
- Observații utilizabile: $1\,489 - 22 = 1\,467$; $R^2 = 0,470$ față de 0,413 pentru un AR(1) ($\hat{\phi} = 0,643$); persistența 0,866

	$\hat{\beta}$	SE OLS	SE NW	t_{NW}
β_0	-0,079	0,025	0,027	-3,0
β_d	0,362	0,031	0,037	9,8
β_w	0,337	0,049	0,048	7,0
β_m	0,167	0,046	0,044	3,8

- Erorile Newey–West sînt cu pînă la 20% mai mari decît cele OLS; toate pantele rămîn semnificative

B5 [Rezolvat]: rezolvare (2/2) — teste și grafic




- Wald $\beta_w = \beta_m$: 4,17, $p = 0,041$: respinsă la 5%, ponderea săptămînală este mai mare
- Ljung-Box(22): $\ln V_t$ 4641, reziduuri 17,5 ($p = 0,73$): trei coeficienți absorb persistența; autocorelația de ordinul 1 a reziduurilor $-0,014$
- Interpretare:** componentele săptămînală și zilnică domină; erorile robuste nu schimbă nicio concluzie; HAR nu lasă autocorelație semnificativă

A6 [Rezolvat]: ce funcție de pierdere ordonează prognozele de varianță? — enunț


- ▣ **Întrebare:** ce funcție de pierdere ordonează corect prognozele de varianță când ținta este un indicator zgomotos?
- ▣ **Date de intrare:** indicatorul V_t nedeplasat condiționat: $\mathbb{E}[V_t | \mathcal{F}_{t-1}] = \mathbb{E}[IV_t | \mathcal{F}_{t-1}]$ [Patton \(2011\)](#);
 $QLIKE(V, F) = V/F - \ln(V/F) - 1$; MSE pe varianță $(V - F)^2$
- ▣ **Cerințe**
 1. Minimizați $\mathbb{E}[QLIKE(V_t, F) | \mathcal{F}_{t-1}]$ în raport cu F și arătați că minimumul se atinge în $\mathbb{E}[IV_t | \mathcal{F}_{t-1}]$.
 2. Pentru două prognoze F_A, F_B arătați că $\Delta L = V(1/F_A - 1/F_B) + \ln(F_A/F_B)$ este liniară în V , deci media ei condiționată este aceeași cu V_t sau cu IV_t : ordinea se păstrează.
 3. Cu varianța adevărată 1, calculați QLIKE și MSE pe varianță pentru $F = 0,5$ și $F = 2$ și comparați cele două ordonări.
- ▣ **Raportați:** condiția de ordinul întâi, argumentul pentru ordonare, cele patru valori ale pierderilor și ce funcție ați folosi
- ▣ Notebook: secțiunea A6

A6 [Rezolvat]: rezolvare




- $\partial_F \mathbb{E}[V/F - \ln V + \ln F - 1] = -\mathbb{E}V/F^2 + 1/F = 0$ dacă $F = \mathbb{E}[V_t | \mathcal{F}_{t-1}] = \mathbb{E}[IV_t | \mathcal{F}_{t-1}]$; derivata a doua $1/F^2 > 0$
- $\text{QLIKE}(V, F_A) - \text{QLIKE}(V, F_B) = V(1/F_A - 1/F_B) + \ln(F_A/F_B)$: liniară în V , iar F_A, F_B sînt cunoscute în $t - 1$, deci înlocuirea lui V_t cu IV_t , nedeplasat condiționat, nu schimbă $\mathbb{E}[\Delta L | \mathcal{F}_{t-1}]$
- QLIKE: $F = 0,5$ dă $2 - \ln 2 - 1 = 0,307$, $F = 2$ dă $0,5 + \ln 2 - 1 = 0,193$; MSE pe varianță: 0,25 și 1, ordinea inversă
- **Interpretare:** ambele funcții sînt robuste, dar QLIKE penalizează mai mult subestimarea, ceea ce contează pentru risc; MSE pe *volatilitate* nu este robustă (pachet de extindere)

Evaluarea prognozelor: origine, țintă, fereastră



- La fiecare origine: reestimăm pe toate datele pînă la $t - 1$, prognozăm F_t , apoi observăm V_t ; nicio valoare din ziua t nu intră în prognoză
- SPY: 1 180 de origini, de la 3 ianuarie 2022 la 18 septembrie 2026; pierderile se compară doar pe date comune
- Prognozele pe o zi log-HAR, HAR, GARCH(1,1)- t , EWMA și RV de ieri (coloana RW), și ținta V_t

Prognoze pe o zi și pierderi cumulate



- QLIKE medie: log-HAR 0,310, GARCH(1,1)-t 0,343; o linie cumulată crescătoare înseamnă că log-HAR are pierderea mai mică
- $d_t = \text{QLIKE}(\text{log-HAR}) - \text{QLIKE}(\text{GARCH})$ este punctul de plecare pentru A8: este diferența mai mare decât întâmplarea?

A8 [Propus]: acuratețe versus calibrare — enunț

- ▣ **Exemplu de urmat:** A5 (statistica Wald) și A6 [Rezolvat]
- ▣ **Întrebare:** este GARCH mai puțin precis decât log-HAR, deplasat sau ambele?
- ▣ **Date de intrare:** prognoze SPY pe o zi, ianuarie 2022 – septembrie 2026; $d_t = \text{QLIKE}(\text{log-HAR}) - \text{QLIKE}(\text{GARCH})$ are media $\bar{d} = -0,0327$, SE Newey–West 0,0142; regresia MZ pentru GARCH, $V_t = a + bF_t + u_t$: $\hat{a} = 0,2418$ (SE 0,2310), $\hat{b} = 0,7046$ (SE 0,2382), $\text{corr}(\hat{a}, \hat{b}) = -0,9750$ (păstrați patru zecimale)
- ▣ **Cerințe**
 1. Acuratețea, H_0 : pierdere așteptată egală. Calculați statistica t Diebold–Mariano, valoarea p bilaterală și decideți la 5%.
 2. Calibrarea, H_0 : $a = 0$, $b = 1$. Calculați statisticile t separate pentru $a = 0$ și $b = 1$.
 3. Construiți matricea de covarianță 2×2 , calculați $W = \delta^\top \hat{V}^{-1} \delta$ cu $\delta = (\hat{a}, \hat{b} - 1)$ și valoarea p din χ^2_2 .
 4. Desenați elipsa de încredere de 95%, marcați $(0, 1)$ și explicați când testele separate și cel comun nu coincid.
- ▣ **Raportați:** trei statistici, trei decizii și o propoziție care separă acuratețea de calibrare

C2 [Propus]: critica unui răspuns AI — enunț

- ▣ **Exemplu de urmat:** A3 și B5 [Rezolvat]; un exercițiu de citire a codului, nu sînt necesare date tick cu tick
- ▣ **Cadrul:** un student îi dă unui asistent AI o serie pandas `px` cu prețuri SPY curate, ordonate în timp, ora New York, 09:30–16:00, mai multe zile, în USD (deci randamentele sînt zecimale, nu în %)
- ▣ **Cerințe**
 1. Răspunsul de pe slide-ul următor conține trei erori conceptuale; restul este corect în acest cadru. Găsiți-le.
 2. Pentru fiecare eroare dați dovada: o derivare, o verificare a rezultatului sau o cifră din curs ori din acest seminar.
 3. Dați corecția: formula, linia de cod și cifra corectată, acolo unde se cere.
 4. Consemnați fiecare eroare găsită efectiv în formatul din `AI_ERRORS.md`: cererea, răspunsul, eroarea, cum ați găsit-o, corecția.
- ▣ **Raportați:** un tabel cu cîte un rînd pentru fiecare eroare (ce, dovada, corecția)
- ▣ Indicații: A3 despre $\mathbb{E}[RV^{(n)}]$ cu zgomot; ce se întîmplă între 16:00 și 09:30; introduceți $RV_t = 1,0 \times 10^{-4}$ (1%²)

C2 [Propus]: critica unui răspuns AI — răspunsul

- **Cererea:** „Calculează din px varianța realizată zilnică, volatilitatea anualizată și regresorii HAR.”
- **Răspunsul, text**
 - ▶ $RV_t = \sum_i r_{t,i}^2$ cu $r_{t,i}$ randamentele log intraday din ziua t ; folosiți fiecare tranzacție: mai multe randamente fac întotdeauna RV_t mai precisă
 - ▶ RV_t este varianța zilnică a SPY: comparați-o direct cu pătratul randamentelor de la o închidere la alta și cu varianța GARCH
 - ▶ HAR: regresia lui RV_{t+1} pe RV_t și pe mediile lui pe 5 și pe 22 de zile [Corsi \(2009\)](#)

```
import numpy as np, pandas as pd
lp = np.log(px)
r = lp.groupby(lp.index.date).diff().dropna()
RV = (r**2).groupby(r.index.date).sum()
vol_ann = np.sqrt(RV) * 252
H = pd.DataFrame({'d': RV,
                  'w': RV.rolling(5).mean(),
                  'm': RV.rolling(22).mean(),
                  'y': RV.shift(-1)}).dropna()
```

Tema pentru acasă

Temă: alegeți una

- ▣ B2, salturi Bitcoin (model: B1), sau B6, prognoza săptămânii următoare (model: B5, A8)
- ▣ Scrieți-o ca folder Quantlet (cod, Metainfo.txt, graficul): formatul folosit în proiectul de echipă
- ▣ Folosirea AI este permisă; notați erorile depistate efectiv, în formatul din AI_ERRORS.md
- ▣ Pachetele de extindere sînt opționale

Pachetele de extindere: ce cere fiecare

Pachet	Exerciții	Cunoștințe necesare
1. Zgomot	A3 extins [Rezolvat], A4, B3 extins [Rezolvat]	A3, B3
2. Salturi	A2 extins, B1 extins [Rezolvat], B2	A2, B1
3. Distribuții	B4	B3 (bootstrap pe blocuri)
4. HAR	A5 extins [Rezolvat], B5 extins [Rezolvat], A7, B7	A5, B5, B1
5. Prognoze	A6 extins [Rezolvat], B6, B6 extins, B9	A6, A8, evaluarea prognozelor
6. Asprime	B8	B3, Capitolul 9 (volatilitatea rough)
7. Proiecte	C1, C3	B5, A6, B9, studiul de caz din curs

- Fiecare exercițiu indică secțiunea din notebook; în cadrul unui pachet, lucrați în ordine
- C1 și C3 pot fi puncte de plecare pentru proiectul de echipă

A3 extins [Rezolvat]: estimarea varianței zgomotului — enunț

▣ Întrebări

- ▶ cum poate fi estimat ω^2 din date?
- ▶ în ce limită este consistent fiecare estimator?

▣ Date de intrare: modelul din A3, n randamente pe zi

▣ Cerințe

1. Arătați că $\mathbb{E}[RV^{\text{all}}/(2n)] = \omega^2 + IV/(2n)$ și precizați limita lui când $n \rightarrow \infty$.
2. Propuneți un al doilea estimator din autocovarianța de ordinul întâi și precizați când este consistent.

▣ Notebook: secțiunea A3


A3 extins [Rezolvat]: rezolvare

- ▣ $\mathbb{E}[\text{RV}^{\text{all}} \mid \sigma] = \text{IV} + 2n\omega^2$, deci $\mathbb{E}[\text{RV}^{\text{all}}/(2n)] = \omega^2 + \text{IV}/(2n)$; legea numerelor mari pentru termenii de zgomot
dă $\hat{\omega}^2 = \text{RV}^{\text{all}}/(2n) \xrightarrow{P} \omega^2$ când $n \rightarrow \infty$ [Bandi & Russell \(2008\)](#)
- ▣ $-\widehat{\text{cov}}(r_i, r_{i-1})$ estimează ω^2 (A3), consistent când numărul de randamente crește, cu condiția ca zgomotul să fie i.i.d. și independent de preț
- ▣ În eșantioane finite primul estimator este contaminat de $\text{IV}/(2n)$; A4 îl compară cu valoarea oracol

A4 [Propus]: RV pe două scări — enunț

▣ **Exemplu de urmat:** A3 [Rezolvat]

▣ **Date de intrare:** o acțiune nelichidă sintetică, cu o sesiune stabilită de 390 de minute: $IV = IQ = 1$, $\omega = 0,03\%$; într-o zi, randamentele de 1 minut ($n = 390$) dau $RV^{\text{all}} = 1,70$; $K = 5$ grile decalate de 5 minute dau $RV^{\text{avg}} = 1,10$




1. Calculați deplasarea din zgomot $2n\omega^2$ la 5 și la 1 minut, precum și n^* din A3 cu intervalul său.
2. Cu $\bar{n} = (n - K + 1)/K$, calculați $TSRV = RV^{\text{avg}} - \frac{\bar{n}}{n}RV^{\text{all}}$, cu și fără factorul $1/(1 - \bar{n}/n)$.
3. Estimați ω^2 de două ori: valoarea oracol $(RV^{\text{all}} - IV)/(2n)$ și estimatorul fezabil $RV^{\text{all}}/(2n)$ din A3 extins.
4. Arătați că TSRV elimină deplasarea din zgomot la ordinul întâi. Opțional: cu $\text{Var}(\text{eroare}) \approx aK/n + bn/K^2$, găsiți K care echilibrează termenii și rata TSRV.

B3 extins [Rezolvat]: un nucleu realizat pe bare de 5 minute — enunț

- ▣ **Întrebare:** schimbă un estimator robust la zgomot valoarea RV SPY pe 5 minute?
- ▣ **Date:** randamentele SPY R și prețurile P ; funcția `realized_kernel` [Barndorff-Nielsen et al. \(2008\)](#): ponderi Parzen, lățimea de bandă $H = \lceil 3,5134 \xi^{4/5} n^{3/5} \rceil$ pe fiecare zi, $\xi^2 = \hat{\omega}^2 / \widehat{IV}$, capetele grilei cursului (deschiderea și închiderea)
- ▣ **Cerințe**
 1. Calculați nucleul pentru fiecare zi și raportul dintre media lui și media RV, cu bootstrap-ul pe blocuri din B3.
 2. Reprezentați distribuția lui $\ln(RV^{(k)} / RV^{(5)})$ pentru 15, 30 și 65 de minute.
- ▣ **Notebook:** secțiunea B3

B3 extins [Rezolvat]: rezolvare



- Nucleu / RV = 0,952, CI [0,910, 0,987] (lățimea mediană $H = 7$): nucleul adaugă autocorelațiile negative mici ($\hat{\rho}_1 = -0,008$); semnificativ, dar mic economic
- Grilele mai rare se împrăștie în jurul valorii de 5 minute: RV rară adaugă zgomot fără să elimine o deplasare detectabilă


A2 extins [Propus]: de ce BV ignoră un salt — enunț

- ▣ **Exemplu de urmat:** A1 [Rezolvat]
- ▣ **Date de intrare:** un salt de mărime κ într-un interval **interior** j ($1 < j < M$): $r_j = \kappa + r_j^c$; celelalte randamente sînt difuzive, $O_p(\Delta^{1/2})$
- ▣ **Cerințe**
 1. Arătați că, la ordinul principal, saltul intră în BV doar prin $|r_{j-1}| |\kappa| + |\kappa| |r_{j+1}|$ și că aceste produse sînt $O_p(\Delta^{1/2})$.
 2. Deduceți că $BV \rightarrow IV$, iar $RV \rightarrow IV + \kappa^2$; prin ce diferă un salt în ultimul interval (ca în A2)?

B1 extins [Rezolvat]: multiplicitate și sezonabilitate intraday — enunț

- ▣ **Întrebare:** câte dintre respingerile din B1 rămân după controlul ratei descoperirilor false și după corecția pentru forma de U din cursul zilei?
- ▣ **Date:** cele $N = 1\,489$ valori p zilnice din B1; funcțiile `bh_count`, `periodicity_sd`
- ▣ **Cerințe**
 1. Benjamini–Hochberg [Benjamini & Hochberg \(1995\)](#): ordonați valorile p și respingeți cele mai mici k , cu k cel mai mare indice pentru care $p_{(k)} \leq kq/N$; aplicați $q = 5\%$ și 1% , precum și Bonferroni ($p < 0,05/N$).
 2. Factorul de periodicitate [Boudt, Croux & Laurent \(2011\)](#): scalați randamentele cu $\sqrt{BV_t/M_t}$, luați rădăcina mediei pătratelor pe fiecare interval de 5 minute, normalizați astfel încât media lui f_i^2 să fie 1; împărțiți $r_{t,i}$ la f_i și repetați B1(2) și pasul 1.
- ▣ **Interpretare:** BH controlează FDR pentru valori p valide, independente sau pozitiv dependente [Benjamini & Yekutieli \(2001\)](#); ce număr ați folosi pentru a construi un regresor de salt?

B1 extins [Rezolvat]: rezolvare



- BH la 5%: cel mai mare k cu $p_{(k)} \leq k \times 0,05/1489$ este $k = 42$ ($p_{(k)} = 0,00140$ față de $0,00141$): 42 de zile cu salt; la 1%: 9; Bonferroni: 7
- După împărțirea la f_i ($f = 1,78$ la deschidere, $0,73$ la minim): 167 de respingeri la 5%, 20 la 0,1%, 17 sub FDR 5%
- **Interpretare:** construim regresorul de salt din zilele cu control FDR și corecție de periodicitate

B2 [Propus]: salturi în Bitcoin — enunț

- ▣ **Exemplu de urmat:** B1 [Rezolvat]
- ▣ **Date:** matricea de prețuri Bitcoin P_b , zile UTC de 24 de ore cu cel puțin 95% din cele 288 de bare, 659 de zile din 747; o zi este etichetată cu data ei UTC
- ▣ **Cerințe**
 1. Aplicați testul raportului din B1 la 0,1% și construiți un tabel zilnic: data, M_t , RV, BV, z, indicatorul de weekend.
 2. Pentru zilele lucrătoare și pentru weekend raportați numărul de zile, numărul de respingeri și rata lor, precum și media BV/RV.
 3. Calculați ponderea salturilor în variația totală și un test binomial unilateral al ratei totale față de 0,001.
- ▣ **Interpretare:** testul binomial presupune teste zilnice independente și cu mărimea corectă
 - ▶ ce stabilește o respingere?
 - ▶ ce nu stabilește?
 - ▶ în care grup sînt respingerile mai frecvente?
 - ▶ care ar putea fi motivul?

B4 [Propus]: randamente standardizate cu volatilitatea realizată — enunț

- ▣ **Exemplu de urmat:** B3 [Rezolvat] (bootstrap pe blocuri)
- ▣ **Date:** randamentele SPY de la deschidere la închidere (1 489 de zile) și randamentele Bitcoin pe 24 de ore (659 de zile), fiecare aliniat cu RV din aceeași zi [Andersen et al. \(2001\)](#); un rând: 7 aprilie 2025, $r_t = 3,09\%$, $RV_t = 45,1$, $z_t = r_t / \sqrt{RV_t} = 0,46$
- ▣ **Cerințe**
 1. Calculați aplatizarea Pearson $\mathbb{E}(x - \bar{x})^4 / s^4$ pentru $u_t = r_t / \text{sd}(r)$ și pentru z_t , cu intervale de 95% din bootstrap pe blocuri mobile, pe perechi (blocuri de 20 de zile, 2 000 de reeșantionări).
 2. Reprezentați histogramele și graficele QQ față de distribuția Normală pentru u_t și z_t ; aplicați Jarque–Bera pe z_t ; calculați ponderea $|z_t| > 3$ (distribuția Normală: 0,27%).
- ▣ **Interpretare:** de unde provin cozile grele? Reper opțional: pentru randamente intraday Gaussiene i.i.d., z_t are aplatizarea $3M/(M + 2)$

A5 extins [Rezolvat]: testul Wald al restricțiilor HAR — enunț

▣ **Exemplu de urmat:** A5 [Rezolvat]

▣ **Cerințe**

1. Scrieți statistica Wald pentru $R\theta = 0$ cu o covarianță Newey–West $\hat{V}_{NW}$ și dați distribuția ei limită sub HAR.
2. Explicați de ce este necesară o covarianță HAC pentru regresia log-varianței.

A5 extins [Rezolvat]: rezolvare

- ▣ $W = (R\hat{\theta})^\top (R\hat{V}_{NW}R^\top)^{-1}R\hat{\theta} \rightarrow \chi^2_{19}$ sub cele 19 restricții HAR
- ▣ Erorile regresiei pe log-varianță sînt heteroscedastice și pot fi autocorelate: covarianța OLS obișnuită ar evalua greșit $\text{Var}(R\hat{\theta})$
- ▣ Testul pe date este în B5 extins, pasul 1

B5 extins [Rezolvat]: testul AR(22) și HARQ — enunț

- ▣ **Exemplu de urmat:** A5 extins, B5 [Rezolvat]
- ▣ **Date:** ca la B5; cvarticitatea realizată RQ_t din randamentele intraday (nu acoperă randamentul peste noapte)
- ▣ **Cerințe**
 1. Estimați AR(22) nerestricționat pentru $\ln V_t$ și testați cele 19 restricții HAR cu un test Wald Newey–West.
 2. Estimați HARQ pe niveluri [Bollerslev, Patton & Quaadvlieg \(2016\)](#),
$$V_{t+1} = \beta_0 + (\beta_d + \beta_Q \sqrt{RQ_t})V_t + \beta_w V_t^{(w)} + \beta_m V_t^{(m)} + \varepsilon$$
, pe RV intraday și pe varianța totală.
 3. Prognozați din 3 ianuarie 2022 pe o fereastră extinsă, înlocuind prognozele care ies din intervalul $[\min, \max]$ al valorilor din eșantion cu media eșantionului [Bollerslev, Patton & Quaadvlieg \(2016\)](#), și aplicați DM față de HAR pe niveluri după QLIKE.
- ▣ **Notebook:** secțiunea B5

B5 extins [Rezolvat]: rezolvare

- ▣ (1) $W = 18,1$, $p = 0,51$ (χ^2_{19}); R^2 0,477 (AR(22)) vs 0,470 (HAR): restricțiile nu sînt respinse; HAR economisește 19 parametri
- ▣ (2) $\hat{\beta}_Q = -0,0088$ (SE 0,0042) pe RV intraday, semnificativ la 5%; $-0,0022$ (SE 0,0024) pe varianța totală, nesemnificativ
- ▣ (3) QLIKE 0,344 (HARQ) vs 0,326 (HAR), DM $t = 1,23$, $p = 0,22$: nicio diferență semnificativă
- ▣ **Interpretare:** semnul prezis de A7 apare, dar cu RV pe 5 minute eroarea de măsurare este mică, iar randamentul peste noapte, neacoperit de RQ, domină zgomotul din varianța totală

A7 [Propus]: atenuarea și argumentul pentru HARQ — enunț

- ▣ **Exemplu de urmat:** A5 [Rezolvat], B5 extins
- ▣ **Date de intrare:** $RV_t = V_t^* + u_t$ (semnal latent plus eroare), V_t^* varianța integrată; $\mathbb{E}[u_t | \sigma] = 0$, $\text{Var}(u_t | \sigma) = 2IQ_t/M$ (asimptotic, A1); erori necorelate între zile și necorelate cu V^* și η ; $V_{t+1}^* = \beta \mathbf{0} + \beta V_t^* + \eta_{t+1}$, $\beta > 0$
- ▣ **Cerințe**
 1. Folosind plim $\hat{\beta} = \text{cov}(RV_{t+1}, RV_t) / \text{Var}(RV_t)$, derivați atenuarea pantei OLS.
 2. Ilustrare (varianța semnalului $\sigma_{V^*}^2$ presupusă independentă de IQ_t): derivați ponderea liniară optimă pe RV_t dat fiind IQ_t și arătați că scade cu IQ_t .
 3. Scrieți un estimator prin variabile instrumentale cu instrumentul RV_{t-1} și precizați condițiile de excludere și de relevanță.

B7 [Propus]: ajută salturile? Modelul HAR-CJ — enunț

- ▣ **Exemplu de urmat:** B5 și B1 [Rezolvat]
- ▣ **Date:** SPY ca la B5; varianta de replicare: zilele cu salt de la 0,1% din B1, fără corecții; $J_t = RV_t - BV_t$ în acele zile, 0 în rest; $C_t = RV_t - J_t + r_{on,t}^2$ (toate în %²) [Andersen, Bollerslev & Diebold \(2007\)](#)
- ▣ **Cerințe**
 1. Regresați $\ln V_{t+1}$ pe $\ln C_t$, $\ln C_t^{(5)}$, $\ln C_t^{(22)}$, $\ln(1 + J_t)$, $\ln(1 + J_t^{(5)})$, $\ln(1 + J_t^{(22)})$, unde (5), (22) sînt medii aritmetice logaritmice după mediere; raportați toți coeficienții cu SE Newey–West și testați comun cei trei coeficienți ai salturilor.
 2. Prognozați din 3 ianuarie 2022 pe o fereastră extinsă și comparați QLIKE cu log-HAR pe date comune, prin DM.
 3. Sensibilitate: repetați cu zilele cu salt din B1 extins (control FDR și corecție de periodicitate).
- ▣ **Interpretare:** HAR-CJ mediază nivelurile înainte de logaritmare, log-HAR mediază logaritmiile: cele două modele nu sînt imbricate; de ce un coeficient al salturilor semnificativ poate să nu aducă câștig de prognoză?

A6 extins [Rezolvat]: de ce MSE pe volatilitate nu este robustă — enunț

▣ **Exemplu de urmat:** A6 [Rezolvat]

▣ **Date de intrare:** IV constantă și $RV = IV \chi_M^2 / M$; momentul dat: $\mathbb{E}\sqrt{\chi_M^2} = \sqrt{2} \Gamma(\frac{M+1}{2}) / \Gamma(\frac{M}{2})$

▣ **Cerințe**

1. Minimizați $\mathbb{E}(\sqrt{RV} - \sqrt{F})^2$ (MSE pe volatilitate) în raport cu F și comparați valoarea optimă cu $\mathbb{E}RV$ prin inegalitatea lui Jensen.
2. Calculați F^*/IV pentru $M = 1$ (randamentul zilnic la pătrat), 6 și 78.

A6 extins [Rezolvat]: rezolvare

- ▣ $\mathbb{E}(\sqrt{RV} - \sqrt{F})^2 = \mathbb{E}RV - 2\sqrt{F} \mathbb{E}\sqrt{RV} + F$, minim în $\sqrt{F} = \mathbb{E}\sqrt{RV}$; din Jensen $(\mathbb{E}\sqrt{RV})^2 < \mathbb{E}RV$: prognoza optimă este deplasată în jos
- ▣ $F^*/IV = \frac{2}{M} \left(\Gamma(\frac{M+1}{2}) / \Gamma(\frac{M}{2}) \right)^2 = 0,637 \ (M=1), 0,920 \ (M=6), 0,994 \ (M=78)$; reprezentat grafic în A6
- ▣ **Interpretare:** față de randamentele zilnice la pătrat, MSE pe volatilitate răsplătește o prognoză cu 36% prea mică; cu RV pe 5 minute distorsiunea aproape dispare

B6 [Propus]: prognoza săptămânii următoare — enunț

- ▣ **Exemplu de urmat:** B5 [Rezolvat], A8, evaluarea prognozelor
- ▣ **Date:** varianța totală SPY V_t (B5) și prețurile de închidere ajustate SPY din 2000, pentru GARCH; ținta $Y_t = V_t + \dots + V_{t+4}$, prognozată la închiderea din $t - 1$; 1 176 de origini din 3 ianuarie 2022
- ▣ **Cerințe**
 1. log-HAR direct: regresați $\ln Y$ pe regresorii din B5, reestimat la fiecare origine folosind doar țintele observate complet până în $t - 1$ (ultimele patru nu sînt); prognoza $\exp(\hat{y} + \hat{s}^2/2)$ [Duan \(1983\)](#).
 2. GARCH(1,1)- t reestimat la fiecare 21 de zile: cu σ_t^2 varianța pe un pas și $\bar{\sigma}^2 = \omega/(1 - \alpha - \beta)$, prognoza $\sum_{h=0}^4 [\bar{\sigma}^2 + (\alpha + \beta)^h (\sigma_t^2 - \bar{\sigma}^2)]$.
 3. Calculați QLIKE și MSE, DM pe QLIKE cu erori HAC, ambii coeficienți MZ cu testul comun pentru $(a, b) = (0, 1)$ și reprezentați diferența cumulată a QLIKE.
- ▣ **Interpretare**
 - ▶ se păstrează avantajul de la o zi al log-HAR la un orizont săptămînal?
 - ▶ ce efect au țintele suprapuse asupra testului DM?

B6 extins [Propus]: un test Giacomini–White condiționat — enunț

▣ **Exemplu de urmat:** B6

▣ **Cerințe**

1. Reestimați ambele metode pe ferestre mobile de lungime fixă (log-HAR: ultimele 250 ținte; GARCH: ultimele 1 000 de randamente), cum cere teoria din [Giacomini & White \(2006\)](#).
2. Cu instrumentele $Z_t = (1, d_{t-5})$ și diferența de pierdere d_{t+5} realizată cinci zile mai târziu, calculați $n \bar{g}^\top \hat{\Omega}^{-1} \bar{g}$ cu $g = Z_t d_{t+5}$; sub ipoteza nulă g este necorelat dincolo de întârzierea 4, deci $\hat{\Omega}$ însumează autocovarianțele neponderate de ordinele 0–4.

B9 [Propus]: ce modele rămân în competiție? Mulțimea de încredere a modelelor — enunț

- ▣ **Exemplu de urmat:** B5 extins, B6
- ▣ **Date:** prognozele SPY pe o zi (log-HAR, HAR, GARCH(1,1)-t, EWMA, RV de ieri) plus HARQ (B5 extins) și SHAR
 Patton & Sheppard (2015): $\beta_d V_t$ înlocuit cu $\beta^+ RS_t^+ + \beta^- RS_t^-$, $RS_t^\pm = \sum_i r_{t,i}^2 1\{r_{t,i} \gtrless 0\}$, randamentul peste noapte socotit ca încă un randament; 1 180 de date comune
- ▣ **Cerințe**
 1. Construiți matricea QLIKE dată $\times$ model pe date comune și verificați că toate prognozele sînt pozitive.
 2. Aplicați MCS Hansen, Lunde & Nason (2011) cu statistica amplitudinii, blocuri de 20 de zile, 10 000 de reșantionări, valoarea de inițializare 42: `MCS(L, size=0.10, reps=10000, block_size=20, method='R', seed=42)`.
 3. Raportați ordinea eliminării și valoarea p MCS a fiecărui model; comparați mulțimile de 90% (mărimea 0,10) și 75% (mărimea 0,25).
- ▣ **Interpretare:** de ce este MCS preferabilă celor 21 de teste DM pe perechi?

B8 [Propus]: cât de rough este volatilitatea? — enunț

- ▣ **Exemplu de urmat:** B3 [Rezolvat] (bootstrap pe blocuri), [Capitolul 9](#)
- ▣ **Date:** serii zilnice SPY pentru patru măsuri: varianța totală, RV intraday, BV, RV subeșantionată la 30 de minute; $x_t = \frac{1}{2} \ln(\text{măsurat}_t)$; decalaje Δ între 1 și 30 de zile de tranzacționare [Gatheral, Jaisson & Rosenbaum \(2018\)](#)
- ▣ **Cerințe**
 1. Calculați $m(q, \Delta)$, media lui $|x_{t+\Delta} - x_t|^q$ pe toate perechile valide, pentru $q \in \{0,5, 1, 1,5, 2, 3\}$; verificați $m(2, 1)$ pentru varianța totală.
 2. Pentru fiecare q regresați $\ln m(q, \Delta)$ pe $\ln \Delta$ cu termen liber: panta ζ_q ; apoi $H = \text{panta lui } \zeta_q \text{ pe } q, \text{ prin origine.}$
 3. CI de 95%: bootstrap pe blocuri mobile, blocuri de 60 de zile, 300 de reeșantionări, incrementele calculate doar în interiorul fiecărui bloc.
 4. Simulați un mers aleator Gaussian (incremente $N(0, 0,1^2)$, valoarea de inițializare 42), scădeți dreapta care îi unește capetele (tot $H = 0,5$), estimați H , adăugați zgomot i.i.d. $N(0, 0,25^2)$ și estimați din nou.
- ▣ **Interpretare**
 - ▶ este H sub 0,5 pentru fiecare măsură?
 - ▶ ce efect are eroarea de măsurare?
- ▣ O singură traiectorie este o ilustrare, nu un studiu de mărime sau putere

C1 [Propus]: este volatilitatea Bitcoin mai previzibilă decât cea a S&P 500? — enunț

- **Date:** prognozele pe o zi pentru SPY și Bitcoin, aceeași fereastră calendaristică 1 martie 2025 – 18 septembrie 2026 (567 de zile calendaristice: SPY 389 de zile de tranzacționare, Bitcoin 422 de zile)
- **Cerințe**
 1. Definiți trei măsuri și calculați-le pentru fiecare activ: R^2 de calibrare al lui $\ln V_t$ pe $\ln F_t$; câștigul QLIKE $1 - \overline{\text{QLIKE}}_{\text{log-HAR}} / \overline{\text{QLIKE}}_{\text{RV ieri}}$; același câștig față de GARCH.
 2. Construiți un CI de 95% pentru diferența de R^2 (Bitcoin minus SPY): reeșantionați aceleași blocuri de 28 de zile calendaristice pentru ambele active (de 2 000 de ori), păstrînd zilele lipsă ale fiecărui activ.
 3. Adăugați în log-HAR pentru Bitcoin o variabilă pentru ziua-țintă de weekend, prognozați din nou și aplicați DM după QLIKE cu și fără ea.
- **Raportați:** tabelul, CI, rezultatul DM și un răspuns în două propoziții; extensie de proiect: Ethereum sau o acțiune BVB și măsura de entropie din [Pele & Mazurencu-Marinescu-Pele \(2019\)](#)

C3 [Propus]: învățarea automată sau HAR pentru SPY? — tema de proiect (1/3)

- Context: [Christensen, Siggaard & Veliyev \(2023\)](#) arată că modelele random forest și rețelele neuronale întrec HAR când se adaugă predictorii la valorile trecute ale RV și că avantajul crește odată cu orizontul de prognoză ([Capitolul 9](#), studiul de caz). Testați acest rezultat pe SPY, cu împărțirea eșantionului și setările modelelor din lucrare.
- (a) Construiți RV zilnică SPY de la deschidere la închidere din barele de 5 minute ale sesiunii obișnuite de tranzacționare (78 de randamente pe zi, ca la B1) și trei ținte: RV_{t+1} , media RV pe următoarele 5 zile și media pe următoarele 22 de zile (Secțiunea 4 a lucrării).
- (b) Construiți două seturi de predictorii disponibili la momentul t : $\mathcal{M}_{\text{HAR}}$ cu RV zilnică, săptămînală și lunară și $\mathcal{M}_{\text{ALL}}$, care adaugă VIX, pătratul randamentului log zilnic al indicelui Hang Seng, momentumul SPY pe o săptămîină, diferența de ordinul întâi a logaritmului volumului în dolari, diferența de ordinul întâi a ratei titlurilor de stat la 3 luni (FRED, DTB3), indicele zilnic al incertitudinii politicii economice (FRED, USEPUINXD) și indicele condițiilor de afaceri Aruoba–Diebold–Scotti (Federal Reserve Bank of Philadelphia). Datați fiecare predictor după data publicării, nu după data la care se referă: folosiți doar valorile publicate pînă la închiderea zilei t (pentru indicele Aruoba–Diebold–Scotti, care este revizuit, versiunile în timp real ale Philadelphia Fed) și precizați seriile pentru care aceste versiuni nu sînt disponibile.
- Precizați care dintre predictorii lucrării (Tabelul 1) nu pot fi construiți pentru un fond indexat și de ce: aceasta este o limitare a datelor, nu un motiv pentru a schimba metoda.

C3 [Propus]: învățarea automată sau HAR pentru SPY? — tema de proiect (2/3)

- (c) Împărțiți eșantionul ca în Anexa A.1 a lucrării: primele 1 000 de zile utilizabile pentru antrenare, următoarele 200 pentru validare, restul pentru test; un rînd aparține unui subset doar dacă întreaga fereastră a țintei se află în acel subset (eliminați ultimele $h - 1$ rînduri dinaintea fiecărei granițe) și raportați numărul de observații utilizabile pentru fiecare orizont; standardizați fiecare predictor doar cu media și varianța din setul de antrenare.
- (d) Estimați HAR, log-HAR (proгноza $\exp(\hat{f} + \hat{\sigma}^2/2)$) și OLS pe toți predictorii pe o fereastră mobilă care reunește seturile de antrenare și validare; elastic net pe o fereastră mobilă de antrenare, fără reunire, cu λ și ponderea de combinare alese pe setul de validare (Secțiunea 2 a lucrării); un random forest cu 500 de arbori pe fereastra reunită, $\lfloor J/3 \rfloor$ predictorii candidați la fiecare ramificare (J : numărul de predictorii) și cel puțin 5 observații într-un nod (Tabelul A.6 din lucrare); și NN_2^{10} : straturi de 4 și 2 neuroni, leaky ReLU, Adam cu rata de învățare 0,001, dropout 0,8, early stopping după 100 de epoci fără îmbunătățirea erorii pe setul de validare, media celor mai bune 10 din 100 de inițializări, antrenată o singură dată pe o fereastră fixă (celelalte setări ca în Tabelul A.6 din lucrare). HAR își păstrează cei trei regresori RV în ambele mulțimi de informații. Înlocuiți prognozele negative cu cea mai mică RV din eșantion.

C3 [Propus]: învățarea automată sau HAR pentru SPY? — tema de proiect (3/3)

- (e) Raportați un tabel cu MSE și QLIKE pe setul de test, relative la HAR, pentru cele trei orizonturi și ambele mulțimi de informații, valorile p ale testului DM unilateral față de HAR (erori HAC pentru țintele suprapuse de 5 și 22 de zile, cu o lățime de bandă mai mare decât $h - 1$, deoarece ponderile Bartlett reduc contribuția autocovarianței de ordin $h - 1$, și o analiză de sensibilitate după lățimea de bandă) și MCS de 90%, ca la B9.
- Interpretare
 - ▶ se păstrează pe SPY clasamentul din Tabelele 2, 3 și 7 ale lucrării?
 - ▶ crește avantajul ML cu orizontul?
 - ▶ se păstrează avantajul ML după QLIKE?
 - ▶ cu un set de test de această lungime, ce vă poate spune un test DM nesemnificativ?
- Exemplu de urmat: B5, A6.
- Extensie de proiect: repetați pe RV Bitcoin pe 24 de ore și comparați între modele importanța RV și a VIX, măsurată prin efectele locale acumulate (Figura 7 a lucrării).

Bibliografie (1/2)

- ▣ Andersen, T.G., Bollerslev, T., Diebold, F.X. (2007). [Roughing it up: including jump components in the measurement, modeling, and forecasting of return volatility](#). *Review of Economics and Statistics*, 89(4), 701–720.
- ▣ Andersen, T.G., Bollerslev, T., Diebold, F.X., Labys, P. (2001). [The distribution of realized exchange rate volatility](#). *Journal of the American Statistical Association*, 96(453), 42–55.
- ▣ Bandi, F.M., Russell, J.R. (2008). [Microstructure noise, realized variance, and optimal sampling](#). *Review of Economic Studies*, 75(2), 339–369.
- ▣ Barndorff-Nielsen, O.E., Hansen, P.R., Lunde, A., Shephard, N. (2008). [Designing realized kernels to measure the ex post variation of equity prices in the presence of noise](#). *Econometrica*, 76(6), 1481–1536.
- ▣ Barndorff-Nielsen, O.E., Shephard, N. (2004). [Power and bipower variation with stochastic volatility and jumps](#). *Journal of Financial Econometrics*, 2(1), 1–37.
- ▣ Benjamini, Y., Hochberg, Y. (1995). [Controlling the false discovery rate: a practical and powerful approach to multiple testing](#). *Journal of the Royal Statistical Society, Series B*, 57(1), 289–300.
- ▣ Benjamini, Y., Yekutieli, D. (2001). [The control of the false discovery rate in multiple testing under dependency](#). *The Annals of Statistics*, 29(4), 1165–1188.
- ▣ Bollerslev, T., Patton, A.J., Quaedvlieg, R. (2016). [Exploiting the errors: a simple approach for improved volatility forecasting](#). *Journal of Econometrics*, 192(1), 1–18.
- ▣ Boudt, K., Croux, C., Laurent, S. (2011). [Robust estimation of intraweek periodicity in volatility and jump detection](#). *Journal of Empirical Finance*, 18(2), 353–367.
- ▣ Christensen, K., Siggaard, M., Veliyev, B. (2023). [A machine learning approach to volatility forecasting](#). *Journal of Financial Econometrics*, 21(5), 1680–1727.
- ▣ Corsi, F. (2009). [A simple approximate long-memory model of realized volatility](#). *Journal of Financial Econometrics*, 7(2), 174–196.
- ▣ Diebold, F.X., Mariano, R.S. (1995). [Comparing predictive accuracy](#). *Journal of Business & Economic Statistics*, 13(3), 253–263.

Bibliografie (2/2)

- ▣ Duan, N. (1983). [Smearing estimate: a nonparametric retransformation method](#). *Journal of the American Statistical Association*, 78(383), 605–610.
- ▣ Franke, J., Härdle, W.K., Hafner, C.M. (2019). [Statistics of Financial Markets: An Introduction](#), 5th ed. Springer.
- ▣ Gatheral, J., Jaisson, T., Rosenbaum, M. (2018). [Volatility is rough](#). *Quantitative Finance*, 18(6), 933–949.
- ▣ Giacomini, R., White, H. (2006). [Tests of conditional predictive ability](#). *Econometrica*, 74(6), 1545–1578.
- ▣ Hansen, P.R., Lunde, A., Nason, J.M. (2011). [The model confidence set](#). *Econometrica*, 79(2), 453–497.
- ▣ Huang, X., Tauchen, G. (2005). [The relative contribution of jumps to total price variance](#). *Journal of Financial Econometrics*, 3(4), 456–499.
- ▣ Künsch, H.R. (1989). [The jackknife and the bootstrap for general stationary observations](#). *Annals of Statistics*, 17(3), 1217–1241.
- ▣ Liu, L.Y., Patton, A.J., Sheppard, K. (2015). [Does anything beat 5-minute RV? A comparison of realized measures across multiple asset classes](#). *Journal of Econometrics*, 187(1), 293–311.
- ▣ Patton, A.J. (2011). [Volatility forecast comparison using imperfect volatility proxies](#). *Journal of Econometrics*, 160(1), 246–256.
- ▣ Patton, A.J., Sheppard, K. (2015). [Good volatility, bad volatility: signed jumps and the persistence of volatility](#). *Review of Economics and Statistics*, 97(3), 683–697.
- ▣ Pele, D.T., Mazurencu-Marinescu-Pele, M. (2019). [Using high-frequency entropy to forecast Bitcoin's daily value at risk](#). *Entropy*, 21(2), 102.
- ▣ Zhang, L., Mykland, P.A., Aït-Sahalia, Y. (2005). [A tale of two time scales: determining integrated volatility with noisy high-frequency data](#). *Journal of the American Statistical Association*, 100(472), 1394–1411.