



Modelarea piețelor financiare

Seminarul 9: Volatilitate realizată — aplicații



Daniel Traian PELE

Drd. Antoaneta Amza, antoaneta.amza@csie.ase.ro

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

Acronime folosite în acest material

- ▣ AI: Artificial Intelligence (inteligență artificială)
- ▣ AR: AutoRegressive (model) (model autoregresiv)
- ▣ BV: Bipower Variation (variația bipower)
- ▣ BVB: Bursa de Valori București
- ▣ CI: Confidence Interval (interval de încredere)
- ▣ DM: Diebold–Mariano (test) (testul Diebold–Mariano de comparare a prognozelor)
- ▣ GARCH: Generalised AutoRegressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă generalizată)
- ▣ HAC: Heteroskedasticity and Autocorrelation Consistent (standard errors) (erori standard robuste la heteroscedasticitate și autocorelație)
- ▣ HAR: Heterogeneous AutoRegressive (model) (model autoregresiv heterogen)
- ▣ HAR-CJ: HAR model with Continuous and Jump components (model HAR cu componentă continuă și componentă de salt)
- ▣ JB: Jarque–Bera (test) (testul de normalitate Jarque–Bera)
- ▣ MAE: Mean Absolute Error (eroarea absolută medie)
- ▣ MSE: Mean Squared Error (eroarea pătratică medie)
- ▣ MZ: Mincer–Zarnowitz (regression) (regresia Mincer–Zarnowitz)
- ▣ NW: Newey–West (standard errors) (erori standard Newey–West)
- ▣ OLS: Ordinary Least Squares (metoda celor mai mici pătrate)
- ▣ QLIKE: Quasi-LIKelihood (loss function) (funcția de pierdere de tip cvasi-verosimilitate)
- ▣ RV: Realised Variance (varianța realizată)
- ▣ SE: Standard Error (eroare standard)
- ▣ SUA: Statele Unite ale Americii
- ▣ TQ: Tripower Quarticity (cvarticitatea tripower)
- ▣ UTC: Coordinated Universal Time (Temps Universel Coordonné) (timpul universal coordonat)
- ▣ VIX: CBOE Volatility IndeX (indicele de volatilitate CBOE)

Cuprins

Introducere

Partea A: pe hârtie

Partea B: calcul și inferență

Partea C: întrebare deschisă și critica unui răspuns AI

Încheiere

Bibliografie

Obiectivele seminarului

La finalul seminarului puteți

- ▣ Calcula pas cu pas varianța realizată și variația bipower și testa o zi pentru salturi
 - ▣ Cuantifica deplasarea din zgomotul de microstructură și alege o frecvență de eșantionare
 - ▣ Estima modele HAR cu erori standard robuste și prognoza varianța
 - ▣ Compara prognoze de varianță cu QLIKE, Diebold–Mariano și Mincer–Zarnowitz
- ▣ Suport: Cursul 9; manualul [Franke, Härdle & Hafner \(2019\)](#)

Structura

- ▣ **Partea A:** opt exerciții pe hârtie (A1–A8)
- ▣ **Partea B:** opt exerciții pe calculator, cu inferență, pe SPY și Bitcoin (B1–B8)
- ▣ **Partea C:** o întrebare deschisă, punct de plecare pentru proiectul de echipă (C1) și critica unui răspuns AI (C2)

Cum lucrăm la acest seminar

- ▣ Problemele **[Rezolvat]** au rezolvarea completă; problemele **[Propus]** au doar cerința: rezolvările se discută la seminar
- ▣ Fiecare problemă propusă indică **modelul**: problema rezolvată care folosește aceeași tehnică
 - ▶ Fiecare exercițiu din Partea B se încheie cu întrebări de interpretare
- ▣ Unități: randamente în %, varianțe zilnice în $\%^2$; anualizăm cu 252 de zile (SPY) sau 365 de zile (Bitcoin)
- ▣ Fiecare măsură realizată zilnică este ea însăși o estimare: raportați cât de precisă este

Probleme rezolvate și propuse

Rezolvate: exemple lucrate în acest material

- ▣ Partea A: A1 (RV și BV pas cu pas), A3 (deplasarea din zgomot și eșantionarea optimă), A5 (o prognoză log-HAR), A6 (QLIKE și MSE)
- ▣ Partea B: B1 (testul de salturi pe SPY), B3 (frecvența de eșantionare cu bootstrap pe blocuri), B5 (log-HAR cu erori Newey–West)

Propuse: le rezolvați voi

- ▣ Partea A: A2 (un salt în șase randamente; model: A1), A4 (RV pe două scări; model: A3), A7 (prognoză pe două zile; model: A5), A8 (DM și MZ pas cu pas; model: A6)
- ▣ Partea B: B2 (salturi Bitcoin; model: B1), B4 (randamente standardizate; model: B3), B6 (prognoze pe 5 zile; model: B5, A6, A8), B7 (HAR-CJ; model: B5, B1), B8 (asprimea; model: B3)
- ▣ Partea C: C1, întrebare deschisă și sămânță de proiect; C2, critica unui răspuns AI

Pregătire: mediul Python și datele

- ▣  **Deschide în Colab:** `capitol9_notebook_seminar.ipynb`
- ▣ Google Colab (recomandat) sau Python local ≥ 3.10 cu `numpy`, `pandas`, `scipy`, `statsmodels`, `arch`, `matplotlib`
- ▣ SPY, bare de 5 minute din sesiunea regulată din SUA, octombrie 2020 – septembrie 2026; Bitcoin, bare de 5 minute, zile UTC de 24 de ore, septembrie 2024 – septembrie 2026
- ▣ Închideri zilnice SPY (ajustate) și Bitcoin pentru GARCH; varianța zilnică totală $SPY = RV_{intraday} + \text{randamentul peste noapte la pătrat}$

Formulele folosite azi

- $RV_t = \sum_{i=1}^M r_{t,i}^2$; $BV_t = \frac{\pi}{2} \frac{M}{M-1} \sum_{i=2}^M |r_{t,i}| |r_{t,i-1}|$; $se(RV_t) = \sqrt{\frac{2}{3} \sum_i r_{t,i}^4}$
- Testul de salturi [Huang & Tauchen \(2005\)](#): $z_t = \frac{(RV_t - BV_t)/RV_t}{\sqrt{\theta M^{-1} \max(\mathbf{1}, \mathbf{TQ}_t/BV_t^2)}}$, $\theta = \pi^2/4 + \pi - 5$
- Zgomot: $\mathbb{E}[RV^{(n)}] = IV + 2n\omega^2$; $n^* = (IQ/(4\omega^4))^{1/3}$ [Bandi & Russell \(2008\)](#); RV pe două scări = $RV^{avg} - \frac{\bar{n}}{n} RV^{all}$ [Zhang, Mykland & Aït-Sahalia \(2005\)](#)
- log-HAR [Corsi \(2009\)](#): $\ln RV_{t+1} = \beta_0 + \beta_d \ln RV_t + \beta_w \overline{\ln RV_t^{(5)}} + \beta_m \overline{\ln RV_t^{(22)}} + \varepsilon_{t+1}$
- QLIKE = $RV/F - \ln(RV/F) - 1$ [Patton \(2011\)](#); DM: $t = \bar{d}/se_{NW}(\bar{d})$ [Diebold & Mariano \(1995\)](#); MZ: $RV_t = a + bF_t + u_t$, $H_0 : a = 0, b = 1$

A1: varianța realizată și variația bipower, pas cu pas [Rezolvat]

Cerință

- ▣ Șase randamente consecutive de 5 minute (%):
0,08, -0,15, 0,03, 0,10, -0,04, 0,12
- ▣ (a) Varianța realizată a jumătății de oră
- ▣ (b) Variația bipower și ponderea $(RV - BV)/RV$
- ▣ (c) RV din două randamente de 15 minute; volatilitatea anualizată dacă întreaga zi ($M = 78$) ar arăta ca această jumătate de oră

Rezolvare

- ▣ Pătrate: 0,0064, 0,0225, 0,0009, 0,0100, 0,0016, 0,0144;
 $RV = 0,0558$
- ▣ $|r_i||r_{i-1}|$: 0,0120, 0,0045, 0,0030, 0,0040, 0,0048; suma
0,0283
- ▣ $BV = \frac{\pi}{2} \cdot \frac{6}{5} \cdot 0,0283 = 0,0533$; $(RV - BV)/RV = 0,044$:
niciun semn de salt
- ▣ 15 minute:
 $(0,08 - 0,15 + 0,03)^2 + (0,10 - 0,04 + 0,12)^2 = 0,0340$:
un număr zgomotos din două randamente
- ▣ $\sqrt{252 \times 0,0558 \times 78/6} = 13,5\%$ pe an

A2: un salt în șase randamente [Propus]

Rezolvarea se discută la seminar

Cerință

- ▣ Aceleași randamente ca în A1, dar ultimul este $-0,90\%$ (un salt produs de o știre)
- ▣ (a) RV, BV și partea de salt $RV - BV$
- ▣ (b) Statistica raportului z cu $M = 6$, știind că $TQ = 0,0097$; respingem la nivelul de $0,1\%$?
- ▣ (c) De ce poate testul să rateze un salt care reprezintă cea mai mare parte a variației?
- ▣ Model: A1

A3: deplasarea din zgomot și eșantionarea optimă [Rezolvat]

Cerință

- $IV = 1\%^2$ pe zi; zgomot i.i.d. cu $\omega = 0,01\%$; sesiune de 23 400 de secunde
- (a) $\mathbb{E}[RV]$ cu randamente la 5 minute, 1 minut, 1 secundă
- (b) n^* optim după MSE cu $IQ = IV^2$ și intervalul corespunzător
- (c) Ce interval ați folosi în practică și de ce?

Rezolvare

- $n = 78$: $1 + 2 \cdot 78 \cdot 0,0001 = 1,0156$; $n = 390$: 1,0780;
 $n = 23\,400$: 5,6800
- $n^* = (1/(4 \cdot 10^{-8}))^{1/3} = 292$: un randament la fiecare 23 400/292 = 80 de secunde
- 1–5 minute: aproape de n^* , deplasare sub 8%; MSE este plat în jurul lui n^* , iar 5 minute este robust la un ω mai mare

A4: o acțiune mai puțin lichidă [Propus]

Rezolvarea se discută la seminar

Cerință

- O acțiune BVB cu $IV = 1\%^2$ și zgomot $\omega = 0,03\%$ (spread mai mare, pas de cotare mai mare)
- (a) Deplasarea la 5 minute și la 1 minut; n^* optim și intervalul de eșantionare
- (b) O zi: $RV^{all} = 1,70$ din randamente de 1 minut ($n = 390$), media pe 5 grile decalate de 5 minute $RV^{avg} = 1,10$; calculați RV pe două scări, cu și fără factorul pentru eșantioane mici
- (c) Estimați ω^2 din RV^{all}
- Model: A3

A5: o prognoză log-HAR [Rezolvat]

Cerință

- log-HAR SPY rotunjit: $\hat{\beta} = (-0,08, 0,36, 0,34, 0,17)$
- Azi: $RV_t = 2,0$; media log RV pe săptămână ln 1,2 și pe lună ln 0,9
- (a) Prognoza pentru mâine, în $\%^2$ și anualizată
- (b) Ponderile pe întârzierea 1, pe fiecare dintre 2–5, pe fiecare dintre 6–22
- (c) Persistența și nivelul de lungă durată implicat de model

Rezolvare

- $-0,08 + 0,36(0,693) + 0,34(0,182) + 0,17(-0,105) = 0,214$;
 $e^{0,214} = 1,238\%^2$, adică 17,7% pe an
- $w_1 = 0,36 + 0,34/5 + 0,17/22 = 0,436$; $w_{2..5} = 0,076$;
 $w_{6..22} = 0,008$
- Persistența $0,36 + 0,34 + 0,17 = 0,87$
- Nivelul de lungă durată $\exp(-0,08/(1 - 0,87)) = 0,540\%^2$
(11,7% pe an; înainte de corecția de varianță)

A6: QLIKE și MSE pas cu pas [Rezolvat]

Cerință

- Varianța realizată în trei zile: 0,8, 1,5, 0,6
- Prognoza A: 1,0, 1,0, 1,0 (constantă); prognoza B: 0,6, 1,6, 0,4
- (a) QLIKE și MSE medii pentru fiecare prognoză
- (b) Cu varianța adevărată 1: QLIKE pentru prognoza 0,5 vs 2,0

Rezolvare

- A: QLIKE 0,0231, 0,0945, 0,1108, media 0,0762; MSE 0,150
- B: QLIKE 0,0457, 0,0020, 0,0945, media 0,0474; MSE 0,030
- B câștigă după ambele: urmărește nivelul volatilității
- QLIKE: $F = 0,5$ dă 0,307, $F = 2,0$ dă 0,193: subestimarea este penalizată mai mult (MSE: 0,25 vs 1, invers)

A7: o prognoză log-HAR pe două zile [Propus]

Rezolvarea se discută la seminar

Cerință

- ▣ Modelul din A5; RV în ultimele cinci zile (azi prima): 2,0, 1,6, 1,3, 1,1, 1,0; media lunară a logaritmulor $\ln 0,9$
- ▣ (a) Prognoza pentru mâine
- ▣ (b) Prognoza pentru poimâine, iterativ: tratăm prognoza log de mâine ca observată, scoatem cea mai veche zi din săptămână și actualizăm media lunară ca $(21 \ln 0,9 + \hat{f}_1)/22$
- ▣ (c) De ce scade prognoza spre nivelul de lungă durată?
- ▣ Model: A5

A8: Diebold–Mariano și Mincer–Zarnowitz pas cu pas [Propus]

Rezolvarea se discută la seminar

Cerință

- ▣ Cursul 9, SPY 2022–2026: diferența medie QLIKE log-HAR minus GARCH $\bar{d} = -0,0327$, eroarea standard Newey–West 0,0142
- ▣ (a) Statistica DM și valoarea p bilaterală
- ▣ (b) MZ pentru GARCH: $\hat{a} = 0,24$ (SE 0,23), $\hat{b} = 0,70$ (SE 0,24): testați separat $a = 0$ și $b = 1$
- ▣ (c) Este „fără deplasare semnificativă” același lucru cu „o prognoză bună”?
- ▣ Model: A6

B1: salturi în SPY [Rezolvat]


Cerință

- ▣ SPY, randamente de 5 minute, 1 489 zile [Huang & Tauchen \(2005\)](#)
- ▣ (a) Statistica raportului z_t pentru fiecare zi; câte zile resping la 5%, 1%, 0,1%?
- ▣ (b) Comparați cu numărul așteptat fără salturi
- ▣ (c) În zilele cu salt la 0,1%: la ce oră este cel mai mare randament de 5 minute?

Interpretare

- ▣ Sunt mai multe respingeri decât ar da nivelul singur?
- ▣ Indică orele salturilor știri programate?
- ▣ Ce nivel ați folosi pentru a construi o componentă de salt pentru prognoză?

B1: rezultate [Rezolvat]



- Respingeri: 235 la 5% (așteptat 74,5), 110 la 1% (așteptat 14,9), 35 la 0,1% (așteptat 1,5); media $z = 0,50$, abaterea standard 1,14
- Zilele de top: 2021-08-27 ($z = 5,22$, saltul 49% din RV, intervalul care se încheie la 10:05), 2022-01-03 ($z = 5,21$, la 09:50), 2025-08-25 ($z = 4,77$, la 16:00)
- Mult mai multe respingeri decât cele așteptate: salturi reale, dar testul și respinge prea des când forma de U intraday face randamentele inegale
- Folosim 0,1%: puține salturi false; componenta de salt este atunci 2,8% din RV totală

B2: salturi în Bitcoin [Propus]

Rezolvarea se discută la seminar

Cerință

- Bitcoin, randamente de 5 minute, 659 zile UTC complete
- (a) Ponderea zilelor cu salt la 0,1%; test binomial față de nivel
- (b) Weekend vs zile lucrătoare: ponderea zilelor cu salt și media BV/RV
- (c) Ponderea salturilor în variația totală
- Model: B1

Interpretare

- De ce sunt zilele cu salt mai frecvente decât la SPY, în timp ce salturile aduc mai puțină varianță?
- Ce face o zi liniștită de weekend „cu salturi”?
- Ați modela împreună volatilitatea din weekend și din zilele lucrătoare?

B3: ce frecvență de eșantionare? [Rezolvat]


Cerință

- SPY: RV din randamente la fiecare 5, 15, 30 și 65 de minute (o grilă și media pe grilele decalate)
- (a) Volatilitatea anualizată medie la fiecare frecvență
- (b) Raportul dintre RV medie și RV pe 5 minute, cu CI de 95% prin bootstrap pe blocuri mobile (blocuri de 20 de zile) [Künsch \(1989\)](#)
- (c) Corelația dintre log RV de azi și log RV pe 5 minute de mâine

Interpretare

- Există deplasare din zgomot la 5 minute?
- De ce bootstrap pe blocuri și nu i.i.d.?
- Ce frecvență dă măsurarea cea mai utilă pentru prognoză?

B3: rezultate [Rezolvat]



Interval	Vol. (o grilă)	Vol. (media grilelor)	Raport [CI 95%]	Corel. ziua următoare	idem, media
5 min	12,93	12,93	1,000 [1,000, 1,000]	0,73	0,73
15 min	12,88	12,79	0,992 [0,954, 1,035]	0,71	0,72
30 min	12,75	12,77	0,973 [0,933, 1,015]	0,70	0,72
65 min	12,76	12,88	0,974 [0,913, 1,037]	0,64	0,70

- Toate intervalele conțin 1: nicio deplasare din zgomot măsurabilă pentru SPY la 5 minute (în acord cu graficul de semnătură plat)
- Bootstrap pe blocuri: RV zilnice sunt puternic autocorelate; reeșantionarea i.i.d. ar face CI prea îngust
- Corelația predictivă scade de la 0,73 (5 min) la 0,64 (65 min, o grilă): RV rară este mai zgomotoasă; media pe grilele decalate recuperează o parte (0,70)

B4: randamente standardizate cu volatilitatea realizată [Propus]

Rezolvarea se discută la seminar

Cerință

- Randamentele SPY deschidere-închidere și randamentele zilnice Bitcoin Andersen et al. (2001)
- (a) Aplatizarea lui $r_t/\text{sd}(r)$ și a lui $r_t/\sqrt{RV_t}$, fiecare cu CI de 95% prin bootstrap pe blocuri
- (b) Testul Jarque-Bera și ponderea $|z| > 3$ comparată cu valoarea Normală 0,27%
- Model: B3 (bootstrap pe blocuri)

Interpretare

- De unde provin cozile grele ale randamentelor zilnice?
- De ce este aplatizarea lui $r_t/\sqrt{RV_t}$ ușor **sub** 3?
- Ce implică acest lucru pentru un model VaR (Capitolul 7)?

B5: log-HAR pentru SPY cu inferență robustă [Rezolvat]

Cerință

- ▣ Varianța zilnică totală SPY, 1 467 zile după prima lună Corsi (2009)
- ▣ (a) log-HAR prin OLS; erori standard obișnuite și Newey–West (7 întârzieri)
- ▣ (b) Testul Wald $\beta_w = \beta_m$
- ▣ (c) Testul Ljung–Box pe reziduuri (22 de întârzieri) și pe log RV însăși; comparați cu un AR(1)

Interpretare

- ▣ Care componentă contează cel mai mult?
- ▣ Schimbă erorile standard robuste vreo concluzie?
- ▣ A surprins HAR memoria lungă?

B5: rezultate [Rezolvat]

	$\hat{\beta}$	SE OLS	SE NW	t_{NW}
β_0	-0,079	0,025	0,027	-3,0
β_d	0,362	0,031	0,037	9,8
β_w	0,337	0,049	0,048	7,0
β_m	0,167	0,046	0,044	3,8

- ▣ $R^2 = 0,470$ față de 0,413 pentru un AR(1) ($\hat{\phi} = 0,643$); persistența 0,866
- ▣ Componenta zilnică este cea mai mare, dar cea săptămânală și cea lunară sunt puternic semnificative; erorile NW sunt cu până la 20% mai mari, nicio concluzie nu se schimbă
- ▣ Wald $\beta_w = \beta_m$: 4,17 ($p = 0,041$): ponderea săptămânală este mai mare
- ▣ Ljung-Box(22): log RV 4641, reziduuri 17,5 ($p = 0,73$): trei coeficienți absorb memoria lungă

B6: prognoza săptămânii următoare [Propus]

Rezolvarea se discută la seminar

Cerință

- ▣ SPY, ținta $\sum_{j=0}^4 RV_{t+j}$ (următoarele 5 zile), prognoze făcute în seara dinaintea lui t , din ianuarie 2022
- ▣ (a) Regresia log-HAR directă a sumei pe 5 zile; fereastră extinsă
- ▣ (b) GARCH(1,1)- t : $\sum_{h=0}^4 [\bar{\sigma}^2 + (\alpha + \beta)^h (\sigma_t^2 - \bar{\sigma}^2)]$
- ▣ (c) QLIKE, MSE, testul DM, regresia MZ
- ▣ Model: B5, A6, A8

Interpretare

- ▣ Se păstrează avantajul log-HAR la un orizont săptămânal?
- ▣ Ținte pe 5 zile care se suprapun: ce efect are asupra testului DM?
- ▣ Care model este deplasat și în ce direcție?

B7: ajută salturile? Modelul HAR-CJ [Propus]

Rezolvarea se discută la seminar

Cerință

- SPY; partea continuă $C_t = RV$ fără salturile semnificative (0,1%) plus randamentul peste noapte la pătrat; partea de salt J_t Andersen, Bollerslev & Diebold (2007)
- (a) Regresați $\ln$ varianța totală pe $\ln C$ (zi, săptămână, lună) și $\ln(1 + J_t)$, cu erori Newey–West
- (b) QLIKE în afara eșantionului față de log-HAR din 2022; testul DM
- Model: B5, B1

Interpretare

- Este coeficientul salturilor semnificativ? Ce semn vă așteptați?
- De ce un coeficient semnificativ poate să nu aducă niciun câștig de prognoză?

B8: cât de aspră este volatilitatea? [Propus]

Rezolvarea se discută la seminar

Cerință

- SPY; $\ln \sigma_t = \frac{1}{2} \ln(\text{măsura})$ pentru patru măsuri: varianța totală, RV intraday, BV, RV subeșantionată la 30 de minute [Gatheral, Jaisson & Rosenbaum \(2018\)](#)
- (a) $\hat{H}$ din $m(q, \Delta)$, $q \in \{0,5, 1, 1,5, 2, 3\}$, $\Delta = 1, \dots, 30$
- (b) CI de 95% prin bootstrap pe blocuri (blocuri de 60 de zile, 300 de reeșantionări)
- (c) Simulați o mișcare browniană ($H = 0,5$), adăugați zgomot și estimați din nou H
- Model: B3 (bootstrap pe blocuri)

Interpretare

- Este H sub 0,5 pentru fiecare măsură?
- Ce efect are eroarea de măsurare asupra lui $\hat{H}$?

C1: este volatilitatea Bitcoin mai previzibilă decât cea a S&P 500? [Propus]

- ▣ Aceeași fereastră în afara eșantionului pentru ambele: martie 2025 – septembrie 2026
 - ▶ log-HAR, GARCH(1,1)- t și RV de ieri pentru SPY (varianța totală) și Bitcoin (RV pe 24 de ore)
- ▣ Definiți „previzibil”: R^2 al log RV pe prognoza log, câștigul QLIKE față de RV de ieri, câștigul față de GARCH
- ▣ Construiți un CI prin bootstrap pe blocuri pentru diferența de R^2 dintre cele două active
- ▣ Îmbunătățiți modelul pentru Bitcoin cu ce ați aflat la B2 (weekendurile); se schimbă răspunsul?
- ▣ Extensie de proiect: adăugați Ethereum sau o acțiune BVB și măsura de entropie din [Pele & Mazurencu-Marinescu-Pele \(2019\)](#) ca regresor

C2: critica unui răspuns AI (1/3) [Propus]

Rezolvarea se discută la seminar

Studentul întreabă un asistent AI

- „Am prețurile tranzacțiilor SPY, fiecare tranzacție între 09:30 și 16:00, într-o serie pandas px cu index de timp. Calculează varianța realizată zilnică, volatilitatea anualizată și regresorii HAR.”

Răspunsul AI: text

- $RV_t = \sum_i r_{t,i}^2$, cu $r_{t,i}$ randamentele log intraday din ziua t Andersen et al. (2001)
- Folosiți fiecare tranzacție: mai multe randamente fac întotdeauna RV_t mai precisă
- RV_t este varianța zilnică a SPY: comparați-o direct cu pătratul randamentelor de la o închidere la alta și cu varianța GARCH
- HAR: regresia lui RV_{t+1} pe RV_t și pe mediile lui pe 5 și pe 22 de zile Corsi (2009)

C2: critica unui răspuns AI (2/3) [Propus]

Rezolvarea se discută la seminar

Răspunsul AI: codul primit împreună cu textul

```
import numpy as np, pandas as pd
lp = np.log(px)
r = lp.groupby(lp.index.date).diff().dropna()
RV = (r**2).groupby(r.index.date).sum()
vol_ann = np.sqrt(RV) * 252
H = pd.DataFrame({'d': RV,
                  'w': RV.rolling(5).mean(),
                  'm': RV.rolling(22).mean(),
                  'y': RV.shift(-1)}).dropna()
```

C2: critica unui răspuns AI (3/3) [Propus]

Rezolvarea se discută la seminar

Cerință

- ▣ Răspunsul conține trei erori; restul este corect: găsiți-le
- ▣ Pentru fiecare eroare, spuneți cum ați detecta-o: un test, o cifră publicată, cursul
- ▣ Dați varianta corectă: formula, linia de cod și cifra
- ▣ Consemnați fiecare eroare ca în `AI_ERRORS.md`
 - ▶ Ce ați întrebat, ce a răspuns AI-ul, ce era greșit, cum v-ați dat seama, varianta corectă

Indicații

- ▣ Ce spune A3 despre $\mathbb{E}[RV^{(n)}]$ când prețurile conțin zgomot?
- ▣ Ce se întâmplă cu SPY între 16:00 și 09:30 a doua zi?
- ▣ Înlocuiți o zi obișnuită, $RV_t = 1,0 \times 10^{-4}$ ($1\%^2$): este plauzibilă volatilitatea anualizată pentru SPY?

Greșeli frecvente

- ▣ Eșantionarea fiecărei tranzacții fără a verifica graficul semnăturii
- ▣ Omiterea randamentului peste noapte: RV intraday subestimează varianța zilnică SPY cu aproximativ o treime
- ▣ Tratarea RV ca varianță adevărată: are o eroare standard și face ca R^2 al prognozelor să pară mic
- ▣ Compararea prognozelor de volatilitate cu MAE sau cu MSE pe volatilitate: nu sunt robuste la proxy-ul zgomotos
- ▣ Erori standard OLS obișnuite în HAR și bootstrap i.i.d. pentru RV zilnică: ambele ignoră autocorelația
- ▣ Citirea oricărui test de salt semnificativ ca un salt produs de știri: mii de teste dau alarme false

Temă pentru acasă (proiect de echipă)

- ▣ Alegeți un activ cu date intraday nediscutat la seminar (Ethereum, o pereche valutară, o acțiune)
- ▣ Construiți RV, BV și o componentă de salt zilnice; arătați graficul semnăturii și tiparul intraday
- ▣ Comparați log-HAR (cu cel puțin o extensie) și GARCH în afara eșantionului cu QLIKE, DM și MZ
- ▣ Livrați un folder Quantlet (cod, Metainfo, grafice) și trei slide-uri: cifre, interpretare, limite
- ▣ Consemnați fiecare eroare AI pe care o prindeți (cel puțin trei pe proiect) în `AI_ERRORS.md` și declarați folosirea AI în `AI_USE.md`

Studiu suplimentar pe Quantinar

Cursuri avansate pe quantinar.com

- ☐  Nonparametric and Semiparametric Models
- ☐  Applied Time Series Analysis with Python

Cod și date

- ☐ Notebook-ul seminarului (Colab); Quantlets: github.com/danpele/MFM/tree/main/Quantlets/Ch_09

Bibliografie

- ▣ Andersen, T.G., Bollerslev, T., Diebold, F.X. (2007). [Roughing it up: including jump components in the measurement, modeling, and forecasting of return volatility](#). *Review of Economics and Statistics*, 89(4), 701–720.
- ▣ Andersen, T.G., Bollerslev, T., Diebold, F.X., Labys, P. (2001). [The distribution of realized exchange rate volatility](#). *Journal of the American Statistical Association*, 96(453), 42–55.
- ▣ Bandi, F.M., Russell, J.R. (2008). [Microstructure noise, realized variance, and optimal sampling](#). *Review of Economic Studies*, 75(2), 339–369.
- ▣ Barndorff-Nielsen, O.E., Shephard, N. (2004). [Power and bipower variation with stochastic volatility and jumps](#). *Journal of Financial Econometrics*, 2(1), 1–37.
- ▣ Corsi, F. (2009). [A simple approximate long-memory model of realized volatility](#). *Journal of Financial Econometrics*, 7(2), 174–196.
- ▣ Diebold, F.X., Mariano, R.S. (1995). [Comparing predictive accuracy](#). *Journal of Business & Economic Statistics*, 13(3), 253–263.
- ▣ Franke, J., Härdle, W.K., Hafner, C.M. (2019). [Statistics of Financial Markets: An Introduction](#), 5th ed. Springer.
- ▣ Gatheral, J., Jaisson, T., Rosenbaum, M. (2018). [Volatility is rough](#). *Quantitative Finance*, 18(6), 933–949.
- ▣ Huang, X., Tauchen, G. (2005). [The relative contribution of jumps to total price variance](#). *Journal of Financial Econometrics*, 3(4), 456–499.
- ▣ Künsch, H.R. (1989). [The jackknife and the bootstrap for general stationary observations](#). *Annals of Statistics*, 17(3), 1217–1241.
- ▣ Patton, A.J. (2011). [Volatility forecast comparison using imperfect volatility proxies](#). *Journal of Econometrics*, 160(1), 246–256.
- ▣ Pele, D.T., Mazurencu-Marinescu-Pele, M. (2019). [Using high-frequency entropy to forecast Bitcoin's daily value at risk](#). *Entropy*, 21(2), 102.
- ▣ Zhang, L., Mykland, P.A., Aït-Sahalia, Y. (2005). [A tale of two time scales: determining integrated volatility with noisy high-frequency data](#). *Journal of the American Statistical Association*, 100(472), 1394–1411.