



## Modelarea piețelor financiare

### Seminarul 13: Machine Learning în finanțe — aplicații



Daniel Traian PELE

Antoaneta Amza

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognostic Economică

MSCA Digital Finance

## Acronime folosite în acest material (1/2)

- ▣ ADF: Augmented Dickey–Fuller (test) (testul Dickey–Fuller augmentat)
- ▣ AI: Artificial Intelligence (inteligență artificială)
- ▣ AUC: Area Under the (ROC) Curve (aria de sub curba ROC)
- ▣ CI: Confidence Interval (interval de încredere)
- ▣ CSCV: Combinatorially Symmetric Cross-Validation (validare încrucișată combinatorie simetrică)
- ▣ CV: Cross-Validation (validare încrucișată)
- ▣ DM: Diebold–Mariano (test) (testul Diebold–Mariano de comparare a prognozelor)
- ▣ DSR: Deflated Sharpe Ratio (raportul Sharpe deflatat)
- ▣ EWMA: Exponentially Weighted Moving Average (medie mobilă ponderată exponențial)
- ▣ FFD: Fixed-width window Fractional Differentiation (diferențiere fracționară cu fereastră fixă)
- ▣ FN: False Negative (fals negativ)
- ▣ GB: Gradient Boosting (boosting pe gradient)
- ▣ HAC: Heteroskedasticity and Autocorrelation Consistent (standard errors) (erori standard robuste la heteroscedasticitate și autocorelație)
- ▣ HP: Hodrick–Prescott (filter) (filtrul Hodrick–Prescott)
- ▣ LASSO: Least Absolute Shrinkage and Selection Operator (regresie penalizată L1 cu selecția variabilelor)
- ▣ MA: Moving Average (medie mobilă)
- ▣ MA20: 20-day Moving Average (medie mobilă pe 20 de zile)
- ▣ MDI: Mean Decrease Impurity (scăderea medie a impurității)
- ▣ ML: Machine Learning (învățare automată)
- ▣ PBO: Probability of Backtest Overfitting (probabilitatea de supraajustare a backtest-ului)
- ▣ PSR: Probabilistic Sharpe Ratio (raportul Sharpe probabilistic)
- ▣ RF: Random Forest (pădure aleatoare)
- ▣ ROC: Receiver Operating Characteristic (curve) (curba caracteristică de operare)
- ▣ RSI: Relative Strength Index (indicele puterii relative)
- ▣ SE: Standard Error (eroare standard)
- ▣ SR: Sharpe Ratio (raportul Sharpe)

## Acronime folosite în acest material (2/2)

- **TN: True Negative (adevărat negativ)**
- **TP: True Positive (adevărat pozitiv)**

# Cuprins

Obiective și pregătire

Partea A: probleme pe hârtie

Partea B: probleme în Python pe date cripto

Partea C: problemă deschisă și critica unui răspuns AI

Temă și aprofundare

## Definiții-cheie (1/3): date, etichete, validare

### Caracteristici și etichete

- **FFD**:  $\tilde{X}_t = \sum_{k=0}^K w_k X_{t-k}$ , ponderi trunchiate când  $|w_k| < \tau$
- **ADF (Dickey & Fuller (1979))**:  $H_0$ : rădăcină unitară; respingem (serie staționară) dacă statistica e sub valoarea critică de 5%
- **EWMA**: abaterea standard a randamentelor log zilnice, cu ponderi descrescătoare exponențial (span 50)
- **Trei bariere**: eticheta  $+1/-1$  dacă bariera superioară/inferioară (multipli  $pt$ ,  $sl$  ai lui  $\sigma_{t_0} \sqrt{h}$ ) e atinsă prima; altfel semnul la  $t_0 + h$

### Validare

- **K-fold CV**:  $K$  blocuri; estimăm pe  $K - 1$ , testăm pe 1, repetăm
- **Leakage**: datele de antrenare conțin informație care se află și în datele de test
- **Purjare / embargo**: eliminăm observațiile de antrenare a căror fereastră de etichetă se suprapune cu testul, plus câteva imediat după

## Definiții-cheie (2/3): modele și metrice de clasificare

### Modele și semnale

- ▣ **Logit-L1**: regresie logistică cu penalizare  $L_1$  (LASSO)
- ▣ **RF**: media unor arbori decorelați; **GB**: arbori mici adăugați succesiv
- ▣ **Încrucișare MA**: long când MA rapidă e peste cea lentă

### Metrici de clasificare

- ▣ Acuratețe =  $\frac{TP+TN}{n}$ ; precizie =  $\frac{TP}{TP+FP}$ ; recall =  $\frac{TP}{TP+FN}$ ;  
 $F_1 = \frac{2PR}{P+R}$  (TP, FP, TN, FN: adevărat/fals pozitive/negative)
- ▣ **ROC AUC**:  $P(\hat{s}_+ > \hat{s}_-)$  pentru un pozitiv și un negativ aleși la întâmplare; 0,5 = fără abilitate
- ▣ **Log loss**:  $\ell_t = -[y_t \ln \hat{p}_t + (1 - y_t) \ln(1 - \hat{p}_t)]$ , pierderea unei prognoze de probabilitate

## Definiții-cheie (3/3): inferență și backtesting

### Incertitudine

- **CI 95%:** estimat  $\pm 1,96$  SE
- **Bootstrap pe blocuri:** reeșantionăm blocuri de  $L$  observații consecutive, ca să păstrăm dependența serială (Künsch (1989))
- **HAC:** varianța Newey–West (Newey & West (1987)), validă la autocorelație
- **DM:** testul Diebold–Mariano pentru acuratețe predictivă egală: test  $t$  pe diferența pierderilor  $d_t = \ell_t^A - \ell_t^B$ , cu SE HAC (Diebold & Mariano (1995))

### Backtesting

- **SR:**  $\bar{r}/\hat{\sigma}$ ; anualizat  $\times \sqrt{365}$  pentru cripto
- **PSR / DSR** (Bailey & López de Prado (2012); Bailey & López de Prado (2014)): folosesc asimetria  $\gamma_3$ , kurtosis  $\gamma_4$  (distribuția Normală: 3)
- $N_{\text{eff}}$ : numărul efectiv de încercări independente
- **PBO:** estimată prin CSCV (Bailey, Borwein, López de Prado & Zhu (2017))

## Cum funcționează seminarul

- ▣ Două tipuri de probleme, în fiecare parte
  - ▶ **[Rezolvat]**: modele lucrate, cu rezolvarea completă în acest material și în notebook
  - ▶ **[Propus]**: le rezolvați voi; fiecare urmează unei probleme rezolvate analoage
- ▣ Partea A: pe hârtie (derivări, cazuri numerice mici)
- ▣ Partea B: Python pe Bitcoin, verificare și inferență: fiecare cifră cu incertitudinea ei
  - ▶ fiecare exercițiu se încheie cu întrebări de interpretare: ce ar schimba concluzia?
- ▣ Partea C: o întrebare deschisă, punct de plecare pentru proiectul de echipă (C1)
  - ▶ și un răspuns AI de criticat (C2): găsiți scurgerile, corectați-le, treceți-le în `AI_ERRORS.md`
- ▣ Reguli: fără informație din viitor, validare purjată, un reper naiv și evidența tuturor încercărilor ([Harvey, Liu & Zhu \(2016\)](#))



## Pregătire: mediul Python și datele

### Mediul de lucru

- Google Colab (recomandat) sau Python local  $\geq 3.10$
- numpy, pandas, scipy, statsmodels, scikit-learn, shap
-  **Deschide în Colab:**  
capitol13\_notebook\_seminar.ipynb

```
import pandas as pd
url = 'https://raw.githubusercontent.com/danpele/MFM/main/data/market/BTC-USD.CC.csv'
btc = pd.read_csv(url, parse_dates=['date']).set_index('date')['close'].loc['2014-09-17':]
```

### Date

- **Bitcoin în dolari americani (BTC-USD)**, zilnic, 2014–2026 (4 385 obs.)
- **Ether (ETH-USD)**, zilnic, 2015–2026 (4 061 obs.)
- Fișiere din repo-ul cursului: data/market

## A1 [Rezolvat]: ponderile diferențierii fracționare

### Cerință

- ▣  $\tilde{X}_t = \sum_{k \geq 0} w_k X_{t-k}$ ,  $w_0 = 1$ ,  $w_k = -w_{k-1} \frac{d-k+1}{k}$  (Hosking (1981); López de Prado (2018))
- ▣ Calculați  $w_0, \dots, w_4$  pentru  $d = 0,5$
- ▣ Verificați  $d = 0$  și  $d = 1$ : ce obținem?
- ▣ De ce păstrează  $0 < d < 1$  memoria?

### Rezolvare

- ▣  $w = (1; -0,5; -0,125; -0,0625; -0,0391)$
- ▣  $d = 0$ :  $w = (1, 0, \dots) \Rightarrow$  prețurile;  $d = 1$ :  $w = (1, -1, 0, \dots) \Rightarrow$  randamentele
- ▣ Pentru  $0 < d < 1$  toate  $w_k < 0$  ( $k \geq 1$ ) scad hiperbolic:  $\tilde{X}_t$  e o sumă ponderată lungă a prețurilor trecute
- ▣ Diferențierea întreagă ( $d = 1$ ) pierde această memorie

## A2 [Propus]: ponderi și lungimea ferestrei

### Cerință

- ▣ Calculați  $w_0, \dots, w_5$  pentru  $d = 0,3$
- ▣ Cu pragul  $\tau = 0,01$ , câte ponderi păstrează FFD pentru  $d = 0,3$  și pentru  $d = 0,5$ ?
- ▣ Explicați de ce un  $d$  mai mic cere o fereastră mai lungă și pierde mai multe observații la începutul eșantionului

### Rezolvare

- ▣ Rezolvați singuri; se discută la seminar. Model: problema rezolvată de dinainte

## A3 [Rezolvat]: eticheta cu trei bariere

## Cerință

- $P_{t_0} = 100$ ,  $\sigma_{t_0} = 1\%$ ,  $h = 5$ ,  $pt = sl = 1$ : bariere  $P_{t_0} e^{\pm \sigma_{t_0} \sqrt{h}}$  (López de Prado (2018))
- Etichetați cele două traiectorii (zilele 0–5)

| Ziua | 0   | 1     | 2     | 3     | 4     | 5    |
|------|-----|-------|-------|-------|-------|------|
| 1    | 100 | 101,0 | 100,4 | 102,5 | 101,2 | 99,8 |
| 2    | 100 | 99,2  | 98,6  | 99,5  | 98,9  | 99,1 |

## Rezolvare

- Lățime  $0,01\sqrt{5} = 0,02236$ : superioară 102.26, inferioară 97.79
- Traectoria 1: ziua 3,  $102,5 \geq 102,26 \Rightarrow +1$  (scăderea ulterioară nu contează)
- Traectoria 2: nicio barieră orizontală;  $\ln(99,1/100) = -0,90\%$  în ziua 5  $\Rightarrow -1$
- O etichetă fixă la 5 zile ar da traiectoriei 1 eticheta  $-1$ , deși un ordin take-profit a câștigat

## A4 [Propus]: bariere asimetrice

### Cerință

- ▣  $P_{t_0} = 50$ ,  $\sigma_{t_0} = 2\%$ ,  $h = 4$ ,  $pt = 2$ ,  $sl = 1$
- ▣ Calculați ambele bariere orizontale și etichetați traiectoriile: (a) 50; 51,5; 53,0; 49,5; 47,9; (b) 50; 52,0; 54,5; 53,0; 51,0
- ▣ Cu  $pt = 2$ ,  $sl = 1$  și un preț fără tendință, ce etichetă e mai frecventă între atingerile orizontale? De ce este o alegere de management al riscului, nu o prognoză?

### Rezolvare

- ▣ Rezolvați singuri; se discută la seminar. Model: problema rezolvată de dinainte

## A5 [Rezolvat]: PSR și DSR

## Cerință

- $\widehat{SR}_{ann} = 1,2$ ,  $T = 756$  obs. zilnice,  $\hat{\gamma}_3 = -0,4$ ,  $\hat{\gamma}_4 = 5$
- $PSR(SR^*) = \Phi\left(\frac{(\widehat{SR} - SR^*)\sqrt{T-1}}{\sqrt{1 - \hat{\gamma}_3\widehat{SR} + \frac{\hat{\gamma}_4 - 1}{4}\widehat{SR}^2}}\right)$  (Bailey & López de Prado (2012))
- Strategia e cea mai bună din  $N = 100$  încercări independente:  
 $SR_0 = \sqrt{V}[(1 - \gamma)\Phi^{-1}(1 - \frac{1}{N}) + \gamma\Phi^{-1}(1 - \frac{1}{N_e})]$ ,  
 $\gamma = 0,5772$ ,  $V = 1/T$ ;  $DSR = PSR(SR_0)$  (Bailey & López de Prado (2014))

## Rezolvare

- $\widehat{SR}$  zilnic  $= 1,2/\sqrt{252} = 0,07559$ ; numitor 1,01782
- $PSR(0) = \Phi(2,041) = 0,979$
- $\sqrt{V} = 0,03637$ ;  $SR_0 = 0,0920$  (anualizat 1.46)
- $DSR = \Phi(-0,444) = 0,329$ : doar norocul dă un SR maxim de  $1,46 > 1,2$ ; nu alocăm capital

## A6 [Propus]: PSR și DSR, eșantion mai scurt

### Cerință

- ▣  $\widehat{SR}_{ann} = 1,5$  pe 2 ani de date zilnice ( $T = 504$ ),  $\hat{\gamma}_3 = -0,2$ ,  $\hat{\gamma}_4 = 6$
- ▣ Calculați  $PSR(0)$ , apoi  $SR_0$  și  $DSR$  dacă strategia e cea mai bună din  $N = 20$  încercări independente ( $V = 1/T$ )
- ▣ Comparați cu A5: un Sharpe mai mare și mai puține încercări, dar este dovada mai puternică? Ce explică diferența?

### Rezolvare

- ▣ Rezolvați singuri; se discută la seminar. Model: problema rezolvată de dinainte

## A7 [Rezolvat]: purjare și embargo

### Cerință

- $n = 20$ , fereastra etichetei  $[i, t_1(i)]$ ,  $t_1(i) = \min(i + 3, 19)$ ; 5 folduri fără amestecare, embargo de 1 observație (López de Prado (2018))
- (a) De ce supraestimează K-Fold cu amestecare acuratețea?
- (b) Foldul de test  $\{8, \dots, 11\}$ : ce observații sunt purjate / sub embargo?

### Rezolvare

- (a) Vecinii au 3 din 4 zile de etichetă comune: amestecarea pune aproape-duplicate în antrenare și test (curs: 69,4% cu amestecare vs 49,7% purjat, pe zgomot pur)
- (b) Purjate înainte:  $\{5, 6, 7\}$  ( $t_1 \geq 8$ ); eliminate după:  $\{12, 13, 14\}$  (12 = embargo; 13–14 încep înainte ca ultima etichetă de test, ziua 14, să fie cunoscută)
- Setul de antrenare  $\{0, \dots, 4\} \cup \{15, \dots, 19\}$



## A8 [Propus]: purjare cu etichete mai scurte

### Cerință

- ▣  $n = 20$ ,  $t_1(i) = \min(i + 2, 19)$ , 5 folduri fără amestecare, embargo de 1 observație
- ▣ Pentru foldul de test  $\{12, \dots, 15\}$ : enumerați observațiile purjate, cele sub embargo și setul de antrenare
- ▣ Cum crește numărul de observații eliminate cu orizontul etichetei? Ce costă asta când  $h = 20$  și foldurile sunt scurte?

### Rezolvare

- ▣ Rezolvați singuri; se discută la seminar. Model: problema rezolvată de dinainte

## A9 [Rezolvat]: AUC pas cu pas, cu eroare standard

## Cerință

- ▣ Scorurile a 3 pozitive: 0,80; 0,55; 0,40; a 3 negative: 0,60; 0,35; 0,20
- ▣ (a) AUC = ponderea perechilor (pozitiv, negativ) ordonate corect (Mann–Whitney  $U/(n_1 n_0)$ )
- ▣ (b) SE Hanley–McNeil (Hanley & McNeil (1982)):
 
$$SE^2 = \frac{A(1-A) + (n_1 - 1)(Q_1 - A^2) + (n_0 - 1)(Q_2 - A^2)}{n_1 n_0}, \quad Q_1 = \frac{A}{2-A},$$

$$Q_2 = \frac{2A^2}{1+A}$$
- ▣ (c) Este AUC semnificativ peste 0,5?

## Rezolvare

- ▣ (a) Perechi corecte: 0,80 bate 3, 0,55 bate 2, 0,40 bate 2  
 $\Rightarrow U = 7, A = 7/9 = 0,778$
- ▣ (b)  $Q_1 = 0,636, Q_2 = 0,681 \Rightarrow SE = 0,207$
- ▣ (c)  $z = (0,778 - 0,5)/0,207 = 1,34$ : nesemnificativ; 6 observații nu pot separa abilitatea de noroc
- ▣ Formula presupune observații independente: în B7 o înlocuim cu un bootstrap pe blocuri

## A10 [Propus]: AUC pas cu pas

### Cerință

- ▣ Pozitive: 0,70; 0,62; 0,48; 0,45; negative: 0,66; 0,50; 0,40; 0,30
- ▣ Calculați AUC, eroarea standard Hanley–McNeil și statistica  $z$  față de 0,5
- ▣ De câte observații ați avea nevoie, la acest AUC, pentru  $z \approx 2$ ? De ce e acest număr prea optimist pentru etichete suprapuse pe 5 zile?

### Rezolvare

- ▣ Rezolvați singuri; se discută la seminar. Model: problema rezolvată de dinainte

## B1 [Rezolvat]: ordinul minim $d^*$ pentru Bitcoin

### Cerință

- FFD pentru  $\ln P_t^{BTC}$  ( $\tau = 10^{-4}$ ),  $d \in \{0; 0,05; \dots; 1\}$ ; ADF (constantă, 1 lag) și  $\text{Corr}(\tilde{x}_t, x_t)$
- Cel mai mic  $d^*$  cu ADF sub valoarea critică de 5%

### Interpretare

- Ce ar schimba  $d^*$ : termenii deterministici ai ADF (constantă vs trend), începutul eșantionului, numărul de lag-uri?

### Rezolvare (BTC 2014–2026)

| $d$  | 0     | 0,05  | 0,10  | 0,15  | 0,20  | 0,25  |
|------|-------|-------|-------|-------|-------|-------|
| ADF  | -1,21 | -2,32 | -2,24 | -2,39 | -2,85 | -3,38 |
| Corr | 1,000 | 0,999 | 0,995 | 0,985 | 0,972 | 0,955 |

- Valoarea critică la 5%  $-2,86 \Rightarrow d^* = 0,25$ , corelație 0,955 cu log-prețul
- Traectoria ADF nu e monotonă în  $d$  ( $-2,32$ , apoi  $-2,24$ ): citim toată curba, nu o singură cifră

## B2 [Propus]: ordinul minim $d^*$ pentru Ether — o capcană

### Cerință

- ▣ Repetați B1 pe  $\ln P_t^{ETH}$  (2015–2026). Ce  $d^*$  obțineți?
- ▣ Refaceți testul pentru  $d = 0$  cu constantă și *trend* și refaceți B1 pe eșantionul care începe în 2018
- ▣ Interpretare: ce  $d^*$  ați folosi într-un model și de ce? Ce spune asta despre testele de rădăcină unitară pe active care au crescut de 1 000 de ori?

### Rezolvare

- ▣ Rezolvați singuri; se discută la seminar. Model: problema rezolvată de dinainte

## B3 [Rezolvat]: etichete cu trei bariere pe Bitcoin

### Cerință

- Volatilitate EWMA (span 50),  $h = 10$ ; etichetăm fiecare zi;  $pt = sl \in \{1, 2\}$
- Ponderile ieșirilor sus / jos / vertical și ale etichetelor +1

### Interpretare

- De ce 56% dintre etichete sunt +1 și care este atunci acuratețea de referință a unui clasificator?

### Rezolvare

|               | Sus   | Jos   | Vertical | +1    |
|---------------|-------|-------|----------|-------|
| $pt = sl = 1$ | 22,7% | 18,2% | 59,1%    | 55,8% |
| $pt = sl = 2$ | 7,2%  | 4,9%  | 87,9%    | 55,7% |

- Barierile mai largi mută majoritatea ieșirilor la bariera verticală: etichetele devin etichete cu orizont fix
- BTC a crescut în eșantion: +1 domină, deci „mereu în sus” e reperul de depășit

## B4 [Propus]: bariere asimetrice pe Bitcoin

### Cerință

- ▣ Repetați B3 cu  $(pt, sl) = (2, 1)$  și  $(1, 2)$ ; raportați ponderile ieșirilor, ponderea  $+1$  și durata medie de deținere
- ▣ Verificați răspunsul de la A4 pe date reale
- ▣ Interpretare: ce variantă ar alege un trend-follower? Cum ar schimba alegerea echilibrul claselor pe care îl vede un clasificator?

### Rezolvare

- ▣ Rezolvați singuri; se discută la seminar. Model: problema rezolvată de dinainte

## B5 [Rezolvat]: Purged K-Fold vs K-Fold cu amestecare

### Cerință

- Scrieți `PurgedKfold(n_splits, t1, pct_embargo)` cu metoda `split(X)` în stil `scikit-learn`
- Setul „leakage”: mers aleator, eticheta = semnul randamentului pe 20 de zile înainte, 5 caracteristici = medii pe 20 de zile ale unui zgomot independent
- Random forest ([Breiman \(2001\)](#)): K-Fold cu amestecare vs Purged K-Fold

### Interpretare

- S-ar reduce diferența cu caracteristici nepersistente? Cu etichete pe 1 zi?

### Rezolvare (seed 42)

- K-Fold cu amestecare: **69,4%**; purjat + embargo 1%: **49,7%**; adevărul: 50%
- Sunt necesare ambele ingrediente: etichete suprapuse și caracteristici persistente; fără oricare dintre ele, scurgerea dispare
- Verificare: pe exemplul A7 clasa elimină {5, 6, 7, 12, 13, 14}



## B6 [Propus]: găsiți scurgerea

### Cerință

- ▣ Notebook-ul adaugă o a 13-a caracteristică, `ma11`, setului din B7; cu Purged K-Fold, random forest-ul atinge acum o acuratețe spectaculoasă pentru direcția BTC la 5 zile
- ▣ Purjarea nu a oprit-o. Găsiți scurgerea (indiciu: citiți cum e construită `ma11` și ordonați caracteristicile după MDI), corectați-o și raportați rezultatul onest
- ▣ Interpretare: de ce nu poate purjarea să prindă acest tip de scurgere? Dați un al doilea exemplu de informație din viitor într-un flux de caracteristici

### Rezolvare

- ▣ Rezolvați singuri; se discută la seminar. Model: problema rezolvată de dinainte

## B7 [Rezolvat]: comparația modelelor și un CI pentru AUC

### Cerință

- Țintă: semnul randamentului log pe 5 zile înainte; 12 caracteristici (momentum, volatilitate, distanțe față de MA, RSI)
- Logit-L1 (Tibshirani (1996)), RF, GB (Friedman (2001)); Purged 5-Fold; MDI/MDA/SHAP (Lundberg & Lee (2017))
- AUC out-of-fold agregat al RF: SE DeLong (DeLong, DeLong & Clarke-Pearson (1988)) vs bootstrap circular pe blocuri ( $L = 20$ , 1 000 replici)

### Interpretare

- De ce e intervalul bootstrap mai larg? Ce lungime de bloc ați apăra?

### Rezolvare (4 181 obs., 54,8% „sus”)

| Media pe folduri | Logit-L1 | RF    | GB    |
|------------------|----------|-------|-------|
| Acuratețe        | 54,8%    | 54,2% | 52,2% |
| ROC AUC          | 0,492    | 0,516 | 0,502 |

- AUC agregat RF 0,512: SE DeLong 0,009, interval 95% [0,495; 0,530],  $p = 0,17$  față de 0,5
- Bootstrap pe blocuri: SE 0,015 (de 1,7 ori mai mare), interval 95% [0,484; 0,543]; 21% dintre replici  $\leq 0,5$
- DeLong presupune observații independente; etichetele suprapuse și grupările de volatilitate o încalcă. Niciun model nu bate „mereu în sus”

## B8 [Propus]: Diebold–Mariano pentru prognoze de probabilitate

### Cerință

- Folosiți probabilitățile out-of-fold agregate din B7 și o prognoză constantă (ponderea zilelor „sus” din antrenare, în fiecare fold)
- Diferența pierderilor  $d_t = \ell_t^A - \ell_t^B$  (log loss); statistica DM =  $\bar{d}/SE_{HAC}(\bar{d})$  cu lag-uri Newey–West 4 și 20; comparați cu  $t$  naiv i.i.d.
- Perechi: RF vs Logit-L1, RF vs constantă, GB vs constantă
- Interpretare: poate un model cu AUC > 0,5 să piardă în fața unei constante la log loss? Ce ar schimba concluzia?

### Rezolvare

- Rezolvați singuri; se discută la seminar. Model: problema rezolvată de dinainte

## B9 [Rezolvat]: meta-etichetare

### Cerință

- Primar: direcția încrucișării MA20/MA50; meta-eticheta = 1 dacă tranzacția primară e profitabilă la ieșirea din cele trei bariere ( $pt = sl = 1$ ,  $h = 10$ ) (López de Prado (2018))
- Secundar: RF pe caracteristici + direcție; antrenare pe primele 60%, pauză de 10 zile, test pe rest

### Interpretare

- Precizia crește, F1 scade: ce metrică contează pentru un trader care plătește costuri pe tranzacție?

### Rezolvare (2022-02 – 2026-09, 1 660 de semnale)

|              | Prec. | Recall | F1    |
|--------------|-------|--------|-------|
| Doar primar  | 0,475 | 1,000  | 0,644 |
| + meta-model | 0,517 | 0,541  | 0,529 |

- Meta-modelul păstrează circa jumătate dintre tranzacții; precizia crește cu 4 puncte, recall-ul se înjumătățește
- Pe tranzacție, mai puține și mai bune pot câștiga după costuri chiar dacă F1 scade

## B10 [Rezolvat]: căutare în grilă, DSR și numărul efectiv de încercări

### Cerință

- MA crossover long/cash pe BTC (2015–2026): rapidă  $\in \{5, \dots, 55\}$ , lentă  $\in \{20, \dots, 240\} \Rightarrow N = 120$  încercări; cea mai bună după Sharpe; PSR și DSR (Bailey & López de Prado (2014))
- $N$  efectiv din matricea de corelație  $120 \times 120$  a randamentelor încercărilor: valori proprii  $\lambda_i$ , raportul de participare  $(\sum \lambda_i)^2 / \sum \lambda_i^2$  și  $\hat{N} = \bar{\rho} + (1 - \bar{\rho})N$  (Bailey & López de Prado (2014))

### Interpretare

- Ce  $N$  și ce  $V[\widehat{SR}]$  ați raporta unui comitet de investiții?


### Rezolvare

- Cea mai bună (5, 40),  $SR_{an} = 1,17$  (buy & hold 0,71);  $T = 4\,279$ , asimetrie 0,11, kurtosis 13,0
- $\lambda_1 = 105,2$  explică 87,7% din varianță; raport de participare 1,3; 4 valori proprii ating 95%;  $\bar{\rho} = 0,873 \Rightarrow \hat{N} = 16,1$

| DSR, $V = 1/T$ | $N = 120$ | $\hat{N} = 16,1$ | $N = 4$ |
|----------------|-----------|------------------|---------|
| $SR_0$ (an.)   | 0,76      | 0,53             | 0,31    |
| DSR            | 0,922     | 0,986            | 0,998   |

- A număra 120 de încercări corelate ca independente deflatează prea mult; întrebarea reală e „peste buy & hold?”

## B10: de ce contează totuși dovada din afara eșantionului



- Rezultat din curs: cea mai bună încrucișare BTC în eșantion (SR 1,65 în 2015–2020) a obținut SR 0,02 în 2021–2026

## B11 [Propus]: probabilitatea de overfitting al backtestului (CSCV)

### Cerință

- Matricea randamentelor zilnice ale celor 120 de încercări din B10, împărțită în  $S = 16$  blocuri contigue; pentru fiecare dintre cele  $\binom{16}{8} = 12\,870$  moduri de a alege 8 blocuri în eșantion (restul în afara lui)
  - ▶ alegeți cel mai bun Sharpe în eșantion; calculați rangul lui relativ  $\omega$  în afara eșantionului și  $\lambda = \ln \frac{\omega}{1-\omega}$
- $PBO = P(\lambda \leq 0)$  (Bailey, Borwein, López de Prado & Zhu (2017)); raportați și Sharpe-ul median în afara eșantionului al câștigătorului din eșantion
- Interpretare: este grila supra-ajustată? Cum ar schimba PBO alegerea lui  $S$  sau adăugarea a 1 000 de strategii aleatoare în grilă?

### Rezolvare

- Rezolvați singuri; se discută la seminar. Model: problema rezolvată de dinainte

## C1 [Propus]: bate un model fundațional boosting-ul?

### Întrebarea

- Bate un model fundațional pentru serii de timp (Capitolul 14), folosit zero-shot, gradient boosting-ul pentru direcția BTC la 5 zile, după validare purjată, test DM și DSR?
- Nu există o metodă unică: propuneți una și apărați-o

### Livrabil

- Un folder Quantlet în repo-ul echipei (cod, Metainfo, un grafic) și un slide cu concluzia și principala limită

### Ce trebuie să conțină răspunsul

- O probabilitate de „sus” din cuantilele prognozate de model, evaluată doar pe date de după datele de pre-antrenare (altfel testul are scurgeri)
- Reperele din B7/B8: log loss pentru gradient boosting și pentru prognoza constantă
- Un test DM pe log loss cu erori HAC și DSR peste *toate* configurațiile încercate



## C2 [Propus]: critica unui răspuns AI

- Un student îi cere unui asistent AI: „Prognozează direcția Bitcoin de mâine din randamentele trecute și evaluează modelul în afara eșantionului, cu validare încrucișată în 5 blocuri”
- Asistentul răspunde cu acest cod (btc: închideri zilnice, fără importuri):

```
r = np.log(btc).diff()
X = pd.DataFrame({'r1': r, 'r5': r.rolling(5).sum(), 'vol20': r.rolling(20).std(),
                  'trend10': r.rolling(10, center=True).mean()})
data = pd.concat([X, r.shift(-1).rename('fwd')], axis=1).dropna()
y = (data['fwd'] > 0).astype(int) # 1 if tomorrow is up
Xs = StandardScaler().fit_transform(data[X.columns])
cv = KFold(n_splits=5, shuffle=True, random_state=0)
model = LogisticRegression(penalty='l1', C=0.1, solver='liblinear')
auc = cross_val_score(model, Xs, y, cv=cv, scoring='roc_auc')
print(round(auc.mean(), 3))
```

- „Rezultat: 0,697. Un AUC de 0,70 în afara eșantionului, pe 4 361 de zile, este un semnal puternic, tranzacționabil; validarea încrucișată este în afara eșantionului, deci nu există supra-ajustare”

## C2 [Propus]: critica unui răspuns AI, cerința

### Cerință

- Răspunsul conține **trei** scurgeri de informație din test în antrenare; restul este corect
- Pentru fiecare eroare
  - ▶ spuneți ce este greșit și de ce
  - ▶ spuneți cum ați detecta-o: o verificare în cod, un rezultat din B5–B7, o regulă din curs
  - ▶ dați codul corectat
- Rulați din nou codul corectat; raportați AUC
- Treceți cele trei erori ca în `AI_ERRORS.md`: ce s-a cerut, ce a răspuns AI-ul, ce era greșit, cum v-ați dat seama, varianta corectă

### Interpretare

- Ce zile intră în `trend10` în ziua  $t$ ? Care dintre ele este ținta?
- Este plauzibil un AUC de 0,70 pentru direcția Bitcoin de a doua zi, având în vedere B6 și B7?
- De ce nu este suficient „validarea încrucișată este în afara eșantionului” pentru serii de timp?

## Temă (proiectul de echipă)

- ▣ Alegeți un activ (indice bursier, acțiune, cripto, curs valutar sau marfă) și livrați
  - ▶ caracteristici fără informație din viitor, inclusiv una FFD cu un  $d^*$  justificat și sensibilitatea lui (B2)
  - ▶ etichete cu trei bariere cu  $(pt, sl, h)$  justificate
  - ▶ cel puțin trei modele cu Purged K-Fold, un test DM față de o prognoză constantă și un CI bootstrap pe blocuri pentru AUC
  - ▶ evidența tuturor încercărilor,  $N$  efectiv, DSR și PBO pentru strategia finală
- ▣ Repo GitHub cu notebook-uri și Metainfo.txt în stil Quantlet; o prezentare de 10 minute
- ▣ Treceți în AI\_ERRORS.md fiecare eroare AI pe care o prindeți, ca în C2: ce s-a cerut, ce era greșit, cum v-ați dat seama, varianta corectă
- ▣ Un rezultat negativ, documentat onest, este un rezultat bun

## Aprofundare pe Quantinar

-  Random Forests — bagging, eroarea out-of-bag, importanța variabilelor
-  Shapley Values — explicații locale independente de model
-  Machine Learning in Financial Risk — estimarea măsurilor de risc cu ML
-  Introduction to Reinforcement Learning — Q-learning, decizii secvențiale

## Bibliografie (1/2)

- Bailey, D.H., Borwein, J., López de Prado, M., Zhu, Q.J. (2017). [The probability of backtest overfitting](#). *Journal of Computational Finance*, 20(4), 39–69.
- Bailey, D.H., López de Prado, M. (2012). [The Sharpe ratio efficient frontier](#). *Journal of Risk*, 15(2), 3–44.
- Bailey, D.H., López de Prado, M. (2014). [The deflated Sharpe ratio: correcting for selection bias, backtest overfitting and non-normality](#). *Journal of Portfolio Management*, 40(5), 94–107.
- Breiman, L. (2001). [Random forests](#). *Machine Learning*, 45(1), 5–32.
- DeLong, E.R., DeLong, D.M., Clarke-Pearson, D.L. (1988). [Comparing the areas under two or more correlated receiver operating characteristic curves: a nonparametric approach](#). *Biometrics*, 44(3), 837–845.
- Dickey, D.A., Fuller, W.A. (1979). [Distribution of the estimators for autoregressive time series with a unit root](#). *Journal of the American Statistical Association*, 74(366), 427–431.
- Diebold, F.X., Mariano, R.S. (1995). [Comparing predictive accuracy](#). *Journal of Business & Economic Statistics*, 13(3), 253–263.
- Friedman, J.H. (2001). [Greedy function approximation: a gradient boosting machine](#). *Annals of Statistics*, 29(5), 1189–1232.
- Gu, S., Kelly, B., Xiu, D. (2020). [Empirical asset pricing via machine learning](#). *Review of Financial Studies*, 33(5), 2223–2273.

## Bibliografie (2/2)

- ▣ Hanley, J.A., McNeil, B.J. (1982). The meaning and use of the area under a receiver operating characteristic (ROC) curve. *Radiology*, 143(1), 29–36.
- ▣ Harvey, C.R., Liu, Y., Zhu, H. (2016). ... and the cross-section of expected returns. *Review of Financial Studies*, 29(1), 5–68.
- ▣ Hosking, J.R.M. (1981). Fractional differencing. *Biometrika*, 68(1), 165–176.
- ▣ Künsch, H.R. (1989). The jackknife and the bootstrap for general stationary observations. *Annals of Statistics*, 17(3), 1217–1241.
- ▣ López de Prado, M. (2018). *Advances in Financial Machine Learning*. Wiley.
- ▣ Lundberg, S.M., Lee, S.-I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems*, 30.
- ▣ Newey, W.K., West, K.D. (1987). A simple, positive semi-definite, heteroskedasticity and autocorrelation consistent covariance matrix. *Econometrica*, 55(3), 703–708.
- ▣ Tibshirani, R. (1996). Regression shrinkage and selection via the lasso. *Journal of the Royal Statistical Society B*, 58(1), 267–288.