



Modelarea piețelor financiare

Seminarul 13: Machine Learning în finanțe — aplicații



Daniel Traian PELE

Antoaneta Amza

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

Acronime folosite în acest material (1/3)

- ▣ **ADF**: Augmented Dickey–Fuller (test) — *testul Dickey–Fuller augmentat*
- ▣ **AI**: Artificial Intelligence — *inteligență artificială*
- ▣ **AIC**: Akaike Information Criterion — *criteriul informațional Akaike*
- ▣ **AUC**: Area Under the (ROC) Curve — *aria de sub curba ROC*
- ▣ **CI**: Confidence Interval — *interval de încredere*
- ▣ **CV**: Cross-Validation — *validare încrucișată*
- ▣ **CW**: Clark–West (test for nested models) — *testul Clark–West pentru modele imbricate*
- ▣ **DM**: Diebold–Mariano (test) — *testul Diebold–Mariano de comparare a prognozelor*
- ▣ **DSR**: Deflated Sharpe Ratio — *raportul Sharpe deflatat*
- ▣ **ELW**: Exact Local Whittle (estimator) — *estimatorul local Whittle exact*
- ▣ **EWMA**: Exponentially Weighted Moving Average — *medie mobilă ponderată exponențial*
- ▣ **FF3**: Fama–French three-factor model — *modelul Fama–French cu trei factori*
- ▣ **FF5**: Fama–French five-factor model — *modelul Fama–French cu cinci factori*
- ▣ **FFD**: Fixed-width window Fractional Differentiation — *diferențiere fracționară cu fereastră fixă*

Acronime folosite în acest material (2/3)

- **FFN**: FeedForward Network — *rețea neuronală feedforward (fără bucle)*
- **FN**: False Negative — *fals negativ*
- **GAN**: Generative Adversarial Network — *rețea generativă adversarială*
- **GB**: Gradient Boosting — *boosting pe gradient*
- **GW**: Giacomini–White (test) — *testul Giacomini–White*
- **HAC**: Heteroskedasticity and Autocorrelation Consistent (standard errors) — *erori standard robuste la heteroscedasticitate și autocorelație*
- **IS**: In-Sample — *în eșantion*
- **LASSO**: Least Absolute Shrinkage and Selection Operator — *regresie penalizată L1 cu selecția variabilelor*
- **LS**: Linear SDF estimated by unregularised Least Squares — *SDF liniar estimat prin cele mai mici pătrate, fără regularizare*
- **LW**: Local Whittle (estimator) — *estimatorul local Whittle*
- **MDA**: Mean Decrease Accuracy — *scăderea medie a acurateței (importanța prin permutare)*
- **MDI**: Mean Decrease Impurity — *scăderea medie a impurității*
- **OLS**: Ordinary Least Squares — *metoda celor mai mici pătrate*
- **OOS**: Out-Of-Sample — *în afara eșantionului*

Acronime folosite în acest material (3/3)

- ▣ **PBO**: Probability of Backtest Overfitting — *probabilitatea de overfitting a backtest-ului*
- ▣ **PSR**: Probabilistic Sharpe Ratio — *raportul Sharpe probabilistic*
- ▣ **PT**: Pesaran–Timmermann (test of directional accuracy) — *testul Pesaran–Timmermann al acurateții direcționale*
- ▣ **RC**: Reality Check (White's test for data snooping) — *testul Reality Check al lui White pentru data snooping*
- ▣ **RF**: Random Forest — *pădure aleatoare*
- ▣ **ROC**: Receiver Operating Characteristic (curve) — *curba caracteristică de operare a receptorului*
- ▣ **SDF**: Stochastic Discount Factor — *factorul stochastic de actualizare*
- ▣ **SE**: Standard Error — *eroare standard*
- ▣ **SHAP**: SHapley Additive exPlanations — *explicații aditive Shapley*
- ▣ **SPA**: Superior Predictive Ability (test) — *testul abilității predictive superioare*
- ▣ **SR**: Sharpe Ratio — *raportul Sharpe*
- ▣ **SUA**: Statele Unite ale Americii
- ▣ **TP**: True Positive — *adevărat pozitiv*
- ▣ **VIX**: CBOE Volatility Index — *indicele de volatilitate CBOE*

Întrebarea zilei și traseul

- ▣ Întrebarea seminarului: **rămîne valid vreun semnal de machine learning pe Bitcoin după etichetare, validare și selecție corecte?**
- ▣ Traseul seminarului
 - ▶ Întîi slide-urile „Noțiuni necesare azi”: [Capitolul 13](#) este cursul de după seminar
 - ▶ Partea I: memorie (A1), etichete (A3, B3), validare (A7, B5)
 - ▶ Partea a II-a: predicția și incertitudinea ei (B7a, B7b, B8), un răspuns AI de criticat (C2), selecție și deflatare (A5)
 - ▶ După curs: B1 (memoria Bitcoin prin local Whittle) și B10 (căutarea în grilă și numărul efectiv de încercări)
- ▣ Livrabile: răspunsurile A, un grafic și un tabel pentru fiecare exercițiu B, codul C2 corectat, o frază de interpretare pentru fiecare exercițiu
- ▣ Notebook-ul zilei: [deschideți notebook-ul seminarului în Colab](#); fiecare cerință își numește secțiunea din notebook
- ▣ Seminar: prof. Daniel Traian Pele, danpele@ase.ro; drd. Antoaneta Amza, antoaneta.amza@csie.ase.ro

Harta exercițiilor

Exercițiu	Întrebare	Tip	Model
A1	ce păstrează un filtru fracționar trunchiat din nivelul prețului?	Rezolvat	–
A3, B3	cum se comportă etichetele cu trei bariere pe traiectorii simple și pe Bitcoin?	Rezolvat	–
A7, B5	ce elimină purjarea și ce simulează amestecarea?	Rezolvat	–
B7a, B7b	depășesc trei modele reperul „mereu în sus”? Cât de incert este AUC?	Rezolvat	–
B8	proгноzează un model mai bine decât o constantă?	Propus	B7a, B7b
C2	ce este greșit într-un răspuns AI?	Propus	B5, B7a
A5	depășește cel mai bun dintre 100 de backtest-uri nivelul atribuibil norocului?	Rezolvat	–
După curs	B1: face diferențierea fracționară prețul Bitcoin staționar? B10: cea mai bună dintre 120 de reguli față de noroc	Rezolvat	–
Pachete de extindere	A2, A3 extins, A4, A6, A8–A10, B2, B4, B6, B7c, B9, B11–B14, C1, C3	ambele	numit la fiecare cerință


- **[Rezolvat]**: rezolvarea completă în slide-uri și în notebook, un model de urmat; **[Propus]**: îl rezolvați dumneavoastră; rezolvarea se discută la seminar
- Partea A: derivări și exemple numerice mici; Partea B: verificare și inferență pe date crypto, fiecare cu o întrebare de interpretare; Partea C: critica unui răspuns AI și puncte de plecare pentru proiect

Datele folosite

Serie	Cîmp	Eșantion fixat	Folosit în
Bitcoin	close	2014-09-17 – 2026-09-18, 4 385 de închideri	B1, B3–B14, C1, C2
Ether	close	2015-08-07 – 2026-09-18, 4 061 de închideri	B2
VIX	close	zilele de tranzacționare din SUA, preluate pe calendarul BTC	B14
Factorii și decilele Kenneth French	Data Library, lunar	1967 – ultima lună	C3

- Închiderile zilnice din datele cursului, câte o serie pe activ (cîmpul folosit: close); criptomonedele se tranzacționează în fiecare zi, deci un an are $A = 365$ de perioade, iar raportul Sharpe anualizat este cel zilnic înmulțit cu $\sqrt{A}$
- Randamente: randamente logaritmice zilnice $r_t = \ln(P_t/P_{t-1})$ pe calendarul propriu al fiecărui activ; nicio închidere lipsă în eşantioanele fixate; evenimentele fără o fereastră completă de h zile la final nu se etichetează

Pregătire: rulați și verificați (1/2)



Pregătire: rulați și verificați (2/2)

```
# notebook section 0 defines load_data
btc = load_data('btc')['Close']
eth = load_data('eth')['Close']
print(len(btc), btc.index[0], btc.index[-1])
print(len(eth), eth.index[0], eth.index[-1])
r = np.log(btc).diff().dropna()
print(round(r.std() * np.sqrt(365), 3))
```



- Rezultat așteptat: BTC 4385 de închideri, 17 sep. 2014 (457,33) – 18 sep. 2026 (80 901,46), volatilitate anualizată 0,666; ETH 4061 de închideri din 7 aug. 2015
- Dacă un număr diferă, opriți-vă și verificați seria, câmpul și datele

Notăție și funcțiile date

- P_t : închiderea din ziua t ; $x_t = \ln P_t$; $r_t = x_t - x_{t-1}$; B : operatorul lag, $Bx_t = x_{t-1}$; momentul deciziei: închiderea zilei t , tranzacția la închiderea următoare
- d : ordinul unui filtru fracționar (o alegere); δ : memoria unei serii, $I(\delta)$ (un parametru necunoscut pe care îl estimăm)
- σ_{t_0} : volatilitatea EWMA a randamentelor logaritmice zilnice, span 50; h : orizontul etichetei; $[t_0, t_1]$: intervalul unei etichete
- SR: raportul Sharpe zilnic $\bar{r}/\hat{\sigma}$ al randamentelor logaritmice zilnice (rata fără risc 0), anualizat $\times \sqrt{365}$; γ_3 asimetria, γ_4 kurtosis obișnuit (distribuția Normală: 3)

Funcția dată (secțiunea 0 a notebook-ului)	Rezultatul returnat
<code>ffd_weights(d, threshold), frac_diff_ffd local_whittle, exact_local_whittle get_daily_vol, triple_barrier</code>	ponderile $w_0, \dots, w_K$; seria filtrată de la ziua K $(\hat{\delta}, \text{SE})$ cu $m = \lfloor n^{0.65} \rfloor$ frecvențe volatilitatea EWMA; un rînd pe eveniment: t_1 , randament, etichetă, tipul ieșirii
<code>PurgedKFold, build_features probabilistic_sharpe_ratio, deflated_sharpe_ratio</code>	pliuri purjate cu embargo; cele 11 caracteristici din B7 PSR și DSR pentru un SR zilnic

Noțiuni necesare azi (1/15): modelul logistic cu penalizare L1



$\hat{p} = 1/(1 + e^{-x^T \beta})$ $\beta_1 = 1$ $\beta_3 = 0.3$ $\beta_4, \beta_5, \beta_6$ (true 0)
 --- Threshold 0.5 $\beta_2 = -0.6$

- **Capitolul 13** este cursul de după seminar: aceste slide-uri sînt minimul necesar pentru cerințele de azi
- Cadrul: caracteristicile x_t cunoscute la închiderea zilei t , eticheta $y_t \in \{0, 1\}$ („sus” = 1)
 - ▶ un clasificator furnizează $\hat{p}_t = \hat{P}(y_t = 1 \mid x_t)$ și prezice „sus” cînd $\hat{p}_t > 0,5$
- **Logit-L1 (Tibshirani (1996))**: legătură logistică, coeficienți micșorați printr-o penalizare în valoare absolută

$$\hat{p} = \frac{1}{1 + e^{-x^T \beta}}, \quad \min_{\beta} \sum_t \ell_t(\beta) + \lambda \sum_j |\beta_j|$$

- ▶ $x^T \beta = \sum_j \beta_j x_j$: scorul liniar; $\beta_j > 0$: o valoare mai mare a lui x_j crește $\hat{p}$
- ▶ ℓ_t : log loss (slide-ul 4/15); $\lambda \geq 0$: ponderea penalizării; în scikit-learn $C = 1/\lambda$
- ▶ panoul de jos: cînd C scade, coeficienții slabi devin exact 0

Noțiuni necesare azi (2/15): arbori, păduri aleatoare și boosting

- ▣ **Arborele de clasificare:** împarte spațiul caracteristicilor prin reguli $x_j \leq c$; în frunza R prezice proporția etichetelor „sus”

$$\hat{p}_R = \frac{1}{n_R} \sum_{t \in R} y_t, \quad G(R) = 2\hat{p}_R(1 - \hat{p}_R)$$

- ▶ n_R : observațiile din R ; G : impuritatea Gini, 0 pentru o frunză pură; fiecare ramificare este aleasă astfel încât să reducă cel mai mult $\sum n_R G(R)$
- ▶ mărimea minimă a frunzei (de exemplu 50): o valoare mai mare dă arbori mai netezi, cu mai puțin overfitting

- ▣ **Pădure aleatoare (RF, Breiman (2001)):** media a B arbori, fiecare crescut pe un eșantion bootstrap, cu o submulțime aleatoare de caracteristici la fiecare ramificare


$$\hat{p}_{RF}(x) = \frac{1}{B} \sum_{b=1}^B \hat{p}_b(x)$$

- ▣ **Gradient boosting (GB, Friedman (2001)):** arbori adăugați unul câte unul, pe scala log-odds

$$F_m(x) = F_{m-1}(x) + \eta h_m(x), \quad \hat{p} = \frac{1}{1 + e^{-F_M(x)}}$$

- ▶ h_m : un arbore mic estimat pe reziduurile $y_t - \hat{p}_{m-1,t}$ (gradientul negativ al log loss)
- ▶ $\eta \in (0, 1]$: rata de învățare; M : numărul de arbori; un η mic învață lent și produce mai puțin overfitting

Noțiuni necesare azi (3/15): acuratețea, curba ROC și AUC



□ **Acuratețea** = $\frac{1}{n} \sum_t 1\{\hat{y}_t = y_t\}$, $\hat{y}_t = 1\{\hat{p}_t > 0,5\}$

► reperul: „mereu sus”, a cărui acuratețe este proporția etichetelor „sus”, nu 50%

□ **Curba ROC** (receiver operating characteristic): pentru fiecare prag c

$$\text{TPR}(c) = P(\hat{p}_t > c \mid y_t = 1), \quad \text{FPR}(c) = P(\hat{p}_t > c \mid y_t = 0)$$

□ **AUC** (Hanley & McNeil (1982)): aria de sub curba ROC


$$\text{AUC} = P(\hat{p}_+ > \hat{p}_-) + \frac{1}{2} P(\hat{p}_+ = \hat{p}_-)$$

► $\hat{p}_+$, $\hat{p}_-$: scorurile unei zile „sus” și ale unei zile „jos” alese la întâmplare

► 0,5: nicio capacitate de ordonare (diagonala); 1: ordonare perfectă; sub 0,5: ordonare inversă

► Exemplu: zilele „sus” (0,7; 0,4), zilele „jos” (0,5; 0,2): 3 din 4 perechi ordonate corect, AUC = 0,75

Noțiuni necesare azi (4/15): log loss



- **Log loss:** penalizează probabilitățile greșite date cu încredere

$$\ell_t = -[y_t \ln \hat{p}_t + (1 - y_t) \ln(1 - \hat{p}_t)]$$

- ▶ $\ell_t \geq 0$: $-\ln \hat{p}_t$ într-o zi „sus”, $-\ln(1 - \hat{p}_t)$ într-o zi „jos”
- ▶ constanta $\hat{p}_t = 0,5$ are pierderea $\ln 2 = 0,693$ în fiecare zi
- ▶ Exemplu: $y_t = 1$; $\hat{p}_t = 0,6$ are pierderea 0,51, $\hat{p}_t = 0,2$ are pierderea 1,61

- **Scorul Brier:** eroarea pătratică a unei probabilități, $b_t = (y_t - \hat{p}_t)^2 \in [0, 1]$
- **AUC** evaluează ordonarea, log loss și Brier calibrarea: un model poate ordona bine și totuși avea probabilități prea dispersate (B8)

Noțiuni necesare azi (5/15): compararea a două prognoze

- Predicție în afara pliului: fiecare zi este prognozată de un model care nu a fost antrenat pe ea (slide-ul 11/15 arată ce zile mai trebuie excluse)
- Compararea a două prognoze, A și B: statistica Diebold–Mariano (DM) (Diebold & Mariano (1995))


$$d_t = \ell_t^A - \ell_t^B, \quad DM = \frac{\bar{d}}{\widehat{SE}(\bar{d})}$$

- ▶ ℓ_t^A, ℓ_t^B : pierderile lui A și B în ziua t ; $d_t > 0$: A este mai slabă în acea zi; $\bar{d}$: media lui d_t
- ▶ H_0 : pierderi așteptate egale; DM are aproximativ distribuția Normală standard; $|DM| > 1,96$: diferență semnificativă la 5%
- $\widehat{SE}(\bar{d})$: eroarea standard Newey–West (Newey & West (1987)), pentru că valorile d_t vecine sînt dependente

$$\widehat{SE}(\bar{d}) = \sqrt{\frac{1}{n} \left[\hat{\gamma}_0 + 2 \sum_{j=1}^q \left(1 - \frac{j}{q+1} \right) \hat{\gamma}_j \right]}$$

- ▶ $\hat{\gamma}_j$: autocovarianța de selecție a lui d_t la lag-ul j ; q : numărul de lag-uri (cel puțin suprapunerea etichetelor)
- ▶ echivalent: regresăm d_t pe o constantă cu erori HAC; valoarea t este DM
- ▶ statistica t naivă (i.i.d.) folosește doar $\hat{\gamma}_0$ și exagerează semnificația cînd $\hat{\gamma}_j > 0$


Noțiuni necesare azi (6/15): incertitudinea unui AUC și bootstrap-ul pe blocuri



- **DeLong (DeLong, DeLong & Clarke-Pearson (1988))**: o eroare standard în formă închisă a AUC, care tratează zilele ca independente
 - ▶ $z = (\text{AUC} - 0,5)/\text{SE} \approx N(0, 1)$ sub H_0 : $\text{AUC} = 0,5$
- **Bootstrap circular pe blocuri (Künsch (1989))**
 - ▶ alegem începuturi aleatoare și luăm blocuri de L zile consecutive (cu reluare de la început după ultima zi) până la n zile
 - ▶ recalculăm statistica $\hat{\theta}_b^*$ în fiecare dintre cele B replici

$$\text{SE}^* = \text{sd}(\hat{\theta}_1^*, \dots, \hat{\theta}_B^*), \quad \text{CI}_{95} = [\hat{\theta}_{(2.5\%)}^*, \hat{\theta}_{(97.5\%)}^*]$$
- $L = 1$ este bootstrap-ul obișnuit; blocurile păstrează dependența din interiorul lor
- Graficul (sume suprapuse pe 5 zile, simulate): $L = 1$ dă eroarea naivă; de la $L \approx 10$, SE este aproape de cea adevărată

Noțiuni necesare azi (7/15): diferențierea fracționară



- Diferențierea de ordin d (Hosking (1981)), cu operatorul lag $Bx_t = x_{t-1}$ și log-prețul x_t

$$(1 - B)^d x_t = \sum_{k \geq 0} w_k x_{t-k}, \quad w_0 = 1, \quad w_k = -w_{k-1} \frac{d - k + 1}{k}$$

- ▶ k : lagul, în zile; w_k : ponderea valorii de acum k zile
- ▶ $d = 0$ păstrează nivelul, $d = 1$ dă randamentul $x_t - x_{t-1}$
- ▶ $d = 0,5$: $w = (1; -0,5; -0,125; -0,0625; \dots)$; ponderile care scad încet păstrează o parte din nivelurile vechi: „memorie”
- FFD (fereastră de lățime fixă, López de Prado (2018)): păstrăm ponderile până la primul $|w_k| < \tau$ (de exemplu 10^{-4}) și aplicăm aceleași $K + 1$ ponderi în fiecare zi
 - ▶ K : ultimul lag păstrat; un d mai mic cere o fereastră mai lungă (panoul de sus)
 - ▶ panoul de jos: FFD cu $d = 0,4$ al unui mers aleator pare să revină la medie

Noțiuni necesare azi (8/15): memoria, testul ADF și local Whittle

- **Memoria** δ : x_t este $I(\delta)$ când $(1 - B)^\delta x_t$ are memorie scurtă
 - ▶ $\delta < \frac{1}{2}$: staționară; $\frac{1}{2} \leq \delta < 1$: nestaționară, cu revenire la medie; $\delta = 1$: rădăcină unitară (mers aleator)
 - ▶ un filtru netrunchiat de ordin d aplicat unei serii $I(1)$ lasă memoria $1 - d$
- **Testul ADF** (Dickey & Fuller (1979)): H_0 : rădăcină unitară ($\gamma = 0$) în regresia

$$\Delta x_t = c + \gamma x_{t-1} + \sum_{j=1}^p \phi_j \Delta x_{t-j} + \varepsilon_t$$

- ▶ statistica: valoarea t a lui $\hat{\gamma}$; distribuția Dickey–Fuller, nu t ; respingem dacă este sub $-2,86$ (5%, cu constantă)
- ▶ regula d minim (López de Prado (2018)): cel mai mic d la care ADF respinge; A1 întreabă ce dovedește aceasta
- **Local Whittle** (Robinson (1995)): $\hat{\delta}$ minimizează, pe cele mai mici m frecvențe Fourier $\lambda_j = 2\pi j/n$

$$R(\delta) = \ln \left(\frac{1}{m} \sum_{j=1}^m \lambda_j^{2\delta} I(\lambda_j) \right) - \frac{2\delta}{m} \sum_{j=1}^m \ln \lambda_j, \quad \text{SE}(\hat{\delta}) = \frac{1}{2\sqrt{m}}$$

- ▶ $I(\lambda_j)$: periodograma; $m = \lfloor n^{0,65} \rfloor$; local Whittle exact (Shimotsu & Phillips (2005)) este valid și pentru $\delta \geq \frac{1}{2}$

Noțiuni necesare azi (9/15): etichete cu orizont fix și volatilitatea EWMA

- Eticheta cu orizont fix pe h zile

$$y_t = 1\{\ln P_{t+h} - \ln P_t > 0\}$$

- $1\{A\} = 1$ dacă A are loc și 0 altfel; P_t : închiderea din ziua t ; h : orizontul, în zile
- eticheta zilei t folosește randamentele din $[t, t+h]$: etichetele vecine au randamente comune

- Volatilitatea EWMA** (medie mobilă ponderată exponențial) a randamentelor logaritmice zilnice r_t

$$\sigma_t^2 = (1 - \alpha) \sigma_{t-1}^2 + \alpha r_t^2, \quad \alpha = \frac{2}{\text{span} + 1}$$


- span 50: $\alpha = 2/51 \approx 0.039$ pentru ziua cea mai recentă; ponderea zilei $t - k$ este $\alpha(1 - \alpha)^k$
- `get_daily_vol` folosește abaterea standard EWMA (cu media scăzută); σ_{t_0} scalează barierele de pe slide-ul următor

- Raportul Sharpe (SR)** al randamentelor zilnice, rata fără risc 0

$$\widehat{SR} = \frac{\bar{r}}{\hat{\sigma}}, \quad \widehat{SR}_{ann} = \widehat{SR} \sqrt{A}$$

- $\bar{r}$, $\hat{\sigma}$: media și abaterea standard a randamentelor zilnice; A : zile pe an (365 pentru Bitcoin, 252 pentru acțiuni)

Noțiuni necesare azi (10/15): metoda celor trei bariere




- Price path
- Daily closes
- Upper $P_{t_0} e^{pt\sigma\sqrt{h}}$
- Lower $P_{t_0} e^{-sl\sigma\sqrt{h}}$
- Vertical $t_0 + h$
- ★ First touch: day 4

- **Trei bariere (López de Prado (2018))**: de la intrarea t_0 , două bariere orizontale și una verticală

$$P_{t_0} e^{+pt\sigma\sqrt{h}}, \quad P_{t_0} e^{-sl\sigma\sqrt{h}}, \quad t_0 + h$$

- ▶ $\sigma_{t_0} \sqrt{h}$: variația logaritmică tipică pe h zile; pt , sl : lățimile de profit și de stop-loss, în unități ale acesteia
- ▶ eticheta $+1$ / -1 la prima atingere orizontală; altfel semnul randamentului la $t_0 + h$; t_1 : ziua ieșirii
- Graficul (simulat): $\sigma = 2\%$, $h = 10$, $pt = sl = 1$: barierele 106,53 și 93,87; închiderea din ziua 4 este 107,02, deci $t_1 = 4$ și eticheta este $+1$, deși traiectoria scade ulterior
- Se verifică doar închiderile zilnice: o atingere în timpul zilei este ratată

Noțiuni necesare azi (11/15): validare onestă



- Validarea încrucișată în K pliuri: antrenare pe $K - 1$ pliuri, test pe cel rămas
 - pliurile **amestecate** combină zilele; cele **contigue** păstrează blocuri de timp
- **Purjarea** (López de Prado (2018)): eliminăm din antrenare orice observație al cărei interval de etichetă se suprapune cu intervalul unei etichete de test
- **Embargoul**: eliminăm și cele e observații imediat după pliul de test, pentru că caracteristicile privesc înapoi
- Exemplu: $n = 10$, intervalele $[i, i + 2]$, pliul de test $\{4, 5\}$ (etichete pînă în ziua 7), $e = 1$
 - eliminăm $\{2, 3\}$ înainte și $\{6, 7\}$ după (6: embargo; 7 începe înainte de sfîrșitul zilei 7); antrenăm pe $\{0, 1, 8, 9\}$
- Graficul: $n = 30$, 5 pliuri, intervalele $[i, i + 2]$, $e = 1$
- Fără purjare, o zi de antrenare are randamente comune cu o zi de test, iar un model flexibil memorează observația vecină (B5)


Noțiuni necesare azi (12/15): raportul Sharpe probabilistic

- Raportul Sharpe probabilistic (PSR, Bailey & López de Prado (2012)): probabilitatea ca SR-ul zilnic adevărat să depășească un reper SR^*

$$PSR(SR^*) = \Phi\left(\frac{(\widehat{SR} - SR^*)\sqrt{T-1}}{D}\right), \quad D = \sqrt{1 - \gamma_3 \widehat{SR} + \frac{\gamma_4 - 1}{4} \widehat{SR}^2}$$

- ▶ $\widehat{SR}$: SR zilnic estimat; T : numărul de randamente; Φ : funcția de repartiție a distribuției Normale standard
- ▶ $\gamma_3 = \frac{1}{T} \sum_t (r_t - \bar{r})^3 / \hat{\sigma}^3$: asimetria; $\gamma_4 = \frac{1}{T} \sum_t (r_t - \bar{r})^4 / \hat{\sigma}^4$: kurtosis obișnuit (3 pentru distribuția Normală)
- ▶ $D/\sqrt{T-1}$: eroarea standard a lui $\widehat{SR}$; asimetria negativă și cozile groase măresc D și scad PSR
- ▶ $D = 1$ în prima aproximare pentru randamente cu distribuția Normală ($\gamma_3 = 0$, $\gamma_4 = 3$, $\widehat{SR}$ mic)
- Interpretare: $PSR(0) = 0,95$ înseamnă o încredere de 95% că SR-ul adevărat este pozitiv, pentru o singură strategie stabilă dinainte

Noțiuni necesare azi (13/15): selecția și raportul Sharpe deflatat



- Selecția: cea mai bună dintre N strategii fără abilitate reală are totuși un SR pozitiv; valoarea lui așteptată este

$$SR_0 = \sqrt{V} \left[(1 - \gamma_E) \Phi^{-1} \left(1 - \frac{1}{N} \right) + \gamma_E \Phi^{-1} \left(1 - \frac{1}{Ne} \right) \right]$$

- V : dispersia SR între încercări; Φ^{-1} : funcția cuantilă a distribuției Normale standard; $e \approx 2.718$; $\gamma_E = 0,5772$: constanta lui Euler

- Raportul Sharpe deflatat (DSR, Bailey & López de Prado (2014))

$$DSR = PSR(SR_0)$$

- PSR față de maximul așteptat sub noroc; peste 0,95: cea mai bună regulă depășește norocul cu o încredere de 95%
- Graficul (simulat, $T = 400$, $V = 1/T$): SR-ul maxim se deplasează spre dreapta când N crește; liniile întrerupte: $SR_0 = 0.079$ ($N = 10$) și 0.127 ($N = 100$)

Noțiuni necesare azi (14/15): un exemplu rezolvat

- ▣ SR zilnic $\widehat{SR} = 0,10$, $T = 400$, $D = 1$: $PSR(0) = \Phi(0,10\sqrt{399}) = \Phi(2,00) = 0,977$
- ▣ Dacă este cea mai bună dintre $N = 10$ încercări, cu $V = 1/T$
 - ▶ $\Phi^{-1}(0,9) = 1,282$, $\Phi^{-1}(1 - \frac{1}{10e}) = 1,789$, $\sqrt{V} = 1/20$
 - ▶ $SR_0 = \frac{1}{20}[0,4228 \cdot 1,282 + 0,5772 \cdot 1,789] = 0,079$
 - ▶ $DSR = \Phi((0,10 - 0,079)\sqrt{399}) = \Phi(0,43) = 0,66$
- ▣ Interpretare: luat singur, SR-ul este convingător (0,977); ca cel mai bun din zece încercări, nu mai este ($0,66 < 0,95$)
- ▣ Mai mult în [Capitolul 13](#), după seminar: teorema strategiei false, importanța caracteristicilor, backtest-urile walk-forward și studiul de caz S&P 500

Noțiuni necesare azi (15/15): instrumente pentru pachetele de extindere

- **Precizia, recall-ul, F1** pentru decizia „luăm tranzacția” (B9); TP, FP, FN: adevărat pozitive, fals pozitive, fals negative

$$\text{precizia} = \frac{TP}{TP + FP}, \quad \text{recall} = \frac{TP}{TP + FN}, \quad F_1 = \frac{2 \cdot \text{precizia} \cdot \text{recall}}{\text{precizia} + \text{recall}}$$

- **Importanța caracteristicilor** (B7c)


- ▶ MDI (mean decrease in impurity): reducerea lui $\sum n_R G(R)$ datorată ramificărilor după caracteristica j , mediată pe arbori; în eșantion
- ▶ MDA (mean decrease in accuracy): $AUC - AUC_{(j)}$, cu $AUC_{(j)}$ AUC-ul de test după permutarea aleatoare a caracteristicii j ; negativ: caracteristica dăunează în afara eșantionului
- ▶ SHAP (Lundberg & Lee (2017)): $\hat{p}(x) = \phi_0 + \sum_j \phi_j(x)$, o împărțire echitabilă a unei predicții între caracteristici; importanța: media lui $|\phi_j|$

- **Corelația de rang Spearman**: corelația Pearson a rangurilor; 1 = ordonări identice

A1 [Rezolvat]: ponderile FFD și fereastra păstrată — cerința

- ▣ **Întrebarea:** ce păstrează un filtru fracționar trunchiat din nivelul prețului?
- ▣ **Date de intrare:** ponderile $w_0 = 1$, $w_k = -w_{k-1} \frac{d-k+1}{k}$ (Hosking (1981)); trunchiere la primul $|w_k| < \tau = 10^{-4}$ (López de Prado (2018)); K = ultimul lag păstrat, deci fereastra folosește $K + 1$ observații; fără fișier de date
- ▣ **Sarcini**
 1. Calculați $w_0, \dots, w_4$ pentru $d = 0,25$ cu relația de recurență.
 2. Cu `ffd_weights(0.25)`, raportați K , lungimea ferestrei $K + 1$ și $\sum_{k \leq K} w_k$; repetați pentru $d = 0,3$ și $d = 0,5$.
 3. Scrieți $\tilde{X}_t = \sum_{k=0}^K w_k X_{t-k}$ ca $(\sum_k w_k) X_t$ minus o combinație a diferențelor $X_t - X_{t-k}$.
 4. Decideți dacă $\tilde{X}_t$ al unui log-preț $I(1)$ este staționar.
- ▣ **Raportați:** cele cinci ponderi, un tabel (d , K , $K + 1$, suma ponderilor), descompunerea și decizia
- ▣ **Interpretare:** regula d minim alege cel mai mic d la care un test ADF respinge: ce dovedește o astfel de respingere?
- ▣ Notebook: secțiunea A1

A1 [Rezolvat]: rezolvare (1/2)



A1 [Rezolvat]: rezolvare (2/2)

1. $w_1 = -0,25$, $w_2 = -0,25 \cdot 0,75/2 = -0,09375$,
 $w_3 = -0,0547$, $w_4 = -0,0376$: toate ponderile
 după w_0 sînt negative

2. Tabel:

d	K	$K + 1$	$\sum_{k \leq K} w_k$
0,25	444	445	0,178
0,30	387	388	0,129
0,50	199	200	0,040

3. $\tilde{X}_t = (\sum_{k \leq K} w_k) X_t - \sum_{k=1}^K w_k (X_t - X_{t-k})$
4. Fiecare $X_t - X_{t-k}$ este $I(0)$, dar primul termen este
 $0,178 X_t$ la $d = 0,25$: $\tilde{X}_t$ rămîne $I(1)$

- Panoul din dreapta: un mers aleator simulat; nivelul scalat (roșu)
 conține rădăcina unitară a seriei FFD (corelație 0,93)
- Interpretare: o respingere ADF arată că testul nu distinge o
 componentă mică cu rădăcină unitară de partea staționară, nu că
 seria este staționară

A3 [Rezolvat]: etichete cu trei bariere pe două traiectorii — cerința

Întrebările

- ▶ ce barieră este atinsă prima?
- ▶ ce etichetă rezultă?



- ▣ **Date de intrare:** intrare $P_{t_0} = 100$, volatilitate zilnică $\sigma_{t_0} = 1\%$, bariera verticală $h = 5$ zile, $pt = sl = 1$; barierele $P_{t_0} e^{\pm pt \sigma_{t_0} \sqrt{h}}$ (López de Prado (2018)); doar închideri zilnice

Sarcini

1. Calculați bariera superioară și cea inferioară.
2. Desenați-le pe cele două traiectorii și marcați prima atingere.
3. Etichetați fiecare traiectorie: +1 sus, -1 jos, iar la bariera verticală semnul lui $\ln(P_{t_0+h}/P_{t_0})$.

- ▣ **Raportați:** cele două bariere, ziua și tipul ieșirii, cele două etichete


- ▣ **Interpretare:** de ce poate primi +1 o traiectorie care se încheie sub 100? Notebook: secțiunea A3



—●— close — vertical barrier

A3 [Rezolvat]: rezolvare

1. Lățimea $0,01\sqrt{5} = 0,02236$: bariera superioară
 $100e^{0,02236} = 102,26$, cea inferioară
 $100e^{-0,02236} = 97,79$
 2. Traectoria 1: ziua 3; $102,5 \geq 102,26$, atingere sus;
 traectoria 2: nicio atingere orizontală în 5 zile
 3. Traectoria 1: +1 (scăderea ulterioară la 99,8 nu contează); traectoria 2: $\ln(99,1/100) = -0,90\%$ la bariera verticală: -1
- ☐ Interpretare: eticheta reține prima ieșire pe care ar fi luat-o un trader, nu prețul de la sfârșitul ferestrei; o ieșire verticală păstrează semnul randamentului final, deci „vertical” și „-1” sînt noțiuni diferite



B3 [Rezolvat]: etichete cu trei bariere pe Bitcoin — cerința

▣ Întrebările

- ▶ cît de des atinge Bitcoin o barieră orizontală în 10 zile?
- ▶ cît de echilibrate sînt etichetele?

- ▣ **Date și setări:** închideri zilnice BTC; fiecare zi este un eveniment t_0 ; σ_{t_0} = volatilitatea EWMA, span 50 (`get_daily_vol`); $h = 10$ zile; monitorizare pe închideri zilnice; evenimentele fără 10 închideri ulterioare sînt eliminate (4 373 de evenimente, 19 sep. 2014 – 8 sep. 2026)

▣ Sarcini

1. Cu `triple_barrier`, etichetați fiecare eveniment pentru $pt = sl = 1$ și $pt = sl = 2$; afișați înregistrarea unui eveniment (t_0 , σ_{t_0} , prețurile barierelor, t_1 , tipul ieșirii, randamentul, eticheta).
2. Calculați ponderile ieșirilor sus, jos și verticale, durata medie de deținere și ponderea etichetelor +1.
3. Faceți tabelul încrucișat tip de ieșire – etichetă finală și comparați cu eticheta cu orizont fix de 10 zile, pe aceleași evenimente.


- ▣ **Raportați:** înregistrarea evenimentului, un tabel pe variante, tabelul încrucișat, graficul ponderilor și al duratelor

▣ Interpretare

- ▶ de ce circa 56% dintre etichete sînt +1?
- ▶ ce acuratețe trebuie atunci depășită?

- ▣ Notebook: secțiunea B3

B3 [Rezolvat]: rezolvare (1/2)



B3 [Rezolvat]: rezolvare (2/2)


	Sus	Jos	Vertical	Zile	+1
$pt = sl = 1$	22,8%	18,2%	59,0%	8,25	55,7%
$pt = sl = 2$	7,2%	4,9%	87,9%	9,58	55,6%
orizont fix 10 zile	–	–	100%	10	55,5%

- Evenimentul din 11 mar. 2024: închidere 72 124, $\sigma = 3,0\%$, bariere 79 336 și 65 568; ieșire jos pe 16 mar., randament $-9,9\%$, eticheta -1
- $pt = sl = 1$: ieșirile verticale se împart în 1 442 de etichete $+1$ și 1 139 de etichete -1 ; cele orizontale dau 995 de $+1$ și 797 de -1
- Interpretare: BTC a crescut în eșantion, deci „mereu în sus” (circa 56%) este reperul; barierele mai largi apropie etichetele de cele cu orizont fix


 MFM_ch13_seminar

A7 [Rezolvat]: costul purjării — cerința

- ▣ **Întrebarea:** ce observații de antrenare trebuie eliminate când etichetele de test se suprapun cu ale lor?
- ▣ **Date de intrare:** $n = 20$ de observații $i = 0, \dots, 19$ (de la zero) în $K = 5$ pliuri contigue de $L = 4$; eticheta lui i acoperă intervalul închis $[i, i + h]$, $h = 3$; embargo $e = 1$ observație după ultimul indice de test; pliul de test $\{8, \dots, 11\}$, ale cărui etichete ajung la ziua 14
- ▣ **Sarcini**
 1. Enumerați observațiile dinaintea pliului de test al căror interval ajunge la ziua 8 (purjate înainte).
 2. Enumerați observația sub embargo și pe cele de după pliul care încep cel târziu în ziua 14 (purjate după).
 3. Numărați reuniunea eliminărilor și proporția pierdută din cele 16 observații din afara testului; pentru un pli interior, cu destule observații de ambele părți, arătați că proporția este $\frac{h + \max(h, e)}{n - L}$.
- ▣ **Interpretare:** de ce supraestimează K-fold cu amestecare acuratețea în acest cadru? Notebook: secțiunea A7



A7 [Rezolvat]: rezolvare (1/2)




A7 [Rezolvat]: rezolvare (2/2)

1. Purjate înainte: $\{5, 6, 7\}$, pentru că $i + 3 \geq 8$
 2. Embargo: $\{12\}$; purjate după: $\{12, 13, 14\}$, pentru că încep pînă în ziua 14; observația 12 sub embargo este și purjată
 3. Reuniunea: $\{5, 6, 7, 12, 13, 14\}$, 6 din 16 pierdute (37,5%); setul de antrenare $\{0, \dots, 4\} \cup \{15, \dots, 19\}$
- Pliu interior general: h observații înainte; după, etichetele care încep înainte de sfîrșitul ultimei etichete de test (h) sau în embargo (e): $\max(h, e)$; proporția $\frac{h + \max(h, e)}{n - L} = \frac{3 + 3}{16}$
 - Interpretare: amestecarea pune vecini cu randamente comune de ambele părți ale împărțirii; un model flexibil îi memorează (B5)

B5 [Rezolvat]: K-fold cu purjare față de K-fold amestecat — cerința

- ▣ **Întrebarea:** cît de mult supraestimează amestecarea acuratețea cînd ținta nu este predictibilă? Un diagnostic sintetic, fără date de piață
- ▣ **Date de intrare** (notebook, secțiunea B5, seed 42): un mers aleator de 3 000 de zile; eticheta = semnul randamentului pe 20 de zile înainte, intervale $[i, i + 20]$; 5 caracteristici = medii pe 20 de zile ale unui zgomot independent; acuratețea adevărată 50%
- ▣ **Sarcini**
 1. Verificați clasa dată `PurgedKFold`: găsiți linia care purjează înainte de pliul de test, linia care aplică embargoul și pe cea care purjează după el; rulați-o pe exemplul din A7.
 2. Estimați o pădure aleatoare ([Breiman \(2001\)](#)); 200 de arbori, frunza minimă 5, seed 42) cu 5-fold amestecat, 5-fold contiguu și 5-fold purjat cu embargo 1% (30 de observații).
 3. Raportați cele cinci acurateți pe pliuri și media lor pentru fiecare schemă.
- ▣ **Raportați:** verificarea pe A7, un grafic și un tabel cu acuratețile pe pliuri
- ▣ **Interpretare**
 - ▶ în acest cadru, ce elimină leakage-ul: purjarea sau renunțarea la amestecare?
 - ▶ s-ar reduce diferența cu etichete pe 1 zi?

B5 [Rezolvat]: rezolvare (1/2)



B5 [Rezolvat]: rezolvare (2/2)

- Pe exemplul din A7 clasa elimină $\{5, 6, 7, 12, 13, 14\}$ pentru pliul de test $\{8, \dots, 11\}$: răspunsul pas cu pas

Schema	Acurateți pe pliuri; media				
amestecat	0,707	0,678	0,698	0,700	0,687; 0,694
contiguu	0,480	0,543	0,553	0,452	0,472; 0,500
purjat	0,485	0,510	0,540	0,473	0,477; 0,497

- Seturile de antrenare purjate păstrează 2 350–2 380 din 2 400 de observații
- Interpretare: aici pliurile contigue elimină deja cea mai mare parte a leakage-ului
- ▶ doar granițele pliurilor au randamente comune; purjarea elimină observațiile de la granițe
 - ▶ leakage-ul apare când există etichete suprapuse și caracteristici persistente (Bergmeir, Hyndman & Koo (2018))
 - ▶ acest seed ilustrează rezultatul doar pentru acest cadru

Cadrul de modelare pe Bitcoin (B6–B8, B12, B14)

- ▣ Ținta: $y_t = 1\{\ln P_{t+5} - \ln P_t > 0\}$, 5 zile calendaristice (criptoactivele se tranzacționează zilnic); intervalul etichetei $[t, t + 5]$
- ▣ Rînduri: fiecare zi cu toate caracteristicile și o fereastră completă de 5 zile: $n = 4\,181$, 4 apr. 2015 – 13 sep. 2026; 54,8% „sus”
- ▣ Validare: `PurgedKFold(5, t1, pct_embargo=0.01)`: 5 pliuri contigue de 836–837 de zile, embargo 41 de zile; aceleași pliuri pentru toate modelele


11 caracteristici (build_features)	Definiție, informație pînă în ziua t
<code>mom_1</code> , <code>mom_5</code> , <code>mom_20</code> , <code>mom_60</code> , <code>mom_120</code>	$x_t - x_{t-h}$
<code>vol_20</code> , <code>vol_60</code> , <code>vol_ratio</code>	abaterea standard a lui r_t pe 20 și 60 de zile $\times \sqrt{365}$; raportul lor
<code>dist_ma50</code> , <code>dist_ma200</code>	x_t minus media lui x pe ultimele 50 sau 200 de zile
<code>rsi_14</code>	indicele de forță relativă, 14 zile, împărțit la 100

- ▣ Modele: Logit-L1 (standardizat, $C = 0,05$, [Tibshirani \(1996\)](#)); RF (400 de arbori, frunza minimă 50, [Breiman \(2001\)](#)); GB (pe histograme, adîncime 3, rată de învățare 0,03; 200 de arbori, [Friedman \(2001\)](#)); seed 42
- ▣ Se salvează pentru exercițiile următoare: un rînd pe dată cu eticheta, pliul, cele trei probabilități în afara pliului și prognoza constantă (proporția „sus” din antrenare în acel pli)

B7a [Rezolvat]: trei modele față de „mereu în sus” — cerința

- ▣ **Întrebarea:** prezice vreunul dintre cele trei modele direcția Bitcoin pe 5 zile mai bine decât „mereu în sus”?
- ▣ **Date:** cadrul de modelare de pe slide-ul anterior
- ▣ **Sarcini**
 1. Estimați Logit-L1, RF și GB pe fiecare pliu de antrenare purjat și prognozați pliul de test; salvați probabilitățile în afara pliului.
 2. Pentru fiecare model, calculați acuratețea ($\hat{p} > 0,5$) și ROC AUC în fiecare pliu de test și mediile lor (**medii pe pliuri**).
 3. Calculați acuratețea „mereu în sus” a fiecărui pliu de test, adică proporția etichetelor „sus”, și media pe pliuri.
 4. Calculați AUC **agregat**: un singur AUC pe toate cele 4 181 de probabilități în afara pliurilor.
- ▣ **Raportați:** un tabel (acuratețe, AUC, abaterea între pliuri), reperul, graficul cu punctele pe pliuri, proporția prognozelor „sus”
- ▣ **Interpretare:** de ce o acuratețe de 54,8% nu este aici o dovadă de abilitate? Notebook: secțiunea B7

B7a [Rezolvat]: rezolvare (1/2)



B7a [Rezolvat]: rezolvare (2/2)


	Logit-L1	RF	GB
Acuratețe, media pe pliuri	54,8%	54,2%	52,2%
AUC, media pe pliuri	0,492	0,516	0,502
AUC agregat	0,466	0,512	0,498
Prezis „sus”	99,6%	70,3%	68,5%

- „Mereu în sus”: proporțiile pe pliuri 61,3%; 53,5%; 56,6%; 51,3%; 51,3%, media 54,8%; niciun model nu îl depășește; Logit-L1 se reduce la „mereu în sus”
- Media pe pliuri și AUC agregat diferă: cinci ordonări mediate față de o singură ordonare pe toate zilele, care amestecă și calibrarea pliurilor
- Interpretare: 54,8% este proporția săptămînilor „sus”, nu o abilitate; întrebarea următoare este cît de incert este 0,512 al RF (B7b)

B7b [Rezolvat]: un CI pentru AUC robust la dependență — cerința

- ▣ **Întrebarea:** diferă semnificativ AUC agregat de 0,512 al RF de 0,5?
- ▣ **Date:** probabilitățile RF în afara pliurilor și etichetele salvate în B7a ($n = 4\,181$); $AUC = P(\hat{p}_+ > \hat{p}_-) + \frac{1}{2}P(\hat{p}_+ = \hat{p}_-)$, 0,5 = nicio ordonare
- ▣ **Sarcini**
 1. Calculați eroarea standard DeLong (DeLong, DeLong & Clarke-Pearson (1988)), CI 95%, $z = (AUC - 0,5)/SE$ și p -value-ul bilateral.
 2. Reșantionați rîndurile cu un bootstrap circular pe blocuri (Künsch (1989)): blocuri de $L \in \{1, 20, 60\}$ zile consecutive, 1000 de replici, seed 42; recalculați de fiecare dată AUC.
 3. Raportați SE bootstrap, CI 95% percentil și proporția replicilor egale cu sau sub 0,5, pentru fiecare L .
- ▣ **Raportați:** un grafic cu intervalele și distribuțiile bootstrap pentru $L = 1$ și $L = 20$
- ▣ **Interpretare**
 - ▶ de ce este intervalul bootstrap pe blocuri mai larg?
 - ▶ ce lungime de bloc ați justifica?
- ▣ Notebook: secțiunea B7

B7b [Rezolvat]: rezolvare (1/2)



B7b [Rezolvat]: rezolvare (2/2)

- ▣ DeLong: SE 0,0090, CI [0,495; 0,530], $z = 1,37$, $p = 0,17$; $L = 1$: SE 0,0091, CI [0,494; 0,530], ca DeLong
- ▣ $L = 20$: SE 0,0150, CI [0,484; 0,543]; 20,8% dintre replici $\leq 0,5$; $L = 60$: SE 0,0141, CI [0,485; 0,541]
- ▣ Interpretare: etichetele suprapuse pe 5 zile și volatility clustering fac zilele vecine dependente; SE robustă la dependență este de 1,7 ori SE DeLong. Un bloc cel puțin egal cu orizontul etichetei, stabil între 20 și 60 de zile: $L = 20$ se poate justifica. Histogramele sînt distribuții ale estimatorului, nu distribuții sub ipoteza nulă

B8 [Propus]: Diebold–Mariano pentru prognoze de probabilitate — cerința

- ▣ **Model:** B7a și B7b [Rezolvat]
- ▣ **Întrebarea:** prognozează vreun model probabilitatea unei săptămîni „sus” mai bine decît o constantă?
- ▣ **Date de intrare:** probabilitățile salvate în B7a, limitate la $[10^{-6}, 1 - 10^{-6}]$; log loss $\ell_t = -[y_t \ln \hat{p}_t + (1 - y_t) \ln(1 - \hat{p}_t)]$; rînd rezolvat, 13 iul. 2015, $y_t = 0$: constantă $\hat{p} = 0,529$, $\ell = -\ln(1 - 0,529) = 0,753$; RF $\hat{p} = 0,496$, $\ell = 0,684$
- ▣ **Sarcini**
 1. Calculați log loss mediu pentru Logit-L1, RF, GB și constantă.
 2. Pentru RF față de Logit-L1, RF față de constantă și GB față de constantă, formați $d_t = \ell_t^A - \ell_t^B$ ($d_t > 0$: modelul A mai slab) și regresați d_t pe o constantă cu erori Newey–West (Newey & West (1987)), lag-uri 4 și 20: statistica DM este valoarea t (Diebold & Mariano (1995)), bilateral.
 3. Calculați statistica t naivă i.i.d. a lui $\bar{d}$ și comparați.
- ▣ **Raportați:** un tabel cu log loss, $\bar{d}$, DM (lag-uri 4, 20) cu p -value-uri, t naiv; un grafic cu d_t cumulat
- ▣ **Interpretare:** poate un model cu AUC peste 0,5 să aibă un log loss mai mare decît o constantă? Probabilitățile din CV agregat sînt descriptive: o afirmație despre utilizare cere prognoze walk-forward. Notebook: secțiunea B8

C2 [Propus]: critica unui răspuns AI — răspunsul

- **Promptul** trimis unui asistent AI: „Prognozează direcția Bitcoin de mâine din randamentele trecute și evaluează modelul în afara eșantionului, cu validare încrucișată în 5 pliuri”
- **Răspunsul** (btc: închideri zilnice 2014-09-17 – 2026-09-18; fără importuri):

```
1 r = np.log(btc).diff()
2 X = pd.DataFrame({'r1': r, 'r5': r.rolling(5).sum(), 'vol20': r.rolling(20).std(),
3                  'trend10': r.rolling(10, center=True).mean()})
4 data = pd.concat([X, r.shift(-1).rename('fwd')], axis=1).dropna()
5 y = (data['fwd'] > 0).astype(int) # 1 if tomorrow is up
6 Xs = StandardScaler().fit_transform(data[X.columns])
7 cv = KFold(n_splits=5, shuffle=True, random_state=0)
8 model = LogisticRegression(penalty='l1', C=0.1, solver='liblinear')
9 auc = cross_val_score(model, Xs, y, cv=cv, scoring='roc_auc')
10 print(round(auc.mean(), 3))
```

- „Rezultat: 0,697. Un AUC de 0,70 în afara eșantionului, pe 4 361 de zile, este un semnal puternic, tranzacționabil; validarea încrucișată este în afara eșantionului, deci nu există overfitting”


C2 [Propus]: critica unui răspuns AI — cerința

- ▣ **Model:** B5 și B7a [Rezolvat]; B6 (extindere) este aceeași capcană într-un model mai mare
- ▣ **Sarcini**
 1. Dați cinci constatări adnotate, fiecare cu numărul liniei: două surse de leakage din test, o schemă de validare care nu corespunde utilizării reale, două afirmații nesustținute.
 2. Pentru fiecare, spuneți cum ați detecta-o: o verificare a rezultatului, un rezultat din B5 sau B7a, o regulă din slide-urile „Noțiuni necesare azi”.
 3. Scrieți un singur pipeline corectat: caracteristici calculate doar din trecut, scalarea în fiecare pliuri de antrenare (`make_pipeline`), `TimeSeriesSplit(n_splits=5, gap=20)`, AUC mediu pe cele 5 pliuri de test.
 4. Raportați un tabel înainte/după: codul AI, apoi fiecare corecție adăugată pe rînd.
 5. Treceți erorile în formatul `AI_ERRORS.md`: cererea, răspunsul, eroarea, cum ați găsit-o, corecția.
- ▣ **Interpretare**
 - ▶ ce zile intră în `trend10` în ziua t ?
 - ▶ care dintre ele este ținta?
- ▣ Un AUC neobișnuit de mare este un motiv să verificați codul, nu o dovadă de leakage

A5 [Rezolvat]: PSR și DSR, fișă de calcul — cerința

- ▣ **Întrebarea:** este convingător un raport Sharpe anualizat de 1,2 pe trei ani, dacă este cel mai bun din 100 de încercări?
- ▣ **Date de intrare** (strategie pe acțiuni, $A = 252$ de zile de tranzacționare pe an): SR anualizat $\widehat{SR}_{an} = 1,2$, $T = 756$ randamente zilnice, $\hat{\gamma}_3 = -0,4$, kurtosis obișnuit $\hat{\gamma}_4 = 5$; $N = 100$ încercări independente, $V = \text{Var}[\widehat{SR}_n] = 1/T$; constanta lui Euler $\gamma_E = 0,5772$ (Bailey & López de Prado (2012); Bailey & López de Prado (2014))
- ▣ **Sarcini**
 1. SR zilnic $\widehat{SR} = 1,2/\sqrt{252}$ și numitorul $D = \sqrt{1 - \hat{\gamma}_3 \widehat{SR} + \frac{\hat{\gamma}_4 - 1}{4} \widehat{SR}^2}$.
 2. $z = \widehat{SR} \sqrt{T-1}/D$ și $PSR(0) = \Phi(z)$.
 3. $SR_0 = \sqrt{V} [(1 - \gamma_E) \Phi^{-1}(1 - \frac{1}{N}) + \gamma_E \Phi^{-1}(1 - \frac{1}{N_e})]$, zilnic și anualizat.
 4. $DSR = \Phi((\widehat{SR} - SR_0) \sqrt{T-1}/D)$.
- ▣ **Raportați:** fiecare număr intermediar, PSR(0) și DSR; derivarea lui D este în extindere (A5 extins)
- ▣ **Interpretare**
 - ▶ pentru randamente i.i.d., reper zero și 100 de încercări, ce spune DSR?
 - ▶ ce N l-ar schimba?
- ▣ Notebook: secțiunea A5

A5 [Rezolvat]: rezolvare (1/2)



A5 [Rezolvat]: rezolvare (2/2)

1. $\widehat{SR} = 1,2/\sqrt{252} = 0,07559$; $D = \sqrt{1 + 0,4 \cdot 0,07559 + 1 \cdot 0,07559^2} = 1,01782$
 2. $z = 0,07559 \cdot \sqrt{755}/1,01782 = 2,041$; $PSR(0) = \Phi(2,041) = 0,979$
 3. $\sqrt{V} = 1/\sqrt{756} = 0,03637$; $\Phi^{-1}(0,99) = 2,326$, $\Phi^{-1}(1 - \frac{1}{100e}) = 2,680$;
 $SR_0 = 0,03637 [0,4228 \cdot 2,326 + 0,5772 \cdot 2,680] = 0,0920$ pe zi, 1,46 anualizat
 4. $z = (0,07559 - 0,0920)\sqrt{755}/1,01782 = -0,444$; $DSR = \Phi(-0,444) = 0,329$
- ☐ Interpretare: numai prin noroc, maximul așteptat al SR anualizat din 100 de încercări i.i.d. fără abilitate este 1,46
- ▶ peste valoarea observată de 1,2: dovada nu atinge pragul ilustrativ de 0,95
 - ▶ cu $N = 1$, DSR este egal cu $PSR(0) = 0,979$

Proiectul de echipă: alegeți un traseu

- ▣ **Standard:** un activ la alegere, prin B1, B3, B7a, B7b și B10, cu matricea randamentelor tuturor regulilor încercate salvată
- ▣ **Avansat:** C1 (model fundațional față de boosting) sau C3 (un SDF fără arbitraj pe decile), în pachetele de extindere
- ▣ Dovezi minime: codul ca Quantlet, un grafic, testul față de un reper, numărul de încercări; folosirea AI în `AI_USE.md`, erorile depistate în `AI_ERRORS.md`
- ▣ Un rezultat negativ, documentat riguros, este un rezultat valid

După curs: două exerciții rezolvate de refăcut

- Rezolvați aceste două exerciții după [Capitolul 13](#): folosesc estimatori și argumente pe care cursul le dezvoltă
 - ▶ B1: estimatorul exact local Whittle ([Shimotsu & Phillips \(2005\)](#)) și inferența asupra memoriei δ a log-prețului Bitcoin; model: A1
 - ▶ B10: o grilă de 120 de reguli de tranzacționare corelate, valorile proprii ale matricei lor de corelație și numărul efectiv de încercări din DSR; model: A5
- Ambele sînt [Rezolvat]: refaceți-le în notebook (secțiunile B1 și B10) și comparați cu slide-urile

B1 [Rezolvat]: memoria log-prețului Bitcoin — cerința

▣ Întrebările

- ▶ ce d alege regula ADF minimă pentru Bitcoin?
- ▶ care este memoria δ a log-prețului?

- ▣ **Date:** $x_t = \ln P_t$, BTC 2014-09-17 – 2026-09-18 ($n = 4\,385$); funcții disponibile: `frac_diff_ffd`, `exact_local_whittle`, `local_whittle`

▣ Sarcini

1. Pentru $d \in \{0; 0,05; \dots; 1\}$, filtrați x_t ($\tau = 10^{-4}$), rulați `adfuller(x, maxlag=1, regression='c', autolag=None)` (Dickey & Fuller (1979)) și notați statistica și $\text{Corr}(\tilde{x}_t, x_t)$ pe datele păstrate de filtru.
2. Raportați d^* , cel mai mic d cu statistica sub valoarea critică la 5%.
3. Estimați δ cu CI 95% ($m = \lfloor n^{0,65} \rfloor$ frecvențe Fourier pentru fiecare serie, n fiind lungimea ei, $\lfloor \cdot \rfloor$ partea întreagă): local Whittle exact (ELW, Shimotsu & Phillips (2005)) pentru x_t și seria FFD la d^* , local Whittle (LW, Robinson (1995)) pentru r_t și $|r_t|$.
4. Testați $H_0 : \delta = 1$ pentru x_t cu $z = (\hat{\delta} - 1)/\text{SE}$, din estimarea nerotunjită.




- ▣ **Raportați:** graficul ADF–corelație, d^* , un tabel cu cele patru estimări și CI, z și p

▣ Interpretare

- ▶ este seria FFD la d^* staționară?
- ▶ unde se află memoria Bitcoin?

- ▣ Notebook: secțiunea B1

B1 [Rezolvat]: rezolvare (1/2)



—●— ADF statistic (constant, 1 lag) $d^* = 0.25$

--- 5% critical value

—■— corr(FFD series, log price)

--- stationarity boundary 0.5 unit root 1


B1 [Rezolvat]: rezolvare (2/2)

- ▣ ADF: $-1,21$ ($d = 0$); $-2,32$ (0,05); $-2,24$ (0,10); $-2,39$ (0,15); $-2,85$ (0,20); $-3,38$ (0,25); valoarea de 5% $-2,86$: $d^* = 0,25$, corelația 0,955; traiectoria nu este monotonă în d
- ▣ ELW log-preț 1,065 [1,000; 1,129] ($m = 232$); FFD la d^* 0,814 [0,747; 0,880]; LW randamente 0,063 [$-0,002$; 0,127]; $|r_t|$ 0,353 [0,289; 0,417]
- ▣ $z = (1,0647 - 1)/0,0328 = 1,97$, p bilateral = 0,049: o respingere la limită spre $\delta > 1$ (bule speculative), niciodată spre staționaritate
- ▣ Interpretare: seria FFD are $\hat{\delta} \approx 1 - d$ în banda de frecvențe, iar CI-ul ei este mult peste $\frac{1}{2}$: nu este staționară; memoria lungă a Bitcoin este în volatilitate, $|r_t|$

B10 [Rezolvat]: căutare în grilă, DSR și numărul efectiv de încercări — cerința

- ▣ **Întrebarea:** după căutarea printre 120 de reguli de medii mobile pe Bitcoin, depășește cea mai bună dintre ele norocul?
- ▣ **Reguli:** fereastra rapidă $f \in \{5, 10, \dots, 55\}$, lentă $s \in \{20, 40, \dots, 240\}$, $s > f$: $N = 120$; semnalul din ziua t : $1\{\bar{x}_{f,t} > \bar{x}_{s,t}\}$ ($\bar{x}_{f,t}$: media log-prețului pe ultimele f zile), deținut în ziua $t + 1$: $r_{t+1}^{(f,s)} = \text{semnal}_t \cdot r_{t+1}$; long/numerar, fără costuri, rata fără risc 0
- ▣ **Date:** start comun în prima zi în care fiecare regulă are semnal, 15 mai 2015, pînă la 18 sep. 2026: $T = 4\,145$ zile, $A = 365$
- ▣ **Sarcini**
 1. Construiți matricea de randamente $T \times 120$; alegeți regula cu cel mai bun SR; raportați SR, asimetria, kurtosis și PSR(0) (Bailey & López de Prado (2012)).
 2. Din matricea de corelație 120×120 : valorile proprii, numărul care atinge 95% din varianță și $\hat{N} = \bar{\rho} + (1 - \bar{\rho})N$, cu $\bar{\rho}$ corelația medie din afara diagonalei (euristici, nu teoreme).
 3. Calculați SR_0 și DSR (Bailey & López de Prado (2014)) pentru $N = 120$, $\hat{N}$ și numărul de la 95%, cu $V = 1/T$.
- ▣ **Raportați:** o hartă a rapoartelor Sharpe cu regula aleasă, graficul valorilor proprii, un tabel DSR
- ▣ **Interpretare:** ce N și ce V ați raporta unui comitet de investiții? Notebook: secțiunea B10

B10 [Rezolvat]: rezolvare (1/2)



B10 [Rezolvat]: rezolvare (2/2)

$V = 1/T$	$N = 120$	$\hat{N} = 15,9$	$N = 4$
SR_0 (an.)	0,77	0,53	0,31
DSR	0,922	0,987	0,998

- Cea mai bună regulă (5, 40): SR 1,19 anualizat (buy-and-hold 0,78); asimetrie 0,13, kurtosis 12,8; $PSR(0) = 1,000$
- Cea mai mare valoare proprie, $\lambda_1 = 105,5$, explică 87,9%; 4 valori proprii ating 95%; $\bar{\rho} = 0,875$, $\hat{N} = 15,9$
- Interpretare: tratarea celor 120 de încercări corelate ca independente deflatează excesiv
 - ▶ DSR testează „mai bine decât norocul”, nu „mai bine decât buy-and-hold” (B13)
 - ▶ regula câștigătoare a fost aleasă pe tot eșantionul: o afirmație cere o regulă fixată și un eșantion de verificare neatins (cursul, grila Bitcoin)

Pachetele de extindere: condițiile fiecăruia

Pachet	Exerciții	Condiții
1. Memorie	A2, B2	A1, B1
2. Etichete	A3 extins [Rezolvat], A4, B4	A3, B3
3. Validare și leakage	A8, B6	A7, B5, cadrul de modelare
4. Inferență predictivă	A9 [Rezolvat], A10, B7c [Rezolvat], B12 [Rezolvat]	B7a, B7b, B8
5. Strategii și selecție	A5 extins [Rezolvat], A6, B9 [Rezolvat], B11, B13	A5, B10
6. Inferență cu multe controale	B14	exemplul din curs (VIX)
7. Proiecte	C1, C3	Capitolul 14 (C1); studiul de caz din curs (C3)

- Fiecare exercițiu are secțiunea lui în notebook, cu aceeași etichetă; rezolvați-le în ordine, în cadrul unui pachet
- C1 și C3 sînt puncte de plecare posibile pentru proiectul de echipă

A2 [Propus]: lungimea ferestrei și respingerile ADF prea dese — cerința

- ▣ **Model:** A1 [Rezolvat]
- ▣ **Întrebarea:** cît de des respinge ADF rădăcina unitară în seria FFD a unui mers aleator pur?
- ▣ **Simulare** (`rng = default_rng(42)`): pentru $d \in \{0,3; 0,5\}$ și fiecare dintre 500 de traiectorii, calculați K , extrageți $T + K$ inovații $\varepsilon_s \sim N(0, 1)$ cu $T = 2500$, puneți $X_t = \sum_{s \leq t} \varepsilon_s$ (X pornește de la prima extragere), aplicați filtrul finit și păstrați exact T valori; apoi repetați cu $d = 0,25$ și fără filtru (control)
- ▣ **Sarcini**
 1. Rulați `adfuller(f, maxlag=1, regression='c', autolag=None)` pe fiecare traiectorie și notați respingerile la 5%.
 2. Pe aceleași traiectorii, rulați testul cu lag-uri alese prin AIC (`autolag='AIC'`).
 3. Raportați fiecare frecvență de respingere cu eroarea ei Monte Carlo $\sqrt{\hat{p}(1 - \hat{p})/500}$.
- ▣ **Interpretare:** fiecare traiectorie este $I(1)$
 - ▶ de ce nu distinge testul ADF cu un lag un mers aleator scalat de o serie staționară?
 - ▶ ce d ar face staționar un preț $I(1)$?
- ▣ Notebook: secțiunea A2

B2 [Propus]: memoria Ether, o capcană metodologică — cerința

- ▣ **Model:** B1 [Rezolvat]
- ▣ **Întrebarea:** cât de robustă este regula ADF minimă pe un activ care a crescut de circa 1 000 de ori?
- ▣ **Date:** log-închideri ETH-USD; trei specificații, fiecare cu scanarea completă a grilei $d \in \{0; 0,05; \dots; 1\}$ și un lag ADF

Rînd	Eșantion	Termeni deterministici	Valoarea critică 5%
1	2015-08-07 – 2026-09-18 ($n = 4\,061$)	constantă	−2,86
2	2015-08-07 – 2026-09-18	constantă + trend	−3,41
3	2018-01-01 – 2026-09-18 ($n = 3\,183$)	constantă	−2,86

- ▣ **Sarcini:** (1) raportați d^* și valorile ADF la $d = 0$ și $0,05$ pentru fiecare rînd; (2) ELW cu CI 95% pentru log-preț pe rîndurile 1 și 3; (3) LW pentru $|r_t|$ pe tot eșantionul
- ▣ **Interpretare**
 - ▶ ce d ați folosi într-un model?
 - ▶ de ce acel d ?
- ▣ Notebook: secțiunea B2

A3 extins [Rezolvat]: probabilități de atingere — cerința

- ▣ **Întrebarea:** ce proporție de evenimente ar trebui să se încheie la bariera verticală dacă prețurile ar fi o mișcare browniană?
- ▣ **Cadru:** log-prețul σW_t , W_t o mișcare browniană standard (fără tendință), barierele $+a = pt \sigma \sqrt{h}$ și $-b = -sl \sigma \sqrt{h}$; τ = primul moment în care una este atinsă; martingalele W_t și $W_t^2 - t$ (procesele a căror valoare viitoare așteptată este cea curentă); moment de oprire τ cu $\mathbb{E}[\tau] < \infty$; teorema de oprire opțională: atunci $\mathbb{E}[W_\tau] = 0$ și $\mathbb{E}[W_\tau^2] = \mathbb{E}[\tau]$ (Karatzas & Shreve (1998))
- ▣ **Sarcini**
 1. Fără barieră verticală, derivați P (sus prima) și $\mathbb{E}[\tau]$ prin oprire opțională.
 2. Pentru $pt = sl = 1$ și $h = 10$, calculați $P(\tau > h)$ cu monitorizare continuă, cu

$$P(\tau > h) = \frac{4}{\pi} \sum_{n \geq 0} \frac{(-1)^n}{2n+1} e^{-(2n+1)^2 \pi^2 / 8}.$$
 3. Aproximați monitorizarea zilnică mutînd fiecare barieră în afară cu $0,5826 \sigma$ (Broadie, Glasserman & Kou (1997)); apoi simulați 400 000 de traiectorii de 10 pași zilnici gaussieni (seed 42) și comparați.
- ▣ **Interpretare:** B3 găsește 59,0% ieșiri verticale pe Bitcoin: ce parte din diferența față de valoarea browniană ține de monitorizare și ce parte de date?

A3 extins [Rezolvat]: rezolvare

1. W_t este martingală: $0 = p a - (1 - p) b \Rightarrow p = \frac{b}{a+b} = \frac{sl}{pt+sl}$; $\sigma^2 W_t^2 - \sigma^2 t$ este martingală:
 $\sigma^2 \mathbb{E}[\tau] = p a^2 + (1 - p) b^2 = ab \Rightarrow \mathbb{E}[\tau] = pt \cdot sl \cdot h \text{ zile}$
 2. Monitorizare continuă, exact: $P(\tau > h) = 1,2732 \cdot 0,2912 - \dots = 0,371$
 3. Monitorizare zilnică, aproximativ: $c = 1 + 0,5826/\sqrt{10} = 1,184$, înlocuind $\pi^2/8$ cu $\pi^2/(8c^2)$ obținem 0,528; simulat cu pași zilnici: 0,517 (SE 0,001)
- Interpretare: monitorizarea discretă explică cea mai mare parte a diferenței dintre 37% și 59%; cele 7 puncte rămase pot proveni din cozile groase, volatility clustering și eroarea volatilității EWMA, pe care această comparație nu le separă

A4 [Propus]: bariere asimetrice — cerința

▣ **Model:** A3 și A3 extins [Rezolvat]

▣ **Date de intrare:** $P_{t_0} = 50$, $\sigma_{t_0} = 2\%$, $h = 4$, $pt = 2$, $sl = 1$; traiectoriile (i) 50; 51,5; 53,0; 49,5; 47,9 și (ii) 50; 52,0; 54,5; 53,0; 51,0

▣ **Sarcini**

1. Calculați ambele bariere, desenați-le pe cele două traiectorii și etichetați fiecare traiectorie.
2. Opțional (tendință): pentru $X_t = \mu t + \sigma W_t$ (μ : tendința pe zi) fără barieră verticală, funcția de scală $s(x) = e^{-2\mu x/\sigma^2}$ rezolvă $\frac{\sigma^2}{2}s'' + \mu s' = 0$, deci $s(X_t)$ este martingală; derivați

$$P(\text{sus prima}) = \frac{e^{2\mu b/\sigma^2} - 1}{e^{2\mu b/\sigma^2} - e^{-2\mu a/\sigma^2}} \text{ și evaluați-o pentru } \sigma = 3\%, \mu = 0,1\% \text{ pe zi, } h = 10.$$

▣ **Raportați:** barierele, etichetele, formula și valoarea ei

▣ **Interpretare:** formula nu are barieră verticală: ce traiectorii ar cenzura o barieră verticală la h ? Notebook: secțiunea A4

B4 [Propus]: bariere asimetrice pe Bitcoin — cerința

- ▣ **Model:** B3 [Rezolvat] și A3 extins
- ▣ **Date:** evenimentele, volatilitatea EWMA și etichetarea din B3, $h = 10$; variantele $(pt, sl) = (2, 1)$ și $(1, 2)$
- ▣ **Sarcini**
 1. Raportați ponderile ieșirilor, ponderea etichetelor +1 și durata medie de deținere pentru ambele variante.
 2. Calculați ponderea ieșirilor sus între ieșirile orizontale, sus/(sus + jos).
 3. Comparați-o cu $sl/(pt + sl)$ (fără barieră verticală) și cu o simulare: 400 000 de traiectorii de 10 pași zilnici gaussieni, în unități de σ , bariere la $pt\sqrt{10}$ și $-sl\sqrt{10}$, seed 42, tendință zero și tendința BTC $\bar{r}/\hat{\sigma} = 0,034$ pe zi; dați SE a simulării.
- ▣ **Interpretare:** cum schimbă alegerea echilibrul claselor pe care îl vede un clasificator? Asimetria este o ipoteză de modelare, nu o regulă optimă de tranzacționare. Notebook: secțiunea B4

A8 [Propus]: purjare cu etichete mai scurte — cerința

- ▣ **Model:** A7 [Rezolvat]
- ▣ **Date de intrare:** ca în A7, cu intervalele închise $[i, \min(i + 2, 19)]$ ($h = 2$), embargo $e = 1$, pliul de test $\{12, \dots, 15\}$
- ▣ **Sarcini**
 1. Pe o axă a indicilor 0–19, completați un tabel cu coloanele purjate înainte, embargo, purjate după și reuniunea.
 2. Verificați numărătoarea cu formula din A7.
 3. Pliu interior cu $n = 250$, $K = 5$ ($L = 50$), $h = 20$, $e = 1$: calculați proporția pierdută; repetați cu $K = 10$ ($L = 25$).
- ▣ **Interpretare**
 - ▶ ce proporție din eșantion elimină purjarea când etichetele sînt lungi și pliurile scurte?
 - ▶ ce soluții ați propune?
- ▣ **Notebook:** secțiunea A8

B6 [Propus]: identificarea leakage-ului — cerința

- ▣ **Model:** B5 [Rezolvat] și C2
- ▣ **Date:** cadrul de modelare plus o a 12-a caracteristică, construită în notebook ca `ma11 = r.rolling(11, center=True).mean()`; RF cu 300 de arbori (nu 400 ca în B7a), frunza minimă 50, seed 42, 5-fold purjat; 4 181 de rînduri
- ▣ **Sarcini**
 1. Scrieți datele $t - 5, \dots, t + 5$ care intră în `ma11` în ziua t și marcați-le pe cele din fereastra țintei $t + 1, \dots, t + 5$; ordonați cele 12 caracteristici după MDI.
 2. Calculați corelația lui `ma11` și a mediei retrospective `r.rolling(11).mean()` cu randamentul pe 5 zile înainte.
 3. Raportați acuratețea și AUC pentru: 11 caracteristici + `ma11` centrată; 11 + retrospectivă; cele 11 de bază, pe aceleași rînduri, pliuri și setări.
- ▣ **Interpretare:** de ce nu poate purjarea să detecteze acest leakage? Dați un al doilea exemplu de informație din viitor într-un flux de caracteristici. Notebook: secțiunea B6

A9 [Rezolvat]: AUC pas cu pas — cerința

▣ Întrebările




- ▶ ce măsoară AUC?
- ▶ cât de incert este cu șase observații?

- ▣ **Date de intrare:** scorurile a 3 pozitive (0,80; 0,55; 0,40) și 3 negative (0,60; 0,35; 0,20); $n_1 = n_0 = 3$ pozitive și negative; U = numărul perechilor (pozitiv, negativ) ordonate corect, $A = U/(n_1 n_0) = U/9$; SE Hanley–McNeil (Hanley & McNeil (1982)): $SE^2 = \frac{A(1-A) + (n_1-1)(Q_1-A^2) + (n_0-1)(Q_2-A^2)}{n_1 n_0}$, $Q_1 = \frac{A}{2-A}$, $Q_2 = \frac{2A^2}{1+A}$

▣ Sarcini

1. Completați grila de comparație 3×3 (este pozitivul peste negativ?) și calculați U și A .
 2. Desenați curba ROC în trepte și verificați că aria ei este A .
 3. Calculați SE și statistica Wald $z = (A - 0,5)/SE$, bilateral.
 4. Enumerați cele 20 de moduri de a eticheta 3 dintre cele 6 scoruri ca pozitive, calculați U pentru fiecare și $P(U \geq 7)$ exact.
- ▣ **Interpretare:** ce ipoteză a SE nu mai este îndeplinită pentru etichete suprapuse pe 5 zile? Notebook: secțiunea A9

A9 [Rezolvat]: rezolvare (1/2)



— ROC, AUC = 0.778 --- no skill ■ U at least as large as observed

A9 [Rezolvat]: rezolvare (2/2)

1. 0,80 este peste 3 negative, 0,55 peste 2; 0,40 peste 2: $U = 7$, $A = 0,778$; (2) aria curbei în trepte este $\frac{1}{3} \cdot \frac{1}{3} + \frac{2}{3} \cdot 1 = \frac{7}{9}$
 3. $Q_1 = 0,636$, $Q_2 = 0,681$, $SE = 0,207$, $z = 1,34$, $p = 0,18$ (asimptotic, nesigur cu șase puncte)
 4. Exact: $P(U \geq 7) = 4/20 = 0,20$, p bilateral = 0,40 cu etichete interschimbabile: șase observații nu pot separa abilitatea de noroc
- ☐ Ambele SE presupun observații independente; etichetele suprapuse au randamente comune, deci eșantionul efectiv este mai mic: B7b folosește în schimb un bootstrap pe blocuri


A10 [Propus]: AUC ca statistică U și varianța DeLong — cerința

- ▣ **Model:** A9 [Rezolvat]
- ▣ **Date de intrare:** 4 pozitive (0,70; 0,62; 0,48; 0,45); 4 negative (0,66; 0,50; 0,40; 0,30); nucleul $\psi(s_i, s_j) = 1\{s_i > s_j\} + \frac{1}{2}1\{s_i = s_j\}$, cu s_i scorul pozitivei i , s_j al negativei j , $1\{\cdot\}$ funcția indicator; $n_1 = n_0 = 4$
- ▣ **Sarcini**
 1. Completați grila 4×4 a lui ψ ; calculați U , AUC și SE Hanley–McNeil.
 2. Mediile pe rînduri $V_{10}(i)$ și pe coloane $V_{01}(j)$ ale grilei (valori de plasare); varianțele lor de selecție S_{10} , S_{01} , cu numitorii $n_1 - 1$ și $n_0 - 1$.
 3. $SE\ DeLong = \sqrt{S_{10}/n_1 + S_{01}/n_0}$ (DeLong, DeLong & Clarke-Pearson (1988)).
 4. Demonstrație opțională: prin descompunerea Hoeffding, AUC este asimptotic suma a două medii independente ale valorilor de plasare.
- ▣ **Interpretare:** argumentul este asimptotic, nu o garanție exactă pentru eșantioane mici: ce înseamnă asta cu 8 scoruri? Notebook: secțiunea A10

B7c [Rezolvat]: concordanța măsurilor de importanță — cerința

- ▣ **Întrebarea:** ordonează măsurile de importanță în eșantion și în afara lui cele 11 caracteristici la fel?
- ▣ **Date:** cadrul de modelare, cu o împărțire cronologică separată: RF (400 de arbori, frunza minimă 50) estimat pe primele 70% (pînă la 8 apr. 2023), evaluat după o pauză de 5 + 41 de zile, din 24 mai 2023; o singură împărțire, pentru că importanțele cer un singur model estimat
- ▣ **Sarcini**
 1. MDI din pădurea estimată; MDA ca scăderea AUC de test cînd o caracteristică este permutată (10 repetări); media $|SHAP|$ pe 300 de zile de test ([Lundberg & Lee \(2017\)](#)).
 2. Corelațiile de rang Spearman între cele trei măsuri.
- ▣ **Interpretare**
 - ▶ ce înseamnă un MDA negativ?
 - ▶ de ce estompează caracteristicile corelate toate cele trei măsuri?
- ▣ Notebook: secțiunea B7

B7c [Rezolvat]: rezolvare (1/2)



B7c [Rezolvat]: rezolvare (2/2)

- MDI pune primele `vol_60`, `vol_20`, `mom_120`; MDA este negativ pentru ambele caracteristici de volatilitate și cel mai mare pentru `rsi_14` (0,026)
- Spearman: MDI-SHAP 0,75, MDI-MDA -0,42, MDA-SHAP -0,10: ordonările în eșantion și în afara lui nu concordă
- Interpretare: un MDA negativ înseamnă că, pe date noi, caracteristica permutată dă un scor mai bun decât cea reală: un semn de overfitting, în limita zgomotului de eșantionare; caracteristicile corelate își împart și își diluează importanța, iar permutarea extrapolează în afara datelor

B12 [Rezolvat]: Pesaran–Timmermann și Clark–West — cerința

▣ Întrebările

- ▶ conțin semnele prezise informație?
- ▶ adaugă caracteristicile informație unei prognoze constante?


- ▣ **Date:** probabilitățile salvate în B7a și constanta din B8; $x_t = 1\{\hat{p}_t > 0,5\}$. Precizare înainte de a începe: Clark–West (Clark & West (2007)) este derivat pentru modele liniare imbricate și prognoze reale în afara eșantionului; pe probabilitățile unui logit penalizat din CV purjat agregat este o corecție aproximativă, descriptivă

▣ Sarcini

1. Pentru fiecare model: $\hat{P} = \text{proporția semnelor corecte}$, $\hat{P}^* = \hat{p}_y \hat{p}_x + (1 - \hat{p}_y)(1 - \hat{p}_x)$ și $PT = (\hat{P} - \hat{P}^*) / \sqrt{\hat{V}(\hat{P}) - \hat{V}(\hat{P}^*)}$ (Pesaran & Timmermann (1992)); $\hat{p}_y, \hat{p}_x$: proporțiile de „sus” realizate și prezise; n : numărul de zile; $\hat{V}(\hat{P}) = \hat{P}^*(1 - \hat{P}^*)/n$,
 $\hat{V}(\hat{P}^*) = [(2\hat{p}_y - 1)^2 \hat{p}_x(1 - \hat{p}_x) + (2\hat{p}_x - 1)^2 \hat{p}_y(1 - \hat{p}_y)]/n + 4\hat{p}_y \hat{p}_x(1 - \hat{p}_y)(1 - \hat{p}_x)/n^2$.
2. Statistica t a pantei în $y_t = a + b x_t + u_t$ cu erori Newey–West (4 lag-uri), bilateral.
3. Logit-L1 ($\hat{p}_{1,t}$) față de constantă ($\hat{p}_{0,t}$): $f_t = (y_t - \hat{p}_{0,t})^2 - [(y_t - \hat{p}_{1,t})^2 - (\hat{p}_{0,t} - \hat{p}_{1,t})^2]$; CW = t HAC pentru $\bar{f}$, unilateral (pozitiv = caracteristicile ajută); DM pe pierderea Brier, bilateral.

- ▣ **Interpretare:** de ce pot DM și Clark–West să nu fie de acord la modele imbricate? Notebook: secțiunea B12

B12 [Rezolvat]: rezolvare (1/2)



B12 [Rezolvat]: rezolvare (2/2)

	Prezis sus	$\hat{P}$	$\hat{P}^*$	PT	t_{HAC}
Logit-L1	99,6%	0,548	0,548	0,89	0,82
RF	70,3%	0,542	0,519	3,20	2,21
GB	68,5%	0,522	0,518	0,65	0,45

- RF: acuratețea de 54,2% este sub „mereu în sus” (54,8%), dar semnele lui nu sînt independente de rezultat: $PT = 3,20$; cu erori HAC $t = 2,21$, $p = 0,03$
- Clark–West, Logit-L1 față de constantă: $t = -0,56$, p unilateral = 0,71; DM pe Brier: $t = 1,37$ (pozitiv = logit mai slab), $p = 0,17$
- DM întreabă dacă logit-ul *estimat* prognozează mai bine, iar zgomotul de estimare îl dezavantajează sub ipoteza nulă imbricată; CW adaugă înapoi $(\hat{p}_0 - \hat{p}_1)^2$ și întreabă dacă coeficienții populației sînt zero; aici niciunul nu găsește semnal
- Dependența semnelor (PT) nu înseamnă depășirea reperului clasei majoritare și nici un log loss mai bun (B8)

 MFM_ch13_seminar

A5 extins [Rezolvat]: varianța raportului Sharpe — cerința

- ▣ **Întrebarea:** de unde vine numitorul D din A5?
- ▣ **Cadru:** T randamente i.i.d. cu media μ , varianța σ^2 , asimetria γ_3 , kurtosis obișnuit γ_4 ;
 $SR = \mu/\sigma = g(m_1, m_2) = m_1/\sqrt{m_2 - m_1^2}$, cu $m_j = \mathbb{E}[r^j]$; metoda delta: $T \text{Var}(\widehat{SR}) \approx \nabla g^\top \Sigma \nabla g$, cu ∇g gradientul lui g în raport cu (m_1, m_2) și Σ matricea de covarianță a lui (r, r^2)
- ▣ **Sarcini**
 1. Calculați gradientul ∇g .
 2. Calculați $\text{Var}(r)$, $\text{Cov}(r, r^2)$ și $\text{Var}(r^2)$ în funcție de $\mu, \sigma, \gamma_3, \gamma_4$.
 3. Arătați că $T \text{Var}(\widehat{SR}) \approx \nabla g^\top \Sigma \nabla g = 1 - \gamma_3 SR + \frac{\gamma_4 - 1}{4} SR^2$ (Lo (2002)).
- ▣ **Interpretare:** ce moment face ca o strategie cu asimetrie negativă să pară mai precisă decît este?

A5 extins [Rezolvat]: rezolvare

1. $\nabla g = \left(\frac{1}{\sigma} + \frac{\mu^2}{\sigma^3}, -\frac{\mu}{2\sigma^3} \right)$
 2. $\text{Var}(r) = \sigma^2$, $\text{Cov}(r, r^2) = \sigma^3\gamma_3 + 2\mu\sigma^2$, $\text{Var}(r^2) = \sigma^4(\gamma_4 - 1) + 4\mu\sigma^3\gamma_3 + 4\mu^2\sigma^2$
 3. În $\nabla g^\top \Sigma \nabla g$ termenii în μ^2/σ^2 se reduc și rămâne $1 - \gamma_3 SR + \frac{\gamma_4 - 1}{4} SR^2$; pentru distribuția Normală ($\gamma_3 = 0$, $\gamma_4 = 3$) $1 + \frac{1}{2} SR^2$
- Interpretare: cu $SR > 0$, asimetria negativă adaugă $|\gamma_3|SR$ la varianță, iar cozile groase adaugă $\frac{\gamma_4 - 3}{4} SR^2$; ignorarea lor subestimează SE; A5 a folosit $\gamma_3 = -0,4$, $\gamma_4 = 5$


A6 [Propus]: DSR pe un eșantion mai scurt și constanta Gumbel — cerința

- ▣ **Model:** A5 și A5 extins [Rezolvat]
- ▣ **Date de intrare:** $\widehat{SR}_{an} = 1,5$, $T = 504$ randamente zilnice ($A = 252$ pe an), $\hat{\gamma}_3 = -0,2$, $\hat{\gamma}_4 = 6$, $N = 20$ încercări independente, $V = 1/T$; constanta lui Euler $\gamma_E = 0,5772$ (nu asimetria)
- ▣ **Sarcini**
 1. Completați fișa din A5: $\widehat{SR}$, D , $PSR(0)$, SR_0 (zilnic și anualizat), DSR.
 2. Opțional: cu parametrul de poziție $b_N = \Phi^{-1}(1 - \frac{1}{N})$ și scala $a_N = \Phi^{-1}(1 - \frac{1}{N_e}) - b_N$, maximul $\max_n Z_n$ a N extrageri independente Z_n din distribuția Normală standard are aproximativ o distribuție Gumbel; arătați că media lui este $(1 - \gamma_E)b_N + \gamma_E\Phi^{-1}(1 - \frac{1}{N_e})$.
 3. Opțional: verificați prin simulare pentru $N = 100$, 20 000 de extrageri, seed 42, și desenați distribuția.
- ▣ **Interpretare**
 - ▶ este dovada mai puternică decât în A5?
 - ▶ trece de 0,95?
- ▣ Notebook: secțiunea A6

B9 [Rezolvat]: meta-etichetarea unei reguli de medii mobile — cerința

- ▣ **Întrebarea:** poate un clasificator să indice când merită urmată o regulă simplă de trend?
- ▣ **Direcția primară:** $s_t = \text{sign}(MA_{20}(P)_t - MA_{50}(P)_t)$ pe prețuri, o tranzacție candidată în fiecare zi eligibilă (o direcție zilnică permanentă, nu doar la încrucișări); ieșire prin cele trei bariere $pt = sl = 1$, $h = 10$; meta-eticheta brută $1\{s_t \cdot r_{t_0, t_1} > 0\}$ (López de Prado (2018)); $MA_k(P)_t$: media închiderilor pe ultimele k zile; r_{t_0, t_1} : randamentul logaritm de la intrare la ieșire
- ▣ **Modelul secundar:** RF (400 de arbori, frunza minimă 50, ponderi echilibrate ale claselor) pe cele 11 caracteristici plus s_t ; antrenare pe primele 60% din 4 174 de evenimente (pînă la 9 feb. 2022), pauză 10 zile, test 20 feb. 2022 – 6 sep. 2026 (1 660 de tranzacții)
- ▣ **Sarcini:** (1) matricea de confuzie pentru „intrăm în tranzacție dacă $\hat{p} > 0,5$ ”; (2) precizia, recall-ul, F1 înainte (toate tranzacțiile) și după; (3) randamentul brut pe tranzacție, păstrate față de omise
- ▣ **Interpretare:** tranzacțiile se suprapun: acesta nu este un backtest de portofoliu; ce ar adăuga o regulă de alocare a capitalului și costurile? Notebook: secțiunea B9

B9 [Rezolvat]: rezolvare (1/2)



B9 [Rezolvat]: rezolvare (2/2)

1. Executate: 426 câștigătoare, 398 pierzătoare; omise: 362 câștigătoare, 474 pierzătoare (824 din 1 660 păstrate, 49,6%)
 2. Înainte: precizie 0,475, recall 1 (fiecare câștigătoare este executată), F1 0,644; după: 0,517; 0,541; 0,529
 3. Randamentul logaritmă brut pe tranzacție: toate $-0,27\%$, păstrate $+0,19\%$, omise $-0,73\%$
- ☐ Interpretare: filtrarea crește precizia și randamentul pe tranzacție, iar F1 scade; pașii următori sînt un test bootstrap pe blocuri al acestui randament, costurile, o regulă de alocare pentru tranzacțiile suprapuse și un DSR pe toate variantele de meta-model încercate

B11 [Propus]: probabilitatea de overfitting a backtest-ului — cerința

- ▣ **Model:** B10 [Rezolvat]; slide-ul despre PBO din curs
- ▣ **Date:** matricea de randamente $4\,145 \times 120$ din B10, împărțită în $S = 16$ blocuri contigue cu `np.array_split` (un bloc de 260 de zile, cincisprezece de 259) ([Bailey, Borwein, López de Prado & Zhu \(2017\)](#))
- ▣ **Exercițiu pregător:** faceți pașii de mai jos pas cu pas pentru 4 strategii și 4 blocuri
- ▣ **Sarcini**
 1. Pentru fiecare dintre cele $\binom{16}{8} = 12\,870$ alegeri de 8 blocuri în eșantion, alegeți regula cu cel mai bun SR în eșantion.
 2. Ordonăți crescător toate cele 120 de reguli în afara eșantionului (ranguri medii la egalitate), $\omega = \text{rang}/(N + 1)$, $\lambda = \ln \frac{\omega}{1-\omega}$.
 3. Raportați $\text{PBO} = P(\lambda \leq 0)$, λ median, SR median IS și OOS al câștigătorului, proporția cu SR OOS < 0 și histograma lui λ .
- ▣ **Interpretare:** PBO este proporția câștigătorilor selectați aflați la sau sub mediana OOS, nu probabilitatea de a pierde bani; este grila afectată de overfitting? Notebook: secțiunea B11

B13 [Propus]: Reality Check, SPA și StepM pe cele 120 de reguli — cerința

- ▣ **Model:** B10 [Rezolvat]; funcții disponibile: `stationary_bootstrap_index` și `snooping_tests` (notebook, secțiunea B13)
- ▣ **Ipoteza nulă:** $H_0 : \max_k \mathbb{E}[d_{k,t}] \leq 0$ cu $d_{k,t} = r_{k,t} - r_{0,t}$; repere numerar ($r_0 = 0$) și buy-and-hold ($r_0 = r_t$); aceste teste compară randamentele *medii*, DSR privește rapoartele Sharpe
- ▣ **Bootstrap** (Politis & Romano (1994)): un singur șir de indici pe replică, aplicat tuturor coloanelor (zile întregi), bloc mediu de 20 de zile (în fiecare zi un bloc se încheie cu probabilitatea 1/20), 2 000 de replici, seed 42; $\hat{\omega}_k = \sqrt{n}$ abaterea standard bootstrap a lui $\bar{d}_k$
- ▣ **Sarcini**
 1. RC (White (2000)), cu $\bar{d}_k^*$ media regulii k într-o replică și n numărul de zile: $p =$ proporția replicilor cu $\max_k \sqrt{n}(\bar{d}_k^* - \bar{d}_k) \geq \max_k \sqrt{n} \bar{d}_k$.
 2. SPA (Hansen (2005)): studentizat, $t_k = \sqrt{n} \bar{d}_k / \hat{\omega}_k$, recentrînd doar regulile cu $t_k \geq -\sqrt{2 \ln \ln n}$; StepM (Romano & Wolf (2005)) la 5%: respingem fiecare regulă peste cuantila de 95% a maximului pe regulile active, repetăm pînă nu mai respingem.
 3. Raportați pe fiecare reper: cea mai mare medie studentizată, ambele p -value-uri, numărul ipotezelor nule respinse; desenați distribuția bootstrap a maximului.
- ▣ **Interpretare**
 - ce metodă tratează încercările corelate fără să aleagă N ?
 - depășește vreo regulă deținerea Bitcoin?

B14 [Propus]: selecție dublă, puterea predictivă a VIX pentru Bitcoin — cerința

- ▣ **Model:** exemplul din curs despre puterea predictivă a VIX pentru randamentele S&P 500
- ▣ **Precizare:** penalizarea plug-in presupune scoruri independente; cu rezultate suprapuse pe 5 zile, intervalul de mai jos este o aproximare ilustrativă, nu un CI de 95% validat
- ▣ **Date:** cadrul de modelare ($n = 4181$); y_t = randamentul logaritmic BTC pe 5 zile înainte, în bp; $d_t = \log \text{VIX}$ la închiderea din aceeași dată calendaristică, reportat peste weekenduri și sărbătorile din SUA (ultima închidere cunoscută la închiderea BTC), standardizat; controale: cele 11 caracteristici, pătratele și produsele lor două câte două ($p = 77$), standardizate
- ▣ **Penalizarea (Belloni, Chernozhukov & Hansen (2014)):** $\min_{\beta} \frac{1}{n} \sum_t (y_t - x_t^\top \beta)^2 + \frac{\lambda}{n} \sum_j \hat{\psi}_j |\beta_j|$, $\lambda = 2c\sqrt{n} \Phi^{-1}(1 - \gamma/(2p))$, $c = 1,1$, $\gamma = 0,1/\ln n$, ponderile $\hat{\psi}_j$ (scala zgomotului pentru controlul j) iterate; dată ca rlasso
- ▣ **Sarcini:** (1) LASSO pentru y_t pe (d_t, x_t) : este păstrat VIX? (2) $\hat{S}_y$ și $\hat{S}_d$, controalele păstrate de un LASSO al lui y_t , respectiv al lui d_t , pe x_t ; (3) OLS pentru y_t pe d_t și $x_{\hat{S}_y \cup \hat{S}_d}$ cu erori HAC (4 lag-uri): $\hat{\theta}$ (coeficientul lui d_t), SE, interval; plus OLS doar cu VIX și cu toate cele 77 de controale
- ▣ **Interpretare:** de ce nu dă LASSO-ul simplu o inferență validă? Citiți $\hat{\theta}$ ca un coeficient predictiv, nu ca o primă de risc cauzală asociată fricii. Notebook: secțiunea B14

C1 [Propus]: un model fundațional față de boosting — descrierea proiectului

- ▣ **Întrebarea:** prognozează un model fundațional pentru serii de timp din [Capitolul 14](#), folosit zero-shot, direcția Bitcoin pe 5 zile mai bine decât gradient boosting și o constantă?
- ▣ **Protocol** (proiect de echipă, notat după protocol și dovezi, nu după semnul rezultatului)
 1. Numiți modelul și versiunea, data-limită documentată a preantrenării și testați doar pe date ulterioare; altfel declarați contaminarea ca limită.
 2. Prognozați direct distribuția randamentului pe 5 zile (nu cuantile zilnice însumate); $P(r_{t,t+5} > 0)$ prin interpolarea liniară a funcției de repartiție predictive în 0, cu tratarea cozilor declarată.
 3. Reestimați gradient boosting și constanta la fiecare moment pe o fereastră mobilă fixă (de ex. 3 ani); log loss pe aceleași date; testul Giacomini–White ([Giacomini & White \(2006\)](#)) cu erori HAC; un grafic comparativ.
 4. Opțional: o regulă long/numerar pentru $P(\text{sus}) > 0,5$ cu costuri și DSR peste toate configurațiile și prompturile încercate.
- ▣ **Livrabil:** un folder Quantlet (cod, `Metainfo.txt`, un grafic) și un slide cu concluzia și principala limită

C3 [Propus]: un SDF fără arbitraj pe decile — descrierea proiectului (1/2)

- ▣ **Întrebarea:** întrece un factor stochastic de actualizare (SDF) liniar fără arbitraj, pe portofolii sortate după caracteristici, portofoliile tangente Fama–French ([Fama & French \(2015\)](#)) în afara eşantionului, ca în studiul de caz din curs ([Chen, Pelger & Zhu \(2024\)](#))?
- ▣ **Date:** portofoliile decile ponderate după valoare ale celor 15 sortări univariate din [Kenneth French Data Library](#) (mărime, valoare contabilă/de piață, profitabilitate operațională, investiții, câștig/preț, flux de numerar/preț, randamentul dividendului, momentum, reversal pe termen scurt și lung, accruals, beta de piață, emisiuni nete de acțiuni, varianță, varianță reziduală), lunar, minus dobânda pe o lună; fișierele de factori FF3 și FF5
- ▣ **Componente:** pentru fiecare caracteristică, media decilelor 1–5 și a decilelor 6–10: 30 de factori $\tilde{F}_{t+1}$; doar lunile cu toate cele 30 de componente și FF5, fără imputare; salvați panelul fixat, cu data descărcării
- ▣ **Limită:** jumătățile decilelor ponderate după valoare înlocuiesc componentele ponderate după rang ale celor 46 de caracteristici pe acțiuni individuale: o extindere pe date de portofoliu, nu o replicare a GAN-ului la nivel de acțiune
- ▣ **Împărțire:** estimare pe 1967–1986, reglare pe 1987–1991, test pe 1992–2016 și din 2017 până la ultima lună

C3 [Propus]: un SDF fără arbitraj pe decile — descrierea proiectului (2/2)

▣ **Model:** A5 (inferență pentru raportul Sharpe) și B12 (teste predictive) [Rezolvat]

▣ **Etape**

1. Reproduceți reperele FF3 și FF5: ponderile tangente $w \propto \hat{\Sigma}^{-1} \hat{\mu}$ pe 1967–1986, SR lunar pe 1992–2016 cu CI 95% (Lo (2002)); comparați cu cursul (FF5 0,22, FF3 0,20).
2. Cu $\mu =$ media lui $\tilde{F}$ și $Q =$ media lui $\tilde{F}\tilde{F}^\top$ (un moment de ordinul doi, nu o covarianță) pe 1967–1986: $\hat{\theta}_{LS} = Q^{-1}\mu$ (rezolvați sistemul, nu inversați), $\hat{\theta}_{EN} = \arg \min_{\theta} \|\mu - Q\theta\|_2^2 + \lambda_2 \|\theta\|_2^2 + \lambda_1 \|\theta\|_1$ pe o grilă raportată de ponderi de penalizare $\lambda_1, \lambda_2 \geq 0$, aleasă după SR pe 1987–1991.
3. Cu ponderile fixate: SR al lui $F = \hat{\theta}^\top \tilde{F}$ pe ambele perioade de test; diferențe de SR pe perechi, pe lunile aliniate (metoda delta HAC sau bootstrap pe blocuri); DSR peste grilă.
4. Coeficienții $\hat{\beta}_i = \overline{R_i^e F}$ pe 1967–1986; proiectați lunar randamentele de test pe $\hat{\beta}$; variația explicată $1 - \overline{\hat{\epsilon}^2} / (\overline{R^e})^2$, cu $\hat{\epsilon} = R^e - \hat{\beta}F$ eroarea de evaluare și bara o medie în timp, și R^2 transversal pe caracteristică; un grafic cu randamentele medii realizate față de cele implicate.

▣ **Interpretare**

- ▶ de ce poate un SDF liniar fără arbitraj să întreacă o rețea de prognoză (Chen, Pelger & Zhu (2024), Tabelul I)?
- ▶ se menține rezultatul de după 2016 după corecția pentru configurațiile încercate?

Bibliografie (1/5)

- ▣ Bailey, D.H., Borwein, J., López de Prado, M., Zhu, Q.J. (2017). The probability of backtest overfitting. *Journal of Computational Finance*, 20(4), 39–69.
- ▣ Bailey, D.H., López de Prado, M. (2012). The Sharpe ratio efficient frontier. *Journal of Risk*, 15(2), 3–44.
- ▣ Bailey, D.H., López de Prado, M. (2014). The deflated Sharpe ratio: correcting for selection bias, backtest overfitting and non-normality. *Journal of Portfolio Management*, 40(5), 94–107.
- ▣ Belloni, A., Chernozhukov, V., Hansen, C. (2014). Inference on treatment effects after selection among high-dimensional controls. *Review of Economic Studies*, 81(2), 608–650.
- ▣ Bergmeir, C., Hyndman, R.J., Koo, B. (2018). A note on the validity of cross-validation for evaluating autoregressive time series prediction. *Computational Statistics & Data Analysis*, 120, 70–83.
- ▣ Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32.
- ▣ Broadie, M., Glasserman, P., Kou, S. (1997). A continuity correction for discrete barrier options. *Mathematical Finance*, 7(4), 325–349.

Bibliografie (2/5)

- ▣ Chen, L., Pelger, M., Zhu, J. (2024). Deep learning in asset pricing. *Management Science*, 70(2), 714–750.
- ▣ Clark, T.E., West, K.D. (2007). Approximately normal tests for equal predictive accuracy in nested models. *Journal of Econometrics*, 138(1), 291–311.
- ▣ DeLong, E.R., DeLong, D.M., Clarke-Pearson, D.L. (1988). Comparing the areas under two or more correlated receiver operating characteristic curves: a nonparametric approach. *Biometrics*, 44(3), 837–845.
- ▣ Dickey, D.A., Fuller, W.A. (1979). Distribution of the estimators for autoregressive time series with a unit root. *Journal of the American Statistical Association*, 74(366), 427–431.
- ▣ Diebold, F.X., Mariano, R.S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3), 253–263.
- ▣ Fama, E.F., French, K.R. (2015). A five-factor asset pricing model. *Journal of Financial Economics*, 116(1), 1–22.
- ▣ Friedman, J.H. (2001). Greedy function approximation: a gradient boosting machine. *Annals of Statistics*, 29(5), 1189–1232.
- ▣ Giacomini, R., White, H. (2006). Tests of conditional predictive ability. *Econometrica*, 74(6), 1545–1578.
- ▣ Gu, S., Kelly, B., Xiu, D. (2020). Empirical asset pricing via machine learning. *Review of Financial Studies*, 33(5), 2223–2273.

Bibliografie (3/5)

- ▣ Hanley, J.A., McNeil, B.J. (1982). The meaning and use of the area under a receiver operating characteristic (ROC) curve. *Radiology*, 143(1), 29–36.
- ▣ Hansen, P.R. (2005). A test for superior predictive ability. *Journal of Business & Economic Statistics*, 23(4), 365–380.
- ▣ Harvey, C.R., Liu, Y., Zhu, H. (2016). ... and the cross-section of expected returns. *Review of Financial Studies*, 29(1), 5–68.
- ▣ Hosking, J.R.M. (1981). Fractional differencing. *Biometrika*, 68(1), 165–176.
- ▣ Karatzas, I., Shreve, S.E. (1998). *Brownian Motion and Stochastic Calculus*, 2nd ed. Springer.
- ▣ Künsch, H.R. (1989). The jackknife and the bootstrap for general stationary observations. *Annals of Statistics*, 17(3), 1217–1241.
- ▣ Lo, A.W. (2002). The statistics of Sharpe ratios. *Financial Analysts Journal*, 58(4), 36–52.

Bibliografie (4/5)

- ▣ López de Prado, M. (2018). *Advances in Financial Machine Learning*. Wiley.
- ▣ Lundberg, S.M., Lee, S.-I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems*, 30.
- ▣ Newey, W.K., West, K.D. (1987). A simple, positive semi-definite, heteroskedasticity and autocorrelation consistent covariance matrix. *Econometrica*, 55(3), 703–708.
- ▣ Pesaran, M.H., Timmermann, A. (1992). A simple nonparametric test of predictive performance. *Journal of Business & Economic Statistics*, 10(4), 461–465.
- ▣ Politis, D.N., Romano, J.P. (1994). The stationary bootstrap. *Journal of the American Statistical Association*, 89(428), 1303–1313.
- ▣ Robinson, P.M. (1995). Gaussian semiparametric estimation of long range dependence. *Annals of Statistics*, 23(5), 1630–1661.
- ▣ Romano, J.P., Wolf, M. (2005). Stepwise multiple testing as formalized data snooping. *Econometrica*, 73(4), 1237–1282.

Bibliografie (5/5)

- Shimotsu, K., Phillips, P.C.B. (2005). [Exact local Whittle estimation of fractional integration](#). *Annals of Statistics*, 33(4), 1890–1933.
- Tibshirani, R. (1996). [Regression shrinkage and selection via the lasso](#). *Journal of the Royal Statistical Society B*, 58(1), 267–288.
- White, H. (2000). [A reality check for data snooping](#). *Econometrica*, 68(5), 1097–1126.