



Modelarea piețelor financiare

Seminarul 13: Machine Learning în finanțe — aplicații



Daniel Traian PELE
Antoaneta Amza

Academia de Studii Economice din București
IDA Institute Digital Assets
Blockchain Research Center
AI4EFin Artificial Intelligence for Energy Finance
Academia Română, Institutul de Prognoză Economică
MSCA Digital Finance

Acronime folosite în acest material (1/2)

- ▣ ADF: Augmented Dickey–Fuller (test) (testul Dickey–Fuller augmentat)
- ▣ AI: Artificial Intelligence (inteligență artificială)
- ▣ AIC: Akaike Information Criterion (criteriul informațional Akaike)
- ▣ AUC: Area Under the (ROC) Curve (aria de sub curba ROC)
- ▣ CI: Confidence Interval (interval de încredere)
- ▣ CSCV: Combinatorially Symmetric Cross-Validation (validare încrucișată combinatorie simetrică)
- ▣ CV: Cross-Validation (validare încrucișată)
- ▣ CW: Clark–West (test for nested models) (testul Clark–West pentru modele imbricate)
- ▣ DM: Diebold–Mariano (test) (testul Diebold–Mariano de comparare a prognozelor)
- ▣ DSR: Deflated Sharpe Ratio (raportul Sharpe deflatat)
- ▣ ELW: Exact Local Whittle (estimator) (estimatorul local Whittle exact)
- ▣ EV: Explained Variation (variația explicată)
- ▣ EWMA: Exponentially Weighted Moving Average (medie mobilă ponderată exponențial)
- ▣ FF3: Fama–French three-factor model (modelul Fama–French cu trei factori)
- ▣ FF5: Fama–French five-factor model (modelul Fama–French cu cinci factori)
- ▣ FFD: Fixed-width window Fractional Differentiation (diferențiere fracționară cu fereastră fixă)
- ▣ FFN: FeedForward Network (rețea neuronală feedforward (fără bucle))
- ▣ FN: False Negative (fals negativ)
- ▣ GAN: Generative Adversarial Network (rețea generativă adversarială)
- ▣ GB: Gradient Boosting (boosting pe gradient)
- ▣ GW: Giacomini–White (test) (testul Giacomini–White)
- ▣ HAC: Heteroskedasticity and Autocorrelation Consistent (standard errors) (erori standard robuste la heteroscedasticitate și autocorelație)
- ▣ LASSO: Least Absolute Shrinkage and Selection Operator (regresie penalizată L1 cu selecția variabilelor)
- ▣ LS: Linear SDF estimated by unregularised Least Squares (SDF liniar estimat prin cele mai mici pătrate, fără regularizare)
- ▣ LW: Local Whittle (estimator) (estimatorul local Whittle)
- ▣ MA: Moving Average (medie mobilă)

Acronime folosite în acest material (2/2)

- ▣ MA20: 20-day Moving Average (medie mobilă pe 20 de zile)
- ▣ MDA: Mean Decrease Accuracy (scăderea medie a acurateței (importanța prin permutare))
- ▣ MDI: Mean Decrease Impurity (scăderea medie a impurității)
- ▣ ML: Machine Learning (învățare automată)
- ▣ OLS: Ordinary Least Squares (metoda celor mai mici pătrate)
- ▣ PBO: Probability of Backtest Overfitting (probabilitatea de supraajustare a backtest-ului)
- ▣ PSR: Probabilistic Sharpe Ratio (raportul Sharpe probabilistic)
- ▣ PT: Pesaran–Timmermann (test of directional accuracy) (testul Pesaran–Timmermann al acurateței direcționale)
- ▣ RC: Reality Check (White's test for data snooping) (testul Reality Check al lui White pentru data snooping)
- ▣ RF: Random Forest (pădure aleatoare)
- ▣ ROC: Receiver Operating Characteristic (curve) (curba caracteristică de operare)
- ▣ RSI: Relative Strength Index (indicele puterii relative)
- ▣ SDF: Stochastic Discount Factor (factorul stochastic de actualizare)
- ▣ SE: Standard Error (eroare standard)
- ▣ SHAP: SHapley Additive exPlanations (explicații aditive Shapley)
- ▣ SPA: Superior Predictive Ability (test) (testul abilității predictive superioare)
- ▣ SR: Sharpe Ratio (raportul Sharpe)
- ▣ TN: True Negative (adevărat negativ)
- ▣ TP: True Positive (adevărat pozitiv)
- ▣ VIX: CBOE Volatility IndeX (indicele de volatilitate CBOE)

Cuprins

Obiective și pregătire

Partea A: probleme pe hârtie

Partea B: probleme în Python pe date cripto

Partea C: problemă deschisă și critica unui răspuns AI

Temă și aprofundare

Definiții-cheie (1/4): date, etichete, validare

Caracteristici și etichete

- **FFD**: $\tilde{X}_t = \sum_{k=0}^K w_k X_{t-k}$, ponderi trunchiate când $|w_k| < \tau$
- **ADF (Dickey & Fuller (1979))**: H_0 : rădăcină unitară; respingem dacă statistica e sub valoarea critică de 5% (o respingere nu dovedește staționaritatea: A2)
- **EWMA**: abaterea standard a randamentelor log zilnice, cu ponderi descrescătoare exponențial (span 50)
- **Trei bariere**: eticheta $+1/-1$ dacă bariera superioară/inferioară (multipli pt , sl ai lui $\sigma_{t_0} \sqrt{h}$) e atinsă prima; altfel semnul la $t_0 + h$

Validare

- **K-fold CV**: K blocuri; estimăm pe $K - 1$, testăm pe 1, repetăm
- **Leakage**: datele de antrenare conțin informație care se află și în datele de test
- **Purjare / embargo**: eliminăm observațiile de antrenare a căror fereastră de etichetă se suprapune cu testul, plus câteva imediat după

Definiții-cheie (2/4): modele și metrice de clasificare

Modele și semnale

- ▣ **Logit-L1**: regresie logistică cu penalizare L_1 (LASSO)
- ▣ **RF**: media unor arbori decorelați; **GB**: arbori mici adăugați succesiv
- ▣ **Încrucișare MA**: long când MA rapidă e peste cea lentă

Metrici de clasificare

- ▣ Acuratețe = $\frac{TP+TN}{n}$; precizie = $\frac{TP}{TP+FP}$; recall = $\frac{TP}{TP+FN}$; $F_1 = \frac{2PR}{P+R}$ (TP, FP, TN, FN: adevărat/fals pozitive/negative)
- ▣ **ROC AUC**: $P(\hat{s}_+ > \hat{s}_-) + \frac{1}{2}P(\hat{s}_+ = \hat{s}_-)$ pentru un pozitiv și un negativ aleși la întâmplare; 0,5 = fără abilitate
- ▣ **Log loss**: $\ell_t = -[y_t \ln \hat{p}_t + (1 - y_t) \ln(1 - \hat{p}_t)]$, pierderea unei prognoze de probabilitate

Definiții-cheie (3/4): inferență și backtesting

Incertitudine

- **CI 95%:** estimatie $\pm 1,96 \text{ SE}$
- **Bootstrap pe blocuri:** reeșantionăm blocuri de L observații consecutive, ca să păstrăm dependența serială (Künsch (1989))
- **HAC:** varianța Newey–West (Newey & West (1987)), validă la autocorelație
- **DM:** testul Diebold–Mariano pentru acuratețe predictivă egală: test t pe diferența pierderilor $d_t = \ell_t^A - \ell_t^B$, cu SE HAC (Diebold & Mariano (1995))

Backtesting

- **SR:** $\bar{r}/\hat{\sigma}$ al randamentelor log zilnice; anualizat $\times \sqrt{365}$ pentru crypto
- **PSR / DSR** (Bailey & López de Prado (2012); Bailey & López de Prado (2014)): folosesc asimetria γ_3 , kurtosis γ_4 (distribuția Normală: 3)
- N_{eff} : numărul efectiv de încercări independente
- **PBO:** estimată prin CSCV (Bailey, Borwein, López de Prado & Zhu (2017))

Cum funcționează seminarul

- ▣ Două tipuri de probleme, în fiecare parte
 - ▶ **[Rezolvat]**: exemple rezolvate, cu rezolvarea completă în acest material și în notebook
 - ▶ **[Propus]**: le rezolvați voi; fiecare urmează unei probleme rezolvate analoage
- ▣ Partea A: pe hârtie (derivări, cazuri numerice mici)
- ▣ Partea B: Python pe Bitcoin, verificare și inferență: fiecare cifră cu incertitudinea ei
 - ▶ fiecare exercițiu se încheie cu întrebări de interpretare: ce ar schimba concluzia?
- ▣ Partea C: întrebări deschise, puncte de plecare pentru proiectul de echipă (C1, C3)
 - ▶ și un răspuns AI de criticat (C2): găsiți scurgerile, corectați-le, treceți-le în `AI_ERRORS.md`
- ▣ Reguli: fără informație din viitor, validare purjată, un reper naiv și evidența tuturor încercărilor ([Harvey, Liu & Zhu \(2016\)](#))

Definiții-cheie (4/4): memorie și abilitate predictivă

Memorie

- $I(\delta)$: $(1 - B)^\delta X_t$ este $I(0)$ (staționară, cu densitatea spectrală finită și pozitivă în frecvența 0); X_t însăși este staționară doar pentru $\delta < \frac{1}{2}$
- **LW / ELW**: estimatorii local Whittle (Robinson (1995)) și local Whittle exact (Shimotsu & Phillips (2005)) ai lui δ , din primele m frecvențe Fourier; $SE = 1/(2\sqrt{m})$

Abilitate predictivă

- **PT**: testul Pesaran–Timmermann al independenței semnelor (Pesaran & Timmermann (1992))
- **CW**: testul Clark–West pentru modele imbricate (Clark & West (2007)); **GW**: testul Giacomini–White de abilitate predictivă condiționată (Giacomini & White (2006))
- **RC / SPA / StepM**: teste bootstrap pentru cea mai bună dintre mai multe reguli (White (2000); Hansen (2005); Romano & Wolf (2005))

Lista problemelor

	[Rezolvat]	[Propus]
A	A1 suma ponderilor FFD; A3 probabilități de atingere a bari- erelor; A5 varianța SR, PSR, DSR; A7 costul purjării; A9 AUC și SE	A2 ADF respinge prea des; A4 bariere cu tendință; A6 DSR și constanta Gumbel; A8 purjare; A10 varianța De- Long
B	B1 memoria BTC; B3 trei bariere; B5 CV purjat; B7 modele și CI pentru AUC; B9 meta-etichetare; B10 DSR și N efectiv; B12 PT și CW	B2 memoria ETH; B4 bariere asimet- rice; B6 găsiți scurgerea; B8 Diebold– Mariano; B11 PBO; B13 SPA vs. DSR; B14 selecție dublă
C		C1 model fundațional vs. boosting; C2 critica unui răspuns AI; C3 SDF fără arbitraj pe portofolii decile

□ Fiecare problemă propusă își numește modelul: problema rezolvată analoagă

Pregătire: mediul Python și datele

Mediul de lucru

- Google Colab (recomandat) sau Python local ≥ 3.10
- numpy, pandas, scipy, statsmodels, scikit-learn, shap
-  **Deschide în Colab:**
capitol13_notebook_seminar.ipynb

```
import pandas as pd
url = 'https://raw.githubusercontent.com/danpele/MFM/main/data/market/BTC-USD.CC.csv'
btc = pd.read_csv(url, parse_dates=['date']).set_index('date')['close'].loc['2014-09-17':]
```

Date

- **Bitcoin în dolari americani (BTC-USD)**, zilnic, 2014–2026 (4 385 obs.)
- **Ether (ETH-USD)**, zilnic, 2015–2026 (4 061 obs.)
- Fișiere din repo-ul cursului: data/market

A1 [Rezolvat]: ponderile FFD, sumele lor și lungimea ferestrei

Cerință

- ▣ **Context:** diferențiere fracționară de ordin d cu ponderile $w_0 = 1$, $w_k = -w_{k-1} \frac{d-k+1}{k}$, trunchiate la primul $|w_k| < \tau$ (Hosking (1981); López de Prado (2018)); nu sunt necesare date
- ▣ **Sarcini:**
 - ▶ (a) Arătați că $w_k = \frac{\Gamma(k-d)}{\Gamma(-d)\Gamma(k+1)}$ și că $w_k \sim k^{-(1+d)}/\Gamma(-d)$ pentru k mare.
 - ▶ (b) Arătați că $\sum_{k=0}^K w_k = \frac{\Gamma(K+1-d)}{\Gamma(1-d)\Gamma(K+1)} \sim K^{-d}/\Gamma(1-d)$.
 - ▶ (c) Pentru $d = 0,25$ și $\tau = 10^{-4}$ calculați fereastra K și $\sum_{k \leq K} w_k$.
 - ▶ (d) Decideți dacă seria FFD a unui log-preț $I(1)$ este staționară.
- ▣ **Raportați:** cele două formule, K , suma ponderilor și decizia de la (d)

Interpretare

- ▣ De ce cursul și literatura numesc seria FFD “staționară” și ce este de fapt staționar în ea?

A1: Rezolvare (1/2)

Rezolvare

- (a) w_k este coeficientul lui B^k în $(1 - B)^d = \sum_k \binom{d}{k} (-B)^k$, iar $(-1)^k \binom{d}{k} = \frac{\Gamma(k-d)}{\Gamma(-d)\Gamma(k+1)}$
 - Stirling: $\Gamma(k-d)/\Gamma(k+1) \sim k^{-d-1}$, deci $w_k \sim k^{-(1+d)}/\Gamma(-d)$: o scădere hiperbolică, nu exponențială
- (b) Sumele parțiale ale coeficienților unei serii $f(B)$ sunt coeficienții lui $f(B)/(1-B)$; aici $(1-B)^d/(1-B) = (1-B)^{d-1}$
 - deci $\sum_{k \leq K} w_k = \frac{\Gamma(K+1-d)}{\Gamma(1-d)\Gamma(K+1)} \sim K^{-d}/\Gamma(1-d)$, care tinde la 0 doar când $K \rightarrow \infty$

A1: Rezolvare (2/2)

Rezolvare

- (c) Punem $|w_K| = \tau$: $K \approx (\tau |\Gamma(-d)|)^{-1/(1+d)} = (10^{-4} \cdot 4,902)^{-0,8} = 444$ de lag-uri (și recursia se oprește la 444)
- Suma ponderilor: $K^{-d}/\Gamma(1-d) = 444^{-0,25}/1,2254 = 0,2177/1,2254 = 0,178$
- (d) Descompunem: $\tilde{X}_t = (\sum_{k \leq K} w_k)X_t - \sum_{k=1}^K w_k(X_t - X_{t-k})$
 - ▶ dacă X_t este $I(1)$, fiecare $X_t - X_{t-k}$ este $I(0)$, deci al doilea termen este staționar
 - ▶ primul termen este $0,178 X_t$: un mers aleator scalat, deci $\tilde{X}_t$ rămâne $I(1)$
- Interpretare: doar combinațiile $X_t - X_{t-k}$ sunt staționare; “memoria” păstrată de FFD este un mic multiplu al nivelului prețului însuși

A2 [Propus]: lungimea ferestrei, suma ponderilor și respingerile ADF prea dese

Cerință

- ▣ **Context:** formulele din A1 cu $\tau = 10^{-4}$; un Monte Carlo pe mersuri aleatoare pure $X_t = \sum_{s \leq t} \varepsilon_s$, $\varepsilon_s \sim N(0, 1)$ i.i.d., seed 42
- ▣ **Sarcini:**
 - ▶ (a) Pentru $d = 0,3$ și $d = 0,5$ calculați $K(\tau)$ și $\sum_{k \leq K} w_k$ cu formulele închise din A1.
 - ▶ (b) Simulați 500 de mersuri aleatoare, aplicați FFD cu fiecare d și păstrați $T = 2,500$ valori FFD pe traiectorie.
 - ▶ (c) Aplicați testul ADF (constantă, 1 lag) pe fiecare traiectorie FFD și notați cât de des respinge la 5%.
- ▣ **Raportați:** un tabel cu d , K , suma ponderilor și frecvența respingerilor
- ▣ **Model:** A1

Interpretare

- ▣ Mărimea reală este 5%: de ce confundă ADF un mers aleator scalat cu o serie staționară? Ce d ar face staționar un preț $I(1)$?

A3 [Rezolvat]: etichete cu trei bariere și probabilități de atingere

Cerință

- ▣ **Context:** prețul de intrare $P_{t_0} = 100$, volatilitatea zilnică $\sigma_{t_0} = 1\%$, bariera verticală $h = 5$ zile, $pt = sl = 1$, barierele orizontale $P_{t_0} e^{\pm \sigma_{t_0} \sqrt{h}}$ (López de Prado (2018)); la (b)–(c) log-prețul este σW_t , o mișcare browniană fără tendință
- ▣ **Sarcini:**
 - ▶ (a) Etichetați traiectoria 1 (100; 101,0; 100,4; 102,5; 101,2; 99,8) și traiectoria 2 (100; 99,2; 98,6; 99,5; 98,9; 99,1).
 - ▶ (b) Cu barierele $+a = pt \sigma \sqrt{h}$ și $-b = -sl \sigma \sqrt{h}$ și fără bariera verticală, derivați $P(\text{sus prima})$ și $\mathbb{E}[\tau]$ prin oprire opțională.
 - ▶ (c) Pentru $pt = sl = 1$ calculați probabilitatea de a ajunge la bariera verticală, cu monitorizare continuă și zilnică ($h = 10$).
- ▣ **Raportați:** cele două etichete, cele două formule și cele două probabilități de ieșire verticală

Interpretare

- ▣ Cursul găsește 59,0% ieșiri verticale pe S&P 500, iar B3 găsește 59,0% pe Bitcoin: ce explică diferența față de valoarea browniană?

A3: Rezolvare (1/2)

Rezolvare

- (a) Lățimea $0,01\sqrt{5} = 0,02236$: bariera superioară $100e^{0,02236} = 102,26$, cea inferioară 97,79
 - ▶ traiectoria 1: ziua 3, $102,5 \geq 102,26 \Rightarrow$ eticheta +1 (scăderea ulterioară nu contează)
 - ▶ traiectoria 2: nicio atingere orizontală; $\ln(99,1/100) = -0,90\%$ în ziua 5 $\Rightarrow$ eticheta -1
- (b) W_t este martingală: $0 = p a - (1 - p) b \Rightarrow p = \frac{b}{a+b} = \frac{sl}{pt+sl}$
- $\sigma^2 W_t^2 - \sigma^2 t$ este martingală: $\sigma^2 \mathbb{E}[\tau] = p a^2 + (1 - p) b^2 = ab \Rightarrow \mathbb{E}[\tau] = ab/\sigma^2 = pt \cdot sl \cdot h \text{ zile (Karatzas \& Shreve (1998))}$

A3: Rezolvare (2/2)

Rezolvare

- (c) Timpul de ieșire pentru $|W_s| < 1$ pe $[0, 1]$ (soluția în serie a ecuației căldurii):
 - $P(\tau > h) = \frac{4}{\pi} \sum_{n \geq 0} \frac{(-1)^n}{2n+1} e^{-(2n+1)^2 \pi^2 / 8} = 1,2732 \cdot 0,2912 - \dots = 0,371$
- Monitorizarea zilnică ratează atingerile dintre închideri: mutăm fiecare barieră în afară cu $0,5826 \sigma$ (Broadie, Glasserman & Kou (1997)), adică $c = 1 + 0,5826 / \sqrt{10} = 1,184$; înlocuind $\pi^2 / 8$ cu $\pi^2 / (8c^2)$ obținem 0,528
- Interpretare: monitorizarea discretă explică cea mai mare parte a diferenței de la 37% la 59%; restul vine din cozile groase și grupările de volatilitate (volatilitatea EWMA rămâne în urma perioadelor agitate)

A4 [Propus]: bariere asimetrice cu tendință

Cerință

- ▣ **Context:** încălzire cu $P_{t_0} = 50$, $\sigma_{t_0} = 2\%$, $h = 4$, $pt = 2$, $sl = 1$; apoi log-prețul $X_t = \mu t + \sigma W_t$ cu barierele $+a = pt \sigma \sqrt{h}$ și $-b = -sl \sigma \sqrt{h}$
- ▣ **Sarcini:**
 - ▶ (a) Calculați ambele bariere și etichetați traiectoriile (i) 50; 51,5; 53,0; 49,5; 47,9 și (ii) 50; 52,0; 54,5; 53,0; 51,0.
 - ▶ (b) Folosind funcția de scală $s(x) = e^{-2\mu x/\sigma^2}$, derivați $P(\text{sus prima}) = \frac{e^{2\mu b/\sigma^2} - 1}{e^{2\mu b/\sigma^2} - e^{-2\mu a/\sigma^2}}$ și arătați că tinde la $\frac{b}{a+b}$ când $\mu \rightarrow 0$.
 - ▶ (c) Evaluați probabilitatea pentru $\sigma = 3\%$, $\mu = 0,1\%$ pe zi, $h = 10$, $pt = 2$, $sl = 1$.
- ▣ **Raportați:** barierele, cele două etichete, derivarea și valoarea de la (c)
- ▣ **Model:** A3

Interpretare

- ▣ Formula de la (b) nu are barieră verticală: ce traiectorii cenzurează o barieră verticală la h și cu ce reper ați compara rezultatul din B4 pentru $(pt, sl) = (2, 1)$?

A5 [Rezolvat]: varianța raportului Sharpe, PSR și DSR

Cerință

- ▣ **Context:** randamente i.i.d. cu media μ , varianța σ^2 , asimetria γ_3 și kurtosis γ_4 ; o strategie cu $\widehat{SR}_{an} = 1,2$ pe $T = 756$ randamente zilnice, $\hat{\gamma}_3 = -0,4$, $\hat{\gamma}_4 = 5$ (Bailey & López de Prado (2012); Bailey & López de Prado (2014))
- ▣ **Sarcini:**
 - ▶ (a) Derivați $\text{Var}(\widehat{SR}) \approx \frac{1}{T} (1 - \gamma_3 SR + \frac{\gamma_4 - 1}{4} SR^2)$ prin metoda delta (Lo (2002)).
 - ▶ (b) Calculați $PSR(0) = \Phi(\widehat{SR} \sqrt{T-1} / \sqrt{1 - \hat{\gamma}_3 \widehat{SR} + \frac{\hat{\gamma}_4 - 1}{4} \widehat{SR}^2})$ cu SR zilnic.
 - ▶ (c) Calculați SR_0 și $DSR = PSR(SR_0)$ dacă strategia e cea mai bună din $N = 100$ încercări independente, $V = 1/T$.
- ▣ **Raportați:** formula varianței, $PSR(0)$, SR_0 (zilnic și anualizat) și DSR

Interpretare

- ▣ Ați alocat capital acestei strategii? Ce număr de încercări N v-ar face să vă schimbați decizia?

A5: Rezolvare (1/2)

Rezolvare

- (a) $SR = g(m_1, m_2) = m_1 / \sqrt{m_2 - m_1^2}$ cu $m_j = \mathbb{E}[r^j]$; gradientul $\nabla g = \left(\frac{1}{\sigma} + \frac{\mu^2}{\sigma^3}, -\frac{\mu}{2\sigma^3} \right)$
- Momentele lui (r, r^2) : $\text{Var}(r) = \sigma^2$, $\text{Cov}(r, r^2) = \sigma^3 \gamma_3 + 2\mu\sigma^2$, $\text{Var}(r^2) = \sigma^4(\gamma_4 - 1) + 4\mu\sigma^3\gamma_3 + 4\mu^2\sigma^2$
- $T \text{Var}(\widehat{SR}) \approx \nabla g^\top \Sigma \nabla g$; termenii în μ^2/σ^2 se reduc și rămâne $1 - \gamma_3 SR + \frac{\gamma_4 - 1}{4} SR^2$ (distribuția Normală: $1 + \frac{1}{2} SR^2$)

A5: Rezolvare (2/2)

Rezolvare

- (b) $\widehat{SR}$ zilnic $= 1,2/\sqrt{252} = 0,07559$; numitorul $\sqrt{1 + 0,4 \cdot 0,07559 + 1 \cdot 0,07559^2} = 1,01782$
 - $z = 0,07559 \cdot \sqrt{755}/1,01782 = 2,041$, $PSR(0) = \Phi(2,041) = 0,979$
- (c) $\sqrt{V} = 1/\sqrt{756} = 0,03637$; $\Phi^{-1}(0,99) = 2,326$, $\Phi^{-1}(1 - \frac{1}{100e}) = 2,678$
 - $SR_0 = 0,03637 [0,4228 \cdot 2,326 + 0,5772 \cdot 2,678] = 0,0920$ pe zi (1,46 anualizat)
 - $z = (0,07559 - 0,0920)\sqrt{755}/1,01782 = -0,444$, $DSR = \Phi(-0,444) = 0,329$
- Decizie: $DSR < 0,95$; doar norocul dă un SR maxim de 1,46 > 1,2 din 100 de încercări: nu alocăm capital

A6 [Propus]: DSR pe un eșantion mai scurt și constanta Gumbel

Cerință

- ▣ **Context:** o strategie cu $\widehat{SR}_{an} = 1,5$ pe 2 ani de date zilnice ($T = 504$), $\hat{\gamma}_3 = -0,2$, $\hat{\gamma}_4 = 6$; $N = 20$ încercări independente; $Z_1, \dots, Z_N$ i.i.d. $N(0, 1)$
- ▣ **Sarcini:**
 - ▶ (a) Calculați $PSR(0)$, SR_0 și DSR cu $V = 1/T$, pas cu pas ca în A5.
 - ▶ (b) Arătați că $\mathbb{E}[\max_{n \leq N} Z_n] \approx (1 - \gamma)\Phi^{-1}(1 - \frac{1}{N}) + \gamma\Phi^{-1}(1 - \frac{1}{Ne})$ în limita Gumbel, cu locația $b_N = \Phi^{-1}(1 - \frac{1}{N})$ și scala $a_N = \Phi^{-1}(1 - \frac{1}{Ne}) - b_N$.
 - ▶ (c) Verificați (b) prin Monte Carlo pentru $N = 100$ (20,000 de extrageri).
- ▣ **Raportați:** $PSR(0)$, SR_0 , DSR, derivarea și media Monte Carlo
- ▣ **Model:** A5

Interpretare

- ▣ Față de A5, raportul Sharpe e mai mare și sunt mai puține încercări: este dovada mai puternică? Ce explică diferența?

A7 [Rezolvat]: cât costă purjarea?

Cerință

- ▣ **Context:** n observații în K pliuri contigue de lungime $L = n/K$; eticheta observației i se încheie la $t_1(i) = i + h$; embargo de e observații după fiecare pli de test (López de Prado (2018))
- ▣ **Sarcini:**
 - ▶ (a) Pentru un pli de test interior, numărați observațiile de antrenare eliminate înainte și după pli și partea pierdută din datele din afara testului.
 - ▶ (b) Aplicați rezultatul pentru $n = 20$, $K = 5$, $h = 3$, $e = 1$ și pliul de test $\{8, \dots, 11\}$; enumerați observațiile purjate, cele sub embargo și cele de antrenare.
 - ▶ (c) Explicați cum influențează alegerea lui K compromisul dintre bias și varianța estimației CV.
- ▣ **Raportați:** formula generală, cele trei mulțimi de la (b) și compromisul de la (c)

Interpretare

- ▣ De ce supraestimează K-fold cu amestecare acuratețea în acest cadru (curs: 69,4% pe zgomot pur)?

A7: Rezolvare

Rezolvare

- (a) Înainte de pliu: observațiile cu $i + h \geq$ primul indice de test se suprapun cu el: h observații
- După pliu: observațiile care încep înainte de sfârșitul ultimei etichete de test ($i \leq$ ultimul indice de test $+h$) și cel puțin cele e sub embargo: $\max(h, e)$
- Partea pierdută din cele $n - L$ observații din afara testului: $\frac{h + \max(h, e)}{n - L} = \frac{K(h + \max(h, e))}{n(K - 1)}$
- (b) Purjate înainte: $\{5, 6, 7\}$ ($t_1 \geq 8$); eliminate după: $\{12, 13, 14\}$ ($12 =$ embargo, $13-14$ încep înainte de ziua 14, când se cunoaște ultima etichetă de test)
 - setul de antrenare $\{0, \dots, 4\} \cup \{15, \dots, 19\}$: 6 din 16 observații din afara testului pierdute (37,5%), cum spune formula: $\frac{3+3}{16}$
- (c) K mai mare: mai multe date de antrenare (bias pesimist mai mic), dar pliuri de test mai scurte și mai zgomotoase și mai multe granițe purjate; când h e mare față de L , purjarea domină

A8 [Propus]: purjare cu etichete mai scurte

Cerință

- ▣ **Context:** ca în A7, cu $n = 20$, $K = 5$ pliuri neamestecate, sfârșitul etichetei $t_1(i) = \min(i + 2, 19)$ și un embargo de 1 observație
- ▣ **Sarcini:**
 - ▶ (a) Pentru pliul de test $\{12, \dots, 15\}$, enumerați observațiile purjate, pe cele sub embargo și setul de antrenare.
 - ▶ (b) Verificați numărătoarea cu formula din A7.
 - ▶ (c) Folosiți formula pentru a calcula partea pierdută din datele din afara testului pentru $h = 20$ și pliuri de $L = 50$ de zile ($K = 5$).
- ▣ **Raportați:** cele trei mulțimi și cele două proporții
- ▣ **Model:** A7

Interpretare

- ▣ Cât costă purjarea când etichetele sunt lungi și pliurile scurte și cum ați reacționa?

A9 [Rezolvat]: AUC pas cu pas, cu eroare standard

Cerință

- ▣ **Context:** scorurile unui clasificator pentru 3 pozitive (0,80; 0,55; 0,40) și 3 negative (0,60; 0,35; 0,20); eroarea standard Hanley–McNeil (Hanley & McNeil (1982))
- ▣ **Sarcini:**
 - ▶ (a) Calculați AUC ca ponderea perechilor (pozitiv, negativ) ordonate corect, $U/(n_1 n_0)$.
 - ▶ (b) Calculați $SE^2 = \frac{A(1-A) + (n_1 - 1)(Q_1 - A^2) + (n_0 - 1)(Q_2 - A^2)}{n_1 n_0}$ cu $Q_1 = \frac{A}{2-A}$, $Q_2 = \frac{2A^2}{1+A}$.
 - ▶ (c) Testați $H_0: AUC = 0,5$ la 5% cu $z = (A - 0,5)/SE$.
- ▣ **Raportați:** U , AUC, SE, z și decizia

Interpretare

- ▣ Ce ipoteză a formulei SE nu este îndeplinită pentru etichete suprapuse pe 5 zile și în ce direcție deplasează testul?

A9: Rezolvare

Rezolvare

- (a) 0,80 bate 3 negative, 0,55 bate 2, 0,40 bate 2: $U = 7$ din 9 perechi, $A = 0,778$
- (b) $Q_1 = 0,778/1,222 = 0,636$, $Q_2 = 2 \cdot 0,605/1,778 = 0,681$
 - $SE^2 = [0,173 + 2(0,636 - 0,605) + 2(0,681 - 0,605)]/9 = 0,0429$, $SE = 0,207$
- (c) $z = (0,778 - 0,5)/0,207 = 1,34$, $p = 0,18$: nu respingem; șase observații nu pot separa abilitatea de noroc
- Formula presupune observații independente; etichetele suprapuse au randamente comune, deci eșantionul efectiv e mai mic și formula subestimează SE: testul respinge prea des. B7 o înlocuiește cu un bootstrap pe blocuri

A10 [Propus]: AUC ca statistică U și varianța DeLong

Cerință

- ▣ **Context:** scorurile a 4 pozitive (0,70; 0,62; 0,48; 0,45) și 4 negative (0,66; 0,50; 0,40; 0,30); nucleul $\psi(s_i, s_j) = 1\{s_i > s_j\} + \frac{1}{2}1\{s_i = s_j\}$
- ▣ **Sarcini:**
 - ▶ (a) Calculați U , AUC și eroarea standard Hanley–McNeil, ca în A9.
 - ▶ (b) Arătați că $AUC = \frac{1}{n_1 n_0} \sum_{i,j} \psi(s_i, s_j)$ este o statistică U cu două eșantioane; definiți valorile de plasare $V_{10}(i) = \frac{1}{n_0} \sum_j \psi(s_i, s_j)$ și $V_{01}(j) = \frac{1}{n_1} \sum_i \psi(s_i, s_j)$.
 - ▶ (c) Derivați $\widehat{\text{Var}}(AUC) = S_{10}/n_1 + S_{01}/n_0$ (DeLong, DeLong & Clarke-Pearson (1988)), unde S_{10} , S_{01} sunt varianțele de selecție ale valorilor de plasare, și calculați SE DeLong.
- ▣ **Raportați:** U , AUC, cele două erori standard și valorile de plasare
- ▣ **Model:** A9

Interpretare

- ▣ De ce presupun ambele formule observații independente și ce înseamnă asta pentru etichete suprapuse pe 5 zile?

B1 [Rezolvat]: memoria log-prețului Bitcoin: regula ADF vs. local Whittle

Cerință

- ▣ **Context:** închideri zilnice BTC-USD 2014-09-17 – 2026-09-18 (4,385 obs., data/market/BTC-USD.CC.csv), $x_t = \ln P_t$; FFD cu $\tau = 10^{-4}$; $m = n^{0,65}$ frecvențe Fourier
- ▣ **Sarcini:**
 - ▶ (a) Pentru $d \in \{0; 0,05; \dots; 1\}$ calculați seria FFD, statistica ADF (constantă, 1 lag, [Dickey & Fuller \(1979\)](#)) și $\text{Corr}(\tilde{x}_t, x_t)$; găsiți cel mai mic d^* pentru care statistica ADF este sub valoarea critică la 5%.
 - ▶ (b) Estimați memoria cu CI 95%: local Whittle exact ([Shimotsu & Phillips \(2005\)](#)) pentru x_t și seria FFD la d^* , local Whittle ([Robinson \(1995\)](#)) pentru randamente și randamentele absolute.
 - ▶ (c) Testați $H_0 : d = 1$ pentru log-preț cu $z = (\hat{d} - 1) 2\sqrt{m}$.
- ▣ **Raportați:** tabelul ADF pentru $d \leq 0,25$, d^* , cele patru estimății cu CI și testul de la (c)

Interpretare

- ▣ Este seria FFD la d^* staționară? Unde se află de fapt memoria Bitcoin?

B1: Rezolvare (1/2)

Rezolvare

- (a) Statistica ADF în funcție de d (valoarea critică la 5% $-2,86$):

d	0	0,05	0,10	0,15	0,20	0,25
ADF	-1,21	-2,32	-2,24	-2,39	-2,85	-3,38
Corr	1,000	0,999	0,995	0,985	0,972	0,955

- Regula dă $d^* = 0,25$, cu corelația 0,955; traiectoria nu e monotonă în d ($-2,32$, apoi $-2,24$), un prim semn de fragilitate
- Ponderile FFD la $d = 0,25$ însumează 0,178, deci seria FFD conține încă $0,178 x_t$ (A1)

B1: Rezolvare (2/2)

Rezolvare

- (b) Estimațiile memoriei, $m = n^{0,65}$, CI 95% $\hat{d} \pm 1,96/(2\sqrt{m})$:
 - ▶ log-preț (ELW): 1,065 [1,000; 1,129]; seria FFD la $d^* = 0,25$ (ELW): 0,814 [0,747; 0,880]
 - ▶ randamente (LW): 0,063 [-0,002; 0,127]; randamente absolute (LW): 0,353 [0,289; 0,417]
- (c) $z = (1,065 - 1)/0,033 = 1,97$, p bilateral $\approx 0,05$: cel mult o respingere la limită, în direcția $d > 1$ (episoade de bule), niciodată spre staționaritate
- Interpretare: în banda de frecvențe seria FFD are $\hat{d} \approx 1 - 0,25$ (ordinul ei de integrare rămâne 1, A1), iar CI-ul ei este mult peste $\frac{1}{2}$: nu este staționară; memoria lungă a Bitcoin este în volatilitate ($|r_t|$), ca la S&P 500 în curs

B2 [Propus]: memoria Ether: o capcană

Cerință

- ▣ **Context:** închideri zilnice ETH-USD 2015-08-07 – 2026-09-18 (4,061 obs., `data/market/ETH-USD.CC.csv`); funcțiile din B1
- ▣ **Sarcini:**
 - ▶ (a) Repetați regula ADF din B1 pe $\ln P_t^{ETH}$ și raportați d^* împreună cu statisticile ADF la $d = 0$ și $d = 0,05$.
 - ▶ (b) Refaceți testul la $d = 0$ cu constantă și trend și refaceți regula pe eșantionul care începe la 1 ianuarie 2018.
 - ▶ (c) Estimați d prin local Whittle exact (CI 95%) pe ambele eșantioane și prin local Whittle pentru randamentele absolute.
- ▣ **Raportați:** cele trei răspunsuri ale regulii ADF și cele trei estimări ale memoriei, cu CI
- ▣ **Model:** B1

Interpretare

- ▣ Ce d ați folosi într-un model și de ce? Ce spune asta despre testele de rădăcină unitară pe un activ care a crescut de 1,000 de ori?

B3 [Rezolvat]: etichete cu trei bariere pe Bitcoin

Cerință

- ▣ **Context:** închideri zilnice BTC-USD 2014–2026; volatilitatea EWMA a randamentelor log zilnice (span 50); fiecare zi este un eveniment; bariera verticală $h = 10$ zile (López de Prado (2018))
- ▣ **Sarcini:**
 - ▶ (a) Etichetați fiecare zi cu bariere simetrice $pt = sl = 1$ și $pt = sl = 2$ (unități de $\sigma_{t_0} \sqrt{h}$).
 - ▶ (b) Calculați ponderile ieșirilor sus, jos și verticale, durata medie de deținere și ponderea etichetelor +1.
 - ▶ (c) Comparați cu eticheta cu orizont fix de 10 zile.
- ▣ **Raportați:** un tabel pe variante și o histogramă a duratelor de deținere

Interpretare

- ▣ De ce circa 56% dintre etichete sunt +1 și care este atunci acuratețea de referință a unui clasificator?

B3: Rezolvare

Rezolvare

- (a)–(b) Ponderile ieșirilor și etichetele:

	Sus	Jos	Vertical	Zile	+1
$pt = sl = 1$	22,8%	18,2%	59,0%	8,25	55,7%
$pt = sl = 2$	7,2%	4,9%	87,9%	9,58	55,6%
orizont fix 10 zile	–	–	100%	10	55,5%

- (c) Barierele mai largi mută majoritatea ieșirilor la bariera verticală: etichetele converg către etichetele cu orizont fix
- Interpretare: BTC a crescut în eșantion, deci +1 domină oricare ar fi barierele; „mereu în sus” (circa 56%) este reperul de depășit, iar cele 59,0% ieșiri verticale sunt peste cele 52,8% din A3 (monitorizare zilnică): cozile groase și grupările de volatilitate adaugă restul

B4 [Propus]: bariere asimetrice pe Bitcoin

Cerință

- ▣ **Context:** datele, volatilitatea și funcția de etichetare din B3, $h = 10$
- ▣ **Sarcini:**
 - ▶ (a) Repetați B3 cu $(pt, sl) = (2, 1)$ și $(1, 2)$.
 - ▶ (b) Raportați ponderile ieșirilor, ponderea etichetelor $+1$ și durata medie de deținere.
 - ▶ (c) Comparați ponderea ieșirilor sus între ieșirile orizontale cu valoarea pentru orizont infinit $\frac{sl}{pt+sl}$ din A3 și cu un reper simulat cu orizont finit (pași zilnici gaussieni, aceleași bariere, bariera verticală la h).
- ▣ **Raportați:** un tabel cu cele două variante și comparația de la (c)
- ▣ **Model:** B3

Interpretare

- ▣ Ce variantă ar alege un trend-follower? Cum schimbă alegerea echilibrul claselor pe care îl vede un clasificator?

B5 [Rezolvat]: Purged K-Fold vs. K-Fold cu amestecare

Cerință

- ▣ **Context:** un set simulat (seed 42): mers aleator de 3,000 de zile, eticheta = semnul randamentului pe 20 de zile înainte, 5 caracteristici = medii pe 20 de zile ale unui zgomot independent; acuratețea adevărată 50%
- ▣ **Sarcini:**
 - ▶ (a) Scrieți `PurgedKFold(n_splits, t1, pct_embargo)` cu o metodă `split(X)` în stil `scikit-learn`.
 - ▶ (b) Estimați o pădure aleatoare ([Breiman \(2001\)](#); 200 de arbori, frunza minimă 5) și calculați acuratețea în afara pliului pentru 5-fold cu amestecare, 5-fold fără amestecare și 5-fold purjat cu embargo 1%.
 - ▶ (c) Verificați clasa pe exemplul din A7.
- ▣ **Raportați:** cele trei acurateți medii, cu cele cinci valori pe pliuri

Interpretare

- ▣ S-ar reduce diferența cu caracteristici nepersistente? Cu etichete pe 1 zi?

B5: Rezolvare

Rezolvare

- (b) K-fold cu amestecare: **69,4%**; fără amestecare: 50,0%; purjat + embargo 1%: **49,7%**; adevărul: 50%
- (c) Pe exemplul din A7 clasa elimină $\{5, 6, 7, 12, 13, 14\}$ pentru pliul de test $\{8, \dots, 11\}$, ca în derivarea pas cu pas
- Interpretare: amestecarea pune vecini aproape identici în antrenare și test; un model flexibil îi memorează și “prezice” zgomotul pur cu 19 puncte peste hazard
- Sunt necesare ambele ingrediente: etichete suprapuse și caracteristici persistente; fără oricare dintre ele scurgerea dispare (Bergmeir, Hyndman & Koo (2018))

B6 [Propus]: găsiți scurgerea

Cerință

- ▣ **Context:** cadrul de modelare din B7 (BTC, direcția la 5 zile, 11 caracteristici, 5-fold purjat); notebook-ul adaugă o a 12-a caracteristică, `ma11`, iar pădurea aleatoare atinge acum o acuratețe spectaculoasă
- ▣ **Sarcini:**
 - ▶ (a) Citiți cum este construită `ma11` și ordonați toate caracteristicile după MDI.
 - ▶ (b) Calculați corelația lui `ma11` și a unei versiuni calculate doar din observații curente și anterioare cu randamentul-țintă.
 - ▶ (c) Rulați din nou CV-ul cu purjare folosind versiunea calculată doar din observații curente și anterioare și doar cu cele 11 caracteristici de bază.
- ▣ **Raportați:** acuratețea și AUC în cele trei cazuri, ordinea MDI și cele două corelații
- ▣ **Model:** B5

Interpretare

- ▣ De ce nu poate purjarea să prindă acest tip de scurgere? Dați un al doilea exemplu de informație din viitor într-un flux de caracteristici.

B7 [Rezolvat]: compararea modelelor și un CI pentru AUC

Cerință

- ▣ **Context:** BTC 2014–2026; ținta $y_t = 1\{\ln P_{t+5} - \ln P_t > 0\}$; 11 caracteristici (momentum 1–120 zile, volatilitate 20/60 și raportul lor, distanțe față de mediile mobile pe 50 și 200 de zile, RSI); 5-fold purjat, embargo 1%; 4,181 obs., 54,8% „sus”
- ▣ **Sarcini:**
 - ▶ (a) Estimați Logit-L1 ([Tibshirani \(1996\)](#)), o pădure aleatoare și gradient boosting ([Friedman \(2001\)](#)); raportați acuratețea și ROC AUC medii pe pliuri față de „mereu în sus”.
 - ▶ (b) Comparați MDI, MDA și media |SHAP| ([Lundberg & Lee \(2017\)](#)) prin corelații de rang Spearman.
 - ▶ (c) Pentru probabilitățile RF agregate în afara pliurilor calculați un CI 95% pentru AUC cu SE DeLong ([DeLong, DeLong & Clarke-Pearson \(1988\)](#)) și cu bootstrap circular pe blocuri ([Künsch \(1989\)](#)), $L \in \{1, 20, 60\}$, 1,000 de replici.
- ▣ **Raportați:** tabelul modelelor, corelațiile de rang și toate cele patru intervale

Interpretare

- ▣ De ce e intervalul bootstrap mai larg? Ce lungime de bloc ați justifica?

B7: Rezolvare (1/2)

Rezolvare

□ (a) Mediile pe pliuri:

	Logit-L1	RF	GB
Acuratețe	54,8%	54,2%	52,2%
ROC AUC	0,492	0,516	0,502

- Niciun model nu bate „mereu în sus” (54,8%); Logit-L1 prezice „sus” în 99,6% din zile
- (b) Spearman: MDI-SHAP 0,75, MDI-MDA -0,42, MDA-SHAP -0,10: importanțele în eșantion și în afara lui nu concordă

B7: Rezolvare (2/2)

Rezolvare

- (c) AUC agregat RF = 0,512
 - ▶ DeLong: SE 0,009, CI [0,495; 0,530], $z = 1,37$, $p = 0,17$
 - ▶ bootstrap $L = 1$: SE 0,009, CI [0,494; 0,530] (ca DeLong)
 - ▶ $L = 20$: SE 0,015, CI [0,484; 0,543], 21% dintre replici $\leq 0,5$; $L = 60$: SE 0,014, CI [0,485; 0,541]
- Interpretare: DeLong presupune observații independente; etichetele suprapuse pe 5 zile și grupările de volatilitate o încalcă, iar SE robustă la dependență este de 1,7 ori mai mare
- Lungimea blocului: cel puțin orizontul etichetei (5) și suficient de lungă pentru grupările de volatilitate; rezultatele sunt stabile între 20 și 60 de zile, deci alegerea $L = 20$ poate fi justificată

B8 [Propus]: Diebold–Mariano pentru prognoze de probabilitate

Cerință

- ▣ **Context:** probabilitățile agregate în afara pliurilor din B7 și o prognoză constantă egală cu ponderea zilelor „sus” din antrenare în fiecare pli; log loss $\ell_t = -[y_t \ln \hat{p}_t + (1 - y_t) \ln(1 - \hat{p}_t)]$
- ▣ **Sarcini:**
 - ▶ (a) Calculați log loss mediu al celor patru prognoze.
 - ▶ (b) Pentru perechile RF vs. Logit-L1, RF vs. constantă și GB vs. constantă calculați $d_t = \ell_t^A - \ell_t^B$ și statistica DM $\bar{d}/SE_{HAC}(\bar{d})$ (Diebold & Mariano (1995)) cu lag-uri Newey–West 4 și 20.
 - ▶ (c) Comparați cu statistica t naivă i.i.d. și decideți la 5%.
- ▣ **Raportați:** un tabel cu log loss și cu statisticile DM și p -valorile lor
- ▣ **Model:** B7

Interpretare

- ▣ Poate un model cu AUC peste 0,5 să piardă în fața unei constante la log loss? Ce ar schimba concluzia?

B9 [Rezolvat]: meta-etichetare

Cerință

- ▣ **Context:** BTC 2014–2026; modelul primar: direcția încrucișării MA20/MA50; meta-eticheta = 1 dacă tranzacția primară e profitabilă la ieșirea din cele trei bariere ($pt = sl = 1$, $h = 10$) (López de Prado (2018))
- ▣ **Sarcini:**
 - ▶ (a) Construiți meta-etichetele pentru fiecare zi cu semnal primar.
 - ▶ (b) Estimați o pădure aleatoare (ponderi echilibrate ale claselor) pe caracteristici plus direcție, pe primele 60% dintre semnale; testați pe rest după o pauză de 10 zile.
 - ▶ (c) Comparați precizia, recall-ul, F1 și randamentul mediu pe tranzacție înainte (toate tranzacțiile) și după (doar $\hat{p} > 0,5$).
- ▣ **Raportați:** un tabel cu cele două rânduri și numărul de tranzacții

Interpretare

- ▣ Precizia crește, F1 scade: ce metrică contează pentru un trader care plătește costuri pe tranzacție?

B9: Rezolvare

Rezolvare

- Perioada de test 2022-02 – 2026-09, 1,660 de semnale; meta-modelul păstrează 49,6% dintre ele

	Prec.	Recall	F1	Tranz.	Rand./tranz.
Doar primar	0,475	1,000	0,644	1,660	−0,27%
+ meta-model	0,517	0,541	0,529	824	+0,19%

- Precizia crește cu 4 puncte, recall-ul se înjumătățește, iar F1 scade; randamentul mediu pe tranzacție trece de la −0,27% la +0,19%
- Interpretare: cu costuri pe tranzacție contează precizia și randamentul pe tranzacție, nu F1; pasul următor este un test al acestui randament (bootstrap pe blocuri) și un DSR peste toate variantele de meta-model încercate

B10 [Rezolvat]: căutare în grilă, DSR și numărul efectiv de încercări

Cerință

- ▣ **Context:** încrucișare MA long/cash pe log-prețul BTC, 15 mai 2015 – 2026 ($T = 4,145$ zile, prima zi în care fiecare regulă are semnal); fereastra rapidă $\in \{5, 10, \dots, 55\}$, lentă $\in \{20, 40, \dots, 240\}$, lentă $>$ rapidă: $N = 120$ încercări (Bailey & López de Prado (2014))
- ▣ **Sarcini:**
 - ▶ (a) Alegeți cea mai bună încercare după raportul Sharpe și calculați $PSR(0)$.
 - ▶ (b) Din matricea de corelație 120×120 a randamentelor încercărilor calculați valorile proprii, raportul de participare $(\sum \lambda_i)^2 / \sum \lambda_i^2$, numărul minim de valori proprii, în ordine descrescătoare, a căror sumă cumulată explică 95% din total și $\hat{N} = \bar{\rho} + (1 - \bar{\rho})N$.
 - ▶ (c) Calculați SR_0 și DSR pentru $N = 120$, $\hat{N}$ și numărul de la 95%, cu $V = 1/T$.
- ▣ **Raportați:** cea mai bună regulă, SR și momentele ei, măsurile N efectiv și un tabel DSR

Interpretare

- ▣ Ce N și ce $V[\widehat{SR}]$ ați raporta unui comitet de investiții?

B10: Rezolvare


Rezolvare

- (a) Cea mai bună (5, 40): $SR_{an} = 1,19$ (buy & hold 0,78); asimetrie 0,13, kurtosis 12,8; $PSR(0) = 1,000$
- (b) $\lambda_1 = 105,5$ explică 87,9% din varianță; raport de participare 1,3; 4 valori proprii ating 95%; $\bar{\rho} = 0,875 \Rightarrow \hat{N} = 15,9$

DSR, $V = 1/T$	$N = 120$	$\hat{N} = 15,9$	$N = 4$
SR_0 (an.)	0,77	0,53	0,31
DSR	0,922	0,987	0,998

- (c) A număra 120 de încercări corelate ca independente deflatează prea mult (0,922); cu $\hat{N}$ regula trece (0,987)
- Interpretare: DSR testează „SR peste noroc”, nu „peste buy & hold”; raportați $\hat{N}$ cu metoda lui și testați separat față de buy & hold (B13)

B10: de ce contează totuși dovada din afara eșantionului



- Rezultat din curs: cea mai bună încrucișare BTC în eșantion (SR 1,89, mai 2015 – 2020) a obținut SR 0,02 în 2021–2026

B11 [Propus]: probabilitatea de supraajustare a backtestului (CSCV)

Cerință

- ▣ **Context:** matricea $T \times 120$ a randamentelor zilnice ale încercărilor din B10, împărțită în $S = 16$ blocuri contigue (Bailey, Borwein, López de Prado & Zhu (2017))
- ▣ **Sarcini:**
 - ▶ (a) Pentru fiecare dintre cele $\binom{16}{8} = 12,870$ alegeri de 8 blocuri în eșantion, alegeți încercarea cu cel mai bun Sharpe în eșantion.
 - ▶ (b) Calculați rangul ei relativ în afara eșantionului, ω , și logit-ul $\lambda = \ln \frac{\omega}{1-\omega}$.
 - ▶ (c) Raportați $PBO = P(\lambda \leq 0)$, logit-ul median și Sharpe-ul median în și în afara eșantionului al câștigătorului.
- ▣ **Raportați:** PBO, histograma lui λ și rapoartele Sharpe de la (c)
- ▣ **Model:** B10

Interpretare

- ▣ Este grila supraajustată? Cum ar schimba PBO alegerea lui S sau adăugarea a 1,000 de strategii aleatoare în grilă?

B12 [Rezolvat]: Pesaran–Timmermann și Clark–West pentru modelele de direcție BTC

Cerință

- ▣ **Context:** probabilitățile agregate în afara pliurilor din B7 ($n = 4,181$, 54,8% „sus”), semnul prezis $x_t = 1\{\hat{p}_t > 0,5\}$ și prognoza constantă din B8 (Pesaran & Timmermann (1992); Clark & West (2007))
- ▣ **Sarcini:**
 - ▶ (a) Pentru fiecare model calculați $\hat{P}$, $\hat{P}^* = \hat{p}_y \hat{p}_x + (1 - \hat{p}_y)(1 - \hat{p}_x)$ și statistica PT.
 - ▶ (b) Pentru că etichetele pe 5 zile se suprapun, calculați statistica t a pantei în $y_t = a + b x_t + u_t$ cu erori Newey–West (4 lag-uri).
 - ▶ (c) Testați Logit-L1 față de constantă (modele imbricate) cu statistica Clark–West pe pierderea Brier, unilateral, HAC cu 4 lag-uri; comparați cu testul DM simplu pe aceeași pierdere.
- ▣ **Raportați:** un tabel cu $\hat{P}$, $\hat{P}^*$, PT și t HAC; statisticile CW și DM cu p -valorile lor

Interpretare

- ▣ De ce pot DM și Clark–West să nu fie de acord la modele imbricate? Ce ipoteză nulă testează fiecare?

B12: Rezolvare (1/2)

Rezolvare

□ (a)–(b) Testele direcționale:

	Prezis sus	$\hat{P}$	$\hat{P}^*$	PT	t_{HAC}
Logit-L1	99,6%	0,548	0,548	0,89	0,82
RF	70,3%	0,542	0,519	3,20	2,21
GB	68,5%	0,522	0,518	0,65	0,45

- RF: acuratețea (54,2%) este sub „mereu în sus” (54,8%), dar semnele lui nu sunt independente de rezultat: $PT = 3,20$; corecția HAC reduce dovada la $t = 2,21$ ($p = 0,03$)
- Logit-L1 și GB: nicio informație direcțională semnificativă

B12: Rezolvare (2/2)

Rezolvare

- (c) Clark–West, Logit-L1 vs. constantă: $t = -0,56$, p unilateral = 0,71: nicio dovadă că cele 11 caracteristici adaugă informație în modelul populației
- DM pe pierderea Brier: $t = 1,37$ (pozitiv = logit mai slab), $p = 0,17$
- DM întreabă dacă logit-ul *estimat* prognozează mai bine; sub ipoteza nulă imbricată zgomotul suplimentar îl face să piardă, deci DM rareori favorizează modelul mare
- CW adaugă înapoi $(\hat{\beta}_0 - \hat{\beta}_1)^2$ și întreabă dacă coeficienții populației sunt zero; aici ambele sunt de acord: niciun semnal semnificativ
- CW este derivat pentru modele liniare imbricate și prognoze reale în afara eșantionului; pe probabilitățile unui logit penalizat din CV purjat agregat este o corecție aproximativă, descriptivă
- Interpretare: un PT semnificativ (RF) nu face un model util: log loss-ul lui rămâne mai slab decât al constantei (B8)

B13 [Propus]: SPA vs. DSR pe grila de 120 de reguli

Cerință

- ▣ **Context:** matricea de randamente $T \times 120$ din B10 ($T = 4,145$); repere numerar ($r_0 = 0$) și buy-and-hold; bootstrap staționar (Politis & Romano (1994)) cu bloc mediu de 20 de zile, 2,000 de replici, seed 42
- ▣ **Sarcini:**
 - ▶ (a) Calculați diferențele de performanță $d_{k,t} = r_{k,t} - r_{0,t}$ pentru ambele repere.
 - ▶ (b) Calculați p -valoarea Reality Check a lui White (White (2000)), p -valoarea SPA a lui Hansen cu recentrarea consistentă (Hansen (2005)) și numărul de reguli păstrate de StepM Romano–Wolf la 5% (Romano & Wolf (2005)).
 - ▶ (c) Comparați cu DSR din B10 pentru $N = 120$ și $\hat{N} = 15,9$.
- ▣ **Raportați:** un tabel cu cea mai mare statistică studentizată, cele două p -valori și numărul StepM pentru fiecare reper
- ▣ **Model:** B10 și B12; slide-ul din curs „SPA vs. DSR pe grila Bitcoin”

Interpretare

- ▣ Ce metodă tratează încercările corelate fără să aleagă N ? Bate grila strategia buy-and-hold?

B14 [Propus]: selecție dublă: prezice VIX randamentele Bitcoin?

Cerință

- ▣ **Context:** cadrul din B7 ($n = 4,181$); rezultatul $y_t =$ randamentul log BTC pe 5 zile înainte, în puncte de bază; regresorul $d_t = \log$ VIX la închiderea din aceeași dată calendaristică, preluat peste weekenduri și sărbătorile din Statele Unite (data/market/VIX.INDX.csv), standardizat; 5 zile = 5 zile calendaristice BTC; controale: cele 11 caracteristici, pătratele lor și produsele două câte două ($p = 77$), standardizate
- ▣ **Sarcini:**
 - ▶ (a) Rulați un LASSO pentru y_t pe (d_t, x_t) cu penalizarea plug-in $\lambda = 2c\sqrt{n}\Phi^{-1}(1 - \gamma/(2p))$, $c = 1,1$, $\gamma = 0,1/\log n$ (Belloni, Chernozhukov & Hansen (2014)); este păstrat VIX?
 - ▶ (b) Rulați cele două LASSO de selecție (y_t pe x_t , d_t pe x_t) și raportați $|\hat{S}_y|$ și $|\hat{S}_d|$.
 - ▶ (c) Estimați OLS pentru y_t pe d_t și reuniunea controalelor selectate, cu erori HAC (4 lag-uri); dați $\hat{\theta}$, SE și CI 95%.
- ▣ **Raportați:** răspunsul de la (a), mărimile celor două mulțimi și estimația după selecția dublă
- ▣ **Model:** exemplul din curs „Prezice VIX randamentele S&P 500?” și B12

Interpretare

- ▣ De ce nu dă LASSO-ul simplu o inferență validă? Ce spune CI-ul despre o „primă de frică” în cripto?

C1 [Propus]: bate un model fundațional boosting-ul?

Cerință

- ▣ **Context:** direcția BTC la 5 zile din B7 (închideri zilnice 2014–2026); un model fundațional pentru serii de timp din Capitolul 14, folosit zero-shot; reperele din B7/B8; un proiect de echipă fără o metodă unică corectă
- ▣ **Sarcini:**
 - ▶ (a) Alegeți un model și restrângeți fereastra de test la datele de după limita lui de pre-antrenare, altfel testul are scurgeri.
 - ▶ (b) Transformați cuantilele prognozate ale randamentului pe 5 zile în $P(r_{t,t+5} > 0)$ prin interpolare.
 - ▶ (c) Reestimați gradient boosting și prognoza constantă la fiecare moment de prognoză pe o fereastră mobilă de lungime fixă și comparați log loss-urile exact pe aceleași date, prin testul Giacomini–White ([Giacomini & White \(2006\)](#); erori HAC).
 - ▶ (d) Definiți o regulă long/cash pentru $P(\text{sus}) > 0,5$ și calculați DSR sau p -valoarea SPA peste toate configurațiile încercate.
- ▣ **Raportați:** un folder Quantlet în repo-ul echipei (cod, Metainfo.txt, un grafic) și un slide cu concluzia și principala limită

Interpretare

- ▣ Dacă modelul fundațional câștigă, este câștigul relevant economic după costuri și ar rezista următorilor cinci ani de date?

C2 [Propus]: critica unui răspuns AI

- Un student îi cere unui asistent AI: „Prognozează direcția Bitcoin de mâine din randamentele trecute și evaluează modelul în afara eșantionului, cu validare încrucișată în 5 blocuri”
- Asistentul răspunde cu acest cod (btc: închideri zilnice, fără importuri):

```
r = np.log(btc).diff()
X = pd.DataFrame({'r1': r, 'r5': r.rolling(5).sum(), 'vol20': r.rolling(20).std(),
                  'trend10': r.rolling(10, center=True).mean()})
data = pd.concat([X, r.shift(-1).rename('fwd')], axis=1).dropna()
y = (data['fwd'] > 0).astype(int) # 1 if tomorrow is up
Xs = StandardScaler().fit_transform(data[X.columns])
cv = KFold(n_splits=5, shuffle=True, random_state=0)
model = LogisticRegression(penalty='l1', C=0.1, solver='liblinear')
auc = cross_val_score(model, Xs, y, cv=cv, scoring='roc_auc')
print(round(auc.mean(), 3))
```

- „Rezultat: 0,697. Un AUC de 0,70 în afara eșantionului, pe 4 361 de zile, este un semnal puternic, tranzacționabil; validarea încrucișată este în afara eșantionului, deci nu există supraajustare”

C2 [Propus]: critica unui răspuns AI, cerința

Cerință

- Răspunsul conține **două** scurgeri de informație din test în antrenare, o schemă de validare care nu corespunde utilizării reale și **două** afirmații nesustținute
- **Context:** codul și afirmația de pe slide-ul anterior, rulate pe închideri zilnice BTC-USD 2014–2026 (data/market/BTC-USD.CC.csv)
- **Sarcini**, pentru fiecare eroare
 - ▶ (a) Spuneți ce este greșit și de ce.
 - ▶ (b) Spuneți cum ați detecta-o: o verificare în cod, un rezultat din B5–B7, o regulă din curs.
 - ▶ (c) Dați codul corectat.
 - ▶ (d) Rulați din nou codul corectat cu o împărțire walk-forward și raportați AUC.
- **Raportați:** cele cinci erori ca în AI_ERRORS.md: ce s-a cerut, ce a răspuns AI-ul, ce era greșit, cum v-ați dat seama, varianta corectă

Interpretare

- Ce zile intră în trend10 în ziua t ? Care dintre ele este ținta?
- Este plauzibil un AUC de 0,70 pentru direcția Bitcoin de a doua zi, având în vedere B6 și B7?
- De ce nu este suficient „validarea încrucișată este în afara eșantionului” pentru serii de timp?

C3 [Propus]: un SDF fără arbitraj pe decile sortate după caracteristici

Cerință

- Context: studiul de caz de la curs (Chen, Pelger & Zhu (2024), pornind de la Gu, Kelly & Xiu (2020)): cazul liniar (Secțiunea II.F) și reperele FF3/FF5 (Fama & French (2015); Tabelul A.VI) pe decilele și factorii din Kenneth French Data Library
- Sarcini:
 - ▶ (a) Construiți panelul lunar, 1967 – ultima lună: decilele ponderate după valoare ale celor 15 sortări univariate din bibliotecă, în exces față de dobânda pe o lună; pe caracteristică o ramură short (decilele 1–5) și una long (6–10): 30 de factori $\tilde{F}_{t+1}$.
 - ▶ (b) Pe 1967–1986 calculați $\hat{\theta}_{LS} = \hat{\Sigma}^{-1} \hat{\mu}$ (momentul de ordinul doi și media lui $\tilde{F}_{t+1}$), o variantă elastic net cu penalizările alese după raportul Sharpe pe 1987–1991 și ponderile tangente FF3 și FF5.
 - ▶ (c) Cu ponderile fixate, raportați raportul Sharpe lunar al fiecărui portofoliu SDF $F_{t+1} = \hat{\theta}^\top \tilde{F}_{t+1}$ pe 1992–2016, cu un CI de 95% (Lo (2002)).
 - ▶ (d) Estimați $\hat{\beta}_i \propto \overline{R_i^e F}$ pe 1967–1986, proiectați lunar randamentele de test pe $\hat{\beta}$, calculați EV și R^2 transversal pe caracteristică (Secțiunea II.F); repetați (c)–(d) din 2017.
- Raportați: rapoartele Sharpe cu CI (Tabelele I, A.VI); EV și R^2 transversal lângă coloana elastic net (EN) din Tabelul III; un folder Quantlet
- Model: A5 (inferență pentru raportul Sharpe) și B12 (teste de abilitate predictivă)

Interpretare

- De ce întrece un SDF liniar fără arbitraj o rețea de prognoză (Tabelul I)? Rezistă rezultatul de după 2016 configurațiilor încercate?

Temă (proiectul de echipă)

- ▣ Alegeți un activ (indice bursier, acțiune, cripto, curs valutar sau marfă) și livrați
 - ▶ caracteristici fără informație din viitor; pentru orice caracteristică fracționară, o estimare a memoriei (local Whittle) cu CI, aleasă doar pe datele de antrenare (B1–B2)
 - ▶ etichete cu trei bariere cu (pt, sl, h) justificate
 - ▶ cel puțin trei modele cu Purged K-Fold, un test Pesaran–Timmermann, un test DM sau Clark–West față de o prognoză constantă și un CI bootstrap pe blocuri pentru AUC
 - ▶ evidența tuturor încercărilor, N efectiv, DSR, p -valoarea SPA față de buy-and-hold și PBO pentru strategia finală
- ▣ Repo GitHub cu notebook-uri și Metainfo.txt în stil Quantlet; o prezentare de 10 minute
- ▣ Treceți în AI_ERRORS.md fiecare eroare AI pe care o prindeți, ca în C2: ce s-a cerut, ce era greșit, cum v-ați dat seama, varianta corectă
- ▣ Un rezultat negativ, documentat onest, este un rezultat bun

Aprofundare pe Quantinar

-  Random Forests — bagging, eroarea out-of-bag, importanța variabilelor
-  Shapley Values — explicații locale independente de model
-  Machine Learning in Financial Risk — estimarea măsurilor de risc cu ML
-  Introduction to Reinforcement Learning — Q-learning, decizii secvențiale

Bibliografie (1/5)

- ▣ Bailey, D.H., Borwein, J., López de Prado, M., Zhu, Q.J. (2017). [The probability of backtest overfitting](#). *Journal of Computational Finance*, 20(4), 39–69.
- ▣ Bailey, D.H., López de Prado, M. (2012). [The Sharpe ratio efficient frontier](#). *Journal of Risk*, 15(2), 3–44.
- ▣ Bailey, D.H., López de Prado, M. (2014). [The deflated Sharpe ratio: correcting for selection bias, backtest overfitting and non-normality](#). *Journal of Portfolio Management*, 40(5), 94–107.
- ▣ Belloni, A., Chernozhukov, V., Hansen, C. (2014). [Inference on treatment effects after selection among high-dimensional controls](#). *Review of Economic Studies*, 81(2), 608–650.
- ▣ Bergmeir, C., Hyndman, R.J., Koo, B. (2018). [A note on the validity of cross-validation for evaluating autoregressive time series prediction](#). *Computational Statistics & Data Analysis*, 120, 70–83.
- ▣ Breiman, L. (2001). [Random forests](#). *Machine Learning*, 45(1), 5–32.
- ▣ Broadie, M., Glasserman, P., Kou, S. (1997). [A continuity correction for discrete barrier options](#). *Mathematical Finance*, 7(4), 325–349.

Bibliografie (2/5)

- ▣ Chen, L., Pelger, M., Zhu, J. (2024). Deep learning in asset pricing. *Management Science*, 70(2), 714–750.
- ▣ Clark, T.E., West, K.D. (2007). Approximately normal tests for equal predictive accuracy in nested models. *Journal of Econometrics*, 138(1), 291–311.
- ▣ DeLong, E.R., DeLong, D.M., Clarke-Pearson, D.L. (1988). Comparing the areas under two or more correlated receiver operating characteristic curves: a nonparametric approach. *Biometrics*, 44(3), 837–845.
- ▣ Dickey, D.A., Fuller, W.A. (1979). Distribution of the estimators for autoregressive time series with a unit root. *Journal of the American Statistical Association*, 74(366), 427–431.
- ▣ Diebold, F.X., Mariano, R.S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3), 253–263.
- ▣ Fama, E.F., French, K.R. (2015). A five-factor asset pricing model. *Journal of Financial Economics*, 116(1), 1–22.
- ▣ Friedman, J.H. (2001). Greedy function approximation: a gradient boosting machine. *Annals of Statistics*, 29(5), 1189–1232.
- ▣ Giacomini, R., White, H. (2006). Tests of conditional predictive ability. *Econometrica*, 74(6), 1545–1578.
- ▣ Gu, S., Kelly, B., Xiu, D. (2020). Empirical asset pricing via machine learning. *Review of Financial Studies*, 33(5), 2223–2273.

Bibliografie (3/5)

- Hanley, J.A., McNeil, B.J. (1982). The meaning and use of the area under a receiver operating characteristic (ROC) curve. *Radiology*, 143(1), 29–36.
- Hansen, P.R. (2005). A test for superior predictive ability. *Journal of Business & Economic Statistics*, 23(4), 365–380.
- Harvey, C.R., Liu, Y., Zhu, H. (2016). ... and the cross-section of expected returns. *Review of Financial Studies*, 29(1), 5–68.
- Hosking, J.R.M. (1981). Fractional differencing. *Biometrika*, 68(1), 165–176.
- Karatzas, I., Shreve, S.E. (1998). *Brownian Motion and Stochastic Calculus*, 2nd ed. Springer.
- Künsch, H.R. (1989). The jackknife and the bootstrap for general stationary observations. *Annals of Statistics*, 17(3), 1217–1241.
- Lo, A.W. (2002). The statistics of Sharpe ratios. *Financial Analysts Journal*, 58(4), 36–52.

Bibliografie (4/5)

- ▣ López de Prado, M. (2018). *Advances in Financial Machine Learning*. Wiley.
- ▣ Lundberg, S.M., Lee, S.-I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems*, 30.
- ▣ Newey, W.K., West, K.D. (1987). A simple, positive semi-definite, heteroskedasticity and autocorrelation consistent covariance matrix. *Econometrica*, 55(3), 703–708.
- ▣ Pesaran, M.H., Timmermann, A. (1992). A simple nonparametric test of predictive performance. *Journal of Business & Economic Statistics*, 10(4), 461–465.
- ▣ Politis, D.N., Romano, J.P. (1994). The stationary bootstrap. *Journal of the American Statistical Association*, 89(428), 1303–1313.
- ▣ Robinson, P.M. (1995). Gaussian semiparametric estimation of long range dependence. *Annals of Statistics*, 23(5), 1630–1661.
- ▣ Romano, J.P., Wolf, M. (2005). Stepwise multiple testing as formalized data snooping. *Econometrica*, 73(4), 1237–1282.

Bibliografie (5/5)

- Shimotsu, K., Phillips, P.C.B. (2005). [Exact local Whittle estimation of fractional integration](#). *Annals of Statistics*, 33(4), 1890–1933.
- Tibshirani, R. (1996). [Regression shrinkage and selection via the lasso](#). *Journal of the Royal Statistical Society B*, 58(1), 267–288.
- White, H. (2000). [A reality check for data snooping](#). *Econometrica*, 68(5), 1097–1126.