



## Modelarea piețelor financiare

### Seminarul 13: Machine Learning în finanțe — aplicații



Daniel Traian PELE

Antoaneta Amza

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

## Acronime folosite în acest material (1/2)

- ▣ ADF: Augmented Dickey–Fuller (test) (testul Dickey–Fuller augmentat)
- ▣ AI: Artificial Intelligence (inteligență artificială)
- ▣ AIC: Akaike Information Criterion (criteriul informațional Akaike)
- ▣ AUC: Area Under the (ROC) Curve (aria de sub curba ROC)
- ▣ CI: Confidence Interval (interval de încredere)
- ▣ CV: Cross-Validation (validare încrucișată)
- ▣ CW: Clark–West (test for nested models) (testul Clark–West pentru modele imbricate)
- ▣ DM: Diebold–Mariano (test) (testul Diebold–Mariano de comparare a prognozelor)
- ▣ DSR: Deflated Sharpe Ratio (raportul Sharpe deflatat)
- ▣ ELW: Exact Local Whittle (estimator) (estimatorul local Whittle exact)
- ▣ EWMA: Exponentially Weighted Moving Average (medie mobilă ponderată exponențial)
- ▣ FF3: Fama–French three-factor model (modelul Fama–French cu trei factori)
- ▣ FF5: Fama–French five-factor model (modelul Fama–French cu cinci factori)
- ▣ FFD: Fixed-width window Fractional Differentiation (diferențiere fracționară cu fereastră fixă)
- ▣ FFN: FeedForward Network (rețea neuronală feedforward (fără bucle))
- ▣ GAN: Generative Adversarial Network (rețea generativă adversarială)
- ▣ GB: Gradient Boosting (boosting pe gradient)
- ▣ GW: Giacomini–White (test) (testul Giacomini–White)
- ▣ HAC: Heteroskedasticity and Autocorrelation Consistent (standard errors) (erori standard robuste la heteroscedasticitate și autocorelație)
- ▣ IS: In-Sample (în eșantion)
- ▣ LASSO: Least Absolute Shrinkage and Selection Operator (regresie penalizată L1 cu selecția variabilelor)
- ▣ LS: Linear SDF estimated by unregularised Least Squares (SDF liniar estimat prin cele mai mici pătrate, fără regularizare)
- ▣ LW: Local Whittle (estimator) (estimatorul local Whittle)
- ▣ MDA: Mean Decrease Accuracy (scăderea medie a acurateții (importanța prin permutare))
- ▣ MDI: Mean Decrease Impurity (scăderea medie a impurității)
- ▣ OLS: Ordinary Least Squares (metoda celor mai mici pătrate)

## Acronime folosite în acest material (2/2)

- OOS: Out-Of-Sample (în afara eșantionului)
- PBO: Probability of Backtest Overfitting (probabilitatea de overfitting a backtest-ului)
- PSR: Probabilistic Sharpe Ratio (raportul Sharpe probabilistic)
- PT: Pesaran–Timmermann (test of directional accuracy) (testul Pesaran–Timmermann al acurateții direcționale)
- RC: Reality Check (White's test for data snooping) (testul Reality Check al lui White pentru data snooping)
- RF: Random Forest (pădure aleatoare)
- ROC: Receiver Operating Characteristic (curve) (curba caracteristică de operare)
- SDF: Stochastic Discount Factor (factorul stochastic de actualizare)
- SE: Standard Error (eroare standard)
- SHAP: SHapley Additive exPlanations (explicații aditive Shapley)
- SPA: Superior Predictive Ability (test) (testul abilității predictive superioare)
- SR: Sharpe Ratio (raportul Sharpe)
- SUA: Statele Unite ale Americii
- VIX: CBOE Volatility IndeX (indicele de volatilitate CBOE)

## Întrebarea zilei și traseul

- ▣ Întrebarea seminarului: **rezistă vreun semnal de machine learning pe Bitcoin unor etichete, unei validări și unei selecții oneste?**
- ▣ Traseul seminarului
  - ▶ Întîi slide-urile „Ce vă trebuie azi” (cinci slide-uri): [Capitolul 13](#) este cursul de după seminar
  - ▶ Partea I: memorie (A1), etichete (A3, B3), validare (A7, B5)
  - ▶ Partea a II-a: predicția și incertitudinea ei (B7a, B7b, B8), un răspuns AI de criticat (C2), selecție și deflatare (A5)
  - ▶ După curs: B1 (memoria Bitcoin prin local Whittle) și B10 (căutarea în grilă și numărul efectiv de încercări)
- ▣ Ce realizați: răspunsurile A, un grafic și un tabel pentru fiecare exercițiu B, codul C2 corectat, o frază de interpretare pentru fiecare exercițiu
- ▣ Notebook-ul zilei: [deschideți notebook-ul seminarului în Colab](#); fiecare cerință își numește secțiunea din notebook
- ▣ Seminar: drd. Antoaneta Amza, [antoaneta.amza@csie.ase.ro](mailto:antoaneta.amza@csie.ase.ro)

## Harta exercițiilor

| Exercițiu            | Întrebare                                                                                                         | Tip      | Model                    |
|----------------------|-------------------------------------------------------------------------------------------------------------------|----------|--------------------------|
| A1                   | ce păstrează un filtru fracționar trunchiat din nivelul prețului?                                                 | Rezolvat | –                        |
| A3, B3               | cum se comportă etichetele cu trei bariere pe traiectorii simple și pe Bitcoin?                                   | Rezolvat | –                        |
| A7, B5               | ce elimină purjarea și ce simulează amestecarea?                                                                  | Rezolvat | –                        |
| B7a, B7b             | bat trei modele “mereu în sus” și cât de incert este AUC?                                                         | Rezolvat | –                        |
| B8                   | prognosează un model mai bine decât o constantă?                                                                  | Propus   | B7a, B7b                 |
| C2                   | ce este greșit într-un răspuns AI?                                                                                | Propus   | B5, B7a                  |
| A5                   | este cel mai bun dintre 100 de backtesturi mai bun decât norocul?                                                 | Rezolvat | –                        |
| După curs            | B1: face diferențierea fracționară prețul Bitcoin staționar?<br>B10: cea mai bună din 120 de reguli față de noroc | Rezolvat | –                        |
| Pachete de extindere | A2, A3 extins, A4, A6, A8–A10, B2, B4, B6, B7c, B9, B11–B14, C1, C3                                               | ambele   | numit la fiecare cerință |

- **[Rezolvat]:** rezolvarea completă în slide-uri și în notebook, un model de urmat; **[Propus]:** îl rezolvați voi, rezolvarea se discută la seminar
- Partea A: derivări și exemple numerice mici; Partea B: verificare și inferență pe date crypto, fiecare cu o întrebare de interpretare; Partea C: critica unui răspuns AI și puncte de plecare pentru proiect

## Datele folosite


| Serie                                  | Cîmp                | Eșantion fixat                                                     | Folosit în         |
|----------------------------------------|---------------------|--------------------------------------------------------------------|--------------------|
| Bitcoin                                | close               | 2014-09-17 – 2026-09-18,<br>4.385 de închideri                     | B1, B3–B14, C1, C2 |
| Ether                                  | close               | 2015-08-07 – 2026-09-18,<br>4.061 de închideri                     | B2                 |
| VIX                                    | close               | zilele de tranzacționare din<br>SUA, preluate pe calendarul<br>BTC | B14                |
| Factorii și decilele<br>Kenneth French | Data Library, lunar | 1967 – ultima lună                                                 | C3                 |

- Închiderile zilnice din datele cursului, câte o serie pe activ (cîmpul folosit: close); criptomonede se tranzacționează în fiecare zi, deci anualizăm cu  $q = 365$
- Randamente: randamente logaritmice zilnice  $r_t = \ln(P_t/P_{t-1})$  pe calendarul propriu al fiecărui activ; nicio închidere lipsă în eșantioanele fixate; evenimentele fără o fereastră completă de  $h$  zile la final nu se etichetează

## Pregătire: rulați și verificați

```
# notebook section 0 defines load_data
btc = load_data('btc')['Close']
eth = load_data('eth')['Close']
print(len(btc), btc.index[0], btc.index[-1])
print(len(eth), eth.index[0], eth.index[-1])
r = np.log(btc).diff().dropna()
print(round(r.std() * np.sqrt(365), 3))
```

- Rezultat așteptat: BTC 4.385 de închideri, 17 sep. 2014 (457,33) – 18 sep. 2026 (80.901,46), volatilitate anualizată 0,666; ETH 4.061 de închideri din 7 aug. 2015
- Dacă un număr diferă, opriți-vă și verificați seria, câmpul și datele



## Notăție și funcțiile date

- $P_t$ : închiderea din ziua  $t$ ;  $x_t = \ln P_t$ ;  $r_t = x_t - x_{t-1}$ ;  $B$ : operatorul de întârziere,  $Bx_t = x_{t-1}$ ; momentul deciziei: închiderea zilei  $t$ , tranzacția la închiderea următoare
- $d$ : ordinul unui filtru fracționar (o alegere);  $\delta$ : memoria unei serii,  $I(\delta)$  (un parametru necunoscut pe care îl estimăm)
- $\sigma_{t_0}$ : volatilitatea EWMA a randamentelor logaritmice zilnice, span 50;  $h$ : orizontul etichetei;  $[t_0, t_1]$ : intervalul unei etichete
- SR: raportul Sharpe zilnic  $\bar{r}/\hat{\sigma}$  al randamentelor logaritmice zilnice (rata fără risc 0), anualizat  $\times \sqrt{365}$ ;  $\gamma_3$  asimetria,  $\gamma_4$  kurtosis obișnuit (distribuția Normală: 3)

| Funcția dată (secțiunea 0 a notebook-ului)                                                                                             | Ce întoarce                                                                                                                                                                                                                            |
|----------------------------------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <code>ffd_weights(d, threshold),<br/>frac_diff_ffd<br/>local_whittle,<br/>exact_local_whittle<br/>get_daily_vol, triple_barrier</code> | ponderile $w_0, \dots, w_K$ ; seria filtrată de la ziua $K$<br><br>$(\hat{\delta}, \text{SE})$ cu $m = \lfloor n^{0.65} \rfloor$ frecvențe<br><br>volatilitatea EWMA; un rînd pe eveniment: $t_1$ , randament, etichetă, tipul ieșirii |
| <code>PurgedKFold, build_features<br/>probabilistic_sharpe_ratio,<br/>deflated_sharpe_ratio</code>                                     | pliuri purjate cu embargo; cele 11 caracteristici din B7<br>PSR și DSR pentru un SR zilnic                                                                                                                                             |

## Ce vă trebuie azi (1/5): clasificatori și scorurile lor

- ▣ **Capitolul 13** este cursul de după acest seminar: aceste cinci slide-uri sînt minimul necesar pentru cerințele principale de azi; detaliile și rezultatele, la curs
- ▣ Cadrul: caracteristicile  $x_t$  cunoscute la închiderea zilei  $t$ , eticheta  $y_t \in \{0, 1\}$  (sus sau jos în zilele următoare); un clasificator întoarce  $\hat{p}_t = \hat{P}(y_t = 1 \mid x_t)$  și prezice “sus” cînd  $\hat{p}_t > 0,5$
- ▣ Cele trei modele din B7a
  - ▶ Logit-L1:  $\hat{p} = 1/(1 + e^{-x^\top \beta})$  cu penalizarea  $\lambda \|\beta\|_1$ , care anulează exact coeficienții slabi ([Tibshirani \(1996\)](#)); în scikit-learn  $C = 1/\lambda$ , deci un  $C$  mic înseamnă o penalizare puternică
  - ▶ Pădure aleatoare (RF): media multor arbori de decizie, fiecare crescut pe un eșantion bootstrap, cu o submulțime aleatoare de caracteristici la fiecare ramificare ([Breiman \(2001\)](#))
  - ▶ Gradient boosting (GB):  $F_m = F_{m-1} + \eta h_m$ , fiecare arbore mic  $h_m$  corectează ce au ratat arborii anteriori;  $\eta$  este rata de învățare ([Friedman \(2001\)](#))
- ▣ Acuratețea: proporția claselor corecte; reperul ei este “mereu în sus”, a cărei acuratețe este proporția etichetelor “sus”, nu 50%
- ▣ AUC (aria de sub curba ROC, [Hanley & McNeil \(1982\)](#)):  $P(\hat{p}_+ > \hat{p}_-) + \frac{1}{2}P(\hat{p}_+ = \hat{p}_-)$ , probabilitatea ca o zi “sus” aleasă la întâmplare să primească un scor mai mare decît o zi “jos”; 0,5 = nicio ordonare
  - ▶ Exemplu: zilele “sus” au scorurile (0,7; 0,4), zilele “jos” (0,5; 0,2); din cele 4 perechi, 3 sînt ordonate corect (0,4 < 0,5 nu este): AUC = 0,75

## Ce vă trebuie azi (2/5): pierderi și incertitudinea lor

- Predicție în afara pliului: fiecare zi este prognozată de un model care nu a fost antrenat pe ea (slide-ul 4/5 arată ce zile mai trebuie excluse)
- Log loss  $\ell_t = -[y_t \ln \hat{p}_t + (1 - y_t) \ln(1 - \hat{p}_t)]$ : penalizează probabilitățile greșite date cu încredere; AUC judecă ordonarea, log loss calibrarea (B8)
  - ▶ Exemplu:  $y_t = 1$ ;  $\hat{p}_t = 0,6$  costă  $-\ln 0,6 = 0,51$ ,  $\hat{p}_t = 0,2$  costă  $-\ln 0,2 = 1,61$
- Compararea a două prognoze: diferența de pierdere  $d_t = \ell_t^A - \ell_t^B$  și statistica Diebold–Mariano  $\bar{d}/\widehat{SE}(\bar{d})$  (Diebold & Mariano (1995)), cu erori Newey–West (Newey & West (1987)), pentru că valorile  $d_t$  vecine sînt dependente
- Eroarea standard a unui AUC
  - ▶ DeLong (DeLong, DeLong & Clarke-Pearson (1988)): o eroare standard în formă închisă, care tratează zilele ca independente
  - ▶ Bootstrap circular pe blocuri (Künsch (1989)): reeșantionați blocuri de  $L$  zile consecutive (cu reluare de la început după ultima zi), recalculați AUC, citiți SE și CI percentil din replici;  $L = 1$  este bootstrap-ul obișnuit
  - ▶ Blocurile păstrează dependența din interiorul lor, deci cu etichete suprapuse SE-ul pe blocuri este cel onest (B7b)

## Ce vă trebuie azi (3/5): diferențierea fracționară

- Diferențierea de ordin  $d$  cu operatorul de întârziere  $B$ :  $(1 - B)^d x_t = \sum_{k \geq 0} w_k x_{t-k}$ ,  $w_0 = 1$ ,  $w_k = -w_{k-1} \frac{d-k+1}{k}$  (Hosking (1981));  $d = 0$  păstrează nivelul,  $d = 1$  dă randamentul
  - ▶ Exemplu  $d = 0,5$ :  $w = (1; -0,5; -0.125; -0,0625; -0.039; \dots)$ ; ponderile scad încet, deci un  $d$  fracționar păstrează o parte din nivelurile vechi: „memorie”
- FFD (fixed-width window fractional differencing, diferențiere fracționară cu fereastră fixă, López de Prado (2018)): păstrați ponderile pînă la primul  $|w_k| < \tau$  și aplicați aceleași  $K + 1$  ponderi în fiecare zi
- Memoria  $\delta$ :  $x_t$  este  $I(\delta)$  cînd  $(1 - B)^\delta x_t$  are memorie scurtă
  - ▶  $\delta < \frac{1}{2}$ : staționară;  $\frac{1}{2} \leq \delta < 1$ : nestaționară, dar cu revenire la medie;  $\delta = 1$ : rădăcină unitară, un mers aleator; estimarea local Whittle a lui  $\delta$  este în Capitolul 1
  - ▶ Filtrarea unei serii  $I(1)$  cu ordinul  $d$  lasă memoria  $1 - d$ , dacă filtrul nu este trunchiat
- Regula  $d$  minim (López de Prado (2018)): cel mai mic  $d$  la care testul ADF (Dickey & Fuller (1979)) respinge; ADF:  $H_0$  rădăcină unitară, respingem cînd statistica este sub valoarea critică ( $-2,86$  la 5%, cu constantă); A1 întreabă ce dovedește o astfel de respingere

## Ce vă trebuie azi (4/5): etichete și validare onestă

- Eticheta cu orizont fix:  $y_t = 1\{\ln P_{t+h} - \ln P_t > 0\}$ ; scala de volatilitate  $\sigma_{t_0}$ : abaterea standard EWMA a randamentelor log zilnice, span 50 (ponderea  $2/51 \approx 0.039$  pentru ziua cea mai recentă)
- Trei bariere (López de Prado (2018)): de la intrarea  $t_0$ , barierele  $P_{t_0} e^{+pt \sigma_{t_0} \sqrt{h}}$ ,  $P_{t_0} e^{-sl \sigma_{t_0} \sqrt{h}}$  și una verticală la  $t_0 + h$ ; eticheta  $+1 / -1$  după prima atingere orizontală, altfel semnul randamentului la  $t_0 + h$ ;  $t_1 =$  ziua ieșirii
  - Exemplu:  $P_{t_0} = 100$ ,  $\sigma = 2\%$ ,  $h = 4$ ,  $pt = sl = 1$ : lățimea  $0,02\sqrt{4} = 0,04$ , barierele 104,08 și 96,08; închideri 101, 97, 95: atingere jos în ziua 3, eticheta  $-1$
- Etichetele zilelor vecine se suprapun: intervalele  $[t_0, t_1]$  au randamente comune, deci zilele nu sînt independente
- Validarea încrucișată în  $K$  pliuri: antrenare pe  $K - 1$  pliuri, test pe cel rămas; pliurile **amestecate** combină zilele, cele **contigue** păstrează blocuri de timp
- **Purjarea** (López de Prado (2018)): eliminați din antrenare orice observație al cărei interval de etichetă se suprapune cu un interval de test; **embargoul**: eliminați și cele  $e$  observații imediat după pliul de test
  - Exemplu:  $n = 10$ , intervale  $[i, i + 2]$ , pliul de test  $\{4, 5\}$  (etichete pînă în ziua 7),  $e = 1$ : eliminăm  $\{2, 3\}$  înainte și  $\{6, 7\}$  după; antrenăm pe  $\{0, 1, 8, 9\}$

## Ce vă trebuie azi (5/5): selecția și raportul Sharpe deflatat

- Raportul Sharpe probabilistic (PSR, Bailey & López de Prado (2012)): probabilitatea ca SR-ul zilnic adevărat să depășească un reper  $SR^*$ , dat fiind  $T$  randamente cu asimetria  $\gamma_3$  și kurtosis  $\gamma_4$ 
  - ▶  $PSR(SR^*) = \Phi((\widehat{SR} - SR^*)\sqrt{T-1}/D)$ ,  $D = \sqrt{1 - \gamma_3\widehat{SR} + \frac{\gamma_4-1}{4}\widehat{SR}^2}$  ( $D = 1$  în prima aproximare pentru randamente cu distribuția Normală)
- Selecția: cea mai bună dintre  $N$  strategii fără abilitate reală are totuși un SR pozitiv; valoarea lui așteptată este
  - ▶  $SR_0 = \sqrt{V} [(1 - \gamma_E)\Phi^{-1}(1 - \frac{1}{N}) + \gamma_E\Phi^{-1}(1 - \frac{1}{N_E})]$ ,  $V$  dispersia SR între încercări,  $\gamma_E = 0,5772$  constanta lui Euler
- Raportul Sharpe deflatat (DSR, Bailey & López de Prado (2014)):  $DSR = PSR(SR_0)$ , PSR față de norocul celei mai bune încercări
- Exemplu: SR zilnic  $\widehat{SR} = 0,10$ ,  $T = 400$ ,  $D = 1$ :  $PSR(0) = \Phi(0,10\sqrt{399}) = \Phi(2,00) = 0.977$ 
  - ▶ Dacă este cea mai bună din  $N = 10$  încercări, cu  $V = 1/T$ :  $SR_0 = \frac{1}{20}[0,4228 \cdot 1.282 + 0,5772 \cdot 1.789] = 0.079$ ,  
 $DSR = \Phi((0,10 - 0.079)\sqrt{399}) = \Phi(0,43) = 0,66$
- Mai mult în [Capitolul 13](#), după seminar: teorema strategiei false, importanța caracteristicilor, backtest-urile walk-forward și studiul de caz S&P 500

## A1 [Rezolvat]: ponderile FFD și fereastra păstrată — cerința

- ▣ **Întrebarea:** ce păstrează un filtru fracționar trunchiat din nivelul prețului?
- ▣ **Date de intrare:** ponderile  $w_0 = 1$ ,  $w_k = -w_{k-1} \frac{d-k+1}{k}$  (Hosking (1981)); trunchiere la primul  $|w_k| < \tau = 10^{-4}$  (López de Prado (2018));  $K$  = ultimul lag păstrat, deci fereastra folosește  $K + 1$  observații; fără fișier de date
- ▣ **Sarcini**
  1. Calculați  $w_0, \dots, w_4$  pentru  $d = 0,25$  cu relația de recurență.
  2. Cu `ffd_weights(0.25)`, raportați  $K$ , lungimea ferestrei  $K + 1$  și  $\sum_{k \leq K} w_k$ ; repetați pentru  $d = 0,3$  și  $d = 0,5$ .
  3. Scrieți  $\tilde{X}_t = \sum_{k=0}^K w_k X_{t-k}$  ca  $(\sum_k w_k) X_t$  minus o combinație a diferențelor  $X_t - X_{t-k}$ .
  4. Decideți dacă  $\tilde{X}_t$  al unui log-preț  $I(1)$  este staționar.
- ▣ **Raportați:** cele cinci ponderi, un tabel ( $d$ ,  $K$ ,  $K + 1$ , suma ponderilor), descompunerea și decizia
- ▣ **Interpretare:** regula  $d$  minim alege cel mai mic  $d$  la care un test ADF respinge: ce dovedește o astfel de respingere?
- ▣ Notebook: secțiunea A1


## A1 [Rezolvat]: rezolvare

1.  $w_1 = -0,25$ ,  $w_2 = -0,25 \cdot 0,75/2 = -0,09375$ ,  
 $w_3 = -0,0547$ ,  $w_4 = -0,0376$ : toate ponderile  
 după  $w_0$  sînt negative

2. Tabel:

| $d$  | $K$ | $K+1$ | $\sum_{k \leq K} w_k$ |
|------|-----|-------|-----------------------|
| 0,25 | 444 | 445   | 0,178                 |
| 0,30 | 387 | 388   | 0,129                 |
| 0,50 | 199 | 200   | 0,040                 |


3.  $\tilde{X}_t = (\sum_{k \leq K} w_k) X_t - \sum_{k=1}^K w_k (X_t - X_{t-k})$
4. Fiecare  $X_t - X_{t-k}$  este  $I(0)$ , dar primul termen este  
 $0,178 X_t$  la  $d = 0,25$ :  $\tilde{X}_t$  rămîne  $I(1)$



- Panoul din dreapta: un mers aleator simulat; nivelul scalat (roșu)  
 poartă rădăcina unitară a seriei FFD (corelație 0,93)
- Interpretare: o respingere ADF arată că testul confundă o  
 componentă mică cu rădăcină unitară cu partea staționară, nu că  
 seria este staționară


## A3 [Rezolvat]: etichete cu trei bariere pe două traiectorii — cerința

- ▣ **Întrebarea:** ce barieră este atinsă prima și ce etichetă rezultă?
- ▣ **Date de intrare:** intrare  $P_{t_0} = 100$ , volatilitate zilnică  $\sigma_{t_0} = 1\%$ , bariera verticală  $h = 5$  zile,  $pt = sl = 1$ ; barierele  $P_{t_0} e^{\pm pt \sigma_{t_0} \sqrt{h}}$  (López de Prado (2018)); doar închideri zilnice
- ▣ **Sarcini**
  1. Calculați bariera superioară și cea inferioară.
  2. Desenați-le pe cele două traiectorii și marcați prima atingere.
  3. Etichetați fiecare traiectorie: +1 sus, -1 jos, iar la bariera verticală semnul lui  $\ln(P_{t_0+h}/P_{t_0})$ .
- ▣ **Raportați:** cele două bariere, ziua și tipul ieșirii, cele două etichete
- ▣ **Interpretare:** de ce poate primi +1 o traiectorie care se încheie sub 100? Notebook: secțiunea A3



## A3 [Rezolvat]: rezolvare


1. Lățimea  $0,01\sqrt{5} = 0,02236$ : bariera superioară  $100e^{0,02236} = 102,26$ , cea inferioară  $100e^{-0,02236} = 97,79$
  2. Traectoria 1: ziua 3,  $102,5 \geq 102,26$ , atingere sus; traectoria 2: nicio atingere orizontală în 5 zile
  3. Traectoria 1: +1 (scăderea ulterioară la 99,8 nu contează); traectoria 2:  $\ln(99,1/100) = -0,90\%$  la bariera verticală: -1
- ☐ Interpretare: eticheta reține prima ieșire pe care ar fi luat-o un trader, nu prețul de la sfârșitul ferestrei; o ieșire verticală păstrează semnul randamentului final, deci "vertical" și "-1" sînt noțiuni diferite



## B3 [Rezolvat]: etichete cu trei bariere pe Bitcoin — cerința

- **Întrebarea:** cât de des atinge Bitcoin o barieră orizontală în 10 zile și cât de echilibrate sînt etichetele?
- **Date și setări:** închideri zilnice BTC; fiecare zi este un eveniment  $t_0$ ;  $\sigma_{t_0}$  = volatilitatea EWMA, span 50 (`get_daily_vol`);  $h = 10$  zile; monitorizare pe închideri zilnice; evenimentele fără 10 închideri ulterioare sînt eliminate (4.373 de evenimente, 19 sep. 2014 – 8 sep. 2026)
- **Sarcini**
  1. Cu `triple_barrier`, etichetați fiecare eveniment pentru  $pt = sl = 1$  și  $pt = sl = 2$ ; afișați înregistrarea unui eveniment ( $t_0$ ,  $\sigma_{t_0}$ , prețurile barierelor,  $t_1$ , tipul ieșirii, randamentul, eticheta).
  2. Calculați ponderile ieșirilor sus, jos și verticale, durata medie de deținere și ponderea etichetelor +1.
  3. Faceți tabelul încrucișat tip de ieșire – etichetă finală și comparați cu eticheta cu orizont fix de 10 zile, pe aceleași evenimente.
- **Raportați:** înregistrarea evenimentului, un tabel pe variante, tabelul încrucișat, graficul ponderilor și al duratelor
- **Interpretare:** de ce circa 56% dintre etichete sînt +1 și ce acuratețe trebuie atunci depășită? Notebook: secțiunea B3

## B3 [Rezolvat]: rezolvare




|                     | Sus   | Jos   | Vertical | Zile | +1    |
|---------------------|-------|-------|----------|------|-------|
| $pt = sl = 1$       | 22,8% | 18,2% | 59,0%    | 8,25 | 55,7% |
| $pt = sl = 2$       | 7,2%  | 4,9%  | 87,9%    | 9,58 | 55,6% |
| orizont fix 10 zile | —     | —     | 100%     | 10   | 55,5% |

- Evenimentul din 11 mar. 2024: închidere 72.124,  $\sigma = 3,0\%$ , bariere 79.336 și 65.568; ieșire jos pe 16 mar., randament  $-9,9\%$ , eticheta  $-1$
- $pt = sl = 1$ : ieșirile verticale se împart în 1.442 de etichete  $+1$  și 1.139 de etichete  $-1$ ; cele orizontale dau 995 de  $+1$  și 797 de  $-1$
- Interpretare: BTC a crescut în eșantion, deci “mereu în sus” (circa 56%) este reperul; barierele mai largi apropie etichetele de cele cu orizont fix


## A7 [Rezolvat]: cât costă purjarea? — cerința

- **Întrebarea:** ce observații de antrenare trebuie eliminate când etichetele de test se suprapun cu ale lor?
- **Date de intrare:**  $n = 20$  de observații  $i = 0, \dots, 19$  (de la zero) în  $K = 5$  pliuri contigue de  $L = 4$ ; eticheta lui  $i$  acoperă intervalul închis  $[i, i + h]$ ,  $h = 3$ ; embargo  $e = 1$  observație după ultimul indice de test; pliul de test  $\{8, \dots, 11\}$ , ale cărui etichete ajung la ziua 14
- **Sarcini**
  1. Enumerați observațiile dinaintea pliului de test al căror interval ajunge la ziua 8 (purjate înainte).
  2. Enumerați observația sub embargo și pe cele de după pliul care încep cel târziu în ziua 14 (purjate după).
  3. Numărați reuniunea eliminărilor și proporția pierdută din cele 16 observații din afara testului; pentru un pli interior, cu destule observații de ambele părți, arătați că proporția este  $\frac{h + \max(h, e)}{n - L}$ .
- **Interpretare:** de ce supraestimează K-fold cu amestecare acuratețea în acest cadru? Notebook: secțiunea A7



## A7 [Rezolvat]: rezolvare


1. Purjate înainte:  $\{5, 6, 7\}$ , pentru că  $i + 3 \geq 8$
  2. Embargo:  $\{12\}$ ; purjate după:  $\{12, 13, 14\}$ , pentru că încep pînă în ziua 14; observația 12 sub embargo este și purjată
  3. Reuniunea:  $\{5, 6, 7, 12, 13, 14\}$ , 6 din 16 pierdute (37,5%); setul de antrenare  $\{0, \dots, 4\} \cup \{15, \dots, 19\}$
- Pliu interior general:  $h$  observații înainte; după, etichetele care încep înainte de sfîrșitul ultimei etichete de test ( $h$ ) sau în embargo ( $e$ ):  $\max(h, e)$ ; proporția  $\frac{h + \max(h, e)}{n - L} = \frac{3 + 3}{16}$
- Interpretare: amestecarea pune vecini cu randamente comune de ambele părți ale împărțirii; un model flexibil îi memorează (B5)



## B5 [Rezolvat]: K-fold cu purjare vs. K-fold amestecat — cerința

- **Întrebarea:** câtă acuratețe inventează amestecarea când nu există nimic de prezis? Un diagnostic sintetic, fără date de piață
- **Date de intrare** (notebook, secțiunea B5, seed 42): un mers aleator de 3.000 de zile; eticheta = semnul randamentului pe 20 de zile înainte, intervale  $[i, i + 20]$ ; 5 caracteristici = medii pe 20 de zile ale unui zgomot independent; acuratețea adevărată 50%
- **Sarcini**
  1. Verificați clasa dată `PurgedKFold`: găsiți linia care purjează înainte de pliul de test, linia care aplică embargoul și pe cea care purjează după el; rulați-o pe exemplul din A7.
  2. Estimați o pădure aleatoare ([Breiman \(2001\)](#)); 200 de arbori, frunza minimă 5, seed 42) cu 5-fold amestecat, 5-fold contiguu și 5-fold purjat cu embargo 1% (30 de observații).
  3. Raportați cele cinci acurateți pe pliuri și media lor pentru fiecare schemă.
- **Raportați:** verificarea pe A7, un grafic și un tabel cu acuratețile pe pliuri
- **Interpretare:** în acest cadru, ce elimină leakage-ul: purjarea sau renunțarea la amestecare? S-ar reduce diferența cu etichete pe 1 zi?

## B5 [Rezolvat]: rezolvare



- Pe exemplul din A7 clasa elimină  $\{5, 6, 7, 12, 13, 14\}$  pentru pliul de test  $\{8, \dots, 11\}$ : răspunsul pas cu pas

| Schema    | Acurateți pe pliuri; media |       |       |       |        |              |
|-----------|----------------------------|-------|-------|-------|--------|--------------|
| amestecat | 0,707                      | 0,678 | 0,698 | 0,700 | 0,687; | <b>0,694</b> |
| contiguu  | 0,480                      | 0,543 | 0,553 | 0,452 | 0,472; | 0,500        |
| purjat    | 0,485                      | 0,510 | 0,540 | 0,473 | 0,477; | <b>0,497</b> |

- Seturile de antrenare purjate păstrează 2.350–2.380 din 2.400 de observații
- Interpretare: aici pliurile contigue elimină deja cea mai mare parte a leakage-ului, pentru că doar granițele pliurilor au randamente comune; purjarea curăță granițele. Leakage-ul cere etichete suprapuse și caracteristici persistente ([Bergmeir, Hyndman & Koo \(2018\)](#)); acest seed o arată doar pentru acest cadru

## Cadrul de modelare pe Bitcoin (B6–B8, B12, B14)

- ▣ Ținta:  $y_t = 1\{\ln P_{t+5} - \ln P_t > 0\}$ , 5 zile calendaristice (cripto se tranzacționează zilnic); intervalul etichetei  $[t, t + 5]$
- ▣ Rînduri: fiecare zi cu toate caracteristicile și o fereastră completă de 5 zile:  $n = 4.181$ , 4 apr. 2015 – 13 sep. 2026, 54,8% “sus”
- ▣ Validare: PurgedKFold(5, t1, pct\_embargo=0.01): 5 pliuri contigue de 836–837 de zile, embargo 41 de zile; aceleași pliuri pentru toate modelele


| 11 caracteristici (build_features)    | Definiție, informație pînă în ziua $t$                                               |
|---------------------------------------|--------------------------------------------------------------------------------------|
| mom_1, mom_5, mom_20, mom_60, mom_120 | $x_t - x_{t-h}$                                                                      |
| vol_20, vol_60, vol_ratio             | abaterea standard a lui $r_t$ pe 20 și 60 de zile $\times \sqrt{365}$ ; raportul lor |
| dist_ma50, dist_ma200                 | $x_t$ minus media lui $x$ pe ultimele 50 sau 200 de zile                             |
| rsi_14                                | indicele de forță relativă, 14 zile, împărțit la 100                                 |

- ▣ Modele: Logit-L1 (standardizat,  $C = 0,05$ , [Tibshirani \(1996\)](#)); RF (400 de arbori, frunza minimă 50, [Breiman \(2001\)](#)); GB (pe histograme, adîncime 3, rată de învățare 0,03, 200 de arbori, [Friedman \(2001\)](#)); seed 42
- ▣ Se salvează pentru exercițiile următoare: un rînd pe dată cu eticheta, pliul, cele trei probabilități în afara pliului și prognoza constantă (proporția “sus” din antrenare în acel pli)

## B7a [Rezolvat]: trei modele față de “mereu în sus” — cerința

- ▣ **Întrebarea:** prezice vreunul dintre cele trei modele direcția Bitcoin pe 5 zile mai bine decât “mereu în sus”?
- ▣ **Date:** cadrul de modelare de pe slide-ul anterior
- ▣ **Sarcini**
  1. Estimați Logit-L1, RF și GB pe fiecare pliu de antrenare purjat și prognozați pliul de test; salvați probabilitățile în afara pliului.
  2. Pentru fiecare model, calculați acuratețea ( $\hat{p} > 0,5$ ) și ROC AUC în fiecare pliu de test și mediile lor (**medii pe pliuri**).
  3. Calculați acuratețea “mereu în sus” a fiecărui pliu de test, adică proporția etichetelor “sus”, și media pe pliuri.
  4. Calculați AUC **agregat**: un singur AUC pe toate cele 4.181 de probabilități în afara pliurilor.
- ▣ **Raportați:** un tabel (acuratețe, AUC, abaterea între pliuri), reperul, graficul cu punctele pe pliuri, proporția prognozelor “sus”
- ▣ **Interpretare:** de ce o acuratețe de 54,8% nu este aici o dovadă de abilitate? Notebook: secțiunea B7

## B7a [Rezolvat]: rezolvare




|                            | Logit-L1 | RF    | GB    |
|----------------------------|----------|-------|-------|
| Acuratețe, media pe pliuri | 54,8%    | 54,2% | 52,2% |
| AUC, media pe pliuri       | 0,492    | 0,516 | 0,502 |
| AUC agregat                | 0,466    | 0,512 | 0,498 |
| Prezis "sus"               | 99,6%    | 70,3% | 68,5% |

- "Mereu în sus": proporțiile pe pliuri 61,3%, 53,5%, 56,6%, 51,3%, 51,3%, media 54,8%; niciun model nu îl bate; Logit-L1 este "mereu în sus"
- Media pe pliuri și AUC agregat diferă: cinci ordonări mediate vs. o singură ordonare pe toate zilele, care amestecă și calibrarea pliurilor
- Interpretare: 54,8% este proporția săptămînilor "sus", nu o abilitate; întrebarea următoare este cît de incert este 0,512 al RF (B7b)

## B7b [Rezolvat]: un CI pentru AUC robust la dependență — cerința

- ▣ **Întrebarea:** se distinge AUC agregat de 0,512 al RF de 0,5?
- ▣ **Date:** probabilitățile RF în afara pliurilor și etichetele salvate în B7a ( $n = 4.181$ );  $AUC = P(\hat{p}_+ > \hat{p}_-) + \frac{1}{2}P(\hat{p}_+ = \hat{p}_-)$ , 0,5 = nicio ordonare
- ▣ **Sarcini**
  1. Calculați eroarea standard DeLong (DeLong, DeLong & Clarke-Pearson (1988)), CI 95%,  $z = (AUC - 0,5)/SE$  și  $p$ -valoarea bilaterală.
  2. Reșantionați rîndurile cu un bootstrap circular pe blocuri (Künsch (1989)): blocuri de  $L \in \{1, 20, 60\}$  zile consecutive, 1.000 de replici, seed 42; recalculați de fiecare dată AUC.
  3. Raportați SE bootstrap, CI 95% percentil și proporția replicilor egale cu sau sub 0,5, pentru fiecare  $L$ .
- ▣ **Raportați:** un grafic cu intervalele și distribuțiile bootstrap pentru  $L = 1$  și  $L = 20$
- ▣ **Interpretare:** de ce este intervalul bootstrap pe blocuri mai larg și ce lungime de bloc ați justifica? Notebook: secțiunea B7

## B7b [Rezolvat]: rezolvare



- DeLong: SE 0,0090, CI [0,495; 0,530],  $z = 1,37$ ,  $p = 0,17$ ;  $L = 1$ : SE 0,0091, CI [0,494; 0,530], ca DeLong
- $L = 20$ : SE 0,0150, CI [0,484; 0,543], 20,8% dintre replici  $\leq 0,5$ ;  $L = 60$ : SE 0,0141, CI [0,485; 0,541]
- Interpretare: etichetele suprapuse pe 5 zile și grupările de volatilitate fac zilele vecine dependente; SE robustă la dependență este de 1,7 ori SE DeLong. Un bloc cel puțin cât orizontul etichetei, stabil între 20 și 60 de zile:  $L = 20$  se poate justifica. Histogramele sînt distribuții ale estimatorului, nu distribuții sub ipoteza nulă

## B8 [Propus]: Diebold–Mariano pentru prognoze de probabilitate — cerința

- ▣ **Model:** B7a și B7b [Rezolvat]
- ▣ **Întrebarea:** prognozează vreun model probabilitatea unei săptămîni “sus” mai bine decît o constantă?
- ▣ **Date de intrare:** probabilitățile salvate în B7a, limitate la  $[10^{-6}, 1 - 10^{-6}]$ ; log loss  $\ell_t = -[y_t \ln \hat{p}_t + (1 - y_t) \ln(1 - \hat{p}_t)]$ ; rînd rezolvat, 13 iul. 2015,  $y_t = 0$ : constantă  $\hat{p} = 0,529$ ,  $\ell = -\ln(1 - 0,529) = 0,753$ ; RF  $\hat{p} = 0,496$ ,  $\ell = 0,684$
- ▣ **Sarcini**
  1. Calculați log loss mediu pentru Logit-L1, RF, GB și constantă.
  2. Pentru RF vs. Logit-L1, RF vs. constantă și GB vs. constantă, formați  $d_t = \ell_t^A - \ell_t^B$  ( $d_t > 0$ : modelul A mai slab) și regresați  $d_t$  pe o constantă cu erori Newey–West (Newey & West (1987)), lag-uri 4 și 20: statistica DM este valoarea  $t$  (Diebold & Mariano (1995)), bilateral.
  3. Calculați statistica  $t$  naivă i.i.d. a lui  $\bar{d}$  și comparați.
- ▣ **Raportați:** un tabel cu log loss,  $\bar{d}$ , DM (lag-uri 4, 20) cu  $p$ -valori,  $t$  naiv; un grafic cu  $d_t$  cumulat
- ▣ **Interpretare:** poate un model cu AUC peste 0,5 să piardă în fața unei constante la log loss? Probabilitățile din CV agregat sînt descriptive: o afirmație despre utilizare cere prognoze walk-forward. Notebook: secțiunea B8

## C2 [Propus]: critica unui răspuns AI — răspunsul

- **Promptul** trimis unui asistent AI: “Prognozează direcția Bitcoin de mâine din randamentele trecute și evaluează modelul în afara eșantionului, cu validare încrucișată în 5 pliuri”
- **Răspunsul** (btc: închideri zilnice 2014-09-17 – 2026-09-18; fără importuri):

```
1 r = np.log(btc).diff()
2 X = pd.DataFrame({'r1': r, 'r5': r.rolling(5).sum(), 'vol20': r.rolling(20).std(),
3                  'trend10': r.rolling(10, center=True).mean()})
4 data = pd.concat([X, r.shift(-1).rename('fwd')], axis=1).dropna()
5 y = (data['fwd'] > 0).astype(int) # 1 if tomorrow is up
6 Xs = StandardScaler().fit_transform(data[X.columns])
7 cv = KFold(n_splits=5, shuffle=True, random_state=0)
8 model = LogisticRegression(penalty='l1', C=0.1, solver='liblinear')
9 auc = cross_val_score(model, Xs, y, cv=cv, scoring='roc_auc')
10 print(round(auc.mean(), 3))
```

- “Rezultat: 0,697. Un AUC de 0,70 în afara eșantionului, pe 4.361 de zile, este un semnal puternic, tranzacționabil; validarea încrucișată este în afara eșantionului, deci nu există overfitting”

## C2 [Propus]: critica unui răspuns AI — cerința


- ▣ **Model:** B5 și B7a [Rezolvat]; B6 (extindere) este aceeași capcană într-un model mai mare
- ▣ **Sarcini**
  1. Dați cinci constatări adnotate, fiecare cu numărul liniei: două surse de leakage din test, o schemă de validare care nu corespunde utilizării reale, două afirmații nesustținute.
  2. Pentru fiecare, spuneți cum ați detecta-o: o verificare a rezultatului, un rezultat din B5 sau B7a, o regulă din slide-urile „Ce vă trebuie azi”.
  3. Scrieți un singur pipeline corectat: caracteristici calculate doar din trecut, scalarea în fiecare pliuri de antrenare (`make_pipeline`), `TimeSeriesSplit(n_splits=5, gap=20)`, AUC mediu pe cele 5 pliuri de test.
  4. Raportați un tabel înainte/după: codul AI, apoi fiecare corecție adăugată pe rînd.
  5. Treceți erorile în formatul `AI_ERRORS.md`: cererea, răspunsul, eroarea, cum ați găsit-o, corecția.
- ▣ **Interpretare:** ce zile intră în `trend10` în ziua  $t$  și care dintre ele este ținta? Un AUC neobișnuit de mare este un motiv să verificați codul, nu o dovadă de leakage

## A5 [Rezolvat]: PSR și DSR, fișă de calcul — cerința

- ▣ **Întrebarea:** este convingător un raport Sharpe anualizat de 1,2 pe trei ani, dacă este cel mai bun din 100 de încercări?
- ▣ **Date de intrare** (strategie pe acțiuni,  $q = 252$ ):  $\widehat{SR}_{an} = 1,2$ ,  $T = 756$  randamente zilnice,  $\hat{\gamma}_3 = -0,4$ , kurtosis obișnuit  $\hat{\gamma}_4 = 5$ ;  $N = 100$  încercări independente,  $V = \text{Var}[\widehat{SR}_n] = 1/T$ ; constanta lui Euler  $\gamma_E = 0,5772$  (Bailey & López de Prado (2012); Bailey & López de Prado (2014))
- ▣ **Sarcini**
  1. SR zilnic  $\widehat{SR} = 1,2/\sqrt{252}$  și numitorul  $D = \sqrt{1 - \hat{\gamma}_3 \widehat{SR} + \frac{\hat{\gamma}_4 - 1}{4} \widehat{SR}^2}$ .
  2.  $z = \widehat{SR} \sqrt{T-1}/D$  și  $PSR(0) = \Phi(z)$ .
  3.  $SR_0 = \sqrt{V} [(1 - \gamma_E) \Phi^{-1}(1 - \frac{1}{N}) + \gamma_E \Phi^{-1}(1 - \frac{1}{Ne})]$ , zilnic și anualizat.
  4.  $DSR = \Phi((\widehat{SR} - SR_0) \sqrt{T-1}/D)$ .
- ▣ **Raportați:** fiecare număr intermediar, PSR(0) și DSR; derivarea lui  $D$  este în extindere (A5 extins)
- ▣ **Interpretare:** pentru randamente i.i.d., reper zero și 100 de încercări, ce spune DSR? Ce  $N$  l-ar schimba?  
Notebook: secțiunea A5

## A5 [Rezolvat]: rezolvare

1.  $\widehat{SR} = 1,2/\sqrt{252} = 0,07559$ ;  
 $D = \sqrt{1 + 0,4 \cdot 0,07559 + 1 \cdot 0,07559^2} = 1,01782$
  2.  $z = 0,07559 \cdot \sqrt{755}/1,01782 = 2,041$ ;  
 $PSR(0) = \Phi(2,041) = 0,979$
  3.  $\sqrt{V} = 1/\sqrt{756} = 0,03637$ ;  $\Phi^{-1}(0,99) = 2,326$ ,  
 $\Phi^{-1}(1 - \frac{1}{100e}) = 2,680$ ;  
 $SR_0 = 0,03637 [0,4228 \cdot 2,326 + 0,5772 \cdot 2,680] = 0,0920$   
 pe zi, 1,46 anualizat
  4.  $z = (0,07559 - 0,0920)\sqrt{755}/1,01782 = -0,444$ ;  
 $DSR = \Phi(-0,444) = 0,329$
- Interpretare: doar norocul dă un SR anualizat maxim de 1,46 din 100 de încercări i.i.d. fără abilitate, peste 1,2 observat; dovada nu trece pragul ilustrativ de 0,95. Cu  $N = 1$ , DSR este egal cu  $PSR(0) = 0,979$



## Proiectul de echipă: alegeți un traseu

- ▣ **Standard:** un activ ales de voi, prin B1, B3, B7a, B7b și B10, cu matricea randamentelor tuturor regulilor încercate salvată
- ▣ **Avansat:** C1 (model fundațional vs. boosting) sau C3 (un SDF fără arbitraj pe decile), în pachetele de extindere
- ▣ Dovezi minime: codul ca Quantlet, un grafic, testul față de un reper, numărul de încercări; folosirea AI în AI\_USE.md, erorile depistate în AI\_ERRORS.md
- ▣ Un rezultat negativ, documentat onest, este un rezultat bun


## După curs: două exerciții rezolvate de refăcut

- Rezolvați-le pe acestea două după [Capitolul 13](#): folosesc estimatori și argumente pe care cursul le dezvoltă
  - ▶ B1: estimatorul exact local Whittle ([Shimotsu & Phillips \(2005\)](#)) și inferența asupra memoriei  $\delta$  a log-prețului Bitcoin; model: A1
  - ▶ B10: o grilă de 120 de reguli de tranzacționare corelate, valorile proprii ale matricei lor de corelație și numărul efectiv de încercări din DSR; model: A5
- Ambele sînt [Rezolvat]: refaceți-le în notebook (secțiunile B1 și B10) și comparați cu slide-urile

## B1 [Rezolvat]: memoria log-prețului Bitcoin — cerința

- ▣ **Întrebarea:** ce  $d$  alege regula ADF minimă pentru Bitcoin și care este memoria  $\delta$  a log-prețului?
- ▣ **Date:**  $x_t = \ln P_t$ , BTC 2014-09-17 – 2026-09-18 ( $n = 4.385$ ); funcții disponibile: `frac_diff_ffd`, `exact_local_whittle`, `local_whittle`
- ▣ **Sarcini**
  1. Pentru  $d \in \{0; 0,05; \dots; 1\}$ , filtrați  $x_t$  ( $\tau = 10^{-4}$ ), rulați `adfuller(x, maxlag=1, regression='c', autolag=None)` (Dickey & Fuller (1979)) și notați statistica și  $\text{Corr}(\tilde{x}_t, x_t)$  pe datele păstrate de filtru.
  2. Raportați  $d^*$ , cel mai mic  $d$  cu statistica sub valoarea critică la 5%.
  3. Estimați  $\delta$  cu CI 95% ( $m = \lfloor n^{0,65} \rfloor$  pentru fiecare serie): ELW (Shimotsu & Phillips (2005)) pentru  $x_t$  și seria FFD la  $d^*$ , LW (Robinson (1995)) pentru  $r_t$  și  $|r_t|$ .
  4. Testați  $H_0 : \delta = 1$  pentru  $x_t$  cu  $z = (\hat{\delta} - 1)/\text{SE}$ , din estimarea nerotunjită.
- ▣ **Raportați:** graficul ADF–corelație,  $d^*$ , un tabel cu cele patru estimări și CI,  $z$  și  $p$
- ▣ **Interpretare:** este seria FFD la  $d^*$  staționară? Unde se află memoria Bitcoin? Notebook: secțiunea B1

## B1 [Rezolvat]: rezolvare




- ADF:  $-1,21$  ( $d = 0$ ),  $-2,32$  (0,05),  $-2,24$  (0,10),  $-2,39$  (0,15),  $-2,85$  (0,20),  $-3,38$  (0,25); valoarea de 5%  $-2,86$ ;  $d^* = 0,25$ , corelația 0,955; traiectoria nu e monotonă în  $d$
- ELW log-preț 1,065 [1,000; 1,129] ( $m = 232$ ); FFD la  $d^*$  0,814 [0,747; 0,880]; LW randamente 0,063  $[-0,002; 0,127]$ ;  $|r_t|$  0,353 [0,289; 0,417]
- $z = (1,0647 - 1)/0,0328 = 1,97$ ,  $p$  bilateral = 0,049: o respingere la limită spre  $\delta > 1$  (bule), niciodată spre staționaritate
- Interpretare: seria FFD are  $\hat{\delta} \approx 1 - d$  în banda de frecvențe, iar CI-ul ei este mult peste  $\frac{1}{2}$ : nu este staționară; memoria lungă a Bitcoin este în volatilitate,  $|r_t|$

## B10 [Rezolvat]: căutare în grilă, DSR și numărul efectiv de încercări — cerința

- ▣ **Întrebarea:** după căutarea printre 120 de reguli de medii mobile pe Bitcoin, depășește cea mai bună dintre ele norocul?
- ▣ **Reguli:** fereastra rapidă  $f \in \{5, 10, \dots, 55\}$ , lentă  $s \in \{20, 40, \dots, 240\}$ ,  $s > f$ :  $N = 120$ ; semnalul din ziua  $t$ :  $1\{\bar{x}_{f,t} > \bar{x}_{s,t}\}$  (medii ale log-prețului), deținut în ziua  $t + 1$ :  $r_{t+1}^{(f,s)} = \text{semnal}_t \cdot r_{t+1}$ ; long/numerar, fără costuri, rata fără risc 0
- ▣ **Date:** start comun în prima zi în care fiecare regulă are semnal, 15 mai 2015, până la 18 sep. 2026:  $T = 4.145$  zile,  $q = 365$
- ▣ **Sarcini**
  1. Construiți matricea de randamente  $T \times 120$ ; alegeți regula cu cel mai bun SR; raportați SR, asimetria, kurtosis și PSR(0) (Bailey & López de Prado (2012)).
  2. Din matricea de corelație  $120 \times 120$ : valorile proprii, numărul care atinge 95% din varianță și  $\hat{N} = \bar{\rho} + (1 - \bar{\rho})N$ , cu  $\bar{\rho}$  corelația medie din afara diagonalei (euristici, nu teoreme).
  3. Calculați  $SR_0$  și DSR (Bailey & López de Prado (2014)) pentru  $N = 120$ ,  $\hat{N}$  și numărul de la 95%, cu  $V = 1/T$ .
- ▣ **Raportați:** o hartă a rapoartelor Sharpe cu regula aleasă, graficul valorilor proprii, un tabel DSR
- ▣ **Interpretare:** ce  $N$  și ce  $V$  ați raporta unui comitet de investiții? Notebook: secțiunea B10

## B10 [Rezolvat]: rezolvare



| $V = 1/T$    | $N = 120$ | $\hat{N} = 15,9$ | $N = 4$ |
|--------------|-----------|------------------|---------|
| $SR_0$ (an.) | 0,77      | 0,53             | 0,31    |
| DSR          | 0,922     | 0,987            | 0,998   |

- Cea mai bună regulă (5, 40): SR 1,19 anualizat (buy-and-hold 0,78); asimetrie 0,13, kurtosis 12,8;  $PSR(0) = 1,000$
- $\lambda_1 = 105,5$  explică 87,9%; 4 valori proprii ating 95%;  $\bar{\rho} = 0,875$ ,  $\hat{N} = 15,9$
- Interpretare: a număra 120 de încercări corelate ca independente deflătează prea mult; DSR testează “mai bine decât norocul”, nu “mai bine decât buy-and-hold” (B13), iar câștigătoarea a fost aleasă pe tot eșantionul: o afirmație cere o regulă fixată și un eșantion de verificare neatins (cursul, grila Bitcoin)

## Pachetele de extindere: de ce are nevoie fiecare

| Pachet                          | Exerciții                                          | Condiții                                        |
|---------------------------------|----------------------------------------------------|-------------------------------------------------|
| 1. Memorie                      | A2, B2                                             | A1, B1                                          |
| 2. Etichete                     | A3 extins [Rezolvat], A4, B4                       | A3, B3                                          |
| 3. Validare și leakage          | A8, B6                                             | A7, B5, cadrul de modelare                      |
| 4. Inferență predictivă         | A9 [Rezolvat], A10, B7c [Rezolvat], B12 [Rezolvat] | B7a, B7b, B8                                    |
| 5. Strategii și selecție        | A5 extins [Rezolvat], A6, B9 [Rezolvat], B11, B13  | A5, B10                                         |
| 6. Inferență cu multe controale | B14                                                | exemplul din curs (VIX)                         |
| 7. Proiecte                     | C1, C3                                             | Capitolul 14 (C1); studiul de caz din curs (C3) |

- Fiecare exercițiu are secțiunea lui în notebook, cu aceeași etichetă; rezolvați-le în ordine, în cadrul unui pachet
- C1 și C3 sînt puncte de plecare posibile pentru proiectul de echipă

## A2 [Propus]: lungimea ferestrei și respingerile ADF prea dese — cerința

- ▣ **Model:** A1 [Rezolvat]
- ▣ **Întrebarea:** cît de des respinge ADF rădăcina unitară în seria FFD a unui mers aleator pur?
- ▣ **Simulare** (`rng = default_rng(42)`): pentru  $d \in \{0, 3, 0, 5\}$  și fiecare dintre 500 de traiectorii, calculați  $K$ , extrageți  $T + K$  inovații  $\varepsilon_s \sim N(0, 1)$  cu  $T = 2.500$ , puneți  $X_t = \sum_{s \leq t} \varepsilon_s$  ( $X$  pornește de la prima extragere), aplicați filtrul finit și păstrați exact  $T$  valori; apoi repetați cu  $d = 0,25$  și fără filtru (control)
- ▣ **Sarcini**
  1. Rulați `adfuller(f, maxlag=1, regression='c', autolag=None)` pe fiecare traiectorie și notați respingerile la 5%.
  2. Pe aceleași traiectorii, rulați testul cu lag-uri alese prin AIC (`autolag='AIC'`).
  3. Raportați fiecare frecvență de respingere cu eroarea ei Monte Carlo  $\sqrt{\hat{p}(1 - \hat{p})/500}$ .
- ▣ **Interpretare:** fiecare traiectorie este  $I(1)$ : de ce confundă un ADF cu un lag un mers aleator scalat cu o serie staționară? Ce  $d$  ar face staționar un preț  $I(1)$ ? Notebook: secțiunea A2

## B2 [Propus]: memoria Ether, o capcană — cerința

- ▣ **Model:** B1 [Rezolvat]
- ▣ **Întrebarea:** cât de robustă este regula ADF minimă pe un activ care a crescut de circa 1.000 de ori?
- ▣ **Date:** log-închideri ETH-USD; trei specificații, fiecare cu scanarea completă a grilei  $d \in \{0; 0,05; \dots; 1\}$  și un lag ADF

| Rînd | Eșantion                                | Termeni deterministici | Valoarea critică 5% |
|------|-----------------------------------------|------------------------|---------------------|
| 1    | 2015-08-07 – 2026-09-18 ( $n = 4.061$ ) | constantă              | −2,86               |
| 2    | 2015-08-07 – 2026-09-18                 | constantă + trend      | −3,41               |
| 3    | 2018-01-01 – 2026-09-18 ( $n = 3.183$ ) | constantă              | −2,86               |

- ▣ **Sarcini:** (1) raportați  $d^*$  și valorile ADF la  $d = 0$  și 0,05 pentru fiecare rînd; (2) ELW cu CI 95% pentru log-preț pe rîndurile 1 și 3; (3) LW pentru  $|r_t|$  pe tot eșantionul
- ▣ **Interpretare:** ce  $d$  ați folosi într-un model și de ce? Notebook: secțiunea B2

## A3 extins [Rezolvat]: probabilități de atingere — cerința

- ▣ **Întrebarea:** ce proporție de evenimente ar trebui să se încheie la bariera verticală dacă prețurile ar fi o mișcare browniană?
- ▣ **Cadru:** log-prețul  $\sigma W_t$ ,  $W_t$  o mișcare browniană standard (fără tendință), barierele  $+a = pt \sigma \sqrt{h}$  și  $-b = -sl \sigma \sqrt{h}$ ;  $\tau$  = primul moment în care una este atinsă; martingalele  $W_t$  și  $W_t^2 - t$ ; moment de oprire  $\tau$  cu  $\mathbb{E}[\tau] < \infty$  (Karatzas & Shreve (1998))
- ▣ **Sarcini**
  1. Fără barieră verticală, derivați  $P(\text{sus prima})$  și  $\mathbb{E}[\tau]$  prin oprire opțională.
  2. Pentru  $pt = sl = 1$  și  $h = 10$ , calculați  $P(\tau > h)$  cu monitorizare continuă, cu
 
$$P(\tau > h) = \frac{4}{\pi} \sum_{n \geq 0} \frac{(-1)^n}{2n+1} e^{-(2n+1)^2 \pi^2 / 8}.$$
  3. Aproximați monitorizarea zilnică mutînd fiecare barieră în afară cu  $0,5826 \sigma$  (Broadie, Glasserman & Kou (1997)); apoi simulați 400.000 de traiectorii de 10 pași zilnici gaussieni (seed 42) și comparați.
- ▣ **Interpretare:** B3 găsește 59,0% ieșiri verticale pe Bitcoin: ce parte din diferența față de valoarea browniană ține de monitorizare și ce parte de date?

## A3 extins [Rezolvat]: rezolvare

1.  $W_t$  este martingală:  $0 = p a - (1 - p) b \Rightarrow p = \frac{b}{a+b} = \frac{sl}{pt+sl}$ ;  $\sigma^2 W_t^2 - \sigma^2 t$  este martingală:  
 $\sigma^2 \mathbb{E}[\tau] = p a^2 + (1 - p) b^2 = ab \Rightarrow \mathbb{E}[\tau] = pt \cdot sl \cdot h \text{ zile}$
  2. Monitorizare continuă, exact:  $P(\tau > h) = 1,2732 \cdot 0,2912 - \dots = 0,371$
  3. Monitorizare zilnică, aproximativ:  $c = 1 + 0,5826/\sqrt{10} = 1,184$ , înlocuind  $\pi^2/8$  cu  $\pi^2/(8c^2)$  obținem 0,528; simulat cu pași zilnici: 0,517 (SE 0,001)
- Interpretare: monitorizarea discretă explică cea mai mare parte a diferenței dintre 37% și 59%; cele 7 puncte rămase pot proveni din cozile groase, grupările de volatilitate și eroarea volatilității EWMA, pe care această comparație nu le separă

## A4 [Propus]: bariere asimetrice — cerința

▣ **Model:** A3 și A3 extins [Rezolvat]

▣ **Date de intrare:**  $P_{t_0} = 50$ ,  $\sigma_{t_0} = 2\%$ ,  $h = 4$ ,  $pt = 2$ ,  $sl = 1$ ; traiectoriile (i) 50; 51,5; 53,0; 49,5; 47,9 și (ii) 50; 52,0; 54,5; 53,0; 51,0

▣ **Sarcini**

1. Calculați ambele bariere, desenați-le pe cele două traiectorii și etichetați fiecare traiectorie.
2. Opțional (tendență): pentru  $X_t = \mu t + \sigma W_t$  fără barieră verticală,  $s(x) = e^{-2\mu x/\sigma^2}$  rezolvă  $\frac{\sigma^2}{2}s'' + \mu s' = 0$ ,  
deci  $s(X_t)$  este martingală; derivați  $P(\text{sus prima}) = \frac{e^{2\mu b/\sigma^2} - 1}{e^{2\mu b/\sigma^2} - e^{-2\mu a/\sigma^2}}$  și evaluați-o pentru  $\sigma = 3\%$ ,  
 $\mu = 0,1\%$  pe zi,  $h = 10$ .

▣ **Raportați:** barierele, etichetele, formula și valoarea ei

▣ **Interpretare:** formula nu are barieră verticală: ce traiectorii ar cenzura o barieră verticală la  $h$ ? Notebook: secțiunea A4

## B4 [Propus]: bariere asimetrice pe Bitcoin — cerința

- ▣ **Model:** B3 [Rezolvat] și A3 extins
- ▣ **Date:** evenimentele, volatilitatea EWMA și etichetarea din B3,  $h = 10$ ; variantele  $(pt, sl) = (2, 1)$  și  $(1, 2)$
- ▣ **Sarcini**
  1. Raportați ponderile ieșirilor, ponderea etichetelor +1 și durata medie de deținere pentru ambele variante.
  2. Calculați ponderea ieșirilor sus între ieșirile orizontale, sus/(sus + jos).
  3. Comparați-o cu  $sl/(pt + sl)$  (fără barieră verticală) și cu o simulare: 400.000 de traiectorii de 10 pași zilnici gaussieni, în unități de  $\sigma$ , bariere la  $pt\sqrt{10}$  și  $-sl\sqrt{10}$ , seed 42, tendință zero și tendința BTC  $\bar{r}/\hat{\sigma} = 0,034$  pe zi; dați SE a simulării.
- ▣ **Interpretare:** cum schimbă alegerea echilibrul claselor pe care îl vede un clasificator? Asimetria este o ipoteză de modelare, nu o regulă optimă de tranzacționare. Notebook: secțiunea B4

## A8 [Propus]: purjare cu etichete mai scurte — cerința

- ▣ **Model:** A7 [Rezolvat]
- ▣ **Date de intrare:** ca în A7, cu intervalele închise  $[i, \min(i + 2, 19)]$  ( $h = 2$ ), embargo  $e = 1$ , pliul de test  $\{12, \dots, 15\}$
- ▣ **Sarcini**
  1. Pe o axă a indicilor 0–19, completați un tabel cu coloanele purjate înainte, embargo, purjate după și reuniunea.
  2. Verificați numărătoarea cu formula din A7.
  3. Pliu interior cu  $n = 250$ ,  $K = 5$  ( $L = 50$ ),  $h = 20$ ,  $e = 1$ : calculați proporția pierdută; repetați cu  $K = 10$  ( $L = 25$ ).
- ▣ **Interpretare:** cât costă purjarea când etichetele sînt lungi și pliurile scurte și cum ați reacționa? Notebook: secțiunea A8

## B6 [Propus]: găsiți leakage-ul — cerința


- ▣ **Model:** B5 [Rezolvat] și C2
- ▣ **Date:** cadrul de modelare plus o a 12-a caracteristică, construită în notebook ca `ma11 = r.rolling(11, center=True).mean()`; RF cu 300 de arbori (nu 400 ca în B7a), frunza minimă 50, seed 42, 5-fold purjat; 4.181 de rînduri
- ▣ **Sarcini**
  1. Scrieți datele  $t - 5, \dots, t + 5$  care intră în `ma11` în ziua  $t$  și marcați-le pe cele din fereastra țintei  $t + 1, \dots, t + 5$ ; ordonați cele 12 caracteristici după MDI.
  2. Calculați corelația lui `ma11` și a mediei retrospective `r.rolling(11).mean()` cu randamentul pe 5 zile înainte.
  3. Raportați acuratețea și AUC pentru: 11 caracteristici + `ma11` centrată; 11 + retrospectivă; cele 11 de bază, pe aceleași rînduri, pliuri și setări.
- ▣ **Interpretare:** de ce nu poate purjarea să detecteze acest leakage? Dați un al doilea exemplu de informație din viitor într-un flux de caracteristici. Notebook: secțiunea B6

## A9 [Rezolvat]: AUC pas cu pas — cerința

- ▣ **Întrebarea:** ce măsoară AUC și cât de incert este cu șase observații?
- ▣ **Date de intrare:** scorurile a 3 pozitive (0,80; 0,55; 0,40) și 3 negative (0,60; 0,35; 0,20);  $U$  = numărul perechilor (pozitiv, negativ) ordonate corect,  $A = U/9$ ; SE Hanley–McNeil ([Hanley & McNeil \(1982\)](#)):  

$$SE^2 = \frac{A(1-A) + (n_1-1)(Q_1-A^2) + (n_0-1)(Q_2-A^2)}{n_1 n_0}, \quad Q_1 = \frac{A}{2-A}, \quad Q_2 = \frac{2A^2}{1+A}$$
- ▣ **Sarcini**
  1. Completați grila de comparație  $3 \times 3$  (este pozitivul peste negativ?) și calculați  $U$  și  $A$ .
  2. Desenați curba ROC în trepte și verificați că aria ei este  $A$ .
  3. Calculați SE și statistica Wald  $z = (A - 0,5)/SE$ , bilateral.
  4. Enumerați cele 20 de moduri de a eticheta 3 dintre cele 6 scoruri ca pozitive, calculați  $U$  pentru fiecare și  $P(U \geq 7)$  exact.
- ▣ **Interpretare:** ce ipoteză a SE nu mai este îndeplinită pentru etichete suprapuse pe 5 zile? Notebook: secțiunea A9

## A9 [Rezolvat]: rezolvare



- 0,80 bate 3 negative, 0,55 bate 2, 0,40 bate 2:  $U = 7$ ,  $A = 0,778$ ; (2) aria curbei în trepte este  $\frac{1}{3} \cdot \frac{1}{3} + \frac{2}{3} \cdot 1 = \frac{7}{9}$
- $Q_1 = 0,636$ ,  $Q_2 = 0,681$ ,  $SE = 0,207$ ,  $z = 1,34$ ,  $p = 0,18$  (asimptotic, nesigur cu șase puncte)
- Exact:  $P(U \geq 7) = 4/20 = 0,20$ ,  $p$  bilateral = 0,40 cu etichete interschimbabile: șase observații nu pot separa abilitatea de noroc
- ☐ Ambele SE presupun observații independente; etichetele suprapuse au randamente comune, deci eșantionul efectiv este mai mic: B7b folosește în schimb un bootstrap pe blocuri


## A10 [Propus]: AUC ca statistică U și varianța DeLong — cerința

- ▣ **Model:** A9 [Rezolvat]
- ▣ **Date de intrare:** 4 pozitive (0,70; 0,62; 0,48; 0,45), 4 negative (0,66; 0,50; 0,40; 0,30); nucleul  $\psi(s_i, s_j) = 1\{s_i > s_j\} + \frac{1}{2}1\{s_i = s_j\}$
- ▣ **Sarcini**
  1. Completați grila  $4 \times 4$  a lui  $\psi$ ; calculați  $U$ , AUC și SE Hanley–McNeil.
  2. Mediile pe rînduri  $V_{10}(i)$  și pe coloane  $V_{01}(j)$  ale grilei (valori de plasare); varianțele lor de selecție  $S_{10}$ ,  $S_{01}$ , cu numitorul  $n - 1$ .
  3.  $SE\ DeLong = \sqrt{S_{10}/n_1 + S_{01}/n_0}$  (DeLong, DeLong & Clarke-Pearson (1988)).
  4. Demonstrație opțională: prin descompunerea Hoeffding, AUC este asimptotic suma a două medii independente ale valorilor de plasare.
- ▣ **Interpretare:** argumentul este asimptotic, nu o garanție exactă pentru eșantioane mici: ce înseamnă asta cu 8 scoruri? Notebook: secțiunea A10

## B7c [Rezolvat]: concordă măsurile de importanță? — cerința

- ▣ **Întrebarea:** ordonează măsurile de importanță în eșantion și în afara lui cele 11 caracteristici la fel?
- ▣ **Date:** cadrul de modelare, cu o împărțire cronologică separată: RF (400 de arbori, frunza minimă 50) estimat pe primele 70% (pînă la 8 apr. 2023), evaluat după o pauză de 5 + 41 de zile, din 24 mai 2023; o singură împărțire, pentru că importanțele cer un singur model estimat
- ▣ **Sarcini**
  1. MDI din pădurea estimată; MDA ca scăderea AUC de test cînd o caracteristică este permutată (10 repetări); media  $|\text{SHAP}|$  pe 300 de zile de test ([Lundberg & Lee \(2017\)](#)).
  2. Corelațiile de rang Spearman între cele trei măsuri.
- ▣ **Interpretare:** ce înseamnă un MDA negativ și de ce estompează caracteristicile corelate toate cele trei măsuri?  
Notebook: secțiunea B7

## B7c [Rezolvat]: rezolvare




- MDI pune primele vol\_60, vol\_20, mom\_120; MDA este negativ pentru ambele caracteristici de volatilitate și cel mai mare pentru rsi\_14 (0,026)
- Spearman: MDI-SHAP 0,75, MDI-MDA -0,42, MDA-SHAP -0,10: ordonările în eșantion și în afara lui nu concordă
- Interpretare: un MDA negativ înseamnă că, pe date noi, caracteristica permutată dă un scor mai bun decât cea reală: un semn de overfitting, în limita zgomotului de eșantionare; caracteristicile corelate își împart și își diluează importanța, iar permutarea extrapolează în afara datelor

## B12 [Rezolvat]: Pesaran–Timmermann și Clark–West — cerința

- ▣ **Întrebarea:** conțin semnele precise informație și adaugă caracteristicile informație unei prognoze constante?
- ▣ **Date:** probabilitățile salvate în B7a și constanta din B8;  $x_t = 1\{\hat{p}_t > 0,5\}$ . Precizare înainte de a începe: Clark–West ([Clark & West \(2007\)](#)) este derivat pentru modele liniare imbricate și prognoze reale în afara eșantionului; pe probabilitățile unui logit penalizat din CV purjat agregat este o corecție aproximativă, descriptivă
- ▣ **Sarcini**
  1. Pentru fiecare model:  $\hat{P}$  = proporția semnelor corecte,  $\hat{P}^* = \hat{p}_y \hat{p}_x + (1 - \hat{p}_y)(1 - \hat{p}_x)$  și  $PT = (\hat{P} - \hat{P}^*) / \sqrt{\hat{V}(\hat{P}) - \hat{V}(\hat{P}^*)}$  ([Pesaran & Timmermann \(1992\)](#); varianțele sînt în Anexa cursului).
  2. Statistica  $t$  a pantei în  $y_t = a + b x_t + u_t$  cu erori Newey–West (4 lag-uri), bilateral.
  3. Logit-L1 vs. constantă:  $f_t = (y_t - \hat{p}_{0,t})^2 - [(y_t - \hat{p}_{1,t})^2 - (\hat{p}_{0,t} - \hat{p}_{1,t})^2]$ ;  $CW = t$  HAC pentru  $\bar{f}$ , unilateral (pozitiv = caracteristicile ajută); DM pe pierderea Brier, bilateral.
- ▣ **Interpretare:** de ce pot DM și Clark–West să nu fie de acord la modele imbricate? Notebook: secțiunea B12

## B12 [Rezolvat]: rezolvare



|          | Prezis sus | $\hat{P}$ | $\hat{P}^*$ | PT   | $t_{HAC}$ |
|----------|------------|-----------|-------------|------|-----------|
| Logit-L1 | 99,6%      | 0,548     | 0,548       | 0,89 | 0,82      |
| RF       | 70,3%      | 0,542     | 0,519       | 3,20 | 2,21      |
| GB       | 68,5%      | 0,522     | 0,518       | 0,65 | 0,45      |

- RF: acuratețea de 54,2% este sub “mereu în sus” (54,8%), dar semnele lui nu sînt independente de rezultat:  $PT = 3,20$ ; cu erori HAC  $t = 2,21$ ,  $p = 0,03$
- Clark–West, Logit-L1 vs. constantă:  $t = -0,56$ ,  $p$  unilateral = 0,71; DM pe Brier:  $t = 1,37$  (pozitiv = logit mai slab),  $p = 0,17$
- DM întreabă dacă logit-ul *estimat* prognozează mai bine, iar zgomotul de estimare îl face să piardă sub ipoteza nulă imbricată; CW adaugă înapoi  $(\hat{p}_0 - \hat{p}_1)^2$  și întreabă dacă coeficienții populației sînt zero; aici niciunul nu găsește semnal
- Dependența semnelor (PT) nu înseamnă a bate reperul clasei majoritare și nici un log loss mai bun (B8)

## A5 extins [Rezolvat]: varianța raportului Sharpe — cerința

- ▣ **Întrebarea:** de unde vine numitorul  $D$  din A5?
- ▣ **Cadru:**  $T$  randamente i.i.d. cu media  $\mu$ , varianța  $\sigma^2$ , asimetria  $\gamma_3$ , kurtosis obișnuit  $\gamma_4$ ;  
 $SR = \mu/\sigma = g(m_1, m_2) = m_1/\sqrt{m_2 - m_1^2}$ , cu  $m_j = \mathbb{E}[r^j]$
- ▣ **Sarcini**
  1. Calculați gradientul  $\nabla g$ .
  2. Calculați  $\text{Var}(r)$ ,  $\text{Cov}(r, r^2)$  și  $\text{Var}(r^2)$  în funcție de  $\mu, \sigma, \gamma_3, \gamma_4$ .
  3. Arătați că  $T \text{Var}(\widehat{SR}) \approx \nabla g^\top \Sigma \nabla g = 1 - \gamma_3 SR + \frac{\gamma_4 - 1}{4} SR^2$  (Lo (2002)).
- ▣ **Interpretare:** ce moment face ca o strategie cu asimetrie negativă să pară mai precisă decît este?

## A5 extins [Rezolvat]: rezolvare

1.  $\nabla g = \left( \frac{1}{\sigma} + \frac{\mu^2}{\sigma^3}, -\frac{\mu}{2\sigma^3} \right)$
  2.  $\text{Var}(r) = \sigma^2$ ,  $\text{Cov}(r, r^2) = \sigma^3\gamma_3 + 2\mu\sigma^2$ ,  $\text{Var}(r^2) = \sigma^4(\gamma_4 - 1) + 4\mu\sigma^3\gamma_3 + 4\mu^2\sigma^2$
  3. În  $\nabla g^\top \Sigma \nabla g$  termenii în  $\mu^2/\sigma^2$  se reduc și rămâne  $1 - \gamma_3 SR + \frac{\gamma_4 - 1}{4} SR^2$ ; pentru distribuția Normală ( $\gamma_3 = 0$ ,  $\gamma_4 = 3$ )  $1 + \frac{1}{2} SR^2$
- Interpretare: cu  $SR > 0$ , asimetria negativă adaugă  $|\gamma_3|SR$  la varianță, iar cozile groase adaugă  $\frac{\gamma_4 - 3}{4} SR^2$ ; ignorarea lor subestimează SE; A5 a folosit  $\gamma_3 = -0,4$ ,  $\gamma_4 = 5$


## A6 [Propus]: DSR pe un eșantion mai scurt și constanta Gumbel — cerința

- ▣ **Model:** A5 și A5 extins [Rezolvat]
- ▣ **Date de intrare:**  $\widehat{SR}_{an} = 1,5$ ,  $T = 504$  randamente zilnice ( $q = 252$ ),  $\hat{\gamma}_3 = -0,2$ ,  $\hat{\gamma}_4 = 6$ ,  $N = 20$  încercări independente,  $V = 1/T$ ; constanta lui Euler  $\gamma_E = 0,5772$  (nu asimetria)
- ▣ **Sarcini**
  1. Completați fișa din A5:  $\widehat{SR}$ ,  $D$ ,  $PSR(0)$ ,  $SR_0$  (zilnic și anualizat), DSR.
  2. Opțional: cu parametrul de poziție  $b_N = \Phi^{-1}(1 - \frac{1}{N})$  și scala  $a_N = \Phi^{-1}(1 - \frac{1}{N_e}) - b_N$ ,  $\max_n Z_n$  este aproximativ Gumbel; arătați că media lui este  $(1 - \gamma_E)b_N + \gamma_E\Phi^{-1}(1 - \frac{1}{N_e})$ .
  3. Opțional: verificați prin simulare pentru  $N = 100$ , 20.000 de extrageri, seed 42, și desenați distribuția.
- ▣ **Interpretare:** este dovada mai puternică decât în A5 și trece de 0,95? Notebook: secțiunea A6

## B9 [Rezolvat]: meta-etichetarea unei reguli de medii mobile — cerința

- ▣ **Întrebarea:** poate un clasificator să spună când merită urmată o regulă simplă de trend?
- ▣ **Direcția primară:**  $s_t = \text{sign}(MA_{20}(P)_t - MA_{50}(P)_t)$  pe prețuri, o tranzacție candidată în fiecare zi eligibilă (o direcție zilnică permanentă, nu doar la încrucișări); ieșire prin cele trei bariere  $pt = sl = 1$ ,  $h = 10$ ; meta-eticheta brută  $1\{s_t \cdot r_{t_0, t_1} > 0\}$  (López de Prado (2018))
- ▣ **Modelul secundar:** RF (400 de arbori, frunza minimă 50, ponderi echilibrate ale claselor) pe cele 11 caracteristici plus  $s_t$ ; antrenare pe primele 60% din 4.174 de evenimente (pînă la 9 feb. 2022), pauză 10 zile, test 20 feb. 2022 – 6 sep. 2026 (1.660 de tranzacții)
- ▣ **Sarcini:** (1) matricea de confuzie pentru “întrăm în tranzacție dacă  $\hat{p} > 0,5$ ”; (2) precizia, recall-ul, F1 înainte (toate tranzacțiile) și după; (3) randamentul brut pe tranzacție, păstrate vs. sărite
- ▣ **Interpretare:** tranzacțiile se suprapun: acesta nu este un backtest de portofoliu; ce ar adăuga o regulă de alocare a capitalului și costurile? Notebook: secțiunea B9

## B9 [Rezolvat]: rezolvare



1. Executate: 426 câștigătoare, 398 pierzătoare; sărite: 362 câștigătoare, 474 pierzătoare (824 din 1.660 păstrate, 49,6%)
  2. Înainte: precizie 0,475, recall 1 (fiecare câștigătoare este executată), F1 0,644; după: 0,517; 0,541; 0,529
  3. Randamentul logaritmic brut pe tranzacție: toate  $-0,27\%$ , păstrate  $+0,19\%$ , sărite  $-0,73\%$
- ☐ Interpretare: filtrarea crește precizia și randamentul pe tranzacție, iar F1 scade; pașii următori sînt un test bootstrap pe blocuri al acestui randament, costurile, o regulă de alocare pentru tranzacțiile suprapuse și un DSR pe toate variantele de meta-model încercate

## B11 [Propus]: probabilitatea de overfitting a backtestului — cerința

- ▣ **Model:** B10 [Rezolvat]; slide-ul despre PBO din curs
- ▣ **Date:** matricea de randamente  $4.145 \times 120$  din B10, împărțită în  $S = 16$  blocuri contigue cu `np.array_split` (un bloc de 260 de zile, cincisprezece de 259) ([Bailey, Borwein, López de Prado & Zhu \(2017\)](#))
- ▣ **Exercițiu pregător:** faceți pașii de mai jos pas cu pas pentru 4 strategii și 4 blocuri
- ▣ **Sarcini**
  1. Pentru fiecare dintre cele  $\binom{16}{8} = 12.870$  alegeri de 8 blocuri în eșantion, alegeți regula cu cel mai bun SR în eșantion.
  2. Ordonăți crescător toate cele 120 de reguli în afara eșantionului (ranguri medii la egalitate),  $\omega = \text{rang}/(N + 1)$ ,  $\lambda = \ln \frac{\omega}{1-\omega}$ .
  3. Raportați  $\text{PBO} = P(\lambda \leq 0)$ ,  $\lambda$  median, SR median IS și OOS al câștigătorului, proporția cu SR OOS  $< 0$  și histograma lui  $\lambda$ .
- ▣ **Interpretare:** PBO este proporția câștigătorilor selectați aflați la sau sub mediana OOS, nu probabilitatea de a pierde bani; este grila afectată de overfitting? Notebook: secțiunea B11

## B13 [Propus]: Reality Check, SPA și StepM pe cele 120 de reguli — cerința

- **Model:** B10 [Rezolvat]; funcții disponibile: `stationary_bootstrap_index` și `snooping_tests` (notebook, secțiunea B13)
- **Ipoteza nulă:**  $H_0 : \max_k \mathbb{E}[d_{k,t}] \leq 0$  cu  $d_{k,t} = r_{k,t} - r_{0,t}$ ; repere numerar ( $r_0 = 0$ ) și buy-and-hold ( $r_0 = r_t$ ); aceste teste compară randamentele *medii*, DSR privește rapoartele Sharpe
- **Bootstrap** (Politis & Romano (1994)): un singur șir de indici pe replică, aplicat tuturor coloanelor (zile întregi), bloc mediu de 20 de zile ( $q = 1/20$ ), 2.000 de replici, seed 42;  $\hat{\omega}_k = \sqrt{n}$ . abaterea standard bootstrap a lui  $\bar{d}_k$
- **Sarcini**
  1. RC (White (2000)):  $p = \text{proportia replicilor cu } \max_k \sqrt{n}(\bar{d}_k^* - \bar{d}_k) \geq \max_k \sqrt{n} \bar{d}_k$ .
  2. SPA (Hansen (2005)): studentizat, concentrînd doar regulile cu  $t_k \geq -\sqrt{2 \ln \ln n}$ ; StepM (Romano & Wolf (2005)) la 5%: respingem fiecare regulă peste cuantila de 95% a maximumului pe regulile active, repetăm pînă nu mai respingem.
  3. Raportați pe fiecare reper: cea mai mare medie studentizată, ambele  $p$ -valori, numărul ipotezelor nule respinse; desenați distribuția bootstrap a maximumului.
- **Interpretare:** ce metodă tratează încercările corelate fără să aleagă  $N$ ? Bate vreo regulă deținerea Bitcoin?

## B14 [Propus]: selecție dublă: prezice VIX Bitcoin? — cerința

- ▣ **Model:** exemplul din curs “Prezice VIX randamentele S&P 500?”
- ▣ **Precizare:** penalizarea plug-in presupune scoruri independente; cu rezultate suprapuse pe 5 zile, intervalul de mai jos este o aproximare ilustrativă, nu un CI de 95% validat
- ▣ **Date:** cadrul de modelare ( $n = 4.181$ );  $y_t$  = randamentul log BTC pe 5 zile înainte, în bp;  $d_t$  = log VIX la închiderea din aceeași dată calendaristică, reportat peste weekenduri și sărbătorile din SUA (ultima închidere cunoscută la închiderea BTC), standardizat; controale: cele 11 caracteristici, pătratele și produsele lor două câte două ( $p = 77$ ), standardizate
- ▣ **Penalizarea (Belloni, Chernozhukov & Hansen (2014)):**  $\min_{\beta} \frac{1}{n} \sum_t (y_t - \mathbf{x}_t^\top \beta)^2 + \frac{\lambda}{n} \sum_j \hat{\psi}_j |\beta_j|$ ,  
 $\lambda = 2c\sqrt{n} \Phi^{-1}(1 - \gamma/(2p))$ ,  $c = 1,1$ ,  $\gamma = 0,1/\ln n$ , ponderile  $\hat{\psi}_j$  iterate; dată ca `rlasso`
- ▣ **Sarcini:** (1) LASSO pentru  $y_t$  pe  $(d_t, \mathbf{x}_t)$ : este păstrat VIX? (2)  $\hat{S}_y$  și  $\hat{S}_d$ ; (3) OLS pentru  $y_t$  pe  $d_t$  și  $\mathbf{x}_{\hat{S}_y \cup \hat{S}_d}$  cu erori HAC (4 lag-uri):  $\hat{\theta}$ , SE, interval; plus OLS doar cu VIX și cu toate cele 77 de controale
- ▣ **Interpretare:** de ce nu dă LASSO-ul simplu o inferență validă? Citiți  $\hat{\theta}$  ca un coeficient predictiv, nu ca o primă de frică cauzală. Notebook: secțiunea B14

## C1 [Propus]: bate un model fundațional boosting-ul? — descrierea proiectului

- ▣ **Întrebarea:** prognozează un model fundațional pentru serii de timp din [Capitolul 14](#), folosit zero-shot, direcția Bitcoin pe 5 zile mai bine decât gradient boosting și o constantă?
- ▣ **Protocol** (proiect de echipă, notat după protocol și dovezi, nu după semnul rezultatului)
  1. Numiți modelul și versiunea, data-limită documentată a preantrenării și testați doar pe date ulterioare; altfel declarați contaminarea ca limită.
  2. Prognozați direct distribuția randamentului pe 5 zile (nu cuantile zilnice însumate);  $P(r_{t,t+5} > 0)$  prin interpolarea liniară a funcției de repartiție predictive în 0, cu tratarea cozilor declarată.
  3. Reestimați gradient boosting și constanta la fiecare moment pe o fereastră mobilă fixă (de ex. 3 ani); log loss pe aceleași date; testul Giacomini–White ([Giacomini & White \(2006\)](#)) cu erori HAC; un grafic comparativ.
  4. Opțional: o regulă long/numerar pentru  $P(\text{sus}) > 0,5$  cu costuri și DSR peste toate configurațiile și prompturile încercate.
- ▣ **Livrabil:** un folder Quantlet (cod, `Metainfo.txt`, un grafic) și un slide cu concluzia și principala limită

### C3 [Propus]: un SDF fără arbitraj pe decile — descrierea proiectului (1/2)

- ▣ **Întrebarea:** întrece un factor stochastic de actualizare (SDF) liniar fără arbitraj, pe portofolii sortate după caracteristici, portofoliile tangente Fama–French ([Fama & French \(2015\)](#)) în afara eșantionului, ca în studiul de caz din curs ([Chen, Pelger & Zhu \(2024\)](#))?
- ▣ **Date:** portofoliile decile ponderate după valoare ale celor 15 sortări univariate din [Kenneth French Data Library](#) (mărime, valoare contabilă/de piață, profitabilitate operațională, investiții, câștig/preț, flux de numerar/preț, randamentul dividendului, momentum, reversal pe termen scurt și lung, accruals, beta de piață, emisiuni nete de acțiuni, varianță, varianță reziduală), lunar, minus dobânda pe o lună; fișierele de factori FF3 și FF5
- ▣ **Componente:** pentru fiecare caracteristică, media decilelor 1–5 și a decilelor 6–10: 30 de factori  $\tilde{F}_{t+1}$ ; doar lunile cu toate cele 30 de componente și FF5, fără imputare; salvați panelul fixat, cu data descărcării
- ▣ **Limită:** jumătățile decilelor ponderate după valoare înlocuiesc componentele ponderate după rang ale celor 46 de caracteristici pe acțiuni individuale: o extindere pe date de portofoliu, nu o replicare a GAN-ului la nivel de acțiune
- ▣ **Împărțire:** estimare pe 1967–1986, reglare pe 1987–1991, test pe 1992–2016 și din 2017 până la ultima lună

## C3 [Propus]: un SDF fără arbitraj pe decile — descrierea proiectului (2/2)

▣ **Model:** A5 (inferență pentru raportul Sharpe) și B12 (teste predictive) [Rezolvat]

▣ **Etape**

1. Reproduceți reperele FF3 și FF5: ponderile tangente  $w \propto \hat{\Sigma}^{-1} \hat{\mu}$  pe 1967–1986, SR lunar pe 1992–2016 cu CI 95% (Lo (2002)); comparați cu cursul (FF5 0,22, FF3 0,20).
2. Cu  $\mu =$  media lui  $\tilde{F}$  și  $Q =$  media lui  $\tilde{F}\tilde{F}^\top$  (un moment de ordinul doi, nu o covarianță) pe 1967–1986:  $\hat{\theta}_{LS} = Q^{-1}\mu$  (rezolvați sistemul, nu inversați),  $\hat{\theta}_{EN} = \arg \min_{\theta} \|\mu - Q\theta\|_2^2 + \lambda_2 \|\theta\|_2^2 + \lambda_1 \|\theta\|_1$  pe o grilă raportată, aleasă după SR pe 1987–1991.
3. Cu ponderile fixate: SR al lui  $F = \hat{\theta}^\top \tilde{F}$  pe ambele perioade de test; diferențe de SR pe perechi, pe lunile aliniate (metoda delta HAC sau bootstrap pe blocuri); DSR peste grilă.
4. Coeficienții  $\hat{\beta}_i = \overline{R_i^e F}$  pe 1967–1986; proiectați lunar randamentele de test pe  $\hat{\beta}$ ; variația explicată  $1 - \overline{\hat{e}^2} / (\overline{R^e})^2$  și  $R^2$  transversal pe caracteristică; un grafic cu randamentele medii realizate vs. implicate.

▣ **Interpretare:** de ce poate un SDF liniar fără arbitraj să întreaacă o rețea de prognoză (Chen, Pelger & Zhu (2024), Tabelul I)? Se menține rezultatul de după 2016 după corecția pentru configurațiile încercate?

## Bibliografie (1/5)

- ▣ Bailey, D.H., Borwein, J., López de Prado, M., Zhu, Q.J. (2017). The probability of backtest overfitting. *Journal of Computational Finance*, 20(4), 39–69.
- ▣ Bailey, D.H., López de Prado, M. (2012). The Sharpe ratio efficient frontier. *Journal of Risk*, 15(2), 3–44.
- ▣ Bailey, D.H., López de Prado, M. (2014). The deflated Sharpe ratio: correcting for selection bias, backtest overfitting and non-normality. *Journal of Portfolio Management*, 40(5), 94–107.
- ▣ Belloni, A., Chernozhukov, V., Hansen, C. (2014). Inference on treatment effects after selection among high-dimensional controls. *Review of Economic Studies*, 81(2), 608–650.
- ▣ Bergmeir, C., Hyndman, R.J., Koo, B. (2018). A note on the validity of cross-validation for evaluating autoregressive time series prediction. *Computational Statistics & Data Analysis*, 120, 70–83.
- ▣ Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32.
- ▣ Broadie, M., Glasserman, P., Kou, S. (1997). A continuity correction for discrete barrier options. *Mathematical Finance*, 7(4), 325–349.

## Bibliografie (2/5)

- ▣ Chen, L., Pelger, M., Zhu, J. (2024). Deep learning in asset pricing. *Management Science*, 70(2), 714–750.
- ▣ Clark, T.E., West, K.D. (2007). Approximately normal tests for equal predictive accuracy in nested models. *Journal of Econometrics*, 138(1), 291–311.
- ▣ DeLong, E.R., DeLong, D.M., Clarke-Pearson, D.L. (1988). Comparing the areas under two or more correlated receiver operating characteristic curves: a nonparametric approach. *Biometrics*, 44(3), 837–845.
- ▣ Dickey, D.A., Fuller, W.A. (1979). Distribution of the estimators for autoregressive time series with a unit root. *Journal of the American Statistical Association*, 74(366), 427–431.
- ▣ Diebold, F.X., Mariano, R.S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3), 253–263.
- ▣ Fama, E.F., French, K.R. (2015). A five-factor asset pricing model. *Journal of Financial Economics*, 116(1), 1–22.
- ▣ Friedman, J.H. (2001). Greedy function approximation: a gradient boosting machine. *Annals of Statistics*, 29(5), 1189–1232.
- ▣ Giacomini, R., White, H. (2006). Tests of conditional predictive ability. *Econometrica*, 74(6), 1545–1578.
- ▣ Gu, S., Kelly, B., Xiu, D. (2020). Empirical asset pricing via machine learning. *Review of Financial Studies*, 33(5), 2223–2273.

## Bibliografie (3/5)

- ▣ Hanley, J.A., McNeil, B.J. (1982). The meaning and use of the area under a receiver operating characteristic (ROC) curve. *Radiology*, 143(1), 29–36.
- ▣ Hansen, P.R. (2005). A test for superior predictive ability. *Journal of Business & Economic Statistics*, 23(4), 365–380.
- ▣ Harvey, C.R., Liu, Y., Zhu, H. (2016). ... and the cross-section of expected returns. *Review of Financial Studies*, 29(1), 5–68.
- ▣ Hosking, J.R.M. (1981). Fractional differencing. *Biometrika*, 68(1), 165–176.
- ▣ Karatzas, I., Shreve, S.E. (1998). *Brownian Motion and Stochastic Calculus*, 2nd ed. Springer.
- ▣ Künsch, H.R. (1989). The jackknife and the bootstrap for general stationary observations. *Annals of Statistics*, 17(3), 1217–1241.
- ▣ Lo, A.W. (2002). The statistics of Sharpe ratios. *Financial Analysts Journal*, 58(4), 36–52.

## Bibliografie (4/5)

- ▣ López de Prado, M. (2018). *Advances in Financial Machine Learning*. Wiley.
- ▣ Lundberg, S.M., Lee, S.-I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems*, 30.
- ▣ Newey, W.K., West, K.D. (1987). A simple, positive semi-definite, heteroskedasticity and autocorrelation consistent covariance matrix. *Econometrica*, 55(3), 703–708.
- ▣ Pesaran, M.H., Timmermann, A. (1992). A simple nonparametric test of predictive performance. *Journal of Business & Economic Statistics*, 10(4), 461–465.
- ▣ Politis, D.N., Romano, J.P. (1994). The stationary bootstrap. *Journal of the American Statistical Association*, 89(428), 1303–1313.
- ▣ Robinson, P.M. (1995). Gaussian semiparametric estimation of long range dependence. *Annals of Statistics*, 23(5), 1630–1661.
- ▣ Romano, J.P., Wolf, M. (2005). Stepwise multiple testing as formalized data snooping. *Econometrica*, 73(4), 1237–1282.

## Bibliografie (5/5)

- Shimotsu, K., Phillips, P.C.B. (2005). [Exact local Whittle estimation of fractional integration](#). *Annals of Statistics*, 33(4), 1890–1933.
- Tibshirani, R. (1996). [Regression shrinkage and selection via the lasso](#). *Journal of the Royal Statistical Society B*, 58(1), 267–288.
- White, H. (2000). [A reality check for data snooping](#). *Econometrica*, 68(5), 1097–1126.