



Modelarea piețelor financiare

Seminarul 14: Deep learning și modele fundamentale pentru serii de timp — aplicații



Daniel Traian PELE

Drd. Antoaneta Amza, antoaneta.amza@csie.ase.ro

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognostic Economică

MSCA Digital Finance

Acronime folosite în acest material

- ▣ AI: Artificial Intelligence (inteligență artificială)
- ▣ AR: AutoRegressive (model) (model autoregresiv)
- ▣ BET: Bucharest Exchange Trading (index) (indicele de referință al Bursei de Valori București)
- ▣ BVB: Bursa de Valori București
- ▣ CI: Confidence Interval (interval de încredere)
- ▣ DM: Diebold–Mariano (test) (testul Diebold–Mariano de comparare a prognozelor)
- ▣ ES: Expected Shortfall (pierderea așteptată în coadă)
- ▣ FHS: Filtered Historical Simulation (simulare istorică filtrată)
- ▣ FZ0: Fissler–Ziegel loss, zero-homogeneous version (funcția de pierdere Fissler–Ziegel, varianta omogenă de grad zero)
- ▣ GARCH: Generalised AutoRegressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă generalizată)
- ▣ HAR: Heterogeneous AutoRegressive (model) (model autoregresiv heterogen)
- ▣ HS: Historical Simulation (simulare istorică)
- ▣ LSTM: Long Short-Term Memory (network) (rețea cu memorie pe termen lung și scurt)
- ▣ MCS: Model Confidence Set (mulțimea de modele de încredere)
- ▣ QLIKE: Quasi-LIKelihood (loss function) (funcția de pierdere de tip cvasi-verosimilitate)
- ▣ RNN: Recurrent Neural Network (rețea neuronală recurentă)
- ▣ RV: Realised Variance (varianța realizată)

Cuprins

Introducere

Formule de bază

Partea A: derivări cu cifre

Partea B: inferență pe prognoze

Partea C: întrebare deschisă și critica unui răspuns AI

Încheiere

Bibliografie

Obiectivele seminarului

La finalul seminarului puteți

- ▣ Număra parametrii unui LSTM și cuantifica cât de repede i se estompează memoria
- ▣ Tokeniza o serie ca Chronos și citi VaR și ES dintr-o grilă de cuantile
- ▣ Testa dacă un model de deep learning sau fundațional bate un reper puternic (DM, MCS, Kupiec, FZ0)
- ▣ Detecta efectele semințelor și scurgerea de informație din viitor

- ▣ Suport: Cursul 14 și Cursul 8 (backtesting); manualul [Franke, Härdle & Hafner \(2019\)](#)

Structura

- ▣ **Partea A:** opt derivări cu cifre (A1–A8)
- ▣ **Partea B:** opt exerciții pe calculator, cu inferență (B1–B8)
- ▣ **Partea C:** o întrebare deschisă, punct de plecare pentru proiectul de echipă (C1), și un răspuns AI de criticat (C2)

Cum lucrăm la acest seminar

- Problemele **[Rezolvat]** au rezolvarea completă; problemele **[Propus]** au doar cerința: rezolvările se discută la seminar
- Fiecare problemă propusă indică **modelul**: problema rezolvată care folosește aceeași tehnică
 - ▶ Fiecare exercițiu din Partea B se încheie cu întrebări de interpretare
- Numiți mereu reperul: zero pentru randamente, log-HAR pentru volatilitate, FHS pentru riscul de coadă
- Un model „nu semnificativ mai slab” nu este „la fel de bun”: întrebați-vă câtă putere a avut testul

Probleme rezolvate și propuse

Rezolvate: exemple lucrate în acest material

- ▣ Partea A: A1 (parametrii LSTM), A3 (memoria porții de uitare), A5 (tokenizarea), A7 (VaR și ES dintr-o grilă de cuantile)
- ▣ Partea B: B1 (randamente vs zero, S&P 500), B3 (volatilitate realizată vs log-HAR), B5 (VaR 1% și ES 2,5%, S&P 500), B7 (semințe)

Propuse: le rezolvați voi

- ▣ Partea A: A2 (model: A1), A4 (model: A3), A6 (model: A5), A8 (model: A7)
- ▣ Partea B: B2 (model: B1), B4 (model: B3), B6 (model: B5), B8 (model: B3)
- ▣ Partea C: C1, întrebare deschisă și sămânță de proiect; C2, critica unui răspuns AI (backtestul VaR al unui model fundațional)

Pregătire: mediul Python și datele

- ▣  **Deschide în Colab:** `capitol14_notebook_seminar.ipynb`
- ▣ Google Colab (recomandat) sau Python local ≥ 3.10 cu `torch`, `chronos-forecasting`, `timesfm`, `arch`, `pandas`, `scipy`
- ▣ Serii: S&P 500, Bitcoin, BET (închideri zilnice); bare de 5 minute ale SPY pentru varianța realizată; până la 18 septembrie 2026
- ▣ Prognoze: prognozele la o zi din Cursul 14 (context de 512 zile pentru modelele fundamentale; ferestre de 500 sau 1.000 de zile pentru modelele clasice)
- ▣ Randamente r_t în %, pierderi $L_t = -r_t$; $\text{VaR}_\alpha = -q_\alpha$, $\text{ES}_\alpha = -\frac{1}{\alpha} \int_0^\alpha q_u du$

Formule de bază (1/2): rețele și tokeni

- ▣ LSTM (Hochreiter & Schmidhuber (1997)): $c_t = f_t \odot c_{t-1} + i_t \odot g_t$, $h_t = o_t \odot \tanh(c_t)$; porți $\sigma(Wx_t + Uh_{t-1} + b) \in (0, 1)$
- ▣ Parametrii unui strat: $4(hd + h^2 + h)$ sau $4(hd + h^2 + 2h)$ cu doi vectori de deplasare (PyTorch)
- ▣ Memoria pe drumul stării celulei: $\partial c_T / \partial c_{T-k} = \prod_j f_{T-j}$; timpul de înjumătățire $k_{1/2} = \ln 0,5 / \ln f$
- ▣ Atenția (Vaswani et al. (2017)): $\text{softmax}(QK^\top / \sqrt{d_k}) V$
- ▣ Tokenii Chronos (Ansari et al. (2024)): $s = \frac{1}{\epsilon} \sum |x_t|$, $z_t = x_t/s$, indicele intervalului $j = \text{round}((z_t + 15)/\Delta)$, $\Delta = 30/4092$

Formule de bază (2/2): evaluare

- ▣ R^2 în afara eșantionului = $1 - \sum_t (r_t - \hat{r}_t)^2 / \sum_t r_t^2$ (reper: prognoza zero)
- ▣ Diebold–Mariano (Diebold & Mariano (1995)): $DM = \bar{d} / \sqrt{\widehat{LRV} / T}$, $d_t = L_t^A - L_t^B$, varianța pe termen lung Newey–West; negativ: A mai bun
- ▣ QLIKE (Patton (2011)): $RV_t / \hat{h}_t - \log(RV_t / \hat{h}_t) - 1$; HAR (Corsi (2009)): RV pe mediile ei zilnică, pe 5 zile și pe 22 de zile
- ▣ Kupiec (Kupiec (1995)): $LR_{uc} = -2[(T - x) \ln(1 - \alpha) + x \ln \alpha - (T - x) \ln(1 - \hat{\pi}) - x \ln \hat{\pi}] \sim \chi_1^2$
- ▣ FZ0 (Patton, Ziegel & Chen (2019)): $\frac{1}{\alpha \text{ES}} \mathbf{1}\{L > \text{VaR}\}(L - \text{VaR}) + \frac{\text{VaR}}{\text{ES}} + \log \text{ES} - 1$; MCS (Hansen, Lunde & Nason (2011)) la 90%

A1. Numărarea parametrilor unui LSTM [Rezolvat]

Cerință

- Un strat LSTM, dimensiunea intrării $d = 1$, starea ascunsă $h = 16$, strat de ieșire liniar
- Numărați parametrii cu o deplasare pe bloc, apoi ca în PyTorch (doi vectori de deplasare)
- Comparați cu un eșantion de antrenare de 4.000 de randamente zilnice

Rezolvare

- Pe bloc: $hd + h^2 + h = 16 + 256 + 16 = 288$; patru blocuri: 1 152
- PyTorch: $4(16 + 256 + 32) = 1\,216$; stratul de ieșire $h + 1 = 17$; total 1 233
- Circa 3 observații pe parametru: oprirea timpurie și weight decay nu sunt opționale

A2. Două straturi suprapuse și cinci intrări [Propus]

Rezolvarea se discută la seminar

Cerință

- Intrări: 5 variabile pe zi; două straturi LSTM cu $h = 32$; ieșire liniară
- Numărați toți parametrii (convenția PyTorch); al doilea strat primește $d = 32$
- Câți ani de date zilnice dau 3 observații pe parametru?
- Model: A1

A3. Cât de repede se estompează memoria? [Rezolvat]

Cerință

- RNN simplă, cazul scalar: gradientul după k pași este cel mult $|w|^k$; luați $|w| = 0,9$
- LSTM cu poarta de uitare constantă $f = \sigma(b)$ pentru $b = 0$ și $b = 3$
- Calculați ce rămâne după 20 și 50 de pași și timpul de înjumătățire

Rezolvare

- RNN: $0,9^{20} = 0,122$, $0,9^{50} = 0,0052$
- $b = 0$: $f = 0,5$, $0,5^{50} \approx 8,9 \times 10^{-16}$
- $b = 3$: $f = 0,9526$, $f^{50} = 0,088$; timpul de înjumătățire $\ln 0,5 / \ln f = 14,3$ pași
- Valoarea pentru $b = 3$ corespunde gradientului măsurat la decalajul 50 în Cursul 14 (circa 8%)

A4. Timpii de înjumătățire ai porții de uitare [Propus]

Rezolvarea se discută la seminar

Cerință

- Timpul de înjumătățire pentru $b = 1$ și pentru $f = 0,99$
- Ce deplasare b dă $f = 0,99$?
- Cu $b = 5$, ce fracțiune supraviețuiește unui an de tranzacționare (250 de zile)?
- Model: A3

A5. Tokenizarea Chronos a unui context de patru zile [Rezolvat]

Cerință

- Contextul (randamente în %):
 $x = (0,8; -1,2; 0,4; 2,0)$
- Scalarea prin medie, apoi 4.093 de centre echidistante în $[-15, 15]$
- Calculați s , valorile scalate și indicii intervalelor

Rezolvare

- $s = (0,8 + 1,2 + 0,4 + 2,0)/4 = 1,10$
- $z = x/s = (+0,727; -1,091; +0,364; +1,818)$
- $\Delta = 30/4092 = 0,00733$; $j = \text{round}((z + 15)/\Delta) = (2145, 1897, 2096, 2294)$
- Centrul vocabularului este indicele 2046 ($z = 0$): toate cele patru zile sunt aproape de el

A6. O zi de crah în context [Propus]

Rezolvarea se discută la seminar

Cerință

- ▣ Înlocuiți ultima valoare cu $-9,0$: $x = (0,8; -1,2; 0,4; -9,0)$
- ▣ Recalculați s , z și indicii intervalelor
- ▣ Cum se schimbă tokenul randamentului de $0,4\%$? Ce „vede” modelul după un crah?
- ▣ Model: A5

A7. VaR 1% și ES 2,5% dintr-o grilă de cuantile [Rezolvat]

Cerință

- Ultima prognoză Chronos-2 pentru S&P 500 (ziua de după 18.09.2026): $q_{0,01} = -2,704\%$, $q_{0,05} = -1,400\%$
- Calculați VaR 1%, VaR 2,5% (interpolare liniară) și ES 2,5%, păstrând $q_u = q_{0,01}$ pentru $u < 0,01$

Rezolvare

- $\text{VaR } 1\% = -q_{0,01} = 2,704\%$
- $q_{0,025} = q_{0,01} + \frac{0,015}{0,04}(q_{0,05} - q_{0,01}) = -2,215\%$;
 $\text{VaR } 2,5\% = 2,215\%$
- $\text{ES } 2,5\%$
 $= -\frac{1}{0,025} \left[0,01 q_{0,01} + 0,015 \frac{q_{0,01} + q_{0,025}}{2} \right] = 2,557\%$
- ES/VaR la 2,5%: 1,15; o limită inferioară, pentru că coada de sub 1% este tăiată

A8. Un „VaR 1%” din decile [Propus]

Rezolvarea se discută la seminar

Cerință

- Chronos-Bolt, aceeași zi: $q_{0,1} = -0,691\%$, $q_{0,5} = 0,071\%$; niciun nivel sub 10%
- (a) valoarea întoarsă când se cere VaR 1%; (b) o extrapolare Normală: $\hat{\sigma} = (q_{0,5} - q_{0,1})/z_{0,9}$, VaR 1% și ES 2,5%
- Comparați cu Chronos-2 din A7
- Model: A7

B1. Poate ceva să bată prognoza zero pentru S&P 500? [Rezolvat]

Cerință

- Prognoze de randament la o zi pentru șase modele, S&P 500, 2 693 zile din 2016
- R^2 în afara eșantionului cu CI bootstrap pe blocuri de 95% (blocuri de 20 de zile)
- Testul DM pe erorile pătratice față de prognoza zero; ponderea semnelor corecte

Interpretare

- Este semnificativ statistic un R^2 pozitiv de circa 1%?
- De ce 55% semne corecte nu dovedesc abilitate de prognoză?

B1. Rezultate

Model	R^2 (%)	CI 95%	DM [p]	Semn corect (%)
Media istorică	+0,15	[-0,02; +0,40]	-1,67 [0,095]	54,6
AR(1)	+0,94	[-2,65; +4,40]	-0,47 [0,639]	54,1
LSTM	+0,82	[+0,13; +1,43]	-1,57 [0,116]	51,2
Chronos-2	-0,26	[-0,89; +0,38]	+0,81 [0,418]	54,7
Chronos-Bolt	-1,57	[-2,73; -0,24]	+1,76 [0,078]	54,6
TimesFM-2.5	-3,35	[-4,62; -1,95]	+3,23 [0,001]	53,6

- Niciun CI nu exclude zero pe partea pozitivă, cu excepția LSTM ([+0,13; +1,43]), dar valoarea p DM este 0,116: dovezile sunt slabe
- TimesFM-2.5 este semnificativ mai slab decât zero; AR(1) are un CI uriaș, determinat de 2020
- S&P 500 a crescut în 54,6% din zile: „mereu în creștere” nimerește deja semnul în această proporție

B2. Bitcoin și BET [Propus]

Rezolvarea se discută la seminar

Cerință

- ▣ Repetați B1 pentru Bitcoin (2 818 zile din 2019) și BET (2 675 zile din 2016)
- ▣ Model: B1

Interpretare

- ▣ Care serie are randamente zilnice previzibile și ce model le găsește?
- ▣ Legați răspunsul de rezultatele despre eficiență din Capitolul 2

B3. Volatilitatea realizată: mai bine decât log-HAR? [Rezolvat]

Cerință

- ▣ Varianța realizată a SPY, 979 prognoze la o zi; opt modele
- ▣ QLIKE medie, DM față de log-HAR (Newey–West), MCS de 90%
- ▣ Repetați pe cele 218 zile de după 3 noiembrie 2025

Interpretare

- ▣ Ce vă spune apartenența la MCS și ce nu vă spune?
- ▣ De ce contează fereastra de după publicare doar pentru modelele fundamentale?

B3. Rezultate

Model	QLIKE	DM vs log-HAR [p]	MCS p	QLIKE (după)	DM (după)
Random walk	0,326	+4,53 [$<0,001$]	0,00	0,384	+2,81
HAR	0,247	+1,30 [0,194]	0,26	0,270	+1,40
log-HAR	0,234	–	0,95	0,238	–
GARCH-t	0,283	+3,43 [$<0,001$]	0,03	0,295	+2,34
LSTM	0,290	+1,87 [0,062]	0,19	0,231	-0,61
Chronos-2	0,231	-0,62 [0,537]	1,00	0,242	+0,58
Chronos-Bolt	0,232	-0,18 [0,857]	0,95	0,236	-0,39
TimesFM-2.5	0,233	-0,08 [0,938]	0,95	0,244	+0,60

- Chronos-2 are cea mai mică QLIKE, dar nu este semnificativ mai bun decât log-HAR (DM -0,62, $p = 0,537$)
- MCS: random walk și GARCH-t sunt eliminate; MCS spune „nu se pot distinge”, nu „la fel de bune”
- După 3.11.2025, LSTM este cel mai bun (0,231); niciun test DM nu este semnificativ față de log-HAR, cu excepția random walk și GARCH-t

B4. Mediana sau media? Și cât context? [Propus]

Rezolvarea se discută la seminar

Cerință

- Pentru Chronos-2 și TimesFM-2.5, comparați $\exp(q_{0,5})$ cu $\int_0^1 \exp(q_u) du$ pe grilă
- QLIKE pentru Chronos-2 cu contexte de 32, 64, 128, 256 și 512 zile
- Model: B3

Interpretare

- De ce este mediana deplasată ca prognoză de varianță?
- Ce spune efectul contextului despre memoria volatilității?

B5. Backtesting pentru prognozele de coadă pe S&P 500 [Rezolvat]

Cerință

- ▣ Șase modele: HS, GARCH-t, FHS, cuantile directe Chronos-2, FHS cu volatilitatea Chronos-2 sau TimesFM
- ▣ VaR 1%: depășiri, Kupiec, independența Christoffersen
- ▣ (VaR 2,5%, ES 2,5%): FZ0 medie, DM față de FHS

Interpretare

- ▣ De ce eșuează cuantilele directe Chronos-2, în timp ce hibridul trece testul de acoperire?
- ▣ Dacă trece testul de acoperire, egalează hibridul FHS?

B5. Rezultate (S&P 500, 2 693 zile)

Model	Depășiri	Rata (%)	p Kupiec	p indep.	FZ0	DM vs FHS
HS	37	1,37	0,065	0,001	1,309	+2,45
GARCH-t	44	1,63	0,002	0,205	1,026	+1,34
FHS	30	1,11	0,559	0,045	0,999	–
Cuantile Chronos-2	45	1,67	0,001	0,223	1,147	+3,16
FHS + vol. Chronos-2	25	0,93	0,705	0,021	1,084	+2,65
FHS + vol. TimesFM	27	1,00	0,989	0,029	1,059	+1,89

- Chronos-2 direct: 1,67% depășiri, p Kupiec = 0,001: cuantilele lui sunt prea înguste
- Hibridul (Chronos-2): 0,93%, p = 0,705: coada vine din date, prin FHS
- Dar FZ0 este semnificativ mai slabă decât la FHS (DM +2,65): acoperire corectă cu prea mult capital

B6. Bitcoin și VaR 10% pentru toate cele trei modele [Propus]

Rezolvarea se discută la seminar

Cerință

- ▣ Repetați B5 pentru Bitcoin (2818 zile)
- ▣ VaR 10%: ratele de depășire și testele Kupiec pentru cuantilele Chronos-2, Chronos-Bolt și TimesFM-2.5 față de HS și FHS, pe cele trei piețe
- ▣ Model: B5

Interpretare

- ▣ Este îngustimea cuantilelor modelelor fundamentale specifică nivelului de 1%?

B7. Loteria semințelor [Rezolvat]

Cerință

- ▣ Cinci LSTM-uri pentru randamente, identice cu excepția semințelor aleatoare
- ▣ R^2 în afara eșantionului pentru fiecare sămânță și pentru media lor, pe trei piețe

Interpretare

- ▣ Ce ați concluziona dintr-o singură rulare pe Bitcoin?
- ▣ De ce este media semințelor o formă de regularizare?

B7. Rezultate

R^2 (%)	Sămânța 0	1	2	3	4	Media
S&P 500	+0,53	+0,35	+0,48	+0,55	+1,40	+0,82
Bitcoin	-0,08	+0,02	-1,47	-0,49	+0,21	-0,08
BET	+1,10	+1,03	+1,15	+1,25	+1,14	+1,18

- Bitcoin: semințele variază între -1,47% și +0,21%: o singură rulare ar putea „arăta” abilitate sau lipsa ei
- BET: toate cele cinci semințe sunt de acord; media reduce varianța fără a adăuga deplasare, ca bagging-ul

 MFM_ch14_sem_partB

B8. Scurgerea de informație printr-un regresor care privește în viitor [Propus]

Rezolvarea se discută la seminar

Cerință

- log-HAR pentru SPY, dar cu mediile pe 5 și 22 de zile calculate inclusiv ziua prognozată t
- Comparați QLIKE cu log-HAR corect și cu Chronos-2; testul DM
- Model: B3

Interpretare

- Cât de mare este câștigul din privirea în viitor? L-ar putea obține un model corect?
- Unde se poate ascunde aceeași eroare într-un proces de deep learning?

C1. Poate un model fundațional zero-shot să înlocuiască GARCH pentru BET? [Propus]

Rezolvarea se discută la seminar

Cerință

- Un manager de risc propune Chronos-2 pentru VaR 1% și ES 2,5% zilnice ale unei poziții pe BET, în locul modelelor bazate pe GARCH
- Comparați HS, GARCH-t, FHS, cuantilele directe Chronos-2 și FHS cu volatilitatea modelelor fundamentale (2 675 zile din 2016)
- Folosiți acoperirea, independența, FZ0, DM, MCS, zonele Basel pe blocuri de 250 de zile și fereastra de după publicare

Interpretare

- Scrieți o recomandare de o pagină: acceptați, respingeți sau acceptați ca model alternativ (challenger)?
- Extindere pentru proiect: ajustați fin un model fundațional pe acțiuni românești și refaceți testul

C2: critica unui răspuns AI [Propus]

- Un student îi cere unui asistent AI: „Testează retroactiv VaR 1% la o zi, zero-shot, cu Chronos-2 pentru S&P 500 pe ultimele 1500 de zile, cu un context de 512 zile”
- Asistentul răspunde cu acest cod (spx: închideri zilnice, fără importuri):

```
pipe = BaseChronosPipeline.from_pretrained('amazon/chronos-2')
r = 100 * np.log(spx).diff().dropna().to_numpy()      # daily returns, %
test = np.arange(len(r) - 1500, len(r))
q01 = np.empty(len(test))
for i, t in enumerate(test):                          # forecast of r[t]
    ctx = torch.tensor(r[t - 511:t + 1], dtype=torch.float32) # 512 days
    q, _ = pipe.predict_quantiles([ctx[None, :]], prediction_length=1,
                                  quantile_levels=[0.01])
    q01[i] = q[0][0, 0].item()
x = int((r[test] < q01).sum())                          # breaches
print(f"VaR_1%={q01.mean():.2f}%, breaches={x}")
```

- „Rezultat: VaR 1% = -2,41%, depășiri = 5, adică 0,33% față de 15 așteptate: modelul este prudent, deci trece ușor testul Kupiec”

C2: critica unui răspuns AI, cerința [Propus]

Rezolvarea se discută la seminar

Cerință

- Răspunsul conține **trei** erori, în cod și în concluzie; restul este corect
- Pentru fiecare eroare
 - ▶ spuneți ce este greșit și de ce
 - ▶ spuneți cum ați detecta-o: o verificare a indicilor, convenția VaR din curs, statistica testului
 - ▶ dați linia sau concluzia corectată
- Calculați statistica Kupiec și valoarea p pentru 5 depășiri în 1 500 de zile
- Treceți cele trei erori ca în AI_ERRORS.md: ce s-a cerut, ce a răspuns AI-ul, ce era greșit, cum v-ați dat seama, varianta corectă

Interpretare

- Care element din r ar trebui să fie ultimul din context când prognozăm $r[t]$?
- Sunt „prea puține depășiri” o veste bună pentru un manager de risc? Dar pentru autoritatea de supraveghere?
- Ponderile Chronos-2 au fost publicate în toamna lui 2025: sunt ultimele 1 500 de zile un test curat pentru el?

Temă pentru acasă (proiectul de echipă)

- ▣ Alegeți un activ nediscutat la seminar (o acțiune BVB, un crypto-activ, un curs valutar sau o marfă)
- ▣ Prognozați volatilitatea zilnică sau VaR 1% cu un model fundațional, zero-shot, și cu un reper GARCH
 - ▶ Origine mobilă, iar fereastra de context trebuie să se încheie în ziua dinaintea prognozei
 - ▶ Raportați separat perioada de după data publicării modelului
- ▣ Comparați modelele cu testul DM și, pentru VaR, cu testele de acoperire și de independență
- ▣ Notați fiecare eroare AI prinsă în `AI_ERRORS.md` (cel puțin trei pe proiect)
- ▣ Livrați un folder Quantlet (cod, Metainfo, grafice) și trei slide-uri: cifre, interpretare, limite

Bibliografie (1/2)

- ▣ Ansari, A.F., Stella, L., Turkmen, C., Zhang, X., et al. (2024). Chronos: learning the language of time series. *Transactions on Machine Learning Research*; arXiv:2403.07815.
- ▣ Ansari, A.F., Shchur, O., Küken, J., Auer, A., et al. (2025). Chronos-2: from univariate to universal forecasting. arXiv:2510.15821.
- ▣ Corsi, F. (2009). A simple approximate long-memory model of realized volatility. *Journal of Financial Econometrics*, 7(2), 174–196.
- ▣ Diebold, F.X., Mariano, R.S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3), 253–263.
- ▣ Franke, J., Härdle, W.K., Hafner, C.M. (2019). *Statistics of Financial Markets: An Introduction*, 5th ed. Springer.
- ▣ Hansen, P.R., Lunde, A., Nason, J.M. (2011). The model confidence set. *Econometrica*, 79(2), 453–497.

Bibliografie (2/2)

- ▣ Hochreiter, S., Schmidhuber, J. (1997). Long short-term memory. *Neural Computation*, 9(8), 1735–1780.
- ▣ Kupiec, P.H. (1995). Techniques for verifying the accuracy of risk measurement models. *Journal of Derivatives*, 3(2), 73–84.
- ▣ Patton, A.J. (2011). Volatility forecast comparison using imperfect volatility proxies. *Journal of Econometrics*, 160(1), 246–256.
- ▣ Patton, A.J., Ziegel, J.F., Chen, R. (2019). Dynamic semiparametric models for expected shortfall (and value-at-risk). *Journal of Econometrics*, 211(2), 388–413.
- ▣ Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., et al. (2017). Attention is all you need. *NeurIPS*; arXiv:1706.03762.