



Modelarea piețelor financiare

Seminarul 14: Deep learning și modele fundamentale pentru serii de timp — aplicații



Daniel Traian PELE

Drd. Antoaneta Amza, antoaneta.amza@csie.ase.ro

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognostic Economică

MSCA Digital Finance

Acronime folosite în acest material (1/2)

- ▣ ACF: AutoCorrelation Function (funcția de autocorelație)
- ▣ ACI: Adaptive Conformal Inference (inferență conformală adaptivă)
- ▣ AI: Artificial Intelligence (inteligență artificială)
- ▣ AR: AutoRegressive (model) (model autoregresiv)
- ▣ BET: Bucharest Exchange Trading (index) (indicele de referință al Bursei de Valori București)
- ▣ BVB: Bursa de Valori București
- ▣ CI: Confidence Interval (interval de încredere)
- ▣ CRPS: Continuous Ranked Probability Score (scorul de probabilitate ordonat continuu)
- ▣ CRSP: Center for Research in Security Prices (Centrul de cercetare a prețurilor titlurilor (Universitatea din Chicago))
- ▣ CW: Clark–West (test for nested models) (testul Clark–West pentru modele imbricate)
- ▣ DM: Diebold–Mariano (test) (testul Diebold–Mariano de comparare a prognozelor)
- ▣ DQ: Dynamic Quantile (test) (testul cuantilei dinamice)
- ▣ ES: Expected Shortfall (pierdere așteptată în coadă)
- ▣ ETF: Exchange-Traded Fund (fond tranzacționat la bursă)
- ▣ FHS: Filtered Historical Simulation (simulare istorică filtrată)
- ▣ FRED: Federal Reserve Economic Data (baza de date economice a Rezervei Federale (St. Louis))
- ▣ FZ0: Fissler–Ziegel loss, zero-homogeneous version (funcția de pierdere Fissler–Ziegel, varianta omogenă de grad zero)
- ▣ GARCH: Generalised AutoRegressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă generalizată)
- ▣ GPD: Generalised Pareto Distribution (distribuția Pareto generalizată)
- ▣ HAC: Heteroskedasticity and Autocorrelation Consistent (standard errors) (erori standard robuste la heteroscedasticitate și autocorelație)
- ▣ HAR: Heterogeneous AutoRegressive (model) (model autoregresiv heterogen)
- ▣ HS: Historical Simulation (simulare istorică)
- ▣ LR: Likelihood Ratio (test) (testul raportului de verosimilitate)
- ▣ LSTM: Long Short-Term Memory (network) (rețea cu memorie pe termen lung și scurt)
- ▣ MCS: Model Confidence Set (mulțimea de modele de încredere)
- ▣ MDE: Minimum Detectable Effect (efectul minim detectabil)

Acronime folosite în acest material (2/2)

- ▣ MSE: Mean Squared Error (eroarea pătratică medie)
- ▣ PIT: Probability Integral Transform (transformarea integrală de probabilitate)
- ▣ QLIKE: Quasi-LIKelihood (loss function) (funcția de pierdere de tip cvasi-verosimilitate)
- ▣ QS: Quantile Score (scorul cuantic)
- ▣ RFF: Random Fourier Features (trăsături Fourier aleatoare)
- ▣ RV: Realised Variance (varianța realizată)
- ▣ SPA: Superior Predictive Ability (test) (testul abilității predictive superioare)
- ▣ TS: Time Series (in the name TS-Arena) (serii de timp (în numele platformei TS-Arena))
- ▣ VAR: Vector AutoRegression (autoregresie vectorială)

Cuprins

Introducere

Formule de bază

Partea A: derivări

Partea B: inferență pe prognoze

Partea C: întrebare deschisă și critica unui răspuns AI

Încheiere

Bibliografie

Obiectivele seminarului

La finalul seminarului puteți

- Explica dispariția gradientului prin răspunsurile la impuls ale unui VAR și starea celulei LSTM ca AR(1)
- Citi VaR și ES dintr-o grilă de cuantile, cu o coadă GPD; calcula puterea exactă a unui backtest
- Testa corect prognozele: Clark–West, SPA, Romano–Wolf, DQ, PIT și scoruri cuantile, recalibrare conformală
- Detecta efectele inițializării aleatoare, prețurile neactualizate și utilizarea informațiilor viitoare

- Suport: Cursul 14 și Cursul 8 (backtesting); manualul [Franke, Härdle & Hafner \(2019\)](#)

Structura

- **Partea A:** zece derivări (A1–A10)
- **Partea B:** unsprezece exerciții pe calculator, cu inferență (B1–B11)
- **Partea C:** o întrebare deschisă, punct de plecare pentru proiectul de echipă (C1), un răspuns AI de criticat (C2) și un punct de plecare pentru proiect din studiul de caz al cursului (C3)

Cum lucrăm la acest seminar

- Problemele **[Rezolvat]** au rezolvarea completă; problemele **[Propus]** au doar cerința: rezolvările se discută la seminar
- Fiecare problemă propusă indică **modelul**: problema rezolvată care folosește aceeași tehnică
 - ▶ Fiecare exercițiu din Partea B se încheie cu întrebări de interpretare
- Numiți mereu reperul: zero pentru randamente, log-HAR pentru volatilitate, FHS pentru riscul de coadă
- Un model care „nu este semnificativ mai slab” nu este neapărat „la fel de bun”: întrebați-vă câtă putere a avut testul

Probleme rezolvate și propuse

Rezolvate: exemple lucrate în acest material

- ▣ Partea A: A1 (gradienti ca răspunsuri la impuls VAR), A3 (scalarea prin medie), A5 (VaR și ES din grilă), A8 (puterea exactă Kupiec), A10 (QLIKE elicitează media)
- ▣ Partea B: B1 (randamente vs zero, Clark–West, SPA), B3 (volatilitate realizată vs log-HAR), B5 (VaR 1% și ES 2,5%), B7 (semințe), B9 (PIT, Berkowitz, scor cuantilic)

Propuse: le rezolvați voi

- ▣ Partea A: A2 (model: A1), A4 (model: A3), A6 și A7 (model: A5), A9 (model: A8)
- ▣ Partea B: B2 (model: B1), B4, B8, B11 (model: B3), B6 (model: B5), B10 (modele: B5, B9)
- ▣ Partea C: C1, întrebare deschisă și punct de plecare pentru proiect; C2, critica unui răspuns AI (backtestul VaR al unui model fundațional); C3, punct de plecare pentru proiect din studiul de caz al cursului (complexitatea modelelor în prognoza randamentelor)

Pregătire: mediul Python și datele

- ▣  **Deschide în Colab:** `capitol14_notebook_seminar.ipynb`
- ▣ Google Colab (recomandat) sau Python local ≥ 3.10 cu `torch`, `chronos-forecasting`, `timesfm`, `arch`, `pandas`, `scipy`
- ▣ Serii: S&P 500, Bitcoin, BET (închideri zilnice); bare de 5 minute ale SPY pentru varianța realizată; până la 18 septembrie 2026
- ▣ Prognoze: prognozele la o zi din Cursul 14 (context de 512 zile pentru modelele fundamentale; ferestre de 500 sau 1.000 de zile pentru modelele clasice)
- ▣ Randamente r_t în %, pierderi $L_t = -r_t$; $\text{VaR}_\alpha = -q_\alpha$, $\text{ES}_\alpha = -\frac{1}{\alpha} \int_0^\alpha q_u du$

Formule de bază (1/2): rețele și tokeni

- ▣ LSTM (Hochreiter & Schmidhuber (1997)): $c_t = f_t \odot c_{t-1} + i_t \odot g_t$, $h_t = o_t \odot \tanh(c_t)$; porți $\sigma(Wx_t + Uh_{t-1} + b) \in (0, 1)$
- ▣ Parametrii unui strat: $4(hd + h^2 + h)$ sau $4(hd + h^2 + 2h)$ cu doi vectori de termeni liberi (PyTorch)
- ▣ Memoria pe drumul stării celulei: $\partial c_T / \partial c_{T-k} = \prod_j f_{T-j}$; timpul de înjumătățire $k_{1/2} = \ln 0,5 / \ln f$
- ▣ Atenția (Vaswani et al. (2017)): $\text{softmax}(QK^\top / \sqrt{d_k}) V$
- ▣ Tokenii Chronos (Ansari et al. (2024)): $s = \frac{1}{\epsilon} \sum |x_t|$, $z_t = x_t/s$, indicele intervalului $j = \text{round}((z_t + 15)/\Delta)$, $\Delta = 30/4092$

Formule de bază (2/2): evaluare

- ▣ R^2 în afara eşantionului $= 1 - \sum_t (r_t - \hat{r}_t)^2 / \sum_t r_t^2$ (reper: prognoza zero)
- ▣ Diebold–Mariano (Diebold & Mariano (1995)): $DM = \bar{d} / \sqrt{\widehat{LRV} / T}$, $d_t = L_t^A - L_t^B$, varianța pe termen lung Newey–West; negativ: A mai bun
- ▣ QLIKE (Patton (2011)): $RV_t / \hat{h}_t - \log(RV_t / \hat{h}_t) - 1$; HAR (Corsi (2009)): RV pe mediile ei zilnică, pe 5 zile și pe 22 de zile
- ▣ Kupiec (Kupiec (1995)): $LR_{uc} = -2[(T - x) \ln(1 - \alpha) + x \ln \alpha - (T - x) \ln(1 - \hat{\pi}) - x \ln \hat{\pi}] \sim \chi_1^2$
- ▣ FZ0 (Patton, Ziegel & Chen (2019)): $\frac{1}{\alpha \text{ES}} \mathbf{1}\{L > \text{VaR}\} (L - \text{VaR}) + \frac{\text{VaR}}{\text{ES}} + \log \text{ES} - 1$; MCS (Hansen, Lunde & Nason (2011)) la 90%

Formule de bază (3/3): inferență și calibrare

- ▣ Clark–West (Clark & West (2007)), reper imbricat: $\tilde{d}_t = e_{0,t}^2 - [e_{1,t}^2 - (\hat{y}_{0,t} - \hat{y}_{1,t})^2]$, t HAC unilateral
- ▣ Multe modele: SPA (Hansen (2005)), $\max_k \sqrt{T} \bar{d}_k / \hat{\omega}_k$ cu bootstrap staționar; p ajustat pas cu pas Romano–Wolf (Romano & Wolf (2005))
- ▣ DQ (Engle & Manganelli (2004)): regresia lui $I_t - \alpha$ pe $(1, I_{t-1}, \dots, I_{t-4}, \text{VaR}_t)$; $\hat{\beta}^\top X^\top X \hat{\beta} / (\alpha(1 - \alpha)) \sim \chi^2_6$
- ▣ PIT $u_t = \hat{F}_t(y_t)$ i.i.d. $U(0, 1)$ (Diebold, Gunther & Tay (1998)); LR Berkowitz pe $\Phi^{-1}(u_t)$ (Berkowitz (2001)); QS $= \frac{2}{K} \sum_k \text{pinball}_{u_k}$, un analog pe grilă, cu ponderi egale, al CRPS (Gneiting & Raftery (2007))
- ▣ Conformal adaptiv (Gibbs & Candès (2021)): $\alpha_{t+1} = \alpha_t + \gamma(\alpha - \text{err}_t)$; $\hat{Q} = +\infty$ când $\alpha_t \leq 0$; rata de depășire pe termen lung $\rightarrow \alpha$ pentru orice secvență

A1. Gradientul care dispare ca răspuns la impuls VAR [Rezolvat]

Cerință

- **Context:** o rețea recurentă simplă $h_t = \tanh(Wh_{t-1} + Ux_t + b)$ cu două unități ascunse, antrenată prin propagare înapoi în timp; nu sunt necesare date
 - ▶ Se dau: $W = \begin{pmatrix} 0,5 & 0,8 \\ 0 & 0,5 \end{pmatrix}$; liniarizați în punctul fix $h^* = 0$, cu $b = 0$ și $x = 0$
- (a) Derivați jacobiana $\partial h_T / \partial h_{T-k}$ prin regula lanțului și demonstrați că $\|\partial h_T / \partial h_{T-k}\|_2 \leq \|W\|_2^k$
- (b) Arătați că rețeaua liniarizată este un VAR(1) în h_t și că jacobiana este egală cu răspunsul lui la impuls la orizontul k
- (c) Calculați raza spectrală $\rho(W)$, norma spectrală $\|W\|_2$, majorarea $\|W\|_2^k$ și valoarea exactă $\|W^k\|_2$ pentru $k = 5, 20, 50$
- **Raportați** cifrele de la (c) și răspundeți: majorarea prin normă sau raza spectrală este criteriul potrivit pentru gradientul care dispare?

A1. Gradientul care dispare ca răspuns la impuls VAR: rezolvare (1/2)

Rezolvare

- (a) Un pas: $\partial h_t / \partial h_{t-1} = D_t W$, cu $D_t = \text{diag}(1 - h_t^2)$, pentru că $\tanh'(z) = 1 - \tanh^2(z)$
 - ▶ Regula lanțului pe k pași: $\partial h_T / \partial h_{T-k} = \prod_{j=0}^{k-1} D_{T-j} W$
 - ▶ $\|D_t\|_2 = \max_i |1 - h_{t,i}^2| \leq 1$ și $\|AB\|_2 \leq \|A\|_2 \|B\|_2$, deci produsul este cel mult $\|W\|_2^k$
- (b) În $h^* = 0$: $\tanh'(0) = 1$, deci $D_t = I$ și $h_t \approx W h_{t-1} + U x_t$
 - ▶ Acesta este un VAR(1) cu matricea de coeficienți W și termenul de forțare $U x_t$ (o inovație dacă x_t este zgomot alb centrat)
 - ▶ Forma de medie mobilă $h_T = \sum_k W^k U x_{T-k}$ arată că $\partial h_T / \partial h_{T-k} = W^k$ este răspunsul la impuls la orizontul k

A1. Gradientul care dispare ca răspuns la impuls VAR: rezolvare (2/2)

Rezolvare

- (c) W este triunghiulară: valorile proprii sunt elementele diagonalei, deci $\rho(W) = 0,50$; cea mai mare valoare singulară dă $\|W\|_2 = 1,040$
 - ▶ Majorarea la $k = 20$: $1,040^{20} = 2,20$, care crește cu k și nu spune nimic
 - ▶ Exact: $W^k = 0,5^k \begin{pmatrix} 1 & 1,6^k \\ 0 & 1 \end{pmatrix}$, deci $\|W^5\|_2 = 0,254$, $\|W^{20}\|_2 = 3,1 \times 10^{-5}$, $\|W^{50}\|_2 = 7,1 \times 10^{-14}$
- Interpretare: condiția bazată pe normă este suficientă, nu necesară; gradientul dispare în ritmul $k 0,5^k$, pentru că $\rho(W) < 1$ în acest punct fix, unde $D = I$
 - ▶ Formula lui Gelfand $\|W^k\|^{1/k} \rightarrow \rho(W)$: același criteriu ca stabilitatea unui VAR; departe de $h^* = 0$ contează $\rho(DW)$, nu $\rho(W)$

A2. Starea celulei LSTM ca AR(1) [Propus]

Rezolvarea se discută la seminar

Cerință

- **Context:** o celulă LSTM cu poarta de uitare constantă $f = \sigma(b_f)$, poarta de intrare constantă i și candidați g_t i.i.d. cu media 0 și varianța σ_g^2
 - Date pentru (c): randamentele log zilnice ale S&P 500 (GSPC.INDX, data/market) din ianuarie 2000; ACF-ul lui $|r_t|$: 0,289 (decalaj 1), 0,132 (decalaj 50), 0,059 (decalaj 150)
- (a) Arătați că $c_t = fc_{t-1} + ig_t$ este un AR(1) staționar pentru $0 < f < 1$; derivați $\text{Var}(c_t)$ și $\text{Corr}(c_t, c_{t-k})$
- (b) Calculați timpul de înjumătățire $\ln 0,5 / \ln f$ pentru $b_f = 1$ și pentru $f = 0,99$, termenul liber b_f care dă $f = 0,99$ și f^{250} pentru $b_f = 5$
- (c) Ajustați o descreștere geometrică cu amplitudine proprie, $\rho_k = \rho_1 f^{k-1}$ (un semnal AR(1) observat cu zgomot): alegeți f astfel încât $f^{49} = \rho_{50} / \rho_1$; calculați b_f , timpul de înjumătățire și $\rho_{150} = \rho_1 f^{149}$ prezis
- **Raportați** cifrele de la (b) și (c); de ce niciun $f < 1$ fix nu poate reproduce memoria lungă și de ce are nevoie rețeaua în schimb?
- Model: A1

A3. Scalarea prin medie în Chronos: cine mișcă scala? [Rezolvat]

Cerință

- **Context:** Chronos original ([Ansari et al. \(2024\)](#)) împarte un context de C randamente la $s = \frac{1}{C} \sum_t |x_t|$ și plasează $z = x/s$ în 4.093 de intervale echidistante în $[-15, 15]$, $\Delta = 30/4092$
 - Se dă pentru (b): randamentele dintr-un context de patru zile, exprimate în %, $x = (0,8; -1,2; 0,4; 2,0)$
- (a) Fereastra avansează o zi: intră o valoare nouă M și iese x_{out} . Derivați s_{nou} în funcție de s_{vechi} , M , x_{out} și C , precum și factorul cu care se schimbă valoarea scalată a fiecărei zile neschimbate
- (b) Pentru contextul de patru zile calculați s , valorile scalate z și indicii $j = \text{round}((z + 15)/\Delta)$
- **Raportați** formula de la (a) și tabelul cu z și j ; cum depinde de C efectul unui crăh asupra scalei?

A3. Scalarea prin medie în Chronos: cine mișcă scala?: rezolvare

Rezolvare

- (a) Suma valorilor absolute pierde $|x_{\text{out}}|$ și câștigă $|M|$: $\sum_{\text{nou}} = \sum_{\text{vechi}} - |x_{\text{out}}| + |M|$
 - ▶ Împărțind la C : $s_{\text{nou}} = s_{\text{vechi}} + (|M| - |x_{\text{out}}|)/C$
 - ▶ Zi neschimbată x : $z_{\text{nou}} = x/s_{\text{nou}} = z_{\text{vechi}} \cdot s_{\text{vechi}}/s_{\text{nou}}$
- (b) $s = (0,8 + 1,2 + 0,4 + 2,0)/4 = 1,10$
 - ▶ $z = x/s = (+0,727; -1,091; +0,364; +1,818)$; $\Delta = 0,00733$
 - ▶ $j = (2145, 1897, 2096, 2294)$: toate lângă centrul vocabularului, $j = 2046$ pentru $z = 0$
- Interpretare: un crash mută s cu circa $|M|/C$: un context scurt reacționează puternic, unul de 512 zile aproape deloc

A4. O zi de crah în context [Propus]

Rezolvarea se discută la seminar

Cerință

- ▣ **Context:** scalarea din A3; randamentele log zilnice ale S&P 500 (GSPC.INDX, data/market) într-un context de 512 zile
 - ▶ La 16 martie 2020 intră randamentul de -12,77% și iese o zi de 0,51%; înaintea crahului $s_{\text{vechi}} = 0,741\%$
- ▣ (a) Înlocuiți ultima valoare din contextul A3 cu -9,0 și recalculați s , z , j și factorul $s_{\text{vechi}}/s_{\text{nou}}$
- ▣ (b) Aplicați formula din A3(a) cazului S&P 500 și calculați s_{nou} și factorul
- ▣ (c) Calculați valoarea scalată a unei zile obișnuite de 0,4% înainte și după crah, în ambele cazuri
- ▣ **Raportați** s , factorul și z al zilei de 0,4%; face un context de 512 zile ca zilele obișnuite să pară calme după un crah?
- ▣ Model: A3

A5. VaR 1% și ES 2,5% dintr-o grilă de cuantile [Rezolvat]

Cerință

- ▣ **Context:** ultima prognoză zero-shot Chronos-2 pentru S&P 500 (ziua de după 18.09.2026; context de 512 randamente zilnice, GSPC.INDX); nivelurile grilei 1%, 5%, 10%, ..., 99%
 - ▶ Se dau: $q_{0,01} = -2,704\%$, $q_{0,05} = -1,400\%$; convenția $\text{VaR}_\alpha = -q_\alpha$, $\text{ES}_\alpha = -\frac{1}{\alpha} \int_0^\alpha q_u du$
- ▣ (a) Calculați VaR 1%
- ▣ (b) Interpolați liniar $q_{0,025}$ între $q_{0,01}$ și $q_{0,05}$ și calculați VaR 2,5%
- ▣ (c) Calculați ES 2,5%, păstrând $q_u = q_{0,01}$ pentru $u < 0,01$ și folosind q_u liniar pe $[0,01; 0,025]$
- ▣ **Raportați** VaR 1%, VaR 2,5%, ES 2,5% și raportul ES 2,5%/VaR 2,5%; comparați acest raport, la același nivel al cozii, cu valoarea pentru o distribuție Normală de medie zero

A5. VaR 1% și ES 2,5% dintr-o grilă de cuantile: rezolvare

Rezolvare

- (a) $\text{VaR } 1\% = -q_{0,01} = 2,704\%$
- (b) $q_{0,025} = q_{0,01} + \frac{0,025-0,01}{0,05-0,01} (q_{0,05} - q_{0,01}) = -2,704 + 0,375 (-1,400 + 2,704) = -2,215\%$
 ► $\text{VaR } 2,5\% = -q_{0,025} = 2,215\%$
- (c) Împărțim integrala: $\int_0^{0,01} q_u du = 0,01 q_{0,01}$; $\int_{0,01}^{0,025} q_u du = 0,015 (q_{0,01} + q_{0,025})/2$ (trapez)
 ► $\text{ES } 2,5\% = -\frac{1}{0,025} \left[0,01 q_{0,01} + 0,015 \frac{q_{0,01} + q_{0,025}}{2} \right] = 2,557\%$
- Interpretare: $\text{ES } 2,5\% / \text{VaR } 2,5\% = 1,15$, sub valoarea pentru distribuția Normală de medie zero la același nivel, $\varphi(1,96)/(0,025 \cdot 1,96) = 1,19$: grila taie coada de sub 1% (A6)

A6. Coadă limitată a grilei; o coadă GPD [Propus]

Rezolvarea se discută la seminar

Cerință

- ▣ **Context:** grila din A5; pierderile zilnice ale S&P 500 $L = -r$ (GSPC.INDX) pe ultimele 1.000 de zile de tranzacționare până la 18.09.2026
 - ▶ Depășiri peste prag: u = cuantila empirică de 95% a lui L ; excesele $L - u$ urmează o $GPD(\xi, \beta)$ cu $\xi < 1$ (McNeil & Frey (2000))
- ▣ (a) Cu funcția cuantilă exactă pe $[0,01; 0,025]$, demonstrați că păstrarea $q_u = q_{0,01}$ pentru $u < 0,01$ nu mărește niciodată ES 2,5%; apoi arătați că interpolarea liniară din A5 pe $[0,01; 0,025]$ poate greși în ambele sensuri
- ▣ (b) Derivați $ES_\alpha = \frac{VaR_\alpha}{1-\xi} + \frac{\beta-\xi u}{1-\xi}$ din funcția excesului mediu a GPD
- ▣ (c) Estimați ξ, β prin verosimilitate maximă; calculați $VaR_\alpha = u + \frac{\beta}{\xi} \left[(n\alpha/N_u)^{-\xi} - 1 \right]$ pentru $\alpha = 1\%$ și $2,5\%$ și ES 2,5%
- ▣ **Raportați** $u, N_u, \hat{\xi}, \hat{\beta}, VaR$ și ES; comparați ES/VaR cu A5
- ▣ Model: A5

A7. Un „VaR 1%” din decile [Propus]

Rezolvarea se discută la seminar

Cerință

- ▣ **Context:** Chronos-Bolt (small), zero-shot, aceeași zi și același context ca în A5; întoarce doar decilele $q_{0,1}, \dots, q_{0,9}$
 - Se dau: $q_{0,1} = -0,691\%$, $q_{0,5} = 0,071\%$
- ▣ (a) Precizați valoarea întoarsă când se cere VaR 1% dintr-o grilă de decile limitată la cel mai mic nivel
- ▣ (b) Presupuneți o distribuție predictivă Normală cu mediana $q_{0,5}$ și $\hat{\sigma} = (q_{0,5} - q_{0,1})/z_{0,9}$; calculați VaR 1%
 $= -(q_{0,5} + \hat{\sigma} z_{0,01})$ și ES 2,5% $= -(q_{0,5} - \hat{\sigma} \varphi(z_{0,025})/0,025)$
- ▣ (c) Comparați cu Chronos-2 (A5) și evaluați ipoteza extrapolării Normale: ce cauze ale depășirilor prea dese ale cuantilelor directe ale modelelor fundamentale (Cursul 14, Testul 3) poate trata și ce test ar decide?
- ▣ **Raportați** cele trei cifre și comparația
- ▣ Model: A5

A8. Puterea exactă a testului Kupiec [Rezolvat]

Cerință

- **Context:** prognoze VaR 1% pe cele 220 de zile de tranzacționare de după publicarea ponderilor (3.11.2025–18.09.2026); numărul de depășiri $x \sim \text{Bin}(T, \pi)$ cu $T = 220$
 - ▶ Testul LR Kupiec (Kupiec (1995)), bilateral, nivel 5%: respingem dacă $LR_{uc} > \chi^2_{1,0,95} = 3,84$
- (a) Calculați $LR_{uc}(x) = -2[(T - x) \ln 0,99 + x \ln 0,01 - (T - x) \ln(1 - x/T) - x \ln(x/T)]$ pentru $x = 0, 1, 2, \dots$ și găsiți regiunea de respingere
- (b) Calculați nivelul exact $P_{\pi=1\%}(\text{respingere})$
- (c) Calculați puterea $P_{\pi=1,67\%}(\text{respingere})$; 1,67% este rata de depășire a Chronos-2 direct pe S&P 500
- **Raportați** regiunea de respingere, nivelul și puterea; ce îi spune unui manager de risc o nerespingere pe 220 de zile?

A8. Puterea exactă a testului Kupiec: rezolvare (1/2)

Rezolvare

- (a) $x = 0$: $LR = -2 \cdot 220 \ln 0,99 = 4,42 > 3,84$: respingem (prea puține depășiri)
 - ▶ $x = 5$: $LR = 2,65 < 3,84$; $x = 6$: $LR = 4,51 > 3,84$
 - ▶ Regiunea de respingere: $x = 0$ sau $x \geq 6$; regiunea de acceptare: $1 \leq x \leq 5$
- (b) Nivelul = $P_{1\%}(x = 0) + P_{1\%}(x \geq 6) = 0,134$, nu 0,05: cu o statistică discretă nivelul nominal nu poate fi atins

A8. Puterea exactă a testului Kupiec: rezolvare (2/2)

Rezolvare

- (c) Puterea = $P_{1,67\%}(x = 0) + P_{1,67\%}(x \geq 6) = 0,9833^{220} + 0,165 = 0,025 + 0,165 = 0,189$
 - Numărul așteptat de depășiri: $220 \times 1\% = 2,2$ sub H_0 , $220 \times 1,67\% = 3,7$ sub alternativă
- Interpretare: de patru ori din cinci, un model cu 67% prea multe depășiri trece; pe 220 de zile, „nerespins” nu este o dovadă de acoperire corectă

A9. Cât de lungă trebuie să fie fereastra de după publicare? [Propus]

Rezolvarea se discută la seminar

Cerință

- ▣ **Context:** testul Kupiec din A8 (bilateral, 5%) pentru VaR 1%; rata reală de depășire $\pi = 1,67\%$ sau 2%
- ▣ (a) Calculați puterea exactă față de $\pi = 1,67\%$ pentru $T = 1\,000$ și $T = 2\,693$ (tot eșantionul din Cursul 14)
- ▣ (b) Găsiți cel mai mic T cu puterea $\geq 80\%$ și T -ul de la care rămâne peste 80%; explicați de ce puterea nu este monotonă în T
- ▣ (c) Repetați pentru $\pi = 2\%$: puterea la $T = 220$ și T -ul pentru o putere de 80%
- ▣ **Raportați** cifrele; câți ani de date de după publicare cere un backtest curat?
- ▣ Model: A8

A10. Ce funcțională elicitează QLIKE? [Rezolvat]

Cerință

- **Context:** varianța realizată RV a SPY (suma pătratelor randamentelor la 5 minute), prognoze la o zi între 11.10.2022 și 18.09.2026 (979 de zile); pierderea QLIKE $L(y, h) = y/h - \log(y/h) - 1$
 - Chronos-2 pe log RV (context 512) întoarce cuantilele q_u ; raportul mediu dintre $\exp(q_{0,5})$ și $\int_0^1 \exp(q_u) du$: 0,8048
- (a) Minimizați $E[L(Y, h) | \mathcal{F}]$ după $h > 0$ și arătați că minimumul este atins în $E[Y | \mathcal{F}]$
- (b) Presupuneți $\log Y | \mathcal{F} \sim N(\mu, s^2)$: derivați mediana, media, raportul lor și excesul de QLIKE așteptat al prognozei prin mediană
- (c) Din raportul Chronos-2 deduceți un s comun efectiv și excesul de QLIKE (un raport mediat pe zile nu identifică s -ul fiecărei zile)
- **Raportați** derivările și cele două cifre; de ce este $\exp(\text{mediana})$ o prognoză de volatilitate cu eroare sistematică?

A10. Ce funcțională elicitează QLIKE?: rezolvare (1/2)

Rezolvare

- (a) $E[L] = E[Y]/h - E[\log Y] + \log h - 1$; $\partial_h E[L] = -E[Y]/h^2 + 1/h = 0 \Rightarrow h^* = E[Y | \mathcal{F}]$
 - Derivata a doua $2E[Y]/h^3 - 1/h^2 = 1/h^{*2} > 0$ în h^* : un minim; QLIKE este consistentă pentru medie ([Gneiting \(2011\)](#))
- (b) Mediana e^μ , media $m = e^{\mu+s^2/2}$, raportul $e^{-s^2/2}$
 - Cu $h = me^{-s^2/2}$: $E[L(h)] - E[L(m)] = e^{s^2/2} - 1 - s^2/2 > 0$

A10. Ce funcțională elicitează QLIKE?: rezolvare (2/2)

Rezolvare

- (c) $s = \sqrt{-2 \ln(\text{raport})} = \sqrt{-2 \ln 0,8048} = 0,659$; excesul $e^{s^2/2} - 1 - s^2/2 = 1/\text{raport} - 1 + \ln(\text{raport}) = 0,0254$
 - Observat în Cursul 14: QLIKE 0,259 cu mediana față de 0,231 cu media, o diferență de același ordin
- Interpretare: transformările monotone păstrează cuantilele, deci $\exp(\text{mediana lui } \log RV)$ este mediana lui RV, cu circa 20% sub medie; QLIKE răsplătește media

B1. Poate ceva să bată prognoza zero pentru S&P 500? [Rezolvat]

Cerință

- **Context:** randamentele log zilnice ale S&P 500 în % (închideri GSPC.INDX, data/market); perioada de test 04.01.2016–18.09.2026 (2 693 de zile); reper: prognoza zero
 - Prognozele la o zi din Cursul 14, cu date până la închiderea precedentă: media istorică, AR(1) (fereastră mobilă de 1.000 de zile), LSTM (media a 5 semințe), Chronos-2, Chronos-Bolt și TimesFM-2.5 (mediana)
- (a) Calculați R^2 în afara eșantionului $= 1 - \sum_t (r_t - \hat{r}_t)^2 / \sum_t r_t^2$ pentru fiecare model, cu un CI de 95% obținut prin bootstrap circular pe blocuri (blocuri de 20 de zile, 1.000 de extrageri)
- (b) Testați fiecare model față de zero cu testul DM pe erorile pătratice (Newey–West, bilateral, 5%) și calculați ponderea semnelor corecte
- (c) Aplicați Clark–West (Clark & West (2007), unilateral) mediei istorice și AR(1), modele imbricate; aplicați SPA (Hansen (2005)) și Romano–Wolf (Romano & Wolf (2005)) celor șase modele (bootstrap staționar, bloc mediu de 20 de zile, 2.000 de extrageri)
- **Raportați** un tabel (R^2 , CI, DM, p , semne corecte) și valorile p Clark–West, SPA și Romano–Wolf

B1. Poate ceva să bată prognoza zero pentru S&P 500?: întrebări de interpretare

Interpretare

- Este semnificativ statistic un R^2 pozitiv de circa 1%? De ce 55% semne corecte nu dovedesc abilitate?
- Bate ceva prognoza zero după ce ținem cont de imbricare și de căutarea printre șase modele?

B1. Rezolvare (1/3): procedura

Rezolvare

- ▣ Pasul 1: aliniați prognozele și randamentele pe cele 2 693 de zile de test; pierderile $e_{0,t}^2 = r_t^2$ (zero) și $e_{1,t}^2 = (r_t - \hat{r}_t)^2$ (model)
- ▣ Pasul 2: $R^2 = 1 - \sum e_{1,t}^2 / \sum e_{0,t}^2$; bootstrap: extrageți blocuri de 20 de zile consecutive, circular, recalculați R^2 de 1.000 de ori, luați percentilele de 2,5% și 97,5%
- ▣ Pasul 3: $d_t = e_{1,t}^2 - e_{0,t}^2$, $DM = \bar{d} / \sqrt{\widehat{LRV} / T}$ cu $\lfloor 4(T/100)^{2/9} \rfloor$ decalaje Bartlett; $p = 2[1 - \Phi(|DM|)]$; respingem acuratețea egală dacă $p < 0,05$
- ▣ Pasul 4: Clark–West $\tilde{d}_t = e_{0,t}^2 - (e_{1,t}^2 - \hat{r}_t^2)$, statistica t HAC, $p = 1 - \Phi(t)$
- ▣ Pasul 5: SPA și Romano–Wolf: câștigurile studentizate t_k ale lui $e_0^2 - e_{1,k}^2$; bootstrap pentru maximul t_k recentrate; Romano–Wolf elimină pas cu pas modelele respinse

B1. Rezolvare (2/3): rezultate

Model	R^2 (%)	CI 95%	DM [p]	Semn corect (%)
Media istorică	+0,15	[-0,02; +0,40]	-1,67 [0,095]	54,6
AR(1)	+0,94	[-2,65; +4,40]	-0,47 [0,639]	54,1
LSTM	+0,93	[+0,17; +1,59]	-1,70 [0,090]	53,5
Chronos-2	-0,26	[-0,89; +0,38]	+0,81 [0,418]	54,7
Chronos-Bolt	-1,57	[-2,73; -0,24]	+1,76 [0,078]	54,6
TimesFM-2.5	-3,35	[-4,62; -1,95]	+3,23 [0,001]	53,6

- LSTM: CI [+0,17; +1,59] exclude zero, dar DM = -1,70, $p = 0,090 > 0,05$: acuratețea egală cu prognoza zero nu este respinsă la 5%
- TimesFM-2.5 este semnificativ mai slab decât zero; AR(1) are un CI uriaș, determinat de 2020
- S&P 500 a crescut în 54,6% din zile: „mereu în creștere” nimereste deja semnul în această proporție

B1. Rezolvare (3/3): imbricare și multe modele

- Prognoza zero este imbricată în media istorică și în AR(1): sub H_0 zgomotul lor de estimare face testul DM prea conservator
 - ▶ Clark–West: $\tilde{d}_t = r_t^2 - [(r_t - \hat{r}_t)^2 - \hat{r}_t^2]$, t HAC unilateral
 - ▶ Cu reperul zero $\tilde{d}_t = 2r_t\hat{r}_t$: CW testează $E[r_t\hat{r}_t] = 0$, o implicație necesară a ipotezei de diferență martingală pentru prognoze construite din date trecute, asimptotic validă în condiții de momente și cu varianță nedegenerată (Clark & West (2006)); DM, SPA și Romano–Wolf testează egalitatea MSE, o altă ipoteză
 - ▶ p unilateral, DM vs CW: media istorică 0,048 vs 0,007; AR(1) 0,320 vs 0,055
- Șase modele testate față de aceeași prognoză zero: p SPA = 0,130 (H_0 : niciunul nu bate prognoza zero)
 - ▶ p ajustat Romano–Wolf: media istorică 0,164, LSTM 0,161
- Interpretare: CW detectează mica derivă a mediei istorice; după ce ținem cont de căutarea printre șase modele, nimic nu bate prognoza zero pe S&P 500

B2. Bitcoin și BET [Propus]

Rezolvarea se discută la seminar

Cerință

- ▣ **Context:** ca în B1, pentru Bitcoin (închideri BTC-USD.CC, zile calendaristice, 2 818 zile din 01.01.2019) și BET (indicele oficial, data/market/BET.csv, 2 675 de zile din 04.01.2016)
 - ▶ Verificarea prețurilor vechi: ETF-ul Patria-TVBETETF, care replică BET (preț ajustat), unit cu BET pe zilele comune înainte de calculul randamentelor
- ▣ (a) Repetați B1(a)–(b) pentru ambele piețe
- ▣ (b) Pentru LSTM pe BET calculați p DM unilateral și Clark–West, Romano–Wolf în cele șase modele BET, SPA pentru BET și p ajustat Holm pe toate cele 18 teste model–piață
- ▣ (c) Calculați autocorelația de ordinul 1 a BET, corelația prognozei LSTM cu r_{t-1} (Lo & MacKinlay (1990)) și R^2 și p Clark–West pentru semnalul LSTM aplicat randamentului ETF din aceeași zi și din ziua următoare
- ▣ **Raportați** tabelele de la (a) și cifrele de la (b)–(c). Model: B1

B2. Bitcoin și BET: întrebări de interpretare

Interpretare

- Care serie are randamente zilnice previzibile și ce model le găsește?
- Rezistă semnalul la testele multiple și la prețurile vechi? Legați răspunsul de Capitolul 2

B3. Volatilitatea realizată: mai bine decât log-HAR? [Rezolvat]

Cerință

- ▣ **Context:** varianța realizată a SPY $RV_t = \sum_{j=1}^{78} r_{t,j}^2$ din bare de 5 minute (data/market/intraday/SPY.US_5m.csv), zile cu cel puțin 70 de bare; 979 de prognoze la o zi, 11.10.2022–18.09.2026
 - ▶ Modele: random walk, HAR și log-HAR (Corsi (2009); fereastră mobilă de 500 de zile), GARCH-t, LSTM, Chronos-2, Chronos-Bolt, TimesFM-2.5 (media din grilă $\int_0^1 \exp(q_u) du$)
- ▣ (a) Calculați pierderea QLIKE medie (Patton (2011)) a fiecărui model
- ▣ (b) Testați fiecare model față de log-HAR cu DM pe diferențele QLIKE (Newey–West, bilateral, 5%)
- ▣ (c) Calculați mulțimea de modele de încredere de 90% (Hansen, Lunde & Nason (2011); statistica $T_{\max}$, bootstrap circular pe blocuri de 10 zile, 1.000 de extrageri); repetați (a)–(b) pe cele 218 zile de după 3 noiembrie 2025
- ▣ **Raportați** un tabel: QLIKE, DM $[p]$, p MCS, QLIKE și DM după publicare

Interpretare

- ▣ Ce vă spune apartenența la MCS și ce nu vă spune?
- ▣ De ce contează fereastra de după publicare doar pentru modelele fundamentale?

B3. Rezolvare (1/2): procedura

Rezolvare

- ▣ Pasul 1: pierderea zilnică $L_{t,m} = RV_t / \hat{h}_{t,m} - \log(RV_t / \hat{h}_{t,m}) - 1$ pentru fiecare model m ; media pe cele 979 de zile
- ▣ Pasul 2: $d_t = L_{t,m} - L_{t,\log \text{ HAR}}$; DM cu varianță Newey–West; DM negativ: modelul m mai bun; respingem egalitatea dacă $p < 0,05$
- ▣ Pasul 3: MCS: pentru mulțimea rămasă calculați $t_m = (\bar{L}_m - \bar{L}_{\cdot}) / \widehat{se}$, bootstrap pentru $\max_m t_m$; dacă $p < 0,10$ eliminați cel mai slab model și repetați; p MCS al unui model este maximul curent al acestor valori p
- ▣ Pasul 4: repetați pașii 1–3 pe zilele de după 3.11.2025, când toate cele trei seturi de ponderi erau publice

B3. Rezolvare (2/2): rezultate

Model	QLIKE	DM vs log-HAR [p]	MCS p	QLIKE (după)	DM (după)
Random walk	0,326	+4,53 [$<0,001$]	0,00	0,384	+2,81
HAR	0,247	+1,30 [0,195]	0,29	0,270	+1,40
log-HAR	0,234	–	0,95	0,238	–
GARCH-t	0,283	+3,43 [$<0,001$]	0,03	0,295	+2,35
LSTM	0,284	+1,68 [0,094]	0,29	0,233	-0,52
Chronos-2	0,231	-0,62 [0,537]	1,00	0,242	+0,57
Chronos-Bolt	0,232	-0,18 [0,857]	0,95	0,236	-0,39
TimesFM-2.5	0,233	-0,08 [0,938]	0,95	0,244	+0,60

- Chronos-2 are cea mai mică QLIKE, dar nu este semnificativ mai bun decât log-HAR (DM -0,62, $p = 0,537$)
- MCS: random walk și GARCH-t sunt eliminate; MCS spune „nu se pot distinge”, nu „la fel de bune”
- După 3.11.2025, LSTM este cel mai bun (0,233); niciun test DM nu este semnificativ față de log-HAR, cu excepția random walk și GARCH-t

B4. Mediana sau media? Și cât context? [Propus]

Rezolvarea se discută la seminar

Cerință

- **Context:** prognozele de cuantile Chronos-2 și TimesFM-2.5 pentru log RV din B3 (aceleași 979 de zile); Chronos-2 și cu contexte de 32, 64, 128, 256 și 512 zile, în aceleași zile de prognoză
- (a) Pentru ambele modele calculați QLIKE și raportul media prognozei / media RV pentru $\exp(q_{0,5})$ și pentru $\int_0^1 \exp(q_u) du$ (trapez pe grilă)
- (b) Testați mediana față de medie pentru Chronos-2 cu DM pe diferențele QLIKE (Newey–West, 5%)
- (c) Calculați QLIKE Chronos-2 pentru fiecare lungime a contextului și comparați cu log-HAR
- **Raportați** tabelul de la (a), statistica DM și QLIKE pe contexte. Model: B3

Interpretare

- De ce introduce mediana o eroare sistematică în prognoza varianței (A10)?
- Ce spune efectul contextului despre memoria volatilității?

B5. Backtesting pentru prognozele de coadă pe S&P 500 [Rezolvat]

Cerință

- **Context:** randamentele log zilnice ale S&P 500 (GSPC.INDX), 2 693 de zile din 04.01.2016; pierderile $L_t = -r_t$; VaR 1%, VaR 2,5% și ES 2,5% la o zi
 - ▶ Șase modele: HS, GARCH(1,1)- t și FHS (fereastră de 1.000 de zile, reestimate la fiecare 20 de zile), cuantile directe Chronos-2, FHS cu volatilitatea Chronos-2 sau TimesFM
- (a) Numărați depășirile VaR 1% $I_t = 1\{L_t > \text{VaR}_t\}$; aplicați testul Kupiec ([Kupiec \(1995\)](#); bilateral, 5%) și testul de independență Christoffersen (lanț Markov de ordinul 1, χ^2_1)
- (b) Calculați pierderea FZ0 medie ([Patton, Ziegel & Chen \(2019\)](#)) a perechii (VaR 2,5%, ES 2,5%) și testele DM față de FHS (Newey–West, 5%)
- (c) Pentru FHS și hibridul Chronos-2 calculați testul DQ ([Engle & Manganelli \(2004\)](#); constantă, patru valori întârziate ale indicatorului de depășire și VaR_t , χ^2_6)
- **Raportați** un tabel: depășiri, rata, p Kupiec, p independență, FZ0, DM față de FHS

B5. Backtesting pentru prognozele de coadă pe S&P 500: întrebări de interpretare

Interpretare

- ▣ De ce eșuează cuantilele directe Chronos-2, în timp ce hibridul trece testul de acoperire?
- ▣ Dacă trece testul de acoperire, trece și testul de independență și egalează FHS?

B5. Rezolvare (1/2): procedura

Rezolvare

- ▣ Pasul 1: depășirile $x = \sum_t l_t$, rata $\hat{\pi} = x/T$; LR_{uc} ca în A8; respingem acoperirea corectă dacă $p < 0,05$
- ▣ Pasul 2: independența: numărați tranzițiile n_{ij} ale $l_{t-1} \rightarrow l_t$, $\hat{\pi}_{01} = n_{01}/(n_{00} + n_{01})$, $\hat{\pi}_{11} = n_{11}/(n_{10} + n_{11})$; LR pentru $\pi_{01} = \pi_{11}$, χ^2_1 (Christoffersen (1998))
- ▣ Pasul 3: $FZ0 = \frac{\mathbf{1}_{\{L > v\}}(L-v)}{\alpha e} + \frac{v}{e} + \log e - 1$ cu $v = \text{VaR } 2,5\%$, $e = \text{ES } 2,5\%$; DM pe diferențele față de FHS
- ▣ Pasul 4: DQ: regresia lui $l_t - 0,01$ pe $(1, l_{t-1}, \dots, l_{t-4}, \text{VaR}_t)$; $DQ = \hat{\beta}^\top X^\top X \hat{\beta} / (0,01 \cdot 0,99)$; respingem dacă $p < 0,05$

B5. Rezolvare (2/2): rezultate (S&P 500, 2 693 de zile)

Model	Depășiri	Rata (%)	p Kupiec	p indep.	FZ0	DM vs FHS
HS	37	1,37	0,065	0,001	1,309	+2,46
GARCH-t	44	1,63	0,002	0,205	1,026	+1,34
FHS	30	1,11	0,559	0,045	0,999	–
Cuantile Chronos-2	45	1,67	0,001	0,223	1,147	+3,16
FHS + vol. Chronos-2	25	0,93	0,705	0,021	1,084	+2,65
FHS + vol. TimesFM	27	1,00	0,989	0,029	1,059	+1,89

- Chronos-2 direct: 1,67% depășiri, p Kupiec = 0,001: cuantilele lui sunt prea înguste
- Hibridul (Chronos-2): 0,93%, p = 0,705: coada vine din date, prin FHS
- Dar depășirile se grupează (p independență = 0,021, p DQ = 0,001), iar FZ0 este semnificativ mai slabă decât la FHS (DM +2,65): corect în medie, cu prea mult capital

B6. Bitcoin și VaR 10% pentru toate cele trei modele [Propus]

Rezolvarea se discută la seminar

Cerință

- ▣ **Context:** cele șase modele de coadă din B5 pentru Bitcoin (BTC-USD.CC, 2818 zile calendaristice din 01.01.2019); și cuantilele de 10% ale Chronos-2, Chronos-Bolt și TimesFM-2.5 față de HS și FHS pe cele trei piețe
- ▣ (a) Repetați B5(a)–(b) pentru Bitcoin
- ▣ (b) Pentru VaR 10% calculați ratele de depășire și testul Kupiec cu $\alpha = 10\%$ (bilateral, 5%) pentru cele cinci modele pe cele trei piețe
- ▣ **Raportați** tabelul de la (a) și un tabel 3×5 cu ratele de depășire și p Kupiec. Model: B5

Interpretare

- ▣ Este îngustimea cuantilelor modelelor fundamentale specifică nivelului de 1%?

B7. Loteria semințelor [Rezolvat]

Cerință

- ▣ **Context:** LSTM-ul pentru randamente din Cursul 14: intrarea ultimele 20 de randamente standardizate, 16 unități ascunse, pierdere MSE, Adam, weight decay 10^{-4} , oprire timpurie pe ultimele 20% din până la 4.000 de zile de antrenare; antrenat o singură dată înaintea fiecărei perioade de test din B1–B2
 - ▶ Cinci rețele identice cu excepția semințelor aleatoare (0–4)
- ▣ (a) Calculați R^2 în afara eșantionului față de zero pentru fiecare sămânță, pe cele trei piețe
- ▣ (b) Calculați R^2 pentru media celor cinci prognoze
- ▣ **Raportați** un tabel 3×6 cu R^2 (%)

Interpretare

- ▣ Ce ați concluziona dintr-o singură rulare pe Bitcoin?
- ▣ De ce este media prognozelor obținute cu semințe diferite o formă de regularizare?

B7. Rezolvare (1/2): procedura

Rezolvare

- Pasul 1: pentru fiecare sămânță s , $R_s^2 = 1 - \sum_t (r_t - \hat{r}_{t,s})^2 / \sum_t r_t^2$
- Pasul 2: prognoza medie $\bar{r}_t = \frac{1}{5} \sum_s \hat{r}_{t,s}$ și R^2 al ei
- Pasul 3: comparați dispersia între semințe cu mărimea lui R^2 ; din convexitatea erorii pătratice, eroarea pătratică a prognozei medii nu depășește media erorilor pătratice ale prognozelor individuale

B7. Rezolvare (2/2): rezultate

R^2 (%)	Sămânța 0	1	2	3	4	Media
S&P 500	+0,55	+0,37	+0,70	+0,54	+1,96	+0,93
Bitcoin	+0,11	+0,03	-0,79	-0,12	+0,24	+0,04
BET	+1,06	+1,01	+1,12	+1,22	+1,12	+1,15

- Bitcoin: semințele variază între -0,79% și +0,24%: o singură rulare ar putea „arăta” abilitate sau lipsa ei
- BET: toate cele cinci semințe sunt de acord; media reduce varianța fără a introduce o eroare sistematică suplimentară, ca bagging-ul

B8. Informații viitoare în regresori [Propus]

Rezolvarea se discută la seminar

Cerință

- ▣ **Context:** log RV al SPY ca în B3; log-HAR pe o fereastră mobilă de 500 de zile cu regresorii $\log RV_{t-1}$ și mediile pe 5 și 22 de zile; prognoza $\exp(\hat{y}_t + \hat{s}^2/2)$
- ▣ (a) Construiți o variantă greșită în care mediile pe 5 și 22 de zile includ ziua prognozată t
- ▣ (b) Calculați QLIKE pentru log-HAR corect, log-HAR greșit și Chronos-2 pe aceleași 979 de zile; testați varianta greșită față de cea corectă cu DM (Newey–West, 5%)
- ▣ **Raportați** cele trei valori QLIKE, câștigul relativ și testul DM. Model: B3

Interpretare

- ▣ Cât de mare este câștigul din privirea în viitor? L-ar putea obține un model corect?
- ▣ Unde se poate ascunde aceeași eroare într-un proces de deep learning?

B9. Calibrarea întregii distribuții predictive [Rezolvat]

Cerință

- ▣ **Context:** S&P 500 (GSPC.INDX), 2 693 de zile din 04.01.2016; grila Chronos-2 directă de 21 de cuantile (1%, 5%, 10%, ..., 99%); FHS și GARCH-t (fereastră de 1.000 de zile, reestimate la fiecare 20 de zile) evaluate pe aceeași grilă
- ▣ (a) Calculați PIT $u_t = \hat{F}_t(r_t)$ (Diebold, Gunther & Tay (1998)) prin interpolare liniară între cuantilele grilei, cenzurat în afara $[q_{1\%}, q_{99\%}]$; aplicați χ^2 Pearson frecvențelor din cele 22 de intervale ale grilei (21 de grade de libertate)
- ▣ (b) Aplicați testul LR Berkowitz (Berkowitz (2001)) pentru $\mu = 0$, $\sigma = 1$ lui $z_t = \Phi^{-1}(u_t)$, cu o verosimilitate Normală cenzurată sub 1% și peste 99% (χ^2_2 , 5%)
- ▣ (c) Calculați scorul cuantic QS $_t = \frac{2}{K} \sum_k (1\{r_t < q_{u_k}\} - u_k)(q_{u_k} - r_t)$ (un scor cuantic cu ponderi egale; CRPS ar pondera fiecare nivel cu distanța dintre niveluri, Gneiting & Raftery (2007)) și DM pentru Chronos-2 minus FHS, total, în centru (10%–90%) și în cozi
- ▣ **Raportați** histograma PIT și un tabel: ponderile din cozi, $\hat{\mu}/\hat{\sigma}$, p Berkowitz, p χ^2 , QS

Interpretare


- ▣ Este eșecul modelului fundațional în centru sau în cozi?
- ▣ De ce cenzurăm în loc să extrapolăm dincolo de grilă?

B9. Rezolvare (1/2): procedura

Rezolvare

- ▣ Pasul 1: pentru fiecare model, pe propria grilă de 21 de cuantile: dacă $q_{1\%,t} \leq r_t \leq q_{99\%,t}$, u_t = interpolarea liniară a nivelurilor între cele două cuantile vecine; altfel se notează doar „sub” sau „peste”
- ▣ Pasul 2: $\chi^2 = \sum_{j=1}^{22} (O_j - Tp_j)^2 / (Tp_j)$, p_j = lățimea intervalului j
- ▣ Pasul 3: $\ell(\mu, \sigma) = \sum_{\text{interior}} \log \frac{1}{\sigma} \varphi\left(\frac{z_t - \mu}{\sigma}\right) + n_L \log \Phi\left(\frac{c_L - \mu}{\sigma}\right) + n_H \log \left[1 - \Phi\left(\frac{c_H - \mu}{\sigma}\right)\right]$, $c_L = \Phi^{-1}(0,01)$, $c_H = \Phi^{-1}(0,99)$
- ▣ LR = $2[\ell(\hat{\mu}, \hat{\sigma}) - \ell(0, 1)] \sim \chi^2_2$; respingem calibrarea dacă $p < 0,05$; $\hat{\sigma} > 1$ înseamnă rezultate mai dispersate decât prognoza; testul evaluează funcția de repartiție interpolată pe grilă și doar μ, σ , nu dependența în timp a PIT
- ▣ Pasul 4: QS pe toate cele 21 de niveluri, pe cele 17 niveluri centrale și pe cele 4 niveluri din cozi; DM cu varianță Newey–West

B9. Rezolvare (2/2): rezultate



Model	Sub $q_{1\%}$ (%)	Peste $q_{99\%}$ (%)	$\hat{\mu} / \hat{\sigma}$	p Berkowitz	$\chi^2 p$	QS
Chronos-2	1,67	1,08	-0,035 / 1,030	0,019	0,004	0,5101
FHS	1,11	1,34	+0,014 / 0,990	0,599	0,747	0,5062
GARCH-t	1,63	0,30	-0,041 / 0,976	0,023	<0,001	0,5063

- Chronos-2: prea multe randamente sub cuantila de 1%, $\hat{\sigma} > 1$: Berkowitz și χ^2 resping; FHS le trece pe amândouă
- QS, Chronos-2 minus FHS: DM +3,06 (p 0,002); centru +2,51, cozi +3,65: mai slab în ambele, mai ales în cozi
- GARCH-t: Berkowitz (p 0,023) și χ^2 resping: 1,63% sub $q_{1\%}$, dar doar 0,30% peste $q_{99\%}$, o distribuție t simetrică ratează cozile asimetrice; cenzurarea evită inventarea unei cozi pe care grila nu o are

B10. Recalibrarea conformală a Chronos-2 [Propus]

Rezolvarea se discută la seminar

Cerință

- ▣ **Context:** cuantilele Chronos-2 directe din B5, pe cele trei piețe (S&P 500 și BET din 2016, Bitcoin din 2019); evaluare pe zilele comune de după primele 250 de zile de calibrare
- ▣ (a) Corecțai cuantilele de 1% și 2,5% prin inferență conformală adaptivă (Gibbs & Candès (2021)): scoruri $E_t = \hat{q}_{\alpha,t} - r_t$ pe ultimele 250 de zile, cuantila corectată $\hat{q}_{\alpha,t} - \hat{Q}_{1-\alpha_t}(E)$, actualizarea $\alpha_{t+1} = \alpha_t + \gamma(\alpha - \text{err}_t)$ cu $\gamma = 0,001$; deplasați ES 2,5% cu corecția VaR 2,5% (o euristică: fără garanție conformală pentru ES)
- ▣ (b) Repetați cu $\gamma = 0$ (conformal simplu)
- ▣ (c) Testați FHS, Chronos-2 direct, hibridul Chronos-2 și ambele variante conformale: depășiri, acoperire condiționată, DQ (Engle & Manganelli (2004)), FZ0 și DM față de FHS (5%)
- ▣ **Raportați** un tabel pe piață. Modele: B5, B9

Interpretare

- ▣ Poate recalibrarea conformală să facă un model fundațional utilizabil pentru VaR fără GARCH?
- ▣ De ce poate pierde comparația FZ0 un model cu acoperire corectă?

B11. Un test formal înainte/după publicare [Propus]

Rezolvarea se discută la seminar

Cerință

- ▣ **Context:** varianța realizată a SPY, prognozele Chronos-2 și log-HAR din B3 (979 de zile); data-limită comună aleasă pentru perioada de după publicare: 3 noiembrie 2025, prima zi de luni după ce toate cele trei seturi de ponderi erau publice pe Hugging Face (Chronos-2: 30.10.2025); 218 zile după
- ▣ (a) Calculați $d_t = \text{QLIKE}(\text{Chronos-2}) - \text{QLIKE}(\text{log-HAR})$ și mediile lui înainte și după publicare
- ▣ (b) Regresați d_t pe o constantă și $1\{t \geq 3.11.2025\}$ cu erori Newey–West ($\lfloor 4(T/100)^{2/9} \rfloor$ decalaje) și testați $\beta_1 = 0$ la 5%
- ▣ (c) Calculați efectul minim detectabil al lui β_1 , $(z_{0,975} + z_{0,8}) \text{se}_{HAC}(\hat{\beta}_1)$, și limita lui când fereastra de după publicare crește nelimitat (n_{nainte} fix); poate testul atinge vreodată o putere de 80% pentru o diferență de mărimea celei dinainte de publicare?
- ▣ **Raportați** mediile, $\hat{\beta}_1$, t , p , MDE. Model: B3

Interpretare

- ▣ Arată un $\hat{\beta}_1$ nesemnificativ că Chronos-2 nu a memorat perioada de test?
- ▣ Ce design ar da putere testului?

C1. Poate un model fundațional zero-shot să înlocuiască GARCH pentru BET? [Propus]

Rezolvarea se discută la seminar

Cerință

- ▣ **Context:** un manager de risc propune Chronos-2 pentru VaR 1% și ES 2,5% zilnice ale unei poziții pe BET; date: indicele BET oficial (data/market/BET.csv), randamente log zilnice, 2 675 de zile între 04.01.2016 și 18.09.2026; fereastra de după publicare de la 3.11.2025 (217 zile)
- ▣ (a) Testați VaR 1% pentru cele șase modele din B5: depășiri, Kupiec, independența Christoffersen și DQ (5%)
- ▣ (b) Comparați (VaR 2,5%, ES 2,5%) cu FZ0, DM față de FHS și MCS de 90%
- ▣ (c) Clasificați zece blocuri de 250 de zile fără suprapunere în zonele Basel (verde ≤ 4 , galben 5–9, roșu ≥ 10 depășiri); repetați (a) pe fereastra de după publicare
- ▣ (d) Preînregistrați: depuneți prognozele VaR pentru următoarele 20 de zile de tranzacționare înainte ca ele să aibă loc și testați-le ulterior
- ▣ **Raportați** o recomandare de o pagină, cu tabelele de la (a)–(c)

C1. Poate un model fundațional zero-shot să înlocuiască GARCH pentru BET?: întrebări de interpretare

Interpretare

- Acceptați, respingeți sau acceptați ca model alternativ (challenger)?
- Extindere pentru proiect: ajustați fin un model fundațional pe acțiuni românești și refaceți testul

C2: critica unui răspuns AI [Propus]

- Un student îi cere unui asistent AI: „Testează retroactiv VaR 1% la o zi, zero-shot, cu Chronos-2 pentru S&P 500 pe ultimele 1500 de zile, cu un context de 512 zile”
- Asistentul răspunde cu acest cod (spx: închideri zilnice, fără importuri):

```
pipe = BaseChronosPipeline.from_pretrained('amazon/chronos-2')
r = 100 * np.log(spx).diff().dropna().to_numpy()      # daily returns, %
test = np.arange(len(r) - 1500, len(r))
q01 = np.empty(len(test))
for i, t in enumerate(test):                          # forecast of r[t]
    ctx = torch.tensor(r[t - 511:t + 1], dtype=torch.float32) # 512 days
    q, _ = pipe.predict_quantiles([ctx[None, :]], prediction_length=1,
                                quantile_levels=[0.01])
    q01[i] = q[0][0, 0].item()
x = int((r[test] < q01).sum())                          # breaches
print(f"VaR_1%={q01.mean():.2f}%, breaches={x}")
```

- „Rezultat: VaR 1% = -2,41%, depășiri = 5, adică 0,33% față de 15 așteptate: modelul este prudent, deci trece ușor testul Kupiec”

C2: critica unui răspuns AI, cerința [Propus]

Rezolvarea se discută la seminar

Cerință

- ▣ **Context:** codul și concluzia de pe slide-ul anterior; închiderile zilnice ale S&P 500, ultimele 1 500 de zile, Chronos-2 zero-shot cu un context de 512 zile; răspunsul conține **trei** erori, în cod și în concluzie
- ▣ (a) Pentru fiecare eroare, spuneți ce este greșit și de ce
- ▣ (b) Spuneți cum ați detecta-o: o verificare a indicilor, convenția VaR din curs, statistica testului
- ▣ (c) Dați linia sau concluzia corectată și calculați statistica Kupiec și valoarea p pentru 5 depășiri în 1 500 de zile
- ▣ Treceți cele trei erori ca în AI_ERRORS.md: ce s-a cerut, ce a răspuns AI-ul, ce era greșit, cum v-ați dat seama, varianta corectă

Interpretare

- ▣ Care element din x ar trebui să fie ultimul din context când prognozăm $x[t]$?
- ▣ Sunt „prea puține depășiri” o veste bună pentru un manager de risc? Dar pentru autoritatea de supraveghere?
- ▣ Ponderile Chronos-2 au fost publicate în toamna lui 2025: sunt ultimele 1 500 de zile un test curat pentru el?

C3. Modele complexe pe datele cursului [Propus]

Rezolvarea se discută la seminar

Cerință

- Context: studiul de caz din Cursul 14 (Kelly, Malamud & Zhou (2024)) ajustează expunerea la piața americană de acțiuni folosind regresii ridge pe până la 12 000 de trăsături Fourier aleatoare ale celor 15 predictorii din Welch & Goyal (2008); aplicați metoda pe șapte dintre predictorii lui, pe datele cursului, lunar, din 1993 (o aplicație, nu o replicare exactă)
 - Model: B1, doar pentru etapele evaluării; aici R^2 în afara eșantionului = $1 - \text{Var}(\text{eroare})/\text{Var}(R)$ (nota 40 din lucrare), nu R^2 față de prognoza zero din B1
- (a) Construiți datele lunare: randamentele totale ale SPY din prețurile ajustate de la sfârșitul lunii (data/market), minus TB3MS/1200 din luna precedentă (FRED; o aproximare, pentru că TB3MS este o rată de discount anualizată)
 - Predictorii datați t , în zecimale: $\text{tbl} = \text{TB3MS}/100$, $\text{lt}_y = \text{GS10}/100$, $\text{tms} = \text{lt}_y - \text{tbl}$, $\text{df}_y = (\text{BAA} - \text{AAA})/100$, $\text{infl} = \text{variația lunară a CPIAUCSL}$, întârziată cu o lună (date revizuite, nu în timp real), $\text{svr} = \text{suma pătratelor randamentelor log zilnice ale S\&P 500 din luna } t \text{ și randamentul în exces din luna } t \text{ ca predictor pentru luna } t + 1$
- (b) Standardizați ca în Secțiunea V.A a lucrării: randamentele prin împărțire la abaterea standard necentrată din ultimele 12 luni, iar predictorii prin împărțire la abaterea standard pe o fereastră cu început fix și lungime crescătoare, după 36 de luni de inițializare
- (c) Generați 12 000 de trăsături Fourier aleatoare cu $\gamma = 2$ (ec. 20); pentru P pe o grilă de 24 de valori de la 2 la 12 000 (fiecare pereche sinus-cosinus contează ca două trăsături) și $\log_{10} z = -3, \dots, 3$, estimați ridge fără termen liber pe ferestre mobile de 12 luni, cu trăsăturile scalate cu abaterea lor standard din fereastra de antrenare, și calculați randamentul strategiei $\hat{\beta}' S_t R_{t+1}$; calculați media fiecărei statistici pe 1 000 de extrageri ale trăsăturilor
- (d) Estimați regresia liniară cu toți cei șapte predictorii (kitchen sink), cu $z = 0^+$ și $z = 10^3$, pe aceleași ferestre
- Raportați curbele pentru $\|\hat{\beta}\|^2$, R^2 în afara eșantionului și raportul Sharpe în funcție de $c = P/T$ (ca în Figurile 7–8) și un tabel în formatul Tabelului I pentru cele două modele liniare și RFF cu $c = 1\,000$, $z = 10^3$: R^2 , raportul Sharpe anualizat și statistica t asociată, rapoartele de informație față de SPY și față de modelul liniar, cu statisticile t asociate, pierderea maximă, asimetria

C3. Modele complexe pe datele cursului: întrebări de interpretare

Interpretare

- ▣ Regresia voastră kitchen sink are $c = 7/12$, față de $15/12$ în lucrare: mai este aproape de pragul de interpolare și ce prezice curba fără penalizare din Figura 7 pentru R^2 ?
- ▣ Poate raportul Sharpe să fie pozitiv când $R^2 < 0$? Explicați prin descompunerea erorii de prognoză într-o componentă de corelație și una de scală (nota 5 din lucrare)
- ▣ Cu circa 30 de ani de date de test, care este puterea unui test bilateral la 5% pentru un raport de informație de 0,3? Folosiți t așteptat $\approx$ raport $\times \sqrt{\text{ani}}$ și o aproximare Normală
- ▣ Extindere pentru proiect: înlocuiți trăsăturile aleatoare cu reprezentările interne (embeddings) ale unui model fundațional pre-antrenat și repetați (c)

Temă pentru acasă (proiectul de echipă)

- ▣ Alegeți un activ nediscutat la seminar (o acțiune BVB, un crypto-activ, un curs valutar sau o marfă)
- ▣ Prognozați volatilitatea zilnică sau VaR 1% cu un model fundațional, zero-shot, și cu un reper GARCH
 - ▶ Actualizați succesiv momentul emiterii prognozei; fereastra de context trebuie să se încheie în ziua dinaintea celei prognozate
 - ▶ Raportați separat perioada de după data publicării modelului
- ▣ Comparați modelele cu testul DM și, pentru VaR, cu testele de acoperire și de independență
- ▣ Notați fiecare eroare a asistentului AI pe care o identificați în `AI_ERRORS.md` (cel puțin trei pe proiect)
- ▣ Livrați un folder Quantlet (cod, Metainfo, grafice) și trei slide-uri: cifre, interpretare, limite

Bibliografie (1/3)

- ▣ Ansari, A.F., Shchur, O., Küken, J., Auer, A., et al. (2025). [Chronos-2: from univariate to universal forecasting](#). [arXiv:2510.15821](#).
- ▣ Ansari, A.F., Stella, L., Turkmen, C., Zhang, X., et al. (2024). [Chronos: learning the language of time series](#). *Transactions on Machine Learning Research*; [arXiv:2403.07815](#).
- ▣ Berkowitz, J. (2001). [Testing density forecasts, with applications to risk management](#). *Journal of Business & Economic Statistics*, 19(4), 465–474.
- ▣ Christoffersen, P.F. (1998). [Evaluating interval forecasts](#). *International Economic Review*, 39(4), 841–862.
- ▣ Clark, T.E., West, K.D. (2006). [Using out-of-sample mean squared prediction errors to test the martingale difference hypothesis](#). *Journal of Econometrics*, 135(1–2), 155–186.
- ▣ Clark, T.E., West, K.D. (2007). [Approximately normal tests for equal predictive accuracy in nested models](#). *Journal of Econometrics*, 138(1), 291–311.
- ▣ Corsi, F. (2009). [A simple approximate long-memory model of realized volatility](#). *Journal of Financial Econometrics*, 7(2), 174–196.
- ▣ Diebold, F.X., Gunther, T.A., Tay, A.S. (1998). [Evaluating density forecasts with applications to financial risk management](#). *International Economic Review*, 39(4), 863–883.

Bibliografie (2/3)

- ▣ Diebold, F.X., Mariano, R.S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3), 253–263.
- ▣ Engle, R.F., Manganelli, S. (2004). CAViaR: conditional autoregressive value at risk by regression quantiles. *Journal of Business & Economic Statistics*, 22(4), 367–381.
- ▣ Franke, J., Härdle, W.K., Hafner, C.M. (2019). *Statistics of Financial Markets: An Introduction*, 5th ed. Springer.
- ▣ Gibbs, I., Candès, E. (2021). Adaptive conformal inference under distribution shift. *NeurIPS*; arXiv:2106.00170.
- ▣ Gneiting, T. (2011). Making and evaluating point forecasts. *Journal of the American Statistical Association*, 106(494), 746–762.
- ▣ Gneiting, T., Raftery, A.E. (2007). Strictly proper scoring rules, prediction, and estimation. *Journal of the American Statistical Association*, 102(477), 359–378.
- ▣ Hansen, P.R. (2005). A test for superior predictive ability. *Journal of Business & Economic Statistics*, 23(4), 365–380.
- ▣ Hansen, P.R., Lunde, A., Nason, J.M. (2011). The model confidence set. *Econometrica*, 79(2), 453–497.

Bibliografie (3/3)

- ▣ Hochreiter, S., Schmidhuber, J. (1997). Long short-term memory. *Neural Computation*, 9(8), 1735–1780.
- ▣ Kelly, B., Malamud, S., Zhou, K. (2024). The virtue of complexity in return prediction. *Journal of Finance*, 79(1), 459–503.
- ▣ Kupiec, P.H. (1995). Techniques for verifying the accuracy of risk measurement models. *Journal of Derivatives*, 3(2), 73–84.
- ▣ Lo, A.W., MacKinlay, A.C. (1990). An econometric analysis of nonsynchronous trading. *Journal of Econometrics*, 45(1–2), 181–211.
- ▣ McNeil, A.J., Frey, R. (2000). Estimation of tail-related risk measures for heteroscedastic financial time series: an extreme value approach. *Journal of Empirical Finance*, 7(3–4), 271–300.
- ▣ Pascanu, R., Mikolov, T., Bengio, Y. (2013). On the difficulty of training recurrent neural networks. *ICML*; arXiv:1211.5063.
- ▣ Patton, A.J. (2011). Volatility forecast comparison using imperfect volatility proxies. *Journal of Econometrics*, 160(1), 246–256.
- ▣ Patton, A.J., Ziegel, J.F., Chen, R. (2019). Dynamic semiparametric models for expected shortfall (and value-at-risk). *Journal of Econometrics*, 211(2), 388–413.
- ▣ Romano, J.P., Wolf, M. (2005). Stepwise multiple testing as formalized data snooping. *Econometrica*, 73(4), 1237–1282.
- ▣ Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., et al. (2017). Attention is all you need. *NeurIPS*; arXiv:1706.03762.
- ▣ Welch, I., Goyal, A. (2008). A comprehensive look at the empirical performance of equity premium prediction. *Review of Financial Studies*, 21(4), 1455–1508.