



Modelarea piețelor financiare

Seminarul 14: Deep learning și modele fundamentale pentru serii de timp — aplicații



Daniel Traian PELE

Drd. Antoaneta Amza, antoaneta.amza@csie.ase.ro

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognostic Economică

MSCA Digital Finance

Acronime folosite în acest material (1/2)

- ▣ ACF: AutoCorrelation Function (funcția de autocorelație)
- ▣ ACI: Adaptive Conformal Inference (inferență conformală adaptivă)
- ▣ AI: Artificial Intelligence (inteligență artificială)
- ▣ AR: AutoRegressive (model); in event studies: Abnormal Return (model autoregresiv; în studiile de eveniment: randament anormal)
- ▣ BET: Bucharest Exchange Trading (index) (indicele de referință al Bursei de Valori București)
- ▣ BVB: Bursa de Valori București
- ▣ CI: Confidence Interval (interval de încredere)
- ▣ CW: Clark–West (test for nested models) (testul Clark–West pentru modele imbricate)
- ▣ DM: Diebold–Mariano (test) (testul Diebold–Mariano de comparare a prognozelor)
- ▣ DQ: Dynamic Quantile (test) (testul cuantilei dinamice)
- ▣ ES: Expected Shortfall (pierderea așteptată în coadă)
- ▣ ETF: Exchange-Traded Fund (fond tranzacționat la bursă)
- ▣ FHS: Filtered Historical Simulation (simulare istorică filtrată)
- ▣ FRED: Federal Reserve Economic Data (baza de date economice a Rezervei Federale (St. Louis))
- ▣ FZ0: Fissler–Ziegel loss, zero-homogeneous version (funcția de pierdere Fissler–Ziegel, varianta omogenă de grad zero)
- ▣ GARCH: Generalised AutoRegressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă generalizată)
- ▣ GPD: Generalised Pareto Distribution (distribuția Pareto generalizată)
- ▣ HAC: Heteroskedasticity and Autocorrelation Consistent (standard errors) (erori standard robuste la heteroscedasticitate și autocorelație)
- ▣ HAR: Heterogeneous AutoRegressive (model) (model autoregresiv heterogen)
- ▣ HS: Historical Simulation (simulare istorică)
- ▣ LR: Likelihood Ratio (test) (testul raportului de verosimilitate)
- ▣ LSTM: Long Short-Term Memory (network) (rețea cu memorie pe termen lung și scurt)
- ▣ MCS: Model Confidence Set (mulțimea de încredere a modelelor)
- ▣ MDE: Minimum Detectable Effect (efectul minim detectabil)
- ▣ MSE: Mean Squared Error (eroarea pătratică medie)
- ▣ OLS: Ordinary Least Squares (metoda celor mai mici pătrate)

Acronime folosite în acest material (2/2)

- ▣ PIT: Probability Integral Transform (transformarea integrală de probabilitate)
- ▣ QLIKE: Quasi-LIKelihood (loss function) (funcția de pierdere de tip cvasi-verosimilitate)
- ▣ QS: Quantile Score (scorul cuantic)
- ▣ RFF: Random Fourier Features (trăsături Fourier aleatoare)
- ▣ RNN: Recurrent Neural Network (rețea neuronală recurentă)
- ▣ RV: Realised Variance (varianța realizată)
- ▣ SPA: Superior Predictive Ability (test) (testul abilității predictive superioare)
- ▣ SUA: Statele Unite ale Americii
- ▣ VAR: Vector AutoRegression (model vector autoregresiv)

Întrebarea de azi și rezultatele cerute

- ▣ Întrebarea seminarului: **rămân valide prognozele de deep learning și ale modelelor fundamentale în urma unei inferențe corecte?**
- ▣ Traseul seminarului
 - ▶ Noțiuni necesare azi: trei slide-uri introductive despre rețele recurente și modele fundamentale ([Capitolul 14](#) este cursul de după seminar)
 - ▶ A5, A8 pe hîrtie, cu instrumentele din [Capitolele 7–8](#) (VaR și ES dintr-o grilă, puterea unui backtest); apoi A3, A1, cu noțiunile introductive (scalarea Chronos, gradientii ca VAR)
 - ▶ B1, B3, B5 pe prognozele salvate: randamente față de zero, volatilitate față de log-HAR, VaR 1% și ES 2,5% față de FHS
 - ▶ C2: identificați erorile dintr-un răspuns AI; B2 ca temă
- ▣ Livrabile: răspunsurile A, cîte un tabel și un grafic pentru fiecare exercițiu B, codul C2 corectat, cîte o propoziție de interpretare pentru fiecare exercițiu
- ▣ Notebook-ul de azi: [deschideți notebook-ul de seminar în Colab](#); fiecare cerință indică secțiunea din notebook
- ▣ Seminar: drd. Antoaneta Amza, antoaneta.amza@csie.ase.ro; material de sprijin: [Capitolele 7 și 8](#) (VaR, backtesting) și noțiunile introductive de mai jos

Harta exercițiilor

Exercițiul	Întrebarea	Tipul	Model
A5	cum citim VaR și ES dintr-o grilă de cuantile?	Rezolvat	–
A8	ce putere are un backtest pe 220 de zile?	Rezolvat	–
A3	cum modifică un crash scala Chronos?	Rezolvat	–
A1	de ce dispare gradientul unei RNN?	Rezolvat	–
B1	poate un model să depășească prognoza zero pentru randamentele S&P 500?	Rezolvat	–
B3	este un model fundațional mai bun decât log-HAR pentru volatilitate?	Rezolvat	–
B5	trec prognozele VaR ale modelelor fundamentale backtest-urile?	Rezolvat	–
C2	ce este greșit într-un răspuns AI?	Propus	A8, B5
B2	Bitcoin și BET: căutarea unui semnal	Propus	B1
Pachete de extindere	A2, A4, A6, A7, A9, A10, B4, B6–B11, C1, C3 (opționale, după seminar)	ambele	la fiecare cerință

- ▣ **[Rezolvat]:** rezolvarea completă în slide-uri și în notebook, un model de urmat; **[Propus]:** o rezoluți dumneavoastră; rezolvarea se discută la seminar
- ▣ Partea A: derivări pe hîrtie; Partea B: inferență pe prognozele salvate, fiecare cu o întrebare de interpretare; Partea C: întrebări deschise și critica unui răspuns AI

Datele folosite

Seria	Simbol, câmp	Calendar	Perioada de test	Folosit în
S&P 500	GSPC.INDX, close	zile de tranzacționare SUA	04.01.2016–18.09.2026 (2 693)	A3, A5, B1, B5
Bitcoin	BTC-USD.CC, close	toate zilele	01.01.2019–18.09.2026 (2 818)	B2
BET	BET, close	zile de tranzacționare BVB	04.01.2016–18.09.2026 (2 675)	B2
ETF pe BET	TVBETETF.RO, adjusted close	zile de tranzacționare BVB	zilele comune cu BET	B2
SPY bare de 5 minute	SPY.US, close la 5 minute	ore de tranzacționare SUA	11.10.2022–18.09.2026 (979)	B3

- Prețurile zilnice din datele cursului, câte o serie pe activ (câmpul folosit: close / adjusted close); randamentele $r_t = 100 \ln(P_t/P_{t-1})$ pe calendarul propriu al fiecărei serii
- Prognozele la o zi calculate pentru [Capitolul 14](#), salvate împreună cu capitolul: randamente (B1, B2), varianța realizată (B3), VaR și ES (B5); fiecare prognoză folosește date pînă la închiderea precedentă

Pregătire: rulați și verificați

```
# notebook section "Setup" defines
# load_csv(name): a forecast table
d = load_csv('ch14_returns_sp500.csv')
print(d.shape, d.index[0].date(),
      d.index[-1].date())
print(d[['y', 'hist', 'lstm',
        'chronos2_q0.50']].head(3).round(4))
rv = load_csv('ch14_rv.csv')
print(rv.shape)
```

- Rezultatul așteptat: (2693, 51), 2016-01-04 pînă la 2026-09-18; rv: (979, 12)

date	y	hist	lstm	q0,50
2016-01-04	-1,5422	0,0265	0,0595	0,0988
2016-01-05	0,2010	0,0263	0,1044	0,0869
2016-01-06	-1,3202	0,0263	0,0587	0,0861

- y: randamentul realizat (%); celelalte coloane: prognozele făcute în seara precedentă
- Dacă dimensiunea sau primul rînd diferă, opriți-vă și verificați numele fișierului

Notația folosită în toate exercițiile (1/2)

- r_t : randamentul logaritmic zilnic în %
 - ▶ $\hat{r}_t$: prognoza lui la o zi; pierderile $L_t = -r_t$
- R^2 în afara eșantionului $= 1 - \sum_t (r_t - \hat{r}_t)^2 / \sum_t r_t^2$
 - ▶ Reperul este prognoza zero; $R^2 > 0$: erori pătratice mai mici decât ale prognozei zero
- Testul DM (Diebold–Mariano, [Diebold & Mariano \(1995\)](#)): $d_t = L_t^A - L_t^B$, pierderea prognozei A minus cea a lui B
 - ▶ $DM = \bar{d} / \sqrt{\widehat{LRV} / T}$: $\bar{d}$ media pe T zile, $\widehat{LRV}$ varianța pe termen lung Newey–West a lui d_t
 - ▶ Negativ: A mai bun; $|DM| > 1,96$ respinge acuratețea egală la 5%

Notăția folosită în toate exercițiile (2/2)

- ▣ RV: varianța realizată, suma pătratelor randamentelor la 5 minute dintr-o zi
 - ▶ Pierderea QLIKE ([Patton \(2011\)](#)): $RV_t/\hat{h}_t - \log(RV_t/\hat{h}_t) - 1$
 - ▶ $\hat{h}_t$: prognoza varianței; pierderea este 0 pentru o prognoză perfectă
- ▣ $VaR_\alpha = -q_\alpha$, $ES_\alpha = -\frac{1}{\alpha} \int_0^\alpha q_u du$
 - ▶ q_u : cuantila de nivel u a lui r_{t+1} ; depășire $I_t = 1\{L_t > VaR_t\}$
- ▣ Testul Kupiec ([Kupiec \(1995\)](#)): x depășiri în T zile, rata observată $\hat{\pi} = x/T$, nivelul VaR α
 - ▶ $LR_{uc} = -2[(T-x)\ln(1-\alpha) + x\ln\alpha - (T-x)\ln(1-\hat{\pi}) - x\ln\hat{\pi}] \sim \chi_1^2$
 - ▶ $LR_{uc} > 3,84$ respinge acoperirea corectă la 5%

Noțiuni necesare azi (1/3): rețele recurente

- **Capitolul 14** este cursul de după acest seminar: aceste trei slide-uri sînt minimul necesar pentru cerințele principale de azi; detaliile și rezultatele, la curs
- Rețea neuronală: straturi $h = \varphi(Wx + b)$, cu intrările x , matricea de ponderi W , vectorul de termeni liberi b și o funcție de activare φ (tanh, ReLU); ponderile se estimează prin coborîre pe gradient pe o funcție de pierdere, gradientii se obțin prin regula lanțului (backpropagation, [Rumelhart, Hinton & Williams \(1986\)](#))
- Rețea neuronală recurentă (RNN): $h_t = \tanh(Wh_{t-1} + Ux_t + b)$, prognoza $\hat{y}_{t+1} = v^\top h_t + c$ (x_t : intrarea, U : ponderile ei, v , c : ponderile de ieșire și termenul liber); aceeași matrice W la fiecare pas, deci starea h_t rezumă tot trecutul
- Gradientul în timp: cîte o jacobiană la fiecare pas, $\partial h_T / \partial h_{T-k} = \prod_{j=0}^{k-1} D_{T-j} W$, $D_t = \text{diag}(1 - h_t^2)$ ([Pascanu, Mikolov & Bengio \(2013\)](#))
 - ▶ Exemplu scalar, $w = 0,9$, $D_t = 1$: $0,9^{20} = 0,12$, $0,9^{50} = 0,005$; o observație de acum 50 de pași aproape nu mai influențează actualizarea ponderilor: gradientul *dispare*; pentru $|w| > 1$ explodează
 - ▶ Instrumente pentru A1: raza spectrală $\rho(W) = \max_i |\lambda_i|$, cu λ_i valorile proprii ale lui W ; norma spectrală $\|W\|_2 = \text{cea mai mare valoare singulară} = \sqrt{\lambda_{\max}(W^\top W)}$; $\|AB\|_2 \leq \|A\|_2 \|B\|_2$; un $\text{VAR}(1)$ $h_t = Wh_{t-1} + \varepsilon_t$ este stabil dacă și numai dacă $\rho(W) < 1$

Noțiuni necesare azi (2/3): LSTM și modele fundamentale

- LSTM (long short-term memory, [Hochreiter & Schmidhuber \(1997\)](#)): porți cu valori în $(0, 1)$ și o stare a celulei
 $c_t = f_t \odot c_{t-1} + i_t \odot g_t$ (f_t : poarta de uitare, i_t : poarta de intrare, g_t : conținutul nou candidat, $\odot$: produs element cu element)
- ▶ Cu o poartă de uitare constantă f , starea celulei este un AR(1) cu coeficientul f : $f = 0,953$ dă un timp de înjumătățire $\ln 0,5 / \ln 0,953 \approx 14$ pași
- **Model fundamental** pentru serii de timp: o rețea mare, pre-antrenată o singură dată pe multe serii și folosită **zero-shot**: fără nicio estimare pe seria-țintă
- ▶ La prognoză primește doar ultimele C valori (**contextul**, aici $C = 512$ zile) și furnizează o grilă de cuantile q_u ale valorii următoare
- ▶ Prognoza punctuală: mediana $q_{0,5}$ sau media $\int_0^1 q_u du$; tail risk: $\text{VaR}_\alpha = -q_\alpha$ ([Capitolul 7](#))
- Chronos ([Ansari et al. \(2024\)](#)): împarte contextul la $s = \frac{1}{C} \sum_t |x_t|$, rotunjește fiecare $z = x/s$ la unul dintre cele 4 093 de intervale din $[-15, 15]$ (tokeni) și modelează tokenii ca pe cuvinte
- ▶ Exemplu: contextul $x = (1, -2, 1)\%$: $s = 4/3$, $z = (0,75; -1,5; 0,75)$; un crah de -6% înlocuiește prima zi: $s = (2 + 1 + 6)/3 = 3$, valoarea scalată a fiecărei zile anterioare se reduce cu factorul $s_{\text{vechi}}/s_{\text{nou}} = 4/9$ (A3)

Noțiuni necesare azi (3/3): prognozele pe care le testăm


Prognoza	Descriere	Folosită în
Media istorică, AR(1)	reper clasice, fereastră de 1 000 de zile	B1
LSTM	rețea recurentă pe randamentele trecute; media a 5 seed-uri	B1, B3
Chronos-2	119 milioane de parametri, cuantile 1%, 5%, ..., 99%; ponderi publicate pe 30.10.2025 (Ansari et al. (2025))	A5, B1, B3, B5
Chronos-Bolt	48 de milioane de parametri, cuantile 10%–90%; publicat pe 25.11.2024	B1, B3
TimesFM-2.5	231 de milioane de parametri, media și cuantilele 10%–90%; publicat pe 01.10.2025 (Das et al. (2024))	B1, B3, B5
FHS + volatilitatea unui model fundațional	hibrid: scala $\hat{\sigma}_t$ = prognoza modelului pentru $ r_t $, apoi FHS (McNeil & Frey (2000)) pe $r_t/\hat{\sigma}_t$	B5

- Fiecare prognoză este făcută în seara dinainte, din datele de pînă la acea închidere; la seminar se testează doar prognozele salvate; nu se antrenează nicio rețea
- **Contaminare:** un model pre-antrenat poate să fi văzut seriile noastre; un test fără contaminare folosește doar zilele de după publicarea tuturor ponderilor, din 3 noiembrie 2025 (circa 220 de zile de tranzacționare: A8, B3, C2)
- Mai mult în [Capitolul 14](#), după seminar: atenția și patch-urile, designul complet al testelor, rezultatele de după publicare

A5 [Rezolvat]: VaR 1% și ES 2,5% dintr-o grilă de cuantile — Cerință

- ▣ **Întrebarea:** cum transformăm grila de cuantile a unui model fundațional în VaR și ES?
- ▣ **Date:** ultima prognoză zero-shot Chronos-2 pentru S&P 500 (ziua de după 18.09.2026, context de 512 randamente): $q_{0,01} = -2,704\%$, $q_{0,05} = -1,400\%$; nivelurile grilei 1%, 5%, 10%, ..., 99%
- ▣ **Cerințe**
 1. Calculați VaR 1% cu convenția $\text{VaR}_\alpha = -q_\alpha$.
 2. Interpolați liniar $q_{0,025}$ între $q_{0,01}$ și $q_{0,05}$ și calculați VaR 2,5%.
 3. Calculați ES 2,5%, păstrînd $q_u = q_{0,01}$ pentru $u < 0,01$ și folosind q_u liniar pe $[0,01; 0,025]$.
- ▣ **Raportați:** VaR 1%, VaR 2,5%, ES 2,5% și raportul ES 2,5% / VaR 2,5%
- ▣ **Interpretare:** comparați raportul cu valoarea lui pentru o distribuție Normală de medie zero, la același nivel: ce informație lipsește din grilă?

A5 [Rezolvat]: Rezolvare




1. $VaR\ 1\% = -q_{0,01} = 2,704\%$.
 2. $q_{0,025} = q_{0,01} + \frac{0,015}{0,04} (q_{0,05} - q_{0,01}) = -2,704 + 0,375 (-1,400 + 2,704) = -2,215\%$, deci $VaR\ 2,5\% = 2,215\%$.
 3. Împărțim integrala (zona roșie): $\int_0^{0,01} q_u du = 0,01 q_{0,01}$ și $\int_{0,01}^{0,025} q_u du = 0,015 (q_{0,01} + q_{0,025})/2$; $ES\ 2,5\% = -\frac{1}{0,025} [\dots] = 2,557\%$.
- Interpretare: $ES/VaR = 1,15$, sub valoarea pentru distribuția Normală, $\varphi(1,96)/(0,025 \cdot 1,96) = 1,19$
- φ : densitatea distribuției Normale standard
 - Grila trunchiază coada de sub 1%, deci acest ES este o aproximare cu coada trunchiată

A8 [Rezolvat]: Puterea exactă a testului Kupiec — Cerință

- ▣ **Întrebarea:** pot 220 de zile de după publicarea ponderilor să deosebească un VaR 1% corect de unul depășit în 1,67% din zile?
- ▣ **Date:** $T = 220$ de zile (3.11.2025–18.09.2026); depășirile $x \sim \text{Bin}(T, \pi)$, distribuția binomială: T zile, fiecare depășită cu probabilitatea π ; testul Kupiec bilateral la 5%: respingem dacă $LR_{uc} > 3,84$; 1,67% este rata de depășire a Chronos-2 direct pe S&P 500 în tot eșantionul (B5)
- ▣ **Cerințe**
 1. Calculați $LR_{uc}(x)$ pentru $x = 0, 1, 2, \dots$ cu $\alpha = 1\%$ și găsiți regiunea de respingere.
 2. Calculați nivelul exact, probabilitatea de a respinge când $\pi = 1\%$.
 3. Calculați puterea, probabilitatea de a respinge când $\pi = 1,67\%$.
- ▣ **Raportați:** regiunea de respingere, nivelul și puterea
- ▣ **Interpretare:** ce îi spune unui manager de risc o nerespingere pe 220 de zile?

A8 [Rezolvat]: Rezolvare



1. $x = 0$: $LR = -2 \cdot 220 \ln 0,99 = 4,42 > 3,84$, respingem (prea puține depășiri); $x = 5$: $LR = 2,65$; $x = 6$: $LR = 4,51$; regiunea de respingere $x = 0$ sau $x \geq 6$.
2. Nivelul = $P_{1\%}(x = 0) + P_{1\%}(x \geq 6) = 0,134$, nu 0,05: o statistică discretă nu poate atinge nivelul nominal.
3. Puterea = $0,9833^{220} + P_{1,67\%}(x \geq 6) = 0,025 + 0,165 = 0,189$; depășiri așteptate 2,2 sub H_0 , 3,7 sub alternativă.


□ Interpretare: cele două distribuții se suprapun aproape complet

- În patru cazuri din cinci, un model cu 67% mai multe depășiri decât trebuie trece testul
- Deci „nerespins” nu dovedește acoperirea corectă

A3 [Rezolvat]: Scalarea prin medie în Chronos: efectul unei zile noi asupra scalei — Cerință

- ▣ **Întrebarea:** cât de mult schimbă o zi nouă scala la care Chronos împarte contextul?
- ▣ **Date:** Chronos (Ansari et al. (2024)) împarte un context de C randamente la $s = \frac{1}{C} \sum_t |x_t|$ și plasează $z = x/s$ în intervalul $j = \text{round}((z + 15)/\Delta)$, $\Delta = 30/4092$; un context de patru zile $x = (0,8; -1,2; 0,4; 2,0)$ (%)
- ▣ **Cerințe**
 1. Fereastra avansează o zi: intră o valoare nouă M și iese x_{out} ; derivați s_{nou} în funcție de s_{vechi} , M , x_{out} și C .
 2. Derivați factorul cu care se schimbă valoarea scalată z a fiecărei zile neschimbate.
 3. Pentru contextul de patru zile calculați s , valorile scalate z și indicii j .
- ▣ **Raportați:** formula de la pașii 1–2 și un tabel cu x , z , j
- ▣ **Interpretare:** cum depinde de C efectul unui crash asupra scalei?

A3 [Rezolvat]: Rezolvare



1. Suma valorilor absolute pierde $|x_{out}|$ și câștigă $|M|$; împărțind la C : $s_{nou} = s_{vechi} + (|M| - |x_{out}|)/C$.
 2. Zi neschimbată x : $z_{nou} = x/s_{nou} = z_{vechi} \cdot s_{vechi}/s_{nou}$.
 3. $s = (0,8 + 1,2 + 0,4 + 2,0)/4 = 1,10$; $z = (+0,727; -1,091; +0,364; +1,818)$; $\Delta = 0,00733$; $j = (2145, 1897, 2096, 2294)$, lângă centrul $j = 2046$ al lui $z = 0$.
- Interpretare: un crah mută s cu circa $|M|/C$ (roșu: ultima zi înlocuită cu -9% , toate celelalte zile se micșorează); un context de 512 zile aproape nu reacționează

A1 [Rezolvat]: Dispariția gradientului ca răspuns la impuls al unui VAR — Cerință

▣ Întrebările


- ▶ de ce dispare gradientul unei rețele recurente simple?
- ▶ ce mărime determină viteza de dispariție?

- ▣ **Date:** RNN $h_t = \tanh(Wh_{t-1} + Ux_t + b)$ cu două unități ascunse, $W = \begin{pmatrix} 0,5 & 0,8 \\ 0 & 0,5 \end{pmatrix}$, liniarizată în $h^* = 0$ ($b = 0, x = 0$); fără fișier de date

▣ Cerințe

1. Derivați jacobiana $\partial h_T / \partial h_{T-k}$ prin regula lanțului și demonstrați că norma ei spectrală este cel mult $\|W\|_2^k$.
 2. Arătați că rețeaua liniarizată este un VAR(1) în h_t și că jacobiana este egală cu răspunsul lui la impuls la orizontul k .
 3. Calculați raza spectrală $\rho(W)$, norma $\|W\|_2$, majorarea $\|W\|_2^k$ și valoarea exactă $\|W^k\|_2$ pentru $k = 5, 20, 50$.
- ▣ **Raportați:** cele două derivări și un tabel cu cifrele de la pasul 3
- ▣ **Interpretare:** majorarea prin normă sau raza spectrală este criteriul potrivit pentru dispariția gradientului?

A1 [Rezolvat]: Rezolvare



1. Un pas: $\partial h_t / \partial h_{t-1} = D_t W$, $D_t = \text{diag}(1 - h_t^2)$; pe k pași $\prod_j D_{T-j} W$; cum $\|D_t\|_2 \leq 1$ și normele sînt submultiplicative, produsul este cel mult $\|W\|_2^k$.
2. În $h^* = 0$, $D_t = I$: $h_t \approx W h_{t-1} + U x_t$, un VAR(1); din $h_T = \sum_k W^k U x_{T-k}$, $\partial h_T / \partial h_{T-k} = W^k$ este răspunsul la impuls.
3. W este triunghiulară: $\rho(W) = 0,50$; $\|W\|_2 = 1,040$, deci majorarea $1,040^{20} = 2,20$ crește; exact $W^k = 0,5^k \begin{pmatrix} 1 & 1,6k \\ 0 & 1 \end{pmatrix}$: $\|W^5\|_2 = 0,254$, $\|W^{20}\|_2 = 3,1 \times 10^{-5}$, $\|W^{50}\|_2 = 7,1 \times 10^{-14}$.

□ Interpretare: majorarea prin normă este suficientă, nu necesară

- Gradientul dispare ca $k 0,5^k$ pentru că $\rho(W) < 1$, criteriul de stabilitate al unui VAR
- Gelfand: $\|W^k\|^{1/k} \rightarrow \rho(W)$


B1 [Rezolvat]: Modelele față de prognoza zero pentru S&P 500 — Cerință

- ▣ **Întrebarea:** prognozează vreunul dintre cele șase modele randamentele zilnice ale S&P 500 mai bine decât prognoza zero, dacă testăm corect?
- ▣ **Date:** `ch14_returns_sp500.csv`: randamentul realizat y și prognozele `hist` (media istorică), `ar1` (fereastră de 1.000 de zile), `1stm` (5 seed-uri), `chronos2_point`, `bolt_point`, `timesfm_point` (mediane); 2 693 de zile din 04.01.2016
- ▣ **Cerințe**
 1. Calculați R^2 în afara eșantionului pentru fiecare model și un interval bootstrap circular pe blocuri de 95% (blocuri de 20 de zile, 1.000 de extrageri).
 2. Testați fiecare model față de zero cu testul DM pe erorile pătratice (bilateral, 5%) și calculați ponderea semnelor corecte.
 3. Aplicați testul Clark–West ([Clark & West \(2007\)](#)) mediei istorice și AR(1), care conțin prognoza zero drept caz particular.
 4. Aplicați SPA ([Hansen \(2005\)](#)) și Romano–Wolf ([Romano & Wolf \(2005\)](#)) celor șase modele (bootstrap staționar, bloc mediu de 20 de zile).
- ▣ **Raportați:** un grafic cu R^2 și intervalele, un tabel (R^2 , interval, DM [p], semne corecte) și p -value-urile Clark–West, SPA și Romano–Wolf
- ▣ **Interpretare**
 - ▶ este semnificativ aici un R^2 de circa 1%?
 - ▶ de ce 55% semne corecte nu dovedesc abilitate?

B1 [Rezolvat]: Rezolvare (1/3) — Pas cu pas

1. Aliniați prognozele și randamentele pe cele 2 693 de zile de test; pierderile $e_{0,t}^2 = r_t^2$ (zero) și $e_{1,t}^2 = (r_t - \hat{r}_t)^2$ (model); $R^2 = 1 - \sum e_{1,t}^2 / \sum e_{0,t}^2$.
2. Bootstrap: extrageți blocuri de 20 de zile consecutive, circular, recalculați R^2 de 1.000 de ori, luați percentilele de 2,5% și 97,5%; LSTM: $R^2 + 0,93\%$, interval $[+0,17; +1,59]$.
3. DM: $d_t = e_{1,t}^2 - e_{0,t}^2$, varianță Newey–West cu $\lfloor 4(T/100)^{2/9} \rfloor$ laguri; LSTM: DM = $-1,70$, $p = 0,090 > 0,05$: acuratețea egală nu este respinsă, deși intervalul bootstrap exclude zero.
4. Clark–West: cu reperul zero $\tilde{d}_t = r_t^2 - [(r_t - \hat{r}_t)^2 - \hat{r}_t^2] = 2r_t\hat{r}_t$, un test t HAC unilateral pentru $E[r_t\hat{r}_t] = 0$ (Clark & West (2006)); p unilateral, DM față de CW: media istorică 0,048 față de 0,007; AR(1) 0,320 față de 0,055.
5. SPA: bootstrap pentru maximul câștigurilor studentizate recentrate; $p = 0,130$ (H_0 : niciun model nu depășește prognoza zero); Romano–Wolf elimină pas cu pas modelele respinse: media istorică 0,164, LSTM 0,161.

B1 [Rezolvat]: Rezolvare (2/3) — Grafic



- Puncte: R^2 ; bare: intervale bootstrap pe blocuri de 95%; roșu: DM respinge acuratețea egală cu zero la 5%
- TimesFM-2.5 este semnificativ mai slab decât zero; AR(1) are un interval foarte larg, determinat de 2020
- Interpretare: CW detectează micul drift al mediei istorice
 - După căutarea printre șase modele (SPA, Romano–Wolf), niciun model nu depășește prognoza zero

B1 [Rezolvat]: Rezolvare (3/3) — Tabel

Model	R^2 (%)	CI 95%	DM [p]	Semn corect (%)
Media istorică	+0,15	[−0,02; +0,40]	−1,67 [0,095]	54,6
AR(1)	+0,94	[−2,65; +4,40]	−0,47 [0,639]	54,1
LSTM	+0,93	[+0,17; +1,59]	−1,70 [0,090]	53,5
Chronos-2	−0,26	[−0,89; +0,38]	+0,81 [0,418]	54,7
Chronos-Bolt	−1,57	[−2,73; −0,24]	+1,76 [0,078]	54,6
TimesFM-2.5	−3,35	[−4,62; −1,95]	+3,23 [0,001]	53,6

- Indicele a crescut în 54,6% din zile: regula „mereu în creștere” ghicește deja semnul în această proporție
- LSTM: intervalul bootstrap exclude zero, dar p DM = 0,090: cele două proceduri răspund la întrebări ușor diferite și niciuna nu rămîne semnificativă după corecția pentru căutarea printre șase modele


B3 [Rezolvat]: Volatilitatea realizată: modele fundamentale față de log-HAR — Cerință

- ▣ **Întrebarea:** sînt modelele fundamentale zero-shot mai bune decît log-HAR la prognoza varianței realizate a SPY?
- ▣ **Date:** `ch14_rv.csv`: RV (suma a 78 de pătrate ale randamentelor la 5 minute, zile cu cel puțin 70 de bare) și prognozele RW, HAR, logHAR (Corsi (2009); fereastră de 500 de zile), GARCH-t, LSTM, Chronos-2, Chronos-Bolt, TimesFM-2.5 (media din grilă); 979 de zile
- ▣ **Cerințe**
 1. Calculați pierderea QLIKE zilnică a fiecărui model și media ei pe cele 979 de zile.
 2. Testați fiecare model față de log-HAR cu DM pe diferențele QLIKE (bilateral, 5%) și reprezentați diferențele medii cu intervale HAC de 95%.
 3. Calculați mulțimea de modele de încredere de 90% (MCS, Hansen, Lunde & Nason (2011); bootstrap pe blocuri de 10 zile).
 4. Repetați pașii 1–2 pe cele 218 zile de după 3 noiembrie 2025, cînd toate cele trei seturi de ponderi erau publice.
- ▣ **Raportați:** graficul și un tabel: QLIKE, DM [p], p MCS, QLIKE și DM după publicare
- ▣ **Interpretare**
 - ▶ ce informație oferă apartenența la MCS?
 - ▶ ce informație nu oferă?

B3 [Rezolvat]: Rezolvare (1/3) — Pas cu pas

1. Pierderea zilnică $L_{t,m} = RV_t / \hat{h}_{t,m} - \log(RV_t / \hat{h}_{t,m}) - 1$; de exemplu la 11.10.2022, $RV = 1,560$ și prognoza Chronos-2 1,437: $L = 1,085 - \log 1,085 - 1 = 0,0034$; medii: Chronos-2 0,231, log-HAR 0,234.
2. $d_t = L_{t,m} - L_{t,\log \text{ HAR}}$; Chronos-2: $\bar{d} = -0,0030$, $DM = -0,62$, deci eroarea standard HAC este $\bar{d}/DM$, iar intervalul de 95% $[-0,0126; +0,0066]$ conține 0 ($p = 0,537$).
3. MCS: pentru mulțimea rămasă calculați $t_m = (\bar{L}_m - \bar{L}) / \widehat{se}(\bar{L}_m)$ (pierderea medie a modelului m , $\bar{L}$: media pe modelele rămase), bootstrap pentru $\max_m t_m$; dacă $p < 0,10$ eliminați cel mai slab model și repetați; p MCS al unui model este maximul curent al acestor p -value-uri.
4. După 3.11.2025: Chronos-2 $\bar{d} = +0,0038$, interval $[-0,0092; +0,0168]$: mai larg, pentru că 218 zile conțin mai puțină informație.

B3 [Rezolvat]: Rezolvare (2/3) — Grafic



- Puncte: diferența medie de QLIKE față de log-HAR; bare: intervale HAC de 95%; albastru: toată perioada, portocaliu: după 3.11.2025
- Chronos-2 are cea mai mică QLIKE, dar toate intervalele modelelor fundamentale conțin 0
 - Random walk și GARCH-t sînt mai slabe și sînt eliminate din MCS
- Interpretare: apartenența la MCS înseamnă „nu se distinge la 90%”, nu „la fel de bun”

B3 [Rezolvat]: Rezolvare (3/3) — Tabel

Model	QLIKE	DM [p]	MCS p	QLIKE după 3.11.2025
Random walk	0,326	+4,53 [$<0,001$]	0,00	0,384
HAR	0,247	+1,30 [0,195]	0,29	0,270
log-HAR	0,234	–	0,95	0,238
GARCH-t	0,283	+3,43 [$<0,001$]	0,03	0,295
LSTM	0,284	+1,68 [0,094]	0,29	0,233
Chronos-2	0,231	–0,62 [0,537]	1,00	0,242
Chronos-Bolt	0,232	–0,18 [0,857]	0,95	0,236
TimesFM-2.5	0,233	–0,08 [0,938]	0,95	0,244

- După publicare, LSTM este cel mai bun (0,233), cu intervale prea largi pentru un clasament
- HAR în niveluri supraestimează; GARCH-t reacționează la randamentele zilnice, nu la informația intrazilnică


B5 [Rezolvat]: Backtesting pentru prognozele VaR și ES pe S&P 500 — Cerință

- ▣ **Întrebarea:** dau cuantilele directe Chronos-2 sau FHS cu volatilitatea unui model fundațional un VaR 1% și un ES 2,5% utilizabile?
- ▣ **Date:** `ch14_risk_sp500.csv`: randamentul y și, pentru șase modele, coloanele `<model>|VaR1, |VaR2.5, |ES2.5`: HS, GARCH-t, FHS (fereastră de 1.000 de zile, reestimare la fiecare 20 de zile), C2-raw, C2-FHS, TFM-FHS; 2 693 de zile
- ▣ **Cerințe**
 1. Numărați depășirile VaR 1% ale fiecărui model și reprezentați numărul lor cumulat față de dreapta așteptată de 1%.
 2. Aplicați testul Kupiec și testul de independență Christoffersen ([Christoffersen \(1998\)](#), χ^2_1) la 5%.
 3. Calculați pierderea FZ0 medie ([Patton, Ziegel & Chen \(2019\)](#)) a perechii (VaR 2,5%, ES 2,5%) și testele DM față de FHS.
 4. Pentru FHS și hibridul Chronos-2 calculați testul DQ ([Engle & Manganelli \(2004\)](#)): regresia lui $I_t - 0,01$ pe o constantă, patru depășiri întârziate și VaR_t .
- ▣ **Raportați:** graficul și un tabel: depășiri, rata, p Kupiec, p independență, FZ0, DM față de FHS
- ▣ **Interpretare:** de ce trece hibridul testul de acoperire și totuși este inferior FHS?

B5 [Rezolvat]: Rezolvare (1/3) — Pas cu pas

1. Depășirile $x = \sum_t I_t$, rata $\hat{\pi} = x/T$; Chronos-2 direct: $x = 45$, $\hat{\pi} = 1,67\%$ față de 26,9 așteptate: LR_{uc} dă $p = 0,001$, acoperirea corectă este respinsă.
2. Independența: numărați tranzițiile n_{ij} ale $I_{t-1} \rightarrow I_t$; $\hat{\pi}_{01} = n_{01}/(n_{00} + n_{01})$, $\hat{\pi}_{11} = n_{11}/(n_{10} + n_{11})$; LR pentru $\pi_{01} = \pi_{11}$; hibridul: $p = 0,021$, depășirile se grupează.
3. $FZ0 = \frac{1\{L > v\}(L-v)}{\alpha_e} + \frac{v}{e} + \log e - 1$ cu $v = \text{VaR } 2,5\%$, $e = \text{ES } 2,5\%$, $\alpha = 0,025$; hibrid 1,084 față de FHS 0,999, DM $+2,65$.
4. $DQ = \hat{\beta}^\top X^\top X \hat{\beta} / (0,01 \cdot 0,99) \sim \chi_6^2$, X : cei șase regresori, $\hat{\beta}$: coeficienții lor OLS; hibrid $p = 0,001$, FHS $p = 0,021$.

B5 [Rezolvat]: Rezolvare (2/3) — Grafic



- Depășirile VaR 1% cumulate ale celor șase modele; negru întrerupt: 1% din zile
- Chronos-2 direct și GARCH-t sînt deasupra dreptei așteptate (prea înguste)
 - Hibrizii o urmează în medie, dar în trepte în 2020 și 2022 (grupări)
- Interpretare: hibridul preia coada din date prin FHS, deci trece testul de acoperire
 - VaR-ul lui reacționează excesiv: depășirile se grupează și necesarul de capital crește (FZ0 mai mare)

B5 [Rezolvat]: Rezolvare (3/3) — Tabel

Model	Depășiri	Rata (%)	p Kupiec	p indep.	FZ0	DM față de FHS
HS	37	1,37	0,065	0,001	1,309	+2,46
GARCH-t	44	1,63	0,002	0,205	1,026	+1,34
FHS	30	1,11	0,559	0,045	0,999	–
Cuantile Chronos-2	45	1,67	0,001	0,223	1,147	+3,16
FHS + vol. Chronos-2	25	0,93	0,705	0,021	1,084	+2,65
FHS + vol. TimesFM	27	1,00	0,989	0,029	1,059	+1,89

- Chronos-2 direct: 1,67% depășiri, p Kupiec = 0,001: cuantilele lui sînt prea înguste; hibridul: 0,93%, p = 0,705
- Calibrat în medie, dar cu depășiri grupate (p independență = 0,021, p DQ = 0,001) și un necesar de capital prea mare (DM FZ0 +2,65 față de FHS)

C2 [Propus]: Critica unui răspuns AI — răspunsul

- Un student îi cere unui asistent AI: „Fă backtesting pentru VaR 1% la o zi, zero-shot, cu Chronos-2 pentru S&P 500 pe ultimele 1 500 de zile, cu un context de 512 zile”
- Asistentul răspunde cu acest cod (spx: închideri zilnice, fără importuri):

```
pipe = BaseChronosPipeline.from_pretrained('amazon/chronos-2')
r = 100 * np.log(spx).diff().dropna().to_numpy()      # daily returns, %
test = np.arange(len(r) - 1500, len(r))
q01 = np.empty(len(test))
for i, t in enumerate(test):                          # forecast of r[t]
    ctx = torch.tensor(r[t - 511:t + 1], dtype=torch.float32) # 512 days
    q, _ = pipe.predict_quantiles([ctx[None, :]], prediction_length=1,
                                  quantile_levels=[0.01])
    q01[i] = q[0][0, 0, 0].item()
x = int((r[test] < q01).sum())                          # breaches
print(f"VaR1%={q01.mean():.2f}%, breaches={x}")
```

- „Rezultat: VaR 1% = -2,41%, depășiri = 5, adică 0,33% față de 15 așteptate: modelul este prudent, deci trece ușor testul Kupiec”

C2 [Propus]: Critica unui răspuns AI — Cerință

- ▣ **Model:** A8 și B5 [Rezolvat]
- ▣ **Întrebarea:** ce trei erori conține răspunsul, în cod și în concluzie?
- ▣ **Date:** codul și rezultatul de pe slide-ul anterior; închiderile zilnice ale S&P 500, ultimele 1 500 de zile, Chronos-2 zero-shot, context de 512 zile
- ▣ **Cerințe**
 1. Pentru fiecare eroare, precizați ce este greșit și de ce este important.
 2. Precizați cum ați detecta-o: o verificare a indicilor, convenția VaR din [Capitolul 7](#) sau statistica testului.
 3. Dați linia sau concluzia corectată și calculați statistica Kupiec și p -value-ul pentru 5 depășiri în 1 500 de zile.
 4. Treceți cele trei erori în `AI_ERRORS.md`: ce s-a cerut, ce a răspuns AI-ul, ce era greșit, cum ați identificat eroarea, varianta corectă.
- ▣ **Raportați:** cele trei erori cu detectarea și corectarea lor, statistica Kupiec, înregistrarea din jurnal
- ▣ **Interpretare**
 - ▶ sînt „prea puține depășiri” o veste bună pentru un manager de risc?
 - ▶ dar pentru autoritatea de supraveghere?
 - ▶ sînt ultimele 1 500 de zile un test fără contaminare pentru un model publicat în toamna lui 2025?

B2 [Propus]: Bitcoin și BET: căutarea unui semnal — Cerință

▣ **Model:** B1 [Rezolvat]

▣ **Întrebările**

- ▶ se mențin rezultatele din B1 pentru Bitcoin și pentru indicele românesc BET?
- ▶ rămîne vreun semnal BET după controlul pentru prețurile stale (neactualizate)?

▣ **Date:** `ch14_returns_btc.csv` (2 818 zile calendaristice din 01.01.2019) și `ch14_returns_bet.csv` (2 675 de zile din 04.01.2016), aceleași coloane ca în B1; ETF-ul pe BET TVBETETF.R0 (preț ajustat)

▣ **Cerințe**

1. Repetați pașii 1–2 din B1 pentru ambele piețe și reprezentați intervalele R^2 alăturat.
2. Pentru LSTM pe BET, calculați p -value-urile DM unilateral și Clark–West, Romano–Wolf și SPA în cele șase modele BET și p ajustat Holm pe toate cele 18 teste model–piață.
3. Calculați autocorelația de ordinul 1 a BET și corelația prognozei LSTM cu r_{t-1} (Lo & MacKinlay (1990)).
4. Aliniați prețurile BET și ETF pe zilele comune, apoi aplicați semnalul LSTM randamentului ETF din aceeași zi și din ziua următoare (R^2 , p Clark–West).

▣ **Raportați:** graficul cu două panouri, cele două tabele și cifrele de la pașii 2–4

▣ **Interpretare**

- ▶ ce piață are randamente zilnice predictibile?
- ▶ este semnalul tranzacționabil după costuri (Capitolul 2)?

Pasul pentru proiectul de echipă

- Un activ nediscutat la seminar (o acțiune BVB, un criptoactiv, un curs valutar sau o marfă)
- Volatilitatea sau VaR 1% al lui: un model fundațional zero-shot față de un reper GARCH; contextul se încheie în ziua dinaintea prognozei; perioada de după publicare raportată separat
- Testul DM și, pentru VaR, testele de acoperire și independență
- Un folder Quantlet (cod, Metainfo, grafice); utilizarea AI în AI_USE.md, erorile identificate în AI_ERRORS.md; pachetele de extindere sînt opționale

Pachete de extindere: condițiile fiecăruia

Pachetul	Exerciții	Condiții
1. Memoria rețelelor recurente	A2	A1
2. Tokeni și grile de cuantile	A4, A6	A3, A5
3. Tail risk și calibrare	B6, A7, B9 [Rezolvat], B10	A5, B5
4. Puterea testelor	A9, B11	A8, B3
5. Prognoza volatilității	A10 [Rezolvat], B4, B8	B3
6. Practica deep learning	B7 [Rezolvat]	B1
7. Proiecte	C1, C3	B5; studiul de caz din curs

- Parcurgeți exercițiile în ordine în cadrul fiecărui pachet; fiecare exercițiu indică secțiunea din notebook și modelul
- C1 și C3 sînt posibile puncte de plecare pentru proiectul de echipă

A2 [Propus]: Starea celulei LSTM ca AR(1) — Cerință

▣ **Model:** A1 [Rezolvat]

▣ **Întrebările**

- ▶ cît timp își amintește un LSTM cu poarta de uitare constantă?
- ▶ poate reproduce memoria lungă?

▣ **Date:** celula $c_t = fc_{t-1} + ig_t$, $f = \sigma(b_f)$ și i constante, g_t i.i.d. cu media 0 și varianța σ_g^2 ; ACF-ul lui $|r_t|$ pentru S&P 500 din 2000: 0,289 (lag 1), 0,132 (lag 50), 0,059 (lag 150)

▣ **Cerințe**

1. Arătați că c_t este un AR(1) staționar pentru $0 < f < 1$ și derivați $\text{Var}(c_t)$ și $\text{Corr}(c_t, c_{t-k})$.
2. Calculați timpul de înjumătățire $\ln 0,5 / \ln f$ pentru $b_f = 1$ și pentru $f = 0,99$, termenul liber care dă $f = 0,99$ și f^{250} pentru $b_f = 5$.
3. Ajustați $\rho_k = \rho_1 f^{k-1}$ cu $f^{49} = \rho_{50} / \rho_1$ și prognozați ρ_{150} .

▣ **Raportați:** derivările și cifrele de la pașii 2–3

▣ **Interpretare**

- ▶ de ce niciun $f < 1$ fix nu poate reproduce memoria lungă?
- ▶ ce structură alternativă îi trebuie rețelei?

A4 [Propus]: O zi de crah în context — Cerință

- ▣ **Model:** A3 [Rezolvat]
- ▣ **Întrebarea:** face un crah ca zilele obișnuite să pară calme pentru Chronos?
- ▣ **Date:** scalarea din A3; S&P 500 la 16 martie 2020: randamentul de $-12,77\%$ intră într-un context de 512 zile și iese o zi de $0,51\%$; înaintea crahului $s_{\text{vechi}} = 0,741\%$
- ▣ **Cerințe**
 1. Înlocuiți ultima valoare din contextul A3 cu $-9,0$ și recalculați s , z , j și factorul $s_{\text{vechi}}/s_{\text{nou}}$.
 2. Aplicați formula din A3 cazului S&P 500 și calculați s_{nou} și factorul.
 3. Calculați valoarea scalată a unei zile obișnuite de $0,4\%$ înainte și după crah, în ambele cazuri.
- ▣ **Raportați:** s , factorul și z al zilei de $0,4\%$ în ambele cazuri
- ▣ **Interpretare:** face un context de 512 zile ca zilele obișnuite să pară calme după un crah?

A6 [Propus]: Coadă limitată a grilei; o coadă GPD — Cerință

▣ **Model:** A5 [Rezolvat]

▣ **Întrebările**

- ▶ în ce sens deplasează grila ES?
- ▶ ce indică o coadă groasă estimată?

▣ **Date:** grila din A5; pierderile S&P 500 $L = -r$ pe ultimele 1.000 de zile pînă la 18.09.2026; depășiri peste prag: u = cuantila de 95% a lui L , excesele $L - u \sim \text{GPD}(\xi, \beta)$, distribuția Pareto generalizată cu forma ξ (mai mare: coadă mai groasă) și scala β , $\xi < 1$ (McNeil & Frey (2000)); n : mărimea eșantionului, N_u : numărul de excese

▣ **Cerințe**

1. Demonstrați că păstrarea $q_u = q_{0,01}$ pentru $u < 0,01$ nu mărește niciodată ES 2,5% și arătați că interpolarea liniară pe $[0,01; 0,025]$ poate produce erori în ambele sensuri.
2. Derivați $\text{ES}_\alpha = \frac{\text{VaR}_\alpha}{1-\xi} + \frac{\beta-\xi u}{1-\xi}$ din funcția excesului mediu a GPD.
3. Estimați ξ, β prin verosimilitate maximă și calculați $\text{VaR}_\alpha = u + \frac{\beta}{\xi} [(n\alpha/N_u)^{-\xi} - 1]$ pentru 1% și 2,5%, și ES 2,5%.

▣ **Raportați:** u , N_u , $\hat{\xi}$, $\hat{\beta}$, VaR, ES și ES/VaR

▣ **Interpretare:** de ce este ES/VaR mai mare aici decît în A5?

B6 [Propus]: Bitcoin și VaR 10% pentru toate cele trei modele — Cerință

- ▣ **Model:** B5 [Rezolvat]
- ▣ **Întrebările**
 - ▶ se mențin concluziile din B5 pentru Bitcoin?
 - ▶ sînt cuantilele modelelor fundamentale prea înguste chiar și la 10%?
- ▣ **Date:** `ch14_risk_btc.csv` (2 818 zile din 01.01.2019); coloanele `<model>|VaR10` pentru HS, FHS și cuantilele directe Chronos-2, Chronos-Bolt și TimesFM-2.5 din `ch14_risk_<piață>.csv`
- ▣ **Cerințe**
 1. Repetați pașii 1–3 din B5 pentru Bitcoin.
 2. Pentru VaR 10%, calculați ratele de depășire și testul Kupiec cu $\alpha = 10\%$ pentru cele cinci modele pe cele trei piețe.
 3. Reprezentați ratele față de intervalul de 95% al unui model corect.
- ▣ **Raportați:** tabelul pentru Bitcoin, graficul și un tabel 3×5 cu rate și p Kupiec
- ▣ **Interpretare:** este îngustimea cuantilelor modelelor fundamentale specifică nivelului de 1%?

A7 [Propus]: Un „VaR 1%” din decile — Cerință

- ▣ **Model:** A5 [Rezolvat]; după B6
- ▣ **Întrebarea:** ce raportează un model care furnizează doar decile cînd i se cere VaR 1%?
- ▣ **Date:** Chronos-Bolt (small), aceeași zi și același context ca în A5: $q_{0,1} = -0,691\%$, $q_{0,5} = 0,071\%$
- ▣ **Cerințe**
 1. Precizați valoarea returnată cînd se cere VaR 1% dintr-o grilă de decile limitată la cel mai mic nivel.
 2. Presupuneți o distribuție predictivă Normală cu mediana $q_{0,5}$ și $\hat{\sigma} = (q_{0,5} - q_{0,1})/z_{0,9}$, cu $z_{0,9} = 1,2816$ cuantila de 90% a distribuției Normale standard; calculați VaR 1% și ES 2,5%.
 3. Comparați cu Chronos-2 din A5 și cu ratele de depășire ale VaR 10% din B6.
- ▣ **Raportați:** cele trei cifre și comparația
- ▣ **Interpretare:** ce test ar decide dacă extrapolarea Normală funcționează?


B9 [Rezolvat]: Calibrarea întregii distribuții predictive — Cerință

- ▣ **Întrebarea:** este calibrată întreaga distribuție predictivă Chronos-2 sau doar centrul ei?
- ▣ **Date:** S&P 500, 2 693 de zile; grila Chronos-2 directă de 21 de cuantile (1%, 5%, ..., 99%) din `ch14_returns_sp500.csv`; FHS și GARCH-t evaluate pe aceeași grilă
- ▣ **Cerințe**
 1. Calculați PIT $u_t = \hat{F}_t(r_t)$ (Diebold, Gunther & Tay (1998)), cu $\hat{F}_t$ funcția de repartiție predictivă din ziua t (u_t uniform dacă este corectă), prin interpolare liniară, cenzurat în afara $[q_1\%, q_{99}\%]$, și aplicați χ^2 Pearson frecvențelor din cele 22 de intervale.
 2. Aplicați testul LR Berkowitz (Berkowitz (2001)) pentru $\mu = 0$, $\sigma = 1$ lui $z_t = \Phi^{-1}(u_t)$, cu o verosimilitate Normală cenzurată (χ^2_2).
 3. Calculați scorul cuantic QS $_t = \frac{2}{K} \sum_k (1\{r_t < q_{u_k}\} - u_k)(q_{u_k} - r_t)$ și DM pentru Chronos-2 minus FHS, total, în centru și în cozi.
- ▣ **Raportați:** histograma PIT și un tabel: ponderile din cozi, $\hat{\mu}/\hat{\sigma}$, p Berkowitz, $p \chi^2$, QS
- ▣ **Interpretare**
 - ▶ este eșecul în centru sau în cozi?
 - ▶ de ce cenzurăm în loc să extrapolăm?

B9 [Rezolvat]: Rezolvare (1/3) — Pas cu pas

1. Dacă $q_{1\%,t} \leq r_t \leq q_{99\%,t}$, u_t interpolează nivelurile între cele două cuantile vecine; altfel se notează doar „sub” sau „peste”; $\chi^2 = \sum_{j=1}^{22} (O_j - Tp_j)^2 / (Tp_j)$, O_j = frecvența observată și p_j = lățimea intervalului j .
2. $\ell(\mu, \sigma) = \sum_{\text{interior}} \log \frac{1}{\sigma} \varphi\left(\frac{z_t - \mu}{\sigma}\right) + n_L \log \Phi\left(\frac{c_L - \mu}{\sigma}\right) + n_H \log \left[1 - \Phi\left(\frac{c_H - \mu}{\sigma}\right)\right]$, $c_L = \Phi^{-1}(0,01)$, $c_H = \Phi^{-1}(0,99)$; φ , Φ : densitatea și funcția de repartiție ale distribuției Normale standard; n_L , n_H : zilele sub și peste grilă; $LR = 2[\ell(\hat{\mu}, \hat{\sigma}) - \ell(0, 1)]$.
3. QS pe toate cele 21 de niveluri, pe cele 17 niveluri centrale și pe cele 4 niveluri din cozi; DM cu varianță Newey–West.

B9 [Rezolvat]: Rezolvare (2/3) — Grafic



- Frecvența observată raportată la cea așteptată în cele 22 de intervale ale grilei; 1 = calibrare perfectă; vîrfuri la capete: randamente în afara $[q_{1\%}, q_{99\%}]$
- Interpretare: Chronos-2 este mai slab în ambele zone, mai ales în cozi; cenzurarea evită inventarea unei cozi pe care grila nu o are

B9 [Rezolvat]: Rezolvare (3/3) — Tabel

Model	Sub $q_1\%$ (%)	Peste $q_{99}\%$ (%)	$\hat{\mu} / \hat{\sigma}$	p Berkowitz	$\chi^2 p$	QS
Chronos-2	1,67	1,08	-0,035 / 1,030	0,019	0,004	0,5101
FHS	1,11	1,34	+0,014 / 0,990	0,599	0,747	0,5062
GARCH-t	1,63	0,30	-0,041 / 0,976	0,023	<0,001	0,5063

- Chronos-2: prea multe randamente sub $q_1\%$, $\hat{\sigma} > 1$, ambele teste resping; FHS trece; QS Chronos-2 minus FHS: DM +3,06 (centru +2,51, cozi +3,65)

B10 [Propus]: Recalibrarea conformală a Chronos-2 — Cerință

- ▣ **Model:** B5 și B9 [Rezolvat]
- ▣ **Întrebarea:** poate recalibrarea conformală să facă cuantilele directe Chronos-2 un VaR 1% utilizabil fără filtru GARCH?
- ▣ **Date:** cuantilele Chronos-2 directe din B5 pe cele trei piețe; evaluare pe zilele de după primele 250 de zile de calibrare
- ▣ **Cerințe**
 1. Corecți cuantilele de 1% și 2,5% prin inferență conformală adaptivă (Gibbs & Candès (2021)): scorurile $E_t = \hat{q}_{\alpha,t} - r_t$ pe ultimele 250 de zile, cuantila corectată $\hat{q}_{\alpha,t} - \hat{Q}_{1-\alpha_t}(E)$, actualizarea $\alpha_{t+1} = \alpha_t + \gamma(\alpha - \text{err}_t)$, $\gamma = 0,001$; $\hat{q}_{\alpha,t}$: cuantila directă; $\hat{Q}_{1-\alpha_t}(E)$: cuantila empirică $(1 - \alpha_t)$ a scorurilor; $\text{err}_t = 1$ într-o zi cu depășire.
 2. Repetați cu $\gamma = 0$ (conformal simplu); deplasați ES 2,5% cu corecția VaR 2,5%.
 3. Testați FHS, Chronos-2 direct și ambele variante conformale: depășiri, acoperire condiționată, DQ, FZ0 și DM față de FHS.
- ▣ **Raportați:** un grafic cu depășirile pe metode și piețe și un tabel
- ▣ **Interpretare:** de ce poate pierde comparația FZ0 un model cu acoperire corectă?

A9 [Propus]: Lungimea necesară a ferestrei de după publicare — Cerință

- ▣ **Model:** A8 [Rezolvat]
- ▣ **Întrebarea:** de câte zile de după publicare are nevoie un backtest VaR 1% ca să detecteze o rată de depășire de 1,67% sau 2%?
- ▣ **Date:** testul Kupiec bilateral din A8 la 5%; rata reală de depășire $\pi = 1,67\%$ sau 2%
- ▣ **Cerințe**
 1. Calculați puterea exactă față de $\pi = 1,67\%$ pentru $T = 1000$ și $T = 2693$.
 2. Găsiți cel mai mic T cu puterea de cel puțin 80% și T -ul de la care rămîne peste 80%.
 3. Repetați pentru $\pi = 2\%$: puterea la $T = 220$ și T -ul pentru o putere de 80%.
- ▣ **Raportați:** un grafic al puterii în funcție de T și cifrele
- ▣ **Interpretare**
 - ▶ de ce nu este puterea monotonă în T ?
 - ▶ câți ani cere un backtest fără contaminare?

B11 [Propus]: Un test formal înainte/după publicare — Cerință

- ▣ **Model:** B3 și A8 [Rezolvat]
- ▣ **Întrebarea:** scade avantajul Chronos-2 față de log-HAR după publicarea ponderilor, așa cum ar implica ipoteza memorării?
- ▣ **Date:** `ch14_rv.csv` (B3); data-limită 3 noiembrie 2025, prima zi de luni după ce toate cele trei seturi de ponderi erau publice (Chronos-2: 30.10.2025); 761 de zile înainte, 218 după
- ▣ **Cerințe**
 1. Calculați $d_t = \text{QLIKE}(\text{Chronos-2}) - \text{QLIKE}(\text{log-HAR})$ și mediile lui înainte și după data-limită.
 2. Regresați d_t pe o constantă și $1\{t \geq 3.11.2025\}$ cu erori Newey–West și testați $\beta_1 = 0$ la 5%.
 3. Calculați efectul minim detectabil ($z_{0,975} + z_{0,8} \text{se}_{HAC}(\hat{\beta}_1)$) (z_p : cuantile ale distribuției Normale standard, 1,96 și 0,84: un test bilateral la 5% cu puterea 80%) și limita lui cînd fereastra de după publicare crește nelimitat.
- ▣ **Raportați:** un grafic al lui d_t cu ambele medii și intervalele lor; mediile, $\hat{\beta}_1$, t , p , MDE
- ▣ **Interpretare:** arată un $\hat{\beta}_1$ nesemnificativ că Chronos-2 nu a memorat perioada de test?

A10 [Rezolvat]: Funcționala elicitată de QLIKE — Cerință

▣ Întrebările

- ▶ ce prognoză punctuală a varianței răsplătește QLIKE?
- ▶ ce pierdere produce folosirea medianei?

- ▣ **Date:** QLIKE $L(y, h) = y/h - \log(y/h) - 1$; Chronos-2 pe log RV furnizează cuantilele q_u ; raportul mediu dintre $\exp(q_{0,5})$ și $\int_0^1 \exp(q_u) du$ pe cele 979 de zile din B3: 0,8048

▣ Cerințe

1. Minimizați $E[L(Y, h) | \mathcal{F}]$ după $h > 0$ și arătați că minimumul este atins în $E[Y | \mathcal{F}]$.
2. Presupuneți $\log Y | \mathcal{F} \sim N(\mu, s^2)$; derivați mediana, media, raportul lor și excesul de QLIKE așteptat al prognozei prin mediană.
3. Din raportul Chronos-2 deduceți un s comun efectiv și excesul de QLIKE.

- ▣ **Raportați:** derivările, s și excesul

- ▣ **Interpretare:** de ce este $\exp(\text{mediana})$ lui log RV o prognoză deplasată a volatilității?

A10 [Rezolvat]: Rezolvare

1. $E[L] = E[Y]/h - E[\log Y] + \log h - 1$; $\partial_h E[L] = -E[Y]/h^2 + 1/h = 0 \Rightarrow h^* = E[Y | \mathcal{F}]$; derivata a doua $1/h^{*2} > 0$: QLIKE este consistentă pentru medie ([Gneiting \(2011\)](#)).
 2. Mediana e^μ , media $m = e^{\mu+s^2/2}$, raportul $e^{-s^2/2}$; cu $h = me^{-s^2/2}$: $E[L(h)] - E[L(m)] = e^{s^2/2} - 1 - s^2/2 > 0$.
 3. $s = \sqrt{-2 \ln 0,8048} = 0,659$; excesul $1/\text{raport} - 1 + \ln(\text{raport}) = 0,0254$; observat: QLIKE 0,259 cu mediana față de 0,231 cu media.
- Interpretare: transformările monotone păstrează cuantilele, deci $\exp(\text{mediana lui } \log RV)$ este mediana lui RV, cu circa 20% sub medie; QLIKE răsplătește media

B4 [Propus]: Mediana față de medie — Cerință

- ▣ **Model:** A10 și B3 [Rezolvat]
- ▣ **Întrebările**
 - ▶ cît schimbă alegerea funcționalei (mediana sau media) QLIKE-ul unui model fundațional?
 - ▶ cît îl schimbă lungimea contextului?
- ▣ **Date:** ch14_rv.csv: coloanele Chronos-2, Chronos-2|median, TimesFM-2.5, TimesFM-2.5|median;
ch14_ctx.csv: Chronos-2 cu contexte de 32, 64, 128, 256 și 512 zile, în aceleași 979 de zile
- ▣ **Cerințe**
 1. Pentru ambele modele calculați QLIKE și raportul media prognozei / media RV pentru mediană și pentru media din grilă.
 2. Testați mediana față de medie pentru Chronos-2 cu DM pe diferențele QLIKE.
 3. Calculați QLIKE Chronos-2 pentru fiecare lungime a contextului și comparați cu log-HAR.
- ▣ **Raportați:** un grafic cu două panouri, tabelul de la pasul 1, statistica DM
- ▣ **Interpretare:** ce indică efectul contextului despre memoria volatilității?

B8 [Propus]: Look-ahead în regresori — Cerință

▣ **Model:** B3 [Rezolvat]

▣ **Întrebările**

- ▶ cît de mare este câștigul aparent produs de un look-ahead de o zi?
- ▶ I-ar putea egala un model corect?

▣ **Date:** log RV al SPY ca în B3; log-HAR pe o fereastră mobilă de 500 de zile cu regresorii $\log RV_{t-1}$, $\frac{1}{5} \sum_{j=1}^5 \log RV_{t-j}$, $\frac{1}{22} \sum_{j=1}^{22} \log RV_{t-j}$; prognoza $\exp(\hat{y}_t + \hat{s}^2/2)$

▣ **Cerințe**

1. Construiți o variantă greșită în care mediile pe 5 și 22 de zile iau $j = 0, \dots, 4$ și $j = 0, \dots, 21$, deci includ ziua prognozată t .
2. Calculați QLIKE pentru log-HAR corect, log-HAR greșit și Chronos-2 pe aceleași 979 de zile.
3. Testați varianta greșită față de cea corectă cu DM și scrieți un test de leakage pentru propriul cod.


▣ **Raportați:** cele trei valori QLIKE, câștigul relativ și testul DM

▣ **Interpretare:** unde se poate ascunde aceeași eroare într-un flux de lucru de deep learning?

B7 [Rezolvat]: Variabilitatea între seed-uri — Cerință

- ▣ **Întrebarea:** cît schimbă doar seed-ul aleator R^2 în afara eșantionului al unui LSTM?
- ▣ **Date:** LSTM-ul pentru randamente din Cursul 14 (ultimele 20 de randamente standardizate, 16 unități ascunse, MSE, Adam, oprire timpurie); cinci rețele identice cu excepția seed-urilor, coloanele `lstm_s0`, `...`, `lstm_s4` și media lor `lstm` din `ch14_returns_<piață>.csv`
- ▣ **Cerințe**
 1. Calculați R^2 în afara eșantionului față de zero pentru fiecare seed, pe cele trei piețe.
 2. Calculați R^2 pentru media celor cinci prognoze.
 3. Comparați dispersia dintre seed-uri cu mărimea lui R^2 .
- ▣ **Raportați:** un grafic și un tabel 3×6 cu R^2 (%)
- ▣ **Interpretare**
 - ▶ ce concluzie ar fi dat o singură rulare pe Bitcoin?
 - ▶ de ce este media seed-urilor o formă de regularizare?

B7 [Rezolvat]: Rezolvare (1/2) — Grafic



- Albastru: seed-urile individuale; roșu: media celor cinci prognoze
- Interpretare: pe Bitcoin, seed-urile variază de la $-0,79\%$ la $+0,24\%$
 - ▶ O singură rulare ar putea „arăta” abilitate sau lipsa ei; pe BET toate cinci sînt de acord
 - ▶ Media reduce varianța, ca bagging-ul

B7 [Rezolvat]: Rezolvare (2/2) — Tabel

R^2 (%)	Seed 0	1	2	3	4	Media
S&P 500	+0,55	+0,37	+0,70	+0,54	+1,96	+0,93
Bitcoin	+0,11	+0,03	-0,79	-0,12	+0,24	+0,04
BET	+1,06	+1,01	+1,12	+1,22	+1,12	+1,15

- Pas cu pas: $R_s^2 = 1 - \sum_t (r_t - \hat{r}_{t,s})^2 / \sum_t r_t^2$ pentru fiecare seed, apoi pentru $\bar{r}_t = \frac{1}{5} \sum_s \hat{r}_{t,s}$; din convexitate, media nu are eroare pătratică mai mare decât media erorilor componentelor

 MFM_ch14_sem_partB

C1 [Propus]: Un model fundațional zero-shot în locul GARCH pentru BET — Cerință

- ▣ **Model:** B5 [Rezolvat]; extindere de proiect: fine-tuning-ul unui model fundațional pe acțiuni românești
- ▣ **Întrebarea:** un manager de risc propune Chronos-2 pentru VaR 1% și ES 2,5% zilnice ale unei poziții pe BET: acceptați, respingeți sau păstrați ca model alternativ?
- ▣ **Date:** `ch14_risk_bet.csv`, 2 675 de zile din 04.01.2016; fereastra de după publicare de la 3.11.2025 (217 zile)
- ▣ **Cerințe**
 1. Testați VaR 1% pentru cele șase modele din B5: depășiri, Kupiec, independență și DQ.
 2. Comparați (VaR 2,5%, ES 2,5%) cu FZ0, DM față de FHS și MCS de 90%.
 3. Clasificați zece blocuri de 250 de zile în zonele Basel (verde ≤ 4 , galben 5–9, roșu ≥ 10 depășiri) și repetați pasul 1 după publicare.
 4. Preînregistrați prognozele VaR pentru următoarele 20 de zile de tranzacționare și testați-le ulterior.
- ▣ **Raportați:** o recomandare de o pagină, cu tabelele de la pașii 1–3
- ▣ **Interpretare**
 - ▶ ce dovezi v-ar face să schimbați modelul?
 - ▶ când ați face schimbarea?

C3 [Propus]: Modele complexe pe datele cursului (1/2) — Cerință

- ▣ **Model:** B1 pentru etapele evaluării; aici $R^2 = 1 - \text{Var}(\text{eroare})/\text{Var}(R)$ (nota 40 din lucrare)
- ▣ **Întrebarea:** apare pe datele cursului avantajul complexității (Kelly, Malamud & Zhou (2024))?
- ▣ **Date**
 - ▶ Randamentele totale lunare ale SPY din prețurile ajustate de sfârșit de lună, din 1993, minus TB3MS/1200 din luna precedentă (FRED)
 - ▶ Șapte predictorii din Welch & Goyal (2008) datați t : $\text{tbl} = \text{TB3MS}/100$, $\text{lt}y = \text{GS10}/100$, $\text{tms} = \text{lt}y - \text{tbl}$, $\text{df}y = (\text{BAA} - \text{AAA})/100$
 - ▶ infl (CPIAUCSL, întârziat o lună), svar (suma pătratelor randamentelor zilnice S&P 500), randamentul în exces
- ▣ **Cerințe**
 1. Construiți datele lunare și standardizați ca în Secțiunea V.A: randamentele prin abaterea standard necentrată din ultimele 12 luni, predictorii prin abaterea standard pe o fereastră crescătoare, după 36 de luni de inițializare.
 2. Generați 12 000 de trăsături Fourier aleatoare cu $\gamma = 2$ (ec. 20); pentru P de la 2 la 12 000 și $\log_{10} z = -3, \dots, 3$, estimați ridge fără termen liber pe ferestre mobile de 12 luni și calculați randamentul strategiei $\hat{\beta}' S_t R_{t+1}$; mediați pe 1 000 de extrageri.
 3. Estimați regresia liniară cu toți cei șapte predictorii (kitchen sink), cu $z = 0^+$ și $z = 10^3$, pe aceleași ferestre.
- ▣ **Raportați:** slide-ul următor

C3 [Propus]: Modele complexe pe datele cursului (2/2) — raport și întrebări

- **Notații:** R_{t+1} : randamentul în exces din luna următoare; G_t : cei șapte predictorii
 - ▶ S_t : cele P trăsături Fourier aleatoare $\sin(\gamma \omega_i' G_t)$, $\cos(\gamma \omega_i' G_t)$, cu $\omega_i \sim N(0, I)$ extras o singură dată
 - ▶ ridge $\hat{\beta}(z) = (zI + \frac{1}{T} \sum_t S_t S_t')^{-1} \frac{1}{T} \sum_t S_t R_{t+1}$, z : penalizarea, $T = 12$: fereastra; randamentul strategiei $\hat{\beta}' S_t R_{t+1}$; complexitatea $c = P/T$
- **Raportați**
 - ▶ Curbele pentru $\|\hat{\beta}\|^2$, R^2 și raportul Sharpe în funcție de $c = P/T$ (Figurile 7–8)
 - ▶ Un tabel în formatul Tabelului I pentru cele două modele liniare și RFF cu $c = 1000$, $z = 10^3$
 - ▶ Coloanele: R^2 , raportul Sharpe cu t , rapoartele de informație față de SPY și față de modelul liniar cu t , pierderea maximă, asimetria
- **Interpretare**
 - ▶ Regresia dumneavoastră are $c = 7/12$, față de $15/12$ în lucrare: ce prezice curba fără penalizare din Figura 7 pentru R^2 ?
 - ▶ Poate raportul Sharpe să fie pozitiv când $R^2 < 0$? Folosiți descompunerea erorii într-o componentă de corelație și una de scală (nota 5)
 - ▶ Cu circa 30 de ani, care este puterea unui test bilateral la 5% pentru un raport de informație de 0,3 ($t \approx \text{raport} \times \sqrt{\text{ani}}$)?
- **Extindere pentru proiect:** înlocuiți trăsăturile aleatoare cu reprezentările interne (embeddings) ale unui model fundațional pre-antrenat și repetați pasul 2

Bibliografie (1/3)

- ▣ Ansari, A.F., Shchur, O., Küken, J., Auer, A., et al. (2025). [Chronos-2: from univariate to universal forecasting](#). [arXiv:2510.15821](#).
- ▣ Ansari, A.F., Stella, L., Turkmen, C., Zhang, X., et al. (2024). [Chronos: learning the language of time series](#). *Transactions on Machine Learning Research*; [arXiv:2403.07815](#).
- ▣ Berkowitz, J. (2001). [Testing density forecasts, with applications to risk management](#). *Journal of Business & Economic Statistics*, 19(4), 465–474.
- ▣ Christoffersen, P.F. (1998). [Evaluating interval forecasts](#). *International Economic Review*, 39(4), 841–862.
- ▣ Clark, T.E., West, K.D. (2006). [Using out-of-sample mean squared prediction errors to test the martingale difference hypothesis](#). *Journal of Econometrics*, 135(1–2), 155–186.
- ▣ Clark, T.E., West, K.D. (2007). [Approximately normal tests for equal predictive accuracy in nested models](#). *Journal of Econometrics*, 138(1), 291–311.
- ▣ Corsi, F. (2009). [A simple approximate long-memory model of realized volatility](#). *Journal of Financial Econometrics*, 7(2), 174–196.
- ▣ Diebold, F.X., Gunther, T.A., Tay, A.S. (1998). [Evaluating density forecasts with applications to financial risk management](#). *International Economic Review*, 39(4), 863–883.

Bibliografie (2/3)

- ▣ Diebold, F.X., Mariano, R.S. (1995). [Comparing predictive accuracy](#). *Journal of Business & Economic Statistics*, 13(3), 253–263.
- ▣ Engle, R.F., Manganelli, S. (2004). [CAViaR: conditional autoregressive value at risk by regression quantiles](#). *Journal of Business & Economic Statistics*, 22(4), 367–381.
- ▣ Franke, J., Härdle, W.K., Hafner, C.M. (2019). *Statistics of Financial Markets: An Introduction*, 5th ed. Springer.
- ▣ Gibbs, I., Candès, E. (2021). [Adaptive conformal inference under distribution shift](#). *NeurIPS*; arXiv:2106.00170.
- ▣ Gneiting, T. (2011). [Making and evaluating point forecasts](#). *Journal of the American Statistical Association*, 106(494), 746–762.
- ▣ Gneiting, T., Raftery, A.E. (2007). [Strictly proper scoring rules, prediction, and estimation](#). *Journal of the American Statistical Association*, 102(477), 359–378.
- ▣ Hansen, P.R. (2005). [A test for superior predictive ability](#). *Journal of Business & Economic Statistics*, 23(4), 365–380.
- ▣ Hansen, P.R., Lunde, A., Nason, J.M. (2011). [The model confidence set](#). *Econometrica*, 79(2), 453–497.

Bibliografie (3/3)

- ▣ Hochreiter, S., Schmidhuber, J. (1997). Long short-term memory. *Neural Computation*, 9(8), 1735–1780.
- ▣ Kelly, B., Malamud, S., Zhou, K. (2024). The virtue of complexity in return prediction. *Journal of Finance*, 79(1), 459–503.
- ▣ Kupiec, P.H. (1995). Techniques for verifying the accuracy of risk measurement models. *Journal of Derivatives*, 3(2), 73–84.
- ▣ Lo, A.W., MacKinlay, A.C. (1990). An econometric analysis of nonsynchronous trading. *Journal of Econometrics*, 45(1–2), 181–211.
- ▣ McNeil, A.J., Frey, R. (2000). Estimation of tail-related risk measures for heteroscedastic financial time series: an extreme value approach. *Journal of Empirical Finance*, 7(3–4), 271–300.
- ▣ Pascanu, R., Mikolov, T., Bengio, Y. (2013). On the difficulty of training recurrent neural networks. *ICML*; arXiv:1211.5063.
- ▣ Patton, A.J. (2011). Volatility forecast comparison using imperfect volatility proxies. *Journal of Econometrics*, 160(1), 246–256.
- ▣ Patton, A.J., Ziegel, J.F., Chen, R. (2019). Dynamic semiparametric models for expected shortfall (and value-at-risk). *Journal of Econometrics*, 211(2), 388–413.
- ▣ Romano, J.P., Wolf, M. (2005). Stepwise multiple testing as formalized data snooping. *Econometrica*, 73(4), 1237–1282.
- ▣ Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., et al. (2017). Attention is all you need. *NeurIPS*; arXiv:1706.03762.
- ▣ Welch, I., Goyal, A. (2008). A comprehensive look at the empirical performance of equity premium prediction. *Review of Financial Studies*, 21(4), 1455–1508.