



Modelarea piețelor financiare

Seminarul 15: LLM-uri și analiza sentimentului — aplicații



Daniel Traian PELE

Drd. Antoaneta Amza, antoaneta.amza@csie.ase.ro

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

Acronime folosite în acest material

- AI: Artificial Intelligence (inteligență artificială)
- AUC: Area Under the (ROC) Curve (aria de sub curba ROC)
- BERT: Bidirectional Encoder Representations from Transformers (reprezentări bidirecționale produse de codificatorul unui Transformer)
- BVB: Bursa de Valori București
- CAR: Cumulative Abnormal Return (randamentul anormal cumulat)
- CI: Confidence Interval (interval de încredere)
- ECE: Expected Calibration Error (eroarea medie de calibrare)
- FNSPID: Financial News and Stock Price Integration Dataset (setul de date care integrează știri financiare și prețuri de acțiuni)
- GPT-4: Generative Pre-trained Transformer 4 (Transformer generativ pre-antrenat, versiunea 4)
- LLM: Large Language Model (model lingvistic mare)
- LM: Loughran-McDonald (financial sentiment dictionary) (dicționarul financiar de sentiment Loughran-McDonald)
- NLL: Negative Log-Likelihood (logaritmul negativ al verosimilității)
- OLS: Ordinary Least Squares (metoda celor mai mici pătrate)
- PPI: Prediction-Powered Inference (inferență susținută de predicții)
- SE: Standard Error (eroare standard)
- TF-IDF: Term Frequency - Inverse Document Frequency (frecvența termenului înmulțită cu inversul frecvenței în documente)
- UTC: Coordinated Universal Time (Temps Universel Coordonné) (timpul universal coordonat)

Întrebările de azi și traseul

▣ Întrebările seminarului

- ▶ poate un model de limbaj să citească sentimentul financiar?
- ▶ poate acest sentiment să prognozeze randamente care mai pot fi tranzacționate?

▣ Traseul seminarului

- ▶ Întîi slide-urile „Noțiuni necesare azi” (trei slide-uri): [Capitolul 15](#) este cursul de după seminar
 - ▶ A1, A3, A7 pe hîrtie: cum atenuează o etichetă clasificată greșit panta, cît de precis este un test de acuratețe pe perechi, costul de la care o strategie nu mai este profitabilă
 - ▶ B1: este FinBERT mai bun decît un dicționar?
 - ▶ B5: prognozează titlurile randamentele sau doar le descriu?
 - ▶ B7: își amintește LLM-ul piața?
 - ▶ C2: identificați cele trei erori dintr-un răspuns A1; B2 ca temă
- ▣ Livrabile: răspunsurile de la A, cîte un tabel și un grafic pentru fiecare exercițiu B, corecturile de la C2, cîte o frază de interpretare pentru fiecare exercițiu
- ▣ Notebook-ul de azi: [deschideți notebook-ul seminarului în Colab](#); fiecare exercițiu are o secțiune cu aceeași etichetă
- ▣ Seminar: drd. Antoaneta Amza, antoaneta.amza@csie.ase.ro

Harta exercițiilor

Exercițiu	Întrebare	Tip	Model
A1	cît micșorează panta o variabilă binară clasificată greșit?	Rezolvat	–
A3	cît de precis și cît de puternic este un test de acuratețe pe perechi?	Rezolvat	–
A7	de la ce cost pe tranzacție nu mai este profitabilă strategia?	Rezolvat	–
B1	este FinBERT mai precis decît dicționarul LM?	Rezolvat	–
B5	prognozează titlurile randamentele sau le descriu?	Rezolvat	–
B7	își amintește LLM-ul piața?	Rezolvat	–
C2	ce este greșit într-un răspuns AI?	Propus	B1, B5, B7
B2	este un LLM cu 7 miliarde de parametri mai bun decît FinBERT? (temă)	Propus	B1
Pachete de extindere	A2, A4, A5, A6, A8, B3, B4, B6, B8–B11, C1, C3 (opționale, după curs)	ambele	indicat la fiecare enunț

- ☐ **[Rezolvat]**: rezolvarea completă în slide-uri și în notebook, un model de urmat; **[Propus]**: îl rezolvați dumneavoastră; rezolvarea se discută la seminar
- ☐ Partea A: derivări pe hîrtie; Partea B: verificare și inferență pe date reale, fiecare cu o întrebare de interpretare; Partea C: întrebări deschise și critica unui răspuns AI

Datele folosite

Date	Conținut	Scoruri salvate	Folosite în
Twitter Financial News (setul de validare, Hugging Face Hub)	2 388 de titluri din 2022: 1 566 neutre, 475 pozitive, 347 negative	LM, FinBERT, Qwen2.5 (P1–P3), MiniLM	A1–A5, A8, B1–B4, B8, B9, C2
Financial PhraseBank Malo et al. (2014)	4 846 de propoziții din știri, 2 264 cu acord deplin	aceleași scoruri	B3
FNSPID Dong, Fan & Peng (2024)	106 820 de titluri despre 16 acțiuni americane, 27.10.2009–18.12.2023	scorurile zilnice LM, FinBERT, Qwen2.5-7B	A7, A8, B5, B6, B10, B11, C1–C3
Acțiunile și SPY	prețurile ajustate zilnice din datele cursului, câte o serie pe activ (cîmpul folosit: adjusted close), 2009–2023	–	B5, B6, C1, C3
S&P 500	închideri lunare, ian. 2000 – aug. 2026	răspunsurile Qwen2.5 despre fiecare lună	B7, C2

- Scorurile sînt salvate împreună cu Quantlet-urile capitolului, [Quantlets/Ch_15](#): la seminar nu trebuie rulat niciun model de limbaj
- C3 (pachet de extindere) cere o nouă evaluare a titlurilor FNSPID

Pregătire: rulați și verificați

```
# notebook section "Setup" defines the functions that
# read the data
pb, tw = eval_texts()    # PhraseBank, Twitter
P, rets = news_panel()   # FNSPID stock-days
print(len(pb), len(tw))
print(tw['label'].value_counts())
print(P.shape,
      P.index.get_level_values('ticker').nunique())
```

- Rezultatul așteptat
 - ▶ 4 846 și 2 388 de rînduri
 - ▶ neutral 1 566, positive 475, negative 347
 - ▶ (18 282, 19) și 16 acțiuni
- Fiecare rînd din tw conține textul, eticheta umană și probabilitățile fiecărui model (de ex. finbert_negative, qwen7B_positive)
- Dacă cifrele diferă, opriți-vă și verificați fișierele înainte de orice exercițiu

Notății folosite în toate exercițiile

- Tonul după dicționar $\tau = (P - N)/(P + N)$, cu P , N numărul de cuvinte pozitive și negative; LM: listele financiare Loughran–McDonald [Loughran & McDonald \(2011\)](#)
- Probabilitățile modelului $p_k = e^{z_k/T} / \sum_j e^{z_j/T}$ (z_k : logitul răspunsului k , T : temperatura); eticheta $\arg \max_k p_k$; scorul net $s = p_{\text{pos}} - p_{\text{neg}}$; FinBERT [Araci \(2019\)](#), Qwen2.5 [Qwen Team \(2024\)](#)
- Doi clasificatori A și B pe aceleași texte: n_{01} = A greșește și B are dreptate, n_{10} = A are dreptate și B greșește; testul McNemar [McNemar \(1947\)](#): sub H_0 , $n_{01} \sim \text{Bin}(n_{01} + n_{10}; 0,5)$
- Ziua d : prima zi de tranzacționare de la data titlului încolo; $d + 2$: primul randament sigur de după publicare; h : zile după d
- bp: punct de bază, 0,01%; SE: eroare standard; CI: interval de încredere de 95%; t_{NW} : t Newey–West [Newey & West \(1987\)](#); SE grupate: [Petersen \(2009\)](#)

Noțiuni necesare azi (1/3): trei moduri de a citi sentimentul

- **Capitolul 15** este cursul de după acest seminar: aceste trei slide-uri sînt minimul necesar pentru cerințele principale de azi; detaliile și rezultatele, la curs
- **Dicționar** (bag of words): numărăm cuvintele pozitive (P) și negative (N) din liste fixe; listele LM au fost construite din rapoartele anuale 10-K [Loughran & McDonald \(2011\)](#), cu 2 355 de cuvinte negative și doar 354 de cuvinte pozitive
 - ▶ Tonul $\tau = (P - N)/(P + N)$, clasa = semnul lui τ ; exemplu $P = 2$, $N = 1$: $\tau = 1/3$, pozitiv; transparent, dar insensibil la context și la negație
- **FinBERT Araci (2019)**: BERT, un encoder Transformer ([Capitolul 14](#)), antrenat în continuare pe știri financiare și ajustat fin pe propoziții etichetate; rezultatul: p_{pos} , p_{neu} , p_{neg}
 - ▶ Modelul public a fost ajustat fin pe Financial PhraseBank [Malo et al. \(2014\)](#): acuratețea de acolo este parțial în eșantion
- **LLM zero-shot** (Qwen2.5 [Qwen Team \(2024\)](#)): un model de limbaj mare întrebat „Is this headline positive, negative or neutral?”, fără antrenare pe aceste etichete; citim logiții z_k ai celor trei cuvinte-răspuns
 - ▶ Softmax cu temperatura T : $p_k = e^{z_k/T} / \sum_j e^{z_j/T}$; scorul net $s = p_{\text{pos}} - p_{\text{neg}} \in [-1, 1]$
 - ▶ Exemplu $z = (2, 1, 0)$ pentru (pos, neu, neg): $T = 1$ dă $p = (0,665, 0,245, 0,090)$, $s = 0,575$; $T = 2$ aplatizează la $(0,506, 0,307, 0,186)$, $s = 0,320$

Noțiuni necesare azi (2/3): evaluarea unui clasificator de sentiment

- Matricea de confuzie: rîndurile = etichetele umane (adevărul), coloanele = etichetele prezise; acuratețea = diagonala / total
- Exemplu: 100 de titluri, 20 cu adevărat negative; modelul marchează 18 dintre ele și 8 dintre celelalte 80
 - ▶ Ratele: $\pi = 0,20$ cu adevărat negative, $p = 0,26$ marcate, ratări $\alpha_1 = 2/20 = 0,10$, alarme false $\alpha_0 = 8/80 = 0,10$ (datele de intrare din A1)
 - ▶ Acuratețea $(18 + 72)/100 = 0,90$, dar „niciodată negativ” are deja 0,80: comparăm cu clasa majoritară, niciodată cu $1/K$
 - ▶ Macro-F1: media pe clase a lui $F_1 = 2 \text{ prec} \cdot \text{rec} / (\text{prec} + \text{rec})$; aici $(0,783 + 0,935)/2 = 0,86$, iar „niciodată negativ” obține $(0 + 0,889)/2 = 0,44$
- Doi clasificatori pe aceleași titluri sînt **împerecheați**: doar titlurile discordante (n_{01} , n_{10}) indică care este mai bun (testul McNemar, slide-ul de notații; A3, B1)
- O etichetă clasificată greșit este un regresor măsurat cu eroare: panta pe ea este deplasată spre zero (atenuare, Aigner (1973); derivată în A1)

Noțiuni necesare azi (3/3): de la titluri la randamente

- Calendarul: un titlu datat într-o zi calendaristică corespunde zilei d , prima zi de tranzacționare de la acea dată încolo; ora publicării nu se cunoaște, deci randamentul din $d + 1$ poate conține încă reacția
 - ▶ Exemplu: titlu sîmbătă $\Rightarrow d = \text{luni}$; cumpărăm la închiderea de marți ($d + 1$); primul randament tranzacționabil este cel de miercuri ($d + 2$)
 - ▶ O pantă la $h = 0$ măsoară cît de bine *descriu* titlurile ziua; doar $h \geq 2$ este o *prognoză* (B5)
- Regresia de panel $r_{i,d+h}^e = a + b z_{i,d} + \varepsilon$ pe zile-acțiune; erorile sînt corelate în aceeași zi (știri comune) și pentru aceeași acțiune (în timp)
 - ▶ SE grupate [Petersen \(2009\)](#): $\widehat{\text{Var}}(\hat{b}) = (X^\top X)^{-1} \left(\sum_g X_g^\top \hat{u}_g \hat{u}_g^\top X_g \right) (X^\top X)^{-1}$, suma pe grupuri g (zile sau acțiuni)
 - ▶ Doar G grupuri: cu 16 acțiuni folosim valorile critice t_{G-1} (2,13) sau un wild cluster bootstrap [Cameron, Gelbach & Miller \(2008\)](#)
- Strategia de sentiment: la închiderea din $d + 1$, o poziție de semnul lui $s_{i,d}$ în fiecare acțiune cu știri, acoperită (hedging) cu SPY și închisă după o zi; cost c pe tranzacție, patru tranzacții în fiecare zi cu poziții (A7)
- **Look-ahead bias** [Glasserman & Lin \(2023\)](#): un LLM antrenat pe texte pînă la publicarea lui poate să fi citit ce a urmat după un titlu; un test fără contaminare folosește doar date de după publicarea ponderilor (B7, C2)
- Mai mult în [Capitolul 15](#), după seminar: embedding-uri, calibrare, scorurile ca estimări și studiul de caz ChatGPT

A1 [Rezolvat]: atenuarea prin clasificare greșită — enunț

- ▣ **Întrebare:** o regresie folosește eticheta FinBERT „negativ” în locul adevărului; cu cît se micșorează panta?
- ▣ **Date**
 - ▶ Twitter Financial News, setul de validare: $N = 2\,388$ de titluri din 2022, fiecare etichetat negativ, neutru sau pozitiv; eticheta umană este considerată adevărat
 - ▶ Modelul $r = a + \beta s^* + \varepsilon$, $s^* = 1$ dacă titlul este cu adevărat negativ; observăm doar $\hat{s} = 1$ cînd FinBERT prezice negativ
 - ▶ Eroare nediferențială: dat fiind s^* , $\hat{s}$ nu aduce informație suplimentară despre r , deci $\text{Cov}(\varepsilon, \hat{s}) = 0$
 - ▶ $\pi = P(s^* = 1)$, $p = P(\hat{s} = 1)$, alarme false $\alpha_0 = P(\hat{s} = 1 \mid s^* = 0)$, ratări $\alpha_1 = P(\hat{s} = 0 \mid s^* = 1)$
- ▣ **Cerințe**
 - (a) Arătați că $\text{plim } \hat{b} = \beta \text{Cov}(s^*, \hat{s}) / \text{Var}(\hat{s})$.
 - (b) Deduceți $\lambda = \pi(1 - \pi)(1 - \alpha_0 - \alpha_1) / [p(1 - p)]$.
 - (c) Calculați π , p , α_0 , α_1 din matrice, apoi λ cu trei zecimale.
 - (d) Calculați $\text{Cov}(u, s^*)$ pentru $u = \hat{s} - s^*$: este eroarea clasică?
- ▣ **De raportat:** λ , $1/\lambda$ și semnul lui $\text{Cov}(u, s^*)$
- ▣ **Interpretare:** ce parte din efectul adevărat rămîne într-o pantă pe variabila binară FinBERT?


Matricea de confuzie FinBERT, Twitter

Adevărat \ prezis	neg	neu	pos	Total
neg	264	71	12	347
neu	213	1 184	169	1 566
pos	58	133	284	475
Total	535	1 388	465	2 388

A1 [Rezolvat]: rezolvare (1/2)

- ▣ (a) Pentru un singur regresor plim $\hat{b} = \text{Cov}(r, \hat{s}) / \text{Var}(\hat{s})$, iar $\text{Cov}(r, \hat{s}) = \beta \text{Cov}(s^*, \hat{s}) + \text{Cov}(\varepsilon, \hat{s})$; ultimul termen este 0 din ipoteza de eroare nediferențială
- ▣ (b) Ambele variabile sînt binare: $\text{Cov}(s^*, \hat{s}) = P(s^* = 1, \hat{s} = 1) - \pi p = \pi(1 - \alpha_1) - \pi p$
- ▣ Formula probabilității totale: $p = \pi(1 - \alpha_1) + (1 - \pi)\alpha_0$; înlocuind, $\text{Cov}(s^*, \hat{s}) = \pi(1 - \pi)(1 - \alpha_0 - \alpha_1)$
- ▣ $\hat{s}$ este Bernoulli, deci $\text{Var}(\hat{s}) = p(1 - p)$; raportul celor două este λ

A1 [Rezolvat]: rezolvare (2/2)



- (c) $\pi = 347/2\,388 = 0,1453$, $p = 535/2\,388 = 0,2240$,
 $\alpha_1 = 1 - 264/347 = 0,2392$, $\alpha_0 = 271/2\,041 = 0,1328$
- $\lambda = \frac{0,1242 \times 0,6280}{0,2240 \times (1 - 0,2240)} = 0,449$, deci $\beta = 2,23 \hat{b}$
- (d) $\text{Cov}(u, s^*) = 0,0780 - 0,1242 = -0,0462 < 0$:
 eroarea este corelată negativ cu adevărul, deci nu este clasică [Aigner \(1973\)](#)
- Graficul: 2000 de eşantioane simulate cu aceste rate și $\beta = 1$; panta pe $\hat{s}$ are media 0,450 (abaterea standard 0,054), cum prezice λ
- Interpretare: o pantă pe variabila binară FinBERT păstrează doar circa 45% din efectul adevărat

A3 [Rezolvat]: diferența de acuratețe pe perechi: varianță, test exact, putere — enunț

▣ Întrebări

- ▶ cît de precisă este diferența de acuratețe dintre doi clasificatori evaluați pe aceleași titluri?
- ▶ de cîte titluri are nevoie?

▣ Date de intrare

- ▶ Setul de validare Twitter, $n = 2\,388$ de titluri independente; $A =$ dicționarul LM, $B =$ FinBERT
- ▶ Numere discordante: $n_{01} = 539$ (A greșește, B are dreptate), $n_{10} = 252$ (A are dreptate, B greșește)
- ▶ $D_i = 1$ dacă A greșește și B are dreptate, -1 dacă A are dreptate și B greșește, 0 altfel; $d = ED_i = \text{acc}_B - \text{acc}_A$,
 $q = P(D_i \neq 0)$


▣ Cerințe

- (a) Arătați că $\hat{d} = (n_{01} - n_{10})/n$ și deduceți $\text{Var}(\hat{d}) = (q - d^2)/n$.
- (b) Calculați $\hat{d}$, SE, CI 95% și $z = \hat{d}/\text{SE}$.
- (c) Aplicați testul McNemar exact la 5% și formulați decizia.
- (d) Calculați puterea $\Phi(|d|\sqrt{n}/\sqrt{q - d^2} - 1,96)$ dacă d adevărat este $\hat{d}$ și $n_{80} = (1,96 + 0,84)^2(q - d^2)/d^2$.

▣ **De raportat:** $\hat{d}$, SE, CI, z , p exact, decizia, puterea și n_{80}

▣ **Interpretare:** ce titluri determină varianța lui $\hat{d}$?

A3 [Rezolvat]: rezolvare



- (a) $\hat{d} = \frac{1}{n} \sum_i D_i = (n_{01} - n_{10})/n$; $D_i^2 = 1$ exact cînd unul are dreptate și celălalt greșește, deci $ED_i^2 = q$, $\text{Var}(D_i) = q - d^2$ și $\text{Var}(\hat{d}) = (q - d^2)/n$
- (b) $\hat{d} = (539 - 252)/2388 = 0,1202$,
 $\hat{q} = 791/2388 = 0,3312$, $SE = 1,15$ pp, $CI [9,76; 14,28]$ pp, $z = 10,43$
- (c) Sub H_0 ne așteptăm la 395,5 de fiecare parte; p exact $< 0,001$: respingem acuratețea egală
- (d) Puterea $\Phi(+8,47) \approx 100\%$;
 $n_{80} = 7,84 \times (0,3312 - 0,0144)/0,0144 \approx 170$ de titluri (graficul)
- Interpretare: doar titlurile discordante (q) intră în varianță; o diferență de 12 puncte se detectează cu cîteva sute de titluri

A7 [Rezolvat]: costul de echilibru cu eroare standard — enunț

▣ Întrebări

- ▶ de la ce cost pe tranzacție strategia FinBERT nu mai este profitabilă?
- ▶ cît de precis cunoaștem acest cost?

▣ Date de intrare

- ▶ Strategia de sentiment (slide-ul 3/3 din „Noțiuni necesare azi”; studiată în [Capitolul 15](#)): la închiderea din $d + 1$ deschidem o poziție de semn $\text{sign}(s_{i,d})$ în fiecare acțiune cu știri în ziua d , acoperită (hedging) cu SPY și închisă după o zi; patru tranzacții în fiecare zi cu poziții; 3 568 de zile de tranzacționare
- ▶ Semnalul FinBERT: randamentul brut mediu pe toate zilele $\hat{\mu} = 3,27$ bp, $t_{NW} = 1,27$ ($L = 8$ decalaje), ponderea zilelor cu poziții $a = 0,962$, raportul Sharpe brut $\sqrt{252} \hat{\mu} / \sigma = 0,36$


▣ Cerințe

- Scrieți randamentul net zilnic mediu și raportul Sharpe net ca funcții de costul c pe tranzacție.
- Deduceți costul de echilibru c^* la care randamentul net mediu este zero.
- Calculați $\text{SE}(\hat{\mu}) = \hat{\mu} / t$, apoi $\text{SE}(c^*)$ prin metoda delta și CI 95% pentru c^* .
- Obțineți σ din raportul Sharpe brut și calculați raportul Sharpe net la $c = 5$ bp.

▣ De raportat: c^* , SE și CI, raportul Sharpe net

▣ Interpretare: este un cost realist de 5 bp pe tranzacție în interiorul CI pentru c^* ?

A7 [Rezolvat]: rezolvare



- (a) Într-o fracțiune a din zile plătim $4c$: $\mu_{\text{net}} = \mu - 4ac$, $SR_{\text{net}} = \sqrt{252}(\mu - 4ac)/\sigma$, cu σ aproape neschimbat de costuri
- (b) $c^* = \mu/(4a) = 3,27/3,85 = 0,85$ bp pe tranzacție
- (c) $SE(\hat{\mu}) = 3,27/1,27 = 2,57$ bp; cu a fixat de calendarul știrilor, $SE(c^*) = 2,57/3,85 = 0,67$ bp, CI $[-0,46; 2,16]$ bp
- (d) $\sigma = \sqrt{252} \times 3,27/0,36 = 143$ bp;
 $SR_{\text{net}} = \sqrt{252}(3,27 - 3,85 \times 5)/143 = -1,77$
- Interpretare: 5 bp este mult peste CI pentru c^* ; cu turnover zilnic, strategia nu rămîne profitabilă la costuri realiste

 MFM_ch15_sem_partA

B1 [Rezolvat]: FinBERT față de LM — enunț


- ▣ **Întrebare:** este FinBERT, ajustat fin, mai precis decât dicționarul Loughran–McDonald pe titluri pe care nu a fost antrenat?
- ▣ **Date**
 - ▶ Twitter Financial News, setul de validare: $N = 2\,388$ de titluri din 2022, fiecare etichetat negativ, neutru sau pozitiv; eticheta umană este considerată adevărul
 - ▶ A = dicționarul LM (eticheta = semnul tonului), B = FinBERT (eticheta = probabilitatea cea mai mare); funcția `b_pairs` din notebook
- ▣ **Cerințe**
 - (a) Calculați fiecare acuratețe cu CI bootstrap percentil 95%: reeșantionați titlurile de 2 000 de ori (seed 0).
 - (b) Calculați diferența $B - A$ cu CI bootstrap pe perechi: aceleași titluri reeșantionate pentru ambii clasificatori.
 - (c) Numărați n_{01} , n_{10} ; aplicați testul McNemar exact și $(n_{01} - n_{10})^2 / (n_{01} + n_{10})$ față de χ_1^2 (3,84).
- ▣ **De raportat:** un tabel cu cele două acurateți, CI și diferența; n_{01} , n_{10} , ambele p -value-uri și decizia
- ▣ **Interpretare**
 - ▶ de ce este testul pe perechi mai puternic decât compararea celor două intervale?
 - ▶ contează diferența pentru tranzacționare?

B1 [Rezolvat]: rezolvare (1/2)

	Acuratețe (%)	CI 95%
LM	60,5	[58,5; 62,4]
FinBERT	72,5	[70,7; 74,4]
Diferența (pp)	+12,0	[+9,8; +14,2]

- Pasul 1: etichetele ambilor clasificatori pe cele 2 388 de titluri; pasul 2: 2 000 de reeșantionări bootstrap ale indicilor titlurilor; pasul 3: ambele acurateți și diferența lor în fiecare reeșantionare
- (a)–(b) Cele două intervale nu se suprapun, iar CI pe perechi al diferenței exclude 0; coincide practic cu CI analitic din A3

B1 [Rezolvat]: rezolvare (2/2)



- (c) $n_{01} = 539$, $n_{10} = 252$, 395,5 așteptate sub H_0 ; p exact $< 0,001$; $\chi^2 = 104,1 > 3,84$: respingem acuratețea egală
- Împerecherea elimină variația dificultății titlurilor: titlurile pe care ambii le clasifică la fel nu aduc informație
- Interpretare: FinBERT este clar mai bun decât dicționarul în afara datelor lui de antrenare; un câștig de 12 puncte în etichetare nu implică încă nimic despre randamente (B5)

B5 [Rezolvat]: reacție față de predicție — enunț

▣ Întrebări

- ▶ explică scorul zilnic al titlurilor randamentul din ziua știrii?
- ▶ prognozează el primul randament care mai poate fi tranzacționat?
- ▶ cât de largi sînt intervalele corecte?

▣ Date

- ▶ Panelul FNSPID: 18 282 de zile-acțiune cu știri, 16 acțiuni americane, 27.10.2009–18.12.2023; $z_{i,d}$: scorul net zilnic, standardizat pe panel; r^e : randamentul în exces față de SPY (%), din prețurile ajustate zilnice ale cursului
- ▶ Scoruri: FinBERT, Qwen2.5-7B, LM

▣ Cerințe


- Estimați prin OLS $r_{i,d+h}^e = a + b z_{i,d} + \varepsilon$ pentru cele trei scoruri și $h = 0, 1, 2$; raportați b în bp pentru o abatere standard a scorului.
- Calculați trei SE: OLS, grupată pe zile ($G = 3\,434$), grupată pe acțiuni ($G = 16$), cu factorul de eșantion mic $\frac{G}{G-1} \frac{n-1}{n-2}$.
- Comparați fiecare t cu 1,96, iar t grupat pe acțiuni cu valoarea critică $t_{15, 2,13}$.

▣ De raportat: un grafic al pantelor pentru $h = 0$ cu cele trei intervale și un tabel al regresiilor

▣ Interpretare

- ▶ de ce diferă $h = 0$ și $h = 2$?
- ▶ putem avea încredere într-o SE grupată cu 16 grupuri?

B5 [Rezolvat]: rezolvare (1/2)



- Pantele din aceeași zi cu intervalele de 95% ale celor trei erori standard: intervalul grupat pe acțiuni este cel mai larg
- Gruparea pe zile este apropiată de OLS: cu doar 5,3 acțiuni pe zi, zgomotul comun este mic
- Gruparea pe acțiuni înmulțește SE FinBERT la $h = 0$ cu 3,0: panta diferă între acțiuni, iar erorile fiecărei acțiuni sînt corelate în timp

B5 [Rezolvat]: rezolvare (2/2)

Scor	h	b (bp)	SE OLS	SE zi	SE acțiune	t zi	t acțiune
FinBERT	0	+39,2	2,3	2,3	6,9	+17,27	+5,71
FinBERT	2	-0,5	2,2	2,2	1,5	-0,25	-0,35
Qwen2.5-7B	0	+41,4	2,3	2,2	8,1	+19,07	+5,10
Qwen2.5-7B	2	+2,3	2,2	1,9	1,0	+1,19	+2,41
LM	0	+15,5	2,3	1,8	3,3	+8,53	+4,70
LM	2	-0,0	2,2	1,7	0,9	-0,01	-0,03


- $h = 0$: mare cu orice SE (t pe acțiuni peste 4,7): titlurile descriu mișcarea zilei, adesea chiar mișcarea („shares jump”)
- $h = 2$: FinBERT -0,5 bp ($t = -0,25$ pe zile); Qwen $t = +2,41$ pe acțiuni, dar $p = 0,061$ prin wild cluster bootstrap [Cameron, Gelbach & Miller \(2008\)](#) și 0,37 după Holm pe nouă regresii (extensia B10)
- Interpretare: sentimentul explică ziua știrii, nu zilele tranzacționabile; cu 16 acțiuni, inferența cere metode pentru puține grupuri

B7 [Rezolvat]: memoria modelului despre piață — enunț

- **Întrebare:** întrebat fără nicio dată, poate Qwen2.5 să distingă lunile în care S&P 500 a crescut de cele în care a scăzut?
- **Date**
 - ▶ Închideri lunare S&P 500 (GSPC.INDX), ianuarie 2000 – august 2026; o lună este „în creștere” dacă randamentul ei este pozitiv
 - ▶ Qwen2.5 1.5B, 7B, 14B (ponderi publicate pe 19 septembrie 2024) întrebat „Did the S&P 500 index rise or fall during ⟨lună an⟩?”; scorul $P(\text{rise})$
 - ▶ Înainte: 296 de luni până în august 2024 (185 în creștere); după: 23 de luni din octombrie 2024 (13 în creștere)
- **Cerințe**
 - (a) Calculați $AUC = U/(n_{\text{up}}n_{\text{down}})$ (U : Mann–Whitney) pe model și perioadă, cu CI bootstrap din 2000 de extrageri pe luni.
 - (b) Test prin permutare pentru 14B înainte de publicare: amestecați etichetele creștere/scădere de 2000 de ori.
 - (c) Testați $AUC_{\text{înainte}} = AUC_{\text{după}}$ cu varianțele DeLong [DeLong et al. \(1988\)](#) și găsiți cea mai mică scădere detectabilă cu puterea 80%.
- **De raportat:** tabelul AUC cu CI, p prin permutare, z și p DeLong, scăderea detectabilă
- **Interpretare:** ce înseamnă un AUC peste 0,5 când modelul nu vede date?


B7 [Rezolvat]: rezolvare (1/2)

Qwen2.5	AUC înainte	CI 95%	AUC după	CI 95%
1.5B	0,57	[0,51; 0,64]	0,72	[0,49; 0,91]
7B	0,67	[0,61; 0,73]	0,53	[0,28; 0,78]
14B	0,69	[0,62; 0,75]	0,59	[0,35; 0,84]



- (a) 7B și 14B ordonează lunile de creștere peste cele de scădere mult peste nivelul întâmplător înainte de publicare; 1.5B doar marginal; după publicare toate intervalele conțin 0,5

B7 [Rezolvat]: rezolvare (2/2)



- (b) p prin permutare pentru 14B înainte de publicare $<0,001$: niciun AUC amestecat nu atinge valoarea observată (graficul)
- (c) DeLong: SE înainte 0,032, după 0,126; $z = 0,73$, $p = 0,47$: nu respingem egalitatea; scăderea detectabilă $2,80\sqrt{SE_{\text{înainte}}^2 + SE_0^2} = 0,36$, ar fi nevoie de circa 101 luni după publicare
- Interpretare: fără date, discriminarea provine din textul de antrenare; un backtest pe știri anterioare publicării confundă prognoza cu memorarea [Glasserman & Lin \(2023\)](#)

C2 [Propus]: critica unui răspuns AI — răspunsul

- **Cererea studentului:** „Am titlurile FNSPID pentru 16 acțiuni americane, 2009–2023, și randamentele zilnice în exces față de SPY. Verifică dacă Qwen2.5-7B citește sentimentul, apoi testează dacă sentimentul titlurilor prognozează randamentele în afara eșantionului.”
- **Codul asistentului AI** (qwen_label, qwen_score: evaluatorul zero-shot de pe slide-ul 1/3 din „Noțiuni necesare azi”)

```
import pandas as pd, statsmodels.formula.api as smf
from sklearn.metrics import accuracy_score
tw['pred'] = [qwen_label(t) for t in tw['text']] # Twitter validation set
acc = accuracy_score(tw['label'], tw['pred'])
news['day'] = first_trading_day_on_or_after(news['date'])
news['s'] = [qwen_score(t) for t in news['title']] # P(pos) - P(neg)
d = news.groupby(['ticker', 'day'])['s'].mean().reset_index()
d['z'] = (d['s'] - d['s'].mean()) / d['s'].std()
d = d.merge(rets, on=['ticker', 'day']) # rets: ticker, day, xret (%)
fit = smf.ols('xret ~ z', data=d).fit(cov_type='cluster',
                                     cov_kws={'groups': pd.factorize(d['day'])[0]})
```

C2 [Propus]: critica unui răspuns AI — enunț

- ▣ **Model:** B1, B5 și B7 [Rezolvat]
- ▣ **Concluzia asistentului AI**
 - ▶ „Acuratețe 74,2%, de peste două ori cei 33% ai unei ghiciri la întâmplare între trei clase: Qwen2.5-7B citește foarte bine sentimentul financiar.”
 - ▶ „Panta +41,4 bp pentru o abatere standard a scorului, $t = +19,07$ (grupat pe zile): titlurile zilei prognozează randamentul în exces al acțiunii.”
 - ▶ „Qwen2.5 nu a fost antrenat pe aceste etichete sau serii de randamente, deci backtest-ul 2009–2023 este complet în afara eșantionului.”
- ▣ **Întrebare:** codul rulează și cifrele sînt corecte, dar răspunsul conține **trei** erori tipice pentru backtesting-ul sentimentului; care sînt?
- ▣ **Cerințe**
 - ▶ (a) Identificați fiecare eroare: numiți rîndul de cod sau propoziția și explicați de ce este greșită.
 - ▶ (b) Precizați cum ați detecta-o fără să cunoașteți răspunsul: numărul de observații pe clase, o verificare a orelor, o dată de publicare, un test de memorie.
 - ▶ (c) Scrieți codul sau afirmația corectată, cu cifrele pe care le produce.
 - ▶ (d) Notați fiecare eroare în [AI_ERRORS.md](#), cu cîmpurile: ce a răspuns AI-ul, ce era greșit, cum ați identificat eroarea, varianta corectă.

B2 [Propus]: un LLM cu 7 miliarde de parametri față de FinBERT — enunț

- ▣ **Model:** B1 [Rezolvat]
- ▣ **Întrebare:** depășește un LLM deschis general, folosit zero-shot, modelul FinBERT ajustat fin, pe titluri pe care niciunul nu a fost antrenat?
- ▣ **Date**
 - ▶ Twitter Financial News, setul de validare: $N = 2\,388$ de titluri din 2022, fiecare etichetat negativ, neutru sau pozitiv; eticheta umană este considerată adevărul
 - ▶ $A = \text{FinBERT}$, $B = \text{Qwen2.5-7B}$ zero-shot cu promptul P1; niciunul nu a folosit etichete Twitter
- ▣ **Cerințe**
 - (a) Calculați fiecare acuratețe cu CI bootstrap percentil 95%: reeșantionați titlurile de 2 000 de ori (seed 0).
 - (b) Calculați diferența $B - A$ cu CI bootstrap pe perechi: aceleași titluri reeșantionate pentru ambii clasificatori.
 - (c) Numărați n_{01} , n_{10} ; aplicați testul McNemar exact și $(n_{01} - n_{10})^2 / (n_{01} + n_{10})$ față de $\chi^2_1(3,84)$.
- ▣ **De raportat:** aceleași tabel, aceleași teste și același grafic ca în B1
- ▣ **Interpretare**
 - ▶ se suprapun cele două intervale?
 - ▶ este întrebarea astfel tranșată?
 - ▶ ce ar aduce totuși un model mult mai mare și mai lent?

Pasul pentru proiectul de echipă

- ▣ Alegeți o sursă de texte nediscutată la seminar (anunțuri BVB, știri financiare românești, comunicate ale băncilor centrale, postări despre criptoactive)
- ▣ Etichetați cel puțin 200 de texte cu doi adnotatori și raportați acordul; evaluați doar pe o parte separată
- ▣ Consemnați folosirea AI în [AI_USE.md](#) și erorile depistate în [AI_ERRORS.md](#); pachetele de extindere sînt opționale; C1 și C3 sînt puncte de plecare pentru proiect

Pachetele de extindere: condițiile fiecăruia

Pachet	Exerciții	Cunoștințe necesare
1. Eroarea de măsurare	A2, A6	A1
2. Compararea clasificarilor	A4, B3 [Rezolvat], B4, B8	A3, B1
3. Probabilitățile LLM	A5 [Rezolvat]	slide-ul de notații, graficul de calibrare din curs
4. Inferență validă	B9 [Rezolvat], B10, B11	B5, B7
5. Semnale și costuri	A8, B6, C1	A7, B5
6. Laborator de replicare	C3	C1, studiul de caz din curs

- Fiecare exercițiu are secțiunea lui în notebook; rezolvați-le în ordine în cadrul unui pachet
- Utile pentru proiectul de echipă: C1 și C3 sînt posibile puncte de plecare pentru proiect

A2 [Propus]: atenuarea pentru dicționarul LM — enunț

- **Model:** A1 [Rezolvat]
- **Întrebare:** este panta LM mai slabă din Cursul 15 (15,5 bp față de 39,2 bp pentru FinBERT) o reacție mai slabă a pieței sau o măsurare mai imprecisă?
- **Date**
 - ▶ Twitter Financial News, setul de validare: $N = 2\,388$ de titluri din 2022, fiecare etichetat negativ, neutru sau pozitiv; eticheta umană este considerată adevărul
 - ▶ Același model și aceeași ipoteză ca în A1; acum $\hat{s} = 1$ când tonul LM al titlului este negativ
- **Cerințe**
 - (a) Calculați π , p , α_0 și α_1 din matricea LM.
 - (b) Calculați λ și $1/\lambda$ cu formula din A1.
 - (c) Calculați $\text{Cov}(u, s^*)$: este eroarea LM clasică?
 - (d) Comparați λ cu FinBERT (A1)
 - care atenuază mai mult?
 - în ce raport?
- **De raportat:** cele patru rate, λ , $1/\lambda$, raportul

Matricea de confuzie LM, Twitter

Adevărat \ prezis	neg	neu	pos	Total
neg	172	166	9	347
neu	247	1 192	127	1 566
pos	45	349	81	475
Total	464	1 707	217	2 388

A6 [Propus]: κ al lui Fleiss și un pas Dawid–Skene — enunț

▣ **Model:** A1 [Rezolvat]

▣ **Întrebări**

- ▶ cât de mult sînt de acord evaluatorii peste nivelul întâmplător?
- ▶ care este eticheta adevărată cea mai probabilă a unei propoziții disputate?

▣ **Date de intrare**

- ▶ Voturi ilustrative (alese pentru exercițiu): 6 propoziții, cîte $m = 5$ evaluatori
- ▶ $P_i = \sum_j n_{ij}(n_{ij} - 1)/[m(m - 1)]$, $\bar{P} = \frac{1}{N} \sum_i P_i$, $p_j =$ ponderea voturilor pentru j , $\bar{P}_e = \sum_j p_j^2$, $\kappa = (\bar{P} - \bar{P}_e)/(1 - \bar{P}_e)$ [Fleiss \(1971\)](#)

▣ **Cerințe**

- (a) Calculați fiecare P_i și $\bar{P}$.
- (b) Calculați p_j , $\bar{P}_e$ și κ .
- (c) Pasul E din [Dawid & Skene \(1979\)](#): fiecare evaluator dă clasa adevărată cu probabilitatea 0,8 și fiecare altă clasă cu 0,1, distribuție a priori uniformă; calculați $P(\text{adevărat} = j \mid \text{voturi}) \propto \prod_i \pi_{ji}^{n_{ij}}$ pentru propozițiile 4 și 5.
- (d) Comparați probabilitățile a posteriori cu ponderile voturilor și descrieți pasul M.

▣ **De raportat:** κ și cele două distribuții a posteriori

▣ **Interpretare:** cum ați trata propozițiile disputate într-un set de test?

Propoziția	neg	neu	pos
1	5	0	0
2	0	5	0
3	0	1	4
4	1	3	1
5	2	3	0
6	0	2	3

A4 [Propus]: „nicio diferență” și puterea testului — enunț

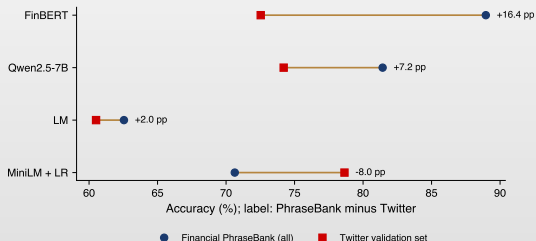
- ▣ **Model:** A3 [Rezolvat]
- ▣ **Întrebare:** FinBERT și Qwen2.5-7B par la egalitate: este asta o dovadă de acuratețe egală sau a unui test slab?
- ▣ **Date de intrare**
 - ▶ Setul de validare Twitter, $n = 2\,388$; $A = \text{FinBERT}$, $B = \text{Qwen2.5-7B}$ (promptul P1); $n_{01} = 395$, $n_{10} = 355$
- ▣ **Cerințe**
 - (a) Calculați $\hat{d}$, $\hat{q}$, SE, CI 95% și z cu formulele din A3.
 - (b) Aplicați testul McNemar exact la 5%.
 - (c) Calculați puterea la $n = 2\,388$ dacă d adevărat este $\hat{d}$ și n_{80} .
 - (d) Folosiți CI pentru a preciza ce diferențe sînt excluse de date.
- ▣ **De raportat:** cifrele din (a)–(d)
- ▣ **Interpretare:** puteți concluziona că cele două modele sînt la fel de precise?

B3 [Rezolvat]: suprapunerea cu datele de antrenare — enunț

- ▣ **Întrebare:** cât din acuratețea FinBERT pe Financial PhraseBank provine din faptul că a fost antrenat pe acest set?
- ▣ **Date**
 - ▶ Financial PhraseBank [Malo et al. \(2014\)](#): 4 846 de propoziții (2 264 cu acord deplin); FinBERT a fost ajustat fin pe o parte a lor (3 101 din 4 845 în [Araci \(2019\)](#))
 - ▶ Setul de validare Twitter, 2 388 de titluri nevăzute de FinBERT; clasificatori: FinBERT, Qwen2.5-7B, LM, MiniLM + regresie logistică antrenată pe Twitter [Wang et al. \(2020\)](#)
- ▣ **Cerințe**
 - (a) Calculați acuratețea (CI bootstrap din 2 000 de extrageri) și F1 macro pe PhraseBank cu acord deplin, pe tot PhraseBank și pe Twitter.
 - (b) Calculați scăderea de la tot PhraseBank la Twitter pentru fiecare clasificator.
 - (c) Calculați diferența diferențelor FinBERT minus Qwen2.5-7B cu CI bootstrap (fiecare set reeșantionat independent).
- ▣ **De raportat:** un tabel cu acurateți și scăderi, diferența diferențelor cu CI
- ▣ **Interpretare:** cum separați „date mai dificile” de „memoria setului de antrenare”?

B3 [Rezolvat]: rezolvare

Acuratețe (%)	PhraseBank, acord 100%	PhraseBank, tot	Twitter	Scădere (pp)	F1 macro, Twitter
FinBERT	97,2	89,0	72,5	16,4	66,8
Qwen2.5-7B	93,6	81,4	74,2	7,2	72,6
LM	65,0	62,5	60,5	2,0	46,2
MiniLM + reg. log.	81,4	70,6	78,6	-8,0	69,9



- (c) $16,4 - 7,2 = 9,2$ pp din acuratețile nerotunjite, CI bootstrap [6,7; 11,9]: exclude 0
- Qwen2.5-7B nu a fost ajustat pe etichetele PhraseBank, deci scăderea lui măsoară dificultatea mai mare a datelor; dacă ambele ar pierde la fel fără suprapunere (o ipoteză netestată), cele 9,2 puncte în plus ale FinBERT provin din suprapunere
- Interpretare: MiniLM variază în sens invers pentru că este antrenat pe Twitter: fiecare model este cel mai bun pe datele pe care a fost antrenat

B4 [Propus]: numărul necesar de etichete — enunț

- ▣ **Model:** B3 [Rezolvat]
- ▣ **Întrebare:** de câte titluri etichetate are nevoie un model supervizat simplu pentru a-l depăși pe FinBERT?
- ▣ **Date**
 - ▶ Twitter Financial News: set de antrenare cu 9 543 de titluri, set de validare cu 2 388; reperul FinBERT, 72,5%, fără etichete Twitter
 - ▶ Regresie logistică ($C = 4$) pe vectorii MiniLM cu 384 de dimensiuni; regresie logistică ($C = 8$) pe trăsături TF-IDF ale cuvintelor și perechilor de cuvinte
- ▣ **Cerințe**
 - (a) Pentru $n \in \{100, 200, 400, \dots, 6\,400, 9\,543\}$ extrageți 10 subseturi aleatoare de antrenare, estimați ambele modele și mediați acuratețea pe validare.
 - (b) Găsiți cel mai mic n la care fiecare model îl depășește în medie pe FinBERT.
 - (c) Raportați abaterea standard a acurateței vectorilor pe cele 10 repetiții la $n = 100$.
- ▣ **De raportat:** curba de învățare și tabelul ei
- ▣ **Interpretare:** de ce vectorii pornesc mai sus, dar cresc mai încet?

B8 [Propus]: sensibilitatea la prompt — enunț

- ▣ **Model:** B1 [Rezolvat]
- ▣ **Întrebare:** se schimbă răspunsul aceluiași LLM când aceeași întrebare este formulată altfel?
- ▣ **Date**
 - ▶ Twitter Financial News, setul de validare: $N = 2\,388$ de titluri din 2022, fiecare etichetat negativ, neutru sau pozitiv; eticheta umană este considerată adevărul
 - ▶ Qwen2.5-7B și 14B cu trei prompturi: P1 „classify the sentiment . . . for investors”, P2 „good, bad or neutral for the stock price”, P3 „what is the sentiment of this text”
- ▣ **Cerințe**
 - (a) Calculați acuratețea cu CI bootstrap din 2 000 de extrageri și ponderea răspunsurilor „neutral” pentru fiecare prompt și model.
 - (b) Aplicați testul McNemar exact pentru P1 față de P3, pentru fiecare model.
 - (c) Calculați ponderea titlurilor cu aceeași etichetă sub toate cele trei prompturi.
- ▣ **De raportat:** un tabel și un grafic pentru cele trei prompturi
- ▣ **Interpretare:** dacă ați alege cel mai bun prompt pe acest set, ce ați face de fapt?

A5 [Rezolvat]: de la probabilitățile etichetelor la un scor și temperatura optimă — enunț

▣ Întrebări

- ▶ cum schimbă temperatura T probabilitățile unui LLM, scorul și calibrarea lui?
- ▶ ce T este optim pentru date?

▣ Date de intrare

- ▶ Un titlu Twitter etichetat **neutru**; Qwen2.5-7B (P1) dă $p_{\text{neg}} = 0,608$, $p_{\text{neu}} = 0,392$, $p_{\text{pos}} = 0,000$ (exact $1,0 \times 10^{-12}$)
- ▶ O jumătate aleatoare a setului de validare ($n = 1\,194$, seed 15): logiții $z_{ik} = \ln p_{ik}$, rescalați $p_{ik}(T) \propto e^{z_{ik}/T}$, pierderea $\text{NLL}(T) = -\sum_i \ln p_{iy_i}(T)$ Guo et al. (2017)

▣ Cerințe

- (a) Dați eticheta, scorul net s și diferența de logit $\ln(p_{\text{neu}}/p_{\text{neg}})$ ale titlului, apoi probabilitățile și s la $T = 2$.
- (b) Explicați de ce etichetele și acuratețea nu depind de T , dar scorul Brier da.
- (c) Deduceți $\text{NLL}'(T)$, evaluați condiția de ordinul întâi la $T = 1$ și rezolvați pentru T^* (Brent pe $[0,5; 50]$).
- (d) Pe cealaltă jumătate, calculați ECE și Brier înainte și după scalare.

▣ De raportat: eticheta, s , $s(T)$, T^* , ECE și Brier înainte și după


▣ Interpretare

- ▶ este LLM-ul prea încrezător sau prea puțin încrezător?
- ▶ ce se întâmplă cu o regulă cu prag pe s ?

A5 [Rezolvat]: rezolvare (1/2)

- ▣ (a) Cea mai mare probabilitate p_{neg} : eticheta negativă, greșită; $s = 0,000 - 0,608 = -0,608$; diferența de logit $\ln(0,392/0,608) = -0,437$
- ▣ La $T = 2$, $p_k(T) \propto \sqrt{p_k}$: $\sqrt{p} = (0,780, 0,626, 1,0 \times 10^{-6})$, suma 1,406, $p(T) = (0,554, 0,446, 0,000)$, $s(T) = -0,554$: aceeași etichetă, scorul se apropie de 0
- ▣ (b) $z \mapsto z/T$ este crescătoare pentru $T > 0$: ordinea logiților, deci argmax și acuratețea, nu se schimbă; probabilitățile, deci Brier și log loss, se schimbă

A5 [Rezolvat]: rezolvare (2/2)




- (c) $\ln p_{iy}(T) = z_{iy}/T - \ln \sum_k e^{z_{ik}/T}$ dă $NLL'(T) = \frac{1}{T^2} \sum_i (z_{iy_i} - \sum_k p_{ik}(T) z_{ik})$
- La $T = 1$ media parantezei este $-2,47 < 0$, deci NLL scade cînd T crește; rădăcina este $T^* = 8,43$
- (d) ECE scade de la 22,6% la 4,3%, Brier de la 0,468 la 0,366 (graficul: fiabilitatea brută și rescalată)
- Interpretare: probabilitățile brute ale LLM sînt mult prea încrezătoare; un prag pe s selectează alte titluri după rescalare

B9 [Rezolvat]: prediction-powered inference cu puține etichete umane — enunț

- ▣ **Întrebare:** pot câteva sute de etichete umane plus un model distorsionat să dea un interval valid și mai îngust pentru tonul mediu al titlurilor?
- ▣ **Date**
 - ▶ Ținta θ = tonul net uman mediu $(-1, 0, 1)$ al celor 2 388 de titluri Twitter de validare, care au rolul populației; f = scorul net FinBERT sau Qwen2.5-7B, fix
 - ▶ Schema: n titluri etichetate (cu Y) și $N - n$ neetichetate (doar cu f), extrase independent, cu întoarcere
- ▣ **Cerințe**
 - (a) Pentru o extragere cu $n = 200$, calculați estimarea doar din etichete $\bar{Y}_n \pm 1,96 s_Y / \sqrt{n}$.
 - (b) Calculați PPI [Angelopoulos et al. \(2023\)](#): $\hat{\theta} = \frac{1}{N-n} \sum_{\text{neetich.}} f - \frac{1}{n} \sum_{\text{etich.}} (f - Y)$, SE
 $= \sqrt{\hat{V}(f)/(N-n) + \hat{V}(f - Y)/n}$, pentru ambele modele.
 - (c) Pentru $n = 100, 200, 400, 800$, repetați de 2 000 de ori și înregistrați acoperirea lui θ și lățimea medie a CI.
- ▣ **De raportat:** estimările dintr-o extragere și un grafic cu acoperirea și lățimea
- ▣ **Interpretare:** de ce media simplă a modelului $\frac{1}{N} \sum f$ nu estimează θ ?

B9 [Rezolvat]: rezolvare



- θ adevărat = 0,054; mediile simple ale modelelor FinBERT $-0,014$ (semn greșit), Qwen $+0,101$: distorsiunea nu scade când N crește
- (a) Doar etichete: $0,010 \pm 1,96 \times 0,042$; (b) PPI-FinBERT: corecția $-0,064$, $\hat{\theta} = 0,054 \pm 1,96 \times 0,036$; PPI-Qwen: corecția $-0,012$, $\hat{\theta} = 0,123 \pm 1,96 \times 0,039$
- (c) $n = 100$: acoperirea 94,7%, 94,3%, 95,4%, lățimea 0,229, 0,204, 0,203 (etichete, PPI-FinBERT, PPI-Qwen); câștigul pentru N mare: 24% și 27%; la $n = 800$ PPI este mai larg (0,087 față de 0,081)
- Interpretare: media modelului converge la o valoare greșită; eșantionul etichetat o corectează, iar PPI este mai îngust doar când $\text{Var}(f - Y) < \text{Var}(Y)$ și multe texte sînt neetichetate

B10 [Propus]: wild cluster bootstrap cu 16 acțiuni — enunț

- ▣ **Model:** B5 [Rezolvat]
- ▣ **Întrebare:** cu doar 16 grupuri de acțiuni, care dintre cele nouă pante din B5 rămân semnificative?
- ▣ **Date**
 - ▶ Panelul FNSPID: 18 282 de zile-acțiune cu știri, 16 acțiuni americane, 27.10.2009–18.12.2023; $z_{i,d}$: scorul net zilnic, standardizat pe panel; r^e : randamentul în exces față de SPY (%), din prețurile ajustate zilnice ale cursului
 - ▶ Cele nouă regresii din B5 (trei scoruri $\times h = 0, 1, 2$), SE grupate pe acțiuni ($G = 16$)
- ▣ **Cerințe**
 - (a) Calculați p -value-ul fiecărei pante cu valori critice t_{15} .
 - (b) Aplicați wild cluster bootstrap cu ipoteza nulă impusă [Cameron, Gelbach & Miller \(2008\)](#): $y_i^* = \bar{y} + w_{g(i)}(y_i - \bar{y})$, ponderi Rademacher $w_g = \pm 1$, 9 999 de extrageri.
 - (c) Calculați t cu grupare pe două dimensiuni, $\hat{V} = \hat{V}_{\text{zi}} + \hat{V}_{\text{acțiune}} - \hat{V}_{\text{zi} \cap \text{acțiune}}$.
 - (d) Ajustați cele nouă p -value-uri bootstrap cu Holm la 5%.
- ▣ **De raportat:** un tabel cu t , cele trei p -value-uri și t pe două dimensiuni
- ▣ **Interpretare:** rămîne semnificativă panta Qwen la $h = 2$?

B11 [Propus]: curba specificațiilor pentru strategia de sentiment — enunț

- ▣ **Model:** B7 [Rezolvat] (un test prin randomizare)
- ▣ **Întrebare:** pe toate variantele rezonabile ale strategiei, există mai multe dovezi de predictibilitate decât ar produce întâmplarea?
- ▣ **Date**
 - ▶ Strategia de sentiment (slide-ul 3/3 din „Noțiuni necesare azi”; studiată în [Capitolul 15](#)): la închiderea din $d + 1$ deschidem o poziție de semn $\text{sign}(s_{i,d})$ în fiecare acțiune cu știri în ziua d , acoperită (hedging) cu SPY și închisă după o zi; patru tranzacții în fiecare zi cu poziții; 3 568 de zile de tranzacționare
 - ▶ Grila din Cursul 15: trei scoruri $\times$ praguri $|s| > b$, $b \in \{0; 0,25; 0,5\}$, $\times$ ziua randamentului $d + 2, \dots, d + 5$: 36 de strategii
- ▣ **Cerințe**
 - (a) Calculați randamentul zilnic mediu și t_{NW} pentru fiecare strategie și reprezentați statisticile t sortate [Simonsohn, Simmons & Nelson \(2020\)](#).
 - (b) Simulați ipoteza nulă comună: schimbați semnul pozițiilor în blocuri de 10 zile de semnal (dependent wild bootstrap [Shao \(2010\)](#)), aceleași schimbări pentru toate 36, de 2 000 de ori.
 - (c) Calculați p -value-urile comune pentru numărul de $t > 1,96$ și pentru t median.
- ▣ **De raportat:** curba sortată și cele două p -value-uri comune
- ▣ **Interpretare:** ce ar ascunde raportarea „cele mai bune specificații”?

A8 [Propus]: strategia Qwen după costuri — enunț

- ▣ **Model:** A7 [Rezolvat]
- ▣ **Întrebare:** strategia Qwen2.5-7B are un randament brut mediu pozitiv statistic: este ea tranzacționabilă?
- ▣ **Date de intrare**
 - ▶ Strategia de sentiment (slide-ul 3/3 din „Noțiuni necesare azi”; studiată în [Capitolul 15](#)): la închiderea din $d + 1$ deschidem o poziție de semn $\text{sign}(s_{i,d})$ în fiecare acțiune cu știri în ziua d , acoperită (hedging) cu SPY și închisă după o zi; patru tranzacții în fiecare zi cu poziții; 3 568 de zile de tranzacționare
 - ▶ Semnalul Qwen2.5-7B: $\hat{\mu} = 5,64$ bp, $t_{NW} = 2,26$ ($L = 8$), $a = 0,950$, raportul Sharpe brut 0,63
- ▣ **Cerințe**
 - (a) Calculați costul de echilibru c^* .
 - (b) Calculați $\text{SE}(c^*)$ prin metoda delta și CI 95%.
 - (c) Obțineți σ și calculați raportul Sharpe net la 5 bp.
- ▣ **De raportat:** c^* , SE, CI, raportul Sharpe net
- ▣ **Interpretare:** un randament brut semnificativ implică profit după costuri?

B6 [Propus]: studiu de eveniment cu tonul Loughran–McDonald — enunț

▣ **Model:** B5 [Rezolvat]

▣ **Întrebări**

- ▶ în jurul zilelor cu știri negative și pozitive, când se mișcă prețul?
- ▶ separă dicționarul cele două grupuri la fel de bine ca FinBERT?

▣ **Date**

- ▶ Panelul FNSPID: 18 282 de zile-acțiune cu știri, 16 acțiuni americane, 27.10.2009–18.12.2023; $z_{i,d}$: scorul net zilnic, standardizat pe panel; r^e : randamentul în exces față de SPY (%), din prețurile ajustate zilnice ale cursului
- ▶ Tonul zilnic LM este exact 0 în 48% dintre zilele-acțiune: grupurile ton < 0 (5 196 de zile-acțiune) și ton > 0 (4 288); FinBERT: terčila inferioară și cea superioară

▣ **Cerințe**

- Pentru fiecare dată, mediați randamentele în exces din zilele $-5, \dots, +5$ pe zilele-acțiune ale acelei date, în fiecare grup.
- Calculați media pe date a CAR pentru $[-5, -1]$, ziua 0, ziua 1 și $[+2, +5]$, cu t_{NW} .
- Reprezentați traiectoriile cumulate medii ale celor patru grupuri.

▣ **De raportat:** tabelul celor patru ferestre și graficul

▣ **Interpretare:** de ce este randamentul de după eveniment pozitiv pentru ambele grupuri Tetlock (2007)?

C1 [Propus]: profitabilitatea sentimentului titlurilor după costuri — enunț

▣ **Model:** A7, B5 [Rezolvat]

▣ **Întrebare:** este profitabilă după costuri realiste o strategie zilnică bazată pe sentimentul titlurilor FNSPID?

▣ **Date**

- ▶ Strategia de sentiment (slide-ul 3/3 din „Noțiuni necesare azi”; studiată în [Capitolul 15](#)): la închiderea din $d + 1$ deschidem o poziție de semn $\text{sign}(s_{i,d})$ în fiecare acțiune cu știri în ziua d , acoperită (hedging) cu SPY și închisă după o zi; patru tranzacții în fiecare zi cu poziții; 3 568 de zile de tranzacționare
- ▶ Poziții ponderate egal; zilele fără știri: randament 0; 5 bp pe tranzacție; scorurile FinBERT, Qwen2.5-7B, LM din tabelele salvate

▣ **Cerințe**

- (a) Pentru FinBERT, calculați randamentul brut zilnic mediu, t_{NW} și un CI bootstrap pe blocuri mobile de 95% (blocuri de 10 zile, 2 000 de extrageri).
 - (b) Calculați raportul Sharpe înainte și după costuri, costul de echilibru și raportul Sharpe la 0, 1, 2, 5, 10 bp.
 - (c) Repetați pentru Qwen2.5-7B și LM și pentru știrile puternice $|s| > 0,5$ (exploratoriu); Holm pe cele trei strategii nefiltrate sau pe toate șase dacă alegeți dintre ele.
 - (d) Pas suplimentar: corectați panta din aceeași zi cu un eșantion aleator de zile-acțiune etichetat de oameni (împărțiți la $\rho(s^*, \hat{s})$ sau corectați momentele OLS ca în B9).
- ▣ **De raportat:** o notă de două pagini cu un tabel de rezultate și grafice și un folder Quantlet
- ▣ **Interpretare:** discutați alinierea în timp, look-ahead bias (B7), survivorship bias pentru cele 16 acțiuni și crowding Lopez-Lira & Tang (2026)

C3 [Propus]: replicarea Lopez-Lira și Tang pe FNSPID — enunț

- **Model:** C1, B5, B10, B7
- **Întrebare:** aplicat cu un model deschis pe titlurile cursului, găsește protocolul publicat pentru GPT-4 Lopez-Lira & Tang (2026) aceeași reacție și același drift?
- **Date de intrare**
 - ▶ Lucrarea: GPT-4 răspunde YES, NO sau UNKNOWN despre fiecare titlu; $s = 1, -1, 0$ determină un portofoliu long-short zilnic; drift-ul pentru știrile dintre ședințe 0,34% pe zi, raport Sharpe 2,97 (tabelul 1)
 - ▶ Date: titlurile FNSPID ale celor 16 acțiuni, prețurile ajustate din datele cursului; primul randament sigur $d + 2$
 - ▶ Modelul: Qwen2.5-7B-Instruct Qwen Team (2024), temperatura 0, prompt-ul din secțiunea 5 a lucrării, nemodificat
- **Cerințe**
 - (a) Evaluați fiecare titlu, extrageți doar prima linie, transformați YES/UNKNOWN/NO în 1/0/ - 1; raportați ponderile și răspunsurile nevalide.
 - (b) Mediați pe zi-acțiune și formați portofoliul zilnic cu convențiile de pe slide-ul următor, cu randamentele din ziua $d + 2$.
 - (c) Raportați media zilnică (bp), t_{NW} , rata de succes, raportul Sharpe, ponderile zilelor cu o componentă și fără poziție.
 - (d) Estimați ec. (1) pe titluri, $h = 0, 2$, cu efecte fixe de acțiune și de dată, SE grupate pe date și acțiuni, p wild cluster bootstrap (B10).
 - (e) Recalculeți raportul Sharpe după 5, 10, 20 bp pe tranzacție dus-întors (figura 4) și comparați cu C1 pe aceleași zile-acțiune.
- **De raportat:** cifrele obținute lângă tabelele 1 și 2 din lucrare, randamentele cumulate brute și nete, un folder Quantlet
- **Interpretare**
 - ▶ ce diferențe față de lucrare pot fi separate cu datele cursului?
 - ▶ ce indică B7 despre distorsiune?

C3 [Propus]: convențiile pentru portofoliu, calendar și costuri

▣ Fixate înaintea oricărei rulări

- ▶ Ponderile (tabelul 1): componenta long = randamentul mediu, cu ponderi egale, al acțiunilor cu $s > 0$, componenta short = la fel pentru $s < 0$, fiecare doar cu cel puțin două acțiuni; long-short = long minus short (expunere brută 2); dacă se califică o singură componentă, se deține doar aceasta (nota 20)
- ▶ Randamentele: randamentele brute ale acțiunilor, ca în tabelul 1; varianta cu hedging pe SPY (ca în C1) este o adaptare a cursului, raportată ca analiză de sensibilitate: cu ambele componente acoperirea se anulează, deci contează doar în zilele cu o singură componentă
- ▶ Calendarul: toate zilele de tranzacționare, ca în C1, cu randament 0 fără poziție; media, t_{NW} și raportul Sharpe pe toate zilele; rata de succes pe zilele cu poziții
- ▶ Costurile (figura 4): c bp pe tranzacție dus-întors pentru fiecare unitate de valoare nominală: $2c$ pe zi cu două componente, c cu una, plus, în varianta cu hedging, c pe valoarea nominală netă SPY (1 în zilele cu o singură componentă)
- ▶ Regresiile (d): randamente brute în % pe zi, ca în tabelul 2; efectele fixe de dată absorb randamentul pieței; wild cluster bootstrap păstrează ambele efecte fixe în modelul nul

Bibliografie (1/3)

- ▣ Aigner, D.J. (1973). Regression with a binary independent variable subject to errors of observation. *Journal of Econometrics*, 1(1), 49–59.
- ▣ Angelopoulos, A.N., Bates, S., Fannjiang, C., Jordan, M.I., Zrnic, T. (2023). Prediction-powered inference. *Science*, 382(6671), 669–674.
- ▣ Araci, D. (2019). FinBERT: financial sentiment analysis with pre-trained language models. arXiv:1908.10063.
- ▣ Cameron, A.C., Gelbach, J.B., Miller, D.L. (2008). Bootstrap-based improvements for inference with clustered errors. *Review of Economics and Statistics*, 90(3), 414–427.
- ▣ Dawid, A.P., Skene, A.M. (1979). Maximum likelihood estimation of observer error-rates using the EM algorithm. *Applied Statistics*, 28(1), 20–28.
- ▣ DeLong, E.R., DeLong, D.M., Clarke-Pearson, D.L. (1988). Comparing the areas under two or more correlated receiver operating characteristic curves: a nonparametric approach. *Biometrics*, 44(3), 837–845.
- ▣ Dong, Z., Fan, X., Peng, Z. (2024). FNSPID: a comprehensive financial news dataset in time series. *Proceedings of the 30th ACM SIGKDD Conference*, 4918–4927.
- ▣ Fleiss, J.L. (1971). Measuring nominal scale agreement among many raters. *Psychological Bulletin*, 76(5), 378–382.

Bibliografie (2/3)

- ▣ Franke, J., Härdle, W.K., Hafner, C.M. (2019). *Statistics of Financial Markets: An Introduction*, 5th ed. Springer.
- ▣ Glasserman, P., Lin, C. (2023). *Assessing look-ahead bias in stock return predictions generated by GPT sentiment analysis*. arXiv:2309.17322.
- ▣ Guo, C., Pleiss, G., Sun, Y., Weinberger, K.Q. (2017). *On calibration of modern neural networks*. *ICML*; arXiv:1706.04599.
- ▣ Lopez-Lira, A., Tang, Y. (2026). *Can ChatGPT forecast stock price movements? Return predictability and large language models*. *Journal of Financial Economics*, 184, 104335.
- ▣ Loughran, T., McDonald, B. (2011). *When is a liability not a liability? Textual analysis, dictionaries, and 10-Ks*. *Journal of Finance*, 66(1), 35–65.
- ▣ Malo, P., Sinha, A., Korhonen, P., Wallenius, J., Takala, P. (2014). *Good debt or bad debt: detecting semantic orientations in economic texts*. *Journal of the Association for Information Science and Technology*, 65(4), 782–796.
- ▣ McNemar, Q. (1947). *Note on the sampling error of the difference between correlated proportions or percentages*. *Psychometrika*, 12(2), 153–157.
- ▣ Newey, W.K., West, K.D. (1987). *A simple, positive semi-definite, heteroskedasticity and autocorrelation consistent covariance matrix*. *Econometrica*, 55(3), 703–708.

Bibliografie (3/3)

- ▣ Petersen, M.A. (2009). [Estimating standard errors in finance panel data sets: comparing approaches](#). *Review of Financial Studies*, 22(1), 435–480.
- ▣ Qwen Team (2024). [Qwen2.5 technical report](#). arXiv:2412.15115.
- ▣ Sarkar, S.K., Vafa, K. (2024). [Lookahead bias in pretrained language models](#). SSRN Working Paper 4754678.
- ▣ Shao, X. (2010). [The dependent wild bootstrap](#). *Journal of the American Statistical Association*, 105(489), 218–235.
- ▣ Simonsohn, U., Simmons, J.P., Nelson, L.D. (2020). [Specification curve analysis](#). *Nature Human Behaviour*, 4(11), 1208–1214.
- ▣ Tetlock, P.C. (2007). [Giving content to investor sentiment: the role of media in the stock market](#). *Journal of Finance*, 62(3), 1139–1168.
- ▣ Wang, W., Wei, F., Dong, L., Bao, H., Yang, N., Zhou, M. (2020). [MiniLM: deep self-attention distillation for task-agnostic compression of pre-trained Transformers](#). *NeurIPS*; arXiv:2002.10957.