



Modelarea piețelor financiare

Seminarul 15: LLM-uri și analiza sentimentului — aplicații



Daniel Traian PELE

Drd. Antoaneta Amza, antoaneta.amza@csie.ase.ro

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognostic Economică

MSCA Digital Finance

Acronime folosite în acest material

- ▣ AI: Artificial Intelligence (inteligență artificială)
- ▣ AUC: Area Under the (ROC) Curve (aria de sub curba ROC)
- ▣ BERT: Bidirectional Encoder Representations from Transformers (reprezentări bidirecționale produse de codificatorul unui Transformer)
- ▣ BVB: Bursa de Valori București
- ▣ CAR: Cumulative Abnormal Return (randamentul anormal cumulat)
- ▣ CI: Confidence Interval (interval de încredere)
- ▣ DELTA: Deep Learning for Text Analytics (Quantinar course) (învățare profundă pentru analiza textelor (curs Quantinar))
- ▣ ECE: Expected Calibration Error (eroarea medie de calibrare)
- ▣ FNSPID: Financial News and Stock Price Integration Dataset (setul de date care integrează știri financiare și prețuri de acțiuni)
- ▣ GI: (Harvard) General Inquirer, dictionary IV-4 (dicționarul Harvard General Inquirer IV-4)
- ▣ IV-4: Harvard IV-4 (version 4 of the General Inquirer word lists) (Harvard IV-4, versiunea 4 a listelor de cuvinte General Inquirer)
- ▣ LDA: Latent Dirichlet Allocation (alocarea Dirichlet latentă (model de teme))
- ▣ LLM: Large Language Model (model lingvistic mare)
- ▣ LM: Loughran-McDonald (financial sentiment dictionary) (dicționarul financiar de sentiment Loughran-McDonald)
- ▣ NLL: Negative Log-Likelihood (logaritmul negativ al verosimilității)
- ▣ OLS: Ordinary Least Squares (metoda celor mai mici pătrate)
- ▣ PPI: Prediction-Powered Inference (inferență susținută de predicții)
- ▣ ROC: Receiver Operating Characteristic (curve) (curba caracteristică de operare)
- ▣ SE: Standard Error (eroare standard)
- ▣ TF-IDF: Term Frequency - Inverse Document Frequency (frecvența termenului înmulțită cu inversul frecvenței în documente)
- ▣ UTC: Coordinated Universal Time (Temps Universel Coordonné) (timpul universal coordonat)

Cuprins

Introducere

Partea A: derivări cu cifre

Partea B: estimare și inferență

Partea C: întrebare deschisă și critica unui răspuns AI

Încheiere

Bibliografie

Obiectivele seminarului

La finalul seminarului puteți

- ▣ Calcula sentimentul unui text cu un dicționar și cu probabilitățile etichetelor unui model lingvistic mare (LLM, *large language model*)
- ▣ Deduce atenuarea pantei unei regresii pe o etichetă de sentiment clasificată greșit, precum și varianța și puterea testelor pe perechi
- ▣ Compara doi clasificatori cu un test pe perechi și detecta contaminarea evaluării prin date de antrenare și utilizarea informației din viitor
- ▣ Realiza inferențe valide folosind scorurile modelelor: prediction-powered inference, wild cluster bootstrap cu puține grupuri, testare multiplă și curbe ale specificațiilor

- ▣ Suport: Cursul 15; manualul [Franke, Härdle & Hafner \(2019\)](#)

Structura

- ▣ **Partea A:** opt derivări cu cifre (A1–A8)
- ▣ **Partea B:** unsprezece exerciții pe calculator, cu inferență (B1–B11)
- ▣ **Partea C:** o întrebare deschisă, punct de plecare pentru proiectul de echipă (C1), și critica unui răspuns AI (C2)

Cum lucrăm la acest seminar

- ▣ Problemele **[Rezolvat]** au rezolvarea completă; problemele **[Propus]** au doar cerința: rezolvările se discută la seminar
- ▣ Fiecare problemă propusă indică **modelul**: problema rezolvată care folosește aceeași tehnică
 - ▶ Fiecare exercițiu din Partea B se încheie cu întrebări de interpretare
- ▣ Puteți folosi un asistent AI, dar declarați-l în [AI_USE.md](#) și notați erorile identificate în [AI_ERRORS.md](#)
 - ▶ C2 exersează exact asta: găsiți erorile dintr-un răspuns AI despre testarea retroactivă a sentimentului
- ▣ Întrebați mereu: era textul public înaintea randamentului pe care încerc să-l prognozez și știa deja modelul rezultatul?

Probleme rezolvate și propuse

Rezolvate: exemple lucrate în acest material

- ▣ Partea A: A1 (atenuarea prin clasificare greșită), A3 (varianța și puterea unui test pe perechi), A5 (probabilitățile și temperatura optimă), A7 (costul de echilibru cu SE)
- ▣ Partea B: B1 (FinBERT vs LM, McNemar), B3 (scurgerea datelor de antrenare), B5 (erori standard grupate), B7 (își amintește LLM-ul piața?), B9 (prediction-powered inference)

Propuse: le rezolvați voi

- ▣ Partea A: A2 (atenuarea LM; model: A1), A4 (puterea, FinBERT vs Qwen; model: A3), A6 (κ Fleiss, Dawid–Skene; model: A1), A8 (Qwen după costuri; model: A7)
- ▣ Partea B: B2 (model: B1), B4 (model: B3), B6 (model: B5), B8 (model: B1), B10 (wild cluster bootstrap; model: B5), B11 (curba specificațiilor; model: B7)
- ▣ Partea C: C1, aduce sentimentul titlurilor câștig după costuri?; C2, critica unui răspuns AI despre testarea retroactivă a sentimentului cu un LLM

Pregătire: mediul Python și datele

- ▣  **Deschide în Colab:** `capitol15_notebook_seminar.ipynb`
- ▣ Google Colab (recomandat) sau Python local ≥ 3.10 cu `numpy`, `pandas`, `scipy`, `scikit-learn`, `matplotlib`; `transformers` doar pentru recalcularea scorurilor
- ▣ Texte etichetate: Financial PhraseBank (4 846 de propoziții din știri, 2 264 cu acord deplin) [Malo et al. \(2014\)](#); Twitter Financial News, setul de validare (2 388 de titluri)
- ▣ Titluri date: FNSPID (*Financial News and Stock Price Integration Dataset*) [Dong, Fan & Peng \(2024\)](#), 106 820 de titluri despre 16 acțiuni americane mari; prețuri zilnice de închidere ale acțiunilor și ale SPY (un fond pe indicele S&P 500)
- ▣ Scorurile tuturor modelelor sunt precalculate în tabelele Capitolului 15; Quantlets: [MFM_ch15_sem_partA](#), [partB](#), [partC](#)

Formulele folosite azi (1/2): scoruri și metrice

- Tonul după dicționar: $\tau = (P - N)/(P + N)$, P , N : numărul de cuvinte pozitive și negative; $\tau = 0$ dacă $P + N = 0$
 - ▶ LM: listele financiare de cuvinte Loughran–McDonald [Loughran & McDonald \(2011\)](#); GI: lista Harvard General Inquirer IV-4, un dicționar general din psihologie
- Probabilitățile etichetelor unui LLM: $p_k = e^{z_k/T} / \sum_j e^{z_j/T}$ (z_k : logitul cuvântului-răspuns k , T : temperatura); scorul net $s = p_{\text{pos}} - p_{\text{neg}}$
 - ▶ FinBERT: un model BERT (*Bidirectional Encoder Representations from Transformers*) ajustat pentru sentimentul financiar [Araci \(2019\)](#); Qwen2.5: LLM-uri cu ponderi deschise [Qwen Team \(2024\)](#)
- Regresor binar clasificat greșit [Aigner \(1973\)](#): $\text{plim } \hat{b} = \beta \pi(1 - \pi)(1 - \alpha_0 - \alpha_1)/[p(1 - p)]$
 - ▶ κ Fleiss = $(\bar{P} - \bar{P}_e)/(1 - \bar{P}_e)$ pentru acordul mai multor evaluatori [Fleiss \(1971\)](#)

Formulele folosite azi (2/2): inferență și semnale

- Testul McNemar [McNemar \(1947\)](#): n_{01} texte unde A greșește și B are dreptate, n_{10} invers; sub H_0 , $n_{01} \sim \text{Bin}(n_{01} + n_{10}, 0,5)$
 - CI bootstrap (interval de încredere): reeșantionăm textele de 2 000 de ori, luăm cuantilele de 2,5% și 97,5%
- AUC (aria de sub curba ROC): probabilitatea ca un caz „în creștere” ales aleator să primească un scor mai mare decât un caz „în scădere”; 0,5 = nicio informație
- PPI [Angelopoulos et al. \(2023\)](#), n texte etichetate și N neetichetate, eșantionate independent, f fix:

$$\hat{\theta} = \frac{1}{N} \sum_{\text{neetich.}} f(\tilde{X}_i) - \frac{1}{n} \sum_{\text{etich.}} (f(X_j) - Y_j), \text{ varianța } \widehat{\text{Var}}(f)/N + \widehat{\text{Var}}(f - Y)/n$$
- Regresia pe panel $r_{i,d+h}^e = a + b z_{i,d} + \varepsilon$: r^e randamentul în exces față de SPY (%), z scorul zilnic standardizat, $h = 0, 1, 2$ zile după ziua știrii d
 - Erori standard (SE): cele mai mici pătrate obișnuite (OLS) sau grupate pe zile ori pe acțiuni [Petersen \(2009\)](#); bp: punct de bază, 0,01%
- Strategia: t Newey–West [Newey & West \(1987\)](#); raportul Sharpe anualizat $\sqrt{252} \bar{r}/s_r$; costul de echilibru = randamentul brut mediu în zilele cu poziții / 4 (patru tranzacții pe zi)

A1: atenuarea prin clasificare greșită (FinBERT) (cerința 1/2) [Rezolvat]

Cerință

□ Context și ipoteze

- Date: Twitter Financial News, setul de validare cu $N = 2\,388$ de titluri publicate în 2022, fiecare etichetat negativ, neutru sau pozitiv de adnotatori; eticheta umană este considerată adevărul
- Regresia de interes: $r = a + \beta s^* + \varepsilon$, unde $s^* = 1$ dacă titlul este cu adevărat negativ și 0 altfel; observăm doar $\hat{s} = 1$ când FinBERT prezice „negativ”
- Ipoteză (eroare nediferențială): odată cunoscut s^* , $\hat{s}$ nu aduce informație despre r , deci $\text{Cov}(\varepsilon, \hat{s}) = 0$
- Notății: $\pi = P(s^* = 1)$, $p = P(\hat{s} = 1)$, rata alarmelor false $\alpha_0 = P(\hat{s} = 1 \mid s^* = 0)$, rata ratărilor $\alpha_1 = P(\hat{s} = 0 \mid s^* = 1)$; matricea de confuzie FinBERT (rânduri: eticheta adevărată, coloane: predicția):

Adevărat \ prezis	neg	neu	pos	Total
neg	264	71	12	347
neu	213	1 184	169	1 566
pos	58	133	284	475
Total	535	1 388	465	2 388

A1: atenuarea prin clasificare greșită (FinBERT) (cerința 2/2) [Rezolvat]

Cerință

▣ Ce aveți de făcut

- ▶ (a) Scrieți limita în probabilitate a pantei OLS a lui r pe $\hat{s}$ și arătați că este egală cu $\beta \text{Cov}(s^*, \hat{s}) / \text{Var}(\hat{s})$ sub ipoteza de mai sus
- ▶ (b) Deduceți $\text{Cov}(s^*, \hat{s}) = \pi(1 - \pi)(1 - \alpha_0 - \alpha_1)$ și $\text{Var}(\hat{s}) = p(1 - p)$, deci factorul de atenuare $\lambda = \pi(1 - \pi)(1 - \alpha_0 - \alpha_1) / [p(1 - p)]$
- ▶ (c) Calculați π , p , α_0 și α_1 din primul rând și prima coloană a matricei, apoi λ cu trei zecimale
- ▶ (d) Calculați $\text{Cov}(u, s^*)$ pentru eroarea de măsurare $u = \hat{s} - s^*$ și decideți dacă eroarea este clasică (necorelată cu s^*)

▣ Ce raportați

- ▶ λ și factorul $1/\lambda$ cu care β adevărat depășește panta observată [Aigner \(1973\)](#)
- ▶ Interpretare: ce implică λ pentru panta pe variabila binară FinBERT „știre negativă” și de ce nu se transferă la pantele pe scorul continuu din Cursul 15?

A1: Rezolvare (1/2) [Rezolvat]

Rezolvare

- (a) Pentru un singur regresor, $\text{plim } \hat{b} = \text{Cov}(r, \hat{s}) / \text{Var}(\hat{s})$; înlocuind $r = a + \beta s^* + \varepsilon$ obținem $\text{Cov}(r, \hat{s}) = \beta \text{Cov}(s^*, \hat{s}) + \text{Cov}(\varepsilon, \hat{s})$
- Eroarea este nediferențială, deci $\text{Cov}(\varepsilon, \hat{s}) = 0$ și $\text{plim } \hat{b} = \beta \text{Cov}(s^*, \hat{s}) / \text{Var}(\hat{s})$
- (b) Ambele variabile sunt binare: $\text{Cov}(s^*, \hat{s}) = P(s^* = 1, \hat{s} = 1) - \pi p = \pi(1 - \alpha_1) - \pi p$
- Din formula probabilității totale $p = \pi(1 - \alpha_1) + (1 - \pi)\alpha_0$; înlocuind, $\text{Cov}(s^*, \hat{s}) = \pi(1 - \pi)(1 - \alpha_1) - \pi(1 - \pi)\alpha_0 = \pi(1 - \pi)(1 - \alpha_0 - \alpha_1)$
- $\hat{s}$ este o variabilă Bernoulli, deci $\text{Var}(\hat{s}) = p(1 - p)$, iar raportul celor două dă λ

A1: Rezolvare (2/2) [Rezolvat]

Rezolvare

- (c) $\pi = 347/2\,388 = 0,1453$ și $p = 535/2\,388 = 0,2240$
- $\alpha_1 = 1 - 264/347 = 0,2392$ (negative ratate); $\alpha_0 = 271/2\,041 = 0,1328$ (titluri neutre sau pozitive numite negative)
- $\lambda = \frac{0,1242 \times 0,6280}{0,2240 \times (1 - 0,2240)} = \frac{0,0780}{0,1738} = 0,449$, deci $\beta = 2,23 \hat{b}$
- (d) $\text{Cov}(u, s^*) = \text{Cov}(\hat{s}, s^*) - \text{Var}(s^*) = 0,0780 - 0,1242 = -0,0462 < 0$: eroarea este corelată negativ cu adevărul, deci nu este clasică [Aigner \(1973\)](#)
- Interpretare: o pantă pe variabila binară FinBERT păstrează doar circa 45% din efectul adevărat; pantele din Cursul 15 folosesc un scor continuu standardizat, atenuat în schimb prin $\rho(s^*, \hat{s})$ (curs), deci λ nu se transferă

A2: atenuarea pentru dicționarul LM (cerința 1/2) [Propus]

Rezolvarea se discută la seminar

Cerință

Context și ipoteze

- Date: Twitter Financial News, setul de validare cu $N = 2\,388$ de titluri publicate în 2022, fiecare etichetat negativ, neutru sau pozitiv de adnotatori; eticheta umană este considerată adevărul
- Aceeași regresie și aceeași ipoteză de eroare nediferențială ca în A1; acum $\hat{s} = 1$ când tonul Loughran–McDonald (LM) al titlului este negativ
- Matricea de confuzie LM pe aceleași titluri (rânduri: eticheta adevărată, coloane: predicția):

Adevărat \ prezis	neg	neu	pos	Total
neg	172	166	9	347
neu	247	1 192	127	1 566
pos	45	349	81	475
Total	464	1 707	217	2 388

A2: atenuarea pentru dicționarul LM (cerința 2/2) [Propus]

Rezolvarea se discută la seminar

Cerință

▣ Ce aveți de făcut

- ▶ (a) Calculați π , p , α_0 și α_1 din primul rând și prima coloană a matricei
- ▶ (b) Calculați factorul de atenuare λ și factorul de corecție $1/\lambda$ cu formula din A1
- ▶ (c) Calculați $\text{Cov}(u, s^*)$ și spuneți dacă eroarea LM este clasică
- ▶ (d) Comparați λ cu valoarea FinBERT din A1: care clasificator atenuează mai mult și în ce raport?

▣ Ce raportați

- ▶ Cele patru rate, λ , $1/\lambda$ și raportul celor doi factori
- ▶ Interpretare: este panta LM mai slabă din Cursul 15 (15,5 bp față de 39,2 bp pentru FinBERT) o dovadă a unei reacții mai slabe a pieței la știrile negative după LM? Model: A1

A3: diferența de acuratețe pe perechi: varianță, test exact, putere (cerința 1/2) [Rezolvat]

Cerință

▣ Context și ipoteze

- Date: Twitter Financial News, setul de validare cu $N = 2\,388$ de titluri publicate în 2022, fiecare etichetat negativ, neutru sau pozitiv de adnotatori; eticheta umană este considerată adevărul
- Clasificatorul A = dicționarul LM, clasificatorul B = FinBERT; numere de cazuri discordante $n_{01} = 539$ (A greșește, B are dreptate) și $n_{10} = 252$ (A are dreptate, B greșește); titlurile sunt independente
- Pentru titlul i , $D_i = 1$ dacă A greșește și B are dreptate, $D_i = -1$ dacă A are dreptate și B greșește, $D_i = 0$ altfel; diferența de acuratețe este $d = ED_i = \text{acc}_B - \text{acc}_A$

A3: diferența de acuratețe pe perechi: varianță, test exact, putere (cerința 2/2) [Rezolvat]

Cerință

□ Ce aveți de făcut

- ▶ (a) Arătați că $\hat{d} = (n_{01} - n_{10})/n$ și deduceți $\text{Var}(\hat{d}) = (q - d^2)/n$, unde $q = P(D_i \neq 0)$ se estimează prin $(n_{01} + n_{10})/n$
- ▶ (b) Calculați $\hat{d}$, eroarea standard, CI 95% $\hat{d} \pm 1,96 \text{ SE}$ și $z = \hat{d}/\text{SE}$
- ▶ (c) Aplicați testul McNemar exact [McNemar \(1947\)](#): sub $H_0 : d = 0$, $n_{01} \sim \text{Bin}(n_{01} + n_{10}; 0,5)$; dați valoarea p bilaterală și decizia la $\alpha = 5\%$
- ▶ (d) Aproximați puterea la $n = 2\,388$ dacă d adevărat este $\hat{d}$, puterea $\approx \Phi(|d|\sqrt{n}/\sqrt{q - d^2} - 1,96)$, și n necesar pentru puterea 80%, $n_{80} = (1,96 + 0,84)^2(q - d^2)/d^2$

□ Ce raportați

- ▶ $\hat{d}$, SE, CI, z , p exact, decizia, puterea și n_{80} ; comparați CI cu CI bootstrap pe perechi din B1
- ▶ Interpretare: ce titluri determină varianța lui $\hat{d}$?

A3: Rezolvare (1/2) [Rezolvat]

Rezolvare

- (a) $\hat{d} = \frac{1}{n} \sum_i D_i = (n_{01} - n_{10})/n$, pentru că 539 termeni sunt +1, 252 sunt -1, iar restul sunt 0
- $D_i^2 = 1$ exact atunci când un clasificator are dreptate și celălalt greșește (două etichete greșite, dar diferite, dau $D_i = 0$), deci $ED_i^2 = q$ și $\text{Var}(D_i) = q - d^2$; cu titluri independente, $\text{Var}(\hat{d}) = (q - d^2)/n$
- (b) $\hat{d} = (539 - 252)/2\,388 = 0,1202$, $\hat{q} = 791/2\,388 = 0,3312$
- $SE = \sqrt{(0,3312 - 0,01444)/2\,388} = 1,15 \text{ pp}$; CI 95% [9,76; 14,28] pp, apropiat de CI bootstrap [+9,8; +14,2] din B1; $z = 10,43$

A3: Rezolvare (2/2) [Rezolvat]

Rezolvare

- (c) Sub H_0 ne așteptăm la 395,5 din cele 791 de titluri discordante de fiecare parte; observând 539, p exact bilateral $< 0,001$
- Decizia: respingem H_0 la 5%; FinBERT este mai precis decât LM pe aceste titluri
- (d) $|d|\sqrt{n}/\sqrt{q-d^2} - 1,96 = +8,47$, deci puterea este $\Phi(+8,47) \approx 100\%$;
 $n_{80} = 7,84 \times (0,3312 - 0,01444)/0,01444 \approx 170$ de titluri
- Interpretare: doar titlurile discordante (q) intră în varianță; o diferență de 12 puncte se poate detecta cu câteva sute de titluri

A4: este „nicio diferență” o problemă de putere? [Propus]

Rezolvarea se discută la seminar

Cerință

▣ Context și ipoteze

- Date: Twitter Financial News, setul de validare cu $N = 2\,388$ de titluri publicate în 2022, fiecare etichetat negativ, neutru sau pozitiv de adnotatori; eticheta umană este considerată adevărul
- Clasificatorul A = FinBERT, clasificatorul B = Qwen2.5-7B zero-shot (promptul P1); $n_{01} = 395$ (A greșește, B are dreptate), $n_{10} = 355$ (A are dreptate, B greșește)
- Pentru titlul i , $D_i = 1$ dacă A greșește și B are dreptate, $D_i = -1$ dacă A are dreptate și B greșește, $D_i = 0$ altfel; diferența de acuratețe este $d = ED_i = acc_B - acc_A$

▣ Ce aveți de făcut

- (a) Calculați $\hat{d}$, $\hat{q}$, SE, CI 95% și z cu formulele din A3
- (b) Aplicați testul McNemar exact la $\alpha = 5\%$ și formulați decizia
- (c) Calculați puterea la $n = 2\,388$ dacă d adevărat este $\hat{d}$ și n_{80}
- (d) Folosiți CI pentru a spune ce diferențe de acuratețe sunt excluse de date

▣ Ce raportați

- Toate cifrele din (a)–(c); interpretare: puteți concluziona că cele două modele sunt la fel de precise? Model: A3

A5 (1/2): de la probabilitățile etichetelor la un scor [Rezolvat]

Cerință

▣ Context și ipoteze

- ▶ Qwen2.5-7B, zero-shot cu promptul P1, un titlu din setul de validare Twitter etichetat **neutru** de adnotatori
- ▶ Probabilitățile cuvintelor-răspuns (rotunjite): $p_{\text{neg}} = 0,608$, $p_{\text{neu}} = 0,392$, $p_{\text{pos}} = 0,000$ (exact $1,0 \times 10^{-12}$); ele provin din logiți prin $p_k = e^{z_k/T} / \sum_j e^{z_j/T}$ cu $T = 1$

▣ Ce aveți de făcut

- ▶ (a) Dați eticheta prezisă $\arg \max_k p_k$ și scorul net $s = p_{\text{pos}} - p_{\text{neg}}$ și spuneți dacă eticheta este corectă
- ▶ (b) Calculați diferența de logit $z_{\text{neu}} - z_{\text{neg}} = \ln(p_{\text{neu}}/p_{\text{neg}})$
- ▶ (c) Calculați probabilitățile, eticheta și scorul la $T = 2$, folosind $p_k(T) \propto p_k^{1/T}$

▣ Ce raportați

- ▶ Eticheta, s , diferența de logit și $p(T)$, $s(T)$; interpretare: ce se întâmplă cu o regulă de tranzacționare cu prag pe s când se schimbă T ?

A5 (1/2): Rezolvare [Rezolvat]

Rezolvare

- ▣ (a) Cea mai mare probabilitate este $p_{\text{neg}} = 0,608$: eticheta este negativă, ceea ce este greșit (clasa adevărată este neutră)
- ▣ $s = p_{\text{pos}} - p_{\text{neg}} = 0,000 - 0,608 = -0,608$: un scor puternic negativ pentru un titlu neutru
- ▣ (b) $z_{\text{neu}} - z_{\text{neg}} = \ln(0,392/0,608) = -0,437$: logitul clasei neutre este mai mic decât cel al clasei negative cu mai puțin de jumătate de unitate
- ▣ (c) Cu $T = 2$, $p_k(T) \propto \sqrt{p_k}$: $\sqrt{p} = (0,780, 0,626, 1,0 \times 10^{-6})$ cu suma 1,406, deci $p(T) = (0,554, 0,446, 0,000)$
- ▣ Eticheta rămâne negativă și $s(T) = -0,554$; interpretare: temperatura păstrează ordinea, dar apropie scorul de 0, deci o regulă ca $|s| > 0,5$ selectează alte titluri

A5 (2/2): estimarea temperaturii [Rezolvat]

Cerință

□ Context și ipoteze

- Probabilitățile Qwen2.5-7B pe o jumătate aleatoare a setului de validare Twitter ($n = 1\,194$ de titluri, sămânța 15); logiții $z_{ik} = \ln p_{ik}$, eticheta adevărată y_i
- Probabilitățile rescalate $p_{ik}(T) = e^{z_{ik}/T} / \sum_l e^{z_{il}/T}$, $T > 0$; pierderea $\text{NLL}(T) = -\sum_i \ln p_{iy_i}(T)$ Guo et al. (2017)

□ Ce aveți de făcut

- (a) Explicați de ce etichetele prezise și acuratețea nu depind de T , dar scorul Brier da
- (b) Deduceți $\text{NLL}'(T)$ și scrieți condiția de ordinul întâi pentru T optim
- (c) Calculați media expresiei din paranteze din condiția de ordinul întâi la $T = 1$, apoi rezolvați pentru T^* cu o metodă numerică (metoda Brent pe $[0,5; 50]$)
- (d) Pe cealaltă jumătate, calculați ECE (10 intervale egale ale probabilității maxime pe $[1/3, 1]$) și scorul Brier $\frac{1}{n} \sum_i \sum_k (p_{ik}(T) - 1\{y_i = k\})^2$ (însumat pe cele 3 clase) înainte și după scalare

□ Ce raportați

- T^* , semnul la $T = 1$, ECE și Brier înainte și după; interpretare: este LLM-ul prea încrezător sau prea puțin încrezător?

A5 (2/2): Rezolvare [Rezolvat]

Rezolvare

- (a) $z \mapsto z/T$ este crescătoare pentru $T > 0$, deci ordinea z_{i1}, z_{i2}, z_{i3} și astfel argmax și acuratețea nu se schimbă; probabilitățile se schimbă, iar odată cu ele Brier și log loss
- (b) $\ln p_{iy}(T) = z_{iy}/T - \ln \sum_k e^{z_{ik}/T}$, deci $\frac{d}{dT} \ln p_{iy}(T) = -\frac{z_{iy}}{T^2} + \frac{1}{T^2} \sum_k p_{ik}(T) z_{ik}$
- $NLL'(T) = \frac{1}{T^2} \sum_i (z_{iy_i} - \sum_k p_{ik}(T) z_{ik}) = 0$: în medie, logitul clasei adevărate trebuie să fie egal cu valoarea sa medie conform distribuției modelului
- (c) La $T = 1$ media parantezei este $-2,47 < 0$, deci NLL scade când T crește; rădăcina este $T^* = 8,43$
- (d) ECE scade de la 22,6% la 4,3%, iar scorul Brier de la 0,468 la 0,366; interpretare: probabilitățile brute ale LLM-ului sunt mult prea încrezătoare

A6: κ al lui Fleiss și un pas Dawid–Skene (cerința 1/2) [Propus]

Rezolvarea se discută la seminar

Cerință

Context și ipoteze

- Tabel ilustrativ (cifre alese pentru exercițiu): 6 propoziții, câte $m = 5$ evaluatori, voturi pentru negativ, neutru, pozitiv
- κ al lui Fleiss [Fleiss \(1971\)](#): $P_i = \sum_j n_{ij}(n_{ij} - 1)/[m(m - 1)]$, $\bar{P} = \frac{1}{N} \sum_i P_i$, $p_j =$ ponderea voturilor pentru j , $\bar{P}_e = \sum_j p_j^2$, $\kappa = (\bar{P} - \bar{P}_e)/(1 - \bar{P}_e)$

Propoziția	neg	neu	pos
1	5	0	0
2	0	5	0
3	0	1	4
4	1	3	1
5	2	3	0
6	0	2	3

A6: κ al lui Fleiss și un pas Dawid–Skene (cerința 2/2) [Propus]

Rezolvarea se discută la seminar

Cerință

▣ Ce aveți de făcut

- ▶ (a) Calculați P_i pentru fiecare propoziție și $\bar{P}$
- ▶ (b) Calculați p_j , $\bar{P}_e$ și κ
- ▶ (c) Pasul E din [Dawid & Skene \(1979\)](#): presupuneți că fiecare evaluator dă clasa adevărată cu probabilitatea 0,8 și fiecare altă clasă cu probabilitatea 0,1, cu o distribuție a priori uniformă; calculați $P(\text{adevărat} = j \mid \text{voturi}) \propto \prod_i \pi_{ji}^{n_{ij}}$ pentru propozițiile 4 și 5
- ▶ (d) Comparați probabilitățile a posteriori cu ponderile voturilor și descrieți pasul M

▣ Ce raportați

- ▶ κ și cele două distribuții a posteriori; interpretare: ce propoziții ați scoate dintr-un set de test și de ce? Model: A1 (probabilitățile de clasificare greșită)

A7: costul de echilibru cu eroare standard [Rezolvat]

Cerință

□ Context și ipoteze

- ▶ Strategia din Cursul 15 pe cele 16 acțiuni FNSPID, 3568 de zile de tranzacționare: la închiderea din $d + 1$ luăm $\text{sign}(s_{i,d})$ în fiecare acțiune cu știri în ziua d , acoperită cu SPY, închidem după o zi; patru tranzacții în fiecare zi cu poziții
- ▶ Semnalul FinBERT: randamentul brut mediu pe toate zilele $\hat{\mu} = 3,27$ bp, t Newey–West = 1,27 Newey & West (1987) cu $L = 8$ decalaje ($L = \lfloor 4(n/100)^{2/9} \rfloor$), ponderea zilelor cu poziții $a = 0,962$, Sharpe brut $\sqrt{252} \hat{\mu} / \sigma = 0,36$

□ Ce aveți de făcut

- ▶ (a) Scrieți randamentul net zilnic mediu și raportul Sharpe net anualizat ca funcții de costul c pe tranzacție, presupunând că aceste costuri modifică foarte puțin volatilitatea σ
- ▶ (b) Deduceți costul de echilibru c^* la care randamentul net mediu este zero
- ▶ (c) Calculați $\text{SE}(\hat{\mu}) = \hat{\mu} / t$, apoi $\text{SE}(c^*)$ prin metoda delta și CI 95% $c^* \pm 1,96 \text{ SE}$
- ▶ (d) Obțineți σ din raportul Sharpe brut și calculați raportul Sharpe net la $c = 5$ bp

□ Ce raportați

- ▶ c^* , SE, CI și raportul Sharpe net; interpretare: este un cost realist de 5 bp pe tranzacție în interiorul CI pentru c^* ?

A7: Rezolvare [Rezolvat]

Rezolvare

- ▣ (a) Într-o fracțiune a din zile plătim $4c$, deci $\mu_{\text{net}} = \mu - 4ac$ și $SR_{\text{net}} = \sqrt{252}(\mu - 4ac)/\sigma$
- ▣ (b) $\mu - 4ac^* = 0$ dă $c^* = \mu/(4a) = 3,27/3,85 = 0,85$ bp pe tranzacție
- ▣ (c) $SE(\hat{\mu}) = 3,27/1,27 = 2,57$ bp; tratând a ca fix (calendarul pozițiilor este dat de calendarul știrilor), c^* este liniar în $\hat{\mu}$, deci $SE(c^*) = 2,57/3,85 = 0,67$ bp, iar CI este $[-0,46; 2,16]$ bp
- ▣ (d) $\sigma = \sqrt{252} \hat{\mu} / SR = \sqrt{252} \times 3,27 / 0,36 = 143$ bp; $SR_{\text{net}} = \sqrt{252}(3,27 - 3,85 \times 5) / 143 = -1,77$
- ▣ Interpretare: 5 bp este mult peste limita superioară a CI; cu rulaj zilnic, strategia nu poate supraviețui unor costuri realiste

A8: strategia Qwen după costuri [Propus]

Rezolvarea se discută la seminar

Cerință

▣ Context și ipoteze

- Strategia din Cursul 15 pe cele 16 acțiuni FNSPID, 3 568 de zile de tranzacționare: la închiderea din $d + 1$ luăm $\text{sign}(s_{i,d})$ în fiecare acțiune cu știri în ziua d , acoperită cu SPY, închidem după o zi; patru tranzacții în fiecare zi cu poziții
- Semnalul Qwen2.5-7B: $\hat{\mu} = 5,64$ bp, t Newey–West = 2,26 ($L = 8$), $a = 0,950$, Sharpe brut 0,63

▣ Ce aveți de făcut

- (b) Deduceți costul de echilibru c^* la care randamentul net mediu este zero
- (c) Calculați $\text{SE}(\hat{\mu}) = \hat{\mu}/t$, apoi $\text{SE}(c^*)$ prin metoda delta și CI 95% $c^* \pm 1,96 \text{ SE}$
- (d) Obțineți σ din raportul Sharpe brut și calculați raportul Sharpe net la $c = 5$ bp
- (e) Cursul 15 raportează un cost de echilibru de 1,5 bp și un Sharpe net de $-1,48$: decideți dacă este o greșeală de copiere

▣ Ce raportați

- c^* , SE, CI, Sharpe net; interpretare: face media brută semnificativă strategia tranzacționabilă? Model: A7

B1: este FinBERT mai bun decât LM? [Rezolvat]

Cerință

Context și ipoteze

- Date: Twitter Financial News, setul de validare cu $N = 2\,388$ de titluri publicate în 2022, fiecare etichetat negativ, neutru sau pozitiv de adnotatori; eticheta umană este considerată adevărul
- Clasificatorul A = dicționarul LM (eticheta = semnul tonului), clasificatorul B = FinBERT (eticheta = clasa cu probabilitatea cea mai mare); cod: b_pairs în notebook

Ce aveți de făcut

- (a) Calculați acuratețea fiecărui clasificator cu CI bootstrap percentil 95%: reeșantionați titlurile cu întoarcere de 2 000 de ori (sămânța 0) și luați cuantilele de 2,5% și 97,5%
- (b) Calculați diferența B – A cu CI bootstrap pe perechi: aceleași titluri reeșantionate pentru ambii clasificatori în fiecare dintre cele 2 000 de extrageri
- (c) Numărați n_{01} și n_{10} , aplicați testul McNemar exact și varianta asimptotică $(n_{01} - n_{10})^2 / (n_{01} + n_{10})$ față de χ^2_1 (valoarea critică 3,84) la $\alpha = 5\%$

Ce raportați

- Un tabel cu valorile acurateții, CI și diferența; n_{01} , n_{10} , valorile p și decizia
- Interpretare: de ce este testul pe perechi mai puternic decât compararea celor două intervale, ce titluri nu aduc informație și este diferența utilă pentru tranzacționare?

B1: Rezolvare (1/2) [Rezolvat]

	Acuratețe (%)	CI 95%
LM	60,5	[58,5; 62,4]
FinBERT	72,5	[70,7; 74,4]
Diferența (pp)	+12,0	[+9,8; +14,2]

Rezolvare

- Pasul 1: etichetele ambilor clasificatori pe cele 2388 de titluri; pasul 2: 2000 de reeșantionări bootstrap ale indicilor titlurilor; pasul 3: valorile acurateții și diferența dintre ele în fiecare reeșantionare
- (a)–(b) Intervalele celor doi clasificatori nu se suprapun, iar CI pe perechi al diferenței exclude 0

B1: Rezolvare (2/2) [Rezolvat]

Rezolvare

- (c) $n_{01} = 539$ (LM greșește, FinBERT are dreptate), $n_{10} = 252$; sub H_0 ne așteptăm la 395,5 fiecare; p binomial exact $< 0,001$
- Asimptotic: $(539 - 252)^2 / 791 = 104,1 > 3,84$; decizia: respingem acuratețea egală la 5%
- Împerecherea elimină variația dificultății titlurilor: titlurile pe care ambii le clasifică corect sau ambii greșit se anulează și nu aduc informație
- Interpretare: FinBERT este clar mai bun decât dicționarul în afara propriilor date de antrenare; un câștig de 12 puncte în acuratețea etichetării nu spune încă nimic despre randamente (B5)

B2: este un LLM de 7 miliarde de parametri mai bun decât FinBERT? [Propus]

Rezolvarea se discută la seminar

Cerință

▣ Context și ipoteze

- Date: Twitter Financial News, setul de validare cu $N = 2388$ de titluri publicate în 2022, fiecare etichetat negativ, neutru sau pozitiv de adnotatori; eticheta umană este considerată adevărul
- Clasificatorul A = FinBERT, clasificatorul B = Qwen2.5-7B zero-shot cu promptul P1; niciunul nu a folosit etichete Twitter

▣ Ce aveți de făcut

- (a) Calculați acuratețea fiecărui clasificator cu CI bootstrap percentil 95%: reeșantionați titlurile cu întoarcere de 2000 de ori (sămânța 0) și luați cuantilele de 2,5% și 97,5%
- (b) Calculați diferența B – A cu CI bootstrap pe perechi: aceleași titluri reeșantionate pentru ambii clasificatori în fiecare dintre cele 2000 de extrageri
- (c) Numărați n_{01} și n_{10} , aplicați testul McNemar exact și varianta asimptotică $(n_{01} - n_{10})^2 / (n_{01} + n_{10})$ față de χ^2_1 (valoarea critică 3,84) la $\alpha = 5\%$

▣ Ce raportați

- Același tabel și aceleași teste ca în B1; interpretare: se suprapun intervalele, tranșează asta întrebarea și ce ați câștiga totuși de la un model mult mai mare și mai lent? Model: B1

B3: scurgerea datelor de antrenare [Rezolvat]

Cerință

▣ Context și ipoteze

- ▶ Financial PhraseBank [Malo et al. \(2014\)](#): 4 846 de propoziții din știri (2 264 cu acord deplin al adnotatorilor); FinBERT a fost ajustat fin pe o parte de antrenare a acestor propoziții (3 101 din 4 845 în [Araci \(2019\)](#))
- ▶ Setul de validare Twitter, 2 388 de titluri, nevăzute de FinBERT; patru clasificatori: FinBERT, Qwen2.5-7B zero-shot, LM, vectori MiniLM + regresie logistică antrenată pe setul de antrenare Twitter [Wang et al. \(2020\)](#)

▣ Ce aveți de făcut

- ▶ (a) Calculați acuratețea (cu CI bootstrap din 2 000 de extrageri) și F1 macro pentru fiecare clasificator pe PhraseBank cu acord deplin, pe tot PhraseBank și pe Twitter
- ▶ (b) Calculați scăderea de la tot PhraseBank la Twitter pentru fiecare clasificator
- ▶ (c) Calculați diferența diferențelor FinBERT minus Qwen2.5-7B și CI bootstrap, reeșantionând fiecare set de date independent de 2 000 de ori

▣ Ce raportați

- ▶ Un tabel cu acurateți, scăderi și F1 macro; diferența diferențelor cu CI
- ▶ Interpretare: cum separați „date mai grele” de „memoria setului de antrenare” și de ce MiniLM se mișcă în sens invers?

B3: Rezolvare [Rezolvat]

Acuratețe (%)	PhraseBank, acord 100%	PhraseBank, tot	Twitter	Scădere (pp)	F1 macro, Twitter
FinBERT	97,2	89,0	72,5	16,4	66,8
Qwen2.5-7B	93,6	81,4	74,2	7,2	72,6
LM	65,0	62,5	60,5	2,0	46,2
MiniLM + reg. log.	81,4	70,6	78,6	-8,0	69,9

Rezolvare

- (b) Scăderea = tot PhraseBank minus Twitter; CI FinBERT pe PhraseBank [88,1; 89,8], pe Twitter [70,7; 74,4]
- (c) $(89,0 - 72,5) - (81,4 - 74,2) = 16,4 - 7,2 = 9,2$ pp, CI bootstrap [6,7; 11,9]: exclude 0
- Interpretare: Qwen2.5-7B nu a fost ajustat fin pe etichetele PhraseBank, deci scăderea lui este reperul pentru datele mai grele; dacă ambele modele ar pierde la fel fără suprapunere (o ipoteză netestată), cele 9,2 puncte în plus ale FinBERT provin din suprapunere; CI acoperă doar zgomotul de eșantionare; MiniLM este antrenat pe Twitter, deci este mai bun acasă

B4: de câte etichete aveți nevoie? [Propus]

Rezolvarea se discută la seminar

Cerință

Context și ipoteze

- ▶ Twitter Financial News: set de antrenare cu 9 543 de titluri etichetate, set de validare cu 2 388; reperul FinBERT, cu 72,5% acuratețe, nu folosește nicio etichetă Twitter
- ▶ Două modele supervizate: regresie logistică ($C = 4$) pe vectorii MiniLM cu 384 de dimensiuni și regresie logistică ($C = 8$) pe trăsături TF-IDF ale cuvintelor și perechilor de cuvinte

Ce aveți de făcut

- ▶ (a) Pentru $n \in \{100, 200, 400, \dots, 6\,400, 9\,543\}$ extrageți 10 subseturi aleatoare de antrenare de mărime n (unul pentru setul complet), estimați ambele modele și calculați acuratețea medie pe validare
- ▶ (b) Găsiți cel mai mic n la care fiecare model îl depășește în medie pe FinBERT
- ▶ (c) Raportați abaterea standard a acurateții clasificatorului bazat pe vectori pe cele 10 repetiții la $n = 100$

Ce raportați

- ▶ Tabelul curbei de învățare; interpretare: de ce vectorii pornesc mai sus, dar cresc mai încet, și câte texte ați eticheta pentru știri despre acțiuni românești? Model: B3

B5: reacție sau predicție și ce erori standard? [Rezolvat]

Cerință

▣ Context și ipoteze

- ▶ Panel de 18 282 de zile-acțiune cu știri pentru 16 acțiuni FNSPID, 3 434 de zile de tranzacționare, 27.10.2009–18.12.2023; scorul zilnic = media scorurilor titlurilor, standardizată pe panel (z)
- ▶ Randamente: închideri zilnice ajustate ale acțiunilor și ale SPY din data/market; randamentul în exces r^e = acțiunea minus SPY, în %; ziua d = prima zi de tranzacționare de la data titlului încolo, deci $d + 2$ este primul randament sigur de după publicare


▣ Ce aveți de făcut

- ▶ (a) Estimați prin OLS $r_{i,d+h}^e = a + b z_{i,d} + \varepsilon$ pentru FinBERT, Qwen2.5-7B și LM și $h = 0, 1, 2$ (nouă regresii); raportați b în bp pentru o abatere standard a scorului
- ▶ (b) Calculați trei erori standard: OLS, grupată pe zile ($G = 3\,434$) și grupată pe acțiuni ($G = 16$), cu estimatorul sandwich și factorul de eșantion mic $\frac{G}{G-1} \frac{n-1}{n-2}$ [Petersen \(2009\)](#)
- ▶ (c) Calculați statisticile t și comparați-le cu 1,96 și cu valoarea critică $t_{15, 2,13}$, pentru gruparea pe acțiuni

▣ Ce raportați

- ▶ Un grafic al pantelor pentru $h = 0$ cu cele trei intervale și un tabel cu toate cele nouă regresii
- ▶ Interpretare: de ce diferă $h = 0$ și $h = 2$, ce grupare contează și puteți avea încredere într-o SE grupată cu 16 grupuri?

B5: Rezolvare (1/3) [Rezolvat]



Rezolvare

- Panta din aceeași zi b (bp pentru o abatere standard a scorului) cu intervale de 95% din cele trei erori standard: intervalul grupat pe acțiuni este mult mai larg

B5: Rezolvare (2/3) [Rezolvat]

Scor	h	b (bp)	SE OLS	SE zi	SE acțiune	t zi	t acțiune
FinBERT	0	+39,2	2,3	2,3	6,9	+17,27	+5,71
FinBERT	2	-0,5	2,2	2,2	1,5	-0,25	-0,35
Qwen2.5-7B	0	+41,4	2,3	2,2	8,1	+19,07	+5,10
Qwen2.5-7B	2	+2,3	2,2	1,9	1,0	+1,19	+2,41
LM	0	+15,5	2,3	1,8	3,3	+8,53	+4,70
LM	2	-0,0	2,2	1,7	0,9	-0,01	-0,03

Rezolvare

- $h = 0$: mare cu orice eroare standard (t pe acțiuni peste 4,7): titlurile descriu mișcarea zilei, adesea chiar mișcarea („shares jump”)
- $h = 2$: FinBERT -0,5 bp ($t = -0,25$ pe zile): prognoza tranzacționabilă lipsește

B5: Rezolvare (3/3) [Rezolvat]

Rezolvare

- Gruparea pe zile este apropiată de OLS: cu doar 5,3 acțiuni pe zi, există puțin zgomot comun de absorbit
- Gruparea pe acțiuni înmulțește SE FinBERT la $h = 0$ cu 3,0: panta diferă între acțiuni, iar erorile fiecărei acțiuni sunt corelate în timp
- Cu 16 grupuri SE grupată este ea însăși zgomotoasă: Qwen la $h = 2$ are $t = +2,41$ pe acțiuni, $p = 0,029$ cu t_{15} , dar 0,061 prin wild cluster bootstrap [Cameron, Gelbach & Miller \(2008\)](#) și 0,37 după Holm pe cele nouă regresii (B10)
- Interpretare: sentimentul explică ziua știrii, nu zilele tranzacționabile; cu 16 acțiuni, inferența trebuie să folosească metode pentru puține grupuri

B6: studiu de eveniment cu tonul Loughran–McDonald (cerința 1/2) [Propus]

Rezolvarea se discută la seminar

Cerință

▣ Context și ipoteze

- ▶ Panel de 18 282 de zile-acțiune cu știri pentru 16 acțiuni FNSPID, 3 434 de zile de tranzacționare, 27.10.2009–18.12.2023; scorul zilnic = media scorurilor titlurilor, standardizată pe panel (z)
- ▶ Randamente: închideri zilnice ajustate ale acțiunilor și ale SPY din data/market; randamentul în exces r^e = acțiunea minus SPY, în %; ziua d = prima zi de tranzacționare de la data titlului încolo, deci $d + 2$ este primul randament sigur de după publicare

B6: studiu de eveniment cu tonul Loughran–McDonald (cerința 2/2) [Propus]

Rezolvarea se discută la seminar

Cerință

▣ Ce aveți de făcut

- ▶ (a) Tonul zilnic LM este exact 0 în 48% dintre zilele-acțiune, deci ambele praguri ale terțilelor sunt 0: formați grupurile disjuncte $\text{ton} < 0$ (5 196 de zile-acțiune) și $\text{ton} > 0$ (4 288), fără zerouri
- ▶ (b) Pentru fiecare dată, mediați pe zilele-acțiune ale acelei date randamentele în exces din zilele $-5, \dots, +5$ din jurul zilei știrii
- ▶ (c) Calculați media pe date a CAR (randamentul anormal cumulat) pentru $[-5, -1]$, ziua 0, ziua 1 și $[+2, +5]$, cu t Newey–West (decalaje $\lfloor 4(n/100)^{2/9} \rfloor$)
- ▶ (d) Repetați (b)–(c) pentru terțila de jos și cea de sus a scorului FinBERT (acolo nu există valori egale)

▣ Ce raportați

- ▶ Un tabel cu cele patru ferestre pentru ambele scoruri și ambele grupuri; interpretare: separă LM câștigătorii de perdanți în ziua 0 la fel de bine ca FinBERT și de ce este randamentul de după eveniment pozitiv pentru ambele grupuri [Tetlock \(2007\)](#)? Model: B5

B7: își amintește modelul piața? [Rezolvat]

Cerință

Context și ipoteze

- ▶ Închideri lunare S&P 500 din data/market (GSPC.INDX), ianuarie 2000 – august 2026; o lună este „în creștere” dacă randamentul ei este pozitiv
- ▶ Qwen2.5 1.5B, 7B și 14B, ponderi publicate pe 19 septembrie 2024 [Qwen Team \(2024\)](#), întrebate fără context „Did the S&P 500 index rise or fall during ⟨lună an⟩?”; scorul $P(\text{rise})$
- ▶ Înainte: 296 de luni până în august 2024 (185 în creștere); după: 23 de luni din octombrie 2024 (13 în creștere)

Ce aveți de făcut


- ▶ (a) Calculați $AUC = U/(n_{\text{up}}n_{\text{down}})$ (U Mann–Whitney) pentru fiecare model și perioadă, cu CI bootstrap din 2000 de extrageri pe luni
- ▶ (b) Aplicați un test prin permutare pentru 14B înainte de publicare: amestecați etichetele creștere/scădere de 2000 de ori; p = ponderea AUC-urilor amestecate cel puțin la fel de mari ca cel observat
- ▶ (c) Testați $AUC_{\text{înainte}} = AUC_{\text{după}}$ cu varianțele DeLong [DeLong et al. \(1988\)](#) (eșantioane independente) la 5% și calculați cea mai mică scădere detectabilă cu puterea 80%

Ce raportați

- ▶ Un tabel cu AUC și CI și un grafic; p prin permutare, z și p DeLong, scăderea detectabilă
- ▶ Interpretare: ce înseamnă un AUC peste 0,5 când modelul nu vede date și ce implică pentru testele retroactive pe știri vechi [Glasserman & Lin \(2023\)](#)?

B7: Rezolvare (1/2) [Rezolvat]

Qwen2.5	AUC înainte	CI 95%	AUC după	CI 95%	$\bar{P}(\text{rise})$ creștere / scădere
1.5B	0,57	[0,51; 0,64]	0,72	[0,49; 0,91]	0,36 / 0,30
7B	0,67	[0,61; 0,73]	0,53	[0,28; 0,78]	0,73 / 0,43
14B	0,69	[0,62; 0,75]	0,59	[0,35; 0,84]	0,81 / 0,54



Rezolvare

- (a) 7B și 14B ordonează lunile de creștere peste cele de scădere mult peste nivelul întâmplător înainte de publicare; modelul 1.5B abia

B7: Rezolvare (2/2) [Rezolvat]

Rezolvare

- (b) p prin permutare pentru 14B înainte de publicare $< 0,001$ (2 000 de amestecări): respingem „nicio cunoaștere” la 5%
- (c) DeLong: SE înainte 0,032, după 0,126; $z = 0,73$, $p = 0,47$: nu respingem egalitatea
- Sub H_0 , SE după publicare este 0,124, deci cea mai mică scădere detectabilă cu puterea 80% este $2,80 \times \sqrt{SE_{\text{înainte}}^2 + SE_0^2} = 0,36$; ar fi nevoie de circa 101 luni după publicare
- Interpretare: nu s-au dat date, deci discriminarea provine cel mai plauzibil din textul de antrenare (rezultatele sau regimurile din jurul lor; lunile sunt tratate ca schimbabile în bootstrap și în permutare); eșantionul de după publicare este mult prea scurt pentru a arăta că memoria a dispărut, iar un test retroactiv pe știri anterioare publicării amestecă prognoza cu amintirea

B8: sensibilitatea la prompt [Propus]

Rezolvarea se discută la seminar

Cerință

▣ Context și ipoteze

- ▶ Date: Twitter Financial News, setul de validare cu $N = 2\,388$ de titluri publicate în 2022, fiecare etichetat negativ, neutru sau pozitiv de adnotatori; eticheta umană este considerată adevărul
- ▶ Qwen2.5-7B și 14B cu trei prompturi care pun aceeași întrebare: P1 „classify the sentiment ... for investors”, P2 „good, bad or neutral for the stock price”, P3 „what is the sentiment of this text”

▣ Ce aveți de făcut

- ▶ (a) Calculați acuratețea cu CI bootstrap din 2 000 de extrageri și ponderea răspunsurilor „neutral” pentru fiecare prompt și model
- ▶ (b) Aplicați testul McNemar exact pentru P1 față de P3, pentru fiecare model, la 5%
- ▶ (c) Calculați ponderea titlurilor care primesc aceeași etichetă sub toate cele trei prompturi

▣ Ce raportați

- ▶ Un tabel cu cele trei prompturi și testul; interpretare: dacă ați alege cel mai bun prompt pe acest set, ce ați face de fapt și de ce cel mai bun prompt răspunde și cel mai des „neutral”? Model: B1

B9: prediction-powered inference cu puține etichete umane [Rezolvat]

Cerință

□ Context și ipoteze

- Date: Twitter Financial News, setul de validare cu $N = 2\,388$ de titluri publicate în 2022, fiecare etichetat negativ, neutru sau pozitiv de adnotatori; eticheta umană este considerată adevărul
- Ținta θ = tonul net uman mediu $(-1, 0, 1)$ al populației de titluri, reprezentată de cele 2 388 de titluri; scorul modelului f = scorul net $P(\text{pos}) - P(\text{neg})$ al FinBERT sau al Qwen2.5-7B
- Schema de eșantionare: pentru n titluri extrase aleator observăm eticheta umană Y ; pentru celelalte $N - n$ folosim doar f ; f este fix (neantrenat pe aceste titluri), deci cele două mulțimi sunt eșantioane independente

□ Ce aveți de făcut

- (a) Pentru o extragere cu $n = 200$, calculați estimarea doar din etichete $\bar{Y}_n \pm 1,96 s_Y / \sqrt{n}$
- (b) Calculați PPI [Angelopoulos et al. \(2023\)](#): $\hat{\theta} = \frac{1}{N-n} \sum_{\text{neetch.}} f - \frac{1}{n} \sum_{\text{etich.}} (f - Y)$ cu SE
 $= \sqrt{\hat{V}(f)/(N-n) + \hat{V}(f - Y)/n}$, pentru ambele modele
- (c) Pentru $n = 100, 200, 400, 800$, extrageți de 2 000 de ori n titluri etichetate și $N - n$ neetichetate, independent, cu întoarcere (cele 2 388 au rolul populației), și înregistrați acoperirea lui θ și lățimea medie a fiecărui CI 95%

□ Ce raportați


- Estimările dintr-o extragere, un tabel sau grafic cu acoperirea și lățimea; interpretare: de ce media simplă a modelului $\frac{1}{N} \sum f$ nu estimează θ , când este PPI mai îngust și cum l-ați folosi pentru regresiiile FNSPID?

B9: Rezolvare (1/2) [Rezolvat]

Rezolvare

- ▣ θ adevărat = 0,054; mediile simple ale modelelor: FinBERT -0,014 (semn greșit), Qwen +0,101: distorsiunea modelului nu scade când N crește
- ▣ (a) O extragere, $n = 200$: doar etichete $0,010 \pm 1,96 \times 0,042$
- ▣ (b) PPI-FinBERT: corecția $\frac{1}{n} \sum (f - Y) = -0,064$, deci $\hat{\theta} = 0,054 \pm 1,96 \times 0,036$; PPI-Qwen: corecția -0,012, $\hat{\theta} = 0,123 \pm 1,96 \times 0,039$
- ▣ Corecția elimină distorsiunea în medie, dar într-o singură extragere poate îndepărta o estimare de θ (aici Qwen); toate cele trei intervale conțin valoarea adevărată în această extragere

B9: Rezolvare (2/2) [Rezolvat]



Rezolvare

- (c) $n = 100$: acoperirea 94,7%, 94,3%, 95,4%, lățimea 0,229, 0,204, 0,203 (etichete, PPI-FinBERT, PPI-Qwen)
- PPI este mai îngust când $\text{Var}(f)/(N - n) + \text{Var}(f - Y)/n < \text{Var}(Y)/n$; pentru N mare câștigul este $1 - \text{Var}(f - Y)/\text{Var}(Y)$: 24% (FinBERT), 27% (Qwen); la $n = 800$ doar $N - n = 1\,588$ de texte sunt neetichetate și PPI este mai larg (0,087 față de 0,081); acoperirea rămâne aproape de 95%
- Interpretare: pentru FNSPID, etichetați toate titlurile unui eșantion aleator de zile-acțiune și corectați fiecare condiție de moment OLS care conține scorul (C1, punctul (e))

B10: wild cluster bootstrap cu 16 acțiuni [Propus]

Rezolvarea se discută la seminar

Cerință

Context și ipoteze

- ▶ Panel de 18 282 de zile-acțiune cu știri pentru 16 acțiuni FNSPID, 3 434 de zile de tranzacționare, 27.10.2009–18.12.2023; scorul zilnic = media scorurilor titlurilor, standardizată pe panel (z)
- ▶ Cele nouă regresii din B5 (trei scoruri $\times h = 0, 1, 2$), cu erori standard grupate pe acțiuni ($G = 16$); gruparea pe o dimensiune presupune acțiuni independente

Ce aveți de făcut

- ▶ (a) Calculați valoarea p a fiecărei pante cu valori critice t_{15}
- ▶ (b) Aplicați wild cluster bootstrap cu ipoteza nulă impusă [Cameron, Gelbach & Miller \(2008\)](#): $y_i^* = \bar{y} + w_{g(i)}\tilde{\varepsilon}_i$, cu reziduurile restricționate $\tilde{\varepsilon}_i = y_i - \bar{y}$, ponderi Rademacher $w_g = \pm 1$, 9 999 de extrageri; $p = P^*(|t^*| \geq |t|)$
- ▶ (c) Calculați t cu grupare pe două dimensiuni, zile și acțiuni, $\hat{V} = \hat{V}_{\text{zi}} + \hat{V}_{\text{acțiune}} - \hat{V}_{\text{zi} \cap \text{acțiune}}$
- ▶ (d) Ajustați cele nouă valori p bootstrap cu procedura descendentă Holm la 5%

Ce raportați

- ▶ Un tabel cu t , cele trei valori p și t pe două dimensiuni; interpretare: de ce este $N(0, 1)$ o referință slabă pentru un t construit din 16 grupuri și supraviețuiește Qwen la $h = 2$? Model: B5

B11: curba specificațiilor pentru strategia de sentiment [Propus]

Rezolvarea se discută la seminar

Cerință

▣ Context și ipoteze

- ▶ Strategia din Cursul 15 pe cele 16 acțiuni FNSPID, 3 568 de zile de tranzacționare: la închiderea din $d + 1$ luăm $\text{sign}(s_{i,d})$ în fiecare acțiune cu știri în ziua d , acoperită cu SPY, închidem după o zi; patru tranzacții în fiecare zi cu poziții
- ▶ Grila din Cursul 15: trei scoruri (LM, FinBERT, Qwen) $\times$ praguri $|s| > b$, $b \in \{0; 0,25; 0,5\}$, $\times$ ziua câștigului $d + 2, \dots, d + 5$ (fiecare o poziție de o zi deschisă la închiderea precedentă): 36 de strategii

▣ Ce aveți de făcut

- ▶ (a) Calculați randamentul zilnic mediu și t Newey–West pentru fiecare dintre cele 36 de strategii și reprezentați statisticile t sortate [Simonsohn, Simmons & Nelson \(2020\)](#)
- ▶ (b) Simulați ipoteza nulă comună de absență a predictibilității: schimbați aleator semnul pozițiilor în blocuri de 10 zile de semnal consecutive (bootstrap sălbatic dependent [Shao \(2010\)](#)), aceleași schimbări pentru toate cele 36 de strategii, de 2 000 de ori
- ▶ (c) Calculați valorile p comune pentru numărul de $t > 1,96$ și pentru t median

▣ Ce raportați

- ▶ Curba sortată și cele două valori p comune; interpretare: de ce trebuie ca schimbarea semnului să fie comună tuturor specificațiilor și ce ar ascunde raportarea „cele mai bune specificații”? Model: B7 (un test prin randomizare)

C1: aduce sentimentul titlurilor câștig după costuri? (cerința 1/2) [Propus]

Rezolvarea se discută la seminar

Cerință

▣ Context și ipoteze

- ▶ Strategia din Cursul 15 pe cele 16 acțiuni FNSPID, 3 568 de zile de tranzacționare: la închiderea din $d + 1$ luăm $\text{sign}(s_{i,d})$ în fiecare acțiune cu știri în ziua d , acoperită cu SPY, închidem după o zi; patru tranzacții în fiecare zi cu poziții
- ▶ Pozițiile sunt acoperite cu SPY și ponderate egal; zilele fără știri: nicio poziție și randament 0; costuri de 5 bp pe tranzacție, patru tranzacții în fiecare zi cu poziții
- ▶ Scoruri: FinBERT, Qwen2.5-7B și LM, din tabelele salvate ale Cursului 15; randamente din data/market

C1: aduce sentimentul titlurilor câștig după costuri? (cerința 2/2) [Propus]

Rezolvarea se discută la seminar

Cerință

▣ Ce aveți de făcut

- ▶ (a) Calculați randamentul brut zilnic mediu, t Newey–West și un CI bootstrap pe blocuri mobile de 95% (blocuri de 10 zile, 2000 de extrageri) pentru semnalul FinBERT
- ▶ (b) Calculați raportul Sharpe anualizat înainte și după costuri, costul de echilibru și raportul Sharpe pentru costuri de 0, 1, 2, 5 și 10 bp
- ▶ (c) Restrângeți la știrile puternice, $|s_{i,d}| > 0,5$ (analiză exploratorie), și (d) repetați totul pentru Qwen2.5-7B și LM; familia principală, fixată dinainte, este formată din cele trei strategii nefiltrate (Holm pe ele); dacă alegeți dintre toate cele șase variante, ajustați pe toate șase
- ▶ (e) Corectați panta din aceeași zi: etichetați toate titlurile unui eșantion aleator de zile-acțiune (tonul zilnic adevărat s^*); fie împărțiți b la $\rho(s^*, \hat{s})$ estimat acolo (corecția din curs pentru un scor standardizat; A1 se aplică doar unei variabile binare), fie corectați ambele momente OLS $E[(1, s^*)^\top (r - a - \beta s^*)] = 0$ cu scorul (B9, curs); bootstrap pe zile
- ▶ (f) Raportați separat titlurile de după publicarea Qwen2.5, când vor fi disponibile

▣ Ce raportați

- ▶ O notă de două pagini cu un tabel de rezultate și grafice și un folder Quantlet (cod, Metainfo, grafice); discutați alinierea în timp, informația din viitor a LLM-ului (B7), supraviețuirea celor 16 acțiuni și aglomerarea [Lopez-Lira & Tang \(2026\)](#)

C2: critica unui răspuns AI (1/3) [Propus]

Rezolvarea se discută la seminar

- **Cererea studentului:** „Am titlurile FNSPID pentru 16 acțiuni americane, 2009–2023, și randamentele zilnice în exces față de SPY. Verifică dacă Qwen2.5-7B citește sentimentul, apoi testează dacă sentimentul titlurilor prognozează randamentele în afara eșantionului.”
- **Răspunsul asistentului AI** (qwen_label, qwen_score: evaluatorul zero-shot din Cursul 15)

```
import pandas as pd, statsmodels.formula.api as smf
from sklearn.metrics import accuracy_score
tw['pred'] = [qwen_label(t) for t in tw['text']] # Twitter validation set
acc = accuracy_score(tw['label'], tw['pred'])
news['day'] = first_trading_day_on_or_after(news['date'])
news['s'] = [qwen_score(t) for t in news['title']] # P(pos) - P(neg)
d = news.groupby(['ticker', 'day'])['s'].mean().reset_index()
d['z'] = (d['s'] - d['s'].mean()) / d['s'].std()
d = d.merge(rets, on=['ticker', 'day']) # rets: ticker, day, xret (%)
fit = smf.ols('xret ~ z', data=d).fit(cov_type='cluster',
                                     cov_kwds={'groups': pd.factorize(d['day'])[0]})
```

C2: critica unui răspuns AI (2/3) [Propus]

Rezolvarea se discută la seminar

□ Concluzia asistentului AI

- ▶ „Acuratețe 74,2%, de peste două ori cei 33% ai unei ghiciri la întâmplare între trei clase: Qwen2.5-7B citește foarte bine sentimentul financiar.”
 - ▶ „Panta +41,4 bp pentru o abatere standard a scorului, $t = +19,07$ (grupat pe zile): titlurile zilei prognozează randamentul în exces al acțiunii.”
 - ▶ „Qwen2.5 nu a fost antrenat pe aceste etichete sau serii de randamente, deci testul retroactiv 2009–2023 este complet în afara eșantionului.”
- Răspunsul conține **trei** erori tipice pentru testarea retroactivă a sentimentului; codul rulează, iar cifrele sunt corecte
- ▶ (a) Găsiți fiecare eroare: numiți rândul de cod sau propoziția și explicați de ce este greșită
 - ▶ (b) Spuneți cum ați detecta-o fără să știți răspunsul: numărul de observații din fiecare clasă, o verificare a orelor, o dată de publicare, un test de memorie
 - ▶ (c) Scrieți codul corectat sau afirmația corectată, cu cifrele pe care le produce
 - ▶ (d) Notați fiecare eroare ca în [AI_ERRORS.md](#): ce a răspuns AI-ul, ce era greșit, cum v-ați dat seama, varianta corectă

Greșeli frecvente

- ▣ Raportarea acurateței fără reperul clasei majoritare și fără F1 macro
- ▣ Evaluarea unui model pe propriile date de antrenare (FinBERT pe PhraseBank)
- ▣ Compararea a doi clasificatori prin intervale separate în loc de un test pe perechi
- ▣ Potrivirea unui titlu fără oră cu randamentul din aceeași zi și numirea lui prognoză
- ▣ Testarea retroactivă a unui LLM pe știri mai vechi decât publicarea ponderilor lui
- ▣ Alegerea promptului, a pragului sau a modelului după vederea rezultatelor de test
- ▣ Ignorarea costurilor și a numărului de grupuri: patru tranzacții pe zi, doar 16 acțiuni
- ▣ Tratarea scorului unui model ca date: pantele sunt atenuate, iar două scoruri de model pot avea erori comune

Temă pentru acasă (proiect de echipă)

- ▣ Alegeți o sursă de texte nediscutată la seminar: anunțurile BVB (Bursa de Valori București), știri financiare românești, comunicatele băncilor centrale sau postări despre cripto-active
- ▣ Etichetați voi cel puțin 200 de texte (doi adnotatori, raportați acordul), după sentimentul față de activul menționat; ajustați pe o parte și evaluați doar pe o parte separată (sau out-of-fold)
- ▣ Comparați LM, FinBERT, un LLM deschis și vectori + regresie logistică: acuratețe și F1 macro cu CI, teste McNemar; pentru textele în română spuneți cum aplicați LM și FinBERT, care sunt pentru engleză (traducere sau un model multilingv)
- ▣ Construiți un semnal cu aliniere corectă în timp; raportați separat perioada de după publicarea LLM-ului
- ▣ Declarați folosirea AI în [AI_USE.md](#) și notați fiecare eroare AI prinsă în [AI_ERRORS.md](#) (cel puțin trei pe proiect, ca în C2)
- ▣ Livrați un folder Quantlet (cod, Metainfo, grafice) și trei slide-uri: cifre, interpretare, limite

Studiu suplimentar pe Quantinar

Cursuri avansate pe quantinar.com

- ☐  Natural Language Processing
- ☐  The Next Word Problem
- ☐  DELTA
- ☐  LDA Extensions

Cod și date

- ☐ Notebook-ul seminarului (Colab); Quantlets: github.com/danpele/MFM/tree/main/Quantlets/Ch_15

Bibliografie (1/2)

- ▣ Aigner, D.J. (1973). [Regression with a binary independent variable subject to errors of observation](#). *Journal of Econometrics*, 1(1), 49–59.
- ▣ Angelopoulos, A.N., Bates, S., Fannjiang, C., Jordan, M.I., Zrnic, T. (2023). [Prediction-powered inference](#). *Science*, 382(6671), 669–674.
- ▣ Araci, D. (2019). [FinBERT: financial sentiment analysis with pre-trained language models](#). arXiv:1908.10063.
- ▣ Cameron, A.C., Gelbach, J.B., Miller, D.L. (2008). [Bootstrap-based improvements for inference with clustered errors](#). *Review of Economics and Statistics*, 90(3), 414–427.
- ▣ Dawid, A.P., Skene, A.M. (1979). [Maximum likelihood estimation of observer error-rates using the EM algorithm](#). *Applied Statistics*, 28(1), 20–28.
- ▣ DeLong, E.R., DeLong, D.M., Clarke-Pearson, D.L. (1988). [Comparing the areas under two or more correlated receiver operating characteristic curves: a nonparametric approach](#). *Biometrics*, 44(3), 837–845.
- ▣ Dong, Z., Fan, X., Peng, Z. (2024). [FNSPID: a comprehensive financial news dataset in time series](#). *Proceedings of the 30th ACM SIGKDD Conference*, 4918–4927.
- ▣ Fleiss, J.L. (1971). [Measuring nominal scale agreement among many raters](#). *Psychological Bulletin*, 76(5), 378–382.
- ▣ Franke, J., Härdle, W.K., Hafner, C.M. (2019). [Statistics of Financial Markets: An Introduction](#), 5th ed. Springer.
- ▣ Glasserman, P., Lin, C. (2023). [Assessing look-ahead bias in stock return predictions generated by GPT sentiment analysis](#). arXiv:2309.17322.
- ▣ Guo, C., Pleiss, G., Sun, Y., Weinberger, K.Q. (2017). [On calibration of modern neural networks](#). *ICML*; arXiv:1706.04599.

Bibliografie (2/2)

- ▣ Lopez-Lira, A., Tang, Y. (2026). [Can ChatGPT forecast stock price movements? Return predictability and large language models.](#) *Journal of Financial Economics*, 184, 104335.
- ▣ Loughran, T., McDonald, B. (2011). [When is a liability not a liability? Textual analysis, dictionaries, and 10-Ks.](#) *Journal of Finance*, 66(1), 35–65.
- ▣ Malo, P., Sinha, A., Korhonen, P., Wallenius, J., Takala, P. (2014). [Good debt or bad debt: detecting semantic orientations in economic texts.](#) *Journal of the Association for Information Science and Technology*, 65(4), 782–796.
- ▣ McNemar, Q. (1947). [Note on the sampling error of the difference between correlated proportions or percentages.](#) *Psychometrika*, 12(2), 153–157.
- ▣ Newey, W.K., West, K.D. (1987). [A simple, positive semi-definite, heteroskedasticity and autocorrelation consistent covariance matrix.](#) *Econometrica*, 55(3), 703–708.
- ▣ Petersen, M.A. (2009). [Estimating standard errors in finance panel data sets: comparing approaches.](#) *Review of Financial Studies*, 22(1), 435–480.
- ▣ Qwen Team (2024). [Qwen2.5 technical report.](#) arXiv:2412.15115.
- ▣ Sarkar, S.K., Vafa, K. (2024). [Lookahead bias in pretrained language models.](#) SSRN Working Paper 4754678.
- ▣ Shao, X. (2010). [The dependent wild bootstrap.](#) *Journal of the American Statistical Association*, 105(489), 218–235.
- ▣ Simonsohn, U., Simmons, J.P., Nelson, L.D. (2020). [Specification curve analysis.](#) *Nature Human Behaviour*, 4(11), 1208–1214.
- ▣ Tetlock, P.C. (2007). [Giving content to investor sentiment: the role of media in the stock market.](#) *Journal of Finance*, 62(3), 1139–1168.
- ▣ Wang, W., Wei, F., Dong, L., Bao, H., Yang, N., Zhou, M. (2020). [MiniLM: deep self-attention distillation for task-agnostic compression of pre-trained Transformers.](#) *NeurIPS*; arXiv:2002.10957.