



## Modelarea piețelor financiare

Seminarul 15: LLM-uri și analiza sentimentului — aplicații



Daniel Traian PELE

Drd. Antoaneta Amza, [antoaneta.amza@csie.ase.ro](mailto:antoaneta.amza@csie.ase.ro)

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognostic Economică

MSCA Digital Finance

## Acronime folosite în acest material

- ▣ **AI:** Artificial Intelligence — *inteligență artificială*
- ▣ **AUC:** Area Under the (ROC) Curve — *aria de sub curba ROC*
- ▣ **BERT:** Bidirectional Encoder Representations from Transformers — *reprezentări bidirecționale produse de codificatorul unui Transformer*
- ▣ **BVB:** Bursa de Valori București
- ▣ **CAR:** Cumulative Abnormal Return — *randamentul anormal cumulat*
- ▣ **CI:** Confidence Interval — *interval de încredere*
- ▣ **ECE:** Expected Calibration Error — *eroarea medie de calibrare*
- ▣ **FNSPID:** Financial News and Stock Price Integration Dataset — *setul de date care integrează știri financiare și prețuri de acțiuni*
- ▣ **GPT-4:** Generative Pre-trained Transformer 4 — *Transformer generativ pre-antrenat, versiunea 4*
- ▣ **LLM:** Large Language Model — *model lingvistic mare*
- ▣ **LM:** Loughran-McDonald (financial sentiment dictionary) — *dicționarul financiar de sentiment Loughran-McDonald*
- ▣ **NLL:** Negative Log-Likelihood — *logaritmul negativ al verosimilității*
- ▣ **OLS:** Ordinary Least Squares — *metoda celor mai mici pătrate*
- ▣ **PPI:** Prediction-Powered Inference — *inferență susținută de predicții*
- ▣ **ROC:** Receiver Operating Characteristic (curve) — *curba caracteristică de operare a receptorului*
- ▣ **SE:** Standard Error — *eroare standard*
- ▣ **TF-IDF:** Term Frequency - Inverse Document Frequency — *frecvența termenului înmulțită cu inversul frecvenței în documente*
- ▣ **UTC:** Coordinated Universal Time (Temps Universel Coordonné) —  *timpul universal coordonat*

## Întrebările de azi și structura seminarului (1/3)

- ▣ Întrebările seminarului
  - ▶ **poate un model de limbaj să citească sentimentul financiar?**
  - ▶ **poate acest sentiment să prognozeze randamente care mai pot fi tranzacționate?**
- ▣ Trei tipuri de exerciții
  - ▶ **A:** exerciții de calcul, pe hîrtie
  - ▶ **B:** exerciții pe date reale, rezolvate în notebook
  - ▶ **C:** întrebări deschise, de exemplu corectarea unui răspuns dat de un instrument AI
- ▣ Fiecare exercițiu este marcat
  - ▶ **[Rezolvat]:** rezolvarea completă este prezentată la seminar
  - ▶ **[Propus]:** îl rezolvați dumneavoastră; soluția se discută la seminar

## Întrebările de azi și structura seminarului (2/3)

### ▣ Exercițiile de azi, în ordine

- ▶ A1: atenuarea pantei prin etichete clasificate greșit
- ▶ A2: diferența de acuratețe pe perechi, varianța ei, testul exact și puterea
- ▶ A3: costul de echilibru al unei strategii, cu eroare standard
- ▶ B1: FinBERT față de dicționarul Loughran–McDonald (LM)
- ▶ B2: reacție sau predicție, prognozează titlurile randamentele sau doar le descriu?
- ▶ B3: memoria modelului despre piață
- ▶ C1: critica unui răspuns AI cu trei erori

### ▣ Acasă

- ▶ B4: un LLM cu 7 miliarde de parametri față de FinBERT

## Întrebările de azi și structura seminarului (3/3)

- ▣ Rezultate de obținut
  - ▶ răspunsurile la exercițiile A
  - ▶ un tabel și un grafic pentru fiecare exercițiu B
  - ▶ corecturile din C1
  - ▶ o propoziție de interpretare pentru fiecare exercițiu
- ▣ Notebook-ul de azi: [deschideți notebook-ul seminarului în Colab](#)
  - ▶ fiecare cerință indică secțiunea din notebook
- ▣ Seminar: prof. Daniel Traian Pele, [danpele@ase.ro](mailto:danpele@ase.ro); drd. Antoaneta Amza, [antoaneta.amza@csie.ase.ro](mailto:antoaneta.amza@csie.ase.ro)

## Harta exercițiilor

| Exercițiu            | Întrebare                                                              | Tip      | Model                    |
|----------------------|------------------------------------------------------------------------|----------|--------------------------|
| A1                   | cît micșorează panta o variabilă binară clasificată greșit?            | Rezolvat | –                        |
| A2                   | cît de precis și cît de puternic este un test de acuratețe pe perechi? | Rezolvat | –                        |
| A3                   | de la ce cost pe tranzacție nu mai este profitabilă strategia?         | Rezolvat | –                        |
| B1                   | este FinBERT mai precis decît dicționarul LM?                          | Rezolvat | –                        |
| B2                   | prognozează titlurile randamentele sau le descriu?                     | Rezolvat | –                        |
| B3                   | își amintește LLM-ul piața?                                            | Rezolvat | –                        |
| C1                   | ce este greșit într-un răspuns AI?                                     | Propus   | B1, B2, B3               |
| B4                   | este un LLM cu 7 miliarde de parametri mai bun decît FinBERT? (temă)   | Propus   | B1                       |
| Pachete de extindere | A4–A8, B5–B11, C2, C3 (opționale, după curs)                           | ambele   | indicat la fiecare enunț |

- ☐ **[Rezolvat]**: rezolvarea completă în slide-uri și în notebook, un model de urmat; **[Propus]**: îl rezolvați dumneavoastră; rezolvarea se discută la seminar
- ☐ Partea A: derivări pe hîrtie; Partea B: verificare și inferență pe date reale, fiecare cu o întrebare de interpretare; Partea C: întrebări deschise și critica unui răspuns AI

## Datele folosite

| Date                                                            | Conținut                                                                                                          | Scoruri salvate                           | Folosite în                      |
|-----------------------------------------------------------------|-------------------------------------------------------------------------------------------------------------------|-------------------------------------------|----------------------------------|
| Twitter Financial News<br>(setul de validare, Hugging Face Hub) | 2 388 de titluri din 2022: 1 566 neutre, 475 pozitive, 347 negative                                               | LM, FinBERT, Qwen2.5 (P1–P3), MiniLM      | A1, A2, A4, A6–A8, B1, B4–B8, C1 |
| Financial PhraseBank <a href="#">Malo et al. (2014)</a>         | 4 846 de propoziții din știri, 2 264 cu acord deplin                                                              | aceleași scoruri                          | B5                               |
| FNSPID <a href="#">Dong, Fan &amp; Peng (2024)</a>              | 106 820 de titluri despre 16 acțiuni americane, 27.10.2009–18.12.2023                                             | scorurile zilnice LM, FinBERT, Qwen2.5-7B | A3, A8, B2, B9–B11, C1–C3        |
| Acțiunile și SPY                                                | prețurile ajustate zilnice din datele cursului, câte o serie pe activ (cîmpul folosit: adjusted close), 2009–2023 | –                                         | B2, B11, C2, C3                  |
| S&P 500                                                         | închideri lunare, ian. 2000 – aug. 2026                                                                           | răspunsurile Qwen2.5 despre fiecare lună  | B3, C1                           |

- Scorurile sînt salvate împreună cu Quantlet-urile capitolului, [Quantlets/Ch\\_15](#): la seminar nu trebuie rulat niciun model de limbaj
- C3 (pachet de extindere) cere o nouă evaluare a titlurilor FNSPID

## Pregătire: rulați și verificați

```
# notebook section "Setup" defines the functions that
# read the data
pb, tw = eval_texts()    # PhraseBank, Twitter
P, rets = news_panel()   # FNSPID stock-days
print(len(pb), len(tw))
print(tw['label'].value_counts())
print(P.shape,
      P.index.get_level_values('ticker').nunique())
```

- Rezultatul așteptat
  - ▶ 4 846 și 2 388 de rînduri
  - ▶ neutral 1 566, positive 475, negative 347
  - ▶ (18 282, 19) și 16 acțiuni
- Fiecare rînd din tw conține textul, eticheta umană și probabilitățile fiecărui model (de ex. finbert\_negative, qwen7B\_positive)
- Dacă cifrele diferă, opriți-vă și verificați fișierele înainte de orice exercițiu

## Notații folosite în toate exercițiile

- Tonul după dicționar  $\tau = (P - N)/(P + N)$ , cu  $P, N$  numărul de cuvinte pozitive și negative; LM: listele financiare Loughran–McDonald [Loughran & McDonald \(2011\)](#)
- Probabilitățile modelului  $p_k = e^{z_k/T} / \sum_j e^{z_j/T}$  ( $z_k$ : logitul răspunsului  $k$ ,  $T$ : temperatura); eticheta  $\arg \max_k p_k$ ; scorul net  $s = p_{\text{pos}} - p_{\text{neg}}$ ; FinBERT [Araci \(2019\)](#), Qwen2.5 [Qwen Team \(2024\)](#)
- Doi clasificatori A și B pe aceleași texte:  $n_{01}$  = A greșește și B are dreptate,  $n_{10}$  = A are dreptate și B greșește; testul McNemar [McNemar \(1947\)](#): sub  $H_0$ ,  $n_{01} \sim \text{Bin}(n_{01} + n_{10}; 0,5)$
- Ziua  $d$ : prima zi de tranzacționare de la data titlului încolo;  $d + 2$ : primul randament sigur de după publicare;  $h$ : zile după  $d$
- bp: punct de bază, 0,01%; SE: eroare standard; CI: interval de încredere de 95%;  $t_{NW}$ :  $t$  Newey–West [Newey & West \(1987\)](#); SE grupate: [Petersen \(2009\)](#)

## Noțiuni necesare azi (1/20): trei moduri de a citi sentimentul

- **Dicționar** (bag of words) [Loughran & McDonald \(2011\)](#): tonul unui text

$$\tau = \frac{P - N}{P + N} \in [-1, 1]$$

- ▶  $P$ ,  $N$ : numărul de cuvinte ale textului găsite într-o listă fixă pozitivă, respectiv negativă
- ▶ Clasa = semnul lui  $\tau$  ( $\tau = 0$ : neutru); exemplu  $P = 2$ ,  $N = 1$ :  $\tau = 1/3$ , pozitiv
- ▶ Listele LM, construite din rapoartele 10-K: 2 355 de cuvinte negative și doar 354 pozitive; transparent, dar insensibil la context și la negație

- **FinBERT** [Araci \(2019\)](#): BERT, un encoder Transformer ([Capitolul 14](#)), antrenat în continuare pe știri financiare

- ▶ Ajustat fin pe propoziții etichetate; rezultatul:  $p_{\text{pos}}$ ,  $p_{\text{neu}}$ ,  $p_{\text{neg}}$ , cu suma 1
- ▶ Ajustat fin pe Financial PhraseBank [Malo et al. \(2014\)](#): acuratețea lui acolo este parțial în eșanțon

- **LLM zero-shot** (Qwen2.5 [Qwen Team \(2024\)](#)): un model de limbaj mare întrebat „Is this headline positive, negative or neutral?”

- ▶ Fără antrenare pe aceste etichete (zero-shot); citim logiții  $z_k$  ai celor trei cuvinte-răspuns (slide-ul următor)

## Noțiuni necesare azi (2/20): de la logiți la probabilități

- Logitul  $z_k$ : scorul nenormalizat al modelului pentru răspunsul  $k \in \{\text{pos, neu, neg}\}$ ; mai mare înseamnă mai probabil
- **Softmax cu temperatura**  $T > 0$ : transformă logiții în probabilități

$$p_k(T) = \frac{e^{z_k/T}}{\sum_j e^{z_j/T}}, \quad \sum_k p_k(T) = 1$$



- ▶  $T = 1$ : probabilitățile proprii ale modelului;  $T > 1$  le aplatizează spre  $1/3$ ;  $T < 1$  le accentuează
- ▶ Contează doar diferențele de logiți:  $z_k - z_j = T \ln(p_k/p_j)$ , diferența de logiți (A7)

- **Eticheta și scorul net**

$$\hat{y} = \arg \max_k p_k, \quad s = p_{\text{pos}} - p_{\text{neg}} \in [-1, 1]$$

- ▶  $\arg \max_k$ : răspunsul cu probabilitatea cea mai mare;  $T$  nu îl schimbă, deoarece împărțirea la  $T > 0$  păstrează ordinea logiților
- ▶  $s > 0$ : ton pozitiv;  $s$  apropiat de 0: neutru sau nedecis;  $s$  se schimbă cu  $T$

## Noțiuni necesare azi (3/20): efectul temperaturii



□ Exemplu: logiții  $z = (2, 1, 0)$  pentru (pos, neu, neg)

►  $T = 1: p = (0,665; 0,245; 0,090)$ ,  $s = 0,575$

►  $T = 2: p = (0,506; 0,307; 0,186)$ ,  $s = 0,320$ : aceeași etichetă, scor împins spre 0

□ Când  $T \rightarrow \infty$ , cele trei probabilități tind la  $1/3$  și  $s \rightarrow 0$ ; o regulă cu prag pe  $s$  depinde deci de  $T$

## Noțiuni necesare azi (4/20): evaluarea unui clasificator

- Matricea de confuzie  $C$ :  $C_{jk}$  = numărul de texte cu eticheta umană  $j$  (rîndul, adevărul) și eticheta prezisă  $k$  (coloana);  $n$  texte,  $K$  clase

- Acuratețea**: proporția textelor de pe diagonală

$$\text{acc} = \frac{1}{n} \sum_{k=1}^K C_{kk}$$

- ▶ Reperul: proporția clasei majoritare (o prezicem mereu), niciodată  $1/K$

- Precizia și recall-ul clasei  $k$**

$$\text{prec}_k = \frac{C_{kk}}{\sum_j C_{jk}}, \quad \text{rec}_k = \frac{C_{kk}}{\sum_j C_{kj}}$$



- ▶ **prec**: proporția textelor marcate  $k$  care sînt cu adevărat  $k$  (coloana); **rec**: proporția textelor  $k$  care sînt marcate (rîndul)

- $F_1$  și macro-F1**

$$F_{1,k} = \frac{2 \text{prec}_k \text{rec}_k}{\text{prec}_k + \text{rec}_k}, \quad \text{macro-F1} = \frac{1}{K} \sum_{k=1}^K F_{1,k}$$

- ▶  **$F_1$** : media armonică, mică dacă oricare dintre ele este mică; macro-F1 dă unei clase rare aceeași pondere ca uneia frecvente

## Noțiuni necesare azi (5/20): acuratețea, macro-F1 și clasa majoritară



- Exemplu: 100 de titluri, 20 cu adevărat negative; modelul marchează 18 dintre ele și 8 dintre celelalte 80
  - Acuratețea  $(18 + 72)/100 = 0,90$ , dar „niciodată negativ” are deja 0,80; macro-F1:  $(0,783 + 0,935)/2 = 0,86$  față de  $(0 + 0,889)/2 = 0,44$
  - Ratele folosite în A1:  $\pi = 0,20$  cu adevărat negative,  $p = 0,26$  marcate, ratări  $\alpha_1 = 2/20 = 0,10$ , alarme false  $\alpha_0 = 8/80 = 0,10$

## Noțiuni necesare azi (6/20): eroarea de măsurare și atenuarea

- Panta OLS pe un singur regresor  $x$ : în eșantioane mari, un raport de momente

$$\text{plim}_{n \rightarrow \infty} \hat{b} = \frac{\text{Cov}(r, x)}{\text{Var}(x)}$$

- ▶  $\text{plim}$ : limita în probabilitate;  $r$ : variabila explicată (un randament)

- Eroare **clasică**: observăm  $x = x^* + u$ , cu  $u$  independent de  $x^*$  și de  $\varepsilon$


$$r = a + \beta x^* + \varepsilon \Rightarrow \text{plim } \hat{b} = \lambda \beta, \quad \lambda = \frac{\text{Var}(x^*)}{\text{Var}(x^*) + \text{Var}(u)}$$

- ▶  $\lambda \in (0, 1]$ : panta este deplasată spre zero (atenuare);  $1/\lambda$  o corectează


- **Variabilă dummy clasificată greșit** [Aigner \(1973\)](#): eticheta  $\hat{s} \in \{0, 1\}$  pentru adevăratul  $s^* \in \{0, 1\}$

- ▶  $\pi = P(s^* = 1)$ ; alarme false  $\alpha_0 = P(\hat{s} = 1 \mid s^* = 0)$ ; ratări  $\alpha_1 = P(\hat{s} = 0 \mid s^* = 1)$
- ▶ Probabilitatea totală:  $p = P(\hat{s} = 1) = \pi(1 - \alpha_1) + (1 - \pi)\alpha_0$
- ▶  $u = \hat{s} - s^*$  poate fi  $-1$  doar dacă  $s^* = 1$ : corelată cu  $s^*$ , deci nu este clasică; [A1](#) deduce  $\lambda$
- ▶ Eroare nediferențială: dat fiind  $s^*$ ,  $\hat{s}$  nu aduce informație suplimentară despre  $r$

## Noțiuni necesare azi (7/20): atenuarea într-o simulare



— on the truth  $s^*$ : slope 0.89    —  $\lambda, \pi = 0.5, \alpha_0 = \alpha_1$     - -  $\lambda, \pi = 0.15$ , only false alarms  
 — on the label  $\hat{s}$ : slope 0.52    —  $\lambda, \pi = 0.15, \alpha_0 = \alpha_1$



- Stînga: 400 de texte simulate,  $\pi = 0,25$ ,  $\alpha_0 = 0,15$ ,  $\alpha_1 = 0,25$ ,  $\beta = 1$ : panta pe etichetă este aproximativ jumătate din panta pe adevăr
- Dreapta:  $\lambda$  în funcție de rata de eroare;  $\lambda = 0$  la 50% erori (aruncarea unei monede); o clasă rară ( $\pi$  mic) pierde mai mult

## Noțiuni necesare azi (8/20): doi clasificatori pe aceleași texte

- Date împerecheate: pentru textul  $i$ ,  $D_i = 1$  dacă A greșește și B are dreptate,  $-1$  dacă A are dreptate și B greșește, 0 altfel
  - ▶  $n_{01}$ ,  $n_{10}$ : numărul de texte cu  $D_i = 1$  și cu  $D_i = -1$  (textele discordante); textele pe care ambii le nimeresc sau ambii le greșesc dau 0
- Diferența de acuratețe și varianța ei (deduse în A2)


$$\hat{d} = \frac{n_{01} - n_{10}}{n}, \quad \text{Var}(\hat{d}) = \frac{q - d^2}{n}$$

- ▶  $d = \text{acc}_B - \text{acc}_A$ ;  $q = P(D_i \neq 0)$ , proporția textelor discordante: doar ele adaugă varianță
- Testul McNemar exact McNemar (1947): sub  $H_0$  (acuratețe egală), fiecare text discordant îl favorizează pe B cu probabilitatea  $\frac{1}{2}$

$$n_{01} \sim \text{Bin}(m, \frac{1}{2}), \quad m = n_{01} + n_{10}, \quad p = \min \{1, 2P(\text{Bin}(m, \frac{1}{2}) \geq \max(n_{01}, n_{10}))\}$$

- ▶ Varianta pentru eșantioane mari:  $\chi^2 = (n_{01} - n_{10})^2 / m$ , comparată cu 3,84, cuantila de 95% a distribuției  $\chi_1^2$

## Noțiuni necesare azi (9/20): testul McNemar și puterea lui



■  $P(n_{01} = k)$  under  $H_0$ : Bin(40, 0.5)


■ as or more extreme than observed

—  $d = 0.03$ ,  $n_{80} = 2608$

—  $d = 0.05$ ,  $n_{80} = 934$

—  $d = 0.12$ ,  $n_{80} = 156$

--- 80% power




□ Puterea testului bilateral de 5% dacă diferența adevărată este  $d$  și numărul  $n$  care dă puterea 80%:

$$\text{puterea} \approx \Phi\left(\frac{|d|\sqrt{n}}{\sqrt{q-d^2}} - 1,96\right), \quad n_{80} = \frac{(1,96 + 0,84)^2 (q - d^2)}{d^2}$$

►  $\Phi$ : funcția de repartiție Normală standard; 0,84: cuantila ei de 80%; stînga: barele roșii =  $p$ -value-ul exact pentru  $m = 40$ ,  $n_{01} = 27$

## Noțiuni necesare azi (10/20): intervale de încredere bootstrap



□ **Bootstrap percentil** pentru o statistică  $\hat{\theta}$  (o acuratețe, o diferență)

► Extragem  $n$  texte cu întoarcere, de  $B$  ori; recalculăm  $\hat{\theta}_b^*$ ,  $b = 1, \dots, B$

► CI 95% =  $[q_{2,5\%}; q_{97,5\%}]$ , percentilele valorilor  $\hat{\theta}_b^*$

□ **Bootstrap împerecheat**: aceleași texte reeșantionate pentru A și B

► Păstrează dificultatea comună a fiecărui text pentru A și B: un interval mai îngust pentru diferență (graficul)

□ **Bootstrap pe blocuri** pentru zile (C2)

► Reeșantionăm blocuri de zile consecutive, ceea ce păstrează dependența serială


## Noțiuni necesare azi (11/20): calitatea ordonării: AUC

- ▣ Problema din B3: separăm lunile „în creștere” ( $n_1$ ) de lunile „în scădere” ( $n_0$ ) cu un scor  $S$ , de ex.  $P(\text{creștere})$
- ▣ **AUC**: probabilitatea ca o lună în creștere aleasă la întâmplare să aibă un scor mai mare decât una în scădere


$$\text{AUC} = \frac{U}{n_1 n_0}, \quad U = \sum_{i \in \text{creștere}} \sum_{j \in \text{scădere}} \left( 1\{S_i > S_j\} + \frac{1}{2} 1\{S_i = S_j\} \right)$$

- ▶  $U$ : statistica Mann–Whitney, numărul perechilor ordonate corect;  $1\{\cdot\}$ : 1 dacă este adevărat, altfel 0
- ▶  $\text{AUC} = 0,5$ : nicio informație; 1: ordonare perfectă; contează doar ordinea scorurilor
- ▣ **Testul de permutare** pentru  $\text{AUC} = 0,5$ 
  - ▶ Permutăm etichetele creștere/scădere de  $B$  ori;  $p = (1 + \#\{\text{AUC}_b^* \geq \text{AUC}\})/(B + 1)$ , #: numărul
- ▣ **Două AUC independente** (înainte și după o dată), erorile standard DeLong [DeLong et al. \(1988\)](#)
  - ▶  $z = (\text{AUC}_1 - \text{AUC}_2) / \sqrt{\text{SE}_1^2 + \text{SE}_2^2} \sim N(0, 1)$  sub  $H_0$ ; diferența detectabilă cu puterea 80% la 5%:  $2,80\sqrt{\text{SE}_1^2 + \text{SE}_2^2}$

## Noțiuni necesare azi (12/20): scoruri, praguri și curba ROC



■ "down" months    --- a threshold  $c$   
■ "up" months    ■ area = AUC = 0.68




— ROC curve  
 ..... no information: AUC = 0.5


- Stînga: scoruri simulate pentru 150 de luni în creștere și 100 în scădere; un prag  $c$  declară „în creștere” orice lună de deasupra lui
- Dreapta: deplasarea lui  $c$  trasează curba ROC, rata adevăraților pozitivi față de rata falșilor pozitivi; aria de sub ea este AUC (aici 0,68)

## Noțiuni necesare azi (13/20): de la titluri la randamente: calendarul

From a calendar date to the tradable return



Simulated: all news priced on day  $d$



—●— CAR, positive news    —●— CAR, negative news    ■ day  $d$ : reaction    ■  $h \geq 2$ : prediction

- Ziua  $d$ : prima zi de tranzacționare de la data titlului încolo; ora nu se cunoaște, deci  $d + 1$  poate conține încă reacția
- O pantă la  $h = 0$  măsoară cât de bine *descriu* titlurile ziua; doar  $h \geq 2$  este o *prognoză* (B2)
- Studiul de eveniment (B11):  $CAR[h_1, h_2] = \sum_{h=h_1}^{h_2} \bar{r}_{d+h}^e$ , randamentul mediu în exces cumulat; dreapta: știri încorporate complet în ziua  $d$

## Noțiuni necesare azi (14/20): regresia de panel și erorile standard grupate

- Regresia de panel pe zile-acțiune (acțiunea  $i$ , ziua  $d$ , orizontul  $h$ )

$$r_{i,d+h}^e = a + b z_{i,d} + \varepsilon_{i,d}$$


- ▶  $r^e$ : randamentul în exces față de SPY;  $z_{i,d}$ : scorul zilnic standardizat pe panel;  $b$ : randamentul la o abatere standard a scorului

- Erorile sînt corelate în aceeași zi (știri comune) și pentru aceeași acțiune (în timp): erorile standard OLS sînt prea mici
- **SE grupate Petersen (2009)**: însumăm scorurile în fiecare grup  $g$  (o zi sau o acțiune)

$$\widehat{\text{Var}}(\hat{\beta}) = c (X^\top X)^{-1} \left( \sum_{g=1}^G X_g^\top \hat{u}_g \hat{u}_g^\top X_g \right) (X^\top X)^{-1}, \quad c = \frac{G}{G-1} \frac{n-1}{n-2}$$

- ▶  $\hat{\beta} = (\hat{a}, \hat{b})$ ;  $X$ : cele  $n$  rînduri  $(1, z_{i,d})$ ;  $X_g, \hat{u}_g$ : rîndurile și reziduurile OLS ale grupului  $g$ ;  $c$ : factorul de eșantion mic
- ▶ Puține grupuri ( $G = 16$  acțiuni): comparăm  $t = \hat{b}/\text{SE}$  cu  $t_{G-1}$  (2,13), nu cu 1,96, sau folosim un wild cluster bootstrap Cameron, Gelbach & Miller (2008)

## Noțiuni necesare azi (15/20): de ce contează gruparea



- Simulare: 16 acțiuni  $\times$  60 de zile, panta adevărată 0; atât scorul, cât și eroarea persistă pentru aceeași acțiune
- SE OLS tratează cele 960 de rânduri ca independente
  - Statistica  $t$  este mult prea dispersată: 57% respingeri false la 5%
- SE grupate cu valoarea critică  $t_{15}$ 
  - Aproximativ 8% respingeri false: aproape de 5%, dar încă peste
  - Cu atât de puține grupuri, un wild cluster bootstrap este mai sigur (B9)

## Noțiuni necesare azi (16/20): o strategie de sentiment, statistica $t$ și costurile

- Strategia (A3): la închiderea din  $d + 1$ , o poziție de semnul lui  $s_{i,d}$  în fiecare acțiune cu știri, acoperită cu SPY și închisă după o zi;  $R_t$ : randamentul ei în ziua  $t$
- Statistica  $t$  Newey–West** Newey & West (1987):  $t$ -ul unei medii cînd zilele sînt dependente serial

$$t_{NW} = \frac{\hat{\mu}}{\sqrt{\hat{\Omega}/T}}, \quad \hat{\Omega} = \hat{\gamma}_0 + 2 \sum_{l=1}^L \left(1 - \frac{l}{L+1}\right) \hat{\gamma}_l$$

►  $\hat{\mu} = \bar{R}$ ;  $\hat{\gamma}_l$ : autocovarianța de selecție a lui  $R_t$  la lag-ul  $l$ ;  $L$ : numărul de lag-uri;  $T$ : numărul de zile

- Costurile**:  $c$  pe tranzacție, patru tranzacții în fiecare zi cu poziții, o proporție  $a$  de astfel de zile


$$\mu_{\text{net}} = \mu - 4ac, \quad SR_{\text{net}} = \frac{\sqrt{A}(\mu - 4ac)}{\sigma}, \quad c^* = \frac{\mu}{4a}$$

►  $A = 252$  de zile de tranzacționare pe an;  $\sigma$ : abaterea standard a randamentelor zilnice;  $SR$ : raportul Sharpe;  $c^*$ : costul de echilibru

- Metoda delta**: SE pentru o funcție de o estimație

►  $SE(g(\hat{\mu})) \approx |g'(\hat{\mu})| SE(\hat{\mu})$ ; cu  $SE(\hat{\mu}) = \hat{\mu}/t_{NW}$  și  $a$  fix:  $SE(c^*) = SE(\hat{\mu})/(4a)$

## Noțiuni necesare azi (17/20): costul de echilibru: o ilustrare




- Date ilustrative, nu cele din A3:  $\mu = 4$  bp pe zi,  $t_{NW} = 1,6$ ,  $a = 1$ ,  $\sigma = 150$  bp
- Raportul Sharpe net scade liniar în  $c$  și trece prin 0 la  $c^* = 4/4 = 1$  bp
- $SE(c^*) = (4/1,6)/4 = 0,63$  bp
  - CI 95% pentru  $c^*$ :  $1 \pm 1,96 \times 0,63 = [-0,23; 2,23]$  bp
  - Un cost realist de 5 bp pe tranzacție se află mult la dreapta intervalului

## Noțiuni necesare azi (18/20): look-ahead bias și încercările multiple

- **Look-ahead bias** [Glasserman & Lin \(2023\)](#): un LLM antrenat pe texte pînă la publicarea lui poate să fi citit ce a urmat după un titlu
  - ▶ Un backtest pe știri de dinaintea publicării amestecă prognoza cu memoria
  - ▶ Testul de memorie ([B3](#)): întrebăm modelul despre luni trecute fără nicio dată; un AUC peste 0,5 înseamnă că își amintește
  - ▶ Test fără contaminare: doar texte publicate după publicarea ponderilor ([B3](#), [C1](#))
- **Încercări multiple**: mai multe scoruri, orizonturi sau prompt-uri, apoi este raportat cel mai bun
  - ▶ Cu 20 de teste independente la 5%, probabilitatea a cel puțin unei respingeri false este  $1 - 0,95^{20} = 0,64$
  - ▶ Raportăm toate încercările sau corectăm  $p$ -value-urile ([B7](#), [B9](#), [B10](#))
- Mai mult în [Capitolul 15](#): embedding-uri, calibrare, scorurile ca estimări și studiul de caz ChatGPT

## Noțiuni necesare azi (19/20): pentru pachetele de extindere: calibrarea



- Calibrarea (A7) Guo et al. (2017): dintre textele cu probabilitatea 0,8, aproximativ 80% ar trebui să fie corecte
- Funcția de pierdere pentru alegerea lui  $T$ 
  - ▶  $NLL(T) = -\sum_i \ln p_{iy_i}(T)$ ,  $y_i$ : eticheta adevărată a textului  $i$
- Scorul Brier: eroarea pătratică medie a probabilităților
  - ▶  $\frac{1}{n} \sum_i \sum_k (p_{ik} - 1\{y_i = k\})^2$
- ECE:  $\sum_b \frac{n_b}{n} |\text{acc}_b - \text{conf}_b|$ 
  - ▶ Intervale  $b$  ale probabilității maxime;  $\text{conf}_b$ : media ei,  $\text{acc}_b$ : acuratețea,  $n_b$ : textele din interval
- Graficul: un model supraîncrezător se află sub diagonală;  $T^* > 1$  îl aduce pe ea

## Noțiuni necesare azi (20/20): pentru pachetele de extindere: instrumente de inferență

- **Corecția Holm** pentru  $M$  teste: ordonăm  $p_{(1)} \leq \dots \leq p_{(M)}$ 
  - ▶  $\tilde{p}_{(j)} = \max_{i \leq j} \min\{1, (M - i + 1) p_{(i)}\}$ ; respingem unde  $\tilde{p} < 0,05$ : cel mult 5% șanse de vreo respingere falsă
- **Wild cluster bootstrap** [Cameron, Gelbach & Miller \(2008\)](#) (B9)
  - ▶  $y_i^* = \bar{y} + w_{g(i)}(y_i - \bar{y})$ ,  $w_g = \pm 1$  cu probabilitatea  $\frac{1}{2}$  pentru fiecare grup;  $p = P^*(|t^*| \geq |t|)$
  - ▶ Grupare dublă:  $\hat{V} = \hat{V}_{\mathbf{zi}} + \hat{V}_{\text{acțiune}} - \hat{V}_{\mathbf{zi} \cap \text{acțiune}}$
- **Prediction-powered inference** [Angelopoulos et al. \(2023\)](#) (B8): media modelului corectată cu deplasarea lui pe textele etichetate
  - ▶  $\hat{\theta} = \frac{1}{N-n} \sum_{\text{neetich.}} f - \frac{1}{n} \sum_{\text{etich.}} (f - Y)$ ;  $f$ : scorul modelului,  $Y$ : eticheta umană
- $\kappa$  **al lui Fleiss** [Fleiss \(1971\)](#) (A5): acordul evaluatorilor peste cel întâmplător
  - ▶  $\kappa = (\bar{P} - \bar{P}_e)/(1 - \bar{P}_e)$ :  $\bar{P}$  acordul observat,  $\bar{P}_e$  cel întâmplător; 0 = întâmplare, 1 = perfect

## A1 [Rezolvat]: atenuarea prin clasificare greșită — enunț

- ▣ **Întrebare:** o regresie folosește eticheta FinBERT „negativ” în locul adevărului; cu cît se micșorează panta?
- ▣ **Date**
  - ▶ Twitter Financial News, setul de validare:  $N = 2\,388$  de titluri din 2022, fiecare etichetat negativ, neutru sau pozitiv; eticheta umană este considerată adevărul
  - ▶ Modelul  $r = a + \beta s^* + \varepsilon$ ,  $s^* = 1$  dacă titlul este cu adevărat negativ; observăm doar  $\hat{s} = 1$  cînd FinBERT prezice negativ
  - ▶ Eroare nediferențială: dat fiind  $s^*$ ,  $\hat{s}$  nu aduce informație suplimentară despre  $r$ , deci  $\text{Cov}(\varepsilon, \hat{s}) = 0$
  - ▶  $\pi = P(s^* = 1)$ ,  $p = P(\hat{s} = 1)$ , alarme false  $\alpha_0 = P(\hat{s} = 1 \mid s^* = 0)$ , ratări  $\alpha_1 = P(\hat{s} = 0 \mid s^* = 1)$
- ▣ **Cerințe**
  - (a) Arătați că  $\text{plim } \hat{b} = \beta \text{Cov}(s^*, \hat{s}) / \text{Var}(\hat{s})$ .
  - (b) Deduceți  $\lambda = \pi(1 - \pi)(1 - \alpha_0 - \alpha_1) / [p(1 - p)]$ .
  - (c) Calculați  $\pi$ ,  $p$ ,  $\alpha_0$ ,  $\alpha_1$  din matrice, apoi  $\lambda$  cu trei zecimale.
  - (d) Calculați  $\text{Cov}(u, s^*)$  pentru  $u = \hat{s} - s^*$ : este eroarea clasică?
- ▣ **De raportat:**  $\lambda$ ,  $1/\lambda$  și semnul lui  $\text{Cov}(u, s^*)$
- ▣ **Interpretare:** ce parte din efectul adevărat rămîne într-o pantă pe variabila binară FinBERT?


Matricea de confuzie FinBERT, Twitter

| Adevărat \ prezis | neg | neu   | pos | Total |
|-------------------|-----|-------|-----|-------|
| neg               | 264 | 71    | 12  | 347   |
| neu               | 213 | 1 184 | 169 | 1 566 |
| pos               | 58  | 133   | 284 | 475   |
| Total             | 535 | 1 388 | 465 | 2 388 |

## A1 [Rezolvat]: rezolvare (1/3)

- ▣ (a) Pentru un singur regresor plim  $\hat{b} = \text{Cov}(r, \hat{s}) / \text{Var}(\hat{s})$ , iar  $\text{Cov}(r, \hat{s}) = \beta \text{Cov}(s^*, \hat{s}) + \text{Cov}(\varepsilon, \hat{s})$ ; ultimul termen este 0 din ipoteza de eroare nediferențială
- ▣ (b) Ambele variabile sînt binare:  $\text{Cov}(s^*, \hat{s}) = P(s^* = 1, \hat{s} = 1) - \pi p = \pi(1 - \alpha_1) - \pi p$
- ▣ Formula probabilității totale:  $p = \pi(1 - \alpha_1) + (1 - \pi)\alpha_0$ ; înlocuind,  $\text{Cov}(s^*, \hat{s}) = \pi(1 - \pi)(1 - \alpha_0 - \alpha_1)$
- ▣  $\hat{s}$  este Bernoulli, deci  $\text{Var}(\hat{s}) = p(1 - p)$ ; raportul celor două este  $\lambda$

## A1 [Rezolvat]: rezolvare (2/3)



## A1 [Rezolvat]: rezolvare (3/3)

- (c)  $\pi = 347/2\,388 = 0,1453$ ,  $p = 535/2\,388 = 0,2240$ ,  $\alpha_1 = 1 - 264/347 = 0,2392$ ,  $\alpha_0 = 271/2\,041 = 0,1328$
- $\lambda = \frac{0,1242 \times 0,6280}{0,2240 \times (1 - 0,2240)} = 0,449$ , deci  $\beta = 2,23 \hat{b}$
- (d)  $\text{Cov}(u, s^*) = 0,0780 - 0,1242 = -0,0462 < 0$ : eroarea este corelată negativ cu adevărul, deci nu este clasică [Aigner \(1973\)](#)
- Graficul: 2 000 de eşantioane simulate cu aceste rate şi  $\beta = 1$ ; panta pe  $\hat{s}$  are media 0,450 (abaterea standard 0,054), cum prezice  $\lambda$
- Interpretare: o pantă pe variabila binară FinBERT păstrează doar circa 45% din efectul adevărat

## A2 [Rezolvat]: diferența de acuratețe pe perechi: varianță, test exact, putere — enunț

### ▣ Întrebări

- ▶ cît de precisă este diferența de acuratețe dintre doi clasificatori evaluați pe aceleași titluri?
- ▶ de cîte titluri are nevoie?


### ▣ Date de intrare

- ▶ Setul de validare Twitter,  $n = 2\,388$  de titluri independente; A = dicționarul LM, B = FinBERT
- ▶ Numere discordante:  $n_{01} = 539$  (A greșește, B are dreptate),  $n_{10} = 252$  (A are dreptate, B greșește)
- ▶  $D_i = 1$  dacă A greșește și B are dreptate,  $-1$  dacă A are dreptate și B greșește, 0 altfel;  $d = ED_i = \text{acc}_B - \text{acc}_A$ ,  $q = P(D_i \neq 0)$

### ▣ Cerințe

- (a) Arătați că  $\hat{d} = (n_{01} - n_{10})/n$  și deduceți  $\text{Var}(\hat{d}) = (q - d^2)/n$ .
  - (b) Calculați  $\hat{d}$ , SE, CI 95% și  $z = \hat{d}/\text{SE}$ .
  - (c) Aplicați testul McNemar exact la 5% și formulați decizia.
  - (d) Calculați puterea  $\Phi(|d|\sqrt{n}/\sqrt{q - d^2} - 1,96)$  dacă  $d$  adevărat este  $\hat{d}$  ( $\Phi$ : funcția de repartiție a distribuției Normale standard) și  $n_{80} = (1,96 + 0,84)^2(q - d^2)/d^2$ , valoarea lui  $n$  pentru puterea 80%.
- ▣ **De raportat:**  $\hat{d}$ , SE, CI,  $z$ ,  $p$  exact, decizia, puterea și  $n_{80}$
- ▣ **Interpretare:** ce titluri determină varianța lui  $\hat{d}$ ?

## A2 [Rezolvat]: rezolvare



- (a)  $\hat{d} = \frac{1}{n} \sum_i D_i = (n_{01} - n_{10})/n$ ;  $D_i^2 = 1$  exact cînd unul are dreptate și celălalt greșește, deci  $ED_i^2 = q$ ,  $\text{Var}(D_i) = q - d^2$  și  $\text{Var}(\hat{d}) = (q - d^2)/n$
- (b)  $\hat{d} = (539 - 252)/2388 = 0,1202$ ,  
 $\hat{q} = 791/2388 = 0,3312$ ,  $\text{SE} = 1,15$  pp, CI [9,76; 14,28] pp,  $z = 10,43$
- (c) Sub  $H_0$  ne așteptăm la 395,5 de fiecare parte;  $p$  exact  $< 0,001$ : respingem acuratețea egală
- (d) Puterea  $\Phi(+8,47) \approx 100\%$ ;  
 $n_{80} = 7,84 \times (0,3312 - 0,01444)/0,01444 \approx 170$  de titluri (graficul)
- Interpretare: doar titlurile discordante ( $q$ ) intră în varianță; o diferență de 12 puncte se detectează cu cîteva sute de titluri

## A3 [Rezolvat]: costul de echilibru cu eroare standard — enunț

### ▣ Întrebări

- ▶ de la ce cost pe tranzacție strategia FinBERT nu mai este profitabilă?
- ▶ cît de precis cunoaștem acest cost?

### ▣ Date de intrare

- ▶ Strategia de sentiment (slide-ul 16/20 din „Noțiuni necesare azi”; studiată în [Capitolul 15](#)): la închiderea din  $d + 1$  deschidem o poziție de semn  $\text{sign}(s_{i,d})$  în fiecare acțiune cu știri în ziua  $d$ , acoperită (hedging) cu SPY și închisă după o zi; patru tranzacții în fiecare zi cu poziții; 3 568 de zile de tranzacționare
- ▶ Semnalul FinBERT: randamentul brut mediu pe toate zilele  $\hat{\mu} = 3,27$  bp,  $t_{NW} = 1,27$  ( $L = 8$  laguri), ponderea zilelor cu poziții  $a = 0,962$ , raportul Sharpe brut  $\sqrt{A} \hat{\mu} / \sigma = 0,36$ , cu  $\sigma$  abaterea standard a randamentelor zilnice și  $A = 252$  de zile de tranzacționare pe an


### ▣ Cerințe

- Scrieți randamentul net zilnic mediu și raportul Sharpe net ca funcții de costul  $c$  pe tranzacție.
- Deduceți costul de echilibru  $c^*$  la care randamentul net mediu este zero.
- Calculați  $\text{SE}(\hat{\mu}) = \hat{\mu} / t$ , apoi  $\text{SE}(c^*)$  prin metoda delta și CI 95% pentru  $c^*$ .
- Obțineți  $\sigma$  din raportul Sharpe brut și calculați raportul Sharpe net la  $c = 5$  bp.

### ▣ De raportat: $c^*$ , SE și CI, raportul Sharpe net

### ▣ Interpretare: este un cost realist de 5 bp pe tranzacție în interiorul CI pentru $c^*$ ?

## A3 [Rezolvat]: rezolvare (1/2)



### A3 [Rezolvat]: rezolvare (2/2)

- (a) Într-o fracțiune  $a$  din zile plătim  $4c$ :  $\mu_{\text{net}} = \mu - 4ac$ ,  $SR_{\text{net}} = \sqrt{A}(\mu - 4ac)/\sigma$ , cu  $\sigma$  aproape neschimbat de costuri
- (b)  $c^* = \mu/(4a) = 3,27/3,85 = 0,85$  bp pe tranzacție
- (c)  $SE(\hat{\mu}) = 3,27/1,27 = 2,57$  bp; cu  $a$  fixat de calendarul știrilor,  $SE(c^*) = 2,57/3,85 = 0,67$  bp, CI  $[-0,46; 2,16]$  bp
- (d)  $\sigma = \sqrt{252} \times 3,27/0,36 = 143$  bp
  - $SR_{\text{net}} = \sqrt{252}(3,27 - 3,85 \times 5)/143 = -1,77$
- Interpretare: 5 bp este mult peste CI pentru  $c^*$ ; cu turnover zilnic, strategia nu rămîne profitabilă la costuri realiste

## B1 [Rezolvat]: FinBERT față de LM — enunț


- ▣ **Întrebare:** este FinBERT, ajustat fin, mai precis decât dicționarul Loughran–McDonald pe titluri pe care nu a fost antrenat?
- ▣ **Date**
  - ▶ Twitter Financial News, setul de validare:  $N = 2\,388$  de titluri din 2022, fiecare etichetat negativ, neutru sau pozitiv; eticheta umană este considerată adevărul
  - ▶  $A$  = dicționarul LM (eticheta = semnul tonului),  $B$  = FinBERT (eticheta = probabilitatea cea mai mare); funcția `b_pairs` din notebook
- ▣ **Cerințe**
  - (a) Calculați fiecare acuratețe cu CI bootstrap percentil 95%: reeșantionați titlurile de 2 000 de ori (seed 0).
  - (b) Calculați diferența  $B - A$  cu CI bootstrap pe perechi: aceleași titluri reeșantionate pentru ambii clasificatori.
  - (c) Numărați  $n_{01}$ ,  $n_{10}$ ; aplicați testul McNemar exact și  $(n_{01} - n_{10})^2 / (n_{01} + n_{10})$  față de  $\chi_1^2$  (3,84).
- ▣ **De raportat:** un tabel cu cele două acurateți, CI și diferența;  $n_{01}$ ,  $n_{10}$ , ambele  $p$ -value-uri și decizia
- ▣ **Interpretare**
  - ▶ de ce este testul pe perechi mai puternic decât compararea celor două intervale?
  - ▶ contează diferența pentru tranzacționare?

## B1 [Rezolvat]: rezolvare (1/2)

|                | Acuratețe (%) | CI 95%        |
|----------------|---------------|---------------|
| LM             | 60,5          | [58,5; 62,4]  |
| FinBERT        | 72,5          | [70,7; 74,4]  |
| Diferența (pp) | +12,0         | [+9,8; +14,2] |

- Pasul 1: etichetele ambilor clasificatori pe cele 2 388 de titluri; pasul 2: 2 000 de reeșantionări bootstrap ale indicilor titlurilor; pasul 3: ambele acurateți și diferența lor în fiecare reeșantionare
- (a)–(b) Cele două intervale nu se suprapun, iar CI pe perechi al diferenței exclude 0; coincide practic cu CI analitic din [A2](#)

## B1 [Rezolvat]: rezolvare (2/2)



- (c)  $n_{01} = 539$ ,  $n_{10} = 252$ , 395,5 așteptate sub  $H_0$ ;  $p$  exact  $< 0,001$ ;  $\chi^2 = 104,1 > 3,84$ : respingem acuratețea egală
- Împerecherea elimină variația dificultății titlurilor: titlurile pe care ambii le clasifică la fel nu aduc informație
- Interpretare: FinBERT este clar mai bun decât dicționarul în afara datelor lui de antrenare; un câștig de 12 puncte în etichetare nu implică încă nimic despre randamente (B2)

## B2 [Rezolvat]: reacție față de predicție — enunț

### ▣ Întrebări

- ▶ explică scorul zilnic al titlurilor randamentul din ziua știrii?
- ▶ prognozează el primul randament care mai poate fi tranzacționat?
- ▶ cât de largi sînt intervalele corecte?

### ▣ Date

- ▶ Panelul FNSPID: 18 282 de zile-acțiune cu știri, 16 acțiuni americane, 27.10.2009–18.12.2023;  $z_{i,d}$ : scorul net zilnic, standardizat pe panel;  $r^e$ : randamentul în exces față de SPY (%), din prețurile ajustate zilnice ale cursului
- ▶ Scoruri: FinBERT, Qwen2.5-7B, LM

### ▣ Cerințe

- Estimați prin OLS  $r_{i,d+h}^e = a + b z_{i,d} + \varepsilon$  pentru cele trei scoruri și  $h = 0, 1, 2$ ; raportați  $b$  în bp pentru o abatere standard a scorului.
- Calculați trei SE: OLS, grupată pe zile ( $G = 3\,434$ ), grupată pe acțiuni ( $G = 16$ ), cu factorul de eșantion mic  $\frac{G}{G-1} \frac{n-1}{n-2}$ .
- Comparați fiecare  $t$  cu 1,96, iar  $t$  grupat pe acțiuni cu valoarea critică  $t_{15, 2,13}$ .

### ▣ De raportat: un grafic al pantelor pentru $h = 0$ cu cele trei intervale și un tabel al regresiilor

### ▣ Interpretare

- ▶ de ce diferă  $h = 0$  și  $h = 2$ ?
- ▶ putem avea încredere într-o SE grupată cu 16 grupuri?

## B2 [Rezolvat]: rezolvare (1/3)



## B2 [Rezolvat]: rezolvare (2/3)

- Pantele din aceeași zi cu intervalele de 95% ale celor trei erori standard: intervalul grupat pe acțiuni este cel mai larg
- Gruparea pe zile este apropiată de OLS: cu doar 5,3 acțiuni pe zi, zgomotul comun este mic
- Gruparea pe acțiuni înmulțește SE FinBERT la  $h = 0$  cu 3,0: panta diferă între acțiuni, iar erorile fiecărei acțiuni sînt corelate în timp

## B2 [Rezolvat]: rezolvare (3/3)


| Scor       | $h$ | $b$ (bp) | SE OLS | SE zi | SE acțiune | $t$ zi | $t$ acțiune |
|------------|-----|----------|--------|-------|------------|--------|-------------|
| FinBERT    | 0   | +39,2    | 2,3    | 2,3   | 6,9        | +17,27 | +5,71       |
| FinBERT    | 2   | -0,5     | 2,2    | 2,2   | 1,5        | -0,25  | -0,35       |
| Qwen2.5-7B | 0   | +41,4    | 2,3    | 2,2   | 8,1        | +19,07 | +5,10       |
| Qwen2.5-7B | 2   | +2,3     | 2,2    | 1,9   | 1,0        | +1,19  | +2,41       |
| LM         | 0   | +15,5    | 2,3    | 1,8   | 3,3        | +8,53  | +4,70       |
| LM         | 2   | -0,0     | 2,2    | 1,7   | 0,9        | -0,01  | -0,03       |

- $h = 0$ : mare cu orice SE ( $t$  pe acțiuni peste 4,7): titlurile descriu mișcarea zilei, adesea chiar mișcarea („shares jump”)
- $h = 2$ : FinBERT -0,5 bp ( $t = -0,25$  pe zile); Qwen  $t = +2,41$  pe acțiuni, dar  $p = 0,061$  prin wild cluster bootstrap [Cameron, Gelbach & Miller \(2008\)](#) și 0,37 după Holm pe nouă regresii (extensia B9)
- Interpretare: sentimentul explică ziua știrii, nu zilele tranzacționabile; cu 16 acțiuni, inferența cere metode pentru puține grupuri

## B3 [Rezolvat]: memoria modelului despre piață — enunț

- **Întrebare:** întrebare fără nicio dată, poate Qwen2.5 să distingă lunile în care S&P 500 a crescut de cele în care a scăzut?
- **Date**
  - ▶ Închideri lunare S&P 500 (GSPC.INDX), ianuarie 2000 – august 2026; o lună este „în creștere” dacă randamentul ei este pozitiv
  - ▶ Qwen2.5 1.5B, 7B, 14B (ponderi publicate pe 19 septembrie 2024) întrebate „Did the S&P 500 index rise or fall during <lună an>?”; scorul  $P(\text{rise})$
  - ▶ Înainte: 296 de luni până în august 2024 (185 în creștere); după: 23 de luni din octombrie 2024 (13 în creștere)
- **Cerințe**
  - (a) Calculați  $AUC = U/(n_{\text{up}}n_{\text{down}})$  ( $U$ : Mann–Whitney) pe model și perioadă, cu CI bootstrap din 2000 de extrageri pe luni.
  - (b) Test prin permutare pentru 14B înainte de publicare: amestecați etichetele creștere/scădere de 2000 de ori.
  - (c) Testați  $AUC_{\text{înainte}} = AUC_{\text{după}}$  cu varianțele DeLong [DeLong et al. \(1988\)](#) și găsiți cea mai mică scădere detectabilă cu puterea 80%.
- **De raportat:** tabelul AUC cu CI,  $p$  prin permutare,  $z$  și  $p$  DeLong, scăderea detectabilă
- **Interpretare:** ce înseamnă un AUC peste 0,5 când modelul nu vede date?

## B3 [Rezolvat]: rezolvare (1/3)




## B3 [Rezolvat]: rezolvare (2/3)

| Qwen2.5 | AUC înainte | CI 95%       | AUC după | CI 95%       |
|---------|-------------|--------------|----------|--------------|
| 1.5B    | 0,57        | [0,51; 0,64] | 0,72     | [0,49; 0,91] |
| 7B      | 0,67        | [0,61; 0,73] | 0,53     | [0,28; 0,78] |
| 14B     | 0,69        | [0,62; 0,75] | 0,59     | [0,35; 0,84] |

- (a) 7B și 14B ordonează lunile de creștere peste cele de scădere mult peste nivelul întâmplător înainte de publicare; 1.5B doar marginal; după publicare toate intervalele conțin 0,5

### B3 [Rezolvat]: rezolvare (3/3)



■ AUC with shuffled up/down labels (2,000 permutations)

■ Observed AUC = 0.69

- (b)  $p$  prin permutare pentru 14B înainte de publicare  $<0,001$ : niciun AUC amestecat nu atinge valoarea observată (graficul)
- (c) DeLong: SE înainte 0,032, după 0,126;  $z = 0,73$ ,  $p = 0,47$ : nu respingem egalitatea
  - Scăderea detectabilă  $2,80\sqrt{SE_{\text{înainte}}^2 + SE_0^2} = 0,36$
  - Ar fi nevoie de circa 101 luni după publicare
- Interpretare: fără date, discriminarea provine din textul de antrenare
  - Un backtest pe știri anterioare publicării confundă prognoza cu memorarea [Glasserman & Lin \(2023\)](#)

## C1 [Propus]: critica unui răspuns AI — răspunsul

- **Cererea studentului:** „Am titlurile FNSPID pentru 16 acțiuni americane, 2009–2023, și randamentele zilnice în exces față de SPY. Verifică dacă Qwen2.5-7B citește sentimentul, apoi testează dacă sentimentul titlurilor prognozează randamentele în afara eșantionului.”
- **Codul asistentului AI** (qwen\_label, qwen\_score: evaluatorul zero-shot de pe slide-urile 1/20 și 2/20 din „Noțiuni necesare azi”)

```
import pandas as pd, statsmodels.formula.api as smf
from sklearn.metrics import accuracy_score
tw['pred'] = [qwen_label(t) for t in tw['text']] # Twitter validation set
acc = accuracy_score(tw['label'], tw['pred'])
news['day'] = first_trading_day_on_or_after(news['date'])
news['s'] = [qwen_score(t) for t in news['title']] # P(pos) - P(neg)
d = news.groupby(['ticker', 'day'])['s'].mean().reset_index()
d['z'] = (d['s'] - d['s'].mean()) / d['s'].std()
d = d.merge(rets, on=['ticker', 'day']) # rets: ticker, day, xret (%)
fit = smf.ols('xret ~ z', data=d).fit(cov_type='cluster',
                                     cov_kws={'groups': pd.factorize(d['day'])[0]})
```

## C1 [Propus]: critica unui răspuns AI — enunț

- ▣ **Model:** B1, B2 și B3 [Rezolvat]
- ▣ **Concluzia asistentului AI**
  - ▶ „Acuratețe 74,2%, de peste două ori cei 33% ai unei ghiciri la întâmplare între trei clase: Qwen2.5-7B citește foarte bine sentimentul financiar.”
  - ▶ „Panta +41,4 bp pentru o abatere standard a scorului,  $t = +19,07$  (grupat pe zile): titlurile zilei prognozează randamentul în exces al acțiunii.”
  - ▶ „Qwen2.5 nu a fost antrenat pe aceste etichete sau serii de randamente, deci backtest-ul 2009–2023 este complet în afara eșantionului.”
- ▣ **Întrebare:** codul rulează și cifrele sînt corecte, dar răspunsul conține **trei** erori tipice pentru backtesting-ul sentimentului; care sînt?
- ▣ **Cerințe**
  - ▶ (a) Identificați fiecare eroare: numiți rîndul de cod sau propoziția și explicați de ce este greșită.
  - ▶ (b) Precizați cum ați detecta-o fără să cunoașteți răspunsul: numărul de observații pe clase, o verificare a orelor, o dată de publicare, un test de memorie.
  - ▶ (c) Scrieți codul sau afirmația corectată, cu cifrele pe care le produce.
  - ▶ (d) Notați fiecare eroare în [AI\\_ERRORS.md](#), cu cîmpurile: ce a răspuns AI-ul, ce era greșit, cum ați identificat eroarea, varianta corectă.

## B4 [Propus]: un LLM cu 7 miliarde de parametri față de FinBERT — enunț

- ▣ **Model:** B1 [Rezolvat]
- ▣ **Întrebare:** depășește un LLM deschis general, folosit zero-shot, modelul FinBERT ajustat fin, pe titluri pe care niciunul nu a fost antrenat?
- ▣ **Date**
  - ▶ Twitter Financial News, setul de validare:  $N = 2\,388$  de titluri din 2022, fiecare etichetat negativ, neutru sau pozitiv; eticheta umană este considerată adevărul
  - ▶  $A = \text{FinBERT}$ ,  $B = \text{Qwen2.5-7B}$  zero-shot cu promptul P1; niciunul nu a folosit etichete Twitter
- ▣ **Cerințe**
  - (a) Calculați fiecare acuratețe cu CI bootstrap percentil 95%: reeșantionați titlurile de 2 000 de ori (seed 0).
  - (b) Calculați diferența  $B - A$  cu CI bootstrap pe perechi: aceleași titluri reeșantionate pentru ambii clasificatori.
  - (c) Numărați  $n_{01}$ ,  $n_{10}$ ; aplicați testul McNemar exact și  $(n_{01} - n_{10})^2 / (n_{01} + n_{10})$  față de  $\chi^2_1(3,84)$ .
- ▣ **De raportat:** aceleași tabel, aceleași teste și același grafic ca în B1
- ▣ **Interpretare**
  - ▶ se suprapun cele două intervale?
  - ▶ este întrebarea astfel tranșată?
  - ▶ ce ar aduce totuși un model mult mai mare și mai lent?

## Pasul pentru proiectul de echipă

- ▣ Alegeți o sursă de texte nediscutată la seminar (anunțuri BVB, știri financiare românești, comunicate ale băncilor centrale, postări despre criptoactive)
- ▣ Etichetați cel puțin 200 de texte cu doi adnotatori și raportați acordul; evaluați doar pe o parte separată
- ▣ Consemnați folosirea AI în [AI\\_USE.md](#) și erorile depistate în [AI\\_ERRORS.md](#); pachetele de extindere sînt opționale; C2 și C3 sînt puncte de plecare pentru proiect

## Pachetele de extindere: condițiile fiecăruia

| Pachet                         | Exerciții                 | Cunoștințe necesare                                                                  |
|--------------------------------|---------------------------|--------------------------------------------------------------------------------------|
| 1. Eroarea de măsurare         | A4, A5                    | A1                                                                                   |
| 2. Compararea clasificatorilor | A6, B5 [Rezolvat], B6, B7 | A2, B1                                                                               |
| 3. Probabilitățile LLM         | A7 [Rezolvat]             | slide-urile 2/20 și 19/20 din „Noțiuni necesare azi”, graficul de calibrare din curs |
| 4. Inferență validă            | B8 [Rezolvat], B9, B10    | B2, B3                                                                               |
| 5. Semnale și costuri          | A8, B11, C2               | A3, B2                                                                               |
| 6. Laborator de replicare      | C3                        | C2, studiul de caz din curs                                                          |

- Fiecare exercițiu are secțiunea lui în notebook; rezolvați-le în ordine în cadrul unui pachet
- Utile pentru proiectul de echipă: C2 și C3 sînt posibile puncte de plecare pentru proiect

## A4 [Propus]: atenuarea pentru dicționarul LM — enunț

- **Model:** A1 [Rezolvat]
- **Întrebare:** este panta LM mai slabă din Cursul 15 (15,5 bp față de 39,2 bp pentru FinBERT) o reacție mai slabă a pieței sau o măsurare mai imprecisă?
- **Date**
  - ▶ Twitter Financial News, setul de validare:  $N = 2\,388$  de titluri din 2022, fiecare etichetat negativ, neutru sau pozitiv; eticheta umană este considerată adevărul
  - ▶ Același model și aceeași ipoteză ca în A1; acum  $\hat{s} = 1$  când tonul LM al titlului este negativ
- **Cerințe**
  - (a) Calculați  $\pi$ ,  $p$ ,  $\alpha_0$  și  $\alpha_1$  din matricea LM.
  - (b) Calculați  $\lambda$  și  $1/\lambda$  cu formula din A1.
  - (c) Calculați  $\text{Cov}(u, s^*)$ : este eroarea LM clasică?
  - (d) Comparați  $\lambda$  cu cel al FinBERT (A1) și calculați raportul celor doi factori.
- **De raportat:** cele patru rate,  $\lambda$ ,  $1/\lambda$ , raportul
- **Interpretare:** care clasificator atenuează mai mult panta?

Matricea de confuzie LM, Twitter

| Adevărat \ | prezis | neg | neu   | pos | Total |
|------------|--------|-----|-------|-----|-------|
| neg        |        | 172 | 166   | 9   | 347   |
| neu        |        | 247 | 1 192 | 127 | 1 566 |
| pos        |        | 45  | 349   | 81  | 475   |
| Total      |        | 464 | 1 707 | 217 | 2 388 |

A5 [Propus]:  $\kappa$  al lui Fleiss și un pas Dawid–Skene — enunț

▣ **Model:** A1 [Rezolvat]

▣ **Întrebări**

- ▶ cât de mult sînt de acord evaluatorii peste nivelul întâmplător?
- ▶ care este eticheta adevărată cea mai probabilă a unei propoziții disputate?

▣ **Date de intrare**

- ▶ Voturi ilustrative (alese pentru exercițiu): 6 propoziții, cîte  $m = 5$  evaluatori
- ▶  $P_i = \sum_j n_{ij}(n_{ij} - 1)/[m(m - 1)]$ ,  $\bar{P} = \frac{1}{N} \sum_i P_i$ ,  $p_j =$  ponderea voturilor pentru  $j$ ,  $\bar{P}_e = \sum_j p_j^2$ ,  $\kappa = (\bar{P} - \bar{P}_e)/(1 - \bar{P}_e)$  [Fleiss \(1971\)](#)

▣ **Cerințe**

- (a) Calculați fiecare  $P_i$  și  $\bar{P}$ .
- (b) Calculați  $p_j$ ,  $\bar{P}_e$  și  $\kappa$ .
- (c) Pasul E din [Dawid & Skene \(1979\)](#): fiecare evaluator dă clasa adevărată cu probabilitatea 0,8 și fiecare altă clasă cu 0,1, distribuție a priori uniformă; calculați  $P(\text{adevărat} = j \mid \text{voturi}) \propto \prod_i \pi_{ji}^{n_{ij}}$  pentru propozițiile 4 și 5.
- (d) Comparați probabilitățile a posteriori cu ponderile voturilor și descrieți pasul M.

▣ **De raportat:**  $\kappa$  și cele două distribuții a posteriori

▣ **Interpretare:** cum ați trata propozițiile disputate într-un set de test?

| Propoziția | neg | neu | pos |
|------------|-----|-----|-----|
| 1          | 5   | 0   | 0   |
| 2          | 0   | 5   | 0   |
| 3          | 0   | 1   | 4   |
| 4          | 1   | 3   | 1   |
| 5          | 2   | 3   | 0   |
| 6          | 0   | 2   | 3   |

◀ Înapoi

▶ Lista exercițiilor

## A6 [Propus]: „nicio diferență” și puterea testului — enunț


- ▣ **Model:** A2 [Rezolvat]
- ▣ **Întrebare:** FinBERT și Qwen2.5-7B par la egalitate: este asta o dovadă de acuratețe egală sau a unui test slab?
- ▣ **Date de intrare**
  - ▶ Setul de validare Twitter,  $n = 2\,388$ ;  $A = \text{FinBERT}$ ,  $B = \text{Qwen2.5-7B}$  (promptul P1);  $n_{01} = 395$ ,  $n_{10} = 355$
- ▣ **Cerințe**
  - (a) Calculați  $\hat{d}$ ,  $\hat{q}$ , SE, CI 95% și  $z$  cu formulele din A2.
  - (b) Aplicați testul McNemar exact la 5%.
  - (c) Calculați puterea la  $n = 2\,388$  dacă  $d$  adevărat este  $\hat{d}$  și  $n_{80}$ .
  - (d) Folosiți CI pentru a preciza ce diferențe sînt excluse de date.
- ▣ **De raportat:** cifrele din (a)–(d)
- ▣ **Interpretare:** puteți concluziona că cele două modele sînt la fel de precise?

## B5 [Rezolvat]: suprapunerea cu datele de antrenare — enunț

- ▣ **Întrebare:** cât din acuratețea FinBERT pe Financial PhraseBank provine din faptul că a fost antrenat pe acest set?
- ▣ **Date**
  - ▶ Financial PhraseBank [Malo et al. \(2014\)](#): 4 846 de propoziții (2 264 cu acord deplin); FinBERT a fost ajustat fin pe o parte a lor (3 101 din 4 845 în [Araci \(2019\)](#))
  - ▶ Setul de validare Twitter, 2 388 de titluri nevăzute de FinBERT; clasificatori: FinBERT, Qwen2.5-7B, LM, MiniLM + regresie logistică antrenată pe Twitter [Wang et al. \(2020\)](#)
- ▣ **Cerințe**
  - (a) Calculați acuratețea (CI bootstrap din 2 000 de extrageri) și F1 macro pe PhraseBank cu acord deplin, pe tot PhraseBank și pe Twitter.
  - (b) Calculați scăderea de la tot PhraseBank la Twitter pentru fiecare clasificator.
  - (c) Calculați diferența diferențelor FinBERT minus Qwen2.5-7B cu CI bootstrap (fiecare set reeșantionat independent).
- ▣ **De raportat:** un tabel cu acurateți și scăderi, diferența diferențelor cu CI
- ▣ **Interpretare:** cum separați „date mai dificile” de „memoria setului de antrenare”?

## B5 [Rezolvat]: rezolvare

| Acuratețe (%)      | PhraseBank, acord 100% | PhraseBank, tot | Twitter | Scădere (pp) | F1 macro, Twitter |
|--------------------|------------------------|-----------------|---------|--------------|-------------------|
| FinBERT            | 97,2                   | 89,0            | 72,5    | 16,4         | 66,8              |
| Qwen2.5-7B         | 93,6                   | 81,4            | 74,2    | 7,2          | 72,6              |
| LM                 | 65,0                   | 62,5            | 60,5    | 2,0          | 46,2              |
| MiniLM + reg. log. | 81,4                   | 70,6            | 78,6    | -8,0         | 69,9              |



● Financial PhraseBank (all)    ■ Twitter validation set

- (c)  $16,4 - 7,2 = 9,2$  pp din acuratețile nerotunjite, CI bootstrap [6,7; 11,9]: exclude 0
- Qwen2.5-7B nu a fost ajustat pe etichetele PhraseBank, deci scăderea lui măsoară dificultatea mai mare a datelor
  - Dacă ambele ar pierde la fel fără suprapunere (o ipoteză netestată), cele 9,2 puncte în plus ale FinBERT provin din suprapunere
- Interpretare: MiniLM variază în sens invers pentru că este antrenat pe Twitter: fiecare model este cel mai bun pe datele pe care a fost antrenat

## B6 [Propus]: numărul necesar de etichete — enunț

- ▣ **Model:** B5 [Rezolvat]
- ▣ **Întrebare:** de câte titluri etichetate are nevoie un model supervizat simplu pentru a-l depăși pe FinBERT?
- ▣ **Date**
  - ▶ Twitter Financial News: set de antrenare cu 9 543 de titluri, set de validare cu 2 388; reperul FinBERT, 72,5%, fără etichete Twitter
  - ▶ Regresie logistică ( $C = 4$ ) pe vectorii MiniLM cu 384 de dimensiuni; regresie logistică ( $C = 8$ ) pe trăsături TF-IDF ale cuvintelor și perechilor de cuvinte
- ▣ **Cerințe**
  - (a) Pentru  $n \in \{100, 200, 400, \dots, 6\,400, 9\,543\}$  extrageți 10 subseturi aleatoare de antrenare, estimați ambele modele și mediați acuratețea pe validare.
  - (b) Găsiți cel mai mic  $n$  la care fiecare model îl depășește în medie pe FinBERT.
  - (c) Raportați abaterea standard a acurateței vectorilor pe cele 10 repetiții la  $n = 100$ .
- ▣ **De raportat:** curba de învățare și tabelul ei
- ▣ **Interpretare:** de ce vectorii pornesc mai sus, dar cresc mai încet?

## B7 [Propus]: sensibilitatea la prompt — enunț

- ▣ **Model:** B1 [Rezolvat]
- ▣ **Întrebare:** se schimbă răspunsul aceluiași LLM când aceeași întrebare este formulată altfel?
- ▣ **Date**
  - ▶ Twitter Financial News, setul de validare:  $N = 2\,388$  de titluri din 2022, fiecare etichetat negativ, neutru sau pozitiv; eticheta umană este considerată adevărul
  - ▶ Qwen2.5-7B și 14B cu trei prompturi: P1 „classify the sentiment . . . for investors”, P2 „good, bad or neutral for the stock price”, P3 „what is the sentiment of this text”
- ▣ **Cerințe**
  - (a) Calculați acuratețea cu CI bootstrap din 2 000 de extrageri și ponderea răspunsurilor „neutral” pentru fiecare prompt și model.
  - (b) Aplicați testul McNemar exact pentru P1 față de P3, pentru fiecare model.
  - (c) Calculați ponderea titlurilor cu aceeași etichetă sub toate cele trei prompturi.
- ▣ **De raportat:** un tabel și un grafic pentru cele trei prompturi
- ▣ **Interpretare:** dacă ați alege cel mai bun prompt pe acest set, ce ați face de fapt?

## A7 [Rezolvat]: de la probabilitățile etichetelor la un scor și temperatura optimă — enunț

### ▣ Întrebări

- ▶ cum schimbă temperatura  $T$  probabilitățile unui LLM, scorul și calibrarea lui?
- ▶ ce  $T$  este optim pentru date?

### ▣ Date de intrare

- ▶ Un titlu Twitter etichetat **neutru**; Qwen2.5-7B (P1) dă  $p_{\text{neg}} = 0,608$ ,  $p_{\text{neu}} = 0,392$ ,  $p_{\text{pos}} = 0,000$  (exact  $1,0 \times 10^{-12}$ )
- ▶ O jumătate aleatoare a setului de validare ( $n = 1\,194$ , seed 15): logiții  $z_{ik} = \ln p_{ik}$ , rescalați  $p_{ik}(T) \propto e^{z_{ik}/T}$ , pierderea  $\text{NLL}(T) = -\sum_i \ln p_{iy_i}(T)$  Guo et al. (2017)

### ▣ Cerințe

- Dați eticheta, scorul net  $s$  și diferența de logit  $\ln(p_{\text{neu}}/p_{\text{neg}})$  ale titlului, apoi probabilitățile și  $s$  la  $T = 2$ .
- Explicați de ce etichetele și acuratețea nu depind de  $T$ , dar scorul Brier da.
- Deduceți  $\text{NLL}'(T)$ , evaluați condiția de ordinul întâi la  $T = 1$  și rezolvați pentru  $T^*$  (Brent pe  $[0,5; 50]$ ).
- Pe cealaltă jumătate, calculați ECE și Brier înainte și după scalare.

### ▣ De raportat: eticheta, $s$ , $s(T)$ , $T^*$ , ECE și Brier înainte și după


### ▣ Interpretare

- ▶ este LLM-ul prea încrezător sau prea puțin încrezător?
- ▶ ce se întâmplă cu o regulă cu prag pe  $s$ ?

## A7 [Rezolvat]: rezolvare (1/3)

- ▣ (a) Cea mai mare probabilitate  $p_{\text{neg}}$ : eticheta negativă, greșită;  $s = 0,000 - 0,608 = -0,608$ ; diferența de logit  $\ln(0,392/0,608) = -0,437$
- ▣ La  $T = 2$ ,  $p_k(T) \propto \sqrt{p_k}$ :  $\sqrt{p} = (0,780, 0,626, 1,0 \times 10^{-6})$ , suma 1,406,  $p(T) = (0,554, 0,446, 0,000)$ ,  $s(T) = -0,554$ : aceeași etichetă, scorul se apropie de 0
- ▣ (b)  $z \mapsto z/T$  este crescătoare pentru  $T > 0$ : ordinea logiților, deci argmax și acuratețea, nu se schimbă; probabilitățile, deci Brier și log loss, se schimbă

## A7 [Rezolvat]: rezolvare (2/3)



## A7 [Rezolvat]: rezolvare (3/3)


- (c)  $\ln p_{iy}(T) = z_{iy}/T - \ln \sum_k e^{z_{ik}/T}$  dă  $\text{NLL}'(T) = \frac{1}{T^2} \sum_i (z_{iy_i} - \sum_k p_{ik}(T) z_{ik})$
- La  $T = 1$  media parantezei este  $-2,47 < 0$ , deci NLL scade cînd  $T$  crește; rădăcina este  $T^* = 8,43$
- (d) ECE scade de la 22,6% la 4,3%, Brier de la 0,468 la 0,366 (graficul: fiabilitatea brută și rescalată)
- Interpretare: probabilitățile brute ale LLM sînt mult prea încrezătoare; un prag pe  $s$  selectează alte titluri după rescalare

 MFM\_ch15\_valid\_inference

## B8 [Rezolvat]: prediction-powered inference cu puține etichete umane — enunț

- ▣ **Întrebare:** pot câteva sute de etichete umane plus un model distorsionat să dea un interval valid și mai îngust pentru tonul mediu al titlurilor?
- ▣ **Date**
  - ▶ Ținta  $\theta$  = tonul net uman mediu  $(-1, 0, 1)$  al celor 2 388 de titluri Twitter de validare, care au rolul populației;  $f$  = scorul net FinBERT sau Qwen2.5-7B, fix
  - ▶ Schema:  $n$  titluri etichetate (cu  $Y$ ) și  $N - n$  neetichetate (doar cu  $f$ ), extrase independent, cu întoarcere
- ▣ **Cerințe**
  - (a) Pentru o extragere cu  $n = 200$ , calculați estimarea doar din etichete  $\bar{Y}_n \pm 1,96 s_Y / \sqrt{n}$  ( $\bar{Y}_n, s_Y$ : media și abaterea standard a celor  $n$  etichete).
  - (b) Calculați PPI [Angelopoulos et al. \(2023\)](#):  $\hat{\theta} = \frac{1}{N-n} \sum_{\text{neetich.}} f - \frac{1}{n} \sum_{\text{etich.}} (f - Y)$ , SE  
 $= \sqrt{\hat{V}(f)/(N-n) + \hat{V}(f - Y)/n}$ , pentru ambele modele.
  - (c) Pentru  $n = 100, 200, 400, 800$ , repetați de 2 000 de ori și înregistrați acoperirea lui  $\theta$  și lățimea medie a CI.
- ▣ **De raportat:** estimările dintr-o extragere și un grafic cu acoperirea și lățimea
- ▣ **Interpretare:** de ce media simplă a modelului  $\frac{1}{N} \sum f$  nu estimează  $\theta$ ?

## B8 [Rezolvat]: rezolvare (1/2)



## B8 [Rezolvat]: rezolvare (2/2)

- ▣  $\theta$  adevărat = 0,054; mediile simple ale modelelor FinBERT -0,014 (semn greșit), Qwen +0,101: distorsiunea nu scade când  $N$  crește
- ▣ (a) Doar etichete:  $0,010 \pm 1,96 \times 0,042$ ; (b) PPI-FinBERT: corecția -0,064,  $\hat{\theta} = 0,054 \pm 1,96 \times 0,036$ ; PPI-Qwen: corecția -0,012,  $\hat{\theta} = 0,123 \pm 1,96 \times 0,039$
- ▣ (c)  $n = 100$ : acoperirea 94,7%, 94,3%, 95,4%, lățimea 0,229, 0,204, 0,203 (etichete, PPI-FinBERT, PPI-Qwen); câștigul pentru  $N$  mare: 24% și 27%; la  $n = 800$  PPI este mai larg (0,087 față de 0,081)
- ▣ Interpretare: media modelului converge la o valoare greșită; eșantionul etichetat o corectează, iar PPI este mai îngust doar când  $\text{Var}(f - Y) < \text{Var}(Y)$  și multe texte sînt neetichetate

## B9 [Propus]: wild cluster bootstrap cu 16 acțiuni — enunț

▣ **Model:** B2 [Rezolvat]

▣ **Întrebare:** cu doar 16 grupuri de acțiuni, care dintre cele nouă pante din B2 rămân semnificative?

▣ **Date**

- ▶ Panelul FNSPID: 18 282 de zile-acțiune cu știri, 16 acțiuni americane, 27.10.2009–18.12.2023;  $z_{i,d}$ : scorul net zilnic, standardizat pe panel;  $r^e$ : randamentul în exces față de SPY (%), din prețurile ajustate zilnice ale cursului
- ▶ Cele nouă regresii din B2 (trei scoruri  $\times h = 0, 1, 2$ ), SE grupate pe acțiuni ( $G = 16$ )

▣ **Cerințe**

- (a) Calculați  $p$ -value-ul fiecărei pante cu valori critice  $t_{15}$ .
- (b) Aplicați wild cluster bootstrap cu ipoteza nulă impusă [Cameron, Gelbach & Miller \(2008\)](#):  $y_i^* = \bar{y} + w_{g(i)}(y_i - \bar{y})$ , ponderi Rademacher  $w_g = \pm 1$  cu probabilitatea  $\frac{1}{2}$ ,  $g(i)$ : acțiunea observației  $i$ ,  $\bar{y}$ : valoarea ajustată sub  $H_0$  (doar termenul liber), 9 999 de extrageri.
- (c) Calculați  $t$  cu grupare pe două dimensiuni,  $\hat{V} = \hat{V}_{\text{zi}} + \hat{V}_{\text{acțiune}} - \hat{V}_{\text{zi} \cap \text{acțiune}}$ .
- (d) Ajustați cele nouă  $p$ -value-uri bootstrap cu Holm la 5%.

▣ **De raportat:** un tabel cu  $t$ , cele trei  $p$ -value-uri și  $t$  pe două dimensiuni

▣ **Interpretare:** rămîne semnificativă panta Qwen la  $h = 2$ ?

## B10 [Propus]: curba specificațiilor pentru strategia de sentiment — enunț

- **Model:** B3 [Rezolvat] (un test prin randomizare)
- **Întrebare:** pe toate variantele rezonabile ale strategiei, există mai multe dovezi de predictibilitate decât ar produce întâmplarea?
- **Date**
  - ▶ Strategia de sentiment (slide-ul 16/20 din „Noțiuni necesare azi”; studiată în [Capitolul 15](#)): la închiderea din  $d + 1$  deschidem o poziție de semn  $\text{sign}(s_{i,d})$  în fiecare acțiune cu știri în ziua  $d$ , acoperită (hedging) cu SPY și închisă după o zi; patru tranzacții în fiecare zi cu poziții; 3 568 de zile de tranzacționare
  - ▶ Grila din Cursul 15: trei scoruri  $\times$  praguri  $|s| > b$ ,  $b \in \{0; 0,25; 0,5\}$ ,  $\times$  ziua randamentului  $d + 2, \dots, d + 5$ : 36 de strategii
- **Cerințe**
  - (a) Calculați randamentul zilnic mediu și  $t_{NW}$  pentru fiecare strategie și reprezentați statisticile  $t$  sortate [Simonsohn, Simmons & Nelson \(2020\)](#).
  - (b) Simulați ipoteza nulă comună: schimbați semnul pozițiilor în blocuri de 10 zile de semnal (dependent wild bootstrap [Shao \(2010\)](#)), aceleași schimbări pentru toate 36, de 2 000 de ori.
  - (c) Calculați  $p$ -value-urile comune pentru numărul de  $t > 1,96$  și pentru  $t$  median.
- **De raportat:** curba sortată și cele două  $p$ -value-uri comune
- **Interpretare:** ce ar ascunde raportarea „cele mai bune specificații”?

## A8 [Propus]: strategia Qwen după costuri — enunț

▣ **Model:** A3 [Rezolvat]

▣ **Întrebare:** strategia Qwen2.5-7B are un randament brut mediu pozitiv statistic: este ea tranzacționabilă?

▣ **Date de intrare**

- ▶ Strategia de sentiment (slide-ul 16/20 din „Noțiuni necesare azi”; studiată în [Capitolul 15](#)): la închiderea din  $d + 1$  deschidem o poziție de semn  $\text{sign}(s_{i,d})$  în fiecare acțiune cu știri în ziua  $d$ , acoperită (hedging) cu SPY și închisă după o zi; patru tranzacții în fiecare zi cu poziții; 3 568 de zile de tranzacționare
- ▶ Semnalul Qwen2.5-7B:  $\hat{\mu} = 5,64$  bp,  $t_{NW} = 2,26$  ( $L = 8$ ),  $a = 0,950$ , raportul Sharpe brut 0,63

▣ **Cerințe**

- (a) Calculați costul de echilibru  $c^*$ .
- (b) Calculați  $\text{SE}(c^*)$  prin metoda delta și CI 95%.
- (c) Obțineți  $\sigma$  și calculați raportul Sharpe net la 5 bp.

▣ **De raportat:**  $c^*$ , SE, CI, raportul Sharpe net

▣ **Interpretare:** un randament brut semnificativ implică profit după costuri?

## B11 [Propus]: studiu de eveniment cu tonul Loughran–McDonald — enunț

▣ **Model:** B2 [Rezolvat]

▣ **Întrebări**

- ▶ în jurul zilelor cu știri negative și pozitive, când se mișcă prețul?
- ▶ separă dicționarul cele două grupuri la fel de bine ca FinBERT?

▣ **Date**

- ▶ Panelul FNSPID: 18 282 de zile-acțiune cu știri, 16 acțiuni americane, 27.10.2009–18.12.2023;  $z_{i,d}$ : scorul net zilnic, standardizat pe panel;  $r^e$ : randamentul în exces față de SPY (%), din prețurile ajustate zilnice ale cursului
- ▶ Tonul zilnic LM este exact 0 în 48% dintre zilele-acțiune: grupurile ton  $< 0$  (5 196 de zile-acțiune) și ton  $> 0$  (4 288); FinBERT: terčila inferioară și cea superioară

▣ **Cerințe**

- Pentru fiecare dată, mediați randamentele în exces din zilele  $-5, \dots, +5$  pe zilele-acțiune ale acelei date, în fiecare grup.
- Calculați media pe date a CAR pentru  $[-5, -1]$ , ziua 0, ziua 1 și  $[+2, +5]$ , cu  $t_{NW}$ .
- Reprezentați traiectoriile cumulate medii ale celor patru grupuri.

▣ **De raportat:** tabelul celor patru ferestre și graficul

▣ **Interpretare:** de ce este randamentul de după eveniment pozitiv pentru ambele grupuri Tetlock (2007)?

## C2 [Propus]: profitabilitatea sentimentului titlurilor după costuri — enunț

▣ **Model:** A3, B2 [Rezolvat]

▣ **Întrebare:** este profitabilă după costuri realiste o strategie zilnică bazată pe sentimentul titlurilor FNSPID?

▣ **Date**

- ▶ Strategia de sentiment (slide-ul 16/20 din „Noțiuni necesare azi”; studiată în [Capitolul 15](#)): la închiderea din  $d + 1$  deschidem o poziție de semn  $\text{sign}(s_{i,d})$  în fiecare acțiune cu știri în ziua  $d$ , acoperită (hedging) cu SPY și închisă după o zi; patru tranzacții în fiecare zi cu poziții; 3 568 de zile de tranzacționare
- ▶ Poziții ponderate egal; zilele fără știri: randament 0; 5 bp pe tranzacție; scorurile FinBERT, Qwen2.5-7B, LM din tabelele salvate

▣ **Cerințe**

- (a) Pentru FinBERT, calculați randamentul brut zilnic mediu,  $t_{NW}$  și un CI bootstrap pe blocuri mobile de 95% (blocuri de 10 zile, 2 000 de extrageri).
  - (b) Calculați raportul Sharpe înainte și după costuri, costul de echilibru și raportul Sharpe la 0, 1, 2, 5, 10 bp.
  - (c) Repetați pentru Qwen2.5-7B și LM și pentru știrile puternice  $|s| > 0,5$  (exploratoriu); Holm pe cele trei strategii nefiltrate sau pe toate șase dacă alegeți dintre ele.
  - (d) Pas suplimentar: corectați panta din aceeași zi cu un eșantion aleator de zile-acțiune etichetat de oameni (împărțiți la  $\rho(s^*, \hat{s})$  sau corectați momentele OLS ca în [B8](#)).
- ▣ **De raportat:** o notă de două pagini cu un tabel de rezultate și grafice și un folder Quantlet
- ▣ **Interpretare:** discutați alinierea în timp, look-ahead bias ([B3](#)), survivorship bias pentru cele 16 acțiuni și crowding [Lopez-Lira & Tang \(2026\)](#)

[◀ Înapoi](#)[▶ Lista exercițiilor](#)

### C3 [Propus]: replicarea Lopez-Lira și Tang pe FNSPID — enunț

- ▣ **Model:** C2, B2, B3, B9
- ▣ **Întrebare:** aplicat cu un model deschis pe titlurile cursului, găsește protocolul publicat pentru GPT-4 Lopez-Lira & Tang (2026) aceeași reacție și același drift?
- ▣ **Date de intrare**
  - ▶ Lucrarea: GPT-4 răspunde YES, NO sau UNKNOWN despre fiecare titlu;  $s = 1, -1, 0$  determină un portofoliu long-short zilnic; drift-ul pentru știrile dintre ședințe 0,34% pe zi, raport Sharpe 2,97 (tabelul 1)
  - ▶ Date: titlurile FNSPID ale celor 16 acțiuni, prețurile ajustate din datele cursului; primul randament sigur  $d + 2$
  - ▶ Modelul: Qwen2.5-7B-Instruct Qwen Team (2024), temperatura 0, prompt-ul din secțiunea 5 a lucrării, nemodificat
- ▣ **Cerințe**
  - (a) Evaluați fiecare titlu, extrageți doar prima linie, transformați YES/UNKNOWN/NO în 1/0/ - 1; raportați ponderile și răspunsurile nevalide.
  - (b) Mediați pe zi-acțiune și formați portofoliul zilnic cu convențiile de pe slide-ul următor, cu randamentele din ziua  $d + 2$ .
  - (c) Raportați media zilnică (bp),  $t_{NW}$ , rata de succes, raportul Sharpe, ponderile zilelor cu o componentă și fără poziție.
  - (d) Estimați ec. (1) pe titluri,  $h = 0, 2$ , cu efecte fixe de acțiune și de dată, SE grupate pe date și acțiuni,  $p$  wild cluster bootstrap (B9).
  - (e) Recalculeți raportul Sharpe după 5, 10, 20 bp pe tranzacție dus-întors (figura 4) și comparați cu C2 pe aceleași zile-acțiune.
- ▣ **De raportat:** cifrele obținute lângă tabelele 1 și 2 din lucrare, randamentele cumulate brute și nete, un folder Quantlet
- ▣ **Interpretare**
  - ▶ ce diferențe față de lucrare pot fi separate cu datele cursului?
  - ▶ ce indică B3 despre distorsiune?

### C3 [Propus]: convențiile pentru portofoliu, calendar și costuri

#### ▣ Fixate înaintea oricărei rulări

- ▶ Ponderile (tabelul 1): componenta long = randamentul mediu, cu ponderi egale, al acțiunilor cu  $s > 0$ , componenta short = la fel pentru  $s < 0$ , fiecare doar cu cel puțin două acțiuni; long-short = long minus short (expunere brută 2); dacă se califică o singură componentă, se deține doar aceasta (nota 20)
- ▶ Randamentele: randamentele brute ale acțiunilor, ca în tabelul 1; varianta cu hedging pe SPY (ca în C2) este o adaptare a cursului, raportată ca analiză de sensibilitate: cu ambele componente acoperirea se anulează, deci contează doar în zilele cu o singură componentă
- ▶ Calendarul: toate zilele de tranzacționare, ca în C2, cu randament 0 fără poziție; media,  $t_{NW}$  și raportul Sharpe pe toate zilele; rata de succes pe zilele cu poziții
- ▶ Costurile (figura 4):  $c$  bp pe tranzacție dus-întors pentru fiecare unitate de valoare nominală:  $2c$  pe zi cu două componente,  $c$  cu una, plus, în varianta cu hedging,  $c$  pe valoarea nominală netă SPY (1 în zilele cu o singură componentă)
- ▶ Regresiile (d): randamente brute în % pe zi, ca în tabelul 2; efectele fixe de dată absorb randamentul pieței; wild cluster bootstrap păstrează ambele efecte fixe în modelul nul

## Bibliografie (1/3)

- ▣ Aigner, D.J. (1973). Regression with a binary independent variable subject to errors of observation. *Journal of Econometrics*, 1(1), 49–59.
- ▣ Angelopoulos, A.N., Bates, S., Fannjiang, C., Jordan, M.I., Zrnic, T. (2023). Prediction-powered inference. *Science*, 382(6671), 669–674.
- ▣ Araci, D. (2019). FinBERT: financial sentiment analysis with pre-trained language models. arXiv:1908.10063.
- ▣ Cameron, A.C., Gelbach, J.B., Miller, D.L. (2008). Bootstrap-based improvements for inference with clustered errors. *Review of Economics and Statistics*, 90(3), 414–427.
- ▣ Dawid, A.P., Skene, A.M. (1979). Maximum likelihood estimation of observer error-rates using the EM algorithm. *Applied Statistics*, 28(1), 20–28.
- ▣ DeLong, E.R., DeLong, D.M., Clarke-Pearson, D.L. (1988). Comparing the areas under two or more correlated receiver operating characteristic curves: a nonparametric approach. *Biometrics*, 44(3), 837–845.
- ▣ Dong, Z., Fan, X., Peng, Z. (2024). FNSPID: a comprehensive financial news dataset in time series. *Proceedings of the 30th ACM SIGKDD Conference*, 4918–4927.
- ▣ Fleiss, J.L. (1971). Measuring nominal scale agreement among many raters. *Psychological Bulletin*, 76(5), 378–382.

## Bibliografie (2/3)

- ▣ Franke, J., Härdle, W.K., Hafner, C.M. (2019). *Statistics of Financial Markets: An Introduction*, 5th ed. Springer.
- ▣ Glasserman, P., Lin, C. (2023). *Assessing look-ahead bias in stock return predictions generated by GPT sentiment analysis*. arXiv:2309.17322.
- ▣ Guo, C., Pleiss, G., Sun, Y., Weinberger, K.Q. (2017). *On calibration of modern neural networks*. ICML; arXiv:1706.04599.
- ▣ Lopez-Lira, A., Tang, Y. (2026). *Can ChatGPT forecast stock price movements? Return predictability and large language models*. *Journal of Financial Economics*, 184, 104335.
- ▣ Loughran, T., McDonald, B. (2011). *When is a liability not a liability? Textual analysis, dictionaries, and 10-Ks*. *Journal of Finance*, 66(1), 35–65.
- ▣ Malo, P., Sinha, A., Korhonen, P., Wallenius, J., Takala, P. (2014). *Good debt or bad debt: detecting semantic orientations in economic texts*. *Journal of the Association for Information Science and Technology*, 65(4), 782–796.
- ▣ McNemar, Q. (1947). *Note on the sampling error of the difference between correlated proportions or percentages*. *Psychometrika*, 12(2), 153–157.
- ▣ Newey, W.K., West, K.D. (1987). *A simple, positive semi-definite, heteroskedasticity and autocorrelation consistent covariance matrix*. *Econometrica*, 55(3), 703–708.

## Bibliografie (3/3)

- ▣ Petersen, M.A. (2009). [Estimating standard errors in finance panel data sets: comparing approaches](#). *Review of Financial Studies*, 22(1), 435–480.
- ▣ Qwen Team (2024). [Qwen2.5 technical report](#). arXiv:2412.15115.
- ▣ Sarkar, S.K., Vafa, K. (2024). [Lookahead bias in pretrained language models](#). SSRN Working Paper 4754678.
- ▣ Shao, X. (2010). [The dependent wild bootstrap](#). *Journal of the American Statistical Association*, 105(489), 218–235.
- ▣ Simonsohn, U., Simmons, J.P., Nelson, L.D. (2020). [Specification curve analysis](#). *Nature Human Behaviour*, 4(11), 1208–1214.
- ▣ Tetlock, P.C. (2007). [Giving content to investor sentiment: the role of media in the stock market](#). *Journal of Finance*, 62(3), 1139–1168.
- ▣ Wang, W., Wei, F., Dong, L., Bao, H., Yang, N., Zhou, M. (2020). [MiniLM: deep self-attention distillation for task-agnostic compression of pre-trained Transformers](#). *NeurIPS*; arXiv:2002.10957.