



Modelarea piețelor financiare

Seminarul 15: LLM-uri și analiza sentimentului — aplicații



Daniel Traian PELE

Drd. Antoaneta Amza, antoaneta.amza@csie.ase.ro

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognostic Economică

MSCA Digital Finance

Acronime folosite în acest material

- ▣ AI: Artificial Intelligence (inteligență artificială)
- ▣ AUC: Area Under the (ROC) Curve (aria de sub curba ROC)
- ▣ BERT: Bidirectional Encoder Representations from Transformers (reprezentări bidirecționale produse de codificatorul unui Transformer)
- ▣ BVB: Bursa de Valori București
- ▣ CAR: Cumulative Abnormal Return (randamentul anormal cumulat)
- ▣ CI: Confidence Interval (interval de încredere)
- ▣ ECB: European Central Bank (Banca Centrală Europeană)
- ▣ FNSPID: Financial News and Stock Price Integration Dataset (setul de date care integrează știri financiare și prețuri de acțiuni)
- ▣ GI: (Harvard) General Inquirer, dictionary IV-4 (dicționarul Harvard General Inquirer IV-4)
- ▣ LLM: Large Language Model (model lingvistic mare)
- ▣ LM: Loughran-McDonald (financial sentiment dictionary) (dicționarul financiar de sentiment Loughran-McDonald)
- ▣ OLS: Ordinary Least Squares (metoda celor mai mici pătrate)
- ▣ ROC: Receiver Operating Characteristic (curve) (curba caracteristică de operare)
- ▣ SE: Standard Error (eroare standard)
- ▣ TF-IDF: Term Frequency - Inverse Document Frequency (frecvența termenului înmulțită cu inversul frecvenței în documente)
- ▣ US: United States (Statele Unite ale Americii)
- ▣ UTC: Coordinated Universal Time (Temps Universel Coordonné) (timpul universal coordonat)

Cuprins

Introducere

Partea A: pe hârtie

Partea B: estimare și inferență

Partea C: întrebare deschisă și critica unui răspuns AI

Încheiere

Bibliografie

Obiectivele seminarului

La finalul seminarului puteți

- ▣ Calcula sentimentul unui text cu un dicționar și cu probabilitățile etichetelor unui model lingvistic mare (LLM, *large language model*)
- ▣ Citi o matrice de confuzie: acuratețe, precizie, recall, F1 și F1 macro
- ▣ Compara doi clasificatori cu un test pe perechi și detecta scurgerea datelor de antrenare și informația din viitor
- ▣ Transforma sentimentul titlurilor într-un semnal de tranzacționare, cu aliniere corectă în timp, erori standard grupate și costuri

- ▣ Suport: Cursul 15; manualul [Franke, Härdle & Hafner \(2019\)](#)

Structura

- ▣ **Partea A:** opt exerciții pe hârtie (A1–A8)
- ▣ **Partea B:** opt exerciții pe calculator, cu inferență (B1–B8)
- ▣ **Partea C:** o întrebare deschisă, punct de plecare pentru proiectul de echipă (C1), și critica unui răspuns AI (C2)

Cum lucrăm la acest seminar

- ▣ Problemele **[Rezolvat]** au rezolvarea completă; problemele **[Propus]** au doar cerința: rezolvările se discută la seminar
- ▣ Fiecare problemă propusă indică **modelul**: problema rezolvată care folosește aceeași tehnică
 - ▶ Fiecare exercițiu din Partea B se încheie cu întrebări de interpretare
- ▣ Puteți folosi un asistent AI, dar declarați-l în [AI_USE.md](#) și notați erorile prinse în [AI_ERRORS.md](#)
 - ▶ C2 exersează exact asta: găsiți erorile dintr-un răspuns AI despre testarea retroactivă a sentimentului
- ▣ Întrebați mereu: era textul public înaintea randamentului pe care încerc să-l prognozez și știa deja modelul rezultatul?

Probleme rezolvate și propuse

Rezolvate: exemple lucrate în acest material

- ▣ Partea A: A1 (tonul după două dicționare), A3 (metrici din matricea de confuzie), A5 (probabilitățile etichetelor și temperatura), A7 (costul de echilibru)
- ▣ Partea B: B1 (FinBERT vs LM, McNemar), B3 (scurgerea datelor de antrenare), B5 (erori standard grupate), B7 (își amintește LLM-ul piața?)

Propuse: le rezolvați voi

- ▣ Partea A: A2 (model: A1), A4 (model: A3), A6 (clasa majoritară; model: A3), A8 (deținere mai lungă; model: A7)
- ▣ Partea B: B2 (LLM vs FinBERT; model: B1), B4 (câte etichete; model: B3), B6 (studiu de eveniment; model: B5), B8 (sensibilitatea la prompt; model: B1)
- ▣ Partea C: C1, aduce sentimentul titlurilor câștig după costuri?; C2, critica unui răspuns AI despre testarea retroactivă a sentimentului cu un LLM

Pregătire: mediul Python și datele

-  **Deschide în Colab:** `capitol15_notebook_seminar.ipynb`
- Google Colab (recomandat) sau Python local ≥ 3.10 cu `numpy`, `pandas`, `scipy`, `scikit-learn`, `matplotlib`; `transformers` doar pentru recalcularea scorurilor
- Texte etichetate: Financial PhraseBank (4 846 de propoziții din știri, 2 264 cu acord deplin) [Malo et al. \(2014\)](#); Twitter Financial News, setul de validare (2 388 de titluri)
- Titluri dateate: FNSPID (*Financial News and Stock Price Integration Dataset*) [Dong, Fan & Peng \(2024\)](#), 106 820 de titluri despre 16 acțiuni americane mari; închideri zilnice ale acțiunilor și ale SPY (un fond pe indicele S&P 500)
- Scorurile tuturor modelelor sunt precalculate în tabelele Capitolului 15; Quantlets: `MFM_ch15_sem_partA`, `partB`, `partC`

Formulele folosite azi (1/2): scoruri și metrice

- Tonul după dicționar: $\tau = (P - N)/(P + N)$, P , N : numărul de cuvinte pozitive și negative; $\tau = 0$ dacă $P + N = 0$
 - LM: listele financiare de cuvinte Loughran–McDonald [Loughran & McDonald \(2011\)](#); GI: lista Harvard General Inquirer IV-4, un dicționar general din psihologie
- Probabilitățile etichetelor unui LLM: $p_k = e^{z_k/T} / \sum_j e^{z_j/T}$ (z_k : logitul cuvântului-răspuns k , T : temperatura); scorul net $s = p_{\text{pos}} - p_{\text{neg}}$
 - FinBERT: un model BERT (*Bidirectional Encoder Representations from Transformers*) ajustat pentru sentimentul financiar [Araci \(2019\)](#); Qwen2.5: LLM-uri cu ponderi deschise [Qwen Team \(2024\)](#)
- Clasa k : precizia = $\frac{TP_k}{TP_k + FP_k}$, recall-ul = $\frac{TP_k}{TP_k + FN_k}$, $F1_k = \frac{2 \text{ prec} \cdot \text{rec}}{\text{prec} + \text{rec}}$; $F1 \text{ macro} = \frac{1}{3} \sum_k F1_k$
 - TP_k : texte din clasa k etichetate k ; FP_k : alte texte etichetate k ; FN_k : texte din clasa k etichetate altfel

Formulele folosite azi (2/2): inferență și semnale

- Testul McNemar [McNemar \(1947\)](#): n_{01} texte unde A greșește și B are dreptate, n_{10} invers; sub H_0 , $n_{01} \sim \text{Bin}(n_{01} + n_{10}, 0,5)$
 - CI bootstrap (interval de încredere): reeșantionăm textele de 2 000 de ori, luăm cuantilele de 2,5% și 97,5%
- AUC (aria de sub curba ROC): probabilitatea ca un caz „în creștere” ales aleator să primească un scor mai mare decât un caz „în scădere”; 0,5 = nicio informație
- Regresia pe panel $r_{i,d+h}^e = a + b z_{i,d} + \varepsilon$: r^e randamentul în exces față de SPY (%), z scorul zilnic standardizat, $h = 0, 1, 2$ zile după ziua știrii d
 - Erori standard (SE): cele mai mici pătrate obișnuite (OLS) sau grupate pe zile ori pe acțiuni [Petersen \(2009\)](#); bp: punct de bază, 0,01%
- Strategia: t Newey–West [Newey & West \(1987\)](#); raportul Sharpe anualizat $\sqrt{252} \bar{r}/s_r$; costul de echilibru = randamentul brut mediu în zilele cu poziții / 4 (patru tranzacții pe zi)

A1: o propoziție, două dicționare [Rezolvat]

Cerință

- Propoziție din Financial PhraseBank, etichetată **pozitivă** de toți adnotatorii:
 - ▶ "Uponor improved its performance in spite of the decrease in residential construction in the US."
- (a) Găsiți cuvintele pozitive și negative LM și GI (15 tokeni)
- (b) Calculați tonul τ și clasa pentru fiecare dicționar
- (c) De ce greșește aici dicționarul general?

Rezolvare

- LM: pozitive *improved*; negative –
 - ▶ $\tau_{LM} = (1 - 0)/(1 + 0) = +1,00$: pozitiv, corect
- GI: pozitive –; negative *spite*, *decrease*
 - ▶ $\tau_{GI} = (0 - 2)/(0 + 2) = -1,00$: negativ, greșit
- GI ratează *improved* și numără *spite* și *decrease*: ele descriu piața construcțiilor, nu firma
- Un sac de cuvinte nu poate vedea că „in spite of” inversează rolul a ceea ce urmează

A2: o propoziție neutră [Propus]

Rezolvarea se discută la seminar

Cerință

- Propoziție din Financial PhraseBank, etichetată **neutră** de toți adnotatorii:
 - ▶ “The ECB can mainly target inflation.”
- (a) Cuvintele LM și GI, tonul și clasa
- (b) Care dicționar este de acord cu adnotatorii și de ce?
- (c) Este *inflation* o veste proastă pentru o bancă? Dar pentru un deținător de obligațiuni?
- Model: A1

A3: metrice din matricea de confuzie [Rezolvat]

Cerință

- FinBERT pe setul de validare Twitter:

Adevărat \ prezis	neg	neu	pos	Total
neg	264	71	12	347
neu	213	1 184	169	1 566
pos	58	133	284	475
Total	535	1 388	465	2 388

- (a) Acuratețea
- (b) Precizia, recall-ul și F1 pentru fiecare clasă
- (c) F1 macro; care clasă este cea mai slabă și de ce?

Rezolvare

- Acuratețea = $(264 + 1\,184 + 284) / 2\,388 = 72,5\%$
- Negativ: prec $264 / 535 = 49,3\%$, rec $264 / 347 = 76,1\%$, F1 $59,9\%$
- Neutru: prec $85,3\%$, rec $75,6\%$, F1 $80,2\%$
- Pozitiv: prec $284 / 465 = 61,1\%$, rec $59,8\%$, F1 $60,4\%$
- F1 macro = $(59,9 + 80,2 + 60,4) / 3 = 66,8\%$, sub acuratețe
- Clasa negativă are cea mai mică precizie: 213 titluri neutre sunt numite negative; o strategie de vânzare în lipsă ar tranzacționa pe ele

A4: clasificatorul Loughran–McDonald [Propus]

Rezolvarea se discută la seminar

Cerință

- Dicționarul LM pe aceleași titluri:

Adevărat \ prezis	neg	neu	pos	Total
neg	172	166	9	347
neu	247	1 192	127	1 566
pos	45	349	81	475
Total	464	1 707	217	2 388

- (a) Acuratețea, precizia, recall-ul și F1 pe clase, F1 macro
- (b) Ce clasă ratează cel mai mult LM și de ce?
- Model: A3

A5: de la probabilitățile etichetelor la un scor [Rezolvat]

Cerință

- Qwen2.5-7B, promptul P1, un titlu Twitter etichetat **neutru** de adnotatori
 - ▶ $p_{\text{neg}} = 0,608$, $p_{\text{neu}} = 0,392$, $p_{\text{pos}} = 0,000$ (rotunjit)
- (a) Eticheta prezisă și scorul net s ; este eticheta corectă?
- (b) Diferența de logit $z_{\text{neu}} - z_{\text{neg}}$
- (c) Probabilitățile, eticheta și scorul la temperatura $T = 2$

Rezolvare

- Eticheta $\arg \max_k p_k = \text{negativ}$: greșit;
 $s = 0,000 - 0,608 = -0,608$
- $z_{\text{neu}} - z_{\text{neg}} = \ln(p_{\text{neu}}/p_{\text{neg}}) = \ln(0,392/0,608) = -0,437$
- La T : $p_k(T) \propto p_k^{1/T}$, aici $\sqrt{p_k}$: 0,780, 0,626, 0; suma 1,406
 - ▶ $p(T) = (0,554, 0,446, 0,000)$, $s(T) = -0,554$
- Temperatura este monotonă: eticheta nu se schimbă, dar scorul se apropie de 0; pragurile pe s selectează atunci alte titluri

A6: reperul clasei majoritare [Propus]

Rezolvarea se discută la seminar

Cerință

- Setul de validare Twitter: 1 566 titluri neutre, 475 pozitive, 347 negative ($N = 2\,388$)
- Un „clasificator” răspunde mereu *neutru*
- (a) Acuratețea lui
- (b) Precizia, recall-ul și F1 pentru fiecare clasă; F1 macro
- (c) Ce etalon ați raporta pentru clasificatorul LM din A4 și de ce?
- Model: A3

A7: costul de echilibru al unui semnal zilnic [Rezolvat]

Cerință

- Strategia FinBERT din Cursul 15: la închiderea zilei $d + 1$, cumpărăm acțiunile cu scor pozitiv și vindem pe cele cu scor negativ al știrilor din ziua d , fiecare acoperită cu SPY; închidem o zi mai târziu
- Zile cu poziții: 96,2%; randamentul brut în exces mediu în acele zile: 3,40 bp
- (a) Tranzacții pe zi cu poziții; costul de echilibru pe tranzacție
- (b) Randamentul net mediu pe zi cu poziții, la 5 bp pe tranzacție
- (c) De câte ori ar trebui să fie mai mare câștigul brut?

Rezolvare

- Patru tranzacții: acțiunea și SPY, la intrare și la ieșire; echilibru $c^* = 3,40/4 = 0,85$ bp
- Net: $3,40 - 4 \cdot 5 = -16,60$ bp pe zi cu poziții
- La 5 bp câștigul brut trebuie să ajungă la 20 bp pe zi: de $20/3,40 = 5,9$ ori mai mult
- Rulajul zilnic este dușmanul: costurile se plătesc în fiecare zi, câștigul este de câțiva puncte de bază

A8: deținere pe cinci zile [Propus]

Rezolvarea se discută la seminar

Cerință

- Același câștig ca în A7, 3,40 bp pe zi, dar fiecare poziție este ținută 5 zile: un ciclu complet (patru tranzacții) la fiecare 5 zile
- (a) Costul pe zi la 5 bp pe tranzacție; costul de echilibru pe tranzacție
- (b) Este realist să presupunem același câștig zilnic în zilele $d + 2$ până la $d + 6$?
- Model: A7

B1: este FinBERT mai bun decât LM? [Rezolvat]

Cerință

- ▣ Setul de validare Twitter, 2 388 de titluri; etichetele dicționarului LM și ale FinBERT
- ▣ (a) Acuratețea fiecăruia, cu CI bootstrap 95%
- ▣ (b) Diferența FinBERT – LM, cu CI bootstrap pe perechi (aceleași texte reeșantionate pentru ambele)
- ▣ (c) Testul McNemar exact [McNemar \(1947\)](#)
- ▣ Cod: `b_pairs` în notebook

Interpretare

- ▣ De ce este testul pe perechi mai puternic decât compararea celor două intervale?
- ▣ Ce texte nu aduc nicio informație în testul McNemar?
- ▣ Este utilă pentru tranzacționare o diferență de această mărime?

B1: rezultate [Rezolvat]

	Acuratețe (%)	CI 95%
LM	60,5	[58,5; 62,4]
FinBERT	72,5	[70,7; 74,4]
Diferența (pp)	+12,0	[+9,8; +14,2]

- n_{01} (LM greșește, FinBERT are dreptate) = 539, $n_{10} = 252$; sub H_0 ne așteptăm la 395,5 fiecare; p exact $< 0,001$
- Varianta asimptotică $(n_{01} - n_{10})^2 / (n_{01} + n_{10}) = 104,1$ vs χ_1^2 dă același verdict
- Textele pe care ambele au dreptate sau ambele greșesc se anulează; perechile elimină variația dificultății textelor
- O victorie clară, în afara datelor de antrenare ale FinBERT; pp: puncte procentuale

B2: este un LLM de 7 miliarde de parametri mai bun decât FinBERT? [Propus]

Rezolvarea se discută la seminar

Cerință

- ▣ Aceleași date; FinBERT față de Qwen2.5-7B, zero-shot, promptul P1 (niciunul nu folosește etichete Twitter)
- ▣ (a) Acuratețile cu CI, diferența pe perechi cu CI
- ▣ (b) Testul McNemar exact
- ▣ Model: B1

Interpretare

- ▣ Se suprapun cele două intervale? Tranșează asta întrebarea?
- ▣ Qwen2.5-7B are mult mai mulți parametri și este mult mai lent: ce ați câștiga totuși de la el?

B3: scurgerea datelor de antrenare [Rezolvat]

Cerință

- FinBERT a fost ajustat pe Financial PhraseBank Araci (2019)
- (a) Acuratețea și F1 macro pentru FinBERT, Qwen2.5-7B, LM și MiniLM + regresie logistică pe
 - ▶ PhraseBank, acord deplin (2 264); tot PhraseBank (4 846); Twitter (2 388)
- (b) Scăderea de la PhraseBank la Twitter pentru fiecare model
- MiniLM Wang et al. (2020): vectori de propoziții; regresia lui logistică este antrenată pe setul de antrenare Twitter

Interpretare

- Titlurile Twitter sunt mai grele pentru toți: cum separați „date mai grele” de „memoria setului de antrenare”?
- De ce modelul MiniLM se mișcă în sens invers?

B3: rezultate [Rezolvat]

Acuratețe (%)	PhraseBank, acord 100%	PhraseBank, tot	Twitter	Scădere (pp)	F1 macro, Twitter
FinBERT	97,2	89,0	72,5	16,4	66,8
Qwen2.5-7B	93,6	81,4	74,2	7,2	72,6
LM	65,0	62,5	60,5	2,0	46,2
MiniLM + reg. log.	81,4	70,6	78,6	-8,0	69,9

- Scăderea: tot PhraseBank minus Twitter; CI FinBERT pe PhraseBank [88,1; 89,8], pe Twitter [70,7; 74,4]
- Diferența diferențelor: FinBERT pierde cu 9,2 pp mai mult decât Qwen2.5-7B, care nu a văzut etichetele PhraseBank: o măsură a scurgerii
- MiniLM este antrenat pe Twitter: mai bun acasă, mai slab pe PhraseBank; fiecare model este cel mai bun pe domeniul lui de antrenare

B4: de câte etichete aveți nevoie? [Propus]

Rezolvarea se discută la seminar

Cerință

- Regresie logistică pe vectorii MiniLM și pe trăsături TF-IDF (frecvența termenului înmulțită cu inversul frecvenței în documente: numărul de cuvinte și perechi de cuvinte)
- Antrenată pe subseturi aleatoare ale setului de antrenare Twitter ($n = 100$ până la 9 543), câte 10 repetiții; evaluată pe setul de validare
- (a) Cel mai mic n la care fiecare îl depășește pe FinBERT (72,5%)
- Model: B3

Interpretare

- De ce vectorii pornesc mai sus, dar cresc mai încet?
- Câte texte ați eticheta pentru o piață nouă, de exemplu știri despre acțiuni românești?

B5: reacție sau predicție și ce erori standard? [Rezolvat]


Cerință

- Panel de 18 282 de zile-acțiune cu știri (3 434 de zile de tranzacționare, 16 acțiuni); scorul zilnic = media scorurilor titlurilor
- (a) Regresați r_{d+h}^e pe z_d pentru FinBERT, Qwen2.5-7B și LM, $h = 0, 1, 2$
- (b) Erori standard: OLS, grupate pe zile, grupate pe acțiuni [Petersen \(2009\)](#)
- FNSPID dă doar data: ziua d este prima zi de tranzacționare de la acea dată încolo, iar $d + 2$ este primul randament sigur de după publicare

Interpretare

- De ce diferă concluziile pentru $h = 0$ și $h = 2$?
- Ce grupare contează aici și puteți avea încredere într-o SE grupată cu 16 grupuri?

B5: rezultate (1/2) [Rezolvat]



- Panta b (bp de randament în exces pentru o abatere standard a scorului) la $h = 0$, cu intervale de 95% din cele trei erori standard

B5: rezultate (2/2) [Rezolvat]

Scor	h	b (bp)	SE OLS	SE zi	SE acțiune	t zi	t acțiune
FinBERT	0	+39,2	2,3	2,3	6,9	+17,27	+5,71
FinBERT	2	-0,5	2,2	2,2	1,5	-0,25	-0,35
Qwen2.5-7B	0	+41,4	2,3	2,2	8,1	+19,07	+5,10
Qwen2.5-7B	2	+2,3	2,2	1,9	1,0	+1,19	+2,41
LM	0	+15,5	2,3	1,8	3,3	+8,53	+4,70
LM	2	-0,0	2,2	1,7	0,9	-0,01	-0,03

- $h = 0$: mare și semnificativ cu orice SE: titlurile descriu mișcarea zilei, adesea chiar mișcarea („shares jump”)
- $h = 2$: FinBERT -0,5 bp ($t = -0,25$): prognoza tranzacționabilă lipsește
- Pe zile $\approx$ OLS (doar 5,3 acțiuni pe zi); pe acțiuni SE a FinBERT la $h = 0$ este de 3,0 ori mai mare: panta diferă între acțiuni
 - Cu 16 grupuri SE grupată este ea însăși zgomotoasă: folosiți valori critice t_{15} sau un wild cluster bootstrap [Cameron, Gelbach & Miller \(2008\)](#); Qwen la $h = 2$ ($t = +2,41$ pe acțiuni) este una din 9 încercări

B6: studiu de eveniment cu tonul Loughran–McDonald [Propus]

Rezolvarea se discută la seminar

Cerință

- Împărțiți zilele cu știri în terțile după tonul zilnic LM; repetați cu FinBERT
- Pentru treimea cea mai negativă și cea mai pozitivă, mediați pe zilele-acțiune ale fiecărei date randamentele în exces din zilele -5 până la $+5$
- (a) CAR (randamentul anormal cumulat) înainte de știre (-5 până la -1), ziua 0, ziua 1, după ($+2$ până la $+5$), cu t Newey–West
- Model: B5

Interpretare

- Separă tonul LM câștigătorii de perdanți în ziua 0 la fel de bine ca FinBERT?
- De ce este randamentul de după eveniment pozitiv pentru ambele grupuri? Tetlock (2007)

B7: își amintește modelul piața? [Rezolvat]


Cerință

- Prompt fără context: „Did the S&P 500 index rise or fall during ⟨lună an⟩?”; scorul $P(\text{rise})$ din probabilitățile cuvintelor-răspuns
- Qwen2.5 1.5B, 7B, 14B; ponderi publicate pe 19 septembrie 2024 [Qwen Team \(2024\)](#)
- (a) AUC pentru direcția fiecărei luni, înainte (până în august 2024) și după (din octombrie 2024) publicare, cu CI bootstrap
- (b) Valoarea p prin permutare pentru 14B înainte de publicare (2000 de amestecări ale etichetelor creștere/scădere)

Interpretare

- Ce înseamnă un AUC peste 0,5 înainte de publicare, dacă modelul nu vede date?
- Poate eșantionul de după publicare dovedi că memoria a dispărut?
- Ce implică asta pentru testele retroactive care notează știri vechi cu un LLM? [Glasserman & Lin \(2023\)](#)

B7: rezultate [Rezolvat]



Qwen2.5	AUC înainte	CI 95%	AUC după	CI 95%	$\bar{P}(\text{rise})$ creștere / scădere
1.5B	0,57	[0,51; 0,64]	0,72	[0,49; 0,91]	0,36 / 0,30
7B	0,67	[0,61; 0,73]	0,53	[0,28; 0,78]	0,73 / 0,43
14B	0,69	[0,62; 0,75]	0,59	[0,35; 0,84]	0,81 / 0,54

- Înainte: 296 luni (185 în creștere, 111 în scădere); după: 23 luni; p prin permutare (14B) $< 0,001$
- 7B și 14B „știu” direcția lunară din trecut: nu au primit date, deci semnalul este memoria textului de antrenare
- După publicare intervalele includ 0,5, dar 23 luni sunt prea puține pentru a dovedi că memoria a dispărut

B8: sensibilitatea la prompt [Propus]

Rezolvarea se discută la seminar

Cerință

- Trei prompturi care pun aceeași întrebare, Qwen2.5-7B și 14B, setul de validare Twitter
 - ▶ P1: „classify the sentiment . . . for investors”; P2: „good, bad or neutral for the stock price”; P3: „what is the sentiment of this text”
- (a) Acuratețea cu CI și ponderea răspunsurilor *neutral* pentru fiecare prompt
- (b) McNemar P1 vs P3; ponderea titlurilor cu aceeași etichetă sub toate cele trei prompturi
- Model: B1

Interpretare

- Dacă ați alege cel mai bun prompt pe acest set, ce ați face de fapt?
- De ce cel mai bun prompt răspunde și cel mai des *neutral*?

C1: aduce sentimentul titlurilor câștig după costuri?

- Strategia din Cursul 15: la închiderea zilei $d + 1$ luăm poziția $\text{sign}(s_{i,d})$ în fiecare acțiune cu știri în ziua d , acoperită cu SPY, ponderi egale; închidem la $d + 2$
 - ▶ Zilele fără știri: nicio poziție, randament 0; costuri: 5 bp pe tranzacție, patru tranzacții pe zi
- (a) Randamentul brut zilnic mediu, t Newey–West, CI bootstrap pe blocuri 95% (blocuri de 10 zile)
- (b) Raportul Sharpe înainte și după costuri; costul de echilibru; Sharpe pentru costuri de la 0 la 10 bp
- (c) Doar știri puternice: tranzacționăm doar dacă $|s_{i,d}| > 0,5$; (d) la fel pentru Qwen2.5-7B și LM
- Discutați: alinierea în timp, informația din viitor a LLM-ului (B7), supraviețuirea celor 16 acțiuni, aglomerarea strategiei Lopez-Lira & Tang (2026)
- Livrabil: o notă de două pagini cu grafice și un folder Quantlet (cod, Metainfo, grafice)

C2: critica unui răspuns AI (1/3) [Propus]

Rezolvarea se discută la seminar

- **Cererea studentului:** „Am titlurile FNSPID pentru 16 acțiuni americane, 2009–2023, și randamentele zilnice în exces față de SPY. Verifică dacă Qwen2.5-7B citește sentimentul, apoi testează dacă sentimentul titlurilor prognozează randamentele în afara eșantionului.”
- **Răspunsul asistentului AI** (qwen_label, qwen_score: evaluatorul zero-shot din Cursul 15)

```
import pandas as pd, statsmodels.formula.api as smf
from sklearn.metrics import accuracy_score
tw['pred'] = [qwen_label(t) for t in tw['text']] # Twitter validation set
acc = accuracy_score(tw['label'], tw['pred'])
news['day'] = first_trading_day_on_or_after(news['date'])
news['s'] = [qwen_score(t) for t in news['title']] # P(pos) - P(neg)
d = news.groupby(['ticker', 'day'])['s'].mean().reset_index()
d['z'] = (d['s'] - d['s'].mean()) / d['s'].std()
d = d.merge(rets, on=['ticker', 'day']) # rets: ticker, day, xret (%)
fit = smf.ols('xret ~ z', data=d).fit(cov_type='cluster',
                                     cov_kwds={'groups': pd.factorize(d['day'])[0]})
```

C2: critica unui răspuns AI (2/3) [Propus]

Rezolvarea se discută la seminar

□ Concluzia asistentului AI

- ▶ „Acuratețe 74,2%, de peste două ori cei 33% ai unei ghiciri la întâmplare între trei clase: Qwen2.5-7B citește foarte bine sentimentul financiar.”
 - ▶ „Panta +41,4 bp pentru o abatere standard a scorului, $t = +19,07$ (grupat pe zile): titlurile zilei prognozează randamentul în exces al acțiunii.”
 - ▶ „Qwen2.5 nu a fost antrenat pe aceste etichete sau serii de randamente, deci testul retroactiv 2009–2023 este complet în afara eșantionului.”
- Răspunsul conține **trei** erori tipice pentru testarea retroactivă a sentimentului; codul rulează, iar cifrele sunt corecte
- ▶ Găsiți fiecare eroare: ce rând sau ce propoziție și de ce este greșită
 - ▶ Spuneți cum ați detecta-o fără să știți răspunsul: o numărare a claselor, o verificare a orelor, o dată de publicare, un test de memorie
 - ▶ Dați codul sau afirmația corectă
 - ▶ Notați fiecare eroare ca în [AI_ERRORS.md](#): ce a răspuns AI-ul, ce era greșit, cum v-ați dat seama, varianta corectă

Greșeli frecvente

- ▣ Raportarea acurateței fără reperul clasei majoritare și fără F1 macro
- ▣ Evaluarea unui model pe propriile date de antrenare (FinBERT pe PhraseBank)
- ▣ Compararea a doi clasificatori prin intervale separate în loc de un test pe perechi
- ▣ Potrivirea unui titlu fără oră cu randamentul din aceeași zi și numirea lui prognoză
- ▣ Testarea retroactivă a unui LLM pe știri mai vechi decât publicarea ponderilor lui
- ▣ Alegerea promptului, a pragului sau a modelului după vederea rezultatelor de test
- ▣ Ignorarea costurilor și a numărului de grupuri: patru tranzacții pe zi, doar 16 acțiuni

Temă pentru acasă (proiect de echipă)

- ▣ Alegeți o sursă de texte nediscutată la seminar: anunțurile BVB (Bursa de Valori București), știri financiare românești, comunicatele băncilor centrale sau postări despre crypto-active
- ▣ Etichetați voi cel puțin 200 de texte (doi adnotatori, raportați acordul)
- ▣ Comparați LM, FinBERT, un LLM deschis și vectori + regresie logistică: acuratețe și F1 macro cu CI, teste McNemar
- ▣ Construiți un semnal cu aliniere corectă în timp; raportați separat perioada de după publicarea LLM-ului
- ▣ Declarați folosirea AI în [AI_USE.md](#) și notați fiecare eroare AI prinsă în [AI_ERRORS.md](#) (cel puțin trei pe proiect, ca în C2)
- ▣ Livrați un folder Quantlet (cod, Metainfo, grafice) și trei slide-uri: cifre, interpretare, limite

Studiu suplimentar pe Quantinar

Cursuri avansate pe quantinar.com

- ☐  Natural Language Processing
- ☐  The Next Word Problem
- ☐  DELTA
- ☐  LDA Extensions

Cod și date

- ☐ Notebook-ul seminarului (Colab); Quantlets: github.com/danpele/MFM/tree/main/Quantlets/Ch_15

Bibliografie (1/2)

- ▣ Araci, D. (2019). *FinBERT: financial sentiment analysis with pre-trained language models*. arXiv:1908.10063.
- ▣ Cameron, A.C., Gelbach, J.B., Miller, D.L. (2008). *Bootstrap-based improvements for inference with clustered errors*. *Review of Economics and Statistics*, 90(3), 414–427.
- ▣ Dong, Z., Fan, X., Peng, Z. (2024). *FNSPID: a comprehensive financial news dataset in time series*. *Proceedings of the 30th ACM SIGKDD Conference*, 4918–4927.
- ▣ Franke, J., Härdle, W.K., Hafner, C.M. (2019). *Statistics of Financial Markets: An Introduction*, 5th ed. Springer.
- ▣ Glasserman, P., Lin, C. (2023). *Assessing look-ahead bias in stock return predictions generated by GPT sentiment analysis*. arXiv:2309.17322.
- ▣ Lopez-Lira, A., Tang, Y. (2026). *Can ChatGPT forecast stock price movements? Return predictability and large language models*. *Journal of Financial Economics*, 184, 104335.
- ▣ Loughran, T., McDonald, B. (2011). *When is a liability not a liability? Textual analysis, dictionaries, and 10-Ks*. *Journal of Finance*, 66(1), 35–65.
- ▣ Malo, P., Sinha, A., Korhonen, P., Wallenius, J., Takala, P. (2014). *Good debt or bad debt: detecting semantic orientations in economic texts*. *Journal of the Association for Information Science and Technology*, 65(4), 782–796.

Bibliografie (2/2)

- McNemar, Q. (1947). Note on the sampling error of the difference between correlated proportions or percentages. *Psychometrika*, 12(2), 153–157.
- Newey, W.K., West, K.D. (1987). A simple, positive semi-definite, heteroskedasticity and autocorrelation consistent covariance matrix. *Econometrica*, 55(3), 703–708.
- Petersen, M.A. (2009). Estimating standard errors in finance panel data sets: comparing approaches. *Review of Financial Studies*, 22(1), 435–480.
- Qwen Team (2024). Qwen2.5 technical report. arXiv:2412.15115.
- Sarkar, S.K., Vafa, K. (2024). Lookahead bias in pretrained language models. SSRN Working Paper 4754678.
- Tetlock, P.C. (2007). Giving content to investor sentiment: the role of media in the stock market. *Journal of Finance*, 62(3), 1139–1168.
- Wang, W., Wei, F., Dong, L., Bao, H., Yang, N., Zhou, M. (2020). MiniLM: deep self-attention distillation for task-agnostic compression of pre-trained Transformers. *NeurIPS*; arXiv:2002.10957.