



## Modelarea piețelor financiare

Seminarul 20: Semnătura traiectoriilor și volatilitatea realizată — aplicații



Daniel Traian PELE

Drd. Antoaneta Amza, [antoaneta.amza@csie.ase.ro](mailto:antoaneta.amza@csie.ase.ro)

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

## Acronime folosite în acest material (1/2)

- **AI:** Artificial Intelligence — *inteligență artificială*
- **AR:** AutoRegressive (model); in event studies: Abnormal Return — *model autoregresiv; în studiile de eveniment: randament anormal*
- **AUDUSD:** Australian dollar / US dollar exchange rate (FX pair code) — *cursul dolar australian / dolar american (codul perechii FX)*
- **BH:** Benjamini–Hochberg (procedure) — *procedura Benjamini–Hochberg*
- **BIC:** Bayesian Information Criterion — *criteriul informațional bayesian*
- **CI:** Confidence Interval — *interval de încredere*
- **CL:** Crude oil (WTI light sweet) futures, NYMEX ticker — *contractul futures pe petrol (WTI), simbolul NYMEX*
- **COVID-19:** COronaVirus Disease 2019 — *boala provocată de coronavirus, 2019*
- **CVX:** Chevron Corporation (NYSE ticker) — *Chevron Corporation, simbolul bursier NYSE*
- **DM:** Diebold–Mariano (test) — *testul Diebold–Mariano de comparare a prognozelor*
- **ES:** E-mini S&P 500 futures (CME ticker) — *contractul futures E-mini S&P 500 (simbolul CME)*
- **EURUSD:** Euro / US dollar exchange rate (FX pair code) — *cursul euro / dolar american (codul perechii FX)*
- **FDR:** False Discovery Rate — *rata descoperirilor false*
- **FWER:** Family-Wise Error Rate — *probabilitatea de cel puțin o eroare de tip I în familia de teste*
- **FX:** Foreign eXchange — *piața valutară*
- **GBPUSD:** British pound / US dollar exchange rate (FX pair code) — *cursul liră sterlină / dolar american (codul perechii FX)*
- **GW:** Giacomini–White (test) — *testul Giacomini–White*
- **HAC:** Heteroskedasticity and Autocorrelation Consistent (standard errors) — *erori standard robuste la heteroscedasticitate și autocorelație*

## Acronime folosite în acest material (2/2)

- **HAR**: Heterogeneous AutoRegressive (model) — *model autoregresiv heterogen*
- **HARQ**: HAR model with Realised Quarticity — *model HAR cu cvarticitatea realizată*
- **JPM**: JPMorgan Chase & Co. (NYSE ticker) — *JPMorgan Chase & Co. (simbolul bursier NYSE)*
- **LASSO**: Least Absolute Shrinkage and Selection Operator — *regresie penalizată L1 cu selecția variabilelor*
- **MA**: Moving Average — *medie mobilă*
- **OLS**: Ordinary Least Squares — *metoda celor mai mici pătrate*
- **OPEC**: Organization of the Petroleum Exporting Countries — *Organizația Țărilor Exportatoare de Petrol*
- **PRDS**: Positive Regression Dependence on a Subset (of p-values) — *dependența pozitivă de regresie pe o submulțime (a p-value-urilor)*
- **QLIKE**: Quasi-LIKElihood (loss function) — *funcția de pierdere de tip cvasi-verosimilitate*
- **RQ**: Realised Quarticity — *cvarticitatea realizată*
- **RV**: Realised Variance — *varianța realizată*
- **SHAR**: Semivariance HAR model — *model HAR cu semivarianțe*
- **SHW**: Sherwin-Williams Company (NYSE ticker) — *Sherwin-Williams Company, simbolul bursier NYSE*
- **USDCAD**: US dollar / Canadian dollar exchange rate (FX pair code) — *cursul dolar american / dolar canadian (codul perechii FX)*
- **USDJPY**: US dollar / Japanese yen exchange rate (FX pair code) — *cursul dolar american / yen japonez (codul perechii FX)*
- **VOLARE**: VOLatility Archive for Realized Estimates (database) — *arhiva de estimatori realizați ai volatilității (bază de date)*

## Întrebările de azi și structura seminarului (1/3)

- ▣ Întrebările seminarului
  - ▶ **ajută forma traiectoriei recente a volatilității la prognoza varianței realizate?**
  - ▶ **cum testăm corect acest lucru?**
- ▣ B1, B2 și B3 folosesc și varianța realizată (Capitolul 9)
- ▣ Trei tipuri de exerciții
  - ▶ **A:** exerciții de calcul, pe hârtie
  - ▶ **B:** exerciții pe date reale, rezolvate în notebook
  - ▶ **C:** întrebări deschise, de exemplu corectarea unui răspuns dat de un instrument AI
- ▣ Fiecare exercițiu este marcat
  - ▶ **[Rezolvat]:** rezolvarea completă este prezentată la seminar
  - ▶ **[Propus]:** îl rezolvați dumneavoastră; soluția se discută la seminar

## Întrebările de azi și structura seminarului (2/3)

- ▣ Exercițiile de azi, în ordine
  - ▶ A1: o semnătură de adâncime 2, pas cu pas
  - ▶ A2: funcția de pierdere QLIKE, minimizantul și asimetria ei
  - ▶ A3: ponderile de nucleu și mărimea efectivă a eșantionului
  - ▶ B1: aria Lévy ca predictor al volatilității realizate (JPM)
  - ▶ B2: modelele HAR, SHAR și HARQ pentru JPM
  - ▶ B3: Sig-LK față de log-HAR pentru JPM, la o zi
  - ▶ B4: corecțiile Holm și BH, pas cu pas, pe 50 de active
  - ▶ C1: critica unui răspuns AI

## Întrebările de azi și structura seminarului (3/3)

- Rezultate de obținut
  - ▶ răspunsurile la exercițiile A
  - ▶ câte o figură și un tabel pentru B1, B2, B3 și B4
  - ▶ codul corectat din C1
  - ▶ o propoziție de interpretare pentru fiecare exercițiu
- Notebook-ul de azi: [deschideți notebook-ul seminarului în Colab](#)
  - ▶ fiecare cerință indică secțiunea din notebook
- Seminar: prof. Daniel Traian Pele, [danpele@ase.ro](mailto:danpele@ase.ro); drd. Antoaneta Amza, [antoaneta.amza@csie.ase.ro](mailto:antoaneta.amza@csie.ase.ro)

## Harta exercițiilor

| Exercițiu                          | Întrebare                                                                      | Tip                                               | Model                      |
|------------------------------------|--------------------------------------------------------------------------------|---------------------------------------------------|----------------------------|
| A1                                 | cum înregistrează semnătura ordinea mișcărilor?                                | Rezolvat                                          | –                          |
| A2                                 | ce prognoză minimizează QLIKE și ce erori sînt penalizate mai mult?            | Rezolvat                                          | –                          |
| A3                                 | cum schimbă temperatura echilibrul dintre asemănare și mărimea eșantionului?   | Rezolvat                                          | –                          |
| B1                                 | are aria Lévy putere predictivă pentru RV din luna următoare (JPM)?            | Rezolvat                                          | –                          |
| B2                                 | se confirmă efectele SHAR și HARQ pentru JPM?                                  | Rezolvat                                          | –                          |
| B3                                 | este Sig-LK superior modelului log-HAR pentru JPM, la o zi?                    | Rezolvat                                          | –                          |
| B4                                 | cîte rezultate semnificative rămîn după corecțiile Holm și BH pe 50 de active? | Rezolvat                                          | –                          |
| C1                                 | ce este greșit într-un răspuns AI?                                             | Propus                                            | A1, A2, B3                 |
| Exerciții suplimentare (opționale) | A4–A10, B5–B8, C2 (opționale, după curs)                                       | Rezolvate și propuse (indicat la fiecare cerință) | indicat la fiecare cerință |

## Harta exercițiilor: tipuri și părți

- **[Rezolvat]**: rezolvarea completă în slide-uri și în notebook, un model de urmat; **[Propus]**: îl rezolvați dumneavoastră, rezolvarea se discută la seminar
- Partea A: derivări pe hîrtie; Partea B: verificare și inferență pe datele VOLARE, fiecare cu o întrebare de interpretare; Partea C: întrebări deschise și critica unui răspuns AI

## Datele folosite

| Setul de date                                 | Active                               | Eșantion                     | Folosit în    |
|-----------------------------------------------|--------------------------------------|------------------------------|---------------|
| Măsurile realizate VOLARE, acțiuni americane  | JPM (toate cele 40 de acțiuni în C2) | 2 ian. 2015 – 30 ian. 2026   | A7, B1–B3, C2 |
| Măsurile realizate VOLARE, futures            | ES (E-mini S&P 500), CL (petrol)     | 28 sept. 2009 – 30 ian. 2026 | B5–B7         |
| Rezultatele Cursului 20 (incluse în notebook) | 50 de active                         | p-value-uri DM unilaterale   | B4, B8        |

- Variabilele din datele VOLARE [Cipollini et al. \(2026\)](#), câte o valoare pe activ și zi de tranzacționare
  - Varianța realizată din randamente la cinci minute,  $RV_t = \sum_i r_{t,i}^2$ , și părțile ei pozitivă și negativă (semivarianțele  $RV_t^+$ ,  $RV_t^-$ )
  - Cvarticitatea realizată (RQ), scala erorii de măsurare a RV; prețurile zilnice de deschidere și de închidere, pentru randamentul logaritm  $r_t$  de la deschidere la închidere
- VOLARE este gratuit pentru cercetare la [volare.unime.it](http://volare.unime.it): descărcați datele de varianță realizată (acțiuni, futures, FX) și setați calea către ele în prima celulă a notebook-ului

## Pregătire: rulați și verificați

```
# notebook section "Signatures, models and tests"
# defines load_asset(kind, symbol): columns
# rv, rsp, rsu, rq and r = ln(close/open)
a = load_asset('stocks', 'JPM')
print(len(a), a.index[0].date(), a.index[-1].date())
print(pd.DataFrame({'RVx1e4': 1e4 * a.rv,
                    'r(%)': 100 * a.r}).head(3))
```

- Rezultatul așteptat: 2 786 zile de tranzacționare, de la 2015-01-02 la 2026-01-30

| date       | RV $\times 10^4$ | r (%) |
|------------|------------------|-------|
| 2015-01-02 | 1,463            | -0,22 |
| 2015-01-05 | 1,855            | -2,56 |
| 2015-01-06 | 2,974            | -2,77 |

- O RV de  $1,46 \times 10^{-4}$  înseamnă o volatilitate zilnică de  $\sqrt{1,46 \times 10^{-4}} = 1,2\%$
- Dacă numărul de zile sau prima valoare diferă, verificați setul de date și activul

## Noțiuni necesare azi (1/18): o fereastră de date este o traiectorie

- ▣ Detalii (teoremele, specificația completă, rezultatele pe 50 de active): [Capitolul 20](#)
- ▣ Considerăm ultimele  $L$  zile din câteva serii și unim punctele prin segmente: o traiectorie

$$X : [a, b] \rightarrow \mathbb{R}^d, \quad X = \left( t, \ln RV_t, \sum_{s \leq t} r_s \right)$$

- ▶  $L$ : lungimea ferestrei în zile (22 în exerciții);  $d$ : numărul de canale (coordonate), aici  $d = 3$ ;  $[a, b]$ : intervalul de timp al ferestrei
- ▶  $RV_t$ : varianța realizată în ziua  $t$ ;  $r_s$ : randamentul logaritmic de la deschidere la închidere al zilei  $s$ , deci al treilea canal este randamentul cumulat
- ▣ **Augmentarea cu timpul**: canalul 1 este chiar timpul
  - ▶ Fără el, o mișcare rapidă și una lentă, cu aceleași valori, nu pot fi distinse
- ▣ Incrementele:  $\Delta_k = X_{t_k} - X_{t_{k-1}} \in \mathbb{R}^d$ , deplasarea tuturor canalelor pe segmentul  $k$ 
  - ▶  $\Delta_k^i$ : componenta  $i$  a lui  $\Delta_k$ ; pentru canalul de timp  $\Delta_k^1 = 1$  zi

## Noțiuni necesare azi (2/18): semnătura

- **Semnătura:** toate integralele iterate ale traiectoriei, grupate pe nivelul  $k$  [Chevyrev & Kormilitzin \(2016\)](#)

$$S^{i_1 \dots i_k} = \int_{a < u_1 < \dots < u_k < b} dX_{u_1}^{i_1} \dots dX_{u_k}^{i_k}$$

- ▶  $(i_1, \dots, i_k)$ : un cuvînt, o listă ordonată de  $k$  canale din  $\{1, \dots, d\}$ ;  $u_1 < \dots < u_k$ : momente ordonate;  $dX_u^i$ : mișcarea canalului  $i$  la momentul  $u$

- Nivelul 1: incrementele totale; nivelul 2: matricea  $d \times d$  a mișcărilor lui  $j$  ponderate cu cît s-a deplasat deja  $i$

$$S^i = X_b^i - X_a^i, \quad S^{ij} = \int_a^b (X_u^i - X_a^i) dX_u^j$$

- ▶  $S^{(1)}, S^{(2)}$ : nivelul 1 (un vector) și nivelul 2 (o matrice); un singur segment cu incrementul  $\Delta$ :  $S^{(1)} = \Delta$ ,  $S^{(2)} = \frac{1}{2} \Delta \Delta^\top$
- ▶ Adîncimea  $N$ : se păstrează nivelurile  $1, \dots, N$  (semnătura trunchiată  $\text{Sig}^N$ ); nivelul  $k$  are  $d^k$  termeni

- Motivul utilizării: cu un canal de timp, semnătura determină traiectoria [Hambly & Lyons \(2010\)](#), iar funcțiile liniare ale semnăturii trunchiate aproximează funcțiile continue de traiectorie, deci servește drept set de variabile explicative într-o regresie

## Noțiuni necesare azi (3/18): identitatea lui Chen și identitatea shuffle

- **Identitatea lui Chen** Chen (1957): semnătura a două traiectorii unite este produsul tensorial al semnăturilor lor; la nivelul 2

$$S^{(2)}(X * Y) = S^{(2)}(X) + S^{(1)}(X) S^{(1)}(Y)^\top + S^{(2)}(Y)$$

- ▶  $X * Y$ : traiectoria  $X$  urmată de traiectoria  $Y$  (unite cap la cap);  $S^{(1)}(X) S^{(1)}(Y)^\top$ : matricea  $d \times d$  a produselor, fiecare mișcare a lui  $X$  precede fiecare mișcare a lui  $Y$

- Aplicată segment cu segment unei traiectorii cu incrementele  $\Delta_1, \dots, \Delta_m$

$$S^{(2)} = \sum_{k=1}^m \frac{1}{2} \Delta_k \Delta_k^\top + \sum_{j < k} \Delta_j \Delta_k^\top$$

- ▶ Prima sumă: fiecare segment cu el însuși; a doua sumă: fiecare pereche ordonată de segmente,  $j$  înaintea lui  $k$

- **Identitatea shuffle**: un produs de termeni de nivelul 1 este o sumă de termeni de nivelul 2

$$S^i S^j = S^{ij} + S^{ji}$$

- ▶ Deci partea simetrică a nivelului 2 este  $\frac{1}{2} \Delta X^i \Delta X^j$ , cu  $\Delta X^i = S^i$  schimbarea totală a canalului  $i$ : nu aduce informație nouă



## Noțiuni necesare azi (4/18): aria Lévy

- ▣ **Aria Lévy:** partea antisimetrică a nivelului 2

$$A^{ij} = \frac{1}{2}(S^{ij} - S^{ji})$$

- ▶ Aria cu semn dintre traiectorie (proiectată pe canalele  $i, j$ ) și coarda ei, dreapta de la început la sfârșit; în sens trigonometric  $> 0$ , în sens orar  $< 0$
- ▶ Înregistrează **ordinea** mișcărilor:  $A^{ij} > 0$  când canalul  $i$  tinde să se miște înaintea canalului  $j$
- ▣ Un exemplu mic, canalele (timp,  $y$ ),  $y = (0, 1, 1)$ :  $\Delta_1 = (1, 1)$ ,  $\Delta_2 = (1, 0)$ 
  - ▶  $S^{(1)} = (2, 1)$ ;  $S^{(2)} = \frac{1}{2}\Delta_1\Delta_1^\top + \frac{1}{2}\Delta_2\Delta_2^\top + \Delta_1\Delta_2^\top = \begin{bmatrix} 2 & 0,5 \\ 1,5 & 0,5 \end{bmatrix}$ ; shuffle:  $S^1S^2 = 2 = 0,5 + 1,5$
  - ▶  $A^{12} = (0,5 - 1,5)/2 = -0,5$ :  $y$  a crescut devreme; pentru  $y = (0, 0, 1)$  (creștere târzie) aceiași pași dau  $A^{12} = +0,5$

## Noțiuni necesare azi (5/18): aria Lévy pe traiectorii simulate



— early rise:  $A^{12} = -5.49$     --- chord    ● start  
— late rise:  $A^{12} = +5.49$     —●— 22-day window:  $A^{12} = -4.44$     ■ end

- Stînga: două traiectorii de 22 de zile cu același început și același sfîrșit; regiunea hașurată este între traiectorie și coardă
  - ▶ creștere devreme:  $A^{12} = -5,49$  (sens orar); creștere târzie:  $A^{12} = +5,49$ ; nivelul 1 este identic, doar aria le deosebește
- Dreapta: canalele (randament cumulat,  $\ln RV$ ); prețul scade întâi, volatilitatea crește apoi:  $A^{12} = -4,44$ 
  - ▶ tipul de efect de ordine pe care B1 îl testează ca predictor al volatilității viitoare


## Noțiuni necesare azi (6/18): Sig-LK, variabilele explicative și ponderile nucleului

- LASSO pe semnături cu ponderi de nucleu, din [Gu et al. \(2024\)](#), aplicat la log RV pentru ziua (sau săptămîna, luna) următoare; reperul: log-HAR (slide-urile următoare)
- Variabilele explicative  $\xi_\tau$  ale zilei  $\tau$ : cei trei termeni log-HAR și semnătura pînă la adîncimea 3 a traiectoriei de 22 de zile (timp, ln RV,  $r$  cumulat) care se încheie în ziua  $\tau$ 
  - $\tau$ : o zi trecută din fereastra de antrenare;  $t$ : originea prognozei, ultima zi observată
- Ponderile nucleului: zilele trecute a căror fereastră seamănă cu cea mai recentă primesc o pondere mai mare

$$w_\tau = \frac{e^{-\gamma \delta_\tau}}{\sum_s e^{-\gamma \delta_s}}, \quad \gamma = \frac{c}{\text{mediana}(\delta)}$$

- $\delta_\tau$ : pătratul distanței euclidiene dintre semnăturile trunchiate ale ferestrei care se termină în  $\tau$  și ale ferestrei care se termină în  $t$ ;  $s$ : parcurge toate zilele de antrenare, deci ponderile însumează 1
- $\gamma \geq 0$ : temperatura;  $c > 0$ : o constantă fără unități; cu  $c = 1$ , o fereastră aflată la distanța mediană primește ponderea  $e^{-1} = 0,37$  față de una identică;  $\gamma = 0$  dă ponderi egale

## Noțiuni necesare azi (7/18): ponderile nucleului și mărimea efectivă a eșantionului



- Stînga: ponderea relativă  $e^{-\gamma \delta_\tau}$  a unei ferestre trecute aflate la distanța  $\delta_\tau$ , cu  $\gamma = c/\text{mediana}(\delta)$ 
  - la distanța mediană:  $e^{-0,5} = 0,61$ ,  $e^{-1} = 0,37$ ,  $e^{-3} = 0,05$  pentru  $c = 0,5$ ; 1; 3
- Dreapta: 1000 de distanțe simulate;  $n_{\text{eff}} = 923, 788, 376$  pentru  $c = 0,5$ ; 1; 3
  - temperatură mai mare: zile mai asemănătoare, dar mai puține observații efective (A3)

## Noțiuni necesare azi (8/18): Sig-LK, mărimea efectivă a eșantionului și LASSO în doi pași

- Costul ponderilor inegale: mai puține observații efective (Kish; A3)

$$n_{\text{eff}} = \frac{1}{\sum_{\tau} w_{\tau}^2}$$

►  $n_{\text{eff}} = n$  pentru ponderi egale  $1/n$ ;  $n_{\text{eff}} = 1$  dacă o singură zi ia toată ponderea

- Doi pași de estimare pe eșantionul de antrenare ponderat

► Pasul 1: un LASSO ponderat minimizează  $\sum_{\tau} w_{\tau} (y_{\tau} - \xi_{\tau}^{\top} \theta)^2 + \lambda \sum_j |\theta_j|$ ;  $y_{\tau}$ : ținta log RV,  $\theta$ : coeficienții; penalizarea  $\lambda \geq 0$  anulează exact unii coeficienți, adică selectează variabilele

►  $\lambda$  se alege prin BIC (Bayesian Information Criterion, criteriul informațional bayesian: potrivirea plus o penalizare pentru fiecare coeficient păstrat)


► Pasul 2: OLS ponderat reestimează doar variabilele selectate, eliminând contracția LASSO spre zero

- Specificația mobilă: ultimele 1 000 de perechi complete (variabile, țintă), reestimare la 5 zile; fiecare prognoză folosește doar datele pînă la momentul ei de origine (fără look-ahead)

## Noțiuni necesare azi (9/18): instrumentele din capitolele anterioare, exercițiu cu exercițiu

- B1, B2: HAR și log-HAR [Corsi \(2009\)](#), SHAR cu semivarianțe [Patton & Sheppard \(2015\)](#), HARQ cu cvarticitatea realizată [Bollerslev, Patton & Quaedvlieg \(2016\)](#), erori standard Newey–West (HAC): [Capitolul 9](#)
- A2, B3: QLIKE și motivul pentru care ierarhizează robust prognozele de varianță față de un proxy cu zgomot [Patton \(2011\)](#): [Capitolul 9](#)
- B3: testele Diebold–Mariano [Diebold & Mariano \(1995\)](#) și Giacomini–White condiționat [Giacomini & White \(2006\)](#): [Capitolul 8](#); bootstrap staționar pentru un interval: [Capitolul 5](#)
- B4: corecțiile Holm (FWER) și Benjamini–Hochberg (FDR) [Benjamini & Hochberg \(1995\)](#): [Capitolul 3](#)
- Singurele noțiuni noi sînt semnătura, aria Lévy și ponderile nucleului de pe slide-urile anterioare; slide-urile următoare reamintesc formulele acestor instrumente, cu exemple simulate

## Noțiuni necesare azi (10/18): varianța realizată, semivarianțele și cvarticitatea



■  $r_{t,i} > 0$ :  $RV^+ = 1.24$

■  $r_{t,i} < 0$ :  $RV^- = 1.98$

- Ziua  $t$  împărțită în  $M$  randamente intraday  $r_{t,i}$  ( $M = 78$  de intervale de cinci minute)

$$RV_t = \sum_{i=1}^M r_{t,i}^2, \quad RV_t^+ = \sum_{i=1}^M r_{t,i}^2 \mathbf{1}\{r_{t,i} > 0\}$$

- $RV_t$  estimează dispersia zilei  $t$ ;  $\sqrt{RV_t}$ : volatilitatea zilnică
- $RV_t^- = RV_t - RV_t^+$ : volatilitatea „rea”, din prețuri în scădere (SHAR)

- Cvarticitatea realizată: scala erorii de măsurare a lui  $RV_t$  (HARQ)

$$RQ_t = \frac{M}{3} \sum_{i=1}^M r_{t,i}^4$$

- mare în zilele cu câteva mișcări mari; dispersia erorii lui  $RV_t$  este aproximativ  $2 RQ_t/M$
- Graficul: o zi simulată cu un salt;  $RV = 3,22$ ,  $RV^- = 1,98 > RV^+ = 1,24$


## Noțiuni necesare azi (11/18): reamintire, familia HAR (B1, B2)

- HAR [Corsi \(2009\)](#): RV din perioada următoare este o funcție liniară de mediile zilnică, săptămînală și lunară ale RV trecute

$$RV_{t+1} = \beta_0 + \beta_d RV_t + \beta_w RV_t^{(w)} + \beta_m RV_t^{(m)} + \varepsilon_{t+1}$$

- ▶  $RV_t^{(w)}, RV_t^{(m)}$ : mediile RV pe ultimele 5 și 22 de zile;  $\beta_d, \beta_w, \beta_m$ : ponderile zilei de ieri, ale ultimei săptămîni, ale ultimei luni;  $\varepsilon_{t+1}$ : eroarea; log-HAR: același model în logaritmi
- SHAR [Patton & Sheppard \(2015\)](#): termenul zilnic descompus în semivarianțele  $RV_t^+$  (din randamentele intraday pozitive) și  $RV_t^-$  (din cele negative)
  - ▶ Coeficienții  $\beta^+, \beta^-$  în locul lui  $\beta_d$ ;  $\beta^- > \beta^+$ : volatilitatea „rea” prezice mai multă volatilitate viitoare decît cea „bună”
- HARQ [Bollerslev, Patton & Quaedvlieg \(2016\)](#): ponderea lui  $RV_t$  scade în zilele în care RV este măsurată mai puțin precis
  - ▶ Adaugă la HAR termenul  $\beta_Q RV_t(RQ_t^{1/2} - \overline{RQ^{1/2}})$ ;  $RQ_t$ : cvarticitatea realizată, scala erorii lui  $RV_t$ ; bara: media de selecție; se așteaptă  $\beta_Q < 0$
- Erorile standard Newey–West (HAC): valide cînd erorile sînt heteroscedastice și autocorelate, ca în cazul țintelor suprapuse

## Noțiuni necesare azi (12/18): mediile HAR și ponderile lor pe laguri



- Stînga: o serie RV simulată cu mediile ei săptămînală și lunară; media lunară se mișcă lent
- Dreapta: HAR este un AR(22) cu ponderi restricționate la trei trepte (A7); aici  $\beta_d = 0,4$ ,  $\beta_w = 0,35$ ,  $\beta_m = 0,15$ 
  - lagul 1: 0,477, lagurile 2–5: cîte 0,077, lagurile 6–22: cîte 0,0068; 4 parametri în loc de 23

## Noțiuni necesare azi (13/18): erorile standard Newey–West (HAC) (B1, B2, B3)

- Regresia  $y_t = x_t^\top \beta + u_t$  cu erori heteroscedastice și autocorelate; covarianța de termen lung a lui  $x_t u_t$

$$\hat{\Omega} = \hat{\Gamma}_0 + \sum_{l=1}^q \left(1 - \frac{l}{q+1}\right) (\hat{\Gamma}_l + \hat{\Gamma}_l^\top), \quad \hat{\Gamma}_l = \frac{1}{T} \sum_{t=l+1}^T \hat{u}_t \hat{u}_{t-l}^\top x_t x_{t-l}^\top$$

- ▶  $q$ : numărul de laguri (lățimea de bandă);  $1 - l/(q+1)$ : ponderile Bartlett, care păstrează  $\hat{\Omega}$  pozitiv semidefinită

- Covarianța sandviș a estimărilor OLS și statisticile  $t$


$$\widehat{\text{Var}}(\hat{\beta}) = (X^\top X)^{-1} T \hat{\Omega} (X^\top X)^{-1}, \quad t = \frac{\hat{\beta}_j}{\text{se}(\hat{\beta}_j)} \approx N(0, 1)$$

- ▶ pentru diferența a doi coeficienți (B2):  $\text{se}(\hat{\beta}^- - \hat{\beta}^+) = \sqrt{V_{--} + V_{++} - 2V_{+-}}$

- ▶ țintele suprapuse pe  $h$  zile fac din  $u_t$  un  $\text{MA}(h-1)$ : alegem  $q \geq h-1$  (22 de laguri pentru țintele lunare din B1)

- $R^2 = 1 - \sum_t \hat{u}_t^2 / \sum_t (y_t - \bar{y})^2$ : proporția din dispersia lui  $y$  explicată de regresori

## Noțiuni necesare azi (14/18): QLIKE și un proxy cu zgomot al volatilității (A2, B3)



- $QLIKE(RV, F) = RV/F - \ln(RV/F) - 1$ : zero doar pentru  $F = RV$ ; stînga: crește abrupt cînd  $F$  este prea mic
- Dreapta: proxy-ul are zgomot ( $RV = \chi^2_8/8$ , media 1); QLIKE și eroarea pătratică sînt minime la  $F = \mathbb{E}[RV] = 1,00$ , eroarea logaritmică la 0,88
  - o pierdere robustă [Patton \(2011\)](#) ordonează prognozele ca varianța adevărată; eroarea logaritmică favorizează o prognoză deplasată



## Noțiuni necesare azi (15/18): reamintire, compararea a două prognoze (B3)

- Testul Diebold–Mariano [Diebold & Mariano \(1995\)](#): este diferența medie de pierdere zero?

$$d_t = L_t^{(1)} - L_t^{(2)}, \quad \text{DM} = \frac{\bar{d}}{\sqrt{\hat{\Omega}_{\text{NW}}/T}} \approx N(0, 1) \text{ sub } H_0: \mathbb{E}[d_t] = 0$$

- ▶  $L_t^{(1)}, L_t^{(2)}$ : pierderile (de ex. QLIKE) modelelor 1 și 2 în ziua  $t$ ;  $\bar{d}$ : media lui  $d_t$  pe cele  $T$  zile de prognoză;  $\hat{\Omega}_{\text{NW}}$ : varianța de termen lung Newey–West a lui  $d_t$
- ▶  $\text{DM} < -1,645$ : modelul 1 este semnificativ mai precis la 5% (unilateral)
- Testul Giacomini–White condiționat [Giacomini & White \(2006\)](#): poate fi prezisă diferența de pierdere din informația trecută?
  - ▶ Se regresează  $d_t$  pe instrumentele  $(1, d_{t-1})$ ; statistica Wald pentru ambii coeficienți = 0 are aproximativ distribuția  $\chi^2(2)$  sub  $H_0$  ( $2 = \text{numărul de instrumente}$ )
- Bootstrap staționar: se reeșantionează blocuri de zile consecutive cu lungime aleatoare (lungimea medie a blocului fixată de utilizator), pentru a păstra dependența serială
  - ▶ Cuantilele de 2,5% și 97,5% ale statisticii replicate dau un CI (Confidence Interval, interval de încredere) de 95%

## Noțiuni necesare azi (16/18): testul Diebold–Mariano cu ținte suprapuse



— equal accuracy,  $E[d_t] = 0$

— model 1 better,  $E[d_t] = -0.15$

naive variance: rejects 39%

Newey-West (5 lags): rejects 10%

—  $N(0, 1)$

- Diferențe de pierdere  $d_t$  simulate pentru prognoze pe 5 zile: zilele vecine au în comun 4 din 5 zile, deci  $d_t$  este autocorelată
  - ▶ stînga: suma cumulată coboară sistematic doar cînd modelul 1 este într-adevăr mai bun
  - ▶ dreapta: sub  $H_0$ , varianța naivă respinge în 39% din cazuri în loc de 5%; Newey–West o aduce la 10%

## Noțiuni necesare azi (17/18): reamintire, multe teste simultan (B4)

- $m$  teste (aici unul pe activ), cu p-value-urile ordonate crescător,  $p_{(1)} \leq \dots \leq p_{(m)}$ 
  - La 5% fiecare, se așteaptă aproximativ  $0,05 m$  respingeri din întâmplare, chiar dacă niciun model nu este mai bun (2,5 din 50)

- **Holm** controlează FWER (Family-Wise Error Rate): probabilitatea a cel puțin unei respingeri false este cel mult 5%


$$\text{respingem cît timp } p_{(k)} \leq \frac{0,05}{m - k + 1}, \quad k = 1, 2, \dots; \text{ ne oprim la primul eșec}$$

- **BH Benjamini & Hochberg (1995)** controlează FDR (False Discovery Rate): proporția așteptată de respingeri false printre toate respingerile este cel mult 5%

$$k^* = \max \left\{ k : p_{(k)} \leq 0,05 \frac{k}{m} \right\}; \quad \text{respingem cele mai mici } k^* \text{ p-value-uri}$$

- Holm este valid sub orice dependență; BH cere p-value-uri independente sau pozitiv dependente; BH respinge cel puțin la fel de multe ipoteze ca Holm

## Noțiuni necesare azi (18/18): Holm și BH pe 50 de teste simulate



- 50 de teste unilaterale simulate, 5 cu un efect real
  - ▶ punctele:  $p_{(k)}$  ordonate; un punct sub o linie este respins de acea regulă
- Respingerile: necorectat 7, Holm 3, BH 4
  - ▶ cu  $m = 50$  primul prag Holm este  $0,05/50 = 0,001$ : rămân doar  $p$ -value-urile foarte mici
  - ▶ dintre cele 7 respingeri necorectate, unele sînt false: din cele 45 de ipoteze nule adevărate se așteaptă aproximativ  $0,05 \cdot 45 = 2,25$

## Notății folosite în toate exercițiile

- $RV_t$ : varianța realizată la cinci minute în ziua  $t$ ;  $r_t = \ln(\text{close}_t / \text{open}_t)$ : randamentul logaritmic de la deschidere la închidere
- Mediile HAR:  $RV_t^{(w)} = \frac{1}{5} \sum_{j=0}^4 RV_{t-j}$ ,  $RV_t^{(m)} = \frac{1}{22} \sum_{j=0}^{21} RV_{t-j}$ ; log-HAR regresează  $\ln RV_{t+1:t+h}$  pe  $\ln RV_t$ ,  $\ln RV_t^{(w)}$ ,  $\ln RV_t^{(m)}$ , cu  $RV_{t+1:t+h}$  media  $RV$  în următoarele  $h$  zile
- Traectoria  $X$  cu incrementele  $\Delta_k$ ; nivelurile semnăturii  $S^{(1)} = \sum_k \Delta_k$  și  $S^{(2)}$  (o matrice  $d \times d$ ); aria Lévy  $A^{12} = (S^{12} - S^{21})/2$
- Pierderea  $QLIKE(RV, F) = RV/F - \ln(RV/F) - 1 \geq 0$  pentru o prognoză  $F$  a  $RV$ , zero doar dacă  $F = RV$ ; diferența de pierdere  $d_t = QLIKE_t^{(1)} - QLIKE_t^{(2)}$ ; statistica DM  $\bar{d}/\sqrt{\hat{\Omega}_{NW}/T}$  (slide-urile anterioare)
- Ponderile nucleului  $w_\tau = e^{-\gamma\delta_\tau} / \sum_s e^{-\gamma\delta_s}$  pentru distanțele de semnătură  $\delta_\tau$ ; mărimea efectivă Kish  $n_{\text{eff}} = 1 / \sum_\tau w_\tau^2$
- Un exemplu:  $RV = 1$ ,  $F = 2$ :  $QLIKE = 0,5 - \ln 0,5 - 1 = 0,193$

## A1 [Rezolvat]: O semnătură de adâncime 2, pas cu pas — Cerință


- **Întrebare:** cum înregistrează o semnătură de adâncime 2 *cînd* s-a mișcat o serie, nu doar *cît*?
- **Date de intrare**
  - ▶ O serie ia valorile  $y = (0, 2, 3, 3)$  în zilele  $t = 0, 1, 2, 3$ ; fără fișier de date
  - ▶ Traectoria augmentată cu timpul  $X_t = (t, y_t)$  este liniară între zile consecutive (canalul 1 = timpul, canalul 2 =  $y$ )
- **Cerințe**
  - (a) Scrieți cele trei incremente  $\Delta_1, \Delta_2, \Delta_3 \in \mathbb{R}^2$  și calculați nivelul 1,  $S^{(1)} = \sum_k \Delta_k$ .
  - (b) Folosiți identitatea lui Chen pentru a arăta că  $S^{(2)} = \sum_k \frac{1}{2} \Delta_k \Delta_k^\top + \sum_{j < k} \Delta_j \Delta_k^\top$ , apoi calculați această matrice  $2 \times 2$ .
  - (c) Verificați rezultatul cu identitatea shuffle  $S^i S^j = S^{ij} + S^{ji}$  pentru  $i = j = 1$  și pentru  $i = 1, j = 2$ .
  - (d) Calculați aria Lévy  $A^{12} = (S^{12} - S^{21})/2$  și desenați traectoria cu coarda ei.
- **Raportați:**  $S^{(1)}$ ,  $S^{(2)}$  și  $A^{12}$
- **Interpretare:** ce spune semnul lui  $A^{12}$  despre momentul în care seria a crescut?
- **Notebook:** secțiunea [A1](#)

## A1 [Rezolvat]: Rezolvare (1/2) — Nivelurile 1 și 2

- (a) Incremente:  $\Delta_1 = (1, 2)$ ,  $\Delta_2 = (1, 1)$ ,  $\Delta_3 = (1, 0)$ ; nivelul 1:  $S^{(1)} = (3, 3)$ , schimbarea totală în timp și în  $y$
- (b) Un segment are  $\text{Sig} = (1, \Delta, \frac{1}{2}\Delta\Delta^\top, \dots)$ ; Chen înmulțește segmentele, iar nivelul 2 al produsului adună fiecare termen pătratic o dată și fiecare pereche ordonată  $j < k$  o dată
- Pătrate:  $\frac{1}{2} \begin{bmatrix} 1 & 2 \\ 2 & 4 \end{bmatrix} + \frac{1}{2} \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix} + \frac{1}{2} \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix} = \begin{bmatrix} 1,5 & 1,5 \\ 1,5 & 2,5 \end{bmatrix}$
- Perechi ordonate:  $\Delta_1\Delta_2^\top + \Delta_1\Delta_3^\top + \Delta_2\Delta_3^\top = \begin{bmatrix} 1 & 1 \\ 2 & 2 \end{bmatrix} + \begin{bmatrix} 1 & 0 \\ 2 & 0 \end{bmatrix} + \begin{bmatrix} 1 & 0 \\ 1 & 0 \end{bmatrix} = \begin{bmatrix} 3 & 1 \\ 5 & 2 \end{bmatrix}$
- Suma:  $S^{(2)} = \begin{bmatrix} 4,5 & 2,5 \\ 6,5 & 4,5 \end{bmatrix}$

## A1 [Rezolvat]: Rezolvare (2/2) — Verificarea shuffle și aria Lévy

- (c) Shuffle,  $i = j = 1$ :  $S^1 S^1 = 9 = 2S^{11} = 2 \cdot 4,5$ ;  $i = 1, j = 2$ :  $S^1 S^2 = 9 = S^{12} + S^{21} = 2,5 + 6,5$ : ambele sînt verificate
- (d) Aria Lévy:  $A^{12} = (2,5 - 6,5)/2 = -2$
- Verificare geometrică (graficul): traiectoria stă deasupra coardei  $y = t$ ; poligonul hașurat are aria 2 și este parcurs în sens orar, de aici semnul minus
- Interpretare: cu canalele (timp,  $y$ ), o arie negativă înseamnă că  $y$  a crescut *devreme* în fereastră; aceeași schimbare netă, distribuită uniform, ar da  $A^{12} = 0$



- Area between path and chord  
(2, run clockwise:  $A = -2$ )
- Path  $X = (t, y)$
- Chord from start to end

## A2 [Rezolvat]: QLIKE: minimizant și asimetrie — Cerință

### ▣ Întrebări

- ▶ ce prognoză minimizează QLIKE așteptată?
- ▶ ce erori penalizează mai mult QLIKE?

- ▣ **Date de intrare:**  $QLIKE(RV, F) = RV/F - \ln(RV/F) - 1$  cu proxy-ul realizat  $RV > 0$  și prognoza  $F > 0$ ;  $\mathbb{E}_t$  = speranța condiționată de informația de la originea prognozei

### ▣ Cerințe

- Derivați  $\mathbb{E}_t[QLIKE(RV, F)]$  în raport cu  $F$  și rezolvați condiția de ordinul întâi.
- Verificați condiția de ordinul al doilea.
- Pentru  $RV = 1$ , calculați QLIKE și eroarea pătratică pentru  $F = 0,5$  și pentru  $F = 1,5$  și reprezentați ambele pierderi în funcție de  $F$ .

- ▣ **Raportați:** minimizantul, cele patru pierderi și graficul


### ▣ Interpretare

- ▶ ce eroare penalizează mai mult QLIKE?
- ▶ de ce se potrivește aceasta managementului riscului?

- ▣ Notebook: secțiunea [A2](#)

## A2 [Rezolvat]: Rezolvare

- (a)  $\mathbb{E}_t[\text{QLIKE}] = \mathbb{E}_t[\text{RV}]/F + \ln F - \mathbb{E}_t[\ln \text{RV}] - 1$ ;  
 $\partial/\partial F = -\mathbb{E}_t[\text{RV}]/F^2 + 1/F = 0 \Rightarrow F^* = \mathbb{E}_t[\text{RV}]$
- (b)  $\partial^2/\partial F^2 = 2\mathbb{E}_t[\text{RV}]/F^3 - 1/F^2 = 1/F^{*2} > 0$  în  $F^*$ : un minim;  $F^*$  depinde doar de  $\mathbb{E}_t[\text{RV}]$ , deci cu un proxy condiționat nedeplasat ordinea pierderilor așteptate este robustă [Patton \(2011\)](#)
- (c)  $\text{QLIKE}(1; 0,5) = 2 - \ln 2 - 1 = 0,307$ ;  
 $\text{QLIKE}(1; 1,5) = 0,667 + \ln 1,5 - 1 = 0,072$ ; erori pătratice 0,25 și 0,25
- Interpretare: QLIKE penalizează subestimarea varianței de aproximativ patru ori mai mult decât aceeași supraestimare; riscul subestimat este eroarea costisitoare (capital prea mic, VaR depășit)




- QLIKE(RV = 1, F)
- - - Squared error  $(1 - F)^2$
- F = 0.5: QLIKE 0.307
- F = 1.5: QLIKE 0.072

## A3 [Rezolvat]: Ponderi de nucleu și mărimea efectivă a eșantionului — Cerință

- **Întrebare:** cum schimbă temperatura nucleului  $\gamma$  echilibrul dintre asemănare și numărul de observații?
- **Date de intrare**
  - ▶ Patru ferestre trecute cu distanțele de semnătură  $\delta = (0,2; 0,5; 1,0; 2,0)$  față de fereastra curentă
  - ▶ Ponderile lui Gu et al. (ec. 12):  $w_\tau = e^{-\gamma\delta_\tau} / \sum_s e^{-\gamma\delta_s}$ ; mărimea efectivă Kish  $n_{\text{eff}} = 1 / \sum_\tau w_\tau^2$
- **Cerințe**
  - (a) Calculați cele patru ponderi pentru  $\gamma = 1$ .
  - (b) Calculați cele patru ponderi pentru  $\gamma = 3$ .
  - (c) Calculați  $n_{\text{eff}}$  în ambele cazuri și comparați cu ponderile egale ( $\gamma = 0$ ).
- **Raportați:** doi vectori de ponderi, două valori  $n_{\text{eff}}$ , un grafic cu bare
- **Interpretare**
  - ▶ ce se câștigă când  $\gamma$  crește?
  - ▶ ce se pierde?
- Notebook: secțiunea [A3](#)

## A3 [Rezolvat]: Rezolvare

- (a)  $e^{-\delta} = (0,819; 0,607; 0,368; 0,135)$ , suma 1,929:  
 $w = (0,425; 0,315; 0,191; 0,070)$
- (b)  $e^{-3\delta} = (0,549; 0,223; 0,050; 0,002)$ , suma 0,824:  
 $w = (0,666; 0,271; 0,060; 0,003)$
- (c)  $n_{\text{eff}} = 4$  pentru  $\gamma = 0$ , 3,12 pentru  $\gamma = 1$  și 1,92 pentru  $\gamma = 3$
- Interpretare: o temperatură mai mare se concentrează pe fereastra cea mai asemănătoare (mai puțină deplasare din perioade diferite), dar înjumătățește informația (mai multă varianță); în curs  $n_{\text{eff}} \approx 816$  din 1000: pierderea de informație este mică, la fel și efectul asupra prognozei



## B1 [Rezolvat]: Aria Lévy ca predictor al volatilității (JPM) — Cerință


- ▣ **Întrebare:** are ordinea mișcărilor prețului și ale volatilității din ultima lună putere predictivă pentru volatilitatea JPM din luna următoare, dincolo de log-HAR?
- ▣ **Date de intrare**
  - ▶ VOLARE [Cipollini et al. \(2026\)](#), JPM (JPMorgan Chase), 2 ian. 2015 – 30 ian. 2026, doar zilele de tranzacționare; RV la cinci minute, prețurile zilnice de deschidere și de închidere
  - ▶ Regresorul:  $A_t$  = aria Lévy a traiectoriei de 22 de zile (randament cumulat, ln RV) care se termină în ziua  $t$ , împărțită la abaterea ei standard
  - ▶ Ținta:  $y_t = \ln RV_{t+1:t+22} - \ln RV_t^{(m)}$ , log RV din luna următoare minus cea din luna trecută (ținte consecutive au în comun 21 din 22 de zile)
- ▣ **Cerințe**
  - (a) Pentru fiecare zi, construiți traiectoria ultimelor 22 de zile, calculați semnătura ei de adâncime 2 și  $A_t = (S^{12} - S^{21})/2$ , apoi standardizați  $A_t$ .
  - (b) Regresați  $y_t$  prin OLS pe o constantă, cei trei termeni log-HAR și  $A_t$ , cu erori standard Newey–West și 22 de laguri.
  - (c) Testați  $H_0$ : coeficientul lui  $A_t = 0$  la 5%, bilateral, și comparați  $R^2$  cu și fără  $A_t$ .
  - (d) Reprezentați un grafic de dispersie pe grupe (binned scatter) al lui  $y_t$  față de  $A_t$ , ambele reziduale față de termenii log-HAR.
- ▣ **Raportați:** coeficientul, e.s. HAC,  $t$ , decizia, ambele  $R^2$ , graficul
- ▣ **Interpretare**
  - ▶ de ce 22 de laguri?
  - ▶ are câștigul importanță economică?
- ▣ Notebook: secțiunea [B1](#)

## B1 [Rezolvat]: Rezolvare (1/2) — Pași

- (a) Semnătura fiecărei ferestre de 22 de puncte cu canalele (randament, ln RV);  $A_t$  este negativă în 46% din ferestre (compatibil cu secvențele de tip levier, fără a le identifica)
- (b) 2743 zile utilizabile; coeficientul lui  $A_t = +0,042$ , e.s. HAC 0,036
- (c)  $t = +0,042/0,036 = +1,18$ ;  $|t| < 1,96$ : nu respingem  $H_0$  la 5%;  $R^2$ : 28,0% fără  $A_t$ , 28,6% cu  $A_t$
- Motivul celor 22 de laguri: țintele consecutive au în comun 21 din cele 22 de zile, deci erorile sînt dependente serial chiar sub  $H_0$ ; RV persistentă poate prelungi dependența, deci este recomandată și o verificare cu 44 de laguri

## B1 [Rezolvat]: Rezolvare (2/2) — Grafic și interpretare

- (d) Graficul: punctele grupelor sînt dispersate în jurul lui zero; banda HAC a pantei conține dreapta orizontală
- Importanța economică: o jumătate de punct de  $R^2$  față de cele 28% explicate de termenii log-HAR este neglijabilă
- Interpretare: pentru JPM, ordinea mișcărilor dintre preț și volatilitate nu aduce informație sigură despre volatilitatea lunii următoare



- JPM: mean of 20 equal-count bins
- OLS slope 0.042 (HAC s.e. 0.036)
- 95% HAC band of the slope


## B2 [Rezolvat]: HAR, SHAR și HARQ pentru JPM — Cerință

- ▣ **Întrebare:** schimbă volatilitatea „rea” (SHAR) și eroarea de măsurare a RV (HARQ) prognozele pentru ziua următoare la JPM?
- ▣ **Date de intrare**
  - ▶ VOLARE [Cipollini et al. \(2026\)](#), JPM (JPMorgan Chase), 2 ian. 2015 – 30 ian. 2026, doar zilele de tranzacționare; RV la cinci minute, semivarianțele  $RV_t^+$ ,  $RV_t^-$  și cvarticitatea realizată RQ; ținta: RV din ziua următoare, în nivel, tot eșantionul
  - ▶ SHAR [Patton & Sheppard \(2015\)](#):  $RV_{t+1} = \beta_0 + \beta^+ RV_t^+ + \beta^- RV_t^- + \beta_w RV_t^{(w)} + \beta_m RV_t^{(m)} + \varepsilon_{t+1}$ , cu  $\beta^+$ ,  $\beta^-$  ponderile semivarianței pozitive și negative
  - ▶ HARQ [Bollerslev, Patton & Quaedvlieg \(2016\)](#): HAR plus termenul  $\beta_Q RV_t (RQ_t^{1/2} - \overline{RQ^{1/2}})$  (slide-ul de reamintire despre familia HAR)
  - ▶ V: matricea de covarianță Newey–West (5 laguri) a estimărilor;  $V_{++}$ ,  $V_{--}$ : varianțele lui  $\hat{\beta}^+$ ,  $\hat{\beta}^-$ ;  $V_{+-}$ : covarianța lor
- ▣ **Cerințe**
  - (a) Estimați HAR [Corsi \(2009\)](#) prin OLS și raportați cele trei pante cu erori standard HAC.
  - (b) Estimați SHAR și testați  $H_0 : \beta^- = \beta^+$  față de  $\beta^- > \beta^+$  cu  $t = (\hat{\beta}^- - \hat{\beta}^+) / \sqrt{V_{--} + V_{++} - 2V_{+-}}$  (diferența estimată împărțită la eroarea ei standard HAC; aproximativ  $N(0, 1)$  sub  $H_0$ ).
  - (c) Estimați HARQ și testați  $H_0 : \beta_Q = 0$  față de  $\beta_Q < 0$ ; reprezentați  $\beta^+$ ,  $\beta^-$  și  $\beta_Q$  cu intervale HAC de 95%.
- ▣ **Raportați:** estimările,  $t$ ,  $p$ , deciziile, graficul coeficienților
- ▣ **Interpretare:** se confirmă cele două efecte din literatură pentru această acțiune?
- ▣ Notebook: secțiunea [B2](#)

## B2 [Rezolvat]: Rezolvare (1/3) — Estimări și teste

- (a) HAR (2 764 zile):  $\beta_d = 0,367$  (0,080),  $\beta_w = 0,494$  (0,149),  $\beta_m = -0,026$  (0,095)
- (b) SHAR:  $\beta^+ = 0,401$  (0,252),  $\beta^- = 0,324$  (0,236); diferența  $-0,078$ ,  $t = -0,17$ , unilateral  $p = 0,566$ : nu respingem  $H_0$
- (c) HARQ:  $\hat{\beta}_Q = -35,062$  (15,904),  $t = -2,20 < -1,645$ : respingem  $H_0$  la 5% unilateral

## B2 [Rezolvat]: Rezolvare (2/3) — Grafic și interpretare



## B2 [Rezolvat]: Rezolvare (3/3) — Grafic și interpretare

- Graficul: cele două intervale SHAR sînt largi și se suprapun (semivarianțele sînt puternic corelate pentru o singură acțiune); intervalul HARQ este sub zero
- Interpretare: în zilele zgomotoase HARQ reduce ponderea RV din acea zi, iar efectul se confirmă pentru JPM; asimetria dintre volatilitatea „bună” și cea „rea” este un rezultat pe panel [Patton & Sheppard \(2015\)](#), nedetectabil doar pentru JPM

 MFM\_ch20\_seminar

## B3 [Rezolvat]: Sig-LK față de log-HAR pentru JPM, la o zi — Cerință

- **Întrebare:** prognozează metoda cu semnături din curs (Sig-LK) RV din ziua următoare pentru JPM mai bine decât log-HAR?
- **Date de intrare**
  - ▶ VOLARE [Cipollini et al. \(2026\)](#), JPM (JPMorgan Chase), 2 ian. 2015 – 30 ian. 2026, doar zilele de tranzacționare; RV la cinci minute, prețurile zilnice de deschidere și de închidere
  - ▶ Specificația din [Capitolul 20](#) (slide-ul de pregătire despre Sig-LK): fereastră mobilă de 1 000 de zile, reestimare la 5 zile, traiectoria (timp, ln RV,  $r$  cumulat) pe 22 de zile, adâncimea 3, LASSO în doi pași cu BIC, temperatura nucleului  $c = 0,5$
- **Cerințe**
  - (a) Produceți prognoze la o zi Sig-LK și log-HAR de la 27 ian. 2020 la 29 ian. 2026 (1 511 zile) și calculați QLIKE medie pentru fiecare.
  - (b) Calculați raportul celor două pierderi medii și CI de 95% prin bootstrap staționar (lungimea medie a blocului 10, 1 000 de replicări).
  - (c) Rulați testul DM (variantă HAC, lățimea de bandă  $\max(h, \lceil T^{1/3} \rceil)$ ) și testul GW condiționat cu instrumentele  $(1, d_{t-1})$  [Giacomini & White \(2006\)](#).
  - (d) Reprezentați diferența cumulată de pierdere  $\sum_{s \leq t} d_s$ .
- **Raportați:** pierderile, raportul și CI,  $t$ ,  $p$ , deciziile, graficul
- **Interpretare:** există vreo dovadă că semnătura aduce valoare pentru JPM?
- Notebook: secțiunea [B3](#)

### B3 [Rezolvat]: Rezolvare (1/2) — Pierderi și teste

- (a) QLIKE medie: Sig-LK 0,1726, log-HAR 0,1727; în medie 4,2 regresori selectați, mărimea efectivă a eșantionului 851 din 1 000
- (b) Raportul 1,000; CI 95% bootstrap [0,956; 1,047] conține 1
- (c) DM:  $d_t = \text{QLIKE}_t^{\text{Sig-LK}} - \text{QLIKE}_t^{\text{log-HAR}}$ ,  $t = \bar{d} / \sqrt{\hat{\Omega}_{\text{NW}} / T} = -0,02$ , unilateral  $p = 0,493$ : nu respingem acuratețea egală
- GW: statistica Wald  $2,85 \sim \chi^2(2)$ ,  $p = 0,241$ : instrumentele  $(1, d_{t-1})$  nu dau dovezi semnificative că diferența de pierdere este previzibilă

## B3 [Rezolvat]: Rezolvare (2/2) — Diferența cumulată de pierdere

- (d) Segmente în sus: log-HAR mai bun; segmente în jos: Sig-LK mai bun; cele mai mari variații apar în martie 2020 și aprilie 2025
- Cîteva zile de stres determină semnul sumei: raportați traiectoria cumulată, nu doar media
- Interpretare: nicio dovadă; cele două prognoze sînt practic identice, iar CI exclude cîștiguri sau pierderi mai mari de aproximativ 5%



— Cumulative QLIKE(Sig-LK) - QLIKE(log-HAR), JPM,  $h = 1$

## B4 [Rezolvat]: Holm și BH, pas cu pas — Cerință


- ▣ **Întrebare:** după corecția pentru 50 de teste, pe câte active este Sig-LK superior modelului log-HAR la o zi?
- ▣ **Date de intrare**
  - ▶ P-value-urile DM pe active din Cursul 20 (incluse în notebook): p-value-uri DM unilaterale pentru „Sig-LK mai bun decât log-HAR” la  $h = 1$  (QLIKE), una pe activ; familia = cele 50 de active
  - ▶ Cele cinci perechi FX, ordonate: EURUSD 0,071, USDJPY 0,213, USDCAD 0,336, AUDUSD 0,718, GBPUSD 0,817
  - ▶  $m$ : numărul de teste; Holm (FWER 5%): comparați al  $k$ -lea cel mai mic  $p_{(k)}$  cu  $0,05/(m - k + 1)$  și opriți-vă la prima nerespingere; BH (FDR 5%) [Benjamini & Hochberg \(1995\)](#): respingeți cele mai mici  $k$  pentru cel mai mare  $k$  cu  $p_{(k)} \leq 0,05 k/m$
- ▣ **Cerințe**
  - (a) Aplicați Holm celor cinci p-value-uri FX ( $m = 5$ ).
  - (b) Aplicați BH aceluiași cinci.
  - (c) Repetați ambele proceduri pentru toate cele 50 de active, numărați respingerile și reprezentați p-value-urile ordonate față de cele trei praguri.
- ▣ **Raportați:** respingerile necorectate, Holm, BH; graficul
- ▣ **Interpretare**
  - ▶ ce putem afirma?
  - ▶ despre câte active?
- ▣ Notebook: secțiunea [B4](#)

## B4 [Rezolvat]: Rezolvare (1/2) — Pași

- (a) Holm,  $m = 5$ :  $p_{(1)} = 0,071$  față de  $0,05/5 = 0,01$ : nicio respingere, ne oprim; p-value-urile ajustate Holm: 0,354, 0,852, apoi 1
- (b) BH: pragurile 0,01; 0,02; 0,03; 0,04; 0,05; fiecare  $p_{(k)}$  este peste pragul său: nicio respingere; cea mai mică p-value ajustat BH este 0,354
- (c) 50 de active: 2 respingeri necorectate; Holm: cel mai mic, ES cu  $p = 0,002$ , este peste  $0,05/50 = 0,001$ : ne oprim, 0 respingeri; BH:  $p_{(1)} > 0,001$  și  $p_{(2)} = 0,028 > 0,002$ , niciun  $k$  nu se califică: 0

## B4 [Rezolvat]: Rezolvare (2/2) — Grafic și interpretare

- Graficul: doar punctele cele mai de jos trec sub linia de 5%; niciunul nu atinge scara Holm sau dreapta BH
- Holm este valid sub orice dependență; BH cere p-value-uri independente sau pozitiv dependente (PRDS) [Benjamini & Yekutieli \(2001\)](#)
- Interpretare: nicio îmbunătățire la nivel de activ nu rămîne semnificativă după corecție; ES este cel mult o pistă pentru un studiu nou, preînregistrat



- Sorted p-values, Sig-LK vs log-HAR,  $h = 1$
- 5% without correction
- Holm:  $0.05 / (m - k + 1)$
- BH:  $0.05 k / m$

## C1 [Propus]: critica unui răspuns AI — răspunsul

- **Cererea** trimisă unui asistent AI: „rv conține RV zilnică la 5 minute a unei acțiuni. Construiește LASSO-ul pe semnături al lui Gu et al. pentru log RV din ziua următoare și evaluează-l cu QLIKE pe ultimele 30% din eșantion.”

- **Răspunsul:** codul de mai jos și concluzia

```
lrv = np.log(rv.values)
S = np.array([sig_path(lrv[t-21:t+1, None], depth=3)          # 22-day window
              for t in range(21, len(lrv) - 1)])
y = lrv[22:]                                                  # next-day log RV
lam = LassoCV(cv=5).fit(S, y).alpha_                          # choose lambda
cut = int(0.7 * len(y))
m = Lasso(alpha=lam).fit(S[:cut], y[:cut])
f = np.exp(m.predict(S[cut:]))
qlike = lambda a, b: a / b - np.log(a / b) - 1
print(qlike(f, np.exp(y[cut:])).mean())
```

- **Concluzia AI:** „LASSO-ul pe semnături are o valoare QLIKE mai mică decât HAR pe setul de test, deci semnăturile surprind forma volatilității și îmbunătățesc prognoza.”

## C1 [Propus]: Critica unui răspuns AI — cerință

Rezolvarea se discută la seminar

- ▣ **Întrebare:** ce erori din răspuns ar schimba concluzia?
- ▣ **Model:** **A1** (augmentarea cu timpul), **A2** (QLIKE), **B3** (evaluare fără informație din viitor); codul conține **cel puțin trei** erori
- ▣ **Cerințe**
  - (a) Găsiți cel puțin trei erori; pentru fiecare, numiți rîndul și explicați într-o frază de ce este greșit.
  - (b) Pentru fiecare eroare, descrieți o verificare care o dezvăluie fără să știți răspunsul (un test unitar, un test privind momentul informației, un caz cunoscut).
  - (c) Evaluați retransformarea exponențială și dacă programul este metoda ponderată în doi pași a lui Gu et al.
  - (d) Scrieți codul corectat și comparați-l cu log-HAR pe aceeași împărțire, cu un test DM.
  - (e) Documentați fiecare eroare ca în [AI\\_ERRORS.md](#): cererea, răspunsul, eroarea, cum ați găsit-o, corecția.
- ▣ **Interpretare:** ar fi justificată concluzia chiar dacă programul ar fi corect?
- ▣ Codul AI rulează de obicei fără mesaje de eroare: greșelile sînt în metodă, nu în sintaxă

## Exercițiile suplimentare: grupe și cunoștințe necesare

| Grupa                         | Exerciții                           | Cunoștințe necesare                 |
|-------------------------------|-------------------------------------|-------------------------------------|
| 1. Algebra semnăturilor       | A4, A5 [Rezolvat], A6               | A1                                  |
| 2. HAR ca AR(22)              | A7 [Rezolvat], A8                   | B2, teste Wald                      |
| 3. Pierderi și ponderi        | A9, A10                             | A2, A3                              |
| 4. Alte active                | B5 (ES), B6 (CL), B7 (ES, $h = 5$ ) | B1, B2, B3                          |
| 5. Testare multiplă la o lună | B8                                  | B4                                  |
| 6. Idee de proiect            | C2, un nucleu sensibil la nivel     | B3, Cursul 20 (ponderile nucleului) |

- Fiecare exercițiu are secțiunea lui în notebook, cu cod de pornire (o celulă de cod goală pentru cele propuse); în cadrul unei grupe, lucrați în ordinea dată
- Exercițiile propuse își indică modelul: exercițiul rezolvat care folosește aceeași tehnică

## A4 [Propus]: Semnătura și identitatea shuffle — Cerință

Rezolvarea se discută la seminar

### ▣ Întrebări

- ▶ care este semnătura unei traiectorii cu trei segmente în plan?
- ▶ care canal s-a mișcat primul?

### ▣ Model: A1

- ▣ **Date de intrare:** O traiectorie în  $\mathbb{R}^2$  prin  $(0, 0) \rightarrow (2, 1) \rightarrow (3, -1) \rightarrow (4, 2)$ , liniară între puncte

### ▣ Cerințe

- (a) Scrieți incrementele și calculați nivelul 1.
- (b) Calculați nivelul 2 cu formula din A1 (pătrate plus perechi ordonate).
- (c) Verificați  $S^1 S^2 = S^{12} + S^{21}$  și calculați aria Lévy  $A^{12}$ .

- ▣ **Raportați:**  $S^{(1)}$ ,  $S^{(2)}$ ,  $A^{12}$ ; **Interpretare:** care canal s-a mișcat primul, în ansamblu?

- ▣ Notebook: secțiunea A4

## A5 [Rezolvat]: Identitatea lui Chen și inversarea traiectoriei — Cerință

### ▣ Întrebări

- ▶ care este semnătura unei traiectorii parcurse dus-întors?
- ▶ de ce contează acest lucru pentru augmentarea cu timpul?

### ▣ Date de intrare

- ▶ Traiectoria  $X : (0, 0) \rightarrow (1, 0) \rightarrow (1, 2)$  din curs, cu  $S^{(1)} = (1, 2)$  și  $S^{(2)} = \begin{bmatrix} 1/2 & 2 \\ 0 & 2 \end{bmatrix}$
- ▶  $\overleftarrow{X}$  este aceeași traiectorie parcursă invers:  $(1, 2) \rightarrow (1, 0) \rightarrow (0, 0)$

### ▣ Cerințe

- (a) Calculați nivelurile 1 și 2 ale  $\text{Sig}(\overleftarrow{X})$  cu formula din A1.
  - (b) Aplicați identitatea lui Chen,  $(A \otimes B)^{(2)} = A^{(2)} + A^{(1)}B^{(1)\top} + B^{(2)}$  cu  $A = \text{Sig}(X)$  și  $B = \text{Sig}(\overleftarrow{X})$ , pentru a calcula nivelul 2 al lui  $X * \overleftarrow{X}$  ( $X$  urmată de  $\overleftarrow{X}$ ).
  - (c) Explicați ce implică rezultatul pentru unicitatea semnăturii.
- ▣ **Raportați:** cele două semnături și nivelul 2 al concatenării; **Interpretare:** de ce adăugăm în practică un canal de timp?
- ▣ Notebook: secțiunea A5

## A5 [Rezolvat]: Rezolvare

- (a) Incrementele inversate  $(0, -2)$ ,  $(-1, 0)$ : nivelul 1 este  $(-1, -2) = -S^{(1)}$ ; nivelul 2: pătratele  $\begin{bmatrix} 1/2 & 0 \\ 0 & 2 \end{bmatrix}$  plus perechea  $\begin{bmatrix} 0 & 0 \\ 2 & 0 \end{bmatrix}$ , deci  $\overleftarrow{S}^{(2)} = \begin{bmatrix} 1/2 & 0 \\ 2 & 2 \end{bmatrix}$
- (b) Chen:  $\begin{bmatrix} 1/2 & 2 \\ 0 & 2 \end{bmatrix} + \begin{bmatrix} -1 & -2 \\ -2 & -4 \end{bmatrix} + \begin{bmatrix} 1/2 & 0 \\ 2 & 2 \end{bmatrix} = \begin{bmatrix} 0 & 0 \\ 0 & 0 \end{bmatrix}$ ; și nivelul 1 este  $S^{(1)} - S^{(1)} = 0$
- (c) Dusul și întorsul sînt „de tip arbore”: semnătura lor este cea a traiectoriei constante; semnătura identifică o traiectorie doar pînă la astfel de segmente [Hambly & Lyons \(2010\)](#)
- Interpretare: un canal de timp strict crescător nu se poate întoarce, deci segmentele de tip arbore sînt imposibile și semnătura determină traiectoria pînă la punctul de start: augmentăm cu timpul și furnizăm nivelul separat

## A6 [Propus]: Aria Lévy a unei bucle — Cerință

Rezolvarea se discută la seminar


- ▣ **Întrebare:** ce informație despre o buclă închisă conține nivelul 2 al semnăturii, dar nu și nivelul 1?
- ▣ **Model:** A5
- ▣ **Date de intrare:** Pătratul unitate  $(0, 0) \rightarrow (1, 0) \rightarrow (1, 1) \rightarrow (0, 1) \rightarrow (0, 0)$ , patru segmente liniare
- ▣ **Cerințe**
  - (a) Calculați nivelul 1 și aria Lévy  $A^{12}$  pentru pătratul parcurs în sens trigonometric.
  - (b) Repetați pentru pătratul parcurs în sens orar și pentru pătratul translatat cu  $(5, 5)$ .
  - (c) Explicați de ce nivelul 1 nu poate distinge bucla de o traiectorie constantă, iar nivelul 2 poate.
- ▣ **Raportați:** trei valori ale  $S^{(1)}$  și  $A^{12}$ ; **Interpretare:** ce invarianță ilustrează translația?
- ▣ Notebook: secțiunea A6

## A7 [Rezolvat]: HAR ca AR(22) restricționat — Cerință

- ▣ **Întrebare:** ce coeficienți pentru cele 22 de laguri implică un model HAR pentru  $\ln RV$  la JPM?
- ▣ **Date de intrare**
  - ▶ VOLARE [Cipollini et al. \(2026\)](#), JPM (JPMorgan Chase), 2 ian. 2015 – 30 ian. 2026, doar zilele de tranzacționare
  - ▶ HAR cu medii ale logaritmulor:  $\ell_t = \ln RV_t$ ,  $\ell_t^{(w)} = \frac{1}{5} \sum_{j=0}^4 \ell_{t-j}$ ,  $\ell_t^{(m)} = \frac{1}{22} \sum_{j=0}^{21} \ell_{t-j}$
  - ▶ Log-HAR din curs folosește logaritmi ai mediilor,  $\ln RV_t^{(w)} \neq \ell_t^{(w)}$  (Jensen), și nu are o formă AR exactă
  - ▶ Tot eșantionul (2 764 zile), OLS, e.s. Newey–West (5 laguri):  $\hat{\beta}_d = 0,408$  (0,027),  $\hat{\beta}_w = 0,299$  (0,046),  $\hat{\beta}_m = 0,196$  (0,040)
- ▣ **Cerințe**
  - (a) Înlocuiți  $\ell_t^{(w)}$  și  $\ell_t^{(m)}$  în ecuația HAR și grupați coeficientul  $\phi_j$  al fiecărui lag  $\ell_{t-j+1}$ ,  $j = 1, \dots, 22$ .
  - (b) Calculați  $\phi_1$ ,  $\phi_2 = \dots = \phi_5$  și  $\phi_6 = \dots = \phi_{22}$  din estimările JPM și reprezentați-i grafic.
  - (c) Calculați suma  $\sum_{j=1}^{22} \phi_j$ .
- ▣ **Raportați:** cele trei valori distincte, suma, graficul
- ▣ **Interpretare**
  - ▶ ce măsoară suma?
  - ▶ este procesul staționar?
- ▣ Notebook: secțiunea [A7](#)

## A7 [Rezolvat]: Rezolvare

- (a)  $\beta_w \ell_t^{(w)} = \sum_{j=1}^5 (\beta_w/5) \ell_{t-j+1}$  și  
 $\beta_m \ell_t^{(m)} = \sum_{j=1}^{22} (\beta_m/22) \ell_{t-j+1}$ : lagul 1 adună toți cei trei termeni, lagurile 2–5 pe cel săptămînal și pe cel lunar, lagurile 6–22 doar pe cel lunar
- (b)  $\phi_1 = 0,408 + 0,299/5 + 0,196/22 = 0,476$ ;  
 $\phi_{2..5} = 0,0688$ ;  $\phi_{6..22} = 0,0089$
- (c)  $\sum_j \phi_j = \beta_d + \beta_w + \beta_m = 0,903$
- Interpretare: suma este persistența log RV; toți  $\phi_j \geq 0$  și suma este sub 1, deci procesul este staționar, cu o descreștere lentă, de tip memorie lungă



- Lag 1: daily + weekly + monthly terms
- Lags 2-5: weekly + monthly terms
- Lags 6-22: monthly term only

## A8 [Propus]: Testarea restricțiilor HAR — Cerință

Rezolvarea se discută la seminar

- ▣ **Întrebare:** cum testăm restricțiile pe care HAR le impune unui AR(22) nerestricționat?
- ▣ **Model:** A7
- ▣ **Date de intrare**
  - ▶ AR(22) nerestricționat pentru  $\ell_t = \ln RV_t$  are un termen liber și pantele  $\phi_1, \dots, \phi_{22}$ ; HAR cu medii ale logaritmilor (A7) este versiunea lui restricționată
  - ▶  $\phi$  este proiecția liniară a lui  $\ell_{t+1}$  pe cele 22 de laguri; date slab dependente cu momente de ordinul patru finite; erorile pot fi heteroscedastice și autocorelate
- ▣ **Cerințe**
  - (a) Numărați restricțiile liniare și scrieți-le ca  $R\phi = 0$ .
  - (b) Scrieți statistica Wald cu o covarianță HAC și distribuția ei sub  $H_0$ .
  - (c) Precizați valoarea critică la 5%.
- ▣ **Interpretare:** dacă testul respinge într-un eșantion lung, ar trebui să renunțăm la HAR pentru prognoză?
- ▣ **Notebook:** secțiunea A8

## A9 [Propus]: QLIKE cu argumentele inversate — Cerință

Rezolvarea se discută la seminar

- ▣ **Întrebare:** ce prognoze recompensează o funcție QLIKE cu argumentele inversate?
- ▣ **Model:** A2
- ▣ **Date de intrare:** Un program calculează  $L(RV, F) = F/RV - \ln(F/RV) - 1$ , QLIKE cu argumentele inversate
- ▣ **Cerințe**
  - (a) Găsiți prognoza  $F^\dagger$  care minimizează  $\mathbb{E}_t[L(RV, F)]$ .
  - (b) Comparați  $F^\dagger$  cu  $\mathbb{E}_t[RV]$  folosind inegalitatea lui Jensen.
  - (c) Precizați ce modele favorizează pierderea inversată.
- ▣ **Interpretare:** de ce poate trece această eroare de verificările elementare?
- ▣ **Notebook:** secțiunea A9

## A10 [Propus]: Limitele temperaturii — Cerință

Rezolvarea se discută la seminar

### ▣ Întrebări

- ▶ ce se întâmplă cu ponderile nucleului la cele două temperaturi extreme?
- ▶ de ce scalăm cu distanța mediană?

### ▣ Model: A3

- ▣ **Date de intrare:**  $n$  ferestre trecute, distanțe  $\delta_\tau > 0$ , temperatura  $\gamma = c/\text{mediana}(\delta)$  ca în curs

### ▣ Cerințe

- (a) Găsiți limitele lui  $w$  și  $n_{\text{eff}}$  când  $c \rightarrow 0$ .
- (b) Găsiți limitele când  $c \rightarrow \infty$  (presupuneți că fereastra cea mai apropiată este unică).
- (c) Arătați că înmulțirea tuturor distanțelor cu  $k > 0$  lasă ponderile neschimbate.
- ▣ **Interpretare:** de ce este necesară scalarea cu mediana pentru a compara  $c$  între 50 de active?
- ▣ Notebook: secțiunea A10

## B5 [Propus]: Aria Lévy pentru futures E-mini S&P 500 — Cerință

Rezolvarea se discută la seminar

- ▣ **Întrebare:** are aria Lévy putere predictivă pentru volatilitatea din luna următoare a contractelor futures E-mini S&P 500 (ES)?
- ▣ **Model:** B1
- ▣ **Date de intrare:** Datele VOLARE pentru futures, 28 sept. 2009 – 30 ian. 2026, ES; RV la cinci minute, prețurile de deschidere și de închidere; ținta, regresorii și cele 22 de laguri Newey–West ca în B1
- ▣ **Cerințe**
  - (a) Repetați pașii (a)–(d) din B1 pentru ES.
  - (b) Testați coeficientul lui  $A_t$  la 1% și la 5%, bilateral.
  - (c) Comparați câștigul de  $R^2$  cu cel pentru JPM.
- ▣ **Interpretare**
  - ▶ ce spune un coeficient pozitiv despre ferestrele cu arie negativă?
  - ▶ poate semnul singur să le eticheteze drept episoade de levier?
- ▣ **Notebook:** secțiunea B5

## B6 [Propus]: HAR, SHAR și HARQ pentru petrol — Cerință

Rezolvarea se discută la seminar

- ▣ **Întrebare:** se confirmă asimetria SHAR și efectul HARQ pentru futures pe petrol (CL)?
- ▣ **Model:** B2
- ▣ **Date de intrare:** Datele VOLARE pentru futures, 28 sept. 2009 – 30 ian. 2026, CL; RV la cinci minute, semivarianțele și cvarticitatea realizată; modelele, testele și Newey–West (5 laguri) ca în B2
- ▣ **Cerințe**
  - (a) Estimați SHAR și testați  $\beta^- > \beta^+$  ca în B2(b).
  - (b) Estimați HARQ și testați  $\beta_Q < 0$  ca în B2(c); reprezentați coeficienții cu intervale HAC de 95%.
  - (c) Comparați ambele rezultate cu JPM.
- ▣ **Interpretare:** de ce ar putea fi asimetria mai puternică pentru o marfă decât pentru o acțiune bancară?
- ▣ **Notebook:** secțiunea B6

## B7 [Propus]: Sig-LK față de log-HAR pentru ES, la o săptămână — Cerință

Rezolvarea se discută la seminar

- ▣ **Întrebare:** este Sig-LK superior modelului log-HAR pentru ES când ținta este RV medie din următoarele cinci zile?
- ▣ **Model:** B3
- ▣ **Date de intrare:** Datele VOLARE pentru futures, 28 sept. 2009 – 30 ian. 2026, ES; specificația din B3 cu  $h = 5$  și  $c = 1,0$  (blocul de validare al contractelor futures)
- ▣ **Cerințe**
  - (a) Produceți prognoze săptămânale Sig-LK și log-HAR cu specificația din B3.
  - (b) Calculați raportul QLIKE și CI 95% prin bootstrap staționar (lungimea medie a blocului 10).
  - (c) Rulați testul DM (lățime de bandă cel puțin  $h = 5$ ) și testul GW condiționat; reprezentați diferența cumulată de pierdere.
- ▣ **Interpretare**
  - ▶ de ce este CI atât de asimetric?
  - ▶ ce implică aceasta pentru puterea testului DM?
- ▣ **Notebook:** secțiunea B7

## B8 [Propus]: Testare multiplă la o lună față de HAR — Cerință

Rezolvarea se discută la seminar

- ▣ **Întrebare:** pe câte active este Sig-LK superior modelului HAR la o lună, după corecția pentru 50 de teste?
- ▣ **Model:** B4
- ▣ **Date de intrare:** Rezultatele Cursului 20: 50 de p-value-uri DM unilaterale pentru „Sig-LK mai bun decât HAR” la  $h = 22$  (QLIKE)
- ▣ **Cerințe**
  - (a) Numărați respingerile la 5% fără corecție.
  - (b) Aplicați Holm și BH ca în B4, numărați respingerile și numiți activul cu cea mai mică p-value.
  - (c) Comparați cu raportul QLIKE mediu agregat al Sig-LK față de HAR la  $h = 22$  (1,334).
- ▣ **Interpretare:** cum poate Sig-LK să fie superior HAR pe mai multe active și totuși inferior în medie?
- ▣ **Notebook:** secțiunea B8

## C2 [Propus]: Un nucleu de semnătură sensibil la nivel — Cerință

Rezolvarea se discută la seminar

- ▣ **Întrebare:** devin ponderile utile într-un crah dacă nucleul ține cont și de *nivelul* volatilității?
- ▣ **Date de intrare**
  - ▶ Nucleul din curs este invariant la translație, deci nu poate recunoaște un regim de volatilitate ridicată (Cursul 20, ponderile din 16 martie 2020); date: VOLARE, cele 40 de acțiuni, 2015–2026
  - ▶ Ideea: adăugăm un **punct de bază** [Morrill et al. \(2020\)](#): traiectoria pornește din media de antrenare a  $\ln RV$  și sare la prima valoare a ferestrei; prin Chen,  $\text{Sig} = \exp_{\otimes}(v) \otimes \text{Sig}(X)$ , cu  $v$  saltul de nivel standardizat și  $\exp_{\otimes}(v) = (1, v, \frac{1}{2}v^{\otimes 2}, \dots)$  semnătura acestui unic segment de salt
- ▣ **Cerințe**
  - (a) Scrieți o preînregistrare de o pagină: 40 de acțiuni,  $h = 1$ , specificația din curs,  $c = 0,5$ , QLIKE, DM cu Holm, subperioada COVID-19 raportată separat.
  - (b) Implementați nucleul cu punct de bază (folosiți actualizarea Chen din notebook) cu aceleași trăsături ca Sig-LK și prognozați.
  - (c) Comparați cu Sig-LK și log-HAR: rapoartele QLIKE medii (toate zilele și COVID-19), numărul activelor cu rezultate semnificativ mai bune față de log-HAR, fără corecție și după Holm.
- ▣ **Interpretare:** dacă sensibilitatea la nivel nu ajută, unde ați căuta în continuare (trăsături, țintă, orizont)?
- ▣ Notebook: secțiunea [C2](#)

## Studiu suplimentar pe Quantinar

### Cursuri avansate pe quantinar.com

- ☐  Statistics of Financial Markets
- ☐  Applied Time Series Analysis with Python

### Cod și date

- ☐ Notebook-ul seminarului (Colab); Quantlets: [github.com/danpele/MFM/tree/main/Quantlets/Ch\\_20](https://github.com/danpele/MFM/tree/main/Quantlets/Ch_20);  
date: [volare.unime.it](https://volare.unime.it)

## Bibliografie (1/2)

- ▣ Benjamini, Y., Hochberg, Y. (1995). [Controlling the false discovery rate: a practical and powerful approach to multiple testing](#). *Journal of the Royal Statistical Society B*, 57(1), 289–300.
- ▣ Benjamini, Y., Yekutieli, D. (2001). [The control of the false discovery rate in multiple testing under dependency](#). *The Annals of Statistics*, 29(4), 1165–1188.
- ▣ Bollerslev, T., Patton, A.J., Quaedvlieg, R. (2016). [Exploiting the errors: a simple approach for improved volatility forecasting](#). *Journal of Econometrics*, 192(1), 1–18.
- ▣ Chen, K.-T. (1957). [Integration of paths, geometric invariants and a generalized Baker–Hausdorff formula](#). *Annals of Mathematics*, 65(1), 163–178.
- ▣ Chevyrev, I., Kormilitzin, A. (2016). [A primer on the signature method in machine learning](#). arXiv:1603.03788.
- ▣ Cipollini, F., Cruciani, G., Gallo, G.M., Insana, A., Otranto, E., Spagnolo, F. (2026). [VOLatility Archive for Realized Estimates \(VOLARE\)](#). arXiv:2602.19732.
- ▣ Corsi, F. (2009). [A simple approximate long-memory model of realized volatility](#). *Journal of Financial Econometrics*, 7(2), 174–196.
- ▣ Diebold, F.X., Mariano, R.S. (1995). [Comparing predictive accuracy](#). *Journal of Business & Economic Statistics*, 13(3), 253–263.

## Bibliografie (2/2)

- ▣ Franke, J., Härdle, W.K., Hafner, C.M. (2019). *Statistics of Financial Markets: An Introduction*, 5th ed. Springer.
- ▣ Giacomini, R., White, H. (2006). *Tests of conditional predictive ability*. *Econometrica*, 74(6), 1545–1578.
- ▣ Gu, H., Guo, X., Jacobs, T.L., Kaminsky, P., Li, X. (2024). *Transportation marketplace rate forecast using signature transform*. *Proceedings of the 30th ACM SIGKDD Conference on Knowledge Discovery and Data Mining*, 4997–5005.
- ▣ Hambly, B., Lyons, T. (2010). *Uniqueness for the signature of a path of bounded variation and the reduced path group*. *Annals of Mathematics*, 171(1), 109–167.
- ▣ Morrill, J., Fermanian, A., Kidger, P., Lyons, T. (2020). *A generalised signature method for multivariate time series feature extraction*. arXiv:2006.00873.
- ▣ Patton, A.J. (2011). *Volatility forecast comparison using imperfect volatility proxies*. *Journal of Econometrics*, 160(1), 246–256.
- ▣ Patton, A.J., Sheppard, K. (2015). *Good volatility, bad volatility: signed jumps and the persistence of volatility*. *Review of Economics and Statistics*, 97(3), 683–697.